

北京大学 2000 年研究生入学考试统计学试题

1、 设简单随机样本 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 满足等式

$$\sum_{i=1}^n X_i = \sum_{i=1}^n Y_i = 0, \sum_{i=1}^n X_i^2 = \sum_{i=1}^n Y_i^2 = 0$$

而且 X 和 Y 之间的样本相关系数为 r ，试写出 Y 对 X 的回归方程。（10 分）

2、 某市场研究机构从一城市居民中随机选择了 2000 户邮寄调查问卷，收回问卷 890 份，按照家庭收入分组情况如下表所示。另外通过已有资料已知该城市中各种收入范围的居民所占百分比现在该市场研究机构需要知道这些问卷是否只有代表性。请使用一种统计检验方法并给出结论。（取显著水平为 0.05）（如有必要，可以参照试卷最后所附的统计表）（15 分）

家庭收入（元）	回收问卷的家庭次数分布	该收入家庭数占城市总家庭数百分比
<500	121	12
500~1000	166	20
1000~2000	313	38
2000~5000	197	23
>=5000	93	7
总计	890	100

3、 某市场的年度销售额数据如下表所示。

年份	销售额（万元）	一次移动平均	二次移动平均
1990	8.60		
1991	10.00		
1992	14.80	11.13	
1993	13.70	12.83	
1994	16.20	14.90	12.96
1995	19.30	16.40	14.71
1996	22.80	19.43	16.91
1997	23.10	21.73	19.19
1998	25.90	23.93	21.70
1999	29.00	26.00	23.89
2000			

（注：图形被省略）

表中：同时列出了 3 年的一次、二次移动平均数。

(1)根据表中提供的资料，试求 2000 年利 2001 年该商场销售额的预测值。

(2)如果使用一次指数平滑方法，选择平滑系数等于多少将导致与上面的一次移动平均值具有相同的滞后效应。

(3)假设我们得到的原始资料是每年的各个季度的销售额，而且根据已有数据初步算得每个季度的季节指数分别为 95%，123%，110%，82%。请利用①的结果预测 2000 年各个季度的销售额。（15 分）

- 4、 设 $X_1, X_2, \dots, X_n$ 是来自在区间 $[0, \theta]$ 上面均匀分布的总体的简单随机样本 ($\theta > 0$)。试求 θ 的最大似然估量 $\hat{\theta}$ (加尖)，并判别 $\hat{\theta}$ (加尖) 是否是 θ 的无偏估计。 (10 分)
- 5、 兹有一家房地产有限公司委托某咨询公司对北京市的高档商品房需求状况进行抽样调查，试问：
- 抽样的类型及其应用的范围(简述之)。(20 分)
 - 如果采用简单随机抽样，当置信度等于 0.95 时，如按不重复抽样方法抽取的必要样本单位数是多少？ (按历史成数方差最大值计算：其允许：误差范围为 $\pm 4.9\%$) (10 分)
- 6、 某管理局所属两个工厂在某年第一、二季度的产值和工人人数资料如下(20 分)

厂名	产值(万元)		工人数(人)	
	第一季度	第二季度	第一季度	第二季度
一厂	60	88	600	800
二厂	24	12	400	200

试利用统计指数法分析全管理局劳动生产率变化的原因。

附表：常用分布的 α 上侧分位数 X_α (即 $P(X \geq X_\alpha) = \alpha$ 表。 (此表略)

2001 年硕士研究生入学考试试题

一、(45 分) 简要回答下列问题：

- 1、(5 分) 统计指标的主要特点是什么？
- 2、(10 分) 在统计中，测定标志变异性的方法有极差、平均差、标准差和标志变动系数等几种主要方法，请用计算公式表示，并分别说明它们的作用和局限性。
- 3、(10 分) 在计算价格指数时，“拉斯贝尔价格指数”和“派许价格指数”有什么不同（用计算公式表示）？各反映什么问题？你认为哪一个公式更具有现实经济意义，为什么？
- 4、(5 分) 增加值和净产值；社会总产值和国内生产总值有什么区别，请具体说明。
- 5、(5 分) 请说明经济效益的基本含义。
- 6、(10 分) 在对单个总体均值的假设 $H_0: u = u_0$ 作 t 检验时，计算机软件得到的 P 值是 0.074，

请你解释此时 P 值的含义。如果计算发现样本均值 $\bar{x} > u_0$ ，现在需要进一步判断是否有充分的理由认为总体均值是否也大于 u_0 ，你该如何去做？根据刚才的 P 值，你对“总体均值是否也大于 u_0 ”可以获得什么结论？

二、(15 分) 计算下列问题

- 1、(10 分) 某电灯泡厂对 2000 个产品进行使用寿命检验，随机抽取 2% 进行测试，如果电灯泡平均使用时间为 1057.63 小时（样本指标 $\bar{x}$ ），电灯泡合格率为 91.75%（样本成数），重复抽样电灯泡平均使用时间抽样平均误差为 2.6535 小时，重复抽样电灯泡合格率抽样平均误差为 1.376%，在 68.27% 和在 95.45% 的概率保证下，求平均数和成数的抽样极限误差。
- 2、(5 分) 在整理我国 1982 年第三次人口普查资料时采用了如下的异距分组：

不满周岁	1-3 岁	4-6 岁	7-12 岁	13-15 岁
16-17 岁	18-19 岁	20-24 岁	25-29 岁	30-40 岁
35-39 岁	40-44 岁	45-49 岁	50-54 岁	55-59 岁
60-64 岁	65-79 岁	80-99 岁	100 岁及以上	

试问：1) 为什么要采用异距数列，为的是说明什么问题？

2) 第一组的下限和最后一组的上限请分别标明。

三、(15 分) 设 $X_1, X_2, \dots, X_n$ 是独立同分布的，具有密度函数

$$f(x; u, \delta) = \frac{1}{\delta} \exp\left(-\frac{x-u}{\delta}\right), x \geq u, -\infty < u < +\infty, \delta > 0$$
 试求 u 和 δ 的最大似然估计。

四、(15 分) 一项民意测验表明，通过抽取简单随机样本调查的 840 名男子和 750 名女子中分别有 16% 和 25% 赞成立法在全国范围内禁止销售烈酒。

- 1、请你写出男女中赞成该项立法的比例之差的 95% 的置信区间；
- 2、有报道说“男子赞成这项法案的比例比女性低 15%”，你根据这项民意测验的结果能否接受该报道的说法，陈述你的理由。

五、(10 分) 对于二元线性回归模型 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$ ，假定利用样本 $(x_{i1}, x_{i2}; y_i)$

$i = 1, 2, \dots, n$ 通过最小二乘估计得到的回归方程是 $\hat{y} = b_0 + b_1 x_1 + b_2 x_2$ ，判决系数是 R^2 ，记

$\hat{y} = b_0 + b_1 x_{i1} + b_2 x_{i2}$ ， $i = 1, 2, \dots, n$ ，试证 $(y_i, \hat{y}_i)$ ， $i = 1, 2, \dots, n$ 的样本相关系数的平方是 R^2 。

2002 年硕士研究生入学考试试题

一、(18 分) 解答下面问题：

- 1、试分析标准正态分布和 t 分布在分布特征上有哪些主要区别？(4 分)；
- 2、什么是一个估计量的标准误差 (Standard Error)？大样本条件下，如何估计样本比率的 $P=x/N$ (其中 x 表示 N 次独立试验中成功的次数) 的标准误差？(5 分)；
- 3、若 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_n$ 分别是来自正态总体 $N(\mu_x, \sigma_x^2)$ 和 $N(\mu_y, \sigma_y^2)$ 的随机样本，请在 σ_x 和 σ_y 未知的时候给出 $\mu_x - \mu_y$ 的 95% 的置信区间。(5 分)；
- 4、对于线性回归模型 $Y_i = \alpha + \beta x_i + \varepsilon_i$, $\varepsilon_i \sim i.i.d$, $N(0, \sigma^2)$ $i=1,2,\dots,n$ 而言，可决定系数 R^2 和 s (s 是 σ 的估计) 之间有什么关系？(4 分)；

二、(15 分) 设 $X_1, X_2, \dots, X_n$ 是来自下面的指数分布的随机样本 $P(x; u) = e^{-(x-u)}$, $x \geq u, -\infty < u < +\infty$

1、试求 u 的极大似然估计 $\hat{u}$ ；(8 分)

2、 $\hat{u}$ 是否是 u 的无偏估计；(7 分)

三、(15 分) 某公司用户服务中心对每天晚上 8:00—10:00 两个小时内用户打来电话的次数进行了统计调查，发现 50 天独立观测得到的打来电话的平均次数是 2.42 次

1、如果已知在该时段打进电话的次数服从泊松 (poisson) 分布，试在显著水平 $\alpha = 0.05$ 的情况下检验“该时段打进电话的平均次数 $u=2$ ”的假设。(8 分)

2、如果不知道该时段打进电话的次数的分布，利用这 50 个独立观测组成的样本如何检验“打进电话次数服从均值是 2 的 poisson 分布”的假设？说明你解决该问题的思路即可。(7 分)

四、(12 分) 对经过 n 次独立观测得到的样本 (Y_i, X_i) $i=1,2,\dots,n$ 拟合如下的回归方程：

$$Y_i = \beta \cdot X_i + \varepsilon_i, \quad \varepsilon_i \sim i.i.d \quad N(0, \sigma^2) \quad \text{假定 } X_i \quad i=1,2,\dots,n \text{ 是确定性的变量 (非随机变量)}。$$

1、试求出 β 的最小二乘估计 $\hat{\beta}$ ；(8 分)

2、给出 σ^2 的估计。(4 分)

五、(25 分) 目前，有的作者用某地区报告期的居民年平均收入来测算该地区购买某种商品的承受力。你觉得这样做会出现哪些问题？应如何才能正确地分析和反映居民地购买承受力。试举例简要说明。

六、(15 分) 某医院欲估计一名医生花在每个病人身上地平均时间。假如要求置信度为 95%，允许的误差范围在 ± 2 分钟。且以以前的经验看病时间的标准差为 6 分钟，试问需要多大的样本？

2003 年硕士研究生入学考试试题

1、(25 分) 按照要求回答下面各个问题：

- 1) (10 分) 在统计调查方案的制定过程中应考虑哪些问题(按序排列)。简述之，并举一例加以说明。
- 2) (10 分) 有哪些现象宜采用不等距分组，试各举一例。
- 3) (5 分) 如果机构厂有四个流水作业的车间。2002 年某月份，第一车间制品合格率为 98% 厂第二车间制品合格率为 95%，第三车间制品合格率为 96%，第四车间制品合格率为 94%，求车间平均产品的合格率。

2、(15 分) 已知某厂下列资料

	一月	二月	三月	四月
月初工人数(人)	2000	2200	2200	2200
增加值(万元)	220	252	292	326

试分别计算各月人均产值，第一季度平均每月人均产值及第一季度人均产值。

- 3、(15 分) MPS 核算中的社会总产值和 SNA 核算中的国内生产总值和国民生产总值有区别(含定义和计算公式)？就国内生产总值的核算着眼点和核算目的来看，有什么缺陷。
- 4、(15 分) 写出“拉斯贝尔价格指数”，“派许价格指数”和“费希尔价格理想指数”的计算公式，它们各说明了什么问题，请分别阐述它们各自的弊病。

5、(12 分) 设 $X_1, X_2, \dots, X_n$ 是来自正态分布 $N(\mu, 1)$ 的一个简单随机样本， $\bar{X}$ 是样本均值， S^2 是样本方差，请你说出下面四个随机变量各服从什么分布，只写出答案即可。

$$1) \sum_{i=1}^n (X_i - \mu)^2 \quad 2) \sum_{i=1}^n (X_i - \bar{X})^2 \quad 3) \frac{\sqrt{n}}{S} (\bar{S} - \mu) \quad 4) \frac{S^2}{n(\bar{X} - \mu)^2}$$

6、(8 分) 设 $X_i, i=1,2,\dots$ 是来自随机变量 X 的一组简单随机样本，且 $E(X) = \mu$ ，令

$$\bar{X}(k) = \frac{1}{k} \sum_{i=1}^k X_i, \text{ 如果在 } \bar{X}(n+1) \text{ 和 } \bar{X}(n) \text{ 之间选择一个做为 } \mu \text{ 的估计，你更愿意使用哪一个？}$$

说明你的理由以及分析过程。

7、(15 分) 某超市欲考察顾客在他们这里的一次消费金额情况，他们在以往的销售记录中随机抽取了 100 次消费的数据。通过描述得到该样本的平均值是 29.44 元，标准差是 20 元，

- 1) (8 分) 请你写出顾客一次消费平均金额的 95% 置信区间？解释该区间的含义？
 - 2) (7 分) 利用该初步调查结果，为了使得上述区间长度不超过 4 元，你觉得应该怎么做？
- 8、(15 分) 设 $X_1, X_2, \dots, X_n$ 是来自密度函数具有如下形式的一个简单随机样本($a > 0$)，

$$f(x; a) = \begin{cases} \frac{1}{a} x^{\frac{1}{a}-1} & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$$

1) (7 分) 求 a 的最大似然估计 $\hat{a}$ ；

2) (8 分) 试求 $n \rightarrow +\infty$ 时 $\hat{a}$ 的抽样分布。

9、(15 分) 一只袋子中装有红、白两种颜色的球，为了检验假设：

H_0 ：袋子中红球、白球的个数相等。

甲同学有放回地在袋子中随机抽取了 $2n$ 个球，并且他只有在 $2n$ 个球中红白两色各为 n 个时

才承认上述假设，否则他一概否定上述假设。

1) (8 分) 试就 $n=5$ 的情况求他所犯第一类错误的概率；

2) (7 分) 考虑时 $n \rightarrow +\infty$ 他所犯第一类错误的概率。

10. (15 分) 针对如下的回归方程

$$y_t = ax_t + e_t, \quad t = 1, 2, 3, \dots, n$$

其中的 $x_t, t = 1, 2, 3, \dots, n$ 是确定性的变量 $E(e_t) = 0$

1) (8 分) 试求 a 的最小二乘估计 $\hat{a}$ ；

2) (7 分) 证明 $\hat{a}$ 是 a 的无偏估计。

启用前机密

北京大学 2004 年硕士研究生入学考试试题

光华人
向上的精神

考试科目：统计学

考试时间：1 月 11 日下午

www.gsmer.net

招生专业：统计学

(答案一律写在答题纸上, 否则不计分)

一、简要回答以下问题(每小题 5 分, 共计 30 分)

- (1) 增加值和净产值的区别与联系
- (2) 据统计我国恩格尔系数有下降的趋势, 这说明什么问题?在运用恩格尔系数研究问题时, 它应用的前提条件是什么?
- (3) 什么是时点数?什么是时期数?一个时点数和另一个有联系的时期数能否直接对比?为什么?
- (4) 在编制组距数列时, 应考虑哪些问题?
- (5) 经济增长和经济发展有何区别?各说明什么问题?
- (6) 平均消费倾向和平均储蓄倾向的测算方法是什么?它们各反映什么问题?

二、(20 分)某公司新推出一种营养型豆奶, 为做好促销工作, 随机地选取顾客作为样本, 并问他们是否喜欢此种豆奶。如果要使置信度为 95%, 抽样误差不超过 0.05, 则在下列两种情况下, 你建议样本的容量各为多大?

- (1) 假设初步估计, 约有 60% 的顾客喜欢此种豆奶。
- (2) 假设没有任何资料可用来估计大约有多少比率的顾客会喜欢此种豆奶。

三、(20 分)请你编制三个组距变量数列, 研究的问题和数据由你自己假设。

- (1) 根据离散变量编制一个统计表。(6 分)
- (2) 根据连续变量编制两个统计表, 其中一个是采用理论界限, 另一个是采用实际界限。如果是按照理论界限编制, 试计算出每组的组距。(14 分)

四、(15 分)设总体 X 服从正态分布 $N(\mu, 0.3^2)$, $X_1, X_2, \dots, X_n$ 是总体 X 的一组样本, $\bar{X}$ 是样本均值, 试问, 样本容量 n 至少应取多大, 才能使 $P\{|\bar{X} - \mu| < 0.1\} \geq 0.95$?

五、(15 分) $X_1, X_2, \dots, X_n$ 是独立同分布的 $\text{Poisson}(\lambda)$ 变量

- (1) 试求 λ 的矩估计 $\hat{\lambda}$;
- (2) 试求 $\hat{\lambda}$ 的方差;
- (3) 试在大样本的情形下构造关于 λ 的 95% 的置信区间。

六、(10 分)假设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 是两组独立同方差的正态的随机变量。他们的期望分别为 μ_X 和 μ_Y 。请在 0.05 的水平下检验如下假设:

$$H_0: 2\mu_X = 3\mu_Y \quad H_1: 2\mu_X \neq 3\mu_Y$$

七、(10 分)考虑如下线性模型: $y_i = \alpha x_i^2 + x_i \varepsilon_i, i = 1, \dots, n$, 其中 $x_i > 0$ 而且 ε_i 是独立同分布的 $N(0, \sigma^2)$ 。请构造一个关于 α 的合理估计, 并讨论其抽样分布。

八、(10 分)Scott 公司进行了一项市场份额的研究。在过去的一年里, 公司 A 的市场份额稳定在 30%, 公司 B 在 50%, 公司 C 在 20%。最近公司 C 开发了一种“新型”产品并取代了当前市场的产品。Scott 受雇于公司 C, 为它判断新产品是否使市场份额发生了改变。Scott 公司通过问卷调查了一组 200 名的顾客群体, 询问他们对公司 A、B、C 的购买偏好, 结果 48 人选择 A, 98 人选择了 B, 54 人选择了 C。根据这些数据, 请你判断市场份额是否已经发生了变化并说明你判断的理由($\alpha = 0.05$)。

九、(20 分)设总体的分布为 $N(0, \theta), 0 < \theta < \infty$ 。 $X_1, X_2, \dots, X_n$ 是来自此总体的简单随机样本。

(1) 试求 θ 的最大似然估计 $\hat{\theta}$

(2) 讨论 $\hat{\theta}$ 的无偏性;

(3) 试求 $\hat{\theta}$ 的方差;

(4) 试求时 $n \rightarrow \infty$ 时 $\hat{\theta}$ 的抽样分布。

光华人
向上的精神
www.gsmer.net

考试中可能用到的分位数:

$$z_{0.025} = 1.96$$

$$z_{0.05} = 1.645$$

$$\chi_{0.05}^2(2) = 5.991$$

$$\chi_{0.05}^2(3) = 7.815$$

其中 z_{α} 为标准正态分布的 α 水平上侧分位数, $\chi_{\alpha}^2(k)$ 为自由度为 k 的 χ^2 分布的 α 水平上侧分位数。

一、 判断题：

一共 6 个小题，考查基本概念。中间大部分原题已经忘掉了，但是大部分题目都不偏，官方提供的参考书上都有，只记得一道当时不是很清楚结论的题目，是关于 p 检验的。关于 p 检验官方提供的参考书中不涉及，可以参考稍微深一点的教科书。简单说来，一般的假设检验过程是确定置信度 $1-\alpha$ ，从而划定否定域，再根据统计量是否处于否定域中判断零假设是否成立；而 p 检验则是反其道行之，先计算出统计量的值，再根据相应分布计算统计量偏离这个计算值的概率，根据此概率与 α 的相对大小判断原假设是否成立。

陈述：置信度 $1-\alpha$ 越大，检验的 p 值越大。

注意讨论各种统计分布下的单边检验和双边检验，不同情况下上述陈述不一定是对的。

二、 一道比较基础的假设检验的题目，具体数值记不住了。好像测的是轮胎的里程，认为轮胎里程遵从正态分布，且其期望里程大于 u 时认为轮胎合格。对一批轮胎进行抽样，得到 N 个样本值，计算后知道样本均值和方差分别为 a 和 S 。问在 95% 置信度下判定这批轮胎是否合格。卷面上给出了 U 检验和 $(N-1)$ 自由度下 T 检验的临界值。

应当选用 T 检验， $T = \frac{a-u}{\frac{S}{\sqrt{N}}}$ 。考场中不允许用计算器，不过 T 统计量很好

算， $\sqrt{N}$ 一眼就开出来了。

三、 比率分布的估计，题目中数字不保证准确。一个总体，抽取了其中的 900 个进行统计，其中具有特征 X 的样本个数为 810。问在 95% 置信度下具有特征 X 的样本的比率的位于何区间中？再问若将比率估计的不确定度（上问中估计区间的长度之一半）控制在 0.01，应取多少个样本？卷面上给出了 U 检验的临界值。不允许用计算器。

900 是大样本，可以用正态分布近似：假定具有特征 X 的样本比率为 p ，则 900 个样本中具有特征 X 的样本个数满足均值 $900p$ ，方差 $900p(1-p)$ 的正态分布。因此得到 U 统计量 $U = \frac{810-900p}{\sqrt{900p(1-p)}}$ 。在 95% 置信度下 U 统计量的估计区

间为 $(-1.96, 1.96)$ 。因此解方程 $\left| \frac{810-900p}{\sqrt{900p(1-p)}} \right| < 1.96$ ，得到 p 的区间估计。具体计

算中由于不允许使用计算器，用 $0.9=810/900$ 近似代替根号下的 p ，得到 $900p(1-p)=9$ 。最终有估计 $0.88 < p < 0.92$ 。

由上问，估计的不确定度为 $1.96 \frac{\sqrt{Np(1-p)}}{N}$ ， N 为估计所取的样本数。为了

手算方便，还是将根号下 p 近似为 0.9，算得 $N > 3.5 \times 10^3$ （这里数字好像有点问题，我印象里当时自己的答案是 N 等于一千多的，应该是“控制在 0.01”这里的具体数字记错了）。

四、 随机量 X 离散分布，概率函数为

$$\begin{cases} p(X=1) = \theta^{n-1} \\ p(X=k) = (1-\theta)\theta^{k-2}, k=2, \dots, n. \end{cases} \quad 0 \leq \theta \leq 1$$

现对 X 进行抽样，得到样本 $x_1, x_2, \dots, x_m$ ，其中 $m < n$ 。依据此样本对 θ 做最大似然估计。

设 $x_1, x_2, \dots, x_m$ 中有 l 个等于 1。

当 $l = m$ 时，似然函数 $L = \theta^{(n-1)m}$ 是 θ 的增函数，显然此时 θ 的最大似然估计是 $\hat{\theta} = 1$ 。

当 $l < m$ 时，似然函数 $L = (1-\theta)^{m-l} \theta^{\Sigma + (n-2)l}$ ，其中 $\Sigma \equiv x_1 + x_2 + \dots + x_m$ 。进一步得到似然方程

$$\frac{\Sigma + (n-2)l}{\theta} - \frac{m-l}{1-\theta} = 0。$$

进而最大似然估计

$$\hat{\theta} = \frac{m-l}{m + \Sigma + (n-3)l}。$$

五、假定随机量 Y 满足 $Y = \beta x + \varepsilon$ ，其中 x 不是随计量，误差项 ε 服从均值为零方差为 σ^2 的正态分布且互不相关。现取出 n 对观测值 (x_i, y_i) ，且满足 $\sum x_i = 0$ 。

首先要求证明最小二乘法估计出的线性回归参数 $b = \frac{l_{xy}}{l_{xx}}$ 是 β 的无偏估计；其次给

出了一个统计量 $Z = \frac{1}{n} \sum \frac{y_i}{x_i}$ ，证明 Z 也是 β 的无偏估计量；最后要求比较 b 和 Z

的有效性。

第一问不证了，两本参考书里都有完整的过程。

第二问证明如下：

$$E(Z) = E\left(\frac{1}{n} \sum \frac{y_i}{x_i}\right) = \frac{1}{n} \sum \frac{E(y_i)}{x_i} = \frac{1}{n} \sum \frac{\beta x_i}{x_i} = \beta$$

第三问：

$$b = \frac{l_{xy}}{l_{xx}} = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2} \stackrel{(\bar{x}=0)}{=} \frac{\overline{xy}}{\overline{x^2}} = \frac{\sum x_i y_i}{\sum x_i^2}；$$

$$D(b) = \frac{D(\sum x_i y_i)}{(\sum x_i^2)^2} \stackrel{(\rho_{ij}=0)}{=} \frac{\sum x_i^2 D(y_i)}{(\sum x_i^2)^2} = \frac{\sum x_i^2}{(\sum x_i^2)^2} \sigma^2 = \frac{1}{\sum x_i^2} \sigma^2；$$

$$D(Z) = \frac{1}{n^2} D\left(\sum \frac{y_i}{x_i}\right) \stackrel{(\rho_{ij}=0)}{=} \frac{1}{n^2} \sum \frac{D(y_i)}{x_i^2} = \frac{1}{n^2} \sum \frac{1}{x_i^2} \sigma^2。$$

根据柯西不等式或者向量的模积不小于向量的积模，有

$$\sum x_i^2 \cdot \sum \frac{1}{x_i^2} \geq \left[\sum \left(x_i \cdot \frac{1}{x_i}\right)\right]^2 = n^2$$

因此一般情况下（等号取不到的，除非各个 x 都相等，根据题目又都等于 0）

$$D(Z) > D(b)$$

06 光华统计试题（统计部分）

一、判断：（2 分/题）

- 1、 $SSR \leq SST$
- 2、若某企业员工的平均年薪增加 20%，则他们的福利状况将有所改善。
- 3、 p 值随着显著性水平 α 增大而增大（大概这个意思吧）
- 4、有效性随着样本量 n 的增加而越有效，无偏性与 n 无关
- 5、好像是估计问题，分布未知且方差未知，一定不能服从 $N(0,1)$ （记不清具体是怎样的了）。
- 6、好像是 F 检验与 t 检验的相关问题（也记不清了）。

二、检验问题（12 分）

某企业称其生产的轮胎使用超过 25000 公里，现抽出 9 个样本，得到样本均值和标准差分别为 27000 公里和 5000 公里，问该企业的广告是否可信？（ $\alpha = 0.05$ ）

三、（12 分）好像是某一项调查，总共有 900 个样本，其中有 810 个赞成

- 1、求 p 的点估计值；
- 2、求 p 的 95% 的置信区间以及相应的极限误差；
- 3、若要将极限误差降低 20%，问需将样本提高到多少个？

四、MLE 问题（12 分）：

$$P\{X = k\} = \theta^{k-1}(1-\theta), \quad k=1, 2, \dots, r$$

$$P\{X = r+1\} = \theta^r, \quad 0 < \theta < 1$$

其中 $X_1, X_2, \dots, X_n$ 为简单随机样本，求 θ 的 MLE。

五、回归问题（12 分）：

$$y_i = \beta x_i + \mu_i,$$

$$\text{其中 } \mu_i \sim N(0, \sigma^2 x_i^2),$$

- 1、验证 β 的 LSE $\hat{\beta}$ 是否为无偏估计？并求 $\text{Var}(\hat{\beta})$ ；
- 2、 β 的另一个估计值： $\tilde{\beta} = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{x_i}$ ，问 $\tilde{\beta}$ 是否为 β 的无偏估计；
- 3、比较 $\text{Var}(\hat{\beta})$ 与 $\text{Var}(\tilde{\beta})$ 的大小。（要用到 Cauchy 不等式）。

试题大概就是这样子，很遗憾，有些记不清了，大家凑和着用吧。另外提醒一句：请不要用于商业用途！

从光华考研热线到现在的光华人，我学到了很多，虽然我备战光华失败，但仍希望为光华人尽自己的一点绵薄之力，希望对大家有所帮助吧，预祝大家 07 年取得好成绩！

一、 判断题：

一共 6 个小题，考查基本概念。中间大部分原题已经忘掉了，但是大部分题目都不偏，官方提供的参考书上都有，只记得一道当时不是很清楚结论的题目，是关于 p 检验的。关于 p 检验官方提供的参考书中不涉及，可以参考稍微深一点的教科书。简单说来，一般的假设检验过程是确定置信度 $1-\alpha$ ，从而划定否定域，再根据统计量是否处于否定域中判断零假设是否成立；而 p 检验则是反其道行之，先计算出统计量的值，再根据相应分布计算统计量偏离这个计算值的概率，根据此概率与 α 的相对大小判断原假设是否成立。

陈述：置信度 $1-\alpha$ 越大，检验的 p 值越大。

注意讨论各种统计分布下的单边检验和双边检验，不同情况下上述陈述不一定是对的。

二、 一道比较基础的假设检验的题目，具体数值记不住了。好像测的是轮胎的里程，认为轮胎里程遵从正态分布，且其期望里程大于 u 时认为轮胎合格。对一批轮胎进行抽样，得到 N 个样本值，计算后知道样本均值和方差分别为 a 和 S 。问在 95% 置信度下判定这批轮胎是否合格。卷面上给出了 U 检验和 $(N-1)$ 自由度下 T 检验的临界值。

应当选用 T 检验， $T = \frac{a-u}{\frac{S}{\sqrt{N}}}$ 。考场中不允许用计算器，不过 T 统计量很好

算， $\sqrt{N}$ 一眼就开出来了。

三、 比率分布的估计，题目中数字不保证准确。一个总体，抽取了其中的 900 个进行统计，其中具有特征 X 的样本个数为 810。问在 95% 置信度下具有特征 X 的样本的比率的位于何区间中？再问若将比率估计的不确定度（上问中估计区间的长度之一半）控制在 0.01，应取多少个样本？卷面上给出了 U 检验的临界值。不允许用计算器。

900 是大样本，可以用正态分布近似：假定具有特征 X 的样本比率为 p ，则 900 个样本中具有特征 X 的样本个数满足均值 $900p$ ，方差 $900p(1-p)$ 的正态分布。因此得到 U 统计量 $U = \frac{810-900p}{\sqrt{900p(1-p)}}$ 。在 95% 置信度下 U 统计量的估计区

间为 $(-1.96, 1.96)$ 。因此解方程 $\left| \frac{810-900p}{\sqrt{900p(1-p)}} \right| < 1.96$ ，得到 p 的区间估计。具体计

算中由于不允许使用计算器，用 $0.9=810/900$ 近似代替根号下的 p ，得到 $900p(1-p)=9$ 。最终有估计 $0.88 < p < 0.92$ 。

由上问，估计的不确定度为 $1.96 \frac{\sqrt{Np(1-p)}}{N}$ ， N 为估计所取的样本数。为了

手算方便，还是将根号下 p 近似为 0.9，算得 $N > 3.5 \times 10^3$ （这里数字好像有点问题，我印象里当时自己的答案是 N 等于一千多的，应该是“控制在 0.01”这里的具体数字记错了）。

四、 随机量 X 离散分布，概率函数为

$$\begin{cases} p(X=1) = \theta^{n-1} \\ p(X=k) = (1-\theta)\theta^{k-2}, k=2, \dots, n. \end{cases} \quad 0 \leq \theta \leq 1$$

现对 X 进行抽样，得到样本 $x_1, x_2, \dots, x_m$ ，其中 $m < n$ 。依据此样本对 θ 做最大似然估计。

设 $x_1, x_2, \dots, x_m$ 中有 l 个等于 1。

当 $l = m$ 时，似然函数 $L = \theta^{(n-1)m}$ 是 θ 的增函数，显然此时 θ 的最大似然估计是 $\hat{\theta} = 1$ 。

当 $l < m$ 时，似然函数 $L = (1-\theta)^{m-l} \theta^{\Sigma + (n-2)l}$ ，其中 $\Sigma \equiv x_1 + x_2 + \dots + x_m$ 。进一步得到似然方程

$$\frac{\Sigma + (n-2)l}{\theta} - \frac{m-l}{1-\theta} = 0。$$

进而最大似然估计

$$\hat{\theta} = \frac{m-l}{m + \Sigma + (n-3)l}。$$

五、假定随机量 Y 满足 $Y = \beta x + \varepsilon$ ，其中 x 不是随计量，误差项 ε 服从均值为零方差为 σ^2 的正态分布且互不相关。现取出 n 对观测值 (x_i, y_i) ，且满足 $\sum x_i = 0$ 。

首先要求证明最小二乘法估计出的线性回归参数 $b = \frac{l_{xy}}{l_{xx}}$ 是 β 的无偏估计；其次给

出了一个统计量 $Z = \frac{1}{n} \sum \frac{y_i}{x_i}$ ，证明 Z 也是 β 的无偏估计量；最后要求比较 b 和 Z

的有效性。

第一问不证了，两本参考书里都有完整的过程。

第二问证明如下：

$$E(Z) = E\left(\frac{1}{n} \sum \frac{y_i}{x_i}\right) = \frac{1}{n} \sum \frac{E(y_i)}{x_i} = \frac{1}{n} \sum \frac{\beta x_i}{x_i} = \beta$$

第三问：

$$b = \frac{l_{xy}}{l_{xx}} = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2} \stackrel{(\bar{x}=0)}{=} \frac{\overline{xy}}{\overline{x^2}} = \frac{\sum x_i y_i}{\sum x_i^2}；$$

$$D(b) = \frac{D(\sum x_i y_i)}{(\sum x_i^2)^2} \stackrel{(\rho_{ij}=0)}{=} \frac{\sum x_i^2 D(y_i)}{(\sum x_i^2)^2} = \frac{\sum x_i^2}{(\sum x_i^2)^2} \sigma^2 = \frac{1}{\sum x_i^2} \sigma^2；$$

$$D(Z) = \frac{1}{n^2} D\left(\sum \frac{y_i}{x_i}\right) \stackrel{(\rho_{ij}=0)}{=} \frac{1}{n^2} \sum \frac{D(y_i)}{x_i^2} = \frac{1}{n^2} \sum \frac{1}{x_i^2} \sigma^2。$$

根据柯西不等式或者向量的模积不小于向量的积模，有

$$\sum x_i^2 \cdot \sum \frac{1}{x_i^2} \geq \left[\sum \left(x_i \cdot \frac{1}{x_i}\right)\right]^2 = n^2$$

因此一般情况下（等号取不到的，除非各个 x 都相等，根据题目又都等于 0）

$$D(Z) > D(b)$$

06 光华统计试题（统计部分）

一、判断：（2 分/题）

- 1、 $SSR \leq SST$
- 2、若某企业员工的平均年薪增加 20%，则他们的福利状况将有所改善。
- 3、 p 值随着显著性水平 α 增大而增大（大概这个意思吧）
- 4、有效性随着样本量 n 的增加而越有效，无偏性与 n 无关
- 5、好像是估计问题，分布未知且方差未知，一定不能服从 $N(0,1)$ （记不清具体是怎样的了）。
- 6、好像是 F 检验与 t 检验的相关问题（也记不清了）。

二、检验问题（12 分）

某企业称其生产的轮胎使用超过 25000 公里，现抽出 9 个样本，得到样本均值和标准差分别为 27000 公里和 5000 公里，问该企业的广告是否可信？（ $\alpha = 0.05$ ）

三、（12 分）好像是某一项调查，总共有 900 个样本，其中有 810 个赞成

- 1、求 p 的点估计值；
- 2、求 p 的 95% 的置信区间以及相应的极限误差；
- 3、若要将极限误差降低 20%，问需将样本提高到多少个？

四、MLE 问题（12 分）：

$$P\{X = k\} = \theta^{k-1}(1-\theta), \quad k=1, 2, \dots, r$$

$$P\{X = r+1\} = \theta^r, \quad 0 < \theta < 1$$

其中 $X_1, X_2, \dots, X_n$ 为简单随机样本，求 θ 的 MLE。

五、回归问题（12 分）：

$$y_i = \beta x_i + \mu_i,$$

$$\text{其中 } \mu_i \sim N(0, \sigma^2 x_i^2),$$

- 1、验证 β 的 LSE $\hat{\beta}$ 是否为无偏估计？并求 $\text{Var}(\hat{\beta})$ ；
- 2、 β 的另一个估计值： $\tilde{\beta} = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{x_i}$ ，问 $\tilde{\beta}$ 是否为 β 的无偏估计；
- 3、比较 $\text{Var}(\hat{\beta})$ 与 $\text{Var}(\tilde{\beta})$ 的大小。（要用到 Cauchy 不等式）。

试题大概就是这样子，很遗憾，有些记不清了，大家凑和着用吧。另外提醒一句：请不要用于商业用途！

从光华考研热线到现在的光华人，我学到了很多，虽然我备战光华失败，但仍希望为光华人尽自己的一点绵薄之力，希望对大家有所帮助吧，预祝大家 07 年取得好成绩！

统计部分（60 分）

1.（20 分）某投资者要对比两支不同的股票记为 A 和 B，为了方便起见，该投资者决定使用方差来度量每只股票的风险，为此，他收集了每只股票 100 天的日度超额收益率，经计算发现两只股票的样本标准差分别为：5%（A）7%（B）。假设每只股票的超额收益率服从正态分布，而且相互独立。那么请问 10%的显著性水平下检验两支股票的方差是否相等。

2.(20 分)某投资经理负责管理三个不同金融投资产品，ABC，他很关心，投资者的性别是否含有影响他对着三种产品的选择，为此，他从客户总数中随机抽取了 100 个样本

	A	B	C
男	10	20	20
女	20	10	20

请在 5%的显著水平下检验投资者性别同金融产品的选择是否有关系。

3.（20 分）假设 (Y_i, X_i) 是来自第 i ($1 \leq i \leq n$) 个样本观测，其中 Y_i 是因变量，而 X_i 是一元解释性变量，假设 Y_i 和 X_i 之间服从如下线性回归模型： $Y_i = \alpha + \beta X_i + \varepsilon_i$ 其中随即干扰项 ε_i 是一个均值为 0 的方差为 σ^2 的正太随机变量，请求出关于 α 的最小二乘估计，并分析该统计量的抽样分布。

一、两支股票A的标准差为5%，B的为7%，在0.1的显著性水平下，二者的方差相同吗？

二、数据如下：

O	A	B	C
男	10	20	20
女	20	10	20

问：男、女与A、B、C的独立性。

三、一元线性回归 $y = a + bx$ ，用最小二乘法推出a的估计量，并求a的分布。

$$2. \sum_{i=1}^N \alpha_i \left(\frac{p - c_i}{p} \right) = \frac{H}{\varepsilon}. \quad (10 \text{分})$$

五、对于某一起盗窃案件有k个目击证人。每个目击证人可以选择告发盗窃犯，也可以选择不告发。由于目击证人都很忙，因此选择告发会带来一些不便，但是将罪犯绳之以法又是大家都希望看到的结果。对于每个目击证人而言，罪犯被抓获产生的效用为4；而罪犯逃脱的效用为0。目击证人告发罪犯本身会带来1的负效用。罪犯被抓获的充分必要条件是有人告发罪犯。

1. 求出所有的纯战略纳什均衡。（6分）
2. 若只有两个目击证人，求出混合战略纳什均衡。（7分）
3. 在k个目击证人的情况下，混合战略纳什均衡具有对称性，求出该均衡，并求出罪犯被抓获的概率。（7分）

第三部分 统计学（共60分）

一、（20分）随机变量 $X \sim N(\mu_1, 4)$ ，随机变量 $Y \sim N(\mu_2, 9)$ 。

1. 求 $\mu = \mu_1 - \mu_2$ 的矩统计量 $\hat{\mu}$ 。
2. 求 $\hat{\mu}$ 的方差。
3. 若由于经费所限， $n_1 + n_2 = 100$ 固定，求 n_1, n_2 ，使得 $D\hat{\mu}$ 最小。

二、（20分）一家厂商实行三种策略进行销售， X_1 ：广告策略， X_2 ：低价格策略， X_3 ：混合策略。对三种策略的销售情况进行了为期20周的观测，得到如下数据：

观测周数	样本均值	样本方差
20	20	20
20	12	13
20	10	10

$\alpha = 0.05$ ，问三种策略是否有显著差异。

1. 请写出对应的 H_0 和 H_1 。
2. 写出计算步骤，得到检验统计值。
3. 根据上述调查，得到什么结论？

三、（20分）假设回归直线过原点，即一元线性回归模型为 $Y_i = \beta X_i + \varepsilon_i, i = 1, \dots, n$ ， $\varepsilon_i \sim N(0, \delta_i^2)$ ，并且干扰项之间相互独立。

1. 给定观测值，求 β 的最小二乘估计 β_{ols} 。
2. 求 $D\beta_{ols}$ 。
3. 若 δ_i^2 已知，求 β 的广义最小二乘估计 β_{gls} 。
4. 求 $D\beta_{gls}$ 。

2012 年统计部分

1、(18 分) 过原点一元线性回归。 $y_i = \beta \cdot x_i + \varepsilon_i$, ε_i 独立, $\varepsilon_i \sim N(0, \delta^2)$, $i=1,2,\dots,n$ 。 <1> 求 β 的最小二乘估计。求该最小二乘估计的方差。(6 分) <2> 求 β 的广义最小二乘估计, 求该广义最小二乘估计的方差。(6 分) <3> 如果将该回归模型变为: $y_i = \beta \cdot x_i + \alpha \cdot z_i + \varepsilon_i$, 那么 β 的最小二乘估计有什么变化? (6 分)

2、(18 分) 厂商三种销售策略。 水平 观测量 均值 标准差
1 20 8 7 2 20 12 13 3 20 20 10
<1> 请列出 H_0 和 H_1 。(6 分) <2> 请进行分析和检验。(5+5=10 分) <3> 根据检验结果, 结论是什么? (2 分)

3、(24 分) 在计量经济学中我们可以使用回归模型来考察变量的关系。一个妇女选择工作与否的意愿可能与家庭收入、个人喜好、工作环境等等很多因素有关。我们可以使用回归模型 $y_i = \beta X_i + \varepsilon_i$, 如果该妇女选择工作则 $X_i = 1$, 否则 $X_i = 0$ 。 <1> 如果我们用上面那个模型来分析这个问题, 会遇到哪些问题? (6 分) <2> 收集数据过程中, 数据往往都有一个概率分布函数。常见的分布函数有哪些? (6 分)

2012 年统计部分

1、（18 分）过原点一元线性回归。 $y_i = \beta * x_i + \varepsilon_i$ ， ε_i 独立， $\varepsilon_i \sim N(0, \delta * \delta)$ ， $i=1.2 \dots n$ 。

<1>求 β 的最小二乘估计。求该最小二乘估计的方差。（6 分）

<2>求 β 的广义最小二乘估计，求该广义最小二乘估计的方差。（6 分）

<3>如果将该回归模型变为： $y_i = \beta * x_i + \alpha * z_i + \varepsilon_i$ ，那么 β 的最小二乘估计有什么变化？（6 分）

2、（18 分）厂商三种销售策略。

水平	观测量	均值	标准差
1	20	7	8
2	20	13	12
3	20	10	20

<1>请列出 H_0 和 H_1 。（6 分）

<2>请进行分析和检验。（5+5=10 分）

<3>根据检验结果，结论是什么？（2 分）

3、（24 分）在计量经济学中我们可以使用回归模型来考察变量的关系。一个妇女选择工作与否的意愿可能与家庭收入、个人喜好、工作环境等等很多因素有关。我们可以使用回归模型 $y_i = \beta X_i + \varepsilon_i$ ，如果该妇女选择工作则 $X_i=1$ ，否则 $X_i=0$ 。

<1>如果我们用上面那个模型来分析这个问题，会遇到哪些问题？（6 分）

<2>收集数据过程中，数据往往都有一个概率分布函数。常见的分布函数有哪些？（6 分）

2013 年统计部分：

1 （10 分）特别简单的一道题，大概是说收集了 100 天的数据，一只股票的年化对数收益率是 $\mu=15\%$ ，标准差 $\sigma=9\%$ ，（1）计算该股票年化对数收益率 95%的置信区间（5 分）

（2）如果股票的价格是 10 元，求股票价格 95%的置信区间（5 分）

2 （15 分）两只股票 A 股和 B 股，也是收集了 100 天的价格数据，样本中 A 股的收益率是 5%，标准差也是 5%。B 股的收益率是 7.5%，标准差是 10%。显著性水平为 5%时。

（1）求 A 股的 90%的置信区间

（2）两只股票的平均收益率是否显著不同？

（3）综合上述分析，请给出你的投资建议

3 （15 分）是一个三变量（包括截距）回归模型，整个模型的每个系数及其标准差都已经给出，还给出了 $n=141$ ，和 $R^2=0.234$ 第一问问的是哪些变量对因变量 y 有显著影响，第二问是检验所有系数为零的假设

4（15 分）题目比较长而且啰嗦，真记不起来是什么了，题目扫了一眼主要看了表格就做题了，大概是说考核员工，回归变量是参加工作的时间和完成该项考核工作的时间，因变量是考评成绩。总共四问，第一问前给出了一个表格，截距、两个变量的系数都已经给出，让列一个回归方程（这可能是第三问，忘了），和写出方差分析的假设，后来给出了一个方差分析表，求方差分析 F 检验，还有一问问系数含义神马的记不清了（这问可能是跟着列方程的那一问）

5（20 分）一个包含截距的一元回归模型，好像是市场证券之类的，因变量是 R_t ，自变量是 M_t ，就问两个系数的最小二乘估计，第二问问假设变量为 M_0 ，因变量的估计是什么，第三问求 R_0 的 95%置信区间

2014 年统计学部分:

1. Poisson 分布的参数估计值的 95% 置信区间, 题目是指数型参数分布族, 0, 1, 2, 3, 4, 5 的个数分别是 102, 59, 41, 8, 0, 1 (好像是这个, 记不清了).

2. 股票在 H, A 两市场同时上市, 收益率分布***** (这个是真记不清了), 问两市场上基金的收益率是否有显著差距.

3. 方程 $C = a_0 + a_1 \text{prot} + \mu$

(1) 若 a_1 和 μ 独立, 解释 a_1 .

(2) 若 a_1 和 μ 不独立, 解释 a_1 .

(3) 给出 a_1 的 LSE, 问什么时候是无偏的.

4. 两基金, 前半部分是取中国一年市场的周数据 (每年三个周无交易), 后半部分是比前半部分更早数据的 15 个周计算得来. 具体数据记不清了. 第一问要你求出两个基金的收益率是否有显著差距, 第二问让你检验方差是否有显著差距.

5. $y = a_0 + a_1 x_1 + a_2 x_2 + a_3 x_3 + \mu$, y 的方差为 0.05, 修正 R 方为 0.6.

(1) 求 μ 方差的无偏估计.

(2) x_2 的方差为 0.08, $x_1 x_2$ 相关系数为 0.5, $x_2 x_3$ 不相关, a_2 的估计值为 0.35, 估计 a_2 的方差.

(3) 如果模型为 $y = b_0 + b_1 x_1 + b_2 x_2 + \mu'$ 那么什么时候有 $a_1 = b_1$.

3. (本大题 20 分) 索洛模型假设生产函数为 $Y = ZK^\alpha L^{1-\alpha}$, 其中 $0 < \alpha < 1$ 为常数, Y 为总产出, K 为资本投入, L 为劳动投入, Z 是全要素生产率 (TFP)。请回答如下问题

(1) 根据以上生产函数, 总产出的增长率可以如何分解为 TFP, 资本以及劳动投入的增长率? (4 分)

(2) 请推导人均产出的表达式。(4 分)

(3) 假设经济体中所有的个体的储蓄率是常数 s , 满足 $0 < s < 1$, 并且折旧率是 δ , 请给出经济进入稳态的条件。(4 分)

(4) 目前一些专家认为中国经济需要提倡多消费, 少储蓄 增粘, 这和索洛模型的预测是否一致? (4 分)

【参考答案】: (1) 对 $Y = ZK^\alpha L^{1-\alpha}$ 求全微分, 容易得到

$$\frac{Y'}{Y} = \frac{Z'}{Z} + \alpha \frac{K'}{K} + (1-\alpha) \frac{L'}{L}$$

这就得到总产出的增长率分解为 TFP, 资本以及劳动投入的增长率。

(2) $y = zk^\alpha$ 其中 y 是人均产出, k 是人均资本占有量。

(3) 进入稳态时有: $sy^* = \delta k^*$, 由此可以计算出稳态时人均资本拥有量和人均产出。

(4) 这与索洛模型预测不一致。索洛模型预测降低储蓄率, 会导致达到均衡时人均产出降低。而这与经济发展是为了增加消费是背道而驰的。所以, 单从索洛模型来看, 现在应该提倡少消费, 多储蓄。以换取以后均衡后的更高福利。

第三部分: 统计学 (本部分 3 道大题, 共 60 分)

1. (共 18 分) 假设离散的回归直线过原点, 即一元线性回归模型为:

$$y_i = \beta x_i + \varepsilon_i, \quad i=1, \dots, n,$$

$\varepsilon_i \sim (0, \sigma_i^2)$ 并且干扰项之间独立。

(1) 给定观测值, 求 β 的最小二乘估计 $\hat{\beta}_{ols}$; $\hat{\beta}_{ols}$ 的方差是多少? (6 分)

(2) 如果 σ_i^2 已知, 求 β 的广义最小二乘估计 $\hat{\beta}_{gls}$; $\hat{\beta}_{gls}$ 的方差是多少? (6 分)

(3) 假设回归方程变为 $y_i = \beta x_i + \alpha z_i + \varepsilon_i$, 即我们增加一个回归变量 z_i 那么 β 的最小二乘估计

会变成多少？（6 分）

【参考答案】：（1）给定观测值，由基本的数学知识，可以得到

$$\beta_{ols} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\text{var}(\beta_{ols}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \text{ 这里 } \sigma^2 \text{ 是 } y \text{ 观测值的样本方差。}$$

（2）给定 σ_i^2 ，此时利用 GLS 估计法有

$$\beta_{ols} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\text{var}(\beta_{ols}) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \sigma_i^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2}$$

（3）若增加一个回归变量， $y_i = \beta x_i + \alpha z_i + \varepsilon_i$ ，可以利用矩阵形式估计出 β

$$\beta_{ols} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n [(x_i - \bar{x})^2 + (z_i - \bar{z})^2]}$$

2.（共 18 分）某饮料公司对新产品的广告可以强调以下三个策略之一：便捷质量好，价格低。为了看哪一个更加能促进销售，它在三个相似的城市进行试点，得到了 20 周的销售数据如下，假定这些销售数据服从等方差的正态分布

重点	观测数	样本值	样本方差
便捷	20	8	7

质量	20	12	13
价格	20	10	10

对 $\sigma = 0.05$ ，检验三个策略的销售是否有显著差异。

- (1) 请写出 H_0 和 H_1 。(6 分)
- (2) 请写出计算步骤并得到检验统计值。(5+5=10 分)
- (3) 根据查表结果，结论是什么？(2 分)

本部分可能会用到的分位数

此列下标看不清	$\alpha = 0.01$	$\alpha = 0.025$	$\alpha = 0.05$	$\alpha = 0.10$
	2.33	1.96	1.64	1.28
	9.21	7.35	5.99	4.61
	11.34	9.35	2.81	6.25
	4.9981	2.9363	2.1688	2.2902
	4.9774	3.9253	2.1504	2.3822
	4.1451	3.3550	2.7664	2.1825
	4.1259	3.3425	2.7681	2.1774

注：该表给出的是上分位数，以标准正态分数 z_α 为例，它所代表的意义是 $P(Z > z_\alpha)$ ，其中 Z 所代表的是一个服从标准正态分布的随机变量。

【参考答案】：(1) 本题实际上是比较给定方差情况下，不同样本的均值是否不同。所以，若设便捷、质量、价格条件下样本分别服从 $N(\mu_1, \sigma^2)$ ， $N(\mu_2, \sigma^2)$ ， $N(\mu_3, \sigma^2)$ 。则作假设判断：

$$H_0 : \mu_1 = \mu_2 = \mu_3$$

$$H_1 : \max\{\mu_1, \mu_2, \mu_3\} > \min\{\mu_1, \mu_2, \mu_3\}$$

- (2) 先检验 $\mu_1 = \mu_2$ ，做统计量；(需要查阅《概率统计》课本上公式)

再检验 $\mu_2 = \mu_3$ ，做统计量；

3. (共 24 分) 我对对妇女是否愿意工作的问题感兴趣，主要想知道妇女是否选择工作的决定是如何受好的教育水平，以往工作经验，孩子数目及配偶年收入（万）影响的。在计量分析里面，自变量

我们就设定为 X （即以上因素），因变量设定为 0 或 1（妇女选择工作就是 1，选择不工作就是 0）。

（1）如果我们用线性回归模型，即 $y_i = \beta x_i + \varepsilon_i$ ，会造成哪些问题？（6 分）

（2）给定这样的一个二无选择问题，我们可以用一个累计分布函数 $F(\cdot)$ 来模拟妇女选择工作的概率，最经典的模型用哪些累计分布函数？

（3）写下最大似然估计的对数似然函数。（6 分）

（4）给定一个累计分布函数，我们想知道配偶的收入对妇女选择工作的概率的影响，即：配偶年收入每增加一万，对一个妇女选择不参加工作最大的提升？请用公式表达。（6 分）

【参考答案】：（1）当 y 取值为 0 或者 1 时，使用线性回归与 probit 和 logit 模型相比较，会造成很大的误差。另外，在进行预测时，线性回归常常得到的预估数介于 0 和 1 之间，失去了实际意义。

（2）最经典的模型有 logit 模型和 probit 模型。若假设 ε_i 服从 logistic 分布，则为 logit 模型，若假设 ε_i 服从正态分布，则为 probit 模型。

（3）最大似然估计的对数似然函数为

$$\text{Log}L = -\sum_{i=1}^n \frac{(y_i - \beta x_i)^2}{2\sigma^2} - \frac{n}{2} \ln(2\pi) - n \ln \sigma$$

（4）取 logistic 分布。 $P(y_i = 1 | x_i) = \frac{1}{1 + e^{-\beta x_i}} = p_i$ 。对上式关于求导，可以得到：

$$\frac{dp}{dx} = \frac{\beta e^{-\beta x_i}}{(1 + e^{-\beta x_i})^2}。$$

此式即可刻画配偶在现有基础上收入增加，对一个妇女选择不参加工作概率的影响。

统计前两题与去年几乎一样，参考去年。

统计第三题：因变量 Y 为女性是否工作，是则 Y 为 1，不是则 Y 为 0；自变量为配偶收入（第四问才明确给出自变量）。

(1) 若以 $Y_i = bX_i + e_i$ 回归，问 OLS 估计会造成什么问题

(2) 现在以 b 来解释 x 的增加对妇女就业概率的影响，有哪些经典的模型？

(3) 写出对数似然方程

(4) 如果配偶收入增加一万，女性就业几率增加多少？

(1) 线性概率模型实际上是 $P(y_i = 1) = bx_i$ ，这样 $E(y_i) = bx_i$ 。
令 $\varepsilon = y_i - E(y_i)$ ，则 $y_i = bx_i + \varepsilon$ 。

线性概率模型缺点为：

① 预测的概率可能不在 $[0, 1]$ 区间内。按照 OLS 估计出 b 后，
给定自变量 x_0 ，对 $P(y_0 = 1)$ 的预测 bx_0 可能大于 1。

② 线性概率模型假设了自变量对因变量有不变的边际效应。比如，设“女性生育的孩子数目”为自变量，因变量为“女性是否工作”。那么按照线性概率模型，生育第一个孩子导致女性是否就业概率的变化将等于生育第二个、第三个孩子导致就业概率的变化。这是不合理的。

③ 线性概率模型存在异方差问题，OLS 估计虽然无偏、一致，但不再是所有线性无偏估计中最有效的估计了。事实上， $D(\varepsilon) = D(y_i) = P(y_i = 1) * (1 - P(y_i = 1)) = bx_i * (1 - bx_i)$ 。这就出现了异

方差。

④最后，注意到原题目中回归不带常数项，这会导致残差之和不为 0，以及 R^2 可能大于 1。

(2) 设 $F()$ 为累计分布函数，一般的离散选择模型为：

$P(y_i = 1) = F(bx_i)$, 从而 $E(y_i) = F(bx_i)$. 令 $\varepsilon = y_i - E(y_i)$, 则 $y_i = F(bx_i) + \varepsilon$.

通常取 $F()$ 为正太分布，得到 Logita 模型： $y_i = \Phi(bx_i) + \varepsilon$;
或者取 $F()$ 为 Logistic 分布， $F(x) = \frac{1}{1+e^{-x}}$, 得到 Probita 模型： $y_i = \frac{1}{1+e^{-bx_i}} + \varepsilon$

(我考试的时候一紧张，就把 Logistic 模型的概率密度函数当分布函数写了……)

(3) 似然函数为： $L(X, y) = \prod_{i=1}^n F(bx_i)^{y_i} (1 - F(bx_i))^{1-y_i}$

从而对数似然函数为：

$$\ln L(X, y) = \sum_{i=1}^n [y_i \ln F(bx_i) + (1 - y_i) \ln (1 - F(bx_i))]$$

对数似然方程为： $\frac{\partial \ln L(X, y)}{\partial b} = 0$, 此即： (设 $f()$ 为概率密度函数。)

$$\sum_{i=1}^n \left[\frac{x_i y_i f(bx_i)}{F(bx_i)} - \frac{(1-y_i)x_i f(bx_i)}{1-F(bx_i)} \right] = 0$$

(4) 设斜率 b 的极大似然估计为 b_{MLE} , 则 $P(y_i = 1) = F(b_{MLE} * x_i)$.

由 $\frac{\partial P(y_i=1)}{\partial x_i} = f(b_{MLE} * x_i) * b_{MLE}$ 可知：

当配偶工资增加 1 万时，女性就业几率增加了 $f(b_{MLE} * x_i) *$

b_{MLE}