



大师兄统计
统计学考研

《九阳神功》 贰〇贰陆-解析册

VERSION: 2026.02.01

简单的前言

该版本输出于 2026.02.01. 如有错误, 请见谅. 由于时间精力限制, 我们无法为未报班同学答疑解惑.
公众号: 大师兄统计.

更新日志:

- 2026.02.01: 增加 2026 真题解析.

Contents

北京大学光华-431 金融学统计	5
北京大学-431 金融学综合-2016	5
北京大学-431 金融学综合-2017	15
北京大学-431 金融学综合-2018	28
北京大学-431 金融学综合-2019	36
北京大学-431 金融学综合-2020	45
北京大学-431 金融学综合-2021	54
北京大学-431 金融学综合-2022	64
北京大学-431 金融学综合-2023	72
北京大学-431 金融学综合-2024	83
北京大学-431 金融学综合-2025	90
北京大学-431 金融学综合-2026	103
 复旦大学-432 统计学	 118
复旦大学-432 统计学-2016 年	118
复旦大学-432 统计学-2017 年	121
复旦大学-432 统计学-2018 年	124
复旦大学-432 统计学-2019 年	127
复旦大学-432 统计学-2020 年	131
复旦大学-432 统计学-2021 年	134
复旦大学-432 统计学-2022 年	138
复旦大学-432 统计学-2023 年	144
复旦大学-432 统计学-2024 年	149
复旦大学-432 统计学-2025 年	152
复旦大学-432 统计学-2026 年	160
 北京师范大学-432 统计学	 173
北京师范大学-432 统计学-2016 年	173
北京师范大学-432 统计学-2017 年	177
北京师范大学-432 统计学-2018 年	181
北京师范大学-432 统计学-2019 年	185
北京师范大学-432 统计学-2020 年	189
北京师范大学-432 统计学-2021 年	193

北京师范大学-432 统计学-2022 年	198
北京师范大学-432 统计学-2023 年	204
北京师范大学-432 统计学-2024 年	210
北京师范大学-432 统计学-2025 年	216
北京师范大学-432 统计学-2026 年	223
中国科学技术大学-432 统计学	230
中国科学技术大学-432 统计学-2016 年	230
中国科学技术大学-432 统计学-2017 年	235
中国科学技术大学-432 统计学-2018 年	240
中国科学技术大学-432 统计学-2019 年	245
中国科学技术大学-432 统计学-2020 年	250
中国科学技术大学-432 统计学-2021 年	254
中国科学技术大学-432 统计学-2022 年	259
中国科学技术大学-432 统计学-2023 年	262
中国科学技术大学-432 统计学-2024 年	268
中国科学技术大学-432 统计学-2025 年	271
中国科学技术大学-432 统计学-2026 年	275
中国科学技术大学-812 概率论与数理统计	287
中国科学技术大学-812 概率论与数理统计-2016 年	287
中国科学技术大学-812 概率论与数理统计-2017 年	292
中国科学技术大学-812 概率论与数理统计-2018 年	297
中国科学技术大学-812 概率论与数理统计-2019 年	302
中国科学技术大学-812 概率论与数理统计-2020 年	311
中国科学技术大学-812 概率论与数理统计-2021 年	315
中国科学技术大学-812 概率论与数理统计-2022 年	320
中国科学技术大学-812 概率论与数理统计-2023 年	323
中国科学技术大学-812 概率论与数理统计-2024 年	327
中国科学技术大学-812 概率论与数理统计-2025 年	331
中国科学技术大学-812 概率论与数理统计-2026 年	335
北京大学数院-856 大数据	345
北京大学数院-856 大数据-2024 年	345
北京大学数院-856 大数据-2025 年	354
北京大学数院-856 大数据-2026 年	361
清华大学-432 统计学	377
清华大学-432 统计学-2016 年	377
清华大学-432 统计学-2017 年	380
清华大学-432 统计学-2018 年	385
清华大学-432 统计学-2019 年	388
清华大学-432 统计学-2020 年	391
清华大学-432 统计学-2021 年	394
清华大学-432 统计学-2022 年	397

清华大学-432 统计学-2023 年	401
清华大学-432 统计学-2024 年	404
清华大学-432 统计学-2025 年	406
清华大学-432 统计学-2026 年	410
北京大学数院-431 金融学	416
北京大学数院-431 金融学综合-2016 年	416
北京大学数院-431 金融学综合-2017 年	420
北京大学数院-431 金融学综合-2018 年	425
北京大学数院-431 金融学综合-2019 年	430
北京大学数院-431 金融学综合-2020 年	434
北京大学数院-431 金融学综合-2021 年	439
北京大学数院-431 金融学综合-2022 年	443
北京大学数院-431 金融学综合-2023 年	447
北京大学数院-431 金融学综合-2024 年	453
北京大学叉院-849 统计学/432 统计学	458
北大叉院-849 统计学-2016 年	458
北大叉院-849 统计学-2017 年	462
北大叉院-849 统计学-2018 年	467
北大叉院-849 统计学-2019 年	472
北大叉院-849 统计学-2020 年	474
北大叉院-849 统计学-2021 年	477
北大叉院-849 统计学-2022 年	481
北大叉院-849 统计学-2023 年	483
复旦大学-861 概率论与数理统计	488
复旦大学 861-861 概率论与数理统计-2018 年	488
复旦大学 861-861 概率论与数理统计-2019 年	491
复旦大学 861-861 概率论与数理统计-2020 年	495
复旦大学 861-861 概率论与数理统计-2021 年	500
南开大学-432 统计学	504
南开大学-432 统计学-2016 年	504
南开大学-432 统计学-2017 年	509
南开大学-432 统计学-2018 年	515
南开大学-432 统计学-2019 年	520
南开大学-432 统计学-2020 年	528
南开大学-432 统计学-2021 年	534
南开大学-432 统计学-2022 年	542
南开大学-432 统计学-2023 年	548
南开大学-432 统计学-2024 年	555

中山大学-432 统计学

558

中山大学-432 统计学-2016 年

558

中山大学-432 统计学-2017 年

567

中山大学-432 统计学-2018 年

576

中山大学-432 统计学-2019 年

585

中山大学-432 统计学-2020 年

594

中山大学-432 统计学-2021 年

603

中山大学-432 统计学-2022 年

609

中山大学-432 统计学-2023 年

614

上海交通大学-432 统计学

622

上海交通大学-432 统计学-2016 年

622

上海交通大学-432 统计学-2017 年

627

上海交通大学-432 统计学-2018 年

633

上海交通大学-432 统计学-2019 年

639

上海交通大学-432 统计学-2020 年

644

上海交通大学-432 统计学-2021 年

654

上海交通大学-432 统计学-2022 年

664

上海交通大学-432 统计学-2023 年

675

上海交通大学-432 统计学-2024 年

686

上海财经大学大学-432 统计学

693

上海财经大学-432 统计学-2023 年

693

众号

大师兄统计

北京大学光华-431 金融学统计

北京大学-431 金融学综合-2016

• 2016 统计部分解析

一、收集同一个公司两个市场的日回报率, 其中 $(x_1, x_2, x_3, \dots, x_n)$ 为 A 市场的股票的回报率, $(y_1, y_2, y_3, \dots, y_n)$ 为 B 市场的股票的回报率

(1) 描述如何检验 A 的回报率是否比 B 的高。

(2) 如何检验 A 的回报率方差和 B 的是否一样。

(3) 如何检验 A 与 B 的股票日回报是否相关。

(4) 如果 $(x_1, x_2, x_3, \dots, x_n)$ 为 A 市场的股票的价格, $(y_1, y_2, y_3, \dots, y_n)$ 为 B 市场的股票的价格。如何检验 A 的股价是否高于 B。

Solution:

(1) 由于是同一个公司两个市场, 从而我们使用 ** 配对样本 t 检验 **, 令 $z_i = x_i - y_i, i = 1, 2, \dots, n$ 。

假定 $z_i \sim N(\mu_z, \sigma_z^2)$, 作如下检验

$$H_0: \mu_z = 0 \leftrightarrow H_1: \mu_z > 0$$

计算 t-统计量为

$$t = \frac{\sqrt{n}\bar{z}}{s_z}$$

在给定显著性水平 α 下, 该检验的拒绝域为

$$W = \{t > t_{1-\alpha}(n-1)\}.$$

(2) 要检验 A 的回报率方差是否与 B 的方差相等, 可以使用方差比较检验, 通常使用 F-检验来执行。

1. ** 提出假设: ** - H_0 : A 和 B 的回报率方差相等, 即 $\sigma_x^2 = \sigma_y^2$, 其中 σ_x^2 是 A 的回报率方差, σ_y^2 是 B 的回报率方差。 - H_1 : A 和 B 的回报率方差不相等, 即 $\sigma_x^2 \neq \sigma_y^2$ 。

2. ** 计算样本方差: ** 分别计算 A 市场和 B 市场的回报率样本方差 (s_x^2 和 s_y^2)。

3. ** 计算 F-统计量: ** 使用以下公式计算 F-统计量:

$$F = \frac{s_x^2}{s_y^2}$$

其中, s_x^2 和 s_y^2 分别是 A 市场和 B 市场的回报率样本方差。

4. ** 确定自由度: ** 确定 F-检验的自由度, 其中自由度分别为 $n_x - 1$ 和 $n_y - 1$, 其中 n_x 和 n_y 分别是 A 市场和 B 市场的样本大小, 本题中二者均为 n 。

5. ** 查找临界值: ** 根据显著性水平 (假设 0.05) 和自由度, 查找 $F_{0.025}(n-1, n-1), F_{0.975}(n-1, n-1)$;

6. ** 做出决策: ** 如果 $F < F_{0.025}(n-1, n-1)$ 或 $F > F_{0.975}(n-1, n-1)$, 则拒绝原假设, 反之接受原假设。

(3) 要检验 A 与 B 的股票日回报是否相关, 可以使用相关系数检验:

1. ** 提出假设: **

- H_0 : A 与 B 的股票日回报不相关, 即相关系数为 0。

- H_1 : A 与 B 的股票日回报相关, 相关系数不为 0。

2. ** 计算相关系数: **

计算相关系数的值, 这个值可以为正数 (正相关)、负数 (负相关) 或接近 0 (不相关)。计算公式为:

$$r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

其中, r_{xy} 是皮尔逊相关系数, x_i 和 y_i 分别是 A 和 B 的回报数据点, $\bar{x}$ 和 $\bar{y}$ 分别是它们的均值。

3. ** 构造拒绝域: **

根据 $\sqrt{n} \cdot r_{xy} \xrightarrow{d} N(0, 1)$ 的结论, 构造拒绝域

$$W = \{|\sqrt{n} \cdot r_{xy}| > z_{1-\frac{\alpha}{2}}\}$$

4. ** 做出决策: **

如果 $|\sqrt{n} \cdot r_{xy}| > z_{1-\frac{\alpha}{2}}$, 则认为他们之间有强相关性, 否则没有强相关性。

(4) 根据题干, 现在想比较的是同一个公司在两个市场的股价, 而不是收益率。在此情况下, 仍为配对样本, 但我们要采取作差检验消除数量级差异: 我们令 $z_i = \frac{x_i}{y_i}$, 作如下检验

$$H_0: \mu_z = 1 \leftrightarrow H_1: \mu_z > 1$$

考虑大样本情况下的 t-检验, 计算 t-统计量为

$$t = \frac{\sqrt{n}(\bar{z} - 1)}{s_z}$$

在给定显著性水平 α 下, 该检验的拒绝域为

$$W = \{t > t_{1-\alpha}(n-1)\}.$$

注: 如果利用作差消除量级的影响。如: 某天 A 市场股价 100, B 市场股价 90 元; 一年后 A 市场股价 10 元, B 市场股价 1 元。通过作差我们发现一年前两市场股价差距为 10 元, 一年后两市场差距为 9 元, 但是否能说一年后两个市场股价更接近? 显然不行。可以看出采取作商的方式更能有效检验该问题。

二、考虑泊松分布 $P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}$, 搜集到样本 $x_1, x_2, \dots, x_n$, 请估计参数 λ 并检验其统计性质。

Solution:

对于泊松分布, 要估计参数 λ 并检验其统计性质。首先, 我们一般使用最大似然估计来估计 λ 。其次, “检验其统计性质” 的问法实际较为奇怪, 并不常见。统计性质一般会指无偏性、相合性, 我们可以考察这两者。

(1) 估计参数 λ :

对于泊松分布, 似然函数为:

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!}$$

对数似然函数为:

$$l(\lambda) = \ln L(\lambda) = \sum_{i=1}^n (-\lambda + x_i \ln(\lambda) - \ln(x_i!))$$

然后, 通过对 $l(\lambda)$ 关于 λ 求导数, 并令导数等于零, 解得 λ 的估计值

$$\hat{\lambda}_{MLE} = \frac{1}{n} \sum_{i=1}^n x_i$$

(2) 检验其统计性质。

先看无偏性, 很显然, $E(\hat{\lambda}_{MLE}) = \frac{1}{n} \cdot n \cdot E(x_1) = \lambda$, 无偏。

再看相合性, 根据大数定律, 有 $\frac{1}{n} \sum_{i=1}^n x_i \xrightarrow{P} E(x_1) = \lambda$, 相合。

三、某老师做研究生成绩 grade 对平时成绩 CGPA 和逃课率 Skipped 的回归如下: $\text{grade} = \alpha_0 + \alpha_1 \text{CGPA} + \alpha_2 \text{Skipped} + \varepsilon$, 其中样本容量为 $n = 141$, $R^2 = 0.234$, α_2 的估计值为 $\hat{\alpha}_2 = 0.36$ 。三个变量 $\alpha_0, \alpha_1, \alpha_2$ 的显著性检验 p 值分别是 0.33, 0.094, 0.021;

(1) 为什么要选择 CGPA 做自变量?

(2) 在显著性水平为 1% 时, Skipped 对 grade 是否没有影响?

(3) 在显著性水平为 1% 时, CGPA 和 Skipped 是否对 grade 同时没有影响?

Solution:

(1) 自变量的选择一般基于经验结论、理论假设 (经济学或物理学理论).

(经验结论例子: “小明发现孩子熊的程度和家长熊的程度是成正比的”; 经济学理论: “柯布-道格拉斯函数说明投入产出成正比”; 物理例子: “杨-米尔斯方程说明规范场强张量关于 ig (耦合常数 g 乘虚数单位 i) 的斜率是对易子 $[A\mu, A\nu]$.”)

选择 CGPA 做自变量是基于经验结论. 老师根据过往的认知得出了 CGPA 是一个重要的变量. 事实上, 任何学生都会直觉地将这两个量挂钩, 一般平时成绩更好的同学其研究生成绩也更好. 此外, 显然, 并没有一个现存的经济理论或者物理理论给出 CGPA 和 grade 的线性关系.

(2) 要判断 Skipped 对 grade 是否有影响, 我们可以进行如下的假设检验:

- ** 零假设 H_0 : Skipped 对 grade 没有影响, 即 $\alpha_2 = 0$.

- ** 备择假设 H_1 : Skipped 对 grade 有影响, 即 $\alpha_2 \neq 0$.

根据给定的 p 值为 0.021, 显著性水平为 1%, 因为 $0.021 > 0.01$, 所以在 1% 的显著性水平下, 我们不能拒绝零假设 H_0 , 即不能认为 Skipped 对 grade 有显著影响.

(3) 同时检验这两个假设, 实际上就是对模型整体的显著性检验. 我们建立原假设 $H_0: \alpha_1 = \alpha_2 = 0$, 对应的检验统计量是

$$F = \frac{(n-k-1)R^2}{k(1-R^2)} \sim F(k, n-k-1),$$

拒绝域是 $W = \{F > F_{0.99}(k, n-k-1) = 4.77\}$.

代入数据, 计算出 F 检验统计量:

$$F = \frac{(n-k-1)R^2}{k(1-R^2)} = \frac{(141-3) \cdot 0.234}{2 \cdot (1-0.234)} = 21.0783 > 4.77,$$

因此拒绝原假设, 认为它们联合起来对 grade 有显著影响.

四、两只股票收益率分布如下: $\varepsilon \sim N(\mu_1, \sigma_1^2)$, $\theta \sim N(\mu_2, \sigma_2^2)$, 假定这两只股票的收益率是独立的, 方差相等. 现有两只股票收益率的样本, $(\varepsilon_1, \varepsilon_2, \varepsilon_3, \dots, \varepsilon_n)$ 和 $(\theta_1, \theta_2, \theta_3, \dots, \theta_m)$. 试求 $\frac{\sum_{i=1}^n (\varepsilon_i - \bar{\varepsilon})^2}{\sum_{i=1}^n (\varepsilon_i - \bar{\varepsilon})^2 + \sum_{j=1}^m (\theta_j - \bar{\theta})^2}$ 的概率分布.

Solution: 参见茆书习题 3.3.18.

记样本均值为 $\bar{\varepsilon}$, $\bar{\theta}$. 记 $\sigma^2 = \sigma_1^2 = \sigma_2^2$.

接下来, 我们考虑随机变量:

$$X = \frac{\sum_{i=1}^n (\varepsilon_i - \bar{\varepsilon})^2}{\sigma^2}$$
$$Y = \frac{\sum_{j=1}^m (\theta_j - \bar{\theta})^2}{\sigma^2}$$

这两个随机变量相互独立, 分别服从自由度为 $n-1$ 和 $m-1$ 的卡方分布. 则记目标随机变量

$$T = \frac{\sigma^2 X}{\sigma^2 (X+Y)} = \frac{X}{X+Y}$$

作变量变换, 记

$$\begin{cases} T = \frac{X}{X+Y} \\ U = X+Y \end{cases}$$

则反变换为 $\begin{cases} X = UT \\ Y = U - UT \end{cases}$, 雅各比行列式

$$J = \frac{\partial(x, y)}{\partial(t, u)} = \begin{vmatrix} u & t \\ -u & 1-t \end{vmatrix} = u(1-t) + tu = u$$

又由于 (X, Y) 的联合密度函数是

$$\begin{aligned} f_{X,Y}(x, y) &= \frac{\left(\frac{1}{2}\right)^{\frac{n-1}{2}}}{\Gamma\left(\frac{n-1}{2}\right)} x^{\frac{n-1}{2}-1} e^{-\frac{x}{2}} \frac{\left(\frac{1}{2}\right)^{\frac{m-1}{2}}}{\Gamma\left(\frac{m-1}{2}\right)} y^{\frac{m-1}{2}-1} e^{-\frac{y}{2}}, x > 0, y > 0 \\ &= \frac{\left(\frac{1}{2}\right)^{\frac{m+n-2}{2}}}{\Gamma\left(\frac{n-1}{2}\right) \Gamma\left(\frac{m-1}{2}\right)} x^{\frac{n-1}{2}-1} y^{\frac{m-1}{2}-1} e^{-\frac{x+y}{2}}, x > 0, y > 0 \end{aligned}$$

则 (T, U) 的联合密度函数是

$$\begin{aligned} f_{T,U}(t, u) &= f_{X,Y}(ut, u-ut) \cdot u, \quad 0 < ut < u \\ &= \frac{\left(\frac{1}{2}\right)^{\frac{n+m-2}{2}}}{\Gamma\left(\frac{n-1}{2}\right) \Gamma\left(\frac{m-1}{2}\right)} (ut)^{\frac{n-1}{2}-1} (u-ut)^{\frac{m-1}{2}-1} e^{-\frac{u}{2}} u, \quad u > 0, 0 < t < 1 \\ &= \left\{ \frac{\left(\frac{1}{2}\right)^{\frac{n+m-2}{2}}}{\Gamma\left(\frac{n-1}{2}\right) \Gamma\left(\frac{m-1}{2}\right)} u^{\frac{n+m-2}{2}-1} e^{-\frac{u}{2}} \right\} \left\{ \frac{\Gamma\left(\frac{n+m-2}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right) \Gamma\left(\frac{m-1}{2}\right)} t^{\frac{n-1}{2}-1} (1-t)^{\frac{m-1}{2}-1} \right\}, \quad u > 0, 0 < t < 1 \end{aligned}$$

故 $U \sim \chi^2(n+m-2)$, $T \sim \text{Beta}\left(\frac{n-1}{2}, \frac{m-1}{2}\right)$ 且二者独立.

五、记 $r_t = \alpha + \beta r_{m_t} + \varepsilon_t$ 为股票市场回报的回归方程, 试求:

(1) 在什么假设下 β 的 OLS 估计量是无偏的? 请给出严格的数学证明。(2) 上述假设在实际中成立么? 为什么?

Solution:

(1) OLS (最小二乘法) 估计量 $\hat{\beta}$ 是无偏的, 当以下假设成立时:

- 零条件均值: $E(\varepsilon_t | r_{m_t}) = 0$, 这表示在给定 r_{m_t} 的条件下, 误差 ε_t 的条件期望为零.

值得注意的是, 只是证明无偏性时, 我们不需要 Gauss-Markov 定理中的所有假设. 如果还需要证明有效性等性质, 则需要进一步的 Gauss-Markov 条件.

为了证明 $\hat{\beta}$ 在假设下是无偏的, 我们可以利用条件期望的性质来进行推导:

首先, 回归方程可以重写为误差项的形式:

$$\varepsilon_t = r_t - \alpha - \beta r_{m_t}$$

然后, 我们可以计算 $\hat{\beta}$ 的期望值:

$$\begin{aligned} E(\hat{\beta}) &= E\left(\frac{\sum_{t=1}^T (r_t - \bar{r})(r_{m_t} - \bar{r}_m)}{\sum_{t=1}^T (r_{m_t} - \bar{r}_m)^2}\right) \\ &= \frac{\sum_{t=1}^T E[(r_t - \bar{r})(r_{m_t} - \bar{r}_m)]}{\sum_{t=1}^T E[(r_{m_t} - \bar{r}_m)^2]} \end{aligned}$$

在上述步骤中, 我们使用了样本均值 $\bar{r}$ 和 $\bar{r}_m$, 它们分别是 r_t 和 r_{m_t} 的均值。

根据无偏性的定义, $E(\varepsilon_t | r_{m_t}) = 0$ 的假设, 我们可以得到:

$$\begin{aligned}
E[(r_t - \bar{r})(r_{mt} - \bar{r}_m)] &= E[(\alpha + \beta r_{mt} + \varepsilon_t - (\alpha + \beta \bar{r}_m))(r_{mt} - \bar{r}_m)] \\
&= E[(\beta r_{mt} - \beta \bar{r}_m + \varepsilon_t)(r_{mt} - \bar{r}_m)] \\
&= E\left\{E[(\beta r_{mt} - \beta \bar{r}_m + \varepsilon_t)(r_{mt} - \bar{r}_m) | r_{mt}]\right\} \\
&= \beta E[(r_{mt} - \bar{r}_m)^2]
\end{aligned}$$

因此, $\hat{\beta}$ 的期望值为:

$$\begin{aligned}
E(\hat{\beta}) &= E\left(\frac{\sum_{t=1}^T (r_t - \bar{r})(r_{mt} - \bar{r}_m)}{\sum_{t=1}^T (r_{mt} - \bar{r}_m)^2}\right) \\
&= \frac{\beta \sum_{t=1}^T E[(r_{mt} - \bar{r}_m)^2]}{\sum_{t=1}^T E[(r_{mt} - \bar{r}_m)^2]} = \beta
\end{aligned}$$

这表明线性模型在零条件均值假设成立的情况下, $\hat{\beta}$ 是无偏的估计量。

(2) 结论: 在金融学理论中, 该假定一般被认为成立; 在现实中, 该假定一般不严格成立。目前基于 CAPM (资本资产定价模型) 的金融学实证研究一般认为该假定在现实是近似成立的, 一些多因子的研究则认为仅一个市场因子并不足以解释全部的公司收益, 此时这个假定不成立。

具体来说, 在本问题中, 题干假设公司个体收益率 r_t 可以被分解为市场驱动的 βr_{mt} 和公司特质部分 ε_t 。假设 $E(\varepsilon_t | r_{mt}) = 0$ 表明了当市场回报已知时, 公司特质部分 ε_t 是一个零均值的随机扰动项, 这实际上是传统的 CAPM 或者单因子市场模型。在这类研究中, 通常认为该假设近似是成立的。

在多因子模型 (如 Fama-French 三因子) 中, 人们认为仅仅一个市场因子无法充分刻画公司收益的全部信息。举个例子, Liu et al. (2019) 提出的四因子模型 (CH4 模型) 在中国市场表现较好, 即: 市场因子、价值因子 (VMG)、规模因子 (SMB) 和情绪因子 (PMO):

$$r_t = \alpha + \beta_1 r_{mt} + \beta_2 r_{VMG,t} + \beta_3 r_{SMB,t} + \beta_4 r_{PMO,t} + \varepsilon_t.$$

这说明, 它们认为题干的 CAPM 模型中的 ε_t 还有其他信息, 这些信息可以被 VMG, SMB 和 PMO 因子解释, 这将违反零均值条件。

此外, 股票市场可能存在长期趋势或波动, 股票价格也可能受到经济状况、政治事件、利率变化等的影响。这些也可能违反了零条件均值假设。

• 2016 微观部分解析

一、(15 分) 甲、乙两名消费者考虑消费两种商品: 饼饼 (其消费量记为 X_1) 与其他商品 (其消费量记为 X_2)。两种商品价格分别为 $P_1 = 10$, $P_2 = 1$ 元。甲乙二人有相同的效用函数:

$$U(X_1, X_2) = X_1^{0.5} X_2^{0.5}$$

同时, 二人的收入相同为 $I = 100$ 元。甲乙二人的唯一区别在于, 乙有一张饼饼的折扣券, 使用该折扣券能以 50% 的价格购买任何数量的饼饼 (折扣券只能使用一次), 甲没有折扣券。

1. 计算两名消费者各自对于两种商品的最优消费量。2. 假设在实际购买商品之前, 甲和乙商量能否以一定的价格将乙的折扣券卖给甲。甲为了得到折扣券, 最高愿意付多少小钱? 3. 乙为了出让折扣券, 至少应得到多少小钱? 4. 乙能否与甲达成一定的协议, 从而将手中的折扣券转让给甲?

Solution:

(1) 消费者 i ($i = \text{甲, 乙}$) 的决策问题是:

$$\max U_i(X_1, X_2) = X_1^{0.5} X_2^{0.5} \text{ s.t. } P_1 X_1 + X_2 = I$$

拉格朗日函数为:

$$\mathcal{L} = X_1^{0.5} X_2^{0.5} + \lambda [I - P_1 X_1 - X_2]$$

$$\frac{\partial \mathcal{L}}{\partial X_1} = 0.5 X_1^{-0.5} X_2^{0.5} - \lambda P_1 = 0$$

$$\frac{\partial \mathcal{L}}{\partial X_2} = 0.5 X_1^{0.5} X_2^{-0.5} - \lambda = 0$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = I - P_1 X_1 - X_2 = 0$$

** 解得 **:

$$X_1 = \frac{0.5I}{P_1}, \quad X_2 = 0.5I$$

对于甲, $P_1 = 10, I = 100$, 代入得:

$$X_1 = 5, \quad X_2 = 50$$

对于乙, $P_1 = 5, I = 100$, 代入得:

$$X_1 = 10, \quad X_2 = 50$$

(2) 由 (1) 分析, 间接效用函数为:

$$U_i = \frac{0.5I}{\sqrt{P_i}}$$

设甲愿意支付的最高金额为 k , 购买折扣券后, 以每单位 5 元购买商品 1。购买折扣券后, 最低应满足效用相等, 即:

$$U_{\text{甲}} = \frac{0.5 \cdot 100}{\sqrt{10}} = \frac{0.5 \cdot (100 - k)}{\sqrt{5}}$$

** 解得 **:

$$k = 100 - 50\sqrt{2} \approx 30$$

因此, 甲愿意支付的最高金额为 30 元。

(3) 分析道理如上。记乙出让折扣券的最低索取金额为 w , 出让折扣券后, 以每单位 10 元购买商品 1。出让折扣券后, 应满足效用相等, 即:

$$U_{\text{乙}} = \frac{0.5 \cdot 100}{\sqrt{5}} = \frac{0.5 \cdot (100 + w)}{\sqrt{10}}$$

** 解得 **:

$$w = 100\sqrt{2} - 100 \approx 40$$

因此, 乙为了出让折扣券至少要卖 40 元。

(4) 甲愿意支付的最高金额 (30) 小于乙最低索取的金额 (40), 故无法达成交易。

二、(15 分) 一个垄断经营者同时销售两种产品。第一种产品的需求曲线是:

$$D_1(p_1, p_2) = \frac{3 - p_2}{p_1^2},$$

第二种产品的需求曲线是:

$$D_2(p_1, p_2) = \frac{3 - p_1}{p_2^2},$$

这个垄断经营者在销售了 y_1 个第一种产品和 y_2 个第二种产品以后, 成本曲线是:

$$C(y_1, y_2) = y_1 + y_2.$$

1. 这两种产品是彼此的替代品还是彼此的互补品？2. 求出这个垄断经营者的利润（使用变量 p_1 和 p_2 表述）。3. 假设这个垄断经营者在第二种产品上被强制定价 $p_2 = 1$ ，但是他可以在 0 到 3 之间任意选择第一种产品的价格 p_1 ，求出可以使这个垄断经营者利润最大化的价格 p_1 。4. 假设这个垄断经营者必须给两种产品选择一样的价格，而这个价格介于 0 到 3 之间。求出可以使这个垄断经营者利润最大化的价格。

Solution:

(1) 根据题中产品 1 和 2 的需求函数，

$$\frac{\partial D_1}{\partial p_2} = -\frac{1}{p_1^2} < 0,$$

因此产品 1 是产品 2 的互补品。同理分析，两种产品是彼此的 ** 互补品 **。

(2) 垄断厂商的利润表达式为：

$$\pi(p_1, p_2) = p_1 D_1 + p_2 D_2 - C(y_1, y_2) = (p_1 - 1) \frac{3 - p_2}{p_1^2} + (p_2 - 1) \frac{3 - p_1}{p_2^2}.$$

(3) 当 $p_2 = 1$ 时，垄断厂商的决策是：

$$\max_{p_1} \pi(p_1) = \frac{2(p_1 - 1)}{p_1^2},$$

其中 $0 < p_1 < 3$ 。设

$$\frac{d\pi}{dp_1} = 2 \left(-\frac{1}{p_1^2} + \frac{2}{p_1^3} \right) = 0,$$

解得 $p_1 = 2$ ，此时垄断厂商利润 $\pi = 0.5$ 。

(4) 此时为统一定价，垄断厂商的决策是：

$$\pi(p) = p D_1 + p D_2 - C(y_1, y_2) = 2(p - 1) \frac{3 - p}{p^2},$$

其中 $0 < p < 3$ 。设

$$\frac{d\pi}{dp} = 2 \left(\frac{3 - p}{p^2} + (p - 1) \left(-\frac{6}{p^3} + \frac{1}{p^2} \right) \right) = 0,$$

解得 $p = 1.5$ ，此时垄断厂商利润 $\pi = \frac{2}{3}$ 。

三、(15 分) 某消费者面临跨期消费选择问题。假设此消费者在今天的消费量为 c_0 ，在明天的消费量为 c_1 ，两期的价格均为 1。假设该消费者今天的收入为 $I_0 = 100$ ，设明天的收入为 I_1 。消费者的效用函数是：

$$U(c_0, c_1) = \ln(c_0) + \ln(c_1)$$

消费者可以选择储蓄，但不能向他人借款，假设利率水平为 $r = 0$ ，求：

1. 若明天的收入 $I_1 = 34$ ，求此消费者的消费决策。2. 若明天的收入存在两种可能，分别是 $I_1 = 100$ 和 $I_1 = 0$ ，两种可能性发生的概率各为 50%，求此消费者的消费决策。

Solution:

(1) 明天的消费量为 $c_1 = 134 - c_0$ 。消费者效用最大化的决策是：

$$\max U(c_0, c_1) = \ln(c_0) + \ln(134 - c_0)$$

计算导数并令其为零，得到：

$$\frac{dU}{dc_0} = \frac{1}{c_0} - \frac{1}{134 - c_0} = 0$$

解得：

$$c_0 = 67, \quad c_1 = 67$$

(2) 消费者在明天的消费量是不确定的：

$$c_1 = (I_0 - c_0) + I_1 = \begin{cases} 200 - c_0, & p = 0.5 \\ 100 - c_0, & 1 - p = 0.5 \end{cases}$$

消费者 ** 期望效用最大化的决策 ** 是：

$$\max EU(c_0, c_1) = \ln(c_0) + \frac{1}{2} [\ln(100 - c_0) + \ln(200 - c_0)]$$

** 约束条件 ** 为 $0 \leq c_0 \leq 100$ (消费量非负且不超过第一期收入)，对 c_0 求导：

$$\frac{dEU}{dc_0} = \frac{1}{c_0} + \frac{1}{2} \left(\frac{-1}{100 - c_0} + \frac{-1}{200 - c_0} \right) = 0$$

化简后得到：

$$c_0^2 - 225c_0 + 10000 = 0$$

解得：

$$c_0 = 112.5 - 12.5\sqrt{17} \approx 61 \quad (\text{符合题意})$$

或

$$c_0 = 112.5 + 12.5\sqrt{17} \approx 164 \quad (\text{不符合题意})$$

明天的消费 c_1 或为 139，或为 39，概率为 0.5。

四、(15 分) 谷歌和百度在市场进行质量竞争，谷歌的质量为 r_1 ，百度的质量为 r_2 。质量 r_1 和 r_2 介于 0 至 5 之间。谷歌的收入函数为：

$$200[0.5 + 0.05(r_1 - r_2)],$$

成本函数为 $c_1 = r_1^2$ ；百度的收入函数为：

$$200[0.5 + 0.05(r_2 - r_1)],$$

成本函数为 $c_2 = 1.25r_2^2$ 。试求：

1. 若百度收购了谷歌，那么利润最大化时的质量 r_1 和 r_2 分别为多少？2. 若百度和谷歌进行寡头竞争， r_1 和 r_2 分别为多少？各自的利润分别为多少？总的利润为多少？和 (1) 中的总质量相比如何？3. 若谷歌有一个投资计划，投入 60 单位的费用进行宣传和市场推广，投资之后的市场结构会发生变化：即谷歌的收入函数变为：

$$200[0.75 + 0.05(r_1 - r_2)],$$

百度的收入函数变为：

$$200[0.25 + 0.05(r_2 - r_1)],$$

假设各自成本不变。请问谷歌会做该项投资么？

Solution:

(1) 百度收购谷歌之后的总利润为：

$$\pi = 200[0.5 + 0.05(r_1 - r_2)] + 200[0.5 + 0.05(r_2 - r_1)] - r_1^2 - 1.25r_2^2$$

不难发现 $r_1 = r_2 = 0$ 时总利润最大。

(2) 寡头竞争时，各自的决策分别如下：

谷歌：

$$\begin{aligned}\max \pi_1 &= 200[0.5 + 0.05(r_1 - r_2)] - r_1^2 \\ \frac{\partial \pi_1}{\partial r_1} &= 10 - 2r_1 = 0\end{aligned}$$

解得 $r_1 = 5$

百度：

$$\begin{aligned}\max \pi_2 &= 200[0.5 + 0.05(r_2 - r_1)] - 1.25r_2^2 \\ \frac{\partial \pi_2}{\partial r_2} &= 10 - 2.5r_2 = 0\end{aligned}$$

解得 $r_2 = 4$

谷歌和百度的利润分别为 $\pi_1 = 85$, $\pi_2 = 70$ ，总质量为 9，大于 (1) 中的总质量 0。

(3) 若谷歌执行该投资计划，则在寡头竞争时，各自的决策分别如下：

谷歌：

$$\begin{aligned}\max \pi_1 &= 200[0.75 + 0.05(r_1 - r_2)] - r_1^2 - 60 \\ \frac{\partial \pi_1}{\partial r_1} &= 10 - 2r_1 = 0\end{aligned}$$

解得 $r_1 = 5$

百度：

$$\begin{aligned}\max \pi_2 &= 200[0.25 + 0.05(r_2 - r_1)] - 1.25r_2^2 \\ \frac{\partial \pi_2}{\partial r_2} &= 10 - 2.5r_2 = 0\end{aligned}$$

解得 $r_2 = 4$

均衡质量与 (2) 相同；双方利润为： $\pi_1 = 75$, $\pi_2 = 20$ 。


可见，若实施该计划，谷歌利润相较不实施会减少 10 单位。因此，该计划不会被谷歌执行。

五、(15 分) 在一个完全竞争的钢铁市场，市场的需求函数为 $P_d = 20 - Q$ ，市场的供给函数为 $P_s = 2 + Q$ 。炼钢企业的污染边际损耗是 $MD = 0.5Q$ 。

1. 画出需求曲线、供给曲线、边际损耗曲线以及社会的边际成本曲线。2. 如果企业不对污染采取措施，那么市场的均衡价格和产量是多少？3. 请问社会最优的产量是什么？相应的污染成本为多少？4. 请问污染的外部性造成的社会福利损失为多少？5. 政府能否通过对产量征税从而达到社会最优产量水平？如果可以，如何征税？

Solution

(1) 如图展示了需求 (Demand)、供给 (Supply)、边际损耗 (MD)、社会边际成本 (SMC) 的曲线与关系。



(2) 如不对污染采取措施, 完全竞争均衡满足市场需求等于市场供给, 有:

$$20 - Q = 2 + Q,$$

解得 $Q = 9, P = 11$ 。

(3) 社会最优意味着社会边际成本 (SMC) 与需求曲线相交, 即:

$$20 - Q = 2 + 1.5Q$$

解得

$$Q^* = 7.2, \quad P^* = 12.8$$

因此, 社会最优时, ** 污染成本 **

$$D = \int_0^{7.2} 0.5Q \, dQ = 12.96.$$

(4) ** 社会福利损失 ** 是 SMC 曲线与 P_d 曲线在 $[7.2, 9]$ 之间的差值, 即

$$\Delta W = - \int_{7.2}^9 [(2 + 1.5Q) - (20 - Q)] \, dQ = -4.05.$$

因此社会福利损失了 4.05。

(5) 政府可以通过 ** 对产量征税 ** 来达到社会最优产量。最优税额应等于边际损害在社会最优产量的水平。对于 $Q = 7.2$, 边际损害为 $MD = 3.6$ 。因此, 政府可以对每单位产量征收 3.6 的税, 使得生产者的边际私人成本加上税额等于社会边际成本, 完全竞争最优即为社会最优。

北京大学-431 金融学综合-2017

• 2017 统计部分解析

一、(15 分) 公司甲同时在大陆 A 股及香港 H 股上市, 现有它在 A 股市场和 H 股市场上过去一年每天的回报预测值 X_i, Y_i 。

(1) 请给出两种检验方法, 检验该股票在 A 股和 H 股上的回报均值是否相等, 需要给出具体的计算过程。

(2) 讨论这两种检验隐含的假设条件。根据你的假设条件讨论, 你认为两种检验有无差异? 如果有, 哪种检验更合理?

[注]: 这里可以选择用“配对样本 t 检验”, “大样本 u 检验”和“Wilcoxon 秩和检验”中的两种, 而由于这里明显是配对样本, 故“配对样本 t 检验”是一定要用的。

(1) 使用 配对样本 t 检验 和 Wilcoxon 秩和检验

配对样本 t 检验:

令差值

$$D_i = X_i - Y_i, \quad i = 1, 2, \dots, n.$$

假设 $D_i \sim N(\mu_D, \sigma_D^2)$, 我们要检验两地市场的平均回报是否相等:

$$H_0: \mu_D = 0 \quad \text{对比} \quad H_1: \mu_D \neq 0,$$

** 检验步骤如下: **

1. 计算样本均值与样本标准差:

$$\bar{D} = \frac{1}{n} \sum_{i=1}^n D_i, \quad s_D = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})^2}.$$

2. 构造检验统计量:

$$t = \frac{\bar{D}}{s_D / \sqrt{n}}.$$

3. 在原假设 H_0 下, t 服从自由度为 $n-1$ 的 t 分布。

4. 给定显著性水平 α , 若

$$|t| > t_{n-1, 1-\alpha/2},$$

则拒绝 H_0 , 认为两市场的平均回报存在显著差异。

** 结论解释: ** 若拒绝 H_0 , 说明该股票在 A 股与 H 股市场上的平均回报存在显著差异; 若无法拒绝 H_0 , 则认为两者的平均回报无显著差别。

Wilcoxon 秩和检验

Wilcoxon 秩和检验的原假设为

$$H_0: F_X = F_Y,$$

备择假设为

$$H_1: F_X \neq F_Y.$$

** 检验步骤如下: **

1. 将两个样本合并为总体

$$Z = \{X_1, \dots, X_{n_1}, Y_1, \dots, Y_{n_2}\},$$

并按从小到大排列, 赋予秩次 R_i (若有相等值, 取平均秩)。

2. 计算 A 股样本的秩和:

$$W_X = \sum_{i=1}^{n_1} R(X_i).$$

3. 在原假设下, W_X 的期望和方差为

$$E(W_X) = \frac{n_1(n_1 + n_2 + 1)}{2}, \quad \text{Var}(W_X) = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12}.$$

4. 当 n_1, n_2 足够大时, 统计量

$$Z = \frac{W_X - E(W_X)}{\sqrt{\text{Var}(W_X)}}$$

近似服从标准正态分布 $N(0, 1)$ 。

5. 给定显著性水平 α , 若 $|Z| > z_{1-\alpha/2}$, 则拒绝原假设 H_0 , 认为两市场的回报分布存在显著差异。

** 结论解释:** 若拒绝 H_0 , 说明该股票在 A 股与 H 股市场的回报分布 (尤其是中位数) 存在显著差异; 若无法拒绝 H_0 , 则认为两者无显著差别。

(2) 这两种检验隐含的假设条件有以下区别:

- t 检验要求正态分布, 而 Wilcoxon 秩和检验不需要这个假设。这意味着如果样本存在偏度或峰度等非正态特征, t 检验可能会失效或不准确, 而 Wilcoxon 秩和检验则更稳健。

- 配对样本 t 检验要求样本数据是一一配对的, 而 Wilcoxon 秩和检验并不要求这点。在本问题中, 数据确实是一一配对的, 因此 t 检验更能利用两个样本的具体数值信息, 而 Wilcoxon 秩和检验只利用了两个样本的相对顺序信息。这种情况下, t 检验可能会更有效, 而 Wilcoxon 秩和检验则可能会损失一些信息。

综上所述, 两种检验有一定的差异, 哪种检验更合理取决于两个样本的实际分布情况和研究目的。一般来说, 如果样本近似正态, t 检验是一个合理的选择; 如果两个样本不服从正态分布, Wilcoxon 秩和检验是一个更保守的选择。

二、(15 分) 给定模型 $\ln(y) = \alpha + \beta \ln(x) + \varepsilon$, 和一组观测值 $(x_i, y_i), i = 1, 2, \dots, n$ 。

(1) 请给出 β 的经济学含义。

(2) 请给出 β 的一个估计。

(3) 验证你上面给的估计的无偏性 (要给出相应的假设条件)

Solution:

(1) β 的经济学含义是 $\ln(x)$ 的百分比变化引起的 $\ln(y)$ 的百分比变化, 也就是 $\ln(x)$ 和 $\ln(y)$ 之间的弹性。

例如, 如果 $\beta = 0.5$, 那么当 $\ln(x)$ 增加 1%, $\ln(y)$ 就会增加 0.5%。

(2) β 的一个估计是最小二乘估计, 即使得残差平方和最小的值。残差平方和的定义为

$$S(\alpha, \beta) = \sum_{i=1}^n (\varepsilon_i)^2 = \sum_{i=1}^n (\ln(y_i) - \alpha - \beta \ln(x_i))^2$$

求解以下方程组, 得到最小二乘估计:

$$\begin{cases} \frac{\partial S}{\partial \alpha} = -2 \sum_{i=1}^n (\ln(y_i) - \alpha - \beta \ln(x_i)) = 0 \\ \frac{\partial S}{\partial \beta} = -2 \sum_{i=1}^n (\ln(y_i) - \alpha - \beta \ln(x_i)) \ln(x_i) = 0 \end{cases}$$

解得:

$$\hat{\beta} = \frac{n \sum_{i=1}^n (\ln(x_i) \ln(y_i)) - (\sum_{i=1}^n \ln(x_i)) (\sum_{i=1}^n \ln(y_i))}{n \sum_{i=1}^n (\ln(x_i))^2 - (\sum_{i=1}^n \ln(x_i))^2}$$

(3) 为了验证 $\hat{\beta}$ 的无偏性, 需要假设以下条件:

- $\mathbb{E}(\varepsilon_i | \mathbf{X}) = 0$, 即误差项的条件期望为零。

我们可以证明：

$$\mathbb{E}(\hat{\beta}) = \mathbb{E} \left(\frac{n \sum_{i=1}^n (\ln(x_i) \ln(y_i)) - (\sum_{i=1}^n \ln(x_i)) (\sum_{i=1}^n \ln(y_i))}{n \sum_{i=1}^n (\ln(x_i))^2 - (\sum_{i=1}^n \ln(x_i))^2} \right)$$

由于 $\ln(y_i) = \alpha + \beta \ln(x_i) + \varepsilon_i$ ，代入上式得：

$$\begin{aligned} \mathbb{E}(\hat{\beta}) &= \mathbb{E} \left(\frac{n \sum_{i=1}^n (\ln(x_i)(\alpha + \beta \ln(x_i) + \varepsilon_i)) - (\sum_{i=1}^n \ln(x_i)) (\sum_{i=1}^n (\alpha + \beta \ln(x_i) + \varepsilon_i))}{n \sum_{i=1}^n (\ln(x_i))^2 - (\sum_{i=1}^n \ln(x_i))^2} \right) \\ &= \frac{n \sum_{i=1}^n (\ln(x_i)(\alpha + \beta \ln(x_i))) - (\sum_{i=1}^n \ln(x_i)) (\sum_{i=1}^n (\alpha + \beta \ln(x_i)))}{n \sum_{i=1}^n (\ln(x_i))^2 - (\sum_{i=1}^n \ln(x_i))^2} \\ &= \frac{\alpha \cdot \{n \sum_{i=1}^n \ln(x_i)\} + \beta \cdot \{n \sum_{i=1}^n (\ln(x_i))^2\} - \alpha \cdot \{n \sum_{i=1}^n \ln(x_i)\} - \beta \cdot \{(\sum_{i=1}^n \ln(x_i))^2\}}{n \sum_{i=1}^n (\ln(x_i))^2 - (\sum_{i=1}^n \ln(x_i))^2} \\ &= \beta \end{aligned}$$

三、(15 分) 为准备研究生入学政治考试，很多学生花了不一样的时间在考试辅导班复习。当然还花了不一样的时间自己在家复习。请你设计一个回归模型，检验“在家复习的时间”与“在考试辅导班复习的时间”对最后考试成绩的影响是否一样。假设你可以得到随机抽取的 n 个考生在家复习的时间 x_i ，在考试辅导班复习的时间 z_i ，和她最后的考试成绩 y_i 。你还可以做其它你认为需要的合理的假设。请给出具体的模型和检验方法。

Solution:

可以考虑一个线性回归模型：

$$y_i = \alpha + \beta x_i + \gamma z_i + \varepsilon_i$$

其中， y_i 是第 i 个考生的考试成绩， x_i 是第 i 个考生在家复习的时间， z_i 是第 i 个考生在考试辅导班复习的时间， ε_i 是误差项。如果写成矩阵形式，记

$$\mathbf{Y} = (y_1, \dots, y_n)^\top, \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 & z_1 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix},$$

则有

$$\mathbf{Y} = \mathbf{X} \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix} + \boldsymbol{\varepsilon}.$$

该模型的常见假设是 Gauss-Markov 假设：

- $\mathbb{E}(\varepsilon_i) = 0$ ，即误差项的期望为零。
- $\mathbb{E}(\varepsilon_i | x_i, z_i) = 0$ ，即误差项和解释变量之间没有相关性。
- $\mathbb{E}(\varepsilon_i^2 | x_i, z_i) = \sigma^2$ ，即误差项的方差为常数。
- $\mathbb{E}(\varepsilon_i \varepsilon_j | x_i, x_j, z_i, z_j) = 0, i \neq j$ ，即不同观测值的误差项之间没有相关性。

要检验“在家复习的时间”与“在考试辅导班复习的时间”对最后考试成绩的影响是否一样，就是要检验 β 和 γ 是否相等。也就是说，要检验以下假设：

$$H_0 : \beta = \gamma \quad v.s. \quad H_1 : \beta \neq \gamma$$

根据最小二乘的回归结论, 我们有

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \\ \hat{\gamma} \end{pmatrix} \sim N \left(\begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix}, \sigma^2 V \right), \quad V = (\mathbf{X}^\top \mathbf{X})^{-1}.$$

要检验 H_0 , 直观来说就是看 $\hat{\theta} = \hat{\beta} - \hat{\gamma}$ 的大小. 由于 $\theta = (0, 1, -1) \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix}$, 我们有

$$\hat{\theta} \sim N(\theta, \sigma^2 v_\theta), \quad v_\theta = (0, 1, -1) V \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}.$$

在原假设成立时, 有

$$\hat{\theta} \sim N(0, \sigma^2 v_\theta),$$

然而其中 σ^2 是未知的, 需要用 $\hat{\sigma}^2 = \frac{SSE}{n-3}$ 去代替, 此时有

$$t = \frac{\hat{\beta} - \hat{\gamma}}{\sqrt{\hat{\sigma}^2 v_\theta}} \stackrel{H_0}{\sim} t(n-3).$$

拒绝域是 $W = \{|t| > t_{1-\alpha/2}(n-3)\}$.

根据自由度为 $n-3$ 的 t 分布表, 查找相应的临界值, 判断 t 统计量是否落在拒绝域内. 如果是, 则拒绝原假设, 即认为两种复习时间对考试成绩的影响不一样; 如果否, 则不能拒绝原假设, 即认为两种复习时间对考试成绩的影响没有显著差异.

此外, 也有另外一个检验方法. 即建立两个线性回归模型:

- Model 1: $y_i = \alpha + \beta x_i + \gamma z_i + \varepsilon_i$.

- Model 2: $y_i = \alpha + \beta(x_i + z_i) + \varepsilon_i$.

分别计算这两种模型下的 SSE, 记作 SSE_1 和 SSE_2 . 这里, 由于 Model 1 更自由, 因此一定有 $SSE_1 \leq SSE_2$. 我们可以看 $SSE_2 - SSE_1$ 的大小: 如果这个值很大则说明允许 $\beta \neq \gamma$ 可以非常有效地降低残差平方和; 如果差值很小则说明允许 $\beta \neq \gamma$ 并不能显著降低残差平方和.

具体的理论是约束回归的结论. 两个残差平方和 SSE_1 和 SSE_2 对应的自由度分别是 $n-3$ 和 $n-2$. 有平方和分解

$$SSE_2 = SSE_1 + (SSE_2 - SSE_1),$$

其中

$$\frac{SSE_1}{\sigma^2(n-3)} \sim \chi^2(n-3), \quad \frac{SSE_2 - SSE_1}{\sigma^2} \sim \chi^2(1),$$

且两者独立. 考虑原假设 $H_0: \beta = \gamma$, 我们可以构造 F 统计量

$$F = \frac{SSE_2 - SSE_1}{SSE_1/(n-3)} \sim F(1, n-3).$$

拒绝域是 $W = \{F > F_{1-\alpha}(1, n-3)\}$, 如果 F 统计量很大则拒绝原假设.

四、(20 分) 假定一个研究者要考查公司管理层的收入是否与公司管理的绩效有关, 收集相关数据建立了一个回归模型, 变量 y 为 CEO 年薪, 变量 x_1 为公司上一年年报收益, 变量 x_2 为公司上一年市场价格, 变量 x_3 为公司杠杆率, 变量 x_4 为公司大股东持股比例, 变量 x_5 为公司规模. 使用的回归模型为:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \varepsilon$$

(1) 请给出 CEO 年薪只与公司的报表收益和市场表现线性相关的零假设和备择假设, 给出假设检验需要的限制模型的形式和检验统计量。

(2) 假定通过上述 50 家公司的数据计算得到的 β_1 的估计值为 0.3, 相应的 t 统计量为 1.5。如果研究者又进一步随机的收集到了更多的数据, 共计收集了 200 家上市公司的数据, 使用 200 家公司数据重新估计模型, 请判断系数的估计值是否会改变, t 统计量大概会是多少, 模型的调整 R^2 是否会改变, 如果会改变, 给出变化的关系。

(3) 请讨论在上面的模型中, 如果公司的收益存在盈余管理, 可能会对估计的结果产生什么影响, 请说明理由, 并指出在什么假设条件下, 即使存在自变量的量度误差也不影响估计的无偏性?

Solution:

(1) CEO 年薪只与公司的报表收益和市场表现线性相关的零假设和备择假设是:

$$H_0: \beta_3 = \beta_4 = \beta_5 = 0 \quad v.s. \quad H_1: \beta_3 \neq 0 \text{ 或 } \beta_4 \neq 0 \text{ 或 } \beta_5 \neq 0$$

假设检验需要的限制模型的形式是:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

检验统计量是:

$$F = \frac{(SSE_R - SSE_U)/(df_R - df_U)}{SSE_U/df_U} \sim F(df_R - df_U, df_U)$$

其中, SSE_R 是限制模型的残差平方和, SSE_U 是不限制模型的残差平方和, df_R 是限制模型的自由度, df_U 是不限制模型的自由度。这里 $df_R = n - 3$, $df_U = n - 6$ 。因此 $F \sim F(3, n - 6)$ 。

根据 F 分布表, 查找相应的临界值, 判断 F 统计量是否落在拒绝域内。如果是, 则拒绝原假设, 即认为 CEO 年薪不仅与公司的报表收益和市场表现线性相关, 还与其他变量有关; 如果否, 则不能拒绝原假设, 即认为 CEO 年薪只与公司的报表收益和市场表现线性相关。

(2) 如果研究者又进一步随机地收集到了更多的数据, 共计收集了 200 家上市公司的数据, 使用 200 家公司数据重新估计模型:

系数的估计值可能会改变, 因为更多的数据可能会提供更多的信息, 从而影响参数的估计。 t 统计量可能会增大, 因为更多的数据可能会减少标准误差, 从而增加 t 统计量的绝对值。具体地, 如果 $\hat{\beta}_1$ 的估计值不变, 那么 t 统计量大概会是原来的 $\sqrt{4}$ 倍, 即 3; 如果 $\hat{\beta}_1$ 的估计值也改变了, 那么 t 统计量可能会更大或更小。

模型的调整 R^2 可能会改变, 因为更多的数据可能会影响模型对因变量的解释程度。具体地, 如果 SSE 不变或减小, 那么调整 R^2 会增大; 如果 SSE 增大超过一定程度, 那么调整 R^2 会减小。

因为没有确切的数据, 所以对于统计量的增大减小, 没有办法给出明确的结论。

(3) 在上面的模型中, 如果公司的收益存在盈余管理, 可能会对估计的结果产生以下影响:

如果盈余管理是随机的, 并且与 CEO 年薪无关, 那么它只会增加误差项 ε_i 的方差, 从而增加参数估计的标准误差和置信区间的宽度, 但不影响参数估计的无偏性和一致性。如果盈余管理是系统性的, 并且与 CEO 年薪有关, 那么它会导致解释变量 x_1 和误差项 ε_i 之间存在相关性, 从而造成内生性问题, 导致参数估计的偏误和不一致性。例如, 如果 CEO 年薪越高, 盈余管理越严重, 那么 β_1 的估计值可能会高估真实值, 因为它同时反映了 CEO 年薪对公司收益的直接影响和 CEO 年薪对盈余管理的间接影响。

在什么假设条件下, 即使存在自变量的量度误差也不影响估计的无偏性? 一个可能的假设条件是:

- 自变量的量度误差是随机的, 并且与真实值无关, 即 $\mathbb{E}(x_i^* - x_i) = 0$, $\mathbb{E}(x_i^* - x_i | x_i) = 0$, 其中 x_i^* 是观测值, x_i 是真实值。
- 自变量的量度误差与误差项无关, 即 $\mathbb{E}((x_i^* - x_i)\varepsilon_i) = 0$ 。

五、(15 分) 下表是从 Wind 资讯的行情数据中随机选取的部分中国同时在大陆的 A 股和香港 H 股上市的公司某一时刻的股票价格。假定我们希望通过这些资料来考查这两个市场是否存在定价的差异。收集到 16 家公司的行情报价数据分别为：

股票简称	A 股股价	B 股股价
中国银行	3.37	3.46
广发证券	18.03	17.18
工商银行	4.41	4.67
中国石油	7.29	5.32
中国神华	18.25	17.38
江西铜业	15.59	9.59
交通银行	5.64	5.94
中国铝业	3.99	2.91
中兴通讯	15.53	10.66
中国中铁	8.65	6.3
中国中车	9.34	6.9
万科	24.2	20.5
新华制药	13.75	5.73
新华保险	43.12	34.45
广深铁路	4.38	4.15
中国铁建	10.53	10.2

通过计算得到 16 家公司 A 股和 H 股的平均价格分别为：12.88 和 10.33，标准差分别为 10.15 和 8.36。（后面的回答使用符号和公式也可以）

- (1) 请给出以这些股票为代表的两个市场股票价格的 95% 的置信区间。
- (2) 请根据以上的信息资料给出一个对这两个市场股票价格定价是否存在差异的一个判断性结论。
- (3) 如果上述公司的选取是随机的，我们想得到一个分辨这两个市场定价差异的 1% 显著水平判断，你认为大概需要收集多少家公司的数据就可以了。

[先说题干的^{理解}]

- (i) 无需多言
- (ii) 最简单的方法是：配对样本 t 检验。也可以采取作商检验。
- (iii) 这里说“公司的选取是随机的”，应该指的是“不是配对样本，但是两个市场上的均值和标准差保持不变，求一个 n ”。因此，最简单的方法做第三题是用两个独立正态总体的 t 检验（可以直接假设方差相等）。

Solution:

(1) 这些股票为代表的两个市场股票价格的 95% 的置信区间是：

- A 股的置信区间：

$$\bar{x}_A \pm t_{\alpha/2,n-1} \frac{s_A}{\sqrt{n}}$$

其中， $\bar{x}_A$ 是 A 股的平均价格， $t_{\alpha/2,n-1}$ 是自由度为 $n-1$ 的 t 分布的上 $\alpha/2$ 分位数， s_A 是 A 股的标准差， n 是样本大小。代入数据得：

$$12.88 \pm 2.131 \frac{10.15}{\sqrt{16}}$$

化简得 12.88 ± 5.41 ，即 A 股的置信区间是 (7.47, 18.29)。

- H 股的置信区间:

$$\bar{x}_H \pm t_{\alpha/2, n-1} \frac{s_H}{\sqrt{n}}$$

其中, $\bar{x}_H$ 是 H 股的平均价格, $t_{\alpha/2, n-1}$ 是自由度为 $n-1$ 的 t 分布的上 $\alpha/2$ 分位数, s_H 是 H 股的标准差, n 是样本大小。代入数据得:

$$10.33 \pm 2.131 \frac{8.36}{\sqrt{16}}$$

化简得: 10.33 ± 4.45 , 即 H 股的置信区间是 (5.88, 14.78)。

(2) 我们构造配对样本 t 检验, 令 $d_i = A_i - B_i$ 表示第 i 家公司的 A 股与 B 股价格差值, 共有 $n = 16$ 组配对观测。根据题中数据计算得到:

$$\bar{d} = 2.55, \quad s_d = 4.56.$$

建立假设检验:

$$H_0: \mu_d = 0 \quad (\text{两市场不存在价格差异}), \quad H_1: \mu_d \neq 0 \quad (\text{两市场存在价格差异}).$$

配对样本 t 统计量为:

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} = \frac{2.55}{4.56/\sqrt{16}} = \frac{2.55}{1.14} = 2.24.$$

自由度为:

$$df = n - 1 = 15,$$

显著性水平 5% 下双尾检验的临界值为:

$$t_{0.025, 15} = 2.131.$$

比较统计量与临界值:

$$|t| = 2.24 > 2.131 = t_{0.025, 15}.$$

因此拒绝原假设 H_0 。

在 5% 显著性水平下, A 股与 B 股股票价格存在显著差异, 且 A 股价格显著高于 B 股价格。

(3) 根据双样本 t 检验 (非配对样本), 显著性水平设为 1%, 双尾临界值

$$z_{0.005} = 2.576.$$

要显著检验均值差异 $\Delta = 2.55$, 当样本量为 n 时, 两独立样本均值差的标准误为

$$SE = \sqrt{\frac{s_A^2 + s_B^2}{n}} = \sqrt{\frac{103.02 + 69.86}{n}} = \sqrt{\frac{172.88}{n}}.$$

显著性条件为

$$\frac{\Delta}{SE} \geq 2.576.$$

因此需要 $n \geq \frac{172.88}{\left(\frac{2.55}{2.576}\right)^2} = \frac{172.88}{0.990^2} \approx 176.3$.

因此，若希望在 1% 显著性水平下显著检验两市场均值差异，大约需要每个市场各收集 $n \approx 176$ 家公司的数据。

· 2017 微观部分解析

一、(15 分) 考虑下面三种情形，并分别作答：

1. 一个消费者消费牛肉 (b) 和胡萝卜 (c)，效用函数为 $U(b, c) = b^{0.5}c^{0.5}$ ，她的初始赋予为 2 公斤牛肉和 3 公斤胡萝卜，她可以在市场上出售自己已有的赋予。请问是否存在一组市场价格使她愿意直接消费自己的赋予。

2. 一个消费者消费饮料 (b) 和薯片 (c)，他的效用函数是 $U(b, c) = \min\{b, c\}$ ，他对于两种商品的初始赋予为 2 公斤薯片和 3 升饮料，他可以在市场上出售自己已有的赋予。请问是否存在一组市场价格使他愿意直接消费自己的赋予。

3. 护林员甲住在郊连山深处，他消费两种产品，汽油和牛肉面。由于他的住处距离最近的牛肉面馆 30 公里，去吃面要开车前往，他每天必须先消耗 6 升汽油，余下的钱全部用于购买牛肉面。请问他的偏好可以用无差异曲线描述吗？如果可以，请画图。

Solution:


(1) 根据赋予算出自己的需求量，使需求量等于赋予即可存在。设牛肉价格为 p ，胡萝卜价格为 1，则有

$$\max v = b^{0.5}c^{0.5}, \quad \text{s.t.} \quad pb + c = 2p + 3$$

解得： $b = \frac{2p+3}{2p}$, $c = \frac{2p+3}{2}$. 令 $b = 2$ ，得 $p = \frac{3}{2}$ 。

(2) 不存在， $v = \min(b, c)$ 最优点在 $b = c$ 处实现，由于初始 $b \neq c$ ，故无法实现消费其赋予。

(3) 必须先消费的汽油量是一定的，剩余的钱不论有多少都是花在牛肉面上。此时钱的增加只反映在牛肉面上，也即汽油无收入效应，牛肉面有收入效应。此时应为拟线性的无差异曲线，收入效应全部体现牛肉面上。



二、(15 分) 一个农民有 10000 元资金，年初他可以用来购买水稻种子 (s) 以及保险 (i)。如果该年天气好，他可以消费水稻种植的产出，产出的大米量 (公斤) 为 $y = 10s^{0.5}$ ；如果天气不好则水稻绝收，他的消费完全来

自保险公司的理赔，保险公司就每份保险赔付给他一公斤大米。天气好的概率为 $\pi = 0.8$ ，种子价格 (p) 为每公斤 1 元，保险价格 (q) 为 2 元一份。

1. 假设农民的效用函数为 $U = \pi \log(C_1) + (1 - \pi) \log(C_2)$ ， C_1 和 C_2 分别是天气好和天气不好的大米消费量。请问他会买多少公斤种子，多少份保险？

2. 假设农民的效用函数为 $U = \min\{\log(C_1), \log(C_2)\}$ ，请问他会买多少公斤种子？

Solution:

(1) 解：农民的目标决策是：

$$\begin{aligned} \max U &= \pi \log(C_1) + (1 - \pi) \log(C_2) \\ \text{s.t. } &s + 2i = 10000 \\ &C_1 = 10s^{0.5}, \quad C_2 = i, \quad \pi = 0.8 \end{aligned}$$

代入整理得：

$$\max U = 0.8 \log(10) + 0.4 \log(10000 - 2i) + 0.2 \log(i)$$

一阶条件 (F.O. C.) 为：

$$0.4 \cdot \frac{-2}{10000 - 2i} + 0.2 \cdot \frac{1}{i} = 0$$

解得：

$$i = \frac{5000}{3}, \quad s = \frac{20000}{3}$$

因此，农民会购买 $\frac{20000}{3}$ 单位种子， $\frac{5000}{3}$ 单位保险。

(2) 解：农民的目标决策是：

$$\begin{aligned} \max U &= \min\{\log(C_1), \log(C_2)\} \\ \text{s.t. } &s + 2i = 10000 \\ &C_1 = 10s^{0.5}, \quad C_2 = i \end{aligned}$$

最优时，必有 $\log(C_1) = \log(C_2)$ 成立，即 $C_1 = C_2$ 。因此，

$$10s^{0.5} = i$$

代入约束条件，得：

$$0.01 \cdot i^2 + 2i - 10000 = 0$$

解得：

$$i = -100 \pm 50\sqrt{404} \approx -100 + 1000$$

舍去负数解，得 $i = 900$ ， $s = 8100$ 。

三、(15 分) 假设城市 W 由两座电厂 (A 和 B) 提供电力。A 和 B 均是热电厂，燃煤烧煤供电的同时会排放空气污染物。为改善空气质量，W 市决定要求 A 和 B 电厂减排。A 电厂减少排放 x_A 万吨污染物的总成本为 $C_A(x_A) = 3x_A^2$ 。B 电厂减少排放 x_B 万吨污染物的总成本为 $C_B(x_B) = 5x_B^2 + 10x_B$ 。W 市政府聘请了环保专家评估减少污染物排放将会给 W 市带来的收益。经测算，如果 A 和 B 分别减排 x_A 和 x_B 万吨，W 市获得的总收益为： $120 \times (x_A + x_B)$ 。请依据以上信息回答下列问题：

1. 计算 A 和 B 的社会最优减排量。2. W 市政府希望通过征收“排污税”降低 A 和 B 的污染物排放量。

(a) 请问 W 市政府需对每万吨污染物征收多少“排污税”才能使 A 和 B 分别达到第 (1) 题的最优排量？

(b) W 市征收如上“排污税”的情形下，请用等式列出 A 和 B 电厂各自决定减排量所面对的优化问题。并证明 A 和 B 各自选择的最优减排量与第 (1) 题中的社会最优减排量相同。3. 假设 W 市政府决定停止征收“排

污税”，并出台相关规定强制要求电厂减少污染物排放量。有建议称 W 市政府要求 A 和 B 电厂每年分别减排 1 万吨污染物。请通过数学推导与文字说明论证这个建议并不是最有效率的。

Solution:

(1) 社会最优的减排量决策是：

$$\max 120 \cdot (x_A + x_B) - 3 \cdot x_A^2 - 5 \cdot x_B^2 - 10 \cdot x_B$$

一阶条件 (F.O. C.) 为：

$$120 - 6x_A = 0$$

$$120 - 10x_B - 10 = 0$$

解得：

$$x_A = 20, \quad x_B = 11$$

(2) (a) 应对每万吨污染物征税 $t = 120$ 。

(b) 在 $t = 120$ 的情况下，A 电厂的决策目标是减少排放总成本最小化：

$$\min 3 \cdot x_A^2 - 120 \cdot x_A$$

一阶条件为：

$$6x_A - 120 = 0$$

解得 $x_A = 20$ ，B 电厂的决策目标是减少排放总成本最小化：

$$\min 5 \cdot x_B^2 + 10 \cdot x_B - 120 \cdot x_B$$

一阶条件为：

$$10x_B + 10 - 120 = 0$$

解得 $x_B = 11$ ，与 (1) 题中的社会最优减排量相同。

(3) 考虑社会总效益的表达式：

$$120 \cdot (x_A + x_B) - 3 \cdot x_A^2 - 5 \cdot x_B^2 - 10 \cdot x_B$$

如果 $x_A = x_B = 1$ ，一阶条件为：

$$120 - 6x_A > 0$$

$$120 - 10x_B - 10 > 0$$

这说明，增加 x_A 和 x_B 会增加社会总效益。因此，各减排 1 万吨污染物并不是最有效率的。

四、(30 分) 公司 1 和公司 2 生产相同的产品，而且成本为 0。两个公司同时选择生产数量，分别满足 $q_1 \geq 0$ 和 $q_2 \geq 0$ 。与之相对应的需求函数是 $P(q) = 12 - q$ ，其中 $q = q_1 + q_2$ 。

1. 找到本博弈的纳什均衡 (q_1, q_2) ，以及纳什均衡下两个公司的利润。

2. 假定公司 2 被强迫生产 $q_2 = 0$ ，而公司 1 是一个垄断经营者，面对的需求函数是 $P(q) = 12 - q$ 且成本为 0。公司 1 的利润是多少？

3. 现在假定这个博弈过程有三个阶段。

- 第一步骤：公司 1 选择是否给予公司 2 一笔贿赂，让公司 2 不参与市场竞争。

- 第二步骤：公司 2 决定是否接受公司 1 的贿赂并不参加市场竞争。

- 第三步骤 a：如果公司 2 接受了公司 1 的贿赂，那么公司 1 就是这个市场上的垄断经营者。公司 1 的成本依然为 0，面对的需求函数数量是 $P(q) = 12 - q$ 。因此公司 1 会获得垄断者的利润，而公司 2 获得这笔贿赂。

- 第三步骤 b: 如果公司 2 拒绝了这笔贿赂, 那么两个公司会进行第 (1) 问中所描述的生产博弈, 他们的利润也如第 (1) 问中所计算。

请找到这一新规则下的子博弈完美均衡 (subgame perfect equilibrium) 策略。在这一博弈完美均衡下, 公司 1 和公司 2 的利润分别是多少?

4. 现在假定有一个新的公司 3 加入这个市场, 公司 3 的产量为 $q_3 \geq 0$, 单位成本为 2。与之相对应的需求函数是 $P(q) = 12 - q$, 其中 $q = q_1 + q_2 + q_3$ 。找到本博弈的纳什均衡 (q_1, q_2, q_3) , 以及纳什均衡下三个公司的利润。

5. 现在假定这个博弈过程有三个阶段。

- 第一步骤: 公司 1 选择是否给予公司 3 一笔贿赂, 让公司 3 不参与市场竞争。
- 第二步骤: 公司 3 决定是否接受公司 1 的贿赂并不参加市场竞争。
- 第三步骤 a: 如果公司 3 接受了公司 1 的贿赂, 那么公司 1 和公司 2 就继续第 (3) 问中所描述的博弈。
- 第三步骤 b: 如果公司 3 拒绝了这笔贿赂, 那么三个公司会进行第 (4) 问中所描述的生产博弈, 他们的利润也如第 (4) 问中所计算。

请找到这一新规则下的子博弈完美均衡策略。在这一子博弈完美均衡下, 公司 1、公司 2 以及公司 3 的利润分别是多少?

Solution:

(1) 给定公司 1 的产量, 公司 2 的决策是:

$$\max \pi_2 = (12 - q_1 - q_2)q_2$$

F.O. C.:

$$12 - 2q_2 - q_1 = 0$$

给定公司 2 的产量, 公司 1 的决策是:

$$\max \pi_1 = (12 - q_1 - q_2)q_1$$

F.O. C.:

$$12 - 2q_1 - q_2 = 0$$

解得:

$$q_1 = q_2 = 4, \quad \pi_1 = \pi_2 = 16$$

(2) 公司 1 的垄断利润最大化决策是:

$$\max \pi_1^m = (12 - q_1)q_1$$

F.O. C.:

$$12 - 2q_1 = 0$$

解得: $q_1 = 6$, 垄断利润为 $\pi_1^m = 36$ 。

(3) 设贿赂金额为 A 。

** 公司 2 的提炼策略: ** - 第二阶段: 若公司 1 贿赂金额 $A \geq 16$, 则接受贿赂金; 若 $A < 16$, 则拒绝贿赂金。- 第三阶段: 若第二阶段接受了贿赂金, 则退出竞争; 若第二阶段拒绝了贿赂金, 或者公司 1 不贿赂, 此时选择古诺产量 $q_2 = 4$, 获得古诺利润 16。

** 公司 1 的提炼策略: ** - 第一步骤: 选择贿赂, 金额 $A = 16$ 。- 第三阶段: 若公司 2 接受贿赂, 那么生产 $q_1 = 6$, 获得垄断利润 20; 若公司 2 拒绝贿赂, 那么公司 1 在第三阶段生产 $q_1 = 4$, 获得古诺利润 16。

均衡结果：公司 1 贿赂金额为 $A = 16$ ，公司 2 接受赎赎金，公司 1 垄断市场。

$$\pi_1 = 20, \quad \pi_2 = 16.$$

(4) 此时求解三个企业的古诺均衡，注意：企业 3 边际成本 > 0 。给定公司 2 和 3 的产量 q_2, q_3 ，公司 1 的决策是：

$$\max \pi_1 = (12 - q_1 - q_2 - q_3)q_1$$

F.O. C.:

$$12 - 2q_1 - q_2 - q_3 = 0$$

给定公司 1 和 3 的产量 q_1, q_3 ，公司 2 的决策是：

$$\max \pi_2 = (12 - q_1 - q_2 - q_3)q_2$$

F.O. C.:

$$12 - 2q_2 - q_1 - q_3 = 0$$

给定公司 1 和 2 的产量 q_1, q_2 ，公司 3 的决策是：

$$\max \pi_3 = (12 - q_1 - q_2 - q_3)q_3$$

F.O. C.:

$$12 - 2q_3 - q_1 - q_2 = 0$$

解上述三个一阶条件，有：

$$q_1 = q_2 = 3.5, \quad q_3 = 1.5$$

此时各企业利润为：

$$\pi_1 = \pi_2 = 12.25, \quad \pi_3 = 2.25.$$

(5) 记公司 1 给公司 3 的贿赂金额为 B ，给公司 2 的贿赂金额为 A 。

我们作下述分析：

**** 考虑公司 3****：

(i) 若 $B \geq 2.25$ ，则接受贿赂；(ii) 若 $B < 2.25$ ，则拒绝贿赂。因此，若公司 1 决定贿赂公司 3，则最优的 $B = 2.25$ 。

**** 公司 3 接受贿赂之后，如果公司 1 贿赂公司 2：**

(i) 若 $A \geq 16$ ，则公司 2 接受赎赎并不参与竞争；(ii) 若 $A < 16$ ，则公司 2 拒绝贿赂。因此，若公司 1 决定贿赂公司 2，则最优的 $A = 16$ 。

**** 总结 ****：

(i) 若公司 1 贿赂公司 2，应选择 $A = 16$ ， $B = 2.25$ ，此时公司 2 接受贿赂，公司 1 获得垄断利润 $\pi_1^m = 36 - 16 - 2.25 = 17.75$ ；(ii) 若公司 1 不贿赂公司 2 且贿赂公司 3，会获得古诺利润

$$\pi_1 = 16 \quad \pi_1 = 16 < 17.75.$$

(iii) 若公司 1 不贿赂公司 2 且不贿赂公司 3，会获得古诺利润

$$\pi_1 = 12.25 \quad \pi_1 = 12.25 < 16 < 17.75.$$

因此，公司 1 会决定贿赂，一定贿赂到底（贿赂公司 2 和公司 3），最终获得 17.25 的垄断利润。

**** 公司 1 的精炼策略 ****：

1. 第一阶段：给公司 3 贿赂金额 $B = 2.25$

2. 第三阶段：

- 若公司 3 拒绝贿赂，则公司 1 生产古诺产量 3.5，获得利润 12.25；
- 若公司 3 接受贿赂，则继续给公司 2 贿赂，金额 $A = 16$ ：
 - 若公司 2 接受，则生产垄断产量 6，获得利润 18.75；
 - 若公司 2 拒绝，则生产古诺产量 4，获得利润 $16 - B = 13.75$ 。

** 公司 2 的提炼策略 **：

1. 第三阶段：

- 若公司 3 拒绝贿赂，那么公司 2 生产古诺产量 3.5，获得利润 12.25；
- 若公司 3 接受贿赂（此时公司 3 退出市场竞争，只有 1 和 2），那么：
 - 当公司 1 贿赂金额 $A \geq 16$ 时，接受贿赂，退出市场竞争；
 - 当公司 1 贿赂金额 $A < 16$ 时，拒绝贿赂，生产古诺产量 4，获得利润 16。

** 公司 3 的提炼策略 **：

1. 第二阶段：

- 若公司 1 贿赂金额 $B \geq 2.25$ ，接受贿赂；
- 若公司 1 贿赂金额 $B < 2.25$ ，拒绝贿赂。

2. 第三阶段：

- 若接受了公司 1 的贿赂，退出市场竞争；
- 若拒绝了公司 1 的贿赂，生产古诺产量 1.5，获得利润 2.25；
- 若公司 1 在第一阶段不贿赂自己，生产古诺产量 $q_1 = 1.5$ ，获得利润 2.25。

在各方的提炼策略下，均衡结果：公司 1 贿赂 $A = 16$ ， $B = 2.25$ ，获得垄断利润 17.75；公司 2 和 3 接受贿赂后退出市场竞争。

北京大学-431 金融学综合-2018

2018 统计部分解析

一、(15 分) 解释或回答以下概念及问题:

(1) (5 分) 随机变量 X 和 Y 的相关性。

(2) (5 分) 随机变量 X 和 Y 的独立性。

(3) (5 分) 如果 X 和 Y 不相关, 那么 X 和 Y 是否独立? 请具体论述。

Solution:

(1) 随机变量 X 和 Y 的相关性可以用相关系数来度量, 相关系数的定义是

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

其中 $\text{Cov}(X, Y)$ 是协方差, $\text{Var}(X)$ 和 $\text{Var}(Y)$ 是方差。相关系数的绝对值越接近 1, 表示相关性越强; 相关系数为正, 表示正相关, 即一个变量增大时另一个变量也增大; 相关系数为负, 表示负相关, 即一个变量增大时另一个变量减小; 相关系数为 0, 表示不相关, 即两个变量之间没有线性相关关系。

(2) 随机变量 X 和 Y 的独立性可以用联合分布函数和边缘分布函数, 或者联合概率密度和边缘概率密度来判断, 如果两个随机变量的联合分布(密度)等于两个随机变量的边缘分布(密度)的乘积, 那么两个随机变量就是独立的。即 $F_{XY}(x, y) = F_X(x)F_Y(y)$ 或者 $f_{XY}(x, y) = f_X(x)f_Y(y)$, 否则我们说两个随机变量不独立。

(3) 如果 X 和 Y 不相关, 那么 X 和 Y 不一定独立。因为不相关只能说明两个随机变量之间没有线性关系, 但不能排除其他非线性关系。例如, 如果 X 是一个均匀分布在 $[-1, 1]$ 的随机变量, 而 $Y = X^2$, 那么

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = E(X^3) - E(X)E(X^2) = 0 - 0 = 0$$

但显然 X 和 Y 不是独立的。

二、(15 分) 给定模型 $y_i = bx_i + \varepsilon_i$, 随机误差项 $\varepsilon_i \sim N(0, \sigma^2)$ 相互独立, 其中 $\sigma^2 > 0$ 未知, 现收集到数据 (x_i, y_i) , $i = 1, 2, \dots, n$.

(1) (5 分) 请给出 b 的最小二乘估计量 $\hat{b}$ 。

(2) (5 分) 求 $\hat{b}$ 的期望、方差和分布。

(3) (5 分) 对于检验问题 $H_0: b = 0$ vs $H_1: b > 0$, 给出检验法。

Solution:

(1) b 的最小二乘估计量 $\hat{b}$ 是使得残差平方和

$$S(b) = \sum_{i=1}^n (y_i - bx_i)^2$$

最小的值。对 $S(b)$ 求导并令其等于 0, 得到

$$\frac{\partial S(b)}{\partial b} = -2 \sum_{i=1}^n (y_i - bx_i)x_i = 0$$

$$\text{解得 } \hat{b} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}.$$

(2) 考虑到 $\hat{b}$ 是 $y_1, y_2, \dots, y_n$ 的线性函数, 且 $y_1, y_2, \dots, y_n$ 具有联合正态分布, 因此估计量也是正态分布, 故只需求其期望与方差。

$\hat{b}$ 的期望是

$$E(\hat{b}) = \frac{\sum_{i=1}^n x_i E(y_i)}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n x_i (bx_i)}{\sum_{i=1}^n x_i^2} = b$$

$\hat{b}$ 的方差是

$$Var(\hat{b}) = \frac{\sum_{i=1}^n x_i^2 Var(y_i)}{(\sum_{i=1}^n x_i^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}$$

$\hat{b}$ 的分布是正态分布, 即 $\hat{b} \sim N(b, \frac{\sigma^2}{\sum_{i=1}^n x_i^2})$.

(3) 对于检验问题 $H_0: b = 0$ vs $H_1: b > 0$, 可以使用单侧 t 检验法。构造统计量

$$t = \frac{\hat{b} - 0}{\sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n x_i^2}}},$$

其中 $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \hat{b}x_i)^2$, 在原假设成立时, 该统计量服从自由度为 $n-1$ 的 t 分布.

则根据给定的显著性水平 α , 查表得到临界值 $t_{1-\alpha}(n-1)$, 如果观察到的统计量值 t 大于临界值 $t_{1-\alpha}(n-1)$, 则拒绝原假设; 否则不拒绝原假设.

三、(10 分) 工商局抽查了 N 家小微企业, 发现 M 家企业存在违规行为。请你设计一个统计模型, 检验企业主的性别男女与违规行为是否有关。

Solution:

可以使用卡方检验法。卡方检验法是一种用于分析两个分类变量之间是否有关联的方法。在这个问题中, 两个分类变量分别是企业主的性别(男或女)和企业是否存在违规行为(是或否)。我们可以用一个二维列联表来表示这两个变量的频数分布, 如下:

	违规	未违规	总计
男	a	b	$a+b$
女	c	d	$c+d$
总计	$a+c$	$b+d$	N

其中, a, b, c, d 是观察到的频数, $N = M + (N - M)$ 是总样本数。我们的假设检验问题是:

H_0 : 性别与违规行为无关

H_1 : 性别与违规行为有关

我们可以构造统计量

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^2 \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

其中, O_{ij} 是第 i 行第 j 列的观察频数, E_{ij} 是第 i 行第 j 列的期望频数, 根据原假设和边际分布计算得到 $E_{ij} = \frac{(O_{i\cdot})(O_{\cdot j})}{N}$ 在原假设成立时, 该统计量近似服从自由度为 $(r-1)(c-1)$ 的卡方分布, 其中 r, c 分别是行数和列数。根据给定的显著性水平 α , 查表得到临界值 $\chi_{1-\alpha}^2((r-1)(c-1))$. 如果观察到的统计量值 χ^2 大于临界值, 则拒绝原假设; 否则不拒绝原假设。

四、(15 分) 在股票交易系统中, 任何一只股票连续两次交易的时间间隔 t_i 服从泊松分布。现有两只股票一周的全部交易数据, 请检验这两只股票是否服从同一泊松分布。

Solution: 用 λ_1, λ_2 表示两个泊松分布的参数, 而 $\bar{X}$ 和 $\bar{Y}$ 分别表示两只股票的交易间隔时间均值, 则根据中心极限定理有 $\sqrt{n}(\bar{X} - \lambda_1) \rightarrow_d N(0, \lambda_1), \sqrt{m}(\bar{Y} - \lambda_2) \rightarrow_d N(0, \lambda_2)$, 因此有

$$\frac{(\bar{X} - \bar{Y}) - (\lambda_1 - \lambda_2)}{\sqrt{\frac{\lambda_1}{n} + \frac{\lambda_2}{m}}} \rightarrow_d N(0, 1),$$

在原假设成立时, $\lambda_1 = \lambda_2$ 且可由两组样本的共同均值 $\hat{\lambda}_0 = \frac{n\bar{X} + m\bar{Y}}{n+m}$ 估计, 且根据大数定律有 $\hat{\lambda}_0 \xrightarrow{p} \lambda_1$. 故根据 Slutsky 定理, 有

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{n\bar{X} + m\bar{Y}}{nm}}} \rightarrow_d N(0, 1).$$

而 Z 可以作为检验统计量, 临界值为 $z_{1-\alpha/2}$, 其中 α 是检验的显著性水平, 当 $|Z| < z_{1-\alpha/2}$ 时接受原假设, 即认为两只股票服从同一泊松分布.

五、(20 分) 假定一个研究者要考查公司管理层的收入是否与公司管理的绩效有关, 收集相关数据建立了一个回归模型, 变量 y 为 CEO 年薪, 变量 x_1 为公司上一年年报收益, 变量 x_2 为公司上一年市场价格, 变量 x_3 为公司盈利能力, 变量 x_4 为公司规模. 使用的回归模型为:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \varepsilon$$

- (1) 如果只利用收集到的 20 家公司进行分析, 是否合适? 如不合适, 请给出原因.
- (2) 如果通过收集数据, 将公司数量增加到 80 家, 使用这些数据重新估计模型, 请判断系数的估计值是否会改变, t 统计量的值是否会改变. 模型的调整 R^2 是否会改变, 如果会改变, 给出其化关系.
- (3) 如果通过上述 80 家公司, 发现模型的 R^2 并不低, 但所有变量的系数都不显著. 请你分析可能存在的原因, 以及如何改进?

Solution:

(1) 如果只利用收集到的 20 家公司进行分析, 可能不太适合, 因为样本量太小, 未知参数的数量是 5 个, 这可能导致回归模型的估计不稳定或不显著.

(2) 如果通过收集数据, 将公司数量增加到 80 家, 使用这些数据重新估计模型, 系数的估计值可能会改变, 因为数据的变化可能影响到回归方程的拟合效果. t 统计量的值也可能会改变, 因为 t 统计量与系数的估计值和标准误差有关. 模型的调整 R^2 可能会改变, 因为调整 R^2 与样本量和自由度有关. 一般来说, 当样本量增加时, 调整 R^2 会越来越接近 R^2 .

(3) 如果通过上述 80 家公司, 发现模型的 R^2 并不低, 但所有变量的系数都不显著. 可能存在的原因有:

- 变量之间存在多重共线性, 即自变量之间相关性较高, 导致系数的估计不准确或不稳定.
- 模型存在异方差性, 即误差项的方差随着自变量的变化而变化, 导致标准误差的估计偏大或偏小.
- 模型存在遗漏变量偏误, 即忽略了一些重要的自变量, 导致系数的估计受到干扰或偏离真实值.

可能改进的方法:

- 检测并消除多重共线性, 可以使用方差膨胀因子 (VIF) 等指标来判断自变量之间是否存在共线性问题, 并尝试删除或合并一些相关性较高的自变量.
- 检测并消除异方差性, 可以使用 White 检验等方法来检验模型是否存在异方差性, 并使用加权最小二乘法 (WLS) 等方法来修正异方差性带来的影响.
- 检测并消除遗漏变量偏误, 可以使用重要性分析等方法来评估自变量对因变量的影响程度, 并尝试添加一些可能相关的自变量.

2018 微观部分解析

一、(20 分) 假设明天的世界有两种气象状态, 晴天或雨天. 晴天时, 消费者可固定享受收益 y_1 碗热干面. 雨天时, 其收益 y_2 是随机的, 具有一半概率为 y_H , 另一半概率为 y_L , 且 $y_H > y_L$. 消费者的偏好是 $U = \min\{E(c_1), E(c_2)\}$, 其中 c_1 和 c_2 分别表示明天在晴天和雨天两种状态下, 消费者所获得的热干面数量, E 表示基于今天信息的数学期望.

公司 C 在今天的期货市场上交易两种状态下的热干面期货, 价格分别为 p_1 和 p_2 . 消费者可以以 p_1 的价格向公司 C 购买晴天的热干面期货, 即今天支付 p_1 , 如果明天是晴天, 则公司 C 提供 1 碗热干面. 如果明天是雨天, 则公司 C 不提供该商品.

消费者的目标是在今天进行期货交易以满足不同气象状态下的期望收益, 假设消费者在今天没有任何初始收益.

1. (5 分) 写出在今天的期货市场上的预算约束。2. (10 分) 求 x_1 的表达式。3. (3 分) x_1 一定是负的吗? 4. (2 分) 若 p_1, p_2 均翻倍, 对 x_1 有何影响?

Solution:

- (1) 由题意, 消费者在今天没有任何初始财富, 即预算约束可表示为:

$$p_1 x_1 + p_2 x_2 = 0$$

- (2) 消费者的目标是最大化效用函数:

$$\max U = \min\{E(c_1), E(c_2)\}$$

其中 $c_1 = y_1 + x_1$, $c_2 = y_2 + x_2$ 。期望收益 $E(c_1) = y_1 + x_1$, $E(c_2) = \frac{y_H + y_L}{2} + x_2$ 。将预算约束代入, 解得

$$x_1 = \frac{p_2}{p_1 + p_2} \left(\frac{y_H + y_L}{2} - y_1 \right)$$

- (3) 根据上式, x_1 的正负取决于 $\frac{y_H + y_L}{2}$ 和 y_1 的大小。当 $\frac{y_H + y_L}{2} > y_1$ 时, $x_1 > 0$; 当 $\frac{y_H + y_L}{2} < y_1$ 时, $x_1 < 0$ 。

- (4) 如果 p_1, p_2 均翻倍, 预算约束仍然为:

$$2p_1 x_1 + 2p_2 x_2 = 0$$

可化简为 $p_1 x_1 + p_2 x_2 = 0$, 所以 x_1 不受影响。

二、(20 分) 考虑一个有三家公司各自生产产品参加的博弈。如果每家公司 i 选择自己公司商品的价格 $P_i \in [0, +\infty)$, 那么这家公司的销售数量是 $1 - P_i + k \sum_{-i} P_j = 1 - P_i + k \sum_{j \neq i} P_j$, 边际成本为 $c_i > 0$ 。请计算每家企业的商品价格以及获得的利润。

Solution:

- (1) 公司 i ($i = 1, 2, 3$) 的决策:

$$\max \pi_i = (P_i - c_i)(1 - P_i + k \sum_{-i} P_j)$$

一阶条件 (F.O. C.):

$$1 - 2P_i + k \sum_{-i} P_j + c_i = 0$$

** 加总每一个一阶条件 **, 得:

$$3 - 2 \sum P_i + 2k \sum P_i + \sum c_i = 0$$

以及

$$\sum P_i = \frac{3 + \sum c_i}{2 - 2k}$$

由于

$$\sum P_i = \frac{3 + \sum c_i}{2 - 2k}$$

表达式比较繁琐, 为了简化分析, 可令

$$\sum P_i = \frac{3 + \sum c_i}{2 - 2k} = A$$

这样, 企业 i 的一阶条件为:

$$1 - 2P_i + k \sum_{-i} P_j + c_i = 0$$

变形得到

$$1 - 2P_i - kP_i + k \sum P_j + c_i = 0$$

因此企业 i 的均衡价格为:

$$P_i = \frac{1 + c_i + kA}{2 + k}, \text{ 其中 } A = \frac{3 + \sum c_i}{2(1 - k)}$$

企业 i 的均衡利润为:

$$\begin{aligned} \pi_i &= (P_i - c_i) \left(1 - P_i + k \sum_{-i} P_j \right) \\ &= (P_i - c_i) [1 - P_i + k(A - P_i)] \\ &= (P_i - c_i) [1 + kA - (1 + k)P_i] \\ &= \frac{1 + c_i + kA}{2 + k} \left[1 + kA - (1 + k) \frac{1 + c_i + kA}{2 + k} \right] \end{aligned}$$

最后, 代入 $A = \frac{3 + \sum c_i}{2(1 - k)}$, 得:


$$\pi_i = \left(\frac{1 + c_i + k \cdot \frac{3 + \sum c_i}{2(1 - k)}}{2 + k} \right)^2 = \left(\frac{(1 + c_i)(2 - 2k) + k(3 + \sum c_i)}{(2 + k)(2 - 2k)} - c_i \right)^2.$$

三、(10 分) 有两种商品 x 和 y , 小丽的效用函数为 $u = x + y$, 小贾的效用函数为 $u = \max\{x, y\}$ 。

1. (3 分) 请用无差异曲线在埃奇沃思矩形图中表示两个人的偏好。
2. (3 分) 请猜想 x 和 y 的均衡价格有什么关系?
3. (4 分) 猜猜在均衡的情况下, 分配结果会是什么样?

Solution:

(1) 如图所示:



(2) x 和 y 的均衡价格比 $\frac{P_x}{P_y} = 1$; 理由如下: (i) 如果 $\frac{P_x}{P_y} > 1$, 那么无人会购买商品 x , 无法形成均衡; (ii) 如果 $\frac{P_x}{P_y} < 1$, 那么无人会购买商品 y , 无法形成均衡。

(3) 根据上面的分析, 商品均衡价格比只能为 1。分配结果的特征: 至少有一人拥有某种商品的全部份额。

四、(25 分) 某市正规划新建一个音乐会场地。假设城市中有两个居民: 小丽 (L) 和小贾 (J)。居民的个入捐赠将成为建造该场地经费的唯一来源。假设两位居民对于私有品 (X_i) 和场地总尺寸 (S) 的效用函数为 $U_i(X_i, S) = 0.5 \ln(X_i) + 0.5 \ln(S)$, 场地总尺寸即为其总座位数 S , 等于由小丽和小贾各自捐赠的座位数之和, 即 $S = S_L + S_J$ 。小丽的收入为 200, 小贾的收入为 100。假设私有品和座位数的单位价格均为 1。

1. (5 分) 如果政府不干预的话, 该场地将会建造多少座位? 其中多少是由小丽捐赠的, 多少是由小贾捐赠的呢?

2. (5 分) 总座椅数的社会最优解是多少? 如果你的答案与 (1) 不同, 请解释原因。

现在, 假设一个座位的价格从 1 变为 P_S , 而私有品的价格仍为 1, 在改变价格的同时, 小丽和小贾的收入按照如下方式相应改变: 当价格变为 P_S 时, 小丽和小贾的预算约束增加了 C_L 和 C_J , 其中 $C_L = (P_S - 1)S_L$, $C_J = (P_S - 1)S_J$ 。增加后的预算约束称为补偿预算约束。

3. (5 分) 写下小丽和小贾的补偿预算约束的表达式。你觉得它们为什么被称作“补偿约束”?

4. (10 分) 通过需求曲线的纵向加总, 求出社会最优解。

(a) 按如下方式推导 S 的逆需求曲线:

i. 满足补偿约束运算的前提下, 最大化小丽和小贾的需求曲线。注意在求导之前, 不要代入 C_L 和 S_J 的表达式。

ii. 对于小丽和小贾, 求解 S_L 和 S_J , 作为 P_S 的自变量的函数形式。请使用你在 (i) 中得到的结果推导社会需求曲线。

(b) 回到 $P_S = 1$, $P_X = 1$ 的初始设定。请通过使社会需求曲线与社会供给曲线 (即场地座位的边际成本) 相等, 找到座椅数的社会均衡数量。和 (2) 结果相比, 是否不同?

Solution: (1) 若政府不干预, 小丽和小贾将分别决策, 最大化自身的效用。记小丽和小贾的收入分别为 $M_L = 200$, $M_J = 100$ 。

$$\max U_i = 0.5 \ln(X_i) + 0.5 \ln(S) \quad \text{s.t.} \quad P_X X_i + P_S S_i = M_i$$

化为一元函数,

$$\max U_i = 0.5 \ln(M_i - S_i) + 0.5 \ln(S)$$

一阶条件得:

$$\frac{dU_i}{dS_i} = 0.5 \cdot \frac{-1}{M_i - S_i} + 0.5 \cdot \frac{1}{S} = 0$$

解得:

$$S = M_i - S_i$$

加和得:

$$\sum S = \sum M_i - S$$

解得:

$$S = \frac{\sum M_i}{3} = 100$$

因此均衡时, 小丽和小贾的捐赠数量是 $S_L = 100$, $S_J = 0$, 总座位数量为 $S = 100$ 。

(2) 由于座椅属于公共物品, 其有效供给数量满足 ** 萨缪尔森原则 **, 即公共物品对私有品的边际替代率之和等于公共物品与私有品的价格比。即:

$$\sum \text{MRS}_{S,X} = 1$$

或对小丽、小贾的效用和做最大化问题：

$$\max U = 0.5 \ln(X_L) + 0.5 \ln(X_J) + 0.5 \ln(S) \text{ s.t. } P_X X_L + P_X X_J + P_S S_i = M_L + M_J$$

解得：

$$X_L = X_J = \frac{M_L + M_J}{4P_X}, S = \frac{M_L + M_J}{2P_S}$$

两种方法均可解得 $S = 150$ ，与 (1) 结果相比，不同的原因是公共品具有 ** 正外部性 **，在私人决策的时候，个体不会考虑到公共品对于其他消费者的正效用，会提供少于社会最优的公共品数量，而社会最优供给考虑了每个人的效用。

(3) * 小丽的补偿约束

$$X_L + P_S S_L = 200 + c_L = 200 + 100(P_S - 1)$$

整理得： $X_L + P_S S_L = 100 + 100P_S$ 。

* 小贾的补偿约束

$$X_J + P_S S_J = 100 + c_J = 100 + 0(P_S - 1)$$

整理得： $X_J + P_S S_J = 100$ 。 $S_L = 100, S_J = 0$ 是第 1 问中计算出的初始捐赠量)

称为补偿预算约束的原因：

这种补偿机制（斯拉茨基补偿）的核心在于维持购买力不变。当价格从 1 变为 P_S 时，消费者的购买力发生了变化。为了消除这种变穷或变富的收入效应，给予的补贴 $c_i = (P_S - 1)S_i^{old}$ 恰好能覆盖购买原捐赠数量所需的额外成本。这确保了消费者在新的价格体系下，依然有能力购买价格变动前的商品组合。

(4) (a) 推导 S 的逆需求曲线

1. 计算补偿后的最优私有品消费 (X_i):

根据效用函数 $U = 0.5 \ln X_i + 0.5 \ln S$ ，消费者在私有品 X 上的最优支出总是占其总预算的一半。

* 小丽的补偿后总预算为 $M'_L = 100 + 100P_S$ 。

$$X_L = 0.5 \times M'_L = 50 + 50P_S$$

* 小贾的补偿后总预算为 $M'_J = 100$ 。

$$X_J = 0.5 \times M'_J = 50$$

2. 计算边际替代率 (MRS) 作为个人支付意愿：

由效用函数可知 $MRS_{S,X}^i = \frac{MU_S}{MU_{X_i}} = \frac{0.5/S}{0.5/X_i} = \frac{X_i}{S}$

* 小丽的边际支付意愿： $P_L = \frac{X_L}{S} = \frac{50+50P_S}{S}$

* 小贾的边际支付意愿： $P_J = \frac{X_J}{S} = \frac{50}{S}$

3. 纵向加总得到社会需求曲线：

对于公共品，社会总支付意愿是个人支付意愿之和（纵向加总）：

$$P_{soc} = P_L + P_J$$

令社会支付意愿等于市场价格 P_S ，代入上述表达式：

$$P_S = \frac{50 + 50P_S}{S} + \frac{50}{S} = \frac{100 + 50P_S}{S}$$

解出 P_S 关于 S 的函数（即逆需求曲线）：

$$P_S \cdot S = 100 + 50P_S \implies P_S(S - 50) = 100$$

$$P_S = \frac{100}{S - 50}$$

(b) 求解社会均衡数量并比较

社会供给曲线：由题目可知，场地的单位边际成本为 $MC = 1$ （私有品和座位价格均为 1）。

社会均衡：令社会需求等于社会供给 ($P_S = MC$):

$$\frac{100}{S - 50} = 1$$

解得：

$$S = 150$$

[注] 该结果与第 (2) 问中计算的社会最优解 ($S = 150$) 完全相同。这是因为通过斯卢茨基补偿消除了价格变化的收入效应后，我们通过加总补偿需求曲线得到的均衡点，恰好反映了在原有资源禀赋下的帕累托最优配置。

北京大学-431 金融学综合-2019

2019 统计部分解析

一、(10 分) 给定两个随机变量 X 和 Y , 它们的方差均存在且不为 0, 请回答下列问题:

(1) (5 分) 若 Y 是 X 的线性函数, 它们的相关系数一定是 1 吗? 请具体论述。

(2) (5 分) 若 X 和 Y 的相关系数为 1, 它们一定是线性函数关系吗? 请具体论述。

Solution:

(1) 不一定, 也有可能是 -1. 根据题意, 不妨设 $Y = aX + b$, 其中 $a \neq 0$. 记 $Var(X) = \sigma^2$, 则容易计算:
 $Var(Y) = Var(aX + b) = a^2\sigma^2$, 以及 $Cov(X, Y) = Cov(X, aX + b) = aVar(X) = a\sigma^2$. 因此

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}} = \frac{a\sigma^2}{|a|\sigma^2} = \begin{cases} 1, & a > 0 \\ -1, & a < 0 \end{cases}.$$

(2) 不一定. 例如 $X \sim N(0, 1)$, 令 $Y = \begin{cases} X, & X \neq 1 \\ 0, & X = 1 \end{cases}$, 则虽然 $Corr(X, Y) = 1$, 但 Y 显然不是 X 的线性函数.

此外, 如果结论改为 “ Y 与 X 几乎处处是线性关系”, 则命题正确.

二、(30 分) 考虑线性回归模型 $y_i = ax_i + bx_i^2 + \varepsilon_i$, 其中 a, b 为未知回归参数, 随机误差项 $\varepsilon_i \sim N(0, \sigma^2)$ ($\sigma^2 > 0$ 但未知) 间相互独立. 现收集到 $(x_i, y_i), i = 1, 2, \dots, n$,

(1) (10 分) 推导出 a 和 b 的极大似然估计量的表达式。

(2) (10 分) 推导上述估计量的期望, 方差和分布。

(3) (10 分) 请描述如何基于观测数据判断回归模型中的二次项是否可以移除?

[注: 用矩阵形式也可以, 要解释清楚矩阵的元素是什么]

Solution:

(1) 似然函数是

$$\mathcal{L}(a, b, \sigma^2; \{(x_i, y_i)\}) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - ax_i - bx_i^2)^2 \right\},$$

将对数似然函数求导并置 0, 有

$$\begin{cases} \frac{\partial \ln \mathcal{L}}{\partial a} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - ax_i - bx_i^2) = 0 \\ \frac{\partial \ln \mathcal{L}}{\partial b} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i^2 (y_i - ax_i - bx_i^2) = 0 \end{cases} \Rightarrow \begin{cases} \sum_{i=1}^n x_i y_i = a \left(\sum_{i=1}^n x_i^2 \right) + b \left(\sum_{i=1}^n x_i^3 \right) \\ \sum_{i=1}^n x_i^2 y_i = a \left(\sum_{i=1}^n x_i^3 \right) + b \left(\sum_{i=1}^n x_i^4 \right) \end{cases}$$

根据 Cramer 法则, 该线性方程组的解是

$$\hat{a} = \frac{\begin{vmatrix} \sum_{i=1}^n x_i y_i & \sum_{i=1}^n x_i^3 \\ \sum_{i=1}^n x_i^2 y_i & \sum_{i=1}^n x_i^4 \end{vmatrix}}{\begin{vmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 \\ \sum_{i=1}^n x_i^3 & \sum_{i=1}^n x_i^4 \end{vmatrix}} = \frac{(\sum_{i=1}^n x_i y_i)(\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)(\sum_{i=1}^n x_i^2 y_i)}{(\sum_{i=1}^n x_i^2)(\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2}$$

$$\hat{b} = \frac{\begin{vmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i^3 & \sum_{i=1}^n x_i^2 y_i \end{vmatrix}}{\begin{vmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 \\ \sum_{i=1}^n x_i^3 & \sum_{i=1}^n x_i^4 \end{vmatrix}} = \frac{(\sum_{i=1}^n x_i^2 y_i)(\sum_{i=1}^n x_i^2) - (\sum_{i=1}^n x_i^3)(\sum_{i=1}^n x_i y_i)}{(\sum_{i=1}^n x_i^2)(\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2}$$

(2) 考虑到 $\hat{a}$ 与 $\hat{b}$ 都是 $y_1, y_2, \dots, y_n$ 的线性函数, 且 $y_1, y_2, \dots, y_n$ 具有联合正态分布, 因此估计量也是正态分布, 故只需求其期望与方差.

$$\begin{aligned} E(\hat{a}) &= \frac{(\sum_{i=1}^n x_i E(y_i)) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3) (\sum_{i=1}^n x_i^2 E(y_i))}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2} \\ &= \frac{(\sum_{i=1}^n x_i \{ax_i + bx_i^2\}) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3) (\sum_{i=1}^n x_i^2 \{ax_i + bx_i^2\})}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2} \\ &= \frac{a (\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) + b (\sum_{i=1}^n x_i^3) (\sum_{i=1}^n x_i^4) - a (\sum_{i=1}^n x_i^3)^2 - b (\sum_{i=1}^n x_i^3) (\sum_{i=1}^n x_i^4)}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2} = a, \end{aligned}$$

$$\begin{aligned} Var(\hat{a}) &= \frac{(\sum_{i=1}^n x_i^4)^2 \sum_{i=1}^n x_i^2 Var(y_i) - (\sum_{i=1}^n x_i^3)^2 \sum_{i=1}^n x_i^4 Var(y_i)}{[(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2]^2} \\ &= \frac{\sigma^2 \{(\sum_{i=1}^n x_i^4)^2 (\sum_{i=1}^n x_i^2) - (\sum_{i=1}^n x_i^3)^2 (\sum_{i=1}^n x_i^4)\}}{[(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2]^2} = \frac{\sigma^2 (\sum_{i=1}^n x_i^4)}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2}, \end{aligned}$$

故有 $\hat{a} \sim N\left(a, \frac{\sigma^2 (\sum_{i=1}^n x_i^4)}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2}\right)$.

$$\begin{aligned} E(\hat{b}) &= \frac{(\sum_{i=1}^n x_i^2 E(y_i)) (\sum_{i=1}^n x_i^2) - (\sum_{i=1}^n x_i^3) (\sum_{i=1}^n x_i E(y_i))}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2} \\ &= \frac{(\sum_{i=1}^n x_i^2 \{ax_i + bx_i^2\}) (\sum_{i=1}^n x_i^2) - (\sum_{i=1}^n x_i^3) (\sum_{i=1}^n x_i \{ax_i + bx_i^2\})}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2} \\ &= \frac{a (\sum_{i=1}^n x_i^3) (\sum_{i=1}^n x_i^2) + b (\sum_{i=1}^n x_i^4) (\sum_{i=1}^n x_i^2) - a (\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^3) - b (\sum_{i=1}^n x_i^3)^2}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2} = b, \end{aligned}$$

$$\begin{aligned} Var(\hat{b}) &= \frac{(\sum_{i=1}^n x_i^2)^2 (\sum_{i=1}^n x_i^4 Var(y_i)) - (\sum_{i=1}^n x_i^3)^2 (\sum_{i=1}^n x_i Var(y_i))}{[(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2]^2} \\ &= \frac{\sigma^2 \{(\sum_{i=1}^n x_i^2)^2 (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2 (\sum_{i=1}^n x_i^2)\}}{[(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2]^2} = \frac{\sigma^2 (\sum_{i=1}^n x_i^2)}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2}, \end{aligned}$$

因此有 $\hat{b} \sim N\left(b, \frac{\sigma^2 (\sum_{i=1}^n x_i^2)}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2}\right)$.

(3) 只需检验二次项系数 b 是否为 0, 考虑假设检验问题: $H_0: b = 0$ vs $H_1: b \neq 0$. 当 H_0 成立时, 检验统计量是 $T = \frac{\hat{b}}{se(\hat{b})} \sim t(n-2)$, 这里 $se(\hat{b}) = \sqrt{\frac{\hat{\sigma}^2 (\sum_{i=1}^n x_i^2)}{(\sum_{i=1}^n x_i^2) (\sum_{i=1}^n x_i^4) - (\sum_{i=1}^n x_i^3)^2}}$, 其中

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{a}x_i - \hat{b}x_i^2)^2.$$

因此对于 α 的显著性水平, 当 $|T| \geq t_{1-\frac{\alpha}{2}}(n-2)$ 时拒绝原假设, 此时认为二次项不可移除, 否则认为可以移除.

三. (25 分) 一家老字号连锁店为了吸引顾客, 正在考虑向其全体信用卡顾客开展一项关于邮寄折扣赠券的促销。如果收到赠券的人当中有超过 10% 的人使用赠送, 则认为这项促销取得了成功。在向全国进行促销之前, 先将赠券分发给 100 名信用卡顾客组成的一个样本。结果样本中有 13 个人使用了赠券。

(1) (5 分) 结合本案例, 请定义什么是总体, 什么是样本。

(2) (5 分) 请构造总体赠券使用率的 90% 的置信区间, 并给出解释。

(3) (15 分) 请提出原假设和备择假设。并使用 0.05 的显著性水平进行检验, 该老字号连锁店应该在全国开展此促销吗?

Solution:

(1) 在本案例中, 总体是指该老字号连锁店的全体信用卡顾客, 样本是指从总体中抽出的 100 名信用卡顾客。

(2) 根据中心极限定理, $\sqrt{n}(\hat{p} - p) \rightarrow_d N(0, p(1-p))$, 再根据 slusky 定理, 有 $\frac{\sqrt{n}(\hat{p} - p)}{\sqrt{p(1-p)}} \rightarrow_d N(0, 1)$.

因此利用正态近似, 总体赠券使用率的 90% 的置信区间可以用以下公式计算:

$$\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

其中, $\hat{p}$ 是样本赠券使用率, n 是样本容量。在本案例中, $\hat{p} = 13/100 = 0.13$, $z_{1-\alpha/2} = z_{0.9} = 1.645$, $n = 100$ 。代入公式得:

$$0.13 \pm 1.645 \sqrt{\frac{0.13(1-0.13)}{100}}$$

简化得: 0.13 ± 0.055 , 即 $[0.075, 0.185]$.

(3) 建立假设:

我们要检验促销活动是否“成功”, 即总体使用率是否显著超过 10%。

* 原假设 (H_0): $p \leq 0.1$ (促销不成功或无显著效果)

* 备择假设 (H_1): $p > 0.1$ (促销成功)

确定检验规则:

* 显著性水平: $\alpha = 0.05$

* 检验类型: 右单尾检验

* 临界值: 查标准正态分布表, $\alpha = 0.05$ 对应的右侧临界值为 $z_{0.05} = 1.645$ 。

* 拒绝域: 若检验统计量 $Z > 1.645$, 则拒绝原假设

计算检验统计量:

在原假设 $p = p_0 = 0.1$ 成立的条件下, 计算 Z 统计量

已知样本比例 $\hat{p} = 13/100 = 0.13$, 样本量 $n = 100$ 。

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

代入数值:

$$Z = \frac{0.13 - 0.1}{\sqrt{\frac{0.1 \times (1-0.1)}{100}}} = 1$$

结论:

计算得到的统计量 $Z = 1$, 临界值 $z_{0.05} = 1.645$ 。统计量未落入拒绝域, 因此无法拒绝原假设 H_0 。在 0.05 的显著性水平下, 目前的样本数据不足以证明赠券的总体使用率显著超过 10%。因此, 该老字号连锁店不应该在全国开展此促销。

四、(10 分) 某公司要了解职工对现行奖励制度是否满意，共调查了 210 个员工，按性别整理如下表：

	满意	不满意	合计
男	30	70	100
女	45	65	110
合计	75	135	210

在显著性 0.05 的水平下，分析男职工和女职工对奖励制度看法是否有显著差异？

Solution:

该问题可以用卡方检验来分析。卡方检验是一种非参数检验，用于检验分类变量之间是否有关联性。在本题中，分类变量是性别和对奖励制度的看法。

为了进行卡方检验，需要先计算观察频数和期望频数的差异。观察频数就是表格中给出的数据，期望频数就是假设两个变量没有关联时的数据。期望频数可以用以下公式计算：

$$E_{ij} = \frac{R_i C_j}{N}$$

其中， E_{ij} 是第 i 行第 j 列的期望频数， R_i 是第 i 行的合计， C_j 是第 j 列的合计， N 是总样本数。在本题中，期望频数如下表：

	满意	不满意	合计
男	35.71	64.29	100
女	39.29	70.71	110
合计	75	135	210

然后计算卡方统计量：

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

其中， χ^2 是卡方统计量， r 是行数， c 是列数， O_{ij} 是第 i 行第 j 列的观察频数。在本题中，卡方统计量为：

$$\chi^2 = \frac{(30 - 35.71)^2}{35.71} + \frac{(70 - 64.29)^2}{64.29} + \frac{(45 - 39.29)^2}{39.29} + \frac{(65 - 70.71)^2}{70.71} = 2.711$$

临界值 $\chi_{1-\alpha}^2((r-1)(c-1)) = \chi_{0.95}^2(1) = 3.841$ 。由于 $\chi^2 < \chi_{0.95}^2(1)$ ，因此不能拒绝原假设，也就是说，在显著性水平为 0.05 的情况下，没有足够的证据表明男职工和女职工对奖励制度看法有显著差异。

2019 微观部分解析

一、(4 分) 甜品店自制中秋节月饼，月饼有两种：五仁月饼 (x_1) 和鲜肉月饼 (x_2)。她观察到消费者对两种盒装的月饼支付意愿相等：一种是 4 个五仁月饼加 2 个鲜肉月饼；另一种是 2 个五仁月饼加 4 个鲜肉月饼。假设消费者的效用函数为 $x_1^\alpha x_2^{1-\alpha}$ ，其中 $0 < \alpha < 1$ 。请问如果改变营销策略，只卖一种种类的月饼：5 个五仁月饼一盒，加送 1 个鲜肉月饼；或者 5 个鲜肉月饼一盒，加送 1 个五仁月饼，消费者对新营销策略中一盒 5 个月饼的支付意愿是否会提高？

Solution:

根据题意，消费者对两种盒装的月饼支付意愿相等，说明 $(4, 2) \sim (2, 4)$ ，并且 $\alpha = 0.5$ 。原营销策略的效用计算为

$$U_0 = 4^\alpha \cdot 2^{1-\alpha} = 2\sqrt{2}$$

新营销策略中：若选择 $x_1 = 5$ 和 $x_2 = 1$ ，则

$$U_1 = 5^\alpha \cdot 1^{1-\alpha} = \sqrt{5}$$

若选择 $x_1 = 1$ 和 $x_2 = 5$ ，则

$$U_1 = 1^\alpha \cdot 5^{1-\alpha} = \sqrt{5}$$

由于 $\sqrt{5} < 2\sqrt{2}$ ，因此新营销策略下的效用降低，消费者的支付意愿不会提高。

二、(16 分) 假设一个人生活在没有集体供暖的地区，他为冬季内取暖所愿付出的最高价格为 W 元。他可以购买毛毯 (x_1) 御寒，也可以烧煤 (x_2) 取暖。他从毛毯和烧煤中获得的热量为 x_1 、 x_2 ，毛毯价格为 p_1 元/条，取暖煤价格为 p_2 元/吨。因治理环境，政府杜绝煤炭使用，天然气 (x_3) 对环境污染比煤炭小，燃烧效率高，但价格 p_3 比较高。用天然气和毛毯取暖获得的热量为 $x_1 x_3^2$ 。

1. (8 分) 政府决定补贴天然气的价格，每吨补贴 t 元，使得补贴之后，这个人可以保持原来的取暖预算并获得同样的取暖效果，求补贴额 t 应该为多少元/吨？

2. (8 分) 如政府考虑不单独补贴天然气，而是发给这个人一笔额外的取暖补贴 T ，可自行选择买毛毯或买天然气或两个都买，都保持同样的取暖效果，取暖补贴 T 应为多少？

Solution:

(1) 煤改气之前，消费者的最优选择是 $x_1 = \frac{W}{2p_1}$ ， $x_2 = \frac{W}{2p_2}$ ，获得效用为

$$u_0 = \frac{W^2}{4p_1 p_2}$$

补贴天然气后，消费者的决策问题是：

$$\max u_1 = x_1 x_3^2 \text{ s.t. } p_1 x_1 + (p_3 - t)x_3 = W$$

解得，

$$x_1 = \frac{W}{3p_1}, \quad x_3 = \frac{2W}{3(p_3 - t)}$$

消费者效用为

$$u_1 = \frac{4W^3}{27p_1(p_3 - t)^2} = u_0 = \frac{W^2}{4p_1 p_2} \Rightarrow t = p_3 - \sqrt{\frac{16Wp_2}{27}}.$$

(2) 给予额外补贴 T 后，消费者决策问题是：

$$\max u_2 = x_1 x_3^2$$

$$\text{s.t. } p_1 x_1 + p_3 x_3 = W + T$$

解得

$$x_1 = \frac{W+T}{3p_1}, \quad x_3 = \frac{2(W+T)}{3p_3}$$

消费者效用为

$$u_2 = \frac{4(W+T)^3}{27p_1 p_3^2} = u_0 = \frac{W^2}{4p_1 p_2}$$

由此解得补贴金额 T 为

$$T = \left(\frac{27W^2 p_3^2}{16p_2} \right)^{\frac{1}{3}} - W.$$

三、(20 分) 某人在当期 T_0 持有一笔现金 x_0 ，考虑投资。每一期现金对此人当期的效用函数为 x^α 。当前市场无风险利率为 r ，有一个投资项目，有 P 的概率会在下一期 T_1 带来现金 $x_1 (x_1 > x_0)$ 或者 $1 - P$ 的概率在再下一期 T_2 带来现金 $x_2 (x_2 > x_0)$ 。已知此人是风险中性，且存在概率 P 使得投资与不投资对此人无差异。

1. (10 分) 求 P

2. (10 分) 假设有第二个人, 每一期现金对第二个人的效用函数为 x^2 , 他与第一个人中的人一样面对同样的投资机会与市场无风险利率。如此时的 P 刚好是你上问求出的值, 则第二个人是否会选择投资此项目呢? 请解释。

Solution:

(1) 由投资者 ** 风险中性 ** 可知, 效用函数为线性, 故可以推得 $\alpha = 1$ 。不投资时, 效用为

$$U_0 = x_0$$

投资时, 期望效用为

$$U_1 = P \cdot \frac{x_1}{1+r} + (1-P) \cdot \frac{x_2}{(1+r)^2}$$

令 $U_1 = U_0$, 解得

$$P = \frac{(1+r)^2 x_0 - x_2}{(1+r)x_1 - x_2}$$

(2) 由于 $u(x) = x^2$, $u'(x) = 2x > 0$, $u''(x) = 2 > 0$, 故消费者为 ** 风险喜好者 **。不投资时, 效用为

$$U_0 = x_0^2$$

投资时, 期望效用为

$$U_1 = P \cdot \left(\frac{x_1}{1+r} \right)^2 + (1-P) \cdot \left(\frac{x_2}{(1+r)^2} \right)^2$$

因为风险喜好者的期望效用 $U_1 > U_0$, 故此人会选择投资。

四、(15 分) 现假设有 A 和 B 两座城市劳动人口均为 L , 其产出分别为 $y_a = aLh_a$ 和 $y_b = bLh_b$, 其中 y_a 为 A 城市产出, a 为 A 城市的技术效率, h_a 为 A 城市劳动力的人均教育水平。B 城市的变量含义依此类推。每座城市的政府可以通过投入来改变教育水平, A 城市把 L 名劳动力教育到 h_a 水平的总成本为 $cL(h_a)^2$, 其中 c 为成本参数, B 城市的相应成本为 $cL(h_b)^2$ 。

1. (5 分) A 城市的政府选择教育水平 h_a 最大化当地的净产出 $aLh_a - cL(h_a)^2$, B 城市的政府选择教育水平 h_b 来最大化当地的净产出 $bLh_b - cL(h_b)^2$, 求两座城市的最优教育水平。

2. (5 分) 假设因为 A 城市的技术效率高于 B 城市, 即 $a > b$, 因此有 m 名 B 城市的劳工在受过教育后移到 A 城市。注意其教育程度 h_b 在迁移后不变, 假设 B 城市在决定教育投入时预计了这一迁移行为, 但无法向迁移的劳工收回教育成本。迁移后两地的产出分别为 $a(Lh_a + mh_b)$ 和 $b(Lh_b - mh_b)$, 求两地的最优教育水平。和 (1) 相比, 允许迁移后的最优教育水平有何变化?

3. (5 分) 假设中央政府介入教育, 承担了教育成本, 通过选择 h_a 和 h_b 来最大化两地的总净产出 $a(Lh_a + mh_b) + b(Lh_b - mh_b) - cL(h_a)^2 - cL(h_b)^2$, 求两地的最优教育水平。和 (1) 相比, 此种情况下的最优教育水平有何变化?

Solution:

(1) 最大化单个城市的净产出:

$$\max aLh_a - cL(h_a)^2$$

一阶条件 (F.O. C.) 为:

$$aL - 2cLh_a = 0$$

解得

$$h_a^* = \frac{a}{2c}$$

同理, 最大化 B 城市的净产出:

$$\max bLh_b - cL(h_b)^2$$

一阶条件为：

$$bL - 2cLh_b = 0$$

解得

$$h_b^* = \frac{b}{2c}$$

(2) 最大化单个城市的净产出：

$$\max a(Lh_a + mh_b) - cL(h_a)^2$$

一阶条件为：

$$aL - 2cLh_a = 0$$

解得

$$h_a^* = \frac{a}{2c}$$

教育水平不变。

对 B 城市，最大化净产出：

$$\max b(L - m)h_b - cL(h_b)^2$$

一阶条件为：

$$b(L - m) - 2cLh_b = 0$$

解得

$$h_b^* = \frac{b(L - m)}{2cL} < \frac{b}{2c}$$

教育水平下降。

(3) 最大化两地总净产出问题为：

$$\max a(Lh_a + mh_b) + b(Lh_b - mh_b) - cL(h_a)^2 - cL(h_b)^2$$

对 h_a 的一阶条件为：

$$aL - 2cLh_a = 0$$

解得

$$h_a^* = \frac{a}{2c}$$

对 h_b 的一阶条件为：

$$b(L - m) - 2cLh_b = 0$$

解得

$$h_b^* = \frac{bL + (a - b)m}{2cL} > \frac{b}{2c}$$

此时 A 城市教育水平不变，但 B 城市教育水平上升。

五、(20 分) 村里有 $2N$ 个居民，其中 N 个居民住在一区，每人养 q_1 只羊，每只羊成本为 c_1 ； N 个居民住在二区，每人养 q_2 只羊，每只羊成本为 c_2 。每只羊带来的收入是 $200 - q$ ， q 是村里羊的总数。

1. (10 分) 找到博弈的纳什均衡下两个区域里每个居民养羊的数量，找出社会效益最优选择下村子里羊的总量。

2. (5 分) 当地政府为了达到社会效益的最优选择，对两个地区按统一标准征税，每只羊征收 t 。计算税收标准 t ，以及对应的纳什均衡下两个区域里每个居民的养羊数量。

3. (5 分) 如果当地政府只对第一区域的居民征税，每只羊征税 t ，以达到社会效益的最优。请计算税收标准 t ，以及对应的纳什均衡下两个区域里每个居民的养羊数量。

Solution:

(1) 对第一区的每个居民而言有利润最大化问题：

$$\max \pi_1 = [200 - (Nq_1 + Nq_2)] q_1 - c_1 q_1$$

一阶条件 (F.O. C.) 为：

$$200 - Nq_2 - 2Nq_1 - c_1 = 0$$

对于第二区的每个居民，利润最大化问题为：

$$\max \pi_2 = [200 - (Nq_1 + Nq_2)] q_2 - c_2 q_2$$

一阶条件为：

$$200 - Nq_1 - 2Nq_2 - c_2 = 0$$

联立两个一阶条件，求得：

$$q_1 = \frac{200 - 2c_1 - c_2}{3N}, \quad q_2 = \frac{200 - c_1 - 2c_2}{3N}$$

社会最优时，最大化全村的总利润：

$$\max \pi = [200 - N(q_1 + q_2)] (q_1 + q_2) - N(c_1 q_1 + c_2 q_2)$$

一阶条件为：

$$200N - 2N^2(q_1 + q_2) - Nc_1 \leq 0$$

$$200N - 2N^2(q_1 + q_2) - Nc_2 \leq 0$$

解得，羊的总量为：

$$N(q_1 + q_2) = \frac{200 - \min\{c_1, c_2\}}{2}$$

(2) 对两个地区分别征税，税率为 t ：

对第一区居民：

$$\max \pi_1 = [200 - Nq_1 - Nq_2] q_1 - (t + c_1)q_1$$

一阶条件为：

$$200 - 2Nq_1 - Nq_2 - t - c_1 = 0$$

对第二区居民：

$$\max \pi_2 = [200 - Nq_1 - Nq_2] q_2 - (t + c_2)q_2$$

一阶条件为：

$$200 - Nq_1 - 2Nq_2 - t - c_2 = 0$$

实际上只需要代入第一问结果，将价格加一个 t 即可。令：

$$q_1 + q_2 = \frac{200 - \min\{c_1, c_2\}}{2}$$

求得：

$$q_1 = \frac{200 - 2c_1 - 2c_2 - \min\{c_1, c_2\}}{4N}, \quad q_2 = \frac{200 - 2c_1 - 2c_2 - \min\{c_1, c_2\}}{4N}$$

税收标准为：

$$t = \frac{200 - 2c_1 - 2c_2 + 3 \min\{c_1, c_2\}}{4}$$

注：此题需要注意审题，题干所说的社会效益最优选择实际上欠妥，目标仅仅是令两区居民养羊总数达到第一问的最优总数。如果考虑政府税收与居民收益总和最大，应也会酌情给分。

(3) 如果只对第一区征税，则：

$$t = 100 - c_1 - c_2 + 1.5 \min\{c_1, c_2\}$$

总结各区域居民的均衡下的养羊数量为：

$$q_1 = \frac{c_2 - \min\{c_1, c_2\}}{N}, \quad q_2 = \frac{100 - c_2 + 0.5 \min\{c_1, c_2\}}{N}$$

北京大学-431 金融学综合-2020

2020 统计部分解析

一、(15 分) 研究团队调查了大、中、小型公司的各 200 名高管, 询问他们是否已经开展了大数据项目, 他们的回答结果如下:

是否已开展大数据项目	小型公司	中型公司	大型公司
是	10%	35%	26%
否	90%	65%	74%

请在 5% 的显著性水平下, 判断不同类型公司是否在开展大数据项目上存在显著差异.

Solution: 这是 $m = 3, n = 2$ 的列联表检验, 其原假设是: 开展大数据项目的比例与公司类型独立, 即开展大数据在不同公司内无差异.

首先将表格改写为具体数值:

是否已开展大数据项目	$i = 1$	$i = 2$	$i = 3$	总
$j = 1$	20	70	52	142
$j = 2$	180	130	148	458
总	200	200	200	600

利用方差分析公式即

$$\chi^2 = \sum_{i=1}^m \sum_{j=1}^n \frac{(N_{ij} - N \cdot p_{i\cdot} \cdot p_{\cdot j})^2}{N \cdot p_{i\cdot} \cdot p_{\cdot j}} = \sum_{i=1}^m \sum_{j=1}^n \frac{(N_{ij} - N \cdot \frac{N_{i\cdot}}{N} \cdot \frac{N_{\cdot j}}{N})^2}{N \cdot \frac{N_{i\cdot}}{N} \cdot \frac{N_{\cdot j}}{N}} = 35.5,$$

在原假设成真时, 有 $\chi^2 \sim \chi^2((m-1)(n-1)) = \chi^2(2)$, 拒绝域为

$$W = \{\chi^2 > \chi_{0.95}^2(2)\}.$$

记 $Y \sim \chi^2(2)$. 由于 $\chi^2(2)$ 等价于参数为 $\lambda = \frac{1}{2}$ 的指数分布, 即

$$Y \sim \text{Exp}(\frac{1}{2}),$$

故

$$P(Y > c) = e^{-c/2}.$$

令

$$P(Y > c) = e^{-c/2} = 0.05,$$

解得

$$\chi_{0.95}^2(2) = c = -2 \ln(0.05) \approx 5.991.$$

显然此时

$$35.5 > 5.991,$$

落入拒绝域, 故认为不同类型公司有明显差异.

二、(15 分) 假设 $X_1, X_2, \dots, X_n$ 是独立同分布的随机变量, 它们的分布密度函数为: $f(x; \beta, \sigma) = \frac{1}{2\sigma} e^{-\frac{|x-\beta|}{\sigma}}, x \in R$.

(1) (5 分) 请写出 $X_1, X_2, \dots, X_n$ 的联合密度函数.

(2) (5 分) 如果 β 已知, 求 σ 的极大似然估计.

(3) (5 分) 如果 σ 已知, 求 β 的极大似然估计.

Solution: (1) 联合密度就是密度函数的累乘, 即

$$f(x; \beta, \sigma) = 2^{-n} \sigma^{-n} \exp \left\{ -\frac{\sum_{i=1}^n |x_i - \beta|}{\sigma} \right\}, \quad x \in R^n.$$

(2) 如果 β 已知, 对数似然函数是

$$\ell(\sigma) = C - n \ln(\sigma) - \frac{\sum_{i=1}^n |x_i - \beta|}{\sigma}, \quad \frac{\partial \ell}{\partial \sigma} = -\frac{n}{\sigma} + \frac{\sum_{i=1}^n |x_i - \beta|}{\sigma^2},$$

令导数为 0, 解得 $\hat{\sigma} = \frac{\sum_{i=1}^n |x_i - \beta|}{n}$.

(3) 如果 σ 已知, 对数似然函数是

$$\ell(\beta) = C - \frac{1}{\sigma} \sum_{i=1}^n |x_i - \beta|,$$

求导并不方便. 由于最大化 ℓ 等同于最小化 $Q(\beta) = \sum_{i=1}^n |x_i - \beta|$, 我们用次序统计量改写为

$$Q(\beta) = \sum_{i=1}^n |x_{(i)} - \beta|,$$

并且有

$$Q(\beta) = \begin{cases} \sum_{j=1}^{n/2} (|x_{(j)} - \beta| + |x_{(n+1-j)} - \beta|), & n \text{ 是偶数} \\ \sum_{j=1}^{(n-1)/2} (|x_{(j)} - \beta| + |x_{(n+1-j)} - \beta|) + |x_{(\frac{n+1}{2})} - \beta|, & n \text{ 是奇数} \end{cases}$$

对 $\forall j$, 当 $\beta \in [x_{(j)}, x_{(n-j+1)}]$ 时, $(|x_{(j)} - \beta| + |x_{(n+1-j)} - \beta|)$ 取到最小值.

而当 n 是奇数时, 当 $\beta = x_{(\frac{n+1}{2})}$ 时, $|x_{(\frac{n+1}{2})} - \beta|$ 达到最小.

若 n 为偶数, 则当 $\beta \in \bigcap_{j=1}^{n/2} [x_{(j)}, x_{(n-j+1)}] = [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}]$ 时, 所有的 $(|x_{(j)} - \beta| + |x_{(n+1-j)} - \beta|)$ 均取最小值, 则此时 $Q(\beta)$ 取最小值.

综上所述, 当 n 为奇数, $\hat{\beta} = x_{(\frac{n+1}{2})}$, 当 n 为偶数, $\hat{\beta}$ 可取 $[x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}]$ 任意值. 或者简单地说, $\hat{\beta}$ 可以取成样本中位数.

三、(15 分) 假设 $y_1, y_2, \dots, y_n$ 独立同服从下述异方差线性回归模型:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中 $\varepsilon_i \sim N(0, i^2)$, $x_1, \dots, x_n$ 是已知数.

(1) (5 分) 求对数似然函数.

(2) (5 分) 请写出 (β_0, β_1) 的极大似然估计 $(\hat{\beta}_0, \hat{\beta}_1)$ 的数学公式.

(3) (5 分) 给出 $(\hat{\beta}_0, \hat{\beta}_1)$ 的统计学分布.

Solution: (1) 似然函数是

$$L(\beta) = \prod_{i=1}^n (2\pi i^2)^{-\frac{1}{2}} \cdot \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \frac{(y_i - \beta_0 - \beta_1 x_i)^2}{i^2} \right\},$$

对数似然函数是

$$\ell(\beta) = C - \frac{1}{2} \sum_{i=1}^n \frac{(y_i - \beta_0 - \beta_1 x_i)^2}{i^2} = C - \frac{1}{2} \sum_{i=1}^n \left(\frac{y_i}{i} - \beta_0 \frac{1}{i} - \beta_1 \frac{x_i}{i} \right)^2.$$

(2) 最大化似然函数等价于最小化 $Q(\beta) = \sum_{i=1}^n \left(\frac{y_i}{i} - \beta_0 \frac{1}{i} - \beta_1 \frac{x_i}{i} \right)^2$, 而若我们记

$$z_i = \frac{y_i}{i}, \quad u_{0,i} = \frac{1}{i}, \quad u_{1,i} = \frac{x_i}{i},$$

则有

$$Q(\beta) = \sum_{i=1}^n (z_i - \beta_0 u_{0,i} - \beta_1 u_{1,i})^2,$$

这就是不带截距项的二元线性回归, 其解为

$$\hat{\beta} = (U^T U)^{-1} U^T Z = \begin{pmatrix} l_{00} & l_{01} \\ l_{10} & l_{11} \end{pmatrix}^{-1} \begin{pmatrix} l_{0z} \\ l_{1z} \end{pmatrix},$$

即 $\hat{\beta}$ 是线性方程组

$$\begin{pmatrix} l_{00} & l_{01} \\ l_{10} & l_{11} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} l_{0z} \\ l_{1z} \end{pmatrix}$$

的解, 其中

$$l_{00} = \sum_{i=1}^n u_{0i}^2, \quad l_{01} = l_{10} = \sum_{i=1}^n u_{0i} u_{1i}, \quad l_{11} = \sum_{i=1}^n u_{1i}^2, \quad l_{0z} = \sum_{i=1}^n u_{0i} z_i, \quad l_{1z} = \sum_{i=1}^n u_{1i} z_i,$$

故代入后有

$$\hat{\beta}_0 = \frac{\begin{vmatrix} l_{0z} & l_{01} \\ l_{1z} & l_{11} \end{vmatrix}}{\begin{vmatrix} l_{00} & l_{01} \\ l_{10} & l_{11} \end{vmatrix}} = \frac{\sum_{i=1}^n u_{1i}^2 \sum_{i=1}^n u_{0i} z_i - \sum_{i=1}^n u_{0i} u_{1i} \sum_{i=1}^n u_{1i} z_i}{\sum_{i=1}^n u_{0i}^2 \sum_{i=1}^n u_{1i}^2 - \left(\sum_{i=1}^n u_{0i} u_{1i} \right)^2} = \frac{\sum_{i=1}^n \frac{x_i^2}{i^2} \sum_{i=1}^n \frac{y_i}{i^2} - \sum_{i=1}^n \frac{x_i}{i^2} \sum_{i=1}^n \frac{x_i y_i}{i^2}}{\sum_{i=1}^n \frac{1}{i^2} \sum_{i=1}^n \frac{x_i^2}{i^2} - \left(\sum_{i=1}^n \frac{x_i}{i^2} \right)^2},$$

$$\hat{\beta}_1 = \frac{\begin{vmatrix} l_{00} & l_{0z} \\ l_{10} & l_{1z} \end{vmatrix}}{\begin{vmatrix} l_{00} & l_{01} \\ l_{10} & l_{11} \end{vmatrix}} = \frac{\sum_{i=1}^n u_{0i}^2 \sum_{i=1}^n u_{1i} z_i - \sum_{i=1}^n u_{0i} u_{1i} \sum_{i=1}^n u_{0i} z_i}{\sum_{i=1}^n u_{0i}^2 \sum_{i=1}^n u_{1i}^2 - \left(\sum_{i=1}^n u_{0i} u_{1i} \right)^2} = \frac{\sum_{i=1}^n \frac{1}{i^2} \sum_{i=1}^n \frac{x_i y_i}{i^2} - \sum_{i=1}^n \frac{x_i}{i^2} \sum_{i=1}^n \frac{y_i}{i^2}}{\sum_{i=1}^n \frac{1}{i^2} \sum_{i=1}^n \frac{x_i^2}{i^2} - \left(\sum_{i=1}^n \frac{x_i}{i^2} \right)^2}.$$

(3) 对于 $z_i = \beta_0 u_{0i} + \beta_1 u_{1i} + e_i$, 其中 $e_i \sim N(0, 1)$, 这已经符合了同方差假设, 此时最小二乘估计的分布是

$$\begin{aligned} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} &\sim N \left(\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, (U^T U)^{-1} \right) \\ &= N \left(\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \frac{\begin{pmatrix} l_{11} & -l_{10} \\ -l_{01} & l_{00} \end{pmatrix}}{\begin{vmatrix} l_{00} & l_{01} \\ l_{10} & l_{11} \end{vmatrix}} \right) \\ &= N \left(\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \frac{\begin{pmatrix} \sum_{i=1}^n \frac{x_i^2}{i^2} & -\sum_{i=1}^n \frac{x_i}{i^2} \\ -\sum_{i=1}^n \frac{x_i}{i^2} & \sum_{i=1}^n \frac{1}{i^2} \end{pmatrix}}{\sum_{i=1}^n \frac{1}{i^2} \sum_{i=1}^n \frac{x_i^2}{i^2} - \left(\sum_{i=1}^n \frac{x_i}{i^2} \right)^2} \right). \end{aligned}$$

四、(15 分) 有一位市场调查员, 他感兴趣的是该地区成年人中购买某商品的比率 θ . 现在他准备调查 n 个顾客 (n 较大), 如果购买了该商品则纪录为 $x_i = 1$, 否则 $x_i = 0$.

(1)(5 分) 求 $\bar{x}$ 的近似分布.

(2)(5 分) 现他要事先确定需要访问多少顾客才能使 $[\bar{x} - d, \bar{x} + d]$ 是 θ 的 $1 - \alpha$ 置信区间? 其中 d 是事先给定的常数.

(3)(5 分) 又假如事先知道去年该比率是 20%, 调查员试图研究今年是否有显著不同, 请写出假设检验问题并给出假设检验过程.

Solution: (1) 显然 $x_1, \dots, x_n$ 独立同服从 $B(1, \theta)$, 期望为 θ , 方差为 $\theta(1 - \theta)$, 根据中心极限定理, 有

$$\bar{x} \sim AN\left(\theta, \frac{\theta(1-\theta)}{n}\right).$$

(2) 利用正态近似有

$$P\left(\left|\sqrt{n}\frac{\bar{x}-\theta}{\sqrt{\theta(1-\theta)}}\right| < z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha,$$

反过来解得

$$\theta \in \left[\bar{x} - \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}}\sqrt{\theta(1-\theta)}, \bar{x} + \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}}\sqrt{\theta(1-\theta)}\right],$$

因此 d 一定要比 $\frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}}\sqrt{\theta(1-\theta)}$ 还大才行, 所以也要比右侧的最大值大, 考虑到二次函数

$$x(1-x) \leq \frac{1}{4}, \quad \text{当 } x = 1/2 \text{ 时取等,}$$

因此有 $d \geq \frac{z_{1-\frac{\alpha}{2}}}{2\sqrt{n}}$, 解得 $n \geq \left(\frac{z_{1-\frac{\alpha}{2}}}{2d}\right)^2$.

(3) 该问题的原假设和备择假设是

$$H_0: \theta = 0.2 \quad \text{vs} \quad H_1: \theta \neq 0.2$$

因此有原假设成立时: $z = \frac{\bar{x}-0.2}{\sqrt{\frac{0.2 \cdot 0.8}{n}}} \sim AN(0, 1)$. 如果 $|z|$ 特别大, 则说明 $\bar{x}$ 距 0.2 相去甚远, 我们拒绝原假设, 故拒绝域是

$$W = \left\{ \frac{|\bar{x} - 0.2|}{\sqrt{\frac{0.2 \cdot 0.8}{n}}} > z_{1-\frac{\alpha}{2}} \right\} = \left\{ \bar{x} > 0.2 + 0.4\sqrt{n}z_{1-\frac{\alpha}{2}} \right\} \cup \left\{ \bar{x} < 0.2 - 0.4\sqrt{n}z_{1-\frac{\alpha}{2}} \right\}.$$

[注]: 写成 $z = \frac{\bar{x}-0.2}{\sqrt{\frac{\bar{x} \cdot (1-\bar{x})}{n}}} \sim AN(0, 1)$ 作为检验统计量也行, 但和第 (2) 问有了差异, 不是很顺畅.

五、(15 分) 假设 X_1 和 X_2 都是独立同分布的泊松随机变量, 均值分别为 μ_1 和 μ_2 。

(1) (5 分) 写出 X_1 的概率分布列.

(2) (5 分) 写出 $X_1 + X_2$ 的概率分布列

(3) (5 分) 请问 $2X_1$ 还服从泊松分布吗?

Solution: (1) 显然有

$$p_1(x) = P(X_1 = x) = \frac{\mu_1^x}{x!} e^{-\mu_1}, \quad x = 0, 1, 2, \dots.$$

(2) 根据泊松分布可加性, $Y = X_1 + X_2$ 仍然是泊松分布, 期望为 $\mu_1 + \mu_2$, 因此有

$$p_Y(y) = P(Y = y) = \frac{(\mu_1 + \mu_2)^y}{y!} e^{-(\mu_1 + \mu_2)}, \quad y = 0, 1, 2, \dots.$$

(3) 不是, 因为 $2X_1$ 的可能取值是 $\{0, 2, 4, 6, 8, \dots\}$, 泊松分布的定义域是 $\{0, 1, 2, 3, \dots\}$, 故 $2X_1$ 不是泊松分布.

· 2020 微观部分解析

一、(15 分) B 城市的市民有两种出行方式：公共交通和私家车。为鼓励绿色出行，B 城市补贴市民的公共交通花销，其中贴补力度为原价格的 50%。即本需要花费 p_1 元/公里的线路在补贴后只需要花费 $0.5 p_1$ 元/公里即可。假设 B 城市的市民平均每月出行的公共交通通勤里程为 x_1 公里，私家车里程为 x_2 公里。私家车出行的成本为 p_2 元/公里。市民从出行中获得的效用为 $u(x_1, x_2) = x_1^{0.2} x_2^{0.8}$ 。

现在专家提出，为缓解高峰时段公共交通运输力不足，建议取消公共交通价格补贴，使得价格恢复为 p_1 元/公里。但这样会使居民的出行效率降低，所以建议每个月给每一位市民一笔固定的收入补贴 s 元。政府的目标是花最少的钱使市民的效用在补贴前后无差异。

1. (5 分) 为了使得市民的效用水平在补贴方式改变前后没有差异， s 最少应为多少？
2. (5 分) 改为固定收入补贴之后市民选择的出行方式 x_1 和 x_2 为多少？
3. (5 分) 哪一种补贴方式对政府的财政负担较小，价格补贴还是固定收入补贴？差异为多少元？

Solution:

(1) 消费者的效用与固定补贴计算

记 m 表示消费者收入，那么：

$$\max u(x_1, x_2) = x_1^{0.2} x_2^{0.8} \text{ s.t. } 0.5 p_1 x_1 + p_2 x_2 = m$$

解得：

$$x_1 = \frac{2m}{5p_1}, \quad x_2 = \frac{4m}{5p_2}$$

效用为：

$$u_0 = \left(\frac{2m}{5p_1}\right)^{0.2} \left(\frac{4m}{5p_2}\right)^{0.8} = \frac{2^{0.2} 4^{0.8} m}{5^{0.2+0.8} p_1^{0.2} p_2^{0.8}} = \frac{2^{0.2} 4^{0.8} m}{5 p_1^{0.2} p_2^{0.8}}$$

改为固定补贴后：

$$\max u(x_1, x_2) = x_1^{0.2} x_2^{0.8} \text{ s.t. } p_1 x_1 + p_2 x_2 = m + s$$

解得：

$$x_1 = 0.2 \cdot \frac{m+s}{p_1}, \quad x_2 = 0.8 \cdot \frac{m+s}{p_2}$$

效用为：

$$u_1 = \left(\frac{m+s}{p_1} \cdot 0.2\right)^{0.2} \left(\frac{m+s}{p_2} \cdot 0.8\right)^{0.8} = \frac{4^{0.8} (m+s)}{5 p_1^{0.2} p_2^{0.8}}$$

令 $u_0 = u_1$ ，得：

$$\frac{2^{0.2} 4^{0.8} m}{5 p_1^{0.2} p_2^{0.8}} = \frac{4^{0.8} (m+s)}{5 p_1^{0.2} p_2^{0.8}}$$

简化后得：

$$s = (2^{0.2} - 1)m$$

因此，补贴金额 s 应为 $s = (2^{0.2} - 1)m$ 。

(2) 补贴后的消费量计算

由上述计算，代入 $s = (2^{0.2} - 1)m$ 得：

$$x_1 = 0.2 \cdot \frac{m+s}{p_1} = \frac{2^{0.2}}{5} \cdot \frac{m}{p_1}$$

$$x_2 = 0.8 \cdot \frac{m+s}{p_2} = \frac{4 \cdot 2^{0.2}}{5} \cdot \frac{m}{p_2}$$

(3) 两种补贴方式的财政负担比较

通过计算：- 价格补贴的补贴金额为 $0.2m$ ；- 固定收入补贴的补贴金额为 $s = (2^{0.2} - 1)m$ 。

利用不等式 $(1+1)^{0.2} < 1+1 \cdot 0.2$, 显然: - ** 固定收入补贴更优 ** , 对政府的财政负担更小。- 两种补贴方式的差异约为 $(1.2 - 2^{0.2})m$ 。

二、(20 分) 一个小商贩在小车上售卖两种商品, 冰淇淋和汽水。他认为未来一周高温和气温正常的概率相等。此小商贩对收入的效用为 $u(w) = w^{0.5}$ 。如果他全部售卖冰淇淋, 则如果未来一周发生高温, 收入为 2500 元; 如果气温正常, 收入为 400 元。如果他全部售卖汽水, 则如果未来一周发生高温, 收入为 1600 元; 如果气温正常, 收入为 900 元。

1. (10 分) 该小贩应怎样组合冰淇淋和汽水的售卖比例 α 和 $1 - \alpha$, 使期望效用最大?

2. (10 分) 有一个保险给只卖冰淇淋的商贩设立。保险的保险费为每周 400 元。如果气温不高 (即气温正常), 则保险赔付 800 元。这个小商贩是否应该购买此保险并只售卖冰淇淋, 还是应该不买保险, 保持 (1) 中的两种商品的售卖比例?

Solution:

(1) 小商贩的期望效用最大化问题

设小商贩的期望效用最大化问题为:

$$\max_{\alpha} EU = 0.5\sqrt{2500\alpha + 1600(1 - \alpha)} + 0.5\sqrt{400\alpha + 900(1 - \alpha)}$$

将期望效用函数展开为:

$$EU = 0.5\sqrt{1600 + 900\alpha} + 0.5\sqrt{900 - 500\alpha}$$

对 α 求导:

$$\frac{dEU}{d\alpha} = 0.5 \cdot \frac{900}{2\sqrt{1600 + 900\alpha}} - 0.5 \cdot \frac{500}{2\sqrt{900 - 500\alpha}} = 0$$

解方程, 得到 α :

$$\alpha = \frac{329}{630} \approx 0.5$$

因此, 小商贩应当选择 $\alpha^* = \frac{329}{630}$ 的 ** 销售比例 ** , 期望效用为:

$$EU_0 = 0.5\sqrt{1600 + 900\alpha^*} + 0.5\sqrt{900 - 500\alpha^*}.$$

近似采用 $\alpha^* = 0.5$, 即冰淇淋和汽水的销售比例相等, 此时:

$$EU_0 = 0.5\sqrt{2050} + 0.5\sqrt{650}.$$

(2) 考虑保险的期望效用

保险费用为 400 元, 若购买保险, 在气温不高时 (即气温正常) 会补偿 800 元。购买保险时的期望效用为:

$$EU_1 = 0.5\sqrt{2100} + 0.5\sqrt{800}$$

对比购买保险与不购买保险的期望效用: - 对于第一个根号部分, 有 $1600 + 900 \cdot \alpha^* = 2070 < 2100$ 。- 对于第二个根号部分, 有 $900 - 500\alpha^* < 900 - 500 \cdot 0.5 = 650 < 800$ 。

因此:

$$EU_1 > EU_0$$

结论: 小商贩应当选择 ** 购买保险 **, 因为购买保险后的期望效用高于不购买保险时的期望效用。

三、(25 分) 某市有两家企业 A 和 B 生产同样的产品, 其生产函数分别为 $y_a = 2(L_a)^{0.5}$ 和 $y_b = (L_b)^{0.5}$, 其中 L_a 为 A 企业的雇佣的工人数量, B 企业的变量含义以此类推。给定外生的产品价格 $p = 30$ 和外生的工资成本 $w = 5$, 两家企业分别最大化其利润。企业的生产过程中产生污染, A 和 B 企业的排污量分别为 $v_a = (y_a)^2$ 和 $v_b = (y_b)^2$ 。A 市居民的效用函数为 $8(L_a + L_b)^{0.5} - (v_a + v_b)$ 。

1. (7 分) 求使该市居民效用最大化的排污水平 v_a 和 v_b 。

2. (6 分) 如果企业 A 和 B 无视污染给居民带来的负效用, 它们的总排污量是多少?
3. (6 分) 如果政府直接规定 A 和 B 两个企业的总排污量, 使其等于 (1) 中的总排污水平, 如何分配排污量才能最大化就业?
4. (6 分) 如果政府收取排污费, 费用为每单位污染收取 t , 请问能否通过设定 t 复刻 (3) 问中的排污量分配? 如果能, 请给出 t 的表达式。

Solution:

(1) 居民效用最大化的目标是:

$$\max U = 8(L_a + L_b)^{0.5} - (v_a + v_b)$$

约束条件为:

$$\begin{aligned} v_a &= (y_a)^2, & v_b &= (y_b)^2 \\ y_a &= 2(L_a)^{0.5}, & y_b &= (L_b)^{0.5} \end{aligned}$$

** 求解得到 **:

$$v_a = 0, \quad v_b = 16$$

(2) 企业 A 和 B 追求自身利润最大化:

对于企业 A:

$$\max \pi_a = py_a - wL_a = 60\sqrt{L_a} - 5L_a$$

一阶条件 (F.O. C.) 为:

$$\frac{30}{\sqrt{L_a}} - 5 = 0$$

** 解得 **:

$$L_a = 36, \quad v_a = 144$$

对于企业 B:

$$\max \pi_b = py_b - wL_b = 30\sqrt{L_b} - 5L_b$$

一阶条件为:

$$\frac{15}{\sqrt{L_b}} - 5 = 0$$

** 解得 **:

$$L_b = 9, \quad v_b = 9$$

最终 $v_a + v_b = 144 + 9 = 153$.

(3) 排污量分配的目标是最大化就业总量, 即:

$$\max L_a + L_b \quad \text{s.t.} \quad v_a + v_b = 16$$

** 解得 **:

$$v_a = 0, \quad v_b = 16$$

与第 1 问结果一致。

(4) 对于企业 A:

$$\max \pi_a = py_a - wL_a - tv_a = 60\sqrt{L_a} - 5L_a - tv_a$$

当 $v_a = 0, v_b = 16$ 时 (隐含了 $L_a = 0$), 发现没有一个 t 可以满足条件。或分析企业 B:

$$\max \pi_b = py_b - wL_b - tv_b = 30\sqrt{L_b} - 5L_b - tv_b$$

一阶条件 (F.O. C.) 为:

$$\frac{15}{\sqrt{v_b}} - 5 - t = 0$$

解得:

$$t = -1.25$$

因此, ** 不存在 ** t 能复刻第 3 问的结果。

四、(15 分) 考虑以下完全信息动态博弈。博弈的参与者为一个垄断性的上游企业 U 与一个垄断性的下游企业 D。在博弈的第一阶段, 企业 U 以单位价格 p_u 向企业 D 销售中间产品。在第二阶段, 企业 D 把中间产品 (一比一地) 加工为最终产品, 并以单位价格 p_d 向消费者出售。假设企业 U 的生产成本为零, 而企业 D 除购买中间产品的费用外亦无其他生产成本。最后, 假设企业 D 面对的需求函数为 $q(p_d) = 1 - p_d$ 。

1. (3 分) 考虑博弈的第二阶段。给定上游企业的中间产品供给价格 p_u , 请求出下游企业关于最终产品的利润最大化定价。

2. (5 分) 回到博弈的第一阶段。给定下游企业的利润最大化定价策略, 请求出上游企业的利润最大化定价 (即子博弈精炼纳什均衡定价)。

3. (2 分) 在均衡时, 产生利润 (即两企业利润的加总) 是多少? 有多少最终产品会销售给消费者?

4. (5 分) 假设现在题中的上下游企业 U 和 D 合并为一个企业。请求出在此情形下, 有多少最终产品会销售给消费者? 与 (3) 中的情形对比, 产生利润与消费者福利有何变化?

Solution:

(1) 给定 p_u , 下游企业的利润最大化目标是:

$$\pi_d = (1 - p_d)(p_d - p_u)$$

对 p_d 求导并令导数为 0, 得到下游企业的 ** 最优定价 ** 为:

$$p_d = \frac{1 + p_u}{2}$$

(2) 给定 $p_d = \frac{1 + p_u}{2}$, 上游企业的利润最大化目标是:

$$\pi_u = p_u(1 - p_d)$$

对 p_u 求导并令导数为 0, 得到上游企业的 ** 最优定价 ** 为:

$$p_u = 0.5$$

(3) 利用上述结果代入各自利润表达式, 得到:

$$\pi_u = \frac{p_u(1 - p_u)}{2} = 0.125$$

$$\pi_d = (1 - p_d)(p_d - p_u) = 0.0625$$

** 加总利润 ** 为:

$$\pi_u + \pi_d = 0.125 + 0.0625 = 0.1875$$

** 产品销量 ** 为:

$$q = 1 - p_d = 0.25$$

(4) 合并一个企业时, 追求利润之和最大化, 即:

$$\max \pi_u + \pi_d = (1 - p)p$$

对 p 求导并令导数为 0，得到 ** 最优定价 ** 为：

$$p = 0.5$$

因此，** 总利润 ** 为：

$$\pi_u + \pi_d = 0.25$$

产品价格降低，福利增加。

北京大学-431 金融学综合-2021

2021 统计部分解析

一、(20 分) 设 (X, Y) 的密度函数是

$$f(x, y) = 2(x + y), \quad 0 \leq x \leq y \leq 1.$$

(1)(10 分) 求 X, Y 的边缘分布;

(2)(10 分) 求 $X + Y$ 的分布.

Solution:

(1) 先求 Y 的边缘, 积分有

$$f_Y(y) = \int_0^y 2(x + y) dx = y^2 + 2y^2 = 3y^2, \quad 0 \leq y \leq 1.$$

再求 X 的边缘, 积分有

$$f_X(x) = \int_x^1 2(x + y) dy = 2x(1 - x) + (1 - x^2) = 1 + 2x - 3x^2, \quad 0 \leq x \leq 1.$$

(2) 作变量变换:

$$\begin{cases} U = X + Y, \\ V = Y, \end{cases} \Rightarrow \begin{cases} u = x + y, \\ v = y, \end{cases} \Rightarrow \begin{cases} x = u - v, \\ y = v, \end{cases} \Rightarrow |J| = 1,$$

因此有

$$f_{U,V}(u, v) = f(u - v, v) = 2u, \quad 0 \leq v \leq 1, v \leq u \leq 2v,$$

当 $u \in (0, 1]$ 有 $\frac{u}{2} \leq v \leq u$, 当 $u \in (1, 2)$, 有 $\frac{u}{2} \leq v \leq 1$, 因此积分得

$$f_U(u) = \int_{\frac{u}{2}}^{\min\{u, 1\}} 2u dv = \begin{cases} u^2, & 0 < u \leq 1, \\ 2u - u^2, & 1 < u < 2. \end{cases}$$

二、(15 分) 为检验声波是否对心率有影响, 对 9 位测试者进行测试, 收集数据如下:

	1	2	3	4	5	6	7	8	9
无声波	69	73	76	68	79	71	75	73	74
有声波	75	80	75	81	74	84	81	75	78

(1)(3 分) 求有声波和无声波时的平均心率差值.

(2)(8 分) 求心率差的 0.95 置信区间.

(3)(2 分) 解释 (2) 问的意义.

(4)(2 分) 根据 (2) 的结果判断, 声波对心率是否有显著影响.

[注]: 可能用到的分位数是 $t_{0.95}(9) = 1.833$, $t_{0.975}(9) = 2.262$, $t_{0.95}(8) = 1.860$, $t_{0.975}(8) = 2.306$.

Solution:

(1) 作差计算得

	1	2	3	4	5	6	7	8	9
差值	6	7	-1	13	-5	13	6	2	4

计算得平均值为 $\bar{x} = 5$. 此外计算出样本标准差是 $s = 5.916$.

(2) 假设心率差 $X \sim N(\mu, \sigma^2)$, 有枢轴量

$$T = \sqrt{n} \frac{\bar{x} - \mu}{s} \sim t(n-1),$$

有置信区间为 $\bar{x} \pm t_{0.975}(n-1) \frac{s}{\sqrt{n}}$, 代入得

$$\left[5 - \frac{2.306}{3} \cdot 5.916, 5 + \frac{2.306}{3} \cdot 5.916 \right] = [0.453, 9.547].$$

(3) 我们有 95% 的把握, 认为 μ 的真实值处于区间 $[0.453, 9.547]$ 中.

(4) 置信区间和假设检验的对偶关系: 双侧置信区间不包含 μ_0 当且仅当双侧假设检验问题

$$H_0: \mu = \mu_0 \quad \text{vs} \quad H_1: \mu \neq \mu_0$$

的原假设被拒绝.

在本题中, 考虑 $H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$. 由于 95% 置信区间中不含 0, 因此该问题的原假设被拒绝, 我们认为声波对心率会产生显著影响.

三、(20 分) 某电视台在考虑缩短广告时间节约成本, 但担心缩短广告时间会导致广告效果产生负面影响, 收集数据如下:

	20s 广告	25s 广告	30s 广告	合计
有印象	16	32	12	60
无印象	44	38	58	140
合计	60	70	70	200

(1)(2 分) 写出 H_0 和 H_1 ;

(2)(5 分) 求各单元格期望计数;

(3)(8 分) 求检验结果;

(4)(5 分) 针对检验结果, 给出你的建议.

Solution: (1) 原假设应为广告时长不影响广告效果, 即

$$H_0: \text{广告效果与广告时长独立} \quad \text{vs} \quad H_1: \text{不独立}$$

(2) 期望计数即为独立情形下预计出现的数量, 由于

$$\hat{p}_{1\cdot} = \frac{60}{200} = 0.3, \quad \hat{p}_{2\cdot} = \frac{70}{200} = 0.35, \quad \hat{p}_{3\cdot} = 0.35,$$

$$\hat{p}_{\cdot 1} = 0.3, \quad \hat{p}_{\cdot 2} = 0.7.$$

而 $E[n_{ij}] = n \cdot \hat{p}_{i\cdot} \cdot \hat{p}_{\cdot j}$, 因此有

	20s 广告	25s 广告	30s 广告	合计
有印象期望	18	21	21	60
无印象期望	42	49	49	140
合计	60	70	70	200

(3) 可计算出对应的差值 (实测 - 期望) 是

	20s 广告	25s 广告	30s 广告
有印象差值	-2	11	-9
无印象差值	2	-11	9

得到列联表检验统计量

$$\chi^2 = \sum_{i,j} \frac{(n_{ij} - E(n_{ij}))^2}{E(n_{ij})} = 14.059,$$

原假设成立时有 $\chi^2 \sim \chi^2((3-1)(2-1)) = \chi^2(2)$, 拒绝域是

$$W = \{\chi^2 \geq \chi_{0.95}^2(2)\},$$

回忆起 $Y \sim \chi^2(2) = \text{Exp}(\frac{1}{2})$, 令 $P(Y > c) = e^{-\frac{c}{2}} = 0.05$, 解得

$$\chi_{0.95}^2(2) = c = -2 \ln(0.05) = 5.99146,$$

显然此时 $14.059 > 5.99146$, 落入拒绝域, 故认为广告时长与广告效果不独立.

(3) 可以发现: 25s 时长的广告效果是最好的. 因此可以将 30s 的广告缩减时间到 25s, 既可以节省成本, 又增强了广告效果.

四、(20 分) 设有线性模型 $Y = a + bX + c \sin X + e$, 其中 $e \sim N(0, d)$. 假设收集到独立数据 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$.

(1)(10 分) 求 a, b, c, d 的极大似然估计 $\hat{a}, \hat{b}, \hat{c}, \hat{d}$.

(2)(5 分) 求 $\hat{a}, \hat{b}, \hat{c}$ 的分布.

(3)(5 分) 根据该模型, 如何判断 Y 与 X 是否存在明显的线性关系?

Solution: (1) 似然函数是

$$L(a, b, c, d) = (2\pi d)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2d} \sum_{i=1}^n (y_i - a - bx_i - c \sin x_i)^2 \right\},$$

对数似然函数是

$$\ell(a, b, c, d) = C - \frac{n}{2} \ln d - \frac{1}{2d} \sum_{i=1}^n (y_i - a - bx_i - c \sin x_i)^2,$$

求导有

$$\begin{cases} \frac{\partial \ell}{\partial a} = \frac{1}{d} \sum_{i=1}^n (y_i - a - bx_i - c \sin x_i), & (1) \\ \frac{\partial \ell}{\partial b} = \frac{1}{d} \sum_{i=1}^n x_i (y_i - a - bx_i - c \sin x_i), & (2) \\ \frac{\partial \ell}{\partial c} = \frac{1}{d} \sum_{i=1}^n \sin x_i (y_i - a - bx_i - c \sin x_i), & (3) \\ \frac{\partial \ell}{\partial d} = -\frac{n}{2d} + \frac{1}{2d^2} \sum_{i=1}^n (y_i - a - bx_i - c \sin x_i)^2, & (4) \end{cases}$$

令它们为 0, 且记 $z_i = \sin x_i$, 由 (4) 直接得

$$\hat{d} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i - \hat{c}z_i)^2,$$

再由 (1) 直接得 $\hat{a} = \bar{y} - \hat{b}\bar{x} - \hat{c}\bar{z}$. 整理 (2) 得

$$\begin{aligned} \sum_{i=1}^n x_i (y_i - a - bx_i - cz_i) &= \sum_{i=1}^n (x_i - \bar{x}) (y_i - \hat{a} - \hat{b}x_i - \hat{c}z_i) \\ &= \sum_{i=1}^n (x_i - \bar{x}) ((y_i - \bar{y}) - \hat{b}(x_i - \bar{x}) - \hat{c}(z_i - \bar{z})) \\ &= l_{xy} - \hat{b}l_{xx} - \hat{c}l_{xz}, \end{aligned}$$

即 $\hat{b}l_{xx} + \hat{c}l_{xz} = l_{xy}$, 同理由 (3) 得 $\hat{b}l_{xz} + \hat{c}l_{zz} = l_{zy}$. 即有线性方程组

$$\begin{cases} l_{xx} \cdot \hat{b} + l_{xz} \cdot \hat{c} = l_{xy}, \\ l_{xz} \cdot \hat{b} + l_{zz} \cdot \hat{c} = l_{zy}, \end{cases}$$

根据克拉默法则, 解得

$$\hat{b} = \frac{l_{xy}l_{zz} - l_{xz}l_{zy}}{l_{xx}l_{zz} - l_{xz}^2}, \quad \hat{c} = \frac{l_{xx}l_{zy} - l_{xy}l_{xz}}{l_{xx}l_{zz} - l_{xz}^2}.$$

代入得

$$\hat{a} = \bar{y} - \hat{b}\bar{x} - \hat{c}\bar{z}, \quad \hat{d} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i - \hat{c}z_i)^2.$$

(2) 根据线性回归结论, 有 $\hat{\beta} \sim N(\beta, Vd)$, 其中 $V = Q^{-1} = (X^T X)^{-1}$, 此处

$$Q = X^T X = \begin{pmatrix} n & \sum x_i & \sum z_i \\ \sum x_i & \sum x_i^2 & \sum x_i z_i \\ \sum z_i & \sum x_i z_i & \sum z_i^2 \end{pmatrix},$$

若记 $V = (v_{ij})$, 则有

$$\hat{a} \sim N(a, v_{11}d), \quad \hat{b} \sim N(b, v_{22}d), \quad \hat{c} \sim N(c, v_{33}d),$$

根据逆矩阵计算公式, 有

$$v_{ij} = \frac{1}{\det(Q)} (-1)^{i+j} Q_{ij}.$$

先计算行列式, 有

$$|Q| \begin{matrix} (2) + (-\bar{x}) \cdot (1) \\ (3) + (-\bar{z}) \cdot (1) \end{matrix} \begin{vmatrix} n & \sum x_i & \sum z_i \\ 0 & \sum x_i^2 - n\bar{x}^2 & \sum x_i z_i - n\bar{x}\bar{z} \\ 0 & \sum x_i z_i - n\bar{x}\bar{z} & \sum z_i^2 - n\bar{z}^2 \end{vmatrix} = n(l_{xx}l_{zz} - l_{xz}^2).$$

因此有

$$\begin{aligned} v_{11}d &= \frac{d}{n(l_{xx}l_{zz} - l_{xz}^2)} \begin{vmatrix} \sum x_i^2 & \sum x_i z_i \\ \sum x_i z_i & \sum z_i^2 \end{vmatrix} = \frac{d}{n(l_{xx}l_{zz} - l_{xz}^2)} \begin{vmatrix} l_{xx} + n\bar{x}^2 & l_{xz} + n\bar{x}\bar{z} \\ l_{xz} + n\bar{x}\bar{z} & l_{zz} + n\bar{z}^2 \end{vmatrix} \\ &= \left(\frac{\bar{z}^2 l_{xx} - 2\bar{x}\bar{z}l_{xz} + \bar{x}^2 l_{zz}}{l_{xx}l_{zz} - l_{xz}^2} + \frac{1}{n} \right) d. \end{aligned}$$

以及

$$v_{22}d = \frac{d}{n(l_{xx}l_{zz} - l_{xz}^2)} \begin{vmatrix} n & \sum z_i \\ \sum z_i & \sum z_i^2 \end{vmatrix} = \frac{l_{zz}}{l_{xx}l_{zz} - l_{xz}^2} d,$$

和

$$v_{33}d = \frac{d}{n(l_{xx}l_{zz} - l_{xz}^2)} \begin{vmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{vmatrix} = \frac{l_{xx}}{l_{xx}l_{zz} - l_{xz}^2} d,$$

综上所述, 有

$$\begin{aligned} \hat{a} &\sim N\left(a, \left(\frac{\bar{z}^2 l_{xx} - 2\bar{x}\bar{z}l_{xz} + \bar{x}^2 l_{zz}}{l_{xx}l_{zz} - l_{xz}^2} + \frac{1}{n} \right) d\right), \\ \hat{b} &\sim N\left(b, \frac{l_{zz}}{l_{xx}l_{zz} - l_{xz}^2} d\right), \quad \hat{c} \sim N\left(c, \frac{l_{xx}}{l_{xx}l_{zz} - l_{xz}^2} d\right). \end{aligned}$$

(3) 根据该模型, 如果 Y 和 X 具有线性关系, 那么系数 $\hat{b}$ 应该非常显著, 同时, 非线性关系项 $\sin X$ 对应的系数 $\hat{c}$ 不应显著.

2021 微观部分解析

一、(5 分) 奶茶店做奶茶, 要加椰果和珍珠两种配料, 剂量用 X_1 和 X_2 表示, 奶茶消费者对一杯奶茶具有完全替代效用 $U = 2X_1 + 3X_2$, 设两种配料对奶茶店的单位成本而言相同。请问奶茶店应该如何分配椰果和珍珠的比例?

Solution:

假设奶茶店的成本函数为 $C(X_1, X_2) = c(X_1 + X_2)$, 其中 c 为两种配料的单位成本。奶茶店的利润最大化问题为:

$$\pi = P_1 X_1 + P_2 X_2 - c(X_1 + X_2)$$

其中 P_1 和 P_2 分别为椰果和珍珠的售价。

消费者的效用函数为:

$$U = 2X_1 + 3X_2$$

消费者的预算约束为:

$$P_1 X_1 + P_2 X_2 \leq I$$

其中 I 为消费者的预算。

显然消费者最优决策:

$$\frac{P_1}{P_2} = \frac{2}{3}$$

- 若 $\frac{P_1}{P_2} < \frac{2}{3}$, 则 $X_1 = \frac{I}{P_1}, X_2 = 0$; - 若 $\frac{P_1}{P_2} > \frac{2}{3}$, 则 $X_1 = 0, X_2 = \frac{I}{P_2}$; - 若 $\frac{P_1}{P_2} = \frac{2}{3}$, 则任意 $X_1 \geq 0, X_2 \geq 0$ 的组合都满足效用最大化。

企业:

$$\min C(X_1, X_2) = c(X_1 + X_2)$$

显然 - 若 $\frac{P_1}{P_2} \leq \frac{2}{3}$, 此时 $X_1 = \frac{I}{P_1}, X_2 = 0$, 令 P_1 尽量大, 最优决策应选择 $P_2 = \frac{3}{2}P_1$; - 若 $\frac{P_1}{P_2} \geq \frac{2}{3}$, 此时 $X_1 = 0, X_2 = \frac{I}{P_2}$, 令 P_2 尽量大, 最优决策应选择 $P_2 = \frac{3}{2}P_1$ 。

因此, 最优价格比例为 $\frac{P_1}{P_2} = \frac{2}{3}$, 不难发现此时有只卖椰果和只卖珍珠两种决策, 显然只卖珍珠奶茶店利润较高。奶茶店应优先提供配料 X_2 (珍珠), 不提供配料 X_1 (椰果)。

注: 此题完全不需要数理分析, 从经济学意义而言, 椰果和珍珠对奶茶店同等成本, 珍珠和椰果对消费者来说又是完全互补品, 且珍珠的效用更高, 显然只放珍珠更能 “以较低成本让消费者满意”, 从而赚取利润。如果一定要数理分析, 也可以考虑固定一个目标效用 u 和一个给定预算 I , 求成本最小化即可。

[经济学论述]

上述结论也可以通过更直观的经济逻辑直接得出, 无需复杂的规划求解。核心在于比较两种配料的成本-效用效率。

1. 产品属性分析: 题目给出的效用函数 $U = 2X_1 + 3X_2$ 表明椰果 (X_1) 和珍珠 (X_2) 对消费者而言是完全替代品。这意味着消费者并不在乎两者的搭配比例, 只在乎总效用的大小。

2. 边际效用与成本比较：- 边际效用：每增加一单位椰果带来 2 单位效用 ($MU_1 = 2$)，每增加一单位珍珠带来 3 单位效用 ($MU_2 = 3$)。显然，珍珠对消费者的价值更高。- 边际成本 (MC)：题目假设两种配料的单位成本相同，即 $MC_1 = MC_2 = c$ 。

3. 效率决策：对于企业而言，其目标是以最低的成本为消费者提供特定的效用水平（或者在固定成本下提供最高的效用以吸引顾客）。我们可以比较两者的效用/成本比率：

$$\frac{MU_1}{MC_1} = \frac{2}{c} < \frac{MU_2}{MC_2} = \frac{3}{c}$$

这表明，花费同样的成本 c ，生产珍珠能产生 3 单位效用，而生产椰果只能产生 2 单位效用。珍珠的生产效率（定义为单位成本产生的消费者效用）是椰果的 1.5 倍。

4. 结论：由于两种商品完全可替代，且珍珠具有绝对的成本效率优势，理性的奶茶店会选择角点解：将所有资源用于生产效率更高的配料 X_2 （珍珠），而完全放弃 X_1 （椰果）。这样做可以在成本不变的情况下最大化消费者的满意度，从而最大化潜在的市场竞争力和利润。

二、(20 分) 两个雇员工资都是 M ，消费者两种商品价格分别为 P_1 和 P_2 ，雇员 1 的效用函数是 $U_1 = X_{11}^{0.5} + X_{12}^{0.5}$ ，雇员 2 的效用函数是 $U_2 = X_{21}^{0.5} X_{22}^{0.5}$ ，现在企业要解雇一名雇员，两名雇员有相同的几率被辞退，被裁员者的收入为 0。

1. (10 分) 假设两名雇员之间签订一份契约，不管谁被解雇了，都和对方平分自己的收入 ($M/2$)，那么两名雇员都有动机签订契约么？

2. (10 分) 现在假设两名雇员都认为对方会不守信用而不履行契约，有违约风险，于是想找一名律师并支付 x 的律师费，将契约写成一份合同。不管谁被解雇，在合同生效时，一方支付 T 的补偿金，保证两人收入一样。请问使得两名雇员都能接受支付 x 的最大值是多少？

Solution:

(1) 先看雇员 1。如果签订契约：无论谁被辞退，收入都是 $0.5M$ 。

$$\max U_1 = x_{11}^{0.5} + x_{12}^{0.5}$$

约束条件为：

$$P_1 x_{11} + P_2 x_{12} = 0.5M$$

解得：

$$x_{11} = \frac{0.5M \cdot P_2}{P_1 + P_2}, \quad x_{12} = \frac{0.5M \cdot P_1}{P_1 + P_2}$$

对应的效用为：

$$U_1(0.5M) = \frac{\sqrt{0.5M}}{\sqrt{P_1 + P_2}} \left(\sqrt{\frac{P_2}{P_1}} + \sqrt{\frac{P_1}{P_2}} \right)$$

如果不签订契约：有 0.5 的概率收入为 0，对应效用为 0；有 0.5 的概率收入为 M ，对应效用为 $U_1(M)$ 。

$$U_1(M) = \frac{\sqrt{M}}{\sqrt{P_1 + P_2}} \left(\sqrt{\frac{P_2}{P_1}} + \sqrt{\frac{P_1}{P_2}} \right)$$

期望效用为：

$$EU_1 = 0.5 \times U_1(M)$$

即：

$$EU_1 = 0.5 \times \frac{\sqrt{M}}{\sqrt{P_1 + P_2}} \left(\sqrt{\frac{P_2}{P_1}} + \sqrt{\frac{P_1}{P_2}} \right)$$

因为 $U_1(0.5M) > 0.5 \times U_1(M)$ ，因此 ** 雇员 1 应该签订契约 **。

再看雇员 2，如果签订合同：

$$\max U_2 = x_{21}^{0.5} x_{22}^{0.5}$$

约束条件为：

$$P_1 x_{21} + P_2 x_{22} = 0.5M$$

解得：

$$x_{21} = \frac{M}{4P_1}, \quad x_{22} = \frac{M}{4P_2}$$

对应的效用为：

$$U_2(0.5M) = \frac{M}{4} \frac{1}{\sqrt{P_1 P_2}}$$

如果不签订合同：有 0.5 的概率收入为 0，对应效用为 0；有 0.5 的概率收入为 M ，对应效用为 $U_2(M)$ 。

$$U_2(M) = \frac{M}{2} \frac{1}{\sqrt{P_1 P_2}}$$

期望效用为：

$$EU_2 = 0.5 \times U_2(M) = \frac{M}{4} \frac{1}{\sqrt{P_1 P_2}} = U_2(0.5M)$$

因此 ** 雇员 2 签订与不签订合同无差异 **。

(2) 根据题意，** 补偿金额为 $T = 0.5M$ **，不管谁被辞退，收入都是相同的，无风险。

对于雇员 1 来说：

$$U_1(0.5M - x) = \sqrt{\frac{0.5M - x}{P_1 + P_2}} \left(\sqrt{\frac{P_2}{P_1}} + \sqrt{\frac{P_1}{P_2}} \right)$$

对于雇员 2 来说：

$$U_2(0.5M - x) = \frac{0.5M - x}{2} \cdot \frac{1}{\sqrt{P_1 P_2}}$$

如果不找律师：

雇员 1 的期望效用为：

$$EU_1 = 0.5 \times \sqrt{\frac{M}{P_1 + P_2}} \left(\sqrt{\frac{P_2}{P_1}} + \sqrt{\frac{P_1}{P_2}} \right)$$

雇员 2 的期望效用为：

$$EU_2 = 0.5 \times U_2(M) = \frac{M}{4} \cdot \frac{1}{\sqrt{P_1 P_2}}$$

对于雇员 1 来说， x 必须满足：

$$U_1(0.5M - x) \geq EU_1 \Rightarrow 0.5M - x \geq 0.25M$$

因此，解得：

$$x \leq 0.25M$$

对于雇员 2 来说，任何 $x > 0$ 都不可行。因此，雇员 2 会选择 ** 不找律师 **。

因此，补偿金额 x 的最大值为 $0.25M$ 。

注：此题难度主要在于理解题意：当聘请律师后，究竟补偿金额为多少？此处确实存在歧义，但我们应该这样去思考：对 2 来说是不会找律师的，如果他没有失业，也自然会给对方 $0.5M$ 而不是更多，因为他无权与 1 一起承担风险；那么当 2 被解雇时，他对于 $0.5M$ 的需求也是自然的。对 1 来说，由于签订合同是有利的，所以他会促成此事，为此承担一个律师费，而不是让 2 一起承担，所以他被解雇后只会有 $0.5M - x$ ，未被解雇也是 $0.5M - x$ 。

三、(15 分) 有两种消费者, 200 名高收入消费者愿意花 20 元购买商品, 300 名低收入消费者愿意花 10 元购买商品, 厂商成本 5 元, 询问:

1. (7 分) 若厂商不能区分两类消费者, 要如何定价才能利润最大化?
2. (8 分) 现在可以购买大数据技术区分二类消费者, 请问厂商愿意花多少钱购买技术?

Solution:

(1) 在不能区分消费者的情况下, 厂商必须采用统一价格。厂商有两种选择: 要么保留两类消费者, 要么只保留一类消费者。

保留两类消费者: 只能收取低收入者的保留价格, 即 10 元。厂商利润为:

$$\pi_b = (10 - 5) \times 500 = 2500$$

保留一类消费者: 收取高收入消费者的保留价格, 即 20 元。厂商利润为:

$$\pi_s = (20 - 5) \times 200 = 3000$$

因此, 无法区分两类消费者的情况下, 厂商选择保留高收入消费者, 定价为 20 元, 利润最大化为 3000 元。

(2) 在能区分两类消费者的情况下, 厂商可以收取每类消费者的保留价格。记厂商花 x 元购买技术, 则厂商利润为:

$$\pi = (10 - 5) \times 300 + (20 - 5) \times 200 - x = 4500 - x$$

厂商购买技术后总利润应不小于 3000 元, 因此有:

$$4500 - x \geq 3000$$

解得:

$$x \leq 1500$$

因此, 厂商最多愿意花 1500 元购买该技术。

四、(15 分) 三个厂商进行博弈, 每个厂商可以选择进入或者不进入, 厂商进入后的收入为 $150/n$, 厂商生产成本为 c , $c \in (50, 75)$ 。

1. (6 分) 求出所有的纯策略纳什均衡。
2. (7 分) 求出唯一对称的混合纳什均衡。
3. (2 分) 与混合纳什均衡中的行为有何关系?

Solution:

(1) 纳什均衡满足互为最优原则。我们分析三种情况:

情况 1: ** 所有三个企业都进入 **

每个企业的利润为:

$$\pi_i = \frac{150}{3} - c < 0$$

因此, 纳什均衡下不可能有三个企业都选择进入市场。

情况 2: ** 只有一个企业进入 **

例如, (进入, 不进入, 不进入)。进入的企业利润为:

$$\pi = 150 - c > 0$$

而不进入的企业利润为 0。如果未进入的企业选择进入, 利润为:

$$\pi = 75 - c > 0$$

因此，一个企业进入的情形不是纳什均衡。

情况 3: ** 两个企业进入 **

例如，(进入，进入，不进入)。此时，进入企业的利润为：

$$\pi = 75 - c > 0$$

不进入的企业利润为 0，如果它选择进入，利润为：

$$\pi = 50 - c < 0$$

因此，这种情况下的均衡是纳什均衡。

纯策略纳什均衡有三种情况：

(进入，进入，不进入)，(进入，不进入，进入)，(不进入，进入，进入)

(2) 设每个企业选择进入的概率为 p ，均衡时“进入”与“不进入”带来的期望利润应无差异。

企业不进入，利润为 0。

企业进入时，利润期望为：

$$(50 - c)p^2 + (150 - c)(1 - p)p + 2p(1 - p)(75 - c)$$

化简为：

$$50p^2 - 150p + 150 - c = 0$$

解得：

$$p = \frac{150 - \sqrt{150^2 - 200 \cdot (150 - c)}}{100} = \frac{15 - \sqrt{2c - 75}}{10}$$

其中 $p \in (0, 1)$ 。

(3) 当成本 $c \rightarrow 50$ 时，进入的概率 $p \rightarrow 1$ 。这说明当进入市场的成本降低时，企业更有可能选择进入市场。

五、(20 分) 张三和李四进行二阶段博弈，行动集为 $\sigma = \{L, R\}$ 。第一阶段，张三先行动选择 $A \in \sigma$ ；第二阶段，李四观察到张三的行动后选择 $B \in \sigma$ ，后行动者可以看到先行动者的选择。两人的收益根据行动的结果有如下关系：- 如果 $A = B = L$ ，则张三获得的收益为 3，李四获得的收益为 1；- 如果 $A = B = R$ ，则张三获得的收益为 1，李四获得的收益为 3；- 如果 $A \neq B$ ，则两人获得的收益都为 0。

1. (7 分) 请求出子博弈精炼均衡。

2. (7 分) 请求出和第一个问不同的纯策略纳什均衡，它是子博弈精炼均衡吗？

3. (6 分) 现在假设在第二阶段开始之前，获得选择是否（无成本）观察张三行动的权利，请求出相同条件下与第二问一致的子博弈精炼均衡。

Solution:

(1) 根据题目给出的博弈树，张三先行动，李四后行动。我们通过 ** 逆向归纳法 ** 求解。

(i) 如果张三选择 L ，李四会选择 L ，因为此时李四的收益为 1，大于选择 R 的收益 0。因此，在张三选择 L 时，李四选择 L ，二人的收益为 (3, 1)。

(ii) 如果张三选择 R ，李四会选择 R ，因为此时李四的收益为 3，大于选择 L 的收益 0。因此，在张三选择 R 时，李四选择 R ，二人的收益为 (1, 3)。

因此，子博弈精炼纳什均衡为 $\{L, (L, R)\}$ 。

(2) 根据博弈的扩展形式，我们可以写出如下收益矩阵：

	(L, L)	(L, R)	(R, L)	(R, R)
L	(3, 1)	(3, 1)	(0, 0)	(0, 0)
R	(0, 0)	(1, 3)	(0, 0)	(1, 3)

左侧为张三的策略，上方为李四的策略。由此可知，共有三个纯策略纳什均衡：

$$\{L, (L, L)\}, \{L, (L, R)\}, \{R, (R, R)\}$$

其中， $\{R, (R, R)\}$ 是与第一个问题不同的纯策略纳什均衡，它不是子博弈精炼均衡，因为张三首先会选择 L，并且这样李四也会选择 L，这个均衡结果并不在 $\{R, (R, R)\}$ 中。

(3) 序贯均衡：我们需要在李四的决策中加入一个“观察”或者“不观察”的选项。注意审题：** 均衡结果与第二问一致 ** 的子博弈精炼均衡。首先考虑李四观察：那么均衡结果与第一问一致，与第二问不一致。所以李四一定不观察，此时由于李四是后做决策，实际上是一个静态博弈：张三无论选择什么，李四的选择都应该是一致的，有没有可能李四以一定的概率选择 L 和 R 呢，不可能，这首先不符合均衡结果，其次也不会是子博弈精炼均衡。所以，李四只会选择 (** 不观察, R **)，因为 (不观察, L) 也不会出现这样的均衡结果，此时只需要考虑张三怎样选择结果是子博弈精炼均衡，显然是 R。结论：R, (R) 为所求子博弈精炼均衡。

北京大学-431 金融学综合-2022

2022 统计部分解析

一、(20 分) 设 X 有密度函数

$$f(x) = \begin{cases} c(1-x^2), & |x| \leq 1, \\ 0, & \text{其他.} \end{cases}$$

(1)(5 分) 求 c .

(2)(10 分) 求 X 的期望和方差.

(3)(5 分) 求 $Y = X^2$ 的概率分布.

Solution:

(1) 由密度函数的正则性, 有

$$1 = c \int_{-1}^1 (1-x^2) dx = c \left(2 - \frac{2}{3} \right) = \frac{4}{3}c,$$

解得 $c = \frac{3}{4}$.

(2) 先计算期望, 由奇函数性质, 有

$$E(X) = \frac{3}{4} \int_{-1}^1 x(1-x^2) dx = 0.$$

再算二阶矩, 由偶函数性质, 有

$$E(X^2) = \frac{3}{4} \int_{-1}^1 x^2(1-x^2) dx = \frac{3}{2} \int_0^1 (x^2 - x^4) dx = \frac{3}{2} \left(\frac{1}{3} - \frac{1}{5} \right) = \frac{1}{5}.$$

因此 $Var(X) = \frac{1}{5}$.

(3) 利用分布函数法, 对 $y \in (0, 1)$, 有

$$P(Y \leq y) = \frac{3}{4} \int_{-\sqrt{y}}^{\sqrt{y}} (1-x^2) dx = \frac{3}{4} \left(2\sqrt{y} - \frac{2}{3}y^{\frac{3}{2}} \right) = \frac{3}{2}y^{\frac{1}{2}} - \frac{1}{2}y^{\frac{3}{2}}.$$

求导, 得

$$f_Y(y) = \frac{3}{4}y^{-\frac{1}{2}} - \frac{3}{4}y^{\frac{1}{2}}, \quad y \in (0, 1).$$

二、(15 分) 某生产灯泡的公司想估计灯泡的平均寿命 (小时). 设灯泡寿命 $X \sim N(\mu, 1000^2)$.

(1)(5 分) 想将 95% 的置信水平的置信区间误差控制在 ± 200 小时内, 需要多少样本量?

(2)(5 分) 现将置信水平改为 99%, 重新回答 (1).

(3)(5 分) 现在考虑置信水平还是 95%, 但误差需要在 ± 100 小时内, 需要多少样本量?

Solution: (1) 枢轴量为 $Z = \sqrt{n} \frac{\bar{x} - \mu}{1000} \sim N(0, 1)$, 因此有置信区间

$$\left[\bar{x} - z_{0.975} \frac{1000}{\sqrt{n}}, \bar{x} + z_{0.975} \frac{1000}{\sqrt{n}} \right].$$

查表得 $z_{0.975} = 1.96$, 因此令

$$1.96 \frac{1000}{\sqrt{n}} \leq 200, \Rightarrow n \geq \left(1.96 \frac{1000}{200} \right)^2 = 96.04.$$

这说明至少需要 97 个样本量.

(2) 同理, 查表得 $z_{0.995} = 2.58$, 因此令

$$2.58 \frac{1000}{\sqrt{n}} \leq 200, \Rightarrow n \geq \left(2.58 \frac{1000}{200} \right)^2 = 166.41.$$

这说明至少需要 167 个样本量.

(3) 令

$$1.96 \frac{1000}{\sqrt{n}} \leq 100, \Rightarrow n \geq \left(1.96 \frac{1000}{100}\right)^2 = 384.16.$$

至少需要 385 个样本量.

三、(20 分) 为调查折扣水平和订阅服务量是否有关, 收集如下数据.

	无折扣	普通折扣	大折扣	总和
订阅	20	50	30	100
不订阅	80	150	70	300
总和	100	200	100	400

(1)(5 分) 写出 H_0 和 H_1 .

(2)(10 分) 给出检验统计量及其在 H_0 下的分布, 并计算其样本值.

(3)(5 分) 在 0.05 显著性水平下, 是否认为折扣水平和订阅服务量有关?

Solution: (1) 原假设应是折扣水平和订阅服务量无关, 备择假设是有关, 即

H_0 : 折扣水平和订阅服务量独立 vs H_1 : 不独立

(2) 列联表检验统计量

$$\chi^2 = \sum_{i,j} \frac{(n_{ij} - n\hat{p}_{i\cdot}\hat{p}_{\cdot j})^2}{n\hat{p}_{i\cdot}\hat{p}_{\cdot j}} \sim \chi^2((3-1)(2-1)) = \chi^2(2).$$

我们先计算出独立时每个单元格期望值 $n\hat{p}_{i\cdot}\hat{p}_{\cdot j}$, 即

	无折扣	普通折扣	大折扣	总和
订阅	25	50	25	100
不订阅	75	150	75	300
总和	100	200	100	400

对应计算出差值 $n_{ij} - n\hat{p}_{i\cdot}\hat{p}_{\cdot j}$, 即

	无折扣	普通折扣	大折扣
订阅差值	-5	0	5
不订阅差值	5	0	-5

因此有卡方统计量的值为

$$\chi^2 = 5^2 \left(\frac{1}{25} + \frac{1}{75} \right) + 0 + 5^2 \left(\frac{1}{25} + \frac{1}{75} \right) = 2.66667.$$

(3) 对应的拒绝域是

$$W = \{\chi^2 \geq \chi_{0.95}^2(2)\},$$

回忆起 $Y \sim \chi^2(2) = \text{Exp}(\frac{1}{2})$, 令 $P(Y > c) = e^{-\frac{c}{2}} = 0.05$, 解得

$$\chi_{0.95}^2(2) = c = -\ln(0.05) = 5.99146,$$

显然此时 $2.66667 < 5.99146$, 不落入拒绝域, 故我们认为订阅量与折扣水平独立.

四、(20 分) 设有线性模型 $Y = a + bX + c \ln X + e$, 其中 $e \sim N(0, \sigma^2)$. 假设收集到独立数据 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$.

(1)(5 分) 求 a, b, c 的 OLS 估计量.

(2)(5 分) 根据该模型, 如何判断 Y 与 X 是否存在明显的线性关系?

(3)(10 分) 如果 Y 与 X 存在线性关系, 求 b 的 OLS 估计量, 并证明它是无偏的.

Solution:

(1) 记 $z_i = \ln x_i$, OLS 估计意味着残差平方和最小, 即

$$Q(a, b, c) = \sum_{i=1}^n (y_i - a - bx_i - cz_i)^2$$

最小. 求导有

$$\begin{cases} \frac{\partial Q}{\partial a} = -\sum_{i=1}^n (y_i - a - bx_i - cz_i), & (1) \\ \frac{\partial Q}{\partial b} = -\sum_{i=1}^n x_i (y_i - a - bx_i - cz_i), & (2) \\ \frac{\partial Q}{\partial c} = -\sum_{i=1}^n z_i (y_i - a - bx_i - cz_i), & (3) \end{cases}$$

令它们为 0, 由 (1) 直接得 $\hat{a} = \bar{y} - \hat{b}\bar{x} - \hat{c}\bar{z}$. 整理 (2) 得

$$\begin{aligned} \sum_{i=1}^n x_i (y_i - a - bx_i - cz_i) &= \sum_{i=1}^n (x_i - \bar{x}) (y_i - \hat{a} - \hat{b}x_i - \hat{c}z_i) \\ &= \sum_{i=1}^n (x_i - \bar{x}) ((y_i - \bar{y}) - \hat{b}(x_i - \bar{x}) - \hat{c}(z_i - \bar{z})) \\ &= l_{xy} - \hat{b}l_{xx} - \hat{c}l_{xz}, \end{aligned}$$

即 $\hat{b}l_{xx} + \hat{c}l_{xz} = l_{xy}$, 同理由 (3) 得 $\hat{b}l_{xz} + \hat{c}l_{zz} = l_{zy}$. 即有线性方程组

$$\begin{cases} l_{xx} \cdot \hat{b} + l_{xz} \cdot \hat{c} = l_{xy}, \\ l_{xz} \cdot \hat{b} + l_{zz} \cdot \hat{c} = l_{zy}, \end{cases}$$

根据克拉默法则, 解得

$$\hat{b} = \frac{l_{xy}l_{zz} - l_{xz}l_{zy}}{l_{xx}l_{zz} - l_{xz}^2}, \quad \hat{c} = \frac{l_{xx}l_{zy} - l_{xy}l_{xz}}{l_{xx}l_{zz} - l_{xz}^2}.$$

代入得 $\hat{a} = \bar{y} - \hat{b}\bar{x} - \hat{c}\bar{z}$.

(2) 根据该模型, 如果 Y 和 X 具有线性关系, 那么系数 $\hat{b}$ 应该非常显著, 同时, 非线性关系项 $\ln X$ 对应的系数 $\hat{c}$ 不应显著.

(3) 如果已知 Y 和 X 只存在线性关系, 则有非线性关系项 $\ln X$ 对应的系数真值为 $c = 0$, 此时残差平方和为 $Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2$, 重复 (1) 中求导步骤得

$$\hat{a} = \bar{y} - \hat{b}\bar{x}, \quad \hat{b} = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

根据期望的线性性, 有

$$\begin{aligned} E(\hat{b}) &= \frac{\sum_{i=1}^n (x_i - \bar{x}) E(y_i - \bar{y})}{l_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x}) (a + bx_i - (a + b\bar{x}))}{l_{xx}} \\ &= \frac{\sum_{i=1}^n b(x_i - \bar{x})^2}{l_{xx}} = \frac{bl_{xx}}{l_{xx}} = b. \end{aligned}$$

2022 微观部分解析

一、(21 分) 假设有两个风险资产 X 和 Y 。每投资 1 元在 X 中, 在牛市时获得的总回报为 R_{X1} , 在熊市时获得的总回报为 R_{X2} 。每投资 1 元在 Y 中, 在牛市时获得的总回报为 R_{Y1} , 在熊市时获得的总回报为 R_{Y2} 。牛市和熊市发生的概率均为 0.5, 投资者可用于投资的金额为 10 元。投资者的期望效用函数为 $E(W_1) - \gamma Var(W_1)$, 其中 W_1 为总投资回报, $E(W_1)$ 和 $Var(W_1)$ 分别为期望和方差, $\gamma = 0.1$ 为风险厌恶系数。投资者没有其他渠道可用于投资。

1. (6 分) 如果 $R_{X1} = 1.5, R_{X2} = 0.9, R_{Y1} = 0.8, R_{Y2} = 1.6$, 假设投资者只能选择其中一个风险资产投资, 那么他会选择哪一个? 为什么? 获得的效用是多少?

2. (6 分) 如果 $R_{X1} = 1.5, R_{X2} = 0.9, R_{Y1} = 0.6, R_{Y2} = 2.0$, 假设投资者只能选择其中一个风险资产投资, 那么他会选择哪一个? 为什么? 获得的效用是多少?

3. (9 分) 如果 $R_{X1} = 1.5, R_{X2} = 0.9, R_{Y1} = 0.6, R_{Y2} = 2.0$, 假设投资者可以分配投资金额比例 α 在风险资产 X , $(1 - \alpha)$ 在风险资产 Y , 其中 $0 \leq \alpha \leq 1$ 。求使得最大化投资者期望效用的 α 。

Solution:

(1) 牛市和熊市的回报分别为:

- 资产 X : 牛市回报 $10 \times 1.5 = 15$, 熊市回报 $10 \times 0.9 = 9$;

- 资产 Y : 牛市回报 $10 \times 0.8 = 8$, 熊市回报 $10 \times 1.6 = 16$ 。

期望和方差为:

$$E(W_X) = 0.5 \times 15 + 0.5 \times 9 = 12, \quad Var(W_X) = 0.5 \times (15 - 12)^2 + 0.5 \times (9 - 12)^2 = 9$$

$$E(W_Y) = 0.5 \times 8 + 0.5 \times 16 = 12, \quad Var(W_Y) = 0.5 \times (8 - 12)^2 + 0.5 \times (16 - 12)^2 = 16$$

效用分别为:

$$U_X = 12 - 0.1 \times 9 = 11.1, \quad U_Y = 12 - 0.1 \times 16 = 10.4.$$

因此投资者选择资产 X , 因为 $U_X > U_Y$ 。

(2) 牛市和熊市的回报分别为:

- 资产 X : 牛市回报 $10 \times 1.5 = 15$, 熊市回报 $10 \times 0.9 = 9$;

- 资产 Y : 牛市回报 $10 \times 0.6 = 6$, 熊市回报 $10 \times 2.0 = 20$ 。

期望和方差为:

$$E(W_X) = 0.5 \times 15 + 0.5 \times 9 = 12, \quad Var(W_X) = 0.5 \times (15 - 12)^2 + 0.5 \times (9 - 12)^2 = 9$$

$$E(W_Y) = 0.5 \times 6 + 0.5 \times 20 = 13, \quad Var(W_Y) = 0.5 \times (6 - 13)^2 + 0.5 \times (20 - 13)^2 = 49$$

效用分别为:

$$U_X = 12 - 0.1 \times 9 = 11.1, \quad U_Y = 13 - 0.1 \times 49 = 8.1$$

这说明, 投资者会选择资产 X , 因为 $U_X > U_Y$ 。

(3) 总回报为:

$$W = 10 \times (\alpha R_X + (1 - \alpha) R_Y)$$

在牛市和熊市下的回报分别为:

$$W_1 = 10 \times (0.9\alpha + 0.6), \quad W_2 = 10 \times (-1.1\alpha + 2.0)$$

求期望, 有:

$$E(W) = 0.5 \times W_1 + 0.5 \times W_2 = -1\alpha + 13,$$

求方差, 有:

$$Var(W) = 100\alpha^2 - 140\alpha + 49.$$

因此, 效用函数是:

$$U(\alpha) = (13 - \alpha) - 0.1 \times (100\alpha^2 - 140\alpha + 49) = 8.1 + 13\alpha - 10\alpha^2.$$

对 $U(\alpha)$ 求导:

$$\frac{dU(\alpha)}{d\alpha} = 13 - 20\alpha,$$

解得最优 α :

$$\alpha = \frac{13}{20} = 0.65.$$

因此, 投资者应将约 65% 的资金投资于资产 X , 35% 的资金投资于资产 Y 。

二、(16 分) 某地消费者需要采购两种商品, 分别为加湿器 x 和净化器 y , 消费者获得的总效用为 $x^{\frac{1}{3}}y^{\frac{2}{3}}$, 加湿器的价格为 1, 净化器价格为 4。消费者采购两种商品的总预算为 24。

1. (4 分) 计算加湿器和净化器的采购数量 x 和 y 。

2. (5 分) 由于净化器能耗较高, 政府考虑把对生产该商品的厂商征税, 从而使其价格变为 $4t_1$ ($t_1 > 1$)。求解 t_1 , 使得净化器的采购量变为问题 (1) 中净化器采购量的 50%。

3. (5 分) 若政府向消费者征收所得税, 使其总预算变为 $24t_2$ ($0 < t_2 < 1$)。求解 t_2 , 使得净化器采购量变为问题 (1) 中净化器采购量的 50%。

4. (2 分) 哪一种征税方案下消费者的效用较高? 有什么政策启示?

Solution:

本题可用常规的拉格朗日乘数法解决, 我们这里展示一种基本不等式法。

(1) 问题等价于:

$$\max_{x,y} x^{\frac{1}{3}}y^{\frac{2}{3}} \quad \text{s.t.} \quad x + 4y = 24$$

通过预算约束 $24 = x + 4y = x + 2y + 2y \geq 3 \cdot \sqrt[3]{x \cdot 2y \cdot 2y} = 3 \cdot 4 \cdot \sqrt[3]{x^{\frac{1}{3}}y^{\frac{2}{3}}}$, 推导出:

$$x^{\frac{1}{3}}y^{\frac{2}{3}} \leq 8 \cdot 4^{-\frac{1}{3}}$$

当且仅当 $x = 2y$ 时取等, 即 $x = 8, y = 4$ 。

(2) 现在有:

$$24 = x + 4t_1y = x + 2t_1y + 2t_1y \geq 3 \cdot (4t_1)^{\frac{1}{3}} \cdot (x^{\frac{1}{3}}y^{\frac{2}{3}})$$

当且仅当 $x = 2t_1y$ 时取等, 即 $y = \frac{4}{t_1}$, 解得 $t_1 = 2$ 。

(3) 新的预算约束为:

$$24t_2 = x + 4y \geq 3 \cdot 4^{\frac{1}{3}} \cdot (x^{\frac{1}{3}}y^{\frac{2}{3}})$$

因此 $y = 4t_2$, 解得 $t_2 = 0.5$ 。

(4) 第 (2) 问中:

$$U_{\max}^2 = 8 \cdot (4t_1)^{-\frac{1}{3}} = 8 \cdot 8^{-\frac{1}{3}}$$

第 (3) 问中:

$$U_{\max}^3 = 8t_2 \cdot 4^{-\frac{1}{3}} = 4 \cdot 4^{-\frac{1}{3}}$$

因此: $U_{\max}^2 > U_{\max}^3$, 这说明对消费者征税时更影响消费者的效用, 对商家征税时消费者的效用影响则较小, 政府在征税时, 应该针对商品征税, 而不是征收所得税。(可参考食品券补贴没有金钱补贴好)

三、(18 分) 市场上有两家厂商, 产品稍有差异但仍可以相互替代。厂商 1 面临的市场逆需求函数为 $p_1 = 100 - 2q_1 - q_2$, 总成本函数是其总产出 q_1 的二次函数, 为 $\frac{1}{2}q_1^2$ 。厂商 2 面临的市场逆需求函数为 $p_2 = 100 - q_1 - \beta q_2$ (其中 $\beta > 1$), 总成本为 q_2 , 即单位产出的成本是常数 1。双方各自定产以便优化各自的利润, 无法协同调控此间的行动。

1. (6 分) 求厂商 1 的产量和利润。
2. (6 分) 求厂商 2 的产量和利润。
3. (4 分) 在何种条件下, 厂商 2 会停止生产。此时, 厂商 1 成为垄断商, 求此时厂商 1 的产量和利润。
4. (2 分) 假设厂商 2 的产量为正。当 β 上升时, 厂商 1 的价格如何变化, 是上升还是下降?

Solution:

(1) (2) 我们需同时考虑两问。厂商 1 的反应函数为:

$$q_1 = \frac{100 - q_2}{5}$$

厂商 2 的反应函数为:

$$q_2 = \frac{99 - q_1}{2\beta}$$

联立求解得:

$$q_1 = \frac{200\beta - 99}{10\beta - 1}, \quad q_2 = \frac{395}{10\beta - 1}$$

在厂商 1 的利润函数中代入 q_1 和 q_2 :

$$\pi_1 = (100 - 2q_1 - q_2) \cdot q_1 - \frac{1}{2}q_1^2 = \frac{(600\beta - 297)(200\beta - 99) - \frac{1}{2}(200\beta - 99)^2}{(10\beta - 1)^2}$$

在厂商 2 的利润函数中代入 q_1 和 q_2 :

$$\pi_2 = (100 - q_1 - \beta q_2) \cdot q_2 - q_2 = \frac{395 \times 395\beta}{(10\beta - 1)^2}.$$

(3) 厂商 2 的反应函数为:

$$q_2 = \frac{99 - q_1}{2\beta}$$

怎样有 $q_2 = 0$? 我们有两种考虑: 第一种, 厂商 1 扩大产量恶性竞争:

$$99 - q_1 = 0 \Rightarrow q_1 = 99$$

第二种，厂商 2 的 β 太大，趋于无穷，使得 q_2 近似为 0。这两种中，第二种更为合理一点，因为它是不变动的，而 q_1 变动下难以保证 2 的一直停产。当厂商 2 停产，厂商 1 成为垄断者，厂商 1 的利润函数为：

$$\pi_1(q_1) = (100 - 2q_1) \cdot q_1 - \frac{1}{2}q_1^2 = 100q_1 - 2.5q_1^2$$

对 q_1 求导数，得：

$$\frac{\partial \pi_1}{\partial q_1} = 100 - 5q_1 = 0 \Rightarrow q_1 = 20$$

代入利润函数，得到：

$$\pi_1 = 100 \times 20 - 2.5 \times 20^2 = 1000$$

因此，当 $\beta \rightarrow \infty$ ，厂商 2 将停产。在厂商 2 停产，厂商 1 的最优垄断产量为 20，利润为 1000。（或厂商 1 保持长时间的 $q_1 = 99$ 的高产量，威胁压迫厂商 2 停产也有可能。）

(4) 回到 (1)、(2) 间的大环境中，有厂商 1 的市场价格为：

$$p_1 = 100 - 2q_1 - q_2,$$

其中：

$$q_1 = \frac{200\beta - 99}{10\beta - 1}, \quad q_2 = \frac{395}{10\beta - 1}.$$

代入得：

$$p_1 = 100 - \frac{400\beta + 197}{10\beta - 1}$$

对 β 求导，得到：

$$\frac{dp_1}{d\beta} = \frac{8000\beta + 2370}{(10\beta - 1)^2}$$

由于 $\frac{dp_1}{d\beta} > 0$ ，因此当 β 上升时，厂商 1 的价格 p_1 上升。

四、(20 分) 有一个村子以养羊闻名。全村有 N 个农户，假设第 i 个用户养 q_i 只羊，那么全村总的养羊只数为 $Q = \sum_{i=1}^N q_i$ 。每只羊在市场上的价格为 $p = 200 - Q$ 。假设养羊没有成本。

1. (5 分) 假设每个农户独立决定养羊的数量来最大化各自的利润。求此时每个农户养羊只数、全村总的养羊只数、每只羊的市场价格以及每个农户的利润。

2. (5 分) 假设村长可以将全村所有农户组织起来，先决定全村的养羊只数，再把总利润平均分给每个农户。问此时全村总的养羊只数、每只羊的市场价格以及每个农户的利润。

3. (4 分) 给定农户数 N ，比较 (1) 和 (2) 中每个农户的养羊数量和利润，以及全村总的养羊数。

4. (2 分) 当 N 趋于无穷大时，(1) 和 (2) 中全村养羊总利润会如何变化？

5. (4 分) 现在村长对农户养的每只羊征税 t ，税款作为村子建设基金费用，因此不再返还农户。村长应该如何设置税额 t ，使得每个农户独立养羊的数量和 (2) 中最大化全村总利润时的每户养羊数相等。

Solution:

(1) 根据轮换对称性，我们只需研究 π_1 即可，有

$$\pi_1 = (200 - q_1 - q_2 - \cdots - q_N) q_N,$$

求得其反应函数为

$$q_1 = \frac{200 - \sum_{j \neq 1} q_j}{2}$$

同理，类比有

$$q_i = \frac{200 - \sum_{j \neq i} q_j}{2}$$

联立求解得

$$Q = \frac{200N}{N+1}$$

因此

$$q_1 = \cdots = q_N = \frac{200}{N+1} p = \frac{200}{N+1}, \pi_1 = \cdots = \pi_N = \frac{40000}{(N+1)^2}$$

(2) 此时 $\pi = (200 - Q)Q$ ，因此 $Q^* = 100$ ，此时

$$q_1 = \cdots = q_N = \frac{100}{N}, \quad p = 100, \quad \pi_1 = \cdots = \pi_N = \frac{10000}{N}.$$

(3) 第 (1) 问中，我们有 $q_1^1 = \frac{200}{N+1}$ ， $\pi_1^1 = \frac{40000}{(N+1)^2}$ ， $Q^1 = \frac{200N}{N+1}$ 。第 (2) 问中，我们有 $q_1^2 = \frac{100}{N}$ ， $\pi_1^2 = \frac{10000}{N}$ ， $Q^2 = 100$ 。可以发现，除了在 $N = 1$ 时结果相等（因为一户就是全村），在 $N > 1$ 时第 (2) 问的结论中每户羊数量少、利润高，总羊数也少。

(4) 第 (1) 问总利润为

$$\pi^1 = \frac{40000N}{(N+1)^2} \rightarrow 0,$$

第二问总利润 $\pi^2 \equiv 10000$ 不变。

(5) 将第一问的 200 替换为 $200 - t$

求得其反应函数为

$$q_i = \frac{200 - t}{N+1}$$

令 q 与第二问中 q 相等：

$$t = 100 - \frac{100}{N}.$$

北京大学-431 金融学综合-2023

2023 统计部分解析

一、(15 分) 设 $X \sim N(0, 1)$, 求 $E[X^3|X \geq 0]$.

Solution: 根据条件期望定义, 有

$$\begin{aligned} E[X^3|X \geq 0] &= \frac{E(X^3 I_{\{X \geq 0\}})}{P(X \geq 0)} = 2E(X^3 I_{\{X \geq 0\}}) = 2 \int_0^{+\infty} \frac{1}{\sqrt{2\pi}} x^3 e^{-\frac{x^2}{2}} dx \\ &= \frac{4}{\sqrt{2\pi}} \int_0^{+\infty} \left(\frac{x^2}{2}\right) e^{-\left(\frac{x^2}{2}\right)} x dx = \frac{4}{\sqrt{2\pi}} \int_0^{+\infty} u e^{-u} du = \frac{4}{\sqrt{2\pi}}. \end{aligned}$$

二、(20 分) 某品牌商发起调查, 调查购买某商品的比率 p . 现在他准备调查 n 个顾客 (n 较大), 如果购买了该商品则纪录为 $x_i = 1$, 否则 $x_i = 0$.

(1)(8 分) 给定置信水平 90%, 给出 p 的置信区间.

(2)(12 分) 保持置信水平 90% 不变, 如果希望置信区间无论如何不超过 1%, 问需要多少样本量?

Solution:

(1) 显然 $x_1, \dots, x_n$ 独立同服从 $B(1, p)$, 期望为 p , 方差为 $p(1-p)$, 根据中心极限定理, 有

$$\bar{x} \sim AN\left(p, \frac{p(1-p)}{n}\right),$$

因此有 $\sqrt{n} \frac{\bar{x}-p}{\sqrt{p(1-p)}} \sim AN(0, 1)$ 可以作为枢轴量, 但分母中 p 未知比较麻烦, 我们考虑 $\sqrt{n} \frac{\bar{x}-p}{\sqrt{\bar{x}(1-\bar{x})}} \sim AN(0, 1)$. 考虑到 $z_{0.95} = 1.645$, 因此有置信区间为

$$p \in \left[\bar{x} - 1.645 \frac{\sqrt{\bar{x}(1-\bar{x})}}{\sqrt{n}}, \bar{x} + 1.645 \frac{\sqrt{\bar{x}(1-\bar{x})}}{\sqrt{n}} \right].$$

(2) 置信区间长度为 $3.29 \frac{\sqrt{\bar{x}(1-\bar{x})}}{\sqrt{n}}$, 令其 ≤ 0.01 , 有

$$n \geq \left(\frac{3.29}{0.01} \right)^2 \bar{x}(1-\bar{x}),$$

我们想要使得它恒成立, 在不知道 $\bar{x}$ 是多少的情况下, 就必须让 n 大于等于右侧的最大值, 利用 $\bar{x}(1-\bar{x}) \leq \frac{1}{4}$, 得

$$n \geq \frac{1}{4} \cdot \left(\frac{3.29}{0.01} \right)^2 = 27060.3.$$

因此至少要调查 27061 个人.

三、(20 分) 设有两组独立样本: $x_1, \dots, x_n$ 来自 $N(\mu_1, \sigma_1^2)$, $y_1, \dots, y_m$ 来自 $N(\mu_2, \sigma_2^2)$. 现 σ_1, σ_2 已知, μ_1, μ_2 未知, 两组之间样本也独立, 记 $\theta = \mu_1 - \mu_2$.

(1)(5 分) 求 θ 的最大似然估计 $\hat{\theta}$.

(2)(5 分) 若 $N = n + m$ 是固定的, 想使 $\hat{\theta}$ 的均方误差最小, 如何设定 n 和 m ?

(3)(5 分) 延续第 (2) 问, 考虑假设检验问题

$$H_0: \theta = 0 \quad \text{vs} \quad H_1: \theta \neq 0$$

给出显著性水平为 α 时的拒绝域.

Solution:

(1) 根据正态 MLE 结论, $\hat{\mu}_1 = \bar{x}$, $\hat{\mu}_2 = \bar{y}$, 由 MLE 不变性, 得 $\hat{\theta} = \bar{x} - \bar{y}$, 它是正态的线性组合, 分布是

$$\hat{\theta} \sim N\left(\theta, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right).$$

(2) 根据 (1), 即在 $N = n + m$ 给定时, 求

$$\text{mse}(\hat{\theta}) = \text{Var}(\hat{\theta}) = \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}$$

的最小值. 这是二元条件极值问题, 可以用拉格朗日乘数法, 但我们可以考虑柯西-施瓦茨不等式, 即

$$(n+m) \left(\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m} \right) \geq \left(\sqrt{n} \cdot \frac{\sigma_1}{\sqrt{n}} + \sqrt{m} \cdot \frac{\sigma_2}{\sqrt{m}} \right)^2 = (\sigma_1 + \sigma_2)^2,$$

当且仅当 $\frac{\sigma_1}{\sqrt{n}} = \frac{\sigma_2}{\sqrt{m}}$ 时取等, 即 $n:m = \sigma_1^2:\sigma_2^2$.

故当我们取 $n = \frac{\sigma_1^2 N}{\sigma_1^2 + \sigma_2^2}$, $m = \frac{\sigma_2^2 N}{\sigma_1^2 + \sigma_2^2}$ 时, mse 最小, 为 $\frac{(\sigma_1 + \sigma_2)^2}{N}$.

【注】: 柯西-施瓦茨不等式指的是

$$(a_1^2 + a_2^2 + \cdots + a_n^2)(b_1^2 + b_2^2 + \cdots + b_n^2) \geq (a_1 b_1 + a_2 b_2 + \cdots + a_n b_n)^2,$$

当且仅当 $\frac{a_1}{b_1} = \frac{a_2}{b_2} = \cdots = \frac{a_n}{b_n}$ 时等号成立.

(3) 检验统计量是

$$z = \frac{\hat{\theta}}{\sqrt{\frac{(\sigma_1 + \sigma_2)^2}{N}}} = \sqrt{N} \frac{\hat{\theta}}{\sigma_1 + \sigma_2},$$

其分布在 H_0 成立时为 $N(0, 1)$. 如果 $|z|$ 较大, 说明 θ 很可能不为 0, 故拒绝域是

$$W = \left\{ |z| > z_{1-\frac{\alpha}{2}} \right\} = \left\{ \left| \hat{\theta} \right| > \frac{\sigma_1 + \sigma_2}{\sqrt{N}} z_{1-\frac{\alpha}{2}} \right\}.$$

四、(20 分) 设有线性模型

$$Y = X\beta + \varepsilon,$$

其中 $Y_{n \times 1}$ 是被解释变量, $X_{n \times p}$ 是秩为 p 的解释变量, $\beta_{p \times 1}$ 是待估参数, $\varepsilon_{n \times 1}$ 是误差项, 满足 $E(\varepsilon|X) = 0$, $\text{Var}(\varepsilon|X) = V(X)$, 其中 $V(X)$ 正定.

(1)(5 分) 求最小二乘估计 $\hat{\beta}$ 的方差. (假设 X 给定)

(2)(10 分) 把 $X\beta$ 分块为

$$X\beta = (X_1, X_2) \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} = X_1\beta_1 + X_2\beta_2,$$

试求 β_2 的最小二乘估计 $\hat{\beta}_2$.

(3)(5 分) 设 $V(X) = I_n$ 单位矩阵, 求 $\text{Var}(\hat{\beta}_2)$. (假设 X 给定)

Solution: (1) 根据最小二乘解, 有 $\hat{\beta} = (X^T X)^{-1} X^T Y$, 故有

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \left((X^T X)^{-1} X^T \right) \text{Var}(Y) \left((X^T X)^{-1} X^T \right)^T \\ &= (X^T X)^{-1} X^T V(X) X (X^T X)^{-1}. \end{aligned}$$

(2) 根据题意, 有

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} X_1^T X_1 & X_1^T X_2 \\ X_2^T X_1 & X_2^T X_2 \end{pmatrix}^{-1} \begin{pmatrix} X_1^T Y \\ X_2^T Y \end{pmatrix},$$

记两个矩阵:

$$P_{X_1} = X_1 (X_1^T X_1)^{-1} X_1^T, \quad M_{X_1} = I_n - P_{X_1},$$

其中 P_{X_1} 是投影到 X_1 张成空间中的投影矩阵, M_{X_1} 是则是投影到与 X_1 垂直的空间的投影矩阵, 可以理解为消去了 X_1 的影响. 根据分块矩阵求逆公式 (见文末 [注]), 有

$$(X^T X)^{-1} = \begin{pmatrix} \cdots & \cdots \\ -(X_2^T M_{X_1} X_2)^{-1} X_2^T X_1 (X_1^T X_1)^{-1} & (X_2^T M_{X_1} X_2)^{-1} \end{pmatrix},$$

因此有

$$\begin{aligned} \hat{\beta}_2 &= -\left(X_2^T M_{X_1} X_2\right)^{-1} X_2^T X_1 \left(X_1^T X_1\right)^{-1} X_1^T Y + \left(X_2^T M_{X_1} X_2\right)^{-1} X_2^T Y \\ &= \left(X_2^T M_{X_1} X_2\right)^{-1} X_2^T Y - \left(X_2^T M_{X_1} X_2\right)^{-1} X_2^T P_{X_1} Y \\ &= \left(X_2^T M_{X_1} X_2\right)^{-1} X_2^T (I_n - P_{X_1}) Y = \left(X_2^T M_{X_1} X_2\right)^{-1} X_2^T M_{X_1} Y. \end{aligned}$$

此外, 利用 M_{X_1} 是投影矩阵 (对称幂等), 即有 $M_{X_1}^2 = M_{X_1}^T M_{X_1} = M_{X_1}$, 我们还可将 $\hat{\beta}_2$ 写为

$$\hat{\beta}_2 = \left[(M_{X_1} X_2)^T (M_{X_1} X_2)\right]^{-1} (M_{X_1} X_2)^T Y,$$

记 $Z = M_{X_1} X_2$, 则恰是用 X_2 作因变量, X_1 作自变量得到的回归残差, 此时有

$$\hat{\beta}_2 = (Z^T Z)^{-1} Z^T Y,$$

也意味着我们将 X_2 投影到 X_1 张成空间的补空间中单独作为变量与 Y 进行回归得到的最小二乘估计.

(3) 由 $\hat{\beta}_2 = (Z^T Z)^{-1} Z^T Y$, 有

$$\begin{aligned} \text{Var}(\hat{\beta}_2) &= \left((Z^T Z)^{-1} Z^T\right) \text{Var}(Y) \left((Z^T Z)^{-1} Z^T\right)^T \\ &= (Z^T Z)^{-1} Z^T Z (Z^T Z)^{-1} = (Z^T Z)^{-1} = (X_2^T M_{X_1} X_2)^{-1}. \end{aligned}$$

【注】: 设 $A_{m \times m}, B_{m \times n}, C_{n \times m}, D_{n \times n}$, 则分块矩阵 $M = \begin{pmatrix} A & B \\ C & D \end{pmatrix}$ 的逆矩阵的求解过程是: 第一步考虑消去 C , 有

$$\begin{pmatrix} I_m & O \\ -CA^{-1} & I_n \end{pmatrix} M = \begin{pmatrix} A & B \\ O & D - CA^{-1}B \end{pmatrix},$$

再考虑消去 B , 有

$$\begin{pmatrix} I_m & O \\ -CA^{-1} & I_n \end{pmatrix} M \begin{pmatrix} I_m & -A^{-1}B \\ O & I_n \end{pmatrix} = \begin{pmatrix} A & O \\ O & D - CA^{-1}B \end{pmatrix},$$

化简并同时求逆矩阵得

$$\begin{aligned} M^{-1} &= \begin{pmatrix} I_m & -A^{-1}B \\ O & I_n \end{pmatrix} \begin{pmatrix} A^{-1} & O \\ O & (D - CA^{-1}B)^{-1} \end{pmatrix} \begin{pmatrix} I_m & O \\ -CA^{-1} & I_n \end{pmatrix} \\ &= \begin{pmatrix} A^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ O & (D - CA^{-1}B)^{-1} \end{pmatrix} \begin{pmatrix} I_m & O \\ -CA^{-1} & I_n \end{pmatrix} \\ &= \begin{pmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{pmatrix}. \end{aligned}$$

一、(20 分) 两期决策问题, 时间记为 $t = 1, 2$, 初始财富为 W , 分配给第一期消费 C_1 和储蓄 S , 第二期消费来自上一期储蓄所得, $C_2 = RS$, 这里储蓄收益率为 R , 为确定性常数, $R = \mu > 1$, 决策人在每一期的效用函数为 $-\frac{1}{C_1} - \frac{\beta}{C_2}$, $0 < \beta < 1$, 其中 β 为贴现率。

1. (5 分) 求第一期的最优消费 C_1 和储蓄 S 表达式, 当储蓄收益率上升时, 储蓄 S 如何变化?

2. (10 分) 假设储蓄收益率 R 有一定风险, 即 R 是分布在 $[\mu - \epsilon, \mu + \epsilon]$ 的均匀分布, 其中 $0 < \epsilon < \mu$, 在作决策时, 决策人不知道 R 具体取多少, 决策人的目标是最大化两期的预期效用和 $-\frac{1}{C_1} - E\left(\frac{\beta}{C_2}\right)$, 其中 E 表示对不确定因素求期望, 求第一期的最优消费 C_1 和储蓄 S 表达式。

3. (5 分) 比较 (1) 和 (2) 中的储蓄 S , 哪个更高? 当 (2) 中 ϵ 上升, 储蓄 S 如何变化?

Solution:

(1) 构造拉格朗日函数:

$$\mathcal{L} = -\frac{1}{C_1} - \beta \cdot \frac{1}{\mu S_1} + \lambda(W - C_1 - S_1)$$

对 C_1 和 S_1 求导数, 并令导数为零: - 对 C_1 求导:

$$\frac{\partial \mathcal{L}}{\partial C_1} = \frac{1}{C_1^2} - \lambda = 0 \Rightarrow \lambda = \frac{1}{C_1^2}$$

- 对 S_1 求导:

$$\frac{\partial \mathcal{L}}{\partial S_1} = \beta \cdot \frac{1}{\mu S_1^2} - \lambda = 0 \Rightarrow \lambda = \frac{\beta}{\mu S_1^2}$$

将两式联立, 消去 λ , 得到:

$$\frac{1}{C_1^2} = \frac{\beta}{\mu S_1^2}$$

取平方根:

$$\frac{1}{C_1} = \frac{\sqrt{\beta}}{\sqrt{\mu} S_1} \Rightarrow C_1 = \frac{\sqrt{\mu}}{\sqrt{\beta}} S_1$$

将其代入预算约束 $W = C_1 + S_1$, 得到:

$$W = \frac{\sqrt{\mu}}{\sqrt{\beta}} S_1 + S_1 = \left(\frac{\sqrt{\mu}}{\sqrt{\beta}} + 1 \right) S_1$$

解出 S_1 :

$$S_1 = \frac{W}{\frac{\sqrt{\mu}}{\sqrt{\beta}} + 1} = \frac{\sqrt{\beta} W}{\sqrt{\mu} + \sqrt{\beta}}$$

然后将其代入 C_1 的表达式, 得到:

$$C_1 = \frac{\sqrt{\mu} W}{\sqrt{\mu} + \sqrt{\beta}}$$

当 μ 增加时, 分母增大, 因此 S_1 减少。

(2) 最大化期望效用:

$$\max E[U] = -\frac{1}{C_1} - \frac{\beta}{S_1} E\left(\frac{1}{R}\right)$$

因此只需将 (1) 问结论中的 μ 替换为 $\frac{1}{E\left(\frac{1}{R}\right)} = \frac{2\epsilon}{\ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right)}$ 。此时, 结论为:

$$\begin{cases} S_1 = \frac{\sqrt{\beta}W}{\sqrt{\ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right)} + \sqrt{\beta}}, \\ C_1 = \frac{\sqrt{\ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right)}W}{\sqrt{\ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right)} + \sqrt{\beta}}. \end{cases}$$

(3) 关于 (1) 和 (2) 中的 S_1 大小关系, 我们只需要判断 μ 和 $\frac{1}{E(\frac{1}{R})}$ 谁大。根据 Jensen 不等式, 有 $E\left(\frac{1}{R}\right) > \frac{1}{E(R)} = \frac{1}{\mu}$, 因此 $\frac{1}{E(\frac{1}{R})} < \mu$, 这说明 S_1 增大。

进一步, 再看 ϵ 增大的影响, 此时只需看函数:

$$g(\epsilon) = \frac{2\epsilon}{\ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right)} = \frac{2\epsilon}{\ln(\mu+\epsilon) - \ln(\mu-\epsilon)}$$

在 $\epsilon > 0$ 的单调性, 那我们不妨看 $h = \frac{1}{g}$ 的单调性。求导, 有:

$$\begin{aligned} h'(\epsilon) &= \frac{1}{4\epsilon^2} \left[\left(\frac{1}{\mu+\epsilon} + \frac{1}{\mu-\epsilon} \right) \cdot 2\epsilon - 2 \cdot \ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right) \right] \\ &= \frac{1}{2\epsilon^2} \left(\frac{2\mu\epsilon}{\mu^2 - \epsilon^2} - \ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right) \right) \end{aligned}$$

定义 $\varphi(\epsilon) = \frac{2\mu\epsilon}{\mu^2 - \epsilon^2} - \ln\left(\frac{\mu+\epsilon}{\mu-\epsilon}\right)$, 有 $\varphi(0) = 0$, 再求导有:

$$\varphi'(\epsilon) = \frac{4\mu\epsilon^2}{(\mu^2 - \epsilon^2)^2} \geq 0$$

这说明 φ 函数单增、恒正, 故 h' 恒正, h 单增。这说明 g 单调减, 即 ϵ 的增大导致 g 的减小, 分母减小, S_1 进一步增大。

二、(20 分) 两个消费者, 分别编号为 $i = 1, 2$, 效用函数分别为 $U_1 = \sqrt{gC_1}$, $U_2 = \sqrt{gC_2}$, 两人各自财富为 W_i , 分配到公共品消费 g_i 和私人消费 C_i , $W_i = g_i + C_i$, 每个人获得的公共品消费 $g = g_1 + g_2$ 。

1. (5 分) 假设有政府可以获得两人的财富, 并由政府直接决定 g_i 和 C_i , 目标是最大化两人效用之和 $\sqrt{gC_1} + \sqrt{gC_2}$, 求最优的公共品消费和私人消费, 并求最优效用和。

2. (10 分) 假设每人独立决策, 同时决定各自的私人消费和公共品消费, 且不知道对方的决策, 求总的公共品消费 g 和每人的私人消费 C_i 。比较此时的效用 (1) 中的最优效用和, 哪个更高? 为什么?

3. (5 分) 假设政府对两人财富课税, 税率为 t , 政府所得 $t(W_1 + W_2)$ 投入公共品, 两人各自对剩下的财富 $(1-t)W_i$ 独立决策, 此时 $g = t(W_1 + W_2) + g_1 + g_2$, 求 t 为多少时, 效用和最大。

Solution:

(1) 构造拉格朗日函数

$$L(C_1, C_2, g, \lambda) = \sqrt{gC_1} + \sqrt{gC_2} + \lambda(W_1 + W_2 - C_1 - C_2 - g),$$

求导, 得到:

$$\begin{cases} \frac{\partial L}{\partial C_1} = \frac{1}{2}\sqrt{g}C_1^{-\frac{1}{2}} - \lambda = 0, \\ \frac{\partial L}{\partial C_2} = \frac{1}{2}\sqrt{g}C_2^{-\frac{1}{2}} - \lambda = 0, \\ \frac{\partial L}{\partial g} = \frac{1}{2}(\sqrt{C_1} + \sqrt{C_2})g^{-\frac{1}{2}} - \lambda = 0, \\ \frac{\partial L}{\partial \lambda} = W_1 + W_2 - C_1 - C_2 - g = 0, \end{cases}$$

解得: $C_1 = C_2 = \frac{W_1+W_2}{4}$, $g = \frac{W_1+W_2}{2}$, $U_{\max} = \frac{\sqrt{2}}{2}(W_1 + W_2)$ 。

此外, 可以利用基本不等式做法: 由 $g + C_1 + C_2 = W_1 + W_2$, 以及 $C_1 + \frac{g}{2} \geq 2\sqrt{C_1 \cdot \frac{g}{2}} = \sqrt{2}\sqrt{C_1 g}$, 得:

$$U = \sqrt{g} \cdot \sqrt{C_1} + \sqrt{g} \cdot \sqrt{C_2} \leq \frac{\sqrt{2}}{2} \left(C_1 + \frac{g}{2} + C_2 + \frac{g}{2} \right) = \frac{\sqrt{2}}{2}(W_1 + W_2) = U_{\max}$$

当且仅当 $C_1 = \frac{g}{2}$, $C_2 = \frac{g}{2}$ 时等号成立, 即有 $C_1 = C_2 = \frac{W_1+W_2}{4}$, 且 $g = \frac{W_1+W_2}{2}$ 。

此外, 题目应该增加条件: W_1 和 W_2 不能差异过大, 否则会出现 $C_1 > W_1$ 或 $g_1 > W_1$ 等情况, 此时原解不成立, 需特别计算。

(2) 搭便车问题

对于 $i = 1$, 有:

$$\max_{g_1, C_1} \sqrt{g_1 + g_2} \cdot \sqrt{C_1} \quad \text{s.t.} \quad W_1 = g_1 + C_1$$

对于 $i = 2$, 有:

$$\max_{g_2, C_2} \sqrt{g_1 + g_2} \cdot \sqrt{C_2} \quad \text{s.t.} \quad W_2 = g_2 + C_2$$

解得:

$$\begin{cases} g_1(g_2) = \frac{W_1 - g_2}{2}, \\ C_1(g_2) = \frac{W_1 + g_2}{2}, \end{cases} \quad \begin{cases} g_2(g_1) = \frac{W_2 - g_1}{2}, \\ C_2(g_1) = \frac{W_2 + g_1}{2}. \end{cases}$$

此时有 $g_1 + g_2 = \frac{1}{3}(W_1 + W_2)$, 回代联立, 解得:

$$C_1 = C_2 = \frac{W_1 + W_2}{3}, \quad g_1 = \frac{2W_1 - W_2}{3}, \quad g_2 = \frac{2W_2 - W_1}{3}.$$

此时:

$$U_1 + U_2 = \frac{2}{3}(W_1 + W_2) < \frac{\sqrt{2}}{2}(W_1 + W_2).$$

通过比较两种机制的结果可以看出, 集中决策下的总效用更高, 而独立决策由于公共品的正外部性, 会产生搭便车效应, 公共物品供给量较低, 导致总效用较小。因此, 集中决策(如通过税收的方式来强制提供公共物品)能够更有效地提高社会福利。

此外, 题目应该增加条件 $2W_1 > W_2$ 以及 $2W_2 > W_1$, 否则需要考虑这些情况, 会给出不同的解: 若 $W_2 > 2W_1$, 则 $g_1 = 0$, $g = g_2 = \frac{W_2}{2}$, $C_1 = W_1$, $C_2 = \frac{W_2}{2}$ 。此时

$$U_2 = \frac{\sqrt{2}}{2}W_1 + \sqrt{\frac{\sqrt{2}-1}{2}}W_2,$$

证明

$$\frac{\sqrt{2}}{2}W_1 + \sqrt{\frac{\sqrt{2}-1}{2}}W_2 < \frac{\sqrt{2}}{2}(W_1 + W_2)$$

只需证明

$$W_1 + \frac{\sqrt{2}-1}{2}W_2 > \sqrt{\frac{W_1 W_2}{2}}.$$

由均值不等式可知:

$$\sqrt{\frac{\sqrt{2}}{2} \cdot \frac{\sqrt{2}-1}{2} W_1 W_2} \geq \sqrt{\frac{\sqrt{2}}{2} \cdot \frac{\sqrt{2}-1}{2} W_1 W_2} > \sqrt{\frac{W_1 W_2}{2}}.$$

故

$$\frac{\sqrt{2}}{2}W_1 + \sqrt{\frac{\sqrt{2}-1}{2}}W_2 < \frac{\sqrt{2}}{2}(W_1 + W_2).$$

若 $W_2 < \frac{1}{2}W_1$, 则 $g_2 = 0$, $g = g_1 = \frac{W_1}{2}$, $C_2 = W_2$, $C_1 = \frac{W_1}{2}$. 此时

$$U_2 = \frac{\sqrt{2}}{2}W_2 + \sqrt{\frac{\sqrt{2}-1}{2}}W_1,$$

同理可得

$$U_2 < \frac{\sqrt{2}}{2}(W_1 + W_2).$$

(3) 问题的进一步分析

对 $i = 1, 2$ 有:

$$\max_{C_i, g_i} \sqrt{t(W_1 + W_2) + g_1 + g_2} \cdot \sqrt{C_i} \quad \text{s.t.} \quad C_i + g_i = (1-t)W_i.$$

解得:

$$\begin{cases} g_i(g_j) = \frac{(1-t)W_i - t(W_i + W_j) - g_j}{2}, \\ C_i(g_j) = \frac{(1-t)W_i + t(W_i + W_j) + g_j}{2}, \end{cases} \quad i, j \in \{1, 2\}.$$

此时, 若不考虑 t 范围, 有:

$$g_1 + g_2 = \left(\frac{1}{3} - t\right)(W_1 + W_2),$$

因此代入解出 $C_1 = C_2 = \frac{1}{3}(W_1 + W_2)$.

这说明:

- (i) 若 $t < \frac{1}{3}$, 则 $g_1 + g_2 = \left(\frac{1}{3} - t\right)(W_1 + W_2)$. 此时 $g = g_1 + g_2 + t(W_1 + W_2)$, 与 (2) 题相无差别。
(ii) 若 $t \geq \frac{1}{3}$, 则 $g_1 = g_2 = 0$, $C_1 = (1-t)W_1$, $C_2 = (1-t)W_2$. 有:

$$\frac{U_1 + U_2}{\sqrt{W_1 + W_2}} = \sqrt{t(1-t)W_1} + \sqrt{t(1-t)W_2} = (\sqrt{W_1} + \sqrt{W_2})\sqrt{t(1-t)} \leq \frac{1}{2}(\sqrt{W_1} + \sqrt{W_2}),$$

且 $t^* = \frac{1}{2}$.

因此, $t = \frac{1}{2}$ 时, 效用最大, 效用和为:

$$U_1 + U_2 = \frac{1}{2}(\sqrt{W_1} + \sqrt{W_2})\sqrt{W_1 + W_2}.$$

注: 作为一道 5 分的题目, 也可以利用经济学意义来解题: 既然个人独立决策会导致搭便车现象, 那就让个人财富完全用于个人消费, 收税用来购买公共品, 即直接令 $t = \frac{1}{2}$, 不难验证成立。并且当收税更多时一定不成立, 当收税少时, 每个人都会希望单独的最大化自己的收益, 仍然会产生搭便车现象, 达不到社会最优。

三、(15 分) 双寡头市场, 企业 1 和企业 2, 需求函数 $P(q_1, q_2) = 1 - q_1 - q_2$, q_1 和 q_2 分别为企业 1、2 的产量。为简化问题, 假设生产成本为 0。需求函数和各自成本为公共知识, 各自决策变量为 q_1 和 q_2 。

1. (5 分) 假设为斯塔克尔伯格模型, 企业 1 为领导型, 企业 2 为追随型, 求均衡 q_1^*, q_2^* 。

2. (10 分) 假设为古诺模型, 即两家同时决策, 不过与经典模型不同的是, 企业 1 准备聘请职业经理人, 工资与产量挂钩, 假设现在企业 1 的目标函数转变为 $\pi_1(q_1, q_2) + \eta \times q_1 - w = (1 - q_1 - q_2) \times q_1 + \eta \times q_1 - w$, 其中 η, w 为共同知识, 现在企业 1 通过选择 q_1 最大化目标函数, 企业 2 的目标函数为 $\pi_2(q_1, q_2) = (1 - q_1 - q_2) \times q_2$ 。企业 2 通过选择产量 q_2 来最大化目标函数, 求该假设下, 企业 1 和企业 2 的均衡产量 (表达为 η 的函数即可)。

Solution:

(1) ** 斯塔克尔伯格均衡 **

首先看企业 2 的利润函数:

$$\pi_2(q_1, q_2) = P(q_1, q_2) \cdot q_2 = (1 - q_1 - q_2) \cdot q_2$$

对 q_2 求导, 得到利润最大化的一阶条件:

$$\frac{\partial \pi_2}{\partial q_2} = 1 - q_1 - 2q_2 = 0$$

解得企业 2 的反应函数:

$$q_2 = \frac{1 - q_1}{2}$$

企业 1 知道企业 2 的反应函数 $q_2 = \frac{1 - q_1}{2}$, 并将其代入企业 1 的利润函数:

$$\pi_1(q_1, q_2) = (1 - q_1 - q_2) \cdot q_1 = \left(\frac{1 - q_1}{2} \right) \cdot q_1$$

化简后:

$$\pi_1(q_1) = \frac{q_1(1 - q_1)}{2}$$

对 q_1 求导, 得到利润最大化的一阶条件:

$$\frac{d\pi_1}{dq_1} = \frac{1 - 2q_1}{2} = 0$$

解得: $q_1^* = \frac{1}{2}$ 。

此时再将 $q_1^* = \frac{1}{2}$ 代入企业 2 的反应函数:

$$q_2^* = \frac{1 - \frac{1}{2}}{2} = \frac{1}{4}$$

因此, 在斯塔克尔伯格均衡下, 企业 1 选择的最优产量为: $q_1^* = \frac{1}{2}$, 企业 2 选择的最优产量为: $q_2^* = \frac{1}{4}$ 。

(2) ** 古诺模型 **

企业 2 的利润函数为:

$$\pi_2(q_1, q_2) = (1 - q_1 - q_2) \cdot q_2$$

对 q_2 求导, 得到利润最大化的一阶条件:

$$\frac{\partial \pi_2}{\partial q_2} = 1 - q_1 - 2q_2 = 0$$

解得企业 2 的反应函数:

$$q_2 = \frac{1 - q_1}{2}$$

企业 1 的目标函数为:

$$\pi_1(q_1, q_2) = (1 - q_1 - q_2) \cdot q_1 + \eta \cdot q_1 - w$$

对 q_1 求导, 得到利润最大化的一阶条件:

$$\frac{\partial \pi_1}{\partial q_1} = 1 - 2q_1 - q_2 + \eta = 0$$

得到企业 1 的反应函数:

$$q_1 = \frac{1}{2}(1 - q_2 - \eta)$$

联立企业 1 和企业 2 的反应函数, 解得在古诺模型均衡下, 企业 1 和企业 2 的均衡产量为:

$$q_1^* = \frac{1+2\eta}{3}, \quad q_2^* = \frac{1-\eta}{3}.$$

当然, 此时还需要考虑 ** 角点解 **, 因此完整答案如下:

- 若 $\eta > 1$, $q_1^* = \frac{1+\eta}{2}, q_2 = 0$ - 若 $-\frac{1}{2} \leq \eta \leq 1$, $q_1^* = \frac{1+2\eta}{3}, q_2^* = \frac{1-\eta}{3}$ - 若 $\eta < -\frac{1}{2}$, $q_1^* = 0, q_2 = \frac{1}{2}$

四、(20 分) 双寡头市场, 企业 1 和企业 2, 需求函数 $P(q_1, q_2) = 9 - q_1 - q_2$, q_1, q_2 分别为企业 1、2 的产量。假设边际生产成本为 C_1 和 C_2 。需求函数和各自成本为共同知识, 各自决策变量为 q_1 和 q_2 。

1. (5 分) 假设为古诺模型, 且边际成本 $C_1 = C_2 = 3$, 求均衡产量。

2. (5 分) 假设企业 1 可以通过研发改善经营绩效, 具体而言, 企业 1 可以通过一次性的投入 $f = 11$, 使 $C_1 = 0$, 如果企业 1 不投入研发, 则 C_1 仍为 3。关于企业 2 的假设不变, $C_2 = 3$ 。在该问题中, 企业 2 在观察企业 1 是否投入后再与其进行同时定产, 假设该博弈结构为共同知识, 求该假设条件下, 纯策略子博弈完美均衡。注意企业 1 决策包含是否投入研发和产量两方面。

3. (10 分) 假设企业 1 是否投入研发与两家企业的产量选择为同时决策, 其他题设与 (2) 一致, 注意与 (2) 的关键区别在于在同时决策的假定条件下, 企业 2 选择产量时不再能观测到企业 1 是否研发。求该假设条件下的纯策略纳什均衡。

Solution:

(1) ** 古诺模型均衡 **

企业的利润函数为:

$$\pi_1(q_1, q_2) = (6 - q_1 - q_2)q_1, \quad \pi_2(q_1, q_2) = (6 - q_1 - q_2)q_2.$$

企业 1 的利润最大化一阶条件为:

$$\frac{\partial \pi_1}{\partial q_1} = 6 - 2q_1 - q_2 = 0$$

解得企业 1 的反应函数:

$$q_1 = \frac{6 - q_2}{2}$$

同理, 企业 2 的利润最大化一阶条件为:

$$\frac{\partial \pi_2}{\partial q_2} = 6 - q_1 - 2q_2 = 0$$

解得企业 2 的反应函数:

$$q_2 = \frac{6 - q_1}{2}$$

联立求解, 得到在古诺均衡下, 企业 1 和企业 2 的均衡产量分别为:

$$q_1^* = q_2^* = 2.$$

(2) ** 不研发时的利润 **

不研发时, $q_1 = 2, q_2 = 2$ 。此时企业 1 和企业 2 的利润为:

$$\pi_1 = 4, \quad \pi_2 = 4.$$

** 进行研发时的利润 **

企业 1 的利润函数为:

$$\pi_1 = (9 - q_1 - q_2) \cdot q_1 - 11$$

对 q_1 求导, 得到反应函数:

$$q_1 = \frac{9 - q_2}{2}$$

企业 2 的反应函数为:

$$q_2 = \frac{6 - q_1}{2}$$

联立解得:

$$q_1 = 4, \quad q_2 = 1$$

此时企业 1 和企业 2 的利润为:

$$\pi_1 = 5, \quad \pi_2 = 1$$

因此, 企业 1 会选择进行研发, 均衡产量为 $q_1 = 4, q_2 = 1$ 。

(3) ** 纳什均衡分析 **

根据第 (2) 问, 存在两个可能的均衡点:

$$X_1 = \{(q_1 = 2, \text{不研发}), q_2 = 2\}, \quad X_2 = \{(q_1 = 4, \text{研发}), q_2 = 1\}.$$

我们只需分析, 在第 (3) 问的条件下, X_1 和 X_2 是否为纳什均衡, 实际上只需看厂商 1 是否可以通过更改其是否研发而得到更高的收益。

先看 X_1 , 当 $q_2 = 2$ 时, 如果厂商 1 改为研发, 此时反应函数是:

$$q_1 = \frac{9 - q_2}{2} = \frac{7}{2}$$

利润为:

$$\pi_1 = (9 - q_1 - q_2)q_1 - 11 = 1.25$$

小于 4, 因此 X_1 是一个纯策略纳什均衡。

再看 X_2 , 当 $q_2 = 1$ 时, 如果厂商 1 改为不研发, 此时反应函数是:

$$q_1 = \frac{6 - q_2}{2} = \frac{5}{2}$$

利润为:

$$\pi_1 = (6 - q_1 - q_2)q_1 = 6.25$$

大于 5，因此 X_2 不是一个纯策略纳什均衡。

综上所述， $X_1 = \{(q_1 = 2, \text{不研发}), q_2 = 2\}$ 为纯策略纳什均衡。

北京大学-431 金融学综合-2024

· 2024 统计部分解析

一、(20 分) 某研究员想要了解某种特定培训对金融分析师预测精度的影响。选取了 10 位金融分析师，在接受特定培训前后，分别记录他们对某股票未来价格的预测误差。以下是这 10 位分析师在接受培训前后对同一股票价格预测的平均误差（单位：美元）：

分析师编号	培训前误差	培训后误差
1	2.5	2.0
2	3.0	2.7
3	1.8	1.5
4	2.0	1.6
5	2.3	2.1
6	1.5	1.2
7	2.2	2.0
8	2.8	2.4
9	1.7	1.3
10	2.6	2.2

Remark: 原题是关于睡眠质量的问题, 这里是我们生成的数据.

请检验这种培训是否对金融分析师的预测误差有显著影响, 其中显著性水平为 0.05.

Solution: 考虑配对样本 t 检验.

根据计算结果, 差值的平均值为 0.34 美元, 标准差为 0.097 美元, 计算得到的 t 值为 11.13. 在自由度为 9 和显著性水平为 0.05 的等尾检验中, 临界值为 2.26. 由于计算得到的 t 值远大于临界值, 我们拒绝原假设, 认为培训对金融分析师的预测误差有显著性影响.

二、(20 分) 设 $X_1, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的独立样本, 且 μ, σ^2 未知, 已知有 $P(X > a) = 0.05$, 求 a 的 MLE.

Solution: 直接计算有

$$P(X > a) = P\left(\frac{X - \mu}{\sigma} > \frac{a - \mu}{\sigma}\right) = 0.05$$

从而有

$$\frac{a - \mu}{\sigma} = u_{0.95} \Rightarrow a = \mu + u_{0.95}\sigma.$$

由极大似然估计的不变性可知

$$\hat{a} = \bar{X} + u_{0.95}S_n.$$

三、(15 分) 设 X, Y 独立服从 $N(0, 1)$, 求 $E \max\{X, Y\}$.

Solution:

茆书原题. 考虑 $\max\{X, Y\} = \frac{X+Y+|X-Y|}{2}$. 从而有 $E \max\{X, Y\} = E|X - Y|/2$. 由经典结论, 若 $Y \sim N(0, \sigma^2)$, 有 $E|Y| = \sqrt{\frac{2}{\pi}}\sigma$; 更进一步 (见 2023 复旦 432 第三题), 若 $Y \sim N(\mu, \sigma^2)$, 有 $E|Y| = \sqrt{\frac{2}{\pi}}\sigma e^{-\frac{\mu^2}{2\sigma^2}} + \mu \left(2\Phi\left(\frac{\mu}{\sigma}\right) - 1\right)$. 而 $X - Y \sim N(0, 2)$. 故有 $E \max\{X, Y\} = E|X - Y|/2 = 1/\sqrt{\pi}$.

四、(15 分) 利用统计方法求极限:

$$\lim_{n \rightarrow \infty} 3^n \int_0^\infty \cdots \int_0^\infty \cos\left(\frac{x_1 + \cdots + x_n}{n}\right) e^{-3(x_1 + \cdots + x_n)} dx_1 \cdots dx_n.$$

Solution:

考虑服从期望为 $1/3$ 的指数分布 i.i.d. 随机变量 $X_1, \dots, X_n$, 原极限为

$$I = \lim_{n \rightarrow \infty} E \left[\cos \left(\frac{X_1 + \dots + X_n}{n} \right) \right],$$

根据大数定律, 有 $Y_n = \frac{X_1 + \dots + X_n}{n} \xrightarrow{P} 1/3$, 故也有 $\cos Y_n \rightarrow \cos \frac{1}{3}$. 由于 $\cos x$ 函数有界, 根据控制收敛定理, 有

$$I = \lim_{n \rightarrow \infty} E[\cos Y_n] = E \left[\lim_{n \rightarrow \infty} \cos Y_n \right] = \cos \frac{1}{3}.$$

· 2024 微观部分解析

一、(20 分) 一个人作两期消费决策, 第一期收入为 2, 消费者在第 t 期的效用函数为 $u = \ln(c_t)$, 消费者的折现率为 1, 可以通过投资平滑过度到下一期。

1. (10 分) 若第二期收入为 1, 可购买利率为 10% 的无风险国债, 问消费者买多少国债最优?

2. (10 分) 若第二期收入不确定, 50% 概率为 2, 50% 概率为 0, 问买多少国债最优?

Solution:

(1) 确定性情形

设第一期的收入为 $y_1 = 2$, 第二期的收入为 $y_2 = 1$, 且无风险国债的收益率为 $r = 0.1$ 。消费者的第一期消费为 c_1 , 第二期消费为 c_2 , 投资国债的金额为 b 。

第一期的消费为:

$$c_1 = 2 - b$$

第二期的消费为:

$$c_2 = 1 + 1.1b$$

目标函数为:

$$\max_b \ln(2 - b) + \ln(1 + 1.1b)$$

对 b 求导并令其等于 0, 解得:

$$b = \frac{1.2}{2.2} \approx 0.545$$

因此, 消费者应投资约 0.545 个单位的收入在无风险国债中。

(2) 不确定性情形

当第二期收入不确定时, 消费者在第一期的收入为 $y_1 = 2$, 第二期有 50% 的概率收入为 2, 50% 的概率收入为 0, 无风险国债的收益率仍为 $r = 0.1$ 。

消费者的第一期消费为 c_1 , 第二期消费分别为:

$$c_2^1 = (2 - c_1)(1 + r) + 2, \quad c_2^2 = (2 - c_1)(1 + r)$$

期望效用函数为:

$$\mathbb{E}(u) = \ln(c_1) + \frac{1}{2} \ln(c_2^1) + \frac{1}{2} \ln(c_2^2)$$

将 c_2^1 和 c_2^2 代入, 化简后期望效用函数为:

$$\max_{c_1} \ln(c_1) + \frac{1}{2} \ln((2 - c_1)(1 + r) + 2) + \frac{1}{2} \ln((2 - c_1)(1 + r))$$

对 c_1 求导并令其等于 0:

$$\frac{1}{c_1} + \frac{1+r}{2((2-c_1)(1+r)+2)} - \frac{1+r}{2(2-c_1)(1+r)} = 0$$

解得 c_1 的最优值为:

$$c_1^* = \frac{24 - \sqrt{114}}{11}$$

消费者应投资的金额为:

$$s^* = 2 - c_1^* = \frac{-2 + \sqrt{114}}{11}$$

结论: 在不确定情形下, 消费者的最优投资国债金额为:

$$\frac{-2 + \sqrt{114}}{11}$$

二、(15 分) 有 4 个生产同质产品的厂家, 单位商品成本 (边际成本) 为 10, 一个代表性的消费者购买 X 单位该产品得到的效用为 $20x - 5x^2$ 。

- (5 分) 若各厂商独立决策并追求利润最大化, 问此时的总供给。
- (5 分) 若各厂商合谋追求利润最大化, 问此时的总供给。
- (5 分) 问题 (1) 和 (2) 中总消费者剩余相差多少? 并解释为什么消费者剩余会有差别。

Solution:

(1) 消费者最优需求量

消费者的效用函数为:

$$U(x) = 20x - 5x^2 - px$$

边际效用为:

$$MU(x) = \frac{dU(x)}{dx} = 20 - 10x - p = 0$$

解得:

$$x^* = 2 - \frac{p}{10}$$

因此, 消费者的最优需求量 x^* 随价格 p 的变化而变化。

市场价格由市场需求函数给出, 假设市场上有 4 个厂商, 采用古诺模型, 每个厂商的产量为:

$$x_i^* = \frac{1}{5}, \quad i = 1, 2, 3, 4$$

总产量为:

$$x_s = 4 \times \frac{1}{5} = \frac{4}{5}$$

(2) 合谋情况下的供给量:

在合谋的情况下, 厂商作为一个整体最大化利润。总利润函数为:

$$\pi = p \cdot X - MC \cdot X = (20 - 10X) \cdot X - 10X$$

展开简化为：

$$\pi = 10X - 10X^2$$

对利润函数求导以最大化利润：

$$\frac{d\pi}{dX} = 10 - 20X = 0$$

解得：

$$X^* = 0.5$$

因此，合谋情况下的总供给量为：

$$X = 0.5$$

(3) 古诺模型下的消费者剩余：

古诺模型下，总产量 $X = \frac{4}{5}$ ，对应的价格为：

$$p = 20 - 10 \times \frac{4}{5} = 12$$

消费者剩余为：

$$CS = \int_0^{4/5} (20 - 10x - 12)dx = \int_0^{4/5} (8 - 10x)dx$$

计算得：

$$CS = \left[8x - 5x^2 \right]_0^{4/5} = 8 \times \frac{4}{5} - 5 \times \left(\frac{4}{5} \right)^2 = \frac{16}{5} = 3.2$$

合谋情况下的消费者剩余：

合谋情况下，总产量 $X = 0.5$ ，对应的价格为：

$$p = 20 - 10 \times 0.5 = 15$$

消费者剩余为：

$$CS = \int_0^{0.5} (20 - 10x - 15)dx = \int_0^{0.5} (5 - 10x)dx$$

计算得：

$$CS = \left[5x - 5x^2 \right]_0^{0.5} = 2.5 - 1.25 = 1.25$$

消费者剩余的差异为：

$$\Delta CS = 3.2 - 1.25 = 1.95$$

合谋情况下，厂商通过减少产量提高了市场价格，这导致消费者支付更高的价格，消费者剩余因此减少。

三、(20 分) 已知有两个股票投资者，可以选择卖空或者放弃，卖空成本为 100，放弃成本为 0。若两者都卖空，每人可获利 200，若只有一个卖空者或无人卖空（有一人放弃或两人都放弃时），则二者收益均为 0。

1. (10 分) 若二者同时决策，求纳什均衡。

2. (10 分) 若二者先后决策且后决策者能看到前者的决策，求子博弈完美均衡。

Solution:

(1) 博弈矩阵分析

博弈矩阵如下：

	B: 卖空	B: 放弃
A: 卖空	(100, 100)	(-100, 0)
A: 放弃	(0, -100)	(0, 0)

· 1. 纯策略纳什均衡

在纯策略下，我们寻找每个玩家的最佳反应：

- 如果 A 选择“卖空”，B 的收益为：选择“卖空”得到 100，选择“放弃”得到 0，因此 B 会选择“卖空”。

- 如果 A 选择“放弃”，B 的收益为：选择“卖空”得到 -100，选择“放弃”得到 0，因此 B 会选择“放弃”。

类似地，A 会基于 B 的选择做出相同的决策。

通过分析，**(A: 卖空, B: 卖空)** 和 **(A: 放弃, B: 放弃)** 是博弈中的两个纯策略纳什均衡。

· 2. 混合策略纳什均衡

假设 A 以概率 p 选择卖空，B 以概率 q 选择卖空。我们需要使得 A 和 B 在选择“卖空”和“放弃”时的期望收益相等。

** 对玩家 A**，选择卖空时的期望收益为：

$$100q - 100(1 - q) = 200q - 100.$$

选择放弃时的期望收益为 0：

令两者相等，得到：

$$200q - 100 = 0$$

解得 $q = \frac{1}{2}$ 。

** 对玩家 B**，选择卖空时的期望收益为：

$$100p - 100(1 - p) = 200p - 100.$$

选择放弃时的期望收益为 0：

令两者相等，得到：

$$200p - 100 = 0$$

解得 $p = \frac{1}{2}$ 。

因此，混合策略纳什均衡是 $p = \frac{1}{2}, q = \frac{1}{2}$ ，即 A 和 B 各以 50% 的概率选择卖空或放弃。

(2) 子博弈完美均衡

现在假设投资者 A 先做决策，B 可以观察到 A 的决策后再做出反应。我们使用逆推归纳法求解子博弈完美均衡。

· 1. B 的决策

B 在观察到 A 的决策后可以做出反应：

- 如果 A 选择卖空，B 有两种选择：- 选择卖空，B 的净收益为 100。- 选择放弃，B 的净收益为 0。

因此，如果 A 选择卖空，B 会选择卖空。

- 如果 A 选择放弃，B 有两种选择：- 选择卖空，B 的净收益为 -100（因为独自卖空）。- 选择放弃，B 的净收益为 0。

因此，如果 A 选择放弃，B 会选择放弃。

· 2. A 的决策

A 知道 B 的反应，A 的决策如下：

- 如果 A 选择卖空，B 也会卖空，A 的净收益为 100。- 如果 A 选择放弃，B 也会放弃，A 的净收益为 0。

因此，A 会选择卖空，因为卖空时的收益（100）大于放弃时的收益（0）。

根据逆推归纳法，子博弈完美均衡为：

- A 选择卖空。- B 看到 A 卖空后也选择卖空。

子博弈完美均衡是卖空，(卖空，放弃)

四、(20 分) 已知公司运行新项目需要投资 100，项目净现值 NPV 为 b ，公司当前固定资产总值为 a ，需要向公众股权融资。公司可能处于以下两种状态之一：状态一： $a = 400, b = 30$ ；状态二： $a = 100, b = 10$ 。公司能够知道自己当前所处的状态，股票市场的投资者认为公司处于两种状态的概率均为 50%（具体情况只有公司知道，投资者无法判断，公司和投资者均为风险中性）。

1. (10 分) 若公司无论如何都在股票市场融资，那么公司的定价应为多少？

2. (10 分) 在 (1) 的条件下，在状态一时公司会选择股票融资吗？状态二呢？请解释原因。

Solution:

(1) 市场对公司股票的定价

假设公司无论处于状态一还是状态二都进行融资，市场投资者会根据公司处于状态一或状态二的概率对公司进行估值。

状态一：

公司当前资产为 $a = 400$ ，项目的净现值为 $b = 30$ ，因此公司在状态一的总价值为：

$$V_1 = a + b + 100 = 400 + 30 + 100 = 530$$

状态二：

公司当前资产为 $a = 100$ ，项目的净现值为 $b = 10$ ，因此公司在状态二的总价值为：

$$V_2 = a + b + 100 = 100 + 10 + 100 = 210$$

投资者的定价：

由于投资者无法判断公司处于哪种状态，只能根据概率进行估计。公司处于状态一和状态二的概率均为 50%，因此投资者的预期公司价值为：

$$\mathbb{E}(V) = 0.5 \times V_1 + 0.5 \times V_2 = 0.5 \times 530 + 0.5 \times 210 = 265 + 105 = 370$$

因此，投资者将公司的定价设为 370。

注意，此题考虑 370 是更为正确的，270 则应该会扣部分分数，这是由于题干已经说明“无论如何都要融资”，而只有融资后才会进行投资随后获得收益，所以计算融资后的价值也是恰当的。如果融资前的价值，那么更应该是 $200 + 50 = 250$ ，但这并没有用到投资收益，所以不是想要的结果。

(2) 公司是否选择融资？

我们分别分析公司在状态一和状态二下是否会选择融资。首先判断，如果投资者要融资，他们预期拿到多少股权？不难计算得到 $\frac{100}{370}$ ，即 $\frac{10}{37}$

状态 1：融资后股东价值为 $\frac{27}{37} \cdot 530 \approx 386.8 < 400$ 即融资后股东拥有的财富下降。

状态 2：融资后股东价值为 $\frac{27}{37} \cdot 210 \approx 153.2 > 100$ 即融资后股东拥有的财富上升。

因此，公司会在状态 1 时选择不融资，状态 2 选择融资。

北京大学-431 金融学综合-2025

2025 统计部分解析

一、不定项选择题（多选，少选，错选均不得分）。（16 分，每题 4 分）

1. $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(0, 1)$ 下列说法正确的是：（ ）

- A. $\bar{x} \sim N(0, \frac{1}{n^2})$
- B. $\frac{\sqrt{n}\bar{x}}{S} \sim t(n-1)$
- C. $\sum_{i=1}^n X_i^2 \sim \chi^2(n)$
- D. $n\bar{x} \sim N(0, n)$

Solution:BCD

A. 样本均值 $\bar{x}$ 的分布是 $N(0, \frac{1}{n})$ ，错误。

2. $X_1, \dots, X_n$ 为总体分布的简单随机样本，下列是总体均值的无偏估计的有：（ ）

- A. X_1
- B. $\bar{X}$
- C. $X_1 - X_2 + X_n$
- D. $10X_1 - 9X_n$

Solution:ABCD 只要审题清楚就不会错。

3. $X_1, \dots, X_n$ 为 $F(X, \theta)$ 的简单随机样本，下列说法正确的是：（ ）

- A. 似然函数是 θ 的函数
- B. 似然函数是 $X_1, \dots, X_n$ 的函数
- C. $g(\theta)$ 的极大似然估计是 $g(\hat{\theta})$ ，其中 $\hat{\theta}$ 为 θ 的极大似然估计
- D. 最大似然估计是似然函数的最大值

Solution:AC

A. 似然函数是给定样本数据 $X_1, \dots, X_n$ 时，参数 θ 的函数，正确。

B. 似然函数是参数 θ 的函数，而不是样本数据 $X_1, \dots, X_n$ 的函数，错误。

C. 由极大似然估计的函数不变性，前提是 g 是一个连续函数，正确。

D. 最大似然估计是使似然函数达到最大值的参数 θ 的值，而不是似然函数的最大值本身，错误。

4. 下列说法正确的是：（ ）

- A. 样本量的增加可以提高检验的显著水平
- B. 经验分布函数是单调增函数
- C. 样本容量越大，样本方差越小
- D. 统计量是样本的函数

Solution:D 或 BD

A. 样本量的增加可以提高检验的统计功效，但不能直接提高检验的显著水平，显著水平通常由研究者设定，错误。

C. 容量越大，方差的估计越稳定，但并不一定越小。方差的大小取决于数据的离散程度，而不是样本容量，错误。

D. 统计量是根据样本数据计算得到的数值，可以视为样本的函数，正确。

B. 有歧义，茆书：经验分布函数为一非减右连续函数

二、（10 分）下列为来自取值为非负整数总体的简单随机样本，样本均值为 1.45，样本方差为 1.8。

取值	0	1	2	3	4	5
频数	250	200	180	100	50	20
频率	0.3125	0.25	0.225	0.125	0.0625	0.025

(1) 求出上述样本的经验分布函数

(2) 利用经验分布计算零点的取值概率；取值大于 2 且小于等于 4 的概率。

Solution: (1) 经验分布函数 $F_n(x)$ 是一个阶梯函数，它在每个样本点 x_i 处跳跃，跳跃的高度等于该样本点的累积频率。

$$F_n(x) = \begin{cases} 0 & \text{if } x < 0 \\ 0.3125 & \text{if } 0 \leq x < 1 \\ 0.5625 & \text{if } 1 \leq x < 2 \\ 0.7875 & \text{if } 2 \leq x < 3 \\ 0.9125 & \text{if } 3 \leq x < 4 \\ 0.975 & \text{if } 4 \leq x < 5 \\ 1 & \text{if } x \geq 5 \end{cases}$$

(2) 根据经验分布函数， $P(X=0) = F_n(0) - F_n(\epsilon) = 0.3125, \epsilon \rightarrow 0^-$ ，所以零点的取值概率为 0.3125。取值大于 2 且小于等于 4 的概率为 $P(2 < x \leq 4) = F_n(4) - F_n(\epsilon') = 0.975 - 0.7875 = 0.1875, \epsilon' \rightarrow 2^+$ 。

三、(10 分) 简述两类错误的含义，并说明在统计检验中如何处理这两类错误的？

Solution: 设拒绝域为 W ，原假设为 H_0 ，备择假设为 H_1 。

(1) 第一类错误: 当原假设 H_0 为真时，我们错误地拒绝了原假设。这种错误也称为“弃真错误”。第一类错误的概率通常用 α 表示， $\alpha = P(H_0)$ ，它也是我们设定的显著性水平。

(2) 第二类错误: 当原假设 H_0 为假时，我们错误地接受了原假设。这种错误也称为“取伪错误”。第二类错误的概率通常用 β 表示。 $\beta = P(H_1)$ 在统计检验中，处理方法如下：控制第一类错误：我们通过设定显著性水平 α 来控制第一类错误的概率。通常 α 被设定为 0.05 或 0.01，这意味着我们愿意接受 5% 或 1% 的弃真错误风险。控制第二类错误：我们可以通过增加样本量来减小第二类错误的概率 β 。此外，还可以选择更合适的检验统计量或使用更精确的测量方法来降低 β 。权衡两类错误：在实际的统计检验中，我们通常需要在第一类错误和第二类错误之间做出权衡，需要根据具体的研究背景和研究目的来确定合适的 α 和 β 。一般来说，会在控制第一类错误水平的基础上，尽量让第二类错误水平小。

四、(10 分) 设 $(X_1, Y_1), \dots, (X_n, Y_n)$ 为一元线性回归模型 $Y = a + bX + \epsilon$ 的 n 个观测样本，其中 $\epsilon \sim N(0, \sigma^2)$ ，记 $\hat{a}_n, \hat{b}_n$ 表示基于上述数据得到的 a, b 的最小二乘估计值。

(1) 若给定 $(X_1, \dots, X_n)$ ，给出 $\sum_{i=1}^n Y_i$ 的分布

(2) $\hat{Y}_k = \hat{a}_n + \hat{b}_n X_k$ ，证明 $\sum_{k=1}^n X_k(Y_k - \hat{Y}_k) = 0$ ，并说明其含义。

(3) 证明 $\hat{a}_n, \hat{b}_n$ 分别为 a, b 的无偏估计。

Solution: (1) $Y_i \sim N(a + bX_i, \sigma^2)$ ， $\sum_{i=1}^n Y_i \sim N(b \sum_{i=1}^n X_i + na, n\sigma^2)$ 。

(2)

$$\begin{aligned}\hat{Y}_k &= \bar{Y} - \hat{b}_n \bar{X} + \hat{b}_n X_k = \bar{Y} + \hat{b}_n (X_k - \bar{X}) \\ Y_k - \hat{Y}_k &= Y_k - \bar{Y} - \hat{b}_n (X_k - \bar{X}) \\ \sum_{k=1}^n X_k (Y_k - \hat{Y}_k) &= \sum_{k=1}^n X_k (Y_k - \bar{Y}) - \hat{b}_n \sum_{k=1}^n X_k (X_k - \bar{X}) \\ &= \sum_{k=1}^n X_k (Y_k - \bar{Y}) - \hat{b}_n (\sum_{k=1}^n X_k^2 - n\bar{X}^2) \\ &= \sum_{k=1}^n X_k (Y_k - \bar{Y}) - \frac{\sum_{k=1}^n (X_k - \bar{X})(Y_k - \bar{Y})}{\sum_{k=1}^n (X_k - \bar{X})^2} (\sum_{k=1}^n X_k^2 - n\bar{X}^2)\end{aligned}$$

由于:

$$\sum_{k=1}^n (X_k - \bar{X})^2 = \sum_{k=1}^n X_k^2 - n\bar{X}^2$$

于是:

$$\sum_{k=1}^n X_k (Y_k - \hat{Y}_k) = \sum_{k=1}^n X_k (Y_k - \bar{Y}) - \sum_{k=1}^n X_k (Y_k - \bar{Y}) = 0$$

这个等式的含义是, 最小二乘估计值 $\hat{a}_n$ 和 $\hat{b}_n$ 使得残差 $Y_k - \hat{Y}_k$ 与自变量 X_k 的乘积之和为零, 即残差与自变量不相关。这是最小二乘法的一个重要性质, 表明最小二乘估计值是无偏的。

(3)

$$\begin{aligned}S &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - (a + bX_i))^2 \\ \frac{\partial S}{\partial a} &= -2 \sum_{i=1}^n (Y_i - a - bX_i) = -2 \left(\sum_{i=1}^n Y_i - na - b \sum_{i=1}^n X_i \right) = 0, \quad a = \bar{Y} - b\bar{X} \\ \frac{\partial S}{\partial b} &= -2 \sum_{i=1}^n (Y_i - a - bX_i) X_i = -2 \left(\sum_{i=1}^n Y_i X_i - a \sum_{i=1}^n X_i - b \sum_{i=1}^n X_i^2 \right) = 0,\end{aligned}$$

将 $a = \bar{Y} - b\bar{X}$ 代入方程, 得到:

$$\begin{aligned}\sum_{i=1}^n Y_i X_i - (\bar{Y} - b\bar{X}) \sum_{i=1}^n X_i - b \sum_{i=1}^n X_i^2 &= 0, \quad \hat{b}_n = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} \\ E(\hat{b}_n) &= \frac{\sum_{i=1}^n (X_i - \bar{X}) E(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})(a + bX_i - a - b\bar{X})}{\sum_{i=1}^n (X_i - \bar{X})^2} \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2 b}{\sum_{i=1}^n (X_i - \bar{X})^2} \\ &= b\end{aligned}$$

$$\hat{a}_n = \bar{Y} - \hat{b}_n \bar{X}, E(\hat{a}_n) = E(\bar{Y} - \hat{b}_n \bar{X}) = E(\bar{Y}) - E(\hat{b}_n) \bar{X} = a + b\bar{X} - b\bar{X} = a$$

所以, $\hat{a}_n, \hat{b}_n$ 分别为 a, b 的无偏估计。

五、(15 分) 设总体为 (a, b) 上的均匀分布, $a < b$, 设 $(X_1, Y_1), \dots, (X_n, Y_n)$ 为该总体的简单随机样本, a, b 为未知参数。

根据 $X_{(1)}, X_{(n)}$ 构建 a 的无偏估计

- (1) 求 a, b 的矩估计
 (2) 求 a, b 的极大似然估计
 (3) 上面关于 a 的两个估计量无偏估计吗? 如果不是, 请说明是否存在无偏估计。

Solution:

(1)

$$E(X) = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

$$\bar{X} = \frac{a+b}{2}, \quad S_n^2 = \frac{(b-a)^2}{12}$$

得到 a 和 b 的矩估计为:

$$\hat{a} = \bar{X} - \sqrt{3S_n^2}, \quad \hat{b} = \bar{X} + \sqrt{3S_n^2}$$

(2) 对于 $[a, b]$ 上的均匀分布, 其概率密度函数为:

$$f(x; a, b) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq x \leq b \\ 0 & \text{otherwise} \end{cases}$$

似然函数为:

$$L(a, b) = \prod_{i=1}^n f(X_i; a, b) = \left(\frac{1}{b-a} \right)^n$$

$$\ln L(a, b) = -n \ln(b-a)$$

为了使似然函数最大, 我们需要使 $b-a$ 最小。由于 $a \leq X_{(1)}$ 和 $b \geq X_{(n)}$, 因此 a 和 b 的极大似然估计为:

$$\hat{a}_{MLE} = X_{(1)}, \quad \hat{b}_{MLE} = X_{(n)}$$

(3) 对于矩估计 $\hat{a} = \bar{X} - \sqrt{3S_n^2}$, 我们有:

$$E(\hat{a}) = E(\bar{X} - \sqrt{3S_n^2}) = E(\bar{X}) - E(\sqrt{3S_n^2}) = \frac{a+b}{2} - E(\sqrt{3S_n^2})$$

由于 $E(\sqrt{3S_n^2}) < \sqrt{E(3S_n^2)} < \frac{b-a}{2}$, 所以 $E(\hat{a}) \neq a$, 因此矩估计 $\hat{a}$ 不是无偏估计。

$$Y_i = \frac{X_i - a}{b-a}, \quad Y_i \sim U(0, 1), \quad Y_{(k)} \sim \text{Beta}(k, n-k+1)$$

则有:

$$Y_{(1)} \sim \text{Beta}(1, n), \quad E(Y_{(1)}) = \frac{1}{n+1}, \quad E(X_{(1)}) = \frac{b-a}{n+1} + a$$

$$Y_{(n)} \sim \text{Beta}(n, 1), \quad E(Y_{(n)}) = \frac{n}{n+1}, \quad E(X_{(n)}) = \frac{n(b-a)}{n+1} + a$$

对于极大似然估计, $E(\hat{a}_{MLE}) = E(X_{(1)})$, 由于 $E(X_{(1)})$ 并不等于 a , 所以极大似然估计 $\hat{a}_{MLE}$ 也不是无偏估计。

$$\hat{a}_{\text{new}} = \frac{nX_{(1)} - X_{(n)}}{n-1}$$

存在无偏估计, 这个估计量是无偏的, 因为:

$$E(\hat{a}_{\text{new}}) = \frac{nE(X_{(1)}) - E(X_{(n)})}{n-1} = a$$

(如果用其他估计方法计算出的无偏估计也是可以的, 答案不唯一)。

六、(15 分) 根据沪深 300 指数在 2020 年和 2023 年的年化日指数收益率得到的信息如下:

企业的股票收益率	样本容量	均值	标准差	偏度
2020 年	244	26.5%	22.3%	-0.84
2023 年	242	-11.2%	10.1%	0.34

- (1) (3 分) 简要说明这两年日指数收益率的分布差异。
- (2) (4 分) 将这两年的样本合并, 求合并后的均值、标准差。
- (3) (4 分) 说明如何检验这两年的日指数收益率均值是否存在显著差异。
- (4) (4 分) 说明如何检验这两年的日指数收益率的标准差是否存在显著差异。

Solution:

(1) ** 均值差异 **: 2020 年的收益率均值为 26.5%, 而 2023 年为 -11.2%, 显示 2020 年的收益率远高于 2023 年。

** 标准差差异 **: 2020 年的标准差为 22.3%, 而 2023 年为 10.1%, 表明 2020 年的收益率波动性更大。

** 偏度差异 **: 负偏度表明 2020 年的分布左偏, 而正峰度表明 2023 年的分布右偏, 两者的形态不同。

(2)

$$\bar{X}_{\text{combined}} = \frac{n_{2020} \cdot \bar{X}_{2020} + n_{2023} \cdot \bar{X}_{2023}}{n_{2020} + n_{2023}} \approx 7.73\%$$

令: $n = n_{2020} + n_{2023} = 244 + 242 = 486$,

$$\begin{aligned} S_{\text{combined}} &= \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X}_{\text{combined}})^2}{n-1}} \\ &= \sqrt{\frac{\sum_{i=1}^{n_{2020}} (X_i - \bar{X}_{\text{combined}})^2 + \sum_{i=n_{2020}+1}^{n_{\text{combined}}} (X_i - \bar{X}_{\text{combined}})^2}{n-1}} \end{aligned}$$

$$\begin{aligned} \sum_{i=1}^{n_{2020}} (X_i - \bar{X}_{\text{combined}})^2 &= \sum_{i=1}^{n_{2020}} (X_i - \bar{X}_{2020} + \bar{X}_{2020} - \bar{X}_{\text{combined}})^2 \\ &= \sum_{i=1}^{n_{2020}} (X_i - \bar{X}_{2020})^2 + \sum_{i=1}^{n_{2020}} (\bar{X}_{2020} - \bar{X}_{\text{combined}})^2 \\ \sum_{i=n_{2020}+1}^{n_{\text{combined}}} (X_i - \bar{X}_{\text{combined}})^2 &= \sum_{i=n_{2020}+1}^{n_{\text{combined}}} (X_i - \bar{X}_{2023})^2 + \sum_{i=n_{2020}+1}^{n_{\text{combined}}} (\bar{X}_{2023} - \bar{X}_{\text{combined}})^2 \end{aligned}$$

$$S_{\text{combined}} = \sqrt{\frac{(n_{2020}-1)S_{2020}^2 + (n_{2023}-1)S_{2023}^2 + n_{2020}(\bar{X}_{2020} - \bar{X}_{\text{combined}})^2 + n_{2023}(\bar{X}_{2023} - \bar{X}_{\text{combined}})^2}{n-1}} \approx 25.6\%$$

(3) 1. 设定原假设和备择假设:

$$H_0: \mu_{2020} = \mu_{2023}, \quad H_1: \mu_{2020} \neq \mu_{2023}$$

1. 选择检验方法: 由于样本标准差未知且不相等, 但是样本容量较大, 可以使用大样本 u 检验来比较两个独立样本的均值。

2. 计算检验统计量:

$$Z = \frac{\bar{X}_{2020} - \bar{X}_{2023}}{\sqrt{\frac{S_{2020}^2}{n_{2020}} + \frac{S_{2023}^2}{n_{2023}}}}$$

1. 确定显著性水平, 令 $\alpha = 0.05$ 。

2. 比较 Z 值与临界值: 如果计算出的 $|Z| > z_{1-\alpha}$ ($z_{1-\alpha}$ 是标准正态分布的分位数), 则拒绝原假设; 否则接受原假设。

(4) 1. 设定原假设和备择假设:

$$H_0: \sigma_{2020} = \sigma_{2023}, \quad H_1: \sigma_{2020} \neq \sigma_{2023}$$

2. 选择检验方法: 由于样本量较大, 可以使用两个正态总体方差比的 F 检验。

3. 计算检验统计量:

$$F = \frac{s_{2020}^2}{s_{2023}^2}$$

4. 确定显著性水平, 令 $\alpha = 0.05$ 。

5. 比较 F 值与临界值: 自由度 $df_{2020} = n_{2020} - 1 = 243$ 和 $df_{2023} = n_{2023} - 1 = 241$, 拒绝域为:

$$W = \left\{ F \leq F_{\frac{\alpha}{2}}(243, 241) \text{ 或 } F \geq F_{1-\frac{\alpha}{2}}(243, 241) \right\}$$

若 F 位于拒绝域中则拒绝原假设, 认为存在显著差异; 否则接受原假设。

2025 微观部分解析

一、(15 分) 小镇上有 N 个居民, 总财富为 1, 财富在 N 个居民中平均分配。每个居民选择将自己的财富拿出 y 进行私人消费, 拿出 x 用于环保支出。每个居民的效用函数是 $u = \sqrt{Xy}$, 其中 X 为小镇的环保总支出 (所有居民的环保支出之和)。

1. (7 分) 小镇居民的环境总支出 X 为多少? 随着 N 如何变化? 2. (8 分) 问题 (1) 的结果反应了什么经济学原理?

Solution:

(1) 最优问题的求解

考虑小镇上的居民 i , 其私人消费为 y_i , 环保支出为 x_i , $i = 1, 2, \dots, N$ 。为了使其效用最大化, 居民的优化问题为:

$$\begin{cases} \max u_i = \sqrt{\left(\sum_{i=1}^N x_i\right) y_i} \\ \text{s.t. } x_i + y_i = \frac{1}{N} \end{cases}$$

通过构建拉格朗日函数,

$$L(x_i, y_i, \lambda) = \sqrt{\left(\sum_{i=1}^N x_i\right) y_i} - \lambda \left(x_i + y_i - \frac{1}{N}\right)$$

求其偏导数, 令偏导数为 0:

$$\begin{cases} \frac{\partial L}{\partial x_i} = \frac{1}{2} \frac{y_i}{\sqrt{\left(\sum_{i=1}^N x_i\right) y_i}} - \lambda = 0 \\ \frac{\partial L}{\partial y_i} = \frac{1}{2} \frac{\sum_{i=1}^N x_i}{\sqrt{\left(\sum_{i=1}^N x_i\right) y_i}} - \lambda = 0 \\ \frac{\partial L}{\partial \lambda} = -\left(x_i + y_i - \frac{1}{N}\right) = 0 \end{cases}$$

通过求解方程组可得：

$$y_i = \sum_{i=1}^N x_i,$$
$$x_i + \sum_{i=1}^N x_i = \frac{1}{N}.$$

由于对称性，可得：

$$\sum_{i=1}^N \left(x_i + \sum_{i=1}^N x_i \right) = 1.$$

最终解得 $X = \frac{1}{N+1}$ ，且 X 随着 N 增加而减少。

(2) 环保支出的经济学分析

1. ** 正外部性与公共产品特性 ** 环保支出是一种正外部性的公共产品，具有非排他性，即一旦发生环保支出行为，很难排除其他人从环境改善中受益。这种特性导致搭便车现象广泛存在，仅依靠市场机制，环保支出的总额往往不足。

2. ** 边际社会收益与私人决策 ** 环保支出的边际社会收益通常大于边际私人收益，因此市场机制下资源配置可能不是最优。居民在决策环保支出时，以自身效用函数最大化为目标，忽略了其行为对社会整体的正外部性影响，从而导致环保支出不足。

二、(20 分) 假设某商品的市场需求函数为 $P = 4 - Q$ ，其中 P 为价格， Q 为总产量。市场中有三家供应企业，其中龙头企业的生产成本函数是 x^2 ，两个中游企业的生产成本函数是 $2x^2$ 。各家企业独自确定最大化自身利润的生产量。

1. (10 分) 求均衡时的总产量。2. (10 分) 若两家中游企业需要获得政府牌照才能销售生产的商品。有 50% 的概率两个中游企业都能获得牌照；有另外 50% 的概率只有一个中游企业能够获得牌照，在这种情况下，具体哪家获得牌照的概率相等。企业需在获得牌照之前进行生产。求均衡时的总产量。

Solution:

(1) 均衡产量求解

记龙头企业的产量为 x_1 ，两个中游企业的产量分别为 x_2, x_3 ，对应的利润分别为 π_1, π_2, π_3 。

对于龙头企业，其利润为：

$$\pi_1 = \left(4 - \sum_{i=1}^3 x_i \right) x_1 - x_1^2$$

对 x_1 求导：

$$\frac{\partial \pi_1}{\partial x_1} = 4 - 3x_1 - \sum_{i=1}^3 x_i$$

类似地，对于中游企业，其利润为：

$$\pi_i = \left(4 - \sum_{i=1}^3 x_i \right) x_i - 2x_i^2, \quad i=2,3$$

对 x_i 求导：

$$\frac{\partial \pi_i}{\partial x_i} = 4 - 5x_i - \sum_{i=1}^3 x_i, \quad i=2,3$$

为使利润最大化，令导数等于 0，联立方程组可得：

$$\begin{cases} x_1 = \frac{10}{13}, \\ x_2 = x_3 = \frac{6}{13}. \end{cases}$$

均衡时，总产量为：

$$Q = \sum_{i=1}^3 x_i = \frac{22}{13}.$$

(2) 龙头企业和中游企业的利润分布：

龙头企业的利润分布

对于龙头企业，其利润分布为：

$$\pi_1 = \begin{cases} (4 - \sum_{i=1}^3 x_i) x_1 - x_1^2, & \text{概率} 0.5, \\ (4 - x_1 - x_3) x_1 - x_1^2, & \text{概率} 0.25, \\ (4 - x_1 - x_2) x_1 - x_1^2, & \text{概率} 0.25. \end{cases}$$

因此，龙头企业的期望利润为：

$$E\pi_1 = (4 - x_1 - 0.75x_2 - 0.75x_3) x_1 - x_1^2$$

对 x_1 求导：

$$\frac{\partial E\pi_1}{\partial x_1} = 4 - 4x_1 - 0.75x_2 - 0.75x_3$$

中游企业 2 的利润分布

对于中游企业 2，其利润分布为：

$$\pi_2 = \begin{cases} (4 - \sum_{i=1}^3 x_i) x_2 - 2x_2^2, & \text{概率} 0.5, \\ (4 - x_1 - x_2) x_2 - 2x_2^2, & \text{概率} 0.25, \\ -2x_2^2, & \text{概率} 0.25. \end{cases}$$

因此，中游企业 2 的期望利润为：

$$E\pi_2 = (3 - 0.75x_1 - 0.75x_2 - 0.5x_3) x_2 - 2x_2^2$$

对 x_2 求导：

$$\frac{\partial E\pi_2}{\partial x_2} = 3 - 0.75x_1 - 5.5x_2 - 0.5x_3$$

中游企业 3 的利润分布

由于对称性，中游企业 3 的导数为：

$$\frac{\partial E\pi_3}{\partial x_3} = 3 - 0.75x_1 - 0.5x_2 - 5.5x_3$$

联立求解均衡解

令导数均为 0，联立方程组可得：

$$\begin{cases} x_1 = \frac{52}{61}, \\ x_2 = x_3 = \frac{24}{61}. \end{cases}$$

均衡时，总产量为：

$$Q = \sum_{i=1}^3 x_i = \frac{100}{61}.$$

三、(20 分) 股票市场上有两个股票投机者，他们将选择是否要卖空股票。如果投机者选择卖空股票，他需要支付成本 $c = 2$ ，而获得的收益为 $v = 1.5N$ ， N 为市场上卖空的人数；如果投机者选择不卖空的话，那么他的成本和收益均为 0。

1. (5 分) 如果两个投机者同时采取纯策略选择是否卖空，请推导出可能的纳什均衡。2. (5 分) 如果两个投机者同时采取相同的混合策略选择是否卖空，请推导出可能的纳什均衡。3. (10 分) 请简要论述，有哪些政策措施可以阻止投机者卖空。

Solution:

(1) 纯策略纳什均衡

由题目可得收益矩阵如下：

	投机者 2 卖空	投机者 2 不卖空
投机者 1 卖空	(1, 1)	(-0.5, 0)
投机者 1 不卖空	(0, -0.5)	(0, 0)

显然，当仅考虑纯策略时，以下两种策略组合达到了纳什均衡：- (卖空, 卖空) - (不卖空, 不卖空)

(2) 混合策略纳什均衡

在混合策略纳什均衡中，参与者以一定的概率分布在不同策略之间进行随机选择。在该均衡中，每个参与者的选择对其收益都是无差异的。

假设投机者 1 和投机者 2 的混合策略分别为 p 和 q ，其中：- 投机者 1 选择“卖空”的概率为 p ，选择“不卖空”的概率为 $1 - p$ ；- 投机者 2 选择“卖空”的概率为 q ，选择“不卖空”的概率为 $1 - q$ 。

收益矩阵更新如下：

	投机者 2 卖空 q	投机者 2 不卖空 $1 - q$
投机者 1 卖空 p	(1, 1)	(-0.5, 0)
投机者 1 不卖空 $1 - p$	(0, -0.5)	(0, 0)

对投机者 1 的期望收益分析

- 选择“卖空”的期望收益为：

$$q \cdot 1 + (1 - q) \cdot (-0.5) = 1.5q - 0.5$$

- 选择“不卖空”的期望收益为 0：

当 $1.5q - 0.5 = 0$ 时，投机者 1 的选择是无差异的，可解得：

$$q = \frac{1}{3}$$

对投机者 2 的期望收益分析

由对称性可得, 投机者 2 的混合策略概率为:

$$p = \frac{1}{3}$$

因此, 在混合策略纳什均衡中: - 投机者 1 和投机者 2 选择“卖空”的概率均为 $\frac{1}{3}$; - 选择“不卖空”的概率均为 $\frac{2}{3}$ 。

(3) 抑制卖空行为的措施

1. ** 降低卖空收益 **: 通过减少卖空交易的收益, 甚至让卖空收益低于成本, 从而使投机者无利可图, 抑制卖空行为。

2. ** 提高卖空成本 **: 增加卖空的交易成本, 使卖空的利润减少, 从而降低投机者选择卖空的意愿。

3. ** 对不卖空行为进行奖励 **: 通过奖励不卖空行为, 提高不卖空的收益, 使得相对而言, 卖空的收益降低, 从而抑制卖空行为。

4. ** 提高卖空门槛或限制卖空数量 **: 通过提高准入门槛或限制卖空的最大数量, 减少参与卖空的投机者数量, 同时限制卖空收益, 从而抑制卖空行为。

5. ** 实施禁止卖空的法律法规 **: 直接通过法律手段禁止卖空交易, 从根本上遏制卖空行为。

四、(20 分) 作为一名风险产业的企业家, 有一个投资项目需要向银行申请 100 万贷款进行投资。投资项目成功的概率为 q (q 的可能值为 $\frac{2}{3}$ 或 $\frac{1}{2}$)。项目成功的收益为 300 万, 项目失败则收益为 0。 q 对于企业家来说是已知的, 而对于银行来说是未知的, 银行仅知晓有 50% 概率 $q = \frac{2}{3}$, 另外 50% 概率 $q = \frac{1}{2}$ 。如果银行将 100 万的资金贷给企业, 银行会要求偿还 F 以维持收支平衡, (注: 只有当项目成功时, 才能偿还银行 F ; 如果项目失败, 银行只能获得 0, 收支平衡是指企业给银行的预期总还款为 100 万)

1. (7 分) 求维持银行收支平衡的 F 的值。2. (7 分) 在 (1) 的基础上, 假设企业家还可以选择投资另一个项目, 该项目的收益是确定的, 即假设投资 100 万后, 未来的收益为 220 万。这意味着在获得 100 万的贷款后, 企业家可以在两个项目中选择预期收益更大的项目进行投资, 在这种情况下, 求维持银行收支平衡的 F 最小值。

3. (6 分) 在 (1) 的基础上, 企业家仅可以选择第一个投资项目进行投资, 假设企业家可以选择将价值 80 万的资产抵押给银行, 如果项目成功, 则抵押资产归还企业; 但如果项目失败, 银行会将资产在市场上出售以弥补损失, 由于流动性的原因, 该抵押资产的出售价格只有 50 万。请问是否存在一个分离均衡, 即当 $q = \frac{2}{3}$ 时, 企业家会选择抵押资产; 当 $q = \frac{1}{2}$ 时, 企业家不会选择抵押资产?

Solution:

(1) 银行的期望收益为:

$$E\Pi_{\text{银}} = E\left[\Pi_{\text{银}} \mid q = \frac{2}{3}\right] P\left\{q = \frac{2}{3}\right\} + E\left[\Pi_{\text{银}} \mid q = \frac{1}{2}\right] P\left\{q = \frac{1}{2}\right\}$$

其中:

$$E\left[\Pi_{\text{银}} \mid q = \frac{2}{3}\right] = \frac{2}{3}F, \quad E\left[\Pi_{\text{银}} \mid q = \frac{1}{2}\right] = \frac{1}{2}F$$

代入得:

$$E\Pi_{\text{银}} = \frac{7}{12}F$$

为维持银行收支平衡, 令 $E\Pi_{\text{银}} = 100$, 可得:

$$F = \frac{1200}{7}$$

(2) 企业家的选择

当企业家选择第二个投资项目时:

$$E\Pi_{\text{企}} = 220 - F$$

** 当项目一的成功概率 $q = \frac{2}{3}$ 时 **:

$$E\Pi_{\text{企}} = \frac{2}{3}(300 - F)$$

令两个项目的期望收益相等，可得：

$$F = 60$$

因此：- 若 $F < 60$ ，企业家选择项目二；- 若 $F > 60$ ，企业家选择项目一。

** 当项目一的成功概率 $q = \frac{1}{2}$ 时 **：

$$E\Pi_{\text{企}} = \frac{1}{2}(300 - F)$$

令两个项目的期望收益相等，可得：

$$F = 140$$

因此：- 若 $F < 140$ ，企业家选择项目二；- 若 $F > 140$ ，企业家选择项目一。

结合以上情况：- 若 $F < 60$ ，企业家只选择项目二；- 若 $F > 140$ ，企业家只选择项目一；- 若 $60 < F < 140$ ，企业家在 $q = \frac{2}{3}$ 时选择项目一，在 $q = \frac{1}{2}$ 时选择项目二。

进一步分析银行的收支平衡：- 若 $F < 60$ ，则 $E\pi_{\text{银}} = F$ ，为使银行收支平衡， $F = 100$ ，与 $F < 60$ 不符，应舍去；- 若 $F > 140$ ，则 $E\pi_{\text{银}} = \frac{7}{12}F$ ，为使银行收支平衡，可得 $F = \frac{1200}{7}$ ；- 若 $60 < F < 140$ ，则：

$$E\pi_{\text{银}} = \frac{1}{2}E\left[\pi_{\text{银}} \mid q = \frac{2}{3}\right] + \frac{1}{2}F = \frac{5}{6}F$$

为使银行收支平衡，可得：

$$F = 120$$

因此，满足银行收支平衡的 F 最小值为 120。

(3) 抵押与不抵押的分离均衡分析

假设市场上存在两个针对不同企业的贷款合同，以实现分离均衡：1. 针对高成功率企业 ($q = 2/3$) 的合同：要求还款 F_1 ，并提供抵押品（对企业价值 80，对银行变现价值 50）。2. 针对低成功率企业 ($q = 1/2$) 的合同：要求还款 F_2 ，无需抵押。

要判断是否存在分离均衡，需验证是否同时满足以下三组约束条件：

1. 激励相容约束激励相容要求每类企业家都认为属于自己的合同比对方的合同能带来更高的期望效用。

* ** 高成功率企业 ($q = 2/3$) 偏好抵押合同： **

$$E\pi_H(\text{抵押}) \geq E\pi_H(\text{不抵押})$$

$$\frac{2}{3}(300 - F_1) - \frac{1}{3}(80) \geq \frac{2}{3}(300 - F_2)$$

$$-\frac{2}{3}F_1 - \frac{80}{3} \geq -\frac{2}{3}F_2$$

化简得：

$$F_2 - F_1 \geq 40$$

* ** 低成功率企业 ($q = 1/2$) 偏好不抵押合同： **

$$E\pi_L(\text{不抵押}) \geq E\pi_L(\text{抵押})$$

$$\frac{1}{2}(300 - F_2) \geq \frac{1}{2}(300 - F_1) - \frac{1}{2}(80)$$

$$-\frac{1}{2}F_2 \geq -\frac{1}{2}F_1 - 40$$

化简得：

$$F_2 - F_1 \leq 80$$

** 综合约束: **

$$40 \leq F_2 - F_1 \leq 80$$

2. 参与约束只有当企业预期的净利润大于等于 0 时, 企业家才会参与贷款, 否则会退出市场。

* ** 高成功率企业 ($q = 2/3$) 的参与条件: **

$$E\pi_H = \frac{2}{3}(300 - F_1) - \frac{1}{3}(80) \geq 0$$

$$200 - \frac{2}{3}F_1 - 26.67 \geq 0$$

$$\frac{2}{3}F_1 \leq 173.33$$

$$F_1 \leq 260$$

* ** 低成功率企业 ($q = 1/2$) 的参与条件: **

$$E\pi_L = \frac{1}{2}(300 - F_2) \geq 0$$

$$150 - \frac{1}{2}F_2 \geq 0$$

$$F_2 \leq 300$$

3. 银行收支平衡约束在分离均衡下, 银行能够区分两类企业。由于银行不知道具体哪个企业是哪类 (只知道概率分布), 但它设计的机制使得两类企业会自动选择对应的合同。因此, 银行的总期望收益需覆盖本金 100 万。

银行的期望收益为:

$$E\pi_{\text{银}} = 0.5 \times E[\pi | \text{高资质}] + 0.5 \times E[\pi | \text{低资质}] = 100$$

其中: * 来自高资质企业的期望回报 (含抵押变现): $\frac{2}{3}F_1 + \frac{1}{3}(50)$ * 来自低资质企业的期望回报: $\frac{1}{2}F_2$

代入得:

$$\frac{1}{2} \left[\frac{2}{3}F_1 + \frac{50}{3} \right] + \frac{1}{2} \left[\frac{1}{2}F_2 \right] = 100$$

$$\frac{1}{3}F_1 + \frac{25}{3} + \frac{1}{4}F_2 = 100$$

$$\frac{1}{3}F_1 + \frac{1}{4}F_2 = \frac{275}{3}$$

化简得:

$$4F_1 + 3F_2 = 1100$$

4. 均衡存在性验证联立所有约束条件:

$$\begin{cases} 4F_1 + 3F_2 = 1100 \\ 40 \leq F_2 - F_1 \leq 80 \\ F_1 \leq 260 \\ F_2 \leq 300 \end{cases}$$

我们寻找是否存在满足上述条件的解 (F_1, F_2)。尝试取下界, 即令 $F_2 = F_1 + 40$: 代入 (1) 式:

$$4F_1 + 3(F_1 + 40) = 1100$$

$$7F_1 + 120 = 1100$$

$$7F_1 = 980 \implies F_1 = 140$$

此时, $F_2 = 140 + 40 = 180$ 。

** 检查是否满足所有条件: ** * $F_2 - F_1 = 40$, 在 $[40, 80]$ 范围内, 满足。* $F_1 = 140 \leq 260$, 满足。
 $F_2 = 180 \leq 300$, 满足。

** 结论: ** 存在满足条件的分离均衡。例如, 银行可以提供一组选择: * 合同 A (需抵押): 利率 (还款额) $F_1 = 140$ 万, 需抵押资产; * 合同 B (无抵押): 利率 (还款额) $F_2 = 180$ 万, 无需抵押。

在该均衡下, 高成功率企业会选择抵押贷款, 低成功率企业会选择无抵押贷款, 且银行能维持收支平衡。

北京大学-431 金融学综合-2026

• 2026 统计部分解析

一、证明以下命题。

1 (5') 设 X, Y 为连续随机变量, 证明全期望公式:

$$E[E[X|Y]] = E[X]$$

2 (10') 证明条件方差分解公式:

$$\text{Var}(X) = E[\text{Var}(X|Y)] + \text{Var}(E[X|Y])$$

Solution:

(1) 证明全期望公式:

对于连续随机变量 X, Y , 设 (X, Y) 的联合概率密度函数为 $f(x, y)$, 边缘密度为 $f_Y(y)$, 条件密度为 $f_{X|Y}(x|y)$ 。条件期望的定义为:

$$E[X|Y=y] = \int_{-\infty}^{+\infty} x \cdot f_{X|Y}(x|y) dx = \int_{-\infty}^{+\infty} x \frac{f(x, y)}{f_Y(y)} dx$$

因此 $E[X|Y]$ 是关于 Y 的函数。对 $E[X|Y]$ 再求关于 Y 的期望:

$$\begin{aligned} E[E[X|Y]] &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{+\infty} x \frac{f(x, y)}{f_Y(y)} dx \right) f_Y(y) dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x \cdot f(x, y) dx dy \\ &= \int_{-\infty}^{+\infty} x \left(\int_{-\infty}^{+\infty} f(x, y) dy \right) dx \\ &= \int_{-\infty}^{+\infty} x \cdot f_X(x) dx \\ &= E[X] \end{aligned}$$

(2) 证明条件方差分解公式:

根据方差定义 $\text{Var}(X) = E[(X - E[X])^2]$, 我们在平方项内加减 $E[X|Y]$ 并展开:

$$\begin{aligned} \text{Var}(X) &= E \left[((X - E[X|Y]) + (E[X|Y] - E[X]))^2 \right] \\ &= E[(X - E[X|Y])^2] + E[(E[X|Y] - E[X])^2] + 2E[(X - E[X|Y])(E[X|Y] - E[X])] \end{aligned}$$

第一项: 利用全期望公式

$$E[(X - E[X|Y])^2] = E[E[(X - E[X|Y])^2 | Y]] = E[\text{Var}(X|Y)]$$

第二项: 利用全期望公式

$$E[(E[X|Y] - E[X])^2] = \text{Var}(E[X|Y])$$

第三项: 利用全期望公式

$$\begin{aligned}
E[(X - E[X|Y])(E[X|Y] - E[X])] &= E[E[(X - E[X|Y])(E[X|Y] - E[X]) | Y]] \\
&= E[(E[X|Y] - E[X]) \cdot E[(X - E[X|Y]) | Y]] \\
&= E[(E[X|Y] - E[X]) \cdot (E[X|Y] - E[X|Y])] \\
&= E[(E[X|Y] - E[X]) \cdot 0] \\
&= 0
\end{aligned}$$

将三项结果相加, 可得:

$$Var(X) = E[Var(X|Y)] + Var(E[X|Y])$$

二、设随机变量 $X \sim U(0, 1)$, $Z \sim U(0, 1/10)$, 且 X 与 Z 相互独立。令 $Y = X + Z$ 。

(1) (5') 求 (X, Y) 的联合概率密度函数 $f(x, y)$;

(2) (5') 求 $Cov(X, Y)$;

(3) (5') 求 $Corr(X, Y)$ 。

Solution:

(1) 求 (X, Y) 的联合概率分布函数:

已知 X 和 Z 的边缘密度函数分别为:

$$f_X(x) = \begin{cases} 1, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}, \quad f_Z(z) = \begin{cases} 10, & 0 < z < 0.1 \\ 0, & \text{其他} \end{cases}$$

由于 X, Z 独立, 在支撑集上 (X, Z) 的联合密度为 $f(x, z) = 10$ 。令 $u = x, v = x + z$ (即 y), 解得: $x = u, z = v - u$ 。雅可比行列式为:

$$J = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial z}{\partial u} & \frac{\partial z}{\partial v} \end{pmatrix} = \det \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} = 1$$

联合密度 $f(x, y) = f_X(x)f_Z(y-x) \cdot |J|$ 。代入密度表达式, 得 $f(x, y) = 1 \cdot 10 \cdot 1 = 10$ 。非零区域由 f_X 和 f_Z 的支撑集决定:

$$\begin{cases} 0 < x < 1 \\ 0 < y - x < 0.1 \end{cases} \Rightarrow \begin{cases} 0 < x < 1 \\ x < y < x + 0.1 \end{cases}$$

故 (X, Y) 的联合概率密度函数为:

$$f(x, y) = \begin{cases} 10, & 0 < x < 1, x < y < x + 0.1 \\ 0, & \text{其他} \end{cases}$$

(2) 求 $Cov(X, Y)$:

由于 $Y = X + Z$, 且 X, Z 相互独立, 故 $Cov(X, Z) = 0$ 。

$$\begin{aligned}
Cov(X, Y) &= Cov(X, X + Z) \\
&= Cov(X, X) + Cov(X, Z) \\
&= Var(X)
\end{aligned}$$

已知 $X \sim U(0, 1)$, 其方差为 $Var(X) = \frac{(1-0)^2}{12} = \frac{1}{12}$ 。所以:

$$Cov(X, Y) = \frac{1}{12}$$

(3) 求 $Corr(X, Y)$:

相关系数公式为 $\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}}$ 。先计算 $Var(Y)$ 。由于 X, Z 独立:

$$Var(Y) = Var(X + Z) = Var(X) + Var(Z)$$

已知 $Z \sim U(0, 0.1)$, 故 $Var(Z) = \frac{(0.1-0)^2}{12} = \frac{0.01}{12} = \frac{1}{1200}$ 。

$$Var(Y) = \frac{1}{12} + \frac{1}{1200} = \frac{100}{1200} + \frac{1}{1200} = \frac{101}{1200}$$

代入计算相关系数:

$$\begin{aligned} Corr(X, Y) &= \frac{\frac{1}{12}}{\sqrt{\frac{1}{12}} \cdot \sqrt{\frac{101}{1200}}} \\ &= \frac{\frac{1}{12}}{\frac{1}{12} \cdot \sqrt{101} \cdot \sqrt{\frac{1}{100}}} \\ &= \frac{1}{\frac{\sqrt{101}}{10}} \\ &= \frac{10}{\sqrt{101}} \end{aligned}$$

三、设二维随机变量 (X, Y) 的联合概率密度函数为:

$$f(x, y) = \begin{cases} kxy, & 0 \leq y \leq x \leq 1 \\ 0, & \text{其他} \end{cases}$$

(1) (5') 求常数 k ;

(2) (5') 求 (X, Y) 的联合分布函数 $F(x, y)$;

(3) (10') 求边缘密度函数 $f_X(x)$ 和 $f_Y(y)$ 。

Solution:

(1) 求 k :

$$\begin{aligned} \int_0^1 dy \int_y^1 8xy dx &= \int_0^1 ky \left[\frac{1}{2} x^2 \right]_y^1 dy \\ &= \int_0^1 \frac{k}{2} y(1 - y^2) dy \\ &= \frac{k}{8} = 1 \end{aligned}$$

解得 $k = 8$ 。

(2) 求联合分布函数 $F(x, y)$:

联合分布函数定义为 $F(x, y) = P(X \leq x, Y \leq y) = \iint_{D_{x,y}} f(u, v) du dv$ 。积分区域 D 为 $\{(x, y) : 0 \leq y \leq x \leq 1\}$ 。我们分情况讨论:

1. 当 $x \leq 0$ 或 $y \leq 0$ 时, $F(x, y) = 0$ 。2. 当 $x \geq 1$ 且 $y \geq 1$ 时, $F(x, y) = 1$ 。3. 当 $0 \leq y \leq 1$ 且 $x \geq 1$ 时, $F(x, y) = \int_0^y dv \int_v^1 8uv dv = 2y^2 - y^4$ 4. 当 $0 \leq y \leq x \leq 1$ 时, $F(x, y) = \int_0^y dv \int_v^x 8uv dv = 2x^2y^2 - y^4$ 5. 当 $0 \leq x \leq 1$ 且 $y \geq x$ 时, $F(x, y) = \int_0^x dv \int_v^1 8uv dv = x^4$

综上所述:

$$F(x, y) = \begin{cases} 0, & x \leq 0 \text{ 或 } y \leq 0 \\ x^4, & 0 < x \leq 1, y > x \\ 2x^2y^2 - y^4, & 0 < y \leq x \leq 1 \\ 2y^2 - y^4, & 0 \leq y \leq 1, x \geq 1 \\ 1, & x \geq 1, y \geq 1 \end{cases}$$

(3) 求边缘密度函数:

边缘密度 $f_X(x)$:

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \int_0^x 8xy dy = 8x \left[\frac{y^2}{2} \right]_0^x = 4x^3, \quad 0 \leq x \leq 1; \text{ else } 0$$

边缘密度 $f_Y(y)$:

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx = \int_y^1 8xy dx = 8y \left[\frac{x^2}{2} \right]_y^1 = 4y(1 - y^2), \quad 0 \leq y \leq 1; \text{ else } 0$$

四、设随机变量 X 服从参数为 $\lambda (\lambda > 0)$ 的泊松分布。

(1) (5') 设 $g(X)$ 为使得期望存在的函数, 证明:

$$E[Xg(X)] = \lambda E[g(X+1)]$$

(2) (5') 求 X 的三阶原点矩 $E[X^3]$ 和四阶原点矩 $E[X^4]$ 。

(3) (10') 设 X_1, X_2 为来自该总体的简单随机样本, 考虑参数 λ 的两个估计量:

$$\hat{\lambda}_1 = \frac{X_1 + X_2}{2}, \quad \hat{\lambda}_2 = \frac{(X_1 - X_2)^2}{2}$$

计算它们的均方误差 (MSE), 并比较这两个估计量的优劣。

(4) (5') 设 $X_1, \dots, X_n$ 为来自该总体的简单随机样本, $\bar{X}$ 为样本均值。请利用 $\bar{X}$ 构造统计量, 在置信水平为 α 的要求下, 对假设 $H_0: \lambda = 1 \leftrightarrow H_1: \lambda \neq 1$ 进行检验 (写出检验统计量及其在大样本下的近似分布, 以及拒绝域)。

Solution:

(1) 证明:

由 $X \sim P(\lambda)$:

$$\begin{aligned}
 E[Xg(X)] &= \sum_{k=0}^{\infty} kg(k) \frac{\lambda^k}{k!} e^{-\lambda} \\
 &= \sum_{k=1}^{\infty} g(k) \frac{\lambda^k}{(k-1)!} e^{-\lambda} \quad (\text{当 } k=0 \text{ 时项为0}) \\
 \text{令 } j &= k-1, = \lambda \sum_{j=0}^{\infty} g(j+1) \frac{\lambda^j}{j!} e^{-\lambda} \\
 &= \lambda E[g(X+1)]
 \end{aligned}$$

(2) 求 $E[X^3]$ 和 $E[X^4]$:

利用第 (1) 问引理 $E[Xg(X)] = \lambda E[g(X+1)]$ 进行递推计算。泊松分布的一阶和二阶矩为:

$$E[X] = \lambda, \quad E[X^2] = \text{Var}(X) + (E[X])^2 = \lambda + \lambda^2$$

计算三阶矩 $E[X^3]$: 令 $g(X) = X^2$, 代入引理:

$$\begin{aligned}
 E[X^3] &= E[X \cdot X^2] = \lambda E[(X+1)^2] \\
 &= \lambda E[X^2 + 2X + 1] \\
 &= \lambda((\lambda^2 + \lambda) + 2\lambda + 1) \\
 &= \lambda^3 + 3\lambda^2 + \lambda
 \end{aligned}$$

计算四阶矩 $E[X^4]$: 令 $g(X) = X^3$, 代入引理:

$$\begin{aligned}
 E[X^4] &= E[X \cdot X^3] = \lambda E[(X+1)^3] \\
 &= \lambda E[X^3 + 3X^2 + 3X + 1] \\
 &= \lambda[(\lambda^3 + 3\lambda^2 + \lambda) + 3(\lambda^2 + \lambda) + 3\lambda + 1] \\
 &= \lambda^4 + 6\lambda^3 + 7\lambda^2 + \lambda
 \end{aligned}$$

(3) 比较估计量的均方误差:

均方误差定义为 $MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2$, 同时也有结论:

$$MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2$$

对于 $\hat{\lambda}_1 = \frac{X_1 + X_2}{2}$:

$$\begin{aligned}
 E[\hat{\lambda}_1] &= \frac{\lambda + \lambda}{2} = \lambda \\
 \text{Var}(\hat{\lambda}_1) &= \frac{1}{4}(\text{Var}(X_1) + \text{Var}(X_2)) = \frac{2\lambda}{4} = \frac{\lambda}{2} \\
 MSE(\hat{\lambda}_1) &= \frac{\lambda}{2}
 \end{aligned}$$

对于 $\hat{\lambda}_2 = \frac{(X_1 - X_2)^2}{2}$: 首先计算期望:

$$E[\hat{\lambda}_2] = \frac{1}{2}E[(X_1 - X_2)^2] = \frac{1}{2}[\text{Var}(X_1 - X_2) + (E[X_1 - X_2])^2] = \frac{1}{2}(2\lambda + 0) = \lambda$$

然后计算方差, 需先求 $E[\hat{\lambda}_2^2] = \frac{1}{4}E[(X_1 - X_2)^4]$ 。展开 $(X_1 - X_2)^4$, 并利用 $E[X_1^k] = E[X_2^k]$:

$$\begin{aligned} E[(X_1 - X_2)^4] &= E[X_1^4 - 4X_1^3X_2 + 6X_1^2X_2^2 - 4X_1X_2^3 + X_2^4] \\ &= 2E[X^4] - 8E[X^3]E[X] + 6(E[X^2])^2 \end{aligned}$$

代入第 (2) 问的结果: $E[(X_1 - X_2)^4] = 12\lambda^2 + 2\lambda$

$$\begin{aligned} Var(\hat{\lambda}_2) &= E[\hat{\lambda}_2^2] - (E[\hat{\lambda}_2])^2 = \frac{12\lambda^2 + 2\lambda}{4} - \lambda^2 = 2\lambda^2 + \frac{\lambda}{2} \\ MSE(\hat{\lambda}_2) &= 2\lambda^2 + \frac{\lambda}{2} \end{aligned}$$

结论: 由于 $\lambda > 0$, $2\lambda^2 + \frac{\lambda}{2} > \frac{\lambda}{2}$, 所以 $MSE(\hat{\lambda}_2) > MSE(\hat{\lambda}_1)$ 因此, 估计量 $\hat{\lambda}_1$ 更优 (方差更小)。

(4) 假设检验:

待检验假设为 $H_0: \lambda = 1 \leftrightarrow H_1: \lambda \neq 1$ 。

根据中心极限定理, 当 n 充分大时, 样本均值 $\bar{X}$ 近似服从正态分布:

$$\bar{X} \sim N\left(\lambda, \frac{\lambda}{n}\right)$$

在 H_0 成立的条件下 (即 $\lambda = 1$), 构造检验统计量:

$$Z = \frac{\bar{X} - 1}{\sqrt{1/n}} = \sqrt{n}(\bar{X} - 1)$$

该统计量在大样本下近似服从标准正态分布: $Z \xrightarrow{d} N(0, 1)$ 。

给定显著性水平 α , 拒绝域为:

$$W = \{|Z| > z_{\alpha/2}\} = \left\{ \left| \sqrt{n}(\bar{X} - 1) \right| > z_{\alpha/2} \right\}$$

其中 $z_{\alpha/2}$ 为标准正态分布的上 $\alpha/2$ 分位数。

• 2026 微观部分解析

五、(1) (5') 请给出风险规避的定义, 并解释为什么通常假设大多数人是风险规避者。(2) (5') 在股票市场中, 经常观察到追涨杀跌的现象 (即价格上涨时需求量增加), 请说明股票是否属于吉芬商品, 并解释导致追涨现象的原因。(3) (5') 请从价格歧视、道德风险、逆向选择、沉没成本、外部性这五个经济学概念中, 指出哪些概念与企业上市 IPO 定价过程密切相关, 并解释原因。

Solution: (1) 风险规避的定义及原因:

定义: 风险规避指在面对不确定性时, 消费者倾向于选择确定性收益而非具有相同期望值的风险收益。若消费者财富为 w , 效用函数为 $u(w)$, 则风险规避者的效用函数满足严格凹性, 即:

$$u''(w) < 0$$

根据 Jensen 不等式, 对于任意风险资产 X , 风险规避者满足:

$$E[u(X)] < u(E[X])$$

即风险收益的期望效用小于期望收益的效用。

原因: 通常假设大多数人是风险规避者, 主要基于边际效用递减规律。即 $u'(w) > 0$ 且 $u''(w) < 0$ 。这意味着随着财富增加, 每增加一单位财富带来的满足感是递减的; 反之, 失去一单位财富造成的痛苦大于获得同等财富带来的快乐。因此, 理性人倾向于规避风险。

(2) 股票市场的追涨杀跌与吉芬商品:

股票不属于吉芬商品。吉芬商品必须同时满足两个条件：

1. 是劣等品；2. 收入效应的绝对值大于替代效应的绝对值。

股票通常被视为正常品，即随着投资者财富增加，对投资资产的需求通常增加。因此它不符合吉芬商品的基本定义。

追涨现象（价格上涨需求增加）的解释：这并非吉芬效应（沿需求曲线滑动），而是需求曲线本身的移动。设股票需求函数为 $D(P, E[P_{t+1}])$ ，其中 P 为当前价格， $E[P_{t+1}]$ 为预期未来价格。涨杀跌的原因在于：1. 预期改变：当前价格 P 上涨被视为利好信号，导致预期价格 $E[P_{t+1}]$ 上升。2. 信息不对称：价格上涨被解读为知情交易者的买入信号。这使得需求曲线向右移动，导致在更高价格下需求量反而增加。

(3) 与 IPO 定价相关的概念：

与企业上市定价过程最为密切相关的概念是逆向选择和道德风险。这两个概念均源于信息不对称理论。

1. 逆向选择

(i) 定义与发生阶段：发生于交易发生之前，指在 IPO 市场上，发行人（企业内部人员）拥有关于企业真实质量的私人信息，而外部投资者无法确切知道该信息。

(ii) 原因分析：

在以下的假设下：市场上有两种类型的企业：好企业和差企业；真实价值： V_G （好）和 V_B （差），且 $V_G > V_B$ ；市场占比：好企业比例为 q ，差企业比例为 $1 - q$ ；信息结构：发行人知道自己的真实价值，投资者只知道分布 q ；若投资者无法区分企业类型，他们愿意支付的最高价格是平均期望价值：

$$\bar{P} = qV_G + (1 - q)V_B$$

对于好企业而言，其真实价值 $V_G > \bar{P}$ （因为 $\bar{P}$ 是加权平均，必然小于最大值）。如果发行价格被限制在 $\bar{P}$ ，好企业会认为自己的股权被贱卖，从而选择退出市场或推迟发行，最终的结果是市场上只剩下差企业。投资者意识到这一点后，会修正预期 $q \rightarrow 0$ ，价格进一步下跌至 V_B 。

(iii) 对 IPO 定价的影响：为了打破上述僵局，让好企业也能成功发行，市场演化出了 IPO 抑价机制。好企业通过故意压低发行价，向市场传递“我有信心在未来通过后续融资或长期增长收回成本”的信号。这解释了为什么 IPO 首日通常会有显著的正收益率，比如最近的沐曦、摩尔线程。

(iv) 处理方法：信号发送：如部分股权保留，原始股东承诺持有大量股份，表明对公司信心。第三方认证：引入高声誉的投资银行和审计师，利用其声誉资本为企业质量背书。

2. 道德风险

(i) 定义与发生阶段：发生于交易发生之后。指在双方签订合约（投资者买入股票）后，由于无法完全监督，代理人（管理层）可能采取损害委托人（股东）利益的行为。

(ii) 委托-代理问题的定量描述：假设企业价值 V 取决于管理者的努力水平 e 和外部随机因素。企业价值： $V(e)$ ，且 $V'(e) > 0$ 。管理者成本： $C(e)$ ，且 $C'(e) > 0$ 。全社会最优：最大化 $V(e) - C(e)$ 。现实情况：由于 IPO 导致所有权和经营权分离，管理者只拥有公司一小部分股份 $\alpha (0 < \alpha < 1)$ 。管理者决策：最大化 $\alpha V(e) - C(e)$ 。

由于 $\alpha < 1$ ，管理者边际收益 $\alpha V'(e)$ 小于社会边际收益 $V'(e)$ ，导致最优努力水平 e^* 下降。这种由代理问题导致的价值损失称为代理成本。

(iii) 对 IPO 定价的影响：理性的投资者在 IPO 定价时具有前瞻性。他们会预见到上市后管理层监控力度的下降和潜在的道德风险，因此在给股票估值时，会直接扣除预期的代理成本。

(iv) 处理方法：激励相容约束：授予管理层股票期权，使其利益与股价绑定。公司治理：设立独立董事会，引入定期财务披露制度。

3. 为什么其他三个概念不涉及？

(i) 价格歧视：虽然在 IPO 的询价过程中，投行会根据机构投资者的报价分配额度，但这更多是一种分配机制。最终的 IPO 发行价格通常对所有一级市场认购者是统一的，并不符合向不同消费者索取不同价格的典型价格歧视定义。相比于信息不对称对定价水平的决定性影响，价格歧视属于次要的技术环节。

(ii) 沉没成本：IPO 定价是基于对未来现金流的折现。企业在上市前投入的研发、设备等属于历史沉没成本，理性的定价只看未来能赚多少钱，而不看过去花了多少钱。因此沉没成本不应进入定价决策。

(iii) 外部性：外部性指经济活动对第三方造成的影响（如污染是负外部性）。虽然某些企业的上市可能产生社会影响，但在 IPO 定价过程中，核心博弈发生在买卖双方之间。除非政府通过税收或补贴将外部性内部化，否则私有市场的 IPO 定价主要关注私人回报而非社会回报，因此外部性和 IPO 定价的关系比较小。

六、已知企业的边际成本 $MC = 10$ 。国内市场消费者购买 x 单位商品获得的效用为 $26x - 2x^2$ ，国外市场消费者购买 x 单位商品获得的效用为 $14x - x^2$ 。

(1) (10') 若企业能够区分国内和国外市场的消费者，求企业的总销量。

(2) (10') 若企业无法分辨不同市场的消费者，求企业的总销量。

Solution: 首先根据消费者效用最大化原则 $P = MU$ 计算两个市场的反需求函数。

国内市场：

$$P_1 = MU_1 = \frac{d(26x_1 - 2x_1^2)}{dx_1} = 26 - 4x_1$$

对应的边际收益为：

$$MR_1 = 26 - 8x_1$$

国外市场：

$$P_2 = MU_2 = \frac{d(14x_2 - x_2^2)}{dx_2} = 14 - 2x_2$$

对应的边际收益为：

$$MR_2 = 14 - 4x_2$$

(1). 三级价格歧视下的总销量

当企业能够区分市场时，会在两个市场分别根据 $MR = MC$ 确定最优销量。在边际成本 $MC = 10$ 的情况下：

国内市场均衡：

$$26 - 8x_1 = 10 \Rightarrow 8x_1 = 16 \Rightarrow x_1 = 2$$

国外市场均衡：

$$14 - 4x_2 = 10 \Rightarrow 4x_2 = 4 \Rightarrow x_2 = 1$$

总销量为：

$$Q = x_1 + x_2 = 3$$

(2). 统一定价下的总销量

当企业无法区分市场时，必须制定统一价格 P 。企业面临两种策略选择：仅在国内市场销售（定高价）或同时在两个市场销售（定低价）。

国外市场的最高保留价格为 $P = 14$ （当 $x_2 = 0$ 时）。

情形一：定价 $P > 14$ （仅面向国内市场）此时需求仅来自国内市场，反需求函数为 $P = 26 - 4Q$ 。由 $MR = MC$ 决定产量：

$$26 - 8Q = 10 \Rightarrow Q = 2$$

此时市场价格：

$$P = 18$$

由于 $18 > 14$ ，国外市场需求确实为 0。此时企业的利润为：

$$\pi_1 = (P - MC) \times Q = (18 - 10) \times 2 = 16$$

情形二：定价 $P \leq 14$ （面向两个市场）此时总需求为两个市场需求之和。国内市场需求为：

$$x_1 = \frac{26 - P}{4} = 6.5 - 0.25P$$

国外市场需求为：

$$x_2 = \frac{14 - P}{2} = 7 - 0.5P$$

总需求函数：

$$Q = x_1 + x_2 = 13.5 - 0.75P$$

对应的反需求函数：

$$P = 18 - \frac{4}{3}Q$$

总边际收益：

$$MR_{total} = 18 - \frac{8}{3}Q$$

由 $MR_{total} = MC$ 决定产量：

$$18 - \frac{8}{3}Q = 10 \Rightarrow \frac{8}{3}Q = 8 \Rightarrow Q = 3$$

此时市场价格：

$$P = 18 - 3 \times \frac{4}{3} = 14$$

企业的利润为：

$$\pi_2 = (P - MC) \times Q = (14 - 10) \times 3 = 12$$

比较两种情形下的利润：

$$\pi_1 = 16 > \pi_2 = 12$$

企业为追求利润最大化，会选择情形一的策略，即 $P = 18$ ，仅在国内市场销售。

因此，统一定价下的总销量为：

$$Q = 2$$

七、已知某企业的产出函数为 $y = 16k - 2k^2$ ，其中 k 为生产要素投入量。该企业仅考虑一期的生产问题，在期初决定投入量 k ，假设获取要素的自身成本忽略不计（即为 0）。生产完毕后，政府对生产要素进行征税，税率为 τ 。假设政府的效用函数为 $U = \tau k - 0.25\tau^2$ 。

(1) (5') 求政府最优税率 τ 和最优生产要素使用量 k 。

(2) (5') 若政府作为先行者并能够信守承诺，求均衡时的 k 和 τ 。

(3) (5') 对比上述两种情况下税率和政府效用的差异，说明这体现了什么经济学原理？

Solution: (1) 求解政府最优税率 τ 和最优生产要素 k ：

此情形为政府无法进行承诺，即企业先决定产量 k ，政府在观测到 k 后再决定税率 τ 。求解采用逆向归纳法。

第二阶段（政府决策）：此时生产要素 k 已为既定数值。政府选择 τ 最大化自身效用：

$$\max_{\tau} U = \tau k - 0.25\tau^2$$

对 τ 求一阶导数并令其为 0：

$$\frac{dU}{d\tau} = k - 0.5\tau = 0 \implies \tau = 2k$$

这是政府对企业产量的反应函数。

第一阶段（企业决策）：企业在决策时会预期到政府的反应 $\tau = 2k$ 。企业将此代入利润函数进行最大化：利润函数为 $\pi = (16k - 2k^2) - \tau k$ 。代入 $\tau = 2k$ ：

$$\pi = 16k - 2k^2 - (2k)k = 16k - 4k^2$$

对 k 求一阶导数并令其为 0：

$$\frac{d\pi}{dk} = 16 - 8k = 0 \implies k = 2$$

代回政府反应函数求 τ ：

$$\tau = 4$$

此时政府的效用为：

$$U = 4 \times 2 - 0.25 \times 4^2 = 4$$

因此，第一问的均衡结果为：

$$\tau = 4, \quad k = 2$$

(2) 求解承诺情形下的均衡 k 和 τ ：

此情形为政府作为先行者并信守承诺，即政府先确定税率 τ ，企业再根据 τ 决定产量 k 。

第二阶段（企业反应函数）：给定税率 τ ，企业最大化利润：

$$\max_k \pi = 16k - 2k^2 - \tau k$$

对 k 求一阶导数并令其为 0:

$$16 - 4k - \tau = 0 \implies k = 4 - 0.25\tau$$

第一阶段 (政府决策): 政府将企业的反应函数 $k = 4 - 0.25\tau$ 代入自身效用函数进行最大化:

$$\max_{\tau} U = \tau(4 - 0.25\tau) - 0.25\tau^2 = 4\tau - 0.25\tau^2 - 0.25\tau^2 = 4\tau - 0.5\tau^2$$

对 τ 求一阶导数并令其为 0:

$$\frac{dU}{d\tau} = 4 - \tau = 0 \implies \tau = 4$$

代回企业反应函数求 k :

$$k = 3$$

此时政府的效用为:

$$U = 4 \times 3 - 0.25 \times 4^2 = 8$$

因此, 承诺情形下的均衡结果为:

$$\tau = 4, \quad k = 3$$

(3) 差异解释和经济学原理分析:

结果对比: 不先行承诺情况: $\tau = 4, \quad k = 2, \quad U = 4$ 先行承诺情况: $\tau = 4, \quad k = 3, \quad U = 8$

差异分析: 虽然两种情况下最终的均衡税率数值相同都是 4, 但产出水平和政府效用却不同。在无法承诺的情况下, 企业预期到一旦自己增加投入 k , 政府为了最大化效用必然会提高税率 $\tau = 2k$, 这种高投入会带来致高税收的预期迫使企业减少了投资, 导致社会处于低产出、低福利的状态。在承诺情况下, 政府事先承诺了税率水平, 使税率不再依赖产出, 使得企业增加投资所带来的效用增加量变大, 从而提高了政府的效用。

体现的经济学原理: 这动态不一致性问题的体现。即便政府事后看来做出了最优选择, 但这种缺乏事先承诺的决策模式会导致私人部门做出防御性的选择。相反, 如果政府能够建立可信的承诺机制, 往往能带来帕累托改进, 实现比相机抉择更优的社会福利结果。

八、(1) (5') 尽管单场马拉松比赛的综合收益往往是亏损的, 为何各地政府仍热衷于举办马拉松比赛? (2) (5') 国家有关部门开始加强监管并给马拉松比赛降温, 请解释进行监管的原因。

Solution: (1) 政府作为公共利益的代表, 其决策依据并非单一项目的财务利润, 而是社会总福利的最大化和政府官员自己的效用。

从政府官员的角度来说, 政府官员作为理性的经济人, 其决策目标是最大化自身的政治效用 (如政绩曝光度、晋升机会), 而非单纯的社会总福利。举办马拉松具有极高的媒体曝光度, 能迅速转化为官员的政绩工程。尽管赛事对城市整体可能造成综合亏损, 但这些成本由广大纳税人分担, 而举办赛事的政治收益却集中在决策者手中。这种激励不相容导致了政府的过度投资行为。

从马拉松活动自身来说, 首先, 马拉松赛事具有显著的正外部性。虽然赛事本身的门票和赞助收入 (私人收益) 可能小于举办成本 (私人成本), 但赛事会产生巨大的溢出效应。数万名参赛者及随行人员会显著增加举办地的餐饮、住宿、交通和旅游消费, 这种乘数效应带动了相关产业链的发展, 增加了地方税收和就业。当把这些外部收益纳入考量时, 举办赛事的边际社会收益往往大于边际社会成本, 因此对政府而言是有效率的。

其次, 这是一种城市品牌建设的信号传递机制。在信息不对称的市场上, 投资者和人才往往不了解一个城市的具体营商环境。举办马拉松可以作为一种高成本的信号, 向外界展示该城市具备优良的基础设施、高效的

行政组织能力和良好的公共治安环境。这种信号有助于降低交易成本，吸引外部投资和高素质人力资本，促进城市长期发展。

最后，马拉松推广具有公共品的属性。政府通过财政补贴举办赛事，旨在提供全民健身的公共服务。这有助于提升居民的健康水平和身体素质，从长期来看，能够提高全社会的人力资本积累，并减少公共医疗卫生支出的负担。

(2) 国家加强监管的根本原因在于纠正市场失灵，防止资源配置效率低下。

首先，马拉松热潮带来了一定的负外部性。频繁的赛事往往伴随着长时间的封路、交通管制和噪音污染，这对非参赛市民的正常出行、工作和生活造成了干扰。如果完全由地方政府或商业机构自行决策，他们往往只考虑举办赛事的直接收益，而忽视了强加给社会的拥堵成本和时间成本。此时，赛事的供给量超过了社会最优水平，需要中央政府通过监管来内部化这些外部成本。

其次，为了解决信息不对称引致的道德风险问题。在马拉松市场中，参赛者（消费者）很难在赛前观测到主办方在医疗救援、补给保障和极端天气应对等方面的真实投入水平。部分追求短期利益的主办方可能会为了压缩成本而牺牲安全保障。因此，需要政府介入制定强制性的安全标准和准入制度。

最后，为了纠正非理性的过度投资和资源错配。部分地方政府在政绩驱动下，忽视本地的经济发展水平和实际承载能力，利用财政资金过度补贴马拉松赛事。在此情境下，国家有限的财政资金、行政资源以及社会公众的注意力可以被视为一种开放存取的公共资源（公地）。各个地方政府则是这片公地上的理性牧羊人。出于自身政绩最大化的私利驱动，每个地方政府作为独立的决策主体，都有强烈的激励去过度消耗这些公共资源来举办马拉松赛事。这是因为对单一地方政府而言，举办赛事所带来的政绩提升和城市曝光是其独享的边际收益，而过度投入造成的财政浪费和资源错配成本（如挤占教育医疗资金带来的负效用）则由全社会共同分担，即成本外部化。因此，每个地方政府都在不断增加对赛事的投入，试图在公共资源池中分得更多份额。当所有地方政府都遵循这一由于产权界定不清导致的个体理性逻辑时，最终导致了集体的非理性结果。这表现为公共资源被过度捕捞和滥用，稀缺的财政资金无法流向边际社会福利更高的民生领域，导致整个社会的公共资源系统效率降低和总体福利的无谓损失。

九、假设小明的效用函数为 $U(W) = 60W - W^2$ ，其中 W 代表财富水平，定义域为 $0 \leq W \leq 30$ 。小明的初始财富为 $W_0 = 20$ 。现有一张彩票，其收益分布为：以 50% 的概率获得 10 元，以 50% 的概率获得 0 元。

(1) (5') 如果小明已持有该彩票，求他愿意出售该彩票的最低价格。

(2) (5') 如果小明未持有该彩票，求他愿意购买该彩票的最高价格。

(3) (5') 随着初始财富 W_0 的下降，第 (1) 问中的出售价格会发生什么变化？请结合微观经济学原理进行解释。

Solution:

(1) 求解持有彩票时的愿意出售价格:

设愿意出售彩票的最低价格为 P_s 。若不出售，持有彩票，其财富分布为：以 50% 的概率财富为 $20+10=30$ ；以 50% 的概率财富为 $20+0=20$ 。此时的期望效用 $E[U]$ 为：

$$E[U] = 0.5 \times U(30) + 0.5 \times U(20)$$

计算各状态的效用：

$$U(30) = 60(30) - 30^2 = 1800 - 900 = 900$$

$$U(20) = 60(20) - 20^2 = 1200 - 400 = 800$$

$$E[U] = 0.5 \times 900 + 0.5 \times 800 = 850$$

若以价格 P_s 出售, 小明获得确定性财富 $20 + P_s$, 出售后的确定性效用应等于持有彩票的期望效用:

$$U(20 + P_s) = 850$$

设 $W_s = 20 + P_s$, 代入效用函数:

$$60W_s - W_s^2 = 850$$

由于定义域 $W \leq 30$, 得:

$$W_s = 30 - 5\sqrt{2}$$

则出售价格 P_s 为:

$$P_s = W_s - 20 = 10 - 5\sqrt{2}$$

即小明愿意以约 $10 - 5\sqrt{2}$ 元的价格卖出该彩票。

(2) 求解未持有彩票时的愿意购买价格:

设愿意购买该彩票的最高价格为 P_b 。若不购买, 财富保持为 20, 效用为:

$$U(20) = 800$$

若以价格 P_b 购买, 其财富状况变为: 以 50% 的概率获得 $20 - P_b + 10 = 30 - P_b$; 以 50% 的概率获得 $20 - P_b + 0 = 20 - P_b$ 。根据出售后的确定性效用等于持有彩票的期望效用:

$$U(20) = 0.5 \times U(30 - P_b) + 0.5 \times U(20 - P_b)$$

代入效用函数:

$$800 = 0.5[60(30 - P_b) - (30 - P_b)^2] + 0.5[60(20 - P_b) - (20 - P_b)^2]$$

由于价格 $P_b > 0$, 解得:

$$P_b = 5\sqrt{3} - 5$$

即小明愿意以约 $5\sqrt{3} - 5$ 元的价格购买该彩票。

(3) 初始财富下降对出售价格的影响分析:

我们先用比较容易理解的定量分析方式做铺垫, 然后再引入使用经济学直觉的判断。我们可以将愿意出售的价格 P_s 表示为初始财富 W_0 的函数, 通过求导来判断其单调性。

出售彩票后的确定性效用等于持有彩票的期望效用:

$$U(W_0 + P_s) = 0.5U(W_0 + 10) + 0.5U(W_0)$$

代入效用函数 $U(W) = 60W - W^2$:

$$60(W_0 + P_s) - (W_0 + P_s)^2 = 0.5[60(W_0 + 10) - (W_0 + 10)^2] + 0.5[60W_0 - W_0^2]$$

化简方程右边:

$$RHS = 30(W_0 + 10) - 0.5(W_0^2 + 20W_0 + 100) + 30W_0 - 0.5W_0^2$$

$$= 60W_0 + 300 - 0.5W_0^2 - 10W_0 - 50 - 0.5W_0^2$$

$$= -W_0^2 + 50W_0 + 250$$

化简方程左边：

$$LHS = 60W_0 + 60P_s - (W_0^2 + 2W_0P_s + P_s^2)$$

$$= -W_0^2 + (60 - 2P_s)W_0 + 60P_s - P_s^2$$

令 $LHS = RHS$ ，消去 W_0^2 并整理关于 P_s 的方程：

$$P_s^2 + (2W_0 - 60)P_s + (250 - 10W_0) = 0$$

解得：

$$P_s = \frac{-(2W_0 - 60) \pm \sqrt{(2W_0 - 60)^2 - 4(250 - 10W_0)}}{2}$$

$$P_s = \frac{60 - 2W_0 \pm \sqrt{4(W_0 - 30)^2 - 1000 + 40W_0}}{2}$$

化简根号内各项：

$$\Delta = 4(W_0^2 - 60W_0 + 900) - 1000 + 40W_0 = 4W_0^2 - 200W_0 + 2600 = 4(W_0^2 - 50W_0 + 650)$$

因此：

$$P_s(W_0) = 30 - W_0 \pm \sqrt{W_0^2 - 50W_0 + 650}$$

由于效用函数是凹函数，出售价格必定小于期望收益（5元），且 $30 - W_0$ 在 $W_0 = 20$ 时为 10，若取加号则价格过高，故取减号：

$$P_s(W_0) = 30 - W_0 - \sqrt{W_0^2 - 50W_0 + 650}$$

对 W_0 求导：

$$\frac{dP_s}{dW_0} = -1 + \frac{25 - W_0}{\sqrt{W_0^2 - 50W_0 + 650}}$$

判断导数符号：我们要比较 $\frac{25 - W_0}{\sqrt{W_0^2 - 50W_0 + 650}}$ 与 1 的大小，即比较 $(25 - W_0)^2$ 与 $W_0^2 - 50W_0 + 650$ 的大小：前一项为 $625 - 50W_0 + W_0^2$ ，后一项为 $650 - 50W_0 + W_0^2$ ，显然 $625 < 650$ ，因此分数的绝对值恒小于 1。所以 $\frac{dP_s}{dW_0} < 0$ 恒成立。

结论：导数为负，说明随着初始财富 W_0 的下降，愿意出售的价格 P_s 会上升。

经济学原理解释：

首先介绍两个概念：风险溢价和绝对风险规避系数。

1. 风险溢价 风险溢价是指风险规避者为了将不确定的风险收益转化为确定的安全收益，所愿意放弃的那部分期望收益。它是期望价值与愿意出售的价格之间的差额：

$$\text{Risk Premium} = E[\text{彩票}] - P_s$$

风险规避程度越高，个体为了获得确定性而愿意放弃的期望收益就越多，即风险溢价越大。

2. 绝对风险规避系数为了精确衡量个体在不同财富水平下对风险的厌恶程度，经济学家阿罗和普拉特提出了绝对风险规避系数。其定义为效用函数二阶导数与一阶导数比值的相反数：

$$R_A(W) = -\frac{U''(W)}{U'(W)}$$

该系数越大，表示个体对风险越厌恶；系数越小，表示越接近风险中性。

基于上述概念，这一结果可以通过绝对风险规避系数的变化来解释：

对于本题中的效用函数 $U(W) = 60W - W^2$ ，代入计算可得其绝对风险规避系数为：

$$R_A(W) = \frac{1}{30 - W}$$

对该系数关于财富 W 求导：

$$R'_A(W) = \frac{1}{(30 - W)^2} > 0$$

由于导数大于 0，说明该个体具有财富增加型绝对风险规避的特征。这意味着随着财富的增加，他反而变得更厌恶风险；反之，当初始财富 W_0 下降时，个体的绝对风险规避系数变小，意味着他的风险规避程度降低，变得更接近风险中性。

因为风险规避程度降低，他所要求的风险补偿（风险溢价）也会随之减少。根据公式：

$$P_s = E[\text{彩票}] - \text{Risk Premium}$$

在彩票期望收益 $E[\text{彩票}]$ 保持不变的情况下，风险溢价减少，必然导致愿意出售的价格 P_s 上升并趋近于期望收益。

复旦大学-432 统计学

复旦大学-432 统计学-2016 年

一、(15 分) 三个人独立地同时破译密码, 且三人能破译密码的概率分别为 $1/5$, $1/3$ 和 $1/4$, 求此密码能够被破译的概率.

Solution: 根据德摩根公式,

$$\begin{aligned} P\{\text{至少有一人破译}\} &= 1 - P\{\text{没有一个人破译}\} \\ &= 1 - \frac{4}{5} \times \frac{2}{3} \times \frac{3}{4} = 0.6. \end{aligned}$$

二、(15 分) 从 $(0,1)$ 中随机地取两个数, 求其积不小于 $3/16$ 且其和不大于 1 的概率.

Solution: 设取到的两个数是 $X, Y \sim U(0,1)$, 其积不小于 $\frac{3}{16}$ 意味着 $XY \geq \frac{3}{16}$, 其和不大于 1 意味着 $X+Y \leq 1$. 令 $D = \{(x,y) : xy \geq \frac{3}{16}, x+y \leq 1\} \cap (0,1)^2$, 该概率为

$$\int_D f(x,y) dx dy = \frac{1}{8} - \int_{\frac{1}{4}}^{\frac{3}{4}} \int_{\frac{3}{16x}}^{\frac{3}{16x}} dy dx = \frac{1}{8} - \int_{\frac{1}{4}}^{\frac{3}{4}} \left(\frac{3}{16x} - \frac{1}{4} \right) dx = \frac{1}{4} - \frac{3 \ln 3}{16}$$

三、(15 分) $X \sim N(0,1)$, 求 $Y = X^2$ 的密度函数.

Solution: 当 $y \geq 0$ 时, $F(y) = P\{Y \leq y\} = P\{X^2 \leq y\} = P\{-\sqrt{y} \leq X \leq \sqrt{y}\} = 2\Phi(\sqrt{y}) - 1$, 故

$$f_Y(y) = F'(y) = 2\varphi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-\frac{y}{2}}, y \geq 0$$

四、(30 分) 记 $(0,1), (1,0), (0,0)$ 三点围成的区域为 D , (X,Y) 服从 D 上的均匀分布, 求

(1)(15 分) $E(X+Y), \text{Var}(X+Y)$;

(2)(15 分) X, Y 的相关系数.

Solution: (1) $E(X+Y) = 2 \int_0^1 \int_0^{1-y} (x+y) dx dy = \int_0^1 (1-y^2) dy = 1 - \frac{1}{3} = \frac{2}{3}$,

$$E(X+Y)^2 = 2 \int_0^1 \int_0^{1-y} (x+y)^2 dx dy = \frac{2}{3} \int_0^1 (1-y^3) dy = \frac{2}{3} \left(1 - \frac{1}{4} \right) = \frac{1}{2},$$

因此

$$\text{Var}(X+Y) = \frac{1}{2} - \frac{4}{9} = \frac{1}{18}.$$

(2) $EXY = 2 \int_0^1 \int_0^{1-y} xy dx dy = \int_0^1 (y^3 - 2y^2 + y) dy = \frac{1}{4} - \frac{2}{3} + \frac{1}{2} = \frac{1}{12}$,

$$EX = EY = 2 \int_0^1 \int_0^{1-y} x dx dy = \int_0^1 (y^2 - 2y + 1) dy = \frac{1}{3} - 1 + 1 = \frac{1}{3},$$

故

$$\text{Cov}(X, Y) = \frac{1}{12} - \frac{1}{9} = -\frac{1}{36}.$$

$$EX^2 = 2 \int_0^1 \int_0^{1-y} x^2 dx dy = \frac{2}{3} \int_0^1 (1-y)^3 dy = \frac{1}{6},$$

故

$$\text{Var}(X) = \text{Var}(Y) = \frac{1}{6} - \frac{1}{9} = \frac{1}{18},$$

进而有 $\rho_{XY} = -\frac{1}{2}$.

五、(15 分) 对于两个只有两个取值的随机变量 X, Y , 试证明 X, Y 独立当且仅当 X, Y 不相关.

Solution:

	$X = x_1$	$X = x_2$	
$Y = y_1$	p_{11}	p_{21}	$1 - q$
$Y = y_2$	p_{12}	p_{22}	q
	$1 - p$	p	

独立一定不相关, 只需证明充分性. 不妨仅讨论 $X' = \frac{X-x_1}{x_2-x_1}$, $Y' = \frac{Y-y_1}{y_2-y_1}$, X, Y 不相关与 X', Y' 不相关是等价的. 当 X', Y' 不相关时, 说明

$$p_{22} = E(X'Y') = E(X')E(Y') = pq,$$

进一步有

$$p_{21} = p - p_{22} = p - pq = p(1 - q),$$

$$p_{12} = q - p_{22} = q - pq = q(1 - p),$$

$$p_{11} = 1 - p - p_{12} = (1 - p) - q(1 - p) = (1 - p)(1 - q).$$

因此 X', Y' 独立, 故 X, Y 也独立.

[Remark]: 有另一证法: 设 $P(X = a) = p_a, P(X = b) = p_b, P(Y = c) = p_c, P(X = d) = p_d$, 联合分布列是 $p_{ac}, p_{ad}, p_{bc}, p_{bd}$. 因为 X, Y 不相关, 有 $E(X)E(Y) = E(XY)$, 得

$$acp_{ac} + adp_{ad} + bcp_{bc} + bdp_{bd} = acp_{ac} + adp_{ad} + bcp_{bc} + bdp_{bd}.$$

由于 “ X 和 Y 不相关” $\Leftrightarrow$ “ $X' = k_1X + m_1$ 和 $Y' = k_2Y + m_2$ 不相关”, 且对任意的线性变换都成立. 考虑变换后 $P(X' = a') = p_a, P(X' = b') = p_b, Y'$ 类似取值为 c', d' , 同理有

$$a'c'p_{ac} + a'd'p_{ad} + b'c'p_{bc} + b'd'p_{bd} = a'c'p_{ac} + a'd'p_{ad} + b'c'p_{bc} + b'd'p_{bd},$$

任取不同的线性变换, 上式即对任意 a', b', c', d' 成立, 因此对应系数需相同, 故有

$$p_ap_c = p_{ac}, \quad p_ap_d = p_{ad}, \quad p_bp_c = p_{bc}, \quad p_bp_d = p_{bd}.$$

第一个答案中用到了对某一个特定的线性变换成立 ($a' = c' = 0, b' = d' = 1$). 第二个答案则运用到了对任意的线性变换成立. 这实际说明了两点分布的独立性是由其对应取值的概率决定, 和它的两个值取值本身是几并没有关系.

还要注意一点, 只有两点对两点才可以由线性变换唯一决定, 而三点分布是做不到的.

六、(15 分) 设有来自总体 $X \sim N(\mu, \sigma^2)$ 的 $2n$ 个随机样本, 试求期望

$$E\left(\sum_{i=1}^n (X_i + X_{n+i} - 2\bar{X})^2\right).$$

Solution: 记 $Y_i = X_i + X_{n+i}, i = 1, 2, \dots, n$, 这样 $Y_1, Y_2, \dots, Y_n$ 就是来自于总体 $N(2\mu, 2\sigma^2)$ 的 n 个随机样本, $\bar{Y} = 2\bar{X}$, 根据样本方差的定义和性质, 我们有

$$\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i + X_{n+i} - 2\bar{X})^2 = \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \bar{Y})^2 \sim \chi^2(n-1)$$

因此

$$E \sum_{i=1}^n (X_i + X_{n+i} - 2\bar{X})^2 = 2(n-1)\sigma^2.$$

七、(15 分) X_1, X_2, X_3 , 是 i.i.d. 的服从 $U(0, 1)$ 的随机变量, 求次序统计量 $X_{(1)}$ 的分布函数与期望.

Solution: 设 $Y = X_{(1)}$, 当 $y \in (0, 1)$ 时,

$$P\{Y \geq y\} = P(\min\{X_1, X_2, X_3\} \geq y) = P^3\{X_1 \geq y\} = (1-y)^3$$

所以分布函数是

$$F(y) = \begin{cases} 0, & y < 0, \\ 1 - (1-y)^3, & 0 \leq y < 1, \\ 1, & y \geq 1. \end{cases}$$

这恰好是 Beta(1, 3) 的分布函数.

$$EY = \int_0^1 y dF(y) = 1 \cdot F(1) - \int_0^1 [1 - (1-y)^3] dy = \frac{1}{4}$$

八、(30 分) 有来自 $X \sim f(x) = \begin{cases} \theta, & 0 \leq x < 1 \\ 1 - \theta, & 1 \leq x < 2, \\ 0, & \text{otherwise} \end{cases}$ 的 n 个简单随机样本, 求

(1)(15 分) θ 的矩估计;

(2)(15 分) θ 的最大似然估计, 已知 $m = \sum_{i=1}^n I[X_i < 1]$.

Solution: (1) $EX = \int_0^1 x\theta dx + \int_1^2 x(1-\theta)dx = \frac{3}{2} - \theta$, 因此

$$\hat{\theta}_1 = \frac{3}{2} - \bar{X}.$$

(2) 似然函数 $L(x_1, \dots, x_n; \theta) = \theta^m (1-\theta)^{n-m}$, $\ln L = m \ln \theta + (n-m) \ln(1-\theta)$, 对 θ 求偏导, 得

$$\frac{\partial \ln L}{\partial \theta} = \frac{m}{\theta} - \frac{n-m}{1-\theta} \stackrel{\text{let}}{=} 0,$$

解得 $\hat{\theta}_2 = \frac{m}{n}$.

复旦大学-432 统计学-2017 年

一、(30 分) 名词解释

(1)(5 分) 样本均值、样本方差;

(2)(5 分) 统计量;

(3)(5 分) 次序统计量;

(4)(5 分) 中位数、样本中位数;

(5)(5 分) 经验分布函数;

(6)(5 分) 无偏估计.

Solution: (1) 样本均值是在某个特定总体中抽取 n 个独立随机样本, 计算得到的平均值, 记作 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 如果总体的期望存在, 则 $\bar{X}$ 是总体期望的强相合估计. 样本方差则是利用该 n 个独立随机样本计算的修正平均离差平方, 修正的意思是取平均时除以的是其自由度 $n-1$ 而非数据个数 n , 样本方差一般记作 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 如果总体的方差存在, 则 S^2 也是总体方差的强相合估计.

(2) 统计量是指其表达式中只含样本而不含未知参数的函数, 本质上是随机变量(向量), 当然在随机样本的取值给定时, 统计量也可以被看作一个已知的常数(常向量), 这时统计量就是“统计量的观测值”的简称.

(3) 次序统计量是指将随机样本 $X_1, X_2, \dots, X_n$ 重新由小到大排列成的统计量, 一般由小到大记作 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$.

(4) 如果 $x_{0.5}$ 满足 $P\{X \leq x_{0.5}\} = 0.5$ 则称 $x_{0.5}$ 为中位数. 而样本中位数 $m_{0.5}$ 则是指取到的随机样本中位于中间的数, 若用次序统计量表示就是

$$m_{0.5} = \begin{cases} x_{(\frac{n+1}{2})}, & n = \text{奇数}, \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & n = \text{偶数}. \end{cases}$$

(5) 经验分布函数是根据样本信息来对总体分布函数作出的估计, 记作

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I[X_i \leq x],$$

根据 Glivenko-Cantelli 定理, 经验分布函数是总体分布函数的一致强相合估计, 即

$$\sup_x |F_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

(6) 如果 $\hat{g}(X_1, \dots, X_n)$ 满足 $E\hat{g}(X_1, \dots, X_n) = g(\theta)$, 则称 $\hat{g}$ 是 g 的无偏估计, 无偏性是一个很重要的优良标准, 但并不是必须的, 如当 EX 存在, 随机样本 X_1 总是总体期望的无偏估计, 但你很难说它是一个很好的估计.

二、(20 分) $X_1, X_2, \text{i.i.d} \sim \text{Exp}(1)$, 求

(1)(10 分) $\frac{X_1}{X_1+X_2}$ 的密度函数;

(2)(10 分) $X_{(2)} - X_{(1)}$ 的密度函数.

Solution: (1) 根据题意, $2X_1 \sim \chi^2(2)$, $2X_2 \sim \chi^2(2)$ 且相互独立, 故 $\frac{X_1}{X_1+X_2} = \frac{2X_1}{2X_1+2X_2} \sim \text{Beta}(1, 1)$, 密度函数为 $f(x) = 1, 0 < x < 1$, 即 $U(0, 1)$.

(2) 很容易发现 $X_{(2)} - X_{(1)} = |X_1 - X_2|$, 根据卷积公式有 $Y = X_1 - X_2$ 的密度函数是

$$f(y) = \begin{cases} \frac{1}{2}e^{-y}, & y \geq 0 \\ \frac{1}{2}e^y, & y < 0 \end{cases}$$

故 $|Y|$ 的密度函数是 $f(x) = e^{-x}, x \geq 0$.

[注] 若 $X \sim \chi^2(m), Y \sim \chi^2(n)$, 且相互独立, 则

$$\frac{X}{X+Y} \sim \text{Beta}\left(\frac{m}{2}, \frac{n}{2}\right).$$

分析如下: 记 $U = \frac{X}{X+Y}, V = X+Y$, 反解后有 $x = uv, y = v - uv$,

$$|J| = \left| \frac{\partial(x, y)}{\partial(u, v)} \right| = \begin{vmatrix} v & u \\ -v & 1-u \end{vmatrix} = v,$$

因此 $f_{U,V}(u, v) = v f_{X,Y}(uv, (1-u)v) = \frac{u^{\frac{m}{2}-1}(1-u)^{\frac{n}{2}-1}}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} \cdot \left(\frac{1}{2}\right)^{\frac{m+n}{2}} v^{\frac{m+n}{2}-1} e^{-\frac{v}{2}}$, 故

$$f_U(u) = \int_0^{+\infty} f_{U,V}(u, v) dv = \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} u^{\frac{m}{2}-1} (1-u)^{\frac{n}{2}-1} \sim \text{Beta}\left(\frac{m}{2}, \frac{n}{2}\right).$$

三、(20 分) X_1, X_2 i.i.d $\sim N(0, 1)$, 求 $\frac{X_1}{X_2}$ 的概率分布.

Solution: 记

$$\begin{cases} U = X_1^2 + X_2^2, \\ V = \frac{X_1}{X_2}, \end{cases} \Rightarrow \begin{cases} u = x_1^2 + x_2^2, \\ v = \frac{x_1}{x_2}, \end{cases}$$

该题转化为茆书第三章原题. 解这个变量变换的反函数, 有 2 支, 它们是

$$\begin{cases} x_1 = v \sqrt{\frac{u}{1+v^2}}, \\ x_2 = \sqrt{\frac{u}{1+v^2}}, \end{cases} \quad \text{或} \quad \begin{cases} x_1 = -v \sqrt{\frac{u}{1+v^2}}, \\ x_2 = -\sqrt{\frac{u}{1+v^2}}, \end{cases}$$

对应的雅可比矩阵是 (x_1, x_2) 对 (u, v) 的偏导矩阵, 这不好求, 我们考虑

$$J^{-1} = \frac{\partial(u, v)}{\partial(x_1, x_2)} = \begin{pmatrix} 2x_1 & 2x_2 \\ \frac{1}{x_2} & -\frac{x_1}{x_2^2} \end{pmatrix}, \Rightarrow \left| \det(J^{-1}) \right| = 2(v^2 + 1),$$

因此有

$$f_{U,V}(u, v) = |J| f_{X,Y}\left(v \sqrt{\frac{u}{1+v^2}}, \sqrt{\frac{u}{1+v^2}}\right) + |J| f_{X,Y}\left(-v \sqrt{\frac{u}{1+v^2}}, -\sqrt{\frac{u}{1+v^2}}\right) = \frac{1}{\pi(1+v^2)} \cdot \frac{1}{2} e^{-\frac{u}{2}},$$

其中 $u > 0, v \in R$, 可以看出: U, V 独立, 且 $U \sim \chi^2(2)$, 而 $V \sim \text{Cau}(0, 1)$ 标准柯西分布, 密度函数是 $p(v) = \frac{1}{\pi} \frac{1}{1+v^2}$.

[注]: 需要特别说明的是, 这里 $\frac{X_1}{X_2}$ 显然是一个关于 0 对称的分布, 而且它的分子、分母都是关于 0 对称的, 因此 $\frac{X_1}{X_2}$ 和 $\frac{X_1}{|X_2|}$ 是同分布的, 而很明显

$$\frac{X_1}{|X_2|} = \frac{N(0, 1)}{\sqrt{\chi^2(1)}}$$

是一个自由度为 1 的 t 分布, 所以 $\frac{X_1}{|X_2|}$ 也是自由度为 1 的 t 分布, 它的概率密度是

$$f(x) = \frac{\Gamma(1)}{\sqrt{\pi}\Gamma(\frac{1}{2})} (x^2 + 1)^{-1} = \frac{1}{\pi} \cdot \frac{1}{1+x^2}, -\infty < x < +\infty,$$

即标准柯西分布.

四、(20 分) $X_1, X_2, \dots, X_n$ i.i.d $\sim F(x)$, 记 $Y_n(x) = \sum_{i=1}^n I[X_i \leq x]$, 求 $\lim_{n \rightarrow \infty} \frac{Y_n(x)}{n}$.

Solution: 根据强大数律, $\lim_{n \rightarrow \infty} \frac{Y_n(x)}{n} = EI[X_1 \leq x] = P(X_1 \leq x) = F(x)$, a.s.

五、(20 分) $X_0, X_1, \dots, X_{2n}, \text{i.i.d} \sim U(0, 1)$, $X_{(0)}, X_{(1)}, \dots, X_{(2n)}$ 为对应的次序统计量, 试证明 $X_{(n)} \xrightarrow{P} \frac{1}{2}$.

Solution: 我们来计算 $Y = X_{(n)}$ 的密度函数, 思想是: 从 $X_0, X_1, \dots, X_{2n}$ 中选出一个当作 Y , 剩下的样本中要有 n 个比 Y 小, n 个比 Y 大, 当然符合的选法有 $\frac{(2n+1)!}{n! \cdot 1! \cdot n!}$ 种, 因此

$$f(y) = \frac{(2n+1)!}{n!n!} P\{X_0 \leq y, X_1 \leq y, \dots, X_{n-1} \leq y\} f_{X_n}(y) P\{X_{n+1} > y, \dots, X_{2n} > y\}$$

$$P\{X_0 \leq y, X_1 \leq y, \dots, X_{n-1} \leq y\} = P^n\{X_0 \leq y\} = y^n,$$

$$P\{X_{n+1} > y, \dots, X_{2n} > y\} = P^n\{X_{2n} > y\} = (1-y)^n,$$

故 $f(y) = \frac{\Gamma(2n+2)}{\Gamma(n+1)\Gamma(n+1)} y^n (1-y)^n, 0 < y < 1$, 这是 $\text{Beta}(n+1, n+1)$ 的分布函数. 根据 Beta 分布的性质,

$$EY = \frac{n+1}{2n+2} = \frac{1}{2}, \quad \text{Var}(Y) = \frac{(n+1)^2}{(2n+2)^2(2n+3)} \rightarrow 0,$$

利用切比雪夫不等式, $P\{|Y - \frac{1}{2}| > \varepsilon\} \leq \frac{\text{Var}(Y)}{\varepsilon^2} \rightarrow 0$, 因此 $X_{(n)} \xrightarrow{P} \frac{1}{2}$.

六、(20 分) 已知连续型随机变量 X 的期望 EX 存在, $f(t) = E|X - t|$ 在 $t = m$ 时取极小值, 证明 $P(X \leq m) = \frac{1}{2}$.

Solution: 设 X 的分布函数是 $F(x)$, 密度函数是 $p(x)$, 则

$$f(t) = \int_{-\infty}^t (t-x)dF(x) + \int_t^{+\infty} (x-t)dF(x) = tF(t) - \int_{-\infty}^t x dF(x) + \int_t^{+\infty} x dF(x) - t(1-F(t)),$$

对 t 求导, 得

$$f'(t) = F(t) + tp(t) - tp(t) - tp(t) - 1 + F(t) + tp(t) = 2F(t) - 1,$$

令 $f'(t) = 0$, 解得 $t = x_{0.5}$ (x_a 表示其满足 $F(x_a) = a$). 二阶导 $f''(t) = 2p(t) \geq 0$, 因此驻点就是极小值点. 根据题意 $m = x_{0.5}$, 故

$$P(X \leq m) = \frac{1}{2}.$$

七、(20 分) $X_1, X_2, X_3, \text{i.i.d} \sim N(0, 1)$, 求

(1)(10 分) $P(X_1 > X_2 > X_3)$;

(2)(10 分) $P(X_1 > X_2, X_1 > X_3)$.

Solution: (1) 根据轮换对称性,

$$\begin{aligned} P(X_1 > X_2 > X_3) &= P(X_1 > X_3 > X_2) = P(X_2 > X_1 > X_3) \\ &= P(X_2 > X_3 > X_1) = P(X_3 > X_1 > X_2) = P(X_3 > X_2 > X_1) \end{aligned}$$

这些事件互不相交, 并且这些事件的并是概率为 1 的事件, 故

$$6P(X_1 > X_2 > X_3) = 1 \Rightarrow P(X_1 > X_2 > X_3) = \frac{1}{6}.$$

(2) 我们发现:

$$P(X_1 > X_2, X_1 > X_3) = P(X_1 = \max\{X_1, X_2, X_3\}),$$

根据轮换对称性,

$$P(X_1 = \max\{X_1, X_2, X_3\}) = P(X_2 = \max\{X_1, X_2, X_3\}) = P(X_3 = \max\{X_1, X_2, X_3\}),$$

故 $P(X_1 > X_2, X_1 > X_3) = \frac{1}{3}$.

复旦大学-432 统计学-2018 年

一、(20 分) 从 1-10 中不放回选 3 个数字, 求以下概率

(1)(5 分) 最小数字是 5;

(2)(5 分) 最大数字是 5;

(3)(5 分) 至少一个小于 6;

(4)(5 分) 一个小于 5, 一个等于 5, 一个大于 5.

Solution:

(1) $\#\Omega = C_{10}^3 = 120$, $\#A_1 = 1 \cdot C_5^2 = 10$, $P(A_1) = \frac{\#A_1}{\#\Omega} = \frac{1}{12}$.

(2) $\#A_2 = 1 \cdot C_4^2 = 6$, $P(A_2) = \frac{\#A_2}{\#\Omega} = \frac{1}{20}$.

(3) $\#A_3 = C_5^3 = 10$, $P(A_3) = 1 - \frac{\#A_3}{\#\Omega} = \frac{11}{12}$.

(4) $\#A_4 = 4 \cdot 1 \cdot 5 = 20$, $P(A_4) = \frac{\#A_4}{\#\Omega} = \frac{1}{6}$.

二、(15 分) 你在重复尝试一个成功概率为 p 的事件, 直至连续出现两次成功或两次失败才停止, 求你以两次成功停止的概率.

Solution:

设 A “以两次成功停止”, $p_0 = P(A)$, $p_1 = P(A \mid \text{第一次成功})$, $p_{-1} = P(A \mid \text{第一次失败})$, 根据全概率公式:

$$\begin{cases} p_0 = p_1 \cdot p + p_{-1} \cdot (1-p) \\ p_1 = p + p_{-1} \cdot (1-p) \\ p_{-1} = p_1 \cdot p \end{cases}$$

解得 $p_0 = \frac{p^2(2-p)}{1-p(1-p)}$.

三、(15 分) 求二项分布, (a, b) 上均匀分布, 伽马分布的期望和方差.

Solution:

(1) 二项分布: $X \sim B(n, p)$, $P(X = k) = C_n^k p^k (1-p)^{n-k}$, $k = 0, 1, \dots, n$,

$$EX = \sum_{k=0}^n k \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} = np \sum_{k=1}^n \frac{(n-1)!}{(k-1)!(n-k)!} p^{k-1} (1-p)^{n-k} = np,$$

$$EX(X-1) = \sum_{k=0}^n k(k-1) C_n^k p^k (1-p)^{n-k} = n(n-1)p^2 \sum_{k=2}^n C_{n-2}^{k-2} p^{k-2} (1-p)^{n-k} = n(n-1)p^2,$$

因此 $EX^2 = n(n-1)p^2 + np$, $DX = EX^2 - (EX)^2 = n(n-1)p^2 + np - n^2p^2 = np(1-p)$.

(2) 均匀分布: $X \sim U(a, b)$, $f(x) = \frac{1}{b-a}$, $a < x < b$,

$$EX = \int_a^b \frac{x}{b-a} dx = \frac{a+b}{2}, DX = \int_a^b \left(x - \frac{a+b}{2}\right)^2 \frac{1}{b-a} dx = \frac{(b-a)^2}{12}.$$

(3) 伽马分布: $X \sim Ga(\alpha, \lambda)$, $f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$, $x > 0$,

$$EX = \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^\alpha e^{-\lambda x} dx = \frac{1}{\lambda \Gamma(\alpha)} \int_0^{+\infty} (\lambda x)^\alpha e^{-\lambda x} d(\lambda x) = \frac{\Gamma(\alpha+1)}{\lambda \Gamma(\alpha)} = \frac{\alpha}{\lambda},$$

$$EX^2 = \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha+1} e^{-\lambda x} dx = \frac{1}{\lambda^2 \Gamma(\alpha)} \int_0^{+\infty} (\lambda x)^{\alpha+1} e^{-\lambda x} d(\lambda x) = \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} = \frac{\alpha(\alpha+1)}{\lambda^2}, \text{ 故 } DX = EX^2 - (EX)^2 = \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}.$$

四、(20 分) 证明 $E(X^2) < \infty$ 的充要条件是级数 $\sum nP(|X| > n)$ 收敛.

Solution: 记 $Y = |X|$, 且 F 是 Y 的分布函数, 则

$$E(Y^2) = \int_0^{+\infty} y^2 dF(y) = \int_0^{+\infty} \int_0^y 2t dt dF(y) = 2 \int_0^{+\infty} t \int_t^{+\infty} dF(y) dt = 2 \int_0^{+\infty} t P(Y > t) dt,$$

一方面有

$$\int_0^{+\infty} tP(Y > t) dt = \sum_{k=0}^{\infty} \int_k^{k+1} tP(Y > t) dt \leq \sum_{k=0}^{\infty} \int_k^{k+1} (k+1)P(Y > k) dt = \sum_{k=0}^{\infty} (k+1)P(Y > k),$$

右侧和 $\sum kP(|X| > k)$ 同敛散, 这说明了 $\sum kP(|X| > k)$ 收敛能推出 $E(Y^2)$ 存在.

同时我们还有

$$\int_0^{+\infty} tP(Y > t) dt = \sum_{k=0}^{\infty} \int_k^{k+1} tP(Y > t) dt \geq \sum_{k=0}^{\infty} \int_k^{k+1} kP(Y > k+1) dt = \sum_{k=0}^{\infty} kP(Y > k+1) = \sum_{k=1}^{\infty} (k-1)P(Y > k),$$

右侧仍然和 $\sum kP(|X| > k)$ 同敛散, 这说明 $E(Y^2)$ 存在可以推出 $\sum kP(|X| > k)$ 收敛. 证明已经结束.

五、(20 分) X_1, X_2, X_3 是取自期望为 α 的指数分布的随机样本, 求概率 $P(X_1 < X_2 < X_3)$ 以及 $X_{(1)}$ 的概率密度.

Solution: 根据轮换对称性, $P(X_1 < X_2 < X_3) = \frac{1}{6}$. 令 $Y = X_{(1)}$, 则当 $y > 0$ 时, $1 - F(y) = P\{Y > y\} = P^3\{X_1 > y\} = e^{-\frac{3}{\alpha}y}$, 故 $f(y) = \frac{3}{\alpha}e^{-\frac{3}{\alpha}y}, y > 0$. 这恰好是 $\text{Exp}(\frac{3}{\alpha})$.

六、(20 分) $P(X_i = -0.3) = P(X_i = 0.4) = \frac{1}{2}, i = 1, 2, \dots, n$, 相互独立, 构造随机变量序列 $Y_n = \prod_{i=1}^n (X_i + 1)$, 求 Y_n 的极限并证明 Y_n 的期望趋于无穷.

Solution: 由强大数律, $\frac{1}{n} \ln Y_n = \frac{1}{n} \sum_{i=1}^n \ln(X_i + 1) \xrightarrow{\text{a.s.}} E \ln(X_1 + 1) = \frac{1}{2} \ln 0.98 < 0$, 故 $\ln Y_n \xrightarrow{\text{a.s.}} -\infty, Y_n \xrightarrow{\text{a.s.}} 0$, 因此 Y_n 的极限是单点分布, 以概率 1 取 0. 而

$$EY_n = \prod_{i=1}^n E(X_i + 1) = \prod_{i=1}^n \left(\frac{0.7 + 1.4}{2} \right) = 1.05^n \rightarrow +\infty.$$

七、(20 分) 有一堆球: 2 红, 3 黑, 4 白. 从中随机摸一个球, 如果是黑色则记你赢, 如果是其他颜色, 则有放回地继续摸球, 直至重复出现该颜色或黑色为止, 如果出现你第一次摸到的颜色, 则你赢, 否则你输. 求你赢的概率.

Solution: 设 A_k 为第 k 次赢的概率, 待求结果为 $P(A) = P(\bigcup_{k=1}^{\infty} A_k) = \sum_{k=1}^{\infty} P(A_k)$. (i) 第一次赢的概率 $P(A_1) = \frac{1}{3}$. (ii) 第 k 次赢 ($k > 1$) 表明: 第一次未摸到黑球, 后续的 $2, 3, \dots, k-1$ 次没有摸到黑也没有摸到你第一次摸中的颜色, 最后第 k 次摸中了最初的颜色, 这一概率肯定与你最初摸到的颜色有关, 考虑全概率公式 $P(A_k) = P(R)P(A_k|R) + P(W)P(A_k|W)$, 其中 R 表示摸到红, W 表示摸到白, 有

$$P(A_k|R) = \left(\frac{4}{9}\right)^{k-2} \frac{2}{9}, \quad P(A_k|W) = \left(\frac{2}{9}\right)^{k-2} \frac{4}{9}.$$

因此

$$P(A_k) = P(R) \frac{2}{9} \left(\frac{4}{9}\right)^{k-2} + P(W) \frac{4}{9} \left(\frac{2}{9}\right)^{k-2} = \frac{4}{81} \left(\frac{4}{9}\right)^{k-2} + \frac{16}{81} \left(\frac{2}{9}\right)^{k-2}.$$

进行求和, 有

$$P(A) = P(A_1) + \frac{4}{81(1-\frac{4}{9})} + \frac{16}{81(1-\frac{2}{9})} = \frac{1}{3} + \frac{4}{45} + \frac{16}{63} = \frac{71}{105}.$$

八、(20 分)

(1)(10 分) 解释相合估计;

(2)(10 分) $X_1, \dots, X_n$ 是来自一个同一个总体的样本, 写出一个中位数的相合估计, 并说明理由.

Solution:

(1) $\hat{g}$ 是 g 的相合估计意味着 $\hat{g} \xrightarrow{P} g$, 这说明了 $\hat{g}$ 是一个很好的估计, 至少在样本量 n 较大时, 它偏离 g 的概率极小. 更进一步, 如果说 $\hat{g}$ 是 g 的强相合估计意味着 $\hat{g} \xrightarrow{\text{a.s.}} g$.

(2) 样本中位数 $X_{[\frac{n}{2}]}$ 就是总体中位数 $x_{0.5}$ 的相合估计量, 设总体密度函数为 $f(x)$, 有样本中位数的渐近正态分布

$$X_{[\frac{n}{2}]} \sim N\left(x_{0.5}, \frac{1}{4nf^2(x_{0.5})}\right),$$

由其渐近正态分布可以得到

$$P\left(\left|X_{[\frac{n}{2}]} - x_{0.5}\right| < \varepsilon\right) = P\left(2\sqrt{n}f(x_{0.5})\left|X_{[\frac{n}{2}]} - x_{0.5}\right| < 2\sqrt{n}f(x_{0.5})\varepsilon\right) \sim \Phi(2\sqrt{n}f(x_{0.5})\varepsilon) - \Phi(-2\sqrt{n}f(x_{0.5})\varepsilon) \rightarrow 1.$$

上式说明了样本中位数 $X_{[\frac{n}{2}]}$ 就是总体中位数 $x_{0.5}$ 的相合估计量.

复旦大学-432 统计学-2019 年

一、(15 分) 甲袋中有 $n-1$ 个白球 1 个黑球, 乙袋中有 n 个白球, 每次从两袋中各取一球进行交换, 求交换 N 次后黑球还在甲袋的概率.

Solution: 设 p_k 为交换 k 次后黑球还在甲袋的概率, 则根据全概率公式,

$$p_{k+1} = p_k \cdot \frac{n-1}{n} + (1-p_k) \cdot \frac{1}{n} = \left(1 - \frac{2}{n}\right) p_k + \frac{1}{n},$$

故有

$$p_N - \frac{1}{2} = \left(1 - \frac{2}{n}\right) \left(p_{N-1} - \frac{1}{2}\right) = \cdots = \left(1 - \frac{2}{n}\right)^N \left(p_0 - \frac{1}{2}\right),$$

即

$$p_N = \frac{1}{2} + \frac{1}{2} \left(1 - \frac{2}{n}\right)^N.$$

二、(15 分) $f(x, y) = Ae^{-(2x+3y)}I[x > 0, y > 0]$, 求

(1)(3 分) A ;

(2)(3 分) $P(X < 2, Y < 1)$;

(3)(3 分) X 的边际密度;

(4)(3 分) $P(X < 3 | Y < 1)$;

(5)(3 分) $f(x | y)$.

Solution:

(1) 由概率的正则性, $1 = \int_{R^2} f(x, y) dx dy = A \int_0^{+\infty} e^{-2x} dx \int_0^{+\infty} e^{-3y} dy = \frac{A}{6} \Rightarrow A = 6$.

(2) $P(X < 2, Y < 1) = \int_0^2 e^{-2x} dx \int_0^1 e^{-3y} dy = 6(1 - e^{-4})(1 - e^{-3})$.

(3) $f_X(x) = \int_0^{+\infty} 6e^{-2x-3y} dy = 2e^{-2x}, x > 0$.

(4) 由于 $f_X(x) = 2e^{-2x}, f_Y(y) = 3e^{-3y}$, 故 X, Y 相互独立, 因此

$$P(X < 3 | Y < 1) = P(X < 3) = 1 - e^{-6}.$$

(5) $f(x | y) = \frac{f(x, y)}{f_Y(y)} = 2e^{-2x}, x > 0, y > 0$.

三、(10 分) $X_1, X_2, \text{i.i.d.} \sim N(\mu, \sigma^2)$, 求 $E \max\{X_1, X_2\}$.

Solution: 令 $Y_i = \frac{X_i - \mu}{\sigma}, i = 1, 2$, 故 $\max\{Y_1, Y_2\} = \frac{\max\{X_1, X_2\} - \mu}{\sigma}$. 而

$$E \max\{Y_1, Y_2\} = EY_1 I_{[Y_1 \geq Y_2]} + EY_2 I_{[Y_1 < Y_2]} = 2EY_1 I_{[Y_1 \geq Y_2]},$$

$$E[Y_1 I_{[Y_1 \geq Y_2]}] = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \int_x^{+\infty} ye^{-\frac{x^2+y^2}{2}} dx dy = \frac{1}{2\pi} \int_{\frac{\pi}{4}}^{\frac{5\pi}{4}} \sin \theta d\theta \int_0^{+\infty} r^2 e^{-\frac{r^2}{2}} dr$$

其中 $\int_0^{+\infty} r^2 e^{-\frac{r^2}{2}} dr = \sqrt{2} \int_0^{+\infty} \sqrt{\frac{r^2}{2}} e^{-\frac{r^2}{2}} d\left(\frac{r^2}{2}\right) = \sqrt{2} \Gamma\left(\frac{3}{2}\right) = \sqrt{\frac{\pi}{2}}$, 故 $E \max\{Y_1, Y_2\} = \frac{1}{\sqrt{\pi}}, E \max\{X_1, X_2\} = \mu + \frac{\sigma}{\sqrt{\pi}}$.

四、(20 分) $EX = 0, \text{Var}(X) = \sigma^2$, 证明对任意 $\varepsilon > 0$, 有

(1)(10 分) $P(|X| > \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$;

(2)(10 分) $P(X > \varepsilon) \leq \frac{\sigma^2}{\sigma^2 + \varepsilon^2}$.

Solution:

(1) 记 $I_{[|X| > \varepsilon]} = \begin{cases} 1, & |X| > \varepsilon, \\ 0, & |X| \leq \varepsilon. \end{cases}$ 它是集合 $\{\omega : |X(\omega)| > \varepsilon\}$ 的示性函数, 可以看出:

$$I_{[|X| > \varepsilon]} \leq \frac{|X|^2}{\varepsilon^2}$$

故 $P(|X| > \varepsilon) = EI_{[|X| > \varepsilon]} \leq \frac{E|X|^2}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}$.

(2) 由马尔可夫不等式, 有

$$P(X > \varepsilon) = P(X + a > \varepsilon + a) \leq \frac{E(X + a)^2}{(\varepsilon + a)^2} = \frac{\sigma^2 + a^2}{(\varepsilon + a)^2},$$

取 $a = \frac{\sigma^2}{\varepsilon}$, 则恰有

$$\frac{\sigma^2 + a^2}{(\varepsilon + a)^2} = \frac{\sigma^2 + \frac{\sigma^4}{\varepsilon^2}}{\left(\varepsilon + \frac{\sigma^2}{\varepsilon}\right)^2} = \frac{\sigma^2}{\sigma^2 + \varepsilon^2},$$

因此 $P(X > \varepsilon) \leq \frac{\sigma^2}{\sigma^2 + \varepsilon^2}$.

[注]: 为什么要取 $a = \frac{\sigma^2}{\varepsilon}$? 这里我们记 $g(a) = \frac{\sigma^2 + a^2}{(\varepsilon + a)^2}$, 这是 a 的函数, 求出它的最大值点即可, 发现恰好在 $a = \frac{\sigma^2}{\varepsilon}$ 取到.

五、(10 分) $X_1, X_2, \text{i.i.d.} \sim N(0, 1)$, 求 $\frac{X_1}{X_2}$ 的分布.

Solution: 重复考察, 略去.

六、(20 分) $X_1, X_2, \dots, X_n, \text{i.i.d.} \sim N(\mu, \sigma^2)$, μ 已知, 证明:

(1)(10 分) $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ 是 σ^2 的有效估计;

(2)(10 分) $\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu|$ 是 σ 的无偏估计, 但不有效.

Solution:

(1) 先计算 σ^2 的 Fisher 信息量, 根据定义

$$I(\sigma^2) = E \left[\frac{\partial \ln f(X; \sigma^2)}{\partial \sigma^2} \right]^2 = \frac{1}{4\sigma^4} E \left[\left(\frac{X - \mu}{\sigma} \right)^2 - 1 \right]^2,$$

恰好 $E \left[\left(\frac{X - \mu}{\sigma} \right)^2 - 1 \right]^2$ 是 $\chi^2(1)$ 的方差, 故 $I(\sigma^2) = \frac{1}{2\sigma^4}$. 因此, σ^2 的 C-R 下界为 $\frac{1}{nI(\sigma^2)} = \frac{2}{n}\sigma^4$. 再计算 $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ 的期望方差, 由于 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$, 期望是 n , 方差是 $2n$, 因此

$$E \left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \right] = \sigma^2, \quad \text{Var} \left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \right] = \frac{2}{n}\sigma^4,$$

它是无偏估计, 方差又恰好达到 C-R 下界, 故是有效估计.

(2) 首先, 令 $g(x) = \sqrt{x}$, 则 σ 的 C-R 下界为 $\frac{[g'(\sigma^2)]^2}{nI(\sigma^2)} = \frac{1}{2n}\sigma^2$, 我们再去计算 $\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu|$ 的期望方差:

$$\frac{1}{\sigma} E|X_1 - \mu| = \int_{-\infty}^{+\infty} |x| \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} x e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}} \Rightarrow E|X_1 - \mu| = \sqrt{\frac{2}{\pi}} \sigma,$$

$$E|X_1 - \mu|^2 = \sigma^2, \text{ 故 } \text{Var}(|X_1 - \mu|) = \sigma^2 - \frac{2}{\pi}\sigma^2 = \left(1 - \frac{2}{\pi}\right)\sigma^2,$$

故 $E \left[\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu| \right] = \sigma, \text{Var} \left[\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu| \right] = \frac{(\frac{\pi}{2} - 1)}{n} \sigma^2$, 它是无偏估计, 但没有达到 C-R 下界, 不是有效估计.

七、(20 分) 总体的分布函数 $F(x)$ 连续单增, $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 是来自该总体的随机样本的次序统计量, $Y_i = F(X_{(i)})$, 求

(1)(10 分) $EY_i, \text{Var}(Y_i)$;

(2)(10 分) $(Y_1, Y_2, \dots, Y_n)^T$ 的协方差矩阵.

Solution:

(1) 由于 $U_1 = F(X_1), U_2 = F(X_2), \dots, U_n = F(X_n)$ 独立同服从 $[0, 1]$ 上均匀分布, 故 $Y_i = U_{(i)}$ 恰好就是均匀分布的次序统计量, 根据次序统计量的定义, 有:

$$f_i(y) = \frac{n!}{(i-1)!(n-i)!} f_U(y) P^{i-1}\{U \leq y\} P^{n-i}\{U \geq y\}, \text{一一代入, 有}$$

$$f_i(y) = \frac{n!}{(i-1)!(n-i)!} y^{i-1} (1-y)^{n-i}, 0 \leq y \leq 1, \text{恰好是 Beta}(i, n-i+1).$$

根据贝塔分布的性质 $EY_i = \frac{i}{n+1}, \text{Var}(Y_i) = \frac{i(n-i+1)}{(n+1)^2(n+2)}.$

(2) 我们考虑 $(Y_i, Y_j), i < j$ 的联合分布, 根据次序统计量的定义, 有

$$f_{i,j}(x, y) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} f_U(x) f_U(y) P^{i-1}\{U \leq x\} P^{j-i-1}\{x \leq U \leq y\} P^{n-j}\{U \geq y\}$$

即

$$f_{i,j}(x, y) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} x^{i-1} (y-x)^{j-i-1} (1-y)^{n-j}, 0 \leq x \leq y \leq 1.$$

协方差问题归为计算积分 $\int_0^1 \int_0^y xy \cdot x^{i-1} (y-x)^{j-i-1} (1-y)^{n-j} dx dy$, 而如果我们把 y 视作 $y = x + (y-x)$, 那么这个积分可以化为两部分:

$$\int_0^1 \int_0^y x^{i+1} (y-x)^{j-i-1} (1-y)^{n-j} dx dy = \frac{(i+1)!(j-i-1)!(n-j)!}{(n+2)!},$$

$$\int_0^1 \int_0^y x^i (y-x)^{j-i} (1-y)^{n-j} dx dy = \frac{i!(j-i)!(n-j)!}{(n+2)!},$$

(首先请看 $f_{i,j}(x, y)$ 的表达式, 会发现

$$\frac{(n+2)!}{(i+1)!(j-i-1)!(n-j)!} x^{i+1} (y-x)^{j-i-1} (1-y)^{n-j}$$

恰也是一个密度函数, 故通过概率的正则性就很容易得到上述两个积分值) 故有 $E[Y_i Y_j] = \frac{i(j+1)}{(n+1)(n+2)}$, 故 $\text{Cov}(Y_i, Y_j) = \frac{i(n+1-j)}{(n+1)^2(n+2)}$. 因此协方差矩阵是 $\Sigma = (a_{ij})_{n \times n}$, 其中 $a_{ij} = \frac{i(n+1-j)}{(n+1)^2(n+2)}, i < j$.

八、(20 分) 有来自总体 $U(\theta, 2\theta)$ 的随机样本 $X_1, \dots, X_n$, 求 θ 的矩估计和 MLE, 并验证无偏性和相合性.

Solution: 先求矩估计, 求期望得 $EX_1 = \frac{3\theta}{2}$, 由替换原理得 $\hat{\theta}_M = \frac{2}{3} \bar{X}$. 求期望容易看出它无偏, 由强大数律知它是强相合估计. 再求 MLE, 写出似然函数是

$$L(\theta) = \frac{1}{\theta^n} I_{\{X_{(n)} < 2\theta\}} I_{\{X_{(1)} > \theta\}} = \frac{I_{\left\{\frac{X_{(n)}}{2} < \theta < X_{(1)}\right\}}}{\theta^n},$$

可以看出 $\frac{1}{\theta^n}$ 关于 θ 单调递减, 故 θ 取最小值时为 MLE, 即 $\hat{\theta}_L = \frac{X_{(n)}}{2}$. 利用变换 $Y_i = \frac{X_i - \theta}{\theta} \sim U(0, 1)$, 知 $Y_{(n)} = \frac{X_{(n)} - \theta}{\theta} \sim \text{Beta}(n, 1)$, 故有

$$E(Y_{(n)}) = \frac{n}{n+1}, \quad E(\hat{\theta}_L) = \frac{1}{2} E(X_{(n)}) = \frac{1}{2} [\theta E(Y_{(n)}) + \theta] = \frac{2n+1}{2n+2} \theta.$$

所以 $\hat{\theta}_L$ 不无偏, 但渐近无偏, 再看相合性, 有

$$\begin{aligned} P\left(\left|\hat{\theta}_L - \theta\right| > \varepsilon_1\right) &= P\left(\left|X_{(n)} - 2\theta\right| > \varepsilon_2\right) \\ &= P\left(\left|Y_{(n)} - 1\right| > \varepsilon_3\right) \\ &= P\left(Y_{(n)} < 1 - \varepsilon_3\right) \\ &= (1 - \varepsilon_3)^n, \end{aligned}$$

级数收敛, 故它是强相合估计.

九、(20 分) 设 $X_1, \dots, X_n$ 是来自 $N(\mu, 1)$ 的随机样本, 考虑假设检验问题

$$H_0: \mu = 1 \quad \text{vs} \quad H_1: \mu = 2$$

给定拒绝域 $W = \{\bar{X} > 1.6\}$, 回答下述问题:

(1)(10 分) $n = 10$, 求犯两类错误的概率 α, β ;

(2)(10 分) 要求第二类错误 $\beta \leq 0.01$, 求样本量的取值范围.

Solution:

(1) 先算第一类错误, 原假设成真时 $\bar{X} \sim N(1, \frac{1}{n})$, 故

$$\begin{aligned}\alpha &= P_{\mu=1}(\bar{X} > 1.6) \\ &= P_{\mu=1}(\sqrt{n}(\bar{X} - 1) > 0.6\sqrt{n}) \\ &= 1 - \Phi(0.6\sqrt{n}) \\ &= 1 - \Phi(0.6\sqrt{10}).\end{aligned}$$

再算第二类错误, 备择假设成真时 $\bar{X} \sim N(2, \frac{1}{n})$, 故

$$\begin{aligned}\beta &= P_{\mu=2}(\bar{X} \leq 1.6) \\ &= P_{\mu=2}(\sqrt{n}(\bar{X} - 2) \leq -0.4\sqrt{n}) \\ &= \Phi(-0.4\sqrt{n}) \\ &= \Phi(-0.4\sqrt{10}).\end{aligned}$$

(2) 根据第 (1) 问计算, 令 $\Phi(-0.4\sqrt{n}) \leq 0.01$, 得

$$-0.4\sqrt{n} \leq -2.33 \implies n \geq \frac{2.33^2}{0.4^2} \implies n \geq 34.$$

复旦大学-432 统计学-2020 年

一、(20 分) 一家有两个孩子, 求下列事件的概率:

(1)(10 分) 已知第一个是女孩, 求第二个是女孩的概率;

(2)(10 分) 已知有一个是女孩, 求另一个是女孩的概率.

Solution:

(1) 首先需要假设: 没有任何信息的情况下一个孩子是女孩的概率是 0.5. 用事件 A_i 表示第 i 个是女孩 ($i = 1, 2$), 则 $P(A_2 | A_1) = \frac{P(A_1 A_2)}{P(A_1)} = \frac{0.25}{0.5} = 0.5$.

(2) $P(A_1 A_2 | A_1 \cup A_2) = \frac{P(A_1 A_2)}{P(A_1 \cup A_2)} = \frac{0.25}{0.75} = \frac{1}{3}$.

二、(15 分) 甲有 21 个硬币, 乙有 20 个硬币, 两人同时抛出所有硬币, 求甲朝上的硬币数多于乙的概率.

Solution: 根据对称性可以知道, $P\{\text{甲朝上的硬币数多于乙}\} = P\{\text{甲朝下的硬币数多于乙}\}$. 用随机变量 X 表示甲朝上的硬币数, 随机变量 Y 表示乙朝上的硬币数. 则:

$$\begin{aligned} P\{X > Y\} &= P\{21 - X > 20 - Y\} = P\{1 - X > -Y\} \\ &= P\{X < Y + 1\} = P\{X \leq Y\} \end{aligned}$$

又 $P\{X > Y\} + P\{X \leq Y\} = 1$, 因此 $P\{X > Y\} = P\{X \leq Y\} = 0.5$.

三、(15 分) 平面上有无数平行直线, 每两条平行直线间隔 2 米, 用边长 1 米的正三角形向平面投掷, 求三角形压到直线的概率.

Solution: 记 $\triangle ABC$ 的三条边分别为 a, b, c . 则三角形与平行线相交有以下几种情况:

(1) 三角形的一个顶点在平行线上;

(2) 三角形的一条边与直线重合;

(3) 三角形的两条边与平行线相交. 根据概率的几何概型 $P(1) = P(2) = 0$, 因此仅需要考虑情况 (3). 而 $P(3) = P_{ab} + P_{ac} + P_{bc}$, 其中 P_{ab} 表示边 ab 与平行线相交. 为此, 记 P_a 表示边 a 与平行线相交, 则 $P_a = P_{ac} + P_{ab}$. 故

$$P(3) = \frac{1}{2} (P_a + P_b + P_c),$$

现仅需要求出 $P_a P_b P_c$. 这是一个 Buffon 投针模型, 其概率是 $P_a = \frac{2a}{d\pi}$, 其中 a 是边 a 的长度, d 是平行线之间的间距, 代入数据可算得 $P_a = \frac{2}{2\pi} = \frac{1}{\pi}$. 同理 $P_b = P_c = \frac{1}{\pi}$. 故

$$P\{\text{三角形压到直线}\} = P(3) = \frac{1}{2} (P_a + P_b + P_c) = \frac{3}{2\pi}.$$

四、(15 分) 8 个男生、7 个女生坐成一排, 设 $X_i = 1$ 表示第 i 个位置与第 $i+1$ 个位置坐的是异性, $X_i = 0$ 表示第 i 个位置与第 $i+1$ 个位置坐的是同性, $\xi = \sum_{i=1}^{14} X_i$, 求 $E\xi$.

Solution: $E\xi = E\left(\sum_{i=1}^{14} X_i\right) = \sum_{i=1}^{14} EX_i$, 考虑到诸 X_i 是同分布的, 现求 EX_1 .

$$EX_1 = P(X_1 = 1) = \frac{C_8^1 C_7^1}{C_{15}^2} = \frac{8 \times 7}{\frac{15 \times 14}{2 \times 1}} = \frac{8}{15}$$

所以 $E\xi = \sum_{i=1}^{14} EX_i = 14EX_1 = \frac{112}{15}$.

五、(15 分) 举出一个期望趋于正无穷, 却依概率收敛到 0 的随机变量序列 $\{X_n\}$.

Solution: 给出这样一个随机变量序列: $P(X_n = 0) = 1 - \frac{1}{n}, P(X_n = n^2) = \frac{1}{n}$. $EX_n = n \rightarrow +\infty$. 而 $P(X_n \neq 0) = \frac{1}{n}$, 则 $X_n \xrightarrow{P} 0$.

六、(20 分) 有来自总体 $X \sim f(x) = \theta x^{\theta-1} I\{0 < x < 1\}$ 的 n 个随机样本, 求

(1)(5 分) θ 的 MLE, 并验证无偏性;

(2)(5 分) 验证 MLE 的一致性;

(3)(5 分) θ 的矩估计;

(4)(5 分) 利用样本中位数对 θ 进行估计.

Solution:

(1) 似然函数 $L(\mathbf{X}; \theta) = \theta^n \left(\prod_{i=1}^n x_i\right)^{\theta-1}$, 对数似然函数 $\ln L = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i$. 令 $\frac{\partial \ln L}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i = 0$, 解得 $\hat{\theta}_L = \frac{n}{\sum_{i=1}^n (-\ln x_i)}$. 又因为总体服从贝塔分布, 属于指数族分布, 其对数似然函数的驻点必定为极大似然估计. 所以 $\hat{\theta}_L = \frac{n}{\sum_{i=1}^n (-\ln x_i)}$ 是 θ 的极大似然估计. 若令 $Y_i = -\ln X_i \sim \text{Exp}(\theta)$, 且由伽马分布的可加性可知 $T = \sum_{i=1}^n y_i \sim \text{Ga}(n, \theta)$, 则极大似然估计可以写为 $\hat{\theta}_L = \frac{n}{T}$.

$$E\hat{\theta}_L = E\frac{n}{T} = \int_0^{+\infty} \frac{n}{t} \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t} dt = \frac{n\theta}{\Gamma(n)} \int_0^{+\infty} (\theta t)^{n-2} e^{-\theta t} d(\theta t) = \frac{n\theta}{\Gamma(n)} \Gamma(n-1) = \frac{n}{n-1} \theta$$

所以 $\hat{\theta}_L$ 不是 θ 的无偏估计, 但它是渐进无偏的.

(2) 上一小题中我们已经算得 $E\hat{\theta}_L = \frac{n}{n-1} \theta \rightarrow \theta$, 现来考虑它的一致性.

$$E\hat{\theta}_L^2 = E\frac{n^2}{T^2} = \frac{n^2 \theta^2}{\Gamma(n)} \int_0^{+\infty} (\theta t)^{n-3} e^{-\theta t} d(\theta t) = \frac{n^2 \theta^2}{\Gamma(n)} \Gamma(n-2) = \frac{n^2}{(n-1)(n-2)} \theta^2,$$

$$\text{Var}(\hat{\theta}_L) = E\hat{\theta}_L^2 - (E\hat{\theta}_L)^2 = \frac{n^2 \theta^2}{(n-1)(n-2)} - \left(\frac{n}{n-1} \theta\right)^2 = \frac{n^2}{(n-1)^2(n-2)} \theta^2.$$

$$\begin{aligned} P\left(|\hat{\theta}_L - \theta| \geq \varepsilon\right) &= P\left|\hat{\theta}_L - \frac{n}{n-1} \theta + \frac{n}{n-1} \theta - \theta\right| \geq \varepsilon \\ &\leq P\left|\hat{\theta}_L - \frac{n}{n-1} \theta\right| \geq \frac{\varepsilon}{2} + P\left|\frac{n}{n-1} \theta - \theta\right| \geq \frac{\varepsilon}{2} > \end{aligned}$$

其中根据切比雪夫不等式 $P\left|\hat{\theta}_L - \frac{n}{n-1} \theta\right| \geq \frac{\varepsilon}{2} \leq \frac{4 \text{Var}(\hat{\theta}_L)}{\varepsilon^2} = \frac{4}{\varepsilon^2} \frac{n^2}{(n-1)^2(n-2)} \theta^2 \rightarrow 0$ 而对于较大的 n , $P\left|\frac{n}{n-1} \theta - \theta\right| \geq \frac{\varepsilon}{2} = 0$. 因此 $P\left|\hat{\theta}_L - \theta\right| \geq \varepsilon \rightarrow 0$, 也就是说 $\hat{\theta}_L$ 是 θ 的一致估计.

(3) 总体服从 $\text{Beta}(\theta, 1)$, 由贝塔分布的数字特征, 我们知道 $EX = \frac{\theta}{\theta+1}$. 据此反解得出 θ 的矩估计 $\hat{\theta}_M = \frac{\bar{x}}{1-\bar{x}}$.

$$(4) \text{ 总体的分布函数是 } F(x) = \begin{cases} 0, & x < 0 \\ x^\theta, & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases} \text{ 令 } F(x) = \frac{1}{2}, \text{ 解得 } x_{0.5} = \left(\frac{1}{2}\right)^{\frac{1}{\theta}}, \text{ 用样本中位数 } m_{0.5} \text{ 代}$$

替总体中位数 $x_{0.5}$, 并反解出 $\hat{\theta} = \frac{1}{\log_{\frac{1}{2}} \frac{1}{m_{0.5}}} = \frac{\log_{\frac{1}{2}} \frac{1}{2}}{\log_{\frac{1}{2}} m_{0.5}} = \log_{m_{0.5}} \frac{1}{2}$ 是基于样本中位数对 θ 的估计.

七、(20 分) $X_1, \dots, X_n, \text{i.i.d.} \sim N(\mu, \sigma^2)$, 证明 $[X_{(1)}, X_{(n)}]$ 是 μ 的置信水平为 $1 - 2^{1-n}$ 的置信区间.

Solution: 先考虑求 $U = x_{(1)}$ 的分布, 由最小值分布的计算公式可知

$$F_U(u) = 1 - \left[1 - \Phi\left(\frac{u - \mu}{\sigma}\right)\right]^n$$

则 $P(\mu < x_{(1)}) = 1 - F_U(\mu) = [1 - \Phi(0)]^n = \left(\frac{1}{2}\right)^n = 2^{-n}$. 根据对称性可知 $P(\mu > x_{(n)}) = 2^{-n}$. 所以 $P(x_{(1)} \leq \mu \leq x_{(n)}) = 1 - 2 \cdot 2^{-n} = 1 - 2^{1-n}$

八、(20 分) 有来自总体 $X \sim f(x) = \frac{1}{2} e^{-|x-\theta|}$ 的 7 个随机样本, 求 θ 的 MLE.

Solution: 重复考察, 略去.

九、(10 分) $(X_1, X_2) \sim N(0, 0; 1, 1; 0)$, 求 $\frac{X_1}{X_2}$ 的概率分布.

Solution: 由于分母 X_2 的分布关于 0 对称, 因此 $\frac{X_1}{|X_2|}$ 与 $\frac{X_1}{X_2}$ 同分布, 而很明显 $\frac{N(0,1)}{\sqrt{\frac{X_2^2(1)}{1}}}$ 是一个自由度为 1 的 t 分布, 所以 $\frac{X_1}{|X_2|}$ 也是自由度为 1 的 t 分布, 它的概率密度是

$$f(x) = \frac{\Gamma(1)}{\sqrt{\pi} \Gamma(\frac{1}{2})} (x^2 + 1)^{-1} = \frac{1}{\pi} \cdot \frac{1}{1 + x^2}, -\infty < x < +\infty,$$

即标准柯西分布.

复旦大学-432 统计学-2021 年

一、(15 分) 某平面上有无数条距离为 2 的等距平行线, 先投掷一边长为 1 的正三角形, 求三角形交于平行线的概率.

Solution: 记 $\triangle ABC$ 的三条边分别为 a, b, c . 则三角形与平行线相交有以下几种情况: (1) 三角形的一个顶点在平行线上; (2) 三角形的一条边与直线重合; (3) 三角形的两条边与平行线相交. 根据概率的几何概型 $P(1) = P(2) = 0$, 因此仅需要考虑情况 (3). 而 $P(3) = P_{ab} + P_{ac} + P_{bc}$, 其中 P_{ab} 表示边 ab 与平行线相交. 为此, 记 P_a 表示边 a 与平行线相交, 则 $P_a = P_{ac} + P_{ab}$. 故

$$P(3) = \frac{1}{2} (P_a + P_b + P_c),$$

现仅要求出 P_a, P_b, P_c . 这是一个 Buffon 投针模型, 其概率是 $P_a = \frac{2a}{d\pi}$, 其中 a 是边 a 的长度, d 是平行线之间的间距, 代入数据可算得 $P_a = \frac{2}{2\pi} = \frac{1}{\pi}$. 同理 $P_b = P_c = \frac{1}{\pi}$. 故

$$P\{\text{三角形压到直线}\} = P(3) = \frac{1}{2} (P_a + P_b + P_c) = \frac{3}{2\pi}.$$

二、(15 分) 甲乙两人抛硬币, 若正面朝上则甲赢 1 元, 反面朝上乙赢 1 元. 共进行 20 轮, 最终两人皆不输不赢. 已知甲初始没有钱, 问在整个过程中甲不欠钱的概率.

Solution: 用折线法, 题设问题是: 从点 $(0, 0)$ 随机游走到点 $(20, 0)$, 期间不能触碰直线 $y = -1$. 首先, 从点 $(0, 0)$ 随机游走到点 $(20, 0)$ 总计有 C_{20}^{10} 种 (20 次中, 甲赢 10 次). 从点 $(0, 0)$ 随机游走到与 $(20, 0)$ 关于 $y = -1$ 对称的点 $(20, -2)$ 总计有 C_{20}^9 种. 故题设事件的概率是:

$$P(A) = 1 - \frac{C_{20}^9}{C_{20}^{10}} = \frac{1}{11}.$$

三、(15 分) $X_0, \dots, X_n, \dots$ 是 i.i.d. 的服从 $U(0, 1)$ 的随机变量, 记

$$N = \inf\{n \geq 1 : X_n > X_0\},$$

求 N 的分布律.

Solution: 先计算给定 $X_0 = x$ 时的条件分布, 它类似几何分布:

$$\begin{aligned} P(N = k | X_0 = x) &= P^{k-1}(X_1 \leq x) P(X_k > x) \\ &= x^{k-1}(1-x) \end{aligned}$$

由连续场合的全概率公式, 有 $P(N = k) = \int_0^1 x^{k-1}(1-x)dx = \frac{1}{k(k+1)}$.

四、(15 分) $X_1, \dots, X_n$ 是 i.i.d. 的随机变量, $P(X = 1) = 0.4, P(X = -0.5) = 0.6$. 令 $S_n = (1 + X_1)(1 + X_2) \cdots (1 + X_n)$, 问 $E(S_n)$ 与 S_n 是否收敛? 若收敛, 求其极限.

Solution: $E(S_n) = \prod_{i=1}^n E(1 + X_i) = (1.1)^n \rightarrow +\infty$, 期望不收敛; 由强大数律 $\frac{1}{n} \ln S_n = \frac{1}{n} \sum_{i=1}^n \ln(1 + X_i) \xrightarrow{\text{a.s.}} E \ln(1 + X_1) = -\frac{1}{5} \ln 2 < 0$, 故 $S_n \xrightarrow{\text{a.s.}} \lim_{n \rightarrow \infty} \exp\{-\frac{n}{5} \ln 2\} = 0$.

五、(15 分) 投掷一枚硬币, 连续出现三次同面则停止, 记投掷次数为 N , 求 EN .

Solution: 设 $A_{-2}, A_{-1}, A_0, A_1, A_2$ 分别表示状态“刚刚连续投出 2 次反面”、“刚刚连续投出 1 次反面”、“初始状态”、“刚刚连续投出 1 次正面”、“刚刚连续投出 2 次正面”. 设 X 表示从当前状态开始, 连续三次同面而

停止的次数, 则有:

$$\begin{aligned}E[X | A_{-2}] &= \frac{1}{2} + \frac{1}{2} (E[X | A_1] + 1) \\E[X | A_{-1}] &= \frac{1}{2} (E[X | A_{-2}] + 1) + \frac{1}{2} (E[X | A_1] + 1) \\E[X | A_0] &= \frac{1}{2} (E[X | A_{-1}] + 1) + \frac{1}{2} (E[X | A_1] + 1) \\E[X | A_1] &= \frac{1}{2} (E[X | A_{-1}] + 1) + \frac{1}{2} (E[X | A_2] + 1) \\E[X | A_2] &= \frac{1}{2} + \frac{1}{2} (E[X | A_{-1}] + 1)\end{aligned}$$

很明显该问题具有对称性, 设

$$x = E[X | A_{-2}] = E[X | A_2], y = E[X | A_{-1}] = E[X | A_1], z = E[X | A_0],$$

故有

$$\begin{cases} x = \frac{1}{2} + \frac{1}{2}(y+1), \\ y = \frac{1}{2}(x+1) + \frac{1}{2}(y+1), \\ z = \frac{1}{2}(y+1) + \frac{1}{2}(y+1), \end{cases} \implies \begin{cases} x - \frac{1}{2}y = 1, \\ x - y = -2, \\ z = y + 1, \end{cases} \implies \begin{cases} x = 4, \\ y = 6, \\ z = 7. \end{cases}$$

故 $EN = E[X | A_0] = 7$.

六、(15 分) X_1, X_2 独立同服从 $N(0, 1)$, 求 $\frac{X_1}{X_2}$ 与 $\frac{X_1^2}{X_2^2}$ 的分布.

Solution: $Y = \frac{X_1}{X_2} \sim \text{Cau}(0, 1)$, 令 $Z = Y^2$,

$$\begin{aligned}P(Z \leq z) &= P(-\sqrt{z} \leq Y \leq \sqrt{z}) \\&= 2 \int_0^{\sqrt{z}} \frac{1}{\pi(1+x^2)} dx \\&= \frac{2}{\pi} \arctan \sqrt{z}\end{aligned}$$

求导后, 有密度函数

$$f_Z(z) = \frac{1}{\pi(1+z)\sqrt{z}}, z > 0$$

换句话说, 由于 $Y \sim t(1)$, 故 $Z = Y^2 \sim F(1, 1)$.

七、(10 分) 简答题:

(1)(5 分) 叙述充分统计量的定义.

(2)(5 分) 叙述 C-R 不等式.

Solution:

(1) 充分统计量是充分蕴含了样本刻画参数信息的统计量, 当充分统计量 T 给定时, 样本的条件分布 $f(x_1, \dots, x_n | T = t)$ 与参数无关.

(2) C-R 不等式是指一类总体 (满足正则性条件: 积分求导可以换序) 考虑参数的函数的无偏估计时方差会具有一个下界, 若对 $g(\theta)$ 作估计, C-R 下界是 $\frac{[g'(\theta)]^2}{nI(\theta)}$, 其中 $I(\theta) = E\left[\frac{\partial \ln f(X; \theta)}{\partial \theta}\right]^2$ 是费雪信息量.

八、(10 分) 有来自总体 $f(x) = 2x, 0 < x < 1$ 的 10 个随机样本 $X_1, \dots, X_{10}$, 问 $\frac{X_{(3)}}{X_{(6)}}$ 与 $X_{(6)}$ 是否独立, 请说明理由.

Solution: $(U = \frac{X_{(3)}}{X_{(6)}}, V = X_{(6)})$ 的联合分布是:

$$\begin{aligned}f(u, v) &= v f_{X_{(3)}, X_{(6)}}(uv, v) \\&= C v^{11} (1-v^2)^4 u^5 (1-u^2)^2\end{aligned}$$

其中, $u \in (0, 1), v \in (0, 1)$, 定义域是矩形且可以因式分解, 故 U, V 独立.

九、(10 分) 有来自总体 $N(\mu, 1)$ 的 n 个随机样本 $X_1, \dots, X_n$, 证明: $\bar{X}$ 是充分统计量.

Solution: 联合密度函数可以写成

$$\begin{aligned} f(x_1, \dots, x_n; \mu) &= C \exp \left\{ -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2} \right\} \\ &= C \exp \left\{ -\frac{-2\mu \sum_{i=1}^n x_i + n\mu^2 + \sum_{i=1}^n x_i^2}{2} \right\} \end{aligned}$$

由因子分解定理, $\bar{X}$ 是充分统计量.

十、(10 分) 有来自总体 $U(\theta, 2\theta)$ 的 n 个随机样本 $X_1, \dots, X_n$, 求 θ 的最大似然估计, 并判断其无偏性与相合性.

Solution: 似然函数是

$$L(\theta) = \frac{1}{\theta^n} I_{\left\{x_{(1)} > \theta > \frac{x_{(n)}}{2}\right\}},$$

前面部分关于 θ 单调递减, 示性函数说明 θ 最小取 $\frac{x_{(n)}}{2}$, 因此最大似然估计是 $\hat{\theta} = \frac{X_{(n)}}{2}$. 令 $Y = \frac{X-\theta}{\theta} \sim U(0, 1)$, 故 $Y_{(n)} \sim \text{Beta}(n, 1)$, 因此 $EY_{(n)} = \frac{n}{n+1} \rightarrow 1$, $\text{Var}(Y_{(n)}) = \frac{n}{(n+1)^2(n+2)} \rightarrow 0$, 故 $Y_{(n)} \xrightarrow{P} 1$, 故有

$$E\hat{\theta} = \frac{2n+1}{2n+2}\theta \neq \theta, \quad \hat{\theta} \xrightarrow{P} \theta.$$

这说明它有偏, 但仍然是相合估计.

十一、(10 分) 有来自总体 $N(\mu, \sigma^2)$ 的 n 个随机样本 $X_1, \dots, X_n$, 其中 μ 已知, 令

$$\hat{\sigma} = \frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu|,$$

验证 $\hat{\sigma}$ 是 σ 的无偏估计, 但不是有效估计.

Solution: 先计算 σ^2 的 Fisher 信息量, 根据定义

$$I(\sigma^2) = E \left[\frac{\partial \ln f(X; \sigma^2)}{\partial \sigma^2} \right]^2 = \frac{1}{4\sigma^4} E \left[\left(\frac{X - \mu}{\sigma} \right)^2 - 1 \right]^2,$$

恰好 $E \left[\left(\frac{X - \mu}{\sigma} \right)^2 - 1 \right]^2$ 是 $\chi^2(1)$ 的方差, 故 $I(\sigma^2) = \frac{1}{2\sigma^4}$. 令 $g(x) = \sqrt{x}$, 则 σ 的 C-R 下界为 $\frac{[g'(\sigma^2)]^2}{nI(\sigma^2)} = \frac{1}{2n}\sigma^2$, 我们再去计算 $\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu|$ 的期望方差:

$$\begin{aligned} \frac{1}{\sigma} E|X_1 - \mu| &= \int_{-\infty}^{+\infty} |x| \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} x e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}} \Rightarrow E|X_1 - \mu| = \sqrt{\frac{2}{\pi}} \sigma, \\ E|X_1 - \mu|^2 &= \sigma^2, \text{ 故 } \text{Var}(|X_1 - \mu|) = \sigma^2 - \frac{2}{\pi} \sigma^2 = \left(1 - \frac{2}{\pi}\right) \sigma^2, \end{aligned}$$

故

$$E \left[\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu| \right] = \sigma, \quad \text{Var} \left[\frac{1}{n} \sqrt{\frac{\pi}{2}} \sum_{i=1}^n |X_i - \mu| \right] = \frac{(\frac{\pi}{2} - 1)}{n} \sigma^2,$$

它是无偏估计, 但没有达到 C-R 下界, 不是有效估计.

十二、(10 分) 有来自总体 $\mathcal{P}(\theta)$ 的 n 个随机样本, 考虑假设检验问题:

$$H_0: \theta = 2 \quad \text{vs} \quad H_1: \theta = 3,$$

有拒绝域 $W = \{\bar{x} \geq 2.8\}$, 问

(1)(5 分) $n = 5$ 时, 犯两类错误的概率分别是多少?

(2)(5 分) n 趋于无穷时, 犯两类错误的概率会有什么变化? 请说明.

Solution:

(1) 第一类错误是:

$$\begin{aligned}\alpha &= P_{\theta=2}\{\bar{X} \geq 2.8\} \\ &= P_{\theta=2}\left\{\sum_{i=1}^5 X_i \geq 14\right\} \\ &= \sum_{k=14}^{\infty} \frac{10^k}{k!} e^{-10}\end{aligned}$$

第二类错误是:

$$\begin{aligned}\beta &= P_{\theta=3}\{\bar{X} < 2.8\} \\ &= P_{\theta=3}\left\{\sum_{i=1}^5 X_i < 14\right\} \\ &= \sum_{k=0}^{13} \frac{15^k}{k!} e^{-15}\end{aligned}$$

(2) 由大数定律:

$$\begin{aligned}\alpha &= P_{\theta=2}\{\bar{X} \geq 2.8\} \\ &\leq P_{\theta=2}\{|\bar{X} - 2| \geq 0.8\} \rightarrow 0 \\ \beta &= P_{\theta=3}\{\bar{X} < 2.8\} \\ &\leq P_{\theta=3}\{|\bar{X} - 3| > 0.2\} \rightarrow 0\end{aligned}$$

所以当样本量趋于无穷时, 两类错误都会趋于 0.

复旦大学-432 统计学-2022 年

一、(20 分) 袋子里有: a 红球, a 黄球, b 蓝球. 有放回摸 3 个球, 设 $A = \{ \text{抽出的球有黄球也有红球, 且红球比黄球先取出} \}$. 求:

(1)(10 分) $P(A)$;

(2)(10 分) 若 $\{ \text{没有摸到蓝球} \}$ 与 A 概率相同, 求 $a : b$.

Solution: [注]: 题干可以理解成 $A_1 = \{ \text{有一个红球比黄球先取出} \}$, 也可以理解成 $A_2 = \{ \text{所有红球比黄球先取出} \}$.

(1) 先考虑 A_1 , 有

$$A_1 = \{ \text{红红黄, 红黄红, 红黄黄, 蓝红黄, 红蓝黄, 红黄蓝} \},$$

故有

$$P(A_1) = \frac{a^3 + a^3 + a^3 + 3a^2b}{(2a+b)^3} = \frac{3a^2(a+b)}{(2a+b)^3}.$$

再考虑 A_2 , 有

$$A_2 = \{ \text{红红黄, 红黄黄, 蓝红黄, 红蓝黄, 红黄蓝} \},$$

故有

$$P(A_2) = \frac{a^3 + a^3 + 3a^2b}{(2a+b)^3} = \frac{a^2(2a+3b)}{(2a+b)^3}.$$

(2) 先计算 $B = \{ \text{没有摸到蓝球} \}$, 有

$$P(B) = \left(\frac{2a}{2a+b} \right)^3 = \frac{8a^3}{(2a+b)^3},$$

若 $P(B) = P(A_1)$, 即

$$8a^3 = 3a^2(a+b) \implies 8a = 3(a+b) \implies \frac{a}{b} = \frac{3}{5}.$$

若 $P(B) = P(A_2)$, 即

$$8a^3 = a^2(2a+3b) \implies 8a = 2a+3b \implies \frac{a}{b} = \frac{1}{2}.$$

二、(10 分) 离散型随机变量 X 的分布列是

$$P(X=a) = P(X=b) = P(X=a+1) = \frac{1}{3},$$

其中 $a < b < a+1$. 求其方差的取值范围.

Solution: 由于 $\text{Var}(X) = \text{Var}(X-a)$, 故不妨假设 X 的取值是

$$P(X=0) = P(X=c) = P(X=1) = \frac{1}{3},$$

其中 $c = b-a \in (0, 1)$, 故有 $EX = \frac{c+1}{3}$, 而

$$EX^2 = \frac{c^2+1}{3}, \quad \text{Var}(X) = \frac{3c^2+3-(c+1)^2}{9} = \frac{2}{9} \left[\left(c - \frac{1}{2} \right)^2 + \frac{3}{4} \right] \in \left[\frac{1}{6}, \frac{2}{9} \right].$$

三、(20 分) 离散型随机变量 X 只取 $x, x+a$ 两个值, 其中 $a > 0$, 且 $\text{Var}(X) = 1$, 求 a 的取值范围及 X 的分布列.

Solution: 题目只给了方差的条件, 而 $\text{Var}(X) = \text{Var}(X-x)$, 故不妨先假设 X 只取 0, a 两个值, 且

$$\text{Var}(X) = a^2p - a^2p^2 = a^2p(1-p) = 1,$$

其中 $p = P(X = a)$, 由于 $p(1-p) \leq \frac{1}{4}$, 因此 $a \geq 2$. 且当 a 给定时, p 是可以解出的, 即

$$p^2 - p + \frac{1}{a^2} = 0 \implies p = \frac{1 \pm \sqrt{1 - \frac{4}{a^2}}}{2}.$$

所以 X 的分布列是

$$P(X = x) = \frac{1 + \sqrt{1 - \frac{4}{a^2}}}{2}, \quad P(X = x + a) = \frac{1 - \sqrt{1 - \frac{4}{a^2}}}{2},$$

或者是

$$P(X = x) = \frac{1 - \sqrt{1 - \frac{4}{a^2}}}{2}, \quad P(X = x + a) = \frac{1 + \sqrt{1 - \frac{4}{a^2}}}{2}.$$

四、(20 分) 设有随机向量 $\begin{pmatrix} X \\ Y \end{pmatrix}$, 已知它经过任意旋转变换后

$$\begin{pmatrix} \cos \alpha & \sin \alpha \\ -\sin \alpha & \cos \alpha \end{pmatrix} \begin{pmatrix} X \\ Y \end{pmatrix}$$

仍与 $\begin{pmatrix} X \\ Y \end{pmatrix}$ 同分布, 试解决下述问题:

(1) 求 $P(0 < Y < X)$;

(2) 求 $\frac{Y}{X}$ 的分布.

Solution:

(1) 设 X, Y 的密度函数是 $f_{X,Y}(x, y)$, 对旋转变换 $(U, V) = (X, Y)A^T$, 由变量变换法, 有

$$f_{U,V}(u, v) = f_{X,Y}((u, v)A) |A| = f_{X,Y}((u, v)A),$$

另一方面, 由于 U, V 与 X, Y 同分布, 故 $f_{U,V}(u, v) = f_{X,Y}(u, v)$, 综上所述, 有

$$f_{X,Y}(x, y) = f_{X,Y}((x, y)A),$$

对任意旋转变换 A 成立. 最直观的一个表达是

$$f_{X,Y}(r \cos \theta, r \sin \theta) = f_{X,Y}(r \cos \alpha, r \sin \alpha) = f_{X,Y}(r, 0) = f_{X,Y}(0, r).$$

作极坐标变换

$$\begin{cases} X = R \cos \Theta, \\ Y = R \sin \Theta, \end{cases}$$

由变量变换法, 有 (R, Θ) 的分布是

$$f_{R,\Theta}(r, \theta) = r f_{X,Y}(r \cos \theta, r \sin \theta) = r f_{X,Y}(r, 0) = r u(r), \quad r \in (0, +\infty), \theta \in (0, 2\pi),$$

可因式分解, 因此 R, Θ 独立, 且 $f_{\Theta}(\theta)$ 是常数, 故 $\Theta \sim U(0, 2\pi)$. 因此

$$P(0 < Y < X) = P\left(\Theta \in \left(0, \frac{\pi}{4}\right)\right) = \frac{1}{8}.$$

(2) $T = \frac{Y}{X} = \tan \Theta \sim \text{ch}(0, 1)$, 标准柯西分布, 可利用分布函数法说明: 这里要注意 Θ 取值是 $(0, 2\pi)$, 对不上反函数 $\arctan$ 的定义域, 要仔细讨论. 对任意 $t > 0$, 有

$$\begin{aligned}\{T \leq t\} &= \{\tan \Theta \leq t\} \\ &= \left\{ \Theta \in [0, \arctan t] \cup \left(\frac{\pi}{2}, \arctan t + \pi\right] \cup \left(\frac{3\pi}{2}, 2\pi\right] \right\},\end{aligned}$$

故 $P(T \leq t) = \frac{\pi + 2\arctan t}{2\pi} = \frac{1}{2} + \frac{\arctan t}{\pi}$, $t > 0$. 再讨论对任意 $t < 0$, 有

$$\begin{aligned}\{T \leq t\} &= \{\tan \Theta \leq t\} \\ &= \left\{ \Theta \in \left(\frac{\pi}{2}, \arctan t + \pi\right] \cup \left(\frac{3\pi}{2}, \arctan t + 2\pi\right] \right\}\end{aligned}$$

故 $P(T \leq t) = \frac{\pi + 2\arctan t}{2\pi} = \frac{1}{2} + \frac{\arctan t}{\pi}$, $t < 0$. 综上所述有

$$F_T(t) = \frac{1}{2} + \frac{\arctan t}{\pi}, \quad t \in \mathbb{R},$$

求导得

$$f_T(t) = \frac{1}{\pi(1+t^2)}, \quad t \in \mathbb{R},$$

这是标准柯西分布.

Remark: 无论对于概率密度函数或是广义概率密度 (如概率质量函数) $f(x, y)$, 正交变换 $(U, V) = (X, Y)A^T$ 的密度函数都满足 $f_{U,V}(u, v) = f_{X,Y}((u, v)A)$. 初等统计中, 很多人可能没有办法理解非连续分布也可以有 f , 另外一个方法是:

(1) 考虑一个幅角从 a 到 b 的扇形 $S(a, b)$, 根据旋转不变性有

$$P((X, Y) \in S(a, b)) = P((X, Y) \in S(a + \theta, b + \theta)), \quad \forall \theta,$$

因此有 $P((X, Y) \in S(0, \pi/4)) = P((X, Y) \in S(\pi/4, \pi/2)) = \cdots = P((X, Y) \in S(7\pi/4, 2\pi))$ 这八部分相等, 且它们相加为 1, 故 $P(0 < Y < X) = P((X, Y) \in S(0, \pi/4)) = 1/8$.

(2) $P(\Theta \in (a, b)) = P((X, Y) \in S(a, b)) = P((X, Y) \in S(0, b - a))$, 再用类似的分块相等的办法 (柯西方程, 见应坚刚划题 6.4) 求出

$$P((X, Y) \in S(0, b - a)) = \frac{b - a}{2\pi},$$

即 $P(\Theta \in (a, b)) \in \frac{b-a}{2\pi}$. 这是均匀分布, 再用 $\arctan$ 证明即可.

柯西方程: 由于不难推出可加性 $P((X, Y) \in S(0, a + b)) = P((X, Y) \in S(0, a)) + P((X, Y) \in S(0, b))$, 即有 $F(a + b) = F(a) + F(b)$, 这是柯西方程, 故有 $F(x) = xF(1)$, 均匀分布.

五、(20 分) 已知 $(X, Y) \sim N(0, 0; 1, 1; \frac{1}{2})$, 求 $P(X > 0, Y > 0)$.

Solution: 令 $W = \frac{2}{\sqrt{3}}(Y - \frac{1}{2}X)$, 则有 $EW = 0$, $\text{Var}(W) = 1$, 且 $\text{Cov}(X, W) = 0$, 故有 X, W 独立同服从标准正态分布. 进一步考虑到

$$P(X > 0, Y > 0) = P(-X > 0, -Y > 0) = P(X < 0, Y < 0),$$

发现

$$P(X > 0, Y > 0) = \frac{1}{2}P(XY > 0) = \frac{1}{2}P\left(\frac{Y}{X} > 0\right),$$

再利用 W 作处理, 即

$$\left\{\frac{Y}{X} > 0\right\} = \left\{\frac{\frac{\sqrt{3}W}{2} + \frac{1}{2}X}{X} > 0\right\} = \left\{\frac{W}{X} > -\frac{1}{\sqrt{3}}\right\}.$$

利用 $\frac{W}{X}$ 服从标准柯西分布, 有

$$P(X > 0, Y > 0) = \frac{1}{2} \int_{-\frac{\sqrt{3}}{3}}^{+\infty} \frac{1}{\pi(1+t^2)} dt = \frac{1}{3}.$$

六、(10 分) $X_1, \dots, X_n, \dots$ 是 i.i.d. 的二阶矩存在随机变量, $Y_n = \sum_{i=1}^n X_i$, 问: $\{\frac{Y_n}{n^2}\}$ 是否服从大数定律.

Solution: [法一]: 令 $Z_n = \frac{Y_n}{n^2}$, 直接计算协方差, 首先有

$$\text{Cov}(Y_k, Y_{k+l}) = \text{Cov}\left(\sum_{j=1}^k X_j, \sum_{j=1}^{k+l} X_j\right) = k \text{Var}(X_1),$$

进一步有, 当 $l \rightarrow \infty$, 有

$$\text{Cov}(Z_k, Z_{k+l}) = \frac{1}{k^2(k+l)^2} \text{Cov}(Y_k, Y_l) = \frac{\text{Var}(X_1)}{k(k+l)^2} \rightarrow 0,$$

由伯恩斯斯坦条件, $\{\frac{Y_n}{n^2}\}$ 服从大数定律.

[法二]: 由强大数律, 有 $Z_n = \frac{1}{n} \cdot \frac{Y_n}{n} \rightarrow 0 \cdot EX_1 = 0$, a.s., 由 stolz 定理, 有

$$\lim_{n \rightarrow \infty} \frac{\sum_{k=1}^n Z_k}{n} = \lim_{n \rightarrow \infty} Z_n = 0, \text{ a.s.}$$

七、(10 分) $X_1, \dots, X_n$ 是 i.i.d. 服从 $N(\mu, \sigma^2)$ 的随机变量, F 是其分布函数, 求 $-2 \sum_{i=1}^n \ln F(X_i)$ 的分布.

Solution: 首先记 $Y_i = F(X_i) \sim U(0, 1)$, 只需计算 $Z_1 = -2Y_1$ 的分布, 由分布函数法, 对 $z > 0$, 有

$$P(Z_1 \leq z) = P(-2 \ln Y_1 \leq z) = P(Y_1 \geq e^{-2z}) = 1 - e^{-2z},$$

这是均值为 1/2 的指数分布, 也是 $\chi^2(2)$ 分布, 由可加性, 得

$$-2 \sum_{i=1}^n \ln F(X_i) \sim \chi^2(2n).$$

八、(10 分) $X_1, \dots, X_6$ 是 i.i.d. 的 $U(0, 1)$ 随机变量, 求 $\text{Var}(2X_{(2)} + 3X_{(3)})$.

Solution: 直接计算, 有

$$\text{Var}(2X_{(2)} + 3X_{(3)}) = 4\text{Var}(X_{(2)}) + 9\text{Var}(X_{(3)}) + 12\text{Cov}(X_{(2)}, X_{(3)}),$$

而边际分布 $X_{(2)} \sim \text{Beta}(2, 5)$, $X_{(3)} \sim \text{Beta}(3, 4)$, 故两个方差项可以直接计算, 即

$$4\text{Var}(X_{(2)}) = \frac{4 \cdot 10}{7^2 \cdot 8} = \frac{10}{98}, \quad 9\text{Var}(X_{(3)}) = \frac{9 \cdot 12}{7^2 \cdot 8} = \frac{27}{98},$$

协方差项可以记公式 $\frac{i(n+1-j)}{(n+1)^2(n+2)}$ (2019 复旦应统第七题), 也可以先写出联合密度

$$g_{2,3}(x, y) = \frac{6!}{1!1!1!3!} x \cdot (1-y)^3 = \frac{6!}{1!3!} x(1-y)^3, \quad 0 < x < y < 1,$$

计算混合矩, 即

$$\begin{aligned} E(X_{(2)}X_{(3)}) &= \frac{6!}{3!} \int_0^1 \int_0^y x^2 y (1-y)^3 dx dy \\ &= \frac{6!}{3!3} \int_0^1 y^4 (1-y)^3 dy \\ &= \frac{6!3!4!}{3!8!3} = \frac{8}{56}. \end{aligned}$$

因此协方差为 $Cov(X_{(2)}, X_{(3)}) = \frac{8}{56} - \frac{6}{49} = \frac{2}{98}$. 将所有计算结果汇总得

$$Var(2X_{(2)} + 3X_{(3)}) = \frac{61}{98}.$$

九、(10 分) X_1, X_2, X_3 是 i.i.d. 的 $U(0, \theta)$ 随机样本, 设 $aX_{(1)}, bX_{(3)}$ 是 θ 的无偏估计, 求 a, b 并比较它们的何者更有效.

Solution: 由于 $\frac{X_{(1)}}{\theta} \sim Beta(1, 3)$, 故 $EX_{(1)} = \frac{1}{4}\theta$, $Var(X_{(1)}) = \frac{3}{80}\theta^2$, 故 $a = 4$, 且 $Var(aX_{(1)}) = \frac{3}{5}\theta^2$. 同理 $X_{(3)} \sim Beta(3, 1)$, 故 $EX_{(3)} = \frac{3}{4}\theta$, $Var(X_{(3)}) = \frac{3}{80}\theta^2$, 故 $b = \frac{4}{3}$, 且 $Var(bX_{(3)}) = \frac{1}{60}\theta^2$. 可以看出 $bX_{(3)}$ 更有效.

十、(10 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $N(\mu, 16)$ 随机样本, μ 的先验分布是 $N(a, b^2)$, 求后验分布.

Solution: 考虑充分统计量 $\bar{X}|\mu \sim N(\mu, \frac{16}{n})$, 有联合密度是

$$\begin{aligned} p(x, \mu) &= p(x|\mu) \pi(\mu) = C \cdot e^{-\frac{(x-\mu)^2}{2 \cdot \frac{16}{n}}} \cdot e^{-\frac{(\mu-a)^2}{2b^2}} \\ &= C \cdot e^{-\frac{(x-\mu)^2}{2 \cdot \frac{16}{n}}} \cdot e^{-\frac{(\mu-a)^2}{2b^2}} \\ &= C e^{-\frac{b^2(x-\mu)^2 + \frac{16}{n}(\mu-a)^2}{2 \cdot \frac{16}{n} b^2}} \\ &= C e^{-\frac{b^2(x-\mu)^2 + \frac{16}{n}(\mu-a)^2}{2 \cdot \frac{16}{n} b^2}} \\ &= C e^{-\frac{(\frac{16}{n} + b^2)\mu^2 - 2(b^2x + \frac{16}{n}a)\mu + (b^2x^2 + \frac{16}{n}a^2)}{2 \cdot \frac{16}{n} b^2}} \\ &= C_1(x) \exp \left\{ -\frac{\left(\mu - \frac{b^2x + \frac{16}{n}a}{b^2 + \frac{16}{n}} \right)^2}{2 \cdot \frac{16}{n} \frac{b^2}{b^2 + \frac{16}{n}}} \right\}, \end{aligned}$$

发现有一个正态分布的核, 故后验分布是

$$\mu|\bar{X} \sim N\left(\frac{b^2\bar{X} + \frac{16}{n}a}{b^2 + \frac{16}{n}}, \frac{\frac{16}{n}b^2}{b^2 + \frac{16}{n}}\right) = N\left(\frac{\frac{n}{16}\bar{X} + \frac{1}{b^2}a}{\frac{n}{16} + \frac{1}{b^2}}, \frac{1}{\frac{n}{16} + \frac{1}{b^2}}\right).$$

可以看出后验均值是样本信息与先验信息的加权平均.

十一、(10 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $U(0, \theta)$ 随机样本, 考虑假设检验问题

$$H_0: \theta \leq 1 \quad \text{vs} \quad H_1: \theta > 1$$

构造拒绝域 $W = \{X_{(n)} \geq c\}$. 回答下述问题:

(1)(5 分) $\alpha = 0.05$, 求 c ;

(2)(5 分) 当 $\theta = 1.5$, 为使得犯第二类错误的概率 $\beta \leq 0.1$, 求至少要多少样本量.

Solution:

(1) 为使显著性水平为 0.05, 有

$$0.05 = \sup_{\theta \leq 1} P_{\theta}(X_{(n)} \geq c) = P_{\theta=1}(X_{(n)} \geq c) = (1-c)^n,$$

解得 $c = 0.95^{\frac{1}{n}}$.

(2) 犯第二类错误的概率是

$$\beta(1.5) = P_{\theta=1.5}(X_{(n)} < 0.95^{\frac{1}{n}}) = \left(\frac{0.95^{\frac{1}{n}}}{1.5}\right)^n = \frac{0.95}{1.5^n},$$

令其小于等于 0.1, 得

$$\frac{0.95}{1.5^n} \leq 0.1 \Rightarrow n \geq \frac{\ln 9.5}{\ln 1.5} \Rightarrow n \geq 6.$$

复旦大学-432 统计学-2023 年

一、(10 分) 从 1 到 $2n+1$ 这些整数里任意挑选 2 个, 求其中一个大于 $n+1$, 另外一个小于 $n+1$ 的概率.

Solution: $\#\Omega = C_{2n+1}^2 = \frac{(2n+1) \cdot 2n}{2 \cdot 1} = n(2n+1)$, $\#A = C_n^1 \cdot C_{n+1}^1 = n^2$, 因此

$$P(A) = \frac{n^2}{n(2n+1)} = \frac{n}{2n+1}.$$

二、(10 分) 证明: 二元正态分布的边际分布是正态分布. 但两个边际正态分布联合却不一定是正态分布, 请举例说明.

Solution: 二元正态 $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$, 令

$$U = \frac{X - \mu_1}{\sigma_1}, \quad V = \frac{Y - \mu_2}{\sigma_2},$$

容易验证 $(U, V) \sim N(0, 0; 1, 1; \rho)$, 再考虑 $Z = \frac{U - \rho V}{\sqrt{1 - \rho^2}}$, 得到

$$(U, Z) \sim N(0, 0; 1, 1; 0),$$

根据独立性直接得到 $U \sim N(0, 1)$, 故 $X = \sigma_1 U + \mu_1 \sim N(\mu_1, \sigma_1^2)$. 同理有 $Y \sim N(\mu_2, \sigma_2^2)$, 结论成立.

反之, 直接考虑 $X \sim N(0, 1)$, 以及 $Y = X$, 而 (X, Y) 没有二元密度函数, 不构成二元正态.

三、(10 分) 设 $X \sim N(0, 1)$, $Y \sim \text{Exp}(1)$, 且它们独立, 求 $\frac{X}{Y}$ 的密度函数.

[考点透析] 我们在三模出了一道计算方式上几乎一致的题, 可以先看这个, 作为练习: 对于 $X \sim N(a, b^2)$, 尝试求 $E|X|$.

对于一个 $Z \sim N(-a, 1)$, 有 $E|Z| = E|W - a|$, 这里 $W \sim N(0, 1)$, 故

$$\begin{aligned} E|Z| &= E|W - a| = E[(W - a)I_{\{W > a\}} + (a - W)I_{\{W < a\}}] \\ &= E[WI_{\{W > a\}}] - E[WI_{\{W < a\}}] + aP(W < a) - aP(W > a) \\ &= E[WI_{\{W > a\}}] - E[WI_{\{W < a\}}] + a(2\Phi(a) - 1), \end{aligned}$$

并且对于计算概率, (W, a) 和 $(-W, a)$ 是完全一致的, 因此

$$E[WI_{\{W < a\}}] = E[-WI_{\{-W < a\}}] = -E[WI_{\{W > -a\}}],$$

所以有 $E[WI_{\{W > a\}}] - E[WI_{\{W < a\}}] = E[WI_{\{-a < W < a\}}] + 2E[WI_{\{W > a\}}] = \sqrt{\frac{2}{\pi}} e^{-\frac{a^2}{2}}.$

因此对 $Y \sim N(a, b^2)$, 有 $E|Y| = \sqrt{\frac{2}{\pi}} b e^{-\frac{a^2}{2b^2}} + a(2\Phi(\frac{a}{b}) - 1).$

现在再回到本题, 利用商的分布, 有 $Z = \frac{X}{Y}$ 的 p.d.f. 是

$$\begin{aligned} f_Z(z) &= \int_0^{+\infty} \frac{1}{\sqrt{2\pi}} v e^{-\frac{z^2 v^2}{2} - v} dv \\ &= \frac{1}{\sqrt{2\pi}} e^{\frac{1}{2z^2}} \int_0^{+\infty} v e^{-\frac{z^2}{2} (v + \frac{1}{z^2})^2} dv \\ &= \frac{1}{|z|} e^{\frac{1}{2z^2}} \int_0^{+\infty} \frac{1}{\sqrt{2\pi} \frac{1}{z^2}} v e^{-\frac{(v + \frac{1}{z^2})^2}{2 \cdot \frac{1}{z^2}}} dv = \frac{1}{|z|} e^{\frac{1}{2z^2}} E[VI_{\{V > 0\}}]. \end{aligned}$$

其中 $V \sim N(-\frac{1}{z^2}, \frac{1}{z^2})$. 我们直接探讨 $V \sim N(a, 1)$ 即可, 其中 $a > 0$, 有

$$E[VI_{\{V > 0\}}] = E[(V - a)I_{\{V - a > -a\}}] + aE[I_{\{V - a > -a\}}] = E[WI_{\{W > -a\}}] + a(1 - \Phi(-a)),$$

这里 $W \sim N(0, 1)$, 我们前面已经算过 $E[W I_{\{W>a\}}] = \sqrt{\frac{1}{2\pi}} e^{-\frac{a^2}{2}}$, 而

$$E[W I_{\{W>-a\}}] = E[W I_{\{-a<W<a\}}] + E[W I_{\{W>a\}}] = \sqrt{\frac{1}{2\pi}} e^{-\frac{a^2}{2}}.$$

再考虑 $V \sim N(a, b^2)$, 有

$$E[V I_{\{V>0\}}] = b E\left[\frac{V}{b} I_{\{\frac{V}{b}>0\}}\right] = b \left[\sqrt{\frac{1}{2\pi}} e^{-\frac{a^2}{2b^2}} + \frac{a}{b} \left(1 - \Phi\left(-\frac{a}{b}\right)\right) \right],$$

因为有 $\frac{V}{b} \sim N(\frac{a}{b}, 1)$, 化简得

$$E[V I_{\{V>0\}}] = \sqrt{\frac{1}{2\pi}} b e^{-\frac{a^2}{2b^2}} + a \left(1 - \Phi\left(-\frac{a}{b}\right)\right).$$

这里代入 $a = -\frac{1}{z^2}$, $b = \frac{1}{|z|}$, 则有

$$E[V I_{\{V>0\}}] = \sqrt{\frac{1}{2\pi}} \frac{1}{|z|} e^{-\frac{1}{2z^2}} - \frac{1}{z^2} \left(1 - \Phi\left(\frac{1}{|z|}\right)\right),$$

因此有

$$f_Z(z) = \sqrt{\frac{1}{2\pi}} \frac{1}{z^2} - \frac{1}{|z|^3} e^{\frac{1}{2z^2}} \left(1 - \Phi\left(\frac{1}{|z|}\right)\right),$$

去除瑕点, 写为

$$f_Z(z) = \begin{cases} \sqrt{\frac{1}{2\pi}} \frac{1}{z^2} - \frac{1}{|z|^3} e^{\frac{1}{2z^2}} \left(1 - \Phi\left(\frac{1}{|z|}\right)\right), & z \neq 0, \\ 0, & z = 0. \end{cases}$$

四、(10 分) 设 $X \sim N(0, 1)$, $Y \sim B(1, p)$, 且它们独立, 求 $X + Y$ 的概率分布.

Solution: 利用微分法, 令 $Z = X + Y$, 有

$$\begin{aligned} P(Z = z) &= P(X = z, Y = 0) + P(X = z - 1, Y = 1) \\ &= (1 - p) \varphi(z) + p \varphi(z - 1), \quad z \in R. \end{aligned}$$

对应的分布函数是

$$F(z) = (1 - p) \Phi(z) + p \Phi(z - 1), \quad z \in R.$$

五、(10 分) 设 Y 是非负随机变量, 且 $0 < \text{Var}(Y) < \infty$, 证明

$$P(Y > 0) \geq \frac{(EY)^2}{E(Y^2)}.$$

Solution: 由于 $Y = 0$ 时对求期望不影响, 故

$$E(I_{\{Y>0\}}^2) E(Y^2) \geq [E(Y I_{\{Y>0\}})]^2 = (EY)^2,$$

而 $E(I_{\{Y>0\}}^2) = P(I_{\{Y>0\}} = 1) = P(Y > 0)$, 结论得证.

六、(15 分) 设 $\alpha > 0, \beta \geq 0, \xi$ 是随机变量. 证明: $\lim_{x \uparrow +\infty} x^{\alpha+\beta} P(|\xi| > x) = 0$ 当且仅当

$$\lim_{x \uparrow +\infty} x^\alpha E(|\xi|^\beta I_{|\xi|>x}) = 0.$$

Solution: 充分性用马尔可夫型不等式很容易证明. 对于必要性: 我们先证明一个等式:

$$\begin{aligned}\beta \int_x^{+\infty} t^{\beta-1} P(|\xi| > t) dt &= \beta \int_x^{+\infty} \int_t^{+\infty} t^{\beta-1} dF(s) dt \\&= \beta \int_x^{+\infty} \int_x^s t^{\beta-1} dt dF(s) \\&= \int_x^{+\infty} (s^\beta - x^\beta) dF(s) \\&= E\left(|\xi|^\beta I_{\{|\xi|>x\}}\right) - x^\beta P(|\xi| > x).\end{aligned}$$

因此, 有

$$x^\alpha \left(E|\xi|^\beta I_{\{|\xi|>x\}} \right) = x^{\alpha+\beta} P(|\xi| > x) + \beta x^\alpha \int_x^{+\infty} t^{\beta-1} P(|\xi| > t) dt.$$

其中, 用洛必达法则, 有

$$\lim_{x \rightarrow +\infty} x^\alpha \int_x^{+\infty} t^{\beta-1} P(|\xi| > t) dt = \lim_{x \rightarrow +\infty} \frac{\int_x^{+\infty} t^{\beta-1} P(|\xi| > t) dt}{x^{-\alpha}} = \lim_{x \rightarrow +\infty} \frac{x^{\beta-1} P(|\xi| > x)}{\alpha x^{-\alpha-1}} = 0$$

命题得证.

七、(15 分) $X \sim N(0, 1)$, f 是有界连续函数, 其导函数也有界连续求证:

(1) (Stein 引理) $E[f(X)X] = E[f'(X)]$;

(2) (Poincare 不等式) $E[(f(X) - Ef(X))^2] \leq E[(f'(X))^2]$.

Solution: (1) 利用分部积分法, 有

$$\begin{aligned}E[f(X)X] &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} f(x) x e^{-\frac{x^2}{2}} dx = -\frac{1}{\sqrt{2\pi}} \left[f(x) e^{-\frac{x^2}{2}} \Big|_{-\infty}^{+\infty} - \int_{-\infty}^{+\infty} f'(x) e^{-\frac{x^2}{2}} dx \right] \\&= 0 + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} f'(x) e^{-\frac{x^2}{2}} dx = E[f'(X)].\end{aligned}$$

(2) [法一]: 概率论方法. 利用方差性质以及柯西-施瓦茨不等式, 有

$$\begin{aligned}\text{Var}(f(X)) &\leq E[(f(X) - f(0))^2] = E\left[\left(\int_0^X f'(t) dt\right)^2\right] \\&\leq E\left[\left(\int_0^X (f'(t))^2 dt\right) \left(\int_0^X 1^2 dt\right)\right] \\&= E\left[X \left(\int_0^X (f'(t))^2 dt\right)\right] \\&= E[(f'(X))^2].\end{aligned}$$

最后一步用了第一问的 Stein 引理.

[法二]: 利用 L^2 空间 (二次可积函数的全体) 的正交展开, 任意一个 $f \in L^2$ 都可以写为正交 Hermite 多项式的形式 (这也称为广义傅里叶展开), 即

$$f(x) = a_0 + \sum_{k=1}^{\infty} a_k \mathcal{H}_k(x),$$

其中 $\{\mathcal{H}_0, \mathcal{H}_1, \mathcal{H}_2, \dots\}$ 是 Hermite 正交函数列 ($\mathcal{H}_0(x) = 1$), 满足

$$E[\mathcal{H}_k(X)] = 0, \quad E[\mathcal{H}_k^2(X)] = 1, \quad E[\mathcal{H}_k(X) \mathcal{H}_j(X)] = 0, k \neq j,$$

其中系数由 $a_k = E[f(X)\mathcal{H}_k(X)]$ 给出, 截止目前都和傅里叶展开几乎无差距. 而 Hermite 正交函数列有一个性质是 $\mathcal{H}'_k(x) = \sqrt{k}\mathcal{H}_{k-1}(x)$, 这个性质类似对应傅里叶展开里的 $(\cos nx)' = -n \sin nx$.

因此, 利用该展开式, 我们有

$$\begin{aligned} \text{Var}(f(X)) &= E[f^2(X)] - a_0^2 = E\left[\left(\sum_{k=0}^{\infty} a_k \mathcal{H}_k(x)\right)^2\right] - a_0^2 \\ &= E\left[\sum_{k=0}^{\infty} a_k^2 \mathcal{H}_k^2(x)\right] - a_0^2 = \sum_{k=1}^{\infty} a_k^2. \end{aligned}$$

同时, 根据 f, f' 有界, 求和与求导交换次序我们有

$$f'(x) = \left(a_0 + \sum_{k=1}^{\infty} a_k \mathcal{H}_k(x)\right)' = \sum_{k=1}^{\infty} a_k \mathcal{H}'_k(x) = \sum_{k=1}^{\infty} a_k \sqrt{k} \mathcal{H}_{k-1}(x),$$

因此发现

$$E[(f'(X))^2] = \sum_{k=1}^{\infty} a_k^2 k \geq \sum_{k=1}^{\infty} a_k^2 = \text{Var}(f(X)).$$

八、(20 分) (1) 请写出 $\mathcal{P}(\lambda)$ 的分布列;

(2) 请证明 $\mathcal{P}(\lambda)$ 的可加性;

(3) 利用中心极限定理证明: $\lim_{n \rightarrow \infty} e^{-n} \sum_{k=0}^n \frac{n^k}{k!} = \frac{1}{2}$.

Solution: (1) 直接写出:

$$P(X=k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

(2) 用特征函数, 泊松分布的特征函数是

$$e^{\lambda(e^{it}-1)},$$

两个独立的泊松分布, $X \sim \mathcal{P}(\lambda_1)$, $Y \sim \mathcal{P}(\lambda_2)$, 且独立, 我们有 $X+Y$ 的特征函数是

$$e^{(\lambda_1+\lambda_2)(e^{it}-1)},$$

由唯一性定理, $X+Y \sim \mathcal{P}(\lambda_1+\lambda_2)$.

(3) 设 $Y_n \sim \mathcal{P}(n)$, 题设概率等同于 $P(Y_n \leq n)$, 而由泊松分布可加性, 我们设 $X_1, X_2, \dots, X_n$ 是 i.i.d. 的 $\mathcal{P}(1)$, 则有 $Y_n = X_1 + \dots + X_n$, 根据中心极限定理, 有

$$\lim_{n \rightarrow \infty} P(Y_n \leq n) = \lim_{n \rightarrow \infty} P\left(\frac{\sum_{k=1}^n X_k - n}{n} \leq 0\right) = \Phi(0) = \frac{1}{2}.$$

九、(10 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 来自 $U(0, \theta)$ 的随机样本, 其次序统计量是 $(X_{(1)}, \dots, X_{(n)})$. 对于假设检验问题

$$H_0: \theta \geq 5 \quad \text{vs} \quad H_1: \theta < 5$$

给定拒绝域 $W = \{X_{(n)} \leq 4\}$, 要求第一类错误小于 0.01, 问 n 至少是多少?

Solution: 第一类错误是

$$\alpha = \sup\{P_\theta(X \in W) : \theta \geq 5\} = P_5(X_{(n)} \leq 4) = \left(\frac{4}{5}\right)^n,$$

令其 ≤ 0.01 , 解得

$$n \geq \frac{\ln(0.01)}{\ln(\frac{4}{5})} = \frac{-2 \ln 10}{2 \ln 2 - \ln 5} = \frac{2 \ln 10}{\ln 5 - 2 \ln 2}.$$

用计算器可以算出 $n \geq 21$, 没有计算器就只能得到上面结论.

十、(10 分) 设总体为均匀分布 $U(\theta, \theta + 1)$, θ 的先验分布是 $U(5, 8)$, 现有观测值: 6.1, 6.5, 6.7, 6.9. 求 θ 的后验分布.

Solution: 条件似然函数是

$$p(x|\theta) = I_{\{x_{(n)-1} < \theta < x_{(1)}\}},$$

故 (x, θ) 的联合密度是

$$h(x, \theta) = \frac{1}{3} I_{\{x_{(n)-1} < \theta < x_{(1)}\}} = \frac{1}{3} I_{\{5.9 < \theta < 6.1\}},$$

积掉 θ , 即 $p_X(x) = \frac{0.2}{3}$, 故有

$$\pi(\theta|x) = \frac{1}{0.2} I_{\{5.9 < \theta < 6.1\}},$$

即 $U(5.9, 6.1)$.

十一、(15 分) 设有来自总体 $f(x; \theta)$ 的 i.i.d. 样本 $X_1, \dots, X_n$.

(1) 叙述充分统计量的定义;

(2) 若 $f(x; \theta) = \theta(1 - \theta)^x, x = 0, 1, \dots$, 判断 $T = \sum_{k=1}^n X_k$ 是否为充分统计量.

Solution: (1) T 是 θ 的充分统计量意味着条件分布

$$P(X = x | T = t)$$

与 θ 无关, 即样本中 T 已经蕴含了 θ 的所有信息.

其等价定义是“因子分解定理”, 即如果联合密度可以写成

$$p(X; \theta) = C(X) S(\theta) h(\theta; T(X))$$

的形式, 则 T 是 θ 的充分统计量.

(2) 联合密度为

$$p(X; \theta) = \theta^n (1 - \theta)^{\sum_{k=1}^n x_k} = \theta^n \cdot (1 - \theta)^{\sum_{k=1}^n x_k},$$

根据因子分解定理, $T = \sum_{k=1}^n X_k$ 是充分统计量.

十二、(15 分) 设有来自 $f(x; \theta) = \theta x^{\theta-1}, 0 < x < 1$ 的 i.i.d. 样本 $X_1, \dots, X_n$.

(1) 求 $g(\theta) = \frac{1}{\theta}$ 的 MLE;

(2) 第 (1) 问的 MLE 是否为有效估计?

Solution: (1) 似然函数和对数似然函数是

$$L(\theta) = \theta^n \prod_{k=1}^n x_k^{\theta-1}, \quad \ln L(\theta) = (\theta - 1) \sum_{k=1}^n \ln x_k + n \ln \theta,$$

求导置零, 得 $\hat{\theta} = -\frac{\sum_{k=1}^n \ln x_k}{n}$.

(2) 可以验证的是, 令 $Y = -\ln X$, 有

$$P(Y = y) = P(-\ln X = y) = P(X = e^{-y}) = \theta e^{-(\theta-1)y} \left| d(e^{-y}) \right| = \theta e^{-\theta y} dy,$$

故有 $E(Y) = \frac{1}{\theta}, \text{Var}(Y) = \frac{1}{\theta^2}$, 因而 $E(\hat{\theta}) = \frac{1}{\theta}, \text{Var}(\hat{\theta}) = \frac{1}{n\theta^2}$. 而对应的 Fisher 信息量是

$$I(\theta) = E \left[\left(\frac{\partial \ln f}{\partial \theta} \right)^2 \right] = E \left[\left(-\ln X - \frac{1}{\theta} \right)^2 \right] = \frac{1}{\theta^2},$$

故 C-R 下界是

$$\text{CR} = \frac{[g'(\theta)]^2}{nI(\theta)} = \frac{1}{n\theta^2} = \text{Var}(\hat{\theta}).$$

因此 $\hat{\theta}$ 是有效估计.

复旦大学-432 统计学-2024 年

一、(10 分) 8 部车随机地停在一列 12 个位置的停车场内, 求 4 个空位恰好连在一起的概率.

Solution:

总样本点个数为 $\#\Omega = C_{12}^4$, 而 4 个空位连在一起的情况数只有 $\#A = 9$, 因此 $P(A) = \frac{1}{55}$.

Remark: 应坚刚《概率论》原题.

二、(10 分) 将 n 个球随机地放进 n 个盒子中, 记空盒个数为 X , 求 X 的期望与方差.

Solution: 记 $X_i = 1$ 表示第 i 个盒子无球, 则有 $X = \sum_{i=1}^n X_i$, 故有期望

$$E(X) = nE(X_1) = n \left(1 - \frac{1}{n}\right)^n,$$

以及方差

$$\begin{aligned} \text{Var}(X) &= n\text{Var}(X_1) + n(n-1)\text{Cov}(X_1, X_2) \\ &= n \left[\left(1 - \frac{1}{n}\right)^n \cdot \left(1 - \left(1 - \frac{1}{n}\right)^n\right) \right] + n(n-1) \left[\left(1 - \frac{2}{n}\right)^n - \left(1 - \frac{1}{n}\right)^{2n} \right]. \end{aligned}$$

Remark: 《考前一天 20 个知识点》命中. 实际也是九阳神功中科大 812-2019-第一题重现.

三、(10 分) 设区域 D 是 $(0,0)$, $(1,0)$, $(1,1)$ 围成的三角形区域, (X,Y) 服从 D 上的均匀分布, 求 $\rho(X,Y)$.

Solution: $S_D = \frac{1}{2}$, 于是 $f(x,y) = \begin{cases} 2, & (x,y) \in D, \\ 0, & \text{其他.} \end{cases}$ 于是

$$\begin{aligned} EX &= \int_0^1 2x \, dx \int_0^x dy = \int_0^1 2x^2 \, dx = \frac{2}{3}, \\ EX^2 &= \int_0^1 2x^2 \, dx \int_0^x dy = \int_0^1 2x^3 \, dx = \frac{1}{2}, \\ \text{Var}(X) &= \frac{1}{2} - \frac{4}{9} = \frac{1}{18}, \\ EY &= \int_0^1 2 \, dx \int_0^x y \, dy = \int_0^1 x^2 \, dx = \frac{1}{3}, \\ EY^2 &= \int_0^1 2 \, dx \int_0^x y^2 \, dy = \int_0^1 \frac{2}{3} x^3 \, dx = \frac{1}{6}, \\ \text{Var}(Y) &= \frac{1}{6} - \frac{1}{9} = \frac{1}{18}, \end{aligned}$$

而 $EXY = \int_0^1 2x \, dx \int_0^x y \, dy = \int_0^1 x^3 \, dx = \frac{1}{4}$, 于是

$$\text{Cov}(X,Y) = EXY - EXEY = \frac{1}{4} - \frac{2}{3} \cdot \frac{1}{3} = \frac{1}{36},$$

则 $\rho_{XY} = \frac{\text{Cov}(X,Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\frac{1}{36}}{\sqrt{\frac{1}{18} \cdot \frac{1}{18}}} = \frac{1}{2}$.

Remark: 九阳神功北大 849-2017-第二题重现.

四、(10 分) 设 X_1, X_2 独立同服从 $N(\mu, \sigma^2)$, 证明: $E \max\{X_1, X_2\} = \mu + \frac{\sigma}{\sqrt{\pi}}$.

Solution: 利用 $\max\{X_1, X_2\} = \frac{X_1+X_2+|X_1-X_2|}{2}$ 即可, 详见茆书 3.4.18 原题.

Remark: 《考前一天 20 个知识点》命中. 同时也是茆书 3.4.18 原题.

五、(10 分) 证明: $E(|X|)$ 存在与 $\sum_{k=0}^{\infty} P(|X| > k)$ 等价.

Solution: 设 F 是 $Y = |X|$ 的分布函数, 则

$$E(Y) = \int_0^{+\infty} y dF(y) = \int_0^{+\infty} \int_0^y dt dF(y) = \int_0^{+\infty} \int_t^{+\infty} dF(y) dt = \int_0^{+\infty} P(Y > t) dt,$$

而 $P(Y > t)$ 关于 t 单调递减趋于 0, 根据积分-级数的同收敛性质, 这个积分和 $\sum_{k=0}^{\infty} P(Y > k)$ 同敛散.

Remark: 《考前一天 20 个知识点》命中.

六、(10 分) X, Y 独立同服从标准柯西分布, 密度函数是 $f(x) = \frac{1}{\pi(1+x^2)}$, 证明: $\frac{X+Y}{2}$ 也服从柯西分布.

Solution: 设 $X \sim \text{Cau}(1, 0)$, 则其特征函数是 $\varphi_X(t) = e^{-|t|}$, 因此有 $Z = \frac{X+Y}{2}$ 的特征函数是

$$\varphi_Z(t) = E[e^{itZ}] = E[e^{i\frac{t}{2}(X+Y)}] = E[e^{i\frac{t}{2}X}] E[e^{i\frac{t}{2}Y}] = e^{-|t|},$$

由唯一性定理, $Z = \frac{X+Y}{2} \sim \text{Cau}(1, 0)$.

Remark: 茆书 4.2.11 原题, 同时也是应坚刚《概率论》原题.

七、(20 分) (Borel-Cantelli 引理) 对于事件序列 A_n , 记 $A = \bigcap_{k=1}^{\infty} \bigcup_{n=k}^{\infty} A_n$.

(1)(10 分) 若 $\sum P(A_n) < \infty$, 则 $P(A) = 0$.

(2)(10 分) 若 A_n 是独立序列, 则 $P(A) = 1$ 等价于 $\sum P(A_n) = \infty$.

Solution: 可在下述视频课程找到解答: (i) 大师兄《一苇渡江》强化班强大数律课程; (ii) 大师兄《一苇渡江》专题班概率极限理论课程; (iii) 大师兄《一苇渡江》李贤平概率论基础-概率极限定理课程; (iv) 大师兄《一苇渡江》何书元概率论-5.4 概率极限理论... 或翻看书本李贤平《概率论基础》第五章.

Remark: Borel-Cantelli 引理属于书本定理, 主流概率论书籍上都能找到这个定理的证明. 这题属于试卷上比较难的, 如果没有复习 Borel-Cantelli 引理的话不是很容易写出来.

八、(20 分) 设独立序列满足 $P(\xi_n = \pm n^\delta) = \frac{1}{2}$.

(1)(10 分) 给出 $\{\xi_n\}$ 服从大数定律的充要条件, 即给出 δ 的范围.

(2)(10 分) 详细证明第 (1) 问的结论.

Solution: (1) 服从大数定律指 $\frac{S_n}{n} \xrightarrow{P} 0$, 其中 $S_n = \sum_{i=1}^n X_i$, 利用切比雪夫不等式, 有

$$P\left(\left|\frac{S_n}{n}\right| > \varepsilon\right) \leq \frac{1}{n^2\varepsilon^2} \text{Var}(S_n) = \frac{1}{n^2\varepsilon^2} \sum_{i=1}^n \text{Var}(\xi_i) = \frac{1}{\varepsilon^2} \frac{\sum_{i=1}^n i^{2\delta}}{n^2},$$

根据 Stolz 公式, 有

$$\lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n i^{2\delta}}{n^2} = \lim_{n \rightarrow \infty} \frac{n^{2\delta}}{n^2 - (n-1)^2} = \lim_{n \rightarrow \infty} \frac{n^{2\delta}}{2n},$$

因此可以看出, 如果 $\delta < \frac{1}{2}$, 则 $P\left(\left|\frac{S_n}{n}\right| > \varepsilon\right) \rightarrow 0$, 即大数定律成立. 而如果 $\delta \geq \frac{1}{2}$, 则 $\text{Var}\left(\frac{S_n}{n}\right) = \frac{\sum_{i=1}^n i^{2\delta}}{n^2}$ 并不收敛于 0. 因此可以合理地猜测: $\{\xi_n\}$ 服从大数定律的充要条件是 $\delta < \frac{1}{2}$.

(2) 现在进行详细证明, 首先对于任意 $\delta > -\frac{1}{2}$, 我们可以作分解 $\frac{S_n}{n} = \frac{S_n}{n^{\delta+\frac{1}{2}}} \cdot \frac{1}{n^{\frac{1}{2}-\delta}}$. 针对 S_n , 可以求出 $B_n^2 := \text{Var}(S_n) = \sum_{i=1}^n i^{2\delta} \sim \frac{1}{2\delta+1} n^{2\delta+1}$, 且显然 $|\xi_n| \leq n^\delta \ll B_n$, 因此李雅普诺夫条件成立, 故有中心极限定理 $\frac{S_n}{n^{\delta+\frac{1}{2}}} \xrightarrow{d} N(0, 2\delta+1)$.

(i) 如果 $\delta < \frac{1}{2}$, 则有 $\frac{1}{n^{\frac{1}{2}-\delta}} \rightarrow 0$, 故 $\frac{S_n}{n} = \frac{S_n}{n^{\delta+\frac{1}{2}}} \cdot \frac{1}{n^{\frac{1}{2}-\delta}} \xrightarrow{P} 0$.

(ii) 如果 $\delta = \frac{1}{2}$, 则有 $\frac{1}{n^{\frac{1}{2}-\delta}} = 1$, 故 $\frac{S_n}{n} = \frac{S_n}{n^{\delta+\frac{1}{2}}} \cdot \frac{1}{n^{\frac{1}{2}-\delta}} \xrightarrow{d} N(0, 2)$.

(iii) 如果 $\delta > \frac{1}{2}$, 则有 $\frac{1}{n^{\frac{1}{2}-\delta}} \rightarrow \infty$, 故 $\frac{S_n}{n} = \frac{S_n}{n^{\delta+\frac{1}{2}}} \cdot \frac{1}{n^{\frac{1}{2}-\delta}} \xrightarrow{P} \infty$.

综上所述, $\{\xi_n\}$ 服从大数定律的充要条件是 $\delta < \frac{1}{2}$.

Remark: 本题充分性比较简单, 运用切比雪夫不等式即可, 必要性则需要证明“不服从大数定律”, 相对较难, 于茆书 4.3.16 曾经考察, 如果没有做过相关内容, 可能不是很容易写出来.

九、(10 分) 设有来自 $U(-\theta, \theta)$ 的简单随机样本 $X_1, \dots, X_n$, 其中 $\theta > 0$.

(1) 证明: $\max\{|X_1|, \dots, |X_n|\}$ 是 θ 的充分统计量.

(2) 求 θ 的 MLE.

Solution: (1) 记 $Y_i = |X_i|$, 则有 $Y_i \sim U(0, \theta)$, 似然函数是 $L(\theta) = \frac{1}{\theta^n} I_{\{0 < \theta < Y_{(n)}\}}$, 根据因子分解定理, $Y_{(n)} = \max\{|X_1|, \dots, |X_n|\}$ 是 θ 的充分统计量.

(2) 可以看出, $L(\theta) = \frac{1}{\theta^n} I_{\{0 < \theta < Y_{(n)}\}}$ 中 $\frac{1}{\theta^n}$ 是 θ 的单调减函数, 因此当 θ 取到最大值 $Y_{(n)}$ 时, 似然函数达到最大, 故 $\hat{\theta} = \max\{|X_1|, \dots, |X_n|\}$.

Remark: 本题属于多次考察的常规题, 一苇渡江课程已经讲过.

十、(10 分) 设有来自 $\mathcal{P}(\sqrt{\lambda})$ 的简单随机样本 $X_1, \dots, X_n$, 其中 $\lambda > 0$.

(1) 求 λ 的 MLE.

(2) 判断 (1) 中的估计量是否无偏.

Solution: (1) 根据泊松分布的结论, $\sqrt{\lambda} = \bar{X}$, 根据 MLE 的不变性, 有 $\hat{\lambda} = \bar{X}^2$.

(2) $E\bar{X}^2 = E(\bar{X})^2 + \text{Var}(\bar{X}) = E(X_1)^2 + \frac{1}{n}\text{Var}(X_1) = \lambda + \frac{\sqrt{\lambda}}{n}$, 不无偏.

Remark: 本题属于多次考察的常规题, 考察 MLE 不变性.

十一、(15 分) 设有来自 $U(\theta, \theta + 1)$ 的简单随机样本 $X_1, \dots, X_n$, 考虑假设检验问题:

$$H_0: \theta = 0 \quad H_1: \theta > 0,$$

定义拒绝域 $W = \{X_{(1)} > k\} \cup \{X_{(n)} > 1\}$, 要使犯第一类错误对概率不足 0.05, 求 k 至少为多少?

Solution: 求第一类错误概率, 有

$$\alpha = P_{\theta=0}(\mathbf{x} \in W) = P_{\theta=0}(X_{(1)} > k) + P_{\theta=0}(X_{(n)} > 1) = (1-k)^n,$$

令 $\alpha \leq 0.05$, 解得 $k \geq 1 - 0.05^{\frac{1}{n}}$.

Remark: 本题属于多次考察的常规题, 类似于九阳神功复旦 432-2023-第九题.

十二、(15 分) 设有来自 $U(0, \theta)$ 的简单随机样本 $X_1, \dots, X_n$, 其中参数 θ 的先验分布是 $\pi(\theta) = \frac{2}{\theta^3}, \theta > 1$. 现有 4 个观测值: 0.1, 1.2, 1.5, 0.9, 求参数的后验分布.

Solution: $\mathbf{x}$ 关于 θ 的条件密度是

$$f(\mathbf{x}|\theta) = \frac{1}{\theta^n}, \quad \theta > x_{(n)},$$

因此联合密度是

$$p(\mathbf{x}, \theta) = \frac{2}{\theta^{n+3}}, \quad \theta > \max\{1, x_{(n)}\},$$

因此有后验密度为

$$\pi(\theta|\mathbf{x}) = \frac{p(\mathbf{x}, \theta)}{p_X(\mathbf{x})} = C(\mathbf{x}) \frac{2}{\theta^{n+3}}, \quad \theta > \max\{1, x_{(n)}\},$$

代入数据得 $\pi(\theta|\mathbf{x}) = C \frac{2}{\theta^7}, \theta > 1.5$, 为满足正则性, 有 $\pi(\theta|\mathbf{x}) = \frac{6 \cdot 1.5^6}{\theta^7}, \theta > 1.5$.

Remark: 茆书 6.5.8 原题.

复旦大学-432 统计学-2025 年

1. (10 分) 你和李四一起玩骰子, 一共有 A, B, C 三种骰子, 分别为 $A = "115555"$, $B = "333444"$, $C = "222666"$, 李四先从中选, 你从剩下的里面再选, 请问你的策略是什么? (即李四选 A, B, C 其中一个, 你如何应对使得投出来的点数大于他的概率更大?)

Solution:

情况 1, 李四选择骰子 A : 选骰子 B : A 掷出 1 时, B 掷出 3 或 4; A 掷出 5 时, B 不可能比他大, 于是点数大于 A 的概率: $\frac{1}{3} \times 1 = \frac{1}{3}$ 选骰子 C : A 掷出 1 时, C 掷出 2 或 6; A 掷出 5 时, C 掷出 6 才比他大, 于是点数大于 A 的概率: $\frac{1}{3} \times 1 + \frac{2}{3} \times \frac{1}{3} = \frac{1}{3} + \frac{2}{9} = \frac{5}{9}$

情况 2, 李四选择骰子 B : 选骰子 A : B 掷出 3 时, A 掷出 5; B 掷出 4 时, A 掷出 5 才比他大, 于是点数大于 B 的概率: $\frac{1}{2} \times \frac{2}{3} + \frac{1}{2} \times \frac{2}{3} = \frac{2}{3}$ 选骰子 C : B 掷出 3 时, C 掷出 6 才比他大; B 掷出 4 时, C 掷出 6 才比他大, 于是点数大于 B 的概率: $\frac{1}{2} \times \frac{1}{3} + \frac{1}{2} \times \frac{1}{3} = \frac{1}{3}$

情况 3, 李四选择骰子 C : 选骰子 A : C 掷出 2 时, A 掷出 5 才比他大; C 掷出 6 时, A 不可能比他大, 于是点数大于 C 的概率: $\frac{2}{3} \times \frac{2}{3} + \frac{1}{3} \times 0 = \frac{4}{9}$ 选骰子 B : C 掷出 2 时, B 掷出 3 或 4 才比他大; C 掷出 6 时, B 不可能比他大, 于是点数大于 C 的概率: $\frac{2}{3} \times 1 = \frac{2}{3}$ 所以策略是: 如果李四选择骰子 A , 你选择骰子 C ; 如果李四选择骰子 B , 你选择骰子 A ; 如果李四选择骰子 C , 你选择骰子 B 。

1. (10 分) X, Y 服从两点分布, 则它们独立的充要条件是: $Cov(X, Y) = 0$.

Solution: 见 2016 年第五题, 原题重现.

3. (10 分) 设概率空间 $(\Omega, \mathcal{F}, P)$ 中的 Ω 的元素个数为 n , 是古典概型, 非平凡事件 A, B 独立. (1) 证明: $|A \cap B| |A^c \cap B^c| = |A^c \cap B| |A \cap B^c|$; (2) 证明: n 为合数.

Solution: (1) 由于 A 和 B 是独立的, 我们有:

$$\begin{aligned} P(A \cap B) &= P(A)P(B) \\ P(A) &= \frac{|A|}{n}, \quad P(B) = \frac{|B|}{n}, \quad P(A \cap B) = \frac{|A \cap B|}{n} \\ \frac{|A \cap B|}{n} &= \frac{|A|}{n} \cdot \frac{|B|}{n} \quad |A \cap B| = \frac{|A||B|}{n} \end{aligned}$$

由于 A^c 和 B^c 也是独立的:

$$\begin{aligned} P(A^c \cap B^c) &= P(A^c)P(B^c) \\ P(A^c) &= 1 - P(A) = 1 - \frac{|A|}{n} = \frac{n - |A|}{n} \\ P(B^c) &= 1 - P(B) = 1 - \frac{|B|}{n} = \frac{n - |B|}{n} \\ P(A^c \cap B^c) &= \frac{n - |A|}{n} \cdot \frac{n - |B|}{n} = \frac{(n - |A|)(n - |B|)}{n^2} \\ |A^c \cap B^c| &= \frac{(n - |A|)(n - |B|)}{n} \end{aligned}$$

接下来, 考虑事件 $A^c \cap B$ 和 $A \cap B^c$:

$$\begin{aligned} P(A^c \cap B) &= P(A^c)P(B) = \frac{n - |A|}{n} \cdot \frac{|B|}{n} = \frac{(n - |A|)|B|}{n^2} \\ |A^c \cap B| &= \frac{(n - |A|)|B|}{n} \\ P(A \cap B^c) &= P(A)P(B^c) = \frac{|A|}{n} \cdot \frac{n - |B|}{n} = \frac{|A|(n - |B|)}{n^2} \\ |A \cap B^c| &= \frac{|A|(n - |B|)}{n} \end{aligned}$$

$$|A \cap B||A^c \cap B^c| = \left(\frac{|A||B|}{n} \right) \left(\frac{(n-|A|)(n-|B|)}{n} \right) = \frac{|A||B|(n-|A|)(n-|B|)}{n^2}$$

$$|A^c \cap B||A \cap B^c| = \left(\frac{(n-|A|)|B|}{n} \right) \left(\frac{|A|(n-|B|)}{n} \right) = \frac{|A||B|(n-|A|)(n-|B|)}{n^2}$$

因此: $|A \cap B||A^c \cap B^c| = |A^c \cap B||A \cap B^c|$ (2) 假设 n 是一个质数。那么 n 的唯一正因数是 1 和 n 本身。由于 A 和 B 是非平凡事件, 它们的个数 $|A|$ 和 $|B|$ 必须在 1 和 $n-1$ 之间。因此, $|A|$ 和 $|B|$ 都不是 n 的因数。从第一部分的等式 $|A \cap B||A^c \cap B^c| = |A^c \cap B||A \cap B^c|$, 我们知道:

$$\frac{|A||B|}{n} \cdot \frac{(n-|A|)(n-|B|)}{n} = \frac{(n-|A|)|B|}{n} \cdot \frac{|A|(n-|B|)}{n}$$

这个等式成立, 但如果我们假设 n 是质数, 那么 $|A|$ 和 $|B|$ 都不能整除 n , 这将导致等式两边的分子不能被 n^2 整除, 从而导致矛盾。因此 n 不能是质数, 它必须是合数。

4. (10 分) 若 $P(X \leq x, Y \leq y) = F(\min(x, y))$, 证明: $P(X = Y) = 1$.

Solution: 《应坚刚》第六章划题. 对任意 $x \in \mathbb{R}$, 有:

$$P(X \leq x < Y) = P(X \leq x, Y < \infty) - P(X \leq x, Y \leq x) = 0,$$

因此容易说明 $\{X < Y\} = \bigcup_{x \in \mathbb{Q}} \{X \leq x < Y\}$ 是零测集, 同理 $\{X > Y\}$ 是零测集, 结论成立。

5. (15 分) X, Y 独立同分布于 F , 二阶矩存在, 证明:

(1) $E|X - Y|^2 = 2\text{Var}(X)$ (2) $\text{Var}(\sin x) \leq \text{Var}(x)$

Solution: (1) 由于 X 和 Y 独立同分布于 F , 我们有:

$$E(X) = E(Y), \text{Var}(X) = \text{Var}(Y)$$

$$E((X - Y)^2) = E(X^2 - 2XY + Y^2) = E(X^2) - 2E(XY) + E(Y^2)$$

由于 X 和 Y 独立, 我们有 $E(XY) = E(X)E(Y)$ 。因此:

$$\begin{aligned} E((X - Y)^2) &= E(X^2) - 2E(X)E(Y) + E(Y^2) \\ &= E(X^2) - 2E(X)^2 + E(X^2) \\ &= 2E(X^2) - 2E(X)^2 \\ &= 2(E(X^2) - E(X)^2) \end{aligned}$$

根据方差的定义, $\text{Var}(X) = E(X^2) - E(X)^2$, 因此:

$$E((X - Y)^2) = 2\text{Var}(X)$$

(2) 庞加莱不等式证法重现, 对任意 x_0 , 有:

$$\begin{aligned} \text{Var}(f(X)) &\leq E\left[\left(f(X) - f(x_0)\right)^2\right] = E\left[\left(\int_{x_0}^X f'(t) dt\right)^2\right] \\ &\leq E\left[\left(\int_{x_0}^X (f'(t))^2 dt\right) \left(\int_{x_0}^X 1^2 dt\right)\right] = E\left[(X - x_0) \left(\int_{x_0}^X (f'(t))^2 dt\right)\right] \\ &\leq \sup_t |(f'(t))^2| \cdot E\left[(X - x_0)^2\right]. \end{aligned}$$

这里 $f'(t)^2 = (\cos t)^2 \leq 1$, 再选 $x_0 = E(X)$, 得证。(也可直接根据第一问的结论证明)

6. (10 分) X_1, X_2 独立同分布于 $U(0, 1)$, 记 $Y_1 = \min(X_1, X_2), Y_2 = \max(X_1, X_2)$, 计算 $E[X_1 | Y_2]$.

Solution: 由于 $Y_2 \sim Be(2, 1), E(X_1) = \frac{1}{2}, E(Y_2) = \frac{2}{3}$,

$$E(X_1 Y_2) = E[E(X_1 Y_2 | Y_2)] = E[Y_2 E(X_1 | Y_2)]$$

并且:

$$Y_1 + Y_2 = X_1 + X_2$$

$$E(X_1 | Y_2) = \frac{1}{2} E(X_1 + X_2 | Y_2)$$

对于 $0 \leq y_1 \leq y_2 \leq 1$:

$$f_{Y_1, Y_2}(y_1, y_2) = 2$$

$$f_{Y_2}(y_2) = \int_0^{y_2} f_{Y_1, Y_2}(y_1, y_2) dy_1 = \int_0^{y_2} 2 dy_1 = 2y_2$$

$$f_{Y_1 | Y_2}(y_1 | y_2) = \frac{f_{Y_1, Y_2}(y_1, y_2)}{f_{Y_2}(y_2)} = \frac{2}{2y_2} = \frac{1}{y_2}$$

$$\begin{aligned} E(Y_1 | Y_2 = y_2) &= \int_0^{y_2} y_1 f_{Y_1 | Y_2}(y_1 | y_2) dy_1 = \int_0^{y_2} y_1 \frac{1}{y_2} dy_1 \\ &= \frac{1}{y_2} \int_0^{y_2} y_1 dy_1 = \frac{1}{y_2} \left[\frac{y_1^2}{2} \right]_0^{y_2} \\ &= \frac{1}{y_2} \cdot \frac{y_2^2}{2} = \frac{y_2}{2} \end{aligned}$$

$$E(X_1 | Y_2) = \frac{1}{2} E(X_1 + X_2 | Y_2) = \frac{1}{2} E(Y_1 + Y_2 | Y_2) = \frac{1}{2} Y_2 + \frac{1}{2} E(Y_1 | Y_2) = \frac{Y_2}{2} + \frac{1}{2} \cdot \frac{Y_2}{2} = \frac{3Y_2}{4}.$$

7. (15 分) 给定二元函数

$$f(x, y) = c \left(e^{-\frac{x^2 + y^2}{2}} + \frac{xy(x^2 - y^2)}{\sqrt{e}} I_D(x, y) \right)$$

其中 $D = \{(x, y) | x^2 + y^2 \leq 1\}$, $c > 0$.

(1) 证明: $f(x, y) > 0$;

(2) 设 (X, Y) 的联合密度为 $f(x, y)$, 求 c .

(3) 求 X, Y 的边缘分布, 求 $\text{Cov}(X, Y)$, X 和 Y 是否独立?

Solution: (1) $(x, y) \notin D$ 时显然大于 0, $(x, y) \in D$ 时, 令 $x = \rho \cos \theta$, $y = \rho \sin \theta$:

$$\begin{aligned} f(x, y) &= c \left(e^{-\frac{\rho^2}{2}} + \frac{\rho^2 \cdot \sin \theta \cos \theta (\cos^2 \theta - \sin^2 \theta)}{\sqrt{e}} \right) \\ &> \left(1 - \frac{1}{2} \rho^2 + \frac{\rho^2 \cdot \sin 4\theta}{4\sqrt{e}} \right) \\ &> c \cdot \left(1 - \frac{1}{2} - \frac{1}{4\sqrt{e}} \right) \\ &> 0 \end{aligned}$$

(2) 由正则性

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1.$$

我们将积分分为两部分: $(x, y) \in D$ 和 $(x, y) \notin D$ 。对于 $(x, y) \notin D$,

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} ce^{-\frac{x^2+y^2}{2}} dx dy - \int_D ce^{-\frac{x^2+y^2}{2}} dx dy.$$

对于 $(x, y) \in D$,

$$\int_D c \left(e^{-\frac{x^2+y^2}{2}} + \frac{xy(x^2-y^2)}{\sqrt{e}} \right) dx dy.$$

将这两部分合并, 我们得到,

$$c \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{x^2+y^2}{2}} dx dy = 1.$$

令 $x = r \cos \theta$, $y = r \sin \theta$, 则 $x^2 + y^2 = r^2$ 。则 $r \geq 0, 0 \leq \theta \leq 2\pi$ 。

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{x^2+y^2}{2}} dx dy = \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}} r dr d\theta$$

令 $u = r^2$, $du = 2r dr$ 。

$$\int_0^{2\pi} d\theta \int_0^{\infty} e^{-\frac{r^2}{2}} r dr = \int_0^{2\pi} d\theta \int_0^{\infty} \frac{1}{2} e^{-\frac{u}{2}} du = \int_0^{2\pi} d\theta \left[-e^{-\frac{u}{2}} \right]_0^{\infty} = \int_0^{2\pi} d\theta = 2\pi$$

(也可直接根据二元正态分布的联合密度函数得出), 于是:

$$c = \frac{1}{2\pi}$$

(3) 首先, 我们求 X 的边缘分布。由于 $f(x, y)$ 关于 y 对称, 所以 X 的边缘分布为

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy = \int_{-\infty}^{\infty} \frac{1}{2\pi} \left(e^{-\frac{x^2+y^2}{2}} + \frac{xy(x^2-y^2)}{\sqrt{e}} 1_D(x, y) \right) dy.$$

由于 $\frac{xy(x^2-y^2)}{\sqrt{e}} 1_D(x, y)$ 关于 y 是奇函数, 所以

$$\int_{-\infty}^{\infty} \frac{xy(x^2-y^2)}{\sqrt{e}} 1_D(x, y) dy = 0.$$

因此:

$$f_X(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-\frac{x^2+y^2}{2}} dy = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}.$$

同理, y 的边缘分布为:

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}.$$

由于: $f_Y(y)f_X(x) \neq f(x, y)$, 所以 X, Y 不独立。

$$E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy \frac{1}{2\pi} \left(e^{-\frac{x^2+y^2}{2}} + \frac{xy(x^2-y^2)}{\sqrt{e}} 1_D(x, y) \right) dx dy.$$

由于 $e^{-\frac{x^2+y^2}{2}}$ 关于 x 和 y 都是对称的, 所以

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xye^{-\frac{x^2+y^2}{2}} dx dy = 0.$$

令: $x = r \cos \theta$ 和 $y = r \sin \theta$, 积分变为:

$$\int_0^{2\pi} \int_0^1 \frac{(r \cos \theta)(r \sin \theta)(r^2 \cos^2 \theta - r^2 \sin^2 \theta)}{\sqrt{e}} r dr d\theta.$$

简化被积函数, 我们得到:

$$\int_0^{2\pi} \int_0^1 \frac{r^5 \cos \theta \sin \theta (\cos^2 \theta - \sin^2 \theta)}{\sqrt{e}} dr d\theta.$$

注意到 $\cos \theta \sin \theta (\cos^2 \theta - \sin^2 \theta)$ 是一个奇函数, 因此:

$$\int_0^{2\pi} \cos \theta \sin \theta (\cos^2 \theta - \sin^2 \theta) d\theta = 0.$$

所以: $Cov(X, Y) = E(XY) - E(X)E(Y) = 0$

8. (10 分) 打怪物会爆装备 1 和 2, 爆出装备 1 的概率是 0.2, 爆出装备 2 的概率是 0.2, 不获得任何装备的概率是 0.6, 设 τ 是集齐装备所用的次数, 求 $E\tau$, $Var\tau$.

Solution: 令: ξ_1 表示收集到第一件装备所需的次数, 其成功概率为 0.4 (因为获得装备 1 或装备 2 的概率为 $0.2 + 0.2 = 0.4$). ξ_2 表示在收集到第一件装备后, 收集到第二件装备所需的次数, 其成功概率为 0.2 (因为获得第 2 个装备的概率为 0.2)。对于几何分布随机变量 $\xi \sim Ge(p)$, 其期望 $E\xi = \frac{1}{p}$ 。因此: $E\xi_1 = \frac{1}{0.4} = 2.5$, $E\xi_2 = \frac{1}{0.2} = 5$

$$E\tau = E\xi_1 + E\xi_2 = 2.5 + 5 = 7.5$$

对于几何分布随机变量 $\xi \sim Ge(p)$, 其方差 $Var\xi = \frac{1-p}{p^2}$ 。因此:

$$Var\xi_1 = \frac{1-0.4}{0.4^2} = \frac{0.6}{0.16} = 3.75$$

$$Var\xi_2 = \frac{1-0.2}{0.2^2} = \frac{0.8}{0.04} = 20$$

$$Var\tau = Var\xi_1 + Var\xi_2 = 3.75 + 20 = 23.75$$

因此, 收集到两件装备所需的期望次数为 7.5 次, 方差为 23.75。

9. (15 分) 设 $X_1, \dots, X_n$ 独立同分布于连续函数 F , 样本 $Y_i = \mu + \sigma[-\ln F(X_i)]^{-\frac{1}{2}}, \mu > 0, \sigma > 0$

(1) 求 (μ, σ) 的最大似然估计。

(2) 若 μ 已知, 求 σ^2 的充分统计量。

Solution: (1) 令 $Z_i = F(X_i)$, 则 $Z_i \sim U(0, 1)$ 。

$$Y_i = \mu + \sigma[-\ln Z_i]^{-\frac{1}{2}}$$

由于 $Z_i \sim U(0, 1)$, $-\ln Z_i$ 服从参数为 1 的指数分布, 即 $-\ln Z_i \sim \text{Exp}(1)$ 。设 $W_i = [-\ln Z_i]^{-\frac{1}{2}}$:

$$P(w_i \leq w) = P\left((-\ln z_i)^{-\frac{1}{2}} \leq w\right) = P\left(z_i \leq e^{-w^{-2}}\right) = e^{-w^{-2}}$$

$$f_{w_i}(w) = 2w^{-3}e^{-w^{-2}}, \quad y_i = \mu + \sigma \cdot w_i$$

$$f_{Y_i}(y_i) = f_{w_i}\left(\frac{y_i - \mu}{\sigma}\right) \cdot \frac{1}{\sigma} = 2\sigma^2 \cdot (y_i - \mu)^{-3} \cdot e^{-\left(\frac{\sigma}{y_i - \mu}\right)^2}$$

$$f(y_1, \dots, y_n) = \prod_{i=1}^n 2\sigma^2 (y_i - \mu)^{-3} e^{-\left(\frac{\sigma}{y_i - \mu}\right)^2}$$

$$\ln f = \sum_{i=1}^n \left[-3 \ln(y_i - \mu) - \left(\frac{\sigma}{y_i - \mu} \right)^2 \right] + 2n \ln \sigma + n \ln 2$$

对 μ 的偏导数为:

$$\begin{aligned} \frac{\partial \ln f}{\partial \mu} &= \sum_{i=1}^n \left[\frac{3}{y_i - \mu} - \frac{2\sigma^2}{(y_i - \mu)^3} \right] = 0 \\ \Rightarrow \sum_{i=1}^n \frac{3(y_i - \mu)^2 - 2\sigma^2}{(y_i - \mu)^3} &= 0 \quad (1) \end{aligned}$$

对 σ 的偏导数为:

$$\begin{aligned} \frac{\partial \ln f}{\partial \sigma} &= \sum_{i=1}^n \frac{-2\sigma}{(y_i - \mu)^2} + \frac{2n}{\sigma} = 0 \\ \Rightarrow \sum_{i=1}^n \frac{1}{(y_i - \mu)^2} &= \frac{n}{\sigma^2} \quad (2) \end{aligned}$$

设 $S_1(\mu) = \sum_{i=1}^n \frac{1}{y_i - \mu}$, $S_2(\mu) = \sum_{i=1}^n \frac{1}{(y_i - \mu)^2}$, $S_3(\mu) = \sum_{i=1}^n \frac{1}{(y_i - \mu)^3}$, 则:

$$3S_1(\mu) - 2\sigma^2 S_3(\mu) = 0, \quad S_2(\mu) - \frac{n}{\sigma^2} = 0$$

(μ, σ) 的极大似然估计即为满足上式的值。注意由于 $\ln f$ 关于 μ, σ 并不单调, 所以不能直接取 $\mu = y_{(1)}$

(2) 根据因子分解定理, 如果似然函数可以写成 $L(\sigma^2) = g(T(Y), \sigma^2)h(Y)$ 的形式, 其中 $T(Y)$ 是样本的函数, g 和 h 是两个函数, 那么 $T(Y)$ 是 σ^2 的充分统计量。似然函数为:

$$L(\sigma^2) = \prod_{i=1}^n 2(y_i - \mu)^{-3} \exp \left\{ \sum_{i=1}^n \left[-\left(\frac{\sigma}{y_i - \mu} \right)^2 \right] + 2n \ln(\sigma) \right\}$$

这里, $T(Y) = \sum_{i=1}^n \frac{1}{(y_i - \mu)^2}$ 是 σ^2 的充分统计量。

10. (15 分) 设总体为对数正态分布 $LN(\mu, \sigma^2)$, 简单样本为 $X_1, \dots, X_n$.

(1) 求 μ 的矩估计、最大似然估计。

(2) 求 $\theta = e^{\mu + \frac{1}{2}}$ 的最大似然估计, 并分析其是否无偏。

Solution: (1) 对于对数正态分布 $LN(\mu, \sigma^2)$, 其均值 $E(X) = e^{\mu + \frac{\sigma^2}{2}}$ 。样本均值 $\bar{X}$ 可作为 $E(X)$ 的估计, 因此:

$$\bar{X} = e^{\mu + \frac{\sigma^2}{2}}$$

解出 μ 得到矩估计:

$$\hat{\mu}_1 = \ln(\bar{X}) - \frac{\sigma^2}{2}$$

$$L(\mu, \sigma) = \prod_{i=1}^n \frac{1}{X_i \sigma \sqrt{2\pi}} e^{-\frac{(\ln X_i - \mu)^2}{2\sigma^2}}$$

$$\ln L(\mu, \sigma) = -n \ln(\sigma) - \frac{n}{2} \ln(2\pi) - \sum_{i=1}^n \frac{(\ln X_i - \mu)^2}{2\sigma^2} - \sum_{i=1}^n \ln X_i$$

对 μ 求偏导数:

$$\frac{\partial \ln L}{\partial \mu} = \sum_{i=1}^n \frac{\ln X_i - \mu}{\sigma^2} = 0$$

$$\hat{\mu}_{MLE} = \frac{1}{n} \sum_{i=1}^n \ln X_i$$

(2) 由极大似然估计的不变性: 若 $(\hat{\mu}, \hat{\sigma})$ 是 (μ, σ) 的极大似然估计, 则对于任何函数 $T(\mu, \sigma)$, T 的极大似然估计为 $T(\hat{\mu}, \hat{\sigma})$ 。因此, θ 的最大似然估计为: $\hat{\theta}_{MLE} = e^{\hat{\mu} + \frac{1}{2}}$, 由于 $\hat{\mu}_{MLE}$ 是 μ 的无偏估计, 我们有: $E(\hat{\mu}_{MLE}) = \mu$ 。

$$E(e^{\mu}) > e^{E(\mu)} = e^{\mu}$$

所以 θ 不是无偏估计。

11. (15 分) 设随机变量 X 的概率密度函数为:

$$f(x; \theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1, \\ 0, & \text{其他} \end{cases}$$

设 X_1, X_2 来自该总体的样本, 考虑假设检验问题:

$$H_0: \theta = 1 \leftrightarrow H_1: \theta = 2,$$

其否定域为 $W = \{(X_1, X_2) \mid X_1 X_2 > \frac{3}{4}\}$, 求第一、二类错误的概率。

Solution: 1. 第一类错误: 弃真。即在 $\theta = 1$ 的情况下, $X_1 X_2 > \frac{3}{4}$ 的概率。当 $\theta = 1$ 时, X 的概率密度函数为 $f(x; 1) = 1$, $0 < x < 1$ 。因此, X_1 和 X_2 都是 $(0, 1)$ 上的均匀分布, $\frac{3}{4x_1} < 1$, 求出 $x_1 > \frac{3}{4}$

$$P(X_1 X_2 > \frac{3}{4} | \theta = 1) = \int_{\frac{3}{4}}^1 \int_{\frac{3}{4x_1}}^1 1 dx_2 dx_1 = \frac{1}{4} + \frac{3 \ln 3}{4} - \frac{3 \ln 2}{2}$$

因此, 第一类错误的概率为:

$$\alpha = \frac{1}{4} + \frac{3 \ln 3}{4} - \frac{3 \ln 2}{2}$$

2. 第二类错误: 取伪, 即在 H_1 为真时接受 H_0 的概率。即在 $\theta = 2$ 的情况下, $X_1 X_2 \leq \frac{3}{4}$ 的概率。当 $x_1 < \frac{3}{4}$ 时, x_2 的积分范围是 $(0, 1)$, 而当 $x_1 \geq \frac{3}{4}$ 时, x_2 的积分范围是 $(0, \frac{3}{4x_1})$ 。因此:

$$P(X_1 X_2 \leq \frac{3}{4} | \theta = 2) = \int_0^{\frac{3}{4}} 2x_1 dx_1 + \int_{\frac{3}{4}}^1 \frac{9}{8x_1} dx_1 = \frac{9}{16} + \frac{9 \ln 2}{4} - \frac{9 \ln 3}{8}$$

因此, 第二类错误的概率为:

$$\beta = \frac{9}{16} + \frac{9 \ln 2}{4} - \frac{9 \ln 3}{8}$$

12. (15 分) 设总体 X 满足 $P(X > x | \theta) = e^{-(\theta x)^k}$, 参数 θ 的先验分布满足 $\theta^k \sim \Gamma(\alpha, \beta)$, 这里 $\alpha = 2$, $\beta = 1$, $k = 2$, 给定样本 $x_1, \dots, x_n$, 求 θ 的后验分布。

Solution: 由于 $P(X > x | \theta) = e^{-(\theta x)^2}$, 我们可以得到 $P(X \leq x | \theta) = 1 - e^{-(\theta x)^2}$ 。

$$f(x_i | \theta) = \frac{d}{dx_i} P(X \leq x_i | \theta) = 2\theta^2 x_i e^{-(\theta x_i)^2}$$

因此:

$$L(x_1, \dots, x_n | \theta) = \prod_{i=1}^n 2\theta^2 x_i e^{-(\theta x_i)^2} = 2^n \theta^{2n} \left(\prod_{i=1}^n x_i \right) e^{-\sum_{i=1}^n (\theta x_i)^2}$$

参数 θ^2 的先验分布为:

$$\theta^2 \sim \Gamma(2, 1)$$

$$g(\theta^2) = \frac{1^2}{\Gamma(2)} (\theta^2)^{2-1} e^{-1 \cdot \theta^2} = \theta^2 e^{-\theta^2}$$

根据贝叶斯定理, 后验分布 $\pi(\theta^2 | x_1, \dots, x_n)$ 与似然函数和先验分布的乘积成正比:

$$\pi(\theta^2 | x_1, \dots, x_n) \propto L(\theta | x_1, \dots, x_n) \cdot g(\theta^2)$$

代入似然函数和先验分布，得到：

$$\pi(\theta^2|x_1, \dots, x_n) \propto 2^n \theta^{2n} \left(\prod_{i=1}^n x_i \right) e^{-\sum_{i=1}^n (\theta x_i)^2} \cdot \theta^2 e^{-\theta^2}$$

$$\pi(\theta^2|x_1, \dots, x_n) \propto \theta^{2n+2} e^{-\theta^2 (\sum_{i=1}^n x_i^2 + 1)}$$

说明 θ^2 后验分布依旧还是伽马分布，参数 θ^2 的后验分布为：

$$\theta^2|x_1, \dots, x_n \sim \Gamma(n+2, \sum_{i=1}^n x_i^2 + 1)$$

于是：

$$f(\theta^2|x_1, \dots, x_n) = \frac{\theta^{2(n+1)}}{\Gamma(n+2)} (\sum_{i=1}^n x_i^2 + 1)^{n+2} e^{-(\sum_{i=1}^n x_i^2 + 1)\theta^2}$$

$$f(\theta|x_1, \dots, x_n) = \begin{cases} f(\theta^2|x_1, \dots, x_n)\theta = \frac{\theta^{2n+3}}{\Gamma(n+2)} (\sum_{i=1}^n x_i^2 + 1)^{n+2} e^{-(\sum_{i=1}^n x_i^2 + 1)\theta^2}, & \theta > 0 \\ -f(\theta^2|x_1, \dots, x_n)\theta = -\frac{\theta^{2n+3}}{\Gamma(n+2)} (\sum_{i=1}^n x_i^2 + 1)^{n+2} e^{-(\sum_{i=1}^n x_i^2 + 1)\theta^2}, & \theta < 0 \end{cases}$$

复旦大学-432 统计学-2026 年

一、在自然数集 $\mathbb{N} := \{n \in \mathbb{Z} : n \geq 1\}$ 上定义概率测度：

$$P(\{n\}) = \frac{6}{\pi^2 n^2}$$

(1) 对于 $p \in \mathbb{N}^+$ ，定义集合 $p_{\mathbb{N}^+} = \{pk : k \in \mathbb{N}^+\}$ ，求 $P(p_{\mathbb{N}^+})$ 。

(2) 若 p 与 q 是不相等的质数，求证事件 $p_{\mathbb{N}^+}$ 与 $q_{\mathbb{N}^+}$ 相互独立。

Solution:

首先验证 $(\mathbb{N}, P)$ 为概率空间。由于黎曼函数 $\zeta(2) = \sum_{n=1}^{\infty} \frac{1}{n^2} = \frac{\pi^2}{6}$ ，故：

$$\sum_{n=1}^{\infty} P(\{n\}) = \frac{6}{\pi^2} \sum_{n=1}^{\infty} \frac{1}{n^2} = 1$$

是良定义的。

(1) 由 $p_{\mathbb{N}^+}$ 的定义（即所有 p 的倍数构成的集合）及概率的可列可加性：

$$\begin{aligned} P(p_{\mathbb{N}^+}) &= \sum_{k=1}^{\infty} P(\{pk\}) \\ &= \sum_{k=1}^{\infty} \frac{6}{\pi^2 (pk)^2} \\ &= \frac{1}{p^2} \left(\frac{6}{\pi^2} \sum_{k=1}^{\infty} \frac{1}{k^2} \right) \end{aligned}$$

注意到括号内即为归一化因子 1（或者说是全概率 $\sum P(\{k\})$ ），故直接得：

$$P(p_{\mathbb{N}^+}) = \frac{1}{p^2}$$

(2) 由于 p, q 是质数且 $p \neq q$ ，故 $\gcd(p, q) = 1$ 。由初等数论基本性质：

$$p|n \wedge q|n \iff \text{lcm}[p, q]|n \iff pq|n$$

从而交集可表示为模 pq 的剩余类（即 pq 的倍数集）：

$$p_{\mathbb{N}^+} \cap q_{\mathbb{N}^+} = (pq)_{\mathbb{N}^+}$$

利用 (1) 的结论，将 pq 视为一个整体代入：

$$P(p_{\mathbb{N}^+} \cap q_{\mathbb{N}^+}) = P((pq)_{\mathbb{N}^+}) = \frac{1}{(pq)^2} = \frac{1}{p^2 q^2}$$

另一方面，计算边缘概率之积：

$$P(p_{\mathbb{N}^+}) \cdot P(q_{\mathbb{N}^+}) = \frac{1}{p^2} \cdot \frac{1}{q^2} = \frac{1}{p^2 q^2}$$

综上，我们有：

$$P(p_{\mathbb{N}^+} \cap q_{\mathbb{N}^+}) = P(p_{\mathbb{N}^+}) P(q_{\mathbb{N}^+})$$

根据独立性的定义，事件 $p_{\mathbb{N}^+}$ 与 $q_{\mathbb{N}^+}$ 相互独立。

Remark：这道题的结论，直观上表明“一个随机整数被质数 p 整除”与“被质数 q 整除”是相互独立的事件。如果我们将此结论推广到所有质数，利用独立事件概率乘积公式，可以推导出欧拉乘积公式的概率形式（本题即为 $s=2$ 时的特例）：

$$\sum_{n=1}^{\infty} \frac{1}{n^s} = \prod_{p \text{ prime}} \frac{1}{1 - p^{-s}}$$

如果我们换一个视角，从直觉出发，先规定“在一个自然数概率模型中，随机整数被 n 整除的概率应该是 $1/n^2$ ”，即假设事件 $A_n = \{X \in \mathbb{N} : n \mid X\}$ 的概率为：

$$P(A_n) = \sum_{k=1}^{\infty} P(X = nk) = \frac{1}{n^2}$$

我们需要求出底层的点概率 $f(n) = P(X = n)$ 是什么。利用莫比乌斯反演公式，我们可以从和函数反解出原函数：

$$\begin{aligned} f(n) &= \sum_{k=1}^{\infty} \mu(k) P(A_{nk}) \\ &= \sum_{k=1}^{\infty} \mu(k) \frac{1}{(nk)^2} \\ &= \frac{1}{n^2} \sum_{k=1}^{\infty} \frac{\mu(k)}{k^2} \end{aligned}$$

这里利用了 Dirichlet 级数的一个著名性质： $\sum_{k=1}^{\infty} \frac{\mu(k)}{k^s} = \frac{1}{\zeta(s)}$ 。当 $s = 2$ 时：

$$f(n) = \frac{1}{n^2} \cdot \frac{1}{\zeta(2)} = \frac{1}{n^2} \cdot \frac{6}{\pi^2} = \frac{6}{\pi^2 n^2}$$

这正是题目中给出的概率测度 $P(\{n\})$ 。这一推导过程展示了该分布在数论结构上的自然性。

二、设 $(\Omega, \mathcal{F}, P)$ 为概率空间。定义其上的两个随机变量 ξ, η 满足 $\xi \sim N(0, 1)$, $\eta \sim b(1, \frac{1}{2})$, ξ 与 η 相互独立。试求：

- (1) 判别随机变量 $Z = \xi + \eta$ 是否为连续型随机变量，并证明你的结论。
- (2) 求 $Z = \xi + \eta$ 的分布函数 $F_Z(z)$ 。

Solution:

- (1) $Z = \xi + \eta$ 是连续型随机变量。

证明：由定义，若随机变量 Z 的分布函数 $F_Z(z)$ 可以表示为某个非负可积函数 $f_Z(z)$ （即概率密度函数）的积分，即 $F_Z(z) = \int_{-\infty}^z f_Z(t) dt$ ，则称 Z 为连续型随机变量。

我们先求 Z 的分布函数 $F_Z(z)$ 。定义事件 $A_0 = \{\eta = 0\}$, $A_1 = \{\eta = 1\}$ 。由于 $\eta \sim b(1, 1/2)$ ，故 $P(A_0) = P(A_1) = \frac{1}{2}$ 。利用全概率公式，并结合 ξ 与 η 的独立性，有：

$$\begin{aligned} F_Z(z) &= P(\xi + \eta \leq z) \\ &= P(\xi + \eta \leq z | \eta = 0)P(\eta = 0) + P(\xi + \eta \leq z | \eta = 1)P(\eta = 1) \\ &= P(\xi \leq z) \cdot \frac{1}{2} + P(\xi + 1 \leq z) \cdot \frac{1}{2} \\ &= \frac{1}{2}P(\xi \leq z) + \frac{1}{2}P(\xi \leq z - 1) \end{aligned}$$

记 $\Phi(x)$ 为标准正态分布 $N(0, 1)$ 的分布函数，其概率密度函数为 $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ 。则上式可写为：

$$F_Z(z) = \frac{1}{2}\Phi(z) + \frac{1}{2}\Phi(z - 1)$$

由于 $\Phi(z)$ 是连续可导函数，且 $\Phi'(z) = \varphi(z)$ ，我们可以对 $F_Z(z)$ 求导得到 Z 的概率密度函数：

$$\begin{aligned} f_Z(z) &= F'_Z(z) = \frac{1}{2}\Phi'(z) + \frac{1}{2}\Phi'(z - 1) \\ &= \frac{1}{2}\varphi(z) + \frac{1}{2}\varphi(z - 1) \end{aligned}$$

显然, 对于任意 z , 有:

$$F_Z(z) = \int_{-\infty}^z \left[\frac{1}{2}\varphi(t) + \frac{1}{2}\varphi(t-1) \right] dt$$

因为找到了 Z 的概率密度函数 $f_Z(z)$, 故 Z 是连续型随机变量。

(2) 由第 (1) 问的推导可知, $Z = \xi + \eta$ 的分布函数 $F_Z(z)$ 为:

$$F_Z(z) = \frac{1}{2}\Phi(z) + \frac{1}{2}\Phi(z-1)$$

其中 $\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$ 为标准正态分布函数。

注: 从测度的卷积角度来看, ξ 的分布是绝对连续测度, η 的分布是离散测度。这里涉及到一个重要的测度论结论: 一个绝对连续测度与任意概率测度的卷积, 依然是绝对连续测度。

直观上, η 的作用是将 ξ 的高斯钟形曲线以 $1/2$ 的概率保持在原位, 以 $1/2$ 的概率向右平移 1 个单位。最终的密度函数是这两个高斯波包的线性叠加。

三、考虑一个包含三个孩子的家庭。假设每个孩子的性别取值服从参数为 $p = \frac{1}{2}$ 的伯努利分布 (即生男、生女的概率均为 $\frac{1}{2}$), 且各次生育事件相互独立。求:

- (1) 该家庭中最多有 1 个女孩的概率;
- (2) 该家庭中三个孩子既有男孩又有女孩的概率。

Solution:

为了严谨地求解上述问题, 我们首先需要定义样本空间 Ω 。令 e_i 表示第 i 个孩子的性别, $i \in \{1, 2, 3\}$, $e_i \in \{B, G\}$, 其中 B 代表男孩, G 代表女孩。样本空间由所有可能的有序三元组组成:

$$\Omega = \{BBB, BBG, BGB, BGG, GBB, GBG, GGB, GGG\}$$

根据乘法原理, 样本空间的基数为 $|\Omega| = 2^3 = 8$ 。由于假设概率相等且独立, 这是一个古典概型, 每个基本事件发生的概率为 $1/8$ 。

(1) 令随机变量 X 表示家庭中女孩的数量。我们需要计算事件 $A = \{X \leq 1\}$ 的概率。该事件可以分解为两个互斥子事件的并集: $A = \{X = 0\} \cup \{X = 1\}$ 。* 当 $X = 0$ 时: 意味着没有女孩, 即全为男孩。 $E_0 = \{BBB\}$, $|E_0| = 1$ 。* 当 $X = 1$ 时: 意味着恰好有 1 个女孩。女孩可能出现在第 1、2 或 3 个位置。 $E_1 = \{GBB, BGB, BBG\}$, $|E_1| = 3$ 。

$$P(A) = P(X=0) + P(X=1) = \frac{|E_0| + |E_1|}{|\Omega|} = \frac{1+3}{8} = \frac{4}{8} = \frac{1}{2}$$

(2) 令事件 B 表示 “既有男孩又有女孩”。考察 B 的对立事件 B^c 。 B^c 表示 “全是男孩或全是女孩”:

$$B^c = \{BBB, GGG\}$$

显然, $|B^c| = 2$ 。

$$P(B^c) = \frac{|B^c|}{|\Omega|} = \frac{2}{8} = \frac{1}{4}$$

所以,

$$P(B) = 1 - P(B^c) = 1 - \frac{1}{4} = \frac{3}{4}$$

四、已知随机向量 (ξ, η) 的联合密度函数为:

$$f(x, y) = \frac{1}{2} \cdot I_{\{0 \leq x \leq 1, 0 \leq y \leq 2\}}$$

其中 I_D 表示集合 D 上的示性函数。求事件概率：

$$P(\{\xi > \frac{1}{2}\} \cup \{\eta > \frac{1}{2}\})$$

Solution:

记随机向量 (ξ, η) 的支撑集为 $\Omega = [0, 1] \times [0, 2]$ 。由题设密度函数为常数可知, (ξ, η) 在 Ω 上服从均匀分布。设所求事件为 A , 利用对立事件 $\bar{A}$ 求解更为简便。根据德·摩根定律, 事件 $\bar{A}$ 为:

$$\bar{A} = \overline{\{\xi > \frac{1}{2}\} \cup \{\eta > \frac{1}{2}\}} = \{\xi \leq \frac{1}{2}\} \cap \{\eta \leq \frac{1}{2}\}$$

该区域 $D_{\bar{A}} = [0, \frac{1}{2}] \times [0, \frac{1}{2}]$ 完全包含于 Ω 内。直接对密度函数积分 (或利用均匀分布的几何性质, 即面积比):

$$P(\bar{A}) = \iint_{D_{\bar{A}}} \frac{1}{2} dx dy = \frac{1}{2} \cdot \left(\frac{1}{2} \times \frac{1}{2}\right) = \frac{1}{8}$$

故所求概率为:

$$P(A) = 1 - P(\bar{A}) = 1 - \frac{1}{8} = \frac{7}{8}$$

五、(单边切比雪夫不等式) 设 ξ 为随机变量, $E\xi = 0, D\xi = \sigma^2 < \infty$, 则对任何一个 $a > 0$, 试证:

$$P\{\xi \geq a\} \leq \frac{\sigma^2}{\sigma^2 + a^2}$$

Solution:

(注: 本题为 2019 年复旦大学 432 真题第四题。)

证明: 对于任意常数 $b > 0$, 我们有:

$$P(\xi \geq a) = P(\xi + b \geq a + b)$$

由于 $a > 0, b > 0$, 故 $a + b > 0$ 。根据马尔可夫不等式, 对随机变量 $(\xi + b)^2$ 应用 (注意到事件 $\{\xi + b \geq a + b\}$ 蕴含 $\{(\xi + b)^2 \geq (a + b)^2\}$):

$$P(\xi + b \geq a + b) \leq P((\xi + b)^2 \geq (a + b)^2) \leq \frac{E[(\xi + b)^2]}{(a + b)^2}$$

展开分子中的期望, 利用 $E\xi = 0$ 和 $E[\xi^2] = D\xi + (E\xi)^2 = \sigma^2$:

$$\begin{aligned} E[(\xi + b)^2] &= E[\xi^2 + 2b\xi + b^2] \\ &= E[\xi^2] + 2bE\xi + b^2 \\ &= \sigma^2 + 0 + b^2 = \sigma^2 + b^2 \end{aligned}$$

因此我们得到一个含参的上界:

$$P(\xi \geq a) \leq \frac{\sigma^2 + b^2}{(a + b)^2}$$

取 $b = \frac{\sigma^2}{a}$, 代入上式, 得:

$$\begin{aligned} \frac{\sigma^2 + b^2}{(a + b)^2} &= \frac{\sigma^2 + (\frac{\sigma^2}{a})^2}{(a + \frac{\sigma^2}{a})^2} \\ &= \frac{\sigma^2 + \frac{\sigma^4}{a^2}}{(\frac{a^2 + \sigma^2}{a})^2} \\ &= \frac{\sigma^2(a^2 + \sigma^2)}{\frac{a^2}{(a^2 + \sigma^2)^2}} \\ &= \frac{\sigma^2}{a^2 + \sigma^2} \end{aligned}$$

证毕。

Remark: 关于参数 $b = \frac{\sigma^2}{a}$ 的选取动机。若我们将不等式右端的上界记为关于 b 的函数 $g(b) = \frac{\sigma^2 + b^2}{(a+b)^2}$, 为了使不等式最强 (即上界最小), 我们需要求出 $g(b)$ 的最小值点。通过求解导数方程 $g'(b) = 0$, 可以发现极值点恰好在 $b = \frac{\sigma^2}{a}$ 处取到, 这保证了我们使用的是该方法下的最优上界。

六、设随机向量 $\xi = (X, Y)^T$ 服从二维正态分布, 且满足标准化条件:

$$\xi \sim N(0, \Sigma), \quad \text{其中 } \Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$$

考虑变换 $Z = \frac{Y - \rho X}{\sqrt{1 - \rho^2}}$ 。

- (1) 求 Z 的边缘分布;
- (2) 证明 X 与 Z 相互独立。

Solution:

令 $c = (1 - \rho^2)^{-1/2}$, 则 $Z = c(Y - \rho X)$ 。由于 (X, Y) 服从联合正态分布, 而 Z 为 X, Y 的线性组合, 故 Z 服从一维正态分布。

- (1) 由期望的线性性, 显然有:

$$E[Z] = c(E[Y] - \rho E[X]) = 0$$

计算 Z 的方差:

$$\begin{aligned} \text{Var}(Z) &= c^2 \cdot \text{Var}(Y - \rho X) \\ &= c^2 [\text{Var}(Y) + \rho^2 \text{Var}(X) - 2\rho \text{Cov}(X, Y)] \end{aligned}$$

代入已知条件 $\text{Var}(X) = \text{Var}(Y) = 1$ 及 $\text{Cov}(X, Y) = \rho$, 得:

$$\text{Var}(Z) = \frac{1}{1 - \rho^2} (1 + \rho^2 - 2\rho^2) = \frac{1 - \rho^2}{1 - \rho^2} = 1$$

从而 $Z \sim N(0, 1)$ 。

- (2) 考查 X 与 Z 的互协方差:

$$\begin{aligned} \text{Cov}(X, Z) &= c \cdot \text{Cov}(X, Y - \rho X) \\ &= c [\text{Cov}(X, Y) - \rho \text{Var}(X)] \end{aligned}$$

将 $\text{Cov}(X, Y) = \rho$ 与 $\text{Var}(X) = 1$ 代入, 有:

$$\text{Cov}(X, Z) = c(\rho - \rho \cdot 1) = 0$$

对于联合正态分布向量, 随机变量互不相关等价于相互独立。既然 X 与 Z 的协方差为零, 故 X 与 Z 相互独立。

Remark: 本题的变换实质上是 Gram-Schmidt 正交化过程。几何上 $Y - \rho X$ 为 Y 在 X 上的垂线 (残差向量), 故正交。

七、(科尔莫戈罗夫零一律) 设 $(\Omega, \mathcal{F}, P)$ 为概率空间, $\{A_n\}_{n \geq 1}$ 是其上相互独立的事件序列。定义事件 A 为集列的上极限:

$$A := \limsup_{n \rightarrow \infty} A_n = \bigcap_{n \geq 1} \bigcup_{k \geq n} A_k$$

- (1) 证明: 事件 A 与有限个事件 $A_1, \dots, A_n$ 相互独立;
- (2) 证明: $P(A) = 0$ 或 1 。

Solution:

(1) 证明:

设 B 是由有限个事件 $A_1, \dots, A_n$ 生成的 (通过交并补运算得到的) 任意事件, 我们的目标是证明 $P(AB) = P(A)P(B)$ 。根据上极限的定义, 事件 A 可以表示为尾部事件序列的极限:

$$A = \bigcap_{m=n+1}^{\infty} \bigcup_{k=m}^{\infty} A_k$$

为了利用独立性, 我们引入“截断”的尾部事件。对于任意 $L \geq m > n$, 定义有限并集:

$$E_{m,L} = \bigcup_{k=m}^L A_k$$

注意到事件 B 仅依赖于下标 $\{1, \dots, n\}$, 而 $E_{m,L}$ 仅依赖于下标 $\{m, \dots, L\}$ 。由于 $m > n$, 这两组下标互不相交, 由序列 $\{A_k\}$ 的相互独立性可知:

$$P(B \cap E_{m,L}) = P(B)P(E_{m,L})$$

利用概率测度的连续性, 我们对上式依次取两次极限。首先, 固定 m , 令 $L \rightarrow \infty$ 。此时 $E_{m,L}$ 单调递增收敛于无穷并集 $E_m = \bigcup_{k=m}^{\infty} A_k$ 。由概率的下连续性, 上述等式变为:

$$P(B \cap E_m) = P(B)P(E_m)$$

其次, 令 $m \rightarrow \infty$ 。此时 E_m 单调递减收敛于上极限 A 。由概率的上连续性, 对上式两边取极限即可得到:

$$P(B \cap A) = P(B)P(A)$$

至此, 我们严格证明了事件 A 与任意有限个事件 $A_1, \dots, A_n$ 相互独立。(2) 为了证明 $P(A)$ 只能取 0 或 1, 我们可以借助于概率论中两个著名的引理——Borel-Cantelli 引理。这两个引理建立了事件 A (即 $\{A_n\}$ 发生无穷多次) 发生的概率与级数 $\sum P(A_n)$ 收敛性之间的关系。

引理 1: 若 $\sum_{n=1}^{\infty} P(A_n) < \infty$, 则 $P(A) = 0$ 。

证明: 根据 A 的定义, 对于任意给定的 n , 有 $A \subseteq \bigcup_{k=n}^{\infty} A_k$ 。由概率的次可加性 (Boole 不等式):

$$0 \leq P(A) \leq P\left(\bigcup_{k=n}^{\infty} A_k\right) \leq \sum_{k=n}^{\infty} P(A_k)$$

由于级数 $\sum_{n=1}^{\infty} P(A_n)$ 收敛, 其尾项也就是级数的余项 $\sum_{k=n}^{\infty} P(A_k)$ 当 $n \rightarrow \infty$ 时趋于 0。因此, 对上式两边取极限 $n \rightarrow \infty$, 可得 $P(A) = 0$ 。

引理 2: 若 $\{A_n\}$ 相互独立, 且 $\sum_{n=1}^{\infty} P(A_n) = \infty$, 则 $P(A) = 1$ 。

证明: 考虑事件 A 的对立事件 A^c 。由对偶律, $A^c = \left(\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k\right)^c = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k^c$ 。这意味着 A^c 表示“从某一项开始, 后面的事件全都不发生”。我们先考察对于固定的 n , 事件序列从 n 到 $n+m$ 都不发生的概率。由于 $\{A_n\}$ 相互独立, $\{A_n^c\}$ 也相互独立:

$$P\left(\bigcap_{k=n}^{n+m} A_k^c\right) = \prod_{k=n}^{n+m} P(A_k^c) = \prod_{k=n}^{n+m} (1 - P(A_k))$$

利用不等式 $1 - x \leq e^{-x}$ (对 $x \geq 0$ 成立):

$$\prod_{k=n}^{n+m} (1 - P(A_k)) \leq \prod_{k=n}^{n+m} e^{-P(A_k)} = e^{-\sum_{k=n}^{n+m} P(A_k)}$$

因为 $\sum_{n=1}^{\infty} P(A_n) = \infty$, 当 $m \rightarrow \infty$ 时, 指数部分趋向于 $-\infty$, 故 $e^{-\infty} \rightarrow 0$ 。于是对于任意固定的 n :

$$P\left(\bigcap_{k=n}^{\infty} A_k^c\right) = \lim_{m \rightarrow \infty} P\left(\bigcap_{k=n}^{n+m} A_k^c\right) = 0$$

既然对于任意 n , 从第 n 项往后全不发生的概率都是 0, 那么:

$$P(A^c) = P\left(\bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k^c\right) \leq \sum_{n=1}^{\infty} P\left(\bigcap_{k=n}^{\infty} A_k^c\right) = 0$$

所以 $P(A^c) = 0$, 即 $P(A) = 1$ 。

回到原题, 下面来证明题目的结论,

对于任意概率空间中的事件序列 $\{A_n\}$, 级数 $\sum_{n=1}^{\infty} P(A_n)$ 作为一个非负项级数, 其敛散性只有两种情况: 要么收敛, 要么发散。

1. 若 $\sum P(A_n) < \infty$, 由引理 1 可知 $P(A) = 0$; 2. 若 $\sum P(A_n) = \infty$, 且 $\{A_n\}$ 相互独立 (满足题目条件), 由引理 2 可知 $P(A) = 1$ 。

由此可得, 在独立性假设下, 事件 A 发生的概率 $P(A)$ 只能是 0 或 1。

八、叙述独立同分布随机变量序列的中心极限定理, 并利用该定理证明以下极限:

$$\lim_{n \rightarrow \infty} \frac{1}{(n-1)!} \int_0^n y^{n-1} e^{-y} dy = \frac{1}{2}$$

Solution:

(1) 设随机变量序列 $\{X_n\}_{n=1}^{\infty}$ 相互独立且服从同一分布 (i.i.d.)。若 X_1 的期望 $\mu = E[X_1]$ 和方差 $\sigma^2 = Var(X_1)$ 均存在且 $\sigma^2 \in (0, \infty)$, 记前 n 项之和为 $S_n = \sum_{i=1}^n X_i$, 则 S_n 标准化后的随机变量列依分布收敛于标准正态分布, 即:

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1), \quad \text{as } n \rightarrow \infty$$

写成分布函数的形式, 对于任意实数 x , 有:

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq x\right) = \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

(2) 证明: 构造独立同分布的随机变量序列 $X_1, X_2, \dots$, 使得每个 X_i 服从参数为 1 的指数分布, 记为 $X_i \sim Exp(1)$ 。此时, 每个变量的期望与方差均为 1, 即 $\mu = E[X_1] = 1, \sigma^2 = Var(X_1) = 1$ 。考虑前 n 项和 $S_n = \sum_{i=1}^n X_i$ 。相互独立的指数分布变量之和服从伽马分布, 具体参数为形状参数 n 和尺度参数 1, 记作 $S_n \sim \Gamma(n, 1)$ 。其概率密度函数为:

$$f_{S_n}(y) = \frac{1}{\Gamma(n)} y^{n-1} e^{-y} = \frac{1}{(n-1)!} y^{n-1} e^{-y}, \quad y > 0$$

注意到题目中的积分表达式恰好对应于随机变量 S_n 在区间 $(0, n]$ 上的概率, 即累积分布函数在 n 处的取值:

$$I_n = \int_0^n \frac{1}{(n-1)!} y^{n-1} e^{-y} dy = P(S_n \leq n)$$

接下来应用 (1) 中叙述的中心极限定理。我们将事件 $\{S_n \leq n\}$ 进行标准化变形。代入 $\mu = 1, \sigma = 1$, 有:

$$P(S_n \leq n) = P\left(\frac{S_n - n \cdot 1}{1 \cdot \sqrt{n}} \leq \frac{n - n}{\sqrt{n}}\right) = P\left(\frac{S_n - n}{\sqrt{n}} \leq 0\right)$$

令 $Z_n = \frac{S_n - n}{\sqrt{n}}$ 。根据中心极限定理, 当 $n \rightarrow \infty$ 时, Z_n 依分布收敛于标准正态变量 $Z \sim N(0, 1)$ 。因此, 上述概率极限收敛于标准正态分布函数在 0 处的值:

$$\lim_{n \rightarrow \infty} I_n = \lim_{n \rightarrow \infty} P(Z_n \leq 0) = \Phi(0)$$

由于标准正态分布的概率密度函数 $\varphi(t)$ 关于原点对称, 故 $\Phi(0) = 1/2$ 。综上所述, 原极限得证:

$$\lim_{n \rightarrow \infty} \frac{1}{(n-1)!} \int_0^n y^{n-1} e^{-y} dy = \frac{1}{2}$$

九、设总体 X 的生存函数为:

$$P(X > x) = \left(\frac{x}{\theta}\right)^{-\alpha}, \quad x \geq \theta, \alpha > 0$$

设 $X_1, X_2, \dots, X_n$ 为来自该总体且独立同分布的样本。

- (1) 求参数 α, θ 的极大似然估计 (MLE);
- (2) 判断求得的 MLE 是否为充分统计量, 并说明理由。

Solution:

分布函数为: $F(x) = 1 - P(X > x) = 1 - \left(\frac{\theta}{x}\right)^\alpha, x \geq \theta$ 。对 x 求导得到概率密度函数:

$$f(x; \alpha, \theta) = \frac{\alpha \theta^\alpha}{x^{\alpha+1}} I(x \geq \theta)$$

(1) 似然函数 $L(\alpha, \theta)$ 为:

$$\begin{aligned} L(\alpha, \theta) &= \prod_{i=1}^n f(x_i; \alpha, \theta) \\ &= \prod_{i=1}^n \left[\frac{\alpha \theta^\alpha}{x_i^{\alpha+1}} I(x_i \geq \theta) \right] \\ &= \alpha^n \theta^{n\alpha} \left(\prod_{i=1}^n x_i \right)^{-(\alpha+1)} \cdot \prod_{i=1}^n I(x_i \geq \theta) \end{aligned}$$

注意到示性函数的乘积 $\prod_{i=1}^n I(x_i \geq \theta)$ 等价于 $I(\min(x_1, \dots, x_n) \geq \theta)$ 。令次序统计量 $X_{(1)} = \min(x_1, \dots, x_n)$, 则似然函数可写为:

$$L(\alpha, \theta) = \alpha^n \theta^{n\alpha} \left(\prod_{i=1}^n x_i \right)^{-(\alpha+1)} I(\theta \leq X_{(1)})$$

观察似然函数中包含 θ 的项: $L(\alpha, \theta) \propto \theta^{n\alpha} I(\theta \leq X_{(1)})$ 。由于 $\alpha > 0, n > 0$, 函数 $g(\theta) = \theta^{n\alpha}$ 在区间 $(0, +\infty)$ 上单调递增。为了使似然函数最大化, 我们需要在满足约束条件 $\theta \leq X_{(1)}$ 的前提下, 选取尽可能大的 θ 。因此, θ 的极大似然估计量为:

$$\hat{\theta}_{MLE} = X_{(1)} = \min(X_1, \dots, X_n)$$

接下来求 α 的 MLE, 固定 $\theta = \hat{\theta} = X_{(1)}$ 。对似然函数取对数:

$$l(\alpha) = \ln L(\alpha, \hat{\theta}) = n \ln \alpha + n\alpha \ln \hat{\theta} - (\alpha + 1) \sum_{i=1}^n \ln X_i$$

对 α 求偏导并令其为 0:

$$\frac{\partial l}{\partial \alpha} = \frac{n}{\alpha} + n \ln \hat{\theta} - \sum_{i=1}^n \ln X_i = 0$$

解得:

$$\frac{n}{\alpha} = \sum_{i=1}^n \ln X_i - n \ln X_{(1)} = \sum_{i=1}^n (\ln X_i - \ln X_{(1)})$$

$$\hat{\alpha}_{MLE} = \frac{n}{\sum_{i=1}^n \ln(X_i/X_{(1)})}$$

综上所述, θ 和 α 的 MLE 分别为:

$$\hat{\theta} = X_{(1)}, \quad \hat{\alpha} = \frac{n}{\sum_{i=1}^n \ln(X_i/X_{(1)})}$$

(2) 回顾似然函数 (即联合密度):

$$f(x; \alpha, \theta) = \underbrace{\alpha^n \theta^{n\alpha} \exp\left(-\alpha \sum_{i=1}^n \ln x_i\right)}_{g(T(x); \alpha, \theta)} \underbrace{I(X_{(1)} \geq \theta) \cdot \left(\prod_{i=1}^n x_i\right)^{-1}}_{h(x)}$$

观察 $g(\cdot)$ 部分, 其依赖于样本 x 仅通过两个量: 1. $X_{(1)}$ (用于示性函数 $I(X_{(1)} \geq \theta)$) 2. $\sum_{i=1}^n \ln x_i$ (用于指数项)

因此, 统计量组 $T = (X_{(1)}, \sum_{i=1}^n \ln X_i)$ 是 (α, θ) 的联合充分统计量。考察 MLE 统计量, 可以看出 MLE 向量与充分统计量组 T 之间存在一一对应 (双射) 关系:

$$\begin{aligned} X_{(1)} &= \hat{\theta} \\ \sum_{i=1}^n \ln X_i &= \frac{n}{\hat{\alpha}} + n \ln \hat{\theta} \end{aligned}$$

因为充分统计量的一一变换仍为充分统计量, 故 $(\hat{\alpha}_{MLE}, \hat{\theta}_{MLE})$ 是参数 (α, θ) 的联合充分统计量。

十、承接上题背景, 设总体 X 服从帕累托分布。设 $X_1, \dots, X_n$ 为来自该总体的独立同分布样本。定义变换后的随机变量 $Y_i = \frac{X_i}{\theta}$ 和 $Z_i = \ln Y_i$ 。

(1) 计算生存函数 $P(Y_i > x)$ 与 $P(Z_i > x)$;

(2) 已知 $\alpha > 2$, 证明极大似然估计量的相合性: $\hat{\theta}_{MLE} \rightarrow \theta, \hat{\alpha}_{MLE}^{-1} \rightarrow \alpha^{-1}$ 。

Solution:

(1) 由题意 $Y_i = \frac{X_i}{\theta}$, 即服从尺度参数为 1 的标准帕累托分布。由于 $X_i \geq \theta$, 故随机变量 Y_i 的支撑集为 $[1, +\infty)$ 。对于任意 $x \geq 1$:

$$P(Y_i > x) = P\left(\frac{X_i}{\theta} > x\right) = P(X_i > \theta x) = \left(\frac{\theta x}{\theta}\right)^{-\alpha} = x^{-\alpha}$$

若 $x < 1$, 则 $P(Y_i > x) = 1$ 。

由题意 $Z_i = \ln Y_i$ 。由于 $Y_i \geq 1$, 故 $Z_i \geq 0$ 。对于任意 $x \geq 0$:

$$P(Z_i > x) = P(\ln Y_i > x) = P(Y_i > e^x) = (e^x)^{-\alpha} = e^{-\alpha x}$$

若 $x < 0$, 则 $P(Z_i > x) = 1$ 。由于 $P(Z_i > x) = e^{-\alpha x} (x \geq 0)$ 对应于指数分布的生存函数, 故 $Z_i \sim \text{Exp}(\alpha)$ 。

(2) 证明:

首先回顾无约束条件下的似然方程求解。似然函数为 $L(\theta, \alpha) = \alpha^n \theta^{n\alpha} \prod_{i=1}^n x_i^{-(\alpha+1)} \mathbb{I}_{\{x_{(1)} \geq \theta\}}$ 。关于 θ 单调递增, 故 $\hat{\theta}_{MLE} = X_{(1)}$ 。关于 α 的对数似然函数求导为零可得无约束估计量 (记为 $\hat{\alpha}_u$):

$$\hat{\alpha}_u = \frac{n}{\sum_{i=1}^n \ln(X_i/X_{(1)})}$$

由于题目限制参数空间 $\alpha > 2$, 似然函数在 α 轴上是单峰的。当 $\hat{\alpha}_u \leq 2$ 时, 似然函数在 $(2, \infty)$ 上单调递减, 极大值在边界处取得 (或趋于边界)。因此, 修正后的极大似然估计量为:

$$\hat{\alpha}_{MLE} = \max(2, \hat{\alpha}_u)$$

对应地，其倒数为：

$$\hat{\alpha}_{MLE}^{-1} = \min\left(\frac{1}{2}, \hat{\alpha}_u^{-1}\right)$$

先证明 $\hat{\theta}_{MLE}$ 的相合性，考察 $\hat{\theta}_{MLE}$ 的依概率收敛性。对于任意 $\epsilon > 0$ ：

$$\begin{aligned} P(|\hat{\theta}_{MLE} - \theta| > \epsilon) &= P(X_{(1)} - \theta > \epsilon) \quad (\text{因 } X_{(1)} \geq \theta \text{ 必然成立}) \\ &= P(X_{(1)} > \theta + \epsilon) \\ &= \prod_{i=1}^n P(X_i > \theta + \epsilon) \\ &= \left[\left(\frac{\theta + \epsilon}{\theta}\right)^{-\alpha}\right]^n \\ &= \left(1 + \frac{\epsilon}{\theta}\right)^{-n\alpha} \end{aligned}$$

由于 $\alpha > 2$ 且 $\epsilon > 0$ ，底数大于 1，当 $n \rightarrow \infty$ 时，上式极限为 0。即 $\hat{\theta}_{MLE} \xrightarrow{P} \theta$ 。

下面证明 $\hat{\alpha}_{MLE}^{-1}$ 的相合性，首先分析无约束估计量的倒数 $\hat{\alpha}_u^{-1}$ ：

$$\hat{\alpha}_u^{-1} = \frac{1}{n} \sum_{i=1}^n \ln\left(\frac{X_i}{X_{(1)}}\right) = \frac{1}{n} \sum_{i=1}^n \ln\left(\frac{X_i}{\theta}\right) - (\ln X_{(1)} - \ln \theta)$$

令 $Z_i = \ln(X_i/\theta)$ 。由第 (1) 问知 $Z_i \sim \text{Exp}(\alpha)$ ，其期望 $E[Z_i] = 1/\alpha$ 。根据弱大数定律 (WLLN)，第一项 $\frac{1}{n} \sum Z_i \xrightarrow{P} 1/\alpha$ 。根据连续映射定理及 $\hat{\theta}_{MLE} \xrightarrow{P} \theta$ ，第二项 $\ln X_{(1)} - \ln \theta \xrightarrow{P} 0$ 。由 Slutsky 定理，无约束估计量满足相合性：

$$\hat{\alpha}_u^{-1} \xrightarrow{P} \frac{1}{\alpha}$$

现在考虑约束条件的影响。由于真实参数满足 $\alpha > 2$ ，即 $\frac{1}{\alpha} < \frac{1}{2}$ 。令函数 $g(t) = \min(\frac{1}{2}, t)$ 。由于 $g(t)$ 是连续函数，且 $\hat{\alpha}_u^{-1} \xrightarrow{P} \frac{1}{\alpha}$ ，根据连续映射定理：

$$\hat{\alpha}_{MLE}^{-1} = g(\hat{\alpha}_u^{-1}) \xrightarrow{P} g\left(\frac{1}{\alpha}\right)$$

因为 $\frac{1}{\alpha} < \frac{1}{2}$ ，所以 $g\left(\frac{1}{\alpha}\right) = \min\left(\frac{1}{2}, \frac{1}{\alpha}\right) = \frac{1}{\alpha}$ 。●

综上所述，即便存在参数限制，极大似然估计量依然满足相合性：

$$\hat{\alpha}_{MLE}^{-1} \xrightarrow{P} \alpha^{-1}$$

十一、设总体 X 的生存函数为 $P(X > x) = \frac{1}{1+x^\alpha}$ 。考虑如下假设检验问题：

$$H_0: \alpha = 1 \leftrightarrow H_1: \alpha = 2$$

现有两个检验（拒绝域）： $*W_1 = \{X_{(1)} > 5\}$ ，即当样本最小值大于 5 时拒绝 H_0 ； $*W_2 = \{X_{(n)} > 5\}$ ，即当样本最大值大于 5 时拒绝 H_0 。

- (1) 求检验 W_1 的第二类错误概率 β_1 ；
- (2) 求检验 W_2 的第二类错误概率 β_2 ；
- (3) 分析随着样本量的变化， $1 - \beta_1$ 与 $1 - \beta_2$ 的变化趋势，并指出哪个检验更合理。

Solution:

首先计算在备择假设 $H_1(\alpha = 2)$ 成立下, 单个样本落在临界值之外的概率。记 p 为在 H_1 下, 单个样本 $X_i > 5$ 的概率:

$$p = P(X_i > 5|H_1) = \frac{1}{1+5^2} = \frac{1}{26}$$

记 q 为在 H_1 下, 单个样本 $X_i \leq 5$ 的概率:

$$q = P(X_i \leq 5|H_1) = 1 - p = \frac{25}{26}$$

(1) 求 β_1 。根据定义, 第二类错误指的是“当 H_1 为真时, 接受 H_0 (即未落入拒绝域)”的概率。对于检验 W_1 , 拒绝域为 $\{X_{(1)} > 5\}$, 故接受域 (未拒绝域) 为 $\bar{W}_1 = \{X_{(1)} \leq 5\}$ 。

$$\begin{aligned}\beta_1 &= P(X_{(1)} \leq 5|H_1) \\ &= 1 - P(X_{(1)} > 5|H_1) \\ &= 1 - P(X_1 > 5, X_2 > 5, \dots, X_n > 5|H_1) \\ &= 1 - \prod_{i=1}^n P(X_i > 5|H_1) \\ &= 1 - \left(\frac{1}{26}\right)^n\end{aligned}$$

(2) 求 β_2 。对于检验 W_2 , 拒绝域为 $\{X_{(n)} > 5\}$, 故接受域 (未拒绝域) 为 $\bar{W}_2 = \{X_{(n)} \leq 5\}$ 。

$$\begin{aligned}\beta_2 &= P(X_{(n)} \leq 5|H_1) \\ &= P(X_1 \leq 5, \dots, X_n \leq 5|H_1) \\ &= \prod_{i=1}^n P(X_i \leq 5|H_1) \\ &= \left(\frac{25}{26}\right)^n\end{aligned}$$

(3) 这里题目的意思是让我们通过比较检验的功效 $(1 - \beta)$ 来分析两个检验的合理性。

对于检验 W_1 , 其功效为:

$$1 - \beta_1 = \left(\frac{1}{26}\right)^n$$

显然, $\lim_{n \rightarrow \infty} (1 - \beta_1) = 0$ 。这说明随着样本量的增加, 检验 W_1 拒绝错误原假设的概率趋近于 0, 这是一个完全失效的检验。

对于检验 W_2 , 其功效为:

$$1 - \beta_2 = 1 - \left(\frac{25}{26}\right)^n$$

由于 $0 < \frac{25}{26} < 1$, 故 $\lim_{n \rightarrow \infty} (1 - \beta_2) = 1$ 。这说明随着样本量增加, 检验 W_2 犯第二类错误的概率趋近于 0, 具有相合性。

因此, 仅从减小第二类错误 (或提高功效) 的角度来看, 检验 W_2 比 W_1 更合理, 因为 W_1 的功效随样本量增加而消失, 而 W_2 的功效随样本量增加而趋于 1。

Remark: 关于题目严谨性的讨论: 虽然从比较 β 的角度得出了 W_2 较优的结论, 但这道题目给出的拒绝域设定在统计学上是不严谨的, 甚至是不合理的。我们在选择检验时, 通常要求先控制第一类错误概率 (显著性水平 α_{level}), 再尽可能减小第二类错误概率。

让我们计算检验 W_2 的第一类错误概率 (记为 α_{W_2}): 在 $H_0: \alpha = 1$ 成立时, 单个样本 $X_i > 5$ 的概率为 $P(X_i > 5|H_0) = \frac{1}{1+5} = \frac{1}{6}$, 故 $X_i \leq 5$ 的概率为 $\frac{5}{6}$ 。

$$\begin{aligned}\alpha_{W_2} &= P(X_{(n)} > 5|H_0) \\ &= 1 - P(X_{(n)} \leq 5|H_0) \\ &= 1 - \left(\frac{5}{6}\right)^n\end{aligned}$$

由此可见: 1. 当 $n \rightarrow \infty$ 时, $\alpha_{W_2} \rightarrow 1$ 。这意味着在大样本下, W_2 几乎必然拒绝原假设 (即使原假设是真的)。
2. 即便在 $n = 1$ 时, 犯第一类错误的概率也高达 $1/6 \approx 0.167$ (远超通常的 0.05)。

综上, W_2 虽然功效高, 但它是以牺牲第一类错误概率 (使其趋近于 1) 为代价的。一个不做任何数据分析直接拒绝 H_0 的检验, 其功效也是 1, 但显然是无用的。因此, 题目中给出的两个拒绝域在实际应用中均不合理。

十二、设样本 $X_i \sim \text{Exp}(\lambda^3)$, 即服从参数为 λ^3 的指数分布。参数 λ 的先验分布为 Gamma 分布结构:

$$\pi(\lambda) \propto \lambda^{\alpha-1} e^{-\beta\lambda}, \quad \lambda > 0, \alpha > 0, \beta > 0$$

求 λ 的后验众数 $\hat{\lambda}$, 并验证 $\hat{\lambda}$ 满足方程:

$$\frac{\alpha + 3n - 1}{\lambda} - \beta - 3\lambda^2 \sum_{i=1}^n x_i = 0$$

且为最大值点。

Solution:

首先写出似然函数, 已知单个样本的概率密度函数为 $f(x_i|\lambda) = \lambda^3 e^{-\lambda^3 x_i}$ 。对于 n 个独立同分布的样本 $x = (x_1, \dots, x_n)$, 似然函数 $L(\lambda|x)$ 为:

$$\begin{aligned}L(\lambda|x) &= \prod_{i=1}^n f(x_i|\lambda) \\ &= \prod_{i=1}^n (\lambda^3 e^{-\lambda^3 x_i}) \\ &= (\lambda^3)^n \cdot \exp\left(-\lambda^3 \sum_{i=1}^n x_i\right) \\ &= \lambda^{3n} \exp(-\lambda^3 S_n)\end{aligned}$$

其中 $S_n = \sum_{i=1}^n x_i$ 。接下来推导后验分布, 根据贝叶斯公式, 后验分布 $\pi(\lambda|x)$ 正比于似然函数乘以先验分布:

$$\begin{aligned}\pi(\lambda|x) &\propto L(\lambda|x) \cdot \pi(\lambda) \\ &\propto \lambda^{3n} e^{-\lambda^3 S_n} \cdot \lambda^{\alpha-1} e^{-\beta\lambda} \\ &= \lambda^{3n+\alpha-1} \exp(-\beta\lambda - \lambda^3 S_n)\end{aligned}$$

下面求解后验众数 $\hat{\lambda}$, 后验众数即使后验密度函数 $\pi(\lambda|x)$ 达到最大的 λ 值。为了便于计算, 我们取对数后验函数, 记为 $l(\lambda)$:

$$l(\lambda) = \ln \pi(\lambda|x) = (3n + \alpha - 1) \ln \lambda - \beta\lambda - S_n \lambda^3 + C$$

其中 C 为与 λ 无关的常数项。对 $l(\lambda)$ 关于 λ 求一阶导数, 并令其为 0:

$$\frac{dl(\lambda)}{d\lambda} = \frac{3n + \alpha - 1}{\lambda} - \beta - 3\lambda^2 S_n$$

令 $l'(\hat{\lambda}) = 0$ 并将 $S_n = \sum_{i=1}^n x_i$ 代回，我们得到方程：

$$\frac{\alpha + 3n - 1}{\hat{\lambda}} - \beta - 3\hat{\lambda}^2 \sum_{i=1}^n x_i = 0$$

此结果与题目中要求验证的方程完全一致。

为了确认该驻点 $\hat{\lambda}$ 确实是极大值点（即后验众数），我们需要检查二阶导数。再次求导：

$$\begin{aligned} l''(\lambda) &= \frac{d}{d\lambda} \left(\frac{3n + \alpha - 1}{\lambda} - \beta - 3S_n \lambda^2 \right) \\ &= -(3n + \alpha - 1)\lambda^{-2} - 0 - 6S_n \lambda \\ &= -\frac{3n + \alpha - 1}{\lambda^2} - 6\lambda \sum_{i=1}^n x_i \end{aligned}$$


由于 λ 是指数分布的参数，必有 $\lambda \geq 0$ 。样本观测值 $x_i \geq 0$ ，故 $S_n \geq 0$ 。先验参数 $\alpha > 0$ 且 $n \geq 1$ ，则系数 $(3n + \alpha - 1)$ 为正。因此，每一项均为非正数，即 $l''(\lambda) < 0$ 。说明对数后验函数 $l(\lambda)$ 是严格凹函数。因此，满足一阶条件的驻点 $\hat{\lambda}$ 必然是全局最大值点。

北京师范大学-432 统计学

北京师范大学-432 统计学-2016 年

一、选择题 (15 分)

1. 下面关于箱线图和算术平均数正确的是 ().



- A. 平均数大于 15
- B. 平均数等于 15
- C. 平均数小于 15
- D. 无法判断

Solution: A.

2. 技术人员对某生产线上的产品每隔 100 件抽样一次, 他使用的抽样方法是 ().

- A. 简单随机抽样
- B. 整群抽样
- C. 分层抽样
- D. 系统抽样

Solution: D.

3. 根据样本已经得到了 θ 的 95% 置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$, 正确的是 ().

- A. 该区间以 95% 的概率包含真值
- B. 参数 θ 在该区间内的概率为 95%
- C. 该区间有 95% 的可能性包含参数 θ
- D. 参数 θ 或者在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内, 或者不在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内

Solution: D. 此时已经根据样本值得到了一个固定的置信区间, 参数要么在这个固定的区间中, 要么不在其中. 注意如果题干改为抽样之前, 则由于样本还未获得, 两个区间端点都是随机的, 随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 覆盖参数真值 θ 的概率是 95%. 但现在, 区间已定, 参数也是个常数, 要么在里面, 要么不在里面.

4. 设 $X \sim N(\mu, \sigma^2)$, 则当 σ 增大时, 概率 $P(|X - \mu| < \sigma)$ 逐渐 ().

- A. 增大
- B. 减小
- C. 不变
- D. 无法确定

Solution: C. $P(|X - \mu| < \sigma) = P\left(\frac{|X - \mu|}{\sigma} < 1\right) = \Phi(1) - \Phi(-1)$ 是定值.

5. 某校学生的成绩服从正态分布 $X \sim N(\mu, 36)$, 在显著性水平 $\alpha = 0.05$ 的情况下, 则要使估计 μ 的测量误差控制在 ± 1 之内, 需要多少样本量 ().

- A. 139
- B. 2238
- C. 48

D. 934

Solution: A. $\bar{X} \sim N(\mu, \frac{36}{n})$, 令 $P(|\bar{X} - \mu| \leq 1) = 0.95$, 化简得

$$P\left(\frac{|\bar{X} - \mu|}{6/\sqrt{n}} \leq \frac{\sqrt{n}}{6}\right) = 0.95,$$

这也意味着 $\frac{\sqrt{n}}{6} = u_{0.025} = 1.96$, 解得 $n = 6^2 \cdot 1.96^2 = 138.298$.

二、问答题

1. (10 分) 抽样调查的主要优点有哪些?

Solution: 1、抽样调查可以减少调查的工作量, 调查内容可以求多、求全或求专, 可以保证调查对象的完整性。

2、可以从数量上以部分推算总体, 利用概率论和数理统计原理, 以一定的概率保证推算结果的可靠程度, 起到全面调查认识总体的功能, 可以保证调查的精度。

3、因为抽样调查是针对总体中的一部分单位进行的, 抽样调查可以大大减少调查费用, 提高调查效率。

4、收集、整理数据、综合样本的速度快, 保证调查的时效性。

2.(10 分) 某篮球队队员年龄为 37, 35, 32, 28, 27, 27, 24, 22, 19, 写出这组数据的分析报告。

Solution: (i) 可以用平均值、中位数、标准差等统计量作分析; (ii) 可以用箱线图、茎叶图等图形作分析; (iii) 可以用集中趋势、离散趋势、分布形状作分析。

这里, 有 $\bar{x} = 27.89$, $s = 5.93$, 变异系数 $C = 0.21$, 中位数 $M = 27$.

茎叶图为

茎	叶
3	7 5 2
2	8 7 7 4 2
1	9

分析: 变异系数较小, 仅为 0.21, 说明数据集中程度较高. 茎叶图中可以也看出, 年龄主要集中在 20 多岁。

3. (12 分) 一个罐子里有黑球和白球, 有放回地抽取一个样本容量为 n 的样本, 其中有 k 个白球, 问: 罐子里黑球和白球数之比 R 的极大似然估计量如何?

Solution: 有放回取球, 取出的白球数 $k \sim B(n, p)$, 其中 p 是白球的比例. 有 $\hat{p} = \frac{k}{n}$, 而 $\frac{1-p}{p} = R$, 根据 MLE 的不变性, 有

$$\hat{R} = \frac{1 - \frac{k}{n}}{\frac{k}{n}} = \frac{n - k}{k}.$$

4. (12 分) 机场大巴从起点站到西单站恰有 n 站, 某次大巴从机场开出时有 m 位旅客, 每位旅客在每站下车都是等可能的 (即每人都有 n 次下车选择), 如果无人下车则中途不停车. 求机场大巴到西单站的平均停车次数。

Solution: $n \left[1 - \left(1 - \frac{1}{n}\right)^m\right]$. 设 $X_1, \dots, X_n$ 分别是各站停车次数, $X_1 = 1$ 表示在第一站停车, $X_1 = 0$ 表示不停车, 则题目所求即为 $E(X) = E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n) = nE(X_1)$. 而

$$E(X_1) = P(X_1 = 1) = 1 - P(X_1 = 0) = 1 - \left(1 - \frac{1}{n}\right)^m,$$

因此 $E(X) = n \left[1 - \left(1 - \frac{1}{n}\right)^m\right]$.

5. (15 分) 下面论述是否正确? 正确的给出证明, 错误的举出反例。

(1) 概率为 0 的事件是不可能事件;

(2) 概率为 1 的事件是必然事件;

(3) 小概率事件迟早会发生。

(1) 错误. 如设 $\Omega = [0, 1]$, $A = \{\frac{1}{2}\}$, 显然 A 并非不可能事件 (并非 $\emptyset$), 但 $P(A) = 0$, 在线段上取到单点的概率为 0.

(2) 错误, 如设 $\Omega = [0, 1]$, $A = [0, 1)$, 显然 A 并非必然事件 (并非全集 Ω), 但 $P(A) = 1$.

(3) 正确, 设事件 $A_1, A_2, \dots$ 发生的概率都非常小, 为 $\varepsilon > 0$, 一直不发生的概率为

$$P\left(\bigcap_{i=1}^{\infty} \bar{A}_i\right) = \prod_{i=1}^{\infty} P(\bar{A}_i) = \lim_{n \rightarrow \infty} (1 - \varepsilon)^n = 0.$$

因此迟早会发生.

6. (20 分) 设 $X_1, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的独立样本.

(1) (7 分) 求 μ, σ^2 的 MLE, 它们是无偏估计吗?

(2) (6 分) 写出样本方差的表达式, 它是无偏估计吗?

(3) (7 分) 如果 $\sigma^2 = 4$, 求 μ 的 $1 - \alpha$ 置信区间.

Solution: 似然函数为

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2},$$

对数似然函数是

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

求导得

$$\ell'(\mu) = -\frac{2 \sum_{i=1}^n (x_i - \mu)}{2\sigma^2}, \quad \ell'(\sigma^2) = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4},$$

令其为 0, 解得

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

$E(\hat{\mu}) = \mu$, 是无偏估计. 但由于 $\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2} \sim \chi^2(n-1)$, 因此 $E(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2$, 不是无偏估计.

(2) 样本方差的表达式是

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

根据第 (1) 问的论述, 它是 σ^2 的无偏估计.

(3) 利用 $\bar{X} \sim N(\mu, \frac{4}{n})$ 构造区间, 即有

$$\mu \in \left[\bar{X} - u_{\frac{\alpha}{2}} \frac{2}{\sqrt{n}}, \bar{X} + u_{\frac{\alpha}{2}} \frac{2}{\sqrt{n}} \right].$$

7. (15 分) 设 $X_1, \dots, X_n$ 是来自一个期望为 μ , 方差为 σ^2 的正态总体独立样本.

(1) (7 分) 为使得 $C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 为 σ^2 的无偏估计, 求 C .

(2) (8 分) $\bar{x}^2$ 是 μ^2 的无偏估计吗? 若不是, 给出 μ^2 的一个无偏估计.

Solution:

(1) 由正态分布性质, 有 $X_{i+1} - X_i \sim N(0, 2\sigma^2)$, 故 $E(X_{i+1} - X_i)^2 = 2\sigma^2$, 由期望的线性可加性, 有

$$E\left[C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2\right] = C \cdot (n-1) \cdot 2\sigma^2,$$

因此 $C = \frac{1}{2(n-1)}$.

(2) 由于 $\bar{x} \sim N(\mu, \frac{\sigma^2}{n})$, 故 $E(\bar{x}^2) = \mu^2 + \frac{\sigma^2}{n}$, 它不是 μ^2 的无偏估计, 修正后看出 $\bar{x}^2 - \frac{S^2}{n}$ 恰好是 μ^2 的无偏估计, 其中 S^2 是样本方差.

8. (15 分) 从 $N(\mu, 1)$ 总体抽取 100 个随机样本 $x_1, \dots, x_{100}$, 为讨论假设检验问题

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$$

构造拒绝域 $W = \{|\bar{x}| < 0.001\}$.

(1)(8 分) 已知 $\Phi(0.01) < 0.505$, 证明犯第一类错误概率 $\alpha < 0.01$;

(2)(7 分) W 是一个合适的拒绝域吗? 为什么?

Solution: (1) 样本均值 $\bar{x} \sim N(\mu, \frac{1}{100})$, 故有

$$\alpha = P_{\mu=0}(|\bar{X}| < 0.001) = P_{\mu=0}(|10\bar{X}| < 0.01) = 2\Phi(0.01) - 1 < 0.01.$$

(2) 不是, 题目所给的 $|\bar{x}| < 0.001$ 实际反而反映了 $|\mu|$ 比较小, 接近于 0, 正确的拒绝域形式应是形如 $\{|\bar{x}| > c\}$, 其中 c 可由显著性水平确定.

10. (20 分) 有下述一元线性回归模型

$$Y_i = a + bX_i + \varepsilon_i$$

以及对应的方差分析表.

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	1212	1			0.0001
残差					
总	1888	29			

(1)(7 分) 补齐方差分析表.

(2)(8 分) 给定 $\alpha = 0.05$, 方程是否显著? 写出原假设和备择假设.

Solution: [注]: 自由度与样本量、参数的关系是: 假设有 n 个样本、 k 个参数, 如 $y = a + bx$ 是 2 个参数, 如 $y = a + b_1x_1 + b_2x_2$ 是 3 个参数, 则总自由度 $n - 1$, 回归自由度 $k - 1$, 残差自由度 $n - k$.

(1) 补齐后如下:

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	1212	1	1212	50.21	0.0001
残差	676	28	24.14		
总	1888	29			

(2) 方程是显著的, 因为 F 检验的 p 值是 $0.0001 < 0.05$, 拒绝原假设. 对应的原假设和备择假设是

$$H_0: \beta = 0 \quad \text{vs} \quad H_1: \beta \neq 0$$

北京师范大学-432 统计学-2017 年

一、选择题 (15 分)

1. 分布中位数小于平均数, 则一般来说, 该分布 ().

- A. 左偏
- B. 右偏
- C. 正偏
- D. 无偏

Solution: B.

2. 根据样本已经得到了 θ 的 95% 置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$, 正确的是 ().

- A. 该区间以 95% 的概率包含真值
- B. 参数 θ 在该区间内的概率为 95%
- C. 该区间有 95% 的可能性包含参数 θ
- D. 参数 θ 或者在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内, 或者不在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内

Solution: D. 此时已经根据样本值得到了一个固定的置信区间, 参数要么在这个固定的区间中, 要么不在其中. 注意如果题干改为抽样之前, 则由于样本还未获得, 两个区间端点都是随机的, 随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 覆盖参数真值 θ 的概率是 95%. 但现在, 区间已定, 参数也是个常数, 要么在里面, 要么不在里面.

3. 下列说法错误的是 ()

- A. 两类错误之和可以大于 1
- B. 假设检验与置信区间没有联系
- C. 增大样本量可以同时提高置信度和精度
- D. 独立一定不相关

Solution: B. 假设检验的接受域与置信区间有对偶关系.

4. 技术人员对某生产线上的产品每隔 10 件抽样一次, 他使用的抽样方法是 ().

- A. 简单随机抽样
- B. 整群抽样
- C. 分层抽样
- D. 系统抽样

Solution: D.

5. 设有来自方差为 σ^2 的总体的随机样本 $X_1, \dots, X_n$, 定义样本均值 $\bar{X}$, 则有 $Var(X_1 - \bar{X}) = ()$.

- A. σ^2
- B. $\frac{n-2}{n}\sigma^2$
- C. $\frac{n+1}{n}\sigma^2$
- D. $\frac{n-1}{n}\sigma^2$

Solution: D. 注意协方差不为 0, 有

$$\begin{aligned} Var(X_1 - \bar{X}) &= Var(X_1) + Var(\bar{X}) - 2Cov(X_1, \bar{X}) \\ &= \sigma^2 + \frac{\sigma^2}{n} - 2\frac{\sigma^2}{n} = \frac{n-1}{n}\sigma^2. \end{aligned}$$

二、问答题

1. (10 分) 随机变量的定义是什么?

Solution: 随机变量本质是一个实值函数, 若有可测空间 $(\Omega, \mathcal{F})$, 则随机变量是

$$X(\omega) : \Omega \rightarrow R,$$

且满足对任意 $x \in R$, 有

$$\{\omega : X(\omega) \leq x\} \in \mathcal{F}.$$

2.(10 分) 某篮球队队员年龄为 37, 35, 32, 28, 27, 27, 24, 22, 19, 写出这组数据的分析报告.

Solution: (i) 可以用平均值、中位数、标准差等统计量作分析; (ii) 可以用箱线图、茎叶图等图形作分析; (iii) 可以用集中趋势、离散趋势、分布形状作分析.

这里, 有 $\bar{x} = 27.89$, $s = 5.93$, 变异系数 $C = 0.21$, 中位数 $M = 27$.

茎叶图为

茎	叶
3	7 5 2
2	8 7 7 4 2
1	9

分析: 变异系数较小, 仅为 0.21, 说明数据集中程度较高. 茎叶图中可以也看出, 年龄主要集中在 20 多岁.

3.(12 分) 一学生接连参加同一课程的两次考试, 第一次及格的概率是 p , 若第一次及格则第二次及格的概率是 p ; 若第一次不及格则第二次及格的概率是 $\frac{p}{2}$. 求:

(1) 若至少有一次及格则他能够取得某资格, 求他取得该资格的概率;

(2) 若已知他第二次已经及格, 求他第一次及格的概率.

Solution: (1) 利用对立事件,

$$P(A) = 1 - P(\bar{A}) = 1 - (1 - p) \left(1 - \frac{p}{2}\right) = 1 - \left(1 - \frac{3p}{2} + \frac{p^2}{2}\right) = \frac{3p - p^2}{2}.$$

(2) 利用条件概率公式

$$P(B_1|B_2) = \frac{P(B_1B_2)}{P(B_2)} = \frac{p^2}{p^2 + (1-p)\frac{p}{2}} = \frac{2p}{p+1}.$$

4. (10 分) 有奖竞猜活动, 三个门里分别是汽车、羊、羊, 猜中汽车得奖. 你先选一个, 然后主持人把没有汽车的门打开, 问: 你此时要不要换? 为什么?

【注意】: 这里要添加一个前提, 那就是主持人是知道门后的东西的, 即他能保证一定打开一扇门, 门后是山羊.

Solution: 首先, 不换获得汽车的概率是 $\frac{1}{3}$. 下面我们考虑换门获得汽车的概率.

总共只有三种情况: (i) 设我们选的是一号羊, 则主持人打开另外一只羊的门, 换门获得汽车; (ii) 设我们选的是二号羊, 则主持人打开另外一只羊的门, 换门获得汽车; (iii) 设我们选的是汽车, 则主持人随便打开一只羊的门, 换门不获得汽车.

综上所述, 只要我们一开始没有选对, 换门都将获得汽车, 这一概率是 $\frac{2}{3}$. 所以我们要换门.

5. (15 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $N(\mu, \sigma^2)$ 的随机样本, 其中 μ, σ^2 是未知参数.

(1) (7 分) 样本标准差是总体标准差无偏估计吗?

(2) (8 分) $\bar{x}^2$ 是 μ^2 的无偏估计吗? 若不是, 给出 μ^2 的一个无偏估计.

Solution: (1) 不是. 已知 $E(S^2) = \sigma^2$, 而

$$\text{Var}(S) = E(S^2) - [E(S)]^2 > 0,$$

即 $[E(S)]^2 < E(S^2) = \sigma^2$, 故 $E(S) < \sigma$.

(2) 由于 $\bar{x} \sim N(\mu, \frac{\sigma^2}{n})$, 故 $E(\bar{x}^2) = \mu^2 + \frac{\sigma^2}{n}$, 它不是 μ^2 的无偏估计, 修正后看出 $\bar{x}^2 - \frac{\sigma^2}{n}$ 恰好是 μ^2 的无偏估计.

6.(15 分) (1) 比较均值、众数、中位数的特点, 并举例说明;

(2) 比较标准差和变异系数的特点, 并举例说明;

(3) 说明标准分数的计算公式, 并说明其意义.

Solution: (1) 平均数、中位数、众数都是度量一组数据集中趋势的统计量。所谓集中趋势是指一组数据向某一中心值靠拢的倾向, 测度集中趋势就是寻找数据一般水平的代表值或中心值。而这三个特征数又各有特点, 能够从不同的角度提供信息。

[平均数] 特点: 计算用到所有的数据, 它能够充分利用数据提供的信息, 它具有良好的数学性质, 因此在实际应用中较为广泛。但它受极端值的影响较大。应用场合: 没有极端值的情况下数据集中趋势的刻画, 例如考研数学平均衡量今年数学难度。

[中位数] 特点: 中位数是一组数据中间位置的代值。计算简单, 不受极端值的影响, 但不能充分利用每个数据所提供的信息。应用场合: 有极端值, 且无某数据重复出现多次的情况下集中趋势的刻画, 例如工资收入的中位数衡量了一个公司员工工资的整体水平。

[众数] 特点: 众数是一组数据中出现次数最多的数据。不受极端值的影响, 当一组数据中某些数据多次重复出现时, 众数往往是人们最关心的一个量。但它不能象平均数那样充分利用数据提供信息。应用场合: 有极端值, 有某些数据多次重复出现时, 如某鞋店卖出鞋码的众数应被进货最多。

(2) 1. 变异系数是无量纲的, 而平均值和标准差的量纲相同都为随机变量的量纲。2. 比较量纲不同的两个随机变量的分散度时用变异系数为好。3. 量纲相同的两个随机变量但平均值差别较大时用变异系数评价分散度。4. 用变异系数评价分散度时消除了平均值大小的影响。

(3) 用公式表示为: $z = (x - \mu)/\sigma$; 其中 z 为标准分数; x 为某一具体分数, μ 为平均数, σ 为标准差。 z 值的量代表着原始分数和母体平均值之间的距离, 是以标准差为单位计算。在原始分数低于平均值时 z 则为负数, 反之则为正数。

7.(15 分) 某人每天上班路上花费 X 分钟, 是随机变量 $N(50, 100)$ 。七点出发, 八点上班。

(1)(7 分) 他某天迟到的概率是多少?

(2)(8 分) 一周 (5 天) 最多迟到一天的概率是多少? 可能用到的: $\Phi(1) = 0.8413$, $\Phi(2) = 0.9772$ 。

Solution: (1) $P(X \geq 60) = P(\frac{X-50}{10} \geq -1) = 1 - \Phi(-1) = \Phi(1) = 0.1587$ 。

(2) 一周迟到天数是 $Y \sim B(5, 0.1587)$, 而

$$P(Y \geq 1) = 0.82.$$

8. (15 分) 设 $X_1, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的独立样本。

(1) (7 分) 求 σ^2 的 MLE, 它是无偏估计吗?

(2) (8 分) 如果 $\sigma^2 = 9$, 求 μ 的 $1 - \alpha$ 置信区间。

Solution: (1) 似然函数为

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2},$$

对数似然函数是

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

求导得

$$\ell'(\mu) = -\frac{2 \sum_{i=1}^n (x_i - \mu)}{2\sigma^2}, \quad \ell'(\sigma^2) = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4},$$

令其为 0, 解得

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

由于 $\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2} \sim \chi^2(n-1)$, 因此 $E(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2$, 不是无偏估计.

(2) 利用 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ 构造区间, 即有

$$\mu \in \left[\bar{X} - u_{\frac{\alpha}{2}} \frac{3}{\sqrt{n}}, \bar{X} + u_{\frac{\alpha}{2}} \frac{3}{\sqrt{n}} \right].$$

9.(15 分) 从 $N(\mu, 1)$ 总体抽取 100 个随机样本 $x_1, \dots, x_{100}$, 为讨论假设检验问题

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$$

构造拒绝域 $W = \{|\bar{x}| < 0.001\}$.

(1)(8 分) 已知 $\Phi(0.01) < 0.505$, 证明犯第一类错误概率 $\alpha < 0.01$;

(2)(7 分) W 是一个合适的拒绝域吗? 为什么?

Solution: (1) 样本均值 $\bar{x} \sim N(\mu, \frac{1}{100})$, 故有

$$\alpha = P_{\mu=0}(|\bar{X}| < 0.001) = P_{\mu=0}(|10\bar{X}| < 0.01) = 2\Phi(0.01) - 1 < 0.01.$$

(2) 不是, $|\bar{x}| < 0.001$ 实际正反应了 $|\mu|$ 比较小, 接近于 0, 正确的拒绝域形式应是形如 $\{|\bar{x}| > c\}$, 其中 c 可由显著性水平确定.

10. (18 分) 有下述一元线性的方差分析表

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	612	1			0.0001
残差					
总	888	29			

(1)(4 分) 样本量和参数分别是几个?

(2)(4 分) 补齐方差分析表.

(3)(5 分) 给定 $\alpha = 0.05$, 方程是否显著?

(4)(5 分) 给出 R^2 , 以及误差方差的估计量.

Solution: (1) 回归平方和的自由度为 1, 说明参数为 2 个. 总平方和的自由度为 29, 说明样本量是 30.

(2) 补齐后为

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	612	1	612	62.07	0.0000
残差	276	28	9.86		
总	888	29			

(3) 方程是显著的, 因为 F 检验的 p 值是 $0.0000 < 0.05$, 拒绝原假设.

(4) $R^2 = \frac{612}{888} = 0.689$, 残差方差的估计量是残差对应的均方, 即 9.86.

北京师范大学-432 统计学-2018 年

一、选择题 (每题 3 分, 共 15 分) 1. 箱线图最中间的线表明的数据是 ().

- A. 平均数
- B. 中位数
- C. 众数
- D. 都不是

Solution: B.

2. 技术人员对某生产线上的产品每隔 100 件抽样一次, 他使用的抽样方法是 ().

- A. 简单随机抽样
- B. 整群抽样
- C. 分层抽样
- D. 系统抽样

Solution: D.

3. 根据样本已经得到了 θ 的 95% 置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$, 正确的是 ().

- A. 该区间以 95% 的概率包含真值
- B. 参数 θ 在该区间内的概率为 95%
- C. 该区间有 95% 的可能性包含参数 θ
- D. 参数 θ 或者在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内, 或者不在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内

Solution: D. 此时已经根据样本值得到了一个固定的置信区间, 参数要么在这个固定的区间中, 要么不在其中. 注意如果题干改为抽样之前, 则由于样本还未获得, 两个区间端点都是随机的, 随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 覆盖参数真值 θ 的概率是 95%. 但现在, 区间已定, 参数也是个常数, 要么在里面, 要么不在里面.

4. 线性回归分析的说法, 正确的是 ().

- A. 选择解释变量时, 残差平方和越小越好
- B. 线性检验是指对变量的线性关系检验
- C. 线性回归中, t 检验与 F 检验等价
- D. 残差与误差有相同的分布, 可用残差估计误差

Solution: B. 变量越多, 残差平方和一定越小, 而选择解释变量时, 以变量对应系数是否能显著为准, A 错误; 线性检验是对变量之间线性关系的检验, B 正确; 一元回归时单个系数的显著性 t 检验与方程整体的 F 检验一致, 注意 $t^2(1, n-1) = F(1, n-1)$, 但多元回归中并不等价, C 错误; 误差 $\varepsilon_i = y_i - a - bx_i \sim N(0, \sigma^2)$, 残差指 $\hat{\varepsilon}_i = y_i - \hat{y}_i = y_i - \hat{a} - \hat{b}x_i$, 它们分布不相同, D 错误.

5. 如果 $\text{Var}(X)$ 存在, 下面说法错误的是 ().

- A. EX 一定存在
- B. $EX^2 > (EX)^2$ 一定成立
- C. 对于 $C \neq EX, \text{Var}(X) < E(X - C)^2$
- D. 标准差 $\sqrt{\text{Var}(X)}$ 一定存在

Solution: B. 如果 $\text{Var}(X) = 0$, 则 $P(X = c) = 1$, 说明 $EX^2 = (EX)^2$.

二、问答题

6. (10 分) 为什么总体可以用随机变量表示?

Solution: 在统计推断过程中, 待研究的对象是总体的分布或总体分布中的某些参数, 我们需要根据得到的随机样本来推断出总体分布或参数的信息. 如果总体不是随机变量而是常数或已知数, 那么也没有必要去研究它的分布和参数. 一般而言, 我们假设总体是一个有分布 $f(x; \theta)$ 的随机变量, 而 $x_1, \dots, x_n$ 是来自该分布的随机样本, 通过样本的信息我们可以得到一些关于 θ 的信息.

7. (10 分) 某高校教研室老师年龄为 60, 58, 46, 46, 41, 43, 38, 38, 34, 31, 写出这组数据的分析报告.

Solution: (i) 可以用平均值、中位数、标准差等统计量作分析; (ii) 可以用箱线图、茎叶图等图形作分析; (iii) 可以用集中趋势、离散趋势、分布形状作分析.

这里, 有 $\bar{x} = 43.5$, $s = 9.48$, 变异系数 $C = 0.28$, 中位数 $M = 42$.

茎叶图为

茎	叶
6	0
5	8
4	6 6 3 1
3	8 8 4 1

分析: 变异系数较小, 仅为 0.28, 说明数据集中程度较高. 茎叶图中可以也看出, 年龄主要集中在 30 多岁和 40 多岁.

8. (15 分) 一架主机、两架副机被派遣前往目的地执行轰炸任务, 目标是击毁敌方的“火种源”. 到达目的地的过程中需要主机为两架副机持续提供燃油, 到达目的地后独立执行轰炸任务, 每架飞机击中“火种源”的概率是 0.3. 但是在前往目的地的过程中要经过敌区, 在此过程中每架飞机均有 0.2 的概率被击落. 问: “火种源”被击中的概率是多少?

Solution: 我们先思考: “有哪些我方战机能到达目的地”, 根据题意, 主机如果被击毁, 没有燃油, 副机也到不了目的地, 故

$$B_1 = \{\text{三架战斗机均到达目的地}\}, \quad P(B_1) = 0.8^3 = 0.512,$$

$$B_2 = \{\text{主机和一架副机到达目的地}\}, \quad P(B_2) = 2 \cdot 0.8^2 \cdot 0.2 = 0.256,$$

$$B_3 = \{\text{只有主机到达目的地}\}, \quad P(B_3) = 0.8 \cdot 0.2^2 = 0.032,$$

$$B_4 = \{\text{无人到达目的地}\}, \quad P(B_4) = 1 - 0.512 - 0.256 - 0.032 = 0.2,$$

再用全概率公式, 得

$$P(A) = 0.512 \cdot (1 - 0.7^3) + 0.256 \cdot (1 - 0.7^2) + 0.032 \cdot 0.3 = 0.476544.$$

9. (15 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $U(\theta, \theta + 1)$ 的随机样本.

(1)(8 分) 求矩估计和极大似然估计;

(2)(7 分) 比较说明矩估计和极大似然估计及其优缺点.

Solution: (1) 先求矩估计, 期望是 $E(X) = \theta + \frac{1}{2}$, 则矩估计 $\hat{\theta}_m = \bar{x} - \frac{1}{2}$. 再看极大似然估计, 似然函数是

$$L(\theta) = I_{\{x_{(n)} - 1 < \theta < x_{(1)}\}},$$

看出, 区间 $[x_{(n)} - 1, x_{(1)}]$ 中任意一个值都是 θ 的 MLE.

(2) 根据大数定律, 矩估计总是相合的; 但矩估计不一定是充分统计量的函数. MLE 则一般都和充分统计量有关, 但缺点是可能不唯一.

10. (15 分) 设有 n 个独立工作的元件, 故障率为 0.1, 现在某项任务一定要 80% 以上原件工作才能完成. 为了以 95% 的把握保证这一事件的成立, 问 n 至少应为多少?

Solution: 设 $X_1, \dots, X_n$ i.i.d. 服从 $B(1, 0.9)$, 且 $X_i = 1$ 表示第 i 个元件正常工作, 题设要求为

$$P\left(\sum_{i=1}^n X_i > 0.8n\right) = 0.95,$$

由于大样本下近似有 $\sum_{i=1}^n X_i \sim N(0.9n, 0.09n)$, 故

$$0.95 = P\left(\sum_{i=1}^n X_i > 0.8n\right) = P\left(\frac{\sum_{i=1}^n X_i - 0.9n}{0.3\sqrt{n}} > -\frac{\sqrt{n}}{3}\right) = \Phi\left(\frac{\sqrt{n}}{3}\right),$$

这意味着 $\frac{\sqrt{n}}{3} = 1.645$, 即 $n = 24.35$, 故至少为 25.

11. (15 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $N(\mu, \sigma^2)$ 的随机样本, 其中 μ, σ^2 是未知参数.

(1) (7 分) 写出样本方差表达式, 它是总体方差无偏估计吗?

(2) (8 分) $\bar{x}^2$ 是 μ^2 的无偏估计吗? 若不是, 给出 μ^2 的一个无偏估计.

Solution: (1) 样本方差是

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

它是总体方差的无偏估计.

(2) 由于 $\bar{x} \sim N(\mu, \frac{\sigma^2}{n})$, 故 $E(\bar{x}^2) = \mu^2 + \frac{\sigma^2}{n}$, 它不是 μ^2 的无偏估计, 修正后看出 $\bar{x}^2 - \frac{S^2}{n}$ 恰好是 μ^2 的无偏估计.

12. (15 分) 从 $N(\mu, 1)$ 总体抽取 100 个随机样本 $x_1, \dots, x_{100}$, 为讨论假设检验问题

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$$

构造拒绝域 $W = \{|\bar{x}| < 0.001\}$.

(1)(8 分) 已知 $\Phi(0.01) < 0.505$, 证明犯第一类错误概率 $\alpha < 0.01$;

(2)(7 分) W 是一个合适的拒绝域吗? 为什么?

Solution: (1) 样本均值 $\bar{x} \sim N(\mu, \frac{1}{100})$, 故有

$$\alpha = P_{\mu=0}(|\bar{X}| < 0.001) = P_{\mu=0}(|10\bar{X}| < 0.01) = 2\Phi(0.01) - 1 < 0.01.$$

(2) 不是, $|\bar{x}| < 0.001$ 实际正反应了 $|\mu|$ 比较小, 接近于 0, 正确的拒绝域形式应是形如 $\{|\bar{x}| > c\}$, 其中 c 可由显著性水平确定.

13. (15 分) 设 $X_1, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的独立样本.

(1) (7 分) 如果 $\mu = 90$, 求 σ^2 的 MLE;

(2) (8 分) 如果 $\sigma^2 = 9$, 求 μ 的 $1 - \alpha$ 置信区间.

Solution: (1) μ 已知, 似然函数为

$$L(\sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2},$$

对数似然函数是

$$\ell(\sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

求导得

$$\ell'(\sigma^2) = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4},$$

令其为 0, 解得

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - 90)^2.$$

(2) 利用 $\bar{X} \sim N(\mu, \frac{9}{n})$ 构造区间, 即有

$$\mu \in \left[\bar{X} - u_{\frac{\alpha}{2}} \frac{3}{\sqrt{n}}, \bar{X} + u_{\frac{\alpha}{2}} \frac{3}{\sqrt{n}} \right].$$

14. (20 分) 有下述线性回归的方差分析表

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	2144.6	2			0.0001
残差		98			
总	8545.6	100			

(1)(5 分) 样本量和参数分别是几个?

(2)(5 分) 补齐方差分析表.

(3)(5 分) 给定 $\alpha = 0.05$, 方程是否显著?

(4)(5 分) 给出 R^2 , 以及误差方差的估计量.

Solution: (1) 回归平方和的自由度为 2, 说明参数为 3 个. 总平方和的自由度为 100, 说明样本量是 101.

(2) 补齐后为

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	2144.6	2	1072.3	17.5	0.0001
残差	6001.0	98	61.2		
总	8545.6	100			

(3) 方程是显著的, 因为 F 检验的 p 值是 $0.0001 < 0.05$, 拒绝原假设.

(4) $R^2 = \frac{2144.6}{8545.6} = 0.251$, 残差方差的估计量是残差对应的均方, 即 61.2.

北京师范大学-432 统计学-2019 年

一、选择题 (每题 5 分, 总计 30 分)

1. 在某公司进行的英语水平测试中, 新员工的平均得分是 80 分, 标准差是 5 分, 中位数是 85 分, 则新员工得分的分布形状是 ().

- A. 对称的
- B. 左偏的
- C. 右偏的
- D. 无法确定

Solution: B. 平均值小于中位数, 说明是左偏的.

2. 从 0-9 选一个数字, 检查学号尾号是此数的学生, 这种抽样方法是 ().

- A. 简单随机抽样
- B. 系统抽样
- C. 方便抽样
- D. 整群抽样

Solution: B.

3. 根据样本已经得到了 θ 的 95% 置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$, 正确的是 ().

- A. 该区间以 95% 的概率包含真值
- B. 参数 θ 在该区间内的概率为 95%
- C. 该区间有 95% 的可能性包含参数 θ
- D. 参数 θ 或者在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内, 或者不在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内

Solution: D. 此时已经根据样本值得到了一个固定的置信区间, 参数要么在这个固定的区间中, 要么不在其中. 注意如果题干改为抽样之前, 则由于样本还未获得, 两个区间端点都是随机的, 随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 覆盖参数真值 θ 的概率是 95%. 但现在, 区间已定, 参数也是个常数, 要么在里面, 要么不在里面.

4. 线性回归分析的说法, 正确的是 ().

- A. 选择解释变量时, 残差平方和越小越好
- B. 线性检验是指对系数的线性关系检验
- C. 一元线性回归中, t 检验与 F 检验等价
- D. 残差与误差有相同的分布, 可用残差估计误差

Solution: C. 变量越多, 残差平方和一定越小, 而选择解释变量时, 以变量对应系数是否能显著为准; 线性检验是对变量之间线性关系的检验; 一元回归时单个系数的显著性 t 检验与方程整体的 F 检验一致, 注意 $t^2(1, n-1) = F(1, n-1)$; 误差 $\varepsilon_i = y_i - a - bx_i \sim N(0, \sigma^2)$, 残差指 $\hat{\varepsilon}_i = y_i - \hat{y}_i = y_i - \hat{a} - \hat{b}x_i$, 它们分布不相同.

5. X, Y 各自服从: $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 当 $P(|X - \mu_1| < 1) > P(|Y - \mu_2| < 1)$ 时, 比较 ().

- A. $\mu_1 > \mu_2$
- B. $\mu_1 < \mu_2$
- C. $\sigma_1 > \sigma_2$
- D. $\sigma_1 < \sigma_2$

Solution: D. 显然不等式条件无法分辨 μ_1 与 μ_2 . 而我们知道

$$2\Phi\left(\frac{1}{\sigma_1}\right) - 1 = P(|X - \mu_1| < 1) > P(|Y - \mu_2| < 1) = 2\left(\frac{1}{\sigma_2}\right) - 1,$$

这说明 $\sigma_1 < \sigma_2$.

6. 设 $X_1, X_2, \dots, X_n$ 为来自正态分布 $N(\mu, \sigma^2)$ 的样本, 其中 σ^2 为已知, $\bar{X}$ 为样本均值. 考虑如下假设检验: $H_0: \mu \leq \mu_0$ v.s. $H_1: \mu > \mu_0$, 标准正态分布的 95% 分位数为 1.645, 在显著性水平为 0.05 时, 拒绝 H_0 等价于 ().

- A. 单侧区间 $\left(\bar{X} + 1.645 \frac{\sigma}{\sqrt{n}}, +\infty\right)$ 不包含 μ_0
 B. 单侧区间 $\left(-\infty, \bar{X} - 1.645 \frac{\sigma}{\sqrt{n}}\right)$ 包含 μ_0
 C. 单侧区间 $\left(-\infty, \bar{X} - 1.645 \frac{\sigma}{\sqrt{n}}\right)$ 不包含 μ_0
 D. 单侧区间 $\left(\bar{X} + 1.645 \frac{\sigma}{\sqrt{n}}, +\infty\right)$ 包含 μ_0 ;

Solution: B. 依题意, 可知这是一个正态总体均值的右单侧检验, 拒绝域为

$$W = \left\{ \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > 1.645 \right\}$$

这等价于 $\mu_0 < \bar{X} - 1.645 \frac{\sigma}{\sqrt{n}}$, 所以选项 B 正确.

二、分析计算题 (共 120 分)

7. (12 分) 10 份外卖订单完成时间为 23.34.45.39.822.87.115.521.526.227.0, (单位 min), 要求用至少两种统计指标和统计图进行分析报告.

Solution: 统计图: 可用茎叶图, 箱线图, 直方图. 统计指标: 平均数, 中位数, 众数, 方差, 极差等.

8. (15 分) 将 A, B, C 三个字母之一输入信道, 输出原字母的概率为 α , 而输出其它任一字母的概率都是 $(1-\alpha)/2$. 现将字母串 AAA, BBB, CCC 之一输入信道, 输入 AAA, BBB, CCC 的概率分别为 0.4, 0.3, 0.3. 已知输出为 ABC, 问输入的是 AAA 概率是多少? (假设信道传输每个字母的工作是独立的)

Solution: 根据贝叶斯公式有

$$P(\text{IN} : \text{AAA} | \text{OUT} : \text{ABC}) = \frac{P(\text{OUT} : \text{ABC} | \text{IN} : \text{AAA})P(\text{IN} : \text{AAA})}{P(\text{OUT} : \text{ABC})}$$

其中 $P(\text{IN} : \text{AAA}) = 0.4, P(\text{OUT} : \text{ABC} | \text{IN} : \text{AAA}) = \alpha \left(\frac{1-\alpha}{2}\right)^2$, 而

$$\begin{aligned} P(\text{OUT} : \text{ABC}) &= \sum_{x \in \{\text{AAA}, \text{BBB}, \text{CCC}\}} P(\text{OUT} : \text{ABC} | \text{IN} : x) P(\text{IN} : x) \\ &= \left[0.4\alpha \left(\frac{1-\alpha}{2}\right)^2 + 0.3\alpha \left(\frac{1-\alpha}{2}\right)^2 + 0.3\alpha \left(\frac{1-\alpha}{2}\right)^2 \right] \\ &= \left(\frac{1-\alpha}{2}\right)^2 \alpha \end{aligned}$$

因此 $P(\text{IN} : \text{AAA} | \text{OUT} : \text{ABC}) = 0.4$.

9. (15 分) 概率为 1 的事件的积事件一定是概率 1 事件吗? 说明你的理由.

Solution: 是的. 设 $A_1, A_2, \dots$ 都是概率 1 事件, 则它们对立事件都是 0 概率事件, 则有

$$P\left(\bigcap_{i=1}^{\infty} A_i\right) = 1 - P\left(\bigcup_{i=1}^{\infty} \bar{A}_i\right) \geq 1 - \sum_{i=1}^{\infty} P(\bar{A}_i) = 1,$$

其中用到了德摩根公式和次可加性.

10. (16 分) 某天体专家取多次测量平均值作为实际估计值. 假设各测量值是独立同分布的随机变量, 已知测量方差为 4, 若想以 95% 的把握使误差控制在 ± 0.5 之内, 问: 至少需要测量多少次?

Solution: 以 $\bar{X}$ 估计 μ , 假设是正态分布,

$$\bar{X} \sim AN\left(\mu, \frac{4}{n}\right),$$

根据题设要求

$$0.95 = P\left(|\bar{X} - \mu| \leq 0.5\right) = P\left(\sqrt{\frac{n}{4}} |\bar{X} - \mu| \leq 0.5\sqrt{\frac{n}{4}}\right) = 2\Phi\left(0.5\sqrt{\frac{n}{4}}\right) - 1,$$

意味着 $0.5\sqrt{\frac{n}{4}} = u_{0.025} = 1.96$, 解得

$$n = 61.4656$$

即至少 62 次.

11. (15 分) 总体 $X \sim N(\mu_1, \sigma_0^2)$, σ_0^2 已知, 样本量为 n_1 . 总体 $Y \sim N(\mu_2, \sigma_1^2)$, 样本量为 n_2 . 两组样本独立.

(1)(5 分) 写出 μ_1 的 $1 - \alpha$ 置信区间;

(2)(5 分) 写出 μ_2 的 $1 - \alpha$ 置信区间;

(3)(5 分) 若 $\sigma_0^2 = \sigma_1^2$, 写出 $(\mu_1 - \mu_2)$ 的 $1 - \alpha$ 置信区间.

Solution: (1) 方差已知, 用枢轴量

$$u = \frac{\bar{X} - \mu_1}{\sigma_0/\sqrt{n_1}} \sim N(0, 1),$$

置信区间是

$$\mu_1 \in \left[\bar{X} - \frac{\sigma_0}{\sqrt{n_1}} u_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma_0}{\sqrt{n_1}} u_{\frac{\alpha}{2}} \right].$$

(2) 方差未知, 用枢轴量

$$t = \frac{\bar{Y} - \mu_2}{S_Y/\sqrt{n_2}} \sim t(n_2 - 1),$$

置信区间是

$$\mu_2 \in \left[\bar{Y} - \frac{S_Y}{\sqrt{n_2}} t_{\frac{\alpha}{2}}(n_2 - 1), \bar{Y} + \frac{S_Y}{\sqrt{n_2}} t_{\frac{\alpha}{2}}(n_2 - 1) \right].$$

(3) 由于 $\sigma_0 = \sigma_1$ 已知, 故有

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2}\right) \sigma_0^2\right),$$

枢轴量为

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1),$$

因此置信区间为

$$\mu_1 - \mu_2 \in \left[\bar{X} - \bar{Y} - u_{\frac{\alpha}{2}} \sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}, \bar{X} - \bar{Y} + u_{\frac{\alpha}{2}} \sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} \right].$$

12. (16 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $U(\theta - 1, \theta + 1)$ 的随机样本.

(1)(8 分) 求矩估计和极大似然估计;

(2)(8 分) 比较说明矩估计和极大似然估计及其优缺点.

Solution: (1) 先求矩估计, 期望是 $E(X) = \theta$, 则矩估计 $\hat{\theta}_m = \bar{x}$. 再看极大似然估计, 似然函数是

$$L(\theta) = \frac{1}{2^n} I_{\{x_{(n)} - 1 < \theta < x_{(1)} + 1\}},$$

看出, 区间 $[x_{(n)} - 1, x_{(1)} + 1]$ 中任意一个值都是 θ 的 MLE.

(2) 根据大数定律, 矩估计总是相合的; 但矩估计不一定是充分统计量的函数. MLE 则一般都和充分统计量有关, 但缺点是可能不唯一.

13. (16 分) 从 $N(\mu, 1)$ 总体抽取 100 个随机样本 $x_1, \dots, x_{100}$, 为讨论假设检验问题

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$$

构造拒绝域 $W = \{|\bar{x}| < 0.001\}$.

(1)(8 分) 已知 $\Phi(0.01) < 0.505$, 证明犯第一类错误概率 $\alpha < 0.01$;

(2)(8 分) W 是一个合适的拒绝域吗? 为什么?

Solution: (1) 样本均值 $\bar{x} \sim N(\mu, \frac{1}{100})$, 故有

$$\alpha = P_{\mu=0}(|\bar{X}| < 0.001) = P_{\mu=0}(|10\bar{X}| < 0.01) = 2\Phi(0.01) - 1 < 0.01.$$

(2) 不是, $|\bar{x}| < 0.001$ 实际正反应了 $|\mu|$ 比较小, 接近于 0, 正确的拒绝域形式应是形如 $\{|\bar{x}| > c\}$, 其中 c 可由显著性水平确定.

14. (16 分) 设有位置模型:

$$X_i = \mu + \varepsilon_i,$$

其中 $\varepsilon_1, \dots, \varepsilon_n$ 独立同分布, 期望为 0, 方差为 σ^2 .

(1)(8 分) 给出 μ 的两种估计及统计原理.

(2)(8 分) 给出 σ^2 的无偏估计 $\hat{\sigma}^2$, 并判断 $\hat{\sigma}$ 是否为 σ 的无偏估计.

Solution: (1) 第一种: 矩估计, 用矩替换. 求期望得 $E(X_1) = \mu$, 因此 $\hat{\mu} = \bar{x}$.

第二种: 最小二乘法. 令

$$Q(\mu) = \sum_{i=1}^n (X_i - \mu)^2$$

最小, 也得 $\hat{\mu} = \bar{x}$.

第三种: 最小一乘法. 令

$$Q(\mu) = \sum_{i=1}^n |X_i - \mu|$$

最小, 得 $\hat{\mu} = x_{0.5}$, 即样本中位数.

注意这里没有分布条件, 不能求 MLE.

(2) 样本方差是总体方差的无偏估计, 故

$$\hat{\sigma}^2 = s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

但是由于

$$E(s^2) = \text{Var}(s) + [E(s)]^2,$$

即有

$$E(s) = \sqrt{E(s^2) - \text{Var}(s)} < \sqrt{E(s^2)} = \sigma.$$

它不是无偏估计.

北京师范大学-432 统计学-2020 年

一、选择题 (每题 3 分, 总计 15 分)

1. 如果数据没有离群值, 箱线图显示的信息不包括 ().

- A. 平均数
- B. 四分位数
- C. 极差
- D. 中位数

Solution: A.

2. 某医生为写论文收集数据, 使用了他自己过往的病情经历, 这种抽样方式称为 ().

- A. 整群抽样
- B. 非随机的方便抽样
- C. 系统抽样
- D. 简单随机抽样

Solution: B.

3. 构造 θ 的 $1 - \alpha$ 置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$, 正确的是 ().

- A. 总体参数一定在区间中
- B. 区间一定覆盖总体参数
- C. $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是统计量
- D. 置信区间是唯一的

Solution: C.

4. 在线性回归模型 $y_i = a + bx_i + \varepsilon_i, i = 1, \dots, n$ 中, 正确的是 ().

- A. (a, b) 的最小二乘估计与最大似然估计等价
- B. 最小二乘法中的残差和为 0
- C. 参数显著性 t 检验不需要假设正态分布
- D. 以上均错误

Solution: D. 如果不给定分布, 无法求得最大似然估计, A 错, 且只有在 ε 是正态分布时两者等价 (高斯-马尔可夫定理). 最小二乘法需求残差平方和最小, 与残差和无关, B 错. 如果没有正态假设, 无法导出检验统计量服从 t 分布, C 错.

5. 抛 n 次硬币, X 是正面向上次数, Y 是反面向上次数, 则 $\text{Corr}(X, Y) = ()$.

- A. -1
- B. 1
- C. 0
- D. 0.5

Solution: A. 由于 $X + Y = n$, 故 $\text{Var}(Y) = \text{Var}(n - X) = \text{Var}(X)$, $\text{Cov}(X, Y) = \text{Cov}(X, n - X) = -\text{Var}(X)$, 因此

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = -1.$$

二、计算题 (总计 135 分)

1. (10 分) 简要给出该组数据统计分析报告(统计指标和统计图). 甲的射击成绩: 81, 88, 84, 80, 90, 83, 80, 90, 81, 85 乙的射击成绩: 92, 85, 88, 81, 81, 86, 81, 76, 81, 89

Solution: 对甲的射击成绩进行分析: $\bar{X}_{\text{甲}} = \frac{1}{n} \sum_{i=1}^n X_i = 85.8$, $S_{\text{甲}}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = 12.4$, $S_{\text{甲}} = 3.52$, 下四分位数位置: $(n+1)/4 = 2.75$, $QL = 82 + 0.75 \times (82 - 82) = 82$, 中位数位置: $(n+1)/2 = (10+1)/2 = 5.5$,

$Me = (86 + 87)/2 = 86.5$, 上四分位数位置: $3(n+1)/4 = 8.25$, $QU = 88 + 0.25 \times (89 - 88) = 88.25$, 变异系数: $V = \frac{s}{\bar{X}} = \frac{3.52}{85.8} = 0.041$.

对乙的射击成绩进行分析: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = 83.5$, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = 20.94$, $S_Z = 4.58$, 下四分位数位置: $(n+1)/4 = 2.75$, $QL = 81 + 0.75 \times (81 - 81) = 81$ 中位数位置: $(n+1)/2 = (10+1)/2 = 5.5$, $Me = (81 + 83)/2 = 82$, 上四分位数位置: $3(n+1)/4 = 8.25$, $QU = 87 + 0.25 \times (88 - 87) = 87.25$, 变异系数: $V = \frac{s_Z}{\bar{X}} = \frac{4.58}{83.5} = 0.055$.

茎叶图:

叶 (甲)	茎	叶 (乙)
	7	6
9 8 8 7 6 5 2 2 0	8	1 1 1 1 3 5 7 8
1	9	2

2. (10 分) 概率与频率的关系是什么? 频率的极限是概率吗?

Solution: 概率是定义在测度空间上的实值函数, 频率指的则是收集到样本后计算出的事件发生的比例. 从定义上来看, 频率也满足概率的三公理.

在某种意义上, 频率的极限是概率, 以两点分布为例, $X_1, \dots, X_n$ 是 i.i.d. 的 $b(1, p)$, 这里 p 是概率, $\bar{X}$ 是频率, 根据大数定律, $\bar{X}$ 依概率收敛到 p .

3. (10 分) 一个不透明的袋子有 $n-1$ 个黑球和 1 个白球, 每次从中取 1 个并放入 1 个黑球, 问第 n 次取出的是黑球的概率.

Solution: 茆原题. 设 $A_n =$ 第 n 次摸到黑球, 则

$$P(A_n) = 1 - P(\bar{A}_n) = 1 - \left(1 - \frac{1}{n}\right)^{n-1} \frac{1}{n},$$

这里 $P(\bar{A}_n)$ 即为之前一直抽黑, 第 n 次取白的概率.

4. (10 分) 甲乙进行一个 5 局 3 胜的比赛, 甲赢一局的概率是 0.6, 乙赢一局的概率是 0.4, 现在甲已经赢了 2 局, 问: 甲最终获胜的概率.

Solution: 除非乙连续赢 3 局, 否则都是甲赢, 故

$$P(\text{甲}) = 1 - P(\text{乙}) = 1 - 0.4^3 = 0.936.$$

5. (10 分) 某地质专家想测量某山的高度, 取多次测量取平均值作为实际高度估计值. 假设各测量值是独立同分布的随机变量, 已知测量方差为 2, 若想以 95% 的把握使误差控制在 ± 1 之内, 问: 至少需要测量多少次?

Solution: 以 $\bar{X}$ 估计 μ , 假设是正态分布,

$$\bar{X} \sim AN\left(\mu, \frac{2}{n}\right),$$

根据题设要求

$$0.95 = P\left(|\bar{X} - \mu| \leq 1\right) = P\left(\sqrt{\frac{n}{2}} |\bar{X} - \mu| \leq \sqrt{\frac{n}{2}}\right) = 2\Phi\left(\sqrt{\frac{n}{2}}\right) - 1,$$

意味着 $\sqrt{\frac{n}{2}} = u_{0.025} = 1.96$, 解得

$$n = 2 \times 1.96^2 = 7.6832,$$

即至少 8 次.

6. (15 分) 总体 $X \sim N(\mu_1, \sigma_0^2)$, σ_0^2 已知, 样本量为 n_1 . 总体 $Y \sim N(\mu_2, \sigma_1^2)$, 样本量为 n_2 . 两组样本独立.

(1)(5 分) 写出 μ_1 的 $1 - \alpha$ 置信区间;

(2)(5 分) 写出 μ_2 的 $1-\alpha$ 置信区间;

(3)(5 分) 若 $\sigma_0^2 = \sigma_1^2$, 写出 $(\mu_1 - \mu_2)$ 的 $1-\alpha$ 置信区间.

Solution: (1) 方差已知, 用枢轴量

$$u = \frac{\bar{X} - \mu_1}{\sigma_0/\sqrt{n_1}} \sim N(0, 1),$$

置信区间是

$$\mu_1 \in \left[\bar{X} - \frac{\sigma_0}{\sqrt{n_1}} u_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma_0}{\sqrt{n_1}} u_{\frac{\alpha}{2}} \right].$$

(2) 方差未知, 用枢轴量

$$t = \frac{\bar{Y} - \mu_1}{S_Y/\sqrt{n}} \sim t(n_2 - 1),$$

置信区间是

$$\mu_1 \in \left[\bar{Y} - \frac{S_Y}{\sqrt{n_2}} t_{\frac{\alpha}{2}}(n_2 - 1), \bar{Y} + \frac{S_Y}{\sqrt{n_2}} t_{\frac{\alpha}{2}}(n_2 - 1) \right].$$

(3) 由于 $\sigma_0 = \sigma_1$ 已知, 故有

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2}\right)\sigma_0^2\right),$$

枢轴量为

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1),$$

因此置信区间为

$$\mu_1 - \mu_2 \in \left[\bar{X} - \bar{Y} - u_{\frac{\alpha}{2}} \sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}, \bar{X} - \bar{Y} + u_{\frac{\alpha}{2}} \sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} \right].$$

7. (15 分) $X_1, X_2, \dots, X_n$ 来自总体 $X \sim [0, 2\theta]$ 的均匀分布.

(1)(8 分) 分别求 θ 的矩估计 $\tilde{\theta}$ 和极大似然估计 $\hat{\theta}$.

(2)(7 分) 讨论 $\hat{\theta}$ 的无偏性, 若非无偏, 则给出一个修正后的无偏估计.

Solution: (1) $E(X) = \theta$, 故矩估计是 $\tilde{\theta} = \bar{X}$. 似然函数是

$$L(\theta) = \frac{1}{2^n \theta^n} I_{\{X_{(n)} \leq 2\theta\}},$$

似然函数关于 θ 递减, 故最大值在 θ 取最小值时达到, 即 $\hat{\theta} = \frac{X_{(n)}}{2}$.

(2) 均匀分布次序统计量结论有 $\frac{X_{(n)}}{2\theta} \sim \text{Beta}(n, 1)$, 故期望是 $E\left[\frac{X_{(n)}}{2\theta}\right] = \frac{n}{n+1}$, 因此 $E[\hat{\theta}] = \frac{n}{n+1}\theta$, 有偏. 修正后的无偏估计是 $\hat{\theta}_a = \frac{n+1}{2n} X_{(n)}$.

8. (15 分) $X_1, \dots, X_n$ 独立同分布, $E(X) = \mu$, $\text{Var}(X) = \sigma^2$.

(1)(5 分) 给出 μ 的最小二乘估计值;

(2)(5 分) 如何判断是否有离群数据? 若有, (1) 的估计会怎样? 有何改进的想法?

(3)(5 分) 样本均值为 $\bar{X}$, 样本方差为 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, S 是 σ 的无偏估计吗? 为什么?

Solution: (1) 设 $X_i = \mu + \varepsilon_i$, 其中 $\varepsilon_1, \dots, \varepsilon_n$ 是 i.i.d. 零均值随机变量, 方差是 σ^2 . 则最小二乘估计意味着

$$Q(\mu) = \sum_{i=1}^n (X_i - \mu)^2$$

达到最小, 求导有 $Q'(\mu) = -2 \sum_{i=1}^n (X_i - \mu) = 0$, 解得 $\hat{\mu} = \bar{X}$.

(2) 利用 3σ 准则可以判断是否有离群值. 离群值将会严重影响样本均值, 即上一问的最小二乘估计. 可以去掉离群值后再重新估计.

(3) 不是. 已知 $E(S^2) = \sigma^2$, 而

$$\text{Var}(S) = E(S^2) - [E(S)]^2 > 0,$$

即 $[E(S)]^2 < E(S^2) = \sigma^2$, 故 $E(S) < \sigma$.

9. (20 分) 作身高 (x) 与臂展 (y) 的一元线性回归: 总计有 $n = 1024$ 个样本, 回归结果如下表

Coefficient	Estimate	Std. Error	t-stat	Pr(> t)
(Intercept)	0.23835	1.91840	0.124	0.901
X	0.99882	0.01096	91.142	0.000

(1)(10 分) 写出参数估计表达式, 根据分析结果写出经验回归方程.

(2)(5 分) 写出误差方差估计的表达式.

(3)(5 分) 说明最后一列 $\text{Pr}(>|t|)$ 的含义, 分别写出对应 H_0, H_1 , 并给出假设检验结果.

Solution: (1) 线性回归 $y = a + bx$ 的参数估计表达式是

$$\hat{b} = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

在回归表中, 结果是

$$y = 0.23835 + 0.99882x.$$

(2) 误差方差的估计是 $\hat{\sigma}^2 = \frac{S_e}{n-2}$, 其中 S_e 是残差平方和, 即 $S_e = \sum_{i=1}^n (y_i - \hat{y}_i)^2$.

(3) $\text{Pr}(>|t|)$ 是指系数是否为 0 的显著性检验的 p 值, 即假设检验问题

$$H_0: a = 0 \quad H_1: a \neq 0$$

和

$$H_0: b = 0 \quad H_1: b \neq 0$$

对应的 p 值. 这里 a 对应的 p 值为 0.901, 不能拒绝原假设, a 不显著. 这里 b 对应的 p 值为 0.000, 拒绝原假设, b 显著, 身高显著影响臂展.

北京师范大学-432 统计学-2021 年

一、选择题 (每题 3 分, 总计 24 分)

1. 若 A 和 B 相互独立, 下列选项正确的是 ()

- A. $P(A\bar{B}) = P(A)P(\bar{B})$
- B. $P(A\bar{B}) > P(A)P(\bar{B})$
- C. $P(A\bar{B}) < P(A)P(\bar{B})$
- D. 以上都不正确

Solution: A. A, B 独立意味着 $A, \bar{B}$ 也独立.

2. 某校学生的成绩服从正态分布 $X \sim N(\mu, 36)$, 在显著性水平 $\alpha = 0.05$ 的情况下, 则要使估计 μ 的测量误差控制在 ± 1 之内, 需要多少样本量 ()

- A. 139
- B. 2238
- C. 48
- D. 934

Solution: A. $\bar{X} \sim N(\mu, \frac{36}{n})$, 令 $P(|\bar{X} - \mu| \leq 1) = 0.95$, 化简得

$$P\left(\frac{|\bar{X} - \mu|}{6/\sqrt{n}} \leq \frac{\sqrt{n}}{6}\right) = 0.95,$$

这也意味着 $\frac{\sqrt{n}}{6} = u_{0.025} = 1.96$, 解得 $n = 6^2 \cdot 1.96^2 = 138.298$.

3. 下列关于直方图和箱线图不正确的是 ()

- A. 直方图柱形面积之和可以大于 1
- B. 箱线图可以展示更多数据
- C. 直方图分组时需要依据总体数量来分组
- D. 在绘制箱线图时, 需要的统计量有最小值、最大值、平均数、 $x_{0.25}$ 分位数和 $x_{0.75}$ 分位数

Solution: D. 还应该有中位数.

4. 对于随机变量 X 与 Y , $X \sim N(0, 1)$, $Y \sim N(0, 1)$, 那么 $X + Y$ 的方差为 ()

- A. 等于 2
- B. 大于 2
- C. 小于 2
- D. 不确定

Solution: D. 不知道 $Cov(X, Y)$, 无法确定.

5. 下列说法错误的是 ()

- A. 两类错误之和可以大于 1
- B. 假设检验与置信区间没有联系
- C. 增大样本量可以同时提高置信度和精度
- D. 独立一定不相关

Solution: B. 假设检验的接受域与置信区间有对偶关系.

6. 已知 X 与 Y 均服从伯努利分布, $b(1, p)$, 且 $Cov(X, Y) = 0$, 则 ()

- A. X 与 Y 独立
- B. X 与 Y 不独立
- C. X, Y 的方差等于 0
- D. X 与 Y 相关

Solution: A. 两值随机变量不相关等价于独立 (茆书原题).

7. 关于置信区间, 不正确的是 ()

- A. 置信区间端点一定是统计量
- B. 置信区间中点一定是无偏估计量
- C. 置信区间可由反转假设检验接受域得到
- D. 置信区间常由枢轴量法构造

Solution: B. 置信区间形式为 $T_1 \leq \theta \leq T_2$, 其中 T_1, T_2 必须是统计量不然无法计算 $P(T_1 \leq \theta \leq T_2)$. 此外, 置信区间中点不一定是无偏估计, 只有很特殊时, 如用正态或者 t 分布此类对称分布构造置信区间时, 才有中点是无偏估计.

8. 设 $X \sim N(\mu, \sigma^2)$, 则当 σ 增大时, 概率 $P(|X - \mu| < \sigma)$ 逐渐 ()

- A. 增大
- B. 减小
- C. 不变
- D. 无法确定

Solution: C. $P(|X - \mu| < \sigma) = P\left(\frac{|X - \mu|}{\sigma} < 1\right) = \Phi(1) - \Phi(-1)$ 是定值.

二、计算分析题 (共 126 分)

1. (16 分) 一个不透明的箱子里有 a 个白球和 b 个红球, k 个人不放回地抽球, 且 $k < a + b$, 求第 i 个人抽到红球的概率.

【提示】: 类似茆书原题 1.5.26, 1.5.27, 用数学归纳法. 这里我们用另外一种条件期望法做.

Solution: 设 X_i 表示第 i 个人抽球时盒中红球数量, 很显然

$$X_1 = b, \quad P(\text{第} i \text{个人抽到红球}) = E\left(\frac{X_i}{a + b - (i - 1)}\right) = \frac{1}{a + b - (i - 1)} \cdot E(X_i),$$

如果 $X_{i-1} = x$ 已知, 则有

$$P(X_i = X_{i-1} - 1 | X_{i-1}) = \frac{X_{i-1}}{a + b - (i - 2)}, \quad P(X_i = X_{i-1} | X_{i-1}) = 1 - \frac{X_{i-1}}{a + b - (i - 2)},$$

求得条件期望为

$$E(X_i | X_{i-1}) = X_{i-1} \left(1 - \frac{1}{a + b - (i - 2)}\right),$$

用重期望公式得

$$E(X_i) = E(X_{i-1}) \left(\frac{a + b - (i - 1)}{a + b - (i - 2)}\right),$$

用递推式得到

$$E(X_i) = E(X_1) \cdot \frac{a + b - 1}{a + b} \cdot \frac{a + b - 2}{a + b - 1} \cdots \frac{a + b - (i - 1)}{a + b - (i - 2)} = \frac{a + b - (i - 1)}{a + b} b,$$

代入得

$$P(\text{第} i \text{个人抽到红球}) = E\left(\frac{X_i}{a + b - (i - 1)}\right) = \frac{1}{a + b - (i - 1)} \cdot E(X_i) = \frac{b}{a + b}.$$

2. (16 分) 两个人打乒乓球, 甲每局获胜概率为 $p > 0.5$, 问:

(1)(8 分) 五局三胜和三局两胜哪个对甲有利?

(2)(8 分) 选择五局三胜, 甲获胜的实际局数的概率分布.

[原题]: 茆 1.5.19.

Solution: (1) 设 $X \sim b(3, p)$, $Y \sim b(5, p)$, 则有

$$P(X \geq 2) = p^3 + 3p^2(1-p),$$

$$P(Y \geq 3) = p^5 + 5p^4(1-p) + 10p^3(1-p)^2,$$

构造函数

$$g(p) = P(Y \geq 3) - P(X \geq 2) = 3p^2(2p^3 - 5p^2 + 4p - 1),$$

考虑 $h(p) = 2p^3 - 5p^2 + 4p - 1$, 显然有 $h(1/2) = h(1) = 0$, 求导得

$$h'(p) = 6p^2 - 10p + 4 = 2(3p^2 - 5p + 2) = 2(3p - 2)(p - 1),$$

看出 $h(p)$ 在 $(1/2, 2/3)$ 严格递增, 但在 $(2/3, 1)$ 严格递减, 而 $h(1/2) = h(1) = 0$, 因此对 $p \in (1/2, 1)$, 有 $h(p) > 0$, 即 $P(Y \geq 3) > P(X \geq 2)$.

(2) 设甲实际获胜时的局数是 $Z \in \{3, 4, 5\}$, 有

$$P(Z = 3) = p^3, \quad P(Z = 4) = C_3^1(1-p)p^3, \quad P(Z = 5) = C_4^2(1-p)^2p^3.$$

3. (16 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $N(\mu, \sigma^2)$, 定义

$$T = \frac{1}{2n(n-1)} \sum_{i=1}^n \sum_{j=1}^n (X_i - X_j)^2,$$

问 T 是否可作为离散程度的衡量标准.

Solution: 可以, 因为 T 就是样本方差 S^2 的恒等变形.

$$\begin{aligned} \sum_{i=1}^n \sum_{j=1}^n (X_i - X_j)^2 &= \sum_{i=1}^n \sum_{j=1}^n (X_i^2 + X_j^2 - 2X_i X_j) \\ &= \sum_{i=1}^n \sum_{j=1}^n (X_i^2 + X_j^2 - 2X_i X_j) \\ &= \sum_{i=1}^n \left(nX_i^2 + \sum_{j=1}^n X_j^2 - 2nX_i \bar{X} \right) \\ &= n \sum_{i=1}^n X_i^2 + n \sum_{j=1}^n X_j^2 - 2n^2 \bar{X}^2 \\ &= 2n \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right), \end{aligned}$$

因此看出

$$T = \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = S^2.$$

4. (16 分) 设某电子产品的寿命服从如下分布:

$$F(x; \alpha, \beta) = \begin{cases} 1 - e^{-\frac{x-\alpha}{\beta}}, & x \geq \alpha \\ 0, & x < \alpha \end{cases}$$

现测得 n 个该电子产品的寿命为 $X_1, X_2, \dots, X_n$, 试求未知参数 α, β 的矩估计和极大似然估计.

Solution: 总体服从双参数指数分布 $\text{Exp}\left(\alpha, \frac{1}{\beta}\right)$, 其中 α 是位置参数, β 是尺度参数, 所以 $EX = \alpha + \beta$, $\text{Var}(X) = \beta^2$, 所以令 $\begin{cases} \bar{x} = \alpha + \beta \\ s^2 = \beta \end{cases}$, 解得矩估计是

$$\begin{cases} \hat{\alpha}_M = \bar{x} - s, \\ \hat{\beta}_M = s, \end{cases}$$

样本的似然函数是

$$\begin{aligned} L(\alpha, \beta) &= \frac{1}{\beta^n} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \alpha)}{\beta}\right\} \mathbf{I}_{\{x_{(1)} \geq \alpha\}} \\ &= \frac{1}{\beta^n} e^{-\frac{n\bar{x}}{\beta}} e^{\frac{\alpha}{\beta}} \mathbf{I}_{\{x_{(1)} \geq \alpha\}}, \end{aligned}$$

显然它是关于 α 在 $(-\infty, x_{(1)})$ 上的增函数, 于是 $\hat{\alpha}_L = x_{(1)}$ 是 α 的极大似然估计. 再求 β 的极大似然估计, 考虑将对数似然函数的偏导置零, 即

$$\frac{\partial \ln L(\alpha, \beta)}{\partial \beta} = -\frac{n}{\beta} + \frac{\sum_{i=1}^n (x_i - \alpha)}{\beta^2} = 0,$$

解得 $\beta = \frac{1}{n} \sum_{i=1}^n (x_i - \alpha)$, 代入 $\hat{\alpha}_L = x_{(1)}$, 得 $\hat{\beta}_L = \bar{x} - x_{(1)}$ 是 β 的极大似然估计.

5. (16 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $N(\mu, \sigma^2)$, 其中 μ 已知, σ^2 未知.

(1)(8 分) 试用两种方法给出 σ^2 的置信区间.

(2)(8 分) 给出 σ^4 的置信区间.

Solution: (1) 可以分别利用

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1), \quad \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$$

来构造区间估计, 它们分别是

$$\left[\frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)} \right], \quad \left[\frac{\sum_{i=1}^n (x_i - \mu)^2}{\chi_{\frac{\alpha}{2}}^2(n)}, \frac{\sum_{i=1}^n (x_i - \mu)^2}{\chi_{1-\frac{\alpha}{2}}^2(n)} \right].$$

(2) 由于 $\{a \leq \sigma^2 \leq b\} = \{a^2 \leq \sigma^4 \leq b^2\}$, 直接得到 σ^4 的区间是

$$\left[\frac{\left[\sum_{i=1}^n (x_i - \mu)^2 \right]^2}{\chi_{\frac{\alpha}{2}}^4(n)}, \frac{\left[\sum_{i=1}^n (x_i - \mu)^2 \right]^2}{\chi_{1-\frac{\alpha}{2}}^4(n)} \right].$$

6. (16 分) 从 $N(\mu, 1)$ 总体抽取 100 个随机样本 $x_1, \dots, x_{100}$, 为讨论假设检验问题

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$$

构造拒绝域 $W = \{|\bar{x}| < 0.001\}$.

(1)(8 分) 已知 $\Phi(0.01) < 0.505$, 证明犯第一类错误概率 $\alpha < 0.01$;

(2)(8 分) W 是一个合适的拒绝域吗? 为什么?

Solution: (1) 样本均值 $\bar{x} \sim N\left(\mu, \frac{1}{100}\right)$, 故有

$$\alpha = P_{\mu=0}(|\bar{X}| < 0.001) = P_{\mu=0}(|10\bar{X}| < 0.01) = 2\Phi(0.01) - 1 < 0.01.$$

(2) 不是, $|\bar{x}| < 0.001$ 实际正反应了 $|\mu|$ 比较小, 接近于 0, 正确的拒绝域形式应是形如 $\{|\bar{x}| > c\}$, 其中 c 可由显著性水平确定.

7. (15 分) 已知 $Y_1, \dots, Y_n$ 是独立随机变量, 其中 $Y_i \sim N(a + bX_i, \sigma^2)$, 其中 $X_1, \dots, X_n$ 是给定常数, 满足 $\sum X_i = 0, \sum X_i^2 > 0$, 试给出

$$T_1 = \bar{Y}, \quad T_2 = \frac{\sum_{i=1}^n X_i Y_i}{\sum_{i=1}^n X_i^2}$$

的分布.

Solution: 它们都是正态的线性组合, 故都是正态分布, 只需求出它们的期望方差即可, 有

$$E(T_1) = \frac{1}{n} \sum_{i=1}^n E(Y_i) = a + b\bar{X} = a, \quad \text{Var}(T_1) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) = \frac{\sigma^2}{n},$$

因此 $T_1 \sim N(a, \frac{\sigma^2}{n})$. 再看 T_2 , 有

$$E(T_2) = \frac{\sum_{i=1}^n X_i (a + bX_i)}{\sum_{i=1}^n X_i^2} = \frac{a \sum_{i=1}^n X_i + b \sum_{i=1}^n X_i^2}{\sum_{i=1}^n X_i^2} = b$$

以及

$$\text{Var}(T_2) = \frac{\sum_{i=1}^n X_i^2 \sigma^2}{(\sum_{i=1}^n X_i^2)^2} = \frac{\sigma^2}{\sum_{i=1}^n X_i^2},$$

因此 $T_2 \sim N\left(b, \frac{\sigma^2}{\sum_{i=1}^n X_i^2}\right)$.

8. (15 分) 检验某产品的次品率 p , 假设检验问题为:

$$H_0: p = 0.1 \quad \text{vs} \quad H_1: p = 0.3$$

检验方法为: 先抽 2 个产品, 都是次品则拒绝原假设, 否则再抽 1 个, 如果第 3 个是次品, 也拒绝原假设 (有放回). 求犯第二类错误的概率.

Solution: 设 $X_k = 1$ 表示第 k 个是次品. 犯第二类错误的概率是

$$\begin{aligned} \beta(0.3) &= P_{p=0.3}(X_1 = 0, X_2 = 0, X_3 = 0) + P_{p=0.3}(X_1 = 1, X_2 = 0, X_3 = 0) \\ &\quad + P_{p=0.3}(X_1 = 0, X_2 = 1, X_3 = 0) = 0.7^3 + 2 \times 0.3 \times 0.7^2 = 0.637. \end{aligned}$$

北京师范大学-432 统计学-2022 年

一、选择题 (每题 3 分, 共 30 分)

1. $P(A) = p_1 > 0, 0 < P(B) = p_2 < 1, A$ 与 B 互不相容, 则 $P(A|B) = ()$.

- A. p_1
- B. p_2
- C. p_1/p_2
- D. 0

Solution: D. 互不相容意味着 $P(AB) = 0$, 故 $P(A|B) = \frac{P(AB)}{P(B)} = 0$

2. 关于古典概率, 下列说法一定错误的是 () .

- A. 所有样本点对应的基本事件和一定为 1
- B. 每个样本点对应的基本事件概率一定相同
- C. 样本点个数可以是无限个
- D. 某事件的概率一定与其所包含的基本事件个数成正比

Solution: C. 古典概型只能是有限样本点.

3. 某个班男生的平均身高标准差为 6 cm, 为估计全校男生的平均身高, 置信水平 95%, 允许误差为 1, 请问所需要的样本个数至少为 () .

- A. 138
- B. 139
- C. 140
- D. 141

Solution: B. 考虑样本均值 $\bar{x}$ 是近似正态分布, 则置信区间为 $\mu \in [\bar{x} - z_{0.025} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{0.025} \frac{\sigma}{\sqrt{n}}]$, 令误差 $z_{0.025} \frac{\sigma}{\sqrt{n}} \leq 1$, 代入 $\sigma = 6, z_{0.025} = 1.96$, 解得 $n \geq 138.3$.

4. 设圆的直径 $d \sim U(a, b)$, 则圆面积的期望 $E(S) = ()$.

- A. $\frac{(b-a)^2}{12}$
- B. $\frac{a+b}{2}$
- C. $\frac{\pi(a^2+ab+b^2)}{12}$
- D. $\frac{\pi(a+b)}{12}$

Solution: C. $d \sim U(a, b), S = \pi r^2 = \frac{\pi}{4} d^2$, 密度函数

$$f(d) = \begin{cases} \frac{1}{b-a} & a \leq d \leq b \\ 0 & \text{其他} \end{cases}$$

求期望 $ES = \int_a^b \frac{\pi}{4} x^2 \cdot \frac{1}{b-a} dx = \frac{\pi}{4(b-a)} \cdot \frac{1}{3} x^3 \Big|_a^b = \frac{\pi(b^3-a^3)}{12(b-a)} = \frac{\pi}{12} (a^2 + ab + b^2)$.

5. 如果 $\text{Var}(X)$ 存在, 下面说法错误的是 () .

- A. EX 一定存在
- B. $EX^2 > (EX)^2$ 一定成立
- C. 对于 $C \neq EX, \text{Var}(X) < E(X-C)^2$
- D. 标准差 $\sqrt{\text{Var}(X)}$ 一定存在

Solution: B. 如果 $\text{Var}(X) = 0$, 则 $P(X=c) = 1$, 说明 $EX^2 = (EX)^2$.

6. 抽样推断的精确度与抽样误差的关系是 () .

- A. 前者提高说明后者变小
- B. 前者提高说明后者变大
- C. 前者提高说明后者不变

D. 没有关系

Solution: A. 要求的精确度越高, 说明置信区间越短, 抽样误差越小.

7. $X_1, \dots, X_n$ 独立同分布, 且 $E(X_1) = \mu, \text{Var}(X_1) = \sigma^2$, 则 $\lim_{n \rightarrow \infty} P(\sum_{k=1}^n X_k < n\mu) = (\quad)$.

A. 0.25

B. 0.5

C. 0.75

D. 1

Solution: B. $\lim_{n \rightarrow \infty} P(\sum_{k=1}^n X_k < n\mu) = \lim_{n \rightarrow \infty} P(\bar{x} < \mu)$, 根据中心极限定理, $\bar{x}$ 近似服从 $N(\mu, \frac{\sigma^2}{n})$, 正态分布小于其期望的概率恰好是 0.5.

8. X 与 Y 独立, 且 XY 均服从 $B(1, 0.4)$, 则 $P(X = Y) = (\quad)$.

A. $\frac{4}{25}$

B. $\frac{6}{25}$

C. $\frac{13}{25}$

D. 0

Solution: C. $P(X = Y) = P(X = Y = 0) + P(X = Y = 1) = \frac{2}{5} \times \frac{2}{5} + \frac{3}{5} \times \frac{3}{5} = \frac{13}{25}$

9. S^2 是从 $N(0, 1)$ 中抽取的 $n = 16$ 的样本方差, 则 $\text{Var}(S^2) = (\quad)$.

A. $\frac{1}{15}$

B. $\frac{2}{15}$

C. $\frac{2}{16}$

D. 1

Solution: B. 由抽样基本定理 (Fisher 引理), 有 $(n-1)S^2 \sim \chi^2(n-1)$, 因此

$$E((n-1)S^2) = n-1, \quad \text{Var}((n-1)S^2) = 2(n-1),$$

解得 $\text{Var}(S^2) = \frac{2}{n-1} = \frac{2}{15}$.

10. $X_1, \dots, X_n$ 为来自 $N(0, \sigma^2)$ 的简单随机样本, 为使得 $C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 为 σ^2 的无偏估计, 则 $C = (\quad)$.

A. $\frac{1}{n-1}$

B. $\frac{1}{n}$

C. $\frac{1}{2(n-1)}$

D. $\frac{1}{2n}$

Solution: C. 由正态分布性质, 有 $X_{i+1} - X_i \sim N(0, 2\sigma^2)$, 故 $E(X_{i+1} - X_i)^2 = 2\sigma^2$, 由期望的线性可加性, 有

$$E[C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2] = C \cdot (n-1) \cdot 2\sigma^2,$$

因此 $C = \frac{1}{2(n-1)}$.

二、计算题 (共 120 分)

1. (10 分) 给出 12 个数据 23、26、31、33、33、34、36、39、40、40、43、49, 用至少两种统计量和统计图进行统计分析.

Solution: 统计分析报告为常考基础题, 务必掌握! 统计图: 可用茎叶图, 箱线图, 直方图. 统计指标: 平均数, 中位数, 众数, 方差, 极差等. 最后给出分析, 可从三个方面展开: 集中趋势, 离散趋势, 分布形状.

2. (15 分) 一个不透明的箱子里有 a 个白球和 b 个红球, k 个人不放回地抽球, 且 $k < a + b$, 求第 i 个人抽到红球的概率.

【提示】：这是 2021 第一大题重复考察，也类似茆书原题 1.5.26, 1.5.27, 用数学归纳法. 这里我们用另外一种条件期望法做.

Solution: 设 X_i 表示第 i 个人抽球时盒中红球数量, 很显然

$$X_1 = b, \quad P(\text{第 } i \text{ 个人抽到红球}) = E\left(\frac{X_i}{a+b-(i-1)}\right) = \frac{1}{a+b-(i-1)} \cdot E(X_i),$$

如果 $X_{i-1} = x$ 已知, 则有

$$P(X_i = X_{i-1} - 1 | X_{i-1}) = \frac{X_{i-1}}{a+b-(i-2)}, \quad P(X_i = X_{i-1} | X_{i-1}) = 1 - \frac{X_{i-1}}{a+b-(i-2)},$$

求得条件期望为

$$E(X_i | X_{i-1}) = X_{i-1} \left(1 - \frac{1}{a+b-(i-2)}\right),$$

用重期望公式得

$$E(X_i) = E(X_{i-1}) \left(\frac{a+b-(i-1)}{a+b-(i-2)}\right),$$

用递推式得到

$$E(X_i) = E(X_1) \cdot \frac{a+b-1}{a+b} \cdot \frac{a+b-2}{a+b-1} \cdots \frac{a+b-(i-1)}{a+b-(i-2)} = \frac{a+b-(i-1)}{a+b} b,$$

代入得

$$P(\text{第 } i \text{ 个人抽到红球}) = E\left(\frac{X_i}{a+b-(i-1)}\right) = \frac{1}{a+b-(i-1)} \cdot E(X_i) = \frac{b}{a+b}.$$

3. (24 分) $X_1, X_2, \dots, X_n$ 相互独立, $X_i \sim N(\beta + \gamma Z_i, \sigma^2)$, $i = 1, 2, \dots, n$, 且 $Z_i + \dots + Z_n = 0$, $Z_1^2 + \dots + Z_n^2 > 0$, 其中 Z_i 是已知数值; β, γ, σ 为未知参数,

(1)(8 分) 求 β, γ, σ^2 的极大似然估计.

(2)(8 分) 分别求 β, γ, σ^2 的 $1 - \alpha$ 的置信区间, 其中给定 $\alpha \in (0, 1)$.

(3)(8 分) 假设 $H_0: \gamma = 0$ vs $H_1: \gamma \neq 0$, 构造 α 水平下的拒绝域.

【提示】：这实际上是一元线性回归.

Solution: (1) 写出似然函数, 即

$$L(\beta, \gamma, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \beta - \gamma Z_i)^2\right\},$$

对数似然函数为

$$\ell(\beta, \gamma, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \beta - \gamma Z_i)^2,$$

求偏导得

$$\begin{cases} \frac{\partial \ell}{\partial \beta} = \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \beta - \gamma Z_i), \\ \frac{\partial \ell}{\partial \gamma} = \frac{1}{2\sigma^2} \sum_{i=1}^n Z_i (X_i - \beta - \gamma Z_i), \\ \frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (X_i - \beta - \gamma Z_i)^2, \end{cases}$$

第一个式子告诉我们 $\bar{X} = \hat{\beta} + \hat{\gamma} \bar{Z} = \hat{\beta}$, 代入第二个式子消元 β 恰好解得

$$\hat{\gamma} = \frac{l_{xz}}{l_{zz}} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Z_i - \bar{Z})}{\sum_{i=1}^n (Z_i - \bar{Z})^2} = \frac{\sum_{i=1}^n (X_i - \bar{X}) Z_i}{\sum_{i=1}^n Z_i^2},$$

再代到第三个解得 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\beta} - \hat{\gamma}Z_i)^2$, 汇总后是

$$\begin{cases} \hat{\gamma} = \frac{l_{xz}}{l_{zz}} = \frac{\sum_{i=1}^n (X_i - \bar{X})Z_i}{\sum_{i=1}^n Z_i^2}, \\ \hat{\beta} = \bar{X}, \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\beta} - \hat{\gamma}Z_i)^2. \end{cases}$$

恰好是最小二乘估计, 只不过因变量是 X , 自变量是 Z .

(2) 根据最小二乘估计结论, 有

$$\hat{\gamma} \sim N\left(\gamma, \frac{1}{l_{zz}}\sigma^2\right), \quad \hat{\beta} \sim N\left(\beta, \left(\frac{1}{n} + \frac{\bar{Z}^2}{l_{zz}}\right)\sigma^2\right), \quad \frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-2),$$

其中 $\hat{\sigma}^2$ 是 σ^2 的无偏估计, 且 $\bar{Z} = 0$. 此处由于 σ 未知, 因此

$$\frac{\hat{\beta} - \beta}{\hat{\sigma}\sqrt{\frac{1}{n} + \frac{\bar{Z}^2}{l_{zz}}}} = \sqrt{n} \frac{\bar{X} - \beta}{\hat{\sigma}} \sim t(n-2), \quad \frac{\hat{\gamma} - \gamma}{\hat{\sigma}\sqrt{\frac{1}{l_{zz}}}} = \sqrt{\sum_{i=1}^n Z_i^2} \frac{\hat{\gamma} - \gamma}{\hat{\sigma}} \sim t(n-2),$$

总结得到置信区间为

$$\begin{aligned} \beta &\in \left[\hat{\beta} - \frac{\hat{\sigma}}{\sqrt{n}} t_{\frac{\alpha}{2}}(n-2), \hat{\beta} + \frac{\hat{\sigma}}{\sqrt{n}} t_{\frac{\alpha}{2}}(n-2) \right], \\ \gamma &\in \left[\hat{\gamma} - \frac{\hat{\sigma}}{\sqrt{\sum_{i=1}^n Z_i^2}} t_{\frac{\alpha}{2}}(n-2), \hat{\gamma} + \frac{\hat{\sigma}}{\sqrt{\sum_{i=1}^n Z_i^2}} t_{\frac{\alpha}{2}}(n-2) \right], \\ \sigma^2 &\in \left[\frac{(n-2)\hat{\sigma}^2}{\chi_{\frac{\alpha}{2}}^2(n-2)}, \frac{(n-2)\hat{\sigma}^2}{\chi_{1-\frac{\alpha}{2}}^2(n-2)} \right]. \end{aligned}$$

(3) 构造检验统计量

$$\sqrt{\sum_{i=1}^n Z_i^2} \cdot \frac{\hat{\gamma}}{\hat{\sigma}} \underset{H_0 \text{ 成立时}}{\sim} t(n-2),$$

当该检验统计量的绝对值特别大时, 我们认为 γ 的真值不应是 0, 故拒绝域是

$$W = \left\{ \left| \sqrt{\sum_{i=1}^n Z_i^2} \cdot \frac{\hat{\gamma}}{\hat{\sigma}} \right| > t_{\frac{\alpha}{2}}(n-2) \right\}.$$

4. (20 分) 已知 (X, Y) 服从二元正态分布, 且 X 和 Y 的边缘分布均服从 $N(0, 1)$, ρ 为 XY 的相关系数, 则:

(1)(10 分) $X = U, Y = \rho U + (1 - \rho^2)^{\frac{1}{2}} V$, 求 (U, V) 的联合密度函数.

(2)(10 分) 记 $\alpha = P(X > 0, Y > 0)$, 证明 $\rho = \cos((1 - 2\alpha)\pi)$.

Solution: (1) (X, Y) 是 (U, V) 的线性组合, 反过来 (U, V) 也是 (X, Y) 的线性组合. 二元正态的线性组合还是正态, 因此我们只需要计算 (U, V) 的期望、方差、协方差, 就可以写出密度函数, 根据题设 $X = U$ 知 $U \sim N(0, 1)$, 而由 $0 = E(Y) = \rho E(U) + \sqrt{1 - \rho^2} E(V)$ 也解得 $E(V) = 0$, 同时有

$$\rho = \text{Cov}(X, Y) = \text{Cov}(U, \rho U + \sqrt{1 - \rho^2} V) = \rho + \sqrt{1 - \rho^2} \text{Cov}(U, V),$$

这说明要么 $\text{Cov}(U, V) = 0$, 要么 $\rho = \pm 1$, 然而当 $\rho = \pm 1$ 时, (X, Y) 的协方差矩阵行列式为 0, 不是二元正态, 故得出 $\text{Cov}(U, V) = 0$. 再回代 $1 = \text{Var}(Y) = \rho^2 \text{Var}(U) + (1 - \rho^2) \text{Var}(V)$, 解得 $\text{Var}(V) = 1$. 综上, $(U, V) \sim N(0, 0; 1, 1; 0)$, 密度函数是

$$\rho = \text{Cov}(X, Y) = \text{Cov}(U, \rho U + \sqrt{1 - \rho^2} V) = \rho + \sqrt{1 - \rho^2} \text{Cov}(U, V).$$

(2) 由 $(-X, -Y)$ 与 (X, Y) 同分布, 因此

$$P(X > 0, Y > 0) = P(-X > 0, -Y > 0) = P(X < 0, Y < 0),$$

因此有

$$\begin{aligned} P(X > 0, Y > 0) &= \frac{1}{2} [P(X > 0, Y > 0) + P(X < 0, Y < 0)] \\ &= \frac{1}{2} P(XY > 0) = \frac{1}{2} P\left(\frac{Y}{X} > 0\right) \\ &= \frac{1}{2} P\left(\frac{\rho U + \sqrt{1-\rho^2}V}{U} > 0\right) \\ &= \frac{1}{2} P\left(\rho + \sqrt{1-\rho^2}\frac{V}{U} > 0\right) \\ &= \frac{1}{2} P\left(\frac{V}{U} > -\frac{\rho}{\sqrt{1-\rho^2}}\right), \end{aligned}$$

利用结论 $T = \frac{V}{U}$ 服从标准柯西分布, 密度函数是 $f(t) = \frac{1}{\pi} \frac{1}{1+t^2}$, 有

$$\begin{aligned} P\left(\frac{V}{U} > -\frac{\rho}{\sqrt{1-\rho^2}}\right) &= \int_{-\frac{\rho}{\sqrt{1-\rho^2}}}^{+\infty} \frac{1}{\pi} \frac{1}{1+t^2} dt \\ &= \frac{1}{\pi} \left(\arctan(+\infty) - \arctan\left(-\frac{\rho}{\sqrt{1-\rho^2}}\right) \right) \\ &= \frac{1}{\pi} \left(\frac{\pi}{2} + \arcsin \rho \right) = \frac{1}{2} + \frac{1}{\pi} \arcsin \rho, \end{aligned}$$

最后回代即有

$$\alpha = P(X > 0, Y > 0) = \frac{1}{4} + \frac{1}{2\pi} \arcsin \rho,$$

整理得

$$\rho = \sin\left(2\pi\left(\alpha - \frac{1}{4}\right)\right) = \sin\left(2\pi\alpha - \frac{\pi}{2}\right) = -\cos(2\pi\alpha) = \cos((1-2\alpha)\pi).$$

5. (15 分) 抽检 N 人血样本, 方案 1: 对每个人进行检验; 方案 2: k 个人一起混检. 已知阳性比例为 p , 证明当 p 较小时, 以适当的 k 按照方案 2 可减少化验次数, 并确定 k 取何值时最适合.

Solution: 设 $n = \frac{N}{k}$, 表示 N 个人总共分成 n 组, 每一组的次数 X_i 可能有两种: (i) 所有人都阴性, 则 $X = 1$; (ii) 有至少一个阳性, 则 $X = 1 + k$. 期望次数是

$$E(X_i) = (1-p)^k + (k+1)[1 - (1-p)^k] = (k+1) - k(1-p)^k,$$

因此总次数是

$$E(X) = nE(X_i) = n(k+1) - nk(1-p)^k,$$

如果 p 特别小, 则有 $(1-p)^k \approx 1 - kp$, 即

$$E(X) \approx nk + n - nk + nk^2p = n(1 + k^2p),$$

而方案 1 需要的次数是 $N = nk$ 次, 只要我们确保 $1 + k^2p < k$, 则有方案 2 的期望次数更小, 在 p 非常小时, 这是很容易做到的. 实际上我们要尽量选择 k 远小于 $\frac{1}{p}$, 以保证

$$k^2p = k \cdot kp \ll k,$$

使得分组的方法由于不分组.

6. (16 分) $X_1, X_2, \dots, X_n$ 来自总体 $X \sim [0, 2\theta]$ 的均匀分布.

(1)(8 分) 分别求 θ 的矩估计 $\hat{\theta}$ 和极大似然估计 $\hat{\theta}$.

(2)(8 分) 讨论 $\hat{\theta}$ 的无偏性, 若非无偏, 则给出一个修正后的无偏估计.

Solution: (1) $E(X) = \theta$, 故矩估计是 $\hat{\theta} = \bar{X}$. 似然函数是

$$L(\theta) = \frac{1}{2^n \theta^n} I_{\{X_{(n)} \leq 2\theta\}},$$

似然函数关于 θ 递减, 故最大值在 θ 取最小值时达到, 即 $\hat{\theta} = \frac{X_{(n)}}{2}$.

(2) 均匀分布次序统计量结论有 $\frac{X_{(n)}}{2\theta} \sim \text{Beta}(n, 1)$, 故期望是 $E[\frac{X_{(n)}}{2\theta}] = \frac{n}{n+1}$, 因此 $E[\hat{\theta}] = \frac{n}{n+1}\theta$, 有偏. 修正后的无偏估计是 $\hat{\theta}_a = \frac{n+1}{2n}X_{(n)}$.

7. (20 分) 厂商称白糖平均每包重量 $m \geq 500g$, 抽取 100 包测得数据如下:

i	每包克重	包数
1	498-499	10
2	499-500	20
3	500-501	50
4	501-502	20

(1)(5 分) 求均值和标准差.

(2)(5 分) 构造均值的 99% 置信区间 ($t_{0.005}(99) \approx 2.626$)

(3)(5 分) 在 $\alpha = 0.01$ 水平下, 检验厂商说法是否可信 ($t_{0.01}(99) \approx 2.364$)

(4)(5 分) 利用正态分布近似, 以 95% 概率对该批糖达 500 g 的比例作区间估计 ($z_{0.025} = 1.96$)

Solution: (1) 分组数据均值为 $\bar{x} = 500.3$, 样本方差 $s^2 = 0.7677$, 样本标准差 $s = 0.876$.

(2) 总体方差未知, 用 t 分布构造区间, 置信区间为

$$\bar{x} \pm \frac{s}{\sqrt{n}} t_{0.005}(99) = [500.07, 500.53].$$

(3) 假设检验问题为

$$H_0: \mu \leq 500 \quad \text{vs} \quad H_1: \mu > 500$$

检验统计量为

$$t = \frac{\bar{x} - 500}{s/\sqrt{n}} = 3.4247 > 2.364,$$

因此商家的说法是可信的.

(4) 记 $p = P(X \geq 500)$, 根据表格得 $\hat{p} = 0.7$, 故有

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})/n}} \xrightarrow{d} N(0, 1),$$

因此置信区间是

$$\hat{p} \pm z_{0.025} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = [0.6102, 0.7898].$$

北京师范大学-432 统计学-2023 年

一、单项选择题 (每题 3 分, 共 18 分)

1. 已知 $P(A \cap B) = P(\bar{A} \cap \bar{B})$, 且 $P(A) = p$, 则 $P(B) = (\quad)$.

- A. p
- B. $1 - p$
- C. 0
- D. $2p$

Solution: 选 B. 利用德摩根公式, 有

$$P(AB) = P(\bar{A}\bar{B}) = 1 - P(A \cup B) = 1 - P(A) - P(B) + P(AB),$$

解得 $P(B) = 1 - P(A) = 1 - p$.

2. 已知 $X \sim N(0, 1)$, Y 以等概率取 -1 和 1, $Z = X \cdot Y$, X 与 Y 独立, 下列错误的是 ().

- A. Z 服从标准正态
- B. X, Z 不相关
- C. X, Z 不独立
- D. (X, Z) 服从二维正态

Solution: 选 D.

23 考研模考题原题重现. 可以验证 $Z \sim N(0, 1)$, 且 $Cov(X, Z) = E(XZ) = E(X^2Y) = 0$, 但是

$$\begin{aligned} P(X \leq 1, Z \leq 1) &= P(X \leq 1, XY \leq 1) \\ &= P(X \leq 1, Y = 1) + P(-1 \leq X \leq 1, Y = -1) \\ &= \Phi(1) - \frac{1}{2}\Phi(-1), \end{aligned}$$

不过 $P(X \leq 1)P(Z \leq 1) = \Phi^2(1)$, 它们不独立. 此外, 考虑 $X = x$ 时, Z 只可能取 $\pm x$, 因此它们不是联合正态. 因为如果它们是联合正态, 那条件分布也会是正态.

3. X, Y 独立服从同一种分布 (参数不一定相同), 且 $X + Y$ 也服从这种名称的分布, 则 X, Y 的分布不可能是 ().

- A. 正态
- B. 二项
- C. 指数
- D. 泊松

Solution: 选 C. 指数分布没有可加性, 即使它们参数一样时加在一起也是 Gamma 分布.

4. $X \sim N(0, 1)$, $Y \sim \chi^2(m)$, $Z \sim \chi^2(n)$, 则正确的说法是 ().

- A. $X^2 \sim \chi^2(1)$
- B. $\frac{X}{\sqrt{Y/m}} \sim t(m)$
- C. $\frac{Y/m}{Z/n} \sim F(m, n)$
- D. 都对

Solution: 选 A. 如果没有强调独立性, 则 B, C 都不一定对.

5. 有来自 $\mathcal{P}(\lambda)$ 的 i.i.d. 样本 $X_1, \dots, X_n$, 则 $E(n\bar{X}^2 + S^2) = (\quad)$.

- A. 2λ
- B. $n\lambda^2 + \lambda$
- C. $\lambda + (n+1)\lambda^2$

D. $2\lambda + n\lambda^2$

Solution: 选 D. $E(\bar{X}^2) = \lambda^2 + \frac{\lambda}{n}$, $E(S^2) = \lambda$, 因此有

$$E(n\bar{X}^2 + S^2) = n\lambda^2 + 2\lambda.$$

6. 有来自 $N(\mu, \sigma^2)$ 的 i.i.d. 样本 $X_1, \dots, X_n$, 记 S_1^2 是 σ^2 的 MLE, S_2^2 是样本方差, 则说法错误的是 ().

- A. S_2^2 是 σ^2 的 MLE
- B. S_1^2 的方差更小
- C. S_2^2 是 σ^2 的无偏估计
- D. S_2 是 σ 的有偏估计

Solution: 选 A. 显然错误.

二、填空题 (每题 3 分, 共 30 分)

1. 甲乙丙独立做题, 做对概率分别是 $1/3, 1/4, 1/5$, 则至少有一人做对的概率是 ____.

Solution: $\frac{3}{5}$.

$$p = 1 - \frac{2}{3} \cdot \frac{3}{4} \cdot \frac{4}{5} = \frac{3}{5}.$$

2. 已知 $\xi \sim U(0, 5)$, 则方程 $4x^2 + 4\xi x + (\xi + 2) = 0$ 有实根的概率是 ____.

Solution: $\frac{3}{5}$. 判别式为 $\Delta = 16\xi^2 - 16(\xi + 2) = 16(\xi^2 - \xi - 2) = 16(\xi + 1)(\xi - 2)$, 令其 ≥ 0 , 解得

$$\{\Delta \geq 0\} = \{\xi \leq -1\} \cup \{\xi \geq 2\},$$

故 $P(\Delta \geq 0) = P(\xi \geq 2) = \frac{3}{5}$.

3. 已知 X, Y, Z i.i.d. 服从 $N(0, 1)$, 则 $E\left(\frac{X^2}{X^2 + Y^2 + Z^2}\right) = \text{____}$.

Solution: $\frac{1}{3}$.

根据对称性, 有

$$E\left(\frac{X^2}{X^2 + Y^2 + Z^2}\right) = E\left(\frac{Y^2}{X^2 + Y^2 + Z^2}\right) = E\left(\frac{Z^2}{X^2 + Y^2 + Z^2}\right),$$

三者相加又是 1, 故显然答案是 $\frac{1}{3}$.

4. 设 $\bar{X}, S^2$ 是样本均值和样本方差, 而 $\bar{X}^2 - cS^2$ 是总体均值平方的无偏估计, 则 $c = \text{____}$.

Solution: $\frac{1}{n}$.

$E(\bar{X}^2) = \mu^2 + \frac{1}{n}\sigma^2$, $E(S^2) = \sigma^2$, 因此 $c = \frac{1}{n}$.

5. 已知 X, Y i.i.d. 服从 $N(\mu, \sigma^2)$, 则 $aX + bY$ 和 $aX - bY$ 的相关系数是 ____.

Solution: $\frac{a^2 - b^2}{a^2 + b^2}$.

先求协方差, 有

$$\text{Cov}(aX + bY, aX - bY) = a^2 \text{Var}(X) - b^2 \text{Var}(Y) = (a^2 - b^2)\sigma^2,$$

同时再算方差, 有

$$\text{Var}(aX + bY) = \text{Var}(aX - bY) = (a^2 + b^2)\sigma^2,$$

故有 $\text{Corr}(aX + bY, aX - bY) = \frac{a^2 - b^2}{a^2 + b^2}$.

6. 已知 X, Y 不相关, $X \sim B(1, p_1)$, $Y \sim B(1, p_2)$, 则 $E(X^2 Y^2) = \text{____}$.

Solution: $p_1 p_2$.

由于两点分布不相关与独立等价, 故

$$E(X^2 Y^2) = E(X^2)E(Y^2) = p_1 p_2.$$

7. 某校学生身高近似服从标准差为 6 的正态分布, 对该校男生身高进行置信水平为 95% 的区间估计, 若要求误差 d_0 不超过 1, 则至少要调查的样本数为 ____.

Solution: 139.

95% 置信区间为

$$\left[\bar{x} - 1.96 \frac{6}{\sqrt{n}}, \bar{x} + 1.96 \frac{6}{\sqrt{n}} \right],$$

令 $d_0 = 1.96 \frac{6}{\sqrt{n}} \leq 1$, 解得 $n \geq 138.298$.

8. 设 $X_1, \dots, X_n$ i.i.d. 服从 $U(0, 1)$, 则 $E(X_{(n)}) =$ ____.

Solution: $\frac{n}{n+1}$.

利用结论: $X_{(n)} \sim \text{Beta}(n, 1)$, 我们有 $E(X_{(n)}) = \frac{n}{n+1}$.

9. 某设备发送 A.B 两种信号, 概率为 1:2, 发射 A 信号但误接收为 B 的概率为 0.02, 发射 B 信号对但接收为 A 的概率为 0.01, 则在接收到 A 信号时发射 A 信号的概率为 ____.

Solution: 0.98.

由贝叶斯公式, 有

$$P(\text{in} : A | \text{out} : A) = \frac{\frac{1}{3} \cdot 0.98}{\frac{1}{3} \cdot 0.98 + \frac{2}{3} \cdot 0.01} = 0.98.$$

10. 某一零件正常工作概率 0.95, 一个机器有 100 个零件, 至少 90 个零件正常工作则机器可正常运作, 问机器正常运作的概率为 ____.

Solution: $\Phi(2.524)$.

设零件工作 $X_i = 1$, 不工作 $X_i = 0$, 则有 $X_i \sim B(1, 0.95)$, 因此有 $Y = \sum_{i=1}^{100} X_i \sim AN(95, 4.75)$, 故有

$$P(\text{正常}) = P(Y \geq 90) = P(Y > 89.5) = P\left(\frac{Y - 95}{\sqrt{4.75}} > \frac{89.5 - 95}{\sqrt{4.75}}\right) = \Phi(2.524).$$

三、分析计算题 (共 102 分)

1. (20 分) 简述两种图示方法, 分析 $X_1, X_2, \dots, X_n$ 是否为正态分布.

Solution: 可以用概率图 (Probability-probability Plot, P-P 图)、分位数图 (Quantile-quantile Plot, Q-Q 图)、直方图等来判断正态性.

P-P 图是以样本的累计频率作为横坐标, 以按照正态分布计算的相应累计概率作为纵坐标, 把样本值表现为直角坐标系中的散点. 如果数据服从正态分布, 则样本点应该围绕第一象限的对角线分布.

Q-Q 图则是以样本的分位数作为横坐标, 以按照正态分布计算的相应分位数作为纵坐标, 把样本表现为直角坐标系的散点. 如果资料服从正态分布, 则样本点应该呈一条围绕第一象限对角线的直线.

直方图指的是将数据以直方图的形式呈现, 并将每个直方图顶部的中点连线, 观察连线是否呈现中间高两边低且对称的钟形分布.

2. (20 分) 证明: $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{2n(n-1)} \sum_{i=1}^n \sum_{j=1}^n (X_i - X_j)^2$, 并说明统计学意义.

Solution: 作恒等变形, 有恒等变形.

$$\begin{aligned} T &:= \sum_{i=1}^n \sum_{j=1}^n (X_i - X_j)^2 = \sum_{i=1}^n \sum_{j=1}^n (X_i^2 + X_j^2 - 2X_i X_j) \\ &= \sum_{i=1}^n \sum_{j=1}^n (X_i^2 + X_j^2 - 2X_i X_j) \\ &= \sum_{i=1}^n \left(nX_i^2 + \sum_{j=1}^n X_j^2 - 2nX_i \bar{X} \right) \\ &= n \sum_{i=1}^n X_i^2 + n \sum_{j=1}^n X_j^2 - 2n^2 \bar{X}^2 \\ &= 2n \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right), \end{aligned}$$

因此看出

$$T = \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = S^2.$$

我们可以发现: S^2 是样本方差, 衡量数据的离散程度. 而 T 是两两样本之间距离平方的平均值, 同样衡量数据的离散程度.

3. (20 分) 有两组独立样本: $X_1, \dots, X_n$ i.i.d. 服从 $N(\mu_1, \sigma^2)$, $Y_1, \dots, Y_m$ i.i.d. 服从 $N(\mu_2, \sigma^2)$.

(1) 求 μ_1, μ_2, σ^2 的 MLE.

(2) 请构造 $H_0: \mu_1 = \mu_2$ 的水平为 α 的拒绝域 (备择假设是其对立).

(3) 请构造 $H_0: \sigma^2 = \sigma_0^2$ 的水平为 α 的拒绝域 (备择假设是其对立).

Solution: (1) 写出似然函数

$$L(\mu_1, \mu_2, \sigma^2) = (2\pi\sigma^2)^{-\frac{m+n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \left(\sum_{i=1}^n (x_i - \mu_1)^2 + \sum_{i=1}^m (y_i - \mu_2)^2 \right) \right\},$$

对数似然函数是

$$\ell(\mu_1, \mu_2, \sigma^2) = A - \frac{m+n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \left(\sum_{i=1}^n (x_i - \mu_1)^2 + \sum_{i=1}^m (y_i - \mu_2)^2 \right).$$

求导置零解得

$$\hat{\mu}_1 = \bar{x}, \quad \hat{\mu}_2 = \bar{y}, \quad \hat{\sigma}^2 = \frac{1}{m+n} \left(\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right).$$

(2) 由于

$$\frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t(m+n-2),$$

其中 s_w^2 是联合样本方差, 即

$$s_w^2 = \frac{1}{m+n-2} \left(\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right),$$

故在原假设成立时有检验统计量 $\frac{\bar{x}-\bar{y}}{s_w\sqrt{\frac{2}{n}}} \sim t(n-2)$, 故拒绝域是

$$W = \left\{ \left| \frac{\bar{x}-\bar{y}}{s_w\sqrt{\frac{1}{n}+\frac{1}{m}}} \right| > t_{1-\frac{\alpha}{2}}(m+n-2) \right\}.$$

(3) 利用 $\frac{(m+n-2)s_w^2}{\sigma_0^2} \sim \chi^2(m+n-2)$, 拒绝域是

$$W = \left\{ \frac{(m+n-2)s_w^2}{\sigma_0^2} < \chi_{\frac{\alpha}{2}}^2(m+n-2) \right\} \cup \left\{ \frac{(m+n-2)s_w^2}{\sigma_0^2} > \chi_{1-\frac{\alpha}{2}}^2(m+n-2) \right\}.$$

4. (20 分) 已知 $X_1, \dots, X_n$ i.i.d. 来自总体 $X \sim N(\mu, \sigma^2)$, 任意 i, j , $\text{Corr}(X_i, X_j) = \rho$.

(1) 求 $E(|X - \mu|)$;

(2) 求 μ 的矩估计;

(3) 证明: $\rho \geq -\frac{1}{n-1}$.

Solution: (1) $|X - \mu| = \sigma|Z|$, 其中 $Z \sim N(0, 1)$, 因此有

$$E(|Z|) = \int_{-\infty}^{+\infty} |z| \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} ze^{-\frac{z^2}{2}} dz = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} e^{-u} du = \sqrt{\frac{2}{\pi}}.$$

故 $E(|X - \mu|) = \sigma\sqrt{\frac{2}{\pi}}$.

(2) 总体期望 $E(X) = \mu$, 由替换原理, $\hat{\mu} = \bar{x}$.

(3) 茆书原题, 利用相关系数矩阵的非负定性, 有

$$\begin{aligned} \begin{vmatrix} 1 & \rho & \cdots & \rho \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{vmatrix} &= \begin{vmatrix} 1+(n-1)\rho & 1+(n-1)\rho & \cdots & 1+(n-1)\rho \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{vmatrix} \\ &= [1+(n-1)\rho] \begin{vmatrix} 1 & 1 & \cdots & 1 \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{vmatrix} \\ &= [1+(n-1)\rho] \begin{vmatrix} 1 & 0 & \cdots & 0 \\ \rho & 1-\rho & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \rho & 0 & \cdots & 1-\rho \end{vmatrix} \\ &= [1+(n-1)\rho] (1-\rho)^{n-1}. \end{aligned}$$

如果 $\rho = 1$, 则相关系数矩阵的行列式为 0, 但也满足 $\rho \geq -\frac{1}{n-1}$. 如果 $\rho < 1$, 那么 $(1-\rho)^{n-1} > 0$, 因此非负定要求了 $1+(n-1)\rho \geq 0$, 故 $\rho \geq -\frac{1}{n-1}$.

5. (12 分) 设 $F(y_1, y_2, \dots, y_d)$ 为 $(Y_1, \dots, Y_d)$ 的联合分布函数, 而 $F_i(y_i)$ 是边际分布. 证明:

$$|F(x_1, \dots, x_d) - F(y_1, \dots, y_d)| \leq \sum_{i=1}^d |F_i(x_i) - F_i(y_i)|.$$

先证 $d = 2$ 时的情形, 再证明一般的情形.

Solution: 这题 23 考研模考题押中原题. 先看 $d = 2$, 简记 $x \wedge y = \min\{x, y\}$, $x \vee y = \max\{x, y\}$, 放缩, 有

$$\begin{aligned} |F(x_1, x_2) - F(y_1, y_2)| &= |F(x_1, x_2) - F(y_1, x_2) + F(y_1, x_2) - F(y_1, y_2)| \\ &\leq |F(x_1, x_2) - F(y_1, x_2)| + |F(y_1, x_2) - F(y_1, y_2)| \\ &= P(x_1 \wedge y_1 < Y_1 \leq x_1 \vee y_1, Y_2 \leq x_2) + P(Y_1 \leq y_1, x_2 \wedge y_2 < Y_1 \leq x_2 \vee y_2) \\ &\leq P(x_1 \wedge y_1 < Y_1 \leq x_1 \vee y_1) + P(x_2 \wedge y_2 < Y_1 \leq x_2 \vee y_2) \\ &= |F_1(x_1) - F_1(y_1)| + |F_2(x_2) - F_2(y_2)|. \end{aligned}$$

而对于一般的 d , 有

$$\begin{aligned} |F(x_1, \dots, x_{d-1}, x_d) - F(y_1, \dots, y_{d-1}, y_d)| &= |F(x_1, \dots, x_{d-1}, x_d) - F(y_1, \dots, y_{d-1}, x_d) + F(y_1, \dots, y_{d-1}, x_d) - F(y_1, \dots, y_{d-1}, y_d)| \\ &\leq |F(x_1, \dots, x_{d-1}, x_d) - F(y_1, \dots, y_{d-1}, x_d)| + |F(y_1, \dots, y_{d-1}, x_d) - F(y_1, \dots, y_{d-1}, y_d)| \\ &\leq |F_{1,d-1}(x_1, \dots, x_{d-1}) - F_{1,d-1}(y_1, \dots, y_{d-1})| + |F_d(x_d) - F_d(y_d)|, \end{aligned}$$

因此 $d - 1$ 时成立可推出 d 时成立, 用归纳假设可以说明对一般的 d 成立.

6. (10 分) 一元线性回归: $Y = \beta_0 + \beta_1 X + \varepsilon$, $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$, 其中 $\hat{\beta}_0, \hat{\beta}_1$ 是最小二乘估计. 证明皮尔逊相关系数的平方 r^2 与拟合优度 R^2 等价. 注意:

$$r = \frac{\sum (X_i - \bar{X}) \cdot (Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}}, \quad R^2 = \frac{\sum (\hat{Y}_i - \bar{Y})^2}{\sum (Y_i - \bar{Y})^2}.$$

Solution:

$$r^2 = \frac{l_{xy}^2}{l_{xx}l_{yy}} = \frac{\hat{\beta}_1^2 l_{xx}}{l_{yy}} = \frac{\sum_{i=1}^n \left[\hat{\beta}_1 (X_i - \bar{X}) \right]^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = R^2.$$

北京师范大学-432 统计学-2024 年

一、(30 分) 试卷中给出了一组数据.

(1) 求该组数据 α 分位数的表达式.

(2) 用两种盒形图描述以上数据, 并说明主要数值的具体含义.

(3) 设 $w_i \in (0, 1)$, 且 $\sum_{i=1}^n w_i = 1$, 定义 $\bar{X}_w = \sum_{i=1}^n w_i X_i$, 证明:

$$\sum_{i=1}^n (X_i - \bar{X}_w)^2 = \frac{1}{2} \sum_{i=1}^n w_i w_j (X_i - X_j)^2$$

并解释该等式的含义.

Solution: (1) 样本 α 分位数 m_α 指的是在 n 个样本 $X_1, \dots, X_n$ 中, 小于等于 m_α 的比例 $\frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq m_\alpha\}} = \alpha$, 这个定义来源于总体分位数 $P(X \leq x_\alpha) = \alpha$.

(2) 盒形图 (Boxplot) 是一种用于显示一组数据分布情况的图表。通常, 盒形图包括以下部分:

中位数: 数据的中位数, 表示为盒子中的一条线。


四分位数: 数据的第一四分位数 (Q1) 和第三四分位数 (Q3), 分别表示数据分布的 25% 和 75% 位置。这两个值定义了盒子的边界。

" 胡须" (Whiskers): 从盒子外延伸出的线, 通常延伸到 1.5 倍的四分位距 (即 $Q3 - Q1$) 之外的最近的数据点。

异常值: 通常使用点来表示, 这些点位于胡须之外。

盒形图的两种常见变体是: (a) 标准盒形图: 使用上述标准定义的元素。(b) 调整后的盒形图: 可能有不同的方法来计算 "胡须" 的长度, 例如, 它们可能延伸到所有非异常值数据点, 或者使用不同的倍数来计算四分位距。

随机生成了 20 个数据, 画图作为示例:



(3) 从右侧出发:

$$\begin{aligned} 2\text{RHS} &:= \sum_{i=1}^n \sum_{j=1}^n w_i w_j (X_i - X_j)^2 = \sum_{i=1}^n w_i \sum_{j=1}^n w_j (X_i^2 + X_j^2 - 2X_i X_j) \\ &= \sum_{i=1}^n w_i \left(X_i^2 + \sum_{j=1}^n w_j X_j^2 - 2X_i \bar{X}_w \right) \\ &= \sum_{i=1}^n w_i X_i^2 + \sum_{j=1}^n w_j X_j^2 - 2\bar{X}_w^2 \\ &= 2 \left(\sum_{i=1}^n w_i X_i^2 - \bar{X}_w^2 \right) = \sum_{i=1}^n w_i (X_i - \bar{X}_w)^2 \end{aligned}$$

原问题中, 等式左侧表示加权计算的方差, 表达了离散程度, 等式右侧则表示两两样本离差平方的加权组合, 也表示了离散程度.

Remark: 第 (3) 问是九阳神功-北师大 432 统计学-2023 年大题第 2 题变式.

二、(30 分) 袋中有 n 个编号为 $1, 2, \dots, n$ 的小球, 随机取 1 个.

(1) 写出该问题的概率空间.

(2) 设 $n = 4$, 举例分别满足以下的事件 A, B, C :

(a) $P(B|A) < P(B)$;

(b) $P(B|A) = P(B)$;

(c) $P(B|A) > P(B)$;

(d) 两两独立, 但不相互独立.

(3) 设袋中有 a 个红球, b 个白球, 假设每次从袋中有放回去取一个球, 直到摸到第 r 个红球停止, 此时次数为 X , 求 X 的分布列和期望.

Solution: (1) 样本空间是所有可能结果的集合. 在这个实验中, 每次实验的结果是取出一个具有特定编号的小球. 因此, 样本空间 Ω 可以定义为: $\Omega = \{1, 2, \dots, n\}$.

事件域 $\mathcal{F}$ 是样本空间的所有子集, 包括空集和样本空间本身, 可以写作 $\mathcal{F} = \{A : A \subset \Omega\}$.

概率测度: 在这个实验中, 由于我们是随机取出一个小球, 每个小球被取出可以被视为样本点 $\omega_i = i$, 它们的概率都是相等的, 都是 $\frac{1}{n}$, 即 $P(\{i\}) = \frac{1}{n}$.

结合之, $(\Omega, \mathcal{F}, P)$ 是该问题的概率空间.

(2) (a) $A = \{1, 2\}, B = \{3\}$; (b) $A = \{1, 2, 3, 4\}, B = \{1\}$; (c) $A = \{1, 2\}, B = \{1\}$; (d) $A = \{1, 2\}, B = \{2, 3\}, C = \{3, 4\}$.

(3) X 是负二项分布 $Nb(p, r)$, 其中 $p = \frac{a}{a+b}$, 故分布列是

$$P(X = k) = C_{k-1}^{r-1} p^r (1-p)^{k-r}, k = r, r+1, \dots,$$

期望是 $E(X) = \frac{r}{p} = \frac{a+b}{a}r$.

三、(30 分) 有来自 $U(a, b)$ 的随机样本 $X_1, \dots, X_n$.

(1) 求 $b-a$ 的 MLE, 判断其无偏性.

(2) 求 $b-a$ 的矩估计.

(3) 在某次拍卖会, 甲、乙、丙对一件物品竞拍, 每人出价一次, 价高者得. 且已知甲如果买下该商品, 将以 8 万元转卖. 现在甲知道乙、丙的出价均独立服从 $U(5, 10)$, 请问甲如何出价使得期望收益最大?

Solution: (1) 联合概率密度函数为: $L(a, b) = \prod_{i=1}^n \frac{1}{b-a}$

最大化 $L(a, b)$ 相当于最小化 $b-a$. 在样本中, b 的最大似然估计是样本的最大值 $X_{(n)}$, a 的最大似然估计是样本的最小值 $X_{(1)}$. 因此, $b-a$ 的最大似然估计是 $X_{(n)} - X_{(1)}$.

接着我们判断无偏性. 我们考虑 $Y_i = \frac{X_i - a}{b-a} \sim U(0, 1)$, 则有次序统计量分布 $Y_{(k)} \sim Be(k, n+1-k)$, 因此 $E(Y_{(1)}) = \frac{1}{n+1}, E(Y_{(n)}) = \frac{n}{n+1}$, 故 $E(X_{(1)}) = a + (b-a)\frac{1}{n+1}, E(X_{(n)}) = a + (b-a)\frac{n}{n+1}$, 因此 $E(X_{(n)} - X_{(1)}) = \frac{n-1}{n+1}(b-a) \neq b-a$, 所以这个估计量是有偏的.

(2) 均匀分布 $U(a, b)$ 的均值和方差分别为 $\mu = \frac{a+b}{2}$ 和 $\sigma^2 = \frac{(b-a)^2}{12}$. 使用样本均值 $\bar{X}$ 和样本方差 S^2 来估计这两个参数, 我们得到: $\hat{b} - \hat{a} = 2\sqrt{3}s$.

(3) 设甲出价 $x \in [5, 8]$, 乙、丙出价为 Y, Z , 则甲的收益是

$$f(x, Y, Z) = (8-x) I_{\{x \geq Y, x \geq Z\}},$$

求期望有 $g(x) = Ef(x, Y, Z) = \frac{(8-x)(x-5)^2}{25}$, 用高数方法找其最大值在 $x = 7$ 取到.

Remark: 前两问与九阳神功-北大 849 统计学-2021 年第七题一致.

四、(30 分) (1) 作出原假设的依据是什么? 原假设和备择假设的地位是否等同?

(2) 以正态分布为例, 简述置信区间和假设检验的区别和联系.

(3) 现有 81 个学生的成绩, 假设其来自于正态分布 $N(\mu, \sigma^2)$, 且样本均值 $\bar{X} = 69.8$, 样本标准差 $s = 10$, $\alpha = 0.05$. (可能用到的分位数: $t_{0.975}(80) = 1.99$, $u_{0.975} = 1.96$, $\chi^2_{0.975}(80) = 106.63$) 请回答下述问题:

(a) 能否认为 $\mu = 72$?

(b) 求 μ 的置信区间.

(c) 能否认为 $\sigma = 8.8$?

Solution:

(1) 作出原假设 (通常表示为 H_0) 的依据通常是以下几点:

(i) 现有理论或知识: 原假设往往基于现有的理论或广泛接受的知识. 例如, 如果现有理论表明两种药物效果相同, 那么原假设可能就是“这两种药物的效果没有差异”.

(ii) 简单性或保守性: 在统计学中, 原假设通常是一个简单假设, 它提出了最简单、最保守的情况. 例如, “新药与安慰剂效果无差别”是一个比“新药比安慰剂效果好”更简单、更保守的假设.

(iii) 研究目的: 研究者可能会根据研究目的来确定原假设. 如果研究目的是证明某种新的干预措施有效, 那么原假设可能就是“新干预措施与现有措施效果相同”.

此外, 原假设和备择假设 (通常表示为 H_1) 在统计假设检验中的地位并不等同. 原假设是被默认为真的假设, 直到有足够的证据来拒绝它. 备择假设则是与原假设相对立的假设, 通常是研究者试图证明的假设. 当统计证据不足以拒绝原假设时, 我们并不接受备择假设, 而是说没有足够的证据支持备择假设. 这表明, 在假设检验中, 原假设具有一定的“优先权”. 这种方法有助于控制做出错误结论的风险, 特别是避免第一类错误.

(2) 区别: 置信区间是针对参数设立的集合, 拒绝域是针对样本的集合. 联系: 在形式上, 置信区间和拒绝域存在互补的关系 (或说置信区间与接受域在形式上是等同的).

以正态分布为例, 正态分布 $N(\mu, 1)$ 中 μ 的 0.95 置信区间是

$$\bar{x} - \frac{z_{0.975}}{\sqrt{n}} \leq \mu \leq \bar{x} + \frac{z_{0.975}}{\sqrt{n}}.$$

同时, $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ 的拒绝域是

$$W = \{|\bar{x} - \mu_0| > \frac{z_{0.975}}{\sqrt{n}}\},$$

接受域可以写成 $W = \{x: \bar{x} - \frac{z_{0.975}}{\sqrt{n}} \leq \mu_0 \leq \bar{x} + \frac{z_{0.975}}{\sqrt{n}}\}$. 显然, 置信区间与接受域在形式上是等同的, 但置信区间中, μ 是未知参数, 接受域中, μ_0 是已知的, 且接受域和拒绝域中, 元素是样本, 而置信区间则是参数的集合.

(3) (a) 使用单样本 t 检验来确定是否可以拒绝原假设 $\mu = 72$. 检验统计量 t 的计算公式为: $t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$ 其中, $\bar{X} = 69.8$, $\mu_0 = 72$, $s = 10$, $n = 81$. 计算得到的 t 值为 -1.98 , 而在 $\alpha = 0.05$ 的显著性水平下的临界 t 值为 ± 1.99 (双尾检验). 因为计算出的 t 值在临界值的范围内, 所以没有足够的证据拒绝原假设 $\mu = 72$.

(b) 对于 μ 的 95% 置信区间, 计算公式为: $\bar{X} \pm t_{0.975} \times \frac{s}{\sqrt{n}}$ 其中, $t_{0.975}$ 为 t 分布在 0.975 处的临界值. 计算得到的置信区间为 $(67.59, 72.01)$.

(c) 使用卡方检验来确定是否可以拒绝原假设 $\sigma = 8.8$. 检验统计量 χ^2 的计算公式为: $\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$ 其中, $\sigma_0 = 8.8$. 计算得到的 χ^2 值为 103.31, 而卡方分布的临界值为 57.15 (下限) 和 106.63 (上限). 因为卡方值在这个范围内, 所以没有足够的证据拒绝原假设 $\sigma = 8.8$.

注意: 题干没有给出 $\chi^2_{0.025}(80) = 57.15$. 但可以推断出它大概率比 $\chi^2(80)$ 的均值 80 要小.

Remark: 《考前一天 20 个知识点》让同学们前去复习接受域和置信区间的对偶关系, 《考前知识点清单》专门陈述了应如何选择原假设和备择假设.

五、(20 分) 现有回归模型 $y_i = \beta_0 + \beta_i x_i + \varepsilon_i$.

(1) 写出判定系数 R^2 的表达式并解释含义.

(2) 请画出方差分析表. (表中写出各种量的公式)

(3) 对于给定的第 i 组数据 (x_i, y_i) , 如何判断它对模型的影响力?

(4) 对于样本 (x_i, y_i) 和 (x_j, y_j) , 这两点连成的斜率是 a_{ij} , 其中 $i = 1, \dots, n, j = 1, \dots, n$, 证明: $\{a_{ij}\}$ 的某一线性组合是 β_1 的最小二乘估计?

Solution: (1) $R^2 = \frac{SS_{\text{reg}}}{SS_{\text{tot}}} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2}$, 它指的是回归平方和占总平方和的比重, 表示自变量对因变量随机性的解释比例, 同时也反映了自变量和因变量的线性相关性强弱.

(2) 方差分析表通常包括以下部分:

来源	平方和	自由度	均方	F统计量
回归	$SSR = \sum (\hat{y}_i - \bar{y})^2$	$n - 1$	$MSR = SSR/1$	$F = MSR/MSE$
残差	$SSE = \sum (y_i - \hat{y}_i)^2$	$n - 2$	$MSE = SSE/(n - 2)$	
总计	$SST = \sum (y_i - \bar{y})^2$	1		

(3) 对于给定的第 i 组数据 (x_i, y_i) , 其对模型的影响力可以通过杠杆值、学生化残差和 Cook's Distance 等方法评估.

(i) 杠杆值 (Leverage)

定义: 杠杆值反映了数据点相对于所有数据点在“预测空间”中的位置, 表明数据点对模型预测的影响程度.

计算公式: $h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{j=1}^n (x_j - \bar{x})^2}$ 其中, h_{ii} 是第 i 个观测值的杠杆值, x_i 是该观测值, $\bar{x}$ 是所有观测值 x 的均值.

影响: 高杠杆值的数据点可能对回归线的斜率有较大影响, 可能导致模型过度适应这些特定点.

(ii) 学生化残差 (Studentized Residuals)

定义: 学生化残差是标准化后的残差, 用于识别离群值.

计算公式: $r_i = \frac{y_i - \hat{y}_i}{s\sqrt{1-h_{ii}}}$ 其中, r_i 是第 i 个数据点的学生化残差, y_i 是观测值, $\hat{y}_i$ 是模型预测值, s 是残差的标准差.

影响: 绝对值大的学生化残差表明数据点与模型预测值相差较大, 可能指示该点为异常值.

(iii) Cook's Distance

定义: Cook's Distance 是一个综合指标, 结合了杠杆值和残差大小, 用来评估数据点对回归系数估计的整体影响.

计算公式: $D_i = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(i)})^2}{p \cdot MSE}$ 其中, D_i 是第 i 个观测值的 Cook's Distance, $\hat{y}_j$ 是包含所有观测值的回归预测, $\hat{y}_{j(i)}$ 是排除第 i 个观测值后的回归预测, p 是模型参数的数量, MSE 是均方误差.

影响: 较大的 Cook's Distance 表明移除或更改该数据点会显著改变回归模型.

(4) 根据 a_{ij} 的定义, 我们有 $y_i - y_j = a_{ij}(x_i - x_j)$, 而 $\hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} = \frac{1}{l_{xx}} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$, 由于 l_{xx} 已是常数, 只需将 $\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$ 表为 a_{ij} 的线性组合即可. 我们有

$$y_i - \bar{y} = \frac{1}{n} \sum_{j=1}^n (y_i - y_j) = \frac{1}{n} \sum_{j=1}^n (x_i - x_j) a_{ij},$$

因此直接得到

$$\hat{\beta}_1 = \frac{1}{nl_{xx}} \sum_{i=1}^n \sum_{j=1}^n (x_i - x_j)(x_i - \bar{x}) a_{ij}.$$

六、(10 分) 设 U_1, U_2 独立, 且期望都是 0, 方差是 σ^2 , 定义

$$X_t = U_1 \sin(2\pi\omega_0 t) + U_2 \cos(2\pi\omega_0 t).$$

(1) 求 $\{X_t\}$ 的自协方差函数;

(2) 对于自协方差函数 $\{g_k, k \in \mathbb{Z}\}$, 如果对任意 n , 对任意序列 $\alpha^\top = (a_1, a_2, \dots)$, 有 $\sum_{k=1}^n \sum_{j=1}^n a_k a_j g(k-j) \geq 0$, 则称自协方差函数非负定, 证明: (1) 中的自协方差函数非负定.

(3) 样本自协方差函数是

$$\begin{cases} \hat{\gamma}(h) = \frac{1}{n} \sum_{t=1}^{n-h} (X_{t+h} - \bar{X})(X_t - \bar{X}), & 0 \leq h \leq n-1. \\ \hat{\gamma}(h) = \hat{\gamma}(-h), & n-1 \leq h < 0, \end{cases}$$

证明样本自协方差矩阵

$$\hat{\Gamma}_n = \begin{bmatrix} \hat{\gamma}_0 & \hat{\gamma}_1 & \cdots & \hat{\gamma}_{n-1} \\ \hat{\gamma}_{-1} & \hat{\gamma}_0 & \cdots & \hat{\gamma}_{n-2} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\gamma}_{-(n-1)} & \hat{\gamma}_{-(n-2)} & \cdots & \hat{\gamma}_0 \end{bmatrix}$$

是非负定的.

Solution: (1) 增加一个条件: $\omega_0 \neq 0$. 容易看出 $E(X_t) = 0, \gamma_0 = \text{Var}(X_t) = \sigma^2$, 再求自协方差, 利用和差化积, 有

$$\begin{aligned} \gamma_{j,k} &= E[X_j X_k] \\ &= E\left(U_1^2 \sin(2\pi\omega_0 j) \sin(2\pi\omega_0 k)\right) + E\left(U_2^2 \cos(2\pi\omega_0 j) \cos(2\pi\omega_0 k)\right) \\ &= \sigma^2 \cos(2\pi\omega_0(j-k)) \end{aligned}$$

只和 $j-k$ 有关, 因此 X_t 平稳, $\gamma_{t,t+h} = \gamma_h = \sigma^2 \cos(2\pi\omega_0 h)$, 其中 $h \in \mathbb{Z}$, 恰好也包含了 $\gamma_0 = \text{Var}(X_t) = \sigma^2$.

(2) 这等价于证明: 对任意 n , 矩阵

$$\Gamma_n = \begin{bmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{n-1} \\ \gamma_{-1} & \gamma_0 & \cdots & \gamma_{n-2} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{-(n-1)} & \gamma_{-(n-2)} & \cdots & \gamma_0 \end{bmatrix}$$

是非负定的. 简单的方法是考虑任意 α_n , 由于 Γ_n 是 $(X_1, \dots, X_n)$ 的协方差矩阵, 有

$$\alpha_n^\top \Gamma_n \alpha_n = \sum_{k=1}^n \sum_{j=1}^n a_k a_j \gamma(k-j) = \sum_{k=1}^n \sum_{j=1}^n a_k a_j \text{Cov}(X_k, X_j) = \text{Var}\left(\sum_{k=1}^n a_k X_k\right) \geq 0.$$

这和证明普通协方差矩阵非负定并没有什么区别.

上述方法没有用到第 (1) 问求出来的结果, 如果要利用之, 即需证明: $\sum_{k=1}^n \sum_{j=1}^n a_k a_j \cos(2\pi\omega_0(k-j)) \geq 0$, 利用欧拉公式,

$$\sum_{k=1}^n \sum_{j=1}^n a_k a_j \cos(2\pi\omega_0(k-j)) = \sum_{k=1}^n \sum_{j=1}^n a_k a_j \mathcal{R}e\left\{e^{i2\pi\omega_0(k-j)}\right\} = \mathcal{R}e\left\{\sum_{k=1}^n \sum_{j=1}^n a_k a_j e^{i2\pi\omega_0(k-j)}\right\},$$

其中 $\mathcal{R}e\{\cdot\}$ 表示取实部. 进一步有

$$\begin{aligned} \sum_{k=1}^n \sum_{j=1}^n a_k a_j e^{i2\pi\omega_0(k-j)} &= \sum_{k=1}^n \sum_{j=1}^n a_k a_j e^{i2\pi\omega_0 k} e^{-i2\pi\omega_0 j} = \sum_{k=1}^n \sum_{j=1}^n a_k a_j e^{i2\pi\omega_0 k} \overline{e^{i2\pi\omega_0 j}} \\ &= \left(\sum_{k=1}^n a_k e^{i2\pi\omega_0 k}\right) \left(\sum_{j=1}^n a_j \overline{e^{i2\pi\omega_0 j}}\right) = \left(\sum_{k=1}^n a_k e^{i2\pi\omega_0 k}\right) \left(\sum_{k=1}^n a_k \overline{e^{i2\pi\omega_0 k}}\right) \\ &= \left(\sum_{k=1}^n a_k e^{i2\pi\omega_0 k}\right) \overline{\left(\sum_{k=1}^n a_k e^{i2\pi\omega_0 k}\right)} = \left|\sum_{k=1}^n a_k e^{i2\pi\omega_0 k}\right|^2, \end{aligned}$$

已经只是实数, 因此有

$$\sum_{k=1}^n \sum_{j=1}^n a_k a_j \cos(2\pi\omega_0(k-j)) = \operatorname{Re} \left\{ \left| \sum_{k=1}^n a_k e^{i2\pi\omega_0 k} \right|^2 \right\} = \left| \sum_{k=1}^n a_k e^{i2\pi\omega_0 k} \right|^2 \geq 0.$$

(3) 先假设 $X_1, \dots, X_n$ 并不全相等, 令 $Y_j = X_j - \bar{X}$, 并记

$$A_{n \times (2n-1)} = \begin{pmatrix} 0 & \cdots & 0 & Y_1 & Y_2 & \cdots & Y_{n-1} & Y_n \\ 0 & \cdots & Y_1 & Y_2 & Y_3 & \cdots & Y_n & 0 \\ \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ Y_1 & \cdots & Y_{n-1} & Y_n & 0 & \cdots & 0 & 0 \end{pmatrix},$$

可以验证, 恰有 $\hat{\Gamma}_n = \frac{1}{n} A A^\top$, 只需验证 A 是行满秩矩阵即可, 这是显然的, 因为只要有一个 Y_k 不是 0, 就会出现非 0 元素在各行不同列出现的情况, 同时我们考虑 $\omega_0 \neq 0$, 因此 $\hat{\Gamma}_n$ 是正定的.

北京师范大学-432 统计学-2025 年

1. 从区间 (a, b) 取 n 个样本, 给定组数 k 。(20 分)

(1) 介绍绘制频率直方图的步骤.

(2) $f(x)$ 为样本密度函数, 任给 $\hat{f}(x)$ 是 $f(x)$ 的估计值, 求 $\hat{f}(x)$ 的均方误差.

Solution:

(1) 1. 确定组数和组距: 组数: k , 组距: $\frac{b-a}{k}$. 2. 计算频数: 对于每个组, 统计落在该组内的样本数量, 即为该组的频数. 3. 计算频率: 将每个组的频数除以总样本数 n , 得到该组的频率. 4. 绘制直方图: 在坐标系中, 横轴表示样本值, 纵轴表示频率. 对于每个组, 绘制一个矩形, 其宽度为组距, 高度为该组的频率. 这些矩形相邻排列, 形成直方图.

(2) 均方误差是 $MSE(\hat{f}(x)) = E[(\hat{f}(x) - f(x))^2]$ 在直方图估计中, 我们通常假设每个组内的样本是独立同分布的, 并且每个样本落入某个特定组的概率是 $f(x)\Delta x$, 其中 Δx 是组距. 在每个组内, 样本数 $\sim B(n, f(x)\Delta x)$, 方差是 $nf(x)\Delta x(1 - f(x)\Delta x)$. 由于:

$$\hat{f}(x) = \frac{\sum_{i=1}^n I_i}{n\Delta x}, \quad E(\hat{f}(x)) = \frac{f(x)n\Delta x}{n\Delta x} = f(x)$$
$$\text{Var}(\hat{f}(x)) = \frac{nf(x)\Delta x(1 - f(x)\Delta x)}{n^2\Delta x^2} = \frac{f(x)(1 - f(x)\Delta x)}{n\Delta x}, \quad \Delta x = \frac{b-a}{k}$$

由于 $\hat{f}(x)$ 为 $f(x)$ 的无偏估计, 所以:

$$MSE(\hat{f}(x)) = \text{Var}(\hat{f}(x)) = \frac{f(x)[k - f(x)(b-a)]}{n(b-a)}$$

2. N 个球一共有 L 种颜色, 第 k 种颜色球的个数为 N_k , 有放回摸球 m 次 (30 分)

(1) 求摸到每种颜色球个数的协方差矩阵.

(2) X_1 为摸到第一种颜色球的个数, $X_1(n)$ 表示在 n 次摸球中摸到第一种颜色球的个数, 证明:

$$P(X_1(n+1) \geq i+1) - P(X_1(n) \geq i+1) = \frac{N_1}{N} P(X_1 = i)$$

(3) 证明:

$$\sum_{k=n-i}^n p^k (1-p)^{n-k} = \frac{\int_0^p x^{n-i-1} (1-x)^i dx}{\int_0^1 x^{n-i-1} (1-x)^i dx}$$

Solution:

(1) 定义随机变量 X_k 为摸到第 k 种颜色球的个数, 其中 $k = 1, 2, \dots, L$. 由于每次摸球是独立的, 并且有放回, 所以 X_k 服从二项分布 $B(m, P_k)$, 其中 $P_k = \frac{N_k}{N}$ 是摸到第 k 种颜色球的概率.

$$E[X_k] = mP_k, \text{Var}(X_k) = mP_k(1 - P_k)$$

对于 X_k 和 X_j ($k \neq j$), 它们的协方差为:

$$\text{Cov}(X_k, X_j) = E[X_k X_j] - E[X_k]E[X_j]$$

由于每次摸球只能摸到一个球, 所以 $X_k + X_j \leq m$. 因此, X_k 和 X_j 是负相关的.

$$E[X_k X_j] = \sum_{i=0}^m \sum_{j=0}^{m-i} i \cdot j \cdot P(X_k = i, X_j = j)$$

由于 X_k 和 X_j 是负相关的, 所以:

$$P(X_k = i, X_j = j) = P(X_k = i) \cdot P(X_j = j | X_k = i)$$

给定 $X_k = i$ ，摸到第 j 种颜色球的概率变为 $\frac{N_j}{N - N_k}$ ，所以：

$$P(X_j = j \mid X_k = i) = \binom{m-i}{j} \left(\frac{N_j}{N - N_k} \right)^j \left(1 - \frac{N_j}{N - N_k} \right)^{m-i-j}$$

$$E[X_k X_j] = \sum_{i=0}^m i \cdot \binom{m}{i} p_k^i (1 - p_k)^{m-i} \sum_{j=0}^{m-i} j \cdot \binom{m-i}{j} \left(\frac{N_j}{N - N_k} \right)^j \left(1 - \frac{N_j}{N - N_k} \right)^{m-i-j}$$

简化后得到：

$$\begin{aligned} E[X_k X_j] &= \sum_{i=0}^{m-1} i \cdot \binom{m}{i} p_k^i (1 - p_k)^{m-i} (m-i) \left(\frac{N_j}{N - N_k} \right) \\ &= m \sum_{i=0}^{m-1} i \cdot \binom{m-1}{i} p_k^i (1 - p_k)^{m-i} \left(\frac{N_j}{N - N_k} \right) \\ &= m(m-1) P_k (1 - P_k) \frac{P_j}{1 - P_k} \\ &= m(m-1) P_k P_j \end{aligned}$$

所以：

$$\text{Cov}(X_k, X_j) = m(m-1) P_k P_j - (m P_k)(m P_j) = -m P_k P_j$$

因此，协方差矩阵 Σ 为：

$$\Sigma_{kj} = \begin{cases} m P_k (1 - P_k) & \text{if } k = j \\ -m P_k P_j & \text{if } k \neq j \end{cases}$$

(2) 设 $P_1 = \frac{N_1}{N}$ 表示摸到第一种颜色球的概率。

$$P(X_1(n) \geq i+1) = \sum_{k=i+1}^n \binom{n}{k} P_1^k \cdot (1 - P_1)^{n-k}$$

$$P(X_1(n+1) \geq i+1) = \sum_{k=i+1}^{n+1} \binom{n+1}{k} P_1^k \cdot (1 - P_1)^{n+1-k}$$

$$\begin{aligned} P(X_1(n+1) \geq i+1) - P(X_1(n) \geq i+1) &= \sum_{k=i+1}^{n+1} \binom{n+1}{k} P_1^k (1 - P_1)^{n+1-k} - \sum_{k=i+1}^n \binom{n}{k} P_1^k (1 - P_1)^{n-k} \\ &= \binom{n+1}{n+1} P_1^{n+1} (1 - P_1)^0 + \sum_{k=i+1}^n \left(\binom{n+1}{k} - \binom{n}{k} \right) P_1^k (1 - P_1)^{n+1-k} \\ &= P_1^{n+1} + \sum_{k=i+1}^n \left(\binom{n+1}{k} - \binom{n}{k} \right) P_1^k (1 - P_1)^{n+1-k} \end{aligned}$$

我们知道， $\binom{n+1}{k} = \binom{n}{k} + \binom{n}{k-1}$ ，因此：

$$\binom{n+1}{k} - \binom{n}{k} = \binom{n}{k-1}$$

将这个性质代入上式, 得到:

$$\begin{aligned}
 P(X_1(n+1) \geq i+1) - P(X_1(n) \geq i+1) &= P_1^{n+1} + \sum_{k=i+1}^n \binom{n}{k-1} P_1^k (1-P_1)^{n+1-k} \\
 &= \sum_{j=i}^n \binom{n}{j} P_1^{j+1} (1-P_1)^{n-j} \\
 &= P_1 \sum_{j=i}^n \binom{n}{j} P_1^j (1-P_1)^{n-j} \\
 &= P_1 P(X_1(n) \geq i)
 \end{aligned}$$

(3) 令:

$$\begin{aligned}
 f(p) &= \sum_{k=n-i}^n p^k (1-p)^{n-k}, g(p) = \frac{\int_0^p x^{n-i+1} (1-x)^i dx}{\int_0^1 x^{n-i+1} (1-x)^i dx} \\
 f'(p) &= \sum_{k=n-i}^n \binom{n}{k} k p^{k-1} (1-p)^{n-k} - \sum_{k=n-i}^{n-1} \binom{n}{k} p^k (n-k) (1-p)^{n-k-1} \\
 &= \sum_{k=n-i}^n n \cdot C_{n-1}^{k-1} \cdot p^{k-1} \cdot (1-p)^{n-k} - \sum_{k=n-i}^{n-1} n \cdot C_{n-1}^k \cdot p^k \cdot (1-p)^{n-k-1} \\
 &= \sum_{k=n-i-1}^{n-1} n \cdot C_{n-1}^k \cdot p^k \cdot (1-p)^{n-k-1} - \sum_{k=n-i}^{n-1} n \cdot C_{n-1}^k \cdot p^k \cdot (1-p)^{n-k-1} \\
 &= n \cdot C_{n-1}^{n-i-1} \cdot p^{n-i-1} \cdot (1-p)^i \\
 &= \frac{\Gamma(n+1)}{\Gamma(n-i)\Gamma(i+1)} p^{n-i-1} (1-p)^i \\
 g'(p) &= \frac{\frac{d}{dp} \int_0^p x^{n-i-1} (1-x)^i dx}{Be(n-i, i+1)} = \frac{\Gamma(n+1) p^{n-i-1} (1-p)^i}{\Gamma(n-i)\Gamma(i+1)} = f'(p)
 \end{aligned}$$

下面验证当 $p=0$ 和 $p=1$ 时, $f(p)$ 和 $g(p)$ 是否相等。

$$f(0) = 0, g(0) = 0$$

$$f(1) = \sum_{k=n-i}^n 1^k (1-1)^{n-k} = 1, g(1) = \frac{\int_0^1 x^{n-i-1} (1-x)^i dx}{\int_0^1 x^{n-i-1} (1-x)^i dx} = 1$$

由于 $f'(p) = g'(p)$ 并且 $f(p)$ 和 $g(p)$ 在边界条件 $p=0$ 和 $p=1$ 下相等, 得出结论 $f(p) = g(p)$ 对所有 p 成立。

3. 在 $U(\theta-c, \theta+c)$ 区间内取样本: $X_1, \dots, X_n$ (20 分)

(1) 求 θ 的矩估计和极大似然估计.

(2) 证明 $\frac{X_{(1)}+X_{(n)}}{2}$ 是 θ 的无偏估计.

Solution:

(1) $X_1, X_2, \dots, X_n$ 来自均匀分布 $U(\theta-c, \theta+c)$, 期望为: $\frac{\theta-c+\theta+c}{2} = \theta$ 。样本均值 $\bar{X}$ 是总体均值的矩估计:

$$\hat{\theta} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$f(x; \theta) = \frac{1}{2c}, \quad \theta-c \leq x \leq \theta+c$$

$$L(\theta) = \prod_{i=1}^n f(X_i; \theta) = \left(\frac{1}{2c}\right)^n, \quad \theta-c \leq X_{(1)} \leq X_{(n)} \leq \theta+c$$

$\theta - c \leq X_{(1)}$ 和 $X_{(n)} \leq \theta + c$ 都成立时似然函数最大, 即 $X_{(n)} - c \leq \theta \leq X_{(1)} + c$ 。因此, 极大似然估计为:

$$\hat{\theta}_{MLE} = \{\theta | X_{(n)} - c \leq \theta \leq X_{(1)} + c\}$$

(2) 令:

$$Y_i = \frac{X_i - a}{b - a}, Y_i \sim U(0, 1), Y_{(k)} \sim \text{Beta}(k, n - k + 1)$$

则

$$Y_{(1)} \sim \text{Beta}(1, n), E(Y_{(1)}) = \frac{1}{n+1}, E(X_{(1)}) = \frac{b-a}{n+1} + a$$

$$Y_{(n)} \sim \text{Beta}(n, 1), E(Y_{(n)}) = \frac{n}{n+1}, E(X_{(n)}) = \frac{n(b-a)}{n+1} + a$$

其中 $a = \theta - c, b = \theta + c$, 所以对于均匀分布 $U(\theta - c, \theta + c)$, 最小值 $X_{(1)}$ 和最大值 $X_{(n)}$ 的期望值分别为:

$$E[X_{(1)}] = \frac{2c}{n+1} + \theta - c, E[X_{(n)}] = \frac{2nc}{n+1} + \theta - c, E\left[\frac{X_{(1)} + X_{(n)}}{2}\right] = \theta$$

所以 $\frac{X_{(1)} + X_{(n)}}{2}$ 是 θ 的无偏估计。

4. $X_1, \dots, X_n$ 服从正态分布 $N(\mu, \sigma^2)$ (20 分)

$$H_0: \mu = \mu_0, \quad H_1: \mu > \mu_0$$

(1) 介绍假设检验原理.

(2) 分别求在 σ^2 已知和未知下的 p 值表达式和其分布.

Solution:

(1) 假设检验是统计学中的一种方法, 用于判断一个假设是否成立, 假设检验的步骤如下:

1. 提出假设: $H_0: \mu = \mu_0, \quad H_1: \mu > \mu_0$ 。

2. 选择检验统计量: 根据数据的类型和分布选择合适的检验统计量, 当 σ 已知的时候可以用单样本的 u 检验, 当 σ 未知时用 t 检验。

3. 确定显著性水平: 选择一个显著性水平 α , 通常为 0.05 或 0.01。

4. 计算检验统计量的值: 根据样本数据计算检验统计量的值。当 $\sigma = \sigma_0$ 已知时统计量为 $Z = \frac{\sqrt{n}(\bar{x} - \mu_0)}{\sigma}$, 当 σ 未知时统计量为: $T = \frac{\sqrt{n}(\bar{x} - \mu_0)}{s}$

5. 根据拒绝域做出决策: 当 $\sigma = \sigma_0$ 已知时拒绝域为 $W = \{Z > z_{1-\alpha}\}$, 当 σ 未知时拒绝域为: $W = \{T > t_{1-\alpha}(n-1)\}$ 。如果统计量落在拒绝域中, 则拒绝零假设, 接受备择假设; 否则, 不拒绝零假设。

(2) (i) 在 σ^2 已知时, 我们会选择检验统计量 $u(\mathbf{X}) = \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma} \sim N(0, 1)$, 当 u 较大时, 或 $\bar{X}$ 比 μ_0 大很多时, 我们会拒绝原假设, p -值的含义是当原假设成立时发生比当前样本还要极端的可能性, 它显然是样本的函数。如果已收集到样本 $\mathbf{x}_0$, 对应统计量 $u_0 = u(\mathbf{x}_0)$, 那么 p -值是:

$$p(\mathbf{x}_0) = P(Z \geq u_0) = 1 - \Phi(u_0) = 1 - \Phi(u(\mathbf{x}_0)).$$

此时, 如果 $\mathbf{x}_0$ 是已知样本, 那么 $p(\mathbf{x}_0)$ 也是已知量, 如果考虑样本是随机变量 $\mathbf{X}$, 那 $p(\mathbf{X})$ 也是随机变量, 即:

$$p(\mathbf{X}) = 1 - \Phi(u(\mathbf{X})),$$

其中由于 $u(\mathbf{X}) \sim N(0, 1)$, 因此 $\Phi(u(\mathbf{X}))$ 是分布函数作用在自身, $\Phi(u(\mathbf{X})) \sim U(0, 1)$, 而 $1 - U(0, 1)$ 仍然服从 $U(0, 1)$, 因此:

$$p(\mathbf{X}) = 1 - \Phi(u(\mathbf{X})) \sim U(0, 1).$$

(ii) 在 σ^2 未知时, 我们会选择检验统计量 $u(\mathbf{X}) = \sqrt{n} \frac{\bar{X} - \mu_0}{s} \sim t(n-1)$, 当 u 较大时, 或 $\bar{X}$ 比 μ_0 大很多时, 我们会拒绝原假设, 如果已收集到样本 $\mathbf{x}_0$, 对应统计量 $u_0 = u(\mathbf{x}_0)$, 那么 p -值是:

$$p(\mathbf{x}_0) = P(T \geq u_0) = 1 - F_{t, n-1}(u(\mathbf{x}_0)).$$

其中 $F_{t,n-1}$ 是 $t(n-1)$ 的分布函数. 此时, 如果 $\mathbf{x}_0$ 是已知样本, 那么 $p(\mathbf{x}_0)$ 也是已知量, 如果考虑样本是随机变量 $\mathbf{X}$, 那 $p(\mathbf{X})$ 也是随机变量, 即:

$$p(\mathbf{X}) = 1 - F_{t,n-1}(u(\mathbf{X})),$$

其中由于 $u(\mathbf{X}) \sim t(n-1)$, 因此 $F_{t,n-1}(u(\mathbf{X}))$ 是分布函数作用在自身, $F_{t,n-1}(u(\mathbf{X})) \sim U(0,1)$, 而 $1 - U(0,1)$ 仍然服从 $U(0,1)$, 因此仍然有:

$$p(\mathbf{X}) = 1 - F_{t,n-1}(u(\mathbf{X})) \sim U(0,1).$$

5. 二元线性回归模型, $y_i\alpha + \beta x_i + \lambda z_i + \epsilon$, $\epsilon \sim N(0, \sigma^2)$. (30 分)

(1) 求 β 的极大似然估计, 数学期望, 方差.

(2) 如果 y 写成 x 的一元回归模型, 求 β 最小二乘估计, 判断其是否是无偏估计, 并比较两种情况下 β 的方差.

Solution:

(1)

$$L = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \alpha - \beta x_i - \lambda z_i)^2}{2\sigma^2}\right)$$

$$\ln L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta x_i - \lambda z_i)^2$$

$$\begin{cases} \frac{\partial \ln L}{\partial \alpha} = 0 \rightarrow \sum_{i=1}^n (y_i - \alpha - \beta x_i - \lambda z_i) = 0 \\ \frac{\partial \ln L}{\partial \beta} = 0 \rightarrow \sum_{i=1}^n x_i (y_i - \alpha - \beta x_i - \lambda z_i) = 0 \\ \frac{\partial \ln L}{\partial \lambda} = 0 \rightarrow \sum_{i=1}^n z_i (y_i - \alpha - \beta x_i - \lambda z_i) = 0 \end{cases}$$

即:

$$\begin{cases} \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} - \hat{\lambda}\bar{z}, & (1) \\ \hat{\alpha} \cdot n\bar{x} + \hat{\beta} \sum_{i=1}^n x_i^2 + \hat{\lambda} \sum_{i=1}^n x_i z_i = \sum_{i=1}^n x_i y_i, & (2) \\ \hat{\alpha} \cdot n\bar{z} + \hat{\beta} \sum_{i=1}^n x_i z_i + \hat{\lambda} \sum_{i=1}^n z_i^2 = \sum_{i=1}^n y_i z_i, & (3) \end{cases}$$

整理方程 (1) (2) 得到: $\hat{\beta}l_{xx} + \hat{\lambda}l_{xz} = l_{xy}$, 同理由方程 (1) (3) 得到: $\hat{\beta}l_{xz} + \hat{\lambda}l_{zz} = l_{zy}$, 于是:

$$\begin{cases} l_{xx} \cdot \hat{\beta} + l_{xz} \cdot \hat{\lambda} = l_{xy} \\ l_{xz} \cdot \hat{\beta} + l_{zz} \cdot \hat{\lambda} = l_{zy} \end{cases}$$

根据克拉默法则解得:

$$\hat{\beta}_{MLE} = \frac{l_{xy}l_{zz} - l_{xz}l_{zy}}{l_{xx}l_{zz} - l_{xz}^2}$$

代入 $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} - \hat{\lambda}\bar{z}$ 得到 $\hat{\alpha}$ 的值.

$$E(\hat{\beta}_{MLE}) = \frac{l_{zz} \sum_{i=1}^n (x_i - \bar{x}) E(y_i - \bar{y}) - l_{xz} \sum_{i=1}^n (z_i - \bar{z}) E(y_i - \bar{y})}{l_{xx}l_{zz} - l_{xz}^2}$$

$$= \frac{\beta(l_{xx}l_{zz} - l_{xz}^2)}{l_{xx}l_{zz} - l_{xz}^2}$$

$$= \beta$$

$$\text{Var}(\hat{\beta}_{MLE}) = \frac{l_{zz}^2 \text{Var}(l_{xy}) + l_{xz}^2 \text{Var}(l_{zy}) - 2l_{xz}l_{zz} \text{Cov}(l_{xy}, l_{zy})}{(l_{xx}l_{zz} - l_{xz}^2)^2}$$

$$= \frac{l_{zz}^2 l_{xx} \sigma^2 + l_{xz}^2 l_{zz} \sigma^2 - 2l_{xz}l_{zz} l_{xz} \sigma^2}{(l_{xx}l_{zz} - l_{xz}^2)^2}$$

$$= \frac{l_{zz} \sigma^2}{l_{xx}l_{zz} - l_{xz}^2}$$

(2) 此时:

$$y_i = \alpha + \beta x_i + \epsilon, \quad \epsilon \sim N(0, \sigma^2), \quad S = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - (\alpha + \beta X_i))^2$$

$$\begin{cases} \frac{\partial S}{\partial \alpha} = -2 \sum_{i=1}^n (Y_i - \alpha - \beta X_i) = -2 (\sum_{i=1}^n Y_i - n\alpha - \beta \sum_{i=1}^n X_i) = 0, & \alpha = \bar{Y} - \beta \bar{X} \\ \frac{\partial S}{\partial \beta} = -2 \sum_{i=1}^n (Y_i - \alpha - \beta X_i) X_i = -2 (\sum_{i=1}^n Y_i X_i - \alpha \sum_{i=1}^n X_i - \beta \sum_{i=1}^n X_i^2) = 0 \end{cases}$$

将 $\alpha = \bar{Y} - \beta \bar{X}$ 代入方程, 得到:

$$\sum_{i=1}^n Y_i X_i - (\bar{Y} - \beta \bar{X}) \sum_{i=1}^n X_i - \beta \sum_{i=1}^n X_i^2 = 0, \quad \hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\begin{aligned} E(\hat{\beta}) &= \frac{\sum_{i=1}^n (X_i - \bar{X}) E(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})(\alpha + \beta X_i - \alpha - \beta \bar{X})}{\sum_{i=1}^n (X_i - \bar{X})^2} \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2 \beta}{\sum_{i=1}^n (X_i - \bar{X})^2} \\ &= \beta \end{aligned}$$

故其是无偏估计。

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{l_{xx}} \leq \text{Var}(\hat{\beta}_{MLE})$$

6. 白噪声: $\epsilon_t \sim N(0, \sigma^2)$, $X_t = 0.5X_{t-1} + \epsilon_t - 1.1\epsilon_{t-1} + 0.3\epsilon_{t-2}$ (30 分)

(1) 化简模型。

(2) 化简模型是否宽平稳? 求其自相关系数。

Solution:

(1) 该模型是 ARMA(1,2) 模型, 其简化形式是

$$(1 - 0.5B) X_t = (1 - 1.1B + 0.3B^2) \epsilon_t,$$

其中 B 是滞后算子. 我们也可以定义滞后多项式

$$\Phi(z) = 1 - 0.5z, \quad \Theta(z) = 1 - 1.1z + 0.3z^2,$$

此时模型可写作 $\Phi(B)X_t = \Theta(B)\epsilon_t$.

(2) (i) ARMA 模型的宽平稳条件是其 AR 部分是宽平稳的, 即 $\Phi(z) = 0$ 的根都在单位圆外, 此处其特征根 $z_0 = 2$ 显然在单位圆外, 因此模型宽平稳. (ii) 为求其自相关系数, 我们需求解其传递形式 $X_t = \sum_{j=0}^{\infty} G_j \epsilon_{t-j}$, 其中 $\{G_j\}$ 是 Green 函数, 且 $G_0 = 1$. 我们可以递推求解, 假设我们需求解其传递形式 $X_t = \sum_{j=0}^{\infty} G_j \epsilon_{t-j}$, 其中 $\{G_j\}$ 是 Green 函数, 且 $G_0 = 1$. 我们可以递推求解, 假设:

$$X_t = (1 + G_1 B + G_2 B^2 + G_3 B^3 + \cdots) \epsilon_t,$$

又根据 $\Phi(B)X_t = \Theta(B)\epsilon_t$, 我们有:

$$(1 - 0.5B) (1 + G_1 B + G_2 B^2 + G_3 B^3 + \cdots) = 1 - 1.1B + 0.3B^2.$$

将左侧对应打开有:

$$1 + (-0.5 + G_1)B + (-0.5G_1 + G_2)B^2 + (-0.5G_2 + G_3)B^3 + \cdots = 1 - 1.1B + 0.3B^2,$$

这说明:

$$\begin{cases} -0.5 + G_1 = -1.1, \\ -0.5G_1 + G_2 = 0.3, \\ -0.5G_k + G_{k+1} = 0, \quad k \geq 2, \end{cases}$$

我们解得:

$$G_1 = -0.6, \quad G_2 = 0, \quad G_k = 0, \quad k \geq 3,$$

因此模型恰化为有限阶 $X_t = \epsilon_t - 0.6\epsilon_{t-1}$, 这一点也可以说明模型平稳, 我们紧接着计算其自协方差函数 γ_k , 显然只有 γ_0, γ_1 非零:

$$\gamma_0 = \text{Var}(X_t) = 1.36\sigma^2, \quad \gamma_1 = E(X_t X_{t+1}) = -0.6\sigma^2, \quad \gamma_k = 0, \quad k \geq 2.$$

因此结论是:

$$\rho_0 = 1, \quad \rho_1 = -\frac{15}{34}, \quad \rho_2 = \rho_3 = \dots = 0.$$

北京师范大学-432 统计学-2026 年

一、(20) 设 X 为非负取值连续型随机变量, $f(x)$ 为其密度函数。在研究 $f(x)$ 函数形式过程中, 仅收集到以下信息 (其中 n_1, n_2, n_3, n_4 及 $a > 0$ 均为已知常数):

取值范围	$[0, a)$	$[a, 2a)$	$[2a, 4a)$	$[4a, 5a)$
观测频数	n_1	n_2	n_3	n_4

(10) (1) 请据此给出密度函数 $f(x)$ 的一种估计 $\hat{f}(x)$ 。

(10) (2) 若 Y 为连续型随机变量, 密度函数恰好为 (1) 中 $\hat{f}(x)$, 请计算 Y 的期望和众数。

Solution:

(1) 记样本总容量为 $N = n_1 + n_2 + n_3 + n_4$ 。基于直方图估计法, 概率密度函数在各区间上的取值为该区间的频率除以区间长度。

各区间长度分别为 $a, a, 2a, a$ 。据此构造分段密度函数 $\hat{f}(x)$ 如下:

$$\hat{f}(x) = \begin{cases} \frac{n_1}{Na}, & 0 \leq x < a \\ \frac{n_2}{Na}, & a \leq x < 2a \\ \frac{n_3}{2Na}, & 2a \leq x < 4a \\ \frac{n_4}{Na}, & 4a \leq x < 5a \\ 0, & \text{其他} \end{cases}$$

(2) 计算 Y 的数学期望 $E[Y]$ 。由期望定义式 $E[Y] = \int_{-\infty}^{+\infty} x \hat{f}(x) dx$, 将积分区间分段展开:

$$E[Y] = \int_0^a x \frac{n_1}{Na} dx + \int_a^{2a} x \frac{n_2}{Na} dx + \int_{2a}^{4a} x \frac{n_3}{2Na} dx + \int_{4a}^{5a} x \frac{n_4}{Na} dx$$

故:

$$\begin{aligned} E[Y] &= \frac{n_1}{Na} \cdot \frac{a^2}{2} + \frac{n_2}{Na} \cdot \frac{3a^2}{2} + \frac{n_3}{2Na} \cdot \frac{12a^2}{2} + \frac{n_4}{Na} \cdot \frac{9a^2}{2} \\ &= \frac{a}{2N} n_1 + \frac{3a}{2N} n_2 + \frac{3a}{N} n_3 + \frac{9a}{2N} n_4 \end{aligned}$$

整理得:

$$E[Y] = \frac{a}{2N} (n_1 + 3n_2 + 6n_3 + 9n_4)$$

关于众数, 即为密度函数 $\hat{f}(x)$ 取得最大值所对应的 x 。比较各区间密度值大小等价于比较校正频数:

$$h_1 = n_1, \quad h_2 = n_2, \quad h_3 = \frac{n_3}{2}, \quad h_4 = n_4$$

令 $M = \max\{n_1, n_2, \frac{n_3}{2}, n_4\}$ 。若最大值在第 k 个指标处取得, 则众数为对应的第 k 个区间 (或该区间的任意一点, 通常取中点作为点估计)。

二、(30) 设 X 服从 $[2, \theta)$ 上的均匀分布, 其中 $\theta > 2$ 为未知常数。

(1) (10) 若 X_1, X_2, X_3, X_4 为 X 的四次独立重复观测, 且 X_1, X_2, X_3, X_4 取值均不超过 3 的概率为 $\frac{1}{16}$, 请计算 X_1, X_2, X_3, X_4 中至少有两个取值大于 3 的概率。

(2) (10) 在 (1) 基础上, 对 X 进行 100 次独立重复观测, 请近似计算其总和大于 $300 + \frac{20}{\sqrt{3}}$ 的概率。

(3) (10) 若对 X 独立重复观测 100 次, 记 $x_1, \dots, x_{100}$ 为对应观测值, 请说明其算术平均与参数 θ 之间的近似函数关系式。

Solution:

(1) 由 $X \sim U[2, \theta]$ 及独立性假设, 四次观测均不超过 3 的概率满足:

$$[P(X \leq 3)]^4 = \left(\frac{3-2}{\theta-2}\right)^4 = \frac{1}{16}$$

解得 $\frac{1}{\theta-2} = \frac{1}{2}$, 从而确定 $\theta = 4$ 。

此时, 单次观测大于 3 的概率为 $p = P(X > 3) = \frac{1}{2}$ 。

设 Y 为 4 次观测中大于 3 的次数, 则 $Y \sim B(4, \frac{1}{2})$ 。所求“至少有两个取值大于 3”的概率为:

$$\begin{aligned} P(Y \geq 2) &= 1 - P(Y = 0) - P(Y = 1) \\ &= 1 - \binom{4}{0} \left(\frac{1}{2}\right)^4 - \binom{4}{1} \left(\frac{1}{2}\right)^4 \\ &= 1 - \frac{1}{16} - \frac{4}{16} \\ &= \frac{11}{16} \end{aligned}$$

(2) 已知 $\theta = 4$, 则:

$$E[X] = 3, \quad Var(X) = \frac{(4-2)^2}{12} = \frac{1}{3}$$

记 $S_{100} = \sum_{i=1}^{100} X_i$ 。由中心极限定理 (CLT), S_{100} 近似服从正态分布:

$$S_{100} \sim N\left(100 \times 3, 100 \times \frac{1}{3}\right) = N\left(300, \frac{100}{3}\right)$$

将待求事件标准化, 计算概率:

$$\begin{aligned} P\left(S_{100} > 300 + \frac{20}{\sqrt{3}}\right) &= P\left(\frac{S_{100} - 300}{10/\sqrt{3}} > \frac{20/\sqrt{3}}{10/\sqrt{3}}\right) \\ &= P(Z > 2) \\ &= 1 - \Phi(2) \\ &\approx 0.0228 \end{aligned}$$

(3) 根据大数定律, 样本均值 $\bar{x}$ 依概率收敛于总体期望。对于 $U[2, \theta]$ 分布, 其期望为:

$$E[X] = \frac{2+\theta}{2}$$

令样本均值近似等于总体期望 $\bar{x} \approx E[X]$, 反解可得近似函数关系式:

$$\theta \approx 2\bar{x} - 2$$

三、(25) 记 X 为某电子元件总体寿命, 假设 X 服从均值为 $\lambda (\lambda > 0)$ 的指数分布。请分别给出以下三种情形下 λ 的最大似然估计:

(1) (15) 从总体中随机抽取的 n 个电子元件, 观测其寿命, 观测值分别为 $x_1, \dots, x_n$ 。

(2) (5) “定时”型收集数据: 即约定 $n (\geq 3)$ 个电子元件同时开始工作, 但观测到 10 个单位时长即停止数据收集; 此时观测到的寿命数据为: 5.3, 6.0, 6.7。

(3) (5) “定数”型收集数据: 即约定 $n (\geq 3)$ 个电子元件同时开始工作, 但观测到 3 个电子元件失效即停止数据收集; 此时观测到的寿命数据为: 5.3, 6.0, 6.7。

Solution: 首先明确总体 X 的概率分布。已知寿命 X 服从均值为 λ 的指数分布, 其概率密度函数和生存函数分别为:

$$f(x; \lambda) = \frac{1}{\lambda} e^{-\frac{x}{\lambda}}, \quad S(x; \lambda) = P(X > x) = e^{-\frac{x}{\lambda}}, \quad x > 0$$

(1) 在此情形下, 观测数据 $x_1, \dots, x_n$ 为独立同分布的完全样本。构建似然函数如下:

$$L(\lambda) = \prod_{i=1}^n f(x_i; \lambda) = \frac{1}{\lambda^n} \exp \left(-\frac{1}{\lambda} \sum_{i=1}^n x_i \right)$$

对数似然函数为:

$$\ln L(\lambda) = -n \ln \lambda - \frac{1}{\lambda} \sum_{i=1}^n x_i$$

对 λ 求导并令其为零, 得到关于 λ 的估计方程:

$$\frac{d \ln L}{d \lambda} = -\frac{n}{\lambda} + \frac{1}{\lambda^2} \sum_{i=1}^n x_i = 0$$

解此方程, 即得 λ 的最大似然估计量:

$$\hat{\lambda}_1 = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

(2) 此为定时截尾试验, 截断时间 $T = 10$ 。观测到的失效数据为 $x_1 = 5.3, x_2 = 6.0, x_3 = 6.7$, 失效个数 $r = 3$; 其余 $n - 3$ 个元件在时刻 T 仍未失效, 被截尾。似然函数由失效数据的密度函数项与截尾数据的生存函数项构成:

$$L(\lambda) = \left[\prod_{i=1}^3 \frac{1}{\lambda} e^{-\frac{x_i}{\lambda}} \right] \cdot [S(T; \lambda)]^{n-3} = \frac{1}{\lambda^3} \exp \left(-\frac{1}{\lambda} \sum_{i=1}^3 x_i \right) \cdot \exp \left(-\frac{10(n-3)}{\lambda} \right)$$

整理得:

$$L(\lambda) = \lambda^{-3} \exp \left(-\frac{1}{\lambda} \left[\sum_{i=1}^3 x_i + 10(n-3) \right] \right)$$

代入具体数值 $\sum_{i=1}^3 x_i = 5.3 + 6.0 + 6.7 = 18.0$, 取对数后求导:

$$\frac{d \ln L}{d \lambda} = -\frac{3}{\lambda} + \frac{18.0 + 10(n-3)}{\lambda^2} = 0$$

解得此时 λ 的最大似然估计:

$$\hat{\lambda}_2 = \frac{18.0 + 10(n-3)}{3}$$

(3) 此为定数截尾试验, 预定失效数 $r = 3$ 。试验在第 3 个元件失效时停止, 此时刻为 $x_{(3)} = 6.7$ 。观测数据即为前 3 个次序统计量, 剩余 $n - 3$ 个元件在 $x_{(3)}$ 时刻被截尾。似然函数形式为:

$$L(\lambda) \propto \left[\prod_{i=1}^3 \frac{1}{\lambda} e^{-\frac{x_{(i)}}{\lambda}} \right] \cdot [S(x_{(3)}; \lambda)]^{n-3}$$

这与定时截尾的结构类似, 区别在于截断时间由随机变量 $x_{(3)}$ 决定。整理似然函数:

$$L(\lambda) \propto \lambda^{-3} \exp \left(-\frac{1}{\lambda} \left[\sum_{i=1}^3 x_i + x_{(3)}(n-3) \right] \right)$$

其中总试验时间为 $T = 18.0 + 6.7(n-3)$ 。建立似然方程：

$$\frac{d \ln L}{d \lambda} = -\frac{3}{\lambda} + \frac{18.0 + 6.7(n-3)}{\lambda^2} = 0$$

解得 λ 的最大似然估计：

$$\hat{\lambda}_3 = \frac{18.0 + 6.7(n-3)}{3}$$

四、(25) 设 X 为均值和方差分别为 μ_X 和 σ_X^2 的随机变量， Z 的均值和方差分别为 α 和 σ^2 的随机变量。已知 $Y = Z + \gamma X$ ，其中 γ 为未知常数。

(1) (15) 若 $Cov(X, Z) = 0$ ，请基于独立重复观测 $(X_1, Y_1), \dots, (X_n, Y_n)$ 给出参数 $\alpha, \gamma, \mu_X, \sigma_X^2$ 及 σ^2 的矩估计。

(2) (5) 请在 (1) 基础上，分别计算 γ 的矩估计和 σ^2 的矩估计的数学期望。

(3) (5) 若 $Cov(X, Z) > 0$ ，但仍使用 (1) 中表达式估计 γ ，请分析此时可能造成的影响。

Solution:

(1) 依据矩估计法原理，直接用样本原点矩和中心矩替代总体矩。对于 X 的参数，可直接写出估计量：

$$\hat{\mu}_X = \bar{X}, \quad \hat{\sigma}_X^2 = S_X^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

又因为 $Y = Z + \gamma X$ 及 $Cov(X, Z) = 0$ ，可知 $Cov(X, Y) = \gamma \sigma_X^2$ 。解出 γ 并代入样本矩，得到其估计量：

$$\hat{\gamma} = \frac{S_{XY}}{S_X^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

再由期望关系 $E[Y] = \alpha + \gamma E[X]$ ，代入样本均值及 $\hat{\gamma}$ ，得 α 的估计：

$$\hat{\alpha} = \bar{Y} - \hat{\gamma} \bar{X}$$

对于 σ^2 ，利用 $Var(Y) = \sigma^2 + \gamma^2 \sigma_X^2$ ，即 $\sigma^2 = Var(Y) - \gamma^2 \sigma_X^2$ 。对应的矩估计量为：

$$\hat{\sigma}^2 = S_Y^2 - \hat{\gamma}^2 S_X^2$$

(2) 首先考察 $\hat{\gamma}$ 。将 Y_i 的表达式代入估计式可得 $\hat{\gamma} = \gamma + \frac{\sum_{i=1}^n (X_i - \bar{X})(Z_i - \bar{Z})}{\sum_{i=1}^n (X_i - \bar{X})^2}$ 。由于 X 与 Z 不相关，误差项的期望为 0，故 $\hat{\gamma}$ 为无偏估计：

$$E[\hat{\gamma}] = \gamma$$

其次考察 $\hat{\sigma}^2$ 。该估计量等价于线性回归中的残差平方和 (RSS) 除以样本量 n 。已知 $E[RSS] = (n-2)\sigma^2$ ，因此：

$$E[\hat{\sigma}^2] = E\left[\frac{RSS}{n}\right] = \frac{n-2}{n}\sigma^2$$

(3) 若 $Cov(X, Z) > 0$ ，根据大数定律，估计量 $\hat{\gamma}$ 将依概率收敛于总体协方差与方差之比：

$$\hat{\gamma} \xrightarrow{P} \frac{Cov(X, Y)}{\sigma_X^2} = \frac{Cov(X, Z) + \gamma \sigma_X^2}{\sigma_X^2} = \gamma + \frac{Cov(X, Z)}{\sigma_X^2}$$

显然，由于 $\sigma_X^2 > 0$ 且 $Cov(X, Z) > 0$ ，偏差项为正。这表明忽略 X, Z 的正相关性会导致对 γ 的高估。

五、(25) 设 $Y_{ji} \sim N(\mu_j, \sigma^2)$ ， $i = 1, \dots, m$ ； $j = 1, \dots, k$ ，且所有 Y_{ji} 均相互独立。这里， k 表示分组数， m 表示各组观测数。记 SS_{tot} 为所有 Y_{ji} 的总变差， SS_{betw} 为组间变差， SS_{with} 为组内变差。

(1) (10) 请给出 $SS_{tot}, SS_{betw}, SS_{with}$ 的各自表达式及其关系式。

(2) (10) 请分别计算 $E(SS_{betw}), E(SS_{with})$ 。

(3) (5) 考虑检验问题 $H_0: \mu_1 = \dots = \mu_k$ 。请给出一种检验统计量，并指出 H_0 成立时该统计量服从的分布。

Solution:

(1) 记第 j 组的样本均值为 $\bar{Y}_j = \frac{1}{m} \sum_{i=1}^m Y_{ji}$ ，总样本均值为 $\bar{Y}_{..} = \frac{1}{km} \sum_{j=1}^k \sum_{i=1}^m Y_{ji}$ 。

根据方差分析 (ANOVA) 的定义，三个平方和 (变差) 的表达式分别为：

$$SS_{tot} = \sum_{j=1}^k \sum_{i=1}^m (Y_{ji} - \bar{Y}_{..})^2$$

$$SS_{betw} = \sum_{j=1}^k \sum_{i=1}^m (\bar{Y}_j - \bar{Y}_{..})^2 = m \sum_{j=1}^k (\bar{Y}_j - \bar{Y}_{..})^2$$

$$SS_{with} = \sum_{j=1}^k \sum_{i=1}^m (Y_{ji} - \bar{Y}_j)^2$$

因为：

$$Y_{ji} - \bar{Y}_{..} = (Y_{ji} - \bar{Y}_j) + (\bar{Y}_j - \bar{Y}_{..})$$

对上式两边平方并对所有 i, j 求和，展开后得到三项：

$$\begin{aligned} \sum_{j=1}^k \sum_{i=1}^m (Y_{ji} - \bar{Y}_{..})^2 &= \sum_{j=1}^k \sum_{i=1}^m (Y_{ji} - \bar{Y}_j)^2 + \sum_{j=1}^k \sum_{i=1}^m (\bar{Y}_j - \bar{Y}_{..})^2 \\ &\quad + 2 \sum_{j=1}^k \sum_{i=1}^m (Y_{ji} - \bar{Y}_j)(\bar{Y}_j - \bar{Y}_{..}) \end{aligned}$$

考察交叉项 C ：

$$C = 2 \sum_{j=1}^k \sum_{i=1}^m (Y_{ji} - \bar{Y}_j)(\bar{Y}_j - \bar{Y}_{..})$$

注意到在内层求和符号 $\sum_{i=1}^m$ 中，变量是 i 。而项 $(\bar{Y}_j - \bar{Y}_{..})$ 仅依赖于下标 j ，与下标 i 无关。因此，我们可以将该项视为常数因子，从内层求和中提取出来：

$$C = 2 \sum_{j=1}^k (\bar{Y}_j - \bar{Y}_{..}) \underbrace{\sum_{i=1}^m (Y_{ji} - \bar{Y}_j)}_{\text{关键部分}}$$

根据第 j 组样本均值的定义 $\bar{Y}_j = \frac{1}{m} \sum_{i=1}^m Y_{ji}$ ，我们有 $\sum_{i=1}^m Y_{ji} = m\bar{Y}_j$ 。直接展开关键部分的求和：

$$\sum_{i=1}^m (Y_{ji} - \bar{Y}_j) = \sum_{i=1}^m Y_{ji} - \sum_{i=1}^m \bar{Y}_j = m\bar{Y}_j - m\bar{Y}_j = 0$$

既然对于任意固定的 j ，内层求和结果均为 0，那么整个交叉项 C 必然为 0。从而：

$$SS_{tot} = SS_{betw} + SS_{with}$$

(2) 首先考察组内变差 SS_{with} 。由于 $Y_{ji} \sim N(\mu_j, \sigma^2)$ ，对于固定的第 j 组，统计量 $\sum_{i=1}^m (Y_{ji} - \bar{Y}_j)^2$ 对应于样本方差的 $(m-1)$ 倍，其服从 $\sigma^2 \chi^2(m-1)$ 分布。根据期望的可加性及各组的独立性，有：

$$E(SS_{with}) = \sum_{j=1}^k E \left[\sum_{i=1}^m (Y_{ji} - \bar{Y}_{j.})^2 \right] = \sum_{j=1}^k (m-1)\sigma^2 = k(m-1)\sigma^2$$

接着考察组间变差 SS_{betw} 。注意到 $\bar{Y}_{j.} \sim N(\mu_j, \sigma^2/m)$ 。利用恒等式：

$$E[\sum (X_i - \bar{X})^2] = (n-1)Var(X) + \sum (E[X_i] - \bar{E})^2$$

将变量 $\bar{Y}_{j.}$ 视为样本量为 k 的随机变量序列，其方差为 σ^2/m 。定义参数总均值 $\bar{\mu} = \frac{1}{k} \sum_{j=1}^k \mu_j$ ，则有：

$$E \left[\sum_{j=1}^k (\bar{Y}_{j.} - \bar{\mu})^2 \right] = (k-1) \frac{\sigma^2}{m} + \sum_{j=1}^k (\mu_j - \bar{\mu})^2$$

代入 SS_{betw} 的定义式（乘以系数 m ），得到其数学期望：

$$E(SS_{betw}) = m \left[(k-1) \frac{\sigma^2}{m} + \sum_{j=1}^k (\mu_j - \bar{\mu})^2 \right] = (k-1)\sigma^2 + m \sum_{j=1}^k (\mu_j - \bar{\mu})^2$$

(3) 考虑检验问题 $H_0: \mu_1 = \dots = \mu_k$ 。当 H_0 成立时，(2) 中导出的期望公式中 $\sum (\mu_j - \bar{\mu})^2$ 项为零，此时 SS_{betw} 与 SS_{with} 经自由度标准化后的期望相等（均为 σ^2 ）。

根据 Cochran 定理，在正态假定下， SS_{betw} 与 SS_{with} 相互独立，且分别服从卡方分布（相差常数倍）。构造 F 检验统计量如下：

$$F = \frac{SS_{betw}/(k-1)}{SS_{with}/(k(m-1))}$$

当原假设 H_0 成立时，该统计量服从第一自由度为 $k-1$ 、第二自由度为 $k(m-1)$ 的 F 分布，即：

$$F \sim F(k-1, k(m-1))$$

六、(20) 考虑时间序列 $X_t = \sin(2\pi Ut)$, $t = 1, 2, \dots$ ，其中 U 服从 $(0, 1)$ 区间上的均匀分布。

(1) (10) 请说明 $\{X_t\}_{t=1}^\infty$ 为宽平稳序列。

(2) (5) 请计算 X_1, X_2, X_3 各自的分布函数。

(3) (5) 序列 $\{X_t\}_{t=1}^\infty$ 是否为严平稳序列？请说明理由。

Solution:

(1) 宽平稳序列需满足两个条件：均值为常数，自协方差函数仅依赖于时间差。

首先验证均值恒定。对于任意整数 $t \geq 1$ ，利用 $U \sim U(0, 1)$ ：

$$E[X_t] = \int_0^1 \sin(2\pi ut) du = \left[-\frac{\cos(2\pi ut)}{2\pi t} \right]_0^1 = \frac{1-1}{2\pi t} = 0$$

其次计算自协方差函数 $\gamma(t, s)$ 。由于 $E[X_t] = 0$ ，有：

$$\gamma(t, s) = E[X_t X_s] = \int_0^1 \sin(2\pi ut) \sin(2\pi us) du$$

利用积化和差公式展开：

$$E[X_t X_s] = \frac{1}{2} \int_0^1 \cos(2\pi u(t-s)) du - \frac{1}{2} \int_0^1 \cos(2\pi u(t+s)) du$$

注意到 $t, s \in \mathbb{Z}^+$, 积分项性质如下: 第一项: 若 $t \neq s$, 则 $t-s$ 为非零整数, 积分为 0。若 $t=s$, 则被积函数为 $\cos(0)=1$, 积分为 1。第二项: 由于 $t+s \geq 2$, 余弦函数在 $[0, 1]$ 上积分周期完整, 结果恒为 0。

故自协方差函数为:

$$\gamma(t, s) = \begin{cases} \frac{1}{2}, & t = s \\ 0, & t \neq s \end{cases}$$

显然 $\gamma(t, s)$ 仅依赖于时间差 $|t-s|$, 故序列为宽平稳序列。

(2) 考察 $X_k = \sin(2\pi kU)$ 。由于 $U \sim U(0, 1)$, 对于任意整数 $k \geq 1$, 变换 $V = kU \pmod{1}$ 仍服从 $U(0, 1)$ 。因此 X_1, X_2, X_3 具有相同的边缘分布, 即反正弦分布。

对于 $x \in (-1, 1)$, 其分布函数推导如下:

$$F(x) = P(\sin(2\pi U) \leq x) = \frac{1}{2} + \frac{1}{\pi} \arcsin x$$

综上, X_1, X_2, X_3 的分布函数均为:

$$F(x) = \begin{cases} 0, & x < -1 \\ \frac{1}{2} + \frac{1}{\pi} \arcsin x, & -1 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

(3) 序列 $\{X_t\}_{t=1}^\infty$ 不是严平稳序列。

严平稳要求有限维分布具有平移不变性。这里考虑验证二维分布 (X_1, X_2) 与 (X_2, X_3) 是否相同。

考察条件事件 $X_t = 1$ 下下一时刻的状态: 对于 (X_1, X_2) : 若 $X_1 = \sin(2\pi U) = 1$, 在 $U \in (0, 1)$ 上有唯一解 $U = \frac{1}{4}$ 。此时必然有:

$$X_2 = \sin(4\pi \cdot \frac{1}{4}) = \sin(\pi) = 0$$

即 $P(X_2 = 0 | X_1 = 1) = 1$ 。

对于 (X_2, X_3) : 若 $X_2 = \sin(4\pi U) = 1$, 在 $U \in (0, 1)$ 上有解 $U \in \{\frac{1}{8}, \frac{5}{8}\}$ 。代入 $X_3 = \sin(6\pi U)$: 当 $U = \frac{1}{8}$ 时, $X_3 = \sin(\frac{3\pi}{4}) = \frac{\sqrt{2}}{2}$ 。当 $U = \frac{5}{8}$ 时, $X_3 = \sin(\frac{15\pi}{4}) = -\frac{\sqrt{2}}{2}$ 。即 $P(X_3 = 0 | X_2 = 1) = 0$ 。

由于条件概率分布不一致, 说明联合分布随时间平移发生变化, 故不是严平稳序列。

中国科学技术大学-432 统计学

中国科学技术大学-432 统计学-2016 年

一、(每小题 8 分, 共 56 分)

1. 设 $P(X_i = -1) = P(X_i = 1) = 1/4, P(X_i = 0) = 1/2, i = 1, 2$, 且 $P(X_1 X_2 = 0) = 1$, 求 $P(X_1 = X_2)_0$.

Solution: 写出 (X_1, X_2) 的联合分布列,

$X_1 \quad X_2$	-1	0	1
-1	0	1/4	0
0	1/4	0	1/4
1	0	1/4	0

于是可得:

$$P(X_1 = X_2) = \sum P(X_1 = i, X_2 = i) = 0 (i = -1, 0, 1)$$

2. 设 A 与 B 为两个随机事件, 满足 $P(A) = 1/4, P(B | A) = 1/3$ 和 $P(A | B) = 1/2$. 定义

$$X = \begin{cases} 1, & \text{若 A 发生} \\ 0, & \text{若 A 不发生} \end{cases}$$

$$Y = \begin{cases} 1, & \text{若 B 发生} \\ 0, & \text{若 B 不发生} \end{cases}$$

求 (X, Y) 的分布律.

Solution: 利用题目条件,

$$P(B | A) = \frac{P(AB)}{P(A)} = \frac{1}{3} \Rightarrow P(AB) = \frac{1}{12}$$

$$P(A | B) = \frac{P(AB)}{P(B)} = \frac{1}{2} \Rightarrow P(B) = \frac{1}{6}$$

以及

$$P(A\bar{B}) = P(A) - P(AB) = \frac{1}{6}$$

$$P(\bar{A}B) = P(B) - P(AB) = \frac{1}{12}$$

$$P(\bar{A}\bar{B}) = P(\bar{A}) - P(\bar{A}B) = \frac{2}{3}$$

据此写出 (X, Y) 的联合分布列,

$Y \quad X$	0	1	
0	2/3	1/6	5/6
1	1/12	1/12	1/6
	3/4	1/4	1

3. 设三维随机向量 (X_1, X_2, X_3) 的协方差矩阵为

$$\begin{pmatrix} 9 & 1 & -2 \\ 1 & 20 & 3 \\ -2 & 3 & 12 \end{pmatrix}$$

定义 $Y_1 = 2X_1 + 3X_2 + X_3, Y_2 = X_1 - 2X_2 + 5X_3, Y_3 = X_2 - X_3$, 求 (Y_1, Y_2, Y_3) 的协方差矩阵.

Solution: 记随机向量 $\mathbf{X} = (X_1, X_2, X_3)^T$, $\mathbf{Y} = A\mathbf{X}$, 其中

$$A = \begin{pmatrix} 2 & 3 & 1 \\ 1 & -2 & 5 \\ 0 & 1 & -1 \end{pmatrix}$$

则由协方差矩阵的定义, 有

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= E(\mathbf{Y} - E\mathbf{Y})(\mathbf{Y} - E\mathbf{Y})^T \\ &= E(A(\mathbf{X} - E\mathbf{X}))(A(\mathbf{X} - E\mathbf{X}))^T = A\text{Cov}(\mathbf{X})A^T \end{aligned}$$

所以随机向量 $\mathbf{Y}$, 即 (Y_1, Y_2, Y_3) 的协方差矩阵是

$$\begin{aligned} \text{Cov}(\mathbf{Y}) &= \begin{pmatrix} 2 & 3 & 1 \\ 1 & -2 & 5 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 9 & 1 & -2 \\ 1 & 20 & 3 \\ -2 & 3 & 12 \end{pmatrix} \begin{pmatrix} 2 & 1 & 0 \\ 3 & -2 & 1 \\ 1 & 5 & -1 \end{pmatrix} \\ &= \begin{pmatrix} 250 & -26 & 48 \\ -26 & 305 & -76 \\ 48 & -76 & 26 \end{pmatrix} \end{aligned}$$

4. 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_n$ 分别是来自于正态总体 $N(\mu_1, 25)$ 和 $N(\mu_2, 25)$ 的两个独立简单样本, 为使 $\mu_1 - \mu_2$ 的置信水平 90% 的置信区间长度不超过 2, 问样本容量 n 应取多大?

Solution: $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{50}{n})$, 于是取枢量: $\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{50/n}} \sim N(0, 1)$, 可得出 $\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间为:

$$\left[\bar{X} - \bar{Y} - \sqrt{\frac{50}{n}} \mu_{1-\frac{\alpha}{2}}, \bar{X} - \bar{Y} + \sqrt{\frac{50}{n}} \mu_{1-\frac{\alpha}{2}} \right]$$

则置信区间长度为 $2\sqrt{\frac{50}{n}} u_{1-\frac{\alpha}{2}} = 2\sqrt{\frac{50}{n}} u_{0.95}$, 令 $2\sqrt{\frac{50}{n}} \mu_{0.95} \leq 2$, 其中查表可得 $\mu_{0.95} = 1.645$, 解得 $n \geq 135.3$, 因此 n 至少为 136.

5. 设 $X_1, X_2, \dots, X_n$ 是来自于正态总体 $N(\mu, \sigma^2)$ 的简单随机样本, 其中 μ, σ^2 皆未知. 确定常数 c 使得 $c \sum_{i=1}^{n-1} (X_n - X_i)^2$ 为 σ^2 的无偏估计.

Solution: 由题意有 $X_n - X_i \sim N(0, 2\sigma^2)$, 因此 $E(X_n - X_i)^2 = 2\sigma^2$, 所以

$$E \sum_{i=1}^{n-1} (X_n - X_i)^2 = 2(n-1)\sigma^2$$

于是应取 $c = \frac{1}{2(n-1)}$.

6. 设总体 X 的概率密度函数为

$$f(x; \theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$$

又设 X_1, X_2 是取自该总体的简单样本, 需要考虑的假设检验问顶为 $H_0: \theta = 1 \leftrightarrow H_1: \theta = 2$, 其否定域为 $\{(X_1, X_2): 3X_1 \leq 4X_2\}$, 求此检验的功效函数以及犯两种类型错误的概率.

Solution: 样本的联合密度函数是 $f_{X_1, X_2}(x, y) = \theta^2 x^{\theta-1} y^{\theta-1}, 0 < x, y < 1$. 先求检验的功效函数

$$\rho(\theta) = P_\theta(3X_1 \leq 4X_2) = \int_0^1 dx \int_{\frac{3}{4}x}^1 \theta^2 x^{\theta-1} y^{\theta-1} dy = 1 - \frac{1}{2} \left(\frac{3}{4} \right)^\theta$$

于是犯两类错误的概率是:

$$\alpha = \rho(1) = \frac{5}{8}$$
$$\beta = 1 - \rho(2) = \frac{9}{32}$$

7. 设 $\Phi(x)$ 为标准正态分布的分布函数, 随机变量 X 的分布函数为

$$F(x) = 0.4\Phi\left(\frac{x-2}{4}\right) + 0.6\Phi(x), \forall x \in R$$

求 EX .

Solution: 容易求 X 的密度函数 $f(x) = 0.1\varphi\left(\frac{x-2}{4}\right) + 0.6\varphi(x)$, 其中 $\varphi(\cdot)$ 是标准正态分布的密度函数, 则

$$EX = \int_{-\infty}^{+\infty} \frac{1}{10}x\varphi\left(\frac{x-2}{4}\right)dx + \int_{-\infty}^{+\infty} \frac{3}{5}x\varphi(x)dx$$
$$= 0.8 + 0 = 0.8$$

二、(20 分) 设在 $(0,1)$ 区间上任意选取一点, 该点坐标记为 X ; 然后在区间 $(0, X)$ 上随机地选取一个点, 其坐标记为 Y .

- (1) 求 Y 的概率密度函数;
- (2) 求 $X+Y$ 和 Y 的数学期望;
- (3) 求 X 与 Y 之间的相关系数.

Solution:

(1) 由题意有 $X \sim U(0,1)$, 而 $Y|X=x \sim U(0,x)$, 利用连续场合的全概率公式, 可知 Y 的边际密度函数是

$$f_Y(y) = \int_0^1 \frac{1}{x} I_{\{y < x\}} dx$$
$$= \int_y^1 \frac{1}{x} dx = -\ln y, 0 < y < 1$$

(2) 显然有 $EX = \frac{1}{2}$, 再由重期望公式, $EY = E(E(Y|X)) = E\left(\frac{X}{2}\right) = \frac{1}{4}$, 因此有 $E(X+Y) = \frac{3}{4}$.

(3) 再次利用重期望公式, 有

$$EXY = E(E(XY|X)) = E\left(\frac{X^2}{2}\right) = \frac{1}{2} \left(\frac{1}{12} + \frac{1}{4}\right) = \frac{1}{6}$$

所以 $\text{Cov}(X,Y) = EXY - EXEY = \frac{1}{24}$. 再计算 X 与 Y 的方差, 对于标准均匀分布 X , 有 $\text{Var}(X) = \frac{1}{12}$, 对于 Y 的方差, 利用方差恒等式

$$\text{Var}(Y) = E[\text{Var}(Y|X)] + \text{Var}[E(Y|X)]$$
$$= E\left[\frac{X^2}{12}\right] + \text{Var}\left[\frac{X}{2}\right]$$
$$= \frac{1}{12} \cdot \left(\frac{1}{12} + \frac{1}{4}\right) + \frac{1}{4} \cdot \frac{1}{12}$$
$$= \frac{7}{144}$$

综上所述, $\text{Corr}(X,Y) = \frac{\frac{1}{24}}{\sqrt{\frac{1}{12}}\sqrt{\frac{7}{144}}} = \sqrt{\frac{3}{7}}$.

三、(13 分) 设随机变量 $X \sim N(0,1)$, Y 为另外一个随机变量, 等可能取值 $1, 2, \dots, n$. 记 $Z = X/Y$ 且 Y 与 X 相互独立, 问 Z 是否具有概率密度函数? 若存在概率密度函数, 请求出该概率密度函数.

Solution: 由分布函数定义可以得到,

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P\left(\frac{X}{Y} \leq z\right) = \sum_{i=1}^n P(X \leq zY | Y = i)P(Y = i) \\ &= \frac{1}{n} \sum_{i=1}^n \int_{-\infty}^{zi} \varphi(x) dx \end{aligned}$$

该函数显然是可导的, 其导函数便是 Z 的密度函数,

$$f_Z(z) = \frac{dF(z)}{dz} = \frac{1}{n} \sum_{i=1}^n \frac{i}{\sqrt{2\pi}} \exp\left\{-\frac{z^2 i^2}{2}\right\}, -\infty < z < +\infty$$

四、(12 分) 设 $X_1, \dots, X_9$ 和 $Y_1, \dots, Y_5$ 和分别是来自正态总体 $N(0, 4)$ 和 $N(8, 9)$ 取出的一组简单样本 (即独立同分布样本), 彼此相互独立, 记 $\bar{Y} = \sum_{j=1}^5 Y_j / 5$, 问 $\frac{\sum_{i=1}^9 X_i}{\sqrt{\sum_{j=1}^5 (Y_j - \bar{Y})^2}}$ 服从什么分布?

Solution: 一方面 $\frac{\sum_{i=1}^9 X_i}{6} \sim N(0, 1)$, 另一方面 $\frac{\sum_{j=1}^5 (Y_j - \bar{Y})^2}{9} \sim \chi^2(4)$, 且两者独立, 所以

$$t = \frac{\sum_{i=1}^9 X_i / 6}{\sqrt{\sum_{j=1}^5 (Y_j - \bar{Y})^2 / 9}} = \frac{\sum_{i=1}^9 X_i}{\sqrt{\sum_{j=1}^5 (Y_j - \bar{Y})^2}} \sim t(4)$$

五、(14 分) 设总体 X 分布函数为

$$F(x, \theta) = \begin{cases} 1 - x^{-\theta}, & x > 1 \\ 0, & x \leq 1 \end{cases}$$

其中 $\theta > 1$ 为未知参数, 设 $X_1, X_2, \dots, X_n$ 为来自总体 X 的简单随机样本. 求 θ 的矩估计量和极大似然估计量.

Solution: 先求出总体的密度函数, $f(x, \theta) = \theta x^{-\theta-1}, x > 1$, 于是

$$EX = \int_1^{+\infty} \theta x^{-\theta} dx = \frac{\theta}{\theta - 1},$$

所以 θ 的矩估计为 $\hat{\theta}_M = \frac{\bar{X}}{\bar{X} - 1}$. 再求极大似然估计, 似然函数是

$$L(\theta) = \theta^n \left(\prod_{i=1}^n x_i \right)^{-(\theta+1)}, \quad \theta > 1,$$

对数似然函数为 $\ln L(\theta) = n \ln \theta - (\theta + 1) \sum_{i=1}^n \ln x_i$, 关于参数求偏导, 有

$$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{n}{\theta} - \sum_{i=1}^n \ln x_i, \quad \theta > 1,$$

可以发现, 如果 $\theta < \frac{n}{\sum_{i=1}^n \ln x_i}$, 则 $\ln L(\theta)$ 递增, 如果 $\theta > \frac{n}{\sum_{i=1}^n \ln x_i}$, 则 $\ln L(\theta)$ 递减, 结合 $\theta > 1$, 我们得到 θ 的极大似然估计是

$$\hat{\theta}_{MLE} = \max \left\{ 1, \frac{n}{\sum_{i=1}^n \ln x_i} \right\}.$$

六、(20 分) 现调查 50 个人, 每人回答其性别和喜欢的颜色, 调查结果如下:

	红色	蓝色	绿色
男	5	14	6
女	15	6	4

现欲检验一个人的性别与其喜欢的颜色是否相互独立. 由具体的数据, 检验结果如何? (取显著性水平 $\alpha = 0.025$ 和 $\alpha = 0.01$)

Solution: 独立情况下的理论样本数

	红色	蓝色	绿色
男	10	10	5
女	10	10	5

考虑如下假设检验问题 H_0 : 性别与其喜欢的颜色无关 (独立) vs H_1 : 性别与其喜欢的颜色不独立此时检验统计量为: $\chi^2 = \sum_{i=1}^2 \sum_{j=1}^3 \frac{(n_{ij} - n\hat{p}_{ij})^2}{n\hat{p}_{ij}} \sim \chi^2((2-1)(3-1)) = \chi^2(2)$ 经计算, $\chi^2 = 8.6$, 查分位数表得知 $\alpha = 0.025$ 时, $\chi^2 > \chi_{1-\alpha}^2 = 7.378$, 此时应拒绝原假设, 即我们没有充分的理由能认为性别与喜欢颜色无关 (独立). 而 $\alpha = 0.01$ 时, $\chi^2 < \chi_{1-\alpha}^2 = 9.21$, 此时不应拒绝原假设, 即我们可以认为性别与喜欢颜色无关 (独立).

七、(15 分) 考虑一元线性回归模型 $Y_i = \beta x_i + \varepsilon_i, i = 1, \dots, n$. 其中 $E\varepsilon_i = 0, \text{Var}(\varepsilon_i) = \sigma^2, \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 (\forall i \neq j)$. 试求 β 的最小二乘估计 $\hat{\beta}$, 并证明 $\hat{\beta}$ 为 β 的无偏估计.

Solution:

记 $Q(\beta) = \sum_{i=1}^n (Y_i - \beta x_i)^2$, 最小二乘估计即求解优化问题

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} Q(\beta)$$

令 $\frac{\partial Q}{\partial \beta} = -2 \sum_{i=1}^n (Y_i - \beta x_i) x_i = 0$, 解得 $\hat{\beta} = \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}$ 是唯一驻点.

而目标函数显然为严格凸函数, 因此该唯一驻点是最小值点, 即 β 的最小二估计是

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}, \text{ 又}$$

$$E\hat{\beta} = E \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2} = \frac{1}{\sum_{i=1}^n x_i^2} \sum_{i=1}^n x_i EY_i = \frac{1}{\sum_{i=1}^n x_i^2} \sum_{i=1}^n x_i \beta x_i = \beta$$

因此 $\hat{\beta}$ 为 β 的无偏估计.

中国科学技术大学-432 统计学-2017 年

一、(10 分) 设事件 A, B, C 两两独立, 满足 $P(A) = P(B) = P(C) = p < 0.5$, $ABC = \emptyset$, 且 $P(A \cup B \cup C) = 9/16$, 求 p .

Solution: 由概率的加法公式, 有

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC)$$

已知 A, B, C 两两独立, 可得 $P(AB) = P(AC) = P(BC) = p^2$. 同时又因为 $ABC = \emptyset$, 可得 $P(ABC) = 0$, 又 $P(A \cup B \cup C) = \frac{9}{16}$, 可得如下方程

$$\frac{9}{16} = 3p - 3p^2$$

解得 $p = \frac{1}{4}, \frac{3}{4}$, 又因为 $p < 0.5$, 所以 $p = \frac{1}{4}$.

二、(12 分) 设 X_1, X_2, X_3 为相互独立且服从 $N(\mu, \sigma^2)$ 分布的随机变量, 定义

$$Y_1 = \frac{\sqrt{3}}{3}(X_1 + X_2 + X_3), \quad Y_2 = \frac{\sqrt{2}}{2}(X_1 - X_2)$$

试求 $\text{Var}(Y_1 Y_2)$.

Solution: 由题意 X_1, X_2, X_3 为相互独立且均服从 $N(\mu, \sigma^2)$ 的随机变量, 那么

$$X_1 + X_2 + X_3 \sim N(3\mu, 3\sigma^2), \quad Y_1 \sim N(\sqrt{3}\mu, \sigma^2)$$

$$X_1 - X_2 \sim N(0, 2\sigma^2), \quad Y_2 \sim N(0, \sigma^2)$$

而

$$\begin{aligned} \text{Cov}(Y_1, Y_2) &= \text{Cov}\left(\frac{\sqrt{3}}{3}(X_1 + X_2 + X_3), \frac{\sqrt{2}}{2}(X_1 - X_2)\right) \\ &= \frac{\sqrt{6}}{6} [\text{Var}(X_1) - \text{Var}(X_2)] = 0 \end{aligned}$$

由正态分布的性质可知 Y_1, Y_2 相互独立. 于是

$$\begin{aligned} \text{Var}(Y_1 Y_2) &= E(Y_1^2 Y_2^2) - E^2(Y_1 Y_2) = E(Y_1^2) E(Y_2^2) - E^2(Y_1) E^2(Y_2) \\ &= [\text{Var}(Y_1) + E^2(Y_1)] [\text{Var}(Y_2) + E^2(Y_2)] - E^2(Y_1) E^2(Y_2) \\ &= (\sigma^2 + 3\mu^2)(\sigma^2 + 0) - 3\mu^2 \cdot 0 \\ &= (\sigma^2 + 3\mu^2)\sigma^2 \end{aligned}$$

三、(24 分) 设随机变量 X 服从 (a, b) 区间上的均匀分布, 其中 $0 < a < b < \infty$. 在给定 $X = x$ 的条件下, Y 服从参数为 x (即失效率为常数 x) 的指数分布.

1. 试求 X 与 XY 的联合概率密度;
2. 试判断 X 与 XY 是否相互独立;
3. 求 XY 的分布函数及期望 $E[XY]$;
4. 求函数 $h(x)$ 使得 $h(XY)$ 服从 $U(0, 1)$ 分布.

Solution:

1. 由题意, $f_{Y|X}(y|x) = \begin{cases} xe^{-xy}, & y \geq 0 \\ 0, & y < 0 \end{cases}$, $f_X(x) = \begin{cases} \frac{1}{b-a}, & b < x < a \\ 0, & \text{其他} \end{cases}$, 则 (X, Y) 的联合密度函数是

$$f(x, y) = \begin{cases} \frac{xe^{-xy}}{b-a}, & a < x < b, y \geq 0 \\ 0, & \text{其他} \end{cases}. \quad \text{令 } x = u, xy = v \Rightarrow \begin{cases} x = u \\ y = \frac{v}{u} \end{cases}, \text{ 雅各比行列式为 } |J| = \begin{vmatrix} 1 & 0 \\ -\frac{v}{u^2} & \frac{1}{u} \end{vmatrix} =$$

$\frac{1}{u}$, 则 (U, V) 的联合密度函数是 $f_{U,V}(u, v) = \begin{cases} \frac{ue^{-v}}{b-a} \cdot \frac{1}{u} = \frac{e^{-v}}{b-a}, & a < u < b, v \geq 0 \\ 0, & \text{其他} \end{cases}$, 这也是 (X, XY) 的联合密度函数.

2. 先求 V 和 U 各自的边际密度函数, 它们分别是

$$f_V(v) = \int_a^b f(u, v) du = \int_a^b \frac{e^{-v}}{b-a} du = e^{-v}, v \geq 0$$

$$f_U(u) = f_X(u) = \begin{cases} \frac{1}{b-a}, & b < u < a \\ 0, & \text{其他} \end{cases}$$

而 $f_{U,V}(u, v) = f_U(u)f_V(v)$, 所以 U, V 相互独立, 即 X, XY 相互独立.

3. 由 (2) 知, $f_V(v) = e^{-v}, v \geq 0$, 于是 $EXY = EV = 1$.

4. XY 服从参数为 1 的指数分布, 其分布函数是

$$F_U(u) = \begin{cases} 1 - e^{-u}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

于是令 $h(x) = F_U(x)$, 则 $h(XY) \sim U(0, 1)$.

四、(18 分) 现抛掷一枚不均匀的硬币, 每次抛掷出现正面的概率为 $p \in (0, 1)$, 出现反面的概率为 $q = 1 - p$. 按如下规则进行抛掷, 问正反面出现的平均次数之比各为多少?

1. 抛掷直到抛出第一个正面为止;

2. 抛掷直到抛出第一个反面为止;

3. 抛掷 100 次.

Solution:

1. 抛掷次数 $X \sim Ge(p)$, 则 $EX = \frac{1}{p}$. 故正面平均出现 1 次, 反面平均出现 $\frac{1}{p} - 1$ 次, 两者之比为 $\frac{\frac{1}{p}}{\frac{1}{p} - 1} = \frac{p}{1-p}$.

2. 抛掷次数 $Y \sim Ge(1-p)$, $EY = \frac{1}{1-p}$. 故正面平均出现 $\frac{1}{1-p} - 1$ 次, 反面平均出现 1 次, 两者之比为 $\frac{\frac{1}{1-p} - 1}{1} = \frac{p}{1-p}$.

3. 抛掷得正面次 $Z \sim B(100, p)$, $EZ = 100p$, 故正面平均出现 $100p$ 次, 反面平均出现 $100 - 100p$ 次, 两者之比为 $\frac{100p}{100 - 100p} = \frac{p}{1-p}$.

五、(12 分) 设 $X_1, X_2, \dots, X_n$ 独立同分布, $\sigma^2 = \text{Var}(X_1)$ 存在有限, 但未知. 证明样本方差是 σ^2 的无偏估计, 并判断样本标准差是否为 σ 的无偏估计.

Solution:

记样本方差 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$,

$$\begin{aligned} E[(n-1)s^2] &= E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] \\ &= E\left[\sum_{i=1}^n X_i^2 - n\bar{X}^2\right] \\ &= nE(X_i^2) - nE(\bar{X}^2) \\ &= n\left[\mu^2 + \sigma^2 - \left(\mu^2 + \frac{1}{n}\sigma^2\right)\right] = (n-1)\sigma^2, \end{aligned}$$

因此 $E[s^2] = \sigma^2$. 考虑函数 $g(x) = \sqrt{x}$, 它在 $(0, +\infty)$ 上是凹函数, 由 Jensen 不等式,

$$E(s) = E(g(s^2)) \leq g(E[s^2]) = \sigma$$

其中等号成立的条件为" $g(s^2)$ 几乎处处为线性函数", 而 $g(\cdot)$ 本身是一个非线性函数, 从而这当且仅当 s^2 是单点分布, 而这又当且仅当 X 服从单点分布, 即 $\sigma^2 = 0$. 除此之外, 我们有

$$E(s) < \sigma.$$

六、(20 分) 假设 $X_1, \dots, X_n$ 为从总体 F_θ 中抽取的简单随机样本, F_θ 有概率密度 $f(x, \theta)$, 其中 θ 为未知参数, 且

$$f(x, \theta) = \frac{\theta}{2\sqrt{x}} e^{-\theta\sqrt{x}}, \quad \forall x > 0$$

1. 求 $\sqrt{X_i}$ 的分布;
2. 求 $1/\theta^2$ 的矩估计和极大似然估计;
3. 分别判断所求 $1/\theta^2$ 的矩估计和极大似然估计是否为无偏估计.

Solution:

1. 作总体变换, 令 $Y_i = \sqrt{X_i}$, Y_i 的密度函数是,

$$f_Y(y) = f_X(y^2) |2y| = \theta e^{-\theta y}, \quad y > 0$$

即 $Y_i \text{ i.i.d } \sim \text{Exp}(\theta)$.

2. 由于 $\text{Var}(Y) = \frac{1}{\theta^2}$, 故 $\frac{1}{\theta^2}$ 的矩估计为 $s_Y^2 = \frac{1}{n-1} \sum_{i=1}^n \left(\sqrt{X_i} - \frac{1}{n} \sum_{i=1}^n \sqrt{X_i} \right)^2$. 样本的似然函数为 $L(\theta) = \theta^n e^{-\theta \sum_{i=1}^n y_i}$, 取对数并关于 θ 求导置零, 得似然方程

$$\frac{d \ln L(\theta)}{d\theta} = \frac{n}{\theta} - \sum_{i=1}^n y_i = 0$$

解得 $\hat{\theta} = \frac{n}{\sum_{i=1}^n y_i} = \frac{n}{\sum_{i=1}^n \sqrt{x_i}}$, 又 $\frac{\partial^2 \ln L(Y, \theta)}{\partial \theta^2} = -\frac{1}{\theta^2} < 0$, 所以 $\hat{\theta}$ 是 θ 的极大似然估计, 再由极大似然估计的不变性知, $\left(\frac{\sum_{i=1}^n \sqrt{x_i}}{n} \right)$ 是 $\frac{1}{\theta^2}$ 的极大似然估计.

3. 由 $Y_i \text{ i.i.d } \sim \text{Exp}(\theta) = \text{Ga}(1, \theta)$, 以及伽马分布的可加性, $\sum_{i=1}^n Y_i \sim \text{Ga}(n, \theta)$ 所以

$$\begin{aligned} E \left(\left(\sum_{i=1}^n Y_i \right)^2 \right) &= \left[E \left(\sum_{i=1}^n Y_i \right) \right]^2 + \text{Var} \left(\sum_{i=1}^n Y_i \right) = \left(\frac{n}{\theta} \right)^2 + \frac{n}{\theta^2} = \frac{n+n^2}{\theta^2} \\ E(s_Y^2) &= E \left(\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 \right) \\ &= \frac{1}{n-1} E \left(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2 \right) \\ &= \frac{n}{n-1} \left(\frac{1}{\theta^2} + \frac{1}{\theta^2} - \frac{n^2+n}{n^2\theta^2} \right) = \frac{1}{\theta^2} \end{aligned}$$

所以矩估计是 $\frac{1}{\theta^2}$ 的无偏估计. 而 $E \left(\frac{\sum_{i=1}^n y_i}{n} \right)^2 = \frac{n+1}{n\theta^2}$, 故极大似然估计不是 $\frac{1}{\theta^2}$ 的无偏估计.

七、(12 分) 测量一个物体的重量, 已知测量值服从正态分布 $N(\mu, \sigma^2)$, 测量 10 次, 求出样本均值 10.48, 标准差为 1.36. 试求:

1. 该物体重量 μ 的置信水平为 90% 的置信区间;
2. 测量标准差 σ 的置信水平 95% 的置信区间.

Solution:

1. 取枢轴量 $T = \frac{\sqrt{n}(\bar{X}-\mu)}{s} \sim t(n-1)$, 由于 $P\left\{-t_{\frac{\alpha}{2}}(n-1) \leq \frac{\bar{x}-\mu}{s/\sqrt{n}} \leq t_{\frac{\alpha}{2}}(n-1)\right\} = 1-\alpha$, 反解可得到置信区间

$$\left[\bar{x} - \frac{s}{\sqrt{n}}t_{\frac{\alpha}{2}}(n-1), \bar{x} + \frac{s}{\sqrt{n}}t_{\frac{\alpha}{2}}(n-1)\right]$$

其中 $\alpha = 0.1, n = 10$, 代入数据得 μ 的置信水平为 90% 的置信区间为 $[9.69, 11.27]$.

2. 枢轴量 $\chi^2 = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$, 由于 $P\left\{\chi_{1-\frac{\alpha}{2}}^2(n-1) \leq \frac{(n-1)s^2}{\sigma^2} \leq \chi_{\frac{\alpha}{2}}^2(n-1)\right\} = 1-\alpha$, 反解得到 σ 的置信区间为 $\left[\sqrt{\frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}}, \sqrt{\frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}}\right]$. 其中 $\alpha = 0.05, n = 10$, 代入数据得 σ 的置信水平为 95% 的置信区间为 $[0.94, 2.48]$

八、(12 分) 以 X 记 n 次独立重复试验中某事件 A 发生的次数, 在任一次试验中事件 A 发生的概率为 p . 考虑检验问题 $H_0: p = 0.5 \longleftrightarrow H_1: p > 0.5$. 该检验的否定域为 $X = n$.

1. 该检验犯第一类错误的概率;
2. 当 $p = 0.8$ 时, 求该检验犯第二类错误的概率.

Solution:

1. 犯第一类错误的概率是 $\alpha = P(X = n | H_0) = P(X = n | p = 0.5) = \frac{1}{2^n}$.
2. 犯第二类错误的概率是 $\beta(0.8) = 1 - P(X = n | p = 0.8) = 1 - (0.8)^n$.

九、(18 分) 设 $X_1, \dots, X_6$ 是从正态总体 $N(0, \sigma_1^2)$ 中抽出的随机样本, $Y_1, \dots, Y_9$ 是从正态总体 $N(0, \sigma_2^2)$ 中抽出的另一随机样本, 两组样本独立, 其中 σ_1^2 与 σ_2^2 未知. 已知 $\sum_{i=1}^6 X_i^2 / \sum_{j=1}^9 Y_j^2 = 1.94$, 考虑如下的检验问题: $H_0: \sigma_1^2 \leq \sigma_2^2 \longleftrightarrow H_1: \sigma_1^2 > \sigma_2^2$, 其中检验水平 $\alpha = 0.05$.

Solution: 取检验统计量 $F = \frac{\sum_{i=1}^m X_i^2/m}{\sum_{j=1}^n Y_j^2/n} \sim_{H_0} F(m, n)$, 拒绝域为

$$W = \{F > F_{\alpha}(m, n)\}.$$

其中 $m = 6, n = 9, \alpha = 0.05, F_{0.05}(6, 9) = 3.37$, 代入数据得 $F = \frac{9}{6} \times 1.94 = 2.91 \notin W$, 故不拒绝原假设.

十、(12 分) 设 $X_1, \dots, X_n$ 是从正态总体 $N(\mu, \sigma^2)$ 中抽出的随机样本, 证明样本方差与样本均值相互独立.

Solution: 构造正交矩阵

$$A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ \frac{1}{\sqrt{2 \cdot 1}} & -\frac{1}{\sqrt{2 \cdot 1}} & 0 & \cdots & 0 \\ \frac{1}{\sqrt{3 \cdot 2}} & \frac{1}{\sqrt{3 \cdot 2}} & -\frac{2}{\sqrt{3 \cdot 2}} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \cdots & -\frac{n-1}{\sqrt{n(n-1)}} \end{pmatrix}$$

记随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$, 则 $\mathbf{X}$ 服从 n 维正态分布, 令 $\mathbf{Y} = A\mathbf{X}$, 则由正态分布性质知, $\mathbf{Y}$ 也服从 n 维正态分布, 其均值向量为

$$E\mathbf{Y} = AE\mathbf{X} = A \begin{pmatrix} \mu \\ \mu \\ \vdots \\ \mu \end{pmatrix} = \begin{pmatrix} \sqrt{n}\mu \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

协方差矩阵为 $A^T(\sigma^2 I_n)A = \sigma^2 I_n$. 同时注意到

$$Y_1 = \frac{1}{\sqrt{n}}(X_1 + X_2 + \cdots + X_n) = \sqrt{n}\bar{X}$$

$$\sum_{i=1}^n X_i^2 = \sum_{i=1}^n Y_i^2$$

其中第二点是由正交矩阵的性质得到的. 利用上述第一点可以得到 $\bar{X} \sim \frac{Y_1}{\sqrt{n}} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$. 同时利用上述两点可以得到 $(n-1)S^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 = \sum_{i=1}^n Y_i^2 - Y_1^2 = Y_2^2 + Y_3^2 + Y_4^2 + \cdots + Y_n^2$ 且对于 $i = 2, \cdots, n$, 有 Y_i i.i.d $\sim N(0, \sigma^2)$, 所以 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$. 并且注意到 S^2 仅仅依赖于 $Y_2, Y_3, \cdots, Y_n$, 而 $\bar{X}$ 仅仅依赖于 Y_1 . 由正态分布独立与不相关等价的性质知道, Y_1 与 $Y_2, Y_3, \cdots, Y_n$ 是独立的, 所以 $\bar{X}$ 与 S^2 也是相互独立的.

中国科学技术大学-432 统计学-2018 年

一、(12 分) 设 $g(x)$ 是一个非负随机变量的概率密度函数, 定义

$$f(x, y) = \begin{cases} \frac{g(\sqrt{x^2+y^2})}{2\pi\sqrt{x^2+y^2}}, & x^2 + y^2 > 0 \\ 0, & x = y = 0. \end{cases}$$

问 $f(x, y)$ 是否是一个二维随机向量的概率密度函数?

Solution: 由于 $g(x)$ 为非负随机变量的概率密度函数, 则有 $\int_0^{+\infty} g(x)dx = 1$, 且 $g(x) \geq 0$, 所以 $f(x, y)$ 满足非负性, 此外

$$\iint_R f(x, y)dxdy = \int_0^{2\pi} d\theta \int_0^{+\infty} \frac{g(r)}{2\pi} dr = \int_0^{+\infty} g(r)dr = 1$$

所以 $f(x, y)$ 满足正则性, 综上所述 $f(x, y)$ 是一个二维随机向量的概率密度函数.

二、(14 分) 设 $X \sim N(0, 1)$, $a > 0$ 为常数. 定义 $Y = \begin{cases} X, & |x| \leq a, \\ -X, & |x| > a. \end{cases}$ 求 Y 的分布.

Solution: 先求 Y 的分布函数, 由全概率公式, 有

$$\begin{aligned} P(Y \leq y) &= P(Y \leq y, |X| \leq a) + P(Y \leq y, |X| > a) \\ &= P(X \leq y, -a \leq X \leq a) + P(X \geq -y, X > a) + P(X \geq -y, X < -a) \end{aligned}$$

按照 y 的取值进行分类: (i) $y < -a$, 则

$$F_Y(y) = P(Y \leq y) = P(X \geq -y) = 1 - \Phi(-y) = \Phi(y);$$

(ii) $-a \leq y < a$, 则

$$\begin{aligned} P(Y \leq y) &= P(-a < X \leq y) + P(X > a) \\ &= \Phi(y) - \Phi(-a) + 1 - \Phi(a) = \Phi(y) \end{aligned}$$

(iii) $y \geq a$, 则

$$P(Y \leq y) = P(Y \leq a) + P(a < Y \leq y) = \Phi(y).$$

综上所述有 $Y \sim N(0, 1)$.

三、(14 分) 一个盒子由 a 个白球, b 个黑球和 n 个红球, $a, b, n \in N_+$. 现不放回地依次取出一球, 求白球先于黑球被取出的概率, 并证明该概率与 n 无关.

Solution: 用事件 A_i 表示初始时刻盒中有 i 个红球, 最终白球先于黑球被取出; 用事件 B_1, B_2, B_3 分别表示第一次抽出红、白、黑球, 则显然有 $P(A_0) = \frac{a}{a+b}$. 假设 $P(A_{n-1}) = \frac{a}{a+b}$, 则由全概率公式有

$$\begin{aligned} P(A_n) &= P(A_n | B_1)P(B_1) + P(A_n | B_2)P(B_2) + P(A_n | B_3)P(B_3) \\ &= P(A_{n-1}) \cdot \frac{n}{a+b+n} + 1 \cdot \frac{a}{a+b+n} + 0 \cdot \frac{b}{a+b+n} \\ &= \frac{\frac{a}{a+b}n + a}{a+b+n} = \frac{a}{a+b} \end{aligned}$$

则由数学归纳法知 $P(A_n) \equiv \frac{a}{a+b}$, 与 n 无关.

四、(16 分) 设 $X_1, X_2, \dots, X_n$ 是来自同一总体的简单随机样本, 总体的概率密度是 $f(x) = \begin{cases} 3x^2, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$,

试证明: 对任意 $1 \leq i < j \leq n$, $X_{(i)}/X_{(j)}$ 与 $X_{(j)}$ 相互独立, 并求他们各自的边缘概率密度函数.

Solution: 总体的密度函数是 $F(x) = \begin{cases} 0 & x < 0 \\ x^3 & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases}$, 根据次序统计量联合分布的公式, $(X_{(i)}, X_{(j)})$ 的

联合密度函数是, 对于 $0 < y < z < 1$

$$f_{i,j}(y, z) = \frac{n! \cdot 3y^2 \cdot 3z^2}{(i-1)!(j-i-1)!(n-j)!} (y^3)^{i-1} (z^3 - y^3)^{j-i-1} (1 - z^3)^{n-j}$$

作变换 $\begin{cases} T = \frac{X_{(i)}}{X_{(j)}} \\ U = X_{(j)} \end{cases} \Leftrightarrow \begin{cases} X_{(i)} = TU \\ X_{(j)} = U \end{cases}$, 雅各比行列式 $\frac{\partial(X_{(i)}, X_{(j)})}{\partial(T, U)} = u$, 于是 (T, U) 的密度函数是, 对于 $0 < tu < u < 1$, 即 $0 < u, t < 1$, 有

$$\begin{aligned} f_{T,U}(t, u) &= f_{i,j}(tu, u)|u| \\ &= \frac{n! \cdot 3(tu)^2 \cdot 3u^2 \cdot u}{(i-1)!(j-i-1)!(n-j)!} (tu)^{3(i-1)} (u^3 - (tu)^3)^{j-i-1} (1 - u^3)^{n-j} \\ &= \frac{9n!}{(i-1)!(j-i-1)!(n-j)!} t^{3i-1} (1 - t^3)^{j-i-1} u^{3j-1} (1 - u^3)^{n-j} \end{aligned}$$

由于联合密度的变量可分离, 可看出 T, U 相互独立, 其中 T 的密度函数是

$$f_T(t) = k (1 - t^3)^{j-i-1} t^{3i-1}, 0 < t < 1$$

其中 k 是一个正则化常数, 由于

$$\begin{aligned} \int_0^1 (1 - t^3)^{j-i-1} t^{3i-1} dt &= \frac{1}{3} \int_0^1 (1 - t^3)^{j-i-1} t^{3i-3} dt^3 \\ &= \frac{1}{3} \int_0^1 (1 - y)^{j-i-1} y^{i-1} dy \\ &= \frac{\Gamma(j-i)\Gamma(i)}{3\Gamma(j)} = \frac{(j-i-1)!(i-1)!}{3(j-1)!} \end{aligned}$$

所以 $f_T(t) = \frac{3(j-1)!}{(j-i-1)!(i-1)!} (1 - t^3)^{j-i-1} t^{3i-1}, 0 < t < 1$, 这便是 $\frac{X_{(i)}}{X_{(j)}}$ 的密度函数. 而 $X_{(j)}$ 的边际密度函数是好求的, 直接根据公式, 它是

$$f_j(u) = \frac{3n!}{(j-1)!(n-j)!} (1 - u^3)^{n-j} u^{3j-1}, 0 < u < 1$$

五、(16 分) 设 $X_1, X_2, \dots, X_n \sim N(\mu, \sigma^2), n > 2$, 定义

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, T = \sum_{i=1}^n (X_i - \bar{X})^2 - \frac{n}{n-1} (X_i - \bar{X})^2$$

(1) 求 ET ;

(2) 证明 $\sqrt{\frac{n(n-2)}{n-1}} \cdot \frac{X_1 - \bar{X}}{\sqrt{T}} \sim t_{n-2}$.

Solution: (1) 由于 $X_i - \bar{X} \sim N(0, \frac{n-1}{n}\sigma^2)$, 故 $\left(\frac{X_i - \bar{X}}{\sqrt{\frac{n-1}{n}\sigma^2}}\right)^2 \sim \chi^2(1)$, 于是

$$E(X_1 - \bar{X})^2 = \frac{n-1}{n}\sigma^2$$

所以 $ET = n \cdot \frac{n-1}{n}\sigma^2 - \frac{n}{n-1} \frac{n-1}{n}\sigma^2 = (n-2)\sigma^2$.

(2) 构建正交矩阵

$$A = \begin{bmatrix} \frac{n-1}{\sqrt{n(n-1)}} & \frac{-1}{\sqrt{n(n-1)}} & \cdots & \frac{-1}{\sqrt{n(n-1)}} \\ \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ \vdots & \vdots & \ddots & \vdots \end{bmatrix}$$

该矩阵仅给出了前 2 行, 后 $n-2$ 行只需保证 A 满足正交性即可, 这样的矩阵是一定存在的 (因为我们可以任取其余 $n-2$ 个与 A 的前 2 个行向量线性无关的向量, 再利用施密特正交化的方法给出 A 的后 $n-2$ 行). 记随机向量 $\mathbf{X} = (X_1, X_2, \cdots, X_n)^T$, 作线性变换 $\mathbf{Y} = (Y_1, Y_2, \cdots, Y_n)^T = A\mathbf{X}$, 由于 $\mathbf{X} \sim N_n(\mu\mathbf{1}_n, \sigma^2 I_n)$, 则 $\mathbf{Y} \sim N_n(\mu A\mathbf{1}_n, \sigma^2 I_n)$, 其中特别的有

$$Y_1 = \frac{n}{\sqrt{n(n-1)}} \left(\frac{n-1}{n} X_1 - \frac{1}{n} X_2 - \cdots - \frac{1}{n} X_n \right) = \frac{n}{\sqrt{n(n-1)}} (X_1 - \bar{X})$$
$$Y_2 = \frac{1}{\sqrt{n}} (X_1 + X_2 + \cdots + X_n) = \sqrt{n}\bar{X}$$

需要特别指出的是, 从 $\mathbf{Y}$ 的协方差矩阵可以看出, $\mathbf{Y}$ 的各个分量之间都是独立的, 并且除了 $Y_2 = \sqrt{n}\bar{X} \sim N(\sqrt{n}\mu, \sigma^2)$ 之外, 其余的 Y_j 都服从均值为 0, 方差为 σ^2 的正态分布, 其中方差为 σ^2 是显然的, 关于均值为 0, 记

$$Y_j = a_{j1}X_1 + a_{j2}X_2 + \cdots + a_{jn}X_n$$

其中 $\mathbf{a}_j = (a_{j1}, a_{j2}, \cdots, a_{jn})$ 是与 A 的第二行向量正交的, 即 $\frac{1}{\sqrt{n}} \sum_{i=1}^n a_{ji} = 0$, 于是 $EY_j = E(\sum_{i=1}^n a_{ji}X_i) = \sum_{i=1}^n a_{ji}\mu = 0$. 同时, $T = (n-1)S^2 - Y_1^2$. 再由正交矩阵的性质注意到 $\sum_{i=1}^n X_i^2 = \sum_{i=1}^n Y_i^2$, 就有 $(n-1)S^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 = \sum_{i=1}^n Y_i^2 - Y_2^2 = Y_1^2 + Y_3^2 + Y_4^2 + \cdots + Y_n^2$ 所以 $T = (n-1)S^2 - Y_1^2 = Y_3^2 + Y_4^2 + \cdots + Y_n^2$, 它仅仅是 $Y_3, \cdots, Y_n$ 的函数, 所以它与 Y_1 (即 $X_1 - \bar{X}$) 独立, 并且 $\frac{T}{\sigma^2} \sim \chi^2(n-2)$. 又 $X_1 - \bar{X} \sim N(0, \frac{n-1}{n}\sigma^2)$, 所以

$$\frac{\frac{X_1 - \bar{X}}{\sqrt{\frac{n-1}{n}\sigma^2}}}{\sqrt{\frac{T/\sigma^2}{n-2}}} = \sqrt{\frac{n(n-2)}{n-1}} \frac{X_1 - \bar{X}}{\sqrt{T}} \sim t(n-2)$$

六、(24 分) 一种型号的电子元件寿命的分布函数是

$$F(x, \alpha, \beta) = \begin{cases} 1 - \exp\left\{\frac{-(x-\alpha)}{\beta}\right\}, & x \geq \alpha \\ 0, & x < \alpha \end{cases}$$

$\alpha > 0, \beta > 0$ 均为未知参数. 现取该型号原件 n 个进行独立测试, 测得寿命分别为 $X_1, X_2, \cdots, X_n$

(1) 分别求 α 和 β 的矩估计和极大似然估计;

(2) 所求极大似然估计是否为无偏估计? 若不是无偏估计, 则请基于该极大似然估计构造出 α 和 β 的无偏估计.

Solution: (1) 作总体变换, 有 $Y_i = X_i - \alpha$ i.i.d $\sim \text{Exp}\left(\frac{1}{\beta}\right)$, 由指数分布性质:

$$EX = EY + \alpha = \alpha + \beta, DX = DY = \beta^2$$

用样本矩替代总体矩, 反解得参数的矩估计, 即

$$\begin{cases} \bar{X} = \hat{\alpha} + \hat{\beta} \\ S^2 = \hat{\beta}^2 \end{cases} \Rightarrow \begin{cases} \hat{\alpha} = \bar{X} - S \\ \hat{\beta} = S \end{cases}$$

再求极大似然估计, 似然函数为

$$L(\alpha, \beta) = \frac{1}{\beta^n} e^{-\sum_{i=1}^n \frac{(X_i - \alpha)}{\beta}} I_{\{X_{(n)} \geq \alpha\}}$$

似然函数关于 α 是 $[X_{(1)}, +\infty)$ 上的单调递减函数, 因此可以看出 α 的极大似然估计是 $\hat{\alpha}_L = X_{(1)}$, 再将似然函数取对数并关于 β 求偏导置 0, 可解得 β 的似然方程, 即

$$\frac{\partial \ln L}{\partial \beta} = -\frac{n}{\beta} + \frac{n\bar{X} - n\alpha}{\beta^2} = 0$$

代入 $\hat{\alpha}_L = X_{(1)}$ 解得, $\hat{\beta}_L = \bar{X} - X_{(1)}$ 是 β 的极大似然估计.

(2) 由指数最小值分布结论可知 $Y_{(1)} = X_{(1)} - \alpha \sim \text{Exp}\left(\frac{n}{\beta}\right)$, 故:

$$\begin{aligned} E\hat{\alpha}_L &= E(Y_{(1)} + \alpha) = \frac{\beta}{n} + \alpha \\ E\hat{\beta}_L &= E(\bar{Y} - Y_{(1)}) = \frac{n-1}{n}\beta \end{aligned}$$

所以它们均不是无偏估计. 可构造出下面两个无偏估计,

$$\begin{cases} \tilde{\alpha} = \hat{\alpha}_L - \frac{1}{n-1}\hat{\beta}_L \\ \tilde{\beta} = \frac{n}{n-1}\hat{\beta}_L \end{cases}$$

七、(12 分) 设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 分别为未知参数 θ 的两个无偏估计, 方差有限且大于 0, 假设 $\text{Cov}(\hat{\theta}_1, \hat{\theta}_2) < 0$. 问是否可以基于 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 构造出一个 θ 的无偏估计 $\hat{\theta}_3$, 且满足 $\text{Var}(\hat{\theta}_3) < \text{Var}(\hat{\theta}_1)$?

Solution: 令 $\hat{\theta}_3 = a\hat{\theta}_1 + (1-a)\hat{\theta}_2$, 于是 $E\hat{\theta}_3 = \theta$ 为 θ 的无偏估计, 则 $\text{Var}(a\hat{\theta}_1 + (1-a)\hat{\theta}_2) = a^2 \text{Var}(\hat{\theta}_1) + (1-a)^2 \text{Var}(\hat{\theta}_2) + 2a(1-a) \text{Cov}(\hat{\theta}_1, \hat{\theta}_2)$ 为方便起见, 记

$$c = \text{Cov}(\hat{\theta}_1, \hat{\theta}_2) < 0, \sigma_1^2 = \text{Var}(\hat{\theta}_1), \sigma_2^2 = \text{Var}(\hat{\theta}_2)$$

于是, 令 $H(a) = \text{Var}(a\hat{\theta}_1 + (1-a)\hat{\theta}_2) - \text{Var}(\hat{\theta}_1)$, 即

$$H(a) = (\sigma_1^2 + \sigma_2^2 - 2c)a^2 + 2(c - \sigma_2^2)a + \sigma_2^2 - \sigma_1^2$$

其中二次项系数 $\sigma_1^2 + \sigma_2^2 - 2c = \text{Var}(\hat{\theta}_1 - \hat{\theta}_2) > 0$, 即二次函数 $H(a)$ 的开口向上, 又判别式

$$\Delta = \left[2(c - \sigma_2^2)\right]^2 - 4(\sigma_1^2 + \sigma_2^2 - 2c)(\sigma_2^2 - \sigma_1^2) > 0$$

所以 $H(a)$ 有两个零点, 则我们取其对称轴, 即 $a_0 = \frac{\sigma_2^2 - c}{\sigma_1^2 + \sigma_2^2 - 2c}$, 就必定有 $H(a_0) < 0$, 即 $\text{Var}(a_0\hat{\theta}_1 + (1-a_0)\hat{\theta}_2) < \text{Var}(\hat{\theta}_1)$, 所以取

$$\hat{\theta}_3 = \frac{\sigma_2^2 - c}{\sigma_1^2 + \sigma_2^2 - 2c}\hat{\theta}_1 + \left(1 - \frac{\sigma_2^2 - c}{\sigma_1^2 + \sigma_2^2 - 2c}\right)\hat{\theta}_2$$

就有 $\text{Var}(\hat{\theta}_3) < \text{Var}(\hat{\theta}_1)$.

八、(20 分) 某减肥机构称其疗程可使参加者平均减少体重 5 kg 以上, 为检验广告是否可信, 随机调查了 10 名参加者, 数据 (kg):

参加前	65.39	62.89	63.50	60.83	63.07	62.88	57.80	63.07	66.05	70.78
参加后	61.72	59.43	59.64	57.30	58.50	60.84	51.89	60.02	63.67	65.67

假设参加前后体重均服从正态分布.

(1) 在显著性水平为 0.05 下检验宣传是否可信;

(2) 给出平均减少体重的 95% 的置信区间.

Solution:

(1) 根据题意, 应采取成对数据的假设检验来消除个人差异引起的随机误差. 用随机变量 X_i, Y_i 分别表示第 i 名参与者参加前后的体重, 并设

$$Z_i = X_i - Y_i \sim N(\mu, \sigma^2)$$

考虑假设检验问题, $H_0: \mu \leq 5 \longleftrightarrow H_1: \mu > 5$ 检验统计量为: $T = \frac{\sqrt{n}(\bar{Z}-5)}{s} = \frac{\sqrt{10} \cdot (3.758-5)}{1.184} = -3.317$; 检验的拒绝域是 $W = \{T \geq t_{1-\alpha}(n-1)\} = \{T \geq t_{0.95}(9)\} = \{T \geq 1.833\}$. 则 $T \notin W$, 所以我们不能拒绝原假设, 即宣传不可信.

(2) 取枢轴量 $T = \frac{\sqrt{n}(\bar{Z}-\mu)}{s} \sim t(n-1)$, 由于

$$P\left\{-t_{1-\frac{\alpha}{2}}(n-1) \leq \frac{\bar{Z}-\mu}{s}\sqrt{n} \leq t_{1-\frac{\alpha}{2}}(n-1)\right\} = 1-\alpha$$

反解可得到 μ 的置信区间 $\bar{Z} \pm \frac{s}{\sqrt{n}}t_{1-\frac{\alpha}{2}}(n-1)$, 代入数据可得:

$$\mu \in [2.91, 4.61]$$

九、(22 分) 观察三种药物 A、B、C 治疗 200 例心绞痛的疗效, 数据:

	显著	有效	无效	合计
A	15	37	7	59
B	11	48	13	72
C	16	39	14	69
合计	42	124	34	200

用列联表分析判断这三种药物的疗效有无显著性差异. (检验水平 $\alpha = 0.05$)

Solution:

独立情况下的理论样本数

	显著	有效	无效
A	$59 \cdot 42/200 = 12.39$	$59 \cdot 124/200 = 36.58$	$59 \cdot 34/200 = 10.03$
B	$72 \cdot 42/200 = 15.12$	$72 \cdot 124/200 = 44.64$	$72 \cdot 34/200 = 12.24$
C	$69 \cdot 42/200 = 14.49$	$69 \cdot 124/200 = 42.78$	$69 \cdot 34/200 = 11.73$

考虑假设检验问题 H_0 : 三种药物无显著性差异 v.s. H_1 : 三种药物有显著性差异 检验统计量 $\chi^2 = \sum_{i=1}^3 \sum_{j=1}^3 \frac{n_{ij}-n\hat{p}_i\hat{p}_j}{n\hat{p}_i\hat{p}_j} = 3.82$, 拒绝域为 $W = \{\chi^2 > \chi_{0.95}^2(4) = 9.488\}$, 所以 $\chi^2 \notin W$, 因此我们没有足够理由拒绝原假设, 故可以认为三种药物无显著差异.

中国科学技术大学-432 统计学-2019 年

一、填空题 (每题 5 分, 共 50 分)

1. 有一个信号系统, 输入 0 而输出 1 的可能性为 0.04, 输入 1 而输出 0 的可能性为 0.02; 输入 0 和 1 的概率都是 0.5, 那么输出结果为 0 时, 这个信号是真实的概率是 _____.

Solution: $\frac{48}{49}$ 用事件 A 表示“输入 0”, 用事件 B 表示“输出 0”, 则根据题意有

$$P(\bar{B} | A) = 0.04, P(B | \bar{A}) = 0.02, P(A) = P(\bar{A}) = 0.5$$

所以信号真实的概率为

$$P(A | B) = \frac{P(B | A)P(A)}{P(B | A)P(A) + P(B | \bar{A})P(\bar{A})} = \frac{0.96 \times 0.5}{0.96 \times 0.5 + 0.02 \times 0.5} = \frac{48}{49}$$

1. 若 $f(x) = a/(1+x^2)$ 是密度函数, 则 $a =$ _____.

Solution: $\frac{1}{\pi}$ 根据概率密度函数的正则性有

$$\int_{-\infty}^{+\infty} a \frac{1}{1+x^2} dx = a(\arctan x) \Big|_{-\infty}^{+\infty} = a\pi = 1$$

解得 $a = \frac{1}{\pi}$.

3. 甲乙对弈, 任意一局甲赢的概率是 p , 乙赢的概率是 $1-p$. 若赢一局得一分, 谁先比另一人多得两分谁就是赢家, 则甲赢的概率是 _____.

Solution: $\frac{p^2}{1-2p+2p^2}$ 由于比赛规则要求多赢两分即为获胜, 那么总局数一定为偶数局, 所以可以两局一起考虑: 甲赢两局的概率为 p^2 , 乙赢两局的概率为 $(1-p)^2$, 两局为平局的概率为 $2p(1-p)$ 设甲经过 n 次平局后胜利, 则甲胜的概率为

$$\sum_{n=0}^{+\infty} [2p(1-p)]^n p^2 = p^2 \cdot \frac{1}{1-2p(1-p)} = \frac{p^2}{1-2p+2p^2}$$

4. 一根绳子长 4 米, 剪成两段 X 和 Y , 则 X 和 Y 的相关系数是 _____.

Solution: -1 由题意 $X+Y=4$, 则两者几乎处处存在负的线性关系, 所以两者的相关系数为 -1.

5. 已知泊松分布的参数是 λ , 若 $E(X-1)(X-2)=5$, 则 $\lambda =$ _____.

Solution: 3 已知 $X \sim \mathcal{P}(\lambda)$, 所以 $E(X) = \lambda, EX^2 = \lambda + \lambda^2$. 根据 $E(X^2 - 3X + 2) = 5$, 即 $E(X^2) - 3E(X) + 2 = 5 \Rightarrow \lambda^2 + \lambda - 3\lambda - 3 = 0$, 考虑到 $\lambda > 0$, 解得 $\lambda = 3$.

6. 某个班级有 6 个女生和 10 个男生, 随机组成 8 个小队进行比赛, 每个小队两个人, 记 X 为两个人都是女生的小队个数, 则 $E(X) =$ _____.

Solution: 1 令 $X_i = \begin{cases} 1, & \text{第 } i \text{ 队中两个都是女生,} \\ 0, & \text{否则.} \end{cases}$, 则 $E(X_i) = P(X_i = 1) = \frac{\binom{6}{2}}{\binom{16}{2}} = \frac{1}{8}$, 所以

$$E(X) = \sum_{i=1}^8 E(X_i) = 1$$

7. $X_i (i=1, 2, \dots, 9)$ 服从标准正态分布, 若记 $F(x)$ 为其分布函数, 令 $Z = \max\{F(X_1), F(X_2), \dots, F(X_9)\}$, 则 $EZ =$ _____.

Solution: $\frac{9}{10}$ 正态分布是连续性分布, 于是 $F(X_i) \text{ i.i.d. } \sim U(0, 1)$, 所以

$$Z = \max\{F(X_1), \dots, F(X_9)\} \sim \text{Beta}(9, 1)$$

则 $EZ = \frac{9}{10}$.

8. 一组简单随机样本 X_1, X_2, X_3, X_4 的观测值如下:

$$-2, -1, 0, 2$$

若 $Y = X^3$ 服从正态分布 $N(\mu, 1)$, 则 μ 的 95% 水平置信区间是 _____.

Solution: $[-1.23, 0.73]$ μ 的置信区间是

$$\bar{Y} \pm \frac{s}{\sqrt{n}} u_{\frac{\alpha}{2}} = \bar{Y} \pm \frac{1}{2} u_{\frac{\alpha}{2}} = \frac{1}{4} \pm \frac{1}{2} \cdot 1.96 = [-1.23, 0.73]$$

9. 设 $X_i (i = 1, 2, \dots, n)$ 是来自正态分布 $N(\mu, 25)$ 的简单随机样本, 在 $\alpha = 0.05$ 下, 使得样本落入拒绝域 $P(|\bar{X} - \mu_0| > 2.5)$ 的最小样本容量 n 为 _____.

Solution: 16 令

$$\begin{aligned} P(|\bar{X} - \mu| > 2.5) &= 1 - P\left(-\frac{2.5}{\sqrt{25/n}} \leq \frac{\bar{X} - \mu}{\sqrt{25/n}} \leq \frac{2.5}{\sqrt{25/n}}\right) \\ &= 1 - \Phi\left(\frac{\sqrt{n}}{2}\right) + \Phi\left(-\frac{\sqrt{n}}{2}\right) \leq 0.05 \end{aligned}$$

解得 $n \geq 15.366$, 则最小样本容量为 16.

10. 设 $X_i (i = 1, 2, \dots, 5)$ 是来自同一正态分布的简单随机样本, $Z = \frac{1}{3} \sum_{i=1}^3 X_i, Y = \frac{1}{2} \sum_{i=4}^5 X_i, s^2 = \frac{1}{2} \sum_{i=1}^3 (X_i - Z)^2$, 则 $\frac{\sqrt{2}(Z-Y)}{s}$ 服从的分布是 _____.

Solution: $t(2)$ 根据 Fisher 引理知, $Z \sim N\left(\mu, \frac{\sigma^2}{3}\right), Y \sim N\left(\mu, \frac{\sigma^2}{2}\right), \frac{2s^2}{\sigma^2} \sim \chi^2(2)$, 且它们都是独立的, 于是 $Z - Y \sim N\left(0, \frac{5}{6}\sigma^2\right)$. 进一步, 有 $\frac{\frac{Z-Y}{\sqrt{5/6}\sigma^2}}{\sqrt{2s^2/2\sigma^2}} = \sqrt{\frac{6}{5}} \frac{Z-Y}{s} \sim t(2)$.

二、(20 分) 设随机变量 Y 有概率密度函数 $f(y) = \begin{cases} 2y & 0 < y < 1 \\ 0 & \text{其他} \end{cases}$, X 服从两点分布, $X = 0$ 的概率为

0.5, $X = 2$ 的概率为 0.5, 设 $Z = X + Y$.

(1) $P(Y < EY)$;

(2) Z 的概率密度函数.

Solution: (1) 先计算得 $E(Y) = \int_0^1 2y \cdot y dy = \frac{2}{3}$, 所以

$$P\left(Y < \frac{2}{3}\right) = \int_0^{\frac{2}{3}} 2y dy = \frac{4}{9}$$

(2) 先计算 Z 的分布函数, 根据全概率公式

$$\begin{aligned} P(Z \leq z) &= P(X + Y \leq z) \\ &= P(Y \leq z)P(X = 0) + P(2 + Y \leq z)P(X = 2) \end{aligned}$$

再根据 z 的取值进行分类: (i) $z \leq 0, P(Z \leq z) = 0$; (ii) $0 < z \leq 1, P(Z \leq z) = \frac{1}{2}z^2$; (iii) $1 < z \leq 2, P(Z \leq z) = \frac{1}{2}$; (iv) $2 < z \leq 3, P(Z \leq z) = \frac{1}{2}[1 + (z-2)^2] = \frac{1}{2}z^2 - 2z + \frac{5}{2}$; (v) $z > 3, P(Z \leq z) = 1$. 故 Z 的密度函数是

$$f(z) = \begin{cases} z, & 0 < z \leq 1, \\ z-2, & 2 < z \leq 3. \end{cases}$$

三、(20 分) $X_i (i = 1, 2, \dots, n)$ 是来自均匀分布 $U(0, \theta)$ 总体的简单随机样本, 有以下几个估计量 $\hat{\theta}_1 = A_n \bar{x}, \hat{\theta}_2 = B_n x_{(1)}, \hat{\theta}_3 = C_n x_{(n)}$.

(1) 若上述三个估计量都是 θ 的无偏估计, 试求 A_n, B_n, C_n ;

(2) 在 (1) 的条件下, 哪个估计量最有效.

Solution: (1) 作总体变换, 令 $Y_i = \frac{X_i}{\theta} \sim U(0, 1)$ 则有 $Y_{(i)} \sim \text{Beta}(i, n-i+1)$. 由于三个估计量都是 θ 的无偏估计, 则 $E(A_n \bar{X}) = A_n \cdot \frac{\theta}{2} = \theta \Rightarrow A_n = 2$ $E(B_n X_{(1)}) = B_n E(\theta Y_{(1)}) = B_n \cdot \frac{1}{n+1} \theta = \theta \Rightarrow B_n = n+1$ $E(C_n X_{(n)}) = C_n E(\theta Y_{(n)}) = C_n \cdot \frac{n}{n+1} \theta = \theta \Rightarrow C_n = \frac{n+1}{n}$

$$(2) \text{Var}(\hat{\theta}_1) = \text{Var}(2\bar{X}) = 4 \text{Var}(\bar{X}) = 4 \cdot \frac{\text{Var}(X)}{n} = 4 \cdot \frac{1}{n} \cdot \frac{\theta^2}{12} = \frac{\theta^2}{3n}$$

$$\text{Var}(\hat{\theta}_2) = (n+1)^2 \text{Var}(X_{(1)}) = (n+1)^2 \cdot \theta^2 \cdot \frac{n}{(n+1)^2(n+2)} = \frac{n}{n+2} \theta^2$$

$\text{Var}(\hat{\theta}_3) = \left(\frac{n+1}{n}\right)^2 \text{Var}(X_{(n)}) = \frac{(n+1)^2}{n^2} \cdot \theta^2 \cdot \frac{n}{(n+1)^2(n+2)} = \frac{1}{n(n+2)} \theta^2$ 由 $\text{Var}(\hat{\theta}_2) \geq \text{Var}(\hat{\theta}_1) \geq \text{Var}(\hat{\theta}_3)$ 知, $\hat{\theta}_3$ 最有效.

由 $\text{Var}(\hat{\theta}_2) \geq \text{Var}(\hat{\theta}_1) \geq \text{Var}(\hat{\theta}_3)$ 知, $\hat{\theta}_3$ 最有效.

四、(20 分) 秋名山车队测试了 7 辆 AE86 过弯时的速度, X 为普通漂移过弯时的速度, Y 为采用排水渠过弯的速度, 考虑到车性能的差异和车手水平以及测量误差等因素, 我们可以假设 $X_i \sim N(\mu_1, \sigma^2)$, $Y_i \sim N(\mu_2, \sigma^2)$, 其中参数均未知, 并且诸 X_i, Y_i 独立.

车辆号	1	2	3	4	5	6	7
X	15.3	20.1	18.5	21.3	17.8	19.6	16.3
Y	17.2	19.2	20.0	20.8	19.1	20.4	17.7

(1) 尝试建立成对数据的假设检验, 并判断采用排水渠过弯是否可以显著增加车速 (选取显著性水平 $\alpha = 0.05$);

(2) 令 $d_i = \mathbf{I}_{\{Y_i > X_i\}}$, 证明 d_i 服从伯努利分布, 若假设其参数为 p , 考虑假设检验问题:

$$H_0: p = 0.5 \quad \text{vs} \quad H_1: p > 0.5$$

给出该检验的拒绝域, 并判断采用排水渠过弯是否可以显著增加车速 (选取显著性水平 $\alpha = 0.05$).

Solution: (1) 记 $Z_i = Y_i - X_i \sim N(\mu, 2\sigma^2)$, 考虑假设检验问题 $H_0: \mu = 0 \longleftrightarrow H_1: \mu > 0$ 检验统计量是 $T = \frac{\bar{Z} - \mu_0}{s/\sqrt{n}} = \frac{0.786 - 0}{\frac{1.071}{\sqrt{7}}} = 5.14$, 检验的拒绝域为 $W = \{T \geq t_{\alpha}(6)\} = \{T \geq t_{0.05}(6)\} = \{T \geq 1.943\}$. 所以 $T \in W$, 应拒绝原假设, 即可以认为使用排水渠过弯可以增加速度.

(2)

$$d_i = \mathbf{I}_{\{Y_i > X_i\}} = \begin{cases} 1, & Y_i > X_i, \\ 0, & Y_i \leq X_i. \end{cases} \text{ 所以 } d_i \sim b(1, P(X_i < Y_i)), \text{ 该检验的拒绝域是}$$

$$W = \left\{ \sum_{i=1}^7 d_i \geq c \right\}$$

这里 $c = \inf \left\{ k : P\left(\sum_{i=1}^7 d_i \geq k\right) \leq 0.05 \mid d_i \sim b\left(1, \frac{1}{2}\right) \right\}$. 计算此时的 p 值

$$p = P\left(\sum_{i=1}^7 d_i \geq 5 \mid d_i \sim b\left(1, \frac{1}{2}\right)\right) = \sum_{i=5}^7 C_7^i \left(\frac{1}{2}\right)^7 = 0.227 > 0.05$$

所以我们无法拒绝原假设, 即认为排水渠过弯不能显著增加车速.

五、(20 分) 以下是甲乙工厂生产的同一零件的数据, 其中零件质量分为差, 一般, 好三个等级.

	差	一般	好
甲	56	40	14
乙	42	40	18

- (1) 试给出甲乙两个工厂生产该零件的废品率的极大似然估计;
 (2) 在 0.05 的显著性水平下, 判断甲乙两个工厂的生产水平是否一致.

Solution: (1) 用 n_1, n_2, n_3 分别表示设甲工厂生产的零件中质量为差、一般、好的个数, 则样本的似然函数以及对数似然函数为

$$L(p) = p_1^{n_1} p_2^{n_2} p_3^{n_3}$$

$$\ln L(p) = n_1 \ln p_1 + n_2 \ln p_2 + n_3 \ln p_3$$

其中, p_1, p_2, p_3 分别表示甲工厂生产出差、一般、好的零件的比率; 于是注意到 $p_1 + p_2 + p_3 = 1$, 则该模型中可变参数仅仅为 2 个, 令

$$\begin{cases} \frac{\partial \ln L}{\partial p_1} = \frac{n_1}{p_1} - \frac{n_3}{1-p_2-p_1} = 0 \\ \frac{\partial \ln L}{\partial p_2} = \frac{n_2}{p_2} - \frac{n_3}{1-p_2-p_1} = 0 \end{cases}$$

$$\text{解得 } \begin{cases} \hat{p}_1 = \frac{n_1}{n_1+n_2+n_3} = \frac{28}{55} \\ \hat{p}_2 = \frac{n_2}{n_1+n_2+n_3} = \frac{4}{11} \end{cases}, \text{ 而 } \hat{p}_3 = 1 - \hat{p}_1 - \hat{p}_2 = \frac{7}{55}.$$

同理对于乙工厂, 用 q_1, q_2, q_3 分别表示甲工厂生产出差、一般、好的零件的比率, 可以解得极大似然估计, $\hat{q}_1 = 0.42, \hat{q}_2 = 0.4, \hat{q}_3 = 0.18$.

(2) 考虑假设检验问题 H_0 : 甲、乙两工厂产品质量一致这其实意味着: 产品质量与加工工厂是独立的. 对应的检验统计量 $\chi^2 = n \left(\sum_{i=1}^2 \sum_{j=1}^3 \frac{n_{ij}^2}{n_{i \cdot} n_{\cdot j}} - 1 \right) = 2.028$, 检验的拒绝域是

$$W = \left\{ \chi^2 \geq \chi_{\alpha}^2((r-1)(s-1)) \right\} = \left\{ \chi^2 \geq \chi_{0.05}^2(2) \right\} = \left\{ \chi^2 \geq 5.991 \right\}$$

因此 $\chi^2 \notin W$, 故没有充分理由拒绝原假设, 可以认为甲、乙两工厂产品质量一致.

六、(20 分) 考虑一元线性回归模型 $Y_i = \alpha + \beta x_i + \varepsilon_i, i = 1, \dots$, 其中 $E\varepsilon_i = 0, Var(\varepsilon_i) = \sigma^2, Cov(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$, 采集到的数据如下表:

	1	2	3	4	5	6	7
X	17.1	10.5	13.8	15.7	11.9	10.4	15.0
Y	16.7	10.4	13.5	15.7	11.6	10.2	14.5

- (1) 试求 α 以及 β 的最小二乘估计, 并给出 σ^2 的估计;
 (2) 若 $x_0 = 15.3$, 在显著性水平 $\alpha = 0.05$ 下求 Y_0 的区间估计.

Solution:

(1) α, β 的最小二乘估计是

$$\begin{cases} \hat{\alpha} = \bar{y} - \bar{x}\hat{\beta} \\ \hat{\beta} = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{cases}$$

$\hat{\sigma}^2$ 的无偏估计是 $\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-2} = \frac{\sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta}x_i)^2}{n-2}$. 代入数据计算 $\hat{\alpha} = 0.0385, \hat{\beta} = 0.9781, \hat{\sigma}^2 = 0.0315$.

(2) 由于 $\hat{y}_0 - y_0 \sim N\left(0, \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}\right) \sigma^2\right)$, 选取

$$T = \frac{\hat{y}_0 - E(y_0)}{\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}} \sim t(n-2)$$

作为枢轴量, 则可解得 y_0 的置信区间为 $[\hat{y}_0 - \delta_0, \hat{y}_0 + \delta_0]$, 其中

$$\begin{aligned}\delta_0 &= t_{\frac{\alpha}{2}}(n-2)\hat{\sigma}\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} \\ &= 2.5706 \cdot \sqrt{0.0315} \cdot \sqrt{1 + \frac{1}{7} + \frac{3.255^2}{289.16}} = 0.495 \\ \hat{y}_0 &= \hat{\alpha} + \hat{\beta}x_0 = 0.0385 + 0.9781 \cdot 15.3 = 15.0034\end{aligned}$$

故 y_0 的 0.95 水平的置信区间为 $[15.0034 \pm 0.329] = [14.6744, 15.3324]$.

中国科学技术大学-432 统计学-2020 年

一、(20 分) 有甲乙两个工厂一起生产某产品, 甲生产占 40%, 乙生产占 60%, 若甲生产次品率为 1%, 乙生产次品率为 2%, 现从生产物品中取出一件为次品, 问该物品为甲工厂生产的概率?

Solution: 记事件 $A =$ “取甲生产物品”, $B =$ “取物品为次品”, 则

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{0.4 \times 0.01}{0.4 \times 0.01 + 0.6 \times 0.02} = 0.25.$$

二、(15 分) $X_1, \dots, X_n$ 为独立同分布的正值随机变量, 求 $E\left[\frac{X_i}{X_1+X_2+\dots+X_n}\right]$.

Solution: 由于 $X_1, X_2, \dots, X_n$ 独立同分布, 故有: $\frac{X_i}{X_1+X_2+\dots+X_n} (i=1, 2, \dots, n)$ 同分布, 于是 $1 = E\left(\frac{X_1+X_2+\dots+X_n}{X_1+X_2+\dots+X_n}\right) = \sum_{i=1}^n E\left(\frac{X_i}{X_1+X_2+\dots+X_n}\right)$, 所以有 $E\left(\frac{X_i}{X_1+X_2+\dots+X_n}\right) = \frac{1}{n}$.

三、(20 分) 有来自总体 $f(x) = \frac{1}{\theta} e^{-\frac{x-\theta}{\theta}} I_{\{x>\theta\}}$ 的随机样本 $X_1, \dots, X_n$, 请分别用 $\bar{X}$ 与 $X_{(1)}$ 构造 θ 的 $1-\alpha$ 置信区间, 并比较哪个更优?

Solution: 作总体变换, 令 $Y_i = X_i - \theta \sim \text{Exp}\left(\frac{1}{\theta}\right)$, 则 $Y_1, \dots, Y_n$ 是来自均值为 θ 的指数分布的样本, 故有结论 $Y_{(1)} \sim \text{Exp}\left(\frac{n}{\theta}\right)$, $n\bar{Y} \sim \text{Ga}\left(n, \frac{1}{\theta}\right)$, 可以将其变为卡方分布, 即有

$$\frac{2n}{\theta} Y_{(1)} \sim \chi^2(2), \quad \frac{2n}{\theta} \bar{Y} \sim \chi^2(2n),$$

因此 $T_1 = \frac{2n}{\theta} (X_{(1)} - \theta) \sim \chi^2(2)$ 和 $T_2 = \frac{2n}{\theta} (\bar{X} - \theta) \sim \chi^2(2n)$ 是枢轴量. 基于这两个枢轴量可以导出等尾置信区间, 即

$$\text{区间一: } \left[\frac{X_{(1)}}{1 + \frac{\chi_{1-\alpha/2}^2(2)}{2n}}, \frac{X_{(1)}}{1 + \frac{\chi_{\alpha/2}^2(2)}{2n}} \right] \quad \text{区间二: } \left[\frac{\bar{X}}{1 + \frac{\chi_{1-\alpha/2}^2(2n)}{2n}}, \frac{\bar{X}}{1 + \frac{\chi_{\alpha/2}^2(2n)}{2n}} \right]$$

关于优良性, 我们认为区间一更精确, 因为可以比较区间长度, 区间一的长度是 $C_1 = \frac{(\chi_{1-\alpha/2}^2(2) - \chi_{\alpha/2}^2(2))/2n}{\left(1 + \frac{\chi_{1-\alpha/2}^2(2)}{2n}\right) \left(1 + \frac{\chi_{\alpha/2}^2(2)}{2n}\right)} X_{(1)}$,

由于 $\chi_{1-\alpha/2}^2(2), \chi_{\alpha/2}^2(2)$ 都是常数, 故其分母趋于 1, 而分子趋于 0, 且与 $\frac{1}{n}$ 同阶. 区间二长度是 $C_2 = \frac{(\chi_{1-\alpha/2}^2(2n) - \chi_{\alpha/2}^2(2n))/2n}{\left(1 + \frac{\chi_{1-\alpha/2}^2(2n)}{2n}\right) \left(1 + \frac{\chi_{\alpha/2}^2(2n)}{2n}\right)} \bar{X}$, 由于在这里分子分母中的分位数 $\chi_{1-\alpha/2}^2(2n), \chi_{\alpha/2}^2(2n)$ 随 n 而动, 故需要进一步探讨, 先考虑分母, 根据 $\chi_{\alpha/2}^2(2n)$ 的定义, 有

$$P\left(Y \leq \chi_{\alpha/2}^2(2n)\right) = \alpha/2 \quad \text{即} \quad P\left(\frac{Y-2n}{2\sqrt{n}} \leq \sqrt{n} \frac{\chi_{\alpha/2}^2(2n) - 2n}{2n}\right) = \alpha/2$$

其中 $Y \sim \chi^2(2n)$, 根据中心极限定理, 有 $\frac{Y-2n}{2\sqrt{n}} \xrightarrow{d} N(0, 1)$, 故由上式可看出

$$\sqrt{n} \frac{\chi_{\alpha/2}^2(2n) - 2n}{2n} \rightarrow z_{\alpha/2}$$

故有 $\frac{\chi_{\alpha/2}^2(2n) - 2n}{2n} \rightarrow 0$, 因此 $\frac{\chi_{\alpha/2}^2(2n)}{2n} \rightarrow 1$, 同理 $\frac{\chi_{1-\alpha/2}^2(2n)}{2n} \rightarrow 1$, 故有 C_2 的分母收敛于常数 4. 再考虑分子, 由于

$$P\left(\chi_{\alpha/2}^2(2n) \leq Y \leq \chi_{1-\alpha/2}^2(2n)\right) = 1 - \alpha$$

即 $P\left(\frac{\chi_{\alpha/2}^2(2n) - 2n}{\sqrt{2n}} \leq \frac{Y - 2n}{\sqrt{2n}} \leq \frac{\chi_{1-\alpha/2}^2(2n) - 2n}{\sqrt{2n}}\right) = 1 - \alpha$, 再次根据中心极限定理, 我们得知 $\frac{\chi_{1-\alpha/2}^2(2n) - \chi_{\alpha/2}^2(2n)}{\sqrt{2n}}$ 是收敛于正常数的, 故对 C_2 而言, 其分子与 $\frac{1}{\sqrt{n}}$ 同阶, 比 C_1 更慢收敛于 0, 再考虑到 $X_{(1)} \leq \bar{X}$, 故当 n 足够大时, 区间一更短.

注: 科大学硕 812 在 2019 年也考察了此题, 在那里我讨论了最短置信区间, 感兴趣可以查看.

四、(20 分) 已知 X 有密度函数

$$f(x) = \begin{cases} -\theta^x \ln \theta, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

其中 $\theta \in (0, 1)$, $X_1, \dots, X_n$ 是来自 X 的随机样本, 试求

(1) θ 的最大似然估计;

(2) $\frac{1}{\ln \theta}$ 的最大似然估计.

Solution: 作参数变换, 令 $\lambda = -\ln \theta > 0$, 则有 X 的密度函数是 $f(x) = \lambda e^{-\lambda x}, x > 0$, 这是参数为 λ 的指数分布, 其 MLE 是 $\hat{\lambda} = \frac{1}{\bar{X}}$, 由 MLE 的不变性, 立即得

$$\hat{\theta} = e^{-\hat{\lambda}} = e^{-\frac{1}{\bar{X}}}, \frac{\hat{1}}{\ln \theta} = -\frac{1}{\hat{\lambda}} = -\bar{X}.$$

五、(15 分) 已知 $X_1, \dots, X_n$ 是来自于指数分布 $f(x) = \frac{1}{\theta} e^{-\frac{x}{\theta}} I_{\{x>0\}}$ 的随机样本, 试求

(1) $X_{(1)}$ 和 $X_{(n)}$ 的密度函数;

(2) $T = \frac{2(X_{(1)} + (n-1)X_{(2)})}{\theta}$ 的密度函数.

Solution: (1) 由次序统计量分布结论, 有

$$f_{X_{(j)}}(x) = \frac{n}{\theta} \exp\left\{-\frac{nx}{\theta}\right\}, \quad x > 0$$
$$f_{X_{(j)}}(x) = \frac{n}{\theta} \exp\left\{-\frac{x}{\theta}\right\} \left\{1 - \exp\left(-\frac{x}{\theta}\right)\right\}^{n-1}, \quad x > 0.$$

(2) 作总体变换, 令 $Y_i = \frac{X_i}{\theta} \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(1)$, 由次序统计量分布结论, 有 $(Y_{(1)}, Y_{(2)})$ 的联合密度是

$$f_{Y_{(1)}, Y_{(2)}}(y_{(1)}, y_{(2)}) = n(n-1) \exp\{-(n-1)y_{(2)} - y_{(1)}\}, \quad y_{(1)} < y_{(2)},$$

作变量变换,

$$\begin{cases} T = 2Y_{(1)} + 2(n-1)Y_{(2)}, \\ U = 2Y_{(1)} - 2(n-1)Y_{(2)}, \end{cases} \Rightarrow \begin{cases} Y_{(1)} = (U+T)/4 \\ Y_{(2)} = (T-U)/(4n-4), \end{cases}$$

对应的雅可比行列式为

$$J = \begin{vmatrix} \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4(n-1)} & -\frac{1}{4(n-1)} \end{vmatrix} = -\frac{1}{8(n-1)}$$

故有

$$f_{T,U}(t,u) = \frac{1}{8(n-1)} f_{Y_{(1)}, Y_{(2)}}\left(\frac{t-u}{4n-4}, \frac{t+u}{4}\right) = \frac{n}{8} e^{-\frac{t}{2}}$$

其中 $t > 0, -t < u < \frac{2-n}{n}t$, 积掉 u , 有

$$f_T(t) = \int_{-t}^{\frac{2-n}{n}t} \frac{1}{8} n \exp\left\{-\frac{t}{2}\right\} du = \frac{1}{4} t e^{-\frac{t}{2}}, \quad t > 0.$$

六、(20 分) 设 $X_1, \dots, X_n$ 是来自 $N(\mu_1, \sigma_1^2)$ 的随机样本, $Y_1, \dots, Y_n$ 是来自 $N(\mu_2, \sigma_2^2)$ 的随机样本.

(1) 对于假设检验问题 $H_0: \sigma_1^2 = \sigma_2^2$, 试给出检验全过程 (备择假设是其对立);

(2) 如果 $\sigma_1^2 = \sigma_2^2$, 对于假设检验问题 $H_0: \mu_1 < \mu_2$, 试给出检验全过程 (备择假设是其对立).

Solution: (1) 由于样本方差 S_1^2, S_2^2 满足

$$\frac{(n-1)S_1^2}{\sigma_1^2} \sim \chi^2(n-1), \quad \frac{(n-1)S_2^2}{\sigma_2^2} \sim \chi^2(n-1),$$

且它们相互独立, 故在原假设成立的情况下有 $F = \frac{S_1^2}{S_2^2} \sim F(n-1, n-1)$, 显然如果统计量 F 过大或过小我们都会拒绝原假设, 为满足其水平为 α , 因此拒绝域为

$$W = \left\{ F < F_{\frac{\alpha}{2}}(n-1, n-1) \right\} \cup \left\{ F > F_{1-\frac{\alpha}{2}}(n-1, n-1) \right\}.$$

(2) 当原假设成真时, 有 $T = \frac{\bar{X} - \bar{Y}}{S_w \sqrt{\frac{2}{n}}} \sim t(2n-2)$, 显然当统计量 T 过大我们会拒绝原假设, 为满足其水平为 α , 因此拒绝域为 $W = \{T > t_{1-\alpha/2}(2n-2)\}$. 注意其中 $S_w^2 = \frac{(n-1)S_1^2 + (n-1)S_2^2}{2n-2}$.

七、(20 分) 叙述 2×2 的列联表独立性检验原理.

Solution: 假设有两个离散分布总体 X, Y , 分别有 m, n 种取值, 根据样本得到的信息: 事件 $(X = x_i, Y = y_j)$ 被观测到的次数是 N_{ij} 次, $i = 1, 2, \dots, m, j = 1, 2, \dots, n$. 根据样本信息来判断 X, Y 是否独立. 其被称为列联表的原因就是该问题可以被写成一个类似二元离散分布的列联表.

我们知道, 如果 X, Y 独立, 那么应该可以在样本中观察到 $\frac{N_{ij}}{N} = \frac{N_{i\cdot}}{N} \cdot \frac{N_{\cdot j}}{N}$ 对所有 i, j 都近似成立, 也就是在直观上讲如果 $\sum_{i=1}^m \sum_{j=1}^n (N_{ij} - N_{i\cdot} \cdot N_{\cdot j} / N)^2$ 越小, 我们就认为越有可能是独立的. 但实际上, 每个事件的偏离程度是不一样的, 也就是 $N_{i\cdot} \cdot N_{\cdot j}$ 的量级越大, 则它本身发生偏差的可能性就越大, 故我们要标准化每个事件的偏离程度, 即用 $\frac{1}{N_{i\cdot} \cdot N_{\cdot j}}$ 作为每个事件的权重, 如果 $\sum_{i=1}^m \sum_{j=1}^n \frac{(N_{ij} - N_{i\cdot} \cdot N_{\cdot j} / N)^2}{N_{i\cdot} \cdot N_{\cdot j}}$ 越小, 我们就认为越有可能是独立的. 恰好, 统计量 $\sum_{i=1}^m \sum_{j=1}^n \frac{(N_{ij} - N_{i\cdot} \cdot N_{\cdot j} / N)^2}{N_{i\cdot} \cdot N_{\cdot j}}$ 近似服从 $\chi^2((m-1)(n-1))$ (可以自己思考一下自由度的问题, 课程和书本都有), 这就给了我们一个很好的用来检验独立性的统计量. 这就是 $m \times n$ 的列联表独立性检验的方法.

八、(20 分) 已知连续型随机变量 $X_1, \dots, X_m, Y_1, \dots, Y_n$ 独立同分布, 令 $\varphi(t) = I_{(t>0)}$, 记 $T = \sum_{i=1}^m \sum_{j=1}^n \varphi(x_i - y_j)$, 试求

(1) ET ;

(2) $Var(T)$.

Solution:

(1) 记 $T_{ij} = \varphi(X_i - Y_j) \sim B(1, \frac{1}{2})$, 其中参数 $\frac{1}{2}$ 由对称性得来. 故有

$$E(T) = E\left(\sum_{i=1}^m \sum_{j=1}^n T_{ij}\right) = \sum_{i=1}^m \sum_{j=1}^n E(T_{ij}) = \frac{mn}{2}.$$

(2) 记 $S_i = \sum_{j=1}^n T_{ij}$, 考虑

$$Var(T) = Var\left(\sum_{i=1}^m S_i\right) = m Var(S_1) + m(m-1) Cov(S_1, S_2),$$

其中 $Var(S_1) = Var\left(\sum_{j=1}^n T_{1j}\right) = n Var(T_{11}) + n(n-1) Cov(T_{11}, T_{12})$, 而由对称性, X_1 在组合 (X_1, Y_1, Y_2) 中居最大的概率是 $\frac{1}{3}$, 故有

$$Cov(T_{11}, T_{12}) = E(T_{11}T_{12}) - \frac{1}{4} = P(X_1 > Y_1, X_1 > Y_2) - \frac{1}{4} = \frac{1}{12},$$

因此 $Var(S_1) = \frac{n}{4} + \frac{n(n-1)}{12}$. 再考虑 $Cov(S_1, S_2)$, 有

$$\begin{aligned} Cov(S_1, S_2) &= Cov\left(\sum_{j=1}^n T_{1j}, \sum_{j=1}^n T_{2j}\right) = \sum_{j=1}^n Cov(T_{1j}, T_{2j}) \\ &= nCov(T_{11}, T_{21}) = \frac{n}{12}, \end{aligned}$$

故 $\text{Var}(T) = \frac{mn}{4} + \frac{mn(n-1)}{12} + \frac{mn(m-1)}{12} = \frac{mn(m+n+1)}{12}$

中国科学技术大学-432 统计学-2021 年

一、(15 分) 甲、乙两人掷骰子, 甲先掷, 如果扔到 1 则把骰子给乙, 否则自己继续, 同样乙也扔到 1 就给甲, 问第 n 次是甲投掷的概率.

Solution: 用事件 A_i 表示第 i 次是甲投掷, 则已知 $P(A_1) = 1$ 以及 $P(A_2) = \frac{5}{6}$. 根据全概率公式, 有

$$\begin{aligned} P(A_n) &= P(A_n | A_{n-1}) P(A_{n-1}) + P(A_n | \overline{A_{n-1}}) P(\overline{A_{n-1}}) \\ &= \frac{5}{6} P(A_{n-1}) + \frac{1}{6} (1 - P(A_{n-1})) \\ &= \frac{2}{3} P(A_{n-1}) + \frac{1}{6} \end{aligned}$$

解此差分方程得 $P(A_n) = (\frac{2}{3})^{n-1} \cdot \frac{1}{2} + \frac{1}{2}$.

二、(15 分) 已知 $X \sim U(0, 1)$, $Y \sim U(\beta, 1)$, $Z_1 \sim U(0, \beta)$, $Z_2 \sim U(0, \beta)$ 且它们相互独立, 记 $V_i = I_{\{X \leq \beta\}} Z_i + I_{\{X > \beta\}} Y$, $i = 1, 2$.

(1) 证明 $V_i \sim U(0, 1)$, $i = 1, 2$;

(2) 求 $\text{Corr}(V_1, V_2)$.

Solution: (1) 已知 $V_1 = I_{\{X \leq \beta\}} Z_1 + I_{\{X > \beta\}} Y$, 且 X, Y, Z_1, Z_2 相互独立, 则

$$\begin{aligned} P(V_1 \leq v) &= P(V_1 \leq v, X \leq \beta) + P(V_1 \leq v, X > \beta) \\ &= P(Z_1 \leq v) P(X \leq \beta) + P(Y \leq v) P(X > \beta) \end{aligned}$$

若 (i) $0 < v \leq \beta$, $P(V_1 \leq v) = \frac{v}{\beta} \cdot \beta + 0 = v$; (ii) $\beta < v \leq 1$, $P(V_1 \leq v) = \beta + (1 - \beta) \cdot \frac{v - \beta}{1 - \beta} = v$; (iii)

$v > 1$, $P(V_1 \leq v) = 1$. 则 $F_{V_1}(v) = \begin{cases} 0, & v \leq 0 \\ v, & 0 < v \leq 1 \\ 1, & v > 1 \end{cases}$ 即 $V_1 \sim U(0, 1)$, 同理 $V_2 \sim U(0, 1)$.

(2) $E(V_1) = E(V_2) = \frac{1}{2}$, $\text{Var}(V_1) = \text{Var}(V_2) = \frac{1}{12}$. 根据重期望公式,

$$\begin{aligned} E(V_1 V_2) &= E(E(V_1 V_2 | X)) \\ &= E(V_1 V_2 | X > \beta) P(X > \beta) + E(V_1 V_2 | X \leq \beta) P(X \leq \beta) \\ &= E(Y^2) (1 - \beta) + E(Z_1 Z_2) \beta \\ &= \left[\left(\frac{1 + \beta}{2} \right)^2 + \frac{(1 - \beta)^2}{12} \right] (1 - \beta) + \left(\frac{\beta}{2} \right)^2 \beta \\ &= \frac{4 - \beta^3}{12} \\ \text{Corr}(V_1, V_2) &= \frac{\text{Cov}(V_1, V_2)}{\sqrt{\text{Var}(V_1)} \cdot \sqrt{\text{Var}(V_2)}} = \frac{E(V_1 V_2) - E(V_1) E(V_2)}{1/12} \\ &= 1 - \beta^3 \end{aligned}$$

三、(15 分) 有线性模型 $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, 其中 ε_i 独立同服从 $N(0, \sigma^2)$, 考虑 $\beta_0, \beta_1, \sigma^2$ 的最小二乘估计, 回答下述问题:

(1) 所有自变量 X_i 都增加 2, 最小二乘估计将会怎么变化?

(2) 所有自变量 X_i 都乘 2, 最小二乘估计将会怎么变化?

Solution:

(1) (β_0, β_1) 的最小二乘估计是

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \hat{\beta}_1 \\ \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{cases}$$

当 x_i 增加 2, 可以发现 $\hat{\beta}_1$ 不改变; 而 $\hat{\beta}_0^* = \bar{y} - (\bar{x} + 2)\hat{\beta}_1 = \hat{\beta}_0 - 2\hat{\beta}_1$.

(2) 当 x_i 变为原来的 2 倍时, 则

$$\hat{\beta}_1^* = \frac{\sum_{i=1}^n (2x_i - 2\bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (2x_i - 2\bar{x})^2} = \frac{1}{2}\hat{\beta}_1$$

而 $\hat{\beta}_0^* = \bar{y} - (2\bar{x})\hat{\beta}_1^* = \bar{y} - \bar{x}\hat{\beta}_1 = \hat{\beta}_0$.

四、(15 分) 已知 $X, Y \sim N(0, \sigma^2)$ 且相互独立, 令 $\theta = \arcsin \frac{X}{\sqrt{X^2 + Y^2}}$, 试

(1) 求 θ 的概率密度函数;

(2) 判断 θ 与 $X^2 + Y^2$ 是否独立.

Solution: [提示] 该题需要注意反正切函数的值域.

$$(1) \text{ 作变换 } \begin{cases} r = \sqrt{X^2 + Y^2} \\ \theta = \arcsin\left(\frac{X}{\sqrt{X^2 + Y^2}}\right) \end{cases} \iff \begin{cases} X = r \sin \theta \\ Y = r \cos \theta \end{cases} \text{ 或 } \begin{cases} X = r \sin \theta \\ Y = -r \cos \theta \end{cases}, \text{ 其中 } r > 0, -\frac{\pi}{2} < \theta < \frac{\pi}{2}.$$

两种情况的雅各比行列式均为 $J = r$.

(X, Y) 的联合密度函数是 $f_{X,Y}(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}, -\infty < x, y < +\infty$, 因此根据公式法 (R, θ) 的联合密度是

$$\begin{aligned} f_{R,\theta}(r, \theta) &= r f_{X,Y}(r \sin \theta, r \cos \theta) + r f_{X,Y}(-r \sin \theta, -r \cos \theta) \\ &= \frac{1}{\pi\sigma^2} e^{-\frac{r^2}{2\sigma^2}} r, r > 0, -\frac{\pi}{2} < \theta < \frac{\pi}{2}. \end{aligned}$$

对 r 积分, 得到 θ 的边缘密度函数

$$f_{\theta}(\theta) = \int_0^{+\infty} f_{R,\theta}(r, \theta) dr = \frac{1}{\pi}, -\frac{\pi}{2} < \theta < \frac{\pi}{2}.$$

(2) 由于 $f_{R,\theta}(r, \theta) = f_R(r)f_{\theta}(\theta)$, 所以 R, θ 相互独立, 因此有 R^2, θ 相互独立, 即 $X^2 + Y^2$ 与 θ 相互独立.

五、(15 分) 某电子元件的寿命服从期望为 λ 的指数分布, 从这批原件中抽取 n 件作寿命试验, 规定到第 r ($0 < r \leq n$) 个电子元件失效时就停止试验, 这样获取了前 r 个次序统计量 $X_{(1)}, \dots, X_{(r)}$, 求

(1) λ 的最大似然估计 $\hat{\lambda}$;

(2) 若 $r = 2$, 判断 $\hat{\lambda}$ 是否为 λ 的无偏估计.

Solution: (1) 对应事件是 $\{X_{(1)} = t_1, X_{(2)} = t_2, \dots, X_{(r)} = t_r\}$, 因此似然函数可写为

$$L(\lambda) = f_{1,\dots,r}(t_1, \dots, t_r | \lambda)$$

其中 $f_{1,\dots,r}(t_1, \dots, t_r | \lambda)$ 是 $(X_{(1)}, \dots, X_{(r)})$ 的联合密度函数, 它是

$$\begin{aligned} f_{1,\dots,r}(t_1, \dots, t_r | \lambda) &= \frac{n!}{(n-r)!} \frac{1}{\lambda^r} e^{-\frac{\sum_{i=1}^r t_i}{\lambda}} \left(e^{-\frac{t_r}{\lambda}}\right)^{n-r}, 0 < t_1 < \dots < t_r \\ &= \frac{n!}{(n-r)!} \frac{1}{\lambda^r} e^{-\frac{1}{\lambda}(\sum_{i=1}^r t_i + (n-r)t_r)}, 0 < t_1 < \dots < t_r \end{aligned}$$

则 $\ln L(\lambda) = \ln\left(\frac{n!}{(n-r)!}\right) - r \ln \lambda - \frac{1}{\lambda}(\sum_{i=1}^r t_i + (n-r)t_r)$, 令

$$\frac{d \ln L(\lambda)}{d \lambda} = -\frac{r}{\lambda} + \frac{\sum_{i=1}^r t_i + (n-r)t_r}{\lambda^2} = 0$$

解得 λ 的极大似然估计是 $\hat{\lambda} = \frac{\sum_{i=1}^r X_{(i)} + (n-r)X_{(r)}}{r}$.

(2) 当 $r = 2$ 时, $\hat{\lambda} = \frac{X_{(1)} + (n-1)X_{(2)}}{2}$, 而

$$nX_{(1)} \sim \text{Exp}\left(\frac{1}{\lambda}\right), (n-1)(X_{(2)} - X_{(1)}) \sim \text{Exp}\left(\frac{1}{\lambda}\right)$$

所以 $EX_{(1)} = \frac{\lambda}{n}, E[(n-1)X_{(2)}] = \lambda + \frac{n-1}{n}\lambda$, 则

$$E\hat{\lambda} = \frac{EX_{(1)} + E[(n-1)X_{(2)}]}{2} = \lambda$$

故 $\hat{\lambda}$ 是 λ 的无偏估计.

六、(15 分) 甲化肥是某化肥厂研制的畅销款, 现该化肥厂研制出改进品种乙化肥, 为探究乙化肥的效果是否好于甲化肥, 你的小组被委任展开对比实验, 第一组选取 13 块稻田, 施用甲化肥, 其亩产平均值为 12.3, 样本方差为 10; 第二组选取 11 块稻田, 施用乙化肥, 其亩产平均为 14.4, 样本方差为 7.8. 假设亩产服从正态分布. 在显著性水平选择 $\alpha = 0.1$ 的情况下, 问:

- (1) 是否能够认为两组的方差相等?
- (2) 是否能够认为乙化肥的均值高于甲化肥?

Solution:

(1) 用随机变量 $X_1, \dots, X_{13}$ 表示施用甲化肥稻田的亩产, 用随机变量 $Y_1, \dots, Y_{11}$ 表示施用乙化肥稻田的亩产. 假设 $X_i \text{ i.i.d. } \sim N(\mu_1, \sigma_1^2), Y_i \text{ i.i.d. } \sim N(\mu_2, \sigma_2^2)$, 考虑假设检验问题

$$H_0: \sigma_1^2 = \sigma_2^2 \longleftrightarrow H_1: \sigma_1^2 \neq \sigma_2^2$$

检验统计量是 $F = \frac{s_1^2}{s_2^2} = \frac{10}{7.8} = 1.28$, 检验的拒绝域是

$$\begin{aligned} W &= \left\{ F \geq F_{\frac{\alpha}{2}}(m-1, n-1) \right\} \cup \left\{ F \leq F_{1-\frac{\alpha}{2}}(m-1, n-1) \right\} \\ &= \left\{ F \geq F_{0.05}(12, 10) \right\} \cup \left\{ F \leq F_{0.95}(12, 10) \right\} \\ &= \left\{ F \geq 2.91 \right\} \cup \left\{ F \leq \frac{1}{2.75} \right\} \end{aligned}$$

所以 $F \notin W$, 因此我们不能拒绝原假设, 应认为两者方差相等.

(2) 考虑假设检验问题 $H_0: \mu_1 - \mu_2 \geq 0 \longleftrightarrow H_1: \mu_1 - \mu_2 < 0$. 检验统计量为

$$\begin{aligned} T &= \frac{\bar{X} - \bar{Y}}{s_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \\ &= \frac{12.3 - 14.4}{\sqrt{\frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}} \sqrt{\frac{1}{13} + \frac{1}{11}}} \\ &= \frac{12.3 - 14.4}{\sqrt{\frac{12 \cdot 10 + 10 \cdot 7.8}{13+11-2}} \cdot \sqrt{\frac{1}{13} + \frac{1}{11}}} = -1.709 \end{aligned}$$

检验的拒绝域为

$$W = \{T \leq -t_{\alpha}(m+n-2)\} = \{T \leq -t_{0.1}(m+n-2)\} = \{T \leq -1.3212\}$$

所以 $T \in W$, 我们应拒绝原假设, 可以认为乙化肥带来的亩产均值高于甲化肥.

七、(20 分) 二维随机变量 (X, Y) 的密度函数为 $f(x, y) = Ae^{-(3x+4y)} x > 0, y > 0$.

- (1) 求系数 A ;
- (2) 问 X 与 Y 是否独立?
- (3) 试求 $Z = X + Y$ 的密度函数;
- (4) 试求 $E(X|X+Y=1)$.

Solution:

(1) 根据概率密度函数的正则性有 $1 = \int_0^{+\infty} dx \int_0^{+\infty} A e^{-(3x+4y)} dy = \frac{A}{12}$, 解得 $A = 12$.

(2) (X, Y) 的联合密度函数 $f(x, y) = 3e^{-3x}4e^{-4y}, x, y > 0$ 是变量可分离的, 即有 $f(x, y) = f_X(x)f_Y(y)$, 所以它们相互独立.

(3) 考虑变量变换 $\begin{cases} Z = X + Y \\ U = X \end{cases} \Leftrightarrow \begin{cases} X = U \\ Y = Z - U \end{cases}$, 变换的雅各比行列式为 $J = \begin{vmatrix} 1 & 0 \\ -1 & 1 \end{vmatrix} = 1$, 因此由公式法, (Z, U) 的联合密度函数是

$$\begin{aligned} f_{Z,U}(z, u) &= f(u, z-u)|1|, u > 0, z-u > 0 \\ &= 12e^{-(4z-u)}, z > u > 0 \end{aligned}$$

因此 Z 的边际密度函数是

$$f_Z(z) = \int_0^z 12e^{-(4z-u)} du = 12e^{-4z}(e^z - 1), z > 0$$

(4) $E(X | X + Y = 1) = E(U | Z = 1)$, 而 U 在 $Z = 1$ 条件下的条件密度函数是

$$f_{U|Z=1}(u) = \frac{f_{U,Z}(u, 1)}{f_Z(1)} = \frac{12e^{-(4-u)}}{12e^{-4}(e-1)} = \frac{e^u}{e-1}, 0 < u < 1$$

所以 $E(U | Z = 1) = \int_0^1 u \frac{e^u}{e-1} du = \frac{1}{e-1}$.

八、(20 分) 甲、乙、丙三个工厂生产同一种产品, 产品质量分别为三个等级 (1,2,3 分别代表高, 中, 低). 今从三个厂中共抽 300 件产品, 逐件检测, 得结果如下:

级数	甲工厂	乙工厂	丙工厂	总和
1 级	36	38	30	104
2 级	40	33	35	108
3 级	18	26	44	88
总和	94	97	109	300

(1) 三个厂的产品质量是否一致?

(2) 若不一致, 问哪个厂的质量更优, 哪个厂更劣?

Solution:

(1) 考虑假设检验问题 H_0 : 三个工厂产品质量一致. 这实际上意味着: 产品质量与工厂独立. 检验统计量 $\chi^2 = n \left[\sum_{i=1}^3 \sum_{j=1}^3 \frac{n_{ij}^2}{n_{i \cdot} n_{\cdot j}} - 1 \right] = 12.275$, 检验的拒绝域是 $W = \{\chi^2 \geq \chi_{\alpha}^2((r-1)(s-1))\} = \{\chi^2 \geq \chi_{0.05}^2(4)\} = \{\chi^2 \geq 9.488\}$ 于是 $\chi^2 \in W$, 故可以拒绝原假设, 即认为三个工厂产品质量不一致.

(2) 考虑用均值作为衡量指标, 则

$$\begin{aligned} \bar{X}_{\text{甲}} &= \frac{36 \times 1 + 40 \times 2 + 18 \times 3}{94} = 1.80851 \\ \bar{X}_{\text{乙}} &= \frac{38 \times 1 + 33 \times 2 + 26 \times 3}{97} = 1.93617 \\ \bar{X}_{\text{丙}} &= \frac{30 \times 1 + 35 \times 2 + 44 \times 3}{109} = 2.12844 \end{aligned}$$

愈小者愈优, 故甲最优, 丙最劣.

九、(20 分) 有来自总体 $N(0, \sigma^2)$ 的随机样本 $X_1, \dots, X_n$, 其次序统计量是 $X_{(1)}, \dots, X_{(n)}$ 是其次序统计量, R_i 是 X_i 的秩, 即 $R_i = j$ 当且仅当 $X_i = X_{(j)}$. 回答下述问题.

(1) 求 $E(R_i)$;

(2) 求 $Cov(R_i, R_j)$;

(3) 判断 $(X_{(1)}, \dots, X_{(n)})$ 与 $(R_1, \dots, R_n)$ 是否独立.

Solution: (1) 根据对称性, X_i 在 n 个样本中排在任意一个位置的概率都一致, 即

$$P(X_i = X_{(j)}) = \frac{1}{n}, j = 1, 2, \dots, n$$

所以有 $P(R_i = j) = \frac{1}{n}, j = 1, 2, \dots, n$, 因此 $E(R_i) = \sum_{j=1}^n \frac{1}{n} = \frac{n+1}{2}$.

(2) 当 $j = i$ 时, 有

$$\begin{aligned} \text{Cov}(R_i, R_i) &= \text{Var}(R_i) \\ &= E(R_i^2) - (ER_i)^2 = \frac{(n+1)(2n+1)}{6} - \frac{(n+1)^2}{4} = \frac{n^2-1}{12} \end{aligned}$$

当 $i \neq j$ 时, 根据对称性有

$$P(R_i = m, R_j = k) = P(R_i = 1, R_j = 2) = \frac{1}{n} \cdot \frac{1}{n-1}, m \neq k$$

则 $E(R_i R_j) = \frac{1}{n(n-1)} [\sum_{m=1}^n \sum_{k=1}^n mk - \sum_{m=1}^n m^2] = \frac{1}{12}(n+1)(3n+2)$. 于是

$$\text{Cov}(R_i, R_j) = E(R_i R_j) - E(R_i) E(R_j) = -\frac{1}{12}(n+1).$$

(3) $(R_1, \dots, R_n)$ 的联合分布列是, 根据对称性有

$$P(R_1 = i_1, R_2 = i_2, \dots, R_n = i_n) = P(R_1 = 1, R_2 = 2, \dots, R_n = n) = \frac{1}{n!}$$

其中 $\{i_1, i_2, \dots, i_n\}$ 是 $\{1, 2, \dots, n\}$ 的任意一种排列. 假设总体密度函数是 $f(x)$, 则 $(X_{(1)}, X_{(2)}, \dots, X_{(n)}, R_1, R_2, \dots, R_n)$ 的联合密度函数是

$$\begin{aligned} h(x_1, \dots, x_n, R_1 = i_1, \dots, R_n = i_n) &= f_{(X_1, X_2, \dots, X_n)}(x_{i_1}, x_{i_2}, \dots, x_{i_n}), x_1 < \dots < x_n \\ &= f(x_{i_1}) \cdots f(x_{i_n}), x_1 < \dots < x_n \\ &= \prod_{i=1}^n f(x_i), x_1 < \dots < x_n \end{aligned}$$

而 $(X_{(1)}, \dots, X_{(n)})$ 的联合密度函数是我们熟知的,

$$f_{(X_{(1)}, \dots, X_{(n)})}(x_1, \dots, x_n) = n! \prod_{i=1}^n f(x_i), x_1 < \dots < x_n$$

因此

$$h(x_1, \dots, x_n, R_1 = i_1, \dots, R_n = i_n) = f_{(X_{(1)}, \dots, X_{(n)})}(x_1, \dots, x_n) \cdot P(R_1 = i_1, \dots, R_n = i_n)$$

所以 $(X_{(1)}, \dots, X_{(n)})$ 与 $(R_1, \dots, R_n)$ 是相互独立的.

中国科学技术大学-432 统计学-2022 年

一、填空与选择题 (35 分)

1. (5 分) 一个醉汉走在路上, 往左走两步就撞了南墙, 往右走三步就会撞北墙。因为喝得太多, 醉汉向左向右走的概率相同都是 0.5, 则醉汉撞到南墙的概率是 ____。

Solution: $\frac{3}{5}$. 画坐标轴, 记起点是 0, 南墙是 -2, 北墙是 3, 记 p_k 为“起点是 k , 最后撞南墙的概率”, 则有

$$p_k = 0.5p_{k-1} + 0.5p_{k+1}, \quad k = -1, 0, 1, 2,$$

化简为 $p_k - p_{k-1} = p_{k+1} - p_k$, 恰好构成等差数列, 结合初值 $p_{-2} = 1, p_3 = 0$, 解得 $p_0 = 3/5$.

2. (10 分) 张先生问李先生: “您家有几个孩子?” 李先生: “两个。” 若张先生问: “大的是男孩子吗?” 李先生回答: “是的。” 则李先生的小孩子也是男孩的概率为 ____。若张先生问: “有男孩子吗?” 李先生回答: “有的。” 则这种情况下李先生的小孩子是男孩子的概率为 ____。

Solution: $\frac{1}{2}; \frac{2}{3}$. 记 $A_1 =$ “第一个是男孩”, $A_2 =$ “第二个是男孩”. 则第一种情况对应的概率是

$$P(A_2|A_1) = P(A_2) = \frac{1}{2}.$$

第二种则是

$$P(A_2|A_1 \cup A_2) = \frac{P(A_2)}{P(A_1 \cup A_2)} = \frac{\frac{1}{2}}{1 - \frac{1}{4}} = \frac{2}{3}.$$

3. (5 分) 请问下列随机变量密度函数相互独立的是:

- A. $6x^2y^3$;
- B. $4(x^3y + xy^3)$;
- C. $6e^{-3x-2y}$;
- D. 以上均无法判断

Solution: D. 所有选项均未给出使密度函数满足非负性, 正则性的条件 (原题如此), 故只能选 D.

4. (10 分) 甲乙玩剪刀石头布的游戏, 胜利得 1 分, 失败得 -1 分, 平局得 0 分, 现在甲出剪刀石头布的概率分别为 $(1/4, 3/8, 3/8)$, 乙出剪刀石头布的概率分别为 $(3/8, 1/4, 3/8)$, 问每场比赛甲的平均得分是 ____。若乙调整策略, 出剪刀石头布的概率均为 $1/3$, 问此时每场比赛甲的平均得分是 ____。

Solution: $-\frac{1}{64}; 0$.

调整前, 有

$$E(X) = 1 \cdot \left(\frac{1}{4} \cdot \left(\frac{3}{8} - \frac{1}{4} \right) + \frac{3}{8} \cdot \left(\frac{3}{8} - \frac{3}{8} \right) + \frac{3}{8} \cdot \left(\frac{1}{4} - \frac{3}{8} \right) \right) = -\frac{1}{64}.$$

调整后, 有

$$E(X) = 1 \cdot \left(\frac{1}{4} \cdot \left(\frac{1}{3} - \frac{1}{3} \right) + \frac{3}{8} \cdot \left(\frac{1}{3} - \frac{1}{3} \right) + \frac{3}{8} \cdot \left(\frac{1}{3} - \frac{1}{3} \right) \right) = 0.$$

5. (5 分) 根据样本已经得到了 θ 的 95% 置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$, 正确的是 ()。

- A. 该区间以 95% 的概率包含真值
- B. 参数 θ 在该区间内的概率为 95%
- C. 该区间有 95% 的可能性包含参数 θ
- D. 参数 θ 或者在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内, 或者不在 $(\hat{\theta}_1, \hat{\theta}_2)$ 内

Solution: D. 此时已经根据样本值得到了一个固定的置信区间, 参数要么在这个固定的区间中, 要么不在其中. 注意如果题干改为抽样之前, 则由于样本还未获得, 两个区间端点都是随机的, 随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 覆盖参数真值 θ 的概率是 95%. 但现在, 区间已定, 参数也是个常数, 要么在里面, 要么不在里面.

二、计算与分析题

1. (25 分) $X \sim N(0, 1)$, $Y \sim B(1, \frac{1}{2})$, 它们独立, 定义 $Z = X(2Y - 1)$.

(1)(7 分) 求 Z 的分布;

(2)(8 分) 求 $\text{Corr}(X, Z)$;

(3)(8 分) X, Z 独立吗?

Solution: (1) 对任意 z , 由于 $-X \sim N(0, 1)$,

$$P(Z \leq z) = P(X \cdot 1 \leq z) P(Y = 1) + P(X \cdot (-1) \leq z) P(Y = 0) = \frac{1}{2} \Phi(z) + \frac{1}{2} \Phi(z) = \Phi(z).$$

因此 $Z \sim N(0, 1)$.

(2) 由于 $E(X) = E(Z) = 0$, 而

$$E(XZ) = E(X^2(2Y - 1)) = E(X^2) E(2Y - 1) = 0,$$

得 $\text{Cov}(X, Z) = 0$, 故 $\text{Corr}(X, Z) = 0$,

(3) 显然不独立, 考虑

$$\begin{aligned} P(X \leq 1, Z \leq 1) &= P(X \leq 1, X \leq 1) P(Y = 1) + P(X \leq 1, -X \leq 1) P(Y = 0) \\ &= \frac{1}{2} \Phi(1) + \frac{1}{2} [\Phi(1) - \Phi(-1)] = \Phi(1) - \frac{1}{2} \Phi(-1) \neq \Phi^2(1). \end{aligned}$$

2. (20 分) 设 $X_1, X_2, \dots$ 是 i.i.d. 连续型非负随机变量 (如跳远成绩), 记

$$A_k = \{X_k = \max\{X_1, \dots, X_k\}\}$$

为一个记录发生. 求:

(1) (8 分) $P(A_k)$;

(2) (12 分) $\text{Var}(\sum_{k=1}^n I_{A_k})$.

Solution:

(1) 根据对称性, $P(A_k) = P(X_k = \max\{X_1, \dots, X_k\}) = \frac{1}{k}$.

(2) 由于 $I_{A_k} \sim B(1, \frac{1}{k})$, 故 $\text{Var}(I_{A_k}) = (1 - \frac{1}{k})\frac{1}{k}$. 再考虑 $k < j$ 时条件概率

$$P(A_j | A_k) = P(X_j = \max\{X_k, X_{k+1}, \dots, X_j\} | A_k),$$

我们发现无论 $X_1, \dots, X_k$ 怎么排序, 还是只要 X_j 在所有当中排第 1 就好, 即条件概率仍然是 $\frac{1}{j}$. 我们计算

$$E(I_{A_k} I_{A_j}) = P(A_k A_j) = \frac{1}{k} P(A_j | A_k) = \frac{1}{k} \frac{1}{j},$$

这也说明协方差为 0, 故有

$$\text{Var}\left(\sum_{k=1}^n I_{A_k}\right) = \sum_{k=1}^n \left(1 - \frac{1}{k}\right) \frac{1}{k}.$$

3. (20 分) 设 $X_1, \dots, X_n$ 是 i.i.d. 的 $N(\mu, \sigma^2)$ 的随机样本, 其中 μ, σ^2 是未知参数.

(1) (10 分) 样本标准差是总体标准差无偏估计吗?

(2) (10 分) $\bar{x}^2$ 是 μ^2 的无偏估计吗? 若不是, 给出 μ^2 的一个无偏估计.

Solution: (1) 不是. 已知 $E(S^2) = \sigma^2$, 而

$$\text{Var}(S) = E(S^2) - [E(S)]^2 > 0,$$

即 $[E(S)]^2 < E(S^2) = \sigma^2$, 故 $E(S) < \sigma$.

(2) 由于 $\bar{x} \sim N(\mu, \frac{\sigma^2}{n})$, 故 $E(\bar{x}^2) = \mu^2 + \frac{\sigma^2}{n}$, 它不是 μ^2 的无偏估计, 修正后看出 $\bar{x}^2 - \frac{\sigma^2}{n}$ 恰好是 μ^2 的无偏估计.

4. (30 分) 为调查某商品在商场货架上的滞留时间, 随机调查 9 个样本的滞留时间 $X_1, \dots, X_9$, 其中计算得到 $\bar{x} = 131$, 假设总体 $X \sim N(\mu, 9)$. $u_{0.95} = 1.645$.

(1)(10 分) 检验 $H_0: \mu \leq 130$, 备择假设是其对立, $\alpha = 0.05$.

(2)(10 分) 若 $\mu = 131$, 样本量改为 n , 求犯第二类错误的概率 β , 并指出: 想要 $\beta \leq 0.05$, 我们应该需要多少样本.

(3)(10 分) 求 $\theta = P(X \leq 130)$ 的 MLE, 并给出 95% 置信下限.

Solution: (1) 拒绝域是

$$W = \left\{ \sqrt{n} \frac{\bar{x} - 130}{\sigma} = \bar{x} - 130 > 1.645 \right\}$$

现在 $\bar{x} - 130 = 1$, 不落入拒绝域, 不能拒绝原假设.

(2) 犯第二类错误的概率是

$$\begin{aligned} \beta &= P\left(\sqrt{n} \frac{\bar{x} - 130}{3} < 1.645 \mid \mu = 131\right) = P\left(\bar{x} - 131 < -1 + \frac{3}{\sqrt{n}} 1.645 \mid \mu = 131\right) \\ &= \Phi\left(\frac{\sqrt{n}}{3} \left(-1 + \frac{3}{\sqrt{n}} 1.645\right)\right) = \Phi\left(-\frac{\sqrt{n}}{3} + 1.645\right), \end{aligned}$$

令其小于 0.05, 则有

$$-\frac{\sqrt{n}}{3} + 1.645 < -1.645,$$

解得 $\sqrt{n} > 9.87$, 故 $n > 97.42$, 取 $n = 98$.

(3) 计算得

$$g(\mu) = P(X \leq 130) = P\left(\frac{X - \mu}{3} \leq \frac{130 - \mu}{3}\right) = \Phi\left(\frac{130 - \mu}{3}\right),$$

由 MLE 不变性, 有 $\hat{g} = \Phi\left(\frac{130 - \bar{x}}{3}\right) = \Phi(-1/3)$. 而由于 Φ 是单调函数, $g(\mu)$ 是 μ 单调减函数, 故有

$$\{\mu \leq a\} = \{g(\mu) \geq g(a)\},$$

我们可以选 a 为 μ 的 0.95 置信上限, 即 $a = \bar{x} + 1.645$, 故有

$$g(a) = \Phi\left(\frac{130 - \bar{x} - 1.645}{3}\right) = \Phi\left(\frac{-2.645}{3}\right)$$

是 $g(\mu)$ 的 0.95 置信下限.

5. (20 分) 有线性模型

$$Y_i = b|x_i - 3| + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

(1)(10 分) 若欲用最小二乘法求 b 的估计, ε 需要满足什么要求?

(2)(10 分) 已知 (x, y) 的三个数据点 $(3, 1), (4, 3), (2, 2)$, 求 b 的最小二乘估计.

Solution: (1) 若要做最小二乘估计, 则 $\varepsilon_1, \dots, \varepsilon_n$ 应该是零均值, 同方差, 协方差为 0, 并且不能和自变量 $|x_i - 3|$ 有相关性. (注意: 不需要正态假设)

(2) 记 $z_i = |x_i - 3|$, 对应的最小二乘估计是 $\hat{b} = \frac{\sum_{i=1}^n z_i y_i}{\sum_{i=1}^n z_i^2}$, 代入数据有

$$\hat{b} = \frac{0 \cdot 1 + 1 \cdot 3 + 1 \cdot 2}{0^2 + 1^2 + 1^2} = 2.5.$$

中国科学技术大学-432 统计学-2023 年

一、填空题 (每题 5 分, 共 50 分)

1. 投掷硬币 n 次, 已知正面出现了 k 次, 则前两次是正面的概率是 ____.

Solution: $\frac{k(k-1)}{n(n-1)}$.

$$\begin{aligned} P\left(X_1 = 1, X_2 = 1 \mid \sum_{i=1}^n X_i = k\right) &= \frac{P(X_1 = 1, X_2 = 1, \sum_{i=3}^n X_i = k-2)}{C_n^k \left(\frac{1}{2}\right)^n} \\ &= \frac{\frac{1}{2} \cdot \frac{1}{2} \cdot C_{n-2}^{k-2} \left(\frac{1}{2}\right)^{n-2}}{C_n^k \left(\frac{1}{2}\right)^n} = \frac{k(k-1)}{n(n-1)}. \end{aligned}$$

2. 设有三角形 ABC , 某人最开始站在 A 点, 随机的向另外两个点走去, 随后每次如此, 问第 n 次他走向 A 点的概率是 ____.

Solution: $\frac{1}{3} \left(1 - \left(-\frac{1}{2}\right)^{n-1}\right)$.

考虑状态法, 设 a_n, b_n, c_n 分别是它第 n 次之后位于三点的概率, 有 $a_0 = 1, b_0 = 0, c_0 = 0$, 以及 $a_1 = 0, b_1 = \frac{1}{2}, c_1 = \frac{1}{2}$. 显然所求概率应为 $p_n = \frac{1-a_{n+1}}{2}$, 即它上一次之后不在 A 点的概率, 再等分给他可以前往的两点.

用全概率公式有

$$\begin{cases} a_{n+1} = 0 \cdot a_n + \frac{1}{2} \cdot b_n + \frac{1}{2} \cdot c_n, \\ b_{n+1} = \frac{1}{2} \cdot a_n + 0 \cdot b_n + \frac{1}{2} \cdot c_n, \\ c_{n+1} = \frac{1}{2} \cdot a_n + \frac{1}{2} \cdot b_n + 0 \cdot c_n, \end{cases} \Rightarrow \begin{pmatrix} a_{n+1} \\ b_{n+1} \\ c_{n+1} \end{pmatrix} = \begin{pmatrix} 0 & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & 0 & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix} \begin{pmatrix} a_n \\ b_n \\ c_n \end{pmatrix},$$

可以用这个矩阵 n 次方去算, 该方法称为马尔科夫链. 但是根据对称性, 我们知道 $b_n = c_n$, 故 $b_n = c_n = \frac{1-a_n}{2}$, 到最后只剩 a_n 一个序列了, 我们反表示出 $a_n = 1 - 2p_{n+1}$, $b_n = c_n = p_{n+1}$, 代入第一个全概率公式即为

$$1 - 2p_{n+2} = p_{n+1}, \Rightarrow p_{n+1} - \frac{1}{3} = -\frac{1}{2} \left(p_n - \frac{1}{3}\right),$$

代入 $p_0 = 0$, 解得

$$p_n = \frac{1}{3} + \left(-\frac{1}{2}\right)^{n-1} \left(0 - \frac{1}{3}\right) = \frac{1}{3} \left(1 - \left(-\frac{1}{2}\right)^{n-1}\right).$$

3. 已知将 A, B, C 三个字母输入信道, 输出正确的概率是 0.8, 输出为其他字母的概率是 0.1, 0.1. 现在, 等概率地输入 $AAAA, BBBB, CCCC$, 且观测到 $ACBA$, 问输入是 $AAAA$ 的概率为 ____.

Solution: 0.8.

利用全概率公式得

$$P(\text{out} : ACBA) = \frac{1}{3} \cdot (0.8^2 \cdot 0.1^2) + \frac{1}{3} \cdot (0.1^3 \cdot 0.8) + \frac{1}{3} \cdot (0.1^3 \cdot 0.8) = 0.00266667,$$

利用贝叶斯公式得

$$P(\text{in} : AAAA) = \frac{\frac{1}{3} \cdot (0.8^2 \cdot 0.1^2)}{P(\text{out} : ACBA)} = 0.8.$$

4. 检验的 p 值是否为统计量? ____.

Solution: 是.

p 值依赖于观测到的样本, 属于统计量.

5. 下列说法正确的个数是 ____.

- (1) R^2 越小说明方程的拟合越好;
 (2) R^2 越大说明方程的拟合越好;
 (3) 残差 $e = \hat{y} - y$ 越大说明方程的拟合越好;
 (4) 残差分析图中, 点的分布越平稳说明方程的拟合越好, 且点分布带状图越窄, 说明拟合精度越高.

Solution: 2.

(1) (3) 显然错误, (2) (4) 正确.

6. 对任意三角形 ABC 内部取一点 P , 在 BC 上取 Q , 则直线 PQ 与 AB 相交的概率是 ____.

- A. $\frac{1}{2}$
 B. $\frac{|BC|}{|AB|+|BC|}$
 C. $\frac{|BC|^2}{|AB|+|BC|}$
 D. $\frac{|AB|+|AC|+\frac{|BC|}{2}}{|AB|+|AC|+|BC|}$ 不确定

Solution: A.

设三角形的边 $BC = a$, B 为原点, BC 为 x 轴, 则 $Q \sim U(0, a)$, $P \sim U(\triangle ABC)$. 先取定 $Q = (q, 0)$, 连接 AQ , P 要落在 $\triangle ABQ$ 里才能满足题设条件, 故有

$$\Pr(P \in \triangle ABQ | Q = q) = \frac{S_{\triangle ABQ}}{S_{\triangle ABC}} = \frac{q}{a},$$

再让 q 动起来, 有

$$\Pr(PQ \cap AB) = \int_0^a \frac{q}{a} \cdot \frac{1}{a} dq = \frac{1}{2}.$$

7. 设 $X_1, \dots, X_9$ 是 i.i.d. 的 $N(0, 1)$ 随机变量, 下列正确的是 ____.

- A. $\frac{X_1^2 + X_2^2 + X_3^2}{X_4^2 + \dots + X_9^2} \sim F(3, 6)$
 B. $2 \frac{X_1^2 + X_2^2 + X_3^2}{X_4^2 + \dots + X_9^2} \sim F(3, 6)$
 C. $\frac{X_1^2}{X_1^2 + X_2^2} \sim F(1, 2)$
 D. $\frac{2X_1^2}{X_1^2 + X_2^2} \sim F(1, 2)$

Solution: B.

注意 C, D 并不满足分子分母的独立性.

8. 已知 $X \sim \mathcal{P}(\lambda)$, $Y \sim \mathcal{P}(\mu)$, 且它们独立, 求 $E(X | X + Y = n) =$ ____.

Solution: $\frac{\lambda n}{\lambda + \mu}$.

$$P(X = k | X + Y = n) = \frac{P(X = k, Y = n - k)}{P(X + Y = n)} = \frac{\frac{\lambda^k}{k!} e^{-\lambda} \frac{\mu^{n-k}}{(n-k)!} e^{-\mu}}{\frac{(\lambda + \mu)^n}{n!} e^{-(\lambda + \mu)}} = C_n^k \left(\frac{\lambda}{\lambda + \mu} \right)^k \left(\frac{\mu}{\lambda + \mu} \right)^{n-k},$$

因此 $X + Y = n$ 时, X 的条件分布是 $B(n, \frac{\lambda}{\lambda + \mu})$, 故期望是 $\frac{\lambda n}{\lambda + \mu}$.

9. 10. 有两题暂无人回忆起来

二、计算分析题

1. (25 分) 已知 $X \sim f(x) = \frac{1}{2} e^{-\frac{1}{2}x}$, $x > 0$, $Y \sim U(0, 1)$, 且它们独立.

- (1) 求联合密度 $f(x, y)$;
 (2) 求 $Z = X + Y$ 的密度函数;
 (3) 求 $t^2 + 2Xt + Y = 0$ 有实根的概率, 保留 3 位小数.

Solution: (1) 根据独立性, 有

$$f(x, y) = \frac{1}{2}e^{-\frac{1}{2}x}, \quad x > 0, \quad 0 < 1 < y.$$

(2) 作变量变换, 有

$$\begin{cases} Z = X + Y, \\ W = Y, \end{cases} \Rightarrow \begin{cases} z = x + y, \\ w = y, \end{cases} \Rightarrow \begin{cases} x = z - w, \\ y = w, \end{cases} \Rightarrow J = \begin{vmatrix} 1 & -1 \\ 0 & 1 \end{vmatrix} = 1,$$

因此有

$$f_{Z,W}(z, w) = f(z - w, w) = \frac{1}{2}e^{-\frac{z}{2} + \frac{w}{2}}, \quad z > w, 0 < w < 1,$$

积掉 W , 得

$$f_Z(z) = \frac{1}{2}e^{-\frac{z}{2}} \int_0^{\min\{z, 1\}} e^{\frac{w}{2}} dw = e^{-\frac{z}{2}} \left(e^{\frac{\min\{z, 1\}}{2}} - 1 \right) = \begin{cases} e^{-\frac{z}{2}} (e^{\frac{1}{2}} - 1), & z > 1, \\ 1 - e^{-\frac{z}{2}}, & 0 < z < 1. \end{cases}$$

(3) $\Delta = 4X^2 - 4Y$, 故所求概率为 $P(X^2 \geq Y)$, 有

$$P(X^2 \geq Y) = \int_0^1 P(X \geq \sqrt{y}) f_Y(y) dy = \int_0^1 e^{-\frac{\sqrt{y}}{2}} dy = 8 \left(1 - \frac{3}{2}e^{-\frac{1}{2}} \right) = 0.721632.$$

2. (10 分) 假设检验问题: 给出两组正态总体数据 X, Y .

(1) 检验 $H_0: \sigma_1^2 = \sigma_2^2$;

(2) 检验 $H_0: \mu_1 = \mu_2$.

3. (25 分) 有来自总体 $f(x, a) = \frac{2x}{a^2}, 0 < x < a$ 的 i.i.d. 样本 $x_1, \dots, x_n$, 已知 $a > 1$.

(1) 求 a 的矩估计 $\hat{a}_1$, 最大似然估计 $\hat{a}_2$, 以及 $P(0 < X < \sqrt{a})$ 的 MLE;

(2) $\hat{a}_1, \hat{a}_2$ 是否为无偏估计, 若不是请修正;

(3) 求 $n(a - \hat{a}_2)$ 在 $n \rightarrow \infty$ 的渐近分布.

Solution: (1) 求总体期望 $E(X)$, 利用 $\frac{X}{a} \sim \text{Beta}(2, 1)$ 或直接积分有 $E(X) = \frac{2}{3}a$, 由替换原理, 得 $\hat{a}_1 = \frac{3}{2}\bar{x}$. 再写似然函数, 有

$$L(a) = \frac{2^n \prod_{i=1}^n x_i}{a^{2n}}, \quad a > \max\{x_{(n)}, 1\},$$

可以看出似然函数关于 a 递减, 故有

$$\hat{a}_2 = \max\{x_{(n)}, 1\} = \begin{cases} 1, & x_{(n)} < 1, \\ x_{(n)}, & x_{(n)} \geq 1. \end{cases}$$

(2) 由于 $E(\bar{x}) = \frac{2}{3}a$, 显然 $\hat{a}_1$ 无偏.

对于 $\hat{a}_2$, 先求 $x_{(n)}$ 的分布, 有

$$P(x_{(n)} \leq t) = P^n(X \leq t) = \left(\frac{t}{a}\right)^{2n}, \quad f_n(t) = \frac{2nt^{2n-1}}{a^{2n}}, \quad 0 < t < a,$$

实际上即为 $\frac{x_{(n)}}{a} \sim \text{Be}(2n, 1)$, 故有

$$E(\hat{a}_2) = \int_0^1 f_n(t) dt + \int_1^a t f_n(t) dt = \frac{1}{a^{2n}} + \frac{2n}{2n+1} \left(a - \frac{1}{a^{2n}} \right) = \frac{2n}{2n+1} \cdot a + \frac{1}{2n+1} \cdot \frac{1}{a^{2n}},$$

由于 $a > 1$, 故 $\frac{1}{a^{2n}} < 1$, 因此

$$\frac{2n}{2n+1} \cdot a + \frac{1}{2n+1} \cdot \frac{1}{a^{2n}} < \frac{2n}{2n+1} \cdot a + \frac{1}{2n+1} < a.$$

故 $\hat{a}_2$ 不无偏. 直接乘一个不含 a 的数不可能修正为无偏估计, 但我们在求期望的过程中, 如果写成

$$\int_0^1 f_n(t) dt + \frac{2n+1}{2n} \int_1^a t f_n(t) dt = \frac{1}{a^{2n}} + \left(a - \frac{1}{a^{2n}}\right) = a,$$

则恰好是无偏估计, 这对应的估计量是

$$\tilde{a}_2 = \begin{cases} 1, & x_{(n)} < 1, \\ \frac{2n+1}{2n} x_{(n)}, & x_{(n)} \geq 1. \end{cases}$$

(3) 记 $T_n = n(a - \hat{a}_2)$, 则有

$$P(T_n \leq t) = P(n(a - \hat{a}_2) \leq t) = P\left(a - \hat{a}_2 \leq \frac{t}{n}\right) = P\left(\hat{a}_2 \geq a - \frac{t}{n}\right),$$

对于 $t > 0$, 总有 n 足够大使得 $a - \frac{t}{n} > 1$, 因此

$$P\left(\hat{a}_2 \geq a - \frac{t}{n}\right) = P\left(x_{(n)} \geq a - \frac{t}{n}\right) = 1 - \left(1 - \frac{t}{an}\right)^{2n} \rightarrow 1 - e^{-\frac{2t}{a}}, \quad t > 0,$$

这说明 $n(a - \hat{a}_2) \xrightarrow{d} \text{Exp}\left(\frac{2}{a}\right)$.

4. (15 分) 叙述题: (1) 叙述多重共线性的定义;

(2) 如何判断多重共线性;

(3) 如何消除多重共线性;

(4) 叙述自变量的选择标准.

Solution: (1) 在回归分析中, 如果两个或两个以上自变量之间存在相关性, 这种自变量之间的相关性, 就称作多重共线性, 也称作自变量间的相关性. 多重共线性的存在违背了线性回归模型的基本假设, 变量之间的线性相关性将会导致矩阵 $X^T X$ 不满秩, 进而导致最小二乘估计不唯一.

(2) 可以借助方差膨胀因子 VIF 来判断共线性, 计算公式是

$$VIF_j = \frac{1}{1 - R_j^2},$$

一般我们认为 $VIF > 10$ 时, 存在多重共线性, 该特征需要删除.

我们也可以分析矩阵 $X^T X$ 的特征值, 如果该矩阵的最小特征值非常接近于 0, 我们也认为存在多重共线性.

(3) 可利用逐步回归筛选并剔除引起多重共线性的变量, 其具体步骤如下: 先用被解释变量对每一个所考虑的自变量做简单回归, 然后以对被解释变量贡献最大的自变量所对应的回归方程为基础, 再逐步引入其余自变量. 经过逐步回归, 使得最后保留在模型中的自变量既是重要的, 又没有严重多重共线性.

(4) 在模型中加入自变量时, 要尽量使得: 残差平方和缩小或决定系数增大, 若某一自变量被引入模型后 SSE 减小很多, 说明该变量对因变量 y 的作用大, 可被引入; 反之, 说明其对 y 的作用小, 不应该被引入. 此外, 还可以根据赤池信息准则 (AIC)、贝叶斯信息准则 (BIC)、对数似然函数值 (LLH) 等方法判断.

5. (25 分) 设有来自 $f(x; \lambda) = \lambda e^{-\lambda x}$ 指数分布的 i.i.d. 样本 $x_1, \dots, x_n$, 但由于某种原因只能观测到 $A_i = I_{\{a_i < x_i < b_i\}}$, 其中 a_i, b_i 是给定常数, $i = 1, 2, \dots, n$.

(1) 写出 $(A_1, \dots, A_n)$ 对应的对数似然函数 $\ell_A(\lambda)$, 同时写出完整样本 $(x_1, \dots, x_n)$ 对应的对数似然函数 $\ell_X(\lambda)$;

(2) 写出基于 $\ell_A(\lambda)$ 所求 MLE 满足的等式;

(3) 分别考虑两个步骤: (i) E 步: 考虑 $X \sim \text{Exp}(\lambda_k)$, 求条件期望

$$Q(\lambda|\lambda_k) = E[\ell_X(\lambda)|A, \lambda_k],$$

(ii) M 步: 极大化 $Q(\lambda)$, 即

$$\lambda_{k+1} = \underset{\lambda}{\operatorname{argmax}} Q(\lambda|\lambda_k).$$

(4) 证明: 通过两个步骤迭代得到的序列 $\lambda_n \rightarrow \hat{\lambda}$, 其中 $\hat{\lambda}$ 是基于 $\ell_A(\lambda)$ 求得的 MLE. (提示: 和 $a_i, b_i, \lambda_k, \lambda_0$ 有关)

Solution: (1) 每个 A_i 都是两点分布, 其参数是

$$p_i(\lambda) = P(a_i < x_i < b_i) = e^{-\lambda a_i} - e^{-\lambda b_i},$$

因此有

$$L_A(\lambda) = \prod_{i=1}^n p_i^{A_i} (1-p_i)^{1-A_i} = \prod_{i=1}^n p_i^{A_i} \cdot \prod_{i=1}^n (1-p_i)^{1-A_i},$$

故有

$$\ell_A(\lambda) = \sum_{i=1}^n A_i \ln p_i + \sum_{i=1}^n (1-A_i) \ln(1-p_i).$$

而全样本对应的对数似然函数是指数分布的联合密度取对数, 即

$$\ell_X(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i.$$

(2) 记 $q_i(\lambda) = a_i e^{-\lambda a_i} - b_i e^{-\lambda b_i}$, 实际上即 $q_i = -\frac{\partial p_i}{\partial \lambda}$, 求导有

$$\begin{aligned} \frac{\partial \ell_A}{\partial \lambda} &= \sum_{i=1}^n A_i \frac{-q_i}{p_i} + \sum_{i=1}^n (1-A_i) \frac{q_i}{1-p_i} \\ &= -\sum_{i=1}^n q_i \left(\frac{A_i}{p_i} - \frac{1-A_i}{1-p_i} \right) = -\sum_{i=1}^n q_i \frac{A_i - p_i}{p_i(1-p_i)}, \end{aligned}$$

因此 MLE $\hat{\lambda}$ 满足

$$\sum_{i=1}^n q_i(\hat{\lambda}) \frac{A_i - p_i(\hat{\lambda})}{p_i(\hat{\lambda})(1-p_i(\hat{\lambda}))} = 0.$$

(3) 先求 $E[x_k|A_k]$, 有

$$E[x_i | A_i = 1] = \frac{E[x_i I_{\{a_i < x_i < b_i\}}]}{P(a_i < x_i < b_i)} = \frac{1}{\lambda} + \frac{q_i}{p_i},$$

其中分子利用了

$$\int_{a_i}^{b_i} \lambda x e^{-\lambda x} dx = \frac{1}{\lambda} \int_{\lambda a_i}^{\lambda b_i} u e^{-u} du = \frac{1}{\lambda} [(\lambda a_i + 1) e^{-\lambda a_i} - (\lambda b_i + 1) e^{-\lambda b_i}] = q_i + \frac{p_i}{\lambda}.$$

同理用 $E[x_i I_{\{x_i \notin (a_i, b_i)\}}] = E[x_i] - E[x_i I_{\{x_i \in (a_i, b_i)\}}]$, 有

$$E[x_i | A_i = 0] = \frac{\frac{1-p_i}{\lambda} - q_i}{1-p_i} = \frac{1}{\lambda} - \frac{q_i}{1-p_i}.$$

因此有 E 步是:

$$\begin{aligned}
 Q(\lambda|\lambda_k) &= E[\ell_X(\lambda) | A, \lambda_k] \\
 &= n \ln \lambda - \lambda \sum_{i=1}^n E[x_i | A_i, \lambda_k] \\
 &= n \ln \lambda - \lambda \sum_{i=1}^n \left(\frac{1}{\lambda_k} + q_i(\lambda_k) \left(\frac{A_i}{p_i(\lambda_k)} - \frac{1 - A_i}{1 - p_i(\lambda_k)} \right) \right) \\
 &= n \ln \lambda - \frac{n\lambda}{\lambda_k} - \lambda \sum_{i=1}^n q_i(\lambda_k) \frac{A_i - p_i(\lambda_k)}{p_i(\lambda_k)(1 - p_i(\lambda_k))}.
 \end{aligned}$$

再考虑 M 步: 对 $Q(\lambda|\lambda_k)$ 求极大化 (注意 λ_k 是常数, 只有 λ 是变量), 可以求得

$$\frac{\partial Q}{\partial \lambda} = \frac{n}{\lambda} - \frac{n}{\lambda_k} - \sum_{i=1}^n q_i(\lambda_k) \frac{A_i - p_i(\lambda_k)}{p_i(\lambda_k)(1 - p_i(\lambda_k))},$$

解得极值点满足

$$\frac{1}{\lambda} = \frac{1}{\lambda_k} + \frac{1}{n} \sum_{i=1}^n q_i(\lambda_k) \frac{A_i - p_i(\lambda_k)}{p_i(\lambda_k)(1 - p_i(\lambda_k))},$$

故有

$$\lambda_{k+1} = \frac{1}{\frac{1}{\lambda_k} + \frac{1}{n} \sum_{i=1}^n q_i(\lambda_k) \frac{A_i - p_i(\lambda_k)}{p_i(\lambda_k)(1 - p_i(\lambda_k))}}.$$

(4) 该序列满足

$$\frac{1}{\lambda_{k+1}} = \frac{1}{\lambda_k} + \frac{1}{n} \sum_{i=1}^n q_i(\lambda_k) \frac{A_i - p_i(\lambda_k)}{p_i(\lambda_k)(1 - p_i(\lambda_k))},$$

记 $D(\lambda_k) = -\sum_{i=1}^n q_i(\lambda_k) \frac{A_i - p_i(\lambda_k)}{p_i(\lambda_k)(1 - p_i(\lambda_k))}$, 这恰好是 ℓ_A 在 λ_k 点的导数, 而

$$\frac{1}{\lambda_{k+1}} = \frac{1}{\lambda_k} - \frac{1}{n} \cdot D(\lambda_k),$$

该序列保证了 λ_k 在导数的同方向迭代, 即保证了函数值 ℓ_A 的上升, 因此 $\{\lambda_n\}$ 一定收敛到 ℓ_A 的某个驻点, 即导数为 0 的点, 即 $\hat{\lambda}$.

中国科学技术大学-432 统计学-2024 年

一、填空题

1. $F_1(x)$ 和 $F_2(x)$ 均为分布函数, 则当 $a = \underline{\hspace{1cm}}, b = \underline{\hspace{1cm}}$ 时, $aF_1(x) - bF_2(x)$ 也为分布函数.

Solution: $a = 1 + b, -1 \leq b \leq 0$.

首先由 $aF_1(+\infty) - bF_2(+\infty) = 1$, 可以得到 $a - b = 1$. 同时当 $a \geq 0$ 以及 $-b \geq 0$ 时, $aF_1(x) - bF_2(x)$ 也满足单调性. 故 $a = 1 + b, -1 \leq b \leq 0$.

2. $X \sim N(0, 1)$, 若 $P(X > x_\alpha) = \alpha$, 则当 $P(|X| < x) = \alpha, x = \underline{\hspace{1cm}}$.

Solution: $-\Phi^{-1}(\Phi(x_\alpha)/2)$.

由题意可以得到 $\Phi(x_\alpha) = 1 - \alpha$ 以及 $2\Phi(x) - 1 = \alpha$. 从而 $\Phi(x_\alpha) + 2\Phi(x) = 2$. 故有 $x = -\Phi^{-1}(\Phi(x_\alpha)/2)$.

3. $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} P(\lambda)$, 则 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的分布为 $\underline{\hspace{1cm}}$.

Solution: $P(\bar{X} = k) = \frac{(n\lambda)^{nk}}{(nk)!} e^{-n\lambda}$.

由泊松分布的可加性可知, $\sum_{i=1}^n X_i \sim P(n\lambda)$. 从而

$$P(\bar{X} = k) = P\left(\sum_{i=1}^n X_i = nk\right) = \frac{(n\lambda)^{nk}}{(nk)!} e^{-n\lambda}.$$

4. $X \sim N(0, 1), Y \sim b(n, p)$, 已知 X, Y 独立, 则 X 与 X^3Y 的协方差为 $\underline{\hspace{1cm}}$.

Solution: $3np$.

$Cov(X, X^3Y) = E(X^4Y) - E(X)E(X^3Y) = E(X^4)E(Y) = 3np$.

5. 现共有一万人投保, 保费总共为 200 万. 已知一年内有一人去世则需要赔偿 1 万元, 且每个人的去世概率为 1.5%, 求

(1) 亏钱的概率为 $\underline{\hspace{1cm}}$. (2) 盈利 10 万到 20 万的概率为 $\underline{\hspace{1cm}}$. (用标准正态分布函数 Φ 表示)

Solution: $1 - \Phi\left(\frac{100}{\sqrt{591}}\right), \Phi\left(\frac{80}{\sqrt{591}}\right) - \Phi\left(\frac{60}{\sqrt{591}}\right)$.

设 X_i 表示第 i 个人是否去世, 则 $X_i \sim b(1, 1.5\%)$. 由 CLT, 亏钱概率为

$$P\left(\sum_{i=1}^{10000} X_i > 200\right) = P\left(\frac{\sum_{i=1}^{10000} X_i - 150}{\sqrt{591}/2} > \frac{100}{\sqrt{591}}\right) \approx 1 - \Phi\left(\frac{100}{\sqrt{591}}\right)$$

同理, 盈利 10 万到 20 万的概率为

$$P\left(180 \leq \sum_{i=1}^{10000} X_i \leq 190\right) = P\left(\frac{60}{\sqrt{591}} \leq \frac{\sum_{i=1}^{10000} X_i - 150}{\sqrt{591}/2} \leq \frac{80}{\sqrt{591}}\right) \\ \approx \Phi\left(\frac{80}{\sqrt{591}}\right) - \Phi\left(\frac{60}{\sqrt{591}}\right)$$

6. X_1, X_2, X_3, X_4 独立同服从于 $N(0, 3)$, 若 $a(X_1 - 4X_2)^2 + b(2X_3 - 3X_4)^2$ 服从卡方分布, 则卡方分布的自由度为 $\underline{\hspace{1cm}}, a + b = \underline{\hspace{1cm}}$.

Solution: 2, 10/221.

首先有 $X_1 - 4X_2 \sim N(0, 51), 2X_3 - 3X_4 \sim N(0, 39)$

从而当 $a = 1/51, b = 1/39$ 时, 有 $a(X_1 - 4X_2)^2 \sim \chi^2(1)$ 以及 $a(2X_3 - 3X_4)^2 \sim \chi^2(1)$. 故自由度为 2, $a + b = 10/221$.

7. $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} P(\lambda)$, 则 λ^2 的一个无偏估计为 $\underline{\hspace{1cm}}$.

Solution: $(T^2 - T)/n^2$, 其中 $T = \sum_{i=1}^n X_i$.

我们考虑充分统计量 $T = \sum_{i=1}^n X_i = n\lambda \sim P(n\lambda)$. 有

$$E(T) = Var(T) = E(T^2) - E^2(T) = E(T^2) - n^2\lambda^2.$$

从而有 $\lambda^2 = [E(T^2) - E(T)]/n^2$. 故无偏估计为 $(T^2 - T)/n^2$.

8. 一批零件长度服从正态分布 $N(\mu, \sigma^2)$, μ, σ 未知. 现在抽取 9 个样本, 均值和方差分别为 40 和 1. 已知 μ 的 90% 置信区间为 $[40 - a \cdot t_{0.05}(n), 40 + a \cdot t_{0.05}(n)]$, 其中 $t_{0.05}(n)$ 表示自由度为 n 的 t 分布的上 0.05 分位数, 则 $a = \underline{\hspace{1cm}}, n = \underline{\hspace{1cm}}$.

Solution: $a = 1/3, n = 8$.

μ 的 90% 置信区间为

$$\left[40 - t_{0.05}(8)\frac{1}{3}, 40 + t_{0.05}(8)\frac{1}{3}\right].$$

故 $a = 1/3, n = 8$.

9. $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Exp}(\lambda)$, 对检验问题 $H_0: \lambda = \lambda_0$ v.s. $H_1: \lambda < \lambda_0$, 其显著性水平为 α 的拒绝域为 $\underline{\hspace{2cm}}$.

Solution: $W = \{2\lambda_0 \sum_{i=1}^n X_i > \chi_{1-\alpha}^2(2n)\}$.

10. (暂无题目, 有回忆者可以联系大师兄)

二、计算与分析题

1. 放开管控前, 检测呈阳性的人中大多有发烧症状, 而放开管控后检测呈阳性的人中大多无发烧症状. 已知管控前检测呈阳性且有发烧症状的概率为万分之一, 管控后检测呈阳性且有发烧症状的概率为百分之一. 试解释上述情况.

Solution: 设 A_1, A_2 分别表示放开管控前后有发烧, B_1, B_2 分别表示放开管控前后检测呈现阳性.

由题意, 显然放开管控后呈现阳性的概率要高于管控前, 有 $P(B_1) < P(B_2)$. 且有 $P(A_1 B_1) > P(A_2 B_2)$.

由条件概率公式我们知道

$$P(A_1|B_1) = \frac{P(A_1 B_1)}{P(B_1)} > \frac{P(A_2 B_2)}{P(B_2)} = P(A_2|B_2).$$

这解释了为什么放开管控前检测阳性的人大多有发烧症状.

2. 已知 $P(X=0) = \theta/4, P(X=1) = 1-\theta, P(X=2) = 3\theta/4$.

(1) 求 θ 的矩估计 $\hat{\theta}_M$ 和 MLE $\hat{\theta}_{MLE}$.

(2) 请问以上估计是无偏估计吗? 如果是的话, 请说明理由; 如果不是的话, 请说明理由并修正.

(3) 请问修正之后哪个估计更加有效.

Solution: (1) $E(X) = 1 + \theta/2$, 从而 $\hat{\theta}_M = 2 - 2\bar{X}$. 而似然函数为

$$L(\theta) = C_1 \theta^{n - \sum_{i=1}^n I(X_i=1)} (1-\theta)^{\sum_{i=1}^n I(X_i=1)}$$
$$l(\theta) = \log L(\theta) = C_2 + \left(n - \sum_{i=1}^n I(X_i=1)\right) \log \theta + \sum_{i=1}^n I(X_i=1) \log(1-\theta)$$

求导并令其为 0, 有

$$l'(\theta) = \frac{n - \sum_{i=1}^n I(X_i=1)}{\theta} - \frac{\sum_{i=1}^n I(X_i=1)}{1-\theta} = 0.$$

故 $\hat{\theta}_{MLE} = 1 - \frac{1}{n} \sum_{i=1}^n I(X_i=1)$.

(2) $E(\hat{\theta}_M) = \theta, E(\hat{\theta}_{MLE}) = 1 - P(X_i=1) = \theta$, 均为无偏估计.

(3) 直接计算有

$$\text{Var}(\hat{\theta}_M) = \frac{4}{n} \text{Var}(X_i) = \frac{6\theta}{n}$$
$$\text{Var}(\hat{\theta}_{MLE}) = \frac{\theta(1-\theta)}{n} < \frac{6\theta}{n} = \text{Var}(\hat{\theta}_M)$$

故 $\hat{\theta}_{MLE}$ 更有效.

3. 经调查, 健康成年男子脉搏服从正态分布 $N(72, 11^2)$, 现测得 16 位成年男子慢性铅中毒患者脉搏平均为 67, 标准差为 7. 请问在 0.05 置信水平下与正常男子脉搏是否有差异 (对均值和方差进行检验). 已知 $t_{0.025}(15) = 2.131, t_{0.05}(16) = 1.753, \chi_{0.975}^2(15) = 6.262, \chi_{0.025}^2(15) = 27.488$.

Solution: 假设成年男子慢性铅中毒患者脉搏服从正态分布 $N(\mu, \sigma^2)$.

首先检验方差

$$H_0: \sigma = 10 \text{ v.s. } H_1: \sigma \neq 10.$$

卡方统计量为

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(15).$$

从而拒绝域为 $W = \{\chi^2 > \chi_{0.025}^2(15) = 27.488\} \cup \{\chi^2 < \chi_{0.975}^2(15) = 6.262\}$.

而 $\chi^2 = 6.07 < 6.262$, 故拒绝原假设, 我们认为方差有差异.

之后再检验均值, 由于方差有差异, 因此我们采用方差未知的 t 检验.

检验统计量为

$$t = \frac{\sqrt{n}(\bar{X} - \mu)}{s} \sim t(n-1).$$

从而拒绝域为 $W = \{|t| > t_{0.025}(15) = 2.131\}$.

而 $|t| = 2.857 > 2.131$, 故拒绝原假设, 我们认为均值有差异.

4. 4 行 3 列的列联表齐性检验.

Solution: 见韦来生 6.5 节, 方法同独立性检验, 注意自由度.

5. $\{X_i\}_{i=1}^n$ 为 μ 的测量值, 测量的方差为 σ^2 .

(1) 建立关于 μ 的线性回归模型;

(2) 求 μ 的估计 $\hat{\mu}$, $\hat{\mu}$ 有什么样的优良性质;

(3) 若随机误差服从 $N(0, \sigma^2)$, 求 μ 的置信水平 $1 - \alpha$ 的置信区间.

Solution: (1) $X_i = \mu + \epsilon_i$, 其中 $E(\epsilon_i|X_i) = 0, \text{Var}(\epsilon_i|X_i) = \sigma^2$.

(2) $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i, \hat{\mu} \xrightarrow{a.s.} \mu$.

(3)

$$\left[\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

中国科学技术大学-432 统计学-2025 年

一、填空题 1. A 发生的概率为 p , B 发生的概率为 q , A, B 为两个基本事件, 且 $p + q \leq 1$, 求 A 先于 B 发生的概率. (6 分)

Solution:

$$P(AB) = \sum_{i=0}^{\infty} (1-p-q)^i p = \frac{p}{p+q}$$

2. X, Y, Z 为相互独立的标准正态分布, 且相互独立, 求 $E(X+Y|X+Y+Z)$. (6 分)

Solution:

第一种方法运用正态分布的条件分布。第二种方法运用对称轮换性, 注意到:

$$E(Z|X+Y+Z) = E(Y|X+Y+Z) = E(X|X+Y+Z)$$

而:

$$E(X+Y+Z|X+Y+Z) = X+Y+Z$$

所以:

$$E(X+Y|X+Y+Z) = \frac{2}{3}(X+Y+Z)$$

3. $\frac{a(X_1+X_2)}{\sqrt{X_3^2+X_4^2+X_5^2}}$ 服从 t 分布, 且 $X_i \sim N(0, \sigma^2), iid$, 求 a . (6 分)

Solution:

凑就完啦! 有点小坑, 因为负的也行, t 分布的对称性, $a = \pm\sqrt{\frac{3}{2}}$

4. $(X, Y) \sim N(0, 0, 1, 4, -0.5)$, 求 $Z = aX + (1-a)Y$ 的方差最小时, a 的取值. (6 分)

Solution:

算就完啦! $a = \frac{5}{7}$

5. $X \sim \text{Poisson}(3)$, 求 $P(\sqrt{n}\bar{X} \leq 3(\sqrt{n}+1))$ (用标准正态分布函数表示) (6 分)

Solution:

做就完啦! $\Phi(\sqrt{3})$

二、选择题

6. α 是显著性水平, p 是 p 值, 则 () (6 分)

A. p 小于 α 应拒绝原假设。

B. p 值与 α 有关

C. p 值与原假设无关。

D. p 值与备择假设无关。

Solution:

p 值是在给定原假设的时候计算, 而 p 值极端的方向的衡量是由备择假设决定的。

7. $\bar{X}$ 是 $N(u, \sigma^2)$ 的样本均值, S^2 是样本方差, 则 () (6 分)

A. s 为 σ 的无偏估计。

B. s 为 σ 的 MLE。

C. $\bar{X}$ 与 S 独立。

D. $\frac{nS^2}{\sigma^2} \sim \chi_n^2$

Solution:

B. $\frac{n-1}{n}S^2$ 才是 σ^2 的 MLE

C. 由 fisher 引理, 易知

8. $F(X)$ 是分布函数, 则下面 () 可能不是分布函数 (6 分)

- A. $(F(X))^2$
- B. $F(X) - (1 - F(X))\ln(1 - F(X))$
- C.
- D. $2(F(X))^2 - F(X)$

Solution:

D. 在 $[0, 1]$ 上都不是单增的

9. $\theta \sim U(0, \pi), X = \cos\theta, Y = \sin\theta$, 则 X, Y (): (6 分)

- A. 不独立, 不相关。
- B. 独立, 不相关。
- C. 不独立, 相关。
- D.

Solution:

独立性很好验证:

$$P(X \in [\frac{\sqrt{2}}{2}, 1], Y \in [\frac{\sqrt{2}}{2}, 1]) = 0$$
$$P(X \in [\frac{\sqrt{2}}{2}, 1]) \neq 0, P(Y \in [\frac{\sqrt{2}}{2}, 1]) \neq 0$$

不相关性由对称性很容易计算。

10. u 置信区间 (95%) 为 $[0.25, 0.95], X \sim N(u, 1)$, 求 $P(X \leq 0)$ 相同置信度的区间 (6 分)

- A. $[\Phi(0.25), \Phi(0.95)]$
- B. $[1 - \Phi(0.95), 1 - \Phi(0.25)]$
- C. $[0.25, 0.95]$
- D.

Solution:

我们有:

$$P(X \leq 0) = P(X - u \leq -u) = \Phi(-u)$$

因为 Φ 为严格单增函数, 所以我们有 $\Phi(-u)$ 的置信区间为:

$$[\Phi(-0.95), \Phi(-0.25)]$$

三、计算题

11. $f(x, y) = \frac{1}{2}(x + y)e^{-(x+y)}, x, y > 0$.

- (1) X, Y 同分布吗, 独立吗. (5 分)
- (2) 求 $f_X(x|Y)$ (5 分)
- (3) $Z = X + Y$, 求 $f_Z(z)$ (5 分)

Solution:

(1) 由对称轮换性, 我们显然可以看出来 X, Y 是同分布的。对于 X 的分布:

$$f_X(x) = \int_0^{+\infty} \frac{1}{2}(x + y)e^{-(x+y)} dy = \frac{1}{2}xe^{-x} + \frac{1}{2}e^{-x}, x > 0$$

所以 X, Y 并不相互独立。

(2)

$$f_X(x|Y) = \frac{f(x, Y)}{f_Y(Y)}$$
$$= \frac{(x + Y)e^{-x}}{Y + 1}$$

(3)

$$f_Z(z) = \int_0^z \frac{1}{2} z e^{-z} dx = \frac{1}{2} z^2 e^{-z}, z > 0$$

12. X_1, X_2, X_3 为 $U(0, 1)$ 三个统计量.

(1) 求 $P(X_1 = X_{(1)}, X_2 = X_{(2)}, X_3 = X_{(3)})$ (2 分)

(2) 求 $f_{X_{(2)}}(x_{(2)})$ (3 分)

(3) $Y = -\ln(X_{(3)})$, 求其分布 (5 分)

(4) $E(X_{(3)} - X_{(1)})$ (5 分)

Solution:

(1) 由对称轮换性, 我们知道:

$$P(X_1 = X_{(1)}, X_2 = X_{(2)}, X_3 = X_{(3)}) = \frac{1}{3!}$$

(2)

$$f_{X_{(2)}}(x_{(2)}) = 6x_{(2)}(1 - x_{(2)}), 0 < x_{(2)} < 1$$

(3)

$$f_{X_{(3)}}(x_{(3)}) = 3x_{(3)}^2, 0 < x_{(3)} < 1$$

$$f_Y(y) = f_{X_{(3)}}(e^{-y}) \left| \frac{dx_{(3)}}{dy} \right| = 3e^{-3y}$$

(4) 我们知道 $X_{(1)} \sim \text{beta}(1, 3), X_{(3)} \sim \text{beta}(3, 1)$

$$E(X_{(3)} - X_{(1)}) = \frac{3}{4} - \frac{1}{4} = \frac{1}{2}$$

13. $f(x) = -\theta^x \ln \theta, \theta \in (0, 1), X_1, \dots, X_n$ 为样本。

(1) 求 θ 的矩估计。(5 分)

(2) $\frac{1}{\ln \theta}$ 的 MLE 估计 $\hat{\theta}$ 。(5 分)

(3) 若 $\lim_{n \rightarrow \infty} P\left(\frac{\sqrt{n}(\hat{\theta} - a)}{\sqrt{b}} \leq x\right) = \Phi(x)$, 求 a, b 。(5 分)

Solution:

注意到 $f(x) = (-\ln \theta)e^{-(\ln \theta)x}$, 所以 $X \sim \text{Exp}(-\ln \theta)$

(1)

$$E(X) = \frac{1}{-\ln \theta}$$

所以

$$\hat{\theta}_m = e^{-\frac{1}{\bar{x}}}$$

(2) 我们知道 $-\ln \theta$ 的 MLE 是 $\frac{1}{\bar{X}}$, 所以由 MLE 的不变性, 我们有:

$$\hat{\theta} = -\bar{X}$$

(3) 由中心极限定理我们有:

$$\frac{\sqrt{n}(-\bar{X} + \frac{1}{\ln \theta})}{\sqrt{(\frac{1}{\ln \theta})^2}} \xrightarrow{d} N(0, 1)$$

所以有 $a = \frac{1}{\ln \theta}, b = (\frac{1}{\ln \theta})^2$

14. $X_1, X_2, \dots, X_{100} \sim N(u, 1)$

(1) $H_0: u = 0 \Leftrightarrow H_1: u \neq 0$, 求拒绝域, 显著水平为 0.05。(7 分)

(2) 若真实值为 0.4, 求检验功效 (保留两位小数). $(\Phi(1.645) = 0.95, \Phi(1.96) = 0.975, \Phi(2.04) = 0.98)$ (8 分)

Solution:

(1)

$$T = \frac{\bar{X} - u}{\sqrt{\frac{1}{100}}} \sim N(0, 1)$$

所以其拒绝域为:

$$W = \{\bar{X} \leq -0.196, \bar{X} \geq 0.196\}$$

(2) 功效函数为:

$$\begin{aligned} g(0.4) &= P_u(\bar{X} \in W) \\ &= 1 - \Phi(5.96) + \Phi(2.04) \\ &= 0.98 \end{aligned}$$

15. 有一家公司, 其提供的信息是他的产品中会随机含有 6 种糖中的一种, 出现概率为:A:0.2, B:0.2, C:0.2, D:0.15, E:0.15, F:0.10. 买了 1000 粒, 经过统计得到含各种糖的个数为:A:180, B:190, C:185, D:165, E:160, F:120. 问信息是否准确。(15 分)

Solution:

拟合优度检验

$$K = \frac{400}{200} + \frac{100}{200} + \frac{225}{200} + \frac{225}{150} + \frac{100}{150} + \frac{400}{100} = 9.792 \leq \chi_5^2(0.975)$$

所以在显著水平 $\alpha = 0.25$ 时, 会认为信息是准确的。

16. $y = X\beta + \epsilon, \epsilon \sim N(0, \sigma^2 I_n)$, X 为设计矩阵。

(1) OLS 与 MSE 是否一样, 说明理由。(7 分)

(2) X_0 是新得到的, $y_0 = X_0^T \beta + \epsilon_0, \epsilon_0$ 与 ϵ 独立, 预测值 $\hat{y}_0 = X_0^T \hat{\beta}$, 问预测值的均方误差。(8 分)

Solution:

(1) 在当前条件下, MLE 与 OLS 求得的 β 是一样的, 因为二者的核心都是最小化 $(y - X\beta)^T(y - X\beta)$ 。

(2) 根据多元回归的结论, 我们有

$$\hat{\beta} = (X^T X)^{-1} X^T Y \sim N(\beta, \sigma^2 (X^T X)^{-1}),$$

这个 $\hat{\beta}$ 是由旧数据估计的, 而 X_0 是新得到的, 他们独立, 因此

$$E(X_0^T \hat{\beta} - y_0)^2 = \text{Var}(X_0^T \hat{\beta}) + E(\epsilon_0)^2 = \sigma^2 (1 + X_0^T (X^T X)^{-1} X_0).$$

中国科学技术大学-432 统计学-2026 年

第一部分 选择题 (共 5 题)

一、计算 10 个骰子的点数之和能被 6 整除的概率。

- A. $1/6$
- B. $1/3$
- C. $1/2$
- D. $1/12$

Solution: A.

记 X_i 为第 i 个骰子的点数 ($i = 1, \dots, 10$), $S_{10} = \sum_{i=1}^{10} X_i$ 为总点数。考察 S_{10} 在模 6 意义下的分布。对于单个骰子 X_i , 其点数在模 6 剩余系 $\{0, 1, 2, 3, 4, 5\}$ 上服从均匀分布:

$$P(X_i \equiv k \pmod{6}) = \frac{1}{6}, \quad k \in \{0, 1, \dots, 5\}$$

设 $S_n = \sum_{i=1}^n X_i$ 。利用数学归纳法考察 S_n 的分布。当 $n = 1$ 时, 上述均匀分布性质显然成立。假设 S_{n-1} 在模 6 下服从均匀分布, 即 $P(S_{n-1} \equiv j) = \frac{1}{6}$ 。由递推关系 $S_n = S_{n-1} + X_n$, 利用全概率公式计算 $S_n \equiv r \pmod{6}$ 的概率:

$$\begin{aligned} P(S_n \equiv r) &= \sum_{k=0}^5 P(S_{n-1} \equiv k) \cdot P(X_n \equiv r - k) \\ &= \sum_{k=0}^5 \frac{1}{6} \cdot \frac{1}{6} \\ &= 6 \times \frac{1}{36} \\ &= \frac{1}{6} \end{aligned}$$

由此可知, 对于任意 $n \geq 1$, 骰子点数之和模 6 恒服从均匀分布。故当 $n = 10$ 时, 点数之和被 6 整除的概率为:

$$P(S_{10} \equiv 0 \pmod{6}) = \frac{1}{6}$$

Remark: 思考: 若十个骰子中只有一枚均匀, 结果如何?

我们可以将前 9 个骰子的点数之和视为一个整体, 记为 S_9 。无论 S_9 的概率分布如何复杂 (若均匀, 则其本质上是一个中间高、两边低的多项式系数分布), 它必然取某个整数值 k 。考察总和 $S_{10} = S_9 + X_{10}$ 。我们在给定 $S_9 = k$ 的条件下分析 S_{10} 模 6 的分布:

$$P(S_{10} \equiv r \mid S_9 = k) = P(k + X_{10} \equiv r \pmod{6}) = P(X_{10} \equiv r - k \pmod{6})$$

因此:

$$P(S_{10} \equiv r \mid S_9 = k) = \frac{1}{6}$$

利用全概率公式, 对 S_9 的所有可能取值 k 进行加权求和:

$$P(S_{10} \equiv r) = \sum_k P(S_{10} \equiv r \mid S_9 = k) \cdot P(S_9 = k) = \frac{1}{6} \sum_k P(S_9 = k) = \frac{1}{6} \cdot 1 = \frac{1}{6}$$

这一视角揭示了一个更本质的结论: 在有限群上的卷积运算中, 只要参与求和的独立变量中至少有一个服从均匀分布, 其总和必然服从均匀分布。这相当于其中一个变量的“均匀性”将整个和的分布“抹平”了。

二、已知 x, y 为常数, X, Y 独立, 下面不一定成立的是:

A. 若 $P(Y = y) > 0$, 则 $P(X \geq x | Y = y) = P(X \geq x)$

B. X^2 与 Y^2 独立

C. $\{X = x\}$ 与 $\{Y = y\}$ 独立

D. (空缺, 暂无人回忆)

Solution:

由于题目要求选出不一定成立的一项, 我们依次分析 A、B、C 三个选项的正确性。已知条件: X, Y 相互独立, x, y 为常数。

选项 A 考察条件概率的定义。已知前提 $P(Y = y) > 0$, 则有:

$$P(X \geq x | Y = y) = \frac{P(X \geq x, Y = y)}{P(Y = y)}$$

由 X 与 Y 的独立, 知 $P(X \geq x, Y = y) = P(X \geq x)P(Y = y)$ 。代入上式分子:

$$\text{右边} = \frac{P(X \geq x)P(Y = y)}{P(Y = y)} = P(X \geq x)$$

该等式恒成立, A 必然成立。

选项 B 根据概率论定理: 若随机变量 X 与 Y 相互独立, 则它们的 Borel 函数 $g(X)$ 与 $h(Y)$ 也相互独立。取 $g(X) = X^2$, $h(Y) = Y^2$, 则 X^2 与 Y^2 必然独立。B 必然成立。

选项 C 考察具体事件的独立性。随机变量 X, Y 独立的定义即为: 对于任意 Borel 集 A, B , 事件 $\{X \in A\}$ 与 $\{Y \in B\}$ 相互独立。取单点集 $A = \{x\}$, $B = \{y\}$, 则事件 $\{X = x\}$ 与 $\{Y = y\}$ 必然独立, 即 $P(X = x, Y = y) = P(X = x)P(Y = y)$ 。C 必然成立。

由于 A、B、C 三项均由独立性的定义或性质直接推导得出, 属于必然成立的命题。因此, 题目中“不一定成立”的选项只能是缺失的 D 选项。

三、设 $X_1, X_2, \dots, X_n$ 独立同分布 (i.i.d.), 且服从参数为 λ 的泊松分布 $P(\lambda)$ 。当 $n \rightarrow \infty$ 时, $\frac{1}{n} \sum_{i=1}^n X_i^2$ 趋近于 $\quad$ 。

A. λ

B. 2λ

C. $\lambda + \lambda^2$

D. λ^2

Solution:

答案: C 已知 $X_i \sim P(\lambda)$, 则其期望和方差分别为:

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda$$

故:

$$E[X^2] = \text{Var}(X) + (E[X])^2 = \lambda + \lambda^2$$

由辛钦大数定律:

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E[X^2], \quad (n \rightarrow \infty)$$

因此, 当 $n \rightarrow \infty$ 时, $\frac{1}{n} \sum_{i=1}^n X_i^2$ 趋近于 $\lambda + \lambda^2$ 。故选 C。

四、车间抽取 $x_1, x_2, \dots, x_9$ 共 9 个样本。已知样本均值 $\bar{x} = 40$, 样本方差 $s^2 = 1$ 。总体服从正态分布 $N(\mu, \sigma^2)$ 。求 μ 的置信区间长度 (给定上分位数), 置信水平为 0.9 (题目中写作 $\alpha = 0.9$)。

A. $2t_{0.1}(8)$

- B. $2t_{0.05}(8)$
 C. $\frac{2}{3}t_{0.05}(8)$
 D. $\frac{2}{3}t_{0.1}(8)$

Solution:

答案: C

由于总体方差 σ^2 未知, 且样本来自正态分布, 我们需要使用 t 分布来构造均值 μ 的置信区间。自由度 $df = n - 1 = 9 - 1 = 8$ 。

μ 的双侧置信区间长度公式为:

$$L = 2 \times t_{\alpha/2}(n-1) \times \frac{s}{\sqrt{n}}$$

代入样本量 $n = 9$, 样本标准差 $s = \sqrt{s^2} = \sqrt{1} = 1$, 分位数 $t_{\alpha/2}(n-1) = t_{0.05}(8)$ 。得:

$$L = 2 \times t_{0.05}(8) \times \frac{1}{3} = \frac{2}{3}t_{0.05}(8)$$

五、下面不一定成立的是:

- A. 若 $\hat{\theta}$ 是 μ 的无偏估计, 则 $\hat{\theta}^2$ 也是 μ^2 的无偏估计
 B. 若 $\hat{\theta}$ 是 μ 渐近估计, 则 $\hat{\theta}^2$ 也是 μ^2 的渐近估计
 C. 若 $\hat{\theta}$ 是 μ 矩估计, 则 $\hat{\theta}^2$ 也是 μ^2 的矩估计
 D. 若 $\hat{\theta}$ 是 μ 最大似然估计, 则 $\hat{\theta}^2$ 也是 μ^2 的最大似然估计

Solution: 选 A

选项 A (不一定成立): 无偏性不满足非线性变换的不变性。已知 $\hat{\theta}$ 是 μ 的无偏估计, 即 $E[\hat{\theta}] = \mu$ 。考察 $\hat{\theta}^2$ 的期望:

$$E[\hat{\theta}^2] = \text{Var}(\hat{\theta}) + (E[\hat{\theta}])^2 = \text{Var}(\hat{\theta}) + \mu^2$$

只要估计量的方差 $\text{Var}(\hat{\theta}) > 0$, 则:

$$E[\hat{\theta}^2] > \mu^2$$

选项 B (成立): 若 $\hat{\theta}$ 是 θ 的相合估计, 且 $g(\cdot)$ 为连续函数, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的相合估计 (由 Slutsky 定理或连续映射定理保证)。

选项 C (成立): 矩估计通常基于“替换原理”, 具有不变性。若 $\hat{\theta}$ 是 θ 的矩估计, 则 $g(\hat{\theta})$ 也就是 $g(\theta)$ 的矩估计。

选项 D (成立): 极大似然估计 (MLE) 具有严格的不变性原理。若 $\hat{\theta}$ 是 θ 的极大似然估计, 则对于任意函数 $g(\theta)$, 其极大似然估计即为 $g(\hat{\theta})$ 。

第二部分 填空题 (共 5 题)

一、设二维随机向量

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} 1 \\ 2 \end{pmatrix}, \begin{pmatrix} 4 & 0 \\ 0 & 9 \end{pmatrix} \right)$$

求 $E(3X^2 + XY + Y^2)$ 。

Solution:

根据二维正态分布的参数定义:

$$E[X] = 1, \quad \text{Var}(X) = 4$$

$$E[Y] = 2, \quad \text{Var}(Y) = 9$$

由于协方差矩阵是对角矩阵, 协方差 $Cov(X, Y) = 0$, 即 X 与 Y 相互独立。

$$E[X^2] = 4 + 1^2 = 5$$

$$E[Y^2] = 9 + 2^2 = 13$$

由于 X, Y 相互独立:

$$E[XY] = E[X]E[Y] = 1 \times 2 = 2$$

利用期望的线性性质:

$$\begin{aligned} E(3X^2 + XY + Y^2) &= 3E[X^2] + E[XY] + E[Y^2] \\ &= 3 \times 5 + 2 + 13 \\ &= 15 + 2 + 13 \\ &= 30 \end{aligned}$$

二、已知点 $A(1, 0)$ 位于以原点为圆心、半径 $R = 1$ 的圆上。现有一条直线随机 (构成弦的两个端点 P_1, P_2 是独立地、均匀地分布在圆周上的) 将圆分成两部分, 求包含点 A 的那一部分圆弧长度的数学期望。

Solution:

设圆周长为 $C = 2\pi R = 2\pi$ 。点 A, P_1, P_2 三点将圆周分割为三段互斥的弧, 记其长度分别为 l_1, l_2, l_3 。由圆周均匀分布的对称性可知, 这三段弧长度的期望相等, 即:

$$E[l_1] = E[l_2] = E[l_3] = \frac{1}{3}E[l_1 + l_2 + l_3] = \frac{C}{3} = \frac{2\pi}{3}$$

记 L_{out} 为不包含点 A 的弧长 (即 P_1, P_2 之间未经过 A 的弧), L_{in} 为包含点 A 的弧长。由几何结构可知, L_{out} 在分布上等同于上述三段弧中的任意一段, 故:

$$E[L_{out}] = \frac{2\pi}{3}$$

由弧长互补关系 $L_{in} + L_{out} = C$, 利用期望的线性性质得:

$$E[L_{in}] = E[C - L_{out}] = 2\pi - E[L_{out}] = 2\pi - \frac{2\pi}{3} = \frac{4\pi}{3}$$

三、设总体 $X \sim N(\mu, \sigma^2)$, $X_1, X_2, \dots, X_n, X_{n+1}$ 为来自该总体的独立样本, 记 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。若统计量

$$\frac{\bar{X}_n - X_{n+1}}{\sqrt{b \sum_{i=1}^n X_i^2 + c \bar{X}_n^2}}$$

服从 t 分布, 求常数 b 和 c 。

Solution:

考虑分子 $\bar{X}_n - X_{n+1}$ 。由于 $X_i \sim N(\mu, \sigma^2)$ 且相互独立, 该线性组合的期望为:

$$E[\bar{X}_n - X_{n+1}] = \mu - \mu = 0$$

方差为:

$$Var(\bar{X}_n - X_{n+1}) = Var(\bar{X}_n) + Var(X_{n+1}) = \frac{\sigma^2}{n} + \sigma^2 = \sigma^2 \left(1 + \frac{1}{n}\right)$$

将其标准化可得随机变量 Z :

$$Z = \frac{\bar{X}_n - X_{n+1}}{\sigma \sqrt{\frac{n+1}{n}}} \sim N(0, 1)$$

利用前 n 个样本构造 χ^2 统计量。根据 Fisher 引理，下述统计量 V 服从自由度为 $n-1$ 的 χ^2 分布，且与 $\bar{X}_n$ （进而与 X_{n+1} 及分子）相互独立：

$$S = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{\sigma^2} \sim \chi^2(n-1)$$

根据 t 分布定义 $T = \frac{Z}{\sqrt{S/(n-1)}}$ ，构造统计量并化简：

$$\begin{aligned} T &= \frac{\frac{\bar{X}_n - X_{n+1}}{\sigma \sqrt{\frac{n+1}{n}}}}{\sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{\sigma^2(n-1)}}} \\ &= \frac{\bar{X}_n - X_{n+1}}{\sqrt{\frac{n+1}{n(n-1)} \sum_{i=1}^n (X_i - \bar{X}_n)^2}} \end{aligned}$$

我们将分母根号内的求和项展开，利用恒等式 $\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^n X_i^2 - n\bar{X}_n^2$ ，代入分母中：

$$\begin{aligned} \text{分母根号内} &= \frac{n+1}{n(n-1)} \left(\sum_{i=1}^n X_i^2 - n\bar{X}_n^2 \right) \\ &= \frac{n+1}{n(n-1)} \sum_{i=1}^n X_i^2 - \frac{n(n+1)}{n(n-1)} \bar{X}_n^2 \\ &= \frac{n+1}{n(n-1)} \sum_{i=1}^n X_i^2 - \frac{n+1}{n-1} \bar{X}_n^2 \end{aligned}$$

对比题目给出的形式 $b \sum_{i=1}^n X_i^2 + c \bar{X}_n^2$ ，可得常数：

$$b = \frac{n+1}{n(n-1)}, \quad c = -\frac{n+1}{n-1}$$

四、设离散型随机变量的分布律如下表所示：

X	1	2	3
P	θ	2θ	$1-3\theta$

现进行假设检验：

$$H_0: \theta = 1 \leftrightarrow H_1: 0 < \theta < 1$$

拒绝域为 $W = \{(x_1, x_2, x_3) \mid x_1, x_2, x_3 \leq 2\}$ ，求：犯第二类错误的概率（表示为 θ 的函数）。

Solution:

（注：题目中 H_0 的 $\theta = 1$ 时 X 不是一个合法的一个随机变量，仅作为假设形式，实际计算关注备择假设 H_1 下的分布）

首先计算单个样本落在区间 $[1, 2]$ 内的概率：

$$P(X \leq 2) = P(X = 1) + P(X = 2) = \theta + 2\theta = 3\theta$$

由于样本 X_1, X_2, X_3 是独立同分布的 (i.i.d)，三个样本同时满足 ≤ 2 的概率为：

$$P(W) = P(X_1 \leq 2, X_2 \leq 2, X_3 \leq 2) = P(X_1 \leq 2) \cdot P(X_2 \leq 2) \cdot P(X_3 \leq 2)$$

代入 3θ ：

$$P(W) = (3\theta) \times (3\theta) \times (3\theta) = 27\theta^3$$

第二类错误 β 的定义是：当备择假设 H_1 为真时，未能落入拒绝域（即接受原假设）的概率。

$$\beta(\theta) = 1 - P(\text{拒绝 } H_0 \mid \theta) = 1 - P(W)$$

将 $P(W) = 27\theta^3$ 代入：

$$\beta(\theta) = 1 - 27\theta^3$$

第三部分 简答题（共 5 题）

一、已知：

$$Y \mid X = x_0 \sim U(x_0, 1)$$

$$f_X(x) = 2(1-x), \quad 0 < x < 1$$

求：

- (1) 联合概率密度 $f(x, y)$;
- (3) 条件期望 $E(XY \mid X = x_0)$;
- (4) 协方差 $Cov(X, Y)$ 。

Solution:

(1)

已知 Y 的条件分布为均匀分布 $U(x, 1)$ ，其条件密度为：

$$f_{Y|X}(y|x) = \frac{1}{1-x}, \quad x < y < 1$$

根据乘法公式 $f(x, y) = f_{Y|X}(y|x) \cdot f_X(x)$ ，得：

$$f(x, y) = \frac{1}{1-x} \cdot 2(1-x) = 2$$

结合变量取值范围 $0 < x < 1$ 且 $x < y < 1$ （即 $0 < x < y < 1$ ），联合概率密度为：

$$f(x, y) = \begin{cases} 2, & 0 < x < y < 1 \\ 0, & \text{其他} \end{cases}$$

(3) 在条件 $X = x_0$ 下， X 可视为常数提取出来：

$$E(XY \mid X = x_0) = x_0 \cdot E(Y \mid X = x_0)$$

由于 $Y \mid X = x_0 \sim U(x_0, 1)$ ，均匀分布的期望为区间端点之和的一半：

$$E(Y \mid X = x_0) = \frac{x_0 + 1}{2}$$

代入得：

$$E(XY \mid X = x_0) = x_0 \left(\frac{1 + x_0}{2} \right) = \frac{x_0 + x_0^2}{2}$$

(4) 协方差计算公式为： $Cov(X, Y) = E(XY) - E(X)E(Y)$ 。

$$E(X) = \int_0^1 x \cdot f_X(x) dx = \int_0^1 x \cdot 2(1-x) dx = 2 \left[\frac{x^2}{2} - \frac{x^3}{3} \right]_0^1 = 2 \left(\frac{1}{2} - \frac{1}{3} \right) = \frac{1}{3}$$

利用全期望公式 $E(Y) = E[E(Y|X)]$:

$$E(Y) = E\left[\frac{X+1}{2}\right] = \frac{1}{2}E(X) + \frac{1}{2} = \frac{1}{2} \cdot \frac{1}{3} + \frac{1}{2} = \frac{2}{3}$$

利用全期望公式 $E(XY) = E[E(XY|X)]$, 结合第 (3) 问的结果:

$$E(XY) = E\left[\frac{X+X^2}{2}\right] = \frac{1}{2}[E(X) + E(X^2)]$$

$$E(X^2) = \int_0^1 x^2 \cdot 2(1-x) dx = 2 \left[\frac{x^3}{3} - \frac{x^4}{4} \right]_0^1 = 2 \left(\frac{1}{3} - \frac{1}{4} \right) = 2 \cdot \frac{1}{12} = \frac{1}{6}$$

代回求 $E(XY)$:

$$E(XY) = \frac{1}{2} \left(\frac{1}{3} + \frac{1}{6} \right) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$$

因此,

$$\text{Cov}(X, Y) = \frac{1}{4} - \frac{1}{3} \cdot \frac{2}{3} = \frac{1}{4} - \frac{2}{9} = \frac{9-8}{36} = \frac{1}{36}$$

二、设总体 X 的概率密度函数为:

$$f(x) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$$

其中 $\theta > 0$ 为未知参数。 $X_1, X_2, \dots, X_n$ 为来自该总体的简单随机样本。

(1) 求 θ 的矩估计 $\hat{\theta}_L$ 和最大似然估计 $\hat{\theta}_M$ 。

(2) 证明 $\frac{1}{\hat{\theta}_M}$ 是 $\frac{1}{\theta}$ 的无偏估计。

(3) 证明 $\frac{1}{\hat{\theta}_M}$ 具有正态渐近性。

Solution:

(1) 首先计算总体的数学期望 $E(X)$:

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx = \int_0^1 x \cdot \theta x^{\theta-1} dx = \theta \int_0^1 x^\theta dx$$

积分得:

$$E(X) = \theta \left[\frac{x^{\theta+1}}{\theta+1} \right]_0^1 = \frac{\theta}{\theta+1}$$

令样本均值等于总体均值, 即 $\bar{X} = \frac{\theta}{\theta+1}$, 解关于 θ 的方程:

$$\bar{X}(\theta+1) = \theta \implies \bar{X} = \theta(1-\bar{X}) \implies \hat{\theta}_L = \frac{\bar{X}}{1-\bar{X}}$$

下面求最大似然估计 $\hat{\theta}_M$

写出似然函数 $L(\theta)$:

$$L(\theta) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \theta x_i^{\theta-1} = \theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1}$$

取对数似然函数 $\ln L(\theta)$:

$$\ln L(\theta) = n \ln \theta + (\theta-1) \sum_{i=1}^n \ln x_i$$

对 θ 求导并令其为 0 (似然方程):

$$\frac{d \ln L}{d \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i = 0$$

解得极大似然估计:

$$\hat{\theta}_M = -\frac{n}{\sum_{i=1}^n \ln X_i}$$

(2) 令待估统计量为 $T = \frac{1}{\theta_M}$ 。根据 (1) 的结果:

$$T = \frac{1}{-\frac{n}{\sum \ln X_i}} = -\frac{1}{n} \sum_{i=1}^n \ln X_i$$

令 $Y_i = -\ln X_i$ 。我们需要先确定随机变量 Y_i 的分布。

$$\begin{aligned} P(Y_i \leq y) &= P(-\ln X_i \leq y) = P(\ln X_i \geq -y) = P(X_i \geq e^{-y}) \\ &= 1 - F_X(e^{-y}) = 1 - \int_0^{e^{-y}} \theta t^{\theta-1} dt \\ &= 1 - (e^{-y})^\theta = 1 - e^{-\theta y}, \quad (y > 0) \end{aligned}$$

可见, Y_i 服从参数为 θ 的指数分布, 即 $Y_i \sim \text{Exp}(\theta)$ 。由指数分布的性质知: $E(Y_i) = \frac{1}{\theta}$, $\text{Var}(Y_i) = \frac{1}{\theta^2}$ 。现在计算 T 的期望:

$$E[T] = E\left[\frac{1}{n} \sum_{i=1}^n Y_i\right] = \frac{1}{n} \sum_{i=1}^n E(Y_i) = \frac{1}{n} \cdot n \cdot \frac{1}{\theta} = \frac{1}{\theta}$$

(3) 由 (2) 可知, 统计量可以表示为独立同分布随机变量的均值:

$$\frac{1}{\hat{\theta}_M} = \frac{1}{n} \sum_{i=1}^n Y_i = \bar{Y}$$

其中 $Y_i = -\ln X_i$ 独立同分布, 且均值 $E(Y_i) = \frac{1}{\theta}$ 和方差 $\text{Var}(Y_i) = \frac{1}{\theta^2}$ 均存在且有限。

根据 Lindeberg-Lévy 中心极限定理:

$$\sqrt{n}(\bar{Y} - E[Y]) \xrightarrow{d} N(0, \text{Var}(Y))$$

代入具体参数:

$$\sqrt{n}\left(\frac{1}{\hat{\theta}_M} - \frac{1}{\theta}\right) \xrightarrow{d} N\left(0, \frac{1}{\theta^2}\right)$$

即 $\frac{1}{\hat{\theta}_M}$ 渐近服从正态分布:

$$\frac{1}{\hat{\theta}_M} \sim AN\left(\frac{1}{\theta}, \frac{1}{n\theta^2}\right)$$

证毕。Remark: 另证:

总体 X 的对数似然函数 (针对单个样本) 为:

$$\ln f(x; \theta) = \ln(\theta x^{\theta-1}) = \ln \theta + (\theta - 1) \ln x$$

对 θ 求一阶导数:

$$\frac{\partial \ln f}{\partial \theta} = \frac{1}{\theta} + \ln x$$

对 θ 求二阶导数:

$$\frac{\partial^2 \ln f}{\partial \theta^2} = -\frac{1}{\theta^2}$$

Fisher 信息量 $I(\theta)$ 为:

$$I(\theta) = -E \left[\frac{\partial^2 \ln f}{\partial \theta^2} \right] = -E \left[-\frac{1}{\theta^2} \right] = \frac{1}{\theta^2}$$

由 MLE 的渐近正态性, 得:

$$\sqrt{n}(\hat{\theta}_M - \theta) \xrightarrow{d} N \left(0, \frac{1}{I(\theta)} \right)$$

代入 $I(\theta) = \frac{1}{\theta^2}$, 得:

$$\sqrt{n}(\hat{\theta}_M - \theta) \xrightarrow{d} N(0, \theta^2)$$

为了求 $\frac{1}{\hat{\theta}_M}$ 的渐近分布, 我们使用 Delta 方法。Delta 方法指出, 若 $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, \sigma^2)$, 则对于可微函数 $g(\cdot)$:

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{d} N \left(0, [g'(\theta)]^2 \cdot \sigma^2 \right)$$

在此题中: $g(\theta) = \theta^{-1}$ 导数 $g'(\theta) = -\theta^{-2} = -\frac{1}{\theta^2}$, 因此统计量 $\frac{1}{\hat{\theta}_M}$ 的渐近分布为:

$$\sqrt{n} \left(\frac{1}{\hat{\theta}_M} - \frac{1}{\theta} \right) \xrightarrow{d} N \left(0, \frac{1}{\theta^2} \right)$$

另外, 也可利用 MLE 不变性, 计算 $\frac{1}{\hat{\theta}}$ 的 Fisher 信息量求解

三、给定两个独立同分布 (i.i.d) 的随机变量 $X, Y \sim N(0, \sigma^2)$ 。定义两个新的随机变量:

$$U = \frac{X^2 + Y^2}{\sigma^2}, \quad V = \frac{|X|}{Y}$$

(1) 求 $f(|X|, Y)$, 即 $|X|$ 与 Y 的联合概率密度函数; (2) 求 $f(u, v)$, 即 U 与 V 的联合概率密度函数; (3) 判断变量 U 和 V 是否独立。

Solution:

(1) 已知 $X \sim N(0, \sigma^2)$, 其概率密度函数 (PDF) 为:

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

令 $Z = |X|$ 。当 $x \leq 0$ 时, $F_Z(x) = P(|X| \leq x) = 0$ 。当 $x > 0$ 时:

$$\begin{aligned} F_Z(x) &= P(|X| \leq x) \\ &= P(-x \leq X \leq x) \\ &= F_X(x) - F_X(-x) \end{aligned}$$

其中 $F_X(x)$ 为 X 的分布函数。对 x 求导得到概率密度函数 $f_Z(x)$:

$$\begin{aligned} f_Z(x) &= \frac{d}{dx} [F_X(x) - F_X(-x)] \\ &= f_X(x) - f_X(-x) \cdot (-1) \\ &= f_X(x) + f_X(-x) \end{aligned}$$

因此:

$$f_{|X|}(x) = \begin{cases} 2f_X(x) = \sqrt{\frac{2}{\pi}} \frac{1}{\sigma} e^{-\frac{x^2}{2\sigma^2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Y 的分布保持不变:

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{y^2}{2\sigma^2}}, \quad -\infty < y < \infty$$

因为 X 与 Y 相互独立, 所以 $|X|$ 与 Y 也相互独立。联合概率密度等于边缘概率密度的乘积:

$$\begin{aligned} f(|X|, Y)(x, y) &= f_{|X|}(x) \cdot f_Y(y) \\ &= \left(\sqrt{\frac{2}{\pi}} \frac{1}{\sigma} e^{-\frac{x^2}{2\sigma^2}} \right) \cdot \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{y^2}{2\sigma^2}} \right) \end{aligned}$$

整理得 (其中 $x > 0$):

$$f(|X|, Y)(x, y) = \frac{1}{\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}, \quad x > 0, -\infty < y < \infty$$

(2)

我们将通过变量变换法从 $(|X|, Y)$ 变换到 (U, V) 。

1. 建立变换关系令 $z = |X|$ (注意 $z > 0$), $y = Y$ 。

$$\begin{cases} u = \frac{z^2+y^2}{\sigma^2} \\ v = \frac{z}{y} \end{cases}$$

2. 求反变换由 $v = \frac{z}{y}$ 得 $z = vy$ 。代入 u 的表达式:

$$u = \frac{(vy)^2 + y^2}{\sigma^2} = \frac{y^2(v^2 + 1)}{\sigma^2}$$

解得 $y^2 = \frac{u\sigma^2}{1+v^2}$ 。由于 $z > 0$, 这意味着 v 和 y 必须同号 (因为 $z = vy$)。因此, 对于每一个 (u, v) ($u > 0, v \neq 0$), 在 (z, y) 平面 ($z > 0$) 上都有唯一确定的点与之对应。

计算 (u, v) 关于 (z, y) 的偏导数行列式 J^{-1} :

$$J^{-1} = \frac{\partial(u, v)}{\partial(z, y)} = \begin{vmatrix} \frac{\partial u}{\partial z} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial z} & \frac{\partial v}{\partial y} \end{vmatrix} = \begin{vmatrix} \frac{2z}{\sigma^2} & \frac{2y}{\sigma^2} \\ \frac{1}{y} & -\frac{z}{y^2} \end{vmatrix}$$

计算行列式的值:

$$\det(J^{-1}) = \frac{2z}{\sigma^2} \left(-\frac{z}{y^2} \right) - \frac{2y}{\sigma^2} \left(\frac{1}{y} \right) = -\frac{2}{\sigma^2} \left(\frac{z^2}{y^2} + 1 \right) = -\frac{2}{\sigma^2} (v^2 + 1)$$

我们需要的雅可比行列式 J 是其倒数的绝对值:

$$|J| = \left| \frac{1}{\det(J^{-1})} \right| = \frac{\sigma^2}{2(1+v^2)}$$

利用公式 $f_{U,V}(u, v) = f_{|X|,Y}(z, y) \cdot |J|$ 。

$$\begin{aligned} f_{U,V}(u, v) &= \left(\frac{1}{\pi\sigma^2} e^{-u/2} \right) \cdot \frac{\sigma^2}{2(1+v^2)} \\ &= \frac{1}{2\pi(1+v^2)} e^{-u/2} \end{aligned}$$

定义域为 $u > 0, -\infty < v < \infty$ 。

(3) 观察 $f(u, v)$ 的表达式, 可以分解为关于 u 的函数和关于 v 的函数的乘积:

$$f(u, v) = \underbrace{\left(\frac{1}{2} e^{-u/2} \right)}_{f_U(u)} \cdot \underbrace{\left(\frac{1}{\pi(1+v^2)} \right)}_{f_V(v)}$$

其中: * $f_U(u) = \frac{1}{2} e^{-u/2}$ ($u > 0$) 是参数为 $1/2$ 的指数分布 (或自由度为 2 的卡方分布)。* $f_V(v) = \frac{1}{\pi(1+v^2)}$ 是标准柯西分布。

由于联合概率密度函数可以分离变量, 故 U 和 V 相互独立。

四、检验“成绩分布”与“性别”是否存在相关性。

性别 \ 成绩分段	$x < 60$	$60 < x < 90$	$x > 90$
男	4	10	2
女	5	14	2

Solution:

H_0 : 成绩分布与性别相互独立 (即没有关系) vs H_1 : 成绩分布与性别不独立 (即有关系)

首先计算各行、各列的合计:

性别	< 60	60-90	> 90	合计
男	4	10	2	16
女	5	14	2	21
合计	9	24	4	总计 $n = 37$

根据独立性假设, 计算每个格子的期望频数 (E_{ij}), 公式为:

$$E_{ij} = \frac{\text{第 } i \text{ 行合计} \times \text{第 } j \text{ 列合计}}{\text{总计 } n}$$

具体计算如下: * 男, < 60: $E_{11} = \frac{16 \times 9}{37} \approx 3.89$ * 男, 60-90: $E_{12} = \frac{16 \times 24}{37} \approx 10.38$ * 男, > 90: $E_{13} = \frac{16 \times 4}{37} \approx 1.73$ * 女, < 60: $E_{21} = \frac{21 \times 9}{37} \approx 5.11$ * 女, 60-90: $E_{22} = \frac{21 \times 24}{37} \approx 13.62$ * 女, > 90: $E_{23} = \frac{21 \times 4}{37} \approx 2.27$

公式:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

代入数据逐项计算:

$$\begin{aligned} \chi^2 &\approx \frac{(4 - 3.89)^2}{3.89} + \frac{(10 - 10.38)^2}{10.38} + \frac{(2 - 1.73)^2}{1.73} \\ &\quad + \frac{(5 - 5.11)^2}{5.11} + \frac{(14 - 13.62)^2}{13.62} + \frac{(2 - 2.27)^2}{2.27} \\ &\approx 0.0031 + 0.0139 + 0.0421 \\ &\quad + 0.0024 + 0.0106 + 0.0321 \\ &\approx 0.104 \end{aligned}$$

自由度: $(-1) \times (-1) = (2-1) \times (3-1) = 2$ 。

设显著性水平为 α , 则只需比较 χ^2 与 $\chi_{\alpha}^2(2)$ 。若 $\chi^2 > \chi_{\alpha}^2(2)$, 则拒绝原假设。

五、已知线性模型: $y = X\beta + \epsilon$, 其中 $\epsilon \sim N(0, \sigma^2 I_n)$, X 为 $n \times p$ 设计矩阵。 $\hat{\beta} = (X^T X)^{-1} X^T y$ 。
令 $y_0 = x_0^T \beta + \epsilon_0$ 为对应于新解释变量 x_0 的新观测值, $\hat{y} = x_0^T \hat{\beta}$ 为其预测值。假设 ϵ_0 与 ϵ 相互独立, 且 $\epsilon_0 \sim N(0, \sigma^2)$ 。求:

(1) $Cov(\hat{\beta}, \epsilon_0)$;

(2) $E(\hat{y} - y_0)^2$ 。

Solution:

(1) 展开 $\hat{\beta}$:

$$\hat{\beta} = (X^T X)^{-1} X^T y = (X^T X)^{-1} X^T (X\beta + \epsilon) = \beta + (X^T X)^{-1} X^T \epsilon$$

由 $\hat{\beta}E[\epsilon \cdot \epsilon_0] = E[\epsilon]E[\epsilon_0] = 0$, 得:

$$\begin{aligned} Cov(\hat{\beta}, \epsilon_0) &= E[(\hat{\beta} - E[\hat{\beta}])(\epsilon_0 - E[\epsilon_0])] \\ &= E\left[\left((X^T X)^{-1} X^T \epsilon\right) \cdot \epsilon_0\right] \\ &= (X^T X)^{-1} X^T \cdot E[\epsilon \cdot \epsilon_0] \\ &= \mathbf{0} \end{aligned}$$

(2)

$$\hat{y} - y_0 = x_0^T \hat{\beta} - (x_0^T \beta + \epsilon_0) = x_0^T (\hat{\beta} - \beta) - \epsilon_0$$

计算均方误差:

$$\begin{aligned} E(\hat{y} - y_0)^2 &= E\left[(x_0^T (\hat{\beta} - \beta) - \epsilon_0)^2\right] \\ &= E\left[(x_0^T (\hat{\beta} - \beta))^2\right] - 2E\left[x_0^T (\hat{\beta} - \beta) \epsilon_0\right] + E[\epsilon_0^2] \end{aligned}$$

其中, 由第 (1) 问可知 $\hat{\beta}$ 与 ϵ_0 独立, 且 $E[\epsilon_0] = 0$, 故交叉项期望为 0。 $E[\epsilon_0^2] = Var(\epsilon_0) = \sigma^2$ 。并且

$$\begin{aligned} E\left[(x_0^T (\hat{\beta} - \beta))^2\right] &= Var(x_0^T \hat{\beta}) \quad (\text{因 } \hat{\beta} \text{ 无偏}) \\ &= x_0^T Var(\hat{\beta}) x_0 \\ &= x_0^T \left(\sigma^2 (X^T X)^{-1}\right) x_0 \\ &= \sigma^2 x_0^T (X^T X)^{-1} x_0 \end{aligned}$$

综上:

$$E(\hat{y} - y_0)^2 = \sigma^2 x_0^T (X^T X)^{-1} x_0 + \sigma^2 = \sigma^2 \left(1 + x_0^T (X^T X)^{-1} x_0\right)$$

中国科学技术大学-812 概率论与数理统计

中国科学技术大学-812 概率论与数理统计-2016 年

一、计算题 (理由要充分. 每小题 8 分, 共 88 分)

1. 连续抛掷一枚非均匀的硬币 n 次, 且假设抛掷的结果并不独立: 第一次掷出正面的概率为 $\alpha (0 < \alpha < 1)$, 第二次后每次出现与前一次相同面的概率为 $\beta (0 < \beta < 1)$. 求第 n 次出现正面的概率, 并讨论 $n \rightarrow \infty$ 时的极限情况.

Solution: 用事件 A_n 表示第 n 次郑出的是正面, 则对于 $n = 1, 2, \dots$

$$\begin{aligned} P(A_{n+1}) &= P(A_{n+1} | A_n) P(A_n) + P(A_{n+1} | \bar{A}_n) P(\bar{A}_n) \\ &= \beta P(A_n) + (1 - \beta) (1 - P(A_n)) \end{aligned}$$

若记 $p_n = P(A_n)$, 则上式为一差分方程, 等式两侧同时减去 $\frac{1}{2}$, 有

$$p_{n+1} - \frac{1}{2} = (2\beta - 1) \left(p_n - \frac{1}{2} \right)$$

又 $p_1 = \alpha$, 则 $p_n = \frac{1}{2} + (\alpha - \frac{1}{2}) (2\beta - 1)^{n-1}$. 显然有 $\lim_{n \rightarrow \infty} p_n = \frac{1}{2}$.

2. 设随机变量 X 的概率密度为 $f(x) = 2(1-x)$, 其中 $0 < x < 1$. 试构造区间 $(0,1)$ 上的一个单调递增函数 $g(x)$, 使得 $g(X)$ 恰好服从参数为 1 的指数分布.

Solution: X 的分布函数是 $F(x) = \begin{cases} 0, & x < 0 \\ 1 - (1-x)^2, & 0 \leq x < 1, \text{ 于是令 } U_1 = 1 - (1-X)^2 \sim U(0,1), \text{ 而} \\ 1, & x \geq 1 \end{cases}$

$U_2 = 1 - U_1 \sim U(0,1)$. $Y \sim \text{Exp}(1)$ 有分布函数 $F_Y(y) = \begin{cases} 1 - e^{-y}, & y \geq 0 \\ 0, & y < 0 \end{cases}$, 其反函数为 $F_Y^{-1}(u) = -\ln(1-u)$, $0 < u < 1$ 则 $-\ln(1-U_1) \sim \text{Exp}(1)$, 即 $-\ln(U_2) = -2\ln(1-X) \sim \text{Exp}(1)$, 于是取 $g(x) = -2\ln(1-x)$, 就有 $g(X) \sim \text{Exp}(1)$, 同时容易验证 $g(x)$ 是单调增加的.

3. 设随机变量 X 和 Y 的联合密度函数为

$$f(x, y) = e^{-x}, \quad 0 < y \leq x < \infty$$

试求 X 与 Y 的相关系数 $\text{Corr}(X, Y)$.

Solution:

$$\begin{aligned} f_X(x) &= \int_0^x e^{-x} dy = xe^{-x}, 0 < x < +\infty \\ f_Y(y) &= \int_y^{+\infty} e^{-x} dx = e^{-y}, 0 < y < +\infty \end{aligned}$$

其中 $Y \sim \text{Exp}(1)$, 于是 $EY = 1, \text{Var}(Y) = 1$. $EX = \int_0^{+\infty} x^2 e^{-x} dx = \Gamma(3) = 2, EX^2 = \int_0^{+\infty} x^3 e^{-x} dx = \Gamma(4) = 6$ 所以 $\text{Var}(X) = 6 - 4 = 2$ $EXY = \int_0^{+\infty} dx \int_0^x xye^{-x} dy = \int_0^{+\infty} xe^{-x} \frac{x^2}{2} dx = \frac{1}{2}\Gamma(4) = 3$ 所以 $\text{Cov}(X, Y) = EXY - EXEY = 3 - 2 \cdot 1 = 1$ 于是 $\text{Corr}(X, Y) = \frac{1}{\sqrt{2 \cdot 1}} = \frac{\sqrt{2}}{2}$.


4. 设有 n 个球依次随机地放入 n 个盒子中, 设每个球放入每个盒子中的概率相等, 求放完后空盒子个数的期望, 以及当 $n \rightarrow \infty$ 时空盒子的平均比例.

Solution: 设 $X_i = \begin{cases} 1, & \text{第 } i \text{ 个盒子空} \\ 0, & \text{第 } i \text{ 个盒子非空,} \end{cases}$ 则空盒子个数 $Y = \sum_{i=1}^n X_i$. 而 $EX_i = P(X_i = 1) = P\{n$

个球均放在剩下 $n-1$ 个空盒中 $\} = \left(\frac{n-1}{n}\right)^n$ 于是 $EY = \sum_{i=1}^n EX_i = n \left(1 - \frac{1}{n}\right)^n$. 空盒子的平均比例是 $E\frac{Y}{n} = \left(1 - \frac{1}{n}\right)^n \rightarrow e^{-1}$.

5. 在一圆周上随机取三个点, 求这些点能落在同一个半圆上 (即能找到一条直径使得它们在该直径的同一侧) 的概率.

Solution: 设三个点分别为 A, B, C, 圆心记为 O, 不失一般性, 以 O 为原点, 取 OA 为 x 轴正方向, 由于对称性, 仅考虑 $\alpha = \angle BOA \sim U(0, \pi)$, 点 C 先不取, 示意图如下,



显然当且仅当点 C 落在红色区域时候, A, B, C 三点不在一个半圆上, 而在 α 给定时, 这一概率是 $\frac{\alpha}{2\pi}$, 于是由连续场合的全概率公式

$$P\{\text{三点在同一侧半圆周}\} = 1 - \int_0^\pi \frac{\alpha}{2\pi} \cdot \frac{1}{\pi} d\alpha = 1 - \frac{1}{4\pi^2} \pi^2 = \frac{3}{4}$$

6. 设 (X, Y) 服从由 x 轴, y 轴及直线 $x + y = 1$ 所围成的区域内的均匀分布, 求 $U = \frac{X}{Y}$ 的概率密度函数.

Solution: $f(x, y) = \begin{cases} \frac{1}{S_D} = 2, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$, 其中 $D = \{(x, y) \mid x > 0, y > 0, x + y < 1\}$ 用增补变量法, 令

$$\begin{cases} U = \frac{X}{Y} \\ V = Y \end{cases}, \text{反解可得} \begin{cases} X = UV \\ Y = V \end{cases}, \text{则 } J = \begin{vmatrix} v & u \\ 0 & 1 \end{vmatrix} = v.$$

$$D_{uv} = \{uv > 0, v > 0, uv + v < 1\} \Rightarrow \left\{ u > 0, 0 < v < \frac{1}{u+1} \right\}$$

对 $\forall (u, v) \in D_{uv}, (U, V)$ 有密度函数 $g(u, v) = f(uv, v)|J| = 2v$. 于是 U 的边际密度函数是 $g_U(u) = \int_0^{\frac{1}{u+1}} 2v dv = \frac{1}{(u+1)^2}, u > 0$

7. 每个分量均为连续型随机变量的随机向量也是连续型的吗? 若不是, 请举例说明.

Solution: 假设 X, Y 都是连续型随机变量, 但限制 $X = Y$, 则 (X, Y) 不存在联合密度函数.

8. 利用中心极限定理, 求掷一枚均匀的硬币, 至少要掷多少次才能保证正面出现的比例落在 45% 和 55% 之间的可能性不小于 90%?

Solution: 设 $X_i = \begin{cases} 1, & \text{第 } i \text{ 次掷出正面} \\ 0, & \text{第 } i \text{ 次掷出反面} \end{cases}$, 则 $X_i \text{ i.i.d} \sim b(1, \frac{1}{2})$. 于是正面比例为 $\bar{x} = \frac{1}{n} \sum_{i=1}^n X_i$. 且

$E\bar{x} = \frac{1}{2}, \text{Var}(\bar{x}) = \frac{1}{4n}$, 根据中心极限定理

$$\begin{aligned} P(0.45 \leq \bar{x} \leq 0.55) &= P\left(-\frac{\sqrt{n}}{10} \leq \frac{\bar{x} - 0.5}{\sqrt{\frac{1}{4n}}} \leq \frac{\sqrt{n}}{10}\right) \\ &\approx 2\Phi\left(\frac{\sqrt{n}}{10}\right) - 1 \geq 0.9 \end{aligned}$$

所以 $\Phi\left(\frac{\sqrt{n}}{10}\right) \geq 0.95 \Rightarrow \frac{\sqrt{n}}{10} \geq 1.645$

$$\sqrt{n} \geq 16.45$$

$$n \geq 270.6025$$

则 n 至少为 271.

9. 设某电子产品的寿命服从如下分布:

$$F(x; \alpha, \beta) = \begin{cases} 1 - e^{-\frac{x-\alpha}{\beta}}, & x \geq \alpha \\ 0, & x < \alpha \end{cases}$$

现测得 n 个该电子产品的寿命为 $X_1, X_2, \dots, X_n$, 试求未知参数 α, β 的矩估计和极大似然估计.

Solution: 总体服从双参数指数分布 $\text{Exp}\left(\alpha, \frac{1}{\beta}\right)$, 其中 α 是位置参数, β 是尺度参数, 所以 $EX = \alpha +$

$\beta, \text{Var}(X) = \beta^2$, 所以令 $\begin{cases} \bar{x} = \alpha + \beta \\ s^2 = \beta^2 \end{cases}$, 解得矩估计是

$$\begin{cases} \hat{\alpha}_M = \bar{x} - s \\ \hat{\beta}_M = s \end{cases}$$

样本的似然函数是

$$\begin{aligned} L(\alpha, \beta) &= \frac{1}{\beta^n} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \alpha)}{\beta}\right\} \mathbf{I}_{\{x_{(1)} \geq \alpha\}} \\ &= \frac{1}{\beta^n} e^{-\frac{n\bar{x}}{\beta}} e^{\frac{n\alpha}{\beta}} \mathbf{I}_{\{x_{(1)} \geq \alpha\}} \end{aligned}$$

显然它是关于 α 在 $(-\infty, x_{(1)})$ 上的增函数, 于是 $\hat{\alpha}_L = x_{(1)}$ 是 α 的极大似然估计. 再求 β 的极大似然估计, 考虑将对数似然函数的偏导置零, 即

$$\frac{\partial \ln L(\alpha, \beta)}{\partial \beta} = -\frac{n}{\beta} + \frac{\sum_{i=1}^n (x_i - \alpha)}{\beta^2} = 0$$

解得 $\beta = \frac{1}{n} \sum_{i=1}^n (x_i - \alpha)$, 代入 $\hat{\alpha}_L = x_{(1)}$, 得 $\hat{\beta}_L = \bar{x} - x_{(1)}$ 是 β 的极大似然估计.

10. 已知某种型号的导线电阻值服从正态分布 $N(\mu, \sigma^2)$, 现测量 16 次, 算得样本均值为 10.78 欧姆, 样本标准差为 1.40 欧姆. 分别求均值 μ 和方差 σ^2 的置信水平为 95% 的置信区间 (精确到小数点后两位).

Solution: 选取枢轴量 $T = \frac{\sqrt{n}(\bar{x} - \mu)}{s} \sim t(n-1)$, 则 μ 的 $1 - \alpha$ 的置信区间是

$$\bar{x} \pm \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$$

此时 $\bar{x} = 10.78, s = 1.4, n = 16, t_{0.975}(15) = 2.132$, 代入上式, 得

$$10.78 \pm \frac{1.4}{4} \cdot 2.132 = [10.03, 11.53]$$

选取枢轴量 $\chi^2 = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$, 则 σ^2 的 $1-\alpha$ 的置信区间是

$$\left[\frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}}^2(n-1)} \right]$$

代入数据 $s = 1.4, n = 16, \chi_{0.975}^2(15) = 27.488, \chi_{0.025}^2(15) = 6.262$, 得到

$$\left[\frac{15 \cdot (1.4)^2}{27.488}, \frac{15 \cdot (1.4)^2}{6.262} \right] = [1.07, 4.70]$$

11. 设总体 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 其中 $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2$ 均未知, 但 $\sigma_1^2 = k\sigma_2^2, k > 0$ 为已知常数. 又设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 是分别来自总体 X 和 Y 的两个独立样本. 记它们的样本均值分别为 $\bar{X}$ 和 $\bar{Y}$, 样本方差分别为 S_X^2 和 S_Y^2 , 及

$$S^2 = \frac{(n-1)S_X^2 + k(m-1)S_Y^2}{n+m-2}$$

对检验水平 $\alpha (0 < \alpha < 1)$, 现欲检验假设

$$H_0: \mu_1 = \mu_2 \leftrightarrow H_1: \mu_1 \neq \mu_2$$

试构造该检验所需的统计量 T , 要求该统计量服从 t 分布, 并写出含有 T 的拒绝域形式.

Solution: $\bar{x} \sim N\left(\mu_1, \frac{k}{n}\sigma_2^2\right), \bar{y} \sim N\left(\mu_2, \frac{1}{m}\sigma_2^2\right)$, 于是

$$Z = \frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{\sigma_2 \sqrt{\frac{k}{n} + \frac{1}{m}}} \sim N(0, 1)$$

根据 Fisher 引理, $\bar{x}$ 与 s_x^2 独立, 且 $\frac{(n-1)s_x^2}{k\sigma_2^2} \sim \chi^2(n-1)$. 同理 $\bar{y}$ 与 s_y^2 独立, 且 $\frac{(m-1)s_y^2}{\sigma_2^2} \sim \chi^2(m-1)$. 所以 $\chi^2 = \frac{(n-1)s_x^2}{k\sigma_2^2} + \frac{(m-1)s_y^2}{\sigma_2^2} = \frac{n+m-2}{k\sigma_2^2} S^2 \sim \chi^2(n+m-2)$, 并且 $\chi^2 Z$ 是独立的. 所以

$$T = \frac{Z}{\sqrt{\chi^2/(n+m-2)}} = \frac{\sqrt{k}[(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)]}{\sqrt{\frac{k}{n} + \frac{1}{m}} S} \sim t(n+m-2)$$

当 H_0 成立时, $T = \frac{\sqrt{k}(\bar{x} - \bar{y})}{\sqrt{\frac{k}{n} + \frac{1}{m}} S} \sim t(n+m-2)$ 可作为检验统计量, 显著性水平为 α 的拒绝域是 $W = \{|T| \geq t_{1-\frac{\alpha}{2}}(n+m-2)\}$.

二、(20 分) 设某全套邮票由 n 种不同类型的邮票组成, 某集邮爱好者每次等可能地获得其中一种. 记 X_n 表示他能聚齐全套 n 种邮票所需集邮次数.

(1)(10 分) 求 X_n 的数学期望和方差.

(2)(10 分) 证明: 当 $n \rightarrow \infty$ 时, $X_n/(n \ln n)$ 依概率收敛到 1.

Solution:

(1) 用 $Y_i (i = 0, 1, \dots, n-1)$ 表示收集到第 i 种邮票后, 新收集到一种邮票所需的次数, 则显然诸 Y_i 是独立的, 并且有

$$P(Y_0 = 1) = 1, Y_i \sim Ge\left(\frac{n-i}{n}\right) (i = 1, 2, \dots, n-1)$$

则 $EX_n = E\left(\sum_{i=0}^{n-1} Y_i\right) = \sum_{i=0}^{n-1} \frac{n}{n-i} = n \sum_{k=1}^n \frac{1}{k}$ $\text{Var}(X_n) = \sum_{i=0}^{n-1} \text{Var}(Y_i) = \sum_{i=1}^{n-1} \frac{n^2}{(n-i)^2} \frac{i}{n} = \sum_{i=1}^{n-1} \frac{n(n-i)}{i^2}$

(2) 由于 $E\left(\frac{X_n}{n \ln n}\right) = \frac{\sum_{k=1}^n \frac{1}{k}}{\ln n} \rightarrow 1$, 以及 $\text{Var}\left(\frac{X_n}{n \ln n}\right) = \frac{1}{n^2 \ln^2 n} \sum_{i=1}^{n-1} \frac{n(n-i)}{i^2} \leq \frac{1}{\ln^2 n} \sum_{i=1}^{n-1} \frac{1}{i^2} \rightarrow 0$, 可知 $\frac{X_n}{n \ln n} \xrightarrow{P} 1$.

三、(24 分) 设总体服从参数为 $\lambda > 0$ 的 Poisson 分布, 且 $X_1, X_2, \dots, X_n$ 为一组来自此总体的简单随机样本. 又设

$$T_n = \sum_{i=1}^n X_i, \quad \hat{g}(\lambda) = \left(1 - \frac{1}{n}\right)^{T_n}, \quad g(\lambda) = e^{-\lambda}$$

(1)(8 分) 问 $\hat{g}$ 是否为 g 的无偏估计? 证明你的结论.

(2)(8 分) 求 $\hat{g}$ 的方差.

(3)(8 分) 证明: $\hat{g}$ 的方差没有达到无偏估计方差的 Cramer-Rao 下界, 但当 $n \rightarrow \infty$ 时它们之比趋向 1.

Solution: (1) 由于 $T_n = \sum_{i=1}^n X_i \sim \text{Poisson}(n\lambda)$, 则

$$E(\hat{g}) = \sum_{k=0}^{\infty} \left(1 - \frac{1}{n}\right)^k \frac{(n\lambda)^k}{k!} e^{-n\lambda} = \sum_{k=0}^{\infty} \frac{[\lambda(n-1)]^k}{k!} e^{-\lambda(n-1)} e^{-\lambda} = e^{-\lambda}$$

所以 $\hat{g}$ 是 $e^{-\lambda}$ 的无偏估计.

(2)

$$\begin{aligned} E(\hat{g}^2) &= \sum_{k=0}^{\infty} \left(1 - \frac{1}{n}\right)^{2k} \frac{(n\lambda)^k}{k!} e^{-n\lambda} \\ &= \sum_{k=0}^{\infty} \frac{\left[(n-2+\frac{1}{n})\lambda\right]^k}{k!} e^{(n-2+\frac{1}{n})\lambda} e^{-(2-\frac{1}{n})\lambda} = e^{-(2-\frac{1}{n})\lambda} \\ \text{Var}(\hat{g}) &= E(\hat{g}^2) - (E\hat{g})^2 = e^{-(2-\frac{1}{n})\lambda} - e^{-2\lambda} = e^{-2\lambda} \left(e^{\frac{\lambda}{n}} - 1\right) \end{aligned}$$

(3) 先计算 Poisson 分布的 Fisher 信息量

$$I(\lambda) = E \left[\frac{\partial \ln P(X; \lambda)}{\partial \lambda} \right]^2 = E \left(\frac{X}{\lambda} - 1 \right)^2 = \frac{1}{\lambda^2} E(X - \lambda)^2 = \frac{1}{\lambda}$$

则 $g(\lambda) = e^{-\lambda}$ 的无偏估计的方差的 C-R 下界是 $\frac{[g'(\lambda)]^2}{nI(\lambda)} = \frac{\lambda}{n} e^{-2\lambda}$ 而 $e^{-2\lambda} \left(e^{\frac{\lambda}{n}} - 1\right) > \frac{\lambda}{n} e^{-2\lambda}$, 所以 $\hat{g}$ 的方差达不到 C-R 下界, 但是

$$\lim_{n \rightarrow \infty} \frac{e^{-2\lambda} \left(e^{\frac{\lambda}{n}} - 1\right)}{\frac{\lambda}{n} e^{-2\lambda}} = \lim_{x \rightarrow 0+} \frac{e^x - 1}{x} = 1$$

四、(18 分) 设总体 X 的概率分布如下表所示, 其中 $p > 0$ 为未知参数.

X	-1	0	1
P	$2p$	$1-5p$	$3p$

现有一样本容量 $n = 60$ 的简单随机样本, 其中 0 出现了 30 次, 1 和 -1 均出现了 15 次.

(1)(9 分) 求 p 的极大似然估计 $\hat{p}$ 的值;

(2)(9 分) 在显著性水平 $\alpha = 0.05$ 下, 利用 $\hat{p}$ 和拟合优度检验, 我们是否可以认为“该组样本来自于总体 X ”

?

Solution:

(1) 样本的似然函数是 $L(p) = (2p)^{n_1} (1-5p)^{n_0} (3p)^{n_1}$, 其中 n_i 表示的是取到 i 的样本数量, 将对数似然函数的导数置 0, 有

$$\frac{d \ln L(p)}{dp} = \frac{n_{-1}}{p} - \frac{5n_0}{1-5p} + \frac{n_1}{p} = 0$$

代入 $n_{-1} = n_1 = 15, n_0 = 30$, 解得 p 的极大似然估计 $\hat{p} = 0.1$.

(2) $\chi^2 = \frac{(15-12)^2}{12} + \frac{(30-30)^2}{30} + \frac{(15-18)^2}{18} = 1.25$ 而 $\chi^2 \sim \chi^{H_0}(1)$, 该检验的拒绝域是 $W = \{\chi^2 \geq \chi_{0.95}^2(1)\} = \{\chi^2 \geq 3.841\}$ 由于 $1.25 \notin W$, 可知此时我们应该接受原假设, 即认为该组样本确实是来自于总体 X .

中国科学技术大学-812 概率论与数理统计-2017 年

一、计算题 (理由要充分. 每小题 8 分, 共 88 分)

1. 设 A 与 B 独立, B 与 C 独立, A 与 C 互斥, 且 $P(A) = 1/2, P(B) = 1/4$ 和 $P(C) = 1/8$. 求 $P(A \cup B \cup C)$.

Solution:

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC) \\ &= \frac{1}{2} + \frac{1}{4} + \frac{1}{8} - P(A)P(B) - 0 - P(B)P(C) + 0 \\ &= \frac{7}{8} - \frac{1}{2} \cdot \frac{1}{4} - \frac{1}{4} \cdot \frac{1}{8} = \frac{23}{32} \end{aligned}$$

2. 设随机变量 X, Y 和 Z 满足 $\text{Var}(X) = \text{Var}(Z) < \infty, \text{Var}(Y) = 4\text{Var}(X)$, 相关系数 $\rho_{X,Y} = -1, \rho_{X,Z} = 1/2$, 求 X 与 $Y + Z$ 的相关系数 $\rho_{X,Y+Z}$.

Solution: 我们首先发现 $\rho_{X,Y} = -1$, 意味着 X, Y 存在几乎处处的线性负相关关系, 即存在 $k < 0, b \in R$, 使得 $Y = kX + b$, a.s., 记 $\text{Var}(X) = \text{Var}(Z) = \sigma^2$, 则

$$\begin{aligned} \text{Cov}(X, Y + Z) &= \text{Cov}(X, Y) + \text{Cov}(X, Z) \\ &= -2\sigma \cdot \sigma + \frac{1}{2}\sigma^2 = -\frac{3}{2}\sigma^2 \\ \text{Var}(Y + Z) &= \text{Var}(Y) + \text{Var}(Z) + 2\text{Cov}(Y, Z) \\ &= 4\sigma^2 + \sigma^2 - 2 \cdot \frac{1}{2} \cdot 2\sigma \cdot \sigma = 3\sigma^2 \end{aligned}$$

所以 $\rho_{X,Y+Z} = \frac{\text{Cov}(X,Y+Z)}{\sqrt{\text{Var}(X)\text{Var}(Y+Z)}} = \frac{-\frac{3}{2}\sigma^2}{\sigma \cdot \sqrt{3}\sigma} = -\frac{\sqrt{3}}{2}$.

3. 设随机变量 X 与 Y 相互独立, 其中 X 服从 $\{1, 2, \dots, n\}$ 上的均匀分布 (即取每个值的概率为 $1/n$), Y 具有概率密度函数 $f(y)$, 问 $X + Y$ 是否具有概率密度函数? 若有, 请求出该概率密度函数.

Solution: 记 $Z = X + Y$, 由微分法知

$$\begin{aligned} P(Z = z) &= P(X + Y = z) \\ &= \sum_{x=1}^n P(Y = z - x)P(X = x) \\ &= \frac{1}{n} \sum_{x=1}^n f(z - x) \end{aligned}$$

于是 Z 具有密度函数 $f_Z(z) = \frac{1}{n} \sum_{x=1}^n f(z - x)$.

4. 投掷一枚均匀的硬币, 如果硬币出现正面, 则再投掷一颗均匀的骰子; 如果硬币出现反面, 则再投掷 2 颗均匀的骰子. 记 Y 为投掷的骰子出现的点数或点数和, 求 $P(Y = 4)$.

Solution: 用事件 A 表示硬币掷出正面, 则由全概率公式

$$\begin{aligned} P(Y = 4) &= P(Y = 4 | A)P(A) + P(Y = 4 | \bar{A})P(\bar{A}) \\ &= \frac{1}{6} \cdot \frac{1}{2} + \left(\frac{1}{6} \cdot \frac{1}{6} \cdot 3 \right) \cdot \frac{1}{2} \\ &= \frac{1}{12} + \frac{1}{12} \cdot \frac{1}{2} = \frac{1}{8} \end{aligned}$$

5. 设 $X_1, X_2, \dots, X_n$ 为正值且独立同分布的随机变量, 求 $E \left[\frac{X_1 + X_2 + \dots + X_k}{X_1 + X_2 + \dots + X_n} \right]$, 其中 $1 \leq k \leq n$.

Solution: 由于

$$\sum_{j=1}^n E \left[\frac{X_j}{X_1 + X_2 + \dots + X_n} \right] = E \left[\frac{X_1 + X_2 + \dots + X_n}{X_1 + X_2 + \dots + X_n} \right] = 1$$

且由对称性, 每一个 $E\left[\frac{X_j}{X_1+X_2+\cdots+X_n}\right]$ 都是相等的, 得 $E\left[\frac{X_j}{X_1+X_2+\cdots+X_n}\right] = \frac{1}{n}$, 于是

$$E\left[\frac{X_1+X_2+\cdots+X_k}{X_1+X_2+\cdots+X_n}\right] = \frac{k}{n}$$

6. 设随机向量 (X, Y) 的联合密度函数为

$$f(x, y) = \begin{cases} (1+xy)/4, & |x| < 1, |y| < 1 \\ 0, & \text{其它} \end{cases}$$

(1) 求 $\text{Var}(X)$; (2) X 与 Y 相互独立吗? (3) X^2 与 Y^2 相互独立吗?(说明原因).

Solution:

(1)

$$\begin{aligned} EX &= \int_{-1}^1 x \, dx \int_{-1}^1 \frac{1+xy}{4} \, dy = \int_{-1}^1 x \left(\frac{1}{2} + 0\right) dx = 0 \\ EX^2 &= \int_{-1}^1 x^2 \, dx \int_{-1}^1 \frac{1+xy}{4} \, dy = \int_{-1}^1 x^2 \left(\frac{1}{2} + 0\right) dx = \frac{1}{3} \\ \text{Var}(X) &= \frac{1}{3} \end{aligned}$$

(2) (X, Y) 的联合密度函数无法进行分解, 于是显然 (X, Y) 是不独立的.

(3) 令 $\begin{cases} U = X^2 \\ V = Y^2 \end{cases}$, 则由微分法, 对于 $\forall u \in (0, 1), v \in (0, 1)$

$$\begin{aligned} P(U=u, V=v) &= P(X=\sqrt{u}, Y=\sqrt{v}) + P(X=\sqrt{u}, Y=-\sqrt{v}) + P(X=-\sqrt{u}, Y=\sqrt{v}) + P(X=-\sqrt{u}, Y=-\sqrt{v}) \\ &= \frac{1+\sqrt{uv}}{2} \frac{1}{4\sqrt{uv}} \, du \, dv + \frac{1-\sqrt{uv}}{2} \frac{1}{4\sqrt{uv}} \, du \, dv \\ &= \frac{1}{4\sqrt{uv}} \, du \, dv \end{aligned}$$

于是 (U, V) 的联合密度函数是 $f_{U,V}(u, v) = \begin{cases} \frac{1}{4\sqrt{uv}}, & 0 < u, v < 1 \\ 0, & \text{其他} \end{cases}$ 则 (U, V) 是相互独立的.

7. 设随机变量 $X_1, X_2, \dots, X_{2n}$ 相互独立, 且皆服从 $N(\mu, \sigma^2)$ 分布, 其中 $\sigma^2 > 0$. 定义

$$\bar{X} = \frac{1}{2n} \sum_{j=1}^{2n} X_j, \quad Y = \sum_{i=1}^n (X_i + X_{n+i} - 2\bar{X})^2$$

求 EY .

Solution: 令 $Z_i = X_i + X_{n+i} \sim N(2\mu, 2\sigma^2)$ ($i = 1, 2, \dots, n$), 于是

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i = \frac{1}{n} \sum_{i=1}^{2n} X_i = 2\bar{X}$$

则 $Y = \sum_{i=1}^n (X_i + X_{n+i} - 2\bar{X})^2 = \sum_{i=1}^n (Z_i - \bar{Z})^2$, 根据 Fisher 引理

$$\frac{Y}{2\sigma^2} = \frac{1}{2\sigma^2} \sum_{i=1}^n (Z_i - \bar{Z})^2 \sim \chi^2(n-1)$$

所以 $EY = 2(n-1)\sigma^2$.

8. 设随机变量 X 服从 (a, b) 区间上的均匀分布, 其中 $0 < a < b < \infty$. 在给定 $X = x$ 的条件下, Y 的条件分布是参数为 x 的指数分布, 证明: XY 服从参数为 1 的指数分布.

Solution: 对 $\forall z > 0$,

$$\begin{aligned} P(XY = z) &= \int_a^b P\left(Y = \frac{z}{x} \mid X = x\right) \frac{1}{b-a} dx \\ &= \frac{1}{b-a} \int_a^b \left(xe^{-z} d\left(\frac{z}{x}\right)\right) dx \quad (\text{该积分号是对 } x \text{ 积分的}) \\ &= \frac{1}{b-a} [(b-a)e^{-z}] dz \\ &= e^{-z} dz \end{aligned}$$

所以 $XY \sim E(1)$.

9. 设 $X_1, X_2, \dots, X_n$ 为来自于正态总体 $N(\mu, 1)$ 的简单随机样本, 若要求参数 μ 的置信系数为 0.95 的置信区间长度不超过 1, 求至少需要抽取的样本量 n .

Solution: μ 的置信区间为 $\bar{x} \pm \frac{1}{\sqrt{n}} z_{0.975}$, 这里 $z_{0.975} = 1.96$, 则置信区间的长度

$$\begin{aligned} \frac{2}{\sqrt{n}} \cdot 1.96 &\leq 1 \\ \sqrt{n} &\geq 3.92 \\ n &\geq 15.37 \end{aligned}$$

于是 n 至少为 16.

10. 设随机变量 X 的概率密度函数为 $f(x) = \frac{x^{\alpha-1}}{\Gamma(\alpha)} e^{-x}, x > 0$, 其中 $\alpha > 1, \Gamma(t)$ 为 Gamma 函数, 满足 $\Gamma(t+1) = t\Gamma(t), t > 0$. 证明: $P(0 < X < 2\alpha) \geq \frac{\alpha-1}{\alpha}$.

Solution: 由于 $X \sim Ga(\alpha, 1)$, 于是 $EX = \alpha, \text{Var}(X) = \alpha$, 则

$$\begin{aligned} P(0 < X < 2\alpha) &= P(-\alpha < X - \alpha < \alpha) \\ &= P(|X - \alpha| < \alpha) \\ &\geq 1 - \frac{\text{Var}(X)}{\alpha^2} = 1 - \frac{\alpha}{\alpha^2} = \frac{\alpha-1}{\alpha} \end{aligned}$$

11. 设 $X_1, \dots, X_9$ 和 $Y_1, \dots, Y_5$ 分别是来自正态总体 $N(0, 4)$ 和 $N(8, 9)$ 取出的一组简单样本 (即独立同分布样本), 彼此相互独立, 记 $\bar{Y} = \sum_{j=1}^5 Y_j / 5$, 问

$$\frac{\sum_{i=1}^9 X_i}{\sqrt{\sum_{j=1}^5 (Y_j - \bar{Y})^2}}$$

服从什么分布?

Solution: 这里 $\sum_{i=1}^9 X_i \sim N(0, 36)$, 所以 $\frac{1}{6} \sum_{i=1}^9 X_i \sim N(0, 1)$. 而 $\frac{1}{9} \sum_{j=1}^5 (Y_j - \bar{Y})^2 \sim \chi^2(4)$, 且 $\frac{1}{6} \sum_{i=1}^9 X_i$ 与 $\frac{1}{9} \sum_{j=1}^5 (Y_j - \bar{Y})^2$ 是相互独立的, 于是有

$$\frac{\frac{1}{6} \sum_{i=1}^9 X_i}{\sqrt{\frac{\frac{1}{9} \sum_{j=1}^5 (Y_j - \bar{Y})^2}{4}}} = \frac{\sum_{i=1}^9 X_i}{\sqrt{\sum_{j=1}^5 (Y_j - \bar{Y})^2}} \sim t(4)$$

二、(18 分) 设 $X_1, X_2, \dots, X_n$ 是从具有概率密度函数

$$f(x, \theta) = \begin{cases} 2 \left(\frac{\theta}{\pi}\right)^{1/2} \exp(-\theta x^2), & x > 0 \\ 0, & x \leq 0 \end{cases}$$

的总体中抽出的一组样本. 用 C-R 不等式法证明 $\hat{\theta} = \frac{2}{n} \sum_{i=1}^n X_i^2$ 是 $1/\theta$ 的最小方差无偏估计. (已知 $\Gamma(1/2) = \sqrt{\pi}$)

Solution: 先作总体变换, 令 $Y = X^2$, 由微分法, 对任意 $y > 0$,

$$\begin{aligned} P(Y = y) &= P(X = \sqrt{y}) \\ &= 2 \left(\frac{\theta}{\pi} \right)^{\frac{1}{2}} \exp(-\theta y) \frac{1}{2} \cdot \frac{1}{\sqrt{y}} dy \\ &= \frac{\theta^{\frac{1}{2}}}{\Gamma(\frac{1}{2})} y^{-\frac{1}{2}} e^{-\theta y} dy \end{aligned}$$

Y 有密度函数 $f_Y(y) = \frac{\theta^{\frac{1}{2}}}{\Gamma(\frac{1}{2})} y^{-\frac{1}{2}} e^{-\theta y}, y > 0$, 即 $Y \sim \text{Gamma}(\frac{1}{2}, \theta)$, 其数学期望与方差是 $EY = \frac{1}{2\theta}, \text{Var}(Y) = \frac{1}{2\theta^2}$. 根据似然原理, 可直接根据总体 Y 进行统计推断, 先计算 θ 的 Fisher 信息量

$$E \left[\frac{\partial \ln f_Y}{\partial \theta} \right]^2 = E \left(\frac{1}{2\theta} - Y \right)^2 = E \left(Y - \frac{1}{2\theta} \right)^2 = \text{Var}(Y) = \frac{1}{2\theta^2}$$

而 $g(\theta) = \frac{1}{\theta}$ 无偏估计方差的 C-R 下界是 $\frac{[g'(\theta)]^2}{nI(\theta)} = \frac{2}{n\theta^2}$. 由于 $E\left(\frac{2}{n} \sum_{i=1}^n X_i^2\right) = \frac{2}{n} E\left(\sum_{i=1}^n Y_i\right) = \frac{1}{\theta}$, 所以 $\frac{2}{n} \sum_{i=1}^n X_i^2$ 是 $\frac{1}{\theta}$ 的无偏估计, 下再计算其方差

$$\text{Var} \left(\frac{2}{n} \sum_{i=1}^n X_i^2 \right) = \frac{4}{n^2} \text{Var} \left(\sum_{i=1}^n Y_i \right) = \frac{4}{n^2} \frac{n}{2\theta^2} = \frac{2}{n\theta^2}$$

它的方差达到 C-R 下界, 故它必定是 $\frac{1}{\theta}$ 的最小方差无偏估计.

三、(24 分) 设 $X_1, X_2, \dots, X_n$ 是取自总体 X 的一组样本, 已知 X 服从三点分布:

$$P(X = -1) = p, \quad P(X = 0) = 1 - 3p, \quad P(X = 1) = 2p$$

其中 $0 < p < 1/3$ 为未知参数.

(1)(6 分) 试分别用样本的一阶和二阶原点矩来估计未知参数 p ;

(2)(6 分) 试求 p 的极大似然估计;

(3)(6 分) 证明这三个点估计都是无偏估计;

(4)(6 分) 问这两个无偏估计, 哪个更有效 (即哪个方差最小)?

Solution: (1) $EX = (-1) \cdot p + 0 \cdot (1 - 3p) + 1 \cdot 2p = p$, 因此 $\hat{p}_1 = \bar{x}$. $EX^2 = (-1)^2 \cdot p + 0^2 \cdot (1 - 3p) + 1^2 \cdot 2p = 3p$,

因此 $\hat{p}_2 = \frac{1}{3n} \sum_{i=1}^n x_i^2$.

(2) $L(p) = p^{n_1} (1 - 3p)^{n_0} (2p)^{n_1}$, 其中 n_i 表示取值为 i 的样本个数, 对数化处理

$$\ln L(p) = n_{-1} \ln p + n_0 \ln(1 - 3p) + n_1 \ln(2p)$$

求其关于参数 p 的偏导,

$$\begin{aligned} \frac{\partial \ln L}{\partial p} &= \frac{n_{-1}}{p} - \frac{3n_0}{1 - 3p} + \frac{n_1}{p} \\ &= \frac{n - n_0}{p} - \frac{3n_0}{1 - 3p} \\ &= \frac{n - n_0 - 3np + 3n_0p - 3n_0p}{p(1 - 3p)} = \frac{n - n_0 - 3np}{p(1 - 3p)} \end{aligned}$$

因为 $0 < p < \frac{1}{3}$, 所以当 $n - n_0 - 3np > 0$ 即 $p < \frac{n - n_0}{3n}$ 时, $\ln L(p)$ 单调增加, 同理当 $p > \frac{n - n_0}{3n}$ 时, $\ln L(p)$ 单调减少, 因此 p 的极大似然估计是 $\hat{p}_L = \frac{n - n_0}{3n}$, 可以发现它和 $\hat{p}_2 = \frac{1}{3n} \sum_{i=1}^n x_i^2$ 是一样的.

(3)

$$E\hat{p}_1 = E\bar{x} = EX_1 = p, E\hat{p}_2 = E\hat{p}_L = \frac{1}{3}EX_1^2 = p$$

$$E\hat{p}_L = \frac{n-n_0}{3n} = \frac{1}{3} \left[1 - E\left(\frac{n_0}{n}\right) \right] = \frac{1}{3}[1 - (1-3p)] = p$$

(4) $\text{Var}(\hat{p}_1) = \text{Var}(\bar{x}) = \frac{1}{n} \text{Var}(X_1) = \frac{1}{n} [EX^2 - (EX)^2] = \frac{3p-p^2}{n}$ $\text{Var}(\hat{p}_2) = \frac{1}{9n} \text{Var}(X_1^2) = \frac{1}{9n} [EX^4 - (EX^2)^2] = \frac{3p-9p^2}{9n} = \frac{p-3p^2}{3n}$ 而 $\text{Var}(\hat{p}_1) = \frac{9p-3p^2}{3n} > \text{Var}(\hat{p}_2)$, 可以看出 $\hat{p}_2$ 即 $\hat{p}_L$ 最有效.

四、(20 分) 某厂用自动装瓶机装油, 规定每瓶质量 500 克, 标准差不超过 10 克, 每天定时检查. 某天抽取 9 瓶, 测得平均质量为 499 克, 标准差 16.03. 假设瓶装油的重量服从正态分布. 问

(1)(10 分) 这台机器工作时是否有系统偏差;

(2)(10 分) 该机器工作是否稳定? (取检验水平 $\alpha = 0.05$)

Solution:

(1) 建立假设检验问题:

$$H_{10} : \mu = 500 \text{ vs } H_{11} : \mu \neq 500$$

检验统计量是 $T = \frac{\sqrt{n}(\bar{x}-\mu_0)}{s} = \frac{3 \cdot (499-500)}{16.03} = -0.1871$ 检验的拒绝域是

$$W_1 = \{|T| \geq t_{1-\frac{\alpha}{2}}(n-1)\} = \{|T| \geq t_{0.975}(8)\} = \{|T| \geq 2.306\}$$

所以 $T \notin W_1$, 因此我们接受原假设, 认为 $\mu = 500$, 即该台机器无系统偏差.

(2) 建立假设检验问题:

$$H_{20} : \sigma^2 \leq 10^2 \text{ vs } H_{21} : \sigma^2 > 10^2$$

检验统计量是 $\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} = \frac{8 \cdot 16.03^2}{10^2} = 20.5569$ 检验的拒绝域是

$$W_2 = \{\chi^2 > \chi_{1-\alpha}^2(n-1)\} = \{\chi^2 > \chi_{0.95}^2(8)\} = \{\chi^2 > 15.507\}$$

所以 $\chi^2 \in W_2$, 因此我们拒绝原假设, 认为该台机器工作不稳定.

中国科学技术大学-812 概率论与数理统计-2018 年

一、计算题 (理由要充分. 每小题 8 分, 共 88 分)

1. 设 A, B 为两个事件, 满足 $P(A|B) = 0.7, P(B|A) = 0.2, P(B^c|A^c) = 0.8$, 求 $P(A \cup B)$.

Solution: $P(B|A^c) = 1 - P(B^c|A^c) = 0.2 = P(B|A)$, 所以 A, B 独立. 则 $P(B) = P(B|A) = 0.2, P(A) = P(A|B) = 0.7$, 所以

$$P(A \cup B) = P(A) + P(B) - P(AB) = 0.2 + 0.7 - 0.2 \cdot 0.7 = 0.76$$

2. 设随机变量 X 与 Y 相互独立, 其中 X 服从 $(0,1)$ 上的均匀分布, Y 分别以概率 $1/3$ 和 $2/3$ 分别取 1 和 3. 问 $X + Y$ 具有概率密度吗? 若有, 请求出该概率密度函数.

Solution: 对 $\forall z \in (1, 2) \cup (3, 4)$, 有

$$\begin{aligned} P(Z = z) &= P(X + Y = z) \\ &= P(X = z - 1)P(Y = 1) + P(X = z - 3)P(Y = 3) \\ &= \begin{cases} \frac{1}{3} dz, & z \in (1, 2) \\ 0, & z \in (3, 4) \end{cases} + \begin{cases} 0, & z \in (1, 2) \\ \frac{2}{3} dz, & z \in (3, 4) \end{cases} \\ &= \begin{cases} \frac{1}{3} dz, & z \in (1, 2) \\ \frac{2}{3} dz, & z \in (3, 4) \end{cases} \end{aligned}$$

因此 $Z = X + Y$ 有密度函数 $f(z) = \begin{cases} \frac{1}{3}, & z \in (1, 2) \\ \frac{2}{3}, & z \in (3, 4) \\ 0, & \text{其他} \end{cases}$

3. 将 A, B, C 三个字母之一输入信道, 输出原字母的概率为 α , 而输出其它任一字母的概率都是 $(1 - \alpha)/2$. 现将字母串 AAA, BBB, CCC 之一输入信道, 输入 AAA, BBB, CCC 的概率分别为 0.4, 0.3, 0.3. 已知输出为 ABC, 问输入的是 AAA 概率是多少?(假设信道传输每个字母的工作是独立的)

Solution: 根据贝叶斯公式有

$$P(\text{IN} : \text{AAA} | \text{OUT} : \text{ABC}) = \frac{P(\text{OUT} : \text{ABC} | \text{IN} : \text{AAA})P(\text{IN} : \text{AAA})}{P(\text{OUT} : \text{ABC})}$$

其中 $P(\text{IN} : \text{AAA}) = 0.4, P(\text{OUT} : \text{ABC} | \text{IN} : \text{AAA}) = \alpha \left(\frac{1-\alpha}{2}\right)^2$, 而

$$\begin{aligned} P(\text{OUT} : \text{ABC}) &= \sum_{x \in \{\text{AAA}, \text{BBB}, \text{CCC}\}} P(\text{OUT} : \text{ABC} | \text{IN} : x)P(\text{IN} : x) \\ &= \left[0.4\alpha \left(\frac{1-\alpha}{2}\right)^2 + 0.3\alpha \left(\frac{1-\alpha}{2}\right)^2 + 0.3\alpha \left(\frac{1-\alpha}{2}\right)^2 \right] \\ &= \left(\frac{1-\alpha}{2}\right)^2 \alpha \end{aligned}$$

因此 $P(\text{IN} : \text{AAA} | \text{OUT} : \text{ABC}) = 0.4$.

4. 设 (X, Y) 服从二维正态分布, 其边际分布为 $X \sim N(4, 1), Y \sim N(6, 99)$, 求概率 $P(X + Y \leq 10)$.

Solution: 记 $(X, Y) \sim N(4, 6; 1, 99; \rho)$, 则 $X + Y \sim N(10, 100 + 6\sqrt{11}\rho)$, 所以

$$P(X + Y \leq 10) = \frac{1}{2}$$

5. 设 X 以概率 p 服从 $N(0, 1)$ 分布, 以概率 $1 - p$ 服从 $N(1, 1)$ 分布, 求 EX 和 $\text{Var}(X)$.

Solution: 记 $Y \sim b(1, p)$, 则 $X|Y = 1 \sim N(0, 1)$, $X|Y = 0 \sim N(1, 1)$, 根据重期望公式

$$\begin{aligned} EX &= E[E(X | Y)] \\ &= E(X | Y = 1)P(Y = 1) + E(X | Y = 0)P(Y = 0) \\ &= 0 \cdot p + 1 \cdot (1 - p) = 1 - p \\ EX^2 &= E\left[E(X^2 | Y)\right] \\ &= E(X^2 | Y = 1)P(Y = 1) + E(X^2 | Y = 0)P(Y = 0) \\ &= 1 \cdot p + 2 \cdot (1 - p) = 2 - p \end{aligned}$$

则 $\text{Var}(X) = 2 - p - (1 - p)^2 = 2 - p - 1 + 2p - p^2 = -p^2 + p + 1$.

6. 设随机变量 X 和 Y 相互独立且皆服从 $N(\mu, \sigma^2)$ 分布, 试求 $Z_1 = \alpha X + \beta Y$ 和 $Z_2 = \alpha X - \beta Y$ 的相关系数, 其中 α, β 为常数.

Solution:

$$\begin{aligned} \text{Var}(Z_1) &= (\alpha^2 + \beta^2)\sigma^2, \text{Var}(Z_2) = (\alpha^2 + \beta^2)\sigma^2 \\ \text{Cov}(Z_1, Z_2) &= \text{Cov}(\alpha X + \beta Y, \alpha X - \beta Y) \\ &= (\alpha^2 - \beta^2)\sigma^2 \end{aligned}$$

$$\text{所以 } \text{Corr}(X, Y) = \frac{(\alpha^2 - \beta^2)\sigma^2}{(\alpha^2 + \beta^2)\sigma^2} = \frac{\alpha^2 - \beta^2}{\alpha^2 + \beta^2}.$$

7. 设 $X_1, X_2, \dots, X_n$ 是一个简单随机样本, $EX = \mu$, $\text{Var}(X) = \sigma^2$, $\hat{\theta}^2 = c \sum_{i=1}^{n-1} (X_i - X_{i+1})^2$ 为 σ^2 的无偏估计, 求 c .

Solution:

$$\begin{aligned} E(\hat{\theta}^2) &= cE\left[\sum_{i=1}^{n-1} (X_i - X_{i+1})^2\right] \\ &= c(n-1)E(X_1 - X_2)^2 \\ &= c(n-1)E(X_1^2 - 2X_1X_2 + X_2^2) \\ &= c(n-1)\left[\mu^2 + \sigma^2 - 2\mu^2 + \mu^2 + \sigma^2\right] = 2c(n-1)\sigma^2 \end{aligned}$$

$$\text{所以 } c = \frac{1}{2(n-1)}.$$

8. 设 $X_1, X_2, \dots, X_5$ 是抽自密度为 $f(x) = \frac{1}{2}e^{-|x-\theta|}$, $-\infty < x < \infty$, 的总体的简单随机样本, $X_{(1)} < X_{(2)} < \dots < X_{(5)}$ 为次序统计量, 求 θ 的极大似然估计.

Solution: 似然函数 $L(\mathbf{X}; \theta) = \left(\frac{1}{2}\right)^5 e^{-\sum_{i=1}^5 |x_i - \theta|} = \left(\frac{1}{2}\right)^5 e^{-\sum_{i=1}^5 |x_{(i)} - \theta|}$. 这里 $x_{(i)}$ 表示的是第 i 次序统计量. 为使似然函数尽量大, 则应使 $e^{-\sum_{i=1}^5 |x_{(i)} - \theta|}$ 尽量大, 也就是使 $\sum_{i=1}^5 |x_{(i)} - \theta|$ 尽量小. 下面研究 $\sum_{i=1}^5 |x_{(i)} - \theta|$ 的性态:

$$\sum_{i=1}^5 |x_{(i)} - \theta| = \left(|x_{(1)} - \theta| + |x_{(5)} - \theta|\right) + \left(|x_{(2)} - \theta| + |x_{(4)} - \theta|\right) + |x_{(3)} - \theta|$$

注意到上式是关于 θ 的函数, 而 $\left(|x_{(1)} - \theta| + |x_{(5)} - \theta|\right)$ 在 $\theta \in [x_{(1)}, x_{(5)}]$ 时取最小值; 同理 $\left(|x_{(2)} - \theta| + |x_{(4)} - \theta|\right)$ 在 $\theta \in [x_{(2)}, x_{(4)}]$ 时取最小值; 而对于 $|x_{(3)} - \theta|$ 而言, 当 $\theta = x_{(3)}$ 时它取最小值 0. 则当 $\theta = x_{(3)}$ 时, 可以使得上式每一部分都取到最小值, 根据前面的分析, $\hat{\theta} = x_{(3)}$ 就是 θ 的 MLE.

9. 设 $X_1, X_2, \dots, X_{10}, X_{11}$ 独立同分布, 共同的分布为 $N(\mu, \sigma^2)$. 记

$$\bar{X} = \frac{1}{10} \sum_{i=1}^{10} X_i, \quad S^2 = \frac{1}{10} \sum_{i=1}^{10} (X_i - \bar{X})^2, \quad Y = \frac{k(\bar{X} - X_{11})}{S}$$

求 k 的值使 Y 服从 t 分布 (给出详细证明, 并指出 t 分布的自由度).

Solution: 根据 Fisher 引理, $\bar{X}$ 与 $\frac{10}{9}S^2$ 是独立的, 且 $\bar{X} \sim N(\mu, \frac{\sigma^2}{10})$, $\frac{10S^2}{\sigma^2} \sim \chi^2(9)$. 那么 $\bar{X} - X_{11} \sim N(0, \frac{11}{10}\sigma^2)$, 且它也是与 $\frac{10}{9}S^2$ 是独立的, 那么

$$Y = \frac{\frac{\bar{X} - X_{11}}{\sqrt{\frac{11}{10}\sigma^2}}}{\sqrt{\frac{10S^2}{\sigma^2}/9}} = \sqrt{\frac{9}{11}} \frac{\bar{X} - X_{11}}{S} \sim t(9)$$

即 $k = \sqrt{\frac{9}{11}}$ Y 服从自由度为 9 的 t 分布.

10. 参数的极大似然估计唯一吗? 若不唯一, 请举例说明.

Solution: 不唯一, 若 $X \sim U(\theta, \theta+1)$, 则 $\forall \hat{\theta} \in [x_{(n)} - 1, x_{(1)}]$ 都是 θ 的 MLE.

11. 设 $\{X_n, n \geq 1\}$ 为 i.i.d. 随机变量序列, $EX_1 = a$ 有限, 求极限

$$\lim_{n \rightarrow \infty} \sin \left(\frac{1}{n} \sum_{i=1}^n X_i \right).$$

Solution: 根据强大数定律, 有 $\frac{1}{n} \sum_{i=1}^n X_i \rightarrow a, a.s.$ 于是

$$\sin \left(\frac{1}{n} \sum_{i=1}^n X_i \right) \rightarrow \sin a, a.s.$$

二、(20 分) 设 (X, Y) 服从以 $(0,1), (1,0), (1,1)$ 为顶点的三角形区域上的均匀分布, 求

(1)(6 分) X 的边际概率密度;

(2)(7 分) 求 $U = X + Y$ 的概率密度;

(3)(7 分) 求 U 的方差.

Solution:

(1) 记题中三角形区域为 D , 其面积 $S_D = \frac{1}{2}$, 则 (X, Y) 的联合密度函数是

$$f(x, y) = \begin{cases} 2, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

X 的边际密度函数是 $f_X(x) = \int_{1-x}^1 2dy = 2x, 0 < x < 1$.

(2) 作变换 $\begin{cases} U = X + Y \\ V = X \end{cases} \Leftrightarrow \begin{cases} X = V \\ Y = U - V \end{cases}$, 雅各比行列式 $J = \begin{vmatrix} 0 & 1 \\ 1 & -1 \end{vmatrix} = -1$, 则对于 $\forall (v, u-v) \in D$,

即 $\begin{cases} 1 < u < 1+v \\ 0 < v < 1 \end{cases}$, (U, V) 有联合密度函数

$$f_{U,V}(u, v) = f(v, u-v)|J| = 2$$

所以 U 的边际密度函数是 $f_U(u) = \int_{u-1}^1 2dv = 2(2-u), 1 < u < 2$

(3) 发现 $U - 1 \sim \text{Beta}(1, 2)$, 所以 $\text{Var}(U) = \frac{2}{3^2 \cdot 4} = \frac{1}{18}$.

三、(24 分) 设 $X_1, X_2, \dots, X_n$ 是从参数 λ 的 Poisson 分布总体中抽取的一组随机样本, λ 未知.

(1)(6 分) 求 λ 的充分完备统计量;

(2)(6 分) 求 $g_1(\lambda) = \lambda^3$ 的最小方差无偏估计;

(3)(6 分) 求 $g_2(\lambda) = P(X_1 = 2)$ 的最小方差无偏估计;

(4)(6 分) 对显著性水平 α , 求检验问题 $H_0: \lambda \geq 1 \longleftrightarrow H_1: \lambda < 1$ 的一致最优检验.

Solution: (1) $L(\lambda) = \prod_{i=1}^n \frac{\lambda^{X_i}}{X_i!} e^{-\lambda} = \frac{1}{\prod_{i=1}^n X_i!} e^{-n\lambda} \exp\{\ln \lambda \cdot \sum_{i=1}^n X_i\}$ 可以看出泊松分布是指数族分布, 根据指数族分布的性质 $T = \sum_{i=1}^n X_i$ 是 λ 的充分完备统计量.

(2) 尝试基于 T 构造 $g_1(\lambda) = \lambda^3$ 的无偏估计, 考虑到求和式

$$\begin{aligned} E[T(T-1)(T-2)] &= \sum_{k=0}^{\infty} k(k-1)(k-2) \frac{(n\lambda)^k}{k!} e^{-n\lambda} \\ &= \sum_{k=3}^{\infty} k(k-1)(k-2) \frac{(n\lambda)^k}{k!} e^{-n\lambda} \\ &= (n\lambda)^3 \sum_{k=3}^{\infty} \frac{(n\lambda)^{k-3}}{(k-3)!} e^{-n\lambda} = n^3 \lambda^3 \end{aligned}$$

因此有 $\hat{g}_1(T) = \frac{T(T-1)(T-2)}{n^3}$ 是 $g_1(\lambda) = \lambda^3$ 的 UMVUE.

(3) 由于 $\hat{g}_2(T) = E(\mathbf{I}_{\{X_1=2\}} | T)$ 是基于充分完备统计量构造的 $P(X_1 = 2)$ 的无偏估计, 它必定是 $P(X_1 = 2)$ 的 UMVUE. 显然对于 $t = 0, 1$, 有 $\hat{g}_2(t) = 0$; 而对于 $t = 2, 3, \dots$

$$\begin{aligned} \hat{g}_2(t) &= P(X_1 = 2 | T = t) \\ &= \frac{P(X_1 = 2, T = t)}{P(T = t)} \\ &= \frac{P(X_1 = 2) P(\sum_{i=2}^n X_i = t-2)}{P(T = t)} \end{aligned}$$

其中 $X_1 \sim \mathcal{P}(\lambda), T \sim \mathcal{P}(n\lambda), \sum_{i=2}^n X_i \sim \mathcal{P}((n-1)\lambda)$, 则

$$\hat{g}_2(t) = \frac{\frac{\lambda^2}{2!} e^{-\lambda} \frac{[(n-1)\lambda]^{t-2}}{(t-2)!} e^{-(n-1)\lambda}}{\frac{(n\lambda)^t e^{-n\lambda}}{t!}} = C_t^2 \left(\frac{1}{n}\right)^2 \left(\frac{n-1}{n}\right)^{t-2}$$

综上 $\hat{g}_2(T) = C_T^2 \left(\frac{1}{n}\right)^2 \left(\frac{n-1}{n}\right)^{T-2} = \frac{T(T-1)}{2} \frac{(n-1)^{T-2}}{n^T}$ 是其 UMVUE.

(4) 考虑简单假设 $H_0: \lambda = \lambda_0$ vs $H_1: \lambda = \lambda_1 < 1$, 根据 $N-P$ 引理, 似然比检验是其最一致最大功效检验, 似然比为

$$\Lambda = \frac{\lambda_1^{\sum_{i=1}^n X_i} e^{-n\lambda_1}}{\lambda_0^{\sum_{i=1}^n X_i} e^{-n\lambda_0}} = \left(\frac{\lambda_1}{\lambda_0}\right)^{\sum_{i=1}^n X_i} e^{n(\lambda_0 - \lambda_1)}$$

可以看出该似然比关于统计量 $T = \sum_{i=1}^n X_i$ 是单调递减的, 所以原问题的一致最大功效检验为 $\phi(T) = \begin{cases} 1, & T < c \\ a, & T = c \\ 0, & T > c \end{cases}$

其中常数 a, c 使得 $E\phi(T) = \alpha$, 可以取

$$c = \inf \left\{ m : \sum_{k=0}^m \frac{n^k}{k!} e^{-n} > \alpha \right\}, \quad a = \left(\alpha - \sum_{k=0}^{m-1} \frac{n^k}{k!} e^{-n} \right) / \frac{n^m}{m!} e^{-n}.$$

四、(18 分) 设学校某次考试考生的成绩服从正态分布, 从中随机抽出 36 位考生的成绩, 算得平均成绩 66.5 分, 标准差为 15. 问在显著水平 0.05 下, 是否可以认为这次考试全体考生的平均成绩为 70 分? 给出检验全过程. 附表: $t_p(n)$ 表示自由度为 n 的 t 分布的 p 分位点.

$$t_{0.95}(35) = 1.6896, \quad t_{0.975}(35) = 2.0301$$

$$t_{0.95}(36) = 1.6883, \quad t_{0.975}(36) = 2.0281$$

Solution: 建立假设检验 $H_0: \mu = 70$ vs $H_1: \mu \neq 70$. 检验统计量是 $T = \frac{\sqrt{n}(\bar{x} - \mu_0)}{s} \sim t(n-1)$. 统计量的观测值为

$$T = \frac{\sqrt{n}(\bar{x} - \mu_0)}{s} = \frac{\sqrt{36}(66.5 - 70)}{15} = -1.4$$

检验的拒绝域是

$$W = \{|T| \geq t_{1-\frac{\alpha}{2}}(n-1)\} = \{|T| \geq t_{0.975}(35)\} = \{|T| \geq 2.0301\}$$

所以 $T = -1.4 \notin W$, 因此我们不能拒绝原假设, 即可以认为这次考试全体考生的平均成绩为 70 分.

中国科学技术大学-812 概率论与数理统计-2019 年

一、(15 分) 将 k 个相同的球随机放入 n 个不同的罐子, 每个球放入各个罐子的可能性相同. 试求

(1)(7 分) 指定的某个罐子恰有 r 个球的概率 ($r < k$);

(2)(8 分) 不空罐子数目的数学期望.

Solution:

(1) 指定的罐子中球的个数服从 $B(k, \frac{1}{n})$, 因此恰有 r 个的概率是

$$C_k^r \left(\frac{1}{n}\right)^r \left(\frac{n-1}{n}\right)^{k-r}.$$

(2) 用 $X_i = 1$ 表示第 i 个罐子无球, 若有球则记 $X_i = 0$, 显然有

$$EX_i = P(X_i = 1) = C_k^0 \left(\frac{1}{n}\right)^0 \left(\frac{n-1}{n}\right)^k = \left(1 - \frac{1}{n}\right)^k,$$

空罐子数的数学期望是 $E[X_1 + \cdots + X_n] = n(1 - \frac{1}{n})^k$, 因此不空罐子数的数学期望是 $n - n(1 - \frac{1}{n})^k$.

二、(20 分) 假设二维随机变量 (X, Y) 的联合概率密度函数为

$$f(x, y) = \begin{cases} \frac{21}{4}x^2y, & x^2 \leq y \leq 1 \\ 0, & \text{其他} \end{cases}$$

(1)(7 分) 求 $Z = X^2Y$ 的概率密度函数;

(2)(8 分) 求 $E(Y|X = 0.5)$;

(3)(5 分) 求 EX^2 .

Solution:

(1) 作变量变换, 令

$$\begin{cases} Z = X^2Y, \\ W = Y, \end{cases} \xrightarrow{\text{反函数}} \begin{cases} X = \pm\sqrt{Z/W}, \\ Y = W, \end{cases} \xrightarrow{\text{对应}} \begin{cases} x = \sqrt{z/w}, \\ y = w, \end{cases} \text{ 和 } \begin{cases} x = -\sqrt{z/w}, \\ y = w, \end{cases}$$

注意到此时有两支反函数, 其雅可比行列式分别是 $|J| = \pm \frac{1}{2\sqrt{zw}}$, 因此有

$$\begin{aligned} f_{Z,W}(z, w) &= f\left(\sqrt{\frac{z}{w}}, w\right) \left|\frac{1}{2\sqrt{zw}}\right| + f\left(-\sqrt{\frac{z}{w}}, w\right) \left|-\frac{1}{2\sqrt{zw}}\right| \\ &= \frac{21}{4} \sqrt{\frac{z}{w}}, 0 \leq z \leq w^2 \leq 1, w \geq 0 \end{aligned}$$

故有 $f_Z(z) = \frac{21\sqrt{z}}{4} \int_{\sqrt{z}}^1 w^{-\frac{1}{2}} dw = \frac{21}{2} \left(z^{\frac{1}{2}} - z^{\frac{3}{4}}\right), 0 \leq z \leq 1$.

(2) 先求 X 的边缘密度, 有

$$f_X(x) = \frac{21x^2}{4} \int_{x^2}^1 y dy = \frac{21}{8} (x^2 - x^6), \quad -1 \leq x \leq 1,$$

故条件分布是

$$f_{Y|X}(y|x) = \frac{2y}{(1-x^4)}, \quad x^2 \leq y \leq 1$$

故有

$$E[Y|X = 0.5] = \frac{2}{(1 - \frac{1}{16})} \int_{\frac{1}{4}}^1 y^2 dy = \frac{2}{\frac{15}{16}} \cdot \frac{21}{64} = 0.7$$

(3) 根据第 (2) 问得到的边际密度, 有

$$E(X^2) = \frac{21}{8} \int_{-1}^1 x^2 (x^2 - x^6) dx = \frac{21}{4} \int_0^1 x^4 (1 - x^4) dx = \frac{21}{4} \cdot \frac{4}{45} = \frac{21}{45}$$

三、(15 分) 设离散型随机变量 X 和 Y 不相关, 分别服从如下分布律

X	-1	0	1
P	1/4	1/2	1/4

Y	0	1
P	1/4	3/4

若 $P(XY = 0) = \frac{1}{2}$, 试求

(1)(8 分) $X + Y$ 的分布律;

(2)(7 分) $\text{Var}(X | Y = 1)$.

Solution: 我们先通过题目给定信息得出联合分布, 由于 $EX = 0, EY = 3/4$, 因此得到 $EXY = 0$, 故有 $P(XY = 1) - P(XY = -1) = 0$, 结合 $P(XY = 1) + P(XY = -1) = 1/2$, 得到 $P(XY = 1) = P(XY = -1) = 1/4$.

(1) 根据得到的联合分布列, 很快得到 $X + Y$ 的分布列是

$X + Y$	-1	0	1	2
P	0	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{4}$

(2) 给定 $Y = 1$, X 的条件分布是

$Y = 1$	$X = -1$	$X = 0$	$X = 1$
P	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

因此有 $E(X | Y = 1) = 0, E(X^2 | Y = 1) = 2/3$, 故 $\text{Var}(X | Y = 1) = 2/3$.

四、(15 分) 设随机变量序列 $\{X_i\}_{i=1}^{\infty}$ 相互独立, 且均服从 $(0, 1)$ 上的均匀分布, 试证明

(1)(7 分) $Y_n = (\prod_{i=1}^n X_i)^{-1/n} \xrightarrow{P} e$, 即依概率收敛成立, 此处 e 为自然常数;

(2)(8 分) 证明 $\sqrt{n}(Y_n - e) \rightarrow_d N(0, e^2)$, 即依分布收敛成立.

Solution: (1) 作变换, 令 $Z_i = -\ln X_i \sim \text{Exp}(1)$, 则 $Z_1, Z_2, \dots, Z_n$ 是来自期望为 1 的指数分布的随机变量序列, 由于 $EZ_1 = 1$, 故根据大数定律, 得 $\frac{\sum_{k=1}^n Z_i}{n} \xrightarrow{P} 1$, 因此有 $Y_n = \exp\left\{\frac{\sum_{k=1}^n Z_i}{n}\right\} \xrightarrow{P} e$.

(2) 同样利用 $Z_1, Z_2, \dots, Z_n$, 由中心极限定理知, $\sqrt{n}\left(\frac{\sum_{k=1}^n Z_i}{n} - 1\right) \xrightarrow{d} N(0, 1)$, 令 $g(x) = e^x$, 借助 Delta 方法, 得 $\sqrt{n}\left(g\left(\frac{\sum_{k=1}^n Z_i}{n}\right) - g(1)\right) \xrightarrow{d} g'(1)N(0, 1)$, 即

$$\sqrt{n}(Y_n - e) \xrightarrow{d} N(0, e^2)$$

五、(20 分) 设 $X_1, \dots, X_n$ 为来自总体 X 的一组简单随机样本, 且 $\log X \sim N(\theta, \theta)$, 其中 $\theta > 0$ 为未知参数. 试

(1)(10 分) 求 θ 的最大似然估计 $\hat{\theta}$, 并证明其是唯一的;

(2)(10 分) 证明 $\hat{\theta}$ 低估 θ , 但仍是 θ 的相合估计.

Solution: (1) 样本的似然函数是

$$L(\theta | x) = (2\pi\theta)^{-\frac{n}{2}} \exp \left\{ -\frac{\sum_{i=1}^n (\ln x_i - \theta)^2}{2\theta} \right\},$$

取对数得 $\ln L(\theta | x) = C_1 - \frac{n}{2} \ln \theta - \frac{\sum_{i=1}^n (\ln x_i - \theta)^2}{2\theta} = C_2 - \frac{n}{2} \ln \theta - \frac{\sum_{i=1}^n (\ln x_i)^2}{2\theta} + \frac{n}{2} \theta$, 因此

求导有

$$\frac{\partial \ln L(\theta | x)}{\partial \theta} = -\frac{n}{2\theta} + \frac{\sum_{i=1}^n (\ln x_i)^2}{2\theta^2} - \frac{n}{2} = \frac{-n\theta + \sum_{i=1}^n (\ln x_i)^2 - n\theta^2}{2\theta^2}$$

考虑 $g(\theta) = -\theta^2 - \theta + \frac{1}{n} \sum_{i=1}^n (\ln x_i)^2$, 它与似然函数的导数同正负, 因此考虑该函数就等同于考察似然函数的单调性. 使得 $g(\theta) = 0$ 的根有两个, 左侧的根是导数由负转正点, 右侧的根是导数由正转负点, 故右侧的根是唯一的 MLE, 即

$$\hat{\theta} = \frac{-1 + \sqrt{1 + \frac{4}{n} \sum_{i=1}^n (\ln x_i)^2}}{2}$$

(2) 记 $T = \frac{1}{n} \sum_{i=1}^n (\ln x_i)^2$, 显然 $E(T) = E[(\ln X)^2] = \theta^2 + \theta$, 由 Jensen 不等式得

$$E \left[\frac{-1 + \sqrt{1 + 4T}}{2} \right] < \frac{-1 + \sqrt{1 + 4E(T)}}{2} = \theta,$$

故 $\hat{\theta}$ 低估 θ , 但由大数定律, $T = \frac{1}{n} \sum_{i=1}^n (\ln x_i)^2 \xrightarrow{P} \theta^2 + \theta$, 因此也有

$$\hat{\theta} = \frac{-1 + \sqrt{1 + 4T}}{2} \xrightarrow{P} \frac{-1 + \sqrt{4\theta^2 + 4\theta + 1}}{2} = \theta.$$

六、(15 分) 设 X 为服从如下分布的离散型随机变量

$$P(X = -1) = p, P(X = k) = (1-p)^2 p^k, k = 0, 1, 2, \dots$$

其中 $p \in (0, 1)$ 为未知参数. 试

(1)(7 分) 求 $(1-p)^2$ 的最小方差无偏估计;

(2)(8 分) 证明 p 的最小方差无偏估计不存在.

Solution: (1) 我们先说明: 任意零的无偏估计都可以写为 $U(X) = aX$ 的形式. 先证 $\Leftarrow$:

$$EX = -p + \sum_{k=0}^{+\infty} k(1-p)^2 p^k = -p + (1-p)^2 \sum_{k=1}^{+\infty} kp^k = 0$$

(注意: $\sum_{k=1}^{+\infty} kp^k = \sum_{k=1}^{+\infty} \sum_{n=1}^k p^k = \sum_{n=1}^{+\infty} \sum_{k=n}^{+\infty} p^k = \sum_{n=1}^{+\infty} \frac{p^n}{1-p} = \frac{p}{(1-p)^2}$)

如果 $\exists a$, s.t. $U(X) = aX$, 则 $EU(X) = aEX = 0$. 再证 $\Rightarrow$: 设 $U(k) = u_k$, 因为 $U(X)$ 是零的无偏估计, 所以有:

$$0 = u_{-1}p + (1-p)^2 \sum_{k=0}^{+\infty} u_k p^k = u_0 + \sum_{k=1}^{+\infty} (u_{k-2} - 2u_{k-1} + u_k) p^k,$$

这个等式要求对于任意 $p \in [0, 1]$ 成立, 等式右侧是关于 p 的一个幂级数, 幂级数要想恒为 0 就必须所有项系数都为 0, 即 $u_0 = 0, u_{k-2} - 2u_{k-1} + u_k = 0$, 第二个式子意味着 $\{u_n\}$ 是等差数列, 而又有 $u_0 = 0$, 因此 $U(k) = u_k = ku_1$. 此外, 显然 $I_{[X=0]}$ 是 $(1-p)^2$ 的无偏估计, 实际它也是 UMVUE, 因为对于任意零的无偏估计 $U(X)$,

$$\text{Cov}(I_{[X=0]}, U(X)) = a \text{Cov}(I_{[X=0]}, X) = aEXI_{[X=0]} = 0,$$

因此 $I_{[X=0]}$ 是 $(1-p)^2$ 的 UMVUE.

(2) 用反证法: 如果 $V(X)$ 是 p 的无偏估计, 设 $V_1(X) = V(X) - I_{[X=-1]}$ 很明显可以看出 $V_1(X)$ 是零的无偏估计, 故存在 a 使得

$$V(X) = aX + I_{[X=-1]},$$

对于任意一个零的无偏估计 bX , $\text{Cov}(V(X), bX) = abEX^2 + bEXI_{[X=-1]} = b[aEX^2 - p]$, 如果想要该式对于任意 p 恒为 0, 就必须要求 EX^2, p 线性相关, 这对于 $EX^2 = \frac{2p}{1-p}$ 来说, 很明显是不满足的. 故 p 的最小方差无偏估计不存在.

(注意: $\sum_{k=1}^{+\infty} k^2 p^k = p^2 \sum_{k=1}^{+\infty} k(k-1)p^{k-2} + p \sum_{k=1}^{+\infty} kp^{k-1} = \frac{p+p^2}{(1-p)^3}$, 故 $EX^2 = p + (1-p)^2 \sum_{k=0}^{+\infty} k^2 p^k = p + \frac{p+p^2}{1-p} = \frac{2p}{1-p}$)

七、(25 分) 设如下回归模型

$$Y_i = \alpha + \beta \xi_i + \epsilon_i$$

$$X_i = \xi_i + \delta_i, i = 1, \dots, n$$

其中 $\epsilon_1, \dots, \epsilon_n \text{i.i.d} \sim N(0, \sigma_\epsilon^2)$, $\delta_1, \dots, \delta_n \text{i.i.d} \sim N(0, \sigma_\delta^2)$, 且诸 ϵ'_i 和 δ'_i 相互独立. $\sigma_\delta^2 = \sigma_\epsilon^2 \lambda$, 其中 λ 固定且已知. 给定观测数据 $(X_1, Y_1), \dots, (X_n, Y_n)$, 则

(1)(15 分) 求 $\alpha, \beta, \sigma_\delta^2$ 的最大似然估计 $\hat{\alpha}, \hat{\beta}, \hat{\sigma}_\delta^2$;

(2)(10 分) 若假设对充分大的 $n, \bar{\xi}_n = \frac{1}{n} \sum_{i=1}^n \xi_i$ 和 $c_1 \leq \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 \leq c_2$ 均一致有界, 证明 $\hat{\alpha}, \hat{\beta}$ 为相合估计.

Solution: 该模型为 error-in-variables model, 其与传统线性回归模型的不同在于观测变量是否为固定值. 在传统线性回归模型中, 观测变量 X_i 被视为已知常数, 而在该模型中, 观测变量为随机变量, 即 $X_i \sim N(\xi_i, \sigma_\delta^2)$. Y_i 与 ξ_i 之间有着线性关系, 但我们观测不到 ξ_i , 只能观测到 X_i , 因此这里 ξ_i 也视作参数.

(1) 在 $\sigma_\delta^2 = \lambda \sigma_\epsilon^2$ 的前提下, 似然函数为:

$$L(\alpha, \beta, \xi_1, \dots, \xi_n, \sigma_\delta^2) = \frac{1}{(2\pi)^n} \frac{\lambda^{n/2}}{(\sigma_\delta^2)^n} \exp \left[- \sum_{i=1}^n \frac{(x_i - \xi_i)^2 + \lambda (y_i - (\alpha + \beta \xi_i))^2}{2\sigma_\delta^2} \right]$$

对于任意的 $(\alpha, \beta, \sigma_\delta^2)$, 似然函数相对于 ξ_i 的最大值点是

$$\xi_i^* = \frac{x_i + \lambda \beta (y_i - \alpha)}{1 + \lambda \beta^2}$$

将上式代入似然函数, 可将似然函数化简为:

$$L(\alpha, \beta, \xi_1^*, \dots, \xi_n^*, \sigma_\delta^2) = \frac{1}{(2\pi)^n} \frac{\lambda^{n/2}}{(\sigma_\delta^2)^n} \exp \left\{ - \frac{1}{2\sigma_\delta^2} \left[\frac{\lambda}{1 + \lambda \beta^2} \sum_{i=1}^n (y_i - (\alpha + \beta x_i))^2 \right] \right\}$$

记 $\alpha^* = \sqrt{\lambda} \alpha, \beta^* = \sqrt{\lambda} \beta, y_i^* = \sqrt{\lambda} y_i, i = 1, \dots, n$, 对数似然函数改写为

$$\begin{aligned} \ln L &= -n \ln 2\pi + \frac{n}{2} \ln \lambda - n \ln \sigma_\delta^2 - \frac{1}{2\sigma_\delta^2} \frac{\lambda}{1 + \lambda \beta^2} \sum_{i=1}^n (y_i - (\alpha + \beta x_i))^2 \\ &= -n \ln 2\pi + \frac{n}{2} \ln \lambda - n \ln \sigma_\delta^2 - \frac{1}{2\sigma_\delta^2} \frac{1}{1 + \beta^{*2}} \sum_{i=1}^n (y_i^* - (\alpha^* + \beta^* x_i))^2 \end{aligned}$$

上式对 $\alpha^*, \beta^*, \sigma_\delta^2$ 求导, 并令导数为 0, 有似然方程

$$\begin{cases} \frac{\partial \ln L}{\partial \alpha^*} = \frac{1}{\sigma_\delta^2} \frac{1}{1+\beta^{*2}} \sum_{i=1}^n (y_i^* - (\alpha^* + \beta^* x_i)) = 0 \\ \frac{\partial \ln L}{\partial \beta^*} = \frac{1}{\sigma_\delta^2} \frac{1}{1+\beta^{*2}} \sum_{i=1}^n x_i (y_i^* - (\alpha^* + \beta^* x_i)) + \frac{\beta^*}{\sigma_\delta^2 (1+\beta^{*2})^2} \sum_{i=1}^n (y_i^* - (\alpha^* + \beta^* x_i))^2 = 0 \\ \frac{\partial \ln L}{\partial \sigma_\delta^2} = -\frac{n}{\sigma_\delta^2} + \frac{1}{\sigma_\delta^4} \frac{1}{1+\beta^{*2}} \sum_{i=1}^n (y_i^* - (\alpha^* + \beta^* x_i))^2 = 0 \end{cases}$$

利用第一个式子可知 $y_i^* - (\alpha^* + \beta^* x_i) = (y_i^* - \bar{y}^*) - \beta^* (x_i - \bar{x})$, 用其化简第二个式子, 有

$$\begin{aligned} (1 + \beta^{*2}) \sum_{i=1}^n (x_i - \bar{x}) ((y_i^* - \bar{y}^*) - \beta^* (x_i - \bar{x})) + \beta^* \sum_{i=1}^n ((y_i^* - \bar{y}^*) - \beta^* (x_i - \bar{x}))^2 &= 0 \\ (1 + \beta^{*2}) (l_{xy}^* - \beta^* l_{xx}) + \beta^* (l_{yy}^* + \beta^{*2} l_{xx} - 2\beta^* l_{xy}^*) &= 0 \\ -l_{xy}^* \beta^{*2} - (l_{xx} - l_{yy}^*) \beta^* + l_{xy} &= 0 \end{aligned}$$

其中

$$l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, l_{xy}^* = \sum_{i=1}^n (x_i - \bar{x}) (y_i^* - \bar{y}^*), l_{yy}^* = l_{xx} = \sum_{i=1}^n (y_i^* - \bar{y}^*)^2$$

记 $g(\beta^*) = -l_{xy}^* \beta^{*2} - (l_{xx} - l_{yy}^*) \beta^* + l_{xy}$, 它与对数似然函数关于 β^* 的导数有着相同的正负号, 我们要找似然函数的极大值点, 就是找该函数的由正转负点, 即在该二次函数的两个零点处考虑, 而该二次函数的开口方向由 l_{xy}^* 决定, 计算可得两种开口情况下的结果是一样的

$$\hat{\beta}^* = \begin{cases} \frac{-(l_{xx} - l_{yy}^*) + \sqrt{(l_{xx} - l_{yy}^*)^2 + 4l_{xy}^{*2}}}{2l_{xy}^*}, & l_{xy}^* > 0 \\ \frac{-(l_{xx} - l_{yy}^*) - \sqrt{(l_{xx} - l_{yy}^*)^2 + 4l_{xy}^{*2}}}{2l_{xy}^*}, & l_{xy}^* < 0 \end{cases}$$

由于

$$l_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{\lambda} l_{yy}^*, l_{xy} = \sum_{i=1}^n (x_i - \bar{x}) (y_i - \bar{y}) = \frac{1}{\sqrt{\lambda}} l_{xy}^*$$

以及考虑到 $\beta^* = \sqrt{\lambda} \beta$, 有

$$\hat{\beta} = \frac{-(l_{xx} - \lambda l_{yy}) + \sqrt{(l_{xx} - \lambda l_{yy})^2 + 4\lambda l_{xy}^2}}{2\lambda l_{xy}}$$

再利用似然方程的第一个式子可得 $\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$, 以及根据似然方程的第三个式子可得

$$\hat{\sigma}_\delta^2 = \frac{1}{2n} \frac{\lambda}{1 + \lambda \hat{\beta}^2} \sum_{i=1}^n \left(y_i - (\hat{\alpha} + \hat{\beta} x_i) \right)^2$$

(2)

$$\begin{aligned} \frac{1}{n} l_{xx} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \xi_i + \xi_i - \bar{\xi}_n + \bar{\xi}_n - \bar{x})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (x_i - \xi_i)^2 + \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 - (\bar{\xi}_n - \bar{x})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 + \sigma_\delta^2 + o_p(1) \end{aligned}$$

其中 $\frac{1}{n} \sum_{i=1}^n (x_i - \xi_i)^2 \rightarrow_p \sigma_\delta^2$ 直接根据大数定律, 以及 $P\left(\left(\bar{\xi}_n - \bar{x}\right)^2 > \varepsilon\right) \leq \frac{E(\bar{\xi}_n - \bar{x})^2}{\varepsilon} = \frac{1}{\varepsilon} \frac{\sigma_\delta^2}{n} \rightarrow 0$.

$$\begin{aligned}
\frac{1}{n}l_{yy}^* &= \frac{1}{n} \sum_{i=1}^n (y_i^* - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n \left((y_i^* - \alpha^* - \beta^* \xi_i) + \beta^* (\xi_i - \bar{\xi}_n) + (\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*) \right)^2 \\
&= \frac{1}{n} \sum_{i=1}^n (y_i^* - \alpha^* - \beta^* \xi_i)^2 + \frac{1}{n} \beta^{*2} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 - (\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*)^2 \\
&= \beta^{*2} \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 + \sigma_\delta^2 + o_p(1)
\end{aligned}$$

其中同样 $\frac{1}{n} \sum_{i=1}^n (y_i^* - \alpha^* - \beta^* \xi_i)^2 \rightarrow_p \sigma_\delta^2$ 直接根据大数定律, 以及

$$P\left(\left(\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*\right)^2 > \varepsilon\right) \leq \frac{E\left(\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*\right)^2}{\varepsilon} = \frac{1}{\varepsilon} \frac{\sigma_\delta^2}{n} \rightarrow 0$$

$$\begin{aligned}
\frac{1}{n}l_{xy}^* &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i^* - \bar{y}^*) \\
&= \frac{1}{n} \sum_{i=1}^n (x_i - \xi_i + \xi_i - \bar{\xi}_n + \bar{\xi}_n - \bar{x}) \left((y_i^* - \alpha^* - \beta^* \xi_i) + \beta^* (\xi_i - \bar{\xi}_n) + (\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*) \right) \\
&= \frac{1}{n} \sum_{i=1}^n (x_i - \xi_i) \left((y_i^* - \alpha^* - \beta^* \xi_i) + \beta^* (\xi_i - \bar{\xi}_n) + (\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*) \right) \\
&\quad + \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n) \left((y_i^* - \alpha^* - \beta^* \xi_i) + \beta^* (\xi_i - \bar{\xi}_n) + (\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*) \right) \\
&\quad + \frac{1}{n} \sum_{i=1}^n (\bar{\xi}_n - \bar{x}) \left((y_i^* - \alpha^* - \beta^* \xi_i) + \beta^* (\xi_i - \bar{\xi}_n) + (\alpha^* + \beta^* \bar{\xi}_n - \bar{y}^*) \right)
\end{aligned}$$

上面三行和式中, 第一行三项均可根据大数定律得出依概率收敛到 0; 第二行中的第一项根据大数定律可知收敛到 0, 第三项可直接为 0; 第三行中的第一、三项可根据大数定律得知依概率收敛到 0, 第二项直接为 0, 故仅剩第二行第二项保持不动, 即

$$\frac{1}{n}l_{xy}^* = \beta^* \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 + o_p(1)$$

综上, 根据依概率收敛的性质, 有

$$\begin{aligned}
\hat{\beta}^* &= \frac{-(l_{xx} - l_{yy}^*) + \sqrt{(l_{xx} - l_{yy}^*)^2 + 4l_{xy}^{*2}}}{2l_{xy}^*} \\
&\xrightarrow{p} \frac{-(1 - \beta^{*2}) \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 + \sqrt{(1 - \beta^{*2})^2 \left[\frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 \right]^2 + 4\beta^{*2} \left[\frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 \right]}}{2\beta^* \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2} \\
&= \frac{(\beta^{*2} - 1) \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 + (\beta^{*2} + 1) \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2}{2\beta^* \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2} = \beta^*
\end{aligned}$$

即 $\hat{\beta}^*$ 是 β^* 的相合估计, 因此 $\hat{\beta}$ 是 β 的相合估计. 再考虑 $\hat{\alpha}$, 由于

$$\hat{\alpha} = \bar{y} - \bar{x}\hat{\beta} = (\alpha + \bar{\xi}_n\beta) - \bar{x}\hat{\beta} = \alpha + \bar{\xi}_n\beta - \bar{x}\hat{\beta}$$

其中

$$\begin{aligned}\bar{\xi}_n\beta - \bar{x}\hat{\beta} &= \bar{\xi}_n\beta - \bar{\xi}_n\hat{\beta} + \bar{\xi}_n\hat{\beta} - \bar{x}\hat{\beta} \\ &= \bar{\xi}_n(\beta - \hat{\beta}) + (\bar{\xi}_n - \bar{x})\hat{\beta}\end{aligned}$$

根据 $\hat{\beta}$ 的相合性以及 $\bar{\xi}_n$ 的有界性, 有 $\bar{\xi}_n(\beta - \hat{\beta}) \rightarrow_p 0$. 而

$$P\left(|\bar{\xi}_n - \bar{x}| > \varepsilon\right) \leq \frac{E(\bar{\xi}_n - \bar{x})^2}{\varepsilon^2} = \frac{1}{\varepsilon^2} \frac{\sigma_\delta^2}{n} \rightarrow 0$$

故 $\bar{\xi}_n - \bar{x} \rightarrow_p 0$, 所以 $(\bar{\xi}_n - \bar{x})\hat{\beta} \rightarrow_p 0$, 综上有

$$\hat{\alpha} = \alpha + o_p(1) \rightarrow_p \alpha$$

即 $\hat{\alpha}$ 是 α 的相合估计.

注: 特别需要指出的是, 该模型中 $\hat{\sigma}_\delta^2 \rightarrow_p \frac{\sigma_\delta^2}{2}$.

八、(25 分) 假设 $X_1, \dots, X_n$ 为来自总体 $f(x) = \frac{1}{\theta} e^{-\frac{x-\theta}{\theta}} I(x > \theta)$ 的简单随机样本, 其中 $\theta > 0$ 为未知参数. 记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 为样本均值, $X_{(1)} = \min_{1 \leq i \leq n} X_i$, 对 $0 < \alpha < 1/2$, 则

(1) (10 分) 利用枢轴变量法, 分别基于 $\bar{X}$ 和 $X_{(1)}$ 构造 θ 的 $1 - \alpha$ 置信区间.

(2) (8 分) 上述两个置信区间何者更优?

(3) (7 分) 试给出假设 $H_0: P(X > 1) \geq p_0$ 的一个水平 α 检验, 其中 $0 < p_0 < 1$ 为一已知数.

Solution: (1) 作总体变换, 令 $Y_i = X_i - \theta \sim \text{Exp}(\frac{1}{\theta})$, 则 $Y_1, \dots, Y_n$ 是来自均值为 θ 的指数分布的样本, 故有结论 $Y_{(1)} \sim \text{Exp}(\frac{n}{\theta})$, $n\bar{Y} \sim \text{Ga}(n, \frac{1}{\theta})$, 可以将其变为卡方分布, 即有

$$\frac{2n}{\theta} Y_{(1)} \sim \chi^2(2), \quad \frac{2n}{\theta} \bar{Y} \sim \chi^2(2n),$$

因此 $T_1 = \frac{2n}{\theta} (X_{(1)} - \theta) \sim \chi^2(2)$ 和 $T_2 = \frac{2n}{\theta} (\bar{X} - \theta) \sim \chi^2(2n)$ 是枢轴量, 对于 T_1 , 我们试导出最短置信区间, 因为 $a \leq T_1 \leq b$ 意味着 $\frac{X_{(1)}}{1 + \frac{b}{2n}} \leq \theta \leq \frac{X_{(1)}}{1 + \frac{a}{2n}}$, 因此求最小值就相当于求函数 $l(a, b) = \frac{1}{1 + \frac{a}{2n}} - \frac{1}{1 + \frac{b}{2n}}$ 在条件 $\int_a^b e^{-\frac{1}{2}x} dx = 1 - \alpha$ 的条件下的极小值, 用拉格朗日乘数法, 设

$$L(a, b) = \frac{1}{1 + \frac{a}{2n}} - \frac{1}{1 + \frac{b}{2n}} + \lambda \left[\int_a^b e^{-\frac{1}{2}x} dx - (1 - \alpha) \right]$$

求偏导数, 有

$$\begin{cases} \frac{\partial L}{\partial a} = -\frac{1}{2n(1 + \frac{a}{2n})^2} - \lambda e^{-\frac{1}{2}a} = 0 \\ \frac{\partial L}{\partial b} = \frac{1}{2n(1 + \frac{b}{2n})^2} + \lambda e^{-\frac{1}{2}b} = 0 \\ \frac{\partial L}{\partial \lambda} = \int_a^b e^{-\frac{1}{2}x} dx - (1 - \alpha) \equiv 0 \end{cases}$$

解得 a, b 满足下列关系:

$$\begin{cases} \left(1 + \frac{a}{2n}\right)^2 e^{-\frac{1}{2}a} = \left(1 + \frac{b}{2n}\right)^2 e^{-\frac{1}{2}b} \\ \int_a^b e^{-\frac{1}{2}x} dx = 1 - \alpha \end{cases}$$

这样的 a, b 使得区间 $\left[\frac{X_{(1)}}{1 + \frac{b}{2n}}, \frac{X_{(1)}}{1 + \frac{a}{2n}}\right]$ 最短, 记作区间一: $\left[\frac{X_{(1)}}{1 + \frac{\chi_{1-\alpha+\beta_1}^2(2)}{2n}}, \frac{X_{(1)}}{1 + \frac{\chi_{\beta_1}^2(2)}{2n}}\right]$. 对于 T_2 , 因为 $a \leq T_2 \leq b$ 意味着

$\frac{\bar{X}}{1 + \frac{b}{2n}} \leq \theta \leq \frac{\bar{X}}{1 + \frac{a}{2n}}$, 因此求最小值就相当于求函数 $l(a, b) = \frac{1}{1 + \frac{a}{2n}} - \frac{1}{1 + \frac{b}{2n}}$ 在条件 $\int_a^b \frac{1}{2n\Gamma(n)} x^{n-1} e^{-\frac{1}{2}x} dx = 1 - \alpha$ 的条件下的极小值, 用拉格朗日乘数法, 设

$$L(a, b) = \frac{1}{1 + \frac{a}{2n}} - \frac{1}{1 + \frac{b}{2n}} + \lambda \left[\int_a^b x^{n-1} e^{-\frac{1}{2}x} dx - C \right]$$

其中 $C = 2^n \Gamma(n)(1 - \alpha)$, 求偏导数, 有

$$\begin{cases} \frac{\partial L}{\partial a} = -\frac{1}{2n(1 + \frac{a}{2n})^2} - \lambda a^{n-1} e^{-\frac{1}{2}a} \\ \frac{\partial L}{\partial b} = \frac{1}{2n(1 + \frac{b}{2n})^2} + \lambda b^{n-1} e^{-\frac{1}{2}b} = \\ \frac{\partial L}{\partial \lambda} = \int_a^b x^{n-1} e^{-\frac{1}{2}x} dx - C \equiv 0, \end{cases}$$

解得 a, b 满足下列关系:

$$\begin{cases} \left(1 + \frac{a}{2n}\right)^2 a^{n-1} e^{-\frac{1}{2}a} = \left(1 + \frac{b}{2n}\right)^2 b^{n-1} e^{-\frac{1}{2}b} \\ \int_a^b \frac{1}{2^n \Gamma(n)} x^{n-1} e^{-\frac{1}{2}x} dx = 1 - \alpha \end{cases}$$

这样的 a, b 使得区间 $\left[\frac{\bar{X}}{1 + \frac{b}{2n}}, \frac{\bar{X}}{1 + \frac{a}{2n}}\right]$ 最短, 记作区间二: $\left[\frac{\frac{\bar{X}}{1 + \frac{b}{2n}}}{\frac{\chi_{1-\alpha+\beta_1}^2(2n)}{1 + \frac{\chi_{1-\alpha+\beta_1}^2(2n)}{2n}}}, \frac{\frac{\bar{X}}{1 + \frac{a}{2n}}}{\frac{\chi_{\beta_1}^2(2n)}{1 + \frac{\chi_{\beta_1}^2(2n)}{2n}}}\right]$.

注: 考试时遇到复杂情形也可考虑等尾置信区间, 大概率可得分.

(2) 我认为区间一更精确, 可以比较区间长度, 区间一的长度是

$$C_1 = \frac{(\chi_{1-\alpha+\beta_1}^2(2) - \chi_{\beta_1}^2(2))/2n}{\left(1 + \frac{\chi_{1-\alpha+\beta_1}^2(2)}{2n}\right) \left(1 + \frac{\chi_{\beta_1}^2(2)}{2n}\right)} X_{(1)},$$

由于 $\chi_{1-\alpha+\beta_1}^2(2) - \chi_{\beta_1}^2(2)$ 都是常数, 故其分母趋于 1, 而分子趋于 0, 且与 $\frac{1}{n}$ 同阶. 区间二的长度是

$$C_2 = \frac{(\chi_{1-\alpha+\beta_1}^2(2n) - \chi_{\beta_1}^2(2n))/2n}{\left(1 + \frac{\chi_{1-\alpha+\beta_1}^2(2n)}{2n}\right) \left(1 + \frac{\chi_{\beta_1}^2(2n)}{2n}\right)} \bar{X},$$

这里由于 $\chi_{1-\alpha+\beta_1}^2(2n), \chi_{\beta_1}^2(2n)$ 随 n 而动, 故需要进一步探讨, 先考虑分母, 根据 $\chi_{\theta_2}^2(2n)$ 的定义, 有

$$P(Y \leq \chi_{\beta_2}^2(2n)) = \beta_2, \text{ 即 } P\left(\frac{Y - 2n}{2\sqrt{n}} \leq \sqrt{n} \frac{\chi_{\beta_2}^2(2n) - 2n}{2n}\right) = \beta_2,$$

其中 $Y \sim \chi^2(2n)$, 根据中心极限定理, 有 $\frac{Y-2n}{2\sqrt{n}} \xrightarrow{d} N(0, 1)$, 故由上式可看出 $\sqrt{n} \frac{\chi_{\beta_2}^2(2n) - 2n}{2n} \rightarrow z_{\beta_2}$, 故有 $\frac{\chi_{\beta_2}^2(2n) - 2n}{2n} \rightarrow 0$, 因此 $\frac{\chi_{\beta_2}^2(2n)}{2n} \rightarrow 1$, 同理 $\frac{\chi_{1-\alpha+\beta_1}^2(2n)}{2n} \rightarrow 1$, 故有 C_2 的分母收敛于常数 4. 再考虑分子, 由于

$$P(\chi_{\beta_1}^2(2n) \leq Y \leq \chi_{1-\alpha+\beta_1}^2(2n)) = 1 - \alpha$$

$$\text{即 } P\left(\frac{\chi_{\beta_1}^2(2n) - 2n}{\sqrt{2n}} \leq \frac{Y - 2n}{\sqrt{2n}} \leq \frac{\chi_{1-\alpha+\beta_1}^2(2n) - 2n}{\sqrt{2n}}\right) = 1 - \alpha, \text{ 再次根据中心极限定理, 我们得知 } \frac{\chi_{1-\alpha+\beta_1}^2(2n) - \chi_{\beta_1}^2(2n)}{\sqrt{2n}}$$

是收敛于正常数的, 故对 C_2 而言, 其分子与 $\frac{1}{\sqrt{n}}$ 同阶, 比 C_1 更慢收敛于 0, 再考虑到 $X_{(1)} \leq \bar{X}$, 故当 n 足够大时, 区间一更短.

注: 若考虑的是等尾置信区间, 依然是由 $X_{(1)}$ 构造的置信区间更短, 讨论过程类似.

(3) 借助经验分布函数思想, 令 $U = \sum_{i=1}^n I_{\{x_i > 1\}}$, 则有当 T 过小时拒绝原假设, 即检验函数是 $T(x_1, \dots, x_n) = I_{\{U < m\}} + r I_{\{U = m\}}$, 意味着若 $U < m$ 则拒绝原假设, 若 $U = m$ 则以概率 r 拒绝原假设, 为使得其水平为 α , 需保证 m, r 满足

$$\sum_{k=0}^{m-1} C_n^k p_0^k (1 - p_0)^{n-k} + r C_n^m p_0^m (1 - p_0)^{n-m} = \alpha,$$

这样的 m, r 是找得到的, 即令

$$m = \inf \left\{ s : \sum_{k=0}^s C_n^k p_0^k (1-p_0)^{n-k} > \alpha \right\},$$

$$r = \frac{\alpha - \sum_{k=0}^{m-1} C_n^k p_0^k (1-p_0)^{n-k}}{C_n^m p_0^m (1-p_0)^{n-m}}$$

中国科学技术大学-812 概率论与数理统计-2020 年

一、(15 分) 设 A, B 为两个事件且 $P(B) > 0$, 判断下面两个不等式的正误:

- (1)(7 分) $P(A|B) \geq 1 - \frac{P(A^c)}{P(B)}$;
(2)(8 分) $P(A|B) \leq 1 - \frac{P(A^c) - P(B^c)}{P(B)}$.

Solution:

(1) 正确, 因为

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{P(B) - P(A^cB)}{P(B)} = 1 - \frac{P(A^cB)}{P(B)} \geq 1 - \frac{P(A^c)}{P(B)}.$$

(2) 正确, 因为 $P(A^cB) = P(A^c) - P(A^cB^c) \geq P(A^c) - P(B^c)$, 因此

$$P(A|B) = 1 - \frac{P(A^cB)}{P(B)} \leq 1 - \frac{P(A^c) - P(B^c)}{P(B)}.$$

二、(15 分) 设 $X_1, X_2, \dots, X_n$ 独立同分布, 共同分布的概率密度函数为 $f(x) = ce^{-c(x-a)}, x > a$, 其中 $c > 0$ 为常数. 记 $W_n = \min\{X_1, \dots, X_n\}$, 试问 W_n 在依概率意义下收敛吗? 并求极限.

Solution: 作总体变换, 令 $Y_i = X_i - a \sim \text{Exp}(c)$, 则 $Y_1, Y_2, \dots, Y_n$ 是来自均值为 $\frac{1}{c}$ 的指数分布总体的随机样本, 其最小次序统计量 $Y_{(1)} = W_n - a \sim \text{Exp}(nc)$, 故有

$$EW_n = a + EY_{(1)} = a + \frac{1}{nc} \rightarrow a, \\ \text{Var}(W_n) = \text{Var}(Y_{(1)}) = \frac{1}{n^2 c^2} \rightarrow 0,$$

故对于任意 $\varepsilon > 0$, 有

$$P(|W_n - a| > \varepsilon) = P(|W_n - EW_n + EW_n - a| > \varepsilon) \\ \leq P\left(|W_n - EW_n| > \frac{\varepsilon}{2}\right) + P\left(|EW_n - a| > \frac{\varepsilon}{2}\right),$$

当 n 足够大时, $\{|EW_n - a| > \frac{\varepsilon}{2}\}$ 是空集, 而根据切比雪夫不等式, 有

$$P\left(|W_n - EW_n| > \frac{\varepsilon}{2}\right) \leq \frac{4}{\varepsilon^2} \text{Var}(W_n) \rightarrow 0,$$

综上所述, 有 $W_n \xrightarrow{P} a$.

三、(15 分) 设样本 $X_1, X_2, \dots, X_n$ 为取自一总体的随机样本, 该总体的概率密度函数为

$$f_\theta(x) = \frac{\theta}{2\sqrt{x}} e^{-\theta\sqrt{x}}, \quad x > 0$$

当 $x < 0$ 时, $f_\theta(x) = 0$.

(1)(7 分) 求 θ 的极大似然估计;

(2)(8 分) 求 θ 的矩估计.

Solution: (1) 样本组成的似然函数是

$$L(\theta | x_1, \dots, x_n) = \frac{\theta^n}{2\sqrt{\prod_{i=1}^n x_i}} e^{-\theta \sum_{i=1}^n \sqrt{x_i}} \propto C(x_1, \dots, x_n) \theta^n e^{-\theta \sum_{i=1}^n \sqrt{x_i}},$$

则对数似然函数是

$$\ln L(\theta | X) = C_1(x_1, \dots, x_n) + n \ln \theta - \theta \sum_{i=1}^n \sqrt{x_i},$$

求导得 $\frac{\partial \ln L(\theta|X)}{\partial \theta} = \frac{n}{\theta} - \sum_{i=1}^n \sqrt{x_i}$, 解得 $\hat{\theta}_L = \frac{n}{\sum_{i=1}^n \sqrt{x_i}}$.

(2) 求期望, 有

$$\begin{aligned} EX &= \frac{\theta}{2} \int_0^{+\infty} \sqrt{x} e^{-\theta \sqrt{x}} dx \\ &= \frac{\theta}{2} \int_0^{+\infty} t e^{-\theta t} dt^2 \\ &= \frac{1}{\theta^2} \int_0^{+\infty} (\theta t)^2 e^{-\theta t} d(\theta t) = \frac{2}{\theta^2} \end{aligned}$$

用替换原理, 得 $\hat{\theta}_M = \sqrt{\frac{2}{\bar{x}}}$.

四、(15 分) 一个工厂考虑如下的检验问题 $H_0: p \leq 0.1 \longleftrightarrow H_1: p > 0.1$, 其中 p 是该工厂生产的一批元件的废品率. 先随机抽取两个元件检测, 如果这两个皆是废品, 则拒绝 H_0 ; 否则, 再抽取第 3 个元件检测, 若该元件为废品, 则拒绝 H_0 . 在其它情形下, 接受 H_0 . 求

(1)(7 分) 该检验的功效函数;

(2)(8 分) 该检验的真实水平.

Solution: 题设检验问题表示的是: 设 $X_1, X_2, X_3 \sim B(1, p)$, 拒绝域是

$$W = \{X_1 = 1, X_2 = 1\} \cup \left(\overline{\{X_1 = 1, X_2 = 1\}} \cap \{X_3 = 1\} \right).$$

(1) 根据上述分析, 很容易看出

$$\rho(p) = P_p \{ (X_1, X_2, X_3) \in W \} = p^2 + (1 - p^2)p = p + p^2 - p^3.$$

(2) 由于 $\rho'(p) = 1 + 2p - 3p^2 > 0$ 在 $0 \leq p \leq 0.1$ 时恒成立, 故假设检验的水平是

$$\alpha = \sup_{p \leq 0.1} \rho(p) = \rho(0.1) = 0.1 + (0.1)^2 - (0.1)^3 = 0.109.$$

五、(20 分) 设 $X_1, X_2, \dots, X_n$ 是从两点分布 $B(1, p)$ 中抽取的一组随机样本, $p \in [0, 1]$ 为未知参数.

(1)(10 分) 求充分完备统计量;

(2)(10 分) 求 $g(p) = p(1 - p)$ 的最小方差无偏估计.

Solution: (1) 似然函数是

$$L(p | x_1, \dots, x_n) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i},$$

根据因子分解定理, 知 $T = \sum_{i=1}^n X_i \sim B(n, p)$ 是充分统计量. 结合两点分布总体是指数族的事实, 知 $T = \sum_{i=1}^n X_i \sim B(n, p)$ 是充分完备统计量.

(2) 显然 $I_{\{X_1=1, X_2=0\}}$ 是 $g(p)$ 的无偏估计, 因此有 $E[I_{\{X_1=1, X_2=0\}} | T]$ 是由充分完备统计量构造的无偏估计, 是 UMVUE. 我们指出有

$$E[I_{\{X_1=1, X_2=0\}} | T] = \frac{T(n-T)}{n(n-1)},$$

即 $\frac{T(n-T)}{n(n-1)}$ 是 $g(p)$ 的 UMVUE. 因为当 $t = 0$ 时, $E[I_{\{X_1=1, X_2=0\}} | T = t] = 0$, 当 $t \geq 1$ 时, 有

$$\begin{aligned} E[I_{\{X_1=1, X_2=0\}} | T = t] &= P\left(X_1 = 1, X_2 = 0 \mid \sum_{i=1}^n X_i = t\right) \\ &= \frac{P(X_1 = 1, X_2 = 0, \sum_{i=3}^n X_i = t-1)}{P(\sum_{i=1}^n X_i = t)} \\ &= \frac{p(1-p)C_{n-2}^{t-1}p^{t-1}(1-p)^{n-t-1}}{C_n^t p^t (1-p)^{n-t}} \\ &= \frac{\frac{(n-2)!}{(t-1)!(n-t-1)!}}{\frac{n!}{t!(n-t)!}} = \frac{t(n-t)}{n(n-1)}. \end{aligned}$$

六、(20 分) 设 $X_1, X_2, \dots, X_n$ 是从正态总体 $N(\theta, 4)$ 取出的一组随机样本, 求检验问题

$$H_0: \theta \leq 2 \longleftrightarrow H_1: \theta > 2$$

的水平 α 的一致最优检验.

Solution: 对于正态总体而言, 题设检验等同于

$$H_0: \theta = 2 \quad \text{vs} \quad H_1: \theta = \theta_1 > 2$$

来自该正态总体的样本的似然函数是

$$L(\theta | x) = C \exp \left\{ -\frac{1}{8} \sum_{i=1}^n (x_i - \theta)^2 \right\} = C \exp \left\{ \frac{n\theta}{4} \bar{x} - \frac{\sum_{i=1}^n x_i^2}{8} + \frac{\theta^2}{8} \right\}$$

由 N-P 引理, 其 UMP 拒绝域应是 $\{\lambda(x) > c\}$, 其中

$$\lambda(x) = \frac{L(\theta_1 | x)}{L(2 | x)} = \exp \left\{ \frac{n\bar{x}}{4} (\theta_1 - 2) + \frac{\theta_1^2 - 4}{8} \right\},$$

其关于 $\bar{x}$ 是单调增函数, 因此 $\{\lambda(x) > c\} = \{\bar{x} > c_1\}$, 为使得其水平为 α , 故有

$$W = \left\{ \frac{\bar{x} - 2}{\sqrt{4/n}} > z_{1-\alpha} \right\}.$$

七、(25 分) 设 $X_1, X_2, \dots, X_n$ 是从标准正态总体取出的一组随机样本, 试

(1)(10 分) 证明 $\sum_{i=1}^n X_i^2$ 与 $\{X_1^2/\sum_{i=1}^n X_i^2, \dots, X_n^2/\sum_{i=1}^n X_i^2\}$ 相互独立.

(2)(15 分) 求 $\{X_1^2/\sum_{i=1}^n X_i^2, \dots, X_n^2/\sum_{i=1}^n X_i^2\}$ 的联合密度函数.

Solution:

(1) 作总体变换, 令 $Y_i = X_i^2 \sim \chi^2(1) = Ga(\frac{1}{2}, \frac{1}{2})$, 则 $Y_1, Y_2, \dots, Y_n$ 是来自卡方分布 (伽马分布) 总体的随机样本, $Ga(\frac{1}{2}, \frac{1}{2})$ 密度函数是 $\frac{1}{\sqrt{2\pi y}} e^{-\frac{y}{2}}$, 是指数族, 可以由联合密度及因子分解定理得知 $\sum_{i=1}^n Y_i$ 是充分完全统计量. 根据伽马分布是尺度族的事实, 得知 $(\frac{Y_1}{\sum_{i=1}^n Y_i}, \dots, \frac{Y_n}{\sum_{i=1}^n Y_i})$ 是尺度参数的辅助统计量, 由 Basu 定理, $\sum_{i=1}^n Y_i$ 与它们独立.

(2) 可以看出这个随机向量退化到 $n-1$ 维度, 因为它们之和是固定值, 因此只需考虑 $\{Y_2/\sum_{i=1}^n Y_i, \dots, Y_n/\sum_{i=1}^n Y_i\}$ 的密度函数 $p(t_2, t_3, \dots, t_n)$, 再令其表达式中出现的 $1 - \sum_{i=2}^n t_i$ 写为 t_1 便是它们的联合密度. 作变量变换, 令

$$\left\{ \begin{array}{l} U_1 = \sum_{i=1}^n Y_i, \\ U_2 = Y_2/U_1, \\ \vdots \\ U_n = Y_n/U_1, \end{array} \right. \xrightarrow{\text{反函数}} \left\{ \begin{array}{l} Y_1 = U_1(1 - \sum_{i=2}^n U_i), \\ Y_2 = U_1 U_2, \\ \vdots \\ Y_n = U_1 U_n, \end{array} \right. \xrightarrow{\text{对应}} \left\{ \begin{array}{l} y_1 = u_1(1 - \sum_{i=2}^n u_i), \\ y_2 = u_1 u_2, \\ \vdots \\ y_n = u_1 u_n, \end{array} \right.$$

有雅可比行列式 $|J| = u_1^{n-1}$ (将后面的每一行加到第一行计算), 且不妨将表达式中的 $u_2, u_3, \dots, u_n$ 写为 $t_2, t_3, \dots, t_n$, 并将式中出现的 $1 - \sum_{i=2}^n t_i$ 为 t_1 , 故

$$\begin{aligned} p(u_1, t_1, t_2, \dots, t_n) &= u_1^{n-1} f_Y(u_1 t_1, u_1 t_2, \dots, u_1 t_n) \\ &= \frac{(2\pi)^{-\frac{n}{2}} u_1^{\frac{n}{2}-1} e^{-\frac{u_1}{2}}}{\sqrt{t_1 t_2 \cdots t_n}}, \quad u_1 > 0, t_i > 0, \sum_{i=1}^n t_i = 1. \end{aligned}$$

我们发现,即使不用 Basu 定理,仅从联合密度也可以看出第 (1) 问的独立性. 因此发现题设要求的随机向量的密度函数就是上面的联合密度除以 $\sum_{i=1}^n Y_i$ 的密度, 即

$$p_T(t_1, t_2, \dots, t_n) = \frac{\Gamma\left(\frac{n}{2}\right)}{\sqrt{\pi^n t_1 t_2 \cdots t_n}}, \quad t_i > 0, \sum_{i=1}^n t_i = 1.$$

事实上,也可直接从第 (1) 问的结论出发,根据独立性可以知道 $(Y_1, \dots, Y_n)$ 的联合密度函数应该是 $\left(\frac{Y_1}{\sum_{i=1}^n Y_i}, \dots, \frac{Y_n}{\sum_{i=1}^n Y_i}\right)$ 的联合密度函数与 $\sum_{i=1}^n Y_i$ 的密度函数的乘积. 反过来利用 $(Y_1, \dots, Y_n)$ 的联合密度函数除以 $\sum_{i=1}^n Y_i$ 的密度函数便可更加迅速地得到 $\left(\frac{Y_1}{\sum_{i=1}^n Y_i}, \dots, \frac{Y_n}{\sum_{i=1}^n Y_i}\right)$ 的联合密度函数.

八、(25 分) $(X_1, Y_1), \dots, (X_n, Y_n)$ 是来自以 $x = 0, y = 0, x + y = \theta > 0$ 围成的均匀分布总体的 i.i.d. 样本, 试求

(1)(10 分) θ 的充分完备统计量.

(2)(15 分) e^θ 的最小方差无偏估计.

(1) 似然函数为

$$L(\theta) = \frac{2^n}{\theta^{2n}} I_{\{X_{(1)} \geq 0, Y_{(1)} \geq 0\}} I_{\{\max\{X_i + Y_i\} \leq \theta\}},$$

根据因子分解定理, $T_{(n)} = \max\{X_{(i)} + Y_{(i)}\}$ 是充分统计量. 我们不妨记 $T_i = X_i + Y_i$, 则对任意的 $t \in (0, \theta)$, 有

$$F_T(t) = P(T_i \leq t) = P(X_i + Y_i \leq t) = \frac{t^2/2}{\theta^2/2} = \frac{t^2}{\theta^2}.$$

所以诸 T_i 独立同分布, 密度函数为

$$f_T(t) = \frac{2t}{\theta^2}, 0 \leq t \leq \theta.$$

注意到实际上有 $T/\theta \sim \text{Beta}(2, 1)$. 容易算得 $T_{(n)}$ 的密度函数为

$$f_{T_{(n)}}(t) = \frac{2n}{\theta^{2n}} t^{2n-1}, 0 \leq t \leq \theta.$$

且注意到 $T_{(n)}/\theta \sim \text{Beta}(2n, 1)$. 现证明 $T_{(n)}$ 是完备的, 假设存在一个函数 $g(\cdot)$ 使得 $E_\theta[g(T_{(n)})] = 0$ 对任意 $\theta > 0$ 恒成立, 即

$$0 = \int_0^\theta g(t) \frac{2n}{\theta^{2n}} t^{2n-1} dt = \frac{2n}{\theta^{2n}} \int_0^\theta g(t) t^{2n-1} dt,$$

故有 $0 = \int_0^\theta g(t) t^{2n-1} dt$, 两侧求导得 $g(\theta) \theta^{2n-1} = 0$ 对任意 $\theta > 0$ 恒成立, 故 $g(x) \equiv 0, \forall x > 0$, 因此有 $g(T) = 0$, a.s., 这说明了 $T_{(n)}$ 是完备的. 因此有 $T_{(n)}$ 是 θ 的充分完备统计量.

(2) 设存在函数 $h(\cdot)$ 使得 $E_\theta[h(T_{(n)})] = e^\theta$ 对任意 $\theta > 0$ 恒成立, 即

$$\int_0^\theta h(t) \frac{2n}{\theta^{2n}} t^{2n-1} dt = e^\theta,$$

化简后得

$$\int_0^\theta h(t) t^{2n-1} dt = \frac{1}{2n} \theta^{2n} e^\theta,$$

两侧求导并化简得

$$\begin{aligned} h(\theta) \theta^{2n-1} &= \frac{1}{2n} (2n \theta^{2n-1} e^\theta + \theta^{2n} e^\theta) \\ h(\theta) &= \frac{1}{2n} (2n e^\theta + \theta e^\theta) = e^\theta \left(1 + \frac{\theta}{2n}\right) \end{aligned}$$

验证有 $E\left[e^{T_{(n)}} \left(1 + \frac{T_{(n)}}{2n}\right)\right] = e^\theta$, 故根据 Lehmann-Scheffe 定理, $e^{T_{(n)}} \left(1 + \frac{T_{(n)}}{2n}\right)$ 是 e^θ 的 UMVUE.

中国科学技术大学-812 概率论与数理统计-2021 年

一、(20 分) 若河边仅有一个码头, 甲乙两船在 0:00-24:00 之间, 等可能的在任意时刻到达码头, 且到达时刻独立。若甲到达码头需停靠 2h, 乙需停靠 1h。问:

(1)(10 分) 甲乙停靠时间间隔大于 2h 的概率。

(2)(10 分) 一艘船到达后需要等待一段时间的概率。

Solution: (1) 设 X, Y 分别是甲乙到达的时间, 它们是 i.i.d. 的服从 $U(0, 24)$ 的随机变量, 则有类似几何分布:

$$P(|X - Y| > 2) = \frac{22 \times 22}{24 \times 24} = \frac{121}{144}.$$

(2) 需要等待意味着 $A = \{-2 < X - Y < 1\}$, 该概率是

$$P(A) = 1 - \frac{\frac{1}{2} \cdot 22 \cdot 22 + \frac{1}{2} \cdot 23 \cdot 23}{24 \cdot 24} = \frac{139}{1152}.$$

二、(20 分) 随机向量 (X, Y) 有联合密度 $f(x, y) = C(1 + xy)I_{\{|x| < 1, |y| < 1\}}$.

(1)(5 分) 求 C ;

(2)(5 分) 求 $X = x$ 时, Y 的条件分布;

(3)(10 分) 证明 X^2 与 Y^2 独立。

Solution: (1) 积分, 有 $\int_{-1}^1 \int_{-1}^1 (1 + xy) dx dy = 4$, 故有 $C = 1/4$.

(2) 先求 f_X , 有 $f_X(x) = \int_{-1}^1 \frac{1}{4}(1 + xy) dy = \frac{1}{2}$, 是均匀分布, 故条件分布是

$$f_{Y|X}(y|x) = \frac{1}{2}(1 + xy), \quad |x| < 1, |y| < 1.$$

(3) 令 $U = X^2, V = Y^2$, 有

$$P(U \leq u, V \leq v) = \int_{-\sqrt{u}}^{\sqrt{u}} \int_{-\sqrt{v}}^{\sqrt{v}} \frac{1}{4}(1 + xy) dx dy = \sqrt{u}\sqrt{v},$$

其中 $u \in (0, 1), v \in (0, 1)$, 而边际分布是

$$P(U \leq u) = P(-\sqrt{u} \leq X \leq \sqrt{u}) = \sqrt{u},$$

同理 $P(V \leq v) = \sqrt{v}$, 因此我们发现它们独立。

三、(20 分) 盒中有大小形状相同的 n 个白球, m 个黑球, 依次从中取出 k 个球, $k < n + m$, 记 X 为取出球中白球的个数, I_j 为第 j 次取出的球为白球的示性随机变量, $j \leq k$.

(1)(5 分) 求 I_j 的分布;

(2)(5 分) 求 (I_i, I_j) 的分布, $i < j \leq k$;

(3)(10 分) 求 $E(X), \text{Var}(X)$.

Solution: (1) 根据抽签与顺序无关, 任意一次取出白球的概率都是 $\frac{n}{n+m}$, 取出黑球的概率是 $\frac{m}{n+m}$, 故 $I_j \sim B(1, \frac{n}{n+m})$.

(2) 第 i 次和第 j 次都取出白球的概率是 $\frac{n}{n+m} \frac{n-1}{n+m-1}$, 同理, 有

$$|I_i = 0|I_i = 1| \quad |I_j = 0|I_j = 1| \quad \begin{aligned} & \frac{m}{n+m} \frac{m-1}{n+m-1} \quad \frac{n}{n+m} \frac{n-1}{n+m-1} \\ & \frac{n}{n+m} \frac{m}{n+m-1} \quad \frac{m}{n+m} \frac{n}{n+m-1} \end{aligned}$$

(3) 显然 $X = \sum_{i=1}^k I_i$, 故有 $E(X) = \frac{nk}{n+m}$, 方差略麻烦一些, 有

$$\text{Var}(X) = \text{Var}\left(\sum_{i=1}^k I_i\right) = k\text{Var}(I_1) + k(k-1)\text{Cov}(I_1, I_2),$$

其中 $Var(I_1) = \frac{nm}{(n+m)^2}$,

$$Cov(I_1, I_2) = \frac{n(n-1)}{(n+m)(n+m-1)} - \frac{n^2}{(n+m)^2},$$

汇总后有

$$Var(X) = \frac{kmn(m+n-k)}{(m+n)^2(m+n-1)}.$$

四、(15 分) 证明: 随机变量序列 $\{X_n\}$ 依概率收敛于 0 的充分必要条件是

$$E \left[\frac{|X_n|}{1+|X_n|} \right] \rightarrow 0.$$

Solution: 先证必要性: 已知 X_n 依概率收敛于 0, 考虑到当 $x > 0$ 时, $g(x) = \frac{x}{1+x} \leq 1$ 有界, 根据有界收敛定理, 有

$$\lim_{n \rightarrow \infty} E \left[\frac{|X_n|}{1+|X_n|} \right] = E \left[\lim_{n \rightarrow \infty} \frac{|X_n|}{1+|X_n|} \right] = E[0] = 0.$$

再证充分性: 已知 $E \left[\frac{|X_n|}{1+|X_n|} \right] \rightarrow 0$, 考虑到当 $x > 0$ 时, $g(x) = \frac{x}{1+x}$ 单调, 故对任意 $\varepsilon > 0$, 有

$$P(|X| > \varepsilon) = E \left[I_{\{|X| > \varepsilon\}} \right] = E \left[I_{\{g(|X|) > g(\varepsilon)\}} \right] \leq \frac{1}{g(\varepsilon)} E \left[g(|X|) I_{\{|X| > \varepsilon\}} \right] \leq \frac{1}{g(\varepsilon)} E \left[\frac{|X_n|}{1+|X_n|} \right],$$

充分性得证.

五、(20 分) 设 $X_1, \dots, X_n$ 来自离散分布 $P(X=0) = \frac{2(1-\theta)}{2-\theta}, P(X=1) = \frac{\theta}{2-\theta}$ 的随机样本, 其中 $\theta \in (0, 1)$, 求:

(1)(5 分) θ 的矩估计 $\hat{\theta}_1$;

(2)(5 分) θ 的最大似然估计 $\hat{\theta}_2$;

(3)(10 分) $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 的渐近分布.

Solution: (1) 求期望, 有

$$E(X_1) = \frac{\theta}{2-\theta},$$

用样本矩替换并反解, 得到 $\hat{\theta}_1 = \frac{2\bar{x}}{1+\bar{x}}$.

(2) 根据两点分布的 MLE 及其不变性, 有 $\frac{\hat{\theta}_2}{2-\hat{\theta}_2} = \bar{x}$, 反解得 $\hat{\theta}_2 = \frac{2\bar{x}}{1+\bar{x}}$.

(3) 由 CLT, 我们有

$$\sqrt{n} \left(\bar{x} - \frac{\theta}{2-\theta} \right) \xrightarrow{d} N \left(0, \frac{2\theta(1-\theta)}{(2-\theta)^2} \right),$$

令 $g(x) = \frac{2x}{1+x}$, 求导有 $g'(x) = \frac{2}{(1+x)^2}$, $g' \left(\frac{\theta}{2-\theta} \right) = \frac{(2-\theta)^2}{2} \neq 0$, 故由 Delta 方法, 我们有

$$\sqrt{n} (g(\bar{x}) - \theta) \xrightarrow{d} \frac{(2-\theta)^2}{2} N \left(0, \frac{2\theta(1-\theta)}{(2-\theta)^2} \right) = N \left(0, \frac{\theta(1-\theta)(2-\theta)^2}{2} \right).$$

六、(20 分) 为调查某商品在商场货架上的滞留时间, 随机调查 9 个样本的滞留时间 $X_1, \dots, X_9$, 其中计算得到 $\bar{x} = 131$, 假设总体 $X \sim N(\mu, 9)$. $u_{0.95} = 1.645$.

(1)(5 分) 检验 $H_0: \mu \leq 130$, 备择假设是其对立, $\alpha = 0.05$.

(2)(5 分) 若 $\mu = 131$, 样本量改为 n , 求犯第二类错误的概率 β , 并指出: 想要 $\beta \leq 0.05$, 我们应该需要多少样本.

(3)(10 分) 求 $\theta = P(X \leq 130)$ 的 MLE, 并给出 95% 置信下限.

Solution: (1) 拒绝域是

$$W = \left\{ \sqrt{n} \frac{\bar{x} - 130}{\sigma} = \bar{x} - 130 > 1.645 \right\}$$

现在 $\bar{x} - 130 = 1$, 不落入拒绝域, 不能拒绝原假设.

(2) 犯第二类错误的概率是

$$\begin{aligned}\beta &= P\left(\sqrt{n}\frac{\bar{x}-130}{3} < 1.645 \mid \mu = 131\right) = P\left(\bar{x} - 131 < -1 + \frac{3}{\sqrt{n}}1.645 \mid \mu = 131\right) \\ &= \Phi\left(\frac{\sqrt{n}}{3}\left(-1 + \frac{3}{\sqrt{n}}1.645\right)\right) = \Phi\left(-\frac{\sqrt{n}}{3} + 1.645\right),\end{aligned}$$

令其小于 0.05, 则有

$$-\frac{\sqrt{n}}{3} + 1.645 < -1.645,$$

解得 $\sqrt{n} > 9.87$, 故 $n > 97.42$, 取 $n = 98$.

(3) 计算得

$$g(\mu) = P(X \leq 130) = P\left(\frac{X - \mu}{3} \leq \frac{130 - \mu}{3}\right) = \Phi\left(\frac{130 - \mu}{3}\right),$$

由 MLE 不变性, 有 $\hat{g} = \Phi\left(\frac{130 - \bar{x}}{3}\right) = \Phi(-1/3)$. 而由于 Φ 是单调函数, $g(\mu)$ 是 μ 单调减函数, 故有

$$\{\mu \leq a\} = \{g(\mu) \geq g(a)\},$$

我们可以选 a 为 μ 的 0.95 置信上限, 即 $a = \bar{x} + 1.645$, 故有

$$g(a) = \Phi\left(\frac{130 - \bar{x} - 1.645}{3}\right) = \Phi\left(\frac{-2.645}{3}\right)$$

是 $g(\mu)$ 的 0.95 置信下限.

七、(20 分) 人的早晚收缩压 $(X, Y) \sim N(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2, \rho)$, 随机抽取 n 人, 其中 $n - m$ 人有早晚数据 $(X_1, Y_1), \dots, (X_{n-m}, Y_{n-m})$, 剩下 m 人只有早上数据 $X_{n-m+1}, \dots, X_n$, 令 $\beta = \rho \frac{\sigma_y}{\sigma_x}$. 只有 μ_x, μ_y 是待估参数.

(1)(10 分) 求 μ_y 的 MLE $\hat{\mu}_y$;

(2)(10 分) 证明 $\hat{\mu}_y$ 是无偏估计, 并求条件方差 $\text{Var}(\hat{\mu}_y | X_1, \dots, X_n)$.

Solution: (1) 写出对数似然函数, 有

$$\ell(\mu_x, \mu_y) = C - \frac{\sum_{i=1}^{n-m} \left[\frac{(x_i - \mu_x)^2}{\sigma_x^2} - \frac{2\rho(x_i - \mu_x)(y_i - \mu_y)}{\sigma_x \sigma_y} + \frac{(y_i - \mu_y)^2}{\sigma_y^2} \right]}{2(1 - \rho^2)} - \frac{\sum_{i=n-m+1}^n (x_i - \mu_x)^2}{2\sigma_x^2},$$

求导, 有

$$\begin{cases} \frac{\partial \ell}{\partial \mu_x} = \frac{1}{1 - \rho^2} \sum_{i=1}^{n-m} \left(\frac{x_i - \mu_x}{\sigma_x^2} - \rho \frac{y_i - \mu_y}{\sigma_x \sigma_y} \right) + \sum_{i=n-m+1}^n \frac{x_i - \mu_x}{\sigma_x^2}, \\ \frac{\partial \ell}{\partial \mu_y} = \frac{1}{1 - \rho^2} \sum_{i=1}^{n-m} \left(\frac{y_i - \mu_y}{\sigma_y^2} - \rho \frac{x_i - \mu_x}{\sigma_x \sigma_y} \right), \end{cases}$$

令第二个式子为 0, 得

$$\mu_y = \frac{\sum_{i=1}^{n-m} y_i}{n - m} - \frac{\beta \sum_{i=1}^{n-m} x_i}{n - m} + \beta \mu_x,$$

而令第一个式子即 $\frac{\partial \ell}{\partial \mu_x} = 0$, 得

$$\sum_{i=1}^{n-m} (x_i - \mu_x) - (1 - \rho^2) \sum_{i=n-m+1}^n (x_i - \mu_x) + \frac{\rho \sigma_x}{\sigma_y} \sum_{i=1}^{n-m} (y_i - \mu_y) = 0,$$

代入 $\mu_y = \frac{\sum_{i=1}^{n-m} y_i}{n - m} - \frac{\beta \sum_{i=1}^{n-m} x_i}{n - m} + \beta \mu_x$, 解得 $\hat{\mu}_x = \bar{x} = \frac{\sum_{i=1}^n x_i}{n}$, 故有

$$\hat{\mu}_y = \bar{y}_{n-m} - \beta(\bar{x}_{n-m} - \bar{x}_n),$$

这里我们用 $\bar{x}_{n-m}$ 表示用前 $n-m$ 个样本计算的样本均值.

(2) 求期望, 由于 $E(\bar{y}_{n-m}) = \mu_y$, $E(\bar{x}_{n-m}) = E(\bar{x}_n) = \mu_x$, 因此很显然 $E(\hat{\mu}_y) = \mu_y$.

再考虑方差, 当 $X_1, \dots, X_n$ 已知, $\hat{\mu}_y$ 中只有 $\bar{y}_{n-m}$ 需要被考虑, 剩下的部分已经是已知了, 而

$$y_i | (X_1, \dots, X_n) \sim N \left(\mu_y + \beta (x_i - \mu_x), (1 - \rho^2) \sigma_y^2 \right),$$

从 $i = 1, 2, \dots, n-m$ 求一个平均, 有

$$E(\bar{y}_{n-m} | \mathbf{X}) = \frac{1}{n-m} \sum_{i=1}^{n-m} (\mu_y + \beta (x_i - \mu_x)) = \mu_y + \beta (\bar{x}_{n-m} - \mu_x), \quad \text{Var}(\bar{y}_{n-m} | \mathbf{X}) = \frac{(1 - \rho^2) \sigma_y^2}{n-m},$$

故条件分布应为

$$\hat{\mu}_y | (X_1, \dots, X_n) \sim N \left(\mu_y + \beta (\bar{x}_n - \mu_x), \frac{(1 - \rho^2) \sigma_y^2}{n-m} \right),$$

因此条件方差是 $\frac{(1-\rho^2)\sigma_y^2}{n-m}$.

八、(15 分) 设有线性模型

$$Y = X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I_n),$$

其中

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix},$$

对于 $\lambda > 0$, 定义

$$\hat{\beta} = \arg \min_{\beta} \left\{ \|Y - X\beta\|^2 + \lambda \|\beta\|^2 \right\}.$$

(1)(7 分) 试求残差平方和 $SSE(\lambda) = \|Y - X\hat{\beta}\|^2$ 的期望.

(2)(8 分) 记 $S_\lambda = X(X^T X + \lambda I_p)^{-1} X^T$, 证明:

$$\sum_{i=1}^n (y_i - x_i^T \hat{\beta}_{-i})^2 = \sum_{i=1}^n \left(\frac{y_i - x_i^T \hat{\beta}}{1 - S_\lambda(i, i)} \right)^2,$$

其中 $\hat{\beta}_{-i}$ 是去除掉数据 (x_i, y_i) 后的估计量, 而 $S_\lambda(i, i)$ 是矩阵 S_λ 的 (i, i) 元.

Solution: (1) 令 $Q(\beta) = \|Y - X\beta\|^2 + \lambda \|\beta\|^2$, 求导有

$$\frac{\partial Q}{\partial \beta} = -2X^T(Y - X\beta) + 2\lambda\beta = 2(X^T X + \lambda I_p)\beta - 2X^T Y,$$

得 $\hat{\beta} = (X^T X + \lambda I_p)^{-1} X^T Y$, 即岭回归解. 而

$$SSE(\lambda) = (Y - X\hat{\beta})^T (Y - X\hat{\beta}) = Y^T (I_n - S_\lambda)^T (I_n - S_\lambda) Y,$$

而对矩阵 A , 有

$$\begin{aligned} E(Y^T A Y) &= E(\text{tr}\{Y^T A Y\}) = E(\text{tr}\{A Y Y^T\}) = \text{tr}\{E(A Y Y^T)\} \\ &= \text{tr}\{A E(Y Y^T)\} = \text{tr}\left\{A \cdot (\sigma^2 I_n + X\beta\beta^T X^T)\right\} \\ &= \sigma^2 \text{tr}\{A\} + \text{tr}\{A X\beta\beta^T X^T\} = \sigma^2 \text{tr}\{A\} + \text{tr}\{\beta^T X^T A X \beta\} \\ &= \sigma^2 \text{tr}\{A\} + \beta^T X^T A X \beta, \end{aligned}$$

代入 $A = (I_n - S_\lambda)^T (I_n - S_\lambda)$, 有

$$E(SSE(\lambda)) = \sigma^2 \text{tr} \left\{ (I_n - S_\lambda)^T (I_n - S_\lambda) \right\} + \beta^T X^T (I_n - S_\lambda)^T (I_n - S_\lambda) X \beta.$$

(2) 显然,

$$\begin{aligned} \hat{\beta}_{-i} &= \left(X^T X - x_i x_i^T + \lambda I_p \right)^{-1} X_{-i}^T Y_{-i} \\ &= \left(X^T X + \lambda I_p - x_i x_i^T \right)^{-1} \left(X^T Y - x_i y_i \right), \end{aligned}$$

利用下述逆展开公式:

$$\left(\Sigma + \mu v^T \right)^{-1} = \Sigma^{-1} - \frac{\Sigma^{-1} \mu v^T \Sigma^{-1}}{1 + \mu^T \Sigma^{-1} v},$$

记 $A = X^T X + \lambda I_p$, 我们得到

$$\left(A - x_i x_i^T \right)^{-1} = A^{-1} + \frac{A^{-1} x_i x_i^T A^{-1}}{1 - x_i^T A^{-1} x_i} = A^{-1} + \frac{A^{-1} x_i x_i^T A^{-1}}{1 - S_\lambda(i, i)},$$

其中 $x_i^T A^{-1} x_i = S_\lambda(i, i)$, 进而有

$$\hat{\beta}_{-i} = \hat{\beta} + \frac{A^{-1} x_i x_i^T}{1 - S_\lambda(i, i)} \hat{\beta} - \frac{A^{-1} x_i y_i}{1 - S_\lambda(i, i)},$$

代入 $y_i - x_i^T \hat{\beta}_{-i}$, 注意利用 $x_i^T A^{-1} x_i = S_\lambda(i, i)$, 得

$$y_i - x_i^T \hat{\beta}_{-i} = y_i - x_i^T \hat{\beta} + \frac{S_\lambda(i, i)}{1 - S_\lambda(i, i)} x_i^T \hat{\beta} - \frac{S_\lambda(i, i)}{1 - S_\lambda(i, i)} y_i = \frac{y_i - x_i^T \hat{\beta}}{1 - S_\lambda(i, i)},$$

因此结论得证.

中国科学技术大学-812 概率论与数理统计-2022 年

一、(15 分) 构造一个二维随机变量 (X, Y) 的联合 p.d.f, 使得 X 的边缘密度函数为

$$f_X(x) = \frac{2}{\pi(b^2 - a^2)} \left[\sqrt{(b^2 - x^2)_+} - \sqrt{(a^2 - x^2)_+} \right]$$

其中 $(\cdot)_+$ 表示 $\cdot$ 的正部.

Solution:

$$f(x, y) = \frac{2}{\pi(b^2 - a^2)}, a < x^2 + y^2 < b^2, y > 0$$

二、(20 分) 现有 I^+, I^- 两种信号, 向后依次传播, 传播出错的概率是 p . 设初始信号为 I^+ , 求

(1) 传播两次后, 信号还是 I^+ 的概率;

(2) 传播 n 次后, 信号是 I^- 的概率.

Solution:

(1) 直接计算即可, 变了 2 次或没变, 概率是 $p^2 + (1-p)^2$,

(2) 这题类似茆书中"第一天晴天, 求第 n 天也是晴天的概率", 可以用递推法给出答案. 除了递推法, 我们还可以设 n 次中的传播出错的次数 $X \sim B(n, p)$, 则目标即为求 X 是奇数的概率, 我们考虑其对应的母函数

$$\psi_X(s) = E[s^X] = \sum_{k=0}^n s^k C_n^k p^k q^{n-k} = (ps + q)^n.$$

而

$$1 = \psi_X(1) = E[1^X] = P(X \text{ 取奇}) + P(X \text{ 取偶}),$$

$$(q-p)^n = \psi_X(-1) = E[(-1)^X] = 1 \cdot P(X \text{ 取偶}) - 1 \cdot P(X \text{ 取奇}),$$

因此我们有

$$P(X \text{ 取奇}) = \frac{1 - (q-p)^n}{2} = \frac{1 - (1-2p)^n}{2}.$$

三、(15 分) (X, Y) 有联合密度函数

$$f(x, y) = \frac{2}{(n+1)!} (2y+x)^n e^{-2y-x}, x > 0, y > 0$$

设 $U = 2Y + X, V = 3X + 8Y$.

(1) 求 (U, V) 的联合分布以及 U 的边缘分布;

(2) 求 $V | U = u$ 的条件分布;

(3) 求 $E(X | U = u)$ 以及 $E(Y | U = u)$.

Solution: (1)

$$f_{U,V}(u, v) = \frac{u^n e^{-u}}{(n+1)!}, 3u < v < 4u$$

$$f_U(u) = \frac{u^{n+1} e^{-u}}{(n+1)!}, u > 0$$

(2) $(3u, 4u)$ 上的均匀分布;

(3)

$$E(X | U = u) = E(4U - V | U = u) = 4u - \frac{7}{2}u = \frac{1}{2}u$$

$$E(Y | U = u) = E\left(-\frac{3}{2}U + \frac{1}{2}V | U = u\right) = -\frac{3}{2}u + \frac{7}{4}u = \frac{1}{4}u$$

四、(20 分) X, Y, Z, W, V, Q 服从独立标准正态分布, 求 $T = \frac{(XW+YV+ZQ)^2}{W^2+V^2+Q^2}$ 的分布.

Solution: 先考虑 $U = \frac{XW+YV+ZQ}{\sqrt{W^2+V^2+Q^2}}$ 关于 W, V, Q 的条件分布, 有

$$P(U \leq t | W = w, V = v, Q = q) = \Phi(t)$$

不依赖于 w, v, q , 这里 $\Phi(t)$ 是标准正态 c.d.f, 而又注意到上式左侧是关于 t, w, v, q 的函数, 故记其为 $G(t, w, v, q)$, U 的无条件分布即

$$P(U \leq t) = E[G(t, W, V, Q)] = E[\Phi(t)] = \Phi(t)$$

所以 $U \sim N(0, 1)$, $T = U^2 \sim \chi_1^2$.

五、(15 分) 已知 $X_n \rightarrow_p X$, 试证 $X_n^2 \rightarrow_p X^2$.

Solution: 按定义即可, 茆书上便有.

六、(30 分) $X_1, X_2, \dots, X_n$ 是来自泊松分布总体 $\mathcal{P}(\theta)$ 的简单随机样本. 以 $T_n = (1 - \frac{1}{n}) \sum_{i=1}^n X_i$ 作为 $e^{-\theta}$ 的估计. 试问

(1) T_n 是否是无偏估计?

(2) T_n 是否是 UMVUE?

(3) T_n 是否是有效估计?

Solution: (1) 注意到 $Y = \sum_{i=1}^n X_i \sim \mathcal{P}(n\theta)$, 则有

$$\begin{aligned} E(T_n) &= E\left[\left(1 - \frac{1}{n}\right)^Y\right] = \sum_{k=0}^{+\infty} \left(1 - \frac{1}{n}\right)^k \frac{(n\theta)^k}{k!} e^{-n\theta} \\ &= e^{-n\theta} e^{(n-1)\theta} \sum_{k=0}^{+\infty} \frac{[(n-1)\theta]^k}{k!} e^{-(n-1)\theta} \\ &= e^{-\theta} \end{aligned}$$

故 T_n 是无偏估计.

(2) 根据完备指数族的性质, $Y = \sum_{i=1}^n X_i \sim \mathcal{P}(n\theta)$ 是 θ 的充分完备统计量, 而 T_n 是基于其构造的 $e^{-\theta}$ 的无偏估计, 因此根据 Lehmann-Scheffe 定理, 它是 UMVUE.

(3) 先计算 C-R 下界, Fisher 信息量是

$$I(\theta) = -E\left[\frac{\partial^2 f(X; \theta)}{\partial \theta^2}\right] = -E\left[-\frac{X}{\theta^2}\right] = \frac{1}{\theta}$$

故 $g(\theta) = e^{-\theta}$ 无偏估计方差的下界是 $\frac{[g'(\theta)]^2}{nI(\theta)} = \frac{\theta}{n} e^{-2\theta}$.

再计算 T_n 的方差, 首先有

$$\begin{aligned} E(T_n^2) &= \sum_{k=0}^{+\infty} \left(1 - \frac{1}{n}\right)^{2k} \frac{(n\theta)^k}{k!} e^{-n\theta} \\ &= \sum_{k=0}^{+\infty} \frac{[(n-2+\frac{1}{n})\theta]^k}{k!} e^{-n\theta} \\ &= e^{-n\theta} e^{(n-2+\frac{1}{n})\theta} \sum_{k=0}^{+\infty} \frac{[(n-2+\frac{1}{n})\theta]^k}{k!} e^{-(n-2+\frac{1}{n})\theta} \\ &= e^{(\frac{1}{n}-2)\theta} \end{aligned}$$

则

$$Var(T_n) = E(T_n^2) - (ET_n)^2 = e^{(\frac{1}{n}-2)\theta} - e^{-2\theta} = e^{-2\theta} \left(e^{\frac{\theta}{n}} - 1\right) > \frac{\theta}{n} e^{-2\theta}$$

因此它不是有效估计.

注: 虽然此处 T_n 不是有效估计, 但它是渐近有效的.

七、(10 分) 现有正态分布 $\mathcal{N}(\mu, 1)$ 的 n 个样本 $x_1, x_2, \dots, x_n$, 取值小于 0 时记为 1, 否则记为 0, 求 μ 的 MLE.

Solution: $P(x_1 = 1) = P(X < 0) = \Phi(-\mu)$, 故 $x_i \sim b(1, \Phi(-\mu))$. 于是 $\Phi(-\mu)$ 的 MLE 是 $\bar{x}$, 根据 MLE 的不变性有 $\hat{\mu} = -\Phi^{-1}(\bar{x})$.

八、(25 分) 回归结果解读.

中国科学技术大学-812 概率论与数理统计-2023 年

一、(16 分) 袋中有 a 个白球和 b 个黑球. 第一次如果摸出白球则放回, 同时再放进一个白球, 如果第一次摸出黑球同理. 以此类推, 第 k , 如果摸出白球则放回, 同时再放进 k 个白球, 黑球同理. 问第 n 次摸到白球的概率.

Solution: 设第 $n-1$ 次取球后, 第 n 次取球前, 袋中白球数为 X_n , 此时袋中总球数应为

$$(a+b) + \sum_{k=1}^{n-1} k = (a+b) + \frac{(n-1)n}{2},$$

故所求概率是 $p_n = \frac{E(X_n)}{(a+b) + \frac{(n-1)n}{2}}$. 现用条件期望法求 $E(X_n)$, 当 $X_{n-1} = x$ 给定时, 有

$$\begin{aligned} E(X_n | X_{n-1} = x) &= (x+n-1) \cdot \frac{x}{(a+b) + \frac{(n-2)(n-1)}{2}} + x \cdot \left(1 - \frac{x}{(a+b) + \frac{(n-2)(n-1)}{2}}\right) \\ &= \frac{(a+b) + \frac{(n-1)n}{2}}{(a+b) + \frac{(n-2)(n-1)}{2}} x, \end{aligned}$$

这说明了

$$E(X_n | X_{n-1}) = \frac{(a+b) + \frac{(n-1)n}{2}}{(a+b) + \frac{(n-2)(n-1)}{2}} X_{n-1},$$

重期望公式揭示了

$$E(X_n) = \frac{(a+b) + \frac{(n-1)n}{2}}{(a+b) + \frac{(n-2)(n-1)}{2}} E(X_{n-1}), \Rightarrow \frac{E(X_n)}{(a+b) + \frac{(n-1)n}{2}} = \frac{E(X_{n-1})}{(a+b) + \frac{(n-2)(n-1)}{2}},$$

这也说明

$$p_n = p_{n-1} = \cdots = p_1 = \frac{a}{a+b}.$$

二、(20 分) 设总体的分布是 $f(x) = 3x^2, 0 < x < 1$, 从中抽取 i.i.d. 样本 $x_1, \cdots, x_n$.

(1) 求 $(x_{(1)}, \cdots, x_{(n)})$ 即次序统计量的密度函数;

(2) 证明: $\frac{X_{(i)}}{X_{(j)}}, X_{(j)}$ 独立, 其中 $1 \leq i < j \leq n$.

Solution: (1) 联合密度是

$$f(X) = 3^n \prod_{i=1}^n x_i^2, \quad 0 < x_i < 1,$$

由次序统计量密度公式有

$$p(x_{(1)}, \cdots, x_{(n)}) = n! 3^n \prod_{i=1}^n x_{(i)}^2, \quad 0 < x_{(1)} < \cdots < x_{(n)} < 1.$$

(2) 根据次序统计量密度公式, $(X_{(i)}, X_{(j)})$ 的密度是

$$\begin{aligned} p_{i,j}(u, v) &= \frac{n!}{(i-1)!(j-i-1)!(n-j)!} u^{3(i-1)} \cdot 3u^2 \cdot (v^3 - u^3)^{j-i-1} \cdot 3v^2 \cdot (1-v^3)^{n-j} \\ &= C \cdot u^{3i-1} v^2 (v^3 - u^3)^{j-i-1} (1-v^3)^{n-j}, \quad 0 < u < v < 1, \end{aligned}$$

作变量变换:

$$\begin{cases} Z = \frac{X_{(i)}}{X_{(j)}}, \\ W = X_{(j)}, \end{cases} \Rightarrow \begin{cases} z = \frac{u}{v}, \\ w = v, \end{cases} \Rightarrow \begin{cases} u = zw, \\ v = w, \end{cases}$$

对应的雅可比行列式是 $J = \begin{vmatrix} w & z \\ 0 & 1 \end{vmatrix} = w$, 因此有

$$\begin{aligned} p_{Z,W}(z, w) &= wp_{i,j}(zw, w) = wC(zw)^{3i-1}w^2(w^3 - (zw)^3)^{j-i-1}(1-w^3)^{n-j} \\ &= Cz^{3i-1}(1-z^3)^{j-i-1}w^{3j-1}(1-w^3)^{n-j}, \quad 0 < z < 1, 0 < w < 1. \end{aligned}$$

可因式分解, Z, W 独立.

三、(16 分) 设 (X, Y) 的密度函数是

$$f(x, y) = \begin{cases} \frac{1}{4}(1 - \frac{1}{2}|x - y|), & (x, y) \in D_1, \\ 0, & \text{其他,} \end{cases}$$

其中 $D_1 = \{(x, y) : |x + y| < 2, |x - y| < 2\}$.

(1) 求 $X + Y$ 的分布函数;

(2) 给定 $X = Y$, 求 $X + Y$ 的条件分布.

Solution: (1) 作变量变换: $U = X + Y, V = X - Y$, 有 $|u| < 2, |v| < 2$, 得到 (U, V) 的 p.d.f. 是

$$f_{U,V}(u, v) = |J|f\left(\frac{u+v}{2}, \frac{u-v}{2}\right) = \frac{1}{8}(1 - |v|), \quad -2 < u < 2, -2 < v < 2,$$

它们独立, 且 U 是 $(-2, 2)$ 上均匀分布. 故有 U 的 c.d.f. 是

$$P(U \leq u) = \frac{u+2}{4}, \quad u \in (-2, 2).$$

(2) $X = Y$ 对应 $V = 0$, 然而 (U, V) 独立, 故此时 U 的条件分布还是 $U(-2, 2)$.

四、(16 分) 已知标准柯西分布密度函数

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in R,$$

且有 $X_1, \dots, X_n$ 是 i.i.d. 的该分布. 记

$$T_n = \max\{X_1, \dots, X_n\},$$

证明: $\frac{\pi}{n}T_n$ 按分布收敛于某分布 T .

Solution: 根据最大值定义, 首先对 $t < 0$, 有

$$P\left(\frac{\pi}{n}T_n \leq t\right) = P^n\left(X_1 \leq \frac{nt}{\pi}\right) = \left(\frac{1}{\pi} \arctan\left(\frac{nt}{\pi}\right) + \frac{1}{2}\right)^n \leq \left(\frac{1}{2}\right)^n \rightarrow 0.$$

对 $t > 0$, 则是一个 1^∞ 型未定式, 我们利用 $\arctan x + \arctan \frac{1}{x} = \frac{\pi}{2}$, 得到

$$\frac{1}{2} + \frac{1}{\pi} \arctan\left(\frac{nt}{\pi}\right) = \frac{1}{2} + \frac{1}{\pi} \left(\frac{\pi}{2} - \arctan\left(\frac{\pi}{nt}\right)\right) = 1 - \frac{1}{\pi} \arctan\left(\frac{\pi}{nt}\right),$$

因此有

$$P\left(\frac{\pi}{n}T_n \leq t\right) = \left(1 - \frac{1}{\pi} \arctan\left(\frac{\pi}{nt}\right)\right)^n \sim e^{-n \cdot \frac{1}{\pi} \arctan(\frac{\pi}{nt})} \rightarrow e^{-\frac{1}{t}}.$$

这已经说明了结论.

五、(42 分) 已知总体密度函数是

$$f(x; \sigma) = \frac{x}{\sigma^2} e^{-\frac{x^2}{2\sigma^2}}, \quad x > 0,$$

且有随机样本 $x_1, \dots, x_n$.

- (1) 求 X^2 的分布;
- (2) 求 σ^2 的 MLE;
- (3) 证明 MLE 的无偏性;
- (4) 求 σ 的矩估计, 已知 $\Gamma(1/2) = \sqrt{\pi}$;
- (5) 给出 $H_0: \sigma^2 = 1$ vs $H_1: \sigma^2 > 1$ 的水平为 α 的拒绝域;
- (6) 在大样本下, 利用中心极限定理给出上一问假设检验问题的近似水平为 α 的拒绝域.

Solution: (1) 利用分布函数法, 有

$$P(X^2 \leq y) = P(X \leq \sqrt{y}), \quad f_{X^2}(y) = f(\sqrt{y}) \frac{1}{2\sqrt{y}} = \frac{1}{2\sigma^2} e^{-\frac{y}{2\sigma^2}}.$$

实际上是均值为 $2\sigma^2$ 的指数分布.

- (2) 不妨考虑 $Y = X^2$ 的样本, 根据指数分布性质, $2\hat{\sigma}_L^2 = \bar{y} = \frac{1}{n} \sum_{i=1}^n x_i^2$, 因此有

$$\hat{\sigma}_L^2 = \frac{1}{2n} \sum_{i=1}^n x_i^2.$$

- (3) 由于 $E(Y) = 2\sigma^2$, 因此 $E(\bar{y}) = 2\sigma^2$, 故 $E(\hat{\sigma}_L^2) = \sigma^2$, 无偏.

- (4) 先求 $E(X)$, 有

$$E(X) = \int_0^{+\infty} \frac{x^2}{\sigma^2} e^{-\frac{x^2}{2\sigma^2}} dx = \frac{1}{2} \int_{-\infty}^{+\infty} \frac{x^2}{\sigma^2} e^{-\frac{x^2}{2\sigma^2}} dx = \frac{\sqrt{2\pi}}{2\sigma} \int_{-\infty}^{+\infty} \frac{x^2}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} dx = \sqrt{\frac{\pi}{2}} \sigma.$$

因此有 $\hat{\sigma}_M = \sqrt{\frac{2}{\pi}} \bar{x}$.

- (5) 不妨考虑 Y 的样本, 这是指数分布, 其 UMPT 由 $W = \{\sum_{k=1}^n y_k > C\}$ 给出, 利用原假设成立时, $Y \sim \text{Exp}(\frac{1}{2}) = \chi^2(2)$, 有 $\sum_{k=1}^n y_k \sim \chi^2(2n)$, 故 $C = \chi_{1-\alpha}^2(2n)$, 因此该问题的水平为 α 的 UMPT 是

$$W_1 = \left\{ \sum_{k=1}^n x_k^2 > \chi_{1-\alpha}^2(2n) \right\}.$$

- (6) 同理, 利用 CLT, 原假设成立时有近似分布

$$\frac{\sum_{k=1}^n y_k - 2n}{2\sqrt{n}} \sim AN(0, 1),$$

故有 $C = 2n + 2\sqrt{n}u_{1-\alpha}$, 汇总得

$$W_2 = \left\{ \sum_{k=1}^n x_k^2 > 2n + 2\sqrt{n}u_{1-\alpha} \right\}.$$

六、(20 分) 设 $X \sim B(1, p)$, 有 i.i.d. 样本 $x_1, \dots, x_n$.

- (1) 给出充分完备统计量;
- (2) 求 $g(p) = p(1-p)$ 的一致最小方差无偏估计.

Solution: (1) 写出联合密度函数, 是

$$f(X; p) = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} = (1-p)^n \cdot \left(\frac{p}{1-p} \right)^{\sum_{i=1}^n x_i},$$

根据指数族性质, $T = \sum_{i=1}^n X_i$ 是其充分完备统计量.

(2) 令 $\hat{g} = \frac{T(n-T)}{n(n-1)}$, 利用 $T \sim B(n, p)$, 有

$$\begin{aligned} E[T \cdot (n-T)] &= \sum_{k=0}^n k(n-k) \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \\ &= \sum_{k=1}^{n-1} k(n-k) \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \\ &= \sum_{k=1}^{n-1} \frac{n!}{(k-1)!(n-k-1)!} p^k (1-p)^{n-k} \\ &= n(n-1)p(1-p) \sum_{k=1}^{n-1} \frac{(n-2)!}{(k-1)!(n-k-1)!} p^{k-1} (1-p)^{n-k-1} \\ &= n(n-1)p(1-p) \sum_{i=0}^{n-2} \frac{(n-2)!}{i!(n-2-i)!} p^i (1-p)^{n-2-i} \\ &= n(n-1)p(1-p). \end{aligned}$$

由 L-S 定理, $\hat{g} = \frac{T(n-T)}{n(n-1)}$ 是 $g(p) = p(1-p)$ 的 UMVUE.

七、(20 分) 设有回归模型

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中残差 $\varepsilon \sim N(0, \sigma^2)$. 设 $(\hat{\beta}_0, \hat{\beta}_1)$ 是参数的最小二乘估计.

- (1) 给出 $\hat{\beta}_0$ 和 $\hat{\beta}_1$ 的分布;
- (2) 求 $Cov(\hat{\beta}_0, \hat{\beta}_1)$;
- (3) 利用残差平方和给出 σ^2 的无偏估计.

Solution: 本题是经典最小二乘模型, 具体过程可参见茆书定理 8.4.1, 这里把答案打出.

(1) $(\hat{\beta}_0, \hat{\beta}_1)$ 的分布是

$$\begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} \sim N \left(\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \begin{pmatrix} \frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} & -\frac{\bar{x}}{l_{xx}} \\ -\frac{\bar{x}}{l_{xx}} & \frac{1}{l_{xx}} \end{pmatrix} \sigma^2 \right).$$

(2) $Cov(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}}{l_{xx}} \sigma^2$.

(3) 利用 $\frac{SSE}{\sigma^2} \sim \chi^2(n-2)$, 则 $\hat{\sigma}^2 = \frac{SSE}{n-2}$.

中国科学技术大学-812 概率论与数理统计-2024 年

一、(20 分) 独立地多次抛掷一枚硬币, 每次正面朝上的概率为 p , 当出现连续 2 次正面朝上的情况时停止抛掷. 记 n 为正整数, 求抛掷过程中正面朝上的次数大于 n 的概率.

Solution: 设 X 表示停止抛掷时正面朝上的次数, 考虑 $P(X = n + k), k \geq 1$, 由于停止抛掷时必定是连续 2 次正面朝上, 因此只需使前 $n + k - 1$ 正面朝上不连续, 利用插空法以及负二项分布的正则性有,

$$P(X = n + k) = \sum_{m=n+k-2}^{\infty} C_m^{n+k-2} p^{n+k} (1-p)^m = p^{n+k} \sum_{m=n+k-2}^{\infty} C_m^{n+k-2} (1-p)^m = p(1-p)^{n+k-2}.$$

故所求概率为

$$P(X > n) = \sum_{k=1}^{\infty} P(X = n + k) = \sum_{k=1}^{\infty} p(1-p)^{n+k-2} = (1-p)^{n-1}.$$

二、(15 分) 设 X, Y 是独立同分布的随机变量, 且 X 的密度函数为

$$f(x) = \begin{cases} \frac{1}{\sqrt{2\pi}x^3} e^{-\frac{1}{2x}}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

求 $X^{-4} + Y^{-4}$ 的分布.

Solution: 令 $U = X^{-4}, V = Y^{-4}$, 则 U 的密度函数为

$$f_U(u) = f_X(u^{-1/4}) \left| \frac{dx}{du} \right| = \frac{1}{4\sqrt{2\pi}} u^{-7/8} e^{-\frac{1}{2}u^{1/4}} I(u > 0).$$

从而我们可以得到 $T = U + V$ 的分布为

$$f_T(t) = \int_0^t f_U(t-x) f_V(x) dx$$

Remark: 令 $U = X^{-1}$, 我们可以发现 $U \sim Ga(\frac{1}{2}, \frac{1}{2}) = \chi^2(1)$. 从而所求分布为两个 $\chi^2(1)$ 分布四次方的和.

三、(20 分) 设 X 是标准正态随机变量, 对 $t \in \mathbb{R}$, 定义 $g(x) = e^{tx}$.

(1)(10 分) 计算 $E(g(X))$.

(2)(10 分) 证明 $E(Xg(X)) = E(g'(X))$.

Solution: (1) 正态分布的矩母函数 $Eg(X) = e^{\frac{1}{2}t^2}$.

(2) Stein 引理的证明已经出现过很多次, 这里不在赘述, 见专题班.

四、(21 分) 设 $\{X_{nk}, n = 1, 2, \dots, k = 1, 2, \dots, n\}$ 是一族随机变量. 当 $n < k$ 时, 定义 $X_{nk} = 0$. 假设对于任意固定的 $k \geq 1$, $X_{nk} \xrightarrow{P} 0$ ($n \rightarrow \infty$).

(1)(7 分) 对于固定的 $m \geq 1$, 证明 $\sum_{k=1}^m X_{nk} \xrightarrow{P} 0$.

(2)(7 分) 举例说明 $\sum_{k=1}^m X_{nk} \xrightarrow{P} 0$ 不一定成立.

(3)(7 分) 进一步假设 $\limsup_{m \rightarrow \infty} \limsup_{n \rightarrow \infty} \sum_{k=m+1}^n E|X_{nk}| = 0$, 证明 $\lim_{m \rightarrow \infty} \sum_{k=1}^m X_{nk} \xrightarrow{P} 0$.

Solution: (1) 由于 m 是有限固定的, 由经典结论: 若 $X \xrightarrow{P} 0, Y \xrightarrow{P} 0$, 则 $X + Y \xrightarrow{P} 0$, 可知有 $\sum_{k=1}^m X_{nk} \xrightarrow{P} 0$ ($n \rightarrow \infty$).

(2) 考虑 $X_{nk} = \frac{1}{n}$, 此时满足对于任意固定的 $k \geq 1$, $X_{nk} \xrightarrow{P} 0$ ($n \rightarrow \infty$). 但此时

$$\sum_{k=1}^m X_{nk} = \sum_{k=1}^n \frac{1}{n} = 1 \quad (m = n \rightarrow \infty)$$

(3) 由 Markov 不等式

$$P\left(\left|\sum_{k=m+1}^n X_{nk}\right| > \varepsilon\right) \leq P\left(\sum_{k=m+1}^n |X_{nk}| > \varepsilon\right) \leq \frac{\sum_{k=m+1}^n E|X_{nk}|}{\varepsilon}$$

由 $\limsup_{m \rightarrow \infty} \limsup_{n \rightarrow \infty} \sum_{k=m+1}^n E|X_{nk}| = 0$ 可知

$$\sum_{k=m+1}^n X_{nk} \xrightarrow{p} 0 \quad (n \rightarrow \infty, m \rightarrow \infty),$$

即

$$\sum_{k=m+1}^{\infty} X_{nk} \xrightarrow{p} 0 \quad (m \rightarrow \infty).$$

这表明对于任意 $\varepsilon > 0, m_0 > 0$, s.t.

$$P\left(\left|\sum_{k=m_0+1}^{\infty} X_{nk}\right| > \varepsilon\right) \rightarrow 0.$$

结合第 (1) 问, 我们有

$$P\left(\left|\sum_{k=1}^{\infty} X_{nk}\right| > \varepsilon\right) \leq P\left(\left|\sum_{k=1}^{m_0} X_{nk}\right| > \varepsilon\right) + P\left(\left|\sum_{k=m_0+1}^{\infty} X_{nk}\right| > \varepsilon\right) \rightarrow 0.$$

即 $\sum_{k=1}^m X_{nk} \xrightarrow{p} 0$.

Remark: $\{X_{nk}\}$ 便是在统计中常用的 triangular null array, 不仅有对于这类 array 的相合性质, 同样也有对应的中心极限定理, 感兴趣的同学可以自行搜索.

五、(24 分) $X_1, \dots, X_n$ 是来自均匀分布 $U(0, \theta)$ 的简单随机样本.

(1)(12 分) 基于 θ 的矩估计, 利用中心极限定理构造 θ 的 $1 - \alpha$ 的大样本置信区间.

(2)(12 分) 基于 θ 的极大似然估计构造 θ 的 $1 - \alpha$ 的置信区间.

Solution: (1) $EX = \theta/2$, 从而 $\hat{\theta}_M = 2\bar{X}$. 由 CLT, 有

$$\frac{\sqrt{n}(\hat{\theta}_M - \theta)}{\theta/\sqrt{3}} \xrightarrow{d} N(0, 1),$$

进而有 θ 的 $1 - \alpha$ 的大样本置信区间为

$$\left[\left(1 + \frac{u_{1-\alpha/2}}{\sqrt{3n}}\right)^{-1} \hat{\theta}_M, \left(1 - \frac{u_{1-\alpha/2}}{\sqrt{3n}}\right)^{-1} \hat{\theta}_M \right]$$

(2) 显然有 $\hat{\theta}_{MLE} = X_{(n)}$. 考虑

$$P\left(n\left(\theta - \hat{\theta}_{MLE}\right) > x\right) = P\left(X_{(n)} < \theta - \frac{x}{n}\right) = \left(1 - \frac{x}{n\theta}\right)^n \rightarrow e^{-\frac{x}{\theta}},$$

这是经典结论, 即 $P\left(n\left(\theta - \hat{\theta}_{MLE}\right) \leq x\right) \rightarrow 1 - e^{-\frac{x}{\theta}}$, 表明了

$$n\left(\theta - \hat{\theta}_{MLE}\right) \sim \text{Exp}\left(\frac{1}{\theta}\right).$$

从而我们利用 $2n(\theta - \hat{\theta}_{MLE})/\theta \sim \chi^2(2)$, 有 θ 的 $1 - \alpha$ 的置信区间为

$$\left[\left(1 - \frac{\chi_{\alpha/2}^2(2)}{2n} \right)^{-1} \hat{\theta}_{MLE}, \left(1 - \frac{\chi_{1-\alpha/2}^2(2)}{2n} \right)^{-1} \hat{\theta}_{MLE} \right]$$

六、(25 分) 设 $(X_i, Y_i)^T, i = 1, 2, \dots, n$ 是二维正态分布 $N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$ 的简单随机样本. 其密度函数为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\},$$

其中 $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$ 为参数.

(1)(10 分) 检验问题 $H_0: \mu_1 = \mu_2 \leftrightarrow H_1: \mu_1 \neq \mu_2$. 写出检验统计量和水平为 α 下的拒绝域.

(2)(15 分) 若 $\mu_1 = \mu_2 = \mu, \sigma_1^2 = \sigma_2^2 = \sigma^2$, 求 μ, σ^2, ρ 的极大似然估计. (要求写出详细的推导过程)

Solution: (1) 考虑

$$\frac{\sqrt{n}(\bar{X} - \bar{Y} - (\mu_1 - \mu_2))}{\sqrt{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}} \sim N(0, 1),$$

以及 $\hat{\sigma}_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \xrightarrow{P} \sigma_1^2, \hat{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \xrightarrow{P} \sigma_2^2, \hat{\rho} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} \xrightarrow{P} \rho$. 由 Slutsky 定理, 有

$$\frac{\sqrt{n}(\bar{X} - \bar{Y} - (\mu_1 - \mu_2))}{\sqrt{\hat{\sigma}_1^2 + \hat{\sigma}_2^2 - 2\hat{\rho}\hat{\sigma}_1\hat{\sigma}_2}} \sim N(0, 1).$$

从而检验统计量为

$$T = \frac{\sqrt{n}(\bar{X} - \bar{Y})}{\sqrt{\hat{\sigma}_1^2 + \hat{\sigma}_2^2 - 2\hat{\rho}\hat{\sigma}_1\hat{\sigma}_2}},$$

并且拒绝域为

$$W = \{|T| > u_{1-\alpha/2}\}.$$

(2) 对数似然为

$$l(\mu, \sigma, \rho) = C - n \log \sigma^2 - \frac{n}{2} \log(1 - \rho^2) - \frac{1}{2(1 - \rho^2)} \sum_{i=1}^n \left[\frac{(X_i - \mu)^2}{\sigma^2} - 2\rho \frac{(X_i - \mu)(Y_i - \mu)}{\sigma^2} + \frac{(Y_i - \mu)^2}{\sigma^2} \right]$$

求偏导有

$$\frac{\partial l(\mu, \sigma, \rho)}{\partial \mu} = \frac{1 + \rho}{\sigma^2(1 - \rho^2)} \sum_{i=1}^n (X_i + Y_i - 2\mu) = 0$$

$$\frac{\partial l(\mu, \sigma, \rho)}{\partial \sigma^2} = -\frac{n}{\sigma^2} + \frac{1}{2(\sigma^2)^2(1 - \rho^2)} \sum_{i=1}^n [(X_i - \mu)^2 - 2\rho(X_i - \mu)(Y_i - \mu) + (Y_i - \mu)^2] = 0$$

$$\frac{\partial l(\mu, \sigma, \rho)}{\partial \rho} = \frac{n\rho}{1 - \rho^2} - \frac{\rho}{\sigma^2(1 - \rho^2)^2} \sum_{i=1}^n [(X_i - \mu)^2 - 2\rho(X_i - \mu)(Y_i - \mu) + (Y_i - \mu)^2] + \frac{1}{\sigma^2(1 - \rho^2)} \sum_{i=1}^n (X_i - \mu)(Y_i - \mu) = 0$$

可以解得

$$\begin{cases} \hat{\mu} = \frac{1}{2n} \sum_{i=1}^n (X_i + Y_i) = \frac{1}{2} (\bar{X} + \bar{Y}) \\ \hat{\sigma}^2 = \frac{1}{2n(1-\rho^2)} \sum_{i=1}^n [(X_i - \hat{\mu})^2 - 2\hat{\rho}(X_i - \hat{\mu})(Y_i - \hat{\mu}) + (Y_i - \hat{\mu})^2] \\ \hat{\rho} = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu})(Y_i - \hat{\mu}) \end{cases}$$

七、(25 分) 已知二元线性回归模型 $y_i = \alpha x_i + \beta z_i + \epsilon_i$, 其中 $\epsilon_i, i = 1, 2, \dots, n$ 独立同服从于 $N(0, \sigma^2)$. $x = (x_1, \dots, x_n)^T, z = (z_1, \dots, z_n)^T$ 是自变量, $y = (y_1, \dots, y_n)^T$ 是因变量. 即 $X = (x, z)_{n \times 2}, I_n$ 为 n 阶单位阵, 假设 $X^T X$ 可逆.

(1)(10 分) 证明 $(\alpha, \beta)^T$ 的极大似然估计和最小二乘估计都是 $(\hat{\alpha}, \hat{\beta})^T = (X^T X)^{-1} X^T y$.

(2)(15 分) 记 $P_x = x(x^T x)^{-1} x^T, \tilde{\beta} = (z^T (I_n - P_x) z)^{-1} z^T (I_n - P_x) y$, 说明 $\tilde{\beta} = \hat{\beta}$, 并求 $\tilde{\beta}$ 的分布.

Solution: (1) 记 $\theta = (\alpha, \beta)^T$, 由题意有, $y = X\theta + \epsilon$.

线性回归模型的极大似然估计以及最小二乘估计出现过很多了, 这里不再重复. 显然有 $\hat{\theta} = (\hat{\alpha}, \hat{\beta})^T = (X^T X)^{-1} X^T y$.

(2) [法一] 直接带入 X , 我们有

$$X^T X = \begin{pmatrix} x^T x & x^T z \\ z^T x & z^T z \end{pmatrix}.$$

利用分块矩阵逆或者是直接计算 2×2 矩阵的逆, 可以得到

$$(X^T X)^{-1} = \begin{pmatrix} x^T x z^T z - x^T z z^T x \end{pmatrix}^{-1} \begin{pmatrix} z^T z & -x^T z \\ -z^T x & x^T x \end{pmatrix}.$$

之后带入计算即可.

[法二] 这里我们使用另一种方法, 记 $N_x = I_n - P_x$. 首先将方程改写,

$$\begin{aligned} y &= x\alpha + z\beta + \epsilon \\ &= x\alpha + P_x z\beta + N_x z\beta + \epsilon \\ &:= \alpha_0 + N_x z\beta + \epsilon \end{aligned}$$

其中 $\alpha_0 = x\alpha + P_x z\beta$. 从而有

$$\hat{\alpha}_0 = \bar{y}, \hat{\beta} = \left(z^T N_x z \right)^{-1} z^T N_x y$$

这说明了 $\tilde{\beta} = \hat{\beta}$, 对 $\hat{\alpha}$ 用同样的技巧也可以说明. 而 $\tilde{\beta}$ 是正态分布的线性组合, 因此只需要说明其均值和方差即可, 我们直接计算有

$$\begin{aligned} E\tilde{\beta} &= \left(z^T N_x z \right)^{-1} z^T N_x (x\alpha + z\beta) = \left(z^T N_x z \right)^{-1} z^T N_x z\beta = \beta \\ \text{Var}(\tilde{\beta}) &= \left(z^T N_x z \right)^{-1} z^T N_x \text{Var}(y) N_x z \left(z^T N_x z \right)^{-1} = \sigma^2 \left(z^T N_x z \right)^{-1} \end{aligned}$$

故 $\tilde{\beta} \sim N\left(\beta, \sigma^2 \left(z^T N_x z \right)^{-1}\right)$.

中国科学技术大学-812 概率论与数理统计-2025 年

1. 甲乙两队比赛, 3 局 2 胜制, 每局结果相互独立, 甲每局获胜概率 0.6, 甲队现有只能使用 1 次的战术, 使当局获胜的概率提升至 0.65, 但若此局失败, 之后每局获胜概率降至 0.5, 试计算甲最终获胜的概率, 并以此说明在第几局使用该战术最佳. (15 分)

Solution:

1) 当不使用战术时, 甲最终获胜的概率是:

$$P() = 0.6^2 + 2 * 0.6^2 * 0.4 = 0.648$$

2) 在第一局使用战术:

$$P() = 0.6 * 0.65 + 0.65 * 0.6 * 0.4 + 0.35 * 0.5^2 = 0.6335$$

在第二局使用战术:

$$P() = 0.6 * 0.65 + 0.6 * 0.35 * 0.5 + 0.4 * 0.65 * 0.6 = 0.651$$

在第三局使用战术:

$$P() = 0.6 * 0.6 + 0.6 * 0.4 * 0.65 + 0.4 * 0.6 * 0.65 = 0.672$$

所以应该在第三局使用战术。

2. $X_i \sim N(u, \sigma_i^2)$, $i = 1, 2, 3, 4, \sigma_i^2$ 各不相同.

(1) 求 $X_1 + X_2$ 的分布密度. (7 分)

(2) 求 $\frac{X_1 - X_2}{X_3 - X_4}$ 的分布密度. (8 分)

Solution:

(1). 由正态分布的性质, 我们易知:

$$X_1 + X_2 \sim N(2u, \sigma_1^2 + \sigma_2^2)$$

(2) 茆书习题我们可以知道这是一个柯西分布, 我们设 $T = \frac{X_1 - X_2}{X_3 - X_4} \sqrt{\frac{\sigma_3^2 + \sigma_4^2}{\sigma_2^2 + \sigma_1^2}}$, $Y = \frac{X_1 - X_2}{\sqrt{\sigma_1^2 + \sigma_2^2}}$, $X = \frac{X_3 - X_4}{\sqrt{\sigma_3^2 + \sigma_4^2}}$ 我们有:

$$P(T \leq t) = P(Y \leq tX, X \geq 0) + P(X \geq tX, X \leq 0)$$

$$= 2 \int_0^{+\infty} dx \int_0^{tx} \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}} dy$$

$$f_T(t) = \frac{dP(T \leq t)}{dt}$$

$$= \frac{1}{\pi} \int_0^{+\infty} x e^{-\frac{t^2+1}{2}x^2} dx$$

$$= \frac{1}{\pi(t^2 + 1)}$$

所以 $\frac{X_1 - X_2}{X_3 - X_4} \sim \text{Cauchy}(\sqrt{\frac{\sigma_3^2 + \sigma_4^2}{\sigma_2^2 + \sigma_1^2}}, 0)$

3. X, Y 是两电子器件寿命分布, 分别为: $X \sim \text{Exp}(1), Y \sim \text{Exp}(2)$, X, Y 独立. 求 (1) 串联, (5 分) (2) 并联, (5 分) (3) 备用, (5 分) 三种结构下的分布、期望, 以及串联和并联下的协方差.

Solution:

(1) 串联, 设整体寿命为 $T_1 = \min\{X, Y\}$, 则:

$$\begin{aligned} P(T_1 > t) &= P(X > t)P(Y > t) \\ &= e^{-3t} \\ F_{T_1}(t) &= 1 - e^{-3t} \\ E(T_1) &= \frac{1}{3} \end{aligned}$$

(2) 并联, 设整体寿命为 $T_2 = \max\{X, Y\}$, 则:

$$\begin{aligned} P(T_2 \leq t) &= P(X \leq t)P(Y \leq t) \\ &= 1 - e^{-t} - e^{-2t} + e^{-3t} \\ E(T_2) &= \frac{7}{6} \end{aligned}$$

(3) 备用, 设整体寿命为 T_3 , 我们易知 $T_3 = X + Y$, 则:

$$\begin{aligned} P(T_3 \leq t) &= P(X + Y \leq t) \\ &= \int_0^t e^{-x} dx \int_0^{t-x} 2e^{-2y} dy \\ &= 1 - 2e^{-t} + e^{-2t} \\ E(T_3) &= \frac{3}{2} \end{aligned}$$

串联和并联下的协方差 $Cov(T_1, T_2)$:

$$\begin{aligned} Cov(T_1, T_2) &= E(T_1 T_2) - E(T_1)E(T_2) \\ &= E(\max\{X, Y\} \min\{X, Y\}) - \frac{7}{18} \\ &= E(XY) - \frac{7}{18} \\ &= \frac{1}{9} \end{aligned}$$

4. $\{X_i\}, i = 1, 2, \dots, n$ 独立, 服从期望为 u , 方差各不相同但最大方差为 b . 证明: $S = \frac{X_1 + X_2 + \dots + X_n}{n}$ 为 u 的相合估计. (20 分)

Solution:

由条件我们有:

$$Var(S) = \frac{Var(X_1 + \dots + X_n)}{n^2} \leq \frac{b}{n}$$

由切比雪夫不等式, 我们有:

$$P(|S - u| \geq \epsilon) \leq \frac{Var(S)}{\epsilon^2} \leq \frac{b}{n\epsilon^2} \rightarrow 0$$

所以 S 是 u 的相合估计

5. 双参数指数分布 $Exp(\frac{1}{\lambda}, u)$, $X_1, \dots, X_n$ 为样本, 证明: $(X_{(1)}, \sum_{i=2}^n X_{(i)})$ 是 u, λ 的充分统计量. (20 分)

Solution:

我们有:

$$\begin{aligned} f(X_1, \dots, X_n) &= \frac{1}{\lambda^n} e^{-\frac{\sum_{i=1}^n (X_i - u)}{\lambda}} I(X_{(1)} > u) \\ &= \frac{1}{\lambda^n} e^{-\frac{nu}{\lambda}} \cdot e^{-\frac{\sum_{i=1}^n X_i}{\lambda}} I(X_{(1)} > u) \end{aligned}$$

由因子分解定理, 我们有 $(X_{(1)}, \sum_{i=1}^n X_i)$ 是 u, λ 的充分统计量, 同时我们注意到有 $\sum_{i=1}^n X_i = \sum_{i=1}^n X_{(i)}$, 我们又注意到 $(X_{(1)}, \sum_{i=1}^n X_{(i)})$ 与 $(X_{(1)}, \sum_{i=2}^n X_{(i)})$ 是一一对应的关系, 所以 $(X_{(1)}, \sum_{i=1}^n X_{(i)})$ 是 u, λ 的充分统计量。

6. $(X_1, X_2, X_3, X_4) \sim M(n; \frac{1}{2} + \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{\theta}{4})$, 样本 (x_1, x_2, x_3, x_4) , $\sum_{i=1}^4 x_i = n$, 潜变量 $Z: (X_1 - Z, Z, X_2, X_3, X_4) \sim M(n; \frac{1}{2} - \frac{\theta}{4}, \frac{\theta}{2}, \frac{1}{4} - \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{\theta}{4})$.

- (1) 求 (x_1, x_2, x_3, x_4) 的对数似然函数. (5 分)
- (2) 求 Z 在 (X_1, X_2, X_3, X_4) 下的条件分布. (5 分)
- (3) 不清楚 (5 分)
- (4) 求 θ^t (10 分)

Solution:

(1) 对数似然函数为:

$$l(\theta) = x_1 \ln(\frac{1}{2} + \frac{\theta}{4}) + x_2 \ln(\frac{1}{4} - \frac{\theta}{4}) + x_3 \ln(\frac{1}{4} - \frac{\theta}{4}) + x_4 \ln(\frac{\theta}{4})$$

(2)

$$P(Z|X_1, X_2, X_3, X_4) = \frac{X_1!}{(X_1 - Z)!Z!} (\frac{2 - \theta}{2 + \theta})^{X_1 - Z} (\frac{2\theta}{2 + \theta})^Z$$

(4) 我们有:

$$l(\theta|(X_1, X_2, X_3, X_4, Z)) = a + (X_1 - Z) \ln(\frac{1}{2} - \frac{\theta}{4}) + Z \ln(\frac{\theta}{2}) + X_2 \ln(\frac{1}{4} - \frac{\theta}{4}) + X_3 \ln(\frac{1}{4} - \frac{\theta}{4}) + X_4 \ln(\frac{\theta}{4})$$

于是, 对于:

$$\begin{aligned} Q(\theta, \theta^{t-1}) &= E_{\theta^t}(l(\theta|(X_1, X_2, X_3, X_4, Z))|(X_1, X_2, X_3, X_4)) \\ &= (x_1 - x_1 p) \ln(\frac{1}{2} - \frac{\theta}{4}) + x_1 p \ln(\frac{\theta}{2}) + x_2 \ln(\frac{1}{4} - \frac{\theta}{4}) + x_3 \ln(\frac{1}{4} - \frac{\theta}{4}) + x_4 \ln(\frac{\theta}{4}) \end{aligned}$$

$$\text{其中 } p = \frac{2\theta^{t-1}}{2 + \theta^{t-1}}$$

$$\frac{dQ}{d\theta} = \frac{x_1 - x_1 p}{2 - \theta} + \frac{x_1 p}{\theta} + \frac{x_2}{1 - \theta} + \frac{x_3}{1 - \theta} + \frac{x_4}{\theta} = 0$$

设 $a = x_1 - x_1 p$, $b = x_1 p + x_4$, $c = x_2 + x_3$ 我们解得

$$\theta^t = \frac{-(a + 2c - 3b) \pm \sqrt{(a + 2c - 3b)^2 - 8b(b - a - c)}}{2(b - a - c)} \text{ (舍去在 } (0, 1) \text{ 外的值)}$$

7. $X_1, \dots, X_n, Y_1, \dots, Y_n$ 独立, $X_i \sim N(u_1, \sigma^2)$, $Y_i \sim N(u_2, \sigma^2)$, σ 已知.

$$H_0: u_1 = u_2 \Leftrightarrow H_1: u_1 - u_2 \neq \delta_n$$

且 $n \rightarrow \infty$ 时, $\delta_n \rightarrow 0$.

- (1) 水平 α 下的拒绝域, 功效函数, 第二类错误. (10 分)
- (2) δ_n 以多大速度趋于 0 时, 第二类错误趋于 0. (10 分)

Solution:

(1) 对于简单假设, 其 ump 拒绝域其实是由 δ_n 的值决定的, 且为单边拒绝域, 但是这里并没有明确表明 δ_n 的范围, 所以我们采用双边拒绝域:

$$W = \{\bar{x} - \bar{y} \leq -u_{1-\alpha/2} \sqrt{\frac{2\sigma^2}{n}} \text{ 或 } \bar{x} - \bar{y} \geq u_{1-\alpha/2} \sqrt{\frac{2\sigma^2}{n}}\}$$

其功效函数:

$$P(X \in W | u_1 - u_2 = k) = \Phi(-u_{1-\alpha/2} - k \sqrt{\frac{n}{2\sigma^2}}) + \Phi(-u_{1-\alpha/2} + k \sqrt{\frac{n}{2\sigma^2}})$$

第二类错误是：

$$P(X \in \bar{W} | u_1 - u_2 = \delta_n) = \Phi(u_{1-\alpha/2} + \delta_n \sqrt{\frac{n}{2\sigma^2}}) - \Phi(-u_{1-\alpha/2} + \delta_n \sqrt{\frac{n}{2\sigma^2}})$$

(2): 显然易见, 当 $\lim_{n \rightarrow \infty} \delta_n \sqrt{n} = \infty$ 时, 第二类错误趋于 0。

8. 多元线性模型:

$$y = b_0 + x_1 b_1 + \dots + x_p b_p + e, \quad e \sim N(0, \sigma^2)$$

样本: $\{y_i, x_{i1}, \dots, x_{ip}\}, i = 1, 2, \dots, n$. 记 X 为第 i, j 元素为 $X_{i,j}$ 的矩阵, $(X^T X)$ 为 $(p+1) \times (p+1)$ 的可逆矩阵.

(1) $(b_0, b_1, \dots, b_p)$ 的最小二乘表达式. (5 分)

(2) 求 σ^2 的相合估计表达式. (7 分)

(3) 基于 (2) 给出以下检验问题的统计量, 及拒绝域. (8 分)

$$H_0: \sigma^2 \geq c \Leftrightarrow H_1: \sigma^2 < c$$

Solution:

(1) 因为 $(X^T X)$ 为可逆矩阵, 所以 OLS 的损失函数为强凸函数, 所以我们有:

$$(b_0, b_1, \dots, b_p)^T = (X^T X)^{-1} X^T Y$$

(2) 由 Cochran 定理, 我们知道:

$$(Y - \hat{Y})^T (Y - \hat{Y}) \sim \sigma^2 \chi_{n-1-p}^2$$

因此我们有:

$$E\left(\frac{(Y - \hat{Y})^T (Y - \hat{Y})}{n-1-p}\right) = \sigma^2$$

$$Var\left(\frac{(Y - \hat{Y})^T (Y - \hat{Y})}{n-1-p}\right) = \frac{2\sigma^4}{n-1-p}$$

所以由切比雪夫不等式, 我们知道 $\frac{(Y - \hat{Y})^T (Y - \hat{Y})}{n-1-p}$ 是 σ^2 的相合估计。

(3) 我们选定检验统计量为 $T = (Y - \hat{Y})^T (Y - \hat{Y})$, 所以其拒绝域为:

$$\{T \leq c \chi_{n-1-p}^2(\alpha)\}$$

中国科学技术大学-812 概率论与数理统计-2026 年

概率论部分:

一、选择题 (每题 5 分, 共 20 分)

1. 事件 A, B 独立, A, C 独立, B, C 互斥。已知 $P(A) = P(B) = \frac{1}{2}$, 且 $P(AC | A \cup B \cup C) = \frac{1}{4}$, 求 $P(C)$ 。

- A. $\frac{1}{6}$
- B. $\frac{1}{4}$
- C. $\frac{1}{3}$
- D. $\frac{1}{2}$

Solution: D

设 $P(C) = x$:

因为 A, C 独立, 所以 $P(AC) = P(A)P(C) = \frac{1}{2}x$ 。

因为 A, B 独立, 所以 $P(AB) = P(A)P(B) = \frac{1}{4}$ 。

因为 B, C 互斥, 所以 $P(BC) = 0$, 进而 $P(ABC) = 0$ 。

$$\text{计算分母 } P(A \cup B \cup C): P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC) \\ = \frac{1}{2} + \frac{1}{2} + x - \frac{1}{4} - \frac{1}{2}x - 0 + 0 = \frac{3}{4} + \frac{1}{2}x$$

计算分子 $P(AC \cap (A \cup B \cup C))$: 由于 $AC \subseteq (A \cup B \cup C)$, 所以分子即为 $P(AC) = \frac{1}{2}x$ 。

根据条件概率公式:

$$\frac{P(AC)}{P(A \cup B \cup C)} = \frac{\frac{1}{2}x}{\frac{3}{4} + \frac{1}{2}x} = \frac{1}{4}$$

解得 $x = \frac{1}{2}$ 。

2. 下列关于随机变量的说法中, 正确的是: ()

- A. 对于连续型随机变量 X , 存在 x 使得 $P(X = x) > 0$
- B. 随机变量 X 在一次试验结束后的取值是确定的
- C. 取值范围为 $(-\infty, +\infty)$ 的随机变量一定是连续型随机变量
- D. 对于连续型随机变量 X , $P(X = x) = 0$ 意味着事件 $\{X = x\}$ 是不可能事件

Solution: B

A. 错误。对于连续型随机变量, 单点概率 $P(X = x) = 0$ 。

B. 正确。随机试验在试验前是不确定的, 但在试验完成后, 会取到一个确定的观测值。

C. 错误。取值在全实轴上的分布也可以是离散的 (例如在所有整数上取值) 或混合型的, 不一定是连续型。

D. 错误。在几何概型或连续型分布中, 概率为 0 的事件是有可能发生的, 概率为 0 不等同于不可能事件。

3. 设随机变量 X, Y 相互独立, 已知 $P(X = 1) = P(X = -1) = \frac{1}{2}$, 且 Y 服从参数为 λ 的泊松分布。令 $Z = XY$, 则 $Cov(X, Z) = ()$

- A. 0
- B. λ
- C. $-\lambda$
- D. 无法确定

Solution: B

根据协方差定义: $Cov(X, Z) = E[XZ] - E[X]E[Z]$ 。

1. 计算期望 $E[X]$ 和 $E[Y]$: $E[X] = 1 \times \frac{1}{2} + (-1) \times \frac{1}{2} = 0$ $Y \sim P(\lambda) \implies E[Y] = \lambda$

2. 计算 $E[Z]$: $E[Z] = E[XY]$, 因为 X, Y 独立, $E[XY] = E[X]E[Y] = 0 \cdot \lambda = 0$ 。

3. 计算 $E[XZ]$: $E[XZ] = E[X \cdot (XY)] = E[X^2Y]$ 因为 X, Y 独立, $E[X^2Y] = E[X^2]E[Y]$ 。由于 X 取值为 1 或 -1, $E[X^2] = 1$ 。所以 $E[XZ] = 1 \cdot \lambda = \lambda$ 。

4. 计算协方差: $Cov(X, Z) = \lambda - 0 \cdot 0 = \lambda$ 。

4. 投掷两枚均匀的骰子, 定义事件 A 为两枚骰子点数之和为奇数, 事件 B 为第一枚骰子的点数为奇数, 事件 C 为第二枚骰子的点数为奇数。下列说法正确的是: ()

A. A, B, C 两两独立且相互独立

B. A, B, C 两两独立且不相互独立

C. A, B, C 两两不独立

D. A 和 B 独立, 但 A 与 C, B 与 C 不独立

Solution: B

1. 对于事件 A (和为奇数), 需要一枚奇数一枚偶数, 即 (奇, 偶) 或 (偶, 奇): $P(A) = \frac{1}{2} \times \frac{1}{2} + \frac{1}{2} \times \frac{1}{2} = \frac{1}{2}$ 。

2. 验证两两独立性: $P(AB)$: 第一枚奇数且和为奇数 $\Rightarrow$ 第二枚必须为偶数。 $P(AB) = P(\text{第一枚奇, 第二枚偶}) = \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$ 。而 $P(A)P(B) = \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$, 故 $P(AB) = P(A)P(B)$, A, B 独立。同理可证 $P(AC) = P(A)P(C)$, A, C 独立。 $P(BC)$: 第一枚奇数且第二枚奇数。 $P(BC) = \frac{1}{4}$, 且 $P(B)P(C) = \frac{1}{4}$, 故 B, C 独立。因此, A, B, C 两两独立。

3. 判断相互独立: ABC 等价于第一枚奇数第二枚奇数且和为奇数。因为奇数 + 奇数 = 偶数, 所以三个事件不可能同时发生。 $P(ABC) = 0$ 。而 $P(A)P(B)P(C) = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{8}$ 。 $P(ABC) \neq P(A)P(B)P(C)$, 故不相互独立。

综上, 选 B。

二、填空题 (每题 5 分, 共 15 分)

5. 设有一个等边三角形 ABC , 一质点从顶点 A 出发, 每一步以相等的概率移动到相邻的两个顶点之一。则 n 步之后该质点位于顶点 A 的概率为 _____。

Solution:

记 a_n 为第 n 步时质点位于顶点 A 的概率。显然 $a_0 = 1$ 。对于 $n \geq 1$, 质点要位于 A , 前一步 ($n-1$ 步) 必须位于 B 或 C 。记 b_n, c_n 分别为第 n 步位于 B, C 的概率。由于对称性, $b_n = c_n$ 。且 $a_{n-1} + b_{n-1} + c_{n-1} = 1$, 故 $b_{n-1} + c_{n-1} = 1 - a_{n-1}$ 。

根据转移规则从 B 或 C 移动到 A 的概率均为 $\frac{1}{2}$:

$$a_n = \frac{1}{2}b_{n-1} + \frac{1}{2}c_{n-1} = \frac{1}{2}(b_{n-1} + c_{n-1}) = \frac{1}{2}(1 - a_{n-1})$$

得到递推关系: $a_n = -\frac{1}{2}a_{n-1} + \frac{1}{2}$ 。设通项为 $a_n + \lambda = -\frac{1}{2}(a_{n-1} + \lambda)$, 代入解得 $\lambda = -\frac{1}{3}$ 。即 $a_n - \frac{1}{3} = -\frac{1}{2}(a_{n-1} - \frac{1}{3})$ 。所以数列 $\{a_n - \frac{1}{3}\}$ 是首项为 $1 - \frac{1}{3} = \frac{2}{3}$, 公比为 $-\frac{1}{2}$ 的等比数列。

$$a_n = \frac{1}{3} + \frac{2}{3} \cdot \frac{(-1)^n}{2^n} = \frac{1}{3} + \frac{(-1)^n}{3 \cdot 2^{n-1}}$$

6. 设 B, C 分别为投掷一枚均匀骰子先后两次出现的点数, 则关于 x 的一元二次方程 $x^2 + Bx + C = 0$ 有实根的概率为 _____。

Solution:

$\Delta = B^2 - 4C \geq 0 \Rightarrow B^2 \geq 4C$ 样本点总数为 36。下面枚举 B 的取值, 寻找满足条件的 C :

1. 当 $B = 1$ 时, $1 \geq 4C$, 无解, 0 个样本点。

2. 当 $B = 2$ 时, $4 \geq 4C \Rightarrow C \leq 1$, 即 $C = 1$, 1 个样本点。

3. 当 $B = 3$ 时, $9 \geq 4C \Rightarrow C \leq 2.25$, 即 $C \in \{1, 2\}$, 2 个样本点。
 4. 当 $B = 4$ 时, $16 \geq 4C \Rightarrow C \leq 4$, 即 $C \in \{1, 2, 3, 4\}$, 4 个样本点。
 5. 当 $B = 5$ 时, $25 \geq 4C \Rightarrow C \leq 6.25$, 即 $C \in \{1, \dots, 6\}$, 6 个样本点。
 6. 当 $B = 6$ 时, $36 \geq 4C \Rightarrow C \leq 9$, 即 $C \in \{1, \dots, 6\}$, 6 个样本点。
 满足条件的事件总数为 19, 故所求概率 $P = \frac{19}{36}$ 。

7. 设袋中有 r 个红球, b 个黑球。每次从袋中任取一球, 观察其颜色后放回, 并同时放入 a 个同色球。则第 1、2 次摸到红球且第 3、4 次摸到黑球的概率为 _____。

Solution:

记 R_i 为第 i 次摸到红球, B_i 为第 i 次摸到黑球。每次摸球的结果是独立事件, 因此 $P(R_1 R_2 B_3 B_4) = P(R_1) \cdot P(R_2 | R_1) \cdot P(B_3 | R_1 R_2) \cdot P(B_4 | R_1 R_2 B_3)$ 。

1. 第 1 次摸到红球的概率:

$$P(R_1) = \frac{r}{r+b}$$

此时袋中红球变为 $r+a$, 总球数变为 $r+b+a$ 。

2. 第 2 次摸到红球的概率:

$$P(R_2 | R_1) = \frac{r+a}{r+b+a}$$

此时袋中红球变为 $r+2a$, 黑球仍为 b , 总球数变为 $r+b+2a$ 。

3. 第 3 次摸到黑球的概率:

$$P(B_3 | R_1 R_2) = \frac{b}{r+b+2a}$$

此时袋中黑球变为 $b+a$, 总球数变为 $r+b+3a$ 。

4. 第 4 次摸到黑球的概率:

$$P(B_4 | R_1 R_2 B_3) = \frac{b+a}{r+b+3a}$$

相乘得:

$$P = \frac{r}{r+b} \cdot \frac{r+a}{r+b+a} \cdot \frac{b}{r+b+2a} \cdot \frac{b+a}{r+b+3a}$$

三、解答题 (共 40 分)。

8. 设二维随机变量 (X, Y) 的联合概率密度函数为:

$$f(x, y) = C e^{-2x^2 - 2xy - 2y^2}, \quad -\infty < x, y < +\infty$$

- (1) 求常数 C ;
 (2) 求在 $X = x$ 的条件下, Y 的条件概率密度 $f_{Y|X}(y|x)$;
 (3) 判断 X 与 Y 是否相互独立, 说明理由。

Solution:

- (1) 根据概率密度函数的性质, $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dy dx = 1$ 。首先对指数部分的 y 进行配方:

$$-2x^2 - 2xy - 2y^2 = -2(y^2 + xy + \frac{x^2}{4}) - \frac{3}{2}x^2 = -2(y + \frac{x}{2})^2 - \frac{3}{2}x^2$$

先对 y 进行积分:

$$\int_{-\infty}^{+\infty} \exp \left[-2(y + \frac{x}{2})^2 \right] dy$$

令 $t = \sqrt{2}(y + \frac{x}{2})$, 则 $dy = \frac{1}{\sqrt{2}}dt$ 。利用 $\int_{-\infty}^{+\infty} e^{-t^2} dt = \sqrt{\pi}$, 可得:

$$\int_{-\infty}^{+\infty} e^{-t^2} \frac{1}{\sqrt{2}} dt = \sqrt{\frac{\pi}{2}}$$

再对 x 进行积分:

$$\int_{-\infty}^{+\infty} C \cdot \sqrt{\frac{\pi}{2}} \cdot \exp\left(-\frac{3}{2}x^2\right) dx = 1$$

利用 $\int_{-\infty}^{+\infty} e^{-ax^2} dx = \sqrt{\frac{\pi}{a}}$, 此处 $a = \frac{3}{2}$:

$$C \cdot \sqrt{\frac{\pi}{2}} \cdot \sqrt{\frac{2\pi}{3}} = 1 \implies C = \frac{\sqrt{3}}{\pi}$$

(2) 首先求 X 的边缘概率密度 $f_X(x)$ 。由 (1) 知:

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \frac{\sqrt{3}}{\pi} e^{-\frac{3}{2}x^2} \int_{-\infty}^{+\infty} e^{-2(y+\frac{x}{2})^2} dy = \sqrt{\frac{3}{2\pi}} e^{-\frac{3}{2}x^2}$$

这表明 $X \sim N(0, 1/3)$ 。

利用条件概率密度定义 $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$:

$$f_{Y|X}(y|x) = \frac{\frac{\sqrt{3}}{\pi} \exp(-2x^2 - 2xy - 2y^2)}{\sqrt{\frac{3}{2\pi}} \exp(-\frac{3}{2}x^2)}$$

因此, 条件概率密度为:

$$f_{Y|X}(y|x) = \sqrt{\frac{2}{\pi}} \exp\left[-2\left(y + \frac{x}{2}\right)^2\right], \quad -\infty < y < +\infty$$

这表明 $Y|X = x \sim N(-\frac{x}{2}, \frac{1}{4})$ 。

(3) X 与 Y 不独立。理由如下, 选择其中一个就行:

1. 联合概率密度 $f(x, y)$ 的指数部分包含交叉项 $-2xy$, 因此无法分离变量写成 $f_X(x)f_Y(y)$ 的形式。
2. 由 (2) 的结果可知, 条件概率密度 $f_{Y|X}(y|x)$ 依赖于 x , 其均值随 x 变化, 故 X 与 Y 不独立。

9. 设有一系列箱子, 编号为 $k = 1, 2, \dots$ 。第 k 号箱子中装有 k 个黑球和 1 个白球。甲乙两人进行游戏: 投掷一枚均匀硬币, 直到出现正面为止, 记此时抛掷的次数为 N 。随后从第 N 号箱子中随机取出一球, 若取出白球则甲获胜, 否则乙获胜。

- (1) 求甲获胜的概率;
- (2) 试判断该游戏规则对谁有利。

Solution:

(1) 记事件 A 为甲获胜 (即摸到白球)。记随机变量 N 为首次出现正面时的抛掷次数。由于硬币是均匀的, N 服从参数为 $p = 1/2$ 的几何分布, 其概率分布律为:

$$P(N = k) = \left(\frac{1}{2}\right)^{k-1} \cdot \frac{1}{2} = \left(\frac{1}{2}\right)^k, \quad k = 1, 2, \dots$$

当 $N = k$ 时, 从第 k 号箱中取球。该箱中有 k 个黑球和 1 个白球, 共 $k+1$ 个球。因此, 在 $N = k$ 的条件下, 摸到白球的条件概率为:

$$P(A | N = k) = \frac{1}{k+1}$$

由全概率公式:

$$P(A) = \sum_{k=1}^{\infty} P(A | N = k) P(N = k) = \sum_{k=1}^{\infty} \frac{1}{k+1} \cdot \left(\frac{1}{2}\right)^k$$

为了计算这个级数, 利用 $\ln(1-x)$ 的麦克劳林展开:

$$-\ln(1-x) = \sum_{j=1}^{\infty} \frac{x^j}{j}, \quad x \in (-1, 1)$$

我们将 $P(A)$ 的表达式变形, 令 $j = k+1$:

$$P(A) = \sum_{k=1}^{\infty} \frac{1}{k+1} \left(\frac{1}{2}\right)^k = 2 \sum_{k=1}^{\infty} \frac{1}{k+1} \left(\frac{1}{2}\right)^{k+1} = 2 \sum_{j=2}^{\infty} \frac{1}{j} \left(\frac{1}{2}\right)^j$$

上式中的求和部分可以表示为:

$$\sum_{j=2}^{\infty} \frac{1}{j} \left(\frac{1}{2}\right)^j = \sum_{j=1}^{\infty} \frac{(1/2)^j}{j} - \frac{1/2}{1} = \left[-\ln\left(1 - \frac{1}{2}\right) \right] - \frac{1}{2} = \ln 2 - 0.5$$

$$P(A) = 2(\ln 2 - 0.5) = 2\ln 2 - 1$$

故甲获胜的概率为 $2\ln 2 - 1$ 。

(2)

$$P(A) = 2(\ln 2 - 0.5) = 2\ln 2 - 1 < 0.5$$

因此, 乙获胜的概率更大, 该游戏规则对乙有利。

10. 设 $\{X_n\}$ 为一随机变量序列, 满足 $E[X_n] = \mu$, 且 $\text{Var}(X_n) \leq b$ (其中 $b > 0$ 为常数)。若存在常数 $M < \infty$, 使得当 $|i-j| > M$ 时, X_i 与 X_j 不相关。证明: $S_n = \frac{1}{n} \sum_{i=1}^n X_i$ 依概率收敛于 μ 。

Proof:

根据马尔可夫不等式, $\forall \epsilon > 0$:

$$P(|S_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(S_n)}{\epsilon^2}$$

我们需要证明当 $n \rightarrow \infty$ 时, 上式右端趋于 0。

首先计算 S_n 的方差:

$$\text{Var}(S_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right)$$

展开求和项的方差:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) + \sum_{i \neq j} \text{Cov}(X_i, X_j)$$

第一部分: 由题设 $\text{Var}(X_i) \leq b$:

$$\sum_{i=1}^n \text{Var}(X_i) \leq nb$$

第二部分: 利用柯西-施瓦茨不等式, $|\text{Cov}(X_i, X_j)| \leq \sqrt{\text{Var}(X_i)\text{Var}(X_j)} \leq \sqrt{b \cdot b} = b$ 。根据题设, 当 $|i-j| > M$ 时, X_i 与 X_j 不相关, 即 $\text{Cov}(X_i, X_j) = 0$ 。因此, 求和仅需考虑 $1 \leq |i-j| \leq M$ 的项。对于固定的 i , 满足 $|i-j| \leq M$ 且 $j \neq i$ 的 j 的个数最多为 $2M$ 个。所以非零协方差项的总个数不超过 $2Mn$ 。于是:

$$\left| \sum_{i \neq j} \text{Cov}(X_i, X_j) \right| \leq \sum_{i \neq j} |\text{Cov}(X_i, X_j)| \leq 2Mn \cdot b$$

综合以上两部分:

$$\text{Var}(S_n) = \frac{1}{n^2} \left[\sum_{i=1}^n \text{Var}(X_i) + \sum_{i \neq j} \text{Cov}(X_i, X_j) \right] \leq \frac{1}{n^2} (nb + 2Mnb) = \frac{b(1+2M)}{n}$$

代回马尔可夫不等式:

$$P(|S_n - \mu| \geq \epsilon) \leq \frac{b(1+2M)}{n\epsilon^2}$$

由于 b, M, ϵ 均为常数, 当 $n \rightarrow \infty$ 时, $\frac{b(1+2M)}{n\epsilon^2} \rightarrow 0$. 故 $P(|S_n - \mu| \geq \epsilon) \rightarrow 0$. 即 $S_n \xrightarrow{P} \mu$.

数理统计部分:

一、选择题 (每题 5 分, 共 15 分)

1. 设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的简单随机样本 ($E[X] = \mu, \text{Var}(X) = \sigma^2$), $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 为样本均值, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本方差, 总体分布的方差为 $D(X) = \sigma^2$. 下列说法中正确的是: ()

- A. S 是 σ 的无偏估计
- B. S^2 是 σ^2 的极大似然估计
- C. $\bar{X}$ 与 S^2 相互独立
- D. 以上说法都不正确

Solution: D

逐项分析如下:

A 错误: S^2 是 σ^2 的无偏估计, 由于开根号 $\sqrt{\cdot}$ 不是线性变换, 根据 Jensen 不等式, $E[S] = E[\sqrt{S^2}] < \sqrt{E[S^2]} = \sigma$. 因此 S 是 σ 的有偏估计。

B 错误: 极大似然估计依赖于具体的分布形式。反例: 正态分布下, σ^2 的 MLE 是 $\frac{1}{n} \sum (X_i - \bar{X})^2$, 而不是样本方差 S^2 。

C 错误: 样本均值 $\bar{X}$ 与样本方差 S^2 相互独立是正态总体的充分必要条件。对于非正态总体, 二者通常是不独立的。

故选 D。

2. 下列关于假设检验的说法中, 正确的是: ()

- A. 若在显著性水平 0.05 下接受 H_0 , 则在 0.01 下一定接受 H_0
- B. 若在显著性水平 0.05 下接受 H_0 , 则在 0.01 下一定拒绝 H_0
- C. 若在显著性水平 0.05 下拒绝 H_0 , 则在 0.01 下一定接受 H_0
- D. 若在显著性水平 0.05 下拒绝 H_0 , 则在 0.01 下一定拒绝 H_0

Solution: A

记 P 值为检验统计量的 p -value, $p \leq \alpha \Rightarrow$ 拒绝 H_0 , $p > \alpha \Rightarrow$ 接受 H_0 。

逐项分析:

A 正确: 若在 $\alpha = 0.05$ 下接受 H_0 , 意味着 $p > 0.05$. 因为 $0.05 > 0.01$, 有 $p > 0.01$. 所以在 $\alpha = 0.01$ 下一定接受 H_0 。

B 错误: 同上, 既然 $p > 0.01$, 在 0.01 下就不会拒绝。

C 错误: 若在 0.05 下拒绝 ($p \leq 0.05$), p 值可能非常小, 此时在 0.01 下也是拒绝的。

D 错误: 若在 0.05 下拒绝 ($p \leq 0.05$), p 值有可能介于 0.01 和 0.05 之间 (例如 $p = 0.03$)。此时 $p > 0.01$, 所以在 0.01 下应该是接受, 而非拒绝。

3. 设 $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 下面是 F 分布的是: ()

- A. $n\bar{X}^2$
- B. nS_n^2
- C. $\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$
- D. $\frac{(n-1)X_1^2}{\sum_{i=2}^n X_i^2}$

Solution:

对于选项 A, 由于 $X_i \sim N(0, \sigma^2)$, 则 $\bar{X} \sim N(0, \sigma^2/n)$ 。标准化后 $\frac{\bar{X}}{\sigma/\sqrt{n}} \sim N(0, 1)$, 其平方 $\frac{n\bar{X}^2}{\sigma^2} \sim \chi^2(1)$ 。即 $n\bar{X}^2$ 服从缩放的卡方分布, 不是 F 分布。

对于选项 B, $nS_n^2 = \sum_{i=1}^n (X_i - \bar{X})^2$ 。根据正态总体的抽样定理: $\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$ 。因此, $\frac{nS_n^2}{\sigma^2} \sim \chi^2(n-1)$ 。这意味着 nS_n^2 服从缩放的卡方分布 (即 $\sigma^2 \cdot \chi^2(n-1)$), 而不是 F 分布。

对于选项 C, 这是一个标准化的样本均值形式。因为 $X_i \sim N(0, \sigma^2)$, 即总体均值 $\mu = 0$, 则 $\frac{\sqrt{n}(\bar{X}-0)}{\sigma} = \frac{\bar{X}}{\sigma/\sqrt{n}} \sim N(0, 1)$ 。该统计量服从标准正态分布。

对于选项 D, 根据 F 分布定义: $U \sim \chi^2(n_1)$, $V \sim \chi^2(n_2)$, 且 U, V 独立, 则 $\frac{U/n_1}{V/n_2} \sim F(n_1, n_2)$ 。 $X_i \sim N(0, \sigma^2)$, $X_i/\sigma \sim N(0, 1)$ 。

1. 分子来源于 X_1 : $(X_1/\sigma)^2$ 是 1 个标准正态变量的平方, 服从 $\chi^2(1)$ 。
2. 分母来源于 $X_2, \dots, X_n$: $\sum_{i=2}^n (X_i/\sigma)^2$ 是 $n-1$ 个独立标准正态变量的平方和, 服从 $\chi^2(n-1)$ 。
3. X_1 与后续样本独立, 故分子分母独立。

构造 F 统计量:

$$F = \frac{\frac{(X_1/\sigma)^2}{1}}{\frac{\sum_{i=2}^n (X_i/\sigma)^2}{n-1}} = \frac{X_1^2}{\frac{1}{n-1} \sum_{i=2}^n X_i^2} = \frac{(n-1)X_1^2}{\sum_{i=2}^n X_i^2}$$

该式符合 F 分布结构, 服从 $F(1, n-1)$ 。故选 D。

二、填空题 (每题 5 分, 共 10 分)

4. 考虑 $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$ 的 μ 的区间估计 (置信水平 $1-\alpha$): i) n 变大, 区间长度会 _____ ii) $1-\alpha$ 变大, 区间长度会 _____ iii) $p < \alpha$, 则 _____ 原假设

Solution: 变小; 变大; 拒绝

由于 $\bar{X} \sim N(\mu, \sigma^2/n)$, 构造枢轴量 $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ 。由 $P(-z_{\alpha/2} \leq \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}) = 1-\alpha$, 解得置信区间 $[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}]$ 。区间长度 $L = (\bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}) - (\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}) = 2z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ 。

- i) n 位于分母, 当 n 变大时, $\frac{1}{\sqrt{n}}$ 变小, 故区间长度变小。
- ii) 当置信水平 $1-\alpha$ 变大时, 显著性水平 α 变小, 对应的临界值 $z_{\alpha/2}$ 变大, 故区间长度变大。
- iii) p 值小于显著性水平 α 是拒绝原假设的判别准则之一。

5. 设分布函数 $F(x) = 0.5\Phi(x) + 0.5\Phi(\frac{x-4}{2})$, 其中 $\Phi(x)$ 是标准正态分布函数, 则 $EX =$ _____。

Solution: 2

题目给出的 $F(x)$ 是两个分布函数的线性组合, 形式为 $F(x) = 0.5F_1(x) + 0.5F_2(x)$, 这定义了一个混合分布。假设服从两点分布的随机变量 I , $P(I=1) = 0.5$, $P(I=2) = 0.5$ 。当 $I=0$ 时, 随机变量 X 服从标准正态分布 $N(0, 1)$; 当 $I=1$ 时, 随机变量 X 服从正态分布 $N(4, 2^2)$ 。

根据全概率公式, 随机变量 X 的累积分布函数为:

$$P(X \leq x) = P(X \leq x|I=1)P(I=1) + P(X \leq x|I=2)P(I=2)$$

也就是:

$$F(x) = \Phi(x) \cdot 0.5 + \Phi(\frac{x-4}{2}) \cdot 0.5$$

这与题干给出的表达式完全一致。因此, X 可以理解为抛一枚均匀硬币, 正面向上则从 $N(0, 1)$ 抽样, 反面向上则从 $N(4, 4)$ 抽样。

$$E[X] = E[X|I=1]P(I=1) + E[X|I=2]P(I=2) = 0 \times 0.5 + 4 \times 0.5 = 2$$

注: 请勿当成随机变量的线性组合 (即 $Y = 0.5X_1 + 0.5X_2$), 虽然在这题比较凑巧, 但两者的方差和分布形态不同。

三、简答题 (共 50 分)

6. (10 分) 设总体 X 的概率密度函数为 $f(x) = \frac{3x^2}{a^3}$, $0 < x < a$ 。现有样本 $X_1, \dots, X_n \sim X$ 。

(1) 求矩估计 $\hat{a}_1$; 极大似然估计 $\hat{a}_2$ 。

(2) $\hat{a}_1$ 与 $\hat{a}_2$ 是无偏吗? 给出理由, 若有偏, 请修正为无偏。

Solution:

(1) 求矩估计 $\hat{a}_1$: 总体 X 的期望为:

$$E[X] = \int_0^a x \cdot f(x) dx = \int_0^a x \cdot \frac{3x^2}{a^3} dx = \frac{3}{4}a$$

令样本均值等于总体矩: $\bar{X} = E[X] = \frac{3}{4}a$ 。解得矩估计量:

$$\hat{a}_1 = \frac{4}{3}\bar{X}$$

求极大似然估计 $\hat{a}_2$: 似然函数为:

$$L(a) = \prod_{i=1}^n f(x_i; a) = \begin{cases} \frac{3^n \prod_{i=1}^n x_i^2}{a^{3n}}, & a \geq x_{(n)} \\ 0, & a < x_{(n)} \end{cases}$$

其中 $x_{(n)} = \max(x_1, \dots, x_n)$ 。当 $a \geq x_{(n)}$ 时, $L(a)$ 是关于 a 的单调递减函数。为了使 $L(a)$ 达到最大, 取定义域内的最小值。故极大似然估计量为:

$$\hat{a}_2 = X_{(n)}$$

(2) $\hat{a}_1$ 的无偏性:

$$E[\hat{a}_1] = E\left[\frac{4}{3}\bar{X}\right] = \frac{4}{3}E[\bar{X}] = \frac{4}{3}E[X] = \frac{4}{3} \cdot \frac{3}{4}a = a$$

所以 $\hat{a}_1$ 是无偏估计。

$\hat{a}_2$ 的无偏性: 首先求统计量 $X_{(n)}$ 的分布。总体分布函数为 $F(x) = \int_0^x \frac{3t^2}{a^3} dt = \frac{x^3}{a^3}$, $0 < x < a$ 。 $X_{(n)}$ 的概率密度函数为:

$$f_{\max}(x) = n[F(x)]^{n-1}f(x) = \frac{3nx^{3n-1}}{a^{3n}}, \quad 0 < x < a$$

计算 $\hat{a}_2$ 的期望:

$$E[\hat{a}_2] = E[X_{(n)}] = \int_0^a x \cdot \frac{3nx^{3n-1}}{a^{3n}} dx = \frac{3n}{a^{3n}} \int_0^a x^{3n} dx = \frac{3n}{a^{3n}} \cdot \frac{a^{3n+1}}{3n+1} = \frac{3n}{3n+1}a$$

因为 $E[\hat{a}_2] \neq a$, 所以 $\hat{a}_2$ 是有偏估计。

由 $E[X_{(n)}] = \frac{3n}{3n+1}a$ 可知:

$$E\left[\frac{3n+1}{3n}X_{(n)}\right] = \frac{3n+1}{3n} \cdot \frac{3n}{3n+1}a = a$$

故修正后的无偏极大似然估计为:

$$\hat{a}_2^* = \frac{3n+1}{3n}\hat{a}_2 = \frac{3n+1}{3n}X_{(n)}$$

7. (12 分) 面粉的质量指标 X 服从正态分布 $N(\mu, \sigma^2)$ 。现随机抽取 n 袋面粉进行检验, 样本记为 $X_1, \dots, X_n$, 且 $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$ 。

(1) 若 σ^2 未知, 试求检验假设 $H_0: \mu \geq \mu_0 \leftrightarrow H_1: \mu < \mu_0$ 的拒绝域。(请给出构造的统计量, 然后直接写出拒绝域)

(2) 若 μ 已知, 试构造一个统计量用于检验假设 $H_0: \sigma^2 \geq C \leftrightarrow H_1: \sigma^2 < C$, 并写出拒绝域。

Solution:

(1) 由于 σ^2 未知, 选取 t 检验统计量:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

其中 $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ 为样本标准差。当 $\mu = \mu_0$ 时, $T \sim t(n-1)$ 。由于备择假设是 $H_1: \mu < \mu_0$, 拒绝域位于左侧。故拒绝域为:

$$W = \{T < -t_\alpha(n-1)\}$$

(2) 由于 μ 已知, 可以构造统计量:

$$\chi^2 = \frac{\sum_{i=1}^n (X_i - \mu)^2}{C}$$

当 $\sigma^2 = C$ 成立时, 该统计量服从自由度为 n 的卡方分布。由于备择假设是 $H_1: \sigma^2 < C$, 拒绝域位于左侧。所以拒绝域为:

$$W = \{\chi^2 < \chi_{1-\alpha}^2(n)\}$$

($\chi_{1-\alpha}^2(n)$ 表示 $\chi^2(n)$ 分布的下 α 分位数)

8. (14 分) 考虑线性回归模型 $y = b_0 + b_1x_1 + \cdots + b_px_p + e$, 其中误差项 $e \sim N(0, \sigma^2)$ 。现有 n 个观察值 $(y_i, x_{i1}, \dots, x_{ip})_{i=1}^n$ 。设 X 是 $n \times (p+1)$ 的设计阵, 且 $X'X$ 可逆。

(1) 设 $\hat{b}$ 是参数向量 $b = (b_0, \dots, b_p)'$ 的最小二乘估计, 求 $\hat{b} - b$ 的分布。

(2) 求回归平方和与残差平方和的表达式。

(3) 求残差平方和的期望 $E[SSE]$ 。

(4) 利用 (3) 中的期望说明: 为什么在选择自变量时, 要给自变量个数加一个 “惩罚”?

Solution:

(1) 最小二乘估计为 $\hat{b} = (X'X)^{-1}X'y$ 。将 $y = Xb + e$ 代入得: $\hat{b} = (X'X)^{-1}X'(Xb + e) = b + (X'X)^{-1}X'e$ 因此 $\hat{b} - b = (X'X)^{-1}X'e$ 。由于 $e \sim N(0, \sigma^2 I_n)$, 且 $\hat{b} - b$ 是 e 的线性变换, 故其服从多元正态分布。期望: $E[\hat{b} - b] = (X'X)^{-1}X'E[e] = 0$ 。方差协方差矩阵: $Var(\hat{b} - b) = (X'X)^{-1}X'Var(e)X(X'X)^{-1} = (X'X)^{-1}X'(\sigma^2 I_n)X(X'X)^{-1} = \sigma^2(X'X)^{-1}$ 故 $\hat{b} - b \sim N(0, \sigma^2(X'X)^{-1})$ 。

(2) 定义矩阵 $H = X(X'X)^{-1}X'$, 全 1 矩阵 J 为 $n \times n$ 矩阵, 元素均为 1。拟合值 $\hat{y} = Hy$, 残差 $\hat{e} = y - \hat{y} = (I - H)y$ 。残差平方和: $SSE = \sum (y_i - \hat{y}_i)^2 = (y - \hat{y})'(y - \hat{y}) = y'(I - H)'(I - H)y = y'(I - H)y$ 回归平方和: $SSR = \sum (\hat{y}_i - \bar{y})^2 = y'(H - \frac{1}{n}J)y$

(3) 由 SSE 的二次型性质及迹的性质: $E[SSE] = E[e'(I - H)e] = E[\text{tr}(e'(I - H)e)] = E[\text{tr}((I - H)ee')] = \text{tr}((I - H)E[ee']) = \text{tr}((I - H)\sigma^2 I_n) = \sigma^2 \text{tr}(I - H)$ 由于 $\text{tr}(H) = \text{tr}(X(X'X)^{-1}X') = \text{tr}((X'X)^{-1}X'X) = \text{tr}(I_{p+1}) = p + 1$, $E[SSE] = \sigma^2(n - (p + 1)) = (n - p - 1)\sigma^2$ 。

(4) 由 (3) 可知 $E[SSE] = (n - p - 1)\sigma^2$ 。这表明, 随着模型中自变量个数 p 的增加, 即使新增的变量与因变量无关, 残差平方和的期望值会自然减小。如果仅以最小化 SSE 或最大化 R^2 为标准来选择模型, 倾向于选择包含更多变量的复杂模型, 导致过拟合。为了抵消 p 增加带来的 SSE 机械性下降, 必须在模型选择中引入一个与 p 正相关的惩罚项, 以平衡模型拟合优度与模型复杂度。

9. (14 分) 设样本 $X_1, \dots, X_n$ 独立同分布于正态分布 $N(\mu, \sigma^2)$ 。

(1) 求 μ 的充分统计量。

(2) 考虑检验问题 $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$, 给出显著性水平 α 下的拒绝域。

(3) 证明: μ_0 落在 μ 的 $1 - \alpha$ 置信区间内, 是接受原假设 H_0 的充要条件。

Solution:

(1) 样本联合密度函数(似然函数)为: $L(\mu; \mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$
 展开指数项: $\sum (x_i - \mu)^2 = \sum x_i^2 - 2\mu \sum x_i + n\mu^2$ 。由因子分解定理:

$$L(\mu; \mathbf{x}) = \underbrace{(2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum x_i^2}{2\sigma^2}\right)}_{h(\mathbf{x})} \cdot \underbrace{\exp\left(\frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{n\mu^2}{2\sigma^2}\right)}_{g(T(\mathbf{x}), \mu)}$$

可以看出, $g(T(\mathbf{x}), \mu)$ 仅通过 $\sum_{i=1}^n x_i$ 依赖于样本。因此, $T = \sum_{i=1}^n X_i$ 是 μ 的充分统计量。

(2) 构造检验统计量 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ 。在 $H_0: \mu = \mu_0$ 成立的条件下, $Z \sim N(0, 1)$ 。对于双侧检验 $H_1: \mu \neq \mu_0$, 当检验统计量的绝对值过大时拒绝原假设。显著性水平为 α 的拒绝域 W 为: $W = \left\{ (x_1, \dots, x_n); \left| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right| > z_{1-\alpha/2} \right\}$
 即 $|\bar{X} - \mu_0| > z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$ 。

(3) μ 的 $1 - \alpha$ 置信区间为: $CI = \left[\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$ μ_0 落在该置信区间的充要条件是:
 $\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu_0 \leq \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$ 变形: $-z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu_0 - \bar{X} \leq z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \iff \left| \mu_0 - \bar{X} \right| \leq z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$
 $\iff \left| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right| \leq z_{1-\alpha/2}$ 上式恰好是统计量未落入 (2) 中拒绝域 (即接受域) 的条件。故 μ_0 落在 $1 - \alpha$ 置信区间是接受 H_0 的充要条件。

北京大学数院-856 大数据

北京大学数院-856 大数据-2024 年

一、(15 分) 甲、乙两人进行象棋比赛, 每局甲胜的概率为 p , 乙胜的概率为 $q = 1 - p$. 若某一方获胜的局数比另一方多三局, 我们则认为他获得了胜利. 求甲获胜的概率.

Solution: 何书元 1.19, 考虑吸收壁问题. 设 A 表示第一局甲获胜, B_i 表示甲比乙多胜 i 场下的最后获胜 ($i < 0$ 表示为少胜), $a_i (i \geq 0)$ 表示甲比乙多胜 i 场下的获胜概率, $a_i (i < 0)$ 表示甲比乙少胜 (乙比甲多胜) i 场下的获胜概. 由全概率公式有

$$\begin{aligned} P(B_i) &= P(B_i|A)P(A)P(B_i|\bar{A})P(\bar{A}) \\ &\Rightarrow a_i = pa_{i+1} + (1-p)a_{i-1}, \quad a_3 = 1, a_{-3} = 0. \end{aligned}$$

从而可以求得甲获胜的概率

$$a_0 = \frac{p^3}{1 - 3p + 3p^2}.$$

Remark: 同样的, 如果是多胜 k 场, 所求概率为

$$\frac{p^k}{1 - kp(1-p)}.$$

二、(15 分) 设 X 与 Y 独立, 都服从标准正态分布. 令 $U = \frac{X+Y}{2}, V = \frac{(X-Y)^2}{4}$, 求出 (U, V) 的联合分布.

Solution: (X, Y) 的联合分布为

$$f_{X,Y}(x, y) = \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}} I(-\infty < x, y < +\infty).$$

而

$$\begin{cases} U = \frac{X+Y}{2} \\ V = \frac{(X-Y)^2}{4} \end{cases} \Rightarrow \begin{cases} X = U + \sqrt{V} \\ Y = U - \sqrt{V} \end{cases} \text{ or } \begin{cases} X = U - \sqrt{V} \\ Y = U + \sqrt{V} \end{cases}$$

进而有 $|J| = \frac{1}{\sqrt{v}}$, 且可以发现 $X^2 + Y^2 = 2(U^2 + V)$. 从而有

$$f_{U,V}(u, v) = f_{X,Y}(x, y)|J| = \frac{1}{\pi} \frac{1}{\sqrt{v}} e^{-(u^2+v)} I(-\infty < u < +\infty, v > 0).$$

三、(15 分) 设 $X_1, \dots, X_N$ 独立同分布于 $U(0, 1)$, $X_{(r)}$ 是对应的次序统计量 ($1 \leq r \leq N$). 若 k 为已知常数, 且 $1 \leq r_1 < r_2 < \dots < r_n \leq N$, 这 n 个下标也已知. 求 $E\left(\prod_{i=1}^n X_{(r_i)}^k\right)$.

Solution: 令 $Y_i = X_{(r_i)}/X_{(r_{i+1})}, i = 1, 2, \dots, n-1$, 以及 $Y_n = X_{(r_n)}$, 可以发现 Y_i 之间相互独立. 利用次序统计量的经典结论, 我们有 $Y_i \sim Be(r_i, r_{i+1} - r_i), i = 1, 2, \dots, n-1$, 以及 $Y_n \sim Be(r_n, N - r_n + 1)$. 故有

$$E\left(\prod_{i=1}^n X_{(r_i)}^k\right) = E\left(Y_1^k Y_2^{2k} \dots Y_n^{nk}\right) = \prod_{i=1}^n E\left(Y_i^{ik}\right)$$

进一步, 由 Beta 分布的性质有

$$\begin{aligned} E\left(\prod_{i=1}^n X_{(r_i)}^k\right) &= \prod_{i=1}^n E\left(Y_i^{ik}\right) \\ &= \prod_{i=1}^{n-1} \left(\frac{B(r_i + ik, r_{i+1} - r_i)}{B(r_i, r_{i+1} - r_i)}\right) \cdot \frac{B(r_n + nk, N - r_n + 1)}{B(r_n, N - r_n + 1)} \\ &= \frac{N!}{(N + nk)!} \prod_{i=1}^n \frac{(r_i - 1 + ik)!}{(r_i - 1 + (i-1)k)!} \end{aligned}$$

Remark: 其实本质为 $X_{(i)}/X_{(j)}$ 与 $X_{(j)}$ 的独立性, 因此对于乘积形式的次序统计量我们会如下计算,

$$E\left(X_{(i)}X_{(j)}\right) = E\left(\frac{X_{(i)}}{X_{(j)}}X_{(j)}^2\right) = E\left(\frac{X_{(i)}}{X_{(j)}}\right)E\left(X_{(j)}^2\right).$$

请好好体会这个式子的思想对于本题解题思路的启发和体现.

四、(15 分) 若 $X_1, X_2, \dots, X_n$ 取自总体 $N(\theta, \sigma_1^2)$, $Y_1, Y_2, \dots, Y_m$ 取自总体 $N(\theta, \sigma_2^2)$, 其中 σ_1, σ_2 已知.

(1)(7 分) 设 $T = c\bar{X} + d\bar{Y}$ 是 θ 的无偏估计, 求 c, d 的值使得 T 的方差最小.

(2)(8 分) 基于第一问求出的 T , 给出 θ 的 $1 - \alpha$ 置信区间.

Solution: (1) 首先需要 $ET = (c + d)\theta = \theta$, 从而约束为 $c + d = 1$. 而目标函数为 $f(c, d) = \text{Var}(T) = c^2 \frac{\sigma_1^2}{n} + d^2 \frac{\sigma_2^2}{m}$. 故问题可以写成

$$c, d = c, d \text{ } f(c, d) \text{ s.t. } c + d = 1$$

这里可以使用拉格朗日乘法或者二次函数极值, 也可以使用柯西不等式有

$$\left(\frac{n}{\sigma_1^2} + \frac{m}{\sigma_2^2}\right) \left(c^2 \frac{\sigma_1^2}{n} + d^2 \frac{\sigma_2^2}{m}\right) \geq (c + d)^2 = 1.$$

等号当且仅当

$$\frac{c \frac{\sigma_1}{\sqrt{n}}}{\frac{\sigma_1}{\sigma_2}} = \frac{d \frac{\sigma_2}{\sqrt{m}}}{\frac{\sigma_2}{\sigma_1}}$$

时成立. 即 $c = \frac{n\sigma_2^2}{m\sigma_1^2 + n\sigma_2^2}, d = \frac{m\sigma_1^2}{m\sigma_1^2 + n\sigma_2^2}$.

(2) 此时的 $T = \frac{n\sigma_2^2}{m\sigma_1^2 + n\sigma_2^2} \bar{X} + \frac{m\sigma_1^2}{m\sigma_1^2 + n\sigma_2^2} \bar{Y} \sim N(\theta, \frac{\sigma_1^2 \sigma_2^2}{m\sigma_1^2 + n\sigma_2^2})$.

故 θ 的 $1 - \alpha$ 置信区间为

$$\left[T - u_{1-\alpha/2} \frac{\sigma_1 \sigma_2}{\sqrt{m\sigma_1^2 + n\sigma_2^2}}, T + u_{1-\alpha/2} \frac{\sigma_1 \sigma_2}{\sqrt{m\sigma_1^2 + n\sigma_2^2}} \right].$$

五、(15 分) 设回归模型为 $Y_i = \alpha + \beta x_i + \epsilon_i$, 其中 $\epsilon_i \stackrel{i.i.d.}{\sim} N(0, \sigma^2)$, 且 σ 已知. 现在将模型修改为 $Y_i = \alpha' + \beta'(x_i - \bar{x}) + \epsilon_i$, 记 $\hat{\alpha}, \hat{\beta}$ 和 $\hat{\alpha}', \hat{\beta}'$ 分别为修改前和修改后的 MLE.

(1)(5 分) 请证明 $\hat{\alpha} = \hat{\alpha}', \hat{\beta} = \hat{\beta}'$;

(2)(5 分) 请求出 $\hat{\alpha}', \hat{\beta}'$ 的分布;

(3)(5 分) 请证明 $\hat{\alpha}'$ 与 $\hat{\beta}'$ 独立.

Solution: (1) $Y_i \sim N(\alpha + \beta x_i, \sigma^2)$, 其似然函数为

$$L(\alpha, \beta) = C_1 \exp \left\{ -\frac{\sum_{i=1}^n (y_i - \alpha - \beta x_i)^2}{2\sigma^2} \right\}.$$

从而其对数似然函数为

$$l(\alpha, \beta) = \log L(\alpha, \beta) = C_2 - \frac{\sum_{i=1}^n (y_i - \alpha - \beta x_i)^2}{2\sigma^2}.$$

对其求偏导

$$\begin{cases} \frac{\partial l}{\partial \alpha} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \alpha - \beta x_i) = 0 \\ \frac{\partial l}{\partial \beta} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - \alpha - \beta x_i) = 0 \end{cases} \Rightarrow \begin{cases} \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} \\ \hat{\beta} = \frac{l_{xy}}{l_{xx}} \end{cases}$$

同理, 令 $x'_i = x_i - \bar{x}$, 只需要说明 $l_{x'y}/l_{x'x'} = l_{xy}/l_{xx}$ 即可. 这是显然的, 因为 $\bar{x'} = 0$.

$$l_{xy}/l_{xx} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x'_i)}{\sum_{i=1}^n (x'_i)^2} = l_{x'y}/l_{x'x'}.$$

但此时的 $\bar{x}$ 和 $\bar{x'}$ 不一定相等, 除非 $\bar{x}$ 几乎处处为 0. 因此可以发现这一问出错了, 我们只能得到 $\hat{\beta} = \hat{\beta'}$. 只有在 $\bar{x}$ 几乎处处为 0 时, 才有 $\hat{\alpha} = \hat{\alpha'}$.

(2) 由于 $\hat{\alpha'}$ 和 $\hat{\beta'}$ 都是正态分布随机变量的线性组合, 因此其分布还是正态分布. 我们只需要计算其期望和方差即可得到具体分布, 最终有

$$\hat{\alpha'} \sim N\left(\alpha', \frac{\sigma^2}{n}\right)$$

$$\hat{\beta'} \sim N\left(\beta', \frac{\sigma^2}{l_{x'x'}}\right)$$

(3) 茆书内容. 利用 $Cov(\hat{\alpha'}, \hat{\beta'}) = -\frac{\bar{x'}}{l_{x'x'}}\sigma^2 = 0$, 从而 $\hat{\alpha'}$ 与 $\hat{\beta'}$ 独立.

六、(7 分) 根据关键码集合 $K = \{\text{xal, wan, wil, zol, yo, xul, yum, wen, wim, zi, yon, xem, wul, zom}\}$ 画出建立 AVL 树的结果.

Solution:

```
R----xal
  L----wen
    |    L----wan
    |    R----wim
    |      L----wil
    |      R----wul
  R----yum
    L----yo
    |    L----xul
    |    |    L----xem
    |    R----yon
  R----zol
    L----zi
    R----zom
```

七、(8 分) 给出一个从 v_0 开始到其他各点的最短路径的 djikstra 算法.

Solution:

```
import sys

def dijkstra(graph, v0):
    """
    Dijkstra's algorithm to find the shortest path from v0 to all other vertices.

    :param graph: A 2D array where graph[u][v] is the weight of the edge from u to v, or
                  sys.maxsize if there is no edge.
    :param v0: The starting vertex.
    :return: A tuple containing two elements. The first is a list where element i is the
             shortest distance from v0 to i. The second is a list where element i is the
             previous vertex on the shortest path from v0 to i.
    """
    try:
```

```

# 检查 graph 是否为二维列表
if not all(isinstance(row, list) for row in graph):
    raise ValueError("Graph must be a 2D list")

n = len(graph)

# 检查 v0 是否为有效的顶点索引
if v0 < 0 or v0 >= n:
    raise ValueError(f"Starting vertex {v0} is out of bounds.")

# 检查边的权重是否有效
if any(graph[u][v] < 0 for u in range(n) for v in range(n) if graph[u][v] != sys.maxsize):
    raise ValueError("Graph contains negative weights.")

distances = [sys.maxsize] * n
distances[v0] = 0
previous = [None] * n
visited = [False] * n

for _ in range(n):
    u = min((v for v in range(n) if not visited[v]), key=lambda v: distances[v])
    visited[u] = True

    for v in range(n):
        if graph[u][v] > 0 and not visited[v] and distances[v] > distances[u] + graph[u][v]:
            distances[v] = distances[u] + graph[u][v]
            previous[v] = u

return distances, previous

except ValueError as e:
    # 打印错误消息并退出程序
    print(f"Error: {e}")
    sys.exit()

```

(1)

```

# Example usage
graph = [
    [0, 2, 0, 6, 0],
    [2, 0, 3, 8, 5],
    [0, 3, 0, 0, 7],
    [6, 8, 0, 0, 9],
    [0, 5, 7, 9, 0]
]

```

```

v0 = 0 # Starting vertex
try:
    shortest_distances, previous_vertices = dijkstra(graph, v0)
    print("Shortest_distances:", shortest_distances)
    print("Previous_vertices_in_path:", previous_vertices)
except Exception as e:
    print(f"An_error_occurred:{e}")

```

输出样例结果

```

Shortest distances: [0, 2, 5, 6, 7]
Previous vertices in path: [None, 0, 1, 0, 1]

```

八、(10 分) 给定原点 v_0 , 试用 Prim 算法求最小生成树, 给出结点访问顺序序列.

Solution:

```

import sys

def prim(graph, v0):
    """
    Prim's algorithm to find the minimum spanning tree starting from vertex v0.

    :param graph: A 2D array where graph[u][v] is the weight of the edge from u to v, or
                  sys.maxsize if there is no edge.
    :param v0: The starting vertex.
    :return: A list of vertices in the order they are added to the minimum spanning tree.
    """
    n = len(graph)
    in_mst = [False] * n # Whether the vertex is in the minimum spanning tree
    key = [sys.maxsize] * n # Key values used to pick minimum weight edge
    parent = [-1] * n # Array to store constructed MST
    key[v0] = 0 # Make key value of v0 0 so that it is picked first
    mst_order = []

    for _ in range(n):
        # Pick the minimum key vertex from the set of vertices not yet included in MST
        u = min((i for i in range(n) if not in_mst[i]), key=lambda i: key[i])
        in_mst[u] = True # Add the picked vertex to the MST
        mst_order.append(u)

        # Update key value and parent index of the adjacent vertices of the picked vertex
        for v in range(n):
            if graph[u][v] > 0 and not in_mst[v] and key[v] > graph[u][v]:
                key[v] = graph[u][v]
                parent[v] = u

```

```

    return mst_order

# Example usage
graph = [
    [0, 2, 0, 6, 0],
    [2, 0, 3, 8, 5],
    [0, 3, 0, 0, 7],
    [6, 8, 0, 0, 9],
    [0, 5, 7, 9, 0]
]

v0 = 0 # Starting vertex
mst_order = prim(graph, v0)

print("Node visit order for MST: ", mst_order)

```

输出样例结果

```
Node visit order for MST: [0, 1, 2, 4, 3]
```

九、(10 分) 分别用栈和队列进行时空状态搜索并说明有什么不同。

Solution: 在进行状态空间搜索时，栈和队列作为数据结构的选择会导致两种不同的搜索策略：深度优先搜索（DFS）和广度优先搜索（BFS）。这两种策略在时间和空间的使用效率上有所不同，适用于不同类型的问题。

使用栈进行深度优先搜索（DFS）：

1. 工作原理：栈是一种后进先出（LIFO）的数据结构。在 DFS 中，栈用于存储待探索的节点。当探索一个节点时，该节点的子节点被推入栈中，并在下一步被探索。

2. 时间和空间特性：时间效率：DFS 通常更快地遍历整个状态空间，但不保证找到最短路径或最优解。空间效率：DFS 通常使用更少的内存，因为它只需要存储一条从根到叶子的路径。

3. 适用场景：DFS 适用于解空间较深或需要遍历整个解空间的问题。

使用队列进行广度优先搜索（BFS）：

1. 工作原理：队列是一种先进先出（FIFO）的数据结构。在 BFS 中，队列用于存储待探索的节点。当探索一个节点时，该节点的所有子节点被加入队列的尾部，并依次被探索。

2. 时间和空间特性：时间效率：BFS 通常更快地找到最短路径或最优解，但可能需要更长时间来遍历整个状态空间。空间效率：BFS 可能需要更多内存，因为它需要存储所有已生成但尚未探索的节点。

3. 适用场景：BFS 适用于需要快速找到最短路径的问题，尤其是在状态空间较广的情况下。

比较：

搜索深度与广度：DFS 深入到每个分支的最深处，而 BFS 逐层探索状态空间。

路径优化：BFS 更有可能找到最短路径，而 DFS 可能会找到较长的解决路径。

内存使用：DFS 在内存使用上更高效，尤其是在解空间非常深但每层分支较少的情况下。BFS 在宽但浅的状态空间中效率较高。

实现复杂度：DFS 的实现通常更简单，尤其是在递归形式的情况下。BFS 的实现相对复杂一些，需要维护一个队列。

选择使用 DFS 还是 BFS 取决于具体问题的特点和需求。例如，DFS 更适合解空间较深的问题，如解决方案可能在较深的层次中；而 BFS 更适合寻找最短路径或最优解的情况。

十、(10 分) 什么是稳定性和适应性，并解释直接插入排序如何做到以上两点。

Solution: 在排序算法的上下文中,“稳定性”和“适应性”是两个重要的特性。

1. 稳定性 (Stability): 定义: 如果排序算法保证相等的元素在排序前后保持原有的顺序, 则该算法是稳定的。

举例: 假设有一组记录 '[A2, B1, A1, B2]', 其中字母代表值, 数字代表原始位置。在稳定的排序算法下, 排序后相同字母的记录会保持原来的相对位置, 例如 '[A1, A2, B1, B2]'。

2. 适应性 (Adaptivity): 定义: 如果排序算法对已经部分排序的输入数据进行排序时, 能够提高其性能, 则该算法是适应性的。适应性强的算法在处理部分排序的数据时更高效。

举例: 如果输入数据是 '[1, 2, 3, 5, 4, 6, 7]', 适应性强的算法会利用这种已经部分排序的特性来减少工作量。

直接插入排序

直接插入排序是一种简单的排序算法, 具有稳定性和适应性。

1. 实现稳定性: 在直接插入排序中, 新元素总是插入到前面已排序部分的适当位置。当遇到相等的元素时, 新元素会被放置在相等元素的后面, 从而保持了它们的相对顺序。这种做法确保了具有相同值的元素在排序后仍然保持其原有的顺序, 从而使算法是稳定的。

2. 实现适应性: 直接插入排序的性能会随输入数据的初始排序程度而改变。如果数据已经部分排序, 算法会进行较少的比较和移动操作。例如, 在最佳情况下 (输入数据已经完全排序), 直接插入排序只需要进行 $n-1$ 次比较和 0 次移动操作。这种对输入数据的初始排序状态敏感的特性使得直接插入排序具有适应性。

总结来说, 直接插入排序因其能保持相等元素的原始顺序而具有稳定性, 且能根据输入数据的部分排序状态调整其性能, 从而具有适应性。这两个特性使得直接插入排序在某些情况下 (如已部分排序的小数据集) 非常有效。

十一、(10 分) 给定一个有 16 个关键码的字典。

(1)(5 分) 使用二分查找搜索一个关键码时的比较次数。

(2)(5 分) 用除余法定义散列函数并设置 $M = 31$, 用开放地址线性探查法建立散列表。

Solution: (1) 二分查找是一种在有序数组中查找特定元素的算法。针对 16 个元素的数组, 最坏情况下的比较次数是确定的。在二分查找中, 每次比较都会将搜索区间减半。因此, 对于含有 16 个元素的数组, 最多需要进行的比较次数可以通过计算 $\log_2(16)$ 得出, 等于 4

(2)

```
import random
```

```
# 散列函数和散列表大小
```

```
M = 31
```

```
hash_table = [None] * M
```

```
# 除余法定义的散列函数
```

```
def hash_function(key):  
    return key % M
```

```
# 开放地址线性探查法
```

```
def linear_probing(hash_table, key):  
    index = hash_function(key)  
    initial_index = index  
    while hash_table[index] is not None:  
        index = (index + 1) % M  
    if index == initial_index: # 避免无限循环
```

```

        raise Exception("散列表已满")
hash_table[index] = key
# 随机生成16个关键码
keys = [random.randint(1, 100) for _ in range(16)]

```

```

# 构建散列表
for key in keys:
    linear_probing(hash_table, key)

```

```

print("散列表:", hash_table)
print("关键码:", keys)

```

输出结果

```

散列表: [62, 31, 95, None, 97, 98, None, None, 39, 40, None, 73, 12, None, None, None, None, 80, 19, 20]
关键码: [19, 98, 95, 29, 62, 20, 39, 57, 40, 97, 12, 60, 82, 73, 80, 31]

```

十二、(10 分) 树的先根遍历的递归和非递归.

Solution:

```

class TreeNode:
    def \_\_\_\_\_init\_\_\_\_\_(self, value):
        self.value = value
        self.left = None
        self.right = None

def preorder_traversal_recursive(root):
    if root:
        print(root.value) # 访问根节点
        preorder_traversal_recursive(root.left) # 遍历左子树
        preorder_traversal_recursive(root.right) # 遍历右子树

def preorder_traversal_iterative(root):
    if root is None:
        return

    stack = [root]

    while stack:
        node = stack.pop()
        print(node.value) # 访问节点

        # 首先压入右子树, 然后是左子树
        if node.right:
            stack.append(node.right)
        if node.left:

```

```
stack.append(node.left)
```

十三、(10 分) 求整数列中最大连续子序列和。

Solution: 求解整数序列中最大连续子序列和的一个经典算法是 Kadane 算法。这个算法非常高效，能在线性时间内解决问题。

算法的基本思想是遍历数组，同时跟踪两个变量：当前位置的最大子序列和和到目前为止的最大子序列和。

```
def max_subarray_sum(nums):  
    """  
    计算给定整数数组的最大连续子序列和。  
    """  
    if len(nums) == 0:  
        return 0  
  
    max_current = max_global = nums[0]  
  
    for num in nums[1:]:  
        max_current = max(num, max_current + num)  
        max_global = max(max_global, max_current)  
  
    return max_global  
  
# 示例  
nums = [-2, 1, -3, 4, -1, 2, 1, -5, 4]  
print("最大连续子序列和:", max_subarray_sum(nums))
```

输出样例结果

最大连续子序列和: 6

北京大学数院-856 大数据-2025 年

1. n 个人随机选三门课, 求至少有一门课没人选的概率。(15 分)

Solution:

设 $A_i = \{i\}$, 则我们有:

$$\begin{aligned} P() &= P(A_1 \cup A_2 \cup A_3) \\ &= P(A_1) + P(A_2) + P(A_3) - P(A_1 A_2) - P(A_1 A_3) - P(A_2 A_3) + P(A_1 A_2 A_3) \\ &= 3 \frac{2^n}{3^n} - 3 \frac{1}{3^n} \end{aligned}$$

2. 随机变量 $(X, Y) \sim N(u_1, u_2, \sigma_1^2, \sigma_2^2, \rho)$, $U = X + CY, V = Y - CY$, 求 (U, V) 的分布, 并求 U, V 独立时, C 的值。(15 分)

Solution:

我们可以看到 U, V 是正态的线性组合, 由正态分布的性质, 我们有

$$\begin{bmatrix} U \\ V \end{bmatrix} = \begin{bmatrix} 1 & C \\ 0 & 1-C \end{bmatrix} \begin{bmatrix} X \\ Y \end{bmatrix} \sim N\left(\begin{bmatrix} u_1 + Cu_2 \\ (1-C)u_2 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 + C^2\sigma_2^2 + 2\rho C\sigma_1\sigma_2 & (1-C)(\rho\sigma_1\sigma_2 + C\sigma_2^2) \\ (1-C)(\rho\sigma_1\sigma_2 + C\sigma_2^2) & (1-C)^2\sigma_2^2 \end{bmatrix}\right)$$

由正态分布的性质我们知道, 当 $C = 1$ 时 U, V 是相互独立。

3. $X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} N(u, \frac{1}{\lambda})$, u 已知, 且有 $\lambda \sim \text{Gamma}(\alpha, \beta)$, 其中 $f(\lambda|\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \lambda^{\alpha-1} \exp(-\beta\lambda)$, 求 $\lambda|\vec{X}$ 和 $E(\lambda|\vec{X})$ 。(20 分)

Solution:

这题的 Gamma 分布其实是给错了, 所以说哪怕是考研真题也会有错误, 我们要大胆质疑!

$$\begin{aligned} \pi(\lambda) &\propto \lambda^{\alpha-1} \exp(-\beta\lambda) \\ f(\lambda|\vec{X}) &\propto f(\vec{X}|\lambda) \pi(\lambda) \\ &\propto \lambda^{\frac{n}{2}} \exp\left(-\frac{\lambda \sum (x_i - u)^2}{2}\right) \lambda^{\alpha-1} \exp(-\beta\lambda) \\ &\propto \lambda^{(\frac{n}{2} + \alpha) - 1} \exp\left(-\left(\beta + \frac{\sum (x_i - u)^2}{2}\right) \lambda\right) \end{aligned}$$

所以由核函数我们可以看出来 $\lambda|\vec{X} \sim \text{Gamma}(\alpha + \frac{n}{2}, \beta + \frac{\sum (x_i - u)^2}{2})$, 所以 $E(\lambda|\vec{X}) = \frac{\alpha + \frac{n}{2}}{\beta + \frac{\sum (x_i - u)^2}{2}}$

4. $X_1, X_2, \dots, X_m \stackrel{\text{iid}}{\sim} N(u_1, \sigma^2), Y_1, Y_2, \dots, Y_n \stackrel{\text{iid}}{\sim} N(u_2, \sigma^2)$, 其中 σ^2 未知, 求 $u_1 - Cu_2$ 的 $1 - \alpha$ 的置信区间, C 为常数。(20 分)

Solution:

其实有多种方式构造这个枢轴量, 我们在这采取类似于课本的构造方式。

$$\begin{aligned} \bar{x} - C\bar{y} &\sim N(u_1 - Cu_2, (\frac{1}{m} + C^2 \frac{1}{n})\sigma^2) \\ (m-1)S_x^2 + (n-1)S_y^2 &\sim \sigma^2 \chi_{m+n-2}^2 \end{aligned}$$

所以我们可以构造如下枢轴量:

$$t = \sqrt{\frac{mn(m+n-2)}{mC^2 + n}} \frac{\bar{x} - C\bar{y} - (u_1 - Cu_2)}{\sqrt{(m-1)S_x^2 + (n-1)S_y^2}} \sim t(m+n-2)$$

所以置信区间如下:

$$[\bar{x} - C\bar{y} \pm t_{1-\alpha/2} \sqrt{\frac{mC^2 + n}{mn(m+n-2)}} \sqrt{(m-1)S_x^2 + (n-1)S_y^2}]$$

5. $Y_i = \beta x_i + \epsilon_i, i = 1, \dots, n$, 其中 $\epsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$

(1) 求 $\hat{\beta}_{MSE}$, 给出 σ^2 的一个无偏估计。(5 分)

(2) 求 β 的 $1 - \alpha$ 的置信区间。(5 分)

(3) 设 $y_0 = \hat{\beta}X_0 + \epsilon_0$, ϵ_0 与 ϵ_i 独立, 给出 y_0 的 $1 - \alpha$ 的预测区间。(10 分)

Solution:

(1).

$$\begin{aligned}\hat{\beta} &= \operatorname{argmin} \sum (Y_i - \beta x_i)^2 \\ &= \frac{\sum x_i Y_i}{\sum x_i^2}\end{aligned}$$

由 Cochran 定理, 我们知道:

$$\sum (Y_i - \hat{\beta}x_i)^2 \sim \sigma^2 \chi_{n-1}^2$$

所以 $\hat{\sigma}^2 = \frac{\sum (Y_i - \hat{\beta}x_i)^2}{n-1}$ 是 σ^2 的一个无偏估计

(2)

$$\hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum x_i^2}\right)$$

所以我们有

$$\frac{\hat{\beta} - \beta}{\sqrt{\frac{\hat{\sigma}^2}{(n-1) \sum x_i^2}}} \sim t(n-1)$$

所以 β 的 $1 - \alpha$ 的置信区间是:

$$\left[-t_{1-\alpha/2} \sqrt{\frac{\hat{\sigma}^2}{(n-1) \sum x_i^2}} + \hat{\beta}, t_{1-\alpha/2} \sqrt{\frac{\hat{\sigma}^2}{(n-1) \sum x_i^2}} + \hat{\beta}\right]$$

(3) 因为是预测区间, 我们有:

$$y_0 = \hat{\beta}x_0 + \epsilon_0 \sim N\left(y_0, \sigma^2\left(\frac{x_0^2}{\sum x_i^2} + 1\right)\right)$$

所以 y_0 的 $1 - \alpha$ 的预测区间是:

$$\left[\hat{\beta}X_0 - t'_{1-\alpha/2} \sqrt{\frac{\hat{\sigma}^2}{(n-1)}\left(\frac{x_0^2}{\sum x_i^2} + 1\right)}, \hat{\beta}X_0 + t'_{1-\alpha/2} \sqrt{\frac{\hat{\sigma}^2}{(n-1)}\left(\frac{x_0^2}{\sum x_i^2} + 1\right)}\right]$$

6. (1) 比较顺序查找、折半查找和散列查找, 并说明为什么有散列和二分这种快速查找还需要顺序。(5 分)

(2) 比较栈和队列。(5 分)

(3) 说说 B_+ 树与 B 树相比的优点。(5 分)

Solution:

(1) 顺序查找:

适用范围: 无序数组或链表。

时间复杂度: $O(n)$ 。

优点: 简单易实现, 不需要数据排序; 适合频繁更新的数据集。

缺点: 大规模数据时效率低。

折半查找 (二分查找):

适用范围: 已排序的数组或列表。

时间复杂度: $O(\log n)$ 。

优点：查找速度快，适合静态或少变动的数据集。

缺点：需要预排序，不适合链表结构。

散列查找：

适用范围：通过哈希函数映射键值到特定位置，适用于哈希表。

时间复杂度：理想情况下接近 $O(1)$ ，冲突严重时可能退化为 $O(n)$ 。

优点：平均查找速度极快，插入和删除操作也快。

缺点：需要额外空间，哈希函数设计不当会导致性能下降。

即使有了散列查找和二分查找，顺序查找依然重要：

1. 灵活性：不要求数据有序，适用于任何线性数据结构。
2. 简单性：实现简单，在小型数据集上表现良好。
3. 适应性：适合频繁更新的数据集，维持有序列表成本高。
4. 通用性：广泛适用，只要能逐个访问元素即可。

(2) 栈 (Stack) vs 队列 (Queue)

栈 (Stack) - 操作方式：后进先出 (LIFO) - 入栈 (Push)：向栈顶添加元素。- 出栈 (Pop)：移除并返回栈顶元素。- 查看栈顶 (Peek/Top)：获取栈顶元素但不移除。- 特点：元素按照最后加入的最先被移除的原则处理；所有操作在一端（栈顶）进行。- 应用场景：- 函数调用栈 - 撤销操作（如文本编辑器中的撤销功能）- 表达式求值与转换

队列 (Queue) - 操作方式：先进先出 (FIFO) - 入队 (Enqueue)：向队尾添加元素。- 出队 (Dequeue)：移除并返回队头元素。- 查看队头 (Front)：获取队头元素但不移除。- 特点：元素按照最先加入的最先被移除的原则处理；插入在队尾，删除在队头。- 应用场景：- 任务调度（如操作系统中的进程调度）- 缓冲区（如网络通信中的数据包传输）- 广度优先搜索 (BFS) 算法

主要区别

特性	栈 (Stack)	队列 (Queue)
存取顺序	后进先出 (LIFO)	先进先出 (FIFO)
操作位置	所有操作在栈顶	插入在队尾，删除在队头
应用场景	追踪最近添加项或回溯	按顺序处理任务或事件
实现复杂度	相对简单	稍微复杂一些
内存管理	只需跟踪一个指针（栈顶）	需要管理前后两个指针（队头和队尾）

通过上述对比可以看出，选择使用栈还是队列取决于具体的应用需求和你希望如何管理和访问数据。每种结构都有其独特的优点和适用场景。

(3) B+ 树与 B 树相比的优点

1. 更高效的范围查询 - B+ 树：所有关键字都存储在叶子节点中，并且叶子节点之间有链表相连。这使得范围查询非常高效，因为可以顺序扫描相连的叶子节点。- B 树：关键字分布在所有层级的节点中，进行范围查询时需要在树的不同层级间跳跃，效率较低。

2. 更高的扇出 (Fan-out) - B+ 树：每个内部节点只存储关键字而不存储数据记录指针，因此可以容纳更多的关键字，提高了每个节点的利用率，减少了树的高度。- B 树：每个节点不仅存储关键字还存储数据记录指针，导致每个节点能容纳的关键字数量较少，树的高度相对较高。

3. 更好的磁盘访问性能 - B+ 树：由于所有数据都在叶子节点中，一次范围查询只需访问一层叶子节点，减少了磁盘 I/O 次数。- B 树：可能需要访问多层节点来完成同样的查询，增加了磁盘 I/O 开销。

4. 简化的插入和删除操作 - B+ 树：插入和删除操作仅影响叶子节点及其直接父节点，简化了维护平衡的操作。- B 树：插入和删除可能导致非叶子节点的变化，增加了维护树结构复杂度。

5. 支持并行处理 - B+ 树：叶子节点之间的链表结构使得多个查询可以在不同的叶子节点上并行执行，提高了并发性。- B 树：缺乏这种直接的链表连接，难以实现高效的并行查询。

通过上述对比可以看出， B_+ 树在许多方面提供了比 B 树更优的性能和特性，特别是在支持大规模数据库系统的高效查询、插入和删除操作方面表现出色。

7. 开放地址法建立散列表。(15 分)

Solution:

开放地址法 (Open Addressing) 是一种解决散列表中哈希冲突的方法。它规定所有元素都存储在散列表的数组本身中，而不是像链地址法那样将溢出元素链接到外部链表。当发生冲突时，通过特定的探测序列来寻找下一个可用的位置。

基本步骤

1. 初始化：- 创建一个大小为 m 的数组 $T[0..m-1]$ ，并将所有位置初始化为空（或使用特殊值表示空位）。
2. 插入操作：- 对于要插入的键 k ，计算其哈希值 $h(k)$ 。- 如果 $T[h(k)]$ 为空，则直接插入该位置。- 如果 $T[h(k)]$ 已被占用，则根据某种探测策略找到下一个可用位置，并继续尝试插入，直到找到空位为止。

3. 查找操作：- 对于要查找的键 k ，从 $h(k)$ 开始按照相同的探测策略依次检查，直到找到键 k 或遇到空位（表示该键不在表中）。

4. 删除操作：- 删除操作较为复杂，因为直接删除可能会导致后续插入或查找失败。通常采用标记删除的方式，即用特殊标记代替实际删除，以保持探测序列的完整性。

探测策略

常见的探测策略包括以下几种：

1. 线性探测 (Linear Probing)

线性探测是最简单的探测方法之一。它在发生冲突时，顺序地检查下一个位置，直到找到空位或遍历完整个数组。

- 公式： $h_i(k) = (h(k) + i) \bmod m$ ，其中 $i = 0, 1, 2, \dots, m-1$

2. 二次探测 (Quadratic Probing)

二次探测通过增加步长的平方来减少聚集现象。这种方法可以有效避免“初级聚集”，但仍然可能存在“次级聚集”。

- 公式： $h_i(k) = (h(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m$ ，其中 c_1 和 c_2 是常数， $i = 0, 1, 2, \dots, m-1$

3. 双重散列 (Double Hashing)

双重散列使用第二个哈希函数来计算探测的步长，这减少了哈希冲突的聚集效应。

- 公式： $h_i(k) = (h_1(k) + i \cdot h_2(k)) \bmod m$ ，其中 $h_1(k)$ 是初始哈希函数， $h_2(k)$ 是第二个哈希函数， $i = 0, 1, 2, \dots, m-1$

优缺点

- 优点：- 存储紧凑：所有元素都在数组内，不需要额外的链表空间。- 查找速度快：可以直接定位到数据的位置。

- 缺点：- 当负载因子较高时，探测效率较低，可能导致大量的碰撞和性能下降。- 删除操作复杂，需要额外的维护。- 对探测策略的选择有较高要求，不同策略的性能差异可能较大。

8. 给出 Kruskal 建边的顺序。(15 分)

Solution:

直接给图推流程是相对简单的，在这里我们给出用并查集实现 Kruskal 的算法。

```
class UnionFind:
```

```
    def __init__(self, n):
        self.parent = list(range(n))
        self.rank = [1] * n
```

```

def find(self, p):
    if self.parent[p] != p:
        self.parent[p] = self.find(self.parent[p])
    return self.parent[p]

def union(self, p, q):
    rootP = self.find(p)
    rootQ = self.find(q)
    if rootP != rootQ:
        if self.rank[rootP] > self.rank[rootQ]:
            self.parent[rootQ] = rootP
        elif self.rank[rootP] < self.rank[rootQ]:
            self.parent[rootP] = rootQ
        else:
            self.parent[rootQ] = rootP
            self.rank[rootP] += 1

def connected(self, p, q):
    return self.find(p) == self.find(q)

```

```

def kruskal(edges, V):
    edges.sort(key=lambda edge: edge[2])

    uf = UnionFind(V)
    mst = []
    mst_weight = 0

    for edge in edges:
        u, v, weight = edge

        if not uf.connected(u, v):
            uf.union(u, v)
            mst.append(edge)
            mst_weight += weight

    return mst, mst_weight

```

9. 写出堆排序的代码，并说明堆排序是否稳定。(15 分)

Solution:

堆排序并不是一个稳定的排序算法，就比如初始数组为 1,2,2，在删除 1 后下一个数是第三个 2，而不是第二个 2。

```

class Min_heap(object):
    def __init__(self,
        data):

```



```

        self.data = data
self.l = len(data)          self.build_Min_heap()

def build_Min_heap(self):
    start = int((self.l-2) / 2)
    for i in range(start, -1, -1):
        l_c = i * 2 + 1
        r_c = i * 2 + 2
        m = l_c
        if r_c < self.l and self.data[r_c] < self.data[l_c]:
            m = r_c
        if self.data[m] < self.data[i]:
            self.data[m], self.data[i] = self.data[i], self.data[m]

def is_min_heap(self, node):
    l_c = node * 2 + 1
    r_c = node * 2 + 2
    if r_c < self.l:
        if self.data[r_c] < self.data[node] or not self.is_min_heap(r_c):
            return False

    if l_c < self.l:
        if self.data[l_c] < self.data[node] or not self.is_min_heap(l_c):
            return False
    return True

def add_element(self, element):
    self.l += 1
    self.data.append(element)
    t = self.l-1
    i = int((self.l -2) / 2)
    while(i >=0 and self.data[i] > element):
        self.data[t] = self.data[i]
        t = i
        i = int((i-1) / 2)
    self.data[t] = element

def del_element(self):
    last = self.l-1
    self.l -= 1
    self.data[0], self.data[last] = self.data[last], self.data[0]
    i = 0

```

```

        d = self.data[0]
    while(i * 2 + 1 < self.l):
        l_c = i * 2 + 1
        r_c = i * 2 + 2
        t = l_c
        if r_c < self.l and self.data[r_c] < self.data[t]:
            t = r_c

        if self.data[t] < d:
            self.data[i] = self.data[t]
        else:
            break
        i = t
    self.data[i] = d

def sort_heap(self):
    while(self.l!=1):
        self.del_element()

```

北京大学数院-856 大数据-2026 年

1. 将 n 个球随机放入 m 个盒子中。试求：(1) 任意一个指定盒子中球的个数的数学期望与方差；(2) 有球的盒子（即非空盒子）个数的数学期望。

Solution:

(1) 对于任意球 $k \in \{1, \dots, n\}$ 与盒子 $j \in \{1, \dots, m\}$ ，记事件 A_{kj} 为“球 k 落入盒子 j ”，则

$$P(A_{kj}) = \frac{1}{m}, \quad \forall k, j$$

考察任意指定盒子 j_0 中球的个数 X 。引入示性随机变量序列 $\{\xi_k\}_{k=1}^n$ ：

$$\xi_k = \mathbb{I}(k \text{ 号球落入 } j_0 \text{ 号盒子}) = \begin{cases} 1, & \text{球 } k \in \text{盒子 } j_0 \\ 0, & \text{球 } k \notin \text{盒子 } j_0 \end{cases}$$

显然， $\xi_1, \dots, \xi_n$ 相互独立且同分布 (i.i.d.)，且 $\xi_k \sim B(1, \frac{1}{m})$ 。注意到 $X = \sum_{k=1}^n \xi_k$ 。由独立同分布随机变量和的性质，可知 $X \sim B(n, \frac{1}{m})$ 。故

$$E[X] = np = \frac{n}{m}$$

$$\text{Var}(X) = np(1-p) = n \cdot \frac{1}{m} \cdot \left(1 - \frac{1}{m}\right) = \frac{n(m-1)}{m^2}$$

(2) 设随机变量 Y 为非空盒子的个数。为利用期望的线性性质，定义盒子 j 的示性变量 η_j ：

$$\eta_j = \mathbb{I}(\text{盒子 } j \text{ 非空}) = \begin{cases} 1, & \text{盒子 } j \text{ 中有球} \\ 0, & \text{盒子 } j \text{ 为空} \end{cases}$$

则非空盒子总数 Y 可表示为 $Y = \sum_{j=1}^m \eta_j$ 。利用数学期望的线性性质，有

$$E[Y] = E\left[\sum_{j=1}^m \eta_j\right] = \sum_{j=1}^m E[\eta_j]$$

为计算 $E[\eta_j]$ ，考察其对立事件“盒子 j 为空”。即

$$P(\eta_j = 0) = P\left(\bigcap_{k=1}^n \{k \text{ 号球} \notin \text{盒子 } j\}\right) = \left(1 - \frac{1}{m}\right)^n$$

从而 $E[\eta_j] = P(\eta_j = 1) = 1 - P(\eta_j = 0) = 1 - \left(\frac{m-1}{m}\right)^n$ 。代回 Y 的期望表达式，考虑到所有盒子具有对称性，即 $E[\eta_j]$ 对所有 j 相等，最终得：

$$E[Y] = \sum_{j=1}^m \left[1 - \left(\frac{m-1}{m}\right)^n\right] = m \left[1 - \left(\frac{m-1}{m}\right)^n\right]$$

Remark: 这道题由于第一问的提示，大部分同学应该能想到用期望的线性性质去拆分。但这里求解 Y 的分布列也是可行的，只是计算量比较大，这里附一个结果供部分同学验证：

$$P(Y = k) = \frac{\binom{m}{k}}{m^n} \sum_{j=0}^k (-1)^j \binom{k}{j} (k-j)^n, \quad k = 1, 2, \dots, \min(n, m)$$

2. (单边切比雪夫不等式) 设 ξ 为随机变量, 满足 $E\xi = 0$, $D\xi = \sigma^2 < \infty$. 试证: 对任何一个 $a > 0$, 有

$$P\{\xi \geq a\} \leq \frac{\sigma^2}{\sigma^2 + a^2}$$

Solution:

(注: 本题为 2019 年复旦大学 432 真题第四题。)

我们通过引入辅助参数构造二次型来证明该不等式。对于任意常数 $b > 0$, 利用不等式的平移不变性, 显然有 $P(\xi \geq a) = P(\xi + b \geq a + b)$ 。由于已知 $a > 0$ 且 $b > 0$, 故 $a + b > 0$ 。此时, 我们可以针对非负随机变量 $(\xi + b)^2$ 应用马尔可夫不等式, 得到如下放缩

$$P(\xi + b \geq a + b) = P((\xi + b)^2 \geq (a + b)^2) \leq \frac{E[(\xi + b)^2]}{(a + b)^2}$$

接下来展开分子中的期望项。利用期望的线性性质以及题目给定的条件 $E\xi = 0$ 和 $E[\xi^2] = D\xi + (E\xi)^2 = \sigma^2$, 计算可得

$$E[(\xi + b)^2] = E[\xi^2 + 2b\xi + b^2] = E[\xi^2] + 2bE\xi + b^2 = \sigma^2 + 0 + b^2 = \sigma^2 + b^2$$

将此期望值代入上述不等式, 得

$$P(\xi \geq a) \leq \frac{\sigma^2 + b^2}{(a + b)^2}$$

取 $b = \frac{\sigma^2}{a}$, 将其代入上式进行化简:

$$\frac{\sigma^2 + b^2}{(a + b)^2} = \frac{\sigma^2 + (\frac{\sigma^2}{a})^2}{(a + \frac{\sigma^2}{a})^2} = \frac{\sigma^2 + \frac{\sigma^4}{a^2}}{(\frac{a^2 + \sigma^2}{a})^2} = \frac{\frac{\sigma^2(a^2 + \sigma^2)}{a^2}}{\frac{(a^2 + \sigma^2)^2}{a^2}} = \frac{\sigma^2}{a^2 + \sigma^2}$$

至此, 不等式得证。

Remark: 关于参数 $b = \frac{\sigma^2}{a}$ 的选取动机。若我们将不等式右端的上界记为关于 b 的函数 $g(b) = \frac{\sigma^2 + b^2}{(a + b)^2}$, 为了使不等式最强 (即上界最小), 我们需要求出 $g(b)$ 的最小值点。通过求解导数方程 $g'(b) = 0$, 可以发现极值点恰好在 $b = \frac{\sigma^2}{a}$ 处取到, 这保证了我们使用的是该方法下的最优上界。

3. 设二维随机变量 (X, Y) 的联合概率密度函数为:

$$f(x, y) = \begin{cases} Cx(x + y), & 0 \leq x \leq 1, 0 \leq y \leq 1, 0 \leq x + y \leq 1 \\ 0, & \text{其他} \end{cases}$$

其中 C 为常数。试求:

- (1) 常数 C 的值;
- (2) (X, Y) 关于 X 和 Y 的边缘概率密度函数 $f_X(x)$ 与 $f_Y(y)$;
- (3) X 与 Y 的数学期望 $E[X], E[Y]$ 及方差 $Var(X), Var(Y)$;
- (4) X 与 Y 的协方差 $Cov(X, Y)$ 及相关系数 ρ_{XY} 。

Solution:

(1) 注意到随机变量 (X, Y) 的支撑集 D 是由直线 $x = 0, y = 0$ 及 $x + y = 1$ 围成的三角形区域。根据概率的归一性, 联合密度函数在 D 上的积分应为 1, 即:

$$\iint_{\mathbb{R}^2} f(x, y) dx dy = \iint_D Cx(x + y) dx dy = 1$$

计算得:

$$\int_0^1 dx \int_0^{1-x} C(x^2 + xy) dy = C \int_0^1 \left[x^2 y + \frac{1}{2} xy^2 \right]_{y=0}^{y=1-x} dx = \frac{C}{2} \int_0^1 (x - x^3) dx = \frac{C}{2} \left[\frac{1}{2} x^2 - \frac{1}{4} x^4 \right]_0^1 = \frac{C}{2} \left(\frac{1}{2} - \frac{1}{4} \right) = \frac{C}{8}$$

令该结果等于 1, 解得常数 $C = 8$ 。

(2) 对于 X 的边缘密度 $f_X(x)$, 积分得:

$$f_X(x) = \int_0^{1-x} 8x(x+y) dy = 8 \cdot \frac{1}{2}(x-x^3) = 4x(1-x^2), \quad 0 \leq x \leq 1$$

对于 Y 的边缘密度 $f_Y(y)$, 积分得:

$$f_Y(y) = \int_0^{1-y} 8(x^2+xy) dx = 8 \left[\frac{x^3}{3} + \frac{x^2y}{2} \right]_0^{1-y} = \frac{4}{3}(1-y)^2(2+y), \quad 0 \leq y \leq 1$$

而在支撑集之外, 边缘密度均为 0。

(3) 根据数学期望的定义:

$$E[X] = \int_0^1 x f_X(x) dx = \int_0^1 4x^2(1-x^2) dx = 4 \left(\frac{1}{3} - \frac{1}{5} \right) = \frac{8}{15}$$

$$E[X^2] = \int_0^1 x^2 f_X(x) dx = \int_0^1 4x^3(1-x^2) dx = 4 \left(\frac{1}{4} - \frac{1}{6} \right) = \frac{1}{3}$$

由此可得 X 的方差为 $Var(X) = E[X^2] - (E[X])^2 = \frac{1}{3} - \left(\frac{8}{15}\right)^2 = \frac{75-64}{225} = \frac{11}{225}$ 。同理计算 Y 的期望与方差:

$$E[Y] = \int_0^1 y \cdot \frac{4}{3}(1-y)^2(2+y) dy = \frac{4}{15}$$

$$E[Y^2] = \int_0^1 y^2 \cdot \frac{4}{3}(1-y)^2(2+y) dy = \frac{1}{9}$$

于是 Y 的方差为 $Var(Y) = \frac{1}{9} - \left(\frac{4}{15}\right)^2 = \frac{25-16}{225} = \frac{9}{225} = \frac{1}{25}$ 。

最后, 我们考察 X 与 Y 的相关性。首先计算混合中心矩 $E[XY]$:

$$E[XY] = \iint_D xy \cdot 8x(x+y) dx dy = 8 \int_0^1 x^2 dx \int_0^{1-x} (xy+y^2) dy = \frac{1}{9}$$

因此, 协方差为:

$$Cov(X, Y) = E[XY] - E[X]E[Y] = \frac{1}{9} - \frac{8}{15} \cdot \frac{4}{15} = \frac{25}{225} - \frac{32}{225} = -\frac{7}{225}$$

进而计算相关系数:

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}} = \frac{-7/225}{\sqrt{11/225} \cdot \sqrt{1/25}} = \frac{-7/225}{\frac{\sqrt{11}}{15} \cdot \frac{1}{5}} = \frac{-7}{\sqrt{11} \cdot 3} = -\frac{7\sqrt{11}}{33}$$

4. 设 $U_1, U_2, \dots$ 是一列独立同分布 (i.i.d.) 的随机变量, 且均服从区间 $[0, 1]$ 上的均匀分布, 即 $U_i \sim U(0, 1)$ 。定义随机变量 N 为使得前 n 个随机变量之和首次超过 1 的最小下标, 即:

$$N = \min \left\{ n : \sum_{i=1}^n U_i > 1 \right\}$$

试求出随机变量 N 的数学期望 $E[N]$ 。

Solution:

考察事件 $\{N > n\}$, 由 N 的定义知, 事件 $\{N > n\}$ 意味着前 n 个随机变量的累加和尚未超过 1, 记 $S_n = \sum_{i=1}^n U_i$, 则有如下等价关系:

$$\{N > n\} \iff \{S_n \leq 1\}$$

由于 $U_1, \dots, U_n$ 独立且服从 $U(0, 1)$, 其联合概率密度在单位超立方体 $[0, 1]^n$ 上恒为 1。因此, 概率 $P(S_n \leq 1)$ 在几何上对应于 n 维空间中区域 $D_n = \{(u_1, \dots, u_n) : u_i \geq 0, \sum_{i=1}^n u_i \leq 1\}$ 的体积。利用几何概率的经典结论或归纳易证, 该标准 n -单纯形的体积为:

$$P(N > n) = P(S_n \leq 1) = \int \cdots \int_{D_n} du_1 \cdots du_n = \frac{1}{n!}$$

容易验证这一结论对 $n = 0, 1$ 同样在形式上成立。

利用非负整数值随机变量期望的尾概率求和公式, 我们有:

$$E[N] = \sum_{n=0}^{\infty} P(N > n)$$

代入上述计算得到的概率, 得:

$$E[N] = \sum_{n=0}^{\infty} \frac{1}{n!} = e$$

5. 设总体 X 服从区间 $[\theta, 2\theta]$ 上的均匀分布, 其中 $\theta > 0$ 为未知参数。设 $X_1, \dots, X_n$ 为来自该总体的简单随机样本, 试求: (1) 参数 θ 的极大似然估计量 (MLE); (2) 该估计量的均方误差 (MSE)。

Solution:

(1) 由于总体 X 的概率密度函数为 $f(x; \theta) = \frac{1}{\theta} \mathbb{I}_{\{\theta \leq x < 2\theta\}}$, 其中 $\mathbb{I}_A$ 为示性函数, 样本 $X_1, \dots, X_n$ 的联合概率密度函数即为似然函数:

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{\{\theta \leq x_i < 2\theta\}} = \frac{1}{\theta^n} \mathbb{I}_{\{\theta \leq x_{(1)}\}} \mathbb{I}_{\{x_{(n)} < 2\theta\}}$$

此处 $x_{(1)} = \min(x_1, \dots, x_n)$ 为样本最小值, $x_{(n)} = \max(x_1, \dots, x_n)$ 为样本最大值。观察示性函数定义的约束条件, 似然函数非零当且仅当 $\theta \leq x_{(1)}$ 且 $\theta > \frac{x_{(n)}}{2}$, 即 $\theta \in (\frac{x_{(n)}}{2}, x_{(1)}]$ 。

考虑似然函数的上确界, 由似然函数单调性, 可知:

$$\hat{\theta}_{MLE} = \frac{X_{(n)}}{2}$$

(2) 直接积分计算 $X_{(n)}$ 的期望平方误差比较繁琐, 利用标准化变换构造 Beta 分布是处理均匀分布次序统计量的标准做法。由 $X_i \sim U(\theta, 2\theta)$, 做线性变换:

$$Z_i = \frac{X_i - \theta}{2\theta - \theta} = \frac{X_i}{\theta} - 1$$

显然, $Z_i \sim U(0, 1)$ 。

$Z_{(n)} = \frac{X_{(n)}}{\theta} - 1$ 是来自 $U(0, 1)$ 样本的最大值。根据结论, $U(0, 1)$ 的第 k 个次序统计量服从 $\text{Beta}(k, n-k+1)$ 分布。所以, $Z_{(n)} \sim \text{Beta}(n, 1)$ 。

从而

$$\text{MSE} = E \left[\left(\hat{\theta} - \theta \right)^2 \right] = E \left[\left(\frac{X_{(n)}}{2} - \theta \right)^2 \right]$$

将 $X_{(n)} = \theta(Z_{(n)} + 1)$ 代入上式:

$$\frac{X_{(n)}}{2} - \theta = \frac{\theta(Z_{(n)} + 1)}{2} - \theta = \frac{\theta}{2}(Z_{(n)} - 1)$$

于是 MSE 变为:

$$\text{MSE} = E \left[\frac{\theta^2}{4} (Z_{(n)} - 1)^2 \right] = \frac{\theta^2}{4} E \left[(1 - Z_{(n)})^2 \right]$$

注意到 $1 - Z_{(n)}$ 其实就是 $U(0, 1)$ 样本的最小值 (或者利用 Beta 分布对称性), 它服从 $\text{Beta}(1, n)$ 分布。因此:

$$E[(1 - Z_{(n)})^2] = \frac{1 \cdot (1+1)}{(1+n)(1+n+1)} = \frac{2}{(n+1)(n+2)}$$

得出结果:

$$\text{MSE} = \frac{\theta^2}{4} \cdot \frac{2}{(n+1)(n+2)} = \frac{\theta^2}{2(n+1)(n+2)}$$

Remark: 介绍几个均匀分布次序统计量的常用结论, 大家可自行证明: 设 $X_1, X_2, \dots, X_n$ 为一组独立同分布 (i.i.d.) 的随机变量, 且服从区间 $(0, 1)$ 上的均匀分布, 记 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 为其对应的次序统计量。则有:

1. 对于任意 $1 \leq i \leq n$ $X_{(i)} \sim \text{Beta}(i, n+1-i)$ 2. $X_{(n)} - X_{(1)} \sim \text{Beta}(n-1, 2)$ 3. 最后, 对任意下标满足 $1 \leq i_1 < i_2 < \dots < i_r \leq n$ 的一组次序统计量。我们构建如下随机变量序列:

$$\frac{X_{(i_1)}}{X_{(i_2)}}, \frac{X_{(i_2)}}{X_{(i_3)}}, \dots, \frac{X_{(i_{r-1})}}{X_{(i_r)}}, X_{(i_r)}$$

这一序列中的随机变量相互独立。且对于任意 $1 \leq k < r$,

$$\frac{X_{(i_k)}}{X_{(i_{k+1})}} \sim \text{Beta}(i_k, i_{k+1} - i_k)$$

6. 设两个独立的随机样本 $X_1, \dots, X_m$ 和 $Y_1, \dots, Y_n$ 分别来自正态总体 $N(\mu_1, \sigma^2)$ 和 $N(\mu_2, \rho\sigma^2)$, 其中 μ_1, μ_2, σ^2 为未知参数, $\rho > 0$ 为已知常数。试求 $\mu_2 - \mu_1$ 的置信水平为 $1 - \alpha$ 的置信区间。

Solution:

这是一个经典的双样本正态均值差估计问题, 其特殊之处在于两总体的方差虽然未知, 但其比例 ρ 已知。为了求解 $\mu_2 - \mu_1$ 的置信区间, 我们首先寻找点估计, 进而通过标准化和方差修正构造枢轴量。

首先, 考虑两个样本的均值 $\bar{X}$ 和 $\bar{Y}$ 。由正态分布的可加性及样本的独立性可知, $\bar{X} \sim N(\mu_1, \frac{\sigma^2}{m})$, $\bar{Y} \sim N(\mu_2, \frac{\rho\sigma^2}{n})$ 。定义差值统计量 $D = \bar{Y} - \bar{X}$, 则 D 服从正态分布:

$$D \sim N\left(\mu_2 - \mu_1, \sigma^2 \left(\frac{1}{m} + \frac{\rho}{n}\right)\right)$$

将其标准化, 可得到包含参数 σ 的标准正态变量:

$$Z = \frac{(\bar{Y} - \bar{X}) - (\mu_2 - \mu_1)}{\sigma \sqrt{\frac{1}{m} + \frac{\rho}{n}}} \sim N(0, 1)$$

由于 σ^2 未知, 我们需要构造其无偏估计量来消去 Z 中的 σ 。考察两个样本的样本方差 (或离差平方和):

$$S_X^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \quad S_Y^2 = \frac{1}{n-1} \sum_{j=1}^n (Y_j - \bar{Y})^2$$

根据 Fisher 引理, $\frac{(m-1)S_X^2}{\sigma^2} \sim \chi^2(m-1)$ 。注意到第二个总体的方差为 $\rho\sigma^2$, 故 $\frac{(n-1)S_Y^2}{\rho\sigma^2} \sim \chi^2(n-1)$ 。利用卡方分布的可加性, 有:

$$W = \frac{(m-1)S_X^2}{\sigma^2} + \frac{(n-1)S_Y^2}{\rho\sigma^2} = \frac{1}{\sigma^2} \left[(m-1)S_X^2 + \frac{1}{\rho}(n-1)S_Y^2 \right]$$

显然, $W \sim \chi^2(m+n-2)$ 。

接下来, 根据 t 分布的定义, 利用 Z 和 W 构造枢轴量 T :

$$T = \frac{Z}{\sqrt{W/(m+n-2)}} = \frac{\frac{(\bar{Y}-\bar{X})-(\mu_2-\mu_1)}{\sigma\sqrt{\frac{1}{m}+\frac{1}{n}}}}{\sqrt{\frac{(m-1)S_X^2+\frac{1}{\rho}(n-1)S_Y^2}{\sigma^2(m+n-2)}}}$$

消去分子分母中的 σ , 我们得到不含未知参数 σ 的 t 统计量:

$$T = \frac{(\bar{Y}-\bar{X})-(\mu_2-\mu_1)}{S_w\sqrt{\frac{1}{m}+\frac{1}{n}}} \sim t(m+n-2)$$

其中,

$$S_w = \sqrt{\frac{(m-1)S_X^2 + \frac{1}{\rho}(n-1)S_Y^2}{m+n-2}}$$

最后, 由 $P(-t_{1-\alpha/2}(m+n-2) \leq T \leq t_{1-\alpha/2}(m+n-2)) = 1-\alpha$ (此处记 $t_{1-\alpha/2}$ 为自由度为 $m+n-2$ 的 t 分布的上 $\alpha/2$ 分位点), 反解不等式中的 $\mu_2-\mu_1$, 即可得到置信区间。综上所述, $\mu_2-\mu_1$ 的 $1-\alpha$ 置信区间为:

$$\left[(\bar{Y}-\bar{X}) - t_{1-\alpha/2} \cdot S_w \sqrt{\frac{1}{m} + \frac{\rho}{n}}, \quad (\bar{Y}-\bar{X}) + t_{1-\alpha/2} \cdot S_w \sqrt{\frac{1}{m} + \frac{\rho}{n}} \right]$$

7. 小堆插入 (本题为模拟数据)

题目: 已知一个现有的小顶堆 (小堆), 其底层数组结构为: $H = [10, 28, 20, 35, 30, 40]$

要求: 请将元素 15 插入到该小顶堆中, 并画出 (或文字描述) 每次 “向上调整” 后的数组状态, 直到堆的性质恢复。


Solution:


小顶堆性质: 任意节点的值 $\leq$ 其子节点的值。堆顶 (数组下标 0) 是最小值。

插入规则: 先将新元素插入到数组的末尾, 然后执行向上调整 (percolate up), 即不断与父节点比较; 如果比父节点小, 则交换, 直到满足堆性质。

父子下标关系: 当前节点下标为 i , 父节点下标为 $\left\lfloor \frac{i-1}{2} \right\rfloor$ 。

插入示意 (新插入元素为 15):





Remark: 以下为实现代码（题目并未要求，仅作参考）。


```
1 #include <vector>
2 #include <algorithm>
3 #include <iostream>
4
5 class MinHeap {
6 public:
7     std::vector<int> heap;
8
9     // 获取父节点索引
10    int parent(int i) { return (i - 1) / 2; }
11
12    // 插入操作
13    void insert(int key) {
14        // 1. 先放到末尾
15        heap.push_back(key);
16        int i = (int)heap.size() - 1;
17
18        // 2. 上滤 (Percolate Up)
19        // 只要当前节点不是根节点，且比父节点小，就交换
20        while (i != 0 && heap[parent(i)] > heap[i]) {
21            std::swap(heap[i], heap[parent(i)]);
22            i = parent(i);
23        }
24    }
25};
```

8. AVL 建树请依次将序列 8, 7, 1, 2, 3, 4, 6, 5 插入到一棵空的 AVL 树中, 请画出每次插入后的树结构变化过程。


Solution:

思路: AVL 是自平衡二叉搜索树。每次插入后, 通过回溯更新节点高度, 计算平衡因子。如果失衡 (平衡因子绝对值 > 1), 则通过旋转 (左旋、右旋、先左后右、先右后左) 来恢复平衡。


【步骤 1-3: 插入 8, 7, 1 (LL 型失衡 $\rightarrow$ 右旋)】



【步骤 4-5: 插入 2, 3 (RR 型失衡 $\rightarrow$ 左旋)】



【步骤 6: 插入 4 (LR 型失衡 $\rightarrow$ 先 2 左旋, 后 7 右旋)】



【步骤 7-8: 插入 6, 5 (RL 型失衡 $\rightarrow$ 先 6 右旋, 后 4 左旋)】



Remark: 以下为实现代码（题目并未要求，仅作补充）。

```
1 #include <algorithm>
2 #include <iostream>
3
4 struct AVLNode {
5     int key;
6     AVLNode *left, *right;
7     int height;
8     AVLNode(int k) : key(k), left(nullptr), right(nullptr), height(1) {}
9 };
10
11 // 获取高度
12 int getHeight(AVLNode* n) {
13     return n ? n->height : 0;
14 }
15
16 // 获取平衡因子
17 int getBalance(AVLNode* n) {
18     return n ? getHeight(n->left) - getHeight(n->right) : 0;
19 }
20
21 // 右旋 (LL情况)
22 AVLNode* rightRotate(AVLNode* y) {
23     AVLNode* x = y->left;
24     AVLNode* T2 = x->right;
25     // 旋转
26     x->right = y;
27     y->left = T2;
28     // 更新高度
29     y->height = std::max(getHeight(y->left), getHeight(y->right)) + 1;
30     x->height = std::max(getHeight(x->left), getHeight(x->right)) + 1;
31     return x;
32 }
33
34 // 左旋 (RR情况)
35 AVLNode* leftRotate(AVLNode* x) {
36     AVLNode* y = x->right;
37     AVLNode* T2 = y->left;
38     // 旋转
39     y->left = x;
40     x->right = T2;
41     // 更新高度
42     x->height = std::max(getHeight(x->left), getHeight(x->right)) + 1;
43     y->height = std::max(getHeight(y->left), getHeight(y->right)) + 1;
44     return y;
45 }
46
```


```

47 // 插入节点并建树
48 AVLNode* insert(AVLNode* node, int key){// 1. 标准BST插入
49     if (!node) return new AVLNode(key);
50     if (key < node->key)
51         node->left = insert(node->left, key);
52     else if (key > node->key)
53         node->right = insert(node->right, key);
54     else
55         return node; // 不允许重复键值
56
57     // 2. 更新高度
58     node->height = 1 + std::max(getHeight(node->left), getHeight(node->right));
59
60     // 3. 获取平衡因子并旋转
61     int balance = getBalance(node);
62
63     // LL Case
64     if (balance > 1 && key < node->left->key)
65         return rightRotate(node);
66
67     // RR Case
68     if (balance < -1 && key > node->right->key)
69         return leftRotate(node);
70
71     // LR Case
72     if (balance > 1 && key > node->left->key) {
73         node->left = leftRotate(node->left);
74         return rightRotate(node);
75     }
76
77     // RL Case
78     if (balance < -1 && key < node->right->key) {
79         node->right = rightRotate(node->right);
80         return leftRotate(node);
81     }
82
83     return node;
84 }

```

9. 删除 B 树节点 (本题为模拟数据)

一棵 5 阶 B 树:



要求: 请依次执行以下删除操作, 并画出每次操作后的树结构:

1. 删除 80 (简单删除)

2. 删除 10 (下溢 → 向兄弟借位/旋转)
3. 删除 50 (删除非叶子节点 → 转化 → 下溢合并 → 降高)

Solution:

分三种情况:

- 叶子节点: 直接删除。
- 内部节点: 用前驱或后继覆盖, 然后递归删除前驱/后继。
- 节点关键字不足: 需要从兄弟借节点或者与兄弟合并。

1. 删除 80 (简单删除)

直接从叶子节点中删除 80。删除后右子节点剩余 [60, 70, 90] (3 个关键字), 满足最小限制 (≥ 2), 无需调整。




2. 删除 10 (下溢 → 向右兄弟借位)

从左子节点 [10, 20] 删除 10, 剩余 [20]。关键字数量为 1, 小于最小值 2。检查右兄弟 [60, 70, 90], 它有 3 个关键字 (富裕), 可以借一个。

调整步骤 (左旋/借位):

1. 父节点下移: 父节点 50 下移到左子节点;
2. 兄弟节点上移: 右兄弟的第一个关键字 60 上移填补父节点。




3. 删除 50 (非叶子节点删除 + 合并)

50 在左叶子节点 [20, 50] 中 (实际上 B 树删除通常针对任意节点; 若删除的是内部节点, 需先与前驱/后继交换)。注: 题目为了连贯性, 这里假设直接删除叶子中的 50。若原题意是删除根节点的 50, 逻辑是先换后删, 结果类似。这里按“删除当前叶子中的 50”处理。

从 [20, 50] 删除 50, 剩余 [20], 发生下溢 ($1 < 2$)。检查右兄弟 [70, 90], 它只有 2 个关键字, 无法借位, 只能合并。

调整步骤 (合并):

1. 父节点下移: 父节点 60 下移, 夹在左右孩子中间;
2. 融合: [左孩子] + [父节点] + [右孩子] 合并为新节点;
3. 根节点处理: 父节点 60 下移后, 原根节点变空, 树的高度降低一层。



经过三次删除后，B 树高度从 2 降为 1，变为一个单独的节点：

[20, 60, 70, 90].

10. 快速排序

Solution:

分治法。选取基准值 (Pivot)，通过 `partition` 函数将数组分为两部分：左边比基准小，右边比基准大，然后递归排序。

```
1 #include <vector>
2 #include <algorithm>
3
4 // 分区函数
5 int partition(std::vector<int>& arr, int low, int high) {
6     int pivot = arr[high]; // 选取最后一个元素作为基准
7     int i = (low - 1); // i 指向小于 pivot 的区域边界
8
9     for (int j = low; j <= high - 1; j++) {
10         if (arr[j] < pivot) {
11             i++;
12             std::swap(arr[i], arr[j]);
13         }
14     }
15     std::swap(arr[i + 1], arr[high]);
16     return (i + 1);
17 }
18
19 // 快排主函数
20 void quickSort(std::vector<int>& arr, int low, int high) {
21     if (low < high) {
22         int pi = partition(arr, low, high);
23
24         quickSort(arr, low, pi - 1);
25         quickSort(arr, pi + 1, high);
26     }
27 }
```

11. 多项式时间设计图可达点

Solution: 判断一个点是否“可达”以及找出所有可达点，最核心的两个算法就是 BFS (广度优先搜索) 和 DFS (深度优先搜索)。虽然它们遍历顺序不同，但对于“可达性”这个问题，两者的时间复杂度都是 $O(V + E)$ (V 为节点数， E 为边数)，都属于多项式时间算法。

```
1 #include <iostream>
2 #include <vector>
3 #include <queue>
4 #include <algorithm> // for sorting output
5
```

```

6 // 使用邻接表来表示图
7 // Graph[u] 包含所有从 u 出发能到达的节点 v
8 using Graph = std::vector<std::vector<int>>>;
9 class GraphReachability {
10 public:
11
12     // 方法 1: BFS (广度优先搜索) - 迭代法
13     static std::vector<int> getReachableBFS(const Graph& g, int startNode) {
14         int n = g.size();
15         std::vector<bool> visited(n, false);
16         std::vector<int> result;
17         std::queue<int> q;
18
19         // 初始化
20         visited[startNode] = true;
21         q.push(startNode);
22         result.push_back(startNode);
23
24         while (!q.empty()) {
25             int u = q.front();
26             q.pop();
27
28             // 遍历 u 的所有邻居
29             for (int v : g[u]) {
30                 if (!visited[v]) {
31                     visited[v] = true;
32                     q.push(v);
33                     result.push_back(v);
34                 }
35             }
36         }
37         return result;
38     }
39
40     // 方法 2: DFS (深度优先搜索) - 递归法
41     static std::vector<int> getReachableDFS(const Graph& g, int startNode) {
42         int n = g.size();
43         std::vector<bool> visited(n, false);
44         std::vector<int> result;
45
46         // 调用递归辅助函数
47         dfsRecursive(g, startNode, visited, result);
48
49         return result;
50     }
51
52 private:

```

```

53 // DFS 的递归核心逻辑
54 static void dfsRecursive(const Graph& g, int u, std::vector<bool>& visited, std::vector<int>& result){
55     visited[u] = true;
56     result.push_back(u);
57
58     for (int v : g[u]) {
59         if (!visited[v]) {
60             dfsRecursive(g, v, visited, result);
61         }
62     }
63 };

```

12. 串的最长回文子串

Solution: 这个问题主要有三种经典的解法:

1. 中心扩散法

核心思想:

回文串具有对称性, 它的中心可能是一个字符 (如 "aba" 的 'b'), 也可能是两个字符之间的空隙 (如 "abba" 中间)。

对于长度为 n 的字符串, 共有 n 个中心 (个字符中心 + 个间隙中心)。我们只需遍历这个中心, 向两边扩散, 直到无法匹配为止。

算法流程: (1) 遍历字符串的每一个位置。(2) 对每个位置, 分别进行两次扩散: 一次假设回文长度为奇数 (以当前字符为中心)。一次假设回文长度为偶数 (以当前字符和下一个字符之间为中心)。(3) 记录并更新找到的最长回文长度和起始位置。时间复杂度: $O(n^2)$ 。我们需要遍历每个中心, 且每次扩散最坏情况下需要 $O(n)$ 时间。空间复杂度: $O(1)$ 。只需要常数空间存储索引。

```

1 def longestPalindrome_center(s: str) -> str:
2     if not s: return ""
3
4     start, end = 0, 0
5
6     def expand(left, right):
7         while left >= 0 and right < len(s) and s[left] == s[right]:
8             left -= 1
9             right += 1
10        return left + 1, right - 1
11
12    for i in range(len(s)):
13        # 奇数长度
14        l1, r1 = expand(i, i)
15        # 偶数长度
16        l2, r2 = expand(i, i + 1)
17
18        if r1 - l1 > end - start:
19            start, end = l1, r1
20        if r2 - l2 > end - start:

```



```

21         start, end = l2, r2
22     return s[start : end + 1]

```

2. 动态规划法

DP 方法适合用来理解状态转移，但在空间上不如中心扩散法优秀。

核心思想：

定义一个二维布尔数组，表示字符串从索引到的子串是否为回文。状态转移方程如下：

$$dp[i][j] = (s[i] == s[j]) \wedge (j - i < 2 \vee dp[i + 1][j - 1])$$

即：如果两端字符相等，且去掉两端后的内部子串也是回文（或者内部子串长度小于 2），则整体是回文。

时间复杂度： $O(n^2)$ 。空间复杂度： $O(n^2)$ 。需要存储二维 DP 表。

3. Manacher 算法

这是该问题的最优解，专门用于解决最长回文子串问题。

核心思想：

利用回文串的对称性，避免重复计算。例如，在 "ababa" 中，当我们知道了中间的 "aba" 是回文，且整个串也是回文时，左边的性质可以“映射”到右边，从而跳过不必要的比较。

关键步骤：(1) 预处理：为了统一奇偶长度的处理，在字符之间插入特殊符号（如 “#”）。‘aba’ → ‘aba#abba’ → ‘abba#’ 这样所有回文串都会变成奇数长度。(2) 维护半径数组 P ： $P[i]$ 表示以 i 为中心的最长回文半径。引入两个变量： C （当前已知的最右回文串的中心）和 R （该回文串的右边界）。(3) 状态转移：当我们在计算 $P[i]$ 时，如果 $i < R$ ，我们可以利用对称点 i' （ i 关于 C 的对称点）的信息：

$$P[i] = \min(P[2C - i], R - i)$$

这一步极大地加速了计算。之后再尝试利用中心扩散法向外扩展，并更新 C 和 R 。

时间复杂度： $O(n)$ 。虽然代码里有循环，但由于 R 只增不减，每个字符只会被访问有限次。空间复杂度： $O(n)$ 。用于存储预处理字符串和半径数组。

```

1 def longestPalindrome_manacher(s: str) -> str:
2     # 1. 预处理字符串
3     t = '#'.join('~{}'.format(s))
4     n = len(t)
5     P = [0] * n
6     C = 0 # 当前回文中心
7     R = 0 # 当前回文右边界
8
9     for i in range(1, n - 1):
10        # 如果 i 在边界 R 内，利用对称性初始化 P[i]
11        if R > i:
12            P[i] = min(R - i, P[2 * C - i])
13
14        # 尝试中心扩散
15        while t[i + 1 + P[i]] == t[i - 1 - P[i]]:
16            P[i] += 1
17
18        # 更新中心和右边界
19        if i + P[i] > R:
20            C = i

```

```
21         R = i + P[i]
22
23 #提取结果max_len = 0
24 center_index = 0
25 for i in range(n):
26     if P[i] > max_len:
27         max_len = P[i]
28         center_index = i
29
30 start = (center_index - max_len) // 2
31 return s[start : start + max_len]
```

清华大学-432 统计学

清华大学-432 统计学-2016 年

一、(30 分) 设 $X_1, X_2, \dots, X_n$ 是来自均匀分布总体 $U(0, \theta)$ 的简单随机样本, 其中 $\theta > 0$ 是未知参数. 定义

$$U_n = \max \{X_1, X_2, \dots, X_n\}, V_n = \min \{X_1, X_2, \dots, X_n\}.$$

(1)(10 分) 求 θ 的最大似然估计;

(2)(10 分) 判断 U_n 和 V_n 是否分别是 θ 的无偏估计, 并说明理由;

(3)(10 分) 试构造 θ 的相合估计, 并说明理由.

Solution:

(1) 总体的密度函数是 $f(x | \theta) = \frac{1}{\theta} I_{[0, \theta]}$, 其中 $I_{[0, \theta]} = \begin{cases} 0, & x \notin [0, \theta] \\ 1, & x \in [0, \theta] \end{cases}$ 是示性函数. 所以似然函数

$L(\mathbf{X} | \theta) = \frac{1}{\theta^n} I_{\{U_n \leq \theta\}} I_{\{V_n \geq 0\}}$, 可以看出它是关于 θ 的单调减函数, 同时从示性函数中看出 $\theta \geq U_n$, 故当 $\theta = U_n$ 时, 似然函数取到最大值. 因此 $\hat{\theta}_{MLE} = U_n$.

(2) $X_i \sim U(0, \theta)$, 易知 $Y_i = \frac{X_i}{\theta} \sim U(0, 1)$. 则

$$U_n = \theta \cdot \max \{Y_1, Y_2, \dots, Y_n\}, V_n = \theta \cdot \min \{Y_1, Y_2, \dots, Y_n\}.$$

而我们知道 $\max \{Y_1, Y_2, \dots, Y_n\} \sim \text{Beta}(n, 1)$, $\min \{Y_1, Y_2, \dots, Y_n\} \sim \text{Beta}(1, n)$. 根据 Beta 分布的性质, 有 $EU_n = \frac{n}{n+1}\theta$, $EV_n = \frac{1}{n+1}\theta$. 也就是说它们都不是 θ 的无偏估计 (但 U_n 是渐近无偏的, 因为 $EU_n \rightarrow \theta$).

(3) 根据 Beta 分布的性质, $\text{Var}(U_n) = \theta^2 \text{Var}(\text{Beta}(n, 1)) = \frac{n}{(n+1)^2(n+2)}\theta^2$, 而

$$\begin{aligned} P\{|U_n - \theta| > \varepsilon\} &= P\left\{\left|U_n - \frac{n}{n+1}\theta + \frac{n}{n+1}\theta - \theta\right| > \varepsilon\right\} \\ &\leq P\left\{\left|U_n - \frac{n}{n+1}\theta\right| > \frac{\varepsilon}{2}\right\} + P\left\{\left|\frac{n}{n+1}\theta - \theta\right| > \frac{\varepsilon}{2}\right\} \end{aligned}$$

根据切比雪夫不等式, $P\left\{\left|U_n - \frac{n}{n+1}\theta\right| > \frac{\varepsilon}{2}\right\} \leq \frac{4\text{Var}(U_n)}{\varepsilon^2} = \frac{4\theta^2}{\varepsilon^2} \frac{n}{(n+1)^2(n+2)}$. 同时当 $n \geq \frac{2\theta}{\varepsilon} - 1$ 时, $P\left\{\left|\frac{n}{n+1}\theta - \theta\right| > \frac{\varepsilon}{2}\right\} = 0$. 目此有

$$\begin{aligned} \sum_{i=1}^{\infty} P\{|U_n - \theta| > \varepsilon\} &= A + \sum_{\left[\frac{\theta}{\varepsilon}\right]}^{\infty} P\{|U_n - \theta| > \varepsilon\} \left(\text{其中 } A = \sum_{i=1}^{\left[\frac{2\theta}{\varepsilon}-1\right]} P\{|U_n - \theta| > \varepsilon\} \right) \\ &\leq A + \sum_{\left[\frac{2\theta}{\varepsilon}\right]}^{\infty} \frac{4\theta^2}{\varepsilon^2} \frac{n}{(n+1)^2(n+2)} < +\infty \end{aligned}$$

由 Borel-Cantelli 引理, U_n 是 θ 的强相合估计.

二、(20 分) 设 $\lambda_n = \frac{1}{n} (n=1, 2, \dots)$, 随机变量 $X_n \sim \mathcal{P}(\lambda_n)$.

(1)(10 分) 证明: X_n 依概率收敛于 0;

(2)(10 分) nX_n 是否依概率收敛于 0, 并说明理由.

Solution:

(1) $P\{|X_n - 0| \geq \varepsilon\} \leq P\{X_n \neq 0\} = 1 - P\{X_n = 0\}$. 而

$$P\{X_n = 0\} = \frac{\lambda_n^0}{0!} e^{-\lambda_n} = e^{-\frac{1}{n}} \rightarrow 1$$

因此 $P\{|X_n - 0| \geq \varepsilon\} \leq 1 - P\{X_n = 0\} \rightarrow 0$. 故 X_n 依概率收敛于 0.

(2) $P\{|nX_n - 0| \geq \varepsilon\} = P\{X_n \geq \frac{\varepsilon}{n}\} \leq P\{X_n \neq 0\} = 1 - P\{X_n = 0\}$. 同理可知 nX_n 依概率收敛于 0.

三、(30 分) 设样本 $Y_1, Y_2, \dots, Y_n$ 独立, $Y_i \sim N(kx_i, \sigma^2)$, $i = 1, 2, \dots, n$, 其中 $x_1, x_2, \dots, x_n$ 是已知非零常数. k 和 σ^2 是未知参数.

(1)(15 分) 求 k 和 σ^2 的最大似然估计;

(2)(15 分) 判断上面得到的估计是否为无偏估计.

Solution:

(1) 似然函数 $L(k, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - kx_i)^2\right\}$ 对数似然函数 $\ln L(k, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - kx_i)^2$

$$\text{令} \begin{cases} \frac{\partial \ln L}{\partial k} = \frac{\sum_{i=1}^n (y_i - kx_i)x_i}{\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (y_i - kx_i)^2}{2\sigma^4} = 0 \end{cases}, \text{可解得} \begin{cases} \hat{k} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{k}x_i)^2 \end{cases}$$

容易验证驻点即为最大值点, 即为 MLE.

(2) $E\hat{k} = E\left(\frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}\right) = \frac{\sum_{i=1}^n x_i E y_i}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n kx_i^2}{\sum_{i=1}^n x_i^2} = k$. 顺便探讨其方差, 有

$$\text{Var}(\hat{k}) = \text{Var}\left(\frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}\right) = \frac{\sum_{i=1}^n x_i^2 \text{Var}(y_i)}{\left(\sum_{i=1}^n x_i^2\right)^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}.$$

再研究 $\hat{\sigma}^2$, 有

$$\begin{aligned} E(n\hat{\sigma}^2) &= \sum_{i=1}^n E(y_i - \hat{k}x_i)^2 = \sum_{i=1}^n E(y_i - kx_i + kx_i - \hat{k}x_i)^2 \\ &= \sum_{i=1}^n E\left[(y_i - kx_i)^2 - 2(y_i - kx_i)(\hat{k}x_i - kx_i) + (\hat{k}x_i - kx_i)^2\right] \\ &= \sum_{i=1}^n E(y_i - kx_i)^2 - 2 \sum_{i=1}^n \text{Cov}(y_i, \hat{k}x_i) + \sum_{i=1}^n E(\hat{k}x_i - kx_i)^2 \\ &= n\sigma^2 - 2 \sum_{i=1}^n x_i \frac{x_i \sigma^2}{\sum_{j=1}^n x_j^2} + \sum_{i=1}^n x_i^2 \text{Var}(\hat{k}) = (n-1)\sigma^2. \end{aligned}$$

即 $\hat{k}$ 是 k 的无偏估计, $\hat{\sigma}^2$ 不是 σ^2 的无偏估计.

四、(20 分) 设离散随机变量 X_n 的分布律为:

$$P(X_n = 0) = 1 - \frac{1}{n}, P(X_n = n) = \frac{1}{n}, n = 1, 2, 3, \dots$$

判断:

(1)(10 分) X_n 的分布函数是否收敛;

(2)(10 分) X_n 是否矩收敛.

[注]: p 阶矩收敛 (L^p 收敛) 的含义是: 假设有 X_n 的一个极限随机变量 X , 如果

$$E|X_n - X|^p \rightarrow 0, \quad n \rightarrow \infty,$$

那么我们说 $X_n \rightarrow_{L^p} X$, 即 L^p 收敛. 一般只讨论 p 为正整数.

Solution:

$$(1) x_n \text{ 的分布函数是 } F_n(x) = \begin{cases} 0, & x < 0 \\ 1 - \frac{1}{n}, & 0 \leq x < n. \\ 1, & x \geq n \end{cases} F(x) = \lim_{n \rightarrow \infty} F_n(x) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases}, \text{ 故 } F_n(x) \xrightarrow{n \rightarrow \infty} F(x).$$

$F(x)$.

(2) 根据第一题, 我们发现了 X_n 存在一个极限 $X = 0$, 因此对任意 $k \in N^+$, 有

$$E|X_n - 0|^k = 0^k \cdot \left(1 - \frac{1}{n}\right) + n^k \cdot \frac{1}{n} = n^{k-1} \rightarrow \begin{cases} 1, & k = 1 \\ \infty, & k > 1 \end{cases}$$

因此 X_n 矩收敛不成立.

五、(30 分) 设总体 X 密度函数为 $f(x) = ax^{a-1}I[0 \leq x \leq 1]$, 其中 a 是未知参数, 参数空间为 $A = \{a \mid a = 1, a = 2\}$, 现有统计假设

$$H_0: a = 1 \quad \text{vs} \quad H_1: a = 2$$

从总体 X 抽取简单随机样本 x_1 和 x_2 , 并构造检验的拒绝域为

$$W = \left\{ (x_1, x_2) \mid x_1 x_2 > \frac{1}{2} \right\},$$

试计算:

(1)(15 分) 犯第一类错误的概率;

(2)(15 分) 检验法的功效.

Solution:

(1) 犯第一类错误的概率

$$\begin{aligned} \alpha &= P\left\{x_1 x_2 > \frac{1}{2} \mid a = 1\right\} = \iint_{x_1 x_2 > \frac{1}{2}} f(x_1 \mid a = 1) f(x_2 \mid a = 1) dx_1 dx_2 \\ &= \iint_{x_1 x_2 > \frac{1}{2}} I_{\{0 \leq x_1, x_2 \leq 1\}} dx_1 dx_2 = \int_{\frac{1}{2}}^1 dx_2 \int_{\frac{1}{2x_2}}^1 dx_1 = \int_{\frac{1}{2}}^1 \left(1 - \frac{1}{2x_2}\right) dx_2 = \frac{1}{2} - \frac{1}{2} \ln 2 \end{aligned}$$

(2) 功效函数 $g(k) = P\{(x_1, x_2) \in W \mid a = k\}$. 则 $g(1) = \alpha = \frac{1}{2} - \frac{1}{2} \ln 2$.

$$g(2) = \iint_{x_1 x_2 > \frac{1}{2}} 4x_1 x_2 I_{\{0 \leq x_1, x_2 \leq 1\}} dx_1 dx_2 = 4 \int_{\frac{1}{2}}^1 x_2 dx_2 \int_{\frac{1}{2x_2}}^1 x_1 dx_1 = 2 \int_{\frac{1}{2}}^1 x_2 \left(1 - \frac{1}{4x_2^2}\right) dx_2 = \frac{3}{4} - \frac{1}{2} \ln 2$$

六、(20 分) 现有来自于某一连续总体的样本观测值如下:

0.904	-0.205	0.125	-0.247	0.712
1.634	-1.107	-2.668	-0.224	1.481
-0.914	-0.035	-0.457	0.261	1.09
-0.459	-1.649	0.426	-0.601	0.416
0.908				

(1)(10 分) 分别计算如下统计量的值: 样本均值, 样本标准差, 样本极差, 样本偏度和峰度;

(2)(10 分) 画出这组样本观测值的箱线图和直方图.

Solution:

(1)

最大值	最小值	极差	均值	标准差	偏度	峰度
1.634	-2.668	4.302	-0.029	1.036	-0.659	0.827

(2)

[注] 由于已不再让带计算器, 此类题目不可能再考. 但最好掌握偏度、峰度的定义与计算公式.

清华大学-432 统计学-2017 年

一、(20 分) 证明函数 $f(x, y) = Ae^{-(ax^2+2bxy+cy^2)}$ 是密度函数的充要条件是:

$$a > 0, c > 0, b^2 < ac \text{ 且 } A = \frac{\sqrt{ac-b^2}}{\pi}.$$

Solution: (必要性) 由于 $f(x, y)$ 是密度函数, 因此 $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$, 而

$$f(x, y) = A \exp \left\{ - \left[a \left(x^2 + \frac{2b}{a} xy \right) + cy^2 \right] \right\} = A \exp \left\{ - \left[a \left(x + \frac{b}{a} y \right)^2 + \left(c - \frac{b^2}{a} \right) y^2 \right] \right\},$$

要想积分收敛, 看出 $a > 0, b^2 - ac < 0$, 同理若对 y 配方由对称性也有 $c > 0$. 在此情形下, 有

$$\begin{aligned} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy &= A \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-a(x+\frac{b}{a}y)^2 - (c-\frac{b^2}{a})y^2} dx dy \\ &= A \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-au^2 - (c-\frac{b^2}{a})y^2} du dy \\ &= A \cdot \frac{\pi}{\sqrt{ac-b^2}}, \end{aligned}$$

由此得 $A = \frac{\sqrt{ac-b^2}}{\pi}$.

(充分性) 此时显然 $f(x, y)$ 非负, 且根据上述计算, 有积分

$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1,$$

故正则性也成立, 即 $f(x, y)$ 是密度函数.

二、(40 分) 已知简单随机样本 $x_1, x_2, \dots, x_n$ i.i.d. $\sim U(0, \theta)$.

(1)(10 分) 证明 $x_{(n)}$ 是充分完备统计量;

(2)(10 分) 证明存在随机变量 X 使得 $n(\theta - x_{(n)}) \xrightarrow{d} X$, 并求 X 的分布;

(3)(10 分) 证明 $x_{(n)}$ 是 θ 的最大似然估计;

(4)(10 分) $x_{(n)}$ 是否为 θ 的无偏估计? 是否为 θ 的弱相合估计? 并说明理由.

Solution:

$f(\mathbf{X} | \theta) = \frac{1}{\theta^n} I_{\{x_{(1)} \geq 0\}} I_{\{x_{(n)} \leq \theta\}}$, 根据因子分解定理, $x_{(n)}$ 是充分统计量. 下证 $x_{(n)}$ 的完备性. 由均匀分布次序统计量的分布, 我们知道 $T = \frac{x_{(n)}}{\theta} \sim Be(n, 1)$. 设有一 Borel 可测函数 $u(\cdot)$, 满足 $E \left[u \left(\frac{x_{(n)}}{\theta} \right) \right] = 0 (\forall \theta > 0)$, 也就是 $E[u(\theta T)] = 0 (\forall \theta > 0)$ 即 $\int_0^1 u(\theta t) n t^{n-1} dt \stackrel{(x=\theta t)}{=} \int_0^\theta u(x) n \left(\frac{x}{\theta} \right)^{n-1} d \left(\frac{x}{\theta} \right) = \frac{n}{\theta^n} \int_0^\theta u(x) x^{n-1} dx = 0$, 因此 $\int_0^\theta u(x) x^{n-1} dx = 0$ 对 $\forall \theta > 0$ 成立, 等式左右对 θ 求导, 得 $u(\theta) \theta^{n-1} = 0 (\forall \theta > 0)$, 故 $u(\theta) \equiv 0 (\forall \theta > 0)$, 而 $x_{(n)} = \theta T \in (0, \theta)$, 故 $P \left\{ u \left(\frac{x_{(n)}}{\theta} \right) = 0 \right\} = 1$. 因此 $x_{(n)}$ 是充分完备统计量.

(2) 记 $Y_n = n(\theta - x_{(n)}) = n(\theta - \theta T) = n\theta(1 - T)$. 而 $T \sim Be(n, 1)$, 其密度函数是:

$$f_T(t) = n t^{n-1} I_{\{0 < t < 1\}},$$

现求 Y_n 的分布, 利用微分法

$$\begin{aligned} P \{Y_n = y\} &= P \{n\theta(1 - T) = y\} = P \left\{ T = 1 - \frac{y}{n\theta} \right\}, \left(\text{其中 } 1 - \frac{y}{n\theta} \in (0, 1) \right) \\ &= f_T \left(1 - \frac{y}{n\theta} \right) \left| d \left(1 - \frac{y}{n\theta} \right) \right|, (0 < y < n\theta) \\ &= n \left(1 - \frac{y}{n\theta} \right)^{n-1} \frac{1}{n\theta} dy, (0 < y < n\theta) \end{aligned}$$

因此 $f_{Y_n}(y) = \begin{cases} \frac{1}{\theta} (1 - \frac{y}{n\theta})^{n-1}, & 0 < y < n\theta \\ 0, & \text{others} \end{cases}$ 所以 Y_n 的分布函数是 $F_{Y_n}(y) = \begin{cases} 0, & y < 0 \\ 1 - (1 - \frac{y}{n\theta})^n, & 0 \leq y < n\theta \\ 1, & y \geq n\theta \end{cases}$

而 $\lim_{n \rightarrow \infty} F_{Y_n}(y) = \begin{cases} 0, & y < 0 \\ 1 - e^{-\frac{y}{\theta}}, & y \geq 0 \end{cases}$, 这是参数为 $\frac{1}{\theta}$ 的指数分布的分布函数. 也就是说 $Y_n \xrightarrow{d} X$, 其中 $X \sim \text{Exp}(\frac{1}{\theta})$.

(3) 总体的密度函数是 $f(x | \theta) = \frac{1}{\theta} I_{[0, \theta]}$, 所以似然函数 $L(\mathbf{X} | \theta) = \frac{1}{\theta^n} I_{\{x_{(n)} \geq 0\}} I_{\{x_{(n)} \leq \theta\}}$, 可以看出它是关于 θ 的单调减函数, 同时从示性函数中看出 $\theta \geq x_{(n)}$, 故当 $\theta = U_n$ 时, 似然函数取到最大值. 因此 $\hat{\theta}_{MLE} = x_{(n)}$.

(4) $E x_{(n)} = E[\theta T] = \theta ET = \frac{n-1}{n}\theta$, 因此 $x_{(n)}$ 不是 θ 的无偏估计. 根据 Beta 分布的数字特征, $\text{Var}(x_{(n)}) = \theta^2 \text{Var}(\text{Beta}(n, 1)) = \frac{n}{(n+1)^2(n+2)}\theta^2$

$$\begin{aligned} P\left\{|x_{(n)} - \theta| > \varepsilon\right\} &= P\left\{\left|x_{(n)} - \frac{n}{n+1}\theta + \frac{n}{n+1}\theta - \theta\right| > \varepsilon\right\} \\ &\leq P\left\{\left|X_n - \frac{n}{n+1}\theta\right| > \frac{\varepsilon}{2}\right\} + P\left\{\left|\frac{n}{n+1}\theta - \theta\right| > \frac{\varepsilon}{2}\right\} \end{aligned}$$

根据切比雪夫不等式,

$$P\left\{\left|x_{(n)} - \frac{n}{n+1}\theta\right| > \frac{\varepsilon}{2}\right\} < \frac{4 \text{Var}(x_{(n)})}{\varepsilon^2} = \frac{4\theta^2}{\varepsilon^2} \frac{n}{(n+1)^2(n+2)} \xrightarrow{n \rightarrow \infty} 0.$$

同时当 $n \geq \frac{2\theta}{\varepsilon} - 1$ 时, $P\left\{\left|\frac{n}{n+1}\theta - \theta\right| > \frac{\varepsilon}{2}\right\} = 0$. 因此 $P\left\{|x_{(n)} - \theta| > \varepsilon\right\} \xrightarrow{n \rightarrow \infty} 0$, 即 $x_{(n)}$ 是 θ 的弱相合估计.

三、(40 分) 已知简单随机样本 $x_1, x_2, \dots, x_n \text{ iid} \sim b(1, p)$, $0 < p < 1$. 参数 p 的先验分布为贝塔分布 $Be(\alpha, \beta)$, 则

(1)(5 分) 求 p 的最大似然估计 $\hat{p}_L$;

(2)(10 分) 求 p 的贝叶斯估计 $\hat{p}_B$;

(3)(10 分) 求 $\hat{p}_L$ 与 $\hat{p}_B$ 的均方误差 $\text{MSE}(\hat{p}_L)$ 与 $\text{MSE}(\hat{p}_B)$;

(4)(10 分) 试确定 α 与 β 的值使得 $\text{MSE}(\hat{p}_B)$ 与 p 无关;

(5)(5 分) 在 (4) 的基础上求出 $\text{MSE}(\hat{p}_B)$ 并比较 $\text{MSE}(\hat{p}_L)$ 与 $\text{MSE}(\hat{p}_B)$ 的大小.

Solution:

(1) 似然函数 $L(\mathbf{X} | p) = p^{n\bar{x}}(1-p)^{n-n\bar{x}}$, 令 $\frac{\partial \ln L}{\partial p} = \frac{n\bar{x}}{p} - \frac{n-n\bar{x}}{1-p} = 0$, 可以解得 $\hat{p}_L = \bar{x}$, 由于总体服从指数族分布, 因此无需二阶导, 其对数似然函数的驻点必定是极大似然估计.

(2) 参数 p 的先验分布是 $H(p) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1}(1-p)^{\beta-1} I_{\{0 < p < 1\}}$. 则样本与参数的联合分布是: $f(\mathbf{X}, p) = L(\mathbf{X})H(p) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{n\bar{x}+\alpha-1}(1-p)^{n-n\bar{x}+\beta-1} I_{\{0 < p < 1\}}$. 样本的边缘分布是:

$$\begin{aligned} m(\mathbf{X}) &= \int_0^1 f(\mathbf{X}, p) dp = \int_0^1 \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{n\bar{x}+\alpha-1}(1-p)^{n-n\bar{x}+\beta-1} dp \\ &= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \mathbf{B}(n\bar{x}+\alpha, n-n\bar{x}+\beta), \text{ (here } \mathbf{B} \text{ represents beta function)} \\ &= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(n\bar{x}+\alpha)\Gamma(n-n\bar{x}+\beta)}{\Gamma(n+\alpha+\beta)} \end{aligned}$$

故参数 p 的后验分布是 $H(p | \mathbf{X}) = \frac{f(\mathbf{X}, p)}{m(\mathbf{X})} = \frac{\Gamma(n\bar{x}+\alpha)\Gamma(n-n\bar{x}+\beta)}{\Gamma(n+\alpha+\beta)} p^{n\bar{x}+\alpha-1}(1-p)^{n-n\bar{x}+\beta-1} I_{\{0 < p < 1\}}$ 也就是说参数的后验分布是 $Be(n\bar{x}+\alpha, n-n\bar{x}+\beta)$, 其后验期望估计是: $\hat{p}_B = E(p | \mathbf{X}) = \frac{n\bar{x}+\alpha}{n+\alpha+\beta}$, 也就是 p 的贝叶斯估计.

(3) $E(\hat{p}_L) = E\bar{x} = p$, 因此 $\hat{p}_L$ 是无偏估计, 它的均方误差即它的方差.

$$MSE(\hat{p}_L) = \text{Var}(\bar{x}) = \frac{p(1-p)}{n}$$

$$\begin{aligned} MSE(\hat{p}_B) &= \text{Var}(\hat{p}_B) + (E\hat{p}_B - p)^2 \\ &= \left(\frac{n}{n+\alpha+\beta}\right)^2 \frac{p(1-p)}{n} + \left[\frac{np+\alpha-(n+\alpha+\beta)p}{n+\alpha+\beta}\right]^2 \\ &= \frac{np(1-p)}{(n+\alpha+\beta)^2} + \frac{[\alpha(1-p)-\beta p]^2}{(n+\alpha+\beta)^2} \\ &= \frac{np-np^2+\alpha^2-2\alpha(\alpha+\beta)p+(\alpha+\beta)^2p^2}{(n+\alpha+\beta)^2} \\ &= \frac{[(\alpha+\beta)^2-n]p^2+[n-2\alpha(\alpha+\beta)]p+\alpha^2}{(n+\alpha+\beta)^2} \end{aligned}$$

(4) $MSE(\hat{p}_B) = \frac{[(\alpha+\beta)^2-n]p^2+[n-2\alpha(\alpha+\beta)]p+\alpha^2}{(n+\alpha+\beta)^2}$ 是一个关于 p 的二次多项式. 若要求它与 p 无关, 则

$$\begin{cases} (\alpha+\beta)^2-n=0 \\ n-2\alpha(\alpha+\beta)=0 \end{cases}, \text{ 解得 } \alpha=\beta=\frac{\sqrt{n}}{2}.$$

(5) 当 $\alpha=\beta=\frac{\sqrt{n}}{2}$ 时,

$$\begin{aligned} MSE(\hat{p}_B) &= \frac{[(\alpha+\beta)^2-n]p^2+[n-2\alpha(\alpha+\beta)]p+\alpha^2}{(n+\alpha+\beta)^2} \\ &= \frac{1}{4} \frac{n}{(n+\sqrt{n})^2} = \frac{1}{4} \frac{1}{n+2\sqrt{n}+1} \end{aligned}$$

而 $MSE(\hat{p}_L) = \text{Var}(\bar{x}) = \frac{p(1-p)}{n}$. $\lim_{n \rightarrow \infty} \frac{MSE(\hat{p}_L)}{MSE(\hat{p}_B)} = \lim_{n \rightarrow \infty} \frac{\frac{p(1-p)}{n}}{\frac{1}{4} \frac{1}{n+2\sqrt{n}+1}} = 4p(1-p) \leq 4 \cdot \frac{1}{4} = 1$ (此处等号当且仅当 $p = \frac{1}{2}$ 时取到) 因此可以判断, 当 n 较大时, $MSE(\hat{p}_L)$ 要比 $MSE(\hat{p}_B)$ 小.

四、(20 分) 已知总体 $X \sim N(\mu, \sigma^2)$, 其中参数 μ 与 σ^2 未知, $x_1, x_2, \dots, x_n$ 是在其中抽取的样本, 试确定 a 与 b 的关系, 使得 σ^2 的 $1-\alpha$ 置信区间 $\left[\frac{nS^2}{a}, \frac{nS^2}{b}\right]$ 最短, 其中

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Solution: $T = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 为枢轴量. 如果 $d-c=1-\alpha, 0 \leq c < d \leq 1$, 则 $P\{\chi_c^2(n-1) < T < \chi_d^2(n-1)\} = 1-\alpha$. 则

$$P\left\{\chi_c^2(n-1) < \frac{1}{\sigma^2} \frac{n-1}{n} nS^2 < \chi_d^2(n-1)\right\} = 1-\alpha,$$

可得 σ^2 的 $1-\alpha$ 置信区间: $\left[\frac{n-1}{n} \frac{nS^2}{\chi_d^2(n-1)}, \frac{n-1}{n} \frac{nS^2}{\chi_c^2(n-1)}\right]$. 可知

$$a = \frac{n}{n-1} \chi_d^2(n-1), b = \frac{n}{n-1} \chi_c^2(n-1).$$

根据题意, 也就是求 $\frac{1}{b} - \frac{1}{a}$ 在 $\int_{\frac{n-1}{n}b}^{\frac{n-1}{n}a} f_{\chi^2(n-1)}(x)dx = 1-\alpha$ 下的条件极小值, 其中 $f_{\chi^2(n-1)}(x)dx$ 是 $\chi^2(n-1)$ 的密度函数. 利用拉格朗日乘数法, 令

$$L(a, b, \lambda) = \frac{1}{b} - \frac{1}{a} + \lambda \left(\int_{\frac{n-1}{n}b}^{\frac{n-1}{n}a} f_{\chi^2(n-1)}(x)dx - 1 + \alpha \right),$$

$$\text{令 } \begin{cases} \frac{\partial L}{\partial a} = \frac{1}{a^2} + \lambda \frac{n-1}{n} f_{\chi^2(n-1)}\left(\frac{n-1}{n}a\right) = 0 \\ \frac{\partial L}{\partial b} = -\frac{1}{b^2} - \lambda \frac{n-1}{n} f_{\chi^2(n-1)}\left(\frac{n-1}{n}b\right) = 0 \\ \frac{\partial L}{\partial \lambda} = \int_{\frac{n-1}{n}b}^{\frac{n-1}{n}a} f_{\chi^2(n-1)}(x)dx - 1 + \alpha = 0 \end{cases}$$

对第一个式子进行变形, 有

$$\begin{aligned}
 (1) \Rightarrow & \frac{1}{a^2} + \lambda \frac{n-1}{n} \frac{\left(\frac{1}{2}\right)^{\frac{n-1}{2}}}{\Gamma\left(\frac{n-1}{2}\right)} \left(\frac{n-1}{n}a\right)^{\frac{n-3}{2}} e^{-\frac{1}{2}\frac{n-1}{n}a} = 0 \\
 & 1 + \lambda \frac{n-1}{n} a^2 \frac{\left(\frac{1}{2}\right)^{\frac{n-1}{2}}}{\Gamma\left(\frac{n-1}{2}\right)} \left(\frac{n-1}{n}a\right)^{\frac{n-3}{2}} e^{-\frac{1}{2}\frac{n-1}{n}a} = 0 \\
 & \lambda \frac{n}{n-1} \left(\frac{n-1}{n}a\right)^2 \left(\frac{n+1}{2}\right) \left(\frac{n-1}{2}\right) \frac{2^2 \left(\frac{1}{2}\right)^2 \left(\frac{1}{2}\right)^{\frac{n-1}{2}}}{\left(\frac{n+1}{2}\right) \left(\frac{n-1}{2}\right) \Gamma\left(\frac{n-1}{2}\right)} \left(\frac{n-1}{n}a\right)^{\frac{n-3}{2}} e^{-\frac{1}{2}\frac{n-1}{n}a} = -1 \\
 & (n^2 + n) \lambda \frac{\left(\frac{1}{2}\right)^{\frac{n+3}{2}}}{\Gamma\left(\frac{n+3}{2}\right)} \left(\frac{n-1}{n}a\right)^{\frac{n+1}{2}} e^{-\frac{1}{2}\frac{n-1}{n}a} = -1 \\
 & f_{\chi^2(n+3)}\left(\frac{n-1}{n}a\right) = -\frac{1}{(n^2+n)\lambda}
 \end{aligned}$$

同理, (2) $\Rightarrow f_{\chi^2(n+3)}\left(\frac{n-1}{n}b\right) = -\frac{1}{(n^2+n)\lambda}$. 因此有 $f_{\chi^2(n+3)}\left(\frac{n-1}{n}a\right) = f_{\chi^2(n+3)}\left(\frac{n-1}{n}b\right)$. 综上所述, a 与 b 需要满足下述关系:

$$\begin{cases} f_{\chi^2(n+3)}\left(\frac{n-1}{n}a\right) = f_{\chi^2(n+3)}\left(\frac{n-1}{n}b\right) \\ \int_{\frac{n-1}{n}b}^{\frac{n-1}{n}a} f_{\chi^2(n-1)}(x)dx = 1 - \alpha \end{cases}$$

五、(30 分) 通过实验观察得出 n 个样本点 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$. 假设 X 与 Y 之间存在线性关系, 并有统计模型 $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i; i = 1, 2, \dots, n$, 其中 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ i.i.d. $\sim N(0, \sigma^2)$. $\beta_0, \beta_1, \sigma^2$ 为参数, X_i 为一般变量, $i = 1, 2, \dots, n$. 则:

(1)(10 分) 求 $\beta_0, \beta_1, \sigma^2$ 的最大似然估计 $\hat{\beta}_0, \hat{\beta}_1, \hat{\sigma}^2$;

(2)(10 分) 上述 $\hat{\sigma}^2$ 是否为 σ^2 的无偏估计? 若是, 请说明理由; 若不是, 试构造 σ^2 的无偏估计;

(3)(10 分) 对线性回归方程的显著性作出假设 $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$, 给出你的检验标准.

Solution:

(1) 由题意可知, $Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, 似然函数

$$L(\mathbf{Y}; \beta_0, \beta_1, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2} \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{\sigma^2}\right\}.$$

对数似然函数 $\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}$. 令
$$\begin{cases} \frac{\partial \ln L}{\partial \beta_0} = \frac{2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)}{2\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \beta_1} = \frac{2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i)}{2\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^4} = 0 \end{cases}, \text{解得}$$

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \frac{l_{xy}}{l_{xx}} \\ \hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} \\ \hat{\sigma}^2 = \frac{\sum_{i=1}^n \left[y_i - \left(\bar{y} - \bar{x} \frac{l_{xy}}{l_{xx}} \right) - \frac{l_{xy}}{l_{xx}} x_i \right]^2}{n} \end{cases} \text{其中} \begin{cases} l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\ l_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \\ l_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \end{cases}$$

(2) 在讨论 $\hat{\sigma}^2$ 之前, 我们需要先去回忆一下 $\hat{\beta}_0, \hat{\beta}_1$ 的分布: 它们是二维正态,

$$\begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} \sim N \left(\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \begin{pmatrix} \left(\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} \right) \sigma^2 & -\frac{\bar{x} \sigma^2}{l_{xx}} \\ -\frac{\bar{x} \sigma^2}{l_{xx}} & \frac{\sigma^2}{l_{xx}} \end{pmatrix} \right),$$

因此有 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \sim N\left(\beta_0 + \beta_1 x_i, \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{l_{xx}}\right) \sigma^2\right)$, 且.

$$\text{Cov}(\hat{y}_i, y_i) = \text{Cov}(\hat{\beta}_0 + \hat{\beta}_1 x_i, y_i) = \text{Cov}(\bar{y}, y_i) + (x_i - \bar{x}) \text{Cov}(\hat{\beta}_1, y_i) = \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{l_{xx}}\right) \sigma^2.$$

再去探讨 $\hat{\sigma}^2$, 有

$$\begin{aligned} E(n\hat{\sigma}^2) &= \sum_{i=1}^n E(y_i - \hat{y}_i)^2 = \sum_{i=1}^n E(y_i - Ey_i + Ey_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^n E\left[(y_i - Ey_i)^2 - 2(y_i - Ey_i)(\hat{y}_i - Ey_i) + (\hat{y}_i - Ey_i)^2\right] \end{aligned}$$

其中, $\sum_{i=1}^n E(y_i - Ey_i)^2 = n\sigma^2$, $\sum_{i=1}^n E(\hat{y}_i - Ey_i)^2 = \sum_{i=1}^n \text{Var}(\hat{y}_i) = 2\sigma^2$, 且.

$$\sum_{i=1}^n E[(y_i - Ey_i)(\hat{y}_i - Ey_i)] = \sum_{i=1}^n \text{Cov}(y_i, \hat{y}_i) = 2\sigma^2.$$

综上所述, 有 $E(n\hat{\sigma}^2) = (n-2)\sigma^2$, 因此 $\hat{\sigma}^2$ 不是无偏估计, 但可找到一个修正的无偏估计

$$\tilde{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2.$$

(3) [法一] 一方面, 这是线性模型的显著性检验, 可以对总平方和进行分解,

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 + \sum_{i=1}^n (\bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x})^2,$$

其中残差平方和 $SSE = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$, 回归平方和 $SSR = \sum_{i=1}^n (\bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x})^2$, 当原假设成立, 这些平方和除以 σ^2 后无疑都是服从卡方分布的, 根据我们的理解与分析, 总平方和的自由度是 $n-1$, 残差平方和的期望是 $(n-2)\sigma^2$, 那么回归平方和就无疑对应一个自由度为 1 的卡方分布. 因此, 当原假设成立时, $F = \frac{SSR}{SSE/(n-2)} \sim F(1, n-2)$, 得到拒绝域为

$$W = \{F \geq F_{1-\alpha}(1, n-2)\}.$$

[法二] 另一方面, 这也是一个系数的 t 检验, 由于 $\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{l_{xx}}\right)$, 因此有

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\sigma^2}{l_{xx}}}} \sim N(0, 1),$$

但是方差项 σ^2 是未知的, 我们只能用无偏估计量

$$\tilde{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

去替代. 而 $\frac{(n-2)\tilde{\sigma}^2}{\sigma^2} \sim \chi^2(n-2)$ 且与分子独立, 因此有原假设成立时的检验

$$W = \{|T| \geq t_{1-\frac{\alpha}{2}}(n-2)\}.$$

两种方法的拒绝域是等价的.

清华大学-432 统计学-2018 年

一、(20 分) 设有独立的随机变量序列 $\{X_n\}$, 其中 $P(X_n = 1) = \frac{1}{n}, P(X_n = 0) = 1 - \frac{1}{n}$,

(1)(6 分) 当 $n \rightarrow +\infty$ 时, EX_n 与 DX_n 是否趋于 0, 请说明理由;

(2)(7 分) 当 $n \rightarrow +\infty$ 时, 是否有 $X_n \xrightarrow{P} 0$, 请说明理由;

(3)(7 分) 当 $n \rightarrow +\infty$ 时, 是否有 $X_n \xrightarrow{a.s.} 0$, 请说明理由.

Solution:

(1) $EX_n = \frac{1}{n}, EX_n^2 = \frac{1}{n}, \text{Var}(X_n) = \frac{1}{n} - \frac{1}{n^2} = \frac{n-1}{n^2}$. 因此 $EX_n = \frac{1}{n} \rightarrow 0, \text{Var}(X_n) = \frac{n-1}{n^2} \rightarrow 0$.

(2) 对于 $\forall \varepsilon > 0$, 有 $P(|X_n| > \varepsilon) \leq P(X_n \neq 0) = \frac{1}{n} \rightarrow 0$, 因此 $X_n \xrightarrow{P} 0$.

(3) 此时由于诸 X_i 独立, 且对于 $\forall \varepsilon \in (0, 1), \sum_{i=1}^n P(|X_i| > \varepsilon) = \sum_{i=1}^n \frac{1}{i} \rightarrow \infty$, 所以由独立场合的 Borel-Cantelli 引理, 有 $X_n \not\xrightarrow{a.s.} 0$.

二、(20 分) 设有一批产品 100 件, 其中 4 件次品. 现从中任取 3 件, 若检验出其中有次品, 则认为该批次产品不合格. 检验时, 正品误判成次品的概率是 0.05, 次品误判成正品的概率 0.01. 试求该批产品检验结果合格的概率.

Solution:

用随机变量 X 表示该次抽检中抽到次品的数量, 事件 A 表示检验结果合格. 则 $P(A) = \sum_{k=0}^3 P(A | X = k)P(X = k)$

$$P(X = k) = \frac{C_4^k C_{96}^{3-k}}{C_{100}^3} = \begin{cases} \frac{7144}{8085}, & k = 0 \\ \frac{304}{2695}, & k = 1 \\ \frac{48}{13475}, & k = 2 \\ \frac{1}{40425}, & k = 3 \end{cases}$$

$$P(A | X = k) = (1 - 0.05)^{3-k} (0.01)^k = \begin{cases} 0.857375, & k = 0 \\ 9.025 \times 10^{-3}, & k = 1 \\ 9.5 \times 10^{-5}, & k = 2 \\ 1 \times 10^{-6}, & k = 3 \end{cases}$$

因此 $P(A) = \sum_{k=0}^3 P(A | X = k)P(X = k) \approx 0.7586$. [点评] 在不能带计算器的前提下, 此类题不可能再考察. 但计算方法仍需掌握.

三、(20 分) 某班级成员一星期迟到共计 50 次, 其中星期一 12 次, 星期二 11 次, 星期三 9 次, 星期四 10 次, 星期五 8 次. 问迟到是否与星期几有关?(注: 记 $f_{\chi^2(n)}(x)$ 是卡方分布 $\chi^2(n)$ 的密度函数, 且 $\int_0^{9.48} f_{\chi^2(4)}(x)dx \approx 0.95, \int_0^{11.07} f_{\chi^2(5)}(x)dx \approx 0.95$)

Solution: 利用卡方拟合优度检验, 设 X 是某一次迟到可能发生在星期 k 的概率 ($k = 1, \dots, 5$), 建立假设检验问题: $H_0: P(X = k) = \frac{1}{5} (k = 1, \dots, 5)$ 构造卡方检验统计量 $\chi^2 = \sum_{k=1}^r \frac{(np_k - n_k)^2}{np_k}$, 其中 r 表示随机变量可能的取值个数, 此处 $r = 5, n$ 为样本总数此时 $n = 50, n_k$ 为随机变量 $X = k$ 的观测值总数, p_k 等于原假设中的 $P(X = k)$ 此处 $p_k \equiv \frac{1}{5}$. 而 $W = \{\chi^2 \geq \chi_{1-\alpha}^2(r-1)\}$, 此时

$$W = \{\chi^2 \geq \chi_{0.95}^2(4)\} = \{\chi^2 \geq 9.48\}.$$

算得 $\chi^2 = \sum_{k=1}^r \frac{(np_k - n_k)^2}{np_k} = \frac{4+1+1+0+4}{10} = 1 \notin W$. 所以不能拒绝原假设, 某一次迟到可能发生在星期 k 的概率应该是相同的, 即迟到与星期几无关.

四、(50 分) 随机变量 X 的密度函数为 $f(x|\theta) = \theta(2-2x)(2x-x^2)^{\theta-1}$, 其中 $0 < x < 1, \theta > 0$. 现有简单随机样本 $X_1, X_2, \dots, X_n$.

(1)(10 分) 记 $Y = -\ln(2X - X^2)$, 试求 Y 的密度函数;

(2)(10 分) 求 X 分布的中位数, 以及 EY ;

(3)(10 分) 求 θ 的极大似然估计 $\hat{\theta}_L$;

(4)(10 分) 求 $\hat{\theta}_L$ 的密度函数;

(5)(10 分) 求 θ 的充分统计量.

Solution:

(1) $Y = -\ln(2X - X^2)$, 则 $2X - X^2 = e^{-y}$ 由公式法, 有

$$\begin{aligned} f_Y(y) &= f_X(y) \left| \frac{dx}{dy} \right| = \theta(2-2x)(e^{-y})^{\theta-1} \left| \frac{dy}{dx} \right|^{-1} \\ &= \theta(2-2x)(e^{-y})^{\theta-1} \left(\frac{2-2x}{2x-x^2} \right)^{-1} \\ &= \theta e^{-\theta y} \end{aligned}$$

根据 $Y = -\ln(2X - X^2)$, 可确定 $f_Y(y) = \theta e^{-\theta y} (y > 0)$, 即 $Y \sim \text{Exp}(\theta)$.

(2) 显然 $EY = \frac{1}{\theta}$.

求 X 的分布函数, 对 $\forall x \in (0, 1)$, $F_X(x) = \int_0^x f(t)dt = (2x - x^2)^\theta$ 则令 $F_X(x_{0.5}) = \frac{1}{2}$, 解二次方程可得

$$x_{0.5} = 1 - \sqrt{1 - \left(\frac{1}{2}\right)^{\frac{1}{\theta}}} \left(\text{还有一根为 } 1 + \sqrt{1 - \left(\frac{1}{2}\right)^{\frac{1}{\theta}}} > 1 \text{ 需舍去} \right)$$

(3) 似然函数 $L(\mathbf{X}; \theta) = \theta^n \prod_{i=1}^n (2 - 2x_i) (2x_i - x_i^2)^{\theta-1}$ 对数似然函数 $\ln L = n \ln \theta + \sum_{i=1}^n \ln(2 - 2x_i) + (\theta - 1) \sum_{i=1}^n \ln(2x_i - x_i^2)$

$$\text{令 } \frac{\partial \ln L}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln(2x_i - x_i^2) = 0, \text{ 得 } \hat{\theta}_L = \frac{n}{-\sum_{i=1}^n \ln(2x_i - x_i^2)}$$

由于总体服从单参指数族分布, 所以驻点一定是极大值点,

$$\hat{\theta}_L = \frac{n}{-\sum_{i=1}^n \ln(2x_i - x_i^2)} = \frac{n}{\sum_{i=1}^n y_i}.$$

(4) 由于 $Y_i \text{iid} \sim \text{Exp}(\theta)$, 由伽马分布的可加性可知 $T = \sum_{i=1}^n y_i \sim \text{Ga}(n, \theta)$, 则求 $\hat{\theta}_L = \frac{n}{T}$ 的分布.

$$\begin{aligned} P\left(\hat{\theta}_L = t\right) &= P\left(\frac{n}{T} = t\right) = P\left(T = \frac{n}{t}\right) \quad \left(\frac{n}{t} > 0\right) \\ &= \frac{\theta^n}{\Gamma(n)} \left(\frac{n}{t}\right)^{n-1} e^{-\theta \frac{n}{t}} \left|d\left(\frac{n}{t}\right)\right| \\ &= \frac{\theta^n}{(n-1)!} \left(\frac{n}{t}\right)^{n-1} e^{-\theta \frac{n}{t}} \frac{n}{t^2} dt \\ &= \frac{(n\theta)^n}{(n-1)!} \left(\frac{1}{t}\right)^{n+1} e^{-\frac{n\theta}{t}} dt \quad (t > 0) \end{aligned}$$

因此 $\hat{\theta}_L$ 的密度函数为逆伽马分布 $f(t) = \frac{(n\theta)^n}{(n-1)!} \left(\frac{1}{t}\right)^{n+1} e^{-\frac{n\theta}{t}} \quad (t > 0)$

(5) 似然函数 $L(\mathbf{X}; \theta) = \theta^n \prod_{i=1}^n (2 - 2x_i) (2x_i - x_i^2)^{\theta-1}$, 由因子分解定理可知: $\prod_{i=1}^n (2X_i - X_i^2)$ 是 θ 的充分统计量.

五、(40 分) 有观测数据 $(x_1, Y_1), (x_2, Y_2), \dots, (x_n, Y_n)$. 并有线性回归模型 $Y_i = \beta x_i + \varepsilon_i; i = 1, 2, \dots, n$, x_i 为不为 0 的随机设置点, 不可观测的随机误差变量 $\varepsilon_i \sim N(0, x_i^2 \sigma^2)$. β, σ^2 为未知参数, 则:

(1)(20 分) 求 β 的最小二乘估计 $\hat{\beta}_{LSE}$ 与 β 的极大似然估计 $\hat{\beta}_{MLE}$, 以及 σ^2 的极大似然估计;

(2)(10 分) $\hat{\beta}_{LSE}, \hat{\beta}_{MLE}$ 是否为 β 的无偏估计? 并比较二者的有效性;

(3)(10 分) 利用似然比检验法给出假设检验问题 $H_0: \beta = 1$ vs $H_1: \beta \neq 1$ 的检验拒绝域.

Solution:

(1) β 的最小二乘估计大家已经很熟悉了, $\hat{\beta}_{LSE} = \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}$. 现在我们继续求极大似然估计: 令 $Z_i = \frac{Y_i}{x_i} \sim N(\beta, \sigma^2), i = 1, 2, \dots, n$, 这就是独立同正态分布样本的估计了, 我们很明显知道

$$\hat{\beta}_{MLE} = \bar{Z} = \frac{1}{n} \sum_{i=1}^n \frac{Y_i}{x_i}, \hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (Z_i - \bar{Z})^2 = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i}{x_i} - \frac{1}{n} \sum_{j=1}^n \frac{Y_j}{x_j} \right)^2.$$

(2) 先求期望, $E\hat{\beta}_{LSE} = \frac{\sum_{i=1}^n x_i EY_i}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n \beta x_i^2}{\sum_{i=1}^n x_i^2} \beta$, 因此 $\hat{\beta}_{LSE}$ 是无偏估计, $E\hat{\beta}_{MLE} = E\bar{Z} = \beta$, 因此 $\hat{\beta}_{MLE}$ 也是无偏估计. 再求方差, 有

$$\text{Var}(\hat{\beta}_{LSE}) = \frac{\sum_{i=1}^n x_i^2 \text{Var}(Y_i)}{(\sum_{i=1}^n x_i^2)^2} = \frac{\sum_{i=1}^n x_i^4 \sigma^2}{(\sum_{i=1}^n x_i^2)^2} \geq \frac{1}{n} \sigma^2, \text{ 当且仅当 } x_1 = \dots = x_n \text{ 取等}.$$

(注意运用柯西-施瓦茨不等式 $(\sum_{i=1}^n 1 \cdot a_i)^2 \leq (\sum_{i=1}^n 1^2) (\sum_{i=1}^n a_i^2) = n \sum_{i=1}^n a_i^2$) 而 $\text{Var}(\hat{\beta}_{MLE}) = \text{Var}(\bar{Z}) = \frac{1}{n} \sigma^2$. 因此 $\hat{\beta}_{MLE}$ 是更有效的. 实际上, 由于正态分布总体均值的估计是有效估计, 因此本题只需想方设法证明 LSE 的方差更大即可.

(3) 仍然借助 $Z_i = \frac{Y_i}{x_i} \sim N(\beta, \sigma^2), i = 1, 2, \dots, n$, 似然函数为

$$L(\beta, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (z_i - \beta)^2 \right\},$$

记 $\hat{\beta} = \bar{z}, \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (z_i - \bar{z})^2$, 分别是 β, σ^2 的 MLE. 当不加限制条件时,

$$\sup L(\beta, \sigma^2) = (2\pi\hat{\sigma}^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (z_i - \hat{\beta})^2 \right\} = (2\pi\hat{\sigma}^2)^{-\frac{n}{2}} \exp \left\{ -\frac{n}{2} \right\},$$

当限制 $\beta = 1$ 时, 记 $\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (z_i - 1)^2$ 是此时 σ^2 的 MLE, 则

$$\sup_{\beta=1} L(\beta, \sigma^2) = (2\pi\tilde{\sigma}^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\tilde{\sigma}^2} \sum_{i=1}^n (z_i - 1)^2 \right\} = (2\pi\tilde{\sigma}^2)^{-\frac{n}{2}} e^{-\frac{n}{2}}$$

因此有

$$\Lambda = \frac{\sup L}{\sup_{\beta=1} L} = \left(\frac{\hat{\sigma}^2}{\tilde{\sigma}^2} \right)^{-\frac{n}{2}} = \left[\frac{\sum_{i=1}^n (z_i - 1)^2}{\sum_{i=1}^n (z_i - \bar{z})^2} \right]^{\frac{n}{2}} = \left[\frac{\sum_{i=1}^n (z_i - \bar{z} + \bar{z} - 1)^2}{\sum_{i=1}^n (z_i - \bar{z})^2} \right]^{\frac{n}{2}} = \left[1 + \frac{n(\bar{z} - 1)^2}{\sum_{i=1}^n (z_i - \bar{z})^2} \right]^{\frac{n}{2}} = \left[1 + \frac{T^2}{n-1} \right]^{\frac{n}{2}}$$

其中 $T = \frac{\sqrt{n}(\bar{z}-1)}{\sqrt{\sum_{i=1}^n (z_i - \bar{z})^2/(n-1)}}$, 而 Λ 显然是 T^2 的单调增函数, 故拒绝域为

$$W = \{\Lambda \geq \lambda\} = \{|T| \geq C\}$$

其中 C 是由显著性水平确定的常数, 由于当 $\beta = 1$ 时, $T \sim t(n-1)$, 故水平为 α 的拒绝域为 $W = \{|T| \geq t_{1-\frac{\alpha}{2}}(n-1)\}$.

清华大学-432 统计学-2019 年

一、(30 分) 独立随机变量序列 $\{X_n\}$, $n \geq 1$, 其中 $X_n \sim N(\frac{1}{n}, \frac{1}{n})$.

(1)(10 分) 当 $n \rightarrow +\infty$ 时, 是否有 $X_n \xrightarrow{P} 0$, 请说明理由;

(2)(10 分) 当 $n \rightarrow +\infty$ 时, 是否有 $X_n \xrightarrow{a.s.} 0$, 请说明理由;

(3)(10 分) 是否存在单调增加的正数列 $\{a_n\}$, 使 $a_n X_n^2 \xrightarrow{d} X$? 其中 $X \sim \chi^2(1)$

Solution:

(1) 对任意 ε , $P\{|X_n| \geq \varepsilon\} \leq P\{|X_n - \frac{1}{n}| \geq \frac{\varepsilon}{2}\} + P\{|\frac{1}{n}| \geq \frac{\varepsilon}{2}\}$, 注意, 利用切比雪夫不等式 $P\{|X_n - \frac{1}{n}| \geq \frac{\varepsilon}{2}\} \leq \frac{4}{\varepsilon^2} \text{Var}(X_n) = \frac{4}{\varepsilon^2} \cdot \frac{1}{n} \rightarrow 0$, 而对第二个式子, n 足够大时, $\{|\frac{1}{n}| \geq \frac{\varepsilon}{2}\}$ 这个事件就是空集, 概率也是 0. 因此 $\lim_{n \rightarrow \infty} P\{|X_n| \geq \varepsilon\} = 0$, 故 $X_n \xrightarrow{P} 0$.

(2) [法一] 复刻第 (1) 问, 有标准正态分布 Z 的任意阶矩存在, $EZ^4 = 3$, 而

$$E\left(X_n - \frac{1}{n}\right)^4 = E\left(\frac{Z}{\sqrt{n}}\right)^4 = \frac{3}{n^2},$$

对任意 ε , $P\{|X_n| \geq \varepsilon\} \leq P\{|X_n - \frac{1}{n}| \geq \frac{\varepsilon}{2}\} + P\{|\frac{1}{n}| \geq \frac{\varepsilon}{2}\}$, 注意, 利用马尔可夫不等式 $P\{|X_n - \frac{1}{n}| \geq \frac{\varepsilon}{2}\} \leq \frac{16}{\varepsilon^4} E\left(X_n - \frac{1}{n}\right)^4 = \frac{48}{\varepsilon^4} \cdot \frac{1}{n^2}$, 级数收敛. 而对第二个式子, n 足够大时, $\{|\frac{1}{n}| \geq \frac{\varepsilon}{2}\}$ 这个事件就是空集, 概率也是 0. 根据比较判别法 $\sum_{n=1}^{\infty} P\{|X_n| \geq \varepsilon\} < +\infty$, 由 Borel-Cantelli 引理, $X_n \xrightarrow{a.s.} 0$. [法二] 借助不等式: 对 $x > 0$ 有 $\int_x^{+\infty} e^{-\frac{t^2}{2}} dt \leq \frac{1}{x} e^{-\frac{x^2}{2}}$, 故

$$P\left\{|X_n - \frac{1}{n}| \geq \frac{\varepsilon}{2}\right\} = P\left\{\sqrt{n}\left|X_n - \frac{1}{n}\right| \geq \frac{\varepsilon\sqrt{n}}{2}\right\} \leq \frac{2}{\sqrt{2\pi}} \frac{2}{\varepsilon\sqrt{n}} e^{-\frac{1}{2} \frac{\varepsilon^2}{4} n} \leq C e^{-\frac{\varepsilon^2}{8} n}$$

等比数列的级数收敛, 因此也能得到 $X_n \xrightarrow{a.s.} 0$.

(3) 在上一题的计算过程中我们已经知道 $\sqrt{n}(X_n - \frac{1}{n}) \sim N(0, 1)$, 故

$$n\left(X_n - \frac{1}{n}\right)^2 = n\left(X_n^2 - \frac{2}{n}X_n + \frac{1}{n^2}\right) = nX_n^2 - 2X_n + \frac{1}{n} \sim \chi^2(1),$$

根据前 2 问, $X_n \xrightarrow{a.s.} 0$, 而 $\frac{1}{n} \rightarrow 0$ 更是显然的, 因此 $nX_n^2 \xrightarrow{d} \chi^2(1)$.

二、(20 分) $X_1, X_2, \dots, X_n$ 是来自总体 $N(\theta, 1)$ 的简单随机样本, 其中 $\theta > 0$, 试求

(1)(10 分) θ 的极大似然估计 $\hat{\theta}_{MLE}$,

(2)(10 分) $\hat{\theta}_{MLE}$ 的极限分布.

Solution:

(1) 似然函数 $L(\theta) = (2\pi)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2\right\}$, 其中 $\theta > 0$,

$$\ln L(\theta) = -\frac{n}{2} \ln 2\pi - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2, \frac{\partial \ln L(\theta)}{\partial \theta} = n(\bar{x} - \theta),$$

因此我们可以看出, 当 $\theta < \bar{x}$ 时, $\frac{\partial \ln L(\theta)}{\partial \theta} > 0$, $L(\theta)$ 单调递增; 而当 $\theta > \bar{x}$ 时, $\frac{\partial \ln L(\theta)}{\partial \theta} < 0$, $L(\theta)$ 单调递减, 这说明了 $\bar{x}$ 是 $L(\theta)$ 的极大值点, $\hat{\theta} = \bar{x}$. 但是如果出现 $\bar{x} \leq 0$, θ 是没有办法取到 $\bar{x}$, 不过通过刚才的求导发现当 $\theta > \bar{x}$ 时 $L(\theta)$ 单调递减, 因此此时 $\hat{\theta} = 0$. 综上所述, $\hat{\theta} = \bar{x} I_{[\bar{x} > 0]}$, 其中 I_A 表示集合 A 的示性函数.

(2) 首先根据辛钦大数定律, $\bar{x} \xrightarrow{P} \theta$, 不难发现 $I_{[\bar{x} > 0]} \xrightarrow{P} 1$. 这是由于

$$\begin{aligned} P(|I(\bar{X} > 0) - 1| > \epsilon) &= P(1 - I(\bar{X} > 0) > \epsilon) \\ &= P(I(\bar{X} > 0) < 1 - \epsilon) \\ &= P(\bar{X} \leq 0) \\ &= P(\sqrt{n}(\bar{X} - \theta) \leq -\sqrt{n}\theta) \\ &= \Phi(-\sqrt{n}\theta) \rightarrow 0. \end{aligned}$$

因此根据依概率收敛的乘法性质, 有 $\hat{\theta} = \bar{x}I_{[\bar{x}>0]} \xrightarrow{P} \theta$. 但是单点分布的极限分布提供的信息过少, 为此我们去研究 $\sqrt{n}(\hat{\theta} - \theta)$ 的渐近性质, 由于有 $\sqrt{n}(\hat{\theta} - \theta) = \sqrt{n}(\bar{x} - \theta) - \sqrt{n}\bar{x}I_{[\bar{x}\leq 0]}$, 其中

$$P\left(\left|\sqrt{n}\bar{x}I_{[\bar{x}\leq 0]}\right| > \varepsilon\right) \leq P\left(\sqrt{n}\bar{x}I_{[\bar{x}\leq 0]} \neq 0\right) \leq P\left(I_{[\bar{x}\leq 0]} \neq 0\right) \rightarrow 0.$$

因此有 $\sqrt{n}\bar{x}I_{[\bar{x}\leq 0]} \xrightarrow{P} 0$, 而 $\sqrt{n}(\bar{x} - \theta) \sim N(0, 1)$, 综上所述有

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, 1).$$

三、(30 分) $X_1, X_2, \dots, X_n$ 是来自总体 $f(x; \theta) = \theta x^{\theta-1}, 0 < x < 1, \theta > 0$ 的简单随机样本.

(1)(10 分) $\sum_{i=1}^n X_i$ 是否为充分统计量?

(2)(10 分) 求 θ 的充分完全统计量 $\hat{\theta}$;

(3)(10 分) 基于 θ 构造 θ 的相合估计量.

Solution: 【第三题】、(1) 似然函数 $L(\theta) = \theta^n \left(\prod_{i=1}^n x_i\right)^{\theta-1}$, 根据因子分解定理, $\prod_{i=1}^n X_i$ 是充分统计量, 包含了样本中蕴含的参数的所有信息, 而 $\sum_{i=1}^n X_i$ 与 $\prod_{i=1}^n X_i$ 并不是一一对应的, 因此不是充分统计量. 至于为何不是一一对应, 理由如下: 情况 1: $X_1 = X_2 = \dots = X_n = \frac{1}{2}$, 此时 $\sum_{i=1}^n X_i = \frac{n}{2}, \prod_{i=1}^n X_i = \frac{1}{2^n}$; 情况 2: $X_1 = \frac{1}{4}, X_2 = \frac{3}{4}, X_3 = \dots = X_n = \frac{1}{2}$, 此时 $\sum_{i=1}^n X_i = \frac{n}{2}, \prod_{i=1}^n X_i = \frac{3}{4} \cdot \frac{1}{2^{n-1}}$; 我们发现, 对于情况 1 和情况 2, $\sum_{i=1}^n X_i$ 的值不变, 但充分统计量 $\prod_{i=1}^n X_i$ 的取值改变, 故 $\sum_{i=1}^n X_i$ 反应不了样本的所有信息.

(2) 总体服从 Beta($\theta, 1$), 是指数族, 因此充分统计量就是其充分完全统计量, 故 $\prod_{i=1}^n X_i$ 是其充分完全统计量, $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n \ln X_i$ 也是其充分完全统计量 (因为和 $\prod_{i=1}^n X_i$ 一一对应).

(3) 令 $Y = -\ln X$, 用微分法求其概率分布:

$$P\{Y = y\} = P\{-\ln X = y\} = P\{X = e^{-y}\} = f(e^{-y}) d(e^{-y}) = \theta e^{-\theta y} dy,$$

因此 $Y \sim \text{Exp}(\theta)$, 根据强大数律 $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n \ln X_i = -\frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{\text{a.s.}} -\frac{1}{\theta}$, 故 $\frac{-n}{\sum_{i=1}^n \ln X_i}$ 是 θ 的强相合估计.

四、(20 分) 假设能够生成一系列服从均匀分布 $U(0, 1)$ 的独立同分布样本 $U_1, U_2, \dots, U_n$. 现有随机变量 X 的密度函数为 $f(x) = 2x, 0 < x < 1$. 请用两种不同方法通过 $U_1, U_2, \dots, U_n$ 生成服从该分布的随机数序列 $X_1, X_2, \dots, X_n$.

Solution: 法一: $X_i = \sqrt{U_i}, i = 1, 2, \dots, n$, 现用微分法说明 $X_i \sim f(x) = 2x$:

$$P\{X = x\} = P\{\sqrt{U} = x\} = P\{U = x^2\} = f_U(x^2) d(x^2) = 2x dx, \text{ 因此 } X_i \sim f(x) = 2x.$$

法二: $X_i = \sqrt{1 - U_i}, i = 1, 2, \dots, n$, 很显然, 由于 $1 - U \sim U(0, 1)$, 故 $X_i \sim f(x) = 2x$.

法三: 我们可以观察到 $f(x) = 2x$ 恰好是 Beta(2, 1) 的密度函数, 而 Beta(2, 1) 可以由均匀分布的次序统计量来生成, 即令 $X_1 = \max\{U_1, U_2\}, \dots, X_n = \max\{U_{2n-1}, U_{2n}\}$, 这些就是服从 Beta(2, 1) 的随机数序列了. [点评]: 法一、法二用的都是分布函数的反函数与均匀分布的关系, 法三实际上并不满足条件, 因为题目要求随机数的数量一致.

五、(20 分) 两独立样本 $\{X_n\}$ i.i.d. $\sim N(\mu_1, \sigma_1^2)$ 和 $\{Y_m\}$ i.i.d. $\sim N(\mu_2, \sigma_2^2)$, 求假设检验问题:

$$H_0: \mu_1 = \mu_2 \quad \text{vs} \quad H_1: \mu_1 \neq \mu_2$$

的拒绝域, 其中 $\sigma_1 = \sigma_2$ 已知.

Solution: 令 $\sigma^2 = \sigma_1^2 = \sigma_2^2$, 构造检验统计量 $U = \frac{(\bar{x} - \bar{y})}{\sigma \sqrt{\frac{1}{n} + \frac{1}{m}}}$, 当原假设成立时, $U \sim N(0, 1)$, 我们认为如果原假设成立时, $|\bar{x} - \bar{y}|$ 理应很小, 如果 $|\bar{x} - \bar{y}|$ 比较大我们就应该拒绝原假设, 因此自然而然地我们得出该检验问题的水平为 α 的拒绝域:

$$W = \left\{ |U| \geq u_{1-\frac{\alpha}{2}} \right\}$$

六、(30 分) 简答题:

(1)(10 分) 简述假设检验中功效, 两类错误和 p 值的概念;

(2)(10 分) 两类错误能不能同时很小? 为什么?

(3)(10 分) 区间估计中的置信区间与假设检验中的拒绝域之间有何联系? 请举例说明.

Solution:

(1) 功效的定义是 $\rho(\theta) = P_{\theta}\{\mathbf{X} \in W\}$, 表示的是样本落入拒绝域的概率, 是参数 θ 的函数.

两类错误分别是: 第一类错误 (拒真错误): 原假设成立时, 样本由于随机性而落入拒绝域; 和第二类错误 (取伪错误): 它代表着当原假设不成立时, 样本由于随机性而落入接受域.

犯第一类错误的概率定义为 $\alpha(\theta) = P_{\theta}\{\mathbf{X} \in W\} (\theta \in \Theta_0)$.

犯第二类错误的概率定义为 $\beta(\theta) = 1 - P_{\theta}\{\mathbf{X} \in W\} (\theta \in \Theta - \Theta_0)$.

如果拒绝域是 $W = \{T(\mathbf{X}) \geq c\}$, 这里 $T(\mathbf{X})$ 是检验统计量, c 是某个常数. 那么 p 值的定义是: $p = \sup_{\theta \in \Theta_0} P\{T(\mathbf{X}) \geq T(\mathbf{x})\}$, 这里 $T(\mathbf{x})$ 表示统计量的观测值. 也就是说 p 值的概念是: 当原假设成立时, 统计量大于它的观测值的概率的上确界 (前提是拒绝域的形式是 $W = \{T(\mathbf{X}) \geq c\}$, 即当统计量 $T(\mathbf{X})$ 较大时进行拒绝).

其他类型的拒绝域对应的 p 值可以类似定义. 或简单的介绍为: p 值是在原假设成立时, 发生比当前观测还要更“极端”的情况的概率, 这里“极端”的概念由拒绝域形式决定. 且 p 值是可以做出拒绝原假设判断的最小显著性水平.

(2) 当样本容量固定时, 两类错误的概率不可能同时很小. 理由如下: 对于一个假设检验问题, 假设有拒绝域 $W_1 = \{T(\mathbf{X}) \geq c_1\}$.

则此时犯第一类错误的概率是 $\alpha_1(\theta) = P_{\theta}\{T(\mathbf{X}) \geq c_1\} (\theta \in \Theta_0)$.

犯第二类错误的概率是 $\beta_1(\theta) = 1 - P_{\theta}\{T(\mathbf{X}) \geq c_1\} = P_{\theta}\{T(\mathbf{X}) < c_1\} (\theta \in \Theta - \Theta_0)$.

为使得犯第一类错误的概率减小, 引入另一个拒绝域 $W_2 = \{T(\mathbf{X}) \geq c_1 + a\} (a > 0)$, 而此时犯第一类错误的概率是 $\alpha_2(\theta) = P_{\theta}\{T(\mathbf{X}) \geq c_1 + a\} (\theta \in \Theta_0)$.

很显然对于 $\forall \theta \in \Theta_0$, 有 $\alpha_2(\theta) \leq \alpha_1(\theta)$. 也就是说犯第一类错误的概率减少了. 但是此时, 犯第二类错误的概率为 $\beta_2(\theta) = P_{\theta}\{T(\mathbf{X}) < c_1 + a\} (\theta \in \Theta - \Theta_0)$, 同样很显然的是 $\forall \theta \in \Theta - \Theta_0$, 有 $\beta_2(\theta) \geq \beta_1(\theta)$. 也就是说当一类错误的概率减少时, 另外一类错误的概率就会增加. 故二者不可能同时很小.

(3) 现有显著性水平为 α 的拒绝域 $W = \{T(\mathbf{X}; \theta_0) \geq c\}$ (其中 θ_0 是已知量, 其值由原假设给出). 那么若将其补集 $\bar{W} = \{T(\mathbf{X}; \theta_0) < c\}$ (也就是接受域) 中的 θ_0 视作未知参数 θ , 并反解出形如 $\{L(\mathbf{X}) < \theta < U(\mathbf{X})\} / \{\theta > L(\mathbf{X})\} / \{\theta < U(\mathbf{X})\}$ 的集合, 那么这一区间就是参数 θ 的 $1 - \alpha$ 置信水平的置信区间.

这种求解置信区间的方法也称作反转接受域. 现在给出一个例子: 正态分布总体 (均值 μ 未知, 方差 σ^2 已知), 给出假设检验问题: $H_0: \mu < \mu_0$ vs $H_1: \mu \geq \mu_0$ 这个假设检验问题显著性水平为 α 的拒绝域是 $W = \left\{ \frac{\sqrt{n}(\bar{x} - \mu_0)}{\sigma} \geq z_{1-\alpha} \right\}$, 若将其中 μ_0 视为未知参数 μ , 从其补集 $\bar{W} = \left\{ \frac{\sqrt{n}(\bar{x} - \mu_0)}{\sigma} < z_{1-\alpha} \right\}$ 中可以反解出 $\left\{ \mu > \bar{x} - \frac{\sigma z_{1-\alpha}}{\sqrt{n}} \right\}$, 而我们知道这正是 μ 的水平为 $1 - \alpha$ 的置信区间.

清华大学-432 统计学-2020 年

一、(30 分) 有独立随机变量 X, Y , 其中 $X \sim U(0, 1), Y \sim U(0, 2)$, 求:

(1)(15 分) 求随机向量 (X, Y) 的分布函数;

(2)(15 分) 求 $Z = X + Y$ 的分布函数.

Solution:

(1) 根据题意,

$$F(x, y) = \begin{cases} 0, & x < 0 \text{ 或 } y < 0, \\ \frac{xy}{2}, & 0 \leq x < 1, 0 \leq y < 2 \\ x, & 0 \leq x < 1, 2 \leq y, \\ \frac{y}{2}, & 1 \leq x, 0 \leq y < 2, \\ 1, & 1 \leq x, 2 \leq y. \end{cases}$$

(2) 当 $0 < z < 1, P(Z \leq z) = P(X + Y \leq z) = \int_0^z P(Y \leq z - x)f(x)dx = \int_0^z \frac{z-x}{2}dx = \frac{z^2}{4},$

$$\text{当 } 1 \leq z < 2, P(Z \leq z) = P(X + Y \leq z) = \int_0^1 P(Y \leq z - x)f(x)dx = \int_0^1 \frac{z-x}{2}dx = \frac{z}{2} - \frac{1}{4},$$

当 $2 \leq z < 3$ 时, $P(Z \leq z) = P(X + Y \leq z) = \int_{z-2}^1 P(Y \leq z - x)f(x)dx = 1 - \frac{(3-z)^2}{4},$ 故

$$F_Z(z) = \begin{cases} 0, & z < 0 \\ \frac{z^2}{4}, & 0 \leq z < 1 \\ \frac{z}{2} - \frac{1}{4}, & 1 \leq z < 2 \\ 1 - \frac{(3-z)^2}{4}, & 2 \leq z < 3 \\ 1, & 3 \leq z \end{cases}$$

二、(30 分) $f(x)$ 是单调的有界连续函数, 且 $f(0) = 0$, 证明: $X_1, X_2, X_3, \dots, X_n$ 依概率收敛于 0 的充分必要条件是 $\lim_{n \rightarrow \infty} E f(|X_n|) = 0$.

Solution:

必要性: [法一] 由于 $X_n \xrightarrow{P} 0$, 故 $|X_n| \xrightarrow{P} 0$, 而 $f(x)$ 是直线上的连续函数, 故 $f(|X_n|) \xrightarrow{P} f(0) = 0$, 同时由于 $f(|X_n|)$ 有界, 根据有界收敛定理

$$\lim_{n \rightarrow \infty} E[f(|X_n|)] = E\left[\lim_{n \rightarrow \infty} f(|X_n|)\right] = 0.$$

[法二] 对任意 $\varepsilon > 0$, 存在 $\delta > 0$, 使得当 $|x| < \delta$ 时, 有 $|f(x)| < \varepsilon$, 故

$$\begin{aligned} E\left[|f(|X_n|)|\right] &= E\left[|f(|X_n|)|I_{\{|X_n| \leq \delta\}}\right] + E\left[|f(|X_n|)|I_{\{|X_n| > \delta\}}\right] \\ &\leq \varepsilon + MP(|X_n| > \delta) \end{aligned}$$

其中 M 是 $|f(x)|$ 的一个上界, 两侧同时取极限, 有 $\lim_{n \rightarrow \infty} E\left[|f(|X_n|)|\right] \leq \varepsilon$, 而 ε 是任取的, 因此 $\lim_{n \rightarrow \infty} E\left[|f(|X_n|)|\right] = 0$, 故 $\lim_{n \rightarrow \infty} E[f(|X_n|)] = 0$.

充分性: 单调连续的函数存在反函数, 且反函数也单调连续, 若有 $f(|X_n|) \xrightarrow{P} f(0) = 0$, 也有 $f^{-1}(x)$ 是直线上的连续函数, 故 $|X_n| \xrightarrow{P} 0$, 也有 $X_n \xrightarrow{P} 0$. 因此必要性只需证明 $f(|X_n|) \xrightarrow{P} f(0) = 0$. 而根据马尔可夫不等式

$$P\left\{|f(|X_n|)| > \varepsilon\right\} \leq \frac{E|f(|X_n|)|}{\varepsilon} \rightarrow 0,$$

因此 $f(|X_n|) \xrightarrow{P} 0$, 故 $X_n \xrightarrow{P} 0$.

三、(50 分) 设有独立的随机变量 $X_1, X_2, X_3, \dots, X_n$, 其中 X_i 的密度函数为 $f_i(x) = e^{i\theta-x} I(x \geq i\theta)$.

(1)(10 分) 证明 $S_n = \min \{X_i/i\}$ 是 θ 的充分统计量;

(2)(10 分) 基于 S_n 构建 θ 的形如 $[S_n + a, S_n + b]$ 最短置信区间;

(3)(10 分) 基于 S_n 构建 θ 的无偏估计 G_n ;

(4)(10 分) 证明 $T_n = \frac{1}{n} \sum_{i=1}^n \frac{X_i-1}{i}$ 是 θ 的无偏估计;

(5)(10 分) 试计算 $\lim_{n \rightarrow \infty} \frac{\text{Var}(G_n)}{\text{Var}(T_n)}$, 并根据此说明二者的有效性.

Solution:

(1) 似然函数

$$L = e^{\frac{n(n+1)}{2}\theta - \sum_{i=1}^n x_i} I\left(\min\left\{\frac{x_i}{i}\right\} \geq \theta\right) = e^{-\sum_{i=1}^n x_i} \cdot e^{\frac{n(n+1)}{2}\theta} I\left(\min\left\{\frac{x_i}{i}\right\} \geq \theta\right),$$

根据因子分解定理, $S_n = \min \left\{ \frac{X_i}{i} \right\}$ 是充分统计量.

(2) 令 $Y_i = \frac{X_i}{i} - \theta$, 现计算 Y_i 的分布, $f_{Y_i}(y) = f_i(i(y+\theta)) \left| \frac{d(i(y+\theta))}{dy} \right| = ie^{-iy} \sim \text{Exp}(i)$, 令 $U = Y_{(1)}$, 易知 $f_U(u) = \sum_{i=1}^n [f_{Y_i}(u) \prod_{j \neq i} P\{Y_j \geq u\}] = \frac{n(n+1)}{2} e^{-\frac{n(n+1)}{2}u} \sim \text{Exp}\left(\frac{n(n+1)}{2}\right)$, 由于指数分布的密度函数是单调递减的, 因此在满足 $P\{c \leq U \leq d\} = 1 - \alpha$ 的条件下想使得 $d - c$ 最小, 就只能选 $c = 0$, 而 d 满足 $\alpha = P\{U > d\} = e^{-\frac{n(n+1)}{2}d} \Rightarrow d = \frac{-2 \ln \alpha}{n(n+1)}$. 又知道 $U = Y_{(1)} = S_n - \theta$, 故 θ 的最短置信区间是 $\left[S_n + \frac{2 \ln \alpha}{n(n+1)}, S_n\right]$.

(3) $U = Y_{(1)} = S_n - \theta \sim \text{Exp}\left(\frac{n(n+1)}{2}\right)$, 故 $E(S_n - \theta) = \frac{2}{n(n+1)} \Rightarrow E\left(S_n - \frac{2}{n(n+1)}\right) = \theta$, 故 $G_n = S_n - \frac{2}{n(n+1)}$ 是 θ 的无偏估计.

(4) $ET_n = \frac{1}{n} \sum_{i=1}^n E\left[\frac{X_i}{i} - \theta\right] + \theta - \frac{1}{n} \sum_{i=1}^n \frac{1}{i}$, 由 (2) 知 $Y_i = \frac{X_i}{i} - \theta \sim \text{Exp}(i)$, 故 $ET_n = \frac{1}{n} \sum_{i=1}^n E\left[\frac{X_i}{i} - \theta\right] + \theta - \frac{1}{n} \sum_{i=1}^n \frac{1}{i} = \theta$, 因此 T_n 是 θ 的无偏估计.

(5) $\text{Var}(G_n) = \text{Var}(S_n) = \text{Var}(S_n + \theta) = \text{Var}\left(\text{Exp}\left(\frac{n(n+1)}{2}\right)\right) = \frac{4}{n^2(n+1)^2}$,

$$\text{Var}(T_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}\left(\frac{X_i}{i} - \frac{1}{i}\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}\left(\frac{X_i}{i}\right) = \frac{1}{n^2} \sum_{i=1}^n \frac{1}{i^2},$$

$\lim_{n \rightarrow \infty} \frac{\text{Var}(G_n)}{\text{Var}(T_n)} = \lim_{n \rightarrow \infty} \frac{4}{(n+1)^2} \sum_{i=1}^n \frac{1}{i^2} = \lim_{n \rightarrow \infty} \frac{4}{(n+1)^2} \cdot \frac{6}{\pi^2} \rightarrow 0$, 因此 G_n 更有效.

四、(40 分) 有简单随机样本 $X_1, X_2, X_3, \dots, X_n$ 与 $Y_1, Y_2, Y_3, \dots, Y_m$, 其中 $X_1 \sim \text{Beta}(\mu, 1), Y_1 \sim \text{Beta}(\theta, 1)$

(1)(10 分) 用似然比检验法给出 $H_0: \mu = \theta$ vs $H_1: \mu \neq \theta$ 的检验法;

(2)(10 分) 证明 (1) 中的检验也可由统计量

$$S = \frac{\sum_{i=1}^n \ln X_i}{\sum_{i=1}^n \ln X_i + \sum_{j=1}^m \ln Y_j}$$

等同给出;

(3)(10 分) 当 H_0 成立时, S 的分布;

(4)(10 分) 基于 (3) 给出 (1) 中真实水平为 0.95 的检验.

Solution: 首先我们要将 Beta 分布做出转换, 令

$$U_i = -\ln X_i \sim \text{Exp}(\mu), i = 1, 2, \dots, n, V_j = -\ln Y_j \sim \text{Exp}(\theta), j = 1, 2, \dots, m.$$

因此我们知道 μ, θ 的 MLE 分别是 $\frac{1}{\bar{u}}, \frac{1}{\bar{v}}$, 而当 $\mu = \theta$ 时, 将两者看作来自同一个总体的样本, 有 μ 的 MLE 是 $\frac{n+m}{n\bar{u}+m\bar{v}}$. 我们写出似然函数: $L(\mu, \theta) = \mu^n \theta^m e^{-(n\mu\bar{u}+m\theta\bar{v})}$,

$$\text{令 } \Lambda = \frac{\sup_{\mu=\theta} L(\mu, \theta)}{\sup_{\mu \neq \theta} L(\mu, \theta)} = \frac{L(\bar{u}^{-1}, \bar{v}^{-1})}{L\left(\frac{n+m}{n\bar{u}+m\bar{v}}, \frac{n+m}{n\bar{u}+m\bar{v}}\right)} = \frac{\bar{u}^{-n} \bar{v}^{-m}}{\left(\frac{n\bar{u}+m\bar{v}}{n+m}\right)^{-(m+n)}},$$

因此 $W = \{\Lambda > C\} = \left\{ \frac{\bar{u}^{-n} \bar{v}^{-m}}{\left(\frac{n\bar{u}+m\bar{v}}{n+m}\right)^{-(n+m)}} > C \right\} = \left\{ \frac{(n\bar{u})^n (m\bar{v})^m}{(n\bar{u}+m\bar{v})^{m+n}} < C_1 \right\}$, 令 $f(x) = x^n(1-x)^m$, 其中 $0 < x < 1$, 我们讨论 f 的单调性:

$$f'(x) = -x^{n-1}(1-x)^{m-1}[(m+n)x - n]$$

可以很明显的看出 $f(x)$ 在 $\frac{n}{m+n}$ 左侧单调递增, 在右侧单调递减, 故对于 a , 存在

$$b, d \left(b < \frac{n}{m+n} < d \right) \text{ 使得 } \{f(x) < a\} = \{x < b\} \cup \{x > d\}.$$

因此, 拒绝域可以写为:

$$W = \{\Lambda > C\} = \left\{ f\left(\frac{n\bar{u}}{n\bar{u}+m\bar{v}}\right) < C_1 \right\} = \left\{ \frac{n\bar{u}}{n\bar{u}+m\bar{v}} < \lambda_1 \right\} \cup \left\{ \frac{n\bar{u}}{n\bar{u}+m\bar{v}} > \lambda_2 \right\}$$

现在我们知道 LRT 统计量是 $\frac{n\bar{u}}{n\bar{u}+m\bar{v}} = \frac{\sum_{i=1}^n \ln X_i}{\sum_{i=1}^n \ln X_i + \sum_{j=1}^m \ln Y_j}$, 第 (2) 问得证.

根据伽马分布的可加性, 当 H_0 真时, $-2\mu \sum_{i=1}^n \ln X_i \sim \chi^2(2n)$, $-2\mu \sum_{i=1}^m \ln Y_i \sim \chi^2(2m)$, 因此 $S = \frac{-2\mu \sum_{i=1}^n \ln X_i}{-2\mu \sum_{i=1}^n \ln X_i - 2\mu \sum_{j=1}^m \ln Y_j} \sim \text{Beta}(n, m)$. 第 (3) 问得解.

重新考虑拒绝域 $W = \{S < \lambda_1\} \cup \{S > \lambda_2\}$, 根据上述的论证, 除了 $\lambda_1 < \frac{n}{m+n} < \lambda_2$, λ_1, λ_2 应满足 $P(\{S < \lambda_1\} \cup \{S > \lambda_2\} | H_0) = \alpha$ 以及 $f(\lambda_1) = f(\lambda_2)$, 其中 $f(x) = x^n(1-x)^m$. 我们发现原假设成立时 $S \sim \text{Beta}(n, m)$, 而 $\frac{\Gamma(m+n+2)}{\Gamma(m+1)\Gamma(n+1)}f(x)$ 恰好是 $\text{Beta}(n+1, m+1)$ 的概率密度函数. 我们记 $Be_{m,n}(x)$ 是 $\text{Beta}(n, m)$ 的密度函数, 则该问题的水平为 α 的拒绝域是 $W = \{S < \lambda_1\} \cup \{S > \lambda_2\}$, 其中 λ_1, λ_2 满足

$$\begin{cases} \int_{\lambda_1}^{\lambda_2} Be_{n,m}(x)dx = 1 - \alpha, \\ Be_{n+1,m+1}(\lambda_1) = Be_{n+1,m+1}(\lambda_2). \end{cases}$$

第 (1) 问得解. 当给定 $\alpha = 0.05$, 拒绝域为 $W = \{S < \lambda_1\} \cup \{S > \lambda_2\}$, 其中 λ_1, λ_2 满足

$$\begin{cases} \int_{\lambda_1}^{\lambda_2} Be_{n,m}(x)dx = 0.95, \\ Be_{n+1,m+1}(\lambda_1) = Be_{n+1,m+1}(\lambda_2). \end{cases}$$

第 (4) 问得解.

清华大学-432 统计学-2021 年

一、(20 分) 已知 (U, V) 满足: $P(U = 1) = P(U = -1) = 1/2$, 且

$$\begin{cases} P(V = -1|U = 1) = \frac{2}{3}, \\ P(V = 1|U = 1) = \frac{1}{3}, \\ P(V = -1|U = -1) = \frac{1}{3}, \\ P(V = 1|U = -1) = \frac{2}{3}, \end{cases}$$

(1)(10 分) 求方程 $x^2 + Ux + V = 0$ 有实根的概率;

(2)(10 分) 求方程 $x^2 + Ux + V = 0$ 最大实根的数学期望.

Solution:

(1) (U, V) 的联合分布律是:

	$U = -1$	$U = 1$
$V = -1$	1/6	1/3
$V = 1$	1/3	1/6

有实根意味着: $U^2 - 4V \geq 0$, 对应为

$$P(U^2 - 4V \geq 0) = P(U = 1, V = -1) + P(U = -1, V = -1) = \frac{1}{2}.$$

(2) 最大实根为 $X = \frac{-U + \sqrt{U^2 - 4V}}{2}$, 而

$$\begin{aligned} P\left(X = \frac{-1 + \sqrt{5}}{2} \mid U^2 - 4V \geq 0\right) &= \frac{2}{3} \\ P\left(X = \frac{1 + \sqrt{5}}{2} \mid U^2 - 4V \geq 0\right) &= \frac{1}{3} \end{aligned}$$

故 $E(X \mid U^2 - 4V \geq 0) = \frac{-1 + 3\sqrt{5}}{6}$.

二、(60 分) 有来自总体 $\text{Exp}(\frac{1}{\lambda})$ 的 n 个随机样本 $X_1, \dots, X_n$, 注意: $\text{Exp}(\frac{1}{\lambda})$ 指的是期望为 λ 的指数分布.

(1)(10 分) 试证: $X_1 + X_2$ 与 $\frac{X_1}{X_2}$ 独立;

(2)(20 分) 求 $X_{(1)}$ 与 $X_{(n)}$ 的相关系数 R , 并计算 $\lim_{n \rightarrow +\infty} nR$;

(3)(10 分) 分别基于 $X_{(1)}$ 和 $\bar{X}$ 构造 λ 的无偏估计;

(4)(20 分) 说明这两个无偏估计是否是弱相合估计.

Solution:

(1) (X_1, X_2) 的联合密度是 $f(x_1, x_2) = \frac{1}{\lambda^2} e^{-\lambda(x_1 + x_2)}$, 可以看出 $X_1 + X_2$ 是指数族的充分完全统计量, $\frac{X_1}{X_2}$ 是尺度族的辅助统计量, 由 Basu 定理, 它们独立,

(2) 令

$$\begin{cases} T_1 = nX_{(1)}, \\ T_2 = (n-1)(X_{(2)} - X_{(1)}) \\ \vdots \\ T_i = (n-i+1)(X_{(i)} - X_{(i-1)}) \\ \vdots \\ T_n = X_{(n)} - X_{(n-1)}, \end{cases}$$

计算雅可比行列式, 易得 $T_1, T_2, \dots, T_n$ 是 i.i.d. 服从 $\text{Exp}(\frac{1}{\lambda})$ 的随机变量, 而且

$$X_{(n)} = \frac{1}{n}T_1 + \frac{1}{n-1}T_2 + \dots + \frac{1}{2}T_{n-1} + T_n$$

故 $EX_{(n)} = (1 + \frac{1}{2} + \dots + \frac{1}{n})\lambda$, $\text{Var}(X_{(n)}) = (1 + \frac{1}{2^2} + \dots + \frac{1}{n^2})\lambda^2$. $X_{(1)}$ 的分布函数是:

$$F_1(x) = P(X_{(1)} \leq x) = 1 - P(X_{(1)} \geq x) = 1 - e^{-\frac{n}{\lambda}x},$$

它是 $\text{Exp}(\frac{n}{\lambda})$, 故 $EX_{(1)} = \frac{\lambda}{n}$, $\text{Var}(X_{(1)}) = \frac{\lambda^2}{n^2}$.

$$\begin{aligned} \text{Cov}(X_{(1)}, X_{(n)}) &= \frac{1}{n^2} \text{Var}(T_1) = \frac{\lambda^2}{n^2}, \\ \text{故 } R &= \frac{\frac{\lambda^2}{n^2}}{\sqrt{\text{Var}(X_{(1)}) \text{Var}(X_{(n)})}} = \frac{\frac{\lambda^2}{n^2}}{\sqrt{\frac{\lambda^2}{n^2} \cdot (\sum_{i=1}^n \frac{1}{i^2}) \lambda^2}} = \frac{1}{n \sqrt{\sum_{i=1}^n \frac{1}{i^2}}}, nR \rightarrow \frac{\sqrt{6}}{\pi}. \end{aligned}$$

(3) $EX_{(1)} = \frac{\lambda}{n}$, 故 $nX_{(1)}$ 是无偏估计; $E\bar{X} = \lambda$, 故 $\bar{X}$ 是无偏估计.

(4) 讨论相合性: 由辛钦大数定律, $\bar{X}$ 是弱相合估计; $nX_{(1)} = T_1 \sim \text{Exp}(\frac{1}{\lambda})$ 不收敛到单点分布, 故不是弱相合估计 (否则它一定收敛到单点分布).

三、(30 分) 设有来自总体 $B(1, \theta)$ 的 $2n$ 个独立样本 $X_1, \dots, X_{2n}$, 其中 $\theta \in [\frac{1}{2}, 1)$.

(1)(20 分) 求 θ 的最大似然估计 $\hat{\theta}$ 与其分布;

(2)(10 分) 利用似然比检验法给出假设检验问题 $H_0: \theta = \frac{1}{2}$ vs $H_1: \theta > \frac{1}{2}$ 的拒绝域.

Solution:

(1) $\hat{\theta} = \max\{\frac{1}{2}, \bar{X}\}$, 其中 $\bar{X} = \frac{1}{2n} \sum_{i=1}^{2n} X_i$, 它的分布列是:

$$P\left(\hat{\theta} = \frac{k}{2n}\right) = P(2n\bar{X} = k) = C_{2n}^k \theta^k (1-\theta)^{2n-k}, k = n+1, \dots, 2n.$$

$$P\left(\hat{\theta} = \frac{1}{2}\right) = P(2n\bar{X} \leq n) = \sum_{k=0}^n C_{2n}^k \theta^k (1-\theta)^{2n-k}.$$

(2) 似然比

$$\Lambda = \frac{L(\hat{\theta})}{L(\frac{1}{2})} = \begin{cases} 1, & \bar{X} < \frac{1}{2}, \\ 2^{2n} [\bar{X}^{\bar{X}} (1-\bar{X})^{(1-\bar{X})}]^{2n}, & \bar{X} \geq \frac{1}{2}, \end{cases}$$

注意到 $g(x) = x^x (1-x)^{1-x}$ 在 $x \geq \frac{1}{2}$ 时递增 (取对数求导), 因此拒绝域是

$$W = \{\Lambda > C\} = \left\{ \sum_{i=1}^{2n} X_i > m \right\}$$

为使得水平恰小于或等于 α , 取 $m = \inf \left\{ s : P\left(\sum_{i=1}^{2n} X_i > s \mid \theta = \frac{1}{2}\right) \right\}$. 若引入随机化检验, 可使水平恰为 α , 此时检验为

$$T(X) = 1_{\{\sum_{i=1}^{2n} X_i > m\}} + \gamma 1_{\{\sum_{i=1}^{2n} X_i = m\}}$$

其中

$$m = \inf \left\{ s : P\left(\sum_{i=1}^{2n} X_i > s \mid \theta = \frac{1}{2}\right) \right\}, \gamma = \frac{\alpha - P\left(\sum_{i=1}^{2n} X_i > m \mid \theta = \frac{1}{2}\right)}{P\left(\sum_{i=1}^{2n} X_i = m \mid \theta = \frac{1}{2}\right)}$$

四、(20 分) 随机向量 X 服从多元正态分布 $N(0, I_n)$, A 是 n 阶对称阵, 试证明: $X^T A X \sim \chi^2(r)$ 的充分必要条件是 A 为幂等矩阵且秩为 r .

Solution:

充分性: A 是投影矩阵, 只有 0 和 1 特征值, 又秩为 r , 故有 r 个特征值为 1, 因此存在正交矩阵 C 使得 $C^T A C = \begin{pmatrix} I_r & O \\ O & O \end{pmatrix}$. 故令 $Y = C^T X \sim N(0, I_n)$, 因此 $X^T A X = Y^T C^T A C Y = Y^T \begin{pmatrix} I_r & O \\ O & O \end{pmatrix} Y \sim \chi^2(r)$.

必要性: 设 A 的特征值是 $\lambda_1, \dots, \lambda_n$, 设 $\Lambda = \text{diag}\{\lambda_1, \dots, \lambda_n\}$, 由于 A 是对称阵, 因此存在正交矩阵 C 使得 $C^T A C = \Lambda$. 故令 $Y = C^T X \sim N(0, I_n)$, 因此

$$X^T A X = Y^T C^T A C Y = Y^T \Lambda Y = \sum_{i=1}^n \lambda_i Y_i^2$$

而 $\sum_{i=1}^n \lambda_i Y_i^2$ 的特征函数是 $\prod_{j=1}^n (1 - 2i\lambda_j t)^{-\frac{1}{2}}$, 若 $\sum_{i=1}^n \lambda_i Y_i^2$ 恰服从 $\chi^2(r)$, 由唯一性定理, $\prod_{j=1}^n (1 - 2i\lambda_j t)^{-\frac{1}{2}} = (1 - 2it)^{-\frac{r}{2}}$ 对任意 $t \in R$ 成立, 因此只能其中有 r 个 1, 其余是 0. 故 $\Lambda = \Lambda^2 = (C^T A C)^2 = C^T A^2 C$, 显然 $A^2 = A$ 是投影矩阵.

五、(20 分) 有来自总体 $X \sim g(x)$ 的 n 个随机样本 $X_1, \dots, X_n$, 已知 $g(x) = \frac{x f(x)}{\mu}$, 其中 $f(x)$ 是未知的概率密度函数, μ 是正则化常数, $x > 0$, 且有

$$1 < \mu \int_0^{+\infty} \frac{f(x)}{x} dx < +\infty,$$

试构造 μ 的相合估计 $\hat{\mu}_n$ 并求其渐近分布.

Solution: 注意到 $E \frac{1}{X} = \frac{1}{\mu} \int_0^{+\infty} f(x) dx = \frac{1}{\mu}$, 由强大数律, $\frac{1}{n} \sum_{i=1}^n \frac{1}{X_i} \xrightarrow{\text{a.s.}} \frac{1}{\mu}$, 此有 $\hat{\mu}_n = \frac{n}{\sum_{i=1}^n \frac{1}{X_i}} \xrightarrow{\text{a.s.}} \mu$. 考虑到 $E \frac{1}{X^2} = \frac{1}{\mu} \int_0^{+\infty} \frac{f(x)}{x} dx > \frac{1}{\mu^2}$ 且存在, 故 $\text{Var}(\frac{1}{X})$ 存在且非零, 不妨设 $\text{Var}(\frac{1}{X}) = \sigma^2$, 由中心极限定理知:

$$\sqrt{n} \left(\frac{\sum_{i=1}^n \frac{1}{X_i}}{n} - \frac{1}{\mu} \right) \xrightarrow{d} N(0, \sigma^2),$$

由 delta 方法, 令 $g(x) = \frac{1}{x}$, $g'(\frac{1}{\mu}) = -\mu^2$, 因此 $\sqrt{n}(\mu - \hat{\mu}_n) \xrightarrow{d} N(0, \mu^4 \sigma^2)$.

清华大学-432 统计学-2022 年

一、(20 分) A, B 独立, $0 < P(A) < 1$, 找出 $A, B, A \cup B$ 相互独立的充要条件.

Solution: 独立意味着: 使得 $P(A)P(A \cup B) = P(A)$, $P(B)P(A \cup B) = P(B)$ 以及

$$P(A)P(B)P(A \cup B) = P(AB).$$

首先前两个条件显然等价于 $P(A \cup B) = 1$, 而第三个条件关键在于题干 A, B 独立, 第三个式子转化为

$$P(A)P(B)P(A \cup B) = P(AB) = P(A)P(B),$$

这也等价于 $P(A \cup B) = 1$. 故 $A, B, A \cup B$ 相互独立的充要条件是 $P(A \cup B) = 1$.

二、(20 分) 一个试验若第 n 次成功, 则第 $n+1$ 次成功的概率为 $\frac{1}{2}$, 若失败, 则下一次成功概率为 $\frac{1}{4}$, 初始 (第一次) 成功概率是 $\frac{1}{2}$. 求:

(1) 第 n 次成功的概率;

(2) 首次成功时的次数的分布、期望、方差.

Solution: (1) 设 $p_n = P(A_n)$ 为第 n 次成功, 则

$$\begin{aligned} p_n &= P(A_n | A_{n-1}) P(A_{n-1}) + P(A_n | \bar{A}_{n-1}) P(\bar{A}_{n-1}) \\ &= \frac{1}{2} p_{n-1} + \frac{1}{4} (1 - p_{n-1}) = \frac{1}{4} p_{n-1} + \frac{1}{4} \end{aligned}$$

解差分方程得 $p_n = \frac{1}{6} \frac{1}{4^{n-1}} + \frac{1}{3}$.

(2) 设首次成功时的次数是 Z , 有分布列

$$P(Z = n) = \begin{cases} \frac{1}{2}, & n = 1 \\ \frac{1}{8} \left(\frac{3}{4}\right)^{n-2}, & n \geq 2 \end{cases}$$

一方面, 硬算期望方差是可行的. 另一方面, 我们看出 Z 可以拆成第一次两点分布 Y 和后续的几何分布 X , 即 $Z = Y + (1 - Y)(1 + X)$, 其中 $Y = I_{A_1} \sim B(1, \frac{1}{2})$, $X \sim Ge(\frac{1}{4})$, 且它们独立, 有分布列

$$P(Z = n) = \begin{cases} P(Y = 1) = \frac{1}{2}, & n = 1 \\ P(Y = 0, X = n - 1) = \frac{1}{8} \left(\frac{3}{4}\right)^{n-2}, & n \geq 2 \end{cases}$$

同时有 $EZ = 3$, $\text{Var}(Z) = E[\text{Var}(Z | X)] + \text{Var}[E(Z | X)] = \frac{1}{4} E(X^2) + \text{Var}\left(\frac{X}{2}\right) = 10$.

三、(60 分) $X_1, \dots, X_n$ 是 i.i.d. 服从 $U(0, \theta)$ 的随机变量, 定义 $U_n(A) = X_n + AX_1$, $V_n(B) = X_{(n)} + BX_{(1)}$.

(1) 求 A 使 $U_n(A)$ 无偏;

(2) 求 B 使 $V_n(B)$ 无偏;

(3) 证明: 任意 A, U_n 不相合;

(4) 证明: 任意 B, V_n 弱相合;

(5) $U_n(-1)$ 与 $V_n(-1)$ 是否同分布?

(6) 当 $\theta = 1$, 记 $F_n(x)$ 是 $2n[1 - V_n(-1)]$ 的分布函数, 求极限分布.

Solution: (1) 由于 $E(X_n) = E(X_1) = \frac{\theta}{2}$, 因此 $A = 1$ 时 $U_n(A)$ 无偏.

(2) 由于 $\frac{X_{(1)}}{\theta} \sim \text{Beta}(1, n)$, $\frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$, 可以计算出 $E(X_{(1)}) = \frac{1}{n+1}\theta$, $E(X_{(n)}) = \frac{n}{n+1}\theta$, 故 $B = 1$ 时 $V_n(B)$ 无偏.

(3) $U_n(A)$ 的分布与 $X_2 + AX_1$ 相同, 有固定分布, 不可能依概率收敛到常数, 因此不可能是相合估计.

(4) 根据 $\frac{X_{(1)}}{\theta} \sim \text{Beta}(1, n)$, $\frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$, 我们得到 $\text{Var}(X_{(1)}) = \text{Var}(X_{(n)}) = \frac{n\theta^2}{(n+1)^2(n+2)} \rightarrow 0$, 结合 $E(X_{(1)}) = \frac{1}{n+1}\theta \rightarrow 0$, $E(X_{(n)}) = \frac{n}{n+1}\theta \rightarrow \theta$, 我们得到

$$X_{(1)} \rightarrow_p 0, \quad X_{(n)} \rightarrow_p \theta,$$

因此对任意 B , 有 $V_n(B) \rightarrow_p \theta + B \cdot 0 = \theta$.

(5) 不同, $U_n(-1) = X_n - X_1$ 可能取负值, $V_n(-1) = X_{(n)} - X_{(1)}$ 则一定非负. 实际上, 根据次序统计量的分布公式, 有

$$p_{1,n}(x_1, x_n) = \frac{n!}{1(n-2)!1} 1(x_n - x_1)^{n-2} 1 = n(n-1)(x_n - x_1)^{n-2},$$

作变量变换, 设

$$\begin{cases} R = X_{(n)} - X_{(1)}, \\ S = X_{(1)}, \end{cases} \Rightarrow \begin{cases} r = x_n - x_1, \\ s = x_1, \end{cases} \Rightarrow \begin{cases} r = x_n - x_1, \\ s = x_1, \end{cases}$$

对应的雅可比行列式是 $|J| = 1$, 因此有

$$p_{R,S}(r, s) = p_{1,n}(s, r+s) = n(n-1)r^{n-2}, \quad 0 < s < 1-r, 0 < r < 1,$$

积掉 s , 得

$$p_R(r) = \int_0^{1-r} n(n-1)r^{n-2} ds = n(n-1)r^{n-2}(1-r),$$

这恰是 $\text{Beta}(n-1, 2)$.

(6) 直接计算, 有

$$F_n(x) = P\left(2n(1 - V_n(-1)) \leq x\right) = P\left(V_n(-1) \geq 1 - \frac{x}{2n}\right),$$

求导得

$$f_n(x) = n(n-1)\left(1 - \frac{x}{2n}\right)^{n-2} \left(\frac{x}{2n}\right) \frac{1}{2n} \rightarrow \frac{1}{2}xe^{-\frac{x}{2}},$$

这是 $Ga(2, \frac{1}{2})$, 即自由度为 4 的卡方分布. 而对应的分布函数极限是

$$F_n(x) \rightarrow 1 - (1 + x/2)e^{-x/2}.$$

四、(15 分) 简答题:

- (1) p 值的定义;
- (2) 接受原假设, 可能犯什么错误;
- (3) 解释统计中的交叉验证, 说明用途.

Solution:

(1) 如果拒绝域是 $W = \{T(\mathbf{X}) \geq c\}$, 这里 $T(\mathbf{X})$ 是检验统计量, c 是某个常数. 那么 p 值的定义是: $p = \sup_{\theta \in \Theta_0} P\{T(\mathbf{X}) \geq T(\mathbf{x})\}$, 这里 $T(\mathbf{x})$ 表示统计量的观测值. 也就是说 p 值的概念是: 当原假设成立时, 统计量大于它的观测值的概率的上确界 (前提是拒绝域的形式是 $W = \{T(\mathbf{X}) \geq c\}$, 即当统计量 $T(\mathbf{X})$ 较大时进行拒绝). 其他类型的拒绝域对应的 p 值可以类似定义. 或简单的介绍为: p 值是在原假设成立时, 发生比当前观测还要更“极端”的情况的概率, 这里“极端”的概念由拒绝域形式决定. 且 p 值是可以做出拒绝原假设判断的最小显著性水平.

(2) 可能发生第二类错误 (取伪错误), 即原假设为假, 但样本由于随机性而落入了接受域.

(3) Holdout 交叉验证: 将样本数据的一部分 (例 70%) 作为训练数据, 剩下的部分作为测试数据. 利用训练数据训练一个统计模型 (例线性模型等), 再计算其在测试数据上的误差 (称为交叉验证误差).

K-Fold 交叉验证: 将数据集等量划分为互不重叠的 K 个子集. 我们每次选取其中 $K-1$ 个子集作为训练数据, 训练出一个统计模型, 并在剩下的 1 个子集上计算误差, 重复 K 次则可以计算得到全体数据上的平均误差, 称为交叉验证误差.

留一交叉验证: 每次留出一个样本, 用剩下 $n-1$ 个样本构建模型, 并计算在留出样本上的误差. 等价于 $(n-1)$ -fold 交叉验证.

交叉验证可用于模型选择, 我们通常会比较多个模型的交叉验证误差, 并选取交叉验证误差最小的模型.

五、(20 分) 设 $X \sim P(\lambda)$. 考虑用 $T(X) = (-2)^X$ 估计 $\tau(\lambda) = e^{-3\lambda}$. 证明它无偏, 并说明是否有不妥, 若有, 如何修正?

Solution: 求期望有

$$E(T) = \sum_{k=0}^{\infty} (-2)^k \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=0}^{\infty} \frac{(-2\lambda)^k}{k!} e^{-\lambda} = e^{-3\lambda},$$

因此无偏. 但 $\tau > 0$, $(-2)^X$ 却很可能为负, 很不妥, 此外, X 越大我们倾向于认为 λ 越大, 即认为 $e^{-3\lambda}$ 越小, 这个估计没有体现. 对于第一个不妥之处, 可采用 $\tilde{T} = \max\{T, 0\}$, 对于第二个不妥之处, 可采用 $G(X) = e^{-3X}$ 估计, 而且它也是 MLE.

六、(15 分) 线性回归模型 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, 其中 $\varepsilon_i \sim N(0, \sigma^2)$, 其中 $\sum_{k=1}^n x_k = 0$, 求:

(1) β_0, β_1 的 MLE;

(2) 求 (β_0, β_1) 联合 $1-\alpha$ 置信区间.

Solution:

(1) 由题意可知, $Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, 似然函数

$$L(\mathbf{Y}; \beta_0, \beta_1, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{\sigma^2} \right\}$$

对数似然函数 $\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}$. 令
$$\begin{cases} \frac{\partial \ln L}{\partial \beta_0} = \frac{2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)}{2\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \beta_1} = \frac{2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i)}{2\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^4} = 0 \end{cases}, \text{解得}$$

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \frac{l_{xy}}{l_{xx}} \\ \hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} \\ \hat{\sigma}^2 = \frac{\sum_{i=1}^n [y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i]^2}{n} \end{cases} \text{其中} \begin{cases} l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\ l_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \\ l_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \end{cases}$$

代入 $\bar{x} = 0$, 我们还能进一步得到 $\hat{\beta}_0 = \bar{y}, \hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$.

(2) 可以证明 $Cov(\hat{\beta}_0, \hat{\beta}_1) = 0$. 先求 $Var(\hat{\beta}_1)$, 有

$$Var(\hat{\beta}_1) = \frac{1}{l_{xx}^2} Var \left(\sum_{i=1}^n (x_i - \bar{x}) y_i \right) = \frac{1}{l_{xx}^2} \sum_{i=1}^n (x_i - \bar{x})^2 Var(y_i) = \frac{\sigma^2}{l_{xx}},$$

再求 $Cov(\hat{\beta}_1, \bar{y})$, 无论 $\hat{\beta}_1$ 还是 $\bar{y}$, 都是 $y_1, \dots, y_n$ 的线性组合, 由样本的性质, 如果 $i \neq j$, 则 $Cov(y_i, y_j) = 0$, 故

$$\begin{aligned} Cov(\hat{\beta}_1, \bar{y}) &= \frac{1}{nl_{xx}} Cov \left(\sum_{i=1}^n (x_i - \bar{x}) y_i, \sum_{j=1}^n y_j \right) \\ &= \frac{1}{nl_{xx}} \sum_{i=1}^n Cov((x_i - \bar{x}) y_i, y_i) \\ &= \frac{\sigma^2}{nl_{xx}} \sum_{i=1}^n (x_i - \bar{x}) = 0. \end{aligned}$$

因此有

$$\text{Cov}(\hat{\beta}_1, \hat{\beta}_0) = -\bar{x}\text{Var}(\hat{\beta}_1) = -\frac{\bar{x}}{l_{xx}}\sigma^2.$$

而 $\bar{x} = 0$, 这说明 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 独立, 故只需分别构造 $1 - \alpha_1$ 置信区间, 其中 $(1 - \alpha_1)^2 = 1 - \alpha$.

其中 $\hat{\beta}_1 \sim N(\beta_1, \frac{\sigma^2}{l_{xx}})$, $\hat{\beta}_0 \sim N(\beta_0, \frac{\sigma^2}{n})$, 用 $\tilde{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$ 去替换构造 t 分布区间, 即

$$\left\{ (\beta_0, \beta_1) : \hat{\beta}_0 - \frac{\tilde{\sigma}}{\sqrt{n}} t_{1-\frac{\alpha_1}{2}} < \beta_0 < \hat{\beta}_0 + \frac{\tilde{\sigma}}{\sqrt{n}} t_{1-\frac{\alpha_1}{2}}, \hat{\beta}_1 - \frac{\tilde{\sigma}}{\sqrt{l_{xx}}} t_{1-\frac{\alpha_1}{2}} < \beta_1 < \hat{\beta}_1 + \frac{\tilde{\sigma}}{\sqrt{l_{xx}}} t_{1-\frac{\alpha_1}{2}} \right\}$$

是联合的置信区间.

清华大学-432 统计学-2023 年

一、(20 分) 已知 X 服从 $f(x) = c \frac{e^{-\frac{x}{2}}}{(1+e^{-\frac{x}{2}})^2}, -\infty < x < \infty$.

(1) 求 c ;

(2) 令 $Y = X^3$, 求 Y 的密度函数.

Solution:

(1) 积分得

$$\int_{-\infty}^{\infty} \frac{e^{-\frac{x}{2}}}{(1+e^{-\frac{x}{2}})^2} = 2 \int_0^{\infty} \frac{dx}{(1+x)^2} = 2,$$

由密度函数的正则性, $c = \frac{1}{2}$.

(2) 用微分法, $\forall y \in \mathbb{R}$,

$$P(Y=y) = P(X=y^{\frac{1}{3}}) = f(y^{\frac{1}{3}}) \left| \frac{d}{dy} y^{\frac{1}{3}} \right| = \frac{1}{6} \frac{y^{-\frac{2}{3}} e^{-\frac{y^{\frac{1}{3}}}{2}}}{(1+e^{-\frac{y^{\frac{1}{3}}}{2}})^2} dy.$$

故密度函数是

$$f_Y(y) = \frac{1}{6} \frac{y^{-\frac{2}{3}} e^{-\frac{y^{\frac{1}{3}}}{2}}}{(1+e^{-\frac{y^{\frac{1}{3}}}{2}})^2}, \quad y \in \mathbb{R}.$$

二、(20 分) 已知 X 的密度函数为

$$f(x; \theta) = \frac{3x^2}{\theta^3}, 0 < x < \theta,$$

其中 θ 的先验分布是 $U(0, 1)$. 求后验分布 $\pi(\theta|X=x)$.

Solution: 利用条件分布理论, 有

$$\pi(\theta|X=x) \propto f(x|\theta)\pi(\theta) \propto \frac{1}{\theta^3} I\{x < \theta < 1\},$$

由正则性: $\pi(\theta|X=x) = \frac{2x^2}{(1-x^2)\theta^3}, x < \theta < 1$.

三、(20 分) 证明: T 是 θ 的无偏估计, 则 $T(x)$ 是 θ 的 UMVUE 的充要条件是对任意零的无偏估计 U , 都有 $E[TU] = 0$.

Solution: [法一]: 对退化的零无偏估计, 显然 $E[TU] = 0$. 而对任一其他无偏估计 $\tilde{T}$ 都可写为 $\tilde{T} = T + U$ 的形式, 其中 U 是某非退化的零的无偏估计. 对每个 U , 可作标准化 $V = \frac{U}{\sqrt{\text{Var}(U)}}$, 则有 $\tilde{T} = T + \lambda V$, 其中 $\lambda^2 = \text{Var}(U)$.

令 $W(\lambda) = \text{Var}(T + \lambda V)$, T 是 UMVUE 意味着对任意 V , 都有 $W(\lambda)$ 在 $\lambda = 0$ 取最小值, 而

$$W(\lambda) = \text{Var}(T) + 2\lambda \text{Cov}(T, V) + \lambda^2 \text{Var}(V),$$

求导有

$$W'(\lambda) = 2\text{Cov}(T, V) + 2\lambda, \quad W''(\lambda) = 2 > 0,$$

对于二阶可导凸函数, 在 $\lambda = 0$ 取极小值等价于 $W'(0) = 0$, 即 $\text{Cov}(T, V) = 0$, 即 $E[TV] = 0, E[TU] = 0$.

[法二]: (1) 充分性. 若对任意 0 的无偏估计 U , 均有 $\text{Cov}(T, U) = 0$. 任取 θ 的无偏估计 $\hat{T}$, 令 $\phi = \hat{T} - T$, 则 ϕ 为 0 的无偏估计;

$$\text{Var}(\hat{T}) = \text{Var}(T + \phi) = \text{Var}(T) + \text{Var}(\phi) \geq \text{Var}(T)$$

即任意 θ 的无偏估计的方差均不小于 T 的方差, T 为 θ 的 UMVUE.

(2) 必要性: 若 T 为 UMVUE, 假设存在 U_0 , s.t. $Cov(T, U_0) \neq 0$, 不妨设 $Cov(T, U_0) > 0$. 则对任意 r , $T + rU_0$ 仍然为 θ 的无偏估计, 而

$$Var(T + rU_0) = Var(T) + r^2 Var(U_0) + 2rCov(T, U_0),$$

取 $\frac{2Cov(T, U_0)}{Var(U_0)} < r < 0$, 则 $Var(T + rU_0) < Var(T)$, 与假设矛盾. 故对任意 θ 的无偏估计 U , 均有 $Cov(T, U) = 0$.

四、(20 分) 设 $X_i \sim \mathcal{N}(\mu, \sigma^2)$, $i = 1, 2, \dots, n$, 其中 σ 已知. 求如下假设检验问题的 UMPT, 若 UMPT 不存在, 请说明理由.

$$(1) H_0: \mu = \mu_0 \quad \text{v.s.} \quad H_1: \mu = \mu_1 < \mu_0.$$

$$(2) H_0: \mu = \mu_0 \quad \text{v.s.} \quad H_1: \mu \neq \mu_0.$$

Solution:

(1) 记 $X_1, \dots, X_n$ 的联合密度函数为 $f(x_1, \dots, x_n | \mu)$. 由 N-P 引理, 拒绝域

$$W = \left\{ \frac{f(x_1, \dots, x_n | \mu_1)}{f(x_1, \dots, x_n | \mu_0)} > c \right\} = \left\{ \sum_{i=1}^n X_i < c_0 \right\}$$

是 UMPT. 考虑显著性水平为 α 的情形, 原假设下由于 $\frac{\sum_{i=1}^n X_i}{n} \sim N(\mu_0, \frac{\sigma^2}{n})$, 因此有

$$W = \left\{ \bar{X} < -\sigma z_{1-\alpha} \sqrt{n} + \mu_0 \right\}.$$

(2) 考虑 $\forall \mu_1 < \mu_0, \mu = \mu_1$ 作为备择假设, 由 (1) 可知, 落入 W 时拒绝原假设在 μ_1 有最高的功效. 由 N-P 引理, 若 $H_0: \mu = \mu_0$ v.s. $H_1: \mu \neq \mu_0$ 存在 UMPT, 则其拒绝域与 W 仅在一个满足

$$\int_A f(x_1, \dots, x_n | \mu_0) = \int_A f(x_1, \dots, x_n | \mu_1) = 0$$

的 A 上不同.

易知, $W' = \{\bar{X} > \sigma z_{1-\alpha} / \sqrt{n} + \mu_0\}$ 为右侧假设时的 UMPT, 它在 $\mu_1 > \mu_0$ 时有最高功效.

显然, 如果要在 $\mu \in R$ 上都有最高功效, 那它又要和 W 几乎处处相等, 又要和 W' 几乎处处相等, 但 W 和 W' 并非几乎处处相等, 故这是不可能做到的.

五、(40 分) $X_1, X_2, \dots, X_n \sim \mathcal{P}(\lambda)$, 并且彼此独立.

(1) 求 λ 的最大似然估计 $\hat{\lambda}_n$

(2) 判断 $\hat{\lambda}_n + \frac{1}{\sqrt{n}}$ 是否为 λ 的相合估计.

(3) 求 $\sqrt{n}(\hat{\lambda}_n - \lambda)$ 的极限分布.

(4) 求 $\sqrt{n}(\hat{\lambda}_n^2 - \lambda^2)$ 的极限分布.

Solution:

(1) 似然函数

$$L(\lambda | X_1, \dots, X_n) = \prod_{i=1}^n \frac{\lambda^{X_i}}{X_i!} e^{-\lambda} = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n X_i}}{\prod_{i=1}^n X_i!},$$

令 $\frac{\partial \ln L}{\partial \lambda} = 0$, 得

$$\hat{\lambda}_n = \frac{1}{n} \sum_{i=1}^n X_i =: \bar{X}.$$

(2) 由 Kolmogorov 强大数律, $\bar{X} \rightarrow \mathbb{E}X_1 = \lambda$, a.s., 故 $\hat{\lambda}_n \rightarrow \lambda$, a.s.. 即 $\hat{\lambda}_n$ 是强相合估计.

(3) 由 Lindeberg-Levy 中心极限定理, $\frac{\sum_{i=1}^n X_i - n\lambda}{\sqrt{n\lambda}} \rightarrow_D \mathcal{N}(0, 1)$, 即:

$$\sqrt{n}(\hat{\lambda}_n - \lambda) \rightarrow_D \mathcal{N}(0, \lambda).$$

(4) 利用 Delta 方法, 令 $g(x) = x^2$, 则有 $g'(x) = 2x$, 故

$$\sqrt{n}(\hat{\lambda}_n^2 - \lambda^2) \xrightarrow{D} 2\lambda\mathcal{N}(0, \lambda) = \mathcal{N}(0, 4\lambda^3).$$

六、(30 分) 有回归模型

$$y_i = \beta x_i + e_i, \quad 1 \leq i \leq n$$

当 $1 \leq i \leq n_1$ 时, $e_i \sim \mathcal{N}(0, \sigma_1^2)$, 当 $n_1 + 1 \leq i \leq n$ 时, $e_i \sim \mathcal{N}(0, \sigma_2^2)$.

(1) 求 β 的最小二乘估计及其分布.

(2) 求 β 的最大似然估计及其分布, 比较其方差与最小二乘估计的方差.

(3) 若 e_i 的分布未知, 但已知其期望方差不变, 求 β 的无偏估计, 使其方差不大于 (1) 中估计量的方差.

Solution: (1) 残差平方和

$$Q(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2,$$

求导得 $\frac{\partial Q}{\partial \beta} = \sum_{i=1}^n (-2)x_i(y_i - \beta x_i) = 0$, 得 β 的最小二乘估计

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}.$$

(2) 似然函数

$$L(\beta) = \left(\frac{1}{\sqrt{2\pi\sigma_1^2}} \right)^{n_1} \exp \left\{ -\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (y_i - \beta x_i)^2 \right\} \left(\frac{1}{\sqrt{2\pi\sigma_2^2}} \right)^{n-n_1} \exp \left\{ -\frac{1}{2\sigma_2^2} \sum_{i=n_1+1}^n (y_i - \beta x_i)^2 \right\},$$

令 $\frac{\partial \ln L}{\partial \beta} = 0$, 得

$$\hat{\beta}_2 = \frac{\sigma_2^2 \sum_{i=1}^{n_1} x_i y_i + \sigma_1^2 \sum_{i=n_1+1}^n x_i y_i}{\sigma_2^2 \sum_{i=1}^{n_1} x_i^2 + \sigma_1^2 \sum_{i=n_1+1}^n x_i^2}.$$

注意到 $y_i \sim \mathcal{N}(x_i \beta, \sigma_1^2), 1 \leq i \leq n_1; y_i \sim \mathcal{N}(x_i \beta, \sigma_2^2), n_1 + 1 \leq i \leq n$. 由于诸 y_i 彼此独立, 由正态分布的性质可知:

$$\hat{\beta}_2 \sim \mathcal{N} \left(\beta, \frac{\sigma_1^2 \sigma_2^2}{\sigma_2^2 \sum_{i=1}^{n_1} x_i^2 + \sigma_1^2 \sum_{i=n_1+1}^n x_i^2} \right).$$

而

$$\text{Var}(\hat{\beta}_1) = \frac{1}{\left(\sum_{i=1}^n x_i^2 \right)^2} \sum_{i=1}^n x_i^2 \text{Var}(y_i) = \frac{\sigma_1^2 \sum_{i=1}^{n_1} x_i^2 + \sigma_2^2 \sum_{i=n_1+1}^n x_i^2}{\left(\sum_{i=1}^n x_i^2 \right)^2}.$$

记 $A := \sum_{i=1}^{n_1} x_i^2, B := \sum_{i=n_1+1}^n x_i^2$. 则:

$$\frac{\text{Var}(\hat{\beta}_2)}{\text{Var}(\hat{\beta}_1)} = \frac{(A+B)^2}{\left(\frac{A}{\sigma_1^2} + \frac{B}{\sigma_2^2} \right) (\sigma_1^2 A + \sigma_2^2 B)}.$$

由柯西不等式:

$$\left(\frac{A}{\sigma_1^2} + \frac{B}{\sigma_2^2} \right) (\sigma_1^2 A + \sigma_2^2 B) \geq (A+B)^2,$$

当且仅当 $\sigma_1 = \sigma_2$ 时, 等号成立. 即 $\text{Var}(\hat{\beta}_2) \leq \text{Var}(\hat{\beta}_1)$.

(3) 仍然可取第二问的估计量, 少了分布条件不影响求期望和方差.

清华大学-432 统计学-2024 年

一、(20 分) 设 X_1, X_2, X_3, X_4 独立同分布于 $N(0, \sigma^2)$, 求 $Y = \frac{X_1^2 + X_2^2}{X_1^2 + X_2^2 + X_3^2 + X_4^2}$ 的分布.

Solution: (1) 茆书 3.3.18 改编. 由于 X_i 均为尺度族, 我们考虑

$$Y = \frac{(X_1^2 + X_2^2)/\sigma^2}{(X_1^2 + X_2^2)/\sigma^2 + (X_3^2 + X_4^2)/\sigma^2} := \frac{Z_1}{Z_1 + Z_2},$$

其中 $Z_1 \sim \chi^2(2) = Ga(1, \frac{1}{2})$, $Z_2 \sim \chi^2(2) = Ga(1, \frac{1}{2})$, 两者独立. 这是经典结论, 我们可以得到最终的分布为 $Be(1, 1) = U(0, 1)$.

二、(1)(10 分) 叙述依分布收敛的定义.

(2)(10 分) 设 $X_n \sim \chi^2(n)$, 令 $Z_n = \frac{X_n - n}{\sqrt{2n}}$. $\{Z_n\}_{n \geq 1}$ 是否依分布收敛, 请说明理由.

Solution: (1) 茆书定义.

(2) 考虑特征函数, 我们知道 X_n 的特征函数为 $\phi_{X_n}(t) = (1 - 2it)^{-n/2}$. 从而 Z_n 的特征函数为

$$\begin{aligned} \phi_{Z_n}(t) &= \phi_{\frac{X_n - n}{\sqrt{2n}}}(t) = e^{-it \frac{n}{\sqrt{2n}}} \phi_{X_n}\left(\frac{t}{\sqrt{2n}}\right) = e^{-it \frac{n}{\sqrt{2n}}} \left(1 - 2i \frac{t}{\sqrt{2n}}\right)^{-n/2} \\ &= \exp \left\{ -it \frac{n}{\sqrt{2n}} - \frac{n}{2} \log \left(1 - 2i \frac{t}{\sqrt{2n}}\right) \right\} \\ &= \exp \left\{ -it \frac{n}{\sqrt{2n}} - \frac{n}{2} \left(-2i \frac{t}{\sqrt{2n}} - \frac{t^2}{n} + o\left(\frac{1}{n}\right) \right) \right\} \\ &= \exp \left\{ -\frac{t^2}{2} + o(1) \right\} \rightarrow \exp \left\{ -\frac{t^2}{2} \right\}. \end{aligned}$$

由唯一性定理可知, $Z_n \xrightarrow{d} N(0, 1)$.

三、(60 分) $X_1, \dots, X_m \stackrel{i.i.d.}{\sim} U(0, \theta_x)$, $Y_1, \dots, Y_n \stackrel{i.i.d.}{\sim} U(0, \theta_y)$, 两者相互独立.

(1)(10 分) 求 (θ_x, θ_y) 的充分统计量;

(2)(20 分) 基于 (1) 的统计量给出 $\theta = \theta_x/\theta_y$ 的无偏估计;

(3)(30 分) 求 $\theta = \theta_x/\theta_y$ 的置信水平为 $1 - \alpha$ 的置信区间.

Solution: (1) $T = (X_{(m)}, Y_{(n)})$.

(2) 考虑 $X_{(m)}/Y_{(n)}$ 的期望, 由于 $X_{(m)}/\theta_x \sim Be(m, 1)$, $Y_{(n)}/\theta_y \sim Be(n, 1)$. 从而有

$$E\left(X_{(m)}/Y_{(n)}\right) = \frac{\theta_x}{\theta_y} E\left(\frac{X_{(m)}}{\theta_x}\right) E\left(\frac{1}{Y_{(n)}/\theta_y}\right) = \frac{\theta_x}{\theta_y} \frac{m}{m+1} \frac{n}{n-1}.$$

(3) 茆书 6.6.18 原题. $\theta = \theta_x/\theta_y$ 的置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\frac{X_{(m)}}{Y_{(n)}} \left(\frac{(m+n)\alpha}{2m} \right)^{1/n}, \frac{X_{(m)}}{Y_{(n)}} \left(\frac{(m+n)\alpha}{2n} \right)^{-1/m} \right].$$

四、(20 分) 现有甲乙两种药品, A 组共 $M (M \geq 100)$ 人, 对 A 组内所有人使用甲药后发现 m 人有副作用; B 组共 $N (N \geq 100)$ 人, 对 B 组内所有人使用乙药后发现 n 人有副作用. 请说明甲乙两药的效果是否有显著差异.

Solution: 考虑两样本比率检验, 设使用甲药后有副作用的人数为 $X \sim b(M, p_1)$, 使用乙药后有副作用的人数为 $Y \sim b(N, p_2)$.

检验问题为 $H_0: p_1 = p_2$ v.s. $H_1: p_1 \neq p_2$. 由于 $M, N \geq 100$, 因此我们考虑大样本检验, 有

$$\frac{\bar{X} - \bar{Y} - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{M} + \frac{p_2(1-p_2)}{N}}} \xrightarrow{d} N(0, 1),$$

再由 Slutsky 定理以及在原假设下 $p_1 = p_2 := p$, 从而我们利用 $\hat{p} = \frac{m+n}{M+N} \xrightarrow{P} p$, 有

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{M} + \frac{1}{N}\right)}} \xrightarrow{d} N(0, 1),$$

其中 $\bar{X} = m/M, \bar{Y} = n/N$. 拒绝域为

$$W = \{|T| > u_{1-\alpha/2}\}.$$

五、(30 分) 设 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} Ga(\alpha, \beta)$, 其中 α 已知.

(1)(10 分) 求 $\beta, \frac{1}{\beta}$ 的 MLE;

(2)(20 分) 说明 $\beta, \frac{1}{\beta}$ 的 MLE 是否达到 C-R 下界.

Solution: (1) 似然函数为

$$L(\beta) = C_1 \beta^{n\alpha} \exp \left\{ -\beta \sum_{i=1}^n X_i \right\}.$$

其对数似然为

$$l(\beta) = \log L(\beta) = C_2 + n\alpha \log \beta - \beta \sum_{i=1}^n X_i.$$

求偏导有

$$\frac{\partial l(\beta)}{\partial \beta} = \frac{n\alpha}{\beta} - \sum_{i=1}^n X_i = 0 \Rightarrow \hat{\beta} = \frac{n\alpha}{\sum_{i=1}^n X_i}.$$

由 MLE 不变性可知, $\hat{\frac{1}{\beta}} = \frac{\sum_{i=1}^n X_i}{n\alpha}$.

(2) 首先计算信息量

$$I(\beta) = -E \left(\frac{\partial^2 l(\beta)}{\partial \beta^2} \right) = -E \left(\frac{\partial^2 l(\beta)}{\partial \beta^2} \right) = \frac{\alpha}{\beta^2}.$$

需要注意的是这里的 $l(\beta)$ 是对单个样本的对数似然函数. 从而对于 β 的 C-R 下界为 $I_1 = \frac{(g'_1(\beta))^2}{nI(\beta)} = \frac{\beta^2}{n\alpha}$,

$\frac{1}{\beta}$ 的 C-R 下界为 $I_2 = \frac{(g'_2(\beta))^2}{nI(\beta)} = \frac{1}{n\alpha\beta^2}$.

而 $\sum_{i=1}^n X_i \sim Ga(n\alpha, \beta)$, 从而

$$E \left(\frac{1}{\sum_{i=1}^n X_i} \right) = \frac{\Gamma(n\alpha - 1)}{\Gamma(n\alpha)} \frac{1}{\beta^{-1}} = \frac{\beta}{n\alpha - 1},$$

$$E \left(\left(\frac{1}{\sum_{i=1}^n X_i} \right)^2 \right) = \frac{\Gamma(n\alpha - 2)}{\Gamma(n\alpha)} \frac{1}{\beta^{-2}} = \frac{\beta^2}{(n\alpha - 1)(n\alpha - 2)}.$$

以及

$$Var(\hat{\beta}) = n^2 \alpha^2 Var \left(\frac{1}{\sum_{i=1}^n X_i} \right) = n^2 \alpha^2 \left(\frac{\beta^2}{(n\alpha - 1)(n\alpha - 2)} - \left(\frac{\beta}{n\alpha - 1} \right)^2 \right) = \frac{\beta^2}{n\alpha} \frac{n^3 \alpha^3}{(n\alpha - 1)^2 (n\alpha - 2)} > \frac{\beta^2}{n\alpha} = I_1,$$

$$Var \left(\frac{\hat{1}}{\hat{\beta}} \right) = \frac{1}{n^2 \alpha^2} Var \left(\sum_{i=1}^n X_i \right) = \frac{1}{n^2 \alpha^2} \frac{n\alpha}{\beta^2} = \frac{1}{n\alpha\beta^2} = I_2.$$

清华大学-432 统计学-2025 年

1. 设有只取非负整数值的独立随机变量 X, Y , 定义 $U = \min\{X, Y\}, V = X - Y$, 试证明: U, V 独立的充分必要条件是 X, Y 服从几何分布且参数相同。(30 分)

注: 见《应坚刚划题》6.4, 6.17, 需要用到下述柯西方程, 在整数处的取值也显然成立.

[柯西方程 I] 如果 $f(x)$ 单调或连续 ($x \geq 0$), 且满足 $f(x+y) = f(x) \cdot f(y)$, 则存在 a , 使得 $f(x) = f(0) \cdot a^x$.

[柯西方程 II] 如果 $f(x)$ 和 $g(y)$ 是单调或连续函数 ($x \geq 0, y \geq 0$), 且 $f(x)g(y) = h(x+y)$, 则 $f(x) = f(0) \cdot a^x$, $g(y) = g(0) \cdot a^y$, $h(z) = h(0) \cdot a^z$.

[Solution]:

“必要性”: 先假设 $v \geq 0$, 运用独立性, 有

$$\begin{aligned} p_X(u+v)p_Y(u) &= P(X=u+v, Y=u) \\ &= P(U=u, V=v) = p_U(u)p_{V^+}(v). \end{aligned}$$

因此有

$$p_X(u+v) = \frac{p_U(u)}{p_Y(u)} \cdot p_{V^+}(v), \quad u \geq 0, v \geq 0,$$

这是柯西方程, 因此有 $P(X=x) = p_X(x) = k_1 \cdot a_1^x$, 是几何分布.

再看 Y , 仍然假设 $v \geq 0$, 运用独立性, 有

$$\begin{aligned} p_X(u)p_Y(u+v) &= P(X=u, Y=u+v) \\ &= P(U=u, V=-v) = p_U(u)p_{V^-}(v), \end{aligned}$$

其中我们用 $p_{V^-}(v)$ 来表示 $P(V=-v)$, 这样使得 $p_{V^-}(v)$ 的定义域还是正半轴. 我们得到柯西方程

$$p_Y(u+v) = \frac{p_U(u)}{p_X(u)} \cdot p_{V^-}(v), \quad u \geq 0, v \geq 0,$$

同理, Y 也是几何分布, 有 $P(Y=y) = k_2 \cdot a_2^y$.

此外, 根据柯西方程, 有 $p_{V^+}(v) \propto a_1^v$, $p_{V^-}(v) \propto a_2^v$, 那么如果有 V 是对称分布 (即 V^+ 和 V^- 同分布), 则 $a_1 = a_2$, 则进一步有 X, Y 参数相同. 但考场上题设并没有给这个条件, 遇此情况自行叙述清楚即可.

2. 离散总体 X , 分布为 $P(X=k) = c \frac{\lambda^k}{k!}, k=1, 2, \dots$, 未知参数 $\lambda > 0, c > 0, x_1, x_2, \dots, x_n$ 为总体 X 的随机样本.

(1) 求 c 。(10 分)

(2) 求 $E(X), Var(X)$ 。(10 分)

(3) 证明: λ 最大似然估计 $\hat{\lambda}_n$ 存在且唯一。(10 分)

(4) 求出 λ 最大似然估计 $\hat{\lambda}_n$ 的渐进分布。(10 分)

Solution:

(1) 由分布的归一性:

$$\sum_{k=1}^{\infty} P(X=k) = 1$$

我们求得 $c = \frac{1}{e^\lambda - 1}$ 。

(2)

$$E(X) = \lambda \frac{e^\lambda}{e^\lambda - 1}, Var(X) = \frac{\lambda e^\lambda (e^\lambda - \lambda - 1)}{(e^\lambda - 1)^2}$$

(3)

$$P(x_1, \dots, x_n) = \frac{\lambda^{\sum x_i}}{\prod x_i!} \left(\frac{1}{e^\lambda - 1}\right)^n$$
$$l(\lambda) = \sum x_i \ln \lambda - n \ln(e^\lambda - 1)$$
$$\frac{dl}{d\lambda} = \frac{n\bar{x}}{\lambda} - n \frac{e^\lambda}{e^\lambda - 1} = 0$$

由上式我们可以得到

$$(\bar{x} - \lambda)e^\lambda - \bar{x} = 0$$

设:

$$f(\lambda) = (\bar{x} - \lambda)e^\lambda - \bar{x}$$
$$f(0) = 0, f(+\infty) = -\infty$$
$$\frac{df}{d\lambda} = (\bar{x} - 1 - \lambda)e^\lambda$$

因为 $\bar{x} \geq 1$ 所以 $f(\lambda)$ 与 0 有且仅有一个交点。

(4) 很显然上述分布依旧属于指数族, 所以其极大似然估计的渐进分布有:

$$\sqrt{n}(\lambda_{MLE} - \lambda) \xrightarrow{d} N(0, I^{-1}(\lambda))$$
$$\sqrt{n}(\lambda_{MLE} - \lambda) \xrightarrow{d} N\left(0, \frac{\lambda(e^\lambda - 1)^2}{(e^\lambda - \lambda - 1)e^\lambda}\right)$$

3. $x_1, x_2, \dots, x_n$ 为总体是 $B(1, p)$ 的随机样本, $n \geq 2, p \in (0, 1)$, 定义 $\sigma_p^2 = p(1-p), \bar{x} = \frac{1}{n} \sum x_i, S_n = \frac{1}{n-1} \sum (x_i - \bar{x})^2, V_n = \frac{1}{n} \sum (x_i - \bar{x})^2$, 其中 $\xrightarrow{d}$ 为分布收敛。

(1) S_n^2, V_n^2 是否为 σ_p^2 的无偏估计。(10 分)

(2) S_n^2, V_n^2 是否为 σ_p^2 的相合估计。(10 分)

(3) 取 $p = \frac{1}{2}$, 证明: 存在非退化随机变量 Z_1, Z_2 使 $n(S_n^2 - \frac{1}{4}) \xrightarrow{d} Z_1, n(V_n^2 - \frac{1}{4}) \xrightarrow{d} Z_2, n \rightarrow \infty$, 给出具体的分布。(20 分)

Solution:

(1) 很显然 S_n^2 是无偏估计, V_n^2 不是无偏估计。

(2) S_n^2 和 V_n^2 都是相合估计: 对于 S_n^2 :

$$Var(S_n^2) = \frac{na}{(n-1)^2} \rightarrow 0$$

所以由马尔可夫大数定律, 我们有:

$$S_n^2 \xrightarrow{p} \sigma_p^2$$

对于 V_n^2 :

$$V_n^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

由辛钦大数定律, 我们有:

$$\frac{1}{n} \sum_{i=1}^n x_i^2 \xrightarrow{p} p, \bar{x} \xrightarrow{p} p$$

所以我们有:

$$V_n^2 \xrightarrow{p} \sigma_p^2$$

(3) 对于 V_n^2 :

$$V_n^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \bar{x} - \bar{x}^2$$

由中心极限定理, 我们知道:

$$\sqrt{n}(\bar{x} - \frac{1}{2}) \xrightarrow{d} N(0, \frac{1}{4})$$

由 delta 引理 (值得注意的是这里的一阶导为 0, 我们要用到二阶的 delta 方法), 我们有:

$$n(V_n^2 - \frac{1}{4}) \xrightarrow{d} -\frac{1}{4}\chi_1^2$$

对于 S_n^2 , 我们有:

$$n(S_n^2 - \frac{1}{4}) = n(V_n^2 - \frac{1}{4}) + \frac{n}{n-1}V_n^2$$

因为 $V_n^2 \xrightarrow{p} \sigma_p^2$, 所以:

$$n(S_n^2 - \frac{1}{4}) \xrightarrow{d} -\frac{1}{4}\chi_1^2 + \frac{1}{4}$$

4. 设 $x_1, \dots, x_m$ 为来自均匀分布 $U(0, \theta_1)$ 总体的随机样本, $y_1, \dots, y_n$ 为来自均匀分布 $U(0, \theta_2)$ 总体的随机样本, 两样本随机样本相互独立, $\theta_1 > 0, \theta_2 > 0$ 。

(1) 求 $H_0: \theta_1 = \theta_2 \leftrightarrow H_1: \theta_1 \neq \theta_2, \alpha \in (0, 1)$ 的似然比检验。(15 分)

(2) $U = \max\{x_1, \dots, x_m\}$, 是否分别存在 θ_1 形成 $[aU, bU]$ 和 $[c+U, d+U]$ 置信水平位 $1-\alpha$ 的置信区间, $1 \leq a < b, 0 \leq c < d$, 其中 a, b, c, d 为常数, $\alpha \in (0, 1)$ (15 分)

(3) 若 (2) 中置信区间存在, 当 $m=1$ 时, 求出置信区间长度的期望最小时对应的 a, b 或 c, d 的值。(10 分)

Solution:

(1)

我们设参数空间为 $\Theta_1 = \{\theta_1 = \theta_2, \theta_1 > 0, \theta_2 > 0\}$ 和 $\Theta_0 = \{\theta_1 > 0, \theta_2 > 0\}, Z = \max\{X_{(m)}, Y_{(n)}\}$ 则我们有:

$$\begin{aligned}\Lambda &= \frac{\argmin_{\theta \in \Theta_1} L(\theta, x)}{\argmin_{\theta \in \Theta_0} L(\theta, x)} \\ &= \frac{X_{(m)}^m Y_{(n)}^n}{Z^{m+n}} \\ \text{拒绝域: } W &= \left\{ \frac{X_{(m)}^m Y_{(n)}^n}{Z^{m+n}} \leq a \right\} \\ &= \left\{ \max\left\{ \left(\frac{X_{(m)}}{Y_{(n)}}\right)^n, \left(\frac{Y_{(n)}}{X_{(m)}}\right)^m \right\} \geq \frac{1}{a} \right\}\end{aligned}$$

我们有:

$$\begin{aligned}P(X \in W | H_0) &= \alpha \\ P(X \in W | H_0) &= \int_0^1 dx \int_0^{a^{\frac{1}{n}}x} mny^{n-1}x^{m-1}dy + \int_0^1 dy \int_0^{a^{\frac{1}{m}}y} mny^{n-1}x^{m-1}dx \\ &= a\end{aligned}$$

解得 $a = \alpha$

(2) 1). 并不存在 $[c+U, d+U]$ 置信水平位 $1-\alpha$ 的置信区间, 反证法: 假设存在 $[c+U, d+U]$ 这样的区间使得置信水平为 $1-\alpha$, 我们就有:

$$P(U - \theta_1 \in [-d, -c]) = 1 - \alpha$$

然而,

$$\begin{aligned}P(U - \theta_1 \in [-d, -c]) &= \int_{-d}^{-c} mx^{m-1} \left(\frac{1}{\theta_1}\right)^m dx \\ &= \frac{d^m - c^m}{\theta_1^m}\end{aligned}$$

可以看到这个概率是随着 θ_1 的变动而变动的，所以并不存在。2) 很显然存在 $[aU, bU]$ 置信水平位 $1 - \alpha$ 的置信区间，因为 $\frac{U}{\theta_1}$ 的分布与参数无关了。

$$\begin{aligned} P\left(\frac{U}{\theta_1} \in \left[\frac{1}{b}, \frac{1}{a}\right]\right) &= \int_{\frac{1}{b}}^{\frac{1}{a}} mx^{m-1} dx \\ &= \frac{1}{a^m} - \frac{1}{b^m} \end{aligned}$$

所以只要 $\frac{1}{a^m} - \frac{1}{b^m} = \alpha$ 的区间都满足条件。(3) 要使得 $[aU, bU]$ 置信区间的期望最小，就是要是 $b - a$ 长度最小，由拉格朗日法，我们很容易得到 $a = 1, b = (1 - \alpha)^{-\frac{1}{m}}$ ，这在基础课程茆书例题 6.6.2 中完整讲解过。

清华大学-432 统计学-2026 年

一、(60 分) 连续掷一枚硬币，正面向上和反面向上的概率分别为 p 和 $1-p$ 。现投掷 n 次，记正面向上次数为 X_n ，反面向上次数为 Y_n ，并定义 $Z_n = X_n - Y_n$ 。

1. (10 分) 求 X_n 的分布
2. (10 分) 求 Z_n 的分布
3. (10 分) 由 Z_n 构造 p 的无偏估计
4. (10 分) 求 $Cov(X_n, Y_n)$
5. (20 分) 若已知 p 的先验分布为 $f(p) = 6p(1-p)$ ，其中 $p \in [0, 1]$ 。在掷 10 次硬币后得 $X_{10} = 5$ ，结合结果求出 p 的后验估计。

Solution:

(1) 求 X_n 的分布:

每次掷硬币为一次伯努利试验， X_n 为 n 次独立重复试验中成功的次数，因此 X_n 服从二项分布 $B(n, p)$ ，分布律为:

$$P(X_n = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, 2, \dots, n$$

(2) 求 Z_n 的分布:

由定义 $Z_n = X_n - Y_n$ ，且 $Y_n = n - X_n$ ，得 $Z_n = 2X_n - n$ 。 Z_n 的取值为 $\{-n, -n+2, \dots, n\}$ 。对于任意可能的取值 k ，有:

$$P(Z_n = k) = P(2X_n - n = k) = P\left(X_n = \frac{n+k}{2}\right)$$

代入 X_n 的分布律:

$$P(Z_n = k) = \binom{n}{\frac{n+k}{2}} p^{\frac{n+k}{2}} (1-p)^{\frac{n-k}{2}}$$

(3) 由 Z_n 构造 p 的无偏估计:

先计算 Z_n 的期望:

$$E[Z_n] = E[2X_n - n] = 2E[X_n] - n = n(2p - 1)$$

由上式解得 p :

$$p = \frac{1}{2} \left(\frac{E[Z_n]}{n} + 1 \right) = E \left[\frac{Z_n + n}{2n} \right]$$

因此， p 的无偏估计为:

$$\hat{p} = \frac{Z_n + n}{2n}$$

(4) 求 $Cov(X_n, Y_n)$:

由于 $Y_n = n - X_n$:

$$\begin{aligned} Cov(X_n, Y_n) &= Cov(X_n, n - X_n) \\ &= Cov(X_n, n) - Cov(X_n, X_n) \\ &= -Var(X_n) \end{aligned}$$

$X_n \sim B(n, p)$, 则 $Var(X_n) = np(1-p)$ 。

$$Cov(X_n, Y_n) = -np(1-p)$$

(5) 求 p 的后验估计:

先验分布密度函数为 $f(p) = 6p(1-p)$, 对应 Beta 分布 $Beta(2, 2)$ 。在 $n = 10$ 次试验中, 观测到 $X = 5$ 。
似然函数为:

$$L(p) = \binom{10}{5} p^5 (1-p)^5 \propto p^5 (1-p)^5$$

根据贝叶斯公式, 后验分布密度正比于先验与似然的乘积:

$$\begin{aligned}\pi(p|X=5) &\propto f(p) \cdot L(p) \\ &\propto p^1 (1-p)^1 \cdot p^5 (1-p)^5 \\ &= p^6 (1-p)^6\end{aligned}$$

这是 $Beta(7, 7)$ 的密度函数的核, $Beta(7, 7)$ 为 p 的后验估计的分布, p 的贝叶斯估计为后验分布的期望:

$$\hat{p} = E[p|X=5] = \frac{7}{7+7} = 0.5$$

二、(20 分) 设 $X_1, X_2, \dots, X_{2n}$ 独立同分布于 $N(0, 1)$ 。求

$$V_n = \frac{2(X_1 X_2 + X_3 X_4 + \dots + X_{2n-1} X_{2n})^2}{\sum_{i=1}^{2n} X_i^2}$$

的极限分布。

Solution:

记 $Y_k = X_{2k-1} X_{2k}$, 其中 $k = 1, 2, \dots, n$ 。由于 X_i 独立同分布于 $N(0, 1)$, 则 Y_k 之间相互独立。
计算 Y_k 的期望与方差:

$$E[Y_k] = E[X_{2k-1}]E[X_{2k}] = 0$$

$$Var(Y_k) = E[Y_k^2] - (E[Y_k])^2 = E[X_{2k-1}^2]E[X_{2k}^2] - 0 = 1$$

分子部分的求和项记为 $S_n = \sum_{k=1}^n Y_k$ 。根据中心极限定理, 当 $n \rightarrow \infty$ 时:

$$\frac{S_n - nE[Y_1]}{\sqrt{nVar(Y_1)}} = \frac{S_n}{\sqrt{n}} \xrightarrow{d} N(0, 1)$$

由连续映射定理可知, 其平方依分布收敛于卡方分布:

$$\left(\frac{S_n}{\sqrt{n}}\right)^2 \xrightarrow{d} \chi^2(1)$$

分母部分记为 $W_{2n} = \sum_{i=1}^{2n} X_i^2$ 。根据大数律, 由于 $E[X_i^2] = 1$, 有:

$$\frac{1}{2n} \sum_{i=1}^{2n} X_i^2 \xrightarrow{p} E[X_1^2] = 1$$

V_n , 分子分母同时除以 $2n$:

$$V_n = \frac{2S_n^2}{W_{2n}} = \frac{2n(\frac{S_n}{\sqrt{n}})^2}{2n(\frac{W_{2n}}{2n})} = \frac{(\frac{S_n}{\sqrt{n}})^2}{\frac{1}{2n} \sum_{i=1}^{2n} X_i^2}$$

根据 Slutsky 定理: 分子 $(\frac{S_n}{\sqrt{n}})^2 \xrightarrow{d} \chi^2(1)$, 分母 $\frac{1}{2n} \sum_{i=1}^{2n} X_i^2 \xrightarrow{p} 1$ 。

因此 V_n 的极限分布为:

$$V_n \xrightarrow{d} \frac{\chi^2(1)}{1} \sim \chi^2(1)$$

即 V_n 的极限分布为 $\chi^2(1)$ 。

三、(35 分) 设 $X_1, X_2, \dots \stackrel{iid}{\sim} N(\theta, 1)$, 其中 θ 是未知参数, $\theta \in \mathbb{R}$, 记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

1. (15 分) $\bar{X}^2$ 是不是 θ^2 的无偏估计? 若不是, 给出 θ^2 的无偏估计。

2. (20 分) 考虑假设检验 $H_0: \theta = 0 \leftrightarrow H_1: \theta = 1$ 。求出该检验水平 α ($\alpha = 0.05$) 下的拒绝域, 并求出检验的功效。

Solution:

(1) 判断无偏性并求无偏估计:

$X_1, \dots, X_n$ 独立同分布于 $N(\theta, 1)$, 则样本均值 $\bar{X}$ 服从 $N(\theta, 1/n)$ 。

计算 $\bar{X}^2$ 的期望:

$$E[\bar{X}^2] = \text{Var}(\bar{X}) + (E[\bar{X}])^2 = \frac{1}{n} + \theta^2$$

因为 $E[\bar{X}^2] > \theta^2$, 所以 $\bar{X}^2$ 不是 θ^2 的无偏估计。

为了构造 θ^2 的无偏估计, 我们需要消除偏差项 $\frac{1}{n}$ 。令 $T = \bar{X}^2 - \frac{1}{n}$, 则 $E[T] = \theta^2$ 。

因此, θ^2 的无偏估计为:

$$\hat{\theta}^2 = \bar{X}^2 - \frac{1}{n}$$

(2) 求拒绝域与检验功效:

检验问题为 $H_0: \theta = 0$ vs $H_1: \theta = 1$ 。

由于 $H_1: \theta = 1 > 0$, 这是一个右侧简单检验。根据 Neyman-Pearson 引理, 拒绝域形式为 $W = \{\bar{X} > C\}$ 。

在 H_0 成立时, $\theta = 0$, $\bar{X} \sim N(0, \frac{1}{n})$ 。

给定显著性水平 $\alpha = 0.05$, 需要满足:

$$P(\bar{X} > C \mid H_0) = 0.05$$

标准化得到:

$$P\left(\frac{\bar{X} - 0}{1/\sqrt{n}} > \frac{C - 0}{1/\sqrt{n}}\right) = P(Z > \sqrt{n}C) = 0.05$$

记标准正态分布 0.05 上分位数为 $Z_{0.05}$ 。(如果考试给了表的话, $Z_{0.05} \approx 1.645$ 。) 即 $\sqrt{n}C = Z_{0.05}$, $C = Z_{0.05}/\sqrt{n}$ 。

所以该检验的拒绝域为:

$$W = \left\{ (x_1, \dots, x_n) : \bar{x} > \frac{Z_{0.05}}{\sqrt{n}} \right\}$$

接下来计算检验功效, 即功效函数 $\beta(\theta)$ 在 $\theta = 1$ 处的值:

$$Power = P(\text{拒绝 } H_0 \mid H_1 \text{ 成立}) = P\left(\bar{X} > \frac{Z_{0.05}}{\sqrt{n}} \mid \theta = 1\right)$$

在 H_1 成立时, $\theta = 1$, $\bar{X}$ 服从 $N(1, \frac{1}{n})$, 则:

$$\begin{aligned} Power &= P\left(\frac{\bar{X} - 1}{1/\sqrt{n}} > \frac{\frac{Z_{0.05}}{\sqrt{n}} - 1}{1/\sqrt{n}}\right) \\ &= P(Z > Z_{0.05} - \sqrt{n}) \\ &= 1 - \Phi(Z_{0.05} - \sqrt{n}) \\ &= \Phi(\sqrt{n} - Z_{0.05}) \end{aligned}$$

四、(20 分) 为检测灯泡寿命, 抽取 n 个样品测试。其中 $X_i (1 \leq i \leq m)$ 在 10000 小时前停止, 剩余 $n - m$ 个 ($m + 1 \leq i \leq n$) 均大于 10000 但不能被检测到。已知寿命分布密度函数为 $f(x|\lambda) = \lambda e^{-\lambda x} I_{\{x>0\}}$ 。

1. (5 分) 求 X_1 的生存函数 $S(x|\lambda) = P(X_1 > x)$ 。

2. (15 分) 记似然函数为 $L(\lambda) = [\prod_{i=1}^m f(x_i|\lambda)] [\prod_{i=m+1}^n S(z_i|\lambda)]$, 其中 $Z_i = \min\{X_i, 10000\}$ 。证明该 $L(\lambda)$ 在 $(0, +\infty)$ 上有取到唯一最大值, 并以此求出 λ 的 MLE。

Solution:

(1) 求生存函数 $S(x|\lambda)$:

生存函数为:

$$S(x|\lambda) = P(X_1 > x) = \int_x^{+\infty} f(t|\lambda) dt$$

当 $x > 0$ 时:

$$S(x|\lambda) = \int_x^{+\infty} \lambda e^{-\lambda t} dt = [-e^{-\lambda t}]_x^{+\infty} = e^{-\lambda x}$$

当 $x \leq 0$ 时, $S(x|\lambda) = 1$ 。

(2) 证明唯一最大值并求 MLE:

将 $f(x_i|\lambda) = \lambda e^{-\lambda x_i}$ 和 $S(z_i|\lambda) = e^{-\lambda z_i}$ 代入似然函数表达式:

$$\begin{aligned} L(\lambda) &= \left[\prod_{i=1}^m \lambda e^{-\lambda x_i} \right] \left[\prod_{i=m+1}^n e^{-\lambda z_i} \right] \\ &= \lambda^m \exp\left(-\lambda \sum_{i=1}^m x_i\right) \cdot \exp\left(-\lambda \sum_{i=m+1}^n z_i\right) \\ &= \lambda^m \exp\left[-\lambda \left(\sum_{i=1}^m x_i + \sum_{i=m+1}^n z_i\right)\right] \end{aligned}$$

对于 $i > m$ 的缺失数据, $Z_i = \min\{X_i, 10000\} = 10000$ 。则总观测时间 $T = \sum_{i=1}^m x_i + (n - m) \times 10000$ 。则 $L(\lambda) = \lambda^m e^{-\lambda T}$ 。

取对数似然函数 $l(\lambda) = \ln L(\lambda)$:

$$l(\lambda) = m \ln \lambda - \lambda T$$

对 λ 求导:

$$\frac{dl(\lambda)}{d\lambda} = \frac{m}{\lambda} - T$$

令导数为 0, 解得唯一驻点:

$$\hat{\lambda} = \frac{m}{T}$$

计算二阶导数:

$$\frac{d^2l(\lambda)}{d\lambda^2} = -\frac{m}{\lambda^2}$$

因为 $m > 0$ 且 $\lambda > 0$, 二阶导数恒小于 0, 说明 $l(\lambda)$ 是严格凹函数。因此, 驻点是全局唯一最大值点。
 λ 的极大似然估计为:

$$\hat{\lambda}_{MLE} = \frac{m}{\sum_{i=1}^m x_i + (n-m) \times 10000}$$

五、(15 分) 设 $X_1, X_2 \stackrel{iid}{\sim} U(\theta, 2\theta)$, 其中 $\theta > 0$ 。记 $Y = \frac{1}{2}(X_1 + X_2)$, 利用 Y 构造 θ 的置信区间。
 对于给定的置信水平 $1 - \alpha$ ($\alpha \in (0, 1)$), 考虑如下形式的置信区间类:

$$C_\alpha = \{[AY, BY] \mid 0 \leq A < B < +\infty\}$$

证明: 在此类置信区间中, 使得区间长度期望最小的区间一定存在, 并求出该置信区间。

Solution:

记 $X_i \sim U(\theta, 2\theta)$, 令 $U_i = X_i/\theta$, 则 $U_i \stackrel{iid}{\sim} U(1, 2)$ 。

构造枢轴量 $Z = \frac{Y}{\theta} = \frac{X_1 + X_2}{2\theta} = \frac{U_1 + U_2}{2}$, Z 密度函数 $f(z)$ 为:

$$f(z) = \begin{cases} 4(z-1), & 1 \leq z \leq 1.5 \\ 4(2-z), & 1.5 < z \leq 2 \\ 0, & \text{其他} \end{cases}$$

由置信区间定义 $C_\alpha = [AY, BY]$, 即 $A\frac{Y}{\theta} \leq 1 \leq B\frac{Y}{\theta} \implies \frac{1}{B} \leq Z \leq \frac{1}{A}$ 。令 $k_1 = \frac{1}{B}, k_2 = \frac{1}{A}$ 。

将置信水平作为约束条件: $\int_{k_1}^{k_2} f(z)dz = 1 - \alpha$ 。区间长度期望作为目标函数: $E[L] = E[Y(B-A)] = \theta E[Z](\frac{1}{k_1} - \frac{1}{k_2})$ 。

要使期望长度最小, 等价于在约束条件下极小化 $g(k_1, k_2) = \frac{1}{k_1} - \frac{1}{k_2}$ 。

由于 $g(k_1, k_2)$ 是连续函数, 且变量 k_1, k_2 取值在有界闭区间内, 理论上必存在极小值。我们通过拉格朗日乘数法寻找该极值点。

构造拉格朗日函数:

$$L(k_1, k_2, \lambda) = \frac{1}{k_1} - \frac{1}{k_2} + \lambda \left(\int_{k_1}^{k_2} f(z)dz - (1 - \alpha) \right)$$

分别对 k_1, k_2 求偏导并令为 0:

$$\begin{cases} \frac{\partial L}{\partial k_1} = -\frac{1}{k_1^2} - \lambda f(k_1) = 0 \\ \frac{\partial L}{\partial k_2} = \frac{1}{k_2^2} + \lambda f(k_2) = 0 \end{cases}$$

消去 λ , 得到最优解必须满足的条件:

$$k_1^2 f(k_1) = k_2^2 f(k_2)$$

α 较小的情况下, 最短置信区间会包含密度函数极大值点, 即 $1 \leq k_1 < 1.5 < k_2 \leq 2$ 。代入密度函数 $f(z)$:

1. 概率约束方程:

$$2(k_1 - 1)^2 + 2(2 - k_2)^2 = \alpha$$

2. 极值点必要方程:

$$k_1^2 \cdot 4(k_1 - 1) = k_2^2 \cdot 4(2 - k_2) \implies k_1^2(k_1 - 1) = k_2^2(2 - k_2)$$

联立上述两个方程组解出唯一的一组 (k_1, k_2) , 即可确定使得期望长度最小的置信区间系数 $A = 1/k_2$ 和 $B = 1/k_1$ 。

[注]: 关于方程组解的存在唯一性说明

虽然通过拉格朗日乘数法导出了参数 k_1, k_2 满足的方程组, 但严格的话需要说明该非线性方程组在指定区域 $1 \leq k_1 < 1.5 < k_2 \leq 2$ 内确实存在唯一解。

令 $x = k_1 - 1, y = 2 - k_2$, 其中 $x, y \in [0, 0.5]$ 。方程组转化为:

1. 约束条件: $2x^2 + 2y^2 = \alpha$

2. 极值条件: $(1+x)^2 x = (2-y)^2 y$

考察函数 $h(t) = t(1+t)^2$ 和 $g(t) = t(2-t)^2$, 在 $t \in [0, 0.5]$ 上, 导数 $h'(t) > 0, g'(t) > 0$, 故 h, g 均为严格单调递增函数, 由极值条件 $h(x) = g(y)$ 可知, 变量 y 是 x 的严格单调递增函数。考察约束条件 $x^2 + y^2 = \alpha/2$, 在第一象限内, y 是 x 的严格单调递减函数。一条严格单调递增的曲线与一条严格单调递减的曲线在第一象限内最多一个交点。而 $(1+x)^2 x = (2-y)^2 y$ 过原点, $2x^2 + 2y^2 = \alpha$ 过 $(0, \sqrt{\alpha/2})$, 则有且只有 1 个交点。

因此, 满足条件的 x, y (即 k_1, k_2) 存在且唯一, 从而保证了所求置信区间的存在性与唯一性。

北京大学数院-431 金融学

北京大学数院-431 金融学综合-2016 年

一、(14 分) 回答下述问题:

(1)(4 分) 52 张扑克牌分给 4 家, 求每一家都是同花色的概率;

(2)(5 分) 甲、乙、丙三人破译密码, 成功的概率分别为 0.5, 0.4, 0.3 且相互独立, 求密码被成功破译的概率;

(3)(5 分) 一个母虫产的卵的数量服从参数为 λ 的泊松分布, 每只卵能孵化幼虫的概率为 p , 求母虫有 n 只后代的概率.

Solution:

(1) $P(A) = \frac{\#A}{\#\Omega}$, 而 $\#A = 4!$, $\#\Omega = \frac{52!}{(13!)^4}$, $\therefore P(A) = \frac{4!(13!)^4}{52!}$.

(2) $P(A \cup B \cup C) = 1 - P(\bar{A} \cap \bar{B} \cap \bar{C}) = 1 - 0.5 \times 0.6 \times 0.7 = 0.79$.

(3) 根据全概率公式: $P(\text{母虫有 } n \text{ 只后代}) = \sum_{k=n}^{+\infty} P(\text{母虫有 } n \text{ 只后代} | \text{母虫产 } k \text{ 个卵}) P(\text{母虫产 } k \text{ 个卵})$, 而 $P(\text{母虫产 } k \text{ 个卵}) = \frac{\lambda^k}{k!} e^{-\lambda}$, $P(\text{母虫有 } n \text{ 只后代} | \text{母虫产 } k \text{ 个卵}) = C_k^n p^n q^{k-n} = \frac{k!}{n!(k-n)!} p^n q^{k-n}$, $\therefore P(\text{母虫有 } n \text{ 只后代}) = \sum_{k=n}^{+\infty} \frac{k!}{n!(k-n)!} p^n q^{k-n} \cdot \frac{\lambda^k}{k!} e^{-\lambda} = \frac{\lambda^n p^n}{n!} e^{-\lambda} \sum_{k=n}^{+\infty} \frac{(q\lambda)^{k-n}}{(k-n)!} = \frac{\lambda^n p^n}{n!} e^{-\lambda} \sum_{i=0}^{+\infty} \frac{(q\lambda)^i}{i!} = \frac{\lambda^n p^n}{n!} e^{-\lambda} e^{q\lambda} = \frac{(\lambda p)^n}{n!} e^{-\lambda p}$. 它恰好是参数为 λp 的泊松分布.

二、(11 分) X_1, X_2 i.i.d $\sim U(0, 1)$, $Y = \min\{X_1, X_2\}$, 求

(1)(6 分) Y 的概率分布;

(2)(5 分) EY 和 DY .

Solution:

(1) 利用微分法:

$$P\{Y = y\} = P\{X_1 = y, X_2 \geq y\} + P\{X_2 = y, X_1 \geq y\} = 2P\{X_1 = y\} P\{X_2 \geq y\},$$

当 $y \in (0, 1)$, $P\{X_1 = y\} = 1dy$, $P\{X_2 \geq y\} = 1 - y$, 因此 $P\{Y = y\} = 2(1 - y)dy$, 所以 $f_Y(y) = 2(1 - y), y \in (0, 1)$.

(2) 如果可以看出 $Y \sim \text{Beta}(1, 2)$, 就直接套入期望方差公式, 不过直接求也是可以的.

$$EY = 2 \int_0^1 y(1 - y)dy = 2 \text{Beta}(2, 2) = \frac{1}{3},$$

$$EY^2 = 2 \int_0^1 y^2(1 - y)dy = 2 \text{Beta}(3, 2) = \frac{1}{6},$$

$$\therefore DY = \frac{1}{6} - \frac{1}{9} = \frac{1}{18}.$$

三、(11 分) X, Y, Z 的密度为 $f(x, y, z) = e^{-(x+y+z)}$, x, y, z 大于 0, 问 X, Y, Z 是否相互独立.

Solution: 先求边缘密度:

$$f_X(x) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-(x+y+z)} dy dz = e^{-x}, f_Y(y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-(x+y+z)} dx dz = e^{-y}$$

$$f_Z(z) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{-(x+y+z)} dx dy = e^{-z}$$

又因为 $f_X(x)f_Y(y)f_Z(z) = f(x, y, z)$, $f_{X,Y} = f_X f_Y$, $f_{Y,Z} = f_Y f_Z$, $f_{X,Z} = f_X f_Z$. 因此 X, Y, Z 相互独立.

四、(14 分) 叙述并证明中心极限定理.

Solution: 中心极限定理说明的是: 在大样本的情况下, 各独立样本 (通常同分布) 的和将近似服从正态分布, 也就是 $\sum_{i=1}^n X_i$ 近似服从 $N(\sum_{i=1}^n EX_i, \sum_{i=1}^n DX_i)$, 中心极限定理经常被用于作近似的区间估计以及拒绝

域. 数学语言描述中心极限定理: 【中心极限定理】若 $X_1, \dots, X_n, i.i.d., EX_1 = \mu, DX_1 = \sigma^2$, 则

$$S_n = \frac{\sum_{i=1}^n (X_i - \mu)}{\sqrt{n}\sigma} \xrightarrow{d} N(0, 1).$$

【证明】利用特征函数进行证明, 设 $X_i - \mu$ 的特征函数为 $\varphi_i(t)$, 由于

$$\varphi_i'(0) = iE(X_i - \mu) = 0, \varphi_i''(0) = -DX_i = -\sigma^2,$$

将 $\varphi_i(t)$ 在 0 点展开到 2 阶, 即

$$\varphi_i(t) = 1 - \frac{\sigma^2}{2}t^2 + o(t^2),$$

利用卷积公式, $\sum_{i=1}^n (X_i - \mu)$ 的特征函数

$$\varphi(t) = \prod_{i=1}^n \varphi_i(t) = \left[1 - \frac{\sigma^2}{2}t^2 + o(t^2)\right]^n,$$

而 $Ee^{itS_n} = Ee^{i\frac{t}{\sqrt{n}\sigma} \sum_{i=1}^n (X_i - \mu)} = \varphi\left(\frac{t}{\sqrt{n}\sigma}\right) = \left[1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right]^n$, 所以 $\lim_{n \rightarrow \infty} Ee^{itS_n} = \lim_{n \rightarrow \infty} \left[1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right]^n = e^{-\frac{t^2}{2}}$, 而等式右侧恰好是标准正态分布的特征函数, 由此见得 $S_n = \frac{\sum_{i=1}^n (X_i - \mu)}{\sqrt{n}\sigma} \xrightarrow{d} N(0, 1)$.

五、(11 分) 有来自总体 $B(1, p)$ 的 n 个随机样本, 求 p 的充分统计量以及 $p(1-p)$ 的 UMVUE.

Solution: 先写出似然函数: $L(x_1, \dots, x_n; p) = p^{\sum_{i=1}^n I[x_i=1]} (1-p)^{n-\sum_{i=1}^n I[x_i=1]} = (1-p)^n \left(\frac{p}{1-p}\right)^{n\bar{X}}$, 根据指数族性质, $T = n\bar{X}$ 是充分完备统计量. 根据 L-S 定理, 只需找出基于 T 的无偏估计. 由于 $T \sim B(n, p)$, 则 $ET = np$, $ET^2 = (np)^2 + np(1-p) = (n^2 - n)p^2 + np$, 令

$$\alpha ET + \beta ET^2 = p(1-p),$$

即

$$\beta(n^2 - n)p^2 + (\alpha + \beta)np = -p^2 + p,$$

比较系数得 $\alpha = \frac{n}{n^2 - n}$, $\beta = \frac{-1}{n^2 - n}$. 故 $E\left[\frac{T - nT^2}{n^2 - n}\right] = p(1-p)$. $\frac{nT - T^2}{n^2 - n}$ 是所求的 UMVUE.

六、(11 分) 有来自总体 $U(0, \theta)$ 的 n 个随机样本, 求在 α 的显著性水平下 θ 的置信区间.

Solution: 用枢轴量法来构造置信区间: 假设来自总体为 $U(0, \theta)$ 的 n 个随机样本为 $X_1, \dots, X_n$, 那么

$$T = \frac{X_{(n)}}{\theta} \sim f(t) = nt^{n-1}, 0 < t < 1,$$

我们想找到 $0 < c < d \leq 1$, 使得

$$1 - \alpha = P\{c \leq T \leq d\}$$

我们可以取 $c = \alpha^{\frac{1}{n}}, d = 1$ 将满足

$$1 - \alpha = P\left\{\alpha^{\frac{1}{n}} \leq \frac{X_{(n)}}{\theta} \leq 1\right\}, \text{ 即 } 1 - \alpha = P\left\{X_{(n)} \leq \theta \leq \frac{X_{(n)}}{\alpha^{\frac{1}{n}}}\right\},$$

则 θ 的 $1 - \alpha$ 置信区间为 $\left[X_{(n)}, \frac{X_{(n)}}{\alpha^{\frac{1}{n}}}\right]$.

七、(14 分) 叙述并证明 Neyman-Pearson 基本引理.

Solution: 【奈曼-皮尔逊基本引理】总体 X 有密度函数 $f(x; \theta)$, 似然函数为 L , 对于假设检验问题:

$$H_0: \theta = \theta_0 \quad \text{Vs} \quad H_1: \theta = \theta_1$$

令 $\lambda(x_1, \dots, x_n) = \frac{L(x_1, \dots, x_n; \theta_1)}{L(x_1, \dots, x_n; \theta_0)}$, $W_0 = \{x: \lambda \geq C\}$, 其中 C 满足 $P(X \in W_0 | \theta = \theta_0) = \alpha$, 那么 $W_0 = \{x: \lambda \geq C\}$ 就是该问题的水平为 α 的 UMP 拒绝域.

【证明】对于任意一个水平小于等于 α 的拒绝域 W , 我们试图证明它犯第二类错误的概率比 W_0 大:

$$\begin{aligned}
 P_{\theta_1}(X \in \bar{W}) - P_{\theta_1}(X \in \bar{W}_0) &= \int_{\bar{W}} L(X; \theta_1) dx_1 \cdots dx_n - \int_{\bar{W}_0} L(X; \theta_1) dx_1 \cdots dx_n \\
 &= \int_{W_0} L(X; \theta_1) dx_1 \cdots dx_n - \int_W L(X; \theta_1) dx_1 \cdots dx_n \\
 &= \int_{W_0-W} L(X; \theta_1) dx_1 \cdots dx_n - \int_{W-W_0} L(X; \theta_1) dx_1 \cdots dx_n \\
 &\geq C \left[\int_{W_0-W} L(X; \theta_0) dx_1 \cdots dx_n - \int_{W-W_0} L(X; \theta_0) dx_1 \cdots dx_n \right] \\
 &= C \left[\int_{W_0} L(X; \theta_0) dx_1 \cdots dx_n - \int_W L(X; \theta_0) dx_1 \cdots dx_n \right] \\
 &\geq C[\alpha - \alpha] = 0
 \end{aligned}$$

八、(14 分) 设线性回归模型

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2),$$

其中 X_i 是常数, 各 X_i 均不相同.

- (1) 求 $\beta_0, \beta_1, \sigma^2$ 的最大似然估计 $\hat{\beta}_0, \hat{\beta}_1, \hat{\sigma}^2$.
- (2) 上述 $\hat{\sigma}^2$ 是否为 σ^2 的无偏估计? 若是, 请说明理由; 若不是, 试构造 σ^2 的无偏估计.
- (3) 给出 $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$ 的显著性水平为 α 的拒绝域.

Solution: (1) 由题意可知, $Y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, 似然函数

$$L(\mathbf{Y}; \beta_0, \beta_1, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{\sigma^2} \right\}$$

对数似然函数 $\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}$. 令

$$\begin{cases} \frac{\partial \ln L}{\partial \beta_0} = \frac{2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)}{2\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \beta_1} = \frac{2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i)}{2\sigma^2} = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^4} = 0 \end{cases}$$

解得

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \frac{l_{xy}}{l_{xx}} \\ \hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} \\ \hat{\sigma}^2 = \frac{\sum_{i=1}^n [y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i]^2}{n} \end{cases}$$

其中
$$\begin{cases} l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\ l_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \\ l_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} \end{cases}$$

(2) 由于 $\frac{S_E}{\sigma^2} \sim \chi^2(n-2)$, 因此有

$$E(\hat{\sigma}^2) = \frac{\sigma^2}{n} E\left(\frac{S_E}{\sigma^2}\right) = \frac{n-2}{n} \sigma^2,$$

故它不是无偏的, 修正的无偏估计为

$$\tilde{\sigma}^2 = \frac{n}{n-2} \hat{\sigma}^2 = \frac{S_E}{n-2}.$$

(3) 这是一个系数的 t 检验, 由于 $\hat{\beta}_1 \sim N(\beta_1, \sigma^2/l_{xx})$, 因此有

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\sigma^2}{l_{xx}}}} \sim N(0, 1),$$

但是方差项 σ^2 是未知的, 我们只能用无偏估计量

$$\tilde{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

去替代. 而 $\frac{(n-2)\tilde{\sigma}^2}{\sigma^2} \sim \chi^2(n-2)$ 且与分子独立, 因此有检验

$$W = \left\{ |T| \geq t_{1-\frac{\alpha}{2}}(n-2) \right\}.$$

北京大学数院-431 金融学综合-2017 年

一、(10 分) 事件 A, B 独立, $P(A - B) = \frac{1}{4}, P(B - A) = \frac{1}{6}$, 求 $P(A), P(B)$.

Solution: 根据题意, 有:

$$\begin{aligned} P(A - B) &= P(A) - P(AB) = \frac{1}{4} \\ P(B - A) &= P(B) - P(AB) = \frac{1}{6} \end{aligned}$$

又 AB 独立, 构造方程组:

$$\begin{cases} x - xy = 1/4, \\ y - xy = 1/6. \end{cases} \text{ 解得 } \begin{cases} x = 1/3, \\ y = 1/4. \end{cases} \text{ 或 } \begin{cases} x = 3/4, \\ y = 2/3. \end{cases}$$

故 $P(A) = 1/3, P(B) = 1/4$, 或 $P(A) = 3/4, P(B) = 2/3$.

二、(10 分) 随机变量 X, U_1, U_2 , i.i.d. $\sim N(0, 1)$, $W_i = a_i X + \sqrt{1 - a_i^2} U_i, i = 1, 2$, 求 (W_1, W_2) 的联合密度.

Solution: 根据题意:

$$\begin{pmatrix} X \\ U_1 \\ U_2 \end{pmatrix} \sim N(\vec{0}, E_3), \text{ 而 } \begin{pmatrix} W_1 \\ W_2 \end{pmatrix} = A \begin{pmatrix} X \\ U_1 \\ U_2 \end{pmatrix}, \text{ 其中 } A = \begin{pmatrix} a_1 & \sqrt{1 - a_1^2} & 0 \\ a_2 & 0 & \sqrt{1 - a_2^2} \end{pmatrix},$$

$$\text{故 } E \begin{pmatrix} W_1 \\ W_2 \end{pmatrix} = AE \begin{pmatrix} X \\ U_1 \\ U_2 \end{pmatrix} = \vec{0}, \Sigma = AA^T = \begin{pmatrix} 1 & a_1 a_2 \\ a_1 a_2 & 1 \end{pmatrix}.$$

所以可以看出联合密度函数为

$$f(x, y) = \frac{1}{2\pi\sqrt{|\Sigma|}} e^{-\frac{1}{2}(x, y)^T \Sigma^{-1} (x, y)} = \frac{1}{2\pi\sqrt{1 - (a_1 a_2)^2}} e^{-\frac{1}{2(1 - a_1^2 a_2^2)}(x^2 - 2a_1 a_2 xy + y^2)}.$$

三、(10 分) $Y_1, Y_2, \dots, Y_n$, i.i.d. $\sim \text{Exp}(1)$,

(1) 求 $D(e^{-Y_1} + Y_1)$;

(2) 证明 $S_n = \sum_{i=1}^n Y_i^2$ 渐近服从正态分布.

Solution:

(1)

$$\begin{aligned} E(e^{-Y_1} + Y_1) &= \int_0^{+\infty} (e^{-y} + y) dF(y) = \int_0^{+\infty} e^{-2y} dy + \int_0^{+\infty} y e^{-y} dy \\ &= \frac{1}{2} \Gamma(1) + \Gamma(2) = \frac{3}{2} \\ E(e^{-Y_1} + Y_1)^2 &= \int_0^{+\infty} (e^{-y} + y)^2 dF(y) = \int_0^{+\infty} (e^{-2y} + 2y e^{-y} + y^2) dF(y) \\ &= \int_0^{+\infty} e^{-3y} dy + \int_0^{+\infty} 2y e^{-2y} dy + \int_0^{+\infty} y^2 e^{-y} dy \\ &= \frac{1}{3} \Gamma(1) + \frac{1}{2} \Gamma(2) + \Gamma(3) = \frac{17}{6} \end{aligned}$$

所以 $D(e^{-Y_1} + Y_1) = E(e^{-Y_1} + Y_1)^2 - [E(e^{-Y_1} + Y_1)]^2 = \frac{17}{6} - \frac{9}{4} = \frac{7}{12}$.

(2) $EY_1^2 = \int_0^{+\infty} y^2 e^{-y} dy = 2, EY_1^4 = \int_0^{+\infty} y^4 e^{-y} dy = 24, DY_1^2 = 24 - 4 = 20$. 根据独立同分布场合下的中心极限定理, 有 $S_n \sim N(2n, 20n)$.

四、(10 分) 每吨大米销售成功利润为 6 元, 销售失败损失 a 元,

(1) 若每天进货 y 吨, 写出利润表达式;

(2) 若只有一个顾客, 其需求 $X_1 \sim U(0, 1)$, 问应该进货几吨;

(3) 若还有一个顾客, 其需求 X_2 与 X_1 独立同分布, 求 (X_1, X_2) 的联合密度;

(4) 在有两个顾客的情况下, 求总需求的概率分布.

Solution:

$$(1) \text{ 设需求为 } x, \text{ 利润 } W(x, y) = \begin{cases} 6y, & y < x, \\ 6x - a(y - x), & y \geq x. \end{cases}$$

$$(2) \text{ 进货量应使得期望利润最大, } W(X, y) = \begin{cases} 6y, & y < X, \\ 6X - a(y - X), & y \geq X \end{cases}$$

$$\begin{aligned} EW &= EW I_{[X > y]} + EW I_{[X \leq y]} \\ &= 6yP(X > y) + (6 + a) \int_0^y x dx - ay^2 \\ &= 6y(1 - y) + \frac{(6 + a)}{2} y^2 - ay^2 \\ &= \left(-\frac{a}{2} - 3\right) y^2 + 6y \end{aligned}$$

很明显当 $y = \frac{6}{6+a}$ 时, 期望利润最大.

(3) $f(x_1, x_2) = I_{[0 < x_1 < 1, 0 < x_2 < 1]}$.

(4) 求 $X = X_1 + X_2$ 的概率密度, 用微分法: 当 $0 < x < 1$

$$\begin{aligned} P\{X = x\} &= P\left(\bigcup_{t=(0,x)} \{X_1 = t, X_2 = x - t\}\right) \\ &= \int_0^x P(X_1 = t, X_2 = x - t) \\ &= \int_0^x \left| \frac{\partial(t, x - t)}{\partial(t, x)} \right| dt dx \\ &= \int_0^x dt dx = x dx \end{aligned}$$

当 $1 \leq x < 2$ 时,

$$\begin{aligned} P\{X = x\} &= P\left(\bigcup_{t \in (x-1, 1)} \{X_1 = t, X_2 = x - t\}\right) \\ &= \int_{x-1}^1 P(X_1 = t, X_2 = x - t) \\ &= \int_{x-1}^1 \left| \frac{\partial(t, x - t)}{\partial(t, x)} \right| dt dx \\ &= \int_{x-1}^1 dt dx = (2 - x) dx \end{aligned}$$

因此, X 的密度函数是

$$f(x) = \begin{cases} x, & 0 < x < 1 \\ 2 - x, & 1 \leq x < 2 \end{cases}$$

五、(10 分) P_{AB} 表示债券评级从 A 转到 B 的概率, 已知

$$\begin{bmatrix} P_{AA} & P_{AB} & P_{AD} \\ P_{BA} & P_{BB} & P_{BD} \\ P_{DA} & P_{DB} & P_{DD} \end{bmatrix} = \begin{bmatrix} 0.8 & 0.1 & 0.1 \\ 0.9 & 0.05 & 0.05 \\ 0 & 0 & 1 \end{bmatrix}$$

(1) 已知债券第 1 次、第 2 次评级为 A , 第 4 次、第 5 次为 B , 求第 3 次评级的概率分布;

(2) 记 $T = \min \{n | \text{第 } n \text{ 次评级为 } D\}$, 求 $E(T | \text{第一次为 } B)$.

Solution:

(1) 因为第 2 次评级为 A (可以把这个视作样本空间, 以省略一个条件概率), 如果只知道这个条件, 则第 3 次评级的概率分布是

$$A : 0.8, B : 0.1, D : 0.1.$$

则根据全概率公式, 第 4 次评级是 B 的概率为

$$P(\text{第 4 次 } B) = 0.8 \cdot 0.1 + 0.1 \cdot 0.05 + 0.1 \cdot 0 = 0.085,$$

根据贝叶斯公式:

$$P(\text{第 3 次 } A | \text{第 4 次 } B) = \frac{0.08}{0.085} = 0.9412,$$

$$P(\text{第 3 次 } B | \text{第 4 次 } B) = \frac{0.005}{0.085} = 0.0588,$$

$$P(\text{第 3 次 } D | \text{第 4 次 } B) = 0.$$

(2) 设 T_A, T_B, T_D 分别是初试评级是 A, B, D 时的第一次评级为 D 时经过的次数, 则

$$T_A = 1 + 0.8T_A + 0.1T_B + 0.1T_D$$

$$T_B = 1 + 0.9T_A + 0.05T_B + 0.05T_D$$

$$T_D = 1$$

对三个等式两边同时求数学期望, 得

$$0.2ET_A - 0.1ET_B = 1.1$$

$$-0.9ET_A + 0.95ET_B = 1.05,$$

9 倍第一式 +2 倍第二式, 得 $ET_B = 12$.

六、(10 分) 随机变量 X 的分布列为

$$P\{X = -1\} = p, \quad P\{X = k\} = (1-p)^2 p^k, \quad k = 0, 1, \dots,$$

证明:

(1) $U(X)$ 是零的无偏估计当且仅当 $\exists a, U(k) = ak, k = -1, 0, 1, \dots$;

(2) $I_{\{X=0\}}$ 是 $(1-p)^2$ 的 UMVUE.

Solution:

(1) 先证 " $\Leftarrow$ ":

$$EX = -p + \sum_{k=0}^{+\infty} k(1-p)^2 p^k = -p + (1-p)^2 \sum_{k=1}^{+\infty} kp^k = 0.$$

(注意: $\sum_{k=1}^{+\infty} kp^k = \sum_{k=1}^{+\infty} \sum_{n=1}^k p^k = \sum_{n=1}^{+\infty} \sum_{k=n}^{+\infty} p^k = \sum_{n=1}^{+\infty} \frac{p^n}{1-p} = \frac{p}{(1-p)^2}$) 如果 $\exists a$, s.t. $U(X) = aX$, 则 $EU(X) = aEX = 0$. 再证 " $\Rightarrow$ ": 设 $U(k) = u_k$, 因为 $U(X)$ 是零的无偏估计, 所以有:

$$0 = u_{-1}p + (1-p)^2 \sum_{k=0}^{+\infty} u_k p^k = u_0 + \sum_{k=1}^{+\infty} (u_{k-2} - 2u_{k-1} + u_k) p^k$$

这个等式要求对于任意 $p \in [0, 1]$ 成立, 等式右侧是关于 p 的一个幂级数, 幂级数要想恒为 0 就必须所有项系数都为 0, 即 $u_0 = 0, u_{k-2} - 2u_{k-1} + u_k = 0$, 第二个等式意味着 $\{u_n\}$ 是等差数列, 而又有 $u_0 = 0$, 因此 $U(k) = u_k = ku_1$.

(2) 先验证无偏性, $E I_{[X=0]} = P\{X=0\} = (1-p)^2$, 无偏性成立. $E X I_{[X=0]} = 0$ 是很显然是成立的, 而对于任意零的无偏估计 $U(X)$,

$$\text{Cov}(I_{[X=0]}, U(X)) = a \text{Cov}(I_{[X=0]}, X) = a E X I_{[X=0]} = 0$$

因此 $I_{[X=0]}$ 是 $(1-p)^2$ 的 UMVUE.

七、(10 分) 有来自下列总体的 n 个随机样本, 求对应的 MLE:

(1) $f(x; \theta) = e^{-(x-\theta)} I[x > \theta];$

(2) $f(x; \theta) = \theta(1-x)^{\theta-1}, \theta > 0, \quad 0 < x < 1;$

(3) $N(\theta, \theta^2), \theta > 0.$

Solution:

(1) $L(x_1, \dots, x_n; \theta) = e^{n\theta - \sum_{i=1}^n x_i} I_{[x_{(1)} > \theta]} \propto e^{n\theta} I_{[x_{(1)} > \theta]} \stackrel{\text{Let}}{=} L_1$, 可以看出, L_1 关于 θ 单调递增, 但由于示性函数的存在, θ 最大只能取到 $x_{(1)}$ (实际上是取不到 $x_{(1)}$, 但 $x_{(1)}$ 是原参数空间一个边界点, 将它加入参数空间不会影响分布的性质), 所以 θ 的 MLE 是 $x_{(1)}$.

(2)

$$L(x_1, \dots, x_n; \theta) = \theta^n \prod_{i=1}^n (1-x_i)^{\theta-1} \propto \theta^n \prod_{i=1}^n (1-x_i)^{\theta} \stackrel{\text{Let}}{=} L_1, \quad \ln L_1 = n \ln \theta + \theta \sum_{i=1}^n \ln(1-x_i)$$

$\frac{\partial \ln L_1}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln(1-x_i)$, 解得驻点 $\theta = -\frac{n}{\sum_{i=1}^n \ln(1-x_i)}$, 因此 θ 的 MLE 是 $\theta = -\frac{n}{\sum_{i=1}^n \ln(1-x_i)}$.

(3)

$$L(x_1, \dots, x_n; \theta) = (2\pi)^{-\frac{n}{2}} |\theta|^{-n} \exp \left\{ -\frac{1}{2\theta^2} \sum_{i=1}^n (x_i - \theta)^2 \right\} \propto |\theta|^{-n} \exp \left\{ -\frac{1}{2\theta^2} \sum_{i=1}^n (x_i - \theta)^2 \right\} \stackrel{\text{Let}}{=} L_1,$$

$$\ln L_1 = -n \ln |\theta| - \frac{1}{2\theta^2} \sum_{i=1}^n (x_i - \theta)^2, \quad \frac{\partial \ln L_1}{\partial \theta} = \frac{n\theta^2 + \theta \sum x_i - \sum x_i^2}{-\theta^3},$$

解得驻点

$$\theta_1 = \frac{-\sum x_i - \sqrt{(\sum x_i)^2 + 4n \sum x_i^2}}{2n}, \theta_2 = \frac{-\sum x_i + \sqrt{(\sum x_i)^2 + 4n \sum x_i^2}}{2n},$$

根据 $\frac{\partial \ln L_1}{\partial \theta}$ 的表达式, 可以看出两个驻点都是极大值点, 但 $\theta_1 < 0$, 因此

$$\theta \text{ 的 MLE 是 } \hat{\theta} = \frac{-\sum x_i + \sqrt{(\sum x_i)^2 + 4n \sum x_i^2}}{2n}.$$

(注意: $\frac{\partial \ln L_1}{\partial \theta} = \frac{n\theta^2 + \theta \sum x_i - \sum x_i^2}{-\theta^3}$, 分子在 $\theta < \theta_2$ 时为负, $\theta > \theta_2$ 时为正, 但分母在这个邻域里是负的, 因此 θ_2 是极大值点.)

八、(10 分) 总体 $X \sim N(\mu, 4^2)$, $x_1, \dots, x_{100}$ 是一组简单随机样本,

(1) 求 $H_0: \mu = 3$ vs $H_1: \mu \neq 3$ 的否定域, $\alpha = 0.1$;

(2) $\bar{x} = 5$, 求 p 值;

(3) $\mu = 2$ 时该检验法的功效.

Solution:

(1) 检验统计量 $u = \frac{\sum_{i=1}^{100}(X_i-3)}{40}$, 在原假设成立时, $u = \frac{\sum_{i=1}^{100}(X_i-3)}{40} \sim N(0, 1)$, 由于此时 $P\{|u| > 1.645\} = 0.1$, 拒绝域 $W = \{|u| > 1.645\}$ 的显著性水平恰好是 $\alpha = 0.1$, 则 $W = \{|u| > 1.645\}$ 是该假设检验问题的 $\alpha = 0.1$ 的 UMPU 否定域.

(2) 此时, $\frac{\sum_{i=1}^{100}(x_i-3)}{40} = 5$, 而 $p = P\{|u| > 5 \mid \mu = 3\} = 0.0000$.

(3) 如果 $\mu = 2$, 那么 $u = \frac{\sum_{i=1}^{100}(X_i-3)}{40} \sim N(-2.5, 1)$, 当 H_1 真, 此时 $P\{|u| < 1.645\} = P\{0.855 < u + 2.5 < 4.145\} = \Phi(4.145) - \Phi(0.855) = 0.1963$, 故功效为 $\rho = 1 - 0.1963 = 0.8037$.

九、(10 分) 设某电子产品的寿命服从如下分布:

$$F(x; \alpha, \beta) = \begin{cases} 1 - e^{-\frac{x-\alpha}{\beta}}, & x \geq \alpha \\ 0, & x < \alpha \end{cases}$$

现测得 n 个该电子产品的寿命为 $X_1, X_2, \dots, X_n$, 试求未知参数 α, β 的矩估计和极大似然估计.

Solution: 总体服从双参数指数分布 $\text{Exp}\left(\alpha, \frac{1}{\beta}\right)$, 其中 α 是位置参数, β 是尺度参数, 所以 $EX = \alpha + \beta$, $\text{Var}(X) = \beta^2$, 所以令 $\begin{cases} \bar{x} = \alpha + \beta \\ s^2 = \beta \end{cases}$, 解得矩估计是

$$\begin{cases} \hat{\alpha}_M = \bar{x} - s \\ \hat{\beta}_M = s \end{cases}$$

样本的似然函数是

$$\begin{aligned} L(\alpha, \beta) &= \frac{1}{\beta^n} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \alpha)}{\beta}\right\} \mathbf{I}_{\{x_{(1)} \geq \alpha\}} \\ &= \frac{1}{\beta^n} e^{-\frac{n\bar{x}}{\beta}} e^{\frac{\alpha}{\beta}} \mathbf{I}_{\{x_{(1)} \geq \alpha\}} \end{aligned}$$

显然它是关于 α 在 $(-\infty, x_{(1)})$ 上的增函数, 于是 $\hat{\alpha}_L = x_{(1)}$ 是 α 的极大似然估计. 再求 β 的极大似然估计, 考虑将对数似然函数的偏导置零, 即

$$\frac{\partial \ln L(\alpha, \beta)}{\partial \beta} = -\frac{n}{\beta} + \frac{\sum_{i=1}^n (x_i - \alpha)}{\beta^2} = 0$$

解得 $\beta = \frac{1}{n} \sum_{i=1}^n (x_i - \alpha)$, 代入 $\hat{\alpha}_L = x_{(1)}$, 得 $\hat{\beta}_L = \bar{x} - x_{(1)}$ 是 β 的极大似然估计.

北京大学数院-431 金融学综合-2018 年

一、(10 分) X, Y , i.i.d. $\sim N(0, 1)$, 且 $\begin{cases} X = R \cos \theta \\ Y = R \sin \theta \end{cases}$, 求 $E(R^2\theta)$, 其中 $R > 0, \theta \in [0, 2\pi]$.

Solution: 给大家两种解法, 思考一下是否可行: 解法一: 根据题意 (X, Y) 的密度函数是 $\frac{1}{2\pi}e^{-\frac{x^2+y^2}{2}}$, 故

$$\begin{aligned} E(R^2\theta) &= \int_{\mathbb{R}^2} (x^2 + y^2) \arctan \frac{y}{x} \cdot \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}} dx dy \\ &= \frac{1}{2\pi} \int_0^{2\pi} \theta d\theta \int_0^{+\infty} r^3 e^{-\frac{r^2}{2}} dr \\ &= \frac{1}{2\pi} \cdot \frac{4\pi^2}{2} \cdot 2 = 2\pi. \end{aligned}$$

解法二: 用微分法,

$$\begin{aligned} P\{R = r, \theta = \alpha\} &= P\{X = r \cos \alpha, Y = r \sin \alpha\} \\ &= f_{X,Y}(r \cos \alpha, r \sin \alpha) \left| \frac{\partial(r \cos \alpha, r \sin \alpha)}{\partial(r, \alpha)} \right| dr d\alpha \\ &= \frac{1}{2\pi} r e^{-\frac{r^2}{2}} dr d\alpha \end{aligned}$$

因此 (R, θ) 的联合密度是 $\frac{1}{2\pi} r e^{-\frac{r^2}{2}}, 0 \leq \theta \leq 2\pi, r > 0$.

$$E(R^2\theta) = \frac{1}{2\pi} \int_0^{2\pi} \theta d\theta \int_0^{+\infty} r^3 e^{-\frac{r^2}{2}} dr = \frac{1}{2\pi} \cdot \frac{4\pi^2}{2} \cdot 2 = 2\pi.$$

[注]: 解法一是一种错误做法, 因为 θ 不能简单地表示为 $\arctan \frac{y}{x}$, θ 的取值范围是 $[0, 2\pi]$, 而 $\arctan \frac{y}{x}$ 则取值在 $(-\frac{\pi}{2}, \frac{\pi}{2})$ 之间.

二、(10 分) $X_1, \dots, X_n$, i.i.d. $\sim f(x) = ax^2 I[1 < x < b]$, 其中 $a > 0, b > 1, B_i = \{X_i > 4^{\frac{1}{3}}\}$,

(1)(5 分) $P(B_1 | B_1 \cup B_2) = 0.7$, 求 a, b ;

(2)(5 分) 在 (1) 的条件下, 证明 $(\prod_{k=1}^n X_k)^{\frac{1}{n}} \rightarrow c$, a.s., 当 $n \rightarrow \infty$, 并求常数 c .

Solution:

(1)

$$\begin{aligned} P(B_1) &= \int_{4^{\frac{1}{3}}}^b ax^2 dx = \frac{a}{3} x^3 \Big|_{4^{\frac{1}{3}}}^b = \frac{a}{3} (b^3 - 4) \\ P(B_1 | B_1 \cup B_2) &= \frac{P(B_1)}{P(B_1) + P(B_2) - P(B_1)P(B_2)} = \frac{1}{2 - P(B_1)} = 0.7, \end{aligned}$$

由 $2 - \frac{a}{3} (b^3 - 4) = \frac{10}{7} \Rightarrow a(b^3 - 4) = \frac{12}{7}$, 此外, 根据概率的正则性, 有 $1 = \int_1^b ax^2 dx = \frac{a}{3} x^3 \Big|_1^b = \frac{a}{3} (b^3 - 1) \Rightarrow a(b^3 - 1) = 3$, 联立后解得 $a = \frac{3}{7}, b = 2$.

(2) $E \ln X_1 = \frac{3}{7} \int_1^2 \ln x \cdot x^2 dx = \frac{3}{7} \int_0^{\ln 2} te^{3t} dt = \frac{8}{7} \ln 2 - \frac{1}{3}$, 根据强大数律

$$\frac{1}{n} \sum_{i=1}^n \ln X_i \rightarrow \frac{8}{7} \ln 2 - \frac{1}{3}, \text{ a.s.}$$

而 $\exp(\cdot)$ 是连续函数, 因此

$$\left(\prod_i X_i \right)^{\frac{1}{n}} = \exp \left(\frac{1}{n} \sum_{i=1}^n \ln X_i \right) \rightarrow \exp \left(\frac{8}{7} \ln 2 - \frac{1}{3} \right) = 2^{\frac{8}{7}} e^{-\frac{1}{3}}, \text{ a.s.}$$

三、(10 分) $(X, Y) \sim f(x, y) = \frac{1}{4} \left[1 + \frac{1}{2} xy (x^2 - y^2) \right], |x| < 1, |y| < 1$, 求 Y 的特征函数.

Solution: 先求 Y 的边缘密度, 根据题意, 有

$$\begin{aligned} f_Y(y) &= \frac{1}{4} \int_{-1}^1 \left[1 + \frac{1}{2}xy(x^2 - y^2) \right] dx \\ &= \frac{1}{4} \left[2 + \frac{1}{2}y \int_{-1}^1 x^3 dx - \frac{1}{2}y^3 \int_{-1}^1 x dx \right] \\ &= \frac{1}{2} \end{aligned}$$

因此, Y 的特征函数是

$$\begin{aligned} \varphi(t) &= Ee^{itY} = E \cos tY + iE \sin tY \\ &= \frac{1}{2} \int_{-1}^1 \cos ty dy \\ &= \frac{\sin t}{t} \end{aligned}$$

四、(10 分) $\{N(t), t \geq 0\}$ 是强度为 λ 的泊松过程, 当 $0 < t < s$ 时, 计算 $E[N(s) | N(t)]$ 以及当 $N(s) = n$ 时, $N(t)$ 的条件分布.

Solution: 法一: 先计算 $N(s) | N(t)$ 的条件分布, 再去计算期望.

$$P\{N(s) = n | N(t) = k\} = \frac{P\{N(s-t) = n-k, N(t) = k\}}{P\{N(t) = k\}} = P\{N(s-t) = n-k\},$$

有了条件分布, 可以计算出条件期望, 即

$$\begin{aligned} E[N(s) | N(t)] &= \sum_{n=N(t)}^{+\infty} n P\{N(s-t) = n - N(t)\} \\ &= \sum_{n=N(t)}^{+\infty} n \cdot \frac{(\lambda(s-t))^{n-N(t)}}{(n-N(t))!} e^{-\lambda(s-t)} \\ &= \lambda(s-t) + N(t) \end{aligned}$$

(注意: $\sum_{n=k}^{+\infty} n \frac{\lambda^{n-k}}{(n-k)!} = \lambda \sum_{n=k}^{+\infty} (n-k) \frac{\lambda^{n-k-1}}{(n-k)!} + k \sum_{n=k}^{+\infty} \frac{\lambda^{n-k}}{(n-k)!} = (\lambda + k)e^{-\lambda}$)

法二: 直接利用泊松过程的独立增量性去计算期望.

$$\begin{aligned} E[N(s) | N(t)] &= E[N(s) - N(t) | N(t)] + E[N(t) | N(t)] \\ &= E[N(s-t) | N(t)] + N(t) \\ &= \lambda(s-t) + N(t) \end{aligned}$$

下面计算 $N(s) = n$ 时, $N(t)$ 的条件分布:

$$\begin{aligned} P\{N(t) = k | N(s) = n\} &= \frac{P\{N(s) = n | N(t) = k\} P\{N(t) = k\}}{P\{N(s) = n\}} \\ &= \frac{P\{N(s-t) = n-k\} P\{N(t) = k\}}{P\{N(s) = n\}} \\ &= \frac{[\lambda(s-t)]^{n-k} e^{-\lambda(s-t)}}{(n-k)!} \cdot \frac{n!}{(\lambda s)^n e^{-\lambda s}} \cdot \frac{(\lambda t)^k e^{-\lambda t}}{k!} \\ &= C_n^k \left(\frac{t}{s}\right)^k \left(\frac{s-t}{s}\right)^{n-k} \end{aligned}$$

五、(10 分) $A_1 \cup A_2 \cup A_3 = \Omega, P(A_1) = P(A_2) = P(A_3) = p$, 且三者不同时发生, 求 p 的范围.

Solution: 对于该题, 我们引入示性函数, 首先由于 $A_1 \cup A_2 \cup A_3 = \Omega$, 有

$$1 \leq I_{A_1} + I_{A_2} + I_{A_3},$$

其次, 由于三者不同时发生, 有

$$I_{A_1} + I_{A_2} + I_{A_3} \leq 2.$$

对上述两式求期望得:

$$1 \leq 3p \leq 2 \Rightarrow \frac{1}{3} \leq p \leq \frac{2}{3}.$$

再考虑构造两个模型使得等号成立:

(1) $\Omega = [0, 1), A_1 = [0, \frac{1}{3}), A_2 = [\frac{1}{3}, \frac{2}{3}), A_3 = [\frac{2}{3}, 1)$, 满足题意, 此时 $p = \frac{1}{3}$.

(2) $\Omega = [0, 1), A_1 = [0, \frac{2}{3}), A_2 = [\frac{1}{3}, 1), A_3 = [0, \frac{1}{3}) \cup [\frac{2}{3}, 1)$, 满足题意, 此时 $p = \frac{2}{3}$. 故 $\frac{1}{3} \leq p \leq \frac{2}{3}$. [注]: 对于给定一定条件, 求 p 的取值范围的题目, 解题思路是分两步走, 第一步是构造出不等式限定住 p 的取值范围, 第二步是构造出相应的模型使得等号成立.

六、(15 分) 总体 $X \sim B(1, p), x_1, \dots, x_n$ 为简单随机样本,

(1)(5 分) 求 p^m 的一致最小方差无偏估计 ($0 < m \leq n$);

(2)(5 分) 求 $P\left(\sum_{j=1}^{n-1} x_j > x_n\right)$ 的一致最小方差无偏估计;

(3)(5 分) 给出一种求 p 的区间估计的方法.

Solution:

(1) 我们知道两点分布有完全的充分统计量 $T = \sum_{i=1}^n x_i \sim B(n, p)$, 现在我们去考虑一个服从 $B(n-m, p)$ 的随机变量 X 的分布列的和, 即

$$\sum_{k=0}^{n-m} \frac{(n-m)!}{k!(n-m-k)!} p^k (1-p)^{n-m-k} = 1,$$

适当作下标的变形, 即为

$$\sum_{k=m}^n \frac{(n-m)!}{(k-m)!(n-k)!} p^{k-m} (1-p)^{n-k} = 1,$$

而 $\sum_{k=0}^{m-1} \frac{(n-m)!}{(k-m)!(n-k)!} p^{k-m} (1-p)^{n-k} \leq P\{X < 0\} = 0$, 所以

$$\sum_{k=0}^n \frac{(n-m)!}{(k-m)!(n-k)!} p^{k-m} (1-p)^{n-k} = 1,$$

左右同时乘 p^m 并注意到 $\frac{(n-m)!}{(k-m)!(n-k)!} = \frac{k \cdot (k-1) \cdots (k-m+1)}{n \cdot (n-1) \cdots (n-m+1)} \cdot \frac{n!}{k!(n-k)!}$, 故

$$\sum_{k=0}^n \frac{k \cdot (k-1) \cdots (k-m+1)}{n \cdot (n-1) \cdots (n-m+1)} C_n^k p^k (1-p)^{n-k} = p^m,$$

即 $E \frac{T \cdot (T-1) \cdots (T-m+1)}{n \cdot (n-1) \cdots (n-m+1)} = p^m$, 这完全的充分统计量构造的, 故是 UMVUE.

(2) 首先有 $E\left(I\left[\sum_{j=1}^{n-1} X_j > X_n\right]\right) = P(\sum_{j=1}^{n-1} X_j > X_n)$. 故由 L-S 定理可知, $E\left(I\left[\sum_{j=1}^{n-1} X_j > X_n\right] \mid T\right)$ 为 $P\left(\sum_{j=1}^{n-1} X_j > X_n\right)$ 的 UMVUE. 当 $T = 0$ 时, 有

$$E\left(I\left[\sum_{j=1}^{n-1} X_j > X_n\right] \mid T = 0\right) = \frac{P\left(\sum_{j=1}^{n-1} X_j > X_n, \sum_{j=1}^n X_j = 0\right)}{P(\sum_{j=1}^n X_j = 0)} = 0.$$

当 $T = 1$ 时, 有

$$\begin{aligned} E \left(I \left[\sum_{j=1}^{n-1} X_j > X_n \right] \mid T = 1 \right) &= \frac{P \left(\sum_{j=1}^{n-1} X_j > X_n, \sum_{j=1}^n X_j = 1 \right)}{P \left(\sum_{j=1}^n X_j = 1 \right)} \\ &= \frac{P \left(\sum_{j=1}^{n-1} X_j = 1 \right) P(X_n = 0)}{P \left(\sum_{j=1}^n X_j = 1 \right)} \\ &= \frac{C_{n-1}^1 \cdot p^1 \cdot (1-p)^{n-2} \cdot (1-p)}{C_n^1 \cdot p^1 \cdot (1-p)^{n-1}} = \frac{n-1}{n}. \end{aligned}$$

当 $T = 2$ 时, 有

$$\begin{aligned} E \left(I \left[\sum_{j=1}^{n-1} X_j > X_n \right] \mid T = 2 \right) &= \frac{P \left(\sum_{j=1}^{n-1} X_j > X_n, \sum_{j=1}^n X_j = 2 \right)}{P \left(\sum_{j=1}^n X_j = 2 \right)} \\ &= \frac{P \left(\sum_{j=1}^{n-1} X_j = 2 \right) P(X_n = 0)}{P \left(\sum_{j=1}^n X_j = 2 \right)} \\ &= \frac{C_{n-1}^2 \cdot p^2 \cdot (1-p)^{n-2} \cdot (1-p)}{C_n^2 \cdot p^2 \cdot (1-p)^{n-1}} = \frac{n-2}{n}. \end{aligned}$$

当 $T \geq 3$ 时, 有

$$E \left(I \left[\sum_{j=1}^{n-1} X_j > X_n \right] \mid T = 3 \right) = \frac{P \left(\sum_{j=1}^{n-1} X_j > X_n, \sum_{j=1}^n X_j = 3 \right)}{P \left(\sum_{j=1}^n X_j = 3 \right)} = 1.$$

综上所述

$$V(T) = \begin{cases} 0, & T = 0 \\ \frac{n-1}{n}, & T = 1 \\ \frac{n-2}{n}, & T = 2 \\ 1, & T \geq 3 \end{cases}$$

是 $P \left(\sum_{j=1}^{n-1} X_j > X_n \right)$ 的 UMVUE.

(3) [法一: 正态近似] 当样本量较大时, 根据中心极限定理, 近似有 $\frac{\sqrt{n}(\bar{x}-p)}{\sqrt{p(1-p)}} \sim (0, 1)$, 但是由于 p 本身就是待估参数, 根据强大数律知道 $\bar{x} \rightarrow p$, a.s., 故近似有

$$\frac{\sqrt{n}(\bar{x}-p)}{\sqrt{\bar{x}(1-\bar{x})}} \sim N(0, 1)$$

因此 p 的水平为 α 的置信区间为

$$\left[\bar{x} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}, \bar{x} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \right].$$

[法二: 利用 Beta 分布] 考虑到恒等式:

$$\begin{aligned} \sum_{i=k}^n C_n^i p^i (1-p)^{n-i} &= \int_0^p \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k} dx, \\ \sum_{i=0}^k C_n^i p^i (1-p)^{n-i} &= \int_p^1 \frac{n!}{k!(n-k-1)!} x^k (1-x)^{n-k-1} dx, \end{aligned}$$

我们去考虑两个单侧区间, 使得 $p \in [0, p_1], p \in [p_2, 1]$ 的概率都是 $\frac{\alpha}{2}$. 如果样本发生了 $\sum_{i=1}^n x_i = n_0$, 那么我们应该找到一个根 p_1 , 使得

$$\frac{\alpha}{2} = \sum_{i=n_0}^n C_n^i p^i (1-p)^{n-i} = \int_0^p \frac{n!}{(n_0-1)!(n-n_0)!} x^{n_0-1} (1-x)^{n-n_0} dx,$$

而等式右侧的积分恰好是 Beta 分布的积分, 故 $p_1 = \text{Beta}_{\frac{\alpha}{2}}(n_0, n - n_0 + 1)$, 同理我们应该找到一个根 p_2 , 使得

$$\frac{\alpha}{2} = \int_p^1 \frac{n!}{n_0!(n-n_0-1)!} x^{n_0} (1-x)^{n-n_0-1} dx,$$

解得 $p_2 = \text{Beta}_{1-\frac{\alpha}{2}}(n_0 + 1, n - n_0)$, 故 p 的水平为 α 的置信区间为

$$\left[\text{Beta}_{\frac{\alpha}{2}}(n_0, n - n_0 + 1), \text{Beta}_{1-\frac{\alpha}{2}}(n_0 + 1, n - n_0) \right].$$

七、(10 分) 现有正态分布 $N(\mu, 1)$ 的 n 个样本 $x_1, \dots, x_n$, 取值小于 0 时记为 1, 否则记为 0, 求 μ 的 MLE

Solution: 由于 $P\{x_1 = 1\} = P\{X < 0\} = P\{X - \mu < -\mu\} = \Phi(-\mu)$, 我们可以看出 $\bar{x}$ 是 $\Phi(-\mu)$ 的 MLE, 现在根据 MLE 的不变性可以得出:

$$-\Phi^{-1}(\bar{x}) \text{ 是 } \mu \text{ 的 MLE.}$$

八、(10 分) 叙述并证明 Neyman-Pearson 引理.

Solution: 该题重复考察多次, 不再赘述.

九、(15 分) $Y, X_1, \dots, X_n$ 是方差有限的随机变量, $EY = \mu, EX_i = \mu_i, X$ 的协方差矩阵 Σ 正定, $C = (\text{Cov}(X_1, Y), \dots, \text{Cov}(X_n, Y))$, 求常数 $b_0, b_1, \dots, b_n$ 使得 $E[Y - b_0 - b_1 X_1 - \dots - b_n X_n]^2$ 达到最小.

Solution: 解法一: 记 $Q = E[Y - b_0 - b_1 X_1 - \dots - b_n X_n]^2$, 由于协方差存在, 可以进行积分号下的求导, 基于此建立正规方程组:

$$\begin{cases} \frac{\partial Q}{\partial b_0} = -2E[Y - b_0 - b_1 X_1 - \dots - b_n X_n] = 0 \\ \frac{\partial Q}{\partial b_i} = -2EX_i[Y - b_0 - b_1 X_1 - \dots - b_n X_n] \stackrel{\text{let}}{=} 0, i = 1, 2, \dots, n \end{cases}$$

解关于 b_0 的式子, 得到 $EY = b_0 + b_1 EX_1 + \dots + b_n EX_n$, 故有

$$EX_i[EY - b_0 - b_1 EX_1 - \dots - b_n EX_n] = 0, i = 1, 2, \dots, n.$$

所以关于 b_i 的式子就等价于 $\text{Cov}(X_i, Y - b_0 - b_1 X_1 - \dots - b_n X_n) = 0$, 即

$$\text{Cov}(X_i, X_1)b_1 + \dots + \text{Cov}(X_i, X_n)b_n = \text{Cov}(X_i, Y),$$

将 n 个式子联立就得到了线性方程组:

$$\Sigma B = C^T,$$

故 $(b_1, b_2, \dots, b_n)^T = \Sigma^{-1}C^T, b_0 = EY - b_1 EX_1 - \dots - b_n EX_n$.

解法二: 显然 $Q = E\left[(Y - EY) + (EY - b_0 - \sum_{i=1}^n b_i EX_i) - (\sum_{i=1}^n b_i (X_i - EX_i))\right]^2$, 将平方打开, 注意到 $EY - b_0 - \sum_{i=1}^n b_i EX_i$ 可以看作常数 A , 故

$$Q = E\left[(Y - EY)^2 + \left(\sum_{i=1}^n b_i (X_i - EX_i)\right)^2 - 2\sum_{i=1}^n b_i (X_i - EX_i)(Y - EY) + A^2\right]$$

即 $Q = \sum_{i=1}^n \sum_{j=1}^n b_i b_j \text{Cov}(X_i, X_j) - 2\sum_{i=1}^n b_i \text{Cov}(X_i, Y) + \text{Var}(Y) + A^2$, 想要使 Q 达最小, 必须让 $A = 0$ 并让前方的二次函数各个偏导为 0, 也能得到一样的线性方程组, 便不赘述.

北京大学数院-431 金融学综合-2019 年

一、(10 分) 盒中有 10 个乒乓球, 2 个被用过, 其余的都是新的. 第一次比赛时从中任取 3 个球用, 比赛结束后放回. 第二次比赛再取 3 个.

(1)(5 分) 求第二次比赛取得都是新球的概率;

(2)(5 分) 已知第二次比赛取得都是新球, 求第一次取得都是新球的概率.

Solution:

(1) 首先计算第一次比赛后, 盒中新球数量的分布情况:

$$P(X_1 = 5) = \frac{8 \cdot 7 \cdot 6}{10 \cdot 9 \cdot 8} = \frac{7}{15}, \quad P(X_1 = 6) = \frac{3 \cdot 8 \cdot 7 \cdot 2}{10 \cdot 9 \cdot 8} = \frac{7}{15}, \quad P(X_1 = 7) = \frac{1}{15}.$$

根据全概率公式:

$$P(A) = \frac{7}{15} \cdot \frac{5 \cdot 4 \cdot 3}{10 \cdot 9 \cdot 8} + \frac{7}{15} \cdot \frac{6 \cdot 4 \cdot 5}{10 \cdot 9 \cdot 8} + \frac{1}{15} \cdot \frac{7 \cdot 6 \cdot 5}{10 \cdot 9 \cdot 8} = 0.136111$$

故第二次比赛取得都是新球的概率是 13.61%.

(2) 根据贝叶斯公式:

$$P(X_1 = 5 | A) = \frac{\frac{7}{15} \cdot \frac{5 \cdot 4 \cdot 3}{10 \cdot 9 \cdot 8}}{P(A)} = 0.285714$$

故已知第一次比赛取得都是新球, 则第一次取得的都是新球的概率是 28.57%.

二、(10 分) 已知随机变量 X 的概率密度 $f(x) = \frac{1}{b} e^{-x^2+2x}, x \in R$,

(1)(5 分) 求 b ;

(2)(5 分) 求 $E(e^{1-X^2})$.

Solution:

(1) $f(x) = \frac{1}{b} e \times e^{-\frac{(x-1)^2}{2 \cdot \frac{1}{2}}}$, 因此为满足概率的正则性, $\frac{1}{b} e = \frac{1}{\sqrt{2\pi \cdot \frac{1}{2}}}$, 因为

$$\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi \cdot \frac{1}{2}}} e^{-\frac{(x-1)^2}{2 \cdot \frac{1}{2}}} dx = 1, \text{ 故 } b = \sqrt{\pi} e$$

(2)

$$\begin{aligned} E(e^{1-X^2}) &= \int_{-\infty}^{+\infty} e^{1-x^2} \frac{1}{e\sqrt{\pi}} e^{-x^2+2x} dx = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{\pi}} e^{-2x^2+2x} dx \\ &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{\pi}} e^{-2(x^2-x+\frac{1}{4})+\frac{1}{2}} dx = \frac{e^{\frac{1}{2}}}{\sqrt{2}} \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi \cdot \frac{1}{4}}} e^{-\frac{(x-\frac{1}{2})^2}{2 \cdot \frac{1}{4}}} dx = \sqrt{\frac{e}{2}} \end{aligned}$$

三、(10 分) $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$, 指出 $X+Y$ 和 $X-Y$ 相互独立的充要条件.

Solution: 首先, 二维正态分布各分量的线性组合仍然是正态分布, 所以 $X+Y, X-Y$ 都仍然是正态分布. 其次, 正态分布的独立与不相关是等价的, 我们去考虑其协方差.

$$\text{Cov}(X+Y, X-Y) = \sigma_1^2 - \sigma_2^2,$$

因此我们可以认为 $X+Y, X-Y$ 相互独立的充要条件是 X, Y 的方差相等.

(1) $X+Y, X-Y$ 相互独立 $\Rightarrow \text{Cov}(X+Y, X-Y) = 0 \Rightarrow \sigma_1^2 = \sigma_2^2$.

(2) $\sigma_1^2 = \sigma_2^2 \Rightarrow \text{Cov}(X+Y, X-Y) = 0 \Rightarrow X+Y, X-Y$ 相互独立.

四、(10 分) 独立序列 $\{X_n\}$, 其子列 $\{X_{2n-1}\}$ 独立同分布, $EX_1 = 0, DX_1 = 1$, 子列 $\{X_{2n}\}$ 独立同分布, $P(X_2 = 1) = P(X_2 = -1) = \frac{1}{2}$. 证明

$$S_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n X_{2i-1} X_{2i}$$

按分布收敛到标准正态分布.

Solution: 令 $Y_n = X_{2n-1}X_{2n}$, 很显然 $\{Y_n\}$ 是独立同分布序列,

$$EY_n = EX_{2n-1}EX_{2n} = 0, DY_n = EY_n^2 = EX_{2n-1}^2EX_{2n}^2 = 1,$$

根据独立同分场合的中心极限定理,

$$S_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i \xrightarrow{d} N(0, 1).$$

五、(10 分) 公司 1 和公司 2 是否违约相互独立, 发生违约的次数都是强度为 λ 的泊松过程, 记公司 i 第一次发生违约的时间为 T_i .

(1)(2 分) 到 t 时刻未发生违约的概率;

(2)(2 分) 求违约风险 $h_i(t) = \lim_{\Delta t \rightarrow 0} \frac{P\{T_i < t + \Delta t | T_i > t\}}{\Delta t}$;

(3)(3 分) 求 $\text{Cov}(\min\{T_1, T_2\}, \max\{T_1, T_2\})$;

(4)(3 分) 已知 $T_1 + T_2 = t$, 求 T_1 的条件分布.

Solution:

(1)

$$P\{N(t) = 0\} = P\{\min\{T_1, T_2\} > t\} = e^{-2\lambda t}.$$

(2) $P\{T_1 < t + \Delta t | T_1 > t\} = \frac{P\{t < T_1 \leq t + \Delta t\}}{P\{T_1 > t\}} = 1 - e^{-\lambda \Delta t}$, 故违约风险 $h_i(t) = \lim_{\Delta t \rightarrow 0} \frac{1 - e^{-\lambda \Delta t}}{\Delta t} = \lambda$.

(3) 想计算 $\text{Cov}(\min\{T_1, T_2\}, \max\{T_1, T_2\})$, 就是要计算 $E(\min\{T_1, T_2\} \max\{T_1, T_2\})$ 和 $E(\min\{T_1, T_2\})E(\max\{T_1, T_2\})$,

而

$$E(\min\{T_1, T_2\} \max\{T_1, T_2\}) = \int_0^{+\infty} \int_x^{+\infty} \lambda^2 x y e^{-\lambda(x+y)} dy dx + \int_0^{+\infty} \int_0^x \lambda^2 x y e^{-\lambda(x+y)} dy dx$$

实际上, $E(\min\{T_1, T_2\} \max\{T_1, T_2\}) = ET_1 T_2 = ET_1 E T_2 = \frac{1}{\lambda^2}$. 同时, $\min\{T_1, T_2\} \sim \text{Exp}(2\lambda)$, $E(\min\{T_1, T_2\}) = \frac{1}{2\lambda}$, 而

$$E(\min\{T_1, T_2\} + \max\{T_1, T_2\}) = E(T_1 + T_2) = \frac{2}{\lambda}, \text{ 故 } E(\max\{T_1, T_2\}) = \frac{3}{2\lambda},$$

因此 $\text{Cov}(\min\{T_1, T_2\}, \max\{T_1, T_2\}) = \frac{1}{\lambda^2} - \frac{3}{4\lambda^2} = \frac{1}{4\lambda^2}$.

(4) $P\{T_1 = t_1, T_1 + T_2 = t\} = P\{T_1 = t_1, T_2 = t - t_1\} = \lambda^2 e^{-\lambda t} dt_1 dt, t > t_1 > 0$ 所以 $(T_1, T_1 + T_2)$ 的联合概率密度是 $\lambda^2 e^{-\lambda t}$, 将 t_1 积分后得到 $T_1 + T_2$ 的边缘密度,

$$f(t) = \int_0^t \lambda^2 e^{-\lambda t} dt_1 = \lambda^2 t e^{-\lambda t}, t > 0,$$

故条件分布为

$$f_{T_1|T_1+T_2}(t_1 | t) = \frac{1}{t}, t > t_1 > 0.$$

六、(10 分) 总体 $X \sim f(x) = \theta x^{\theta-1} I[0 < x < 1]$, 求矩估计并证明其强相合性.

Solution:

$$EX = \int_0^1 \theta x^\theta dx = \frac{\theta}{\theta+1}, \Rightarrow \theta = \frac{EX}{1-EX}, \text{ 用样本矩代替总体矩得到矩估计:}$$

$$\hat{\theta} = \frac{\bar{X}}{1-\bar{X}}, \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

现验证其相合性, 根据强大数律, $\bar{X} \rightarrow EX$, a.s., 故 $\hat{\theta} \rightarrow \frac{EX}{1-EX} = \theta$, a.s.

七、(10 分) 人群中支持某政策的比例为 p , 未知. 随机抽 n 人, 设有 x 人支持, $\hat{p} = \frac{x}{n}$ 为样本支持率.

(1)(5 分) 用正态近似法给出 p 的 95% 置信区间;

(2)(5 分) 要求置信区间长度小于 0.2, n 至少需要多大.

Solution:

(1) 根据独立同分布场合的中心极限定理, 当 n 较大时, 近似地有

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right), \text{ 即 } \sqrt{n} \frac{\hat{p} - p}{\sqrt{p(1-p)}} \sim N(0, 1),$$

但是由于 p 是未知的, 故用 $\hat{p}$ 取代分母的 p (根据强大数律, $\hat{p} \rightarrow p, a.s.$, 因此该取代是合理的), 故近似地有 $\sqrt{n} \frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}} \sim N(0, 1)$, 因此 p 的 95% 置信区间是

$$\left[\hat{p} - 1.96 \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}, \hat{p} + 1.96 \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \right].$$

(2) 置信区间长度 $L = 3.92 \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \leq \frac{1.96}{\sqrt{n}}$ (注意到 $\hat{p}(1-\hat{p}) \leq \frac{1}{4}$), 令 $\frac{1.96}{\sqrt{n}} \leq 0.2$, 解得 $n \geq \left(\frac{1.96}{0.2}\right)^2 = 9.8^2 = 96.04$, 故至少需要 97 个调查对象.

八、(10 分) 叙述 2×2 的列联表独立性检验.

Solution: 假设有两个离散分布总体 X, Y , 分别有 m, n 种取值, 根据样本得到的信息: 事件 $(X = x_i, Y = y_j)$ 被观测到的次数是 N_{ij} 次, $i = 1, 2, \dots, m, j = 1, 2, \dots, n$. 根据样本信息来判断 X, Y 是否独立. 其被称为列联表的原因就是该问题可以被写成一个类似二元离散分布的列联表.

我们知道, 如果 X, Y 独立, 那么应该可以在样本中观察到 $\frac{N_{ij}}{N} = \frac{N_{i.}}{N} \cdot \frac{N_{.j}}{N}$ 对所有 i, j 都近似成立, 也就是在直观上讲如果 $\sum_{i=1}^m \sum_{j=1}^n (N_{ij} - N_{i.} \cdot N_{.j} / N)^2$ 越小, 我们就认为越有可能是独立的. 但实际上, 每个事件的偏离程度是不一样的, 也就是 $N_{i.} \cdot N_{.j}$ 的量级越大, 则它本身发生偏差的可能性就越大, 故我们要标准化每个事件的偏离程度, 即用 $\frac{1}{N_{i.} \cdot N_{.j}}$ 作为每个事件的权重, 如果 $\sum_{i=1}^m \sum_{j=1}^n \frac{(N_{ij} - N_{i.} \cdot N_{.j} / N)^2}{N_{i.} \cdot N_{.j}}$ 越小, 我们就认为越有可能是独立的. 恰好, 统计量 $\sum_{i=1}^m \sum_{j=1}^n \frac{(N_{ij} - N_{i.} \cdot N_{.j} / N)^2}{N_{i.} \cdot N_{.j}}$ 近似服从 $\chi^2((m-1)(n-1))$ (可以自己思考一下自由度的问题, 课程和书本都有), 这就给了我们一个很好的用来检验独立性的统计量. 这就是 $m \times n$ 的列联表独立性检验的方法.

九、(10 分) 设有线性回归模型

$$Y_{ij} = \alpha_i + \beta X_{ij} + \varepsilon_{ij}, \quad i = 1, 2, \dots, m, \quad j = 1, 2, \dots, n,$$

其中误差项 ε_{ij} 独立同服从正态 $N(0, \sigma^2)$, $\alpha_1, \dots, \alpha_m, \beta$ 和 σ^2 是未知参数. 求 $(\alpha_1, \dots, \alpha_m, \beta)$ 的最大似然估计.

Solution: 对数似然函数为

$$\ell(\alpha_1, \dots, \alpha_m, \beta, \sigma^2) = A - \frac{mn}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^m \sum_{j=1}^n (Y_{ij} - \alpha_i - \beta X_{ij})^2,$$

欲求 $(\alpha_1, \dots, \alpha_m, \beta)$ 的最大似然估计, 等价于极小化残差平方和

$$Q(\alpha_1, \dots, \alpha_m, \beta) = \sum_{i=1}^m \sum_{j=1}^n (Y_{ij} - \alpha_i - \beta X_{ij})^2,$$

求导得

$$\frac{\partial Q}{\partial \alpha_i} = -2 \sum_{j=1}^n (Y_{ij} - \alpha_i - \beta X_{ij}), \quad \frac{\partial Q}{\partial \beta} = -2 \sum_{i=1}^m \sum_{j=1}^n X_{ij} (Y_{ij} - \alpha_i - \beta X_{ij}),$$

解得

$$\begin{cases} \hat{\beta} = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^m \sum_{j=1}^n (X_{ij} - \bar{X}_{i.})(Y_{ij} - \bar{Y}_{i.})}{\sum_{i=1}^m \sum_{j=1}^n (X_{ij} - \bar{X}_{i.})^2}, \\ \hat{\alpha}_i = \bar{Y}_{i.} - \hat{\beta} \bar{X}_{i.}, \quad i = 1, 2, \dots, m. \end{cases}$$

十、(10 分) $x_1, \dots, x_n$ 不全为 0, ε_i , i.i.d. $\sim N(0, \sigma^2)$, 有观测值 (x_i, y_i) 满足 $y_i = bx_i + \varepsilon_i$, b, σ^2 未知.

(1) 求 b, σ^2 最大似然估计;

(2) 求 $\hat{b}$ 的分布;

(3) $H_0: b = 0$ vs $H_1: b \neq 0$, 构造水平为 α 的拒绝域.

Solution:

(1) 首先由于 $y_i = bx_i + \varepsilon_i \sim N(bx_i, \sigma^2)$, 记 $\delta = \sigma^2$, 我们写出似然函数

$$L(y_1, \dots, y_n; b, \delta) = (2\pi\delta)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\delta} \sum_{i=1}^n (y_i - bx_i)^2 \right\} \propto \delta^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\delta} \sum_{i=1}^n (y_i - bx_i)^2 \right\} \stackrel{\text{let}}{=} L_1$$

取对数, $\ln L_1 = -\frac{n}{2} \ln \delta - \frac{1}{2\delta} \sum_{i=1}^n (y_i - bx_i)^2$, 求偏导得到方程组:

$$\begin{cases} \frac{\partial \ln L_1}{\partial b} = \frac{1}{\delta} \sum_{i=1}^n (y_i - bx_i) x_i = 0 \\ \frac{\partial \ln L_1}{\partial \delta} = -\frac{n}{2\delta} + \frac{1}{2\delta^2} \sum_{i=1}^n (y_i - bx_i)^2 = 0 \end{cases}$$

解得, $\hat{b} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{b}x_i)^2$.

(2) 由于多元正态分布分量的线性组合还是正态分布, 而

$$E \sum_{i=1}^n x_i y_i = b \sum_{i=1}^n x_i^2, D \sum_{i=1}^n x_i y_i = \sigma^2 \sum_{i=1}^n x_i^2,$$

故 $E \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} = b, D \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}$, 这意味着 $\hat{b} \sim N\left(b, \frac{\sigma^2}{\sum_{i=1}^n x_i^2}\right)$.

(3) 根据第二题的结论, 我们知道

$$\sqrt{\sum_{i=1}^n x_i^2} \frac{\hat{b} - b}{\sigma} \sim N(0, 1),$$

但 σ 是未知的, 但根据 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{b}x_i)^2$, $\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1)$, 因此用 $\tilde{\sigma}^2 = \frac{n}{n-1}\hat{\sigma}^2$ 代替 σ^2 后, 有统计量

$$T = \sqrt{\sum_{i=1}^n x_i^2} \frac{\hat{b} - b}{\tilde{\sigma}} \sim t(n-1).$$

当原假设成立时, $T = \sqrt{\sum_{i=1}^n x_i^2} \hat{b} \sim t(n-1)$, 而且由于 $\hat{b}$ 是 b 的估计量, T 的绝对值应该相当小才对, 如果 T 的绝对值很大, 我们有理由拒绝原假设, 因此拒绝域为

$$W = \left\{ \left| \sqrt{\sum_{i=1}^n x_i^2} \frac{\hat{b}}{\tilde{\sigma}} \right| > t_{1-\frac{\alpha}{2}}(n-1) \right\}$$

北京大学数院-431 金融学综合-2020 年

一、(11 分) 已知 (X, Y) 服从二元正态分布, X, Y 同分布, F 是 X 的分布函数, $EX = 1, F(0) = \frac{1}{10}$.

(1)(5 分) 求 $P(1 < Y < 2)$;

(2)(6 分) 若 $P(Y < 2 | X \geq 2) = \frac{1}{2}$, 求 $P(\max\{X, Y\} > 2)$.

Solution:

(1) 根据题设可以得到 $P\{Y < 0\} = \frac{1}{10}, P\{Y < 1\} = \frac{1}{2}$, 所以 $P\{0 < Y < 1\} = \frac{2}{5}$, 根据正态分布的对称性, $P\{1 < Y < 2\} = \frac{2}{5}$.

(2) $\frac{1}{2} = P\{Y < 2 | X \geq 2\} = \frac{P\{X \geq 2, Y < 2\}}{P\{X \geq 2\}}$, 由此见得

$$P\{X \geq 2, Y < 2\} = \frac{1}{2}P\{X \geq 2\} = \frac{1}{2} \cdot \frac{1}{10} = \frac{1}{20},$$

故 $P\{X \leq 2, Y \leq 2\} = P\{X < 2, Y < 2\} = P\{Y < 2\} - P\{X \geq 2, Y < 2\} = \frac{17}{20}$, 因此

$$P(\max\{X, Y\} > 2) = 1 - \frac{17}{20} = \frac{3}{20}.$$

二、(11 分) $Y_n = \frac{1}{n} \sum_{i=1}^n e^{2X_i}, X_1, X_2, \dots, X_n$ 相互独立且同服从 $U(0, 1)$.

(1)(5 分) 求 $EY_n, \text{Var}(Y_n)$;

(2)(6 分) 证明 Y_n 依概率收敛到某个常数 y , 并求 y .

Solution:

(1) $EY_n = Ee^{2X_1} = \int_0^1 e^{2x} dx = \frac{e^2-1}{2}, Ee^{4X_1} = \int_0^1 e^{4x} dx = \frac{e^4-1}{4}$, 故

$$De^{2X_1} = Ee^{4X_1} - [Ee^{2X_1}]^2 = \frac{e^2-1}{2},$$

因此 $DY_n = \frac{1}{n} De^{2X_1} = \frac{e^2-1}{2n}$.

(2) 利用切比雪夫不等式, 对任意 $\varepsilon > 0$,

$$P\left\{\left|Y_n - \frac{e^2-1}{2}\right| > \varepsilon\right\} \leq \frac{DY_n}{\varepsilon^2} = \frac{e^2-1}{\varepsilon^2} \cdot \frac{1}{n} \rightarrow 0,$$

因此 Y_n 依概率收敛到 $\frac{e^2-1}{2}$. (注: 或直接使用大数定律)

三、(14 分) $\Omega = \{\omega_1, \omega_2, \omega_3\}, P\{\omega_1\} = \frac{1}{3}, P\{\omega_2\} = \frac{1}{6}, P\{\omega_3\} = \frac{1}{2}, X(\omega_1) = 2, X(\omega_2) = X(\omega_3) = 0$.

(1)(4 分) 求 X 的分布函数;

(2)(5 分) 已知 $EY = 2, P(Y = X | X > 0) = 1, P(Y = X | X = 0) = \frac{3}{4}$, 求 Y 的概率分布;

(3)(5 分) 证明 X, Y 不独立也不相关.

Solution:

(1) $P\{X = 0\} = P\{\omega_2\} + P\{\omega_3\} = \frac{2}{3}, P\{X = 2\} = P\{\omega_1\} = \frac{1}{3}$,

$$\text{故 } F(x) = \begin{cases} 0, & x < 0, \\ \frac{2}{3}, & 0 \leq x < 2, \\ 1, & 2 \leq x. \end{cases}$$

(2) $1 = P\{Y = X | X > 0\} = P\{Y = 2 | X = 2\}$, 这意味着 $Y(\omega_1) = 2, \frac{3}{4} = P\{Y = 0 | X = 0\}$, 这意味着 $Y(\omega_2), Y(\omega_3)$ 中有一个是 0, 我们发现

$$\frac{P\{\omega_3\}}{P\{\omega_2\} + P\{\omega_3\}} = \frac{3}{4}, \frac{P\{\omega_2\}}{P\{\omega_2\} + P\{\omega_3\}} = \frac{1}{4}$$

因此 $Y(\omega_3) = 0$. 为使得 $EY = 2$, 必须要满足

$$2 = 2 \cdot \frac{1}{3} + Y(\omega_2) \cdot \frac{1}{6} + 0 \cdot \frac{1}{2} \Rightarrow Y(\omega_2) = 8$$

因此 Y 的概率分布是

Y	0	2	8
P	1/2	1/3	1/6

(3) 先判断独立性, 由于 $\frac{3}{4} = P\{Y = 0 \mid X = 0\} \neq P\{Y = 0\} = \frac{1}{2}$, 因此不独立. 再判断相关性, 首先 $EX = \frac{2}{3}, EY = 2$, 而

$$(X, Y)_{\omega_1} = (2, 2), (X, Y)_{\omega_2} = (0, 8), (X, Y)_{\omega_3} = (0, 0),$$

因此 $EXY = \frac{4}{3} = EXEY$, 不相关.

四、(14 分) $X \sim \text{Exp}(\lambda), \lambda > 1, Y_k = \begin{cases} -1, & X \leq k \\ 0, & k < X \leq 2k, k = 1, 2 \\ 1, & X > 2k \end{cases}$

(1)(7 分) 求 (Y_1, Y_2) 的联合分布;

(2)(7 分) 求 a 的值 ($a \in [1, 10]$), 使得 $E(aY_1 + Y_2)$ 最大.

Solution:

(1) 可以直接将 (Y_1, Y_2) 的联合分布转化为 X 的分布, 先画出联合分布表:

	$Y_1 = -1$	$Y_1 = 0$	$Y_1 = 1$
$Y_2 = -1$	$PX \leq 1$	$P1 < X \leq 2$	0
$Y_2 = 0$	0	0	$P2 < X \leq 4$
$Y_2 = 1$	0	0	$P4 < X$

现在, 只需要计算对应事件的概率即可:

$$P\{X \leq 1\} = 1 - e^{-\lambda}, P\{1 < X \leq 2\} = e^{-\lambda} - e^{-2\lambda}, \\ P\{2 < X \leq 4\} = e^{-2\lambda} - e^{-4\lambda}, P\{4 < X\} = e^{-4\lambda},$$

因此, (Y_1, Y_2) 的联合分布是

	$Y_1 = -1$	$Y_1 = 0$	$Y_1 = 1$
$Y_2 = -1$	$1 - e^{-\lambda}$	$e^{-\lambda} - e^{-2\lambda}$	0
$Y_2 = 0$	0	0	$e^{-2\lambda} - e^{-4\lambda}$
$Y_2 = 1$	0	0	$e^{-4\lambda}$

(2) 令 $Z = aY_1 + Y_2$, 画出其分布列:

Z	$-a-1$	-1	a	$a+1$
P	$1 - e^{-\lambda}$	$e^{-\lambda} - e^{-2\lambda}$	$e^{-2\lambda} - e^{-4\lambda}$	$e^{-4\lambda}$

故 $EZ = -(a+1)(1 - e^{-\lambda}) - (e^{-\lambda} - e^{-2\lambda}) + a(e^{-2\lambda} - e^{-4\lambda}) + (a+1)e^{-4\lambda}$

$$= (e^{-2\lambda} + e^{-\lambda} - 1)a + (e^{-4\lambda} + e^{-2\lambda} - 1).$$

现在要取讨论 $e^{-2\lambda} + e^{-\lambda} - 1$ 的取值, 令 $f(t) = t^2 + t - 1, t \in (0, e^{-1})$, 可以看出 $f(t)$ 与 $e^{-2\lambda} + e^{-\lambda} - 1$ 的取值范围是一样的, $f(t) = t^2 + t - 1 = (t + \frac{1}{2})^2 - \frac{3}{4}$, 在其对称轴右侧单调递增, 且

$$-\frac{3}{4} = f(0) < f(t) < f(e^{-1}) = e^{-2} + e^{-1} - 1 < 2e^{-1} - 1 < 2 \cdot 2^{-1} - 1 = 0,$$

故 $e^{-2\lambda} + e^{-\lambda} - 1 < 0$, 所以 $E[aY_1 + Y_2]$ 关于 a 单调递减, 所以取 $a = 1$.

五、(11 分) (1)(3 分) 解释最小方差无偏估计的含义;

(2)(2 分) 解释两类错误的含义;

(3)(3 分) 解释非参数检验的含义;

(4)(3 分) 解释回归分析中复相关系数的平方的含义.

Solution:

(1) 最小方差无偏估计是指在所有无偏估计中方差最小的, 或者说最小方差无偏估计是一个与任一零的无偏估计不相关的无偏估计. 最小方差无偏估计在几乎处处的意义下是唯一的.

(2) 如果给定假设检验问题: $H_0 : \theta \in \Theta_0$ vs $H_1 : \theta \in \Theta_1$, 设其拒绝域为 W . 第一类错误 (拒真错误) $\alpha(\theta) = P_\theta\{\vec{X} \in W\}$, 其中 $\theta \in \Theta_0$, 表示原假设为真, 但样本值由于随机性落入了拒绝域, 这时候我们得出了结论: 拒绝原假设. 第二类错误 (取伪错误) $\beta(\theta) = P_\theta\{\vec{X} \in \bar{W}\}$, 其中 $\theta \in \Theta_1$, 表示原假设为假, 但样本值由于随机性落入了接受域, 这时候我们得出了结论: 接受原假设.

(3) 参数检验是在总体分布形式已知的情况下, 对总体分布的参数如均值、方差等进行推断的方法. 但是, 在数据分析过程中, 由于种种原因, 人们往往无法对总体分布形态作简单假定, 此时参数检验的方法就不再适用了. 非参数检验正是一类基于这种考虑, 在总体分布未知或知道甚少, 的情况下, 利用样本数据对总体分布形态等进行推断的方法. 由于非参数检验方法在推断过程中不涉及有关总体分布的参数, 因而得名为“非参数”检验.

(4) 复相关系数是测量一个变量与其他多个变量之间线性相关程度的指标, 而在回归分析中复相关系数的平方恰恰就是我们常说的可决系数或拟合优度, 它表示的是整个模型的解释程度, 复相关系数的平方越大 (越接近 1) 则说明回归的解释力度越大.

六、(11 分) 可能出现三种情况 MM, MN, NN, 这三种情况出现的概率分别是 $p^2, 2p(1-p), (1-p)^2$, 一次实验中三种情况分别出现的次数是 n_1, n_2, n_3 , 且次数都 ≥ 10 次.

(1)(5 分) 求 p 的最大似然估计;

(2)(6 分) 试给出检验问题

$$H_0 : MM : MN : NN = 1 : 2 : 1$$

的水平为 α 的拒绝域 (备择假设是其对立).

Solution:

(1) 似然函数 $L = p^{2n_1} \cdot [2p(1-p)]^{n_2} \cdot (1-p)^{2n_3} \propto p^{2n_1+n_2}(1-p)^{n_2+2n_3} = L_1$,

$$\ln L_1 = (2n_1 + n_2) \ln p + (n_2 + 2n_3) \ln(1-p),$$

$\frac{\partial \ln L_1}{\partial p} = \frac{2n_1+n_2}{p} - \frac{n_2+2n_3}{1-p} = 0$, 解得 $\hat{p} = \frac{2n_1+n_2}{2n}$, 其中 $n = n_1 + n_2 + n_3$.

(2)[法一]: 首先原假设等价于 $H_0 : p = \frac{1}{2}$, 我们去考虑总体的矩母函数, 当取到 MM, MN, NN 时分别记作 $X = 1, 0, -1$, 因此可以得到 X 的矩母函数是:

$$Ee^{tX} = e^tp^2 + 2p(1-p) + e^{-t}(1-p)^2 = \left[e^{\frac{t}{2}}p + e^{-\frac{t}{2}}(1-p)\right]^2 = e^{-t} [e^tp + (1-p)]^2,$$

根据卷积公式, $\sum_{i=1}^n X_i$ 的矩母函数是 $e^{-nt} [e^tp + (1-p)]^{2n}$, 因此

$$Y = 2n_1 + n_2 = n + \sum_{i=1}^n X_i$$

的矩母函数是 $[e^t p + (1-p)]^{2n}$, 这恰好是 $B(2n, p)$ 的矩母函数, 因此 $Y \sim B(2n, p)$. 如果原假设成立, 那么 Y 的实际观测值 y_0 应该是与 n 比较接近的. 由于 Y 的分布是对称的, 我们去考虑一个双侧检验: 设 $\sum_{i=y_0}^{2n} C_{2n}^i p^i (1-p)^{2n-i} = \frac{\alpha}{2}$ 与 $\sum_{i=0}^{y_0} C_{2n}^i p^i (1-p)^{2n-i} = \frac{\alpha}{2}$ 的解分别是 $p_U(y_0), p_L(y_0)$, 如果 $p_U(y_0) \geq \frac{1}{2}$ 或 $p_L(y_0) \leq \frac{1}{2}$ 我们就拒绝掉原假设. 再次回想二项分布与 Beta 分布的前世今生, 我们知道

$$p_U(y_0) = \text{Beta}_{\frac{\alpha}{2}}(y_0, 2n - y_0 + 1), p_L(y_0) = \text{Beta}_{1-\frac{\alpha}{2}}(y_0 + 1, 2n - y_0),$$

因此拒绝域为 $W = \{p_U(2n_1 + n_2) \geq \frac{1}{2}\} \cup \{p_L(2n_1 + n_2) \leq \frac{1}{2}\}$.

[法二]: 由于有很多同学看不懂法一的答案, 考场上如果想不到用矩母函数, 我们也可以使用非参的优度检验方法, 尽管不是最优的方法. 在 Θ_0 下, 有 $p = 1/2$. 检验问题对应的 χ^2 统计量为

$$\chi^2 = \sum_{i=1}^3 \frac{(n\hat{p}_i - n_i)^2}{n\hat{p}_i} \underset{\Theta_0}{\approx} \chi^2(2)$$

故此时的拒绝域为 $W = \{\chi^2 > \chi_{1-\alpha}^2(2)\}$.

[注]: 使用拟合优度检验是不严谨的做法, 因为非参的方法没有用上题干中 $p^2, 2p(1-p), (1-p)^2$ 的信息, 但是在题意不明的情况下, 写成非参也是合情合理的.

七、(14 分) f 在 $\{(x_1, \dots, x_d) : 0 \leq x_i \leq 1, i = 1, \dots, d\}$ 上连续, 且

$$\theta = \int_0^1 \cdots \int_0^1 f(x_1, \dots, x_d) dx_1 \cdots dx_d$$

现有服从 $[0, 1]$ 上均匀分布的独立随机变量 $U_0, U_1, \dots, U_{nd-1}$, 令

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n f(U_{id}, U_{id+1}, \dots, U_{id+d-1}).$$

(1)(7 分) 证明 $\hat{\theta}$ 是 θ 的无偏、强相合估计;

(2)(7 分) 构造 θ 的近似 95% 置信区间.

Solution:

(1) 先说明其无偏性, 由于

$$E\hat{\theta} = \frac{1}{n} \sum_{i=0}^{n-1} Ef(U_{id}, \dots, U_{id+d-1}) = Ef(U_0, \dots, U_{d-1}) = \int_{[0,1]^d} f(x_1, \dots, x_d) dx_1 \cdots dx_d = \theta,$$

故 $\hat{\theta}$ 是无偏估计. 而 $\hat{\theta}$ 可以看作独立同分布的 n 项均值, 根据强大数律 $\hat{\theta}$ 是强相合估计.

(2) 因为 f 在 $[0, 1]^d$ 连续, 故 f^2 也在 $[0, 1]^d$ 连续, 因此积分 $\int_{[0,1]^d} f^2(x_1, \dots, x_d) dx_1 \cdots dx_d$ 存在, 令 $\sigma^2 = \int_{[0,1]^d} f^2 dx_1 \cdots dx_d - \theta^2$, 根据中心极限定理, 当 n 较大时, 近似有

$$\sqrt{n} \frac{\hat{\theta} - \theta}{\sigma} \sim N(0, 1),$$

为构造置信区间, 我们还需要得到 σ 的估计量, 令

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=0}^{n-1} [f(U_{id+1}, \dots, U_{id+d-1}) - \hat{\theta}]^2,$$

它是 σ 的相合估计量, 故当 n 较大时, 近似有 $\sqrt{n} \frac{\hat{\theta} - \theta}{\hat{\sigma}} \sim N(0, 1)$, 因此 θ 的近似 95% 置信区间是

$$\left[\hat{\theta} - 1.96 \frac{\hat{\sigma}}{\sqrt{n}}, \hat{\theta} + 1.96 \frac{\hat{\sigma}}{\sqrt{n}} \right]$$

八、(14 分) 已知 $y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$, 约束条件 $\sum_{i=1}^s \alpha_i = 0$, 对每个 $i = 1, 2, \dots, s$, 都有 r 个观测值, 残差相互独立服从 $N(0, \sigma^2)$, μ, α_i, σ^2 未知.

(1)(7 分) 求 μ, α_i 的最小二乘估计;

(2)(7 分) 给出 $H_0: \alpha_1 = \alpha_2 = \dots = \alpha_s = 0$ 的水平为 α 的否定域.

Solution:

(1) 令 $\theta_i = \mu + \alpha_i, i = 1, 2, \dots, s$, 这样可以减少一个参数. 则此时 $y_{ij} = \theta_i + \varepsilon_{ij}$. 为方便, 我们令 $\bar{y}_i = \frac{1}{r} \sum_{j=1}^r y_{ij}$, 对残差平方和进行分解.

$$\begin{aligned} Q &= \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \theta_i)^2 = \sum_{i=1}^s \sum_{j=1}^r \left[(y_{ij} - \bar{y}_i) + (\bar{y}_i - \theta_i) \right]^2 \\ &= \sum_{i=1}^s \sum_{j=1}^r \left[(y_{ij} - \bar{y}_i)^2 + 2(y_{ij} - \bar{y}_i)(\bar{y}_i - \theta_i) + (\bar{y}_i - \theta_i)^2 \right] \\ &= \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_i)^2 + r \sum_{i=1}^s (\bar{y}_i - \theta_i)^2 \end{aligned}$$

要使得残差平方和达到最小, 就必须使得 $\sum_{i=1}^s (\bar{y}_i - \theta_i)^2 = 0$, 这说明了 $\hat{\theta}_i = \bar{y}_i$, 结合约束条件, 我们知道 $\hat{\mu} = \bar{y} = \frac{1}{s} \sum_{i=1}^s \bar{y}_i, \hat{\alpha}_i = \bar{y}_i - \bar{y}, i = 1, 2, \dots, s$.

(2) 对总平方和进行分解:

$$\sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y})^2 = \sum_{i=1}^s \sum_{j=1}^r \left[(y_{ij} - \bar{y}_i) + (\bar{y}_i - \bar{y}) \right]^2 = \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_i)^2 + r \sum_{i=1}^s (\bar{y}_i - \bar{y})^2,$$

在原假设成立的情况下, $y_{ij} \sim N(\mu, \sigma^2)$, 因此

$$\frac{1}{\sigma^2} \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y})^2 \sim \chi^2(sr - 1), \frac{1}{\sigma^2} \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_i)^2 \sim \chi^2(s(r - 1)).$$

由于 $\bar{y}_i \sim N\left(\mu, \frac{\sigma^2}{r}\right)$, 因此 $\frac{r}{\sigma^2} \sum_{i=1}^s (\bar{y}_i - \bar{y})^2 \sim \chi^2(s - 1)$. 而显然, $\sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_i)^2$ 与 $\sum_{i=1}^s (\bar{y}_i - \bar{y})^2$ 独立. (每一个 $\sum_{j=1}^r (y_{ij} - \bar{y}_i)^2$ 都和 $\bar{y}_i$ 独立, $\bar{y}$ 是各 $\bar{y}_i$ 的线性组合, 自然也和每个 $\sum_{j=1}^r (y_{ij} - \bar{y}_i)^2$ 独立) 我们考虑, 原假设成立时组间差异应很小, 而 $\sum_{i=1}^s (\bar{y}_i - \bar{y})^2$ 反映的是组间差异, $\sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_i)^2$ 反映的是组内差异, 当组间差异比起组内差异相对较小时, 我们可以认为原假设是成立的. 故构造统计量

$$F = \frac{r \sum_{i=1}^s (\bar{y}_i - \bar{y})^2 / (s - 1)}{\sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_i)^2 / (sr - s)} \sim F(s - 1, sr - s),$$

故拒绝域为 $W = \{F > F_{1-\alpha}(s - 1, sr - s)\}$.

北京大学数院-431 金融学综合-2021 年

一、(10 分) 某袋中有 4 红球、2 白球, 从中取 2 次球, 请求:

(1)(5 分) 有放回取球, 第二次取到红球的概率;

(2)(5 分) 无放回取球, 第二次取到红球的概率.

Solution:

(1) $P(A) = \frac{2}{3}$.

(2) 运用全概率公式, $P(A) = \frac{4}{6} \cdot \frac{3}{5} + \frac{2}{6} \cdot \frac{4}{5} = \frac{2}{3}$. 实际上, 抽签概率与顺序无关.

二、(10 分) 随机变量 X 只取三个值 0,1,2, 取到它们的概率分别是 0.4,0.3,0.3; 随机变量 $Y \sim B(3, \frac{1}{3})$, 它们相互独立, 令 $S = X + Y$, 求

(1)(5 分) $P(S = 4)$ 与 $P(X = 2 | S = 4)$;

(2)(5 分) ES 与 $\text{Var}(S)$.

Solution:

(1) 由全概率公式

$$\begin{aligned} P(S = 4) &= \sum_{i=0}^2 P(Y = 4 - i | X = i)P(X = i) \\ &= 0.4 \times 0 + 0.3 \times \left(\frac{1}{3}\right)^3 + 0.3 \times 3 \times \frac{2}{3} \times \left(\frac{1}{3}\right)^2 \\ &= \frac{7}{90} \end{aligned}$$

由贝叶斯公式, $P(X = 2 | S = 4) = \frac{0.3 \times 3 \times \frac{2}{3} \times (\frac{1}{3})^2}{\frac{7}{90}} = \frac{6}{7}$.

(2) 由期望线性性, $ES = EX + EY = \frac{9}{10} + 1 = \frac{19}{10}$; 由和的方差公式, $\text{Var}(S) = \text{Var}(X) + \text{Var}(Y) = \frac{69}{100} + \frac{3}{2} = \frac{407}{300}$.

三、(10 分) 随机变量 X, Y 独立同服从标准正态分布, 令 $Z = \min\{X, Y\}, W = \max\{X, Y\}$, 试求

(1)(5 分) Z 与 W 的概率密度;

(2)(5 分) $\text{Cov}(Z, W)$.

Solution:

(1) 由次序统计量的分布公式, (Z, W) 的联合密度函数是

$$g(z, w) = 2!f(z, w) = \frac{1}{\pi} e^{-\frac{z^2 + w^2}{2}}, z < w$$

Z 的生存函数 (1-分布函数) 是: $P(Z \geq z) = P^2(X \geq z) = [1 - \Phi(z)]^2$, 故密度函数是: $2[1 - \Phi(z)]\varphi(z)$. W 的分布函数是: $P(W \leq w) = P^2(X \leq w) = \Phi(w)^2$, 故密度函数是: $2\Phi(w)\varphi(w)$.

(2) 由协方差公式, 有

$$\begin{aligned} \text{Cov}(Z, W) &= E(ZW) - EZEW \\ &= E(XY) - EZEW \\ &= -EZEW \\ &= (EW)^2 \end{aligned}$$

注意到, $W = \frac{|X-Y| + (X+Y)}{2}$, 其中由于 $X - Y \sim N(0, 2)$, 故

$$E|X - Y| = \frac{2}{\sqrt{\pi}}, EW = \frac{1}{\sqrt{\pi}}, \text{故 } \text{Cov}(Z, W) = \frac{1}{\pi}.$$

四、(10 分) 随机向量 (X, Y) 的联合概率密度是 $f(x, y) = c(x^2 + \frac{1}{2}xy)$, 其中 $x \in (0, 1), y \in (0, 2)$,

- (1)(3 分) 求 c ;
 (2)(3 分) 问 X, Y 是否独立;
 (3)(4 分) 求 $P(X + Y \leq 1)$.

Solution:

- (1) 利用概率的正则性, 由于

$$\int_0^2 \int_0^1 \left(x^2 + \frac{1}{2}xy\right) dx dy = \int_0^2 \left(\frac{1}{3} + \frac{1}{4}y\right) dy = \frac{2}{3} + \frac{1}{2} = \frac{7}{6}, \text{ 故 } c = \frac{6}{7}.$$

(2) $f_X(x) = \frac{6}{7} \int_0^2 \left(x^2 + \frac{1}{2}xy\right) dy = \frac{12x^2 + 6x}{7}, x \in (0, 1),$

$$f_Y(y) = \frac{6}{7} \int_0^1 \left(x^2 + \frac{1}{2}xy\right) dx = \frac{6}{7} \left(\frac{1}{3} + \frac{1}{4}y\right) = \frac{2}{7} + \frac{3}{14}y, y \in (0, 2),$$

显然, X, Y 不独立.

- (3) 直接计算积分, 有

$$P(X + Y \leq 1) = \frac{5}{56}.$$

五、(10 分) 随机变量 X 的分布函数是 $F(x) = 1 - \frac{1}{x^3}, x \geq 1$, 令 $Y = \sqrt{X}$.

- (1)(5 分) 求 EY 与 $\text{Var}(Y)$;
 (2)(5 分) 有来自总体 Y 的 n 个随机样本 $Y_1, \dots, Y_n$, 求 a_n 和 b_n 使得

$$\frac{\sum_{i=1}^n Y_i - a_n}{b_n} \xrightarrow{d} N(0, 1).$$

Solution:

- (1) 利用非负随机变量期望公式, 有

$$\begin{aligned} EY &= \int_0^{+\infty} P(Y > y) dy & EY^2 &= 1 + \int_1^{+\infty} P(Y^2 > y) dy \\ &= 1 + \int_1^{+\infty} P(X > y^2) dy & &= 1 + \int_1^{+\infty} P(X > y) dy \\ &= 1 + \int_1^{+\infty} \frac{1}{y^6} dy & &= 1 + \int_1^{+\infty} \frac{1}{y^3} dy \\ &= \frac{6}{5} & &= \frac{3}{2} \end{aligned}$$

故有 $EX = 6/5, \text{Var}(X) = 3/2 - 36/25 = 3/50$.

- (2) 取 $a_n = \frac{6}{5}n, b_n = \sqrt{\frac{3}{50}n}$, 由中心极限定理得

$$\frac{\sum_{i=1}^n Y_i - a_n}{b_n} \xrightarrow{d} N(0, 1).$$

六、(10 分) 有来自总体 $X \sim f(x) = \frac{1}{2\sigma} e^{-\frac{|x|}{\sigma}}$ 的 n 个随机样本 $X_1, \dots, X_n$, 令

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

求证: $ES^2 = 2\sigma^2$.

Solution: 样本方差 S^2 一定是总体方差的无偏估计, 因此只需计算总体方差, 显然总体密度函数关于原点对称, 而

$$\begin{aligned} EX^2 &= \int_{-\infty}^{+\infty} \frac{1}{2\sigma} x^2 e^{-\frac{|x|}{\sigma}} dx \\ &= \sigma^2 \int_0^{+\infty} \left(\frac{x}{\sigma}\right)^2 e^{-\frac{x}{\sigma}} d\left(\frac{x}{\sigma}\right) \\ &= \sigma^2 \Gamma(3) = 2\sigma^2 \end{aligned}$$

故 $ES^2 = \text{Var}(X) = EX^2 = 2\sigma^2$.

七、(10 分) $X_1, \dots, X_n$ 是来自总体 $N(\mu, \sigma^2)$ 的随机样本, μ, σ^2 是未知参数,

(1)(5 分) 求 μ 的置信度为 $1 - \alpha$ 的置信区间;

(2)(5 分) 设上述置信区间长度为 L , 求 EL^2 .

Solution:

(1) 用枢轴量法, 构造 t 统计量

$$T = \sqrt{n} \frac{\bar{X} - \mu}{s} \sim t(n-1),$$

其中 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是样本方差, s 是样本标准差, 因此

$$\left[\bar{X} - \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1), \bar{X} + \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1) \right]$$

是 μ 的置信度为 $1 - \alpha$ 的置信区间.

(2) 显然 $L = \frac{2s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$, $L^2 = \frac{4s^2}{n} t_{1-\frac{\alpha}{2}}^2(n-1)$, 又样本方差是总体方差的无偏估计, 因此

$$EL^2 = \frac{4\sigma^2}{n} t_{1-\frac{\alpha}{2}}^2(n-1)$$

八、(10 分) $X_1, \dots, X_n$ 是来自总体 $N(\mu, \sigma^2)$ 的随机样本, 求 k 使得统计量

$$T = k \sum_{i=1}^n |X_i - \bar{X}|$$

构成 σ 的无偏估计.

Solution: 由于 $E(X_1 - \bar{X}) = 0$, $\text{Cov}(X_1, \bar{X}) = \frac{1}{n}\sigma^2$, 故

$$\text{Var}(X_1 - \bar{X}) = \text{Var}(X_1) + \text{Var}(\bar{X}) - 2\text{Cov}(X_1, \bar{X}) = \frac{n-1}{n}\sigma^2,$$

我们知道, 对于标准正态分布 Z , 有 $E|Z| = \sqrt{\frac{2}{\pi}}$, 故 $E|X_1 - \bar{X}| = \sqrt{\frac{2(n-1)}{n\pi}}\sigma$, 因此有

$$ET = k \sqrt{\frac{2n(n-1)}{\pi}}\sigma$$

为使其为无偏估计, $k = \sqrt{\frac{\pi}{2n(n-1)}}$.

九、(10 分) 现有甲、乙两种工艺, 挑选 30 名工人测试他们完成两种工艺所花费的时间, 分别记作 X_i, Y_i . 若欲探究两种工艺所需工时的差异, 请叙述应使用的模型与检验法.

Solution: 配对样本 t 检验, 由于样本个数一致且每组样本都源于同一工人, 故令

$$Z_i = X_i - Y_i,$$

假定: $Z_1, Z_2, \dots, Z_{30}$ 是来自总体 $Z \sim N(\mu, \sigma^2)$ 的随机样本, 因为样本量很大, 可以近似认为正态分布是合理的, 考虑假设检验问题

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$$

由于在原假设成立时, 有

$$T = \sqrt{30} \frac{\bar{Z}}{s} \sim t(29),$$

其中 s 是样本标准差, $s^2 = \frac{1}{29} \sum_{i=1}^{30} (Z_i - \bar{Z})^2$, 如果原假设为真, T 的绝对值应很小, 如果 T 的绝对值很大, 我们就会考虑拒绝原假设, 故拒绝域是:

$$W = \{|T| > t_{1-\frac{\alpha}{2}}(29)\}$$

即如果观测到的 T_0 使得 $|T_0| > t_{1-\frac{\alpha}{2}}(29)$, 我们就认为两种工艺所需工时有显著差异. [其他思路]: 非参数检验, 如 Kolmogorov 秩和检验. 论述题合理即可, 但切勿写成先检验方差再检验均值, 因为这里是配对样本.

十、(10 分) 已知 $y_{ij} = \mu + a_i + \varepsilon_{ij}$, 其中 $i = 1, \dots, r, j = 1, \dots, s, \sum_{i=1}^r a_i = 0$, 残差 ε_{ij} 独立同服从 $N(0, \sigma^2)$, 令

$$\bar{y}_{i\cdot} = \frac{1}{s} \sum_{j=1}^s y_{ij}, i = 1, \dots, r, \bar{y} = \frac{1}{r} \sum_{i=1}^r \bar{y}_{i\cdot},$$

(1) 试证明:

$$\sum_{i=1}^r \sum_{j=1}^s (y_{ij} - \bar{y})^2 = \sum_{i=1}^r \sum_{j=1}^s (y_{ij} - \bar{y}_{i\cdot})^2 + r \sum_{i=1}^r (\bar{y}_{i\cdot} - \bar{y})^2;$$

(2) 证明: $\sum_{i=1}^r \sum_{j=1}^s (y_{ij} - \bar{y}_{i\cdot})^2$ 与 $\sum_{i=1}^r (\bar{y}_{i\cdot} - \bar{y})^2$ 相互独立.

Solution:

(1) 平方和分解问题

$$\begin{aligned} \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y})^2 &= \sum_{i=1}^s \sum_{j=1}^r \left[(y_{ij} - \bar{y}_{i\cdot}) + (\bar{y}_{i\cdot} - \bar{y}) \right]^2 \\ &= \sum_{i=1}^s \sum_{j=1}^r \left[(y_{ij} - \bar{y}_{i\cdot})^2 + (\bar{y}_{i\cdot} - \bar{y})^2 + 2(y_{ij} - \bar{y}_{i\cdot})(\bar{y}_{i\cdot} - \bar{y}) \right] \\ &= \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_{i\cdot})^2 + r \sum_{i=1}^s (\bar{y}_{i\cdot} - \bar{y})^2 \end{aligned}$$

因为 $\sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_{i\cdot})(\bar{y}_{i\cdot} - \bar{y}) = \sum_{i=1}^s (\bar{y}_{i\cdot} - \bar{y}) \sum_{j=1}^r (y_{ij} - \bar{y}_{i\cdot}) = 0$.

(2) 由 Fisher 引理, 对任意 $i, \sum_{j=1}^r (y_{ij} - \bar{y}_{i\cdot})^2$ 与 $\bar{y}_{i\cdot}$ 相互独立, 而对 $k \neq i, \sum_{j=1}^r (y_{kj} - \bar{y}_{k\cdot})^2$ 与 $\bar{y}_{i\cdot}$ 一定相互独立, 因此有 $\sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_{i\cdot})^2$ 与 $\bar{y}_{i\cdot}$ 相互独立. 又根据 i 的任意性, 有 $\sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_{i\cdot})^2$ 与 $\sum_{i=1}^s (\bar{y}_{i\cdot} - \bar{y})^2$ 相互独立. 易知, $\frac{1}{\sigma^2} \sum_{i=1}^s \sum_{j=1}^r (y_{ij} - \bar{y}_{i\cdot})^2 \sim \chi^2(s(r-1))$, 当原假设成立时, $\bar{y}_{i\cdot} \sim N\left(\mu, \frac{\sigma^2}{r}\right)$, 因此 $\frac{r}{\sigma^2} \sum_{i=1}^s (\bar{y}_{i\cdot} - \bar{y})^2 \sim \chi^2(s-1)$. 又因为它们独立, 故可以构造 F 统计量.

北京大学数院-431 金融学综合-2022 年

一、(5 分) 季度名义利率 6%, 求利息力

Solution: $e^\delta = \left(1 + \frac{0.06}{4}\right)^4 = 1.06136, \delta = \ln 1.06136 = 0.0595511$.

二、(15 分) $i = 0.05, n = 20$, 期末年金, 现金流分别为 100, 110, $\dots$, 200, 200, $\dots$, 求现值.

Solution: 最基本的贴现题型. 答案: $P = 100a_{20|i} + 10Ia_{10|i} = 2036.79$.

三、(15 分) 月名义 6%, 30 年, 月初还款, $L = 100$ 万, 第几次还款后未结余额首次小于 30 万元.

Solution: $A = \frac{1000000}{\ddot{a}_{360|0.5\%}} = \frac{1000000}{167.6256} = 5965.68$, 令 $A\ddot{a}_{360-n|0.5\%} \leq 300000$, 解得 $n = 303$.

四、(15 分) $F = 100, 1 - 5$ 年时 $r = 0.04, 6 - 10$ 年时 $r = 0.06, i = 0.05$, 债券有 50% 可能在 5 年底赎回, 也有 50% 可能在 10 年底赎回, 求 P .

Solution: 如果早赎, 则 $P_1 = 100(1 + 0.05)^{-5} + 4a_{5|0.05} = 95.6705$; 如果不早赎, 则 $P_2 = 100v^{-10} + 4a_{5|0.05} + 6a_{5|0.05}v^{-5} = 99.0628$. 故 $P = 97.37$.

五、(10 分) M 人分组做核酸, 每组 n 人, $k = M/n$ 是整数. 先将每组混合在一起进行检查, 若阳性则对组中每个人进行检查. 设每个人是阳性的概率为 p . 求:

(1) 某个人被测 2 次的概率;

(2) 某个人被检测次数的期望, 求它关于 n 及 p 的单调关系.

Solution: (1) 某个人被测两次意味着他这一组有阳性, 对应的概率是 $1 - (1 - p)^n$;

(2) 某个人要么被检测一次 (概率 $(1 - p)^n$), 要么两次, 因此期望是

$$E(X) = 2 - (1 - p)^n.$$

显然关于 p 单调递增, 而关于 n 单调递增.

六、(10 分) N 是只取非负整数的随机变量, 试证明: $EN^2 = 2 \sum_{n=0}^{\infty} (n + \frac{1}{2}) P(N > n)$.

Solution: $\sum_{n=0}^{\infty} (2n + 1)P(N > n) = \sum_{n=0}^{\infty} \sum_{k=n+1}^{\infty} (2n + 1)p_k = \sum_{k=1}^{\infty} \sum_{n=0}^{k-1} (2n + 1)p_k = \sum_{k=1}^{\infty} k^2 p_k = EN^2$

七、(15 分) $f(x, y) = 1/x, 0 < y < x < 1$.

(1) 验证为 pdf;

(2) 求 X, Y 边际分布;

(3) 求两个条件分布函数.

Solution:

(1) 非负性显然. 直接积分, 有

$$\int_0^1 \int_0^x \frac{1}{x} dy dx = \int_0^1 1 dx = 1.$$

(2) 求边际密度, 有

$$f_X(x) = \int_0^x \frac{1}{x} dy = I_{\{0 < x < 1\}}, \quad f_Y(y) = \int_y^1 \frac{1}{x} dx = -\ln y I_{\{0 < y < 1\}}.$$

(3) 先求条件密度, 有

$$f_{X|Y}(x|y) = -\frac{1}{x \ln y} I_{\{0 < y < x < 1\}}, \quad f_{Y|X}(y|x) = \frac{1}{x} I_{\{0 < y < x < 1\}},$$

积分得到条件分布函数是

$$F_{X|Y}(x|y) = \begin{cases} 0, & x \leq y \\ 1 - \frac{\ln x}{\ln y}, & y < x < 1, \\ 1, & x \geq 1 \end{cases}, \quad F_{Y|X}(y|x) = \begin{cases} 0, & y \leq 0 \\ \frac{y}{x}, & 0 < y < x \\ 1, & y \geq x \end{cases}$$

八、(15 分) $R_1, \dots, R_n$ 是 i.i.d. 随机变量 (收益率), $ER_1 = \mu, \text{Var}(R_1) = \sigma^2 < +\infty, 1 + R_t > 0$.

(1) 什么条件下, $(\prod_{t=1}^n (1 + R_t))^{\frac{1}{n}}$ 几乎必然收敛;

(2) 当收敛时, 比较 (1) 中极限与 μ 大小.

Solution:

(1) 记 $S_n = (\prod_{t=1}^n (1 + R_t))^{\frac{1}{n}}$. 由于 $1 + R_1 > 0$, 故存在 $\varepsilon > 0$, 使得 $1 + R_1 > \varepsilon$, 故 $S_n > (\varepsilon^n)^{\frac{1}{n}} = \varepsilon > 0$. 因此 S_n 几乎必然收敛于 $a > 0$ 等价于 $\ln S_n = \frac{1}{n} \sum_{t=1}^n \ln(1 + R_t)$ 几乎必然收敛于 $\ln a \neq \infty$, 而由强大数律, 这要求 $E(\ln(1 + R_1))$ 存在, 即

$$\int_{-1}^{+\infty} |\ln(1+x)| dF(x) < \infty$$

此时, 有

$$S_n = \left(\prod_{t=1}^n (1 + R_t) \right)^{\frac{1}{n}} \rightarrow_{a.s.} \exp \left\{ E(\ln(1 + R_1)) \right\}.$$

(2) 用 Jensen 不等式. 有

$$E(\ln(1 + R_1)) \leq \ln(1 + E(R_1)) = \ln(1 + \mu),$$

因此我们有

$$\exp \left\{ E(\ln(1 + R_1)) \right\} \leq \exp \left\{ \ln(1 + \mu) \right\} = \mu + 1.$$

九、(15 分) 正态总体 n 样本方差已知, 求 μ^3 和 μ^4 的 UMVUE.

Solution: 注意到

$$0 = E(\bar{X} - \mu)^3 = E(\bar{X}^3 - 3\mu\bar{X}^2 + 3\mu^2\bar{X} - \mu^3) = E(\bar{X}^3) - 3\mu\sigma^2/n - \mu^3,$$

我们有

$$E\left[\bar{X}^3 - \left(3\sigma^2/n\right)\bar{X}\right] = E(\bar{X}^3) - 3\mu\sigma^2/n = \mu^3.$$

因此由 Lehmann-Scheffé 定理可知 $\bar{X}^3 - \frac{3\sigma^2}{n}\bar{X}$ 是 μ^3 的 UMVUE. 类似地注意到

$$\begin{aligned} \frac{3\sigma^4}{n^2} &= E(\bar{X} - \mu)^4 \\ &= E\left[\bar{X}(\bar{X} - \mu)^3\right] \\ &= E\left[\bar{X}^4 - 3\mu\bar{X}^3 + 3\mu^2\bar{X}^2 - \mu^3\bar{X}\right] \\ &= E(\bar{X}^4) - 3\mu\left(3\mu\sigma^2/n + \mu^3\right) + 3\mu^2\left(\sigma^2/n + \mu^2\right) - \mu^4 \\ &= E(\bar{X}^4) - 6\mu^2\sigma^2/n - \mu^4 \\ &= E(\bar{X}^4) - \left(6\sigma^2/n\right)E(\bar{X}^2 - \sigma^2/n) - \mu^4, \end{aligned}$$

我们有 $\bar{X}^4 - \frac{6\sigma^2}{n}(\bar{X}^2 - \frac{\sigma^2}{n}) - \frac{3\sigma^4}{n^2}$ 是 μ^4 的 UMVUE.

十、(10 分) 有来自泊松总体 $\mathcal{P}(\lambda)$ 的 n 个样本 $x_1, x_2, \dots, x_n$, 对显著性水平 α , 求检验问题 $H_0: \lambda \geq 1 \longleftrightarrow H_1: \lambda < 1$ 的一致最优检验.

Solution: 考虑简单假设 $H_0: \lambda = \lambda_0$ vs $H_1: \lambda = \lambda_1 < 1$, 根据 $N - P$ 引理, 似然比检验是其最一致最大功效检验, 似然比为

$$\Lambda = \frac{\sum_{i=1}^{\lambda_1=1} \sum_{i=1}^n X_i X^{-\lambda_1}}{\sum_{i=1}^{\lambda_0=1} \sum_{i=1}^n X_i} = \left(\frac{\lambda_1}{\lambda_0}\right)^{-\lambda_0} \sum_{i=1}^n X_i e^{\lambda_0 - \lambda_1}$$

可以看出该似然比关于统计量 $T = \sum_{i=1}^n X_i$ 是单调递减的, 所以原问题的一致最大功效检验为 $\phi(T) = \begin{cases} 1, & T < c \\ a, & T = c \\ 0, & T > c \end{cases}$

其中常数 a, c 使得 $E\phi(T) = \alpha$, 可以取

$$c = \inf \left\{ m : \sum_{k=0}^m \frac{n^k}{k!} e^{-n} > \alpha \right\}, \quad a = \left(\alpha - \sum_{k=0}^{m-1} \frac{n^k}{k!} e^{-n} \right) / \frac{n^m}{m!} e^{-n}.$$

十一、(10 分) 设有 logist 函数 $\text{logist}(p) = \log\left(\frac{p}{1-p}\right)$. 有数据 $(X_1, Y_1), \dots, (X_n, Y_n)$, 其中 $X_i \in 1 \times p$, $Y_i \in \{0, 1\}$, 假设有 $\text{logist}(P(Y_i = 1 | X_i)) = X_i \beta$, 其中 $\beta \in p \times 1$. 求:

(1) 对数似然函数 $\ln L(\beta)$;

(2) 当 $p = 1$, 说明 $\ln L(\beta)$ 是凹函数 (二阶导为负) 及其对求 β 的 MLE 的意义.

Solution:

(1) 当给定 $X_i = x_i$, Y 是两点分布, $Y = 1$ 的概率可由下式 (代入 logist 函数) 解出

$$\log \left(\frac{P(Y_i = 1 | X_i = x_i)}{1 - P(Y_i = 1 | X_i = x_i)} \right) = x_i \beta,$$

即有

$$P(Y_i = 1 | X_i = x_i) = \frac{1}{1 + e^{-x_i \beta}}, \quad P(Y_i = 0 | X_i = x_i) = \frac{e^{-x_i \beta}}{1 + e^{-x_i \beta}},$$

对应的概率质量函数是

$$p_{Y|X}(y_i | x_i) = \left(\frac{1}{1 + e^{-x_i \beta}} \right)^{y_i} \left(\frac{e^{-x_i \beta}}{1 + e^{-x_i \beta}} \right)^{1-y_i}.$$

考虑从 $i = 1, 2, \dots, n$ 累乘的似然函数, 有

$$L_{Y|X}(\beta; Y|X) = \prod_{i=1}^n \left(\frac{1}{1 + e^{-x_i \beta}} \right)^{y_i} \left(\frac{e^{-x_i \beta}}{1 + e^{-x_i \beta}} \right)^{1-y_i},$$

假设 X_i 的密度是 $p_i(x_i)$, 因此似然函数是

$$L(\beta; Y, X) = \prod_{i=1}^n \left(\frac{1}{1 + e^{-x_i \beta}} \right)^{y_i} \left(\frac{e^{-x_i \beta}}{1 + e^{-x_i \beta}} \right)^{1-y_i} p_i(x_i),$$

则对数似然函数为

$$\ln L(\beta) = \sum_{i=1}^n y_i \ln \left(\frac{1}{1 + e^{-x_i \beta}} \right) + \sum_{i=1}^n (1 - y_i) \ln \left(\frac{e^{-x_i \beta}}{1 + e^{-x_i \beta}} \right) + \sum_{i=1}^n \ln p_i(x_i).$$

(2) 当维度 $p = 1$, 化简上式, 得

$$\ln L(\beta) = - \sum_{i=1}^n \ln(1 + e^{-x_i \beta}) - \beta \sum_{i=1}^n (1 - y_i) x_i + \sum_{i=1}^n \ln p_i(x_i).$$

而对任意 i , 对 $-\ln(1 + e^{-x_i \beta})$ 求二阶导发现为负, 故 $\ln L(\beta)$ 的二阶导为负, 即凹函数. 由于似然函数复杂难以求解析解, 故只能求数值解, 而对于二阶导恒为负的函数而言, 如果找到了函数的驻点, 则该驻点一定是唯一驻点且是最大值点, 即 MLE. 这一事实确保了我们用数值算法求 logist 回归参数 MLE 时的有效性.

十二、(15 分) 考虑被解释变量 $Y_1, \dots, Y_n$, 解释变量 $X_1, \dots, X_n, Z_1, \dots, Z_n$, 其中 Z_i 只有 R, B 两种取值. 有下述三种最小二乘回归结果, 注意考虑 Z_i 时只探讨其对应的 0-1 变量 $I_i = I_{\{Z_i=R\}}$.

回归表 (i):

自变量	回归系数	标准误差	t 统计量	p -value
intercept	56.0919	8.8197	6.5074	0.0000
I	0.9774	0.1660	5.8880	0.0000
模型检验	R^2	F 统计量	p -value	n
	0.81	34.66	0.0000	32

回归表 (ii):

自变量	回归系数	标准误差	t 统计量	p -value
intercept	51.2146	7.61967	6.5074	0.0000
X	1.2354	0.46604	2.6508	0.0012
模型检验	R^2	F 统计量	p -value	n
	0.43	9.66	0.0023	32

回归表 (iii):

自变量	回归系数	标准误差	t 统计量	p -value
intercept	49.2146	9.61967	5.1160	0.0000
I	0.9574	0.06604	14.4972	0.0000
X	0.9967	1.12211	0.8882	0.7209
模型检验	R^2	F 统计量	p -value	n
	0.98	39.45	0.0000	32

- (1) 在回归表 (i) 中, 求回归系数的表达式;
- (2) 给出 R^2 的表达式, 解释其含义;
- (3) 为什么三张表中同一变量的回归系数不一致? 并说出是否有其他回归模型, 可以解释 Y, X, Z 之间的关系.

Solution:

(1) 这是最小二乘回归结果, 因此有 $\hat{\beta}_C = \bar{Y} - \hat{\beta}_I \bar{I}$, $\hat{\beta}_I = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(I_i - \bar{I})}{\sum_{i=1}^n (I_i - \bar{I})^2}$;

(2) $R^2 = \frac{SSR}{SST}$, 表示回归模型的拟合优度; 拟合优度越大, 则解释变量对被解释变量的解释力度越大;

(3) 如表 (i) 和表 (iii) 中的自变量 I 和常数 C , 它们的回归系数不可能相同, 因为最小二乘的原理导致了增加越多的解释变量将使得拟合优度 R^2 越大 ((i) 中的 0.81 到 (iii) 中的 0.98). 反过来看, 如果增加变量后原先变量的回归系数是不变的, 那么只能加入新变量不会使得 R^2 增加, 但这与 (i) 中的 0.81 到 (iii) 中的 0.98 的事实不符. 我认为还可以增加模型 $Y = \beta_C + \beta_I I + \beta_{IX} IX$, 因为从回归表 (i), (ii) 来看, X 和 I 对 Y 都有解释能力 (模型显著), 但在表 (iii) 中 X 的回归系数不显著, 说明当我们用 (I, X) 联合对 Y 作解释时 Y 与 X 并不成立线性关系, 考虑到 I 是 0-1 变量的事实, 故我认为可以采用 $Y = \beta_C + \beta_I I + \beta_{IX} IX$. 此外, 还可以尝试例如: $Y = \beta_C + \beta_I I + \beta_X X^2$ 等, 但尽量不改动已显著的变量 I .

北京大学数院-431 金融学综合-2023 年

一、(12 分) 设 X, Y 独立同服从 $\{0, 1, 2, 3, 4\}$ 上的均匀分布, 记 $XY = 10\xi + \eta$, 即十位数是 ξ , 个位数是 η 。

- (1) 求 ξ 的分布列;
- (2) 求 $P(\eta \leq 1 | \xi = 0)$;
- (3) 求 $E(X\xi)$.

Solution: (1) 直接计算, 有

$$P(\xi = 1) = P(XY = 3 \cdot 4) + P(XY = 4 \cdot 4) = \frac{3}{25},$$

因此 $P(\xi = 0) = \frac{22}{25}$.

(2) 这个概率意味着: $XY < 10$, 即不能取 $(4, 4), (3, 4), (4, 3)$, 在剩下的 22 种情况中, 只有 $(1, 1)$ 和 $(0, k), (k, 0)$ 满足情况, 这里总共有 10 种情况, 故 $P(\eta \leq 1 | \xi = 0) = \frac{5}{11}$.

(3) 求该期望只需考虑 $\xi = 1$ 时, 即有

$$\{X\xi > 0\} = \{(X, Y) = (3, 4), (4, 3), (4, 4)\}$$

故有期望是

$$E(X\xi) = \frac{1}{25} \cdot 3 + \frac{2}{25} \cdot 4 = \frac{11}{25}.$$

二、(13 分) 已知 X 的分布是

$$f(x) = be^{-a|x|}, \quad x \in R,$$

且 $Var(X) = 1$.

- (1) 求 a, b ;
- (2) 记函数

$$g_\varepsilon(x) = \begin{cases} x, & |x| \leq \varepsilon, \\ -x, & |x| > \varepsilon, \end{cases}$$

其中 $\varepsilon > 0$ 已知, 求 $g_\varepsilon(X)$ 的分布;

- (3) 求 $Cov(X, g_\varepsilon(X))$.

Solution: (1) 首先根据正则性, 有

$$1 = \int_{-\infty}^{+\infty} be^{-a|x|} dx = 2b \int_0^{+\infty} e^{-ax} dx = \frac{2b}{a}.$$

其次显然 $E(X) = 0$, 由二阶矩为 1, 有

$$1 = 2b \int_0^{+\infty} x^2 e^{-ax} dx = \frac{2b}{a^3} \int_0^{+\infty} (ax)^2 e^{-ax} d(ax) = \frac{4b}{a^3}.$$

联立解得: $a = \sqrt{2}, b = \frac{1}{\sqrt{2}}$.

(2) 显然有 $Y = g_\varepsilon(X) = XI_{\{|X| \leq \varepsilon\}} - XI_{\{|X| > \varepsilon\}}$, 故当 $|y| < \varepsilon$ 时, 有

$$P(Y = y) = P(X = y) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|y|} dy,$$

当 $|y| > \varepsilon$ 时, 有

$$P(Y = y) = P(X = -y) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|y|} dy,$$

因此 $g_\varepsilon(X)$ 的分布也是 $\frac{1}{\sqrt{2}}e^{-\sqrt{2}|y|}$.

(3) 因为 $E(X) = 0$, 所以只需求混合矩, 有

$$E(XY) = E\left(X^2 I_{\{|X| \leq \varepsilon\}}\right) - E\left(X^2 I_{\{|X| > \varepsilon\}}\right) = E(X^2) - 2E\left(X^2 I_{\{|X| > \varepsilon\}}\right),$$

其中 $E(X^2) = 1$, 而

$$\begin{aligned} E\left(X^2 I_{\{|X| > \varepsilon\}}\right) &= \sqrt{2} \int_{\varepsilon}^{+\infty} x^2 e^{-\sqrt{2}x} dx = \frac{1}{2} \int_{\varepsilon}^{+\infty} (\sqrt{2}x)^2 e^{-\sqrt{2}x} d(\sqrt{2}x) \\ &= \frac{1}{2} \int_{\sqrt{2}\varepsilon}^{+\infty} u^2 e^{-u} du = (\varepsilon^2 + \sqrt{2}\varepsilon + 1) e^{-\sqrt{2}\varepsilon}, \end{aligned}$$

这里用两次分部积分公式或者直接用泊松-伽马恒等式. 最后汇总得

$$\text{Cov}(X, g_\varepsilon(X)) = 1 - 2(\varepsilon^2 + \sqrt{2}\varepsilon + 1) e^{-\sqrt{2}\varepsilon}.$$

三、(12 分) 设 X_1, X_2, X_3, X_4 是 i.i.d. $U(0, c)$ 随机变量, 其中 $c > 0$ 已知. 如果 $X_i \leq kc$ 代表违约. 定义两个产品,

Y_1 : 四个全违约时支付 0 元, 否则支付 1 元,

Y_2 : 两个及以上违约时支付 0 元, 否则支付 1 元.

(1) 求 Y_1, Y_2 的期望;

(2) 求 $P(Y_1 = 0, Y_2 = 1)$ 和 $P(Y_1 = 1, Y_2 = 0)$.

Solution: (1) 实际上违约数量 $Z \sim B(4, k)$, 因此分布是

$$P(Y_1 = 0) = P(Z = 4) = k^4, \quad P(Y_1 = 1) = 1 - k^4,$$

故 $E(Y_1) = 1 - k^4$.

同理有

$$P(Y_2 = 1) = P(Z = 0, 1) = (1 - k)^4 + 4k(1 - k)^3, \quad P(Y_2 = 0) = 1 - (1 - k)^4 - 4k(1 - k)^3,$$

故 $E(Y_2) = (1 - k)^4 + 4k(1 - k)^3$.

(2) 联合分布是

$$P(Y_1 = 0, Y_2 = 0) = P(Z = 4) = k^4, \quad P(Y_1 = 0, Y_2 = 1) = 0,$$

$$P(Y_1 = 1, Y_2 = 1) = P(Z = 0, 1) = (1 - k)^4 + 4k(1 - k)^3,$$

$$P(Y_1 = 1, Y_2 = 0) = P(Z = 2, 3) = 6k^2(1 - k)^2 + 4k^3(1 - k).$$

故有 $P(Y_1 = 0, Y_2 = 1) = 0, P(Y_1 = 1, Y_2 = 0) = P(Z = 2, 3) = 6k^2(1 - k)^2 + 4k^3(1 - k)$.

四、(13 分) 已知 $N(t)$ 是强度为 1 的泊松过程, 定义 Y_n 满足

$$\sqrt{n}Y_n + n = N(n).$$

(1) 证明: $Y_n \xrightarrow{L} N(0, 1)$;

(2) 估算 $P(20 \leq N(25) \leq 25)$.

Solution: (1) 考虑 $X_1, X_2, \dots, X_n$ i.i.d. 服从 $P(1)$, 根据泊松分布可加性可以把 $N(n)$ 写为

$$N(n) = X_1 + X_2 + \dots + X_n,$$

因此利用中心极限定理有

$$Y_n = \frac{N(n) - n}{\sqrt{n}} = \frac{\sum_{k=1}^n X_k - n}{\sqrt{n}} \xrightarrow{L} N(0, 1).$$

(2) 利用中心极限定理的 (这里显然题设不想我们离散修正, 当然修正了也没问题), 有

$$P(20 \leq N(25) \leq 25) = P\left(\frac{20-25}{5} \leq Y_{25} \leq \frac{25-25}{5}\right) \approx \frac{1}{2} - \Phi(-1).$$

五、(15 分) 已知 $Y \sim N(0, \sigma^2)$, 以及 $X = |Y|$, 有来自 X 的 i.i.d. 样本 $X_1, X_2, \dots, X_n$.

(1) 求 X 的分布;

(2) 求 σ^2 的无偏矩估计;

(3) 求 σ^2 的 MLE.

Solution: (1) 用微分法, 有

$$P(X=x) = P(Y=x) + P(Y=-x) = \frac{1}{\sigma} \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2\sigma^2}} dx,$$

因此有

$$f_X(x) = \frac{1}{\sigma} \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2\sigma^2}}, \quad x > 0.$$

(2) 求期望, 有

$$E(X) = \frac{1}{\sigma} \sqrt{\frac{2}{\pi}} \int_0^{+\infty} x e^{-\frac{x^2}{2\sigma^2}} dx = \sigma \sqrt{\frac{2}{\pi}} \int_0^{+\infty} \frac{x}{\sigma} e^{-\frac{1}{2}\left(\frac{x}{\sigma}\right)^2} d\left(\frac{x}{\sigma}\right) = \sigma \sqrt{\frac{2}{\pi}},$$

这对应 $\sigma^2 = \frac{\pi}{2} (E(X))^2$, 根据替换原理有

$$\hat{\sigma}_{M1}^2 = \frac{\pi}{2} \bar{X}^2.$$

然而由于 $E(\bar{X}) = \sigma \sqrt{\frac{2}{\pi}}$, 由 Jensen 不等式有 $E(\bar{X}^2) \geq \sigma^2 \frac{2}{\pi}$, 并且此时等号无法取等, 故有

$$E(\hat{\sigma}_{M1}^2) > \sigma^2,$$

它不是无偏估计, 因此一阶矩不满足, 我们尝试二阶矩. 求期望有

$$E(X^2) = E(Y^2) = \sigma^2,$$

因此由替换原理, $\hat{\sigma}_{M2}^2 = \frac{\sum_{k=1}^n x_k^2}{n}$, 而恰好 $E(\hat{\sigma}_{M2}^2) = E(X^2) = \sigma^2$, 无偏.

(3) 似然函数和对数似然函数是

$$L(\theta) = A \cdot (\sigma^2)^{-\frac{n}{2}} \cdot e^{-\frac{\sum_{k=1}^n x_k^2}{2\sigma^2}}, \quad \ln L(\theta) = C - \frac{n}{2} \ln(\sigma^2) - \frac{\sum_{k=1}^n x_k^2}{2\sigma^2},$$

求导置零解得 $\hat{\sigma}_L^2 = \frac{\sum_{k=1}^n x_k^2}{n}$.

六、(5 分) 设 $X_n \sim B(n, \frac{1}{2})$, 如果要求 $\frac{X_n}{n}$ 与 $\frac{1}{2}$ 的差距小于 0.04 的概率大于 0.95, 求 n 的最小值.

Solution: 利用正态近似, 即 $\frac{X_n}{n} \sim AN(\frac{1}{2}, \frac{1}{4n})$, 故有

$$P\left(\left|\frac{X_n}{n} - \frac{1}{2}\right| < 0.04\right) = P\left(2\sqrt{n}\left|\frac{X_n}{n} - \frac{1}{2}\right| < 0.08\sqrt{n}\right) \approx 2\Phi(0.08\sqrt{n}) - 1,$$

要使得其 ≥ 0.95 , 就要

$$0.08\sqrt{n} \geq 1.96, \Rightarrow n \geq \left(\frac{1.96}{0.08}\right)^2 = 600.25.$$

因此 n 至少为 601.

七、(10 分) 设有来自 $B(r, \theta)$ 的 i.i.d. 样本 $x_1, \dots, x_n$, 其中 r 已知.

(1) 求 Fisher 信息量 $I(\theta)$;

(2) 求 $g(\theta)$ 使得 $g(\theta)$ 的无偏估计的方差下界与 θ 无关.

Solution: (1) 密度函数是

$$p(x; \theta) = C_r^x \theta^x (1 - \theta)^{r-x}, \quad \ln p = A + x \ln \theta + (r - x) \ln (1 - \theta),$$

求导得

$$\frac{\partial \ln p}{\partial \theta} = \frac{x}{\theta} - \frac{r-x}{1-\theta}, \quad \frac{\partial^2 \ln p}{\partial \theta^2} = -\left(\frac{x}{\theta^2} + \frac{r-x}{(1-\theta)^2}\right),$$

Fisher 信息量是

$$I(\theta) = -E\left[\frac{\partial^2 \ln p}{\partial \theta^2}\right] = \frac{r\theta}{\theta^2} + \frac{r(1-\theta)}{(1-\theta)^2} = \frac{r}{\theta(1-\theta)}.$$

(2) $g(\theta)$ 的无偏估计的方差 CR 下界是

$$\text{CR} = \frac{[g'(\theta)]^2}{nI(\theta)} = \frac{\theta(1-\theta)}{nr} [g'(\theta)]^2,$$

直接考虑 $g'(\theta) = \frac{c_0}{\sqrt{\theta(1-\theta)}}$, 其中 c_0 是任意常数, 积分有

$$g(\theta) = k_1 \arcsin(\sqrt{1-\theta}) + k_2.$$

其中 k_1, k_2 是任意常数.

八、(10 分) 设随机变量 X 的分布是 $f(x; \lambda) = \lambda m (\lambda x)^{m-1} e^{-(\lambda x)^m}, x > 0. m > 0$ 已知, 求下述检验的 UMPT:

$$H_0: \lambda = \lambda_0 \quad \text{vs} \quad H_1: \lambda > \lambda_0.$$

并指出检验统计量的分布.

Solution: 密度函数是

$$f(x; \lambda) = \lambda m (\lambda x)^{m-1} e^{-(\lambda x)^m}$$

是指数族, 令 $\eta = -\lambda^m$, 则该指数族的标准形式是

$$f(x; \eta) = S(\eta) C(x) \exp\{\eta \cdot y\},$$

其中 $y = x^m$ 是对应的充分统计量. 且 $H_0: \lambda = \lambda_0 \quad \text{vs} \quad H_1: \lambda > \lambda_0$ 等价于

$$H_0: \eta = -\lambda_0^m \quad \text{vs} \quad H_1: \eta < -\lambda_0^m$$

根据推广的 N-P 引理 (或 Karlin-Rubin 定理), 该问题的 UMPT 是

$$T(X) = I_{\{Y < c\}} = I_{\{X^m < c\}},$$

或是 $W = \{X^m < c\}$, 其中 c 由显著性水平确定.

记 $Z = (\lambda X)^m$, 由微分法得

$$P(Z = z) = P\left(X = \frac{z^{\frac{1}{m}}}{\lambda}\right) = \lambda m z^{\frac{m-1}{m}} e^{-z} d\left(\frac{z^{\frac{1}{m}}}{\lambda}\right) = e^{-z} dz,$$

这是指数分布. 我们再考虑将检验写为

$$W = \{(\lambda_0 X)^m < c_1\}$$

这里检验统计量 $(\lambda_0 X)^m$ 在原假设下恰好是 $Exp(1)$, 故 $c_1 = -\ln(1 - \alpha)$. 汇总得

$$W = \{(\lambda_0 X)^m < -\ln(1 - \alpha)\}$$

是水平为 α 的 UMPT.

九、(10 分) 有线性模型 $Y_{ij} = \alpha_i + \beta x_{ij} + e_{ij}$, $i = 1, \dots, m$, $j = 1, \dots, n$. 其中 $E(e_{ij}) = 0$, $Var(e_{ij}) = \sigma^2$, 求 $(\alpha_1, \dots, \alpha_m, \beta)$ 的 LSE.

Solution: 极小化残差平方和

$$Q(\alpha_1, \dots, \alpha_m, \beta) = \sum_{i=1}^m \sum_{j=1}^n (Y_{ij} - \alpha_i - \beta X_{ij})^2,$$

求导得

$$\frac{\partial Q}{\partial \alpha_i} = -2 \sum_{j=1}^n (Y_{ij} - \alpha_i - \beta X_{ij}), \quad \frac{\partial Q}{\partial \beta} = -2 \sum_{i=1}^m \sum_{j=1}^n X_{ij} (Y_{ij} - \alpha_i - \beta X_{ij}),$$

解得

$$\begin{cases} \hat{\beta} = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^m \sum_{j=1}^n (X_{ij} - \bar{X}_{i\cdot})(Y_{ij} - \bar{Y}_{i\cdot})}{\sum_{i=1}^m \sum_{j=1}^n (X_{ij} - \bar{X}_{i\cdot})^2}, \\ \hat{\alpha}_i = \bar{Y}_{i\cdot} - \hat{\beta} \bar{X}_{i\cdot}, \quad i = 1, 2, \dots, m. \end{cases}$$

十、(10 分) 有两种累积方式, A: 单利 9% 利率; B: 复利 6% 利率. 问何时 A 的利息力首次低于 B.

Solution: 两种累积函数是

$$a_A(t) = 1 + 0.09t, \quad a_B(t) = (1 + 0.06)^t,$$

利息力函数是

$$\delta_A(t) = \frac{0.09}{1 + 0.09t}, \quad \delta_B(t) = \ln(1.06),$$

令 $\delta_A \leq \delta_B$, 有

$$\frac{0.09}{1 + 0.09t} \leq \ln(1.06), \quad \Rightarrow \quad t \geq \frac{\frac{0.09}{\ln(1.06)} - 1}{0.09} = 6.0507.$$

十一、(15 分) 贷款 L 元, 月名利率 12%, 偿债基金月名利率 6%. 每月底偿还 1000 元, 先偿还利息, 剩余部分存至偿债基金, 总计 3 年, 求 L 以及实际利率 r , 结果在百分号下保留 1 位小数.

Solution: 每月需还利息为 $I = 0.01L$, 因此有

$$(1000 - 0.01L) \cdot s_{36|0.005} = L,$$

即有

$$L = \frac{1000 \cdot s_{36|0.005}}{1 + 0.01 \cdot s_{36|0.005}} = 28231.1.$$

实际利率 r 意味着我们需找 r 使得

$$1000 \cdot a_{36|r} = 28231.1.$$

结果需保留 1 位小数, 我们只能考虑试根, 发现 $r = 1.4\%$ 最接近, 即实际月名利率是 $1.4\% \times 12 = 16.8\%$.

十二、(15 分) 20 年贷款 100 万元, 月名利率 6%, 某年出台政策, 调整后的月名利率为 3.6%.

(1) 问原利率下还款的总利息比调整后还款总利息多多少;

(2) 比较两种利率下, 第 2 次还款和最后一次还款中利息的差额.

Solution: (1) 先计算原利率下的利息, 首先有

$$R = \frac{100}{a_{240|0.005}} = 0.716431, \quad K = nR - L = 71.9435.$$

在调整后, 有

$$R = \frac{100}{a_{240|0.003}} = 0.585111, \quad K = nR - L = 40.4268.$$

因此多还利息是 $71.9435 - 40.4268 = 31.5167$ 万元.

(2) 第一种利率下, 有

$$I_2 = iB_1 = 0.005 \cdot 0.716431 \cdot a_{239|0.005} = 0.498918,$$

$$I_n = iB_{n-1} = 0.005 \cdot 0.716431 \cdot a_{1|0.005} = 0.00341158.$$

因此有 $I_2 - I_n = 4955.06$ 元.

第二种利率下, 有

$$I_2 = iB_1 = 0.003 \cdot 0.585111 \cdot a_{239|0.003} = 0.299144,$$

$$I_n = iB_{n-1} = 0.003 \cdot 0.716431 \cdot a_{1|0.003} = 0.00175008.$$

因此有 $I_2 - I_n = 2973.94$ 元.

这两种利率下, 该利息差的差距是 $4955.06 - 2973.94 = 1981.12$ 元.

十三、(10 分) 某公司股票今年收益 3 元, 计划年底分红 1 元。以后每年收益以 8% 增加, 分红则是收益的 $1/3$ 。

(1) 假设收益率是 12%, 计算股票价格;

(2) 求分红现金流的久期。

Solution: (1) 根据分红贴现模型, 有

$$P = \frac{D}{i - k} = \frac{1}{12\% - 8\%} = 25.$$

(2) 根据久期公式, 有

$$\begin{aligned} \bar{d}(i) &= \frac{\sum_{t=1}^{\infty} tv^t C_t}{\sum_{t=1}^{\infty} v^t C_t} = \frac{\sum_{t=1}^{\infty} tv^t (1+k)^{t-1} D}{P} = \frac{Dv}{P} \sum_{t=1}^{\infty} t(v(1+k))^{t-1} \\ &= \frac{Dv}{P} \left(\sum_{t=1}^{\infty} (v(1+k))^t \right)' = \frac{Dv}{P(1-v(1+k))^2} \\ &= \frac{D}{P} \frac{1+i}{(i-k)^2} = \frac{1}{25} \frac{1+12\%}{(12\% - 8\%)^2} = 28. \end{aligned}$$

北京大学数院-431 金融学综合-2024 年

概率论部分

一、(10 分) 现有一副 52 张牌, 4 个花色的扑克. 不断进行独立有放回的抽取, 抽到每种花色的概率是 $1/4$.

(1)(4 分) 求第一次抽到红桃的次数分布;

(2)(6 分) 求首次摸齐 4 个花色的期望和方差.

Solution: (1) 显然这是一个几何分布 $Ge(1/4)$.

(2) 设摸到第 i 个没摸到过的花色需要的次数为 $X_i, i = 1, 2, 3, 4$. 同样的, 我们可以发现 $X_i \sim Ge((4 - i + 1)/4)$, 从而有

$$EX = \sum_{i=1}^4 EX_i = 4 \sum_{i=1}^4 \frac{1}{4 - i + 1} = \frac{25}{3}$$

$$Var(X) = \sum_{i=1}^4 Var(X_i) = 4 \sum_{i=1}^4 \frac{i - 1}{(4 - i + 1)^2} = \frac{130}{9}$$

二、(10 分) $P(X = i, Y = j) = C_j^i \frac{\lambda^j}{j!} e^{-2\lambda}, 0 \leq i \leq j$.

(1)(4 分) 求 Y 的分布;

(2)(3 分) 求 X 的分布;

(3)(3 分) 求 $Y - X$ 的分布.

Solution: (1) 由全概率公式有

$$P(Y = j) = \sum_{i=0}^j P(X = i, Y = j) = \frac{\lambda^j}{j!} e^{-2\lambda} \sum_{i=0}^j C_j^i = \frac{\lambda^j}{j!} e^{-2\lambda} \cdot 2^j = \frac{(2\lambda)^j}{j!} e^{-2\lambda}.$$

这说明 $Y \sim P(2\lambda)$.

(2) 同理可以得到

$$P(X = i) = \sum_{j=i}^{\infty} P(X = i, Y = j) = \frac{\lambda^i}{i!} e^{-2\lambda} \sum_{j=i}^{\infty} \frac{\lambda^{j-i}}{(j-i)!} = \frac{\lambda^i}{i!} e^{-2\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = \frac{\lambda^i}{i!} e^{-2\lambda} \cdot e^{\lambda} = \frac{\lambda^i}{i!} e^{-\lambda}.$$

这说明 $X \sim P(\lambda)$.

(3) 同样由全概率公式有

$$P(Y - X = k) = \sum_{i=0}^{\infty} P(Y - X = k, X = i) = \sum_{i=0}^{\infty} P(X = i, Y = i + k)$$

$$= \sum_{i=0}^{\infty} C_{i+k}^i \frac{\lambda^{i+k}}{(i+k)!} e^{-2\lambda}$$

$$= e^{-2\lambda} \frac{\lambda^k}{k!} \sum_{i=0}^{\infty} \frac{\lambda^i}{i!} = e^{-2\lambda} \frac{\lambda^k}{k!} \cdot e^{\lambda} = \frac{\lambda^k}{k!} e^{-\lambda}.$$

故有 $Y - X \sim P(\lambda)$.

三、(10 分) 设 $X = (X_1, \dots, X_n)^T$ 是随机向量, $E(X) = 0, Cov(X) = (\sigma_{ij})_{n \times n}$, 其中 $\sigma_{ii} > 0, i = 1, 2, \dots, n$. 证明: 若 $|\Sigma| = 0$, 则存在指标 $k \in \{1, 2, \dots, n\}$ 以及 $\{a_i, i \neq k, 1 \leq i \leq n\}$, 使得 $X_k = \sum_{i \neq k} a_i X_i$ 几乎处处成立.

Solution: 由于 $|\Sigma| = 0$, 故存在非零向量 $a = (a_1, \dots, a_n)^T$, 使得 $a^T \Sigma a = 0$.

而由多元分布的性质, 对于 $Y = a^T X$, 有 $EY = a^T EX = 0$ 以及 $Var(a^T X) = a^T Var(X) a = a^T \Sigma a = 0$.

可以发现 Y 的方差为 0, 故 $Y = \sum_{i=1}^n a_i X_i = 0$ 几乎处处成立, 原命题得证.

四、(10 分) 设 $Y = X_1 + \dots + X_N$, 各个 X_i 之间独立同分布, 且 X_i 和 N 也独立, N 的取值为非负整数. 若 X_1 和 N 二阶矩存在, 试用 X_1 和 N 的期望与方差来表示出 Y 的期望和方差.

Solution: 记 $EX_1 = \mu_x, \text{Var}(X_1) = \sigma_x^2, EN = \mu_N, \text{Var}(N) = \sigma_N^2$.

由重期望公式有

$$EY = E(E(Y|N)) = E(N\mu_x) = \mu_x\mu_N.$$

再由条件方差公式

$$\text{Var}(Y) = E(\text{Var}(Y|N)) + \text{Var}(E(Y|N)) = E(N\sigma_x^2) + \text{Var}(N\mu_x) = \mu_N\sigma_x^2 + \mu_x^2\sigma_N^2.$$

五、(10 分) 设 $Z_1, \dots, Z_n$ 独立同分布 $g(z)$, $g(z)$ 为密度函数, X 的密度函数为 $f(x)$, $EX = \mu$.

(1)(5 分) 若 $Y_i = \frac{f(Z_i)}{g(Z_i)}Z_i, i = 1, 2, \dots, n$, 令 $\hat{\theta}_n = \bar{Y}$, 求证: $\hat{\theta}_n \xrightarrow{a.s.} \mu$.

(2)(5 分) 若 $\text{Var}(Y_1) = 1$, 求 $\hat{\theta}_n$ 的渐进分布. 并对于 $\epsilon = 0.01, \alpha = 0.05$, 求最小的 n , 使得 $P(|\hat{\theta}_n - \mu| < \epsilon) \geq 1 - \alpha$ 成立.

Solution: (1) 由 SLLN 可知

$$\hat{\theta}_n \xrightarrow{a.s.} EY_1 = \int \frac{f(z)}{g(z)}zg(z)dz = \int zf(z)dz = \mu.$$

(2) 由 CLT 可知

$$\sqrt{n}(\hat{\theta}_n - \mu) \xrightarrow{d} N(0, 1).$$

从而有

$$P(|\hat{\theta}_n - \mu| < \epsilon) = P\left(|\sqrt{n}(\hat{\theta}_n - \mu)| < \sqrt{n}\epsilon\right) \approx 2\Phi(\sqrt{n}\epsilon) - 1 \geq 1 - \alpha.$$

从而有

$$2\Phi(0.01\sqrt{n}) - 1 \geq 0.95 \Rightarrow \Phi(0.01\sqrt{n}) \geq 0.975,$$

即 $0.01\sqrt{n} \geq 1.96$, 故最小的 n 为 $196^2 = 38416$.

数理统计部分

六、(15 分) 设 $X_1, \dots, X_n$ 独立同分布于 $U(a, b)$, 其中 a, b 未知, $D = \{(a, b) | a \geq 0, b \leq 4, a \leq b - 2\}$.

(1)(5 分) 求 a, b 的矩估计;

(2)(5 分) 求 a, b 的 MLE;

(3)(5 分) 若 (a, b) 的先验分布为 D 上的均匀分布, 求 (a, b) 的后验最大概率估计.

Solution: (1)

$$\begin{cases} EX = \frac{a+b}{2} \\ EX^2 = \frac{a^2+ab+b^2}{3} \end{cases} \Rightarrow \begin{cases} a = EX - \sqrt{3}\sqrt{EX^2 - (EX)^2} \\ b = EX + \sqrt{3}\sqrt{EX^2 - (EX)^2} \end{cases}.$$

故矩估计为

$$\begin{cases} \hat{a}_M = \bar{X} - \sqrt{3}\sqrt{\bar{X}^2 - \bar{X}^2} = \bar{X} - \sqrt{3}S_n \\ \hat{b}_M = \bar{X} + \sqrt{3}\sqrt{\bar{X}^2 - \bar{X}^2} = \bar{X} + \sqrt{3}S_n \end{cases}.$$

(2) 常规的无约束 MLE. $\hat{a}_{MLE} = X_{(1)}, \hat{b}_{MLE} = X_{(n)}$.

(3) 先验分布为

$$\pi(a, b) = \frac{1}{S_d} = \frac{1}{2}I((a, b) \in D).$$

令 $l(a, b) = f(X|a, b)\pi(a, b) = \frac{1}{2}(b-a)^{-n}I(0 \leq a \leq X_{(1)} \leq X_{(n)} \leq b \leq 4, a \leq b-2)$, 显然在边界上取到最大值.

故 (a, b) 的后验最大概率估计为

$$\begin{cases} (x, x+2) \quad \forall x \in \left[\max \{X_{(n)} - 2, 0\}, \min \{X_{(1)}, 2\} \right], & X_{(n)} - X_{(1)} < 2 \\ (X_{(1)}, X_{(n)}), & X_{(n)} - X_{(1)} \geq 2 \end{cases}$$

Remark: 如果第二问认为 (a, b) 的参数空间为 D , 从而带约束的 MLE, 其结果和第三问一样. 但这样二三问基本上没有区别, 所以考场上更倾向于认为第二问就是常规的无约束 MLE. 如果是带约束的 MLE, 一般来说题干会是以下两种表达方式: (i) 设 $X_1, \dots, X_n$ 独立同分布于 $U(a, b)$, 其中 a, b 未知, (a, b) 的参数空间为 D , 其中 $D = \{(a, b) | a \geq 0, b \leq 4, a \leq b - 2\}$. (ii) 设 $X_1, \dots, X_n$ 独立同分布于 $U(a, b)$, 其中 a, b 未知, 且 $a \geq 0, b \leq 4, a \leq b - 2$.

七、(15 分) 设 $X_1, \dots, X_n$ 独立同分布于期望是 $\theta = 1/\lambda$ 的指数分布 $Exp(\lambda)$.

(1)(5 分) 请验证 $\bar{X}$ 是否为 θ 的 UMVUE;

(2)(5 分) 求 Fisher 信息量 $I(\lambda)$;

(3)(5 分) 请比较 θ 无偏估计的方差的 C-R 下界和 $\bar{X}$ 方差的大小关系.

Solution: (1) 指数分布为完备指数族, 从而 $\bar{X}$ 是充分完备统计量. 而 $E\bar{X} = \theta$, 由 L-S 定理可知, $\bar{X}$ 是 θ 的 UMVUE.

(2) 密度函数为 $f(x) = \lambda e^{-\lambda x} I(x > 0)$, 对数似然为

$$l(\lambda) = \log f(\lambda) = \log \lambda - \lambda X.$$

故直接计算有

$$I(\lambda) = -E \left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2} \right) = \frac{1}{\lambda^2}.$$

(3) C-R 下界为 $I_{CR} = \frac{(g'(\lambda))^2}{nI(\lambda)} = \frac{1}{n\lambda^2}$, 而 $Var(\bar{X}) = \frac{1}{n\lambda^2} = I_{CR}$. 两者相等.

八、(10 分) 设 $(X_i, Y_i)^T \stackrel{i.i.d.}{\sim} N_2(\mu, \Sigma), i = 1, 2, \dots, n$, 其中 $\mu = (\mu_1, \mu_2)^T, \Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$.

(1)(5 分) 考虑检验问题 $H_0: \rho = 0$, 请给出其似然比检验并指出检验统计量 T ;

(2)(5 分) 请基于上一问中的检验统计量 T , 构造出水平为 α 的拒绝域.

Solution: (1) 记 $Z_i = (X_i, Y_i)^T$, 在 Θ 下,

$$\begin{cases} \hat{\mu} = \frac{1}{n} \sum_{i=1}^n Z_i \\ \hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (Z_i - \bar{Z})(Z_i - \bar{Z})^T \end{cases} \Rightarrow \begin{cases} \hat{\mu}_1 = \bar{X} \\ \hat{\mu}_2 = \bar{Y} \\ \hat{\sigma}_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\ \hat{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \\ \hat{\rho} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} \end{cases}$$

在 Θ_0 下, $\tilde{\mu}_1 = \bar{X}, \tilde{\mu}_2 = \bar{Y}, \tilde{\sigma}_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \tilde{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2$.

进而有

$$\Lambda(X) = \frac{f(\hat{\mu}, \hat{\Sigma})}{f(\tilde{\mu}, \tilde{\Sigma})} = (1 - \hat{\rho}^2)^{-n/2}.$$

统计量 $T = \hat{\rho}$.

(2) [法一] 注意到 $\hat{\rho}^2 = R^2$, 其中 R^2 是回归方程 $Y = a + bX$ 的拟合优度, 满足 $\frac{R^2}{(1-R^2)/(n-2)} = F \sim F(1, n-2)$, 因此有 $\hat{\rho}^2 = \frac{F}{(n-2)+F}$, 关于 F 是单增函数, 故拒绝域是

$$W = \left\{ \hat{\rho}^2 > \frac{F_{1-\alpha}(1, n-2)}{(n-2) + F_{1-\alpha}(1, n-2)} \right\}.$$

[法二] 我们考虑使用 Wilks 定理, 即似然比的渐进分布, 从而有

$$2 \log \Lambda(X) \xrightarrow{d} \chi^2(1).$$

故水平为 α 的拒绝域为

$$W = \left\{ 2 \log \Lambda(X) = -n \log(1 - T^2) > \chi_{1-\alpha}^2(1) \right\}.$$

[法三] 注意到 $\hat{\rho}^2 = \frac{F}{(n-2)+F}$, 因此有 $(n-2)\hat{\rho}^2 = \frac{F}{1+F/(n-2)}$, 分母中 $1 + F/(n-2) \xrightarrow{P} 1$, 而分子 $F \sim F(1, n-2) = t(n-2)^2$, 而 $t(n-2) \xrightarrow{d} N(0, 1)$, 再把 $n-2$ 替换为 n , 渐进分布不变, 因此有

$$\sqrt{n}\hat{\rho} \xrightarrow{d} N(0, 1),$$

故近似拒绝域是 $W = \left\{ |\hat{\rho}| > \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \right\}$. 这是实操时的常作方法.

Remark: 实际上我们可以得到 T 的精确分布, 考虑 $\frac{T\sqrt{n-2}}{\sqrt{1-T^2}} \sim t(n-2)$ 或者是 $\frac{T^2}{(1-T^2)/(n-2)} \sim F(1, n-2)$.

$$f_T(t) = \frac{\Gamma\left(\frac{n-1}{2}\right)}{\sqrt{\pi}\Gamma\left(\frac{n-2}{2}\right)} (1-t^2)^{(n-4)/2} I(-1 < t < 1).$$

再根据精确分布构造拒绝域.

九、(10 分) 考虑多元回归模型 $Z = Y\beta + e$, 其中 $Y = (Y_1^T, Y_2^T, \dots, Y_n^T)^T, Y_i \in \mathbb{R}^d, i = 1, 2, \dots, n$. 此外 $E(e) = 0, \text{Var}(e) = \sigma^2 I_n$, 并且 Y 已知且列满秩. 若 $\hat{\beta}$ 是 β 的最小二乘估计.

(1)(6 分) 请证明 $\text{Var}(\hat{\beta}) = \sigma^2(Y^T Y)^{-1}$;

(2)(4 分) 请证明残差平方和 $Q(\hat{\beta})$ 的期望为 $(n-d)\sigma^2$.

Solution: (1) $\hat{\beta} = (Y^T Y)^{-1} Y^T Z$, 从而有

$$\text{Var}(\hat{\beta}) = (Y^T Y)^{-1} Y^T \text{Var}(Z) \left((Y^T Y)^{-1} Y^T \right)^T = \sigma^2 (Y^T Y)^{-1}.$$

(2) 记 $P_Y = Y(Y^T Y)^{-1} Y^T$ 为投影阵, 显然 $I_n - P_Y$ 也是个投影阵, 有 $(I_n - P_Y)^T (I_n - P_Y) = I_n - P_Y$, 从而

$$Q(\hat{\beta}) = \|Z - Y\hat{\beta}\|^2 = (Z - Y\hat{\beta})^T (Z - Y\hat{\beta}) = Z^T (I_n - P_Y) Z$$

由二次型期望公式, 若 A 为对称阵, 且 $EX = \mu, \text{Var}(X) = \Sigma$, 则有

$$E(X^T A X) = \mu^T A \mu + \text{tr}(A \Sigma).$$

最终有

$$EQ(\hat{\beta}) = \text{tr} \left((I_n - P_Y) \sigma^2 I_n \right) = \sigma^2 \text{tr}(I_n - P_Y) = (n-d)\sigma^2.$$

金融数学引论部分

一、(10 分) 求实际年利率并排大小:

(1) 半年名利率百分之二; (2) 季度名贴现率百分之二; (3) 利息力为常数百分之二; (4) 半年期债券, 价格 99, 兑现值 100.

Solution: (1) $i_1 = (1 + 0.01)^2 - 1 = 0.0201$; (2) $\frac{1}{1+i_2} = (1 - 0.005)^4 = 0.98015$, 解得 $i_2 = 0.02025$; (3) $i_3 = e^{0.02} - 1 = 0.0202$; (4) $(1 + i_2)^{1/2} = \frac{100}{99}$, 解得 $i_4 = 0.0203$.

故有 $i_1 < i_3 < i_2 < i_4$.

二、(15 分) 某人借款 100 万元, 每月偿还, 实利率 0.45 %.

(1) 按 25 年期偿还, 求每次还款额.

(2) 已经还了 60 次, 重现协商利率为 0.35%, 将剩余余额作为一个新的 15 年期贷款, 求每月还款额.

(3) 设他还想重新贷款一个新的 15 年贷款, 利率还是 0.35%. 但目前有新规出台, 每个人的月贷款不能超过工资的 50%, 它的工资是 20000 元, 问他还能贷款多少?

Solution: (1) $n = 25 \cdot 12 = 300$, 故有 $a_{n|0.45\%} = \frac{1 - (1 + 0.35\%)^{-300}}{0.45\%} = 164.4385$, 因此 $R = \frac{1000000}{a_{n|0.45\%}} = 6081.30$ 元.

(2) 剩余期限是 $n_1 = 300 - 60 = 240$, 故余额是 $B_{60} = R \cdot a_{n_1|0.45\%} = 891357.2735$ 元. 重新计算

$$R_1 = \frac{891357.2735}{a_{180|0.35\%}} = 6682.9542.$$

(3) 他每月还能还款 $R_2 = 10000 - R_1 = 3317.0558$, 因此还能贷款

$$Q = R_2 a_{180|0.35\%} = 442420.0429.$$

也可以直接计算 $Q = \frac{3317.0558}{6682.9542} \cdot 891357.2735 = 442420.0429$.

三、(10 分) 现有 10 万元投资国债, 半年名息率 5%, 兑现值 10 万元, 半年将票息存入银行, 定期半年名利率 2%, 同时后续每半年将此前的银行半年期本息取出和新票息一起继续再次存入, 求累计值和实际年利率.

Solution: 每半年的票息是 $Cg = 100000 \cdot 2.5\% = 2500$, 故 $B_0 = 0$, $B_1 = 2500$ (0.5 年为一个单位), 而 $B_t = 1.01B_{t-1} + 2500$, $t \leq 20$, 因此有 $B_t + 250000 = 1.01(B_{t-1} + 250000)$, 故

$$B_{20} = 1.01^{20}(B_0 + 250000) - 250000 = 55047.5$$

当然, 这一系列计算可以用递增年金. 不过这里没有加上最后的兑现值, 故终值 $F = 155047.5$, 收益率是 4.48%.

四、(15 分) 有两个债券, 分别是 3 年期和 5 年期, 前者年息率是 2%, 后者是 4%, 市场利率 3%, 面值与兑现值均为 100.

(1) 求债券价格和久期.

(2) 两个债券按比例组合后久期是 3 年, 求组合比例.

Solution: (1) 债券价格:

$$P_3 = \frac{2}{1.03} + \frac{2}{1.03^2} + \frac{102}{1.03^3} = 97.1714,$$

$$P_5 = \frac{4}{1.03} + \frac{4}{1.03^2} + \frac{4}{1.03^3} + \frac{4}{1.03^4} + \frac{104}{1.03^5} = 104.58.$$

债券久期:

$$D_3 = \frac{1}{P_3} \left(\frac{2}{1.03} + 2 \cdot \frac{2}{1.03^2} + 3 \cdot \frac{102}{1.03^3} \right) = 2.94063,$$

$$D_5 = \frac{1}{P_5} \left(\frac{4}{1.03} + 2 \cdot \frac{4}{1.03^2} + 3 \cdot \frac{4}{1.03^3} + 4 \cdot \frac{4}{1.03^4} + 5 \cdot \frac{104}{1.03^5} \right) = 4.6393.$$

(2) 设组合 P 投资 x 在第一个债券, $y = 1 - x$ 在第二个债券, 则组合久期

$$3 = \frac{xP_3D_3 + (1-x)P_5D_5}{xP_3 + (1-x)P_5}$$

解得 $x = 0.9674$.

北京大学叉院-849 统计学/432 统计学

北大叉院-849 统计学-2016 年

一、(10 分) 在 7 黑球 3 白球中无放回抽 2 次, 求

(1)(5 分) 第 2 次是白球的概率;

(2)(5 分) 已知第 2 次是黑球, 求第一次是黑球的概率.

Solution:

(1) 用 W_i 表示第 i 次取到的是白球, 则由全概率公式

$$\begin{aligned} P(W_2) &= P(W_2 | W_1) P(W_1) + P(W_2 | \bar{W}_1) P(\bar{W}_1) \\ &= \frac{2}{9} \cdot \frac{3}{10} + \frac{3}{9} \cdot \frac{7}{10} = \frac{6}{90} + \frac{21}{90} = \frac{3}{10} \end{aligned}$$

(2) 由乘法公式, 有

$$P(\bar{W}_1 | \bar{W}_2) = \frac{P(\bar{W}_1 \bar{W}_2)}{P(\bar{W}_2)} = \frac{\frac{7}{10} \cdot \frac{6}{9}}{1 - \frac{3}{10}} = \frac{2}{3}$$

二、(10 分) X, Y 服从 $\{x^2 + y^2 \leq 1\}$ 上的均匀分布, 求

(1)(5 分) X, Y 的分布;

(2)(5 分) 证明 X, Y 不独立.

Solution:

(1) 记 $D = \{x^2 + y^2 \leq 1\}$, 则 $S_D = \pi$, 于是 (X, Y) 的联合密度为

$$f(x, y) = \begin{cases} \frac{1}{\pi}, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

则 X 的边缘密度函数为

$$f_X(x) = \int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}} \frac{1}{\pi} dy = \frac{2\sqrt{1-x^2}}{\pi}, -1 < x < 1$$

同理 Y 的边缘密度函数是 $f_Y(y) = \frac{2\sqrt{1-y^2}}{\pi}, -1 < y < 1$.

(2) 因为 $f_X(x)f_Y(y) \neq f(x, y)$, 所以 X 与 Y 不独立.

三、(15 分) $x_1, \dots, x_n$ i.i.d. $\sim f(x) = 2\lambda x e^{-\lambda x^2}, x > 0$, 求

(1)(5 分) λ 的 MLE;

(2)(5 分) 讨论无偏性;

(3)(5 分) 讨论相合性.

Solution:

(1) 似然函数为 $L(\lambda) = 2^n \lambda^n (\prod_{i=1}^n x_i) e^{-\lambda \sum_{i=1}^n x_i^2}$, 取对数处理, 有

$$\ln L(\lambda) = n \ln 2 + n \ln \lambda + \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n x_i^2$$

令 $\frac{d \ln L}{d \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i^2 = 0$, 解得驻点 $\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^2}$. 又由于 $\frac{d^2 \ln L}{d \lambda^2} = -\frac{n}{\lambda^2} < 0$, 于是所求驻点是对数似然函数的极大值点, 综上所述 $\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^2}$ 是 λ 的 MLE.

(2) 作总体变换, 令 $Y = X^2$, 则 $Y \sim f_Y(y) = \lambda e^{-\lambda y}, y > 0$. 即 X_i^2 相互独立服从参数为 λ 的指数分布, 因为 $g(t) = \frac{1}{t}$ 在 $(0, +\infty)$ 上是严格凸函数, 所以由 Jensen 不等式

$$E(\hat{\lambda}) = E\left(\frac{n}{\sum_{i=1}^n x_i^2}\right) > n \frac{1}{E(\sum_{i=1}^n x_i^2)} = \frac{n}{n\lambda} = \lambda$$

于是 $\hat{\lambda}$ 不是 λ 的无偏估计. (需要注意地是, Jensen 不等式的取等条件为 “ $g(t)$ 几乎处处是线性函数”, 而此处显然不是, 于是 Jensen 不等式严格成立.) 或者利用 $\sum x_i^2 \sim Ga(n, \lambda)$, 计算得到 $E\left(\frac{n}{\sum_{i=1}^n x_i^2}\right) = \frac{n}{n-1}\lambda$, 同样可以说明它不是无偏估计, 但显然不如 Jensen 不等式来得快.

(3) 由于 X_i^2 相互独立, 均服从参数为 λ 的指数分布, 则根据强大数定律, 有

$$\frac{\sum_{i=1}^n x_i^2}{n} \rightarrow \frac{1}{\lambda}, \text{ a.s.}$$

故 $\sum_{i=1}^n \frac{n}{x_i^2} \rightarrow \lambda, \text{ a.s.}$, 即 $\hat{\lambda}$ 是 λ 的强相合估计.

四、(15 分) 有来自总体 $X \sim N(\mu_1, \sigma_1^2)$ 的 $m = 4$ 个独立样本, 其中 $\bar{x} = 125, s_x = 2$, 有来自总体 $Y \sim N(\mu_2, \sigma_2^2)$ 的 $n = 9$ 个样本, 其中 $\bar{y} = 140, s_y = 3$, 求

(1)(7 分) μ_1, μ_2 的 95% 置信区间;

(2)(8 分) 假设检验问题 $H_0: \mu_1 = \mu_2$ 的拒绝域, 其中 $\alpha = 0.05$.

Solution:

(1) 先讨论 μ_1 , 以 $T = \frac{\sqrt{m}(\bar{x} - \mu_1)}{s_x} \sim t(m-1)$ 为枢轴量, 则 μ_1 的 $1-\alpha$ 水平的置信区间为 $\bar{x} \pm \frac{s_x}{\sqrt{m}} t_{1-\frac{\alpha}{2}}(m-1)$, 代入 $\bar{x} = 125, s_x = 2, m = 4, \alpha = 0.05$, 有

$$\bar{x} \pm t_{0.975}(3) = 125 \pm 3.1824 = [121.8176, 128.1824]$$

同理 μ_2 的 $1-\alpha$ 水平的置信区间为 $\bar{y} \pm \frac{s_y}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$, 代入 $\bar{y} = 140, s_y = 3, n = 9, \alpha = 0.05$, 有

$$\bar{y} \pm t_{0.975}(8) = 140 \pm 2.3060 = [137.6940, 142.3060]$$

(2) 先判断是否有 $\sigma_1^2 = \sigma_2^2$, 建立如下假设检验问题:

$$H_{10}: \frac{\sigma_1^2}{\sigma_2^2} = 1 \text{ vs } H_{11}: \frac{\sigma_1^2}{\sigma_2^2} \neq 1$$

该问题的拒绝域是

$$W_1 = \left\{ \frac{s_x^2}{s_y^2} \leq F_{\frac{\alpha}{2}}(m-1, n-1) \right\} \cup \left\{ \frac{s_x^2}{s_y^2} \geq F_{1-\frac{\alpha}{2}}(m-1, n-1) \right\}$$

此时 $m = 4, n = 9, \alpha = 0.05$. 查表有 $F_{0.025}(3, 8) = 0.0688, F_{0.975}(3, 8) = 5.4160$, 而 $\frac{s_x^2}{s_y^2} = \frac{4}{9} \notin W_1$, 于是我们可以接受 H_{10} , 即认为有 $\sigma_1^2 = \sigma_2^2$. 接下来我们来检验 H_0 是否成立, 在 $\sigma_1^2 = \sigma_2^2$ 的条件下, 该问题的检验统计量是 $t = \frac{\bar{x} - \bar{y}}{s_w \sqrt{\frac{1}{m} + \frac{1}{n}}}$, 这里 $s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2}$. 而拒绝域是 $W_0 = \{|t| \geq t_{1-\frac{\alpha}{2}}(m+n-2)\}$. 查表有 $t_{0.975}(11) = 2.2010$, 代入数据计算得 $s_w^2 = \frac{3 \cdot 4 + 8 \cdot 9}{11} = \frac{84}{11}$, 则当前检验统计量的观测值为 $t = \frac{125-140}{\sqrt{\frac{84}{11}} \sqrt{\frac{1}{4} + \frac{1}{9}}} = -9.0329 \in W_0$, 于是我们应该拒绝原假设, 即认为 $\mu_1 \neq \mu_2$.

五、(20 分) 回答下述问题:

(1)(10 分) 叙述 N-P 引理;

(2)(10 分) 利用 N-P 引理推导 UMP 否定域, 并求犯第二类错误的概率:

$$H_0: X \sim N(0, 1) \text{ vs } H_1: X \sim N(2, 1).$$

其中 $x_1, \dots, x_n$ 是来自总体 X 的 i.i.d. 样本.

Solution:

(1) 对于总体 $f(x|\theta)$ 以及检验问题

$$H_0: \theta = \theta_0 \text{ vs } H_1: \theta = \theta_1$$

$W = \{L(\mathbf{X}|\theta_1) > \lambda L(\mathbf{X}|\theta_0)\}$ 是该问题 α 水平的 UMP 拒绝域. 其中 λ 是常数, 满足 $P(\mathbf{X} \in W | \theta = \theta_0) = \alpha$.

(2)

$$\begin{aligned} W &= \{L(\mathbf{X} | \mu = 2) > \lambda L(\mathbf{X} | \mu = 0)\} \\ &= \left\{ (2\pi)^{-\frac{n}{2}} e^{-\frac{\sum_{i=1}^n (x_i - 2)^2}{2}} > \lambda (2\pi)^{-\frac{n}{2}} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} \right\} \\ &= \left\{ \exp \left\{ -\frac{1}{2} \left[\sum_{i=1}^n x_i^2 - \sum_{i=1}^n (x_i - 2)^2 \right] \right\} > \lambda \right\} \\ &= \left\{ \sum_{i=1}^n (2x_i - 2) > \ln \lambda \right\} = \left\{ \bar{x} > 1 + \frac{\ln \lambda}{n} \right\} \end{aligned}$$

记 $C = 1 + \frac{\ln \lambda}{n}$, 则 C 使得 $P\{\bar{x} > C | \mu = 0\} = \alpha$, 解得 $C = \frac{u_{1-\alpha}}{\sqrt{n}}$, 则由 N-P 引理可知, $W = \{\sqrt{n}\bar{x} > u_{1-\alpha}\}$ 是该假设检验问题的 UMP 拒绝域.

$$\begin{aligned} \beta &= P\{\mathbf{X} \notin W | \mu = 2\} \\ &= P\left(\bar{x} \leq \frac{u_{1-\alpha}}{\sqrt{n}} | \mu = 2\right) \\ &= P\left(\sqrt{n}(\bar{x} - 2) \leq \sqrt{n}\left(\frac{u_{1-\alpha}}{\sqrt{n}} - 2\right) | \mu = 2\right) = \Phi(u_{1-\alpha} - 2\sqrt{n}) \end{aligned}$$

六、(30 分) 已知 $Y_i = X_i^T \beta + \varepsilon_i, i = 1, 2, \dots, n, \varepsilon_i \text{ i.i.d. } \sim N(0, \sigma^2), X_i = (X_{1i}, X_{2i}, \dots, X_{si})^T$ 是已知的常数,

(1)(10 分) 求 β, σ^2 的 MLE $\hat{\beta}, \hat{\sigma}^2$;

(2)(10 分) 求 $\hat{\beta}$ 的分布;

(3)(10 分) $Y_i = a + bx_i + \varepsilon_i, i = 1, 2, \dots, n, \varepsilon_i \text{ i.i.d. } \sim N(0, \sigma^2)$, 求 MLE $\hat{a}, \hat{b}$, 并证明 $\hat{a}, \hat{b}$ 独立当且仅当 $\sum_{i=1}^n x_i = 0$.

Solution:

(1) $Y_i \sim N(\mathbf{X}_i \beta, \sigma^2)$, 则样本的似然函数是

$$\begin{aligned} L(\beta, \sigma^2) &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{X}_i^T \beta)^2 \right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{Y} - X\beta)^T (\mathbf{Y} - X\beta) \right\} \end{aligned}$$

其中 $\mathbf{Y} = (y_1, y_2, \dots, y_n)^T, X = [\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n]^T$, 对数似然函数是

$$\ln L(\beta, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{Y} - X\beta)^T (\mathbf{Y} - X\beta)$$

关于各个分量求偏导并置 0, 得到似然方程组,

$$\begin{cases} \frac{\partial \ln L}{\partial \beta} = \frac{1}{\sigma^2} (2X^T \mathbf{Y} - 2X^T X \beta) = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} - \frac{1}{2\sigma^4} (\mathbf{Y} - X\beta)^T (\mathbf{Y} - X\beta) = 0 \end{cases}$$

其中由于 X 满秩, 所以 $X^T X$ 是可逆的, 于是解得对数似然函数的唯一驻点 $\hat{\beta} = (X^T X)^{-1} X^T Y, \hat{\sigma}^2 = \frac{1}{n} (Y - X\hat{\beta})^T (Y - X\hat{\beta})$, 而对数似然函数显然是一山函数, 于是该驻点为其唯一最大值点, 即 $\hat{\beta}$ 与 $\hat{\sigma}^2$ 便是 β 与 σ^2 的 MLE.

(2) $Y = (Y_1, Y_2, \dots, Y_n)^T$ 服从多元正态分布, 即 $Y \sim N(X\beta, \sigma^2 I_n)$. 而 $\hat{\beta} = (X^T X)^{-1} X^T Y$, 于是 $\hat{\beta}$ 亦服从多元正态分布, 且 $E\hat{\beta} = (X^T X)^{-1} X^T X\beta = \beta$ $\text{Cov}(\hat{\beta}) = \sigma^2 (X^T X)^{-1} X^T I_n X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$ 于是 $\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$.

(3) 令 $\beta = (a, b)^T$, 利用 (1) 与 (2) 的结果可知,

$$\begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} \sim N \left(\begin{pmatrix} a \\ b \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} & -\frac{\bar{x}}{l_{xx}} \\ -\frac{\bar{x}}{l_{xx}} & \frac{1}{l_{xx}} \end{pmatrix} \right)$$

其中, $l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$, 由正态分布的性质, $\hat{a}$ 与 $\hat{b}$ 独立当且仅当 $\hat{a}$ 与 $\hat{b}$ 不相关. 而 $\hat{a}$ 与 $\hat{b}$ 不相关. 当且仅当 $\bar{x} = 0$, 即 $\sum_{i=1}^n x_i = 0$.

七、(20 分) 有独立随机序列 X_n , 其分布列是 $P\{X_n = n^\alpha\} = \frac{1}{n}, P\{X_n = 0\} = 1 - \frac{1}{n}$, 问 α 取何值时,

(1)(10 分) X_n 依概率收敛到 0;

(2)(10 分) X_n 几乎必然收敛到 0.

Solution:

(1) 对 $\forall \varepsilon > 0$, $P(|X_n| \geq \varepsilon) \leq P(X_n \neq 0) = \frac{1}{n} \rightarrow 0$. 所以对 $\forall \alpha$, 都有 $X_n \xrightarrow{P} 0$.

(2) 当 $\alpha < 0$ 时, 由马尔可夫不等式, 有 $P(|X_n| \geq \varepsilon) \leq \frac{EX_n}{\varepsilon} = \frac{n^{\alpha-1}}{\varepsilon}$. 而 $\sum_{n=1}^{\infty} P(|X_n| \geq \varepsilon) < +\infty$, 故由 Borel-Cantelli 引理可知 $X_n \rightarrow 0$, a.s. 当 $\alpha \geq 0$, 对 $\forall \varepsilon \in (0, 1)$, 对于任意的 n , 都有 $n^\alpha \geq \varepsilon$, 故 $P(|X_n| \geq \varepsilon) = P(X_n \neq 0) = \frac{1}{n}$, 则 $\sum_{n=1}^{\infty} P(|X_n| \geq \varepsilon) = \sum_{n=1}^{\infty} \frac{1}{n} = +\infty$, 根据 0-1 律知 $X_n \not\rightarrow 0$, a.s.

八、(30 分) 已知 $X_1, X_2, \dots, X_n$, i.i.d. $\sim \text{Exp}(\frac{1}{\theta})$

(1)(10 分) MLE $\hat{\theta}$;

(2)(10 分) 费雪信息量 $I(\theta)$;

(3)(10 分) 是否存在 θ 的有效估计.

Solution:

(1) 似然函数为 $L(\theta) = \frac{1}{\theta^n} e^{-\sum_{i=1}^n \frac{x_i}{\theta}}$, 取对数并关于参数求导置 0, 有

$$\frac{d \ln L}{d \theta} = -\frac{n}{\theta} + \frac{\sum_{i=1}^n x_i}{\theta^2} = 0$$

解得对数似然函数的唯一驻点为 $\hat{\theta} = \bar{x}$, 而根据单参指数族的性质可知, 它必定是 θ 的 MLE.

(2)

$$\begin{aligned} I(\theta) &= E \left[\frac{\partial \ln f(X, \theta)}{\partial \theta} \right]^2 \\ &= E \left(-\frac{1}{\theta} + \frac{X}{\theta^2} \right)^2 \\ &= E \left(\frac{1}{\theta^2} - \frac{2X}{\theta^3} + \frac{X^2}{\theta^4} \right) = \frac{1}{\theta^2} \end{aligned}$$

(3) $E\bar{x} = EX_1 = \theta$, 故 $\bar{x}$ 是 θ 的无偏估计, 其方差 $\text{Var}(\bar{x}) = \frac{1}{n} \text{Var}(X_1) = \frac{\theta^2}{n}$. 而 θ 无偏估计的方差的 C-R 下界是 $\frac{1}{nI(\theta)} = \frac{\theta^2}{n}$, 于是 $\bar{x}$ 是 θ 的有效估计.

北大叉院-849 统计学-2017 年

一、(15 分) X 以等概率取 $-1, 0, 1$, $Y \sim U(0, 1)$, 相互独立, 求 $X + Y$ 的概率密度.

Solution: 记 $Z = X + Y$, 则由全概率公式以及微分法

$$\begin{aligned} P(Z = z) &= P(X + Y = z) \\ &= \sum_{x=-1}^1 P(Y = z - x)P(X = x) \\ &= \frac{1}{3} \sum_{x=-1}^1 \mathbf{I}_{\{0 < z-x < 1\}} dz \\ &= \frac{1}{3} \mathbf{I}_{\{-1 < z < 2\}} dz \end{aligned}$$

于是 $f_Z(z) = \frac{1}{3} \mathbf{I}_{\{-1 < z < 2\}}$.

二、(15 分) (X, Y) 服从 $D = \{0 < x < 1, 0 < y < x\}$ 上的均匀分布, 求 ρ_{XY} .

Solution: $S_D = \frac{1}{2}$, 于是 $f(x, y) = \begin{cases} 2, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$. 于是

$$\begin{aligned} EX &= \int_0^1 2x \, dx \int_0^x dy = \int_0^1 2x^2 \, dx = \frac{2}{3} \\ EX^2 &= \int_0^1 2x^2 \, dx \int_0^x dy = \int_0^1 2x^3 \, dx = \frac{1}{2} \\ \text{Var}(X) &= \frac{1}{2} - \frac{4}{9} = \frac{1}{18} \\ EY &= \int_0^1 2 \, dx \int_0^x y \, dy = \int_0^1 x^2 \, dx = \frac{1}{3} \\ EY^2 &= \int_0^1 2 \, dx \int_0^x y^2 \, dy = \int_0^1 \frac{2}{3} x^3 \, dx = \frac{1}{6} \\ \text{Var}(Y) &= \frac{1}{6} - \frac{1}{3} = \frac{1}{18} \end{aligned}$$

而 $EXY = \int_0^1 2x \, dx \int_0^x y \, dy = \int_0^1 x^3 \, dx = \frac{1}{4}$, 于是

$$\text{Cov}(X, Y) = EXY - EXEY = \frac{1}{4} - \frac{2}{3} \cdot \frac{1}{3} = \frac{1}{36}$$

则 $\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\frac{1}{36}}{\sqrt{\frac{1}{18} \cdot \frac{1}{18}}} = \frac{1}{2}$.

三、(15 分) 长为 1 的木棒分为 3 段, 求能构成三角形的概率.

Solution: 设分段点分别 $X_1, X_2 \text{ i.i.d } \sim U(0, 1)$, 则三段的长度分别是

$$x_{(1)}, x_{(2)} - x_{(1)}, 1 - x_{(2)}$$

设事件 A 表示三段可以构成三角形, 则

$$\begin{aligned} A &= \{x_{(1)} + x_{(2)} - x_{(1)} > 1 - x_{(2)}\} \cap \{x_{(1)} + 1 - x_{(2)} > x_{(2)} - x_{(1)}\} \cap \{1 - x_{(2)} + x_{(2)} - x_{(1)} > x_{(1)}\} \\ &= \left\{x_{(2)} > \frac{1}{2}, x_{(2)} - x_{(1)} < \frac{1}{2}, x_{(1)} < \frac{1}{2}\right\} \end{aligned}$$

于是

$$P(A) = \int_0^{\frac{1}{2}} 2dx_1 \int_{\frac{1}{2}}^{x_1+\frac{1}{2}} dx_2 = 2 \int_0^{\frac{1}{2}} x_1 dx_1 = \frac{1}{4}$$

(注: 这里 $(x_{(1)}, x_{(2)}) \sim f(x_1, x_2) = 2\mathbf{I}_{\{0 < x_1 < x_2 < 1\}}$)

[注]: 本题出现贝特朗奇论, 答案中的做法是随机切成三段, 三段长度倾向于均匀. 如果认为我们先切一刀 $X \sim U(0, 1)$, 再在剩下的切一刀 $Y|X = x \sim U(0, 1 - x)$, 剩下的是 $Z = 1 - X - Y$, 组成三角形的概率则是 $\ln 2 - \frac{1}{2}$. 这样考虑的话, 三段长度不是同分布的, 第一段明显倾向于比另外两段长.

四、(15 分) (X_i, Y_i) 满足 $Y_i = a + bX_i + \varepsilon_i$, ε_i i.i.d. $\sim N(0, \sigma^2)$, 其中 a, b, σ 未知, 现观测到一组新数据 X_0 , 求 Y_0 的 95% 置信区间.

Solution:

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \sim N\left(y_0, \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}\right) \sigma^2\right)$$

$$\text{这里} \begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{cases}$$

用枢轴量 $T = \frac{y_0 - \hat{y}_0}{\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}}} \sim t(n-2)$, 其中 $\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{n-2}$. 可构造 y_0 的 0.95 置信水平的置信区间

$$\hat{y}_0 \pm \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} t_{0.975}(n-2)$$

五、(15 分) 总体 X 的密度函数 $f(x)$ 光滑, 且任意 x_1, x_2 有 $|f(x_1) - f(x_2)| \leq L|x_1 - x_2|$, L 为已知常数, 定义 $\hat{f}(x_0) = \frac{1}{N\lambda} \sum_{i=1}^N K\left(\frac{x_0 - x_i}{\lambda}\right)$, 其中 $M \geq K(t) \geq 0$, 且在勒贝格积分意义下,

$$\int_{-\infty}^{+\infty} K(t) dt = 1, \int_{-\infty}^{+\infty} tK(t) dt = 0, \int_{-\infty}^{+\infty} t^2 K(t) dt = \sigma_k^2 < \infty,$$

这里 M 和 σ_k^2 均为已知常数, 证明:

- (1) (5 分) $|E\hat{f}(x_0) - f(x_0)| \leq c_1 \lambda$;
- (2) (5 分) $\text{Var}[\hat{f}(x_0)] \leq \frac{c_2}{N\lambda^2}$;
- (3) (5 分) 选择合适的 λ , 使 $\text{MSE}[\hat{f}(x_0)] \leq c_3 N^{-\frac{1}{2}}$.

Solution:

(1)

$$\begin{aligned} E\hat{f}(x_0) &= E\left[\frac{1}{N\lambda} \sum_{i=1}^N K\left(\frac{x_0 - X_i}{\lambda}\right)\right] \\ &= \frac{1}{\lambda} EK\left(\frac{x_0 - X_1}{\lambda}\right) = \frac{1}{\lambda} \int_{-\infty}^{+\infty} K\left(\frac{x_0 - x}{\lambda}\right) f(x) dx = \int_{-\infty}^{+\infty} K(u) f(x_0 - \lambda u) du \end{aligned}$$

而 $f(x_0) = \int_{-\infty}^{+\infty} K(u) f(x_0) du$, 所以

$$\begin{aligned} |E\hat{f}(x_0) - f(x_0)| &= \left| \int_{-\infty}^{+\infty} K(u) [f(x_0 - \lambda u) - f(x_0)] du \right| \\ &\leq \int_{-\infty}^{+\infty} |K(u) L \lambda u| du = \lambda L \int_{-\infty}^{+\infty} |u| K(u) du \end{aligned}$$

由于 $\int_{-\infty}^{+\infty} uK(u) du = 0$, 则 $\int_{-\infty}^{+\infty} |u|K(u) du$ 收敛, 记 $c_1 = L \int_{-\infty}^{+\infty} |u|K(u) du$, 则有

$$|E\hat{f}(x_0) - f(x_0)| \leq c_1 \lambda$$

(2)

$$\begin{aligned}
\text{Var} [\hat{f}(x_0)] &= \frac{1}{N^2 \lambda^2} \sum_{i=1}^N \text{Var} \left[K \left(\frac{x_0 - X_i}{\lambda} \right) \right] \\
&= \frac{1}{N \lambda^2} \text{Var} \left[K \left(\frac{x_0 - X_1}{\lambda} \right) \right] \\
&\leq \frac{1}{N \lambda^2} E K^2 \left(\frac{x_0 - X_1}{\lambda} \right) \leq \frac{M^2}{N \lambda^2} = \frac{c_2}{N \lambda^2}
\end{aligned}$$

(3)

$$\begin{aligned}
\text{MSE} (\hat{f}(x_0)) &= [E \hat{f}(x_0) - f(x_0)]^2 + \text{Var} [\hat{f}(x_0)] \\
&\leq c_1^2 \lambda^2 + \frac{c_2}{N \lambda^2} \\
(\text{取 } \lambda = N^{-\frac{1}{4}}) &= c_1^2 N^{-\frac{1}{2}} + c_2 N^{-\frac{1}{2}} = c_3 N^{-\frac{1}{2}}
\end{aligned}$$

六、(20 分) 总体 $X \sim U(0, \theta)$, 随机样本 $x_1, x_2, \dots, x_n$, 求:

(1)(5 分) θ 的矩估计 $\hat{\theta}$;

(2)(5 分) θ 的 MLE $\hat{\theta}_1$;

(3)(5 分) 讨论 $\hat{\theta}$ 的相合性;

(4)(5 分) 讨论 $\hat{\theta}_1$ 的无偏性与相合性.

Solution:

(1) $EX = \frac{\theta}{2}$, 则 $\hat{\theta}_M = 2\bar{x}$ 是 θ 的矩估计.

(2) 似然函数 $L(\theta) = \frac{1}{\theta^n} \mathbf{I}_{\{x_{(n)} \leq \theta\}}$ 是 θ 在 $[x_{(n)}, +\infty)$ 上的减函数, 显然 $\hat{\theta}_L = x_{(n)}$ 是 θ 的极大似然估计.

(3) 根据强大数定律, $\bar{x} \rightarrow \frac{\theta}{2}$, a.s.. 于是 $2\bar{x} \rightarrow \theta$, a.s., 即 $\hat{\theta}_M$ 是 θ 的强相合估计.

(4) 由于 $T = \frac{x_{(n)}}{\theta} \sim \text{Beta}(n, 1)$, 则 $E x_{(n)} = \frac{n}{n+1} \theta$, 即 $\hat{\theta}_M$ 不是 θ 的无偏估计. 但 $E x_{(n)} = \frac{n}{n+1} \theta \rightarrow \theta$, 同时又有

$$\sum_{n=1}^{\infty} \text{Var} (x_{(n)}) = \sum_{n=1}^{\infty} \frac{n}{(n+1)^2(n+2)} \theta < +\infty$$

于是 $x_{(n)} \rightarrow \theta$, a.s., 即 $\hat{\theta}_M$ 是 θ 的强相合估计.

这是因为有如下引理: 若 $E \hat{\theta} \rightarrow \theta$, $\sum_{i=1}^{\infty} \text{Var} (\hat{\theta}_i) < +\infty$ 则 $\hat{\theta}$ 是 θ 的强相合估计.

证明: 由于

$$\begin{aligned}
\sum_{i=1}^{\infty} P \left(|\hat{\theta}_n - \theta| > \varepsilon \right) &\leq \sum_{i=1}^{\infty} P \left(|\hat{\theta}_n - E \hat{\theta}_n| > \frac{\varepsilon}{2} \right) + \sum_{i=1}^{\infty} P \left(|\theta - E \hat{\theta}_n| > \frac{\varepsilon}{2} \right) \\
&\leq \sum_{i=1}^{\infty} \frac{4}{\varepsilon^2} \text{Var} (\hat{\theta}_n) + \sum_{i=1}^{\infty} P \left(|\theta - E \hat{\theta}_n| > \frac{\varepsilon}{2} \right) < +\infty
\end{aligned}$$

故又 Borel-Cantelli 引理知 $\hat{\theta}_n$ 是 θ 的强相合估计.

七、(15 分) 总体 $X \sim B(1, p_1)$, $Y \sim B(1, p_2)$, 随机样本分别为 n 个与 m 个 (足够大), 构造假设检验 $H_0: p_1 \geq p_2$ 使拒绝原假设的概率接近 $1 - \alpha$.

Solution: 根据中心极限定理, 利用正态分布近似, 有

$$\bar{x} \sim AN \left(p_1, \frac{p_1(1-p_1)}{n} \right), \bar{y} \sim AN \left(p_2, \frac{p_2(1-p_2)}{m} \right)$$

于是

$$\frac{(\bar{x} - \bar{y}) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m}}} \sim AN(0, 1)$$

再利用大数定律可知, $\bar{x} \xrightarrow{P} p_1, \bar{y} \xrightarrow{P} p_2$, 根据 Slutsky 定理有

$$\frac{(\bar{x} - \bar{y}) - (p_1 - p_2)}{\sqrt{\frac{\bar{x}(1-\bar{x})}{n} + \frac{\bar{y}(1-\bar{y})}{m}}} \sim AN(0, 1)$$

于是近似水平 α 的拒绝域应为 $W = \left\{ \frac{(\bar{x} - \bar{y}) - (p_1 - p_2)}{\sqrt{\frac{\bar{x}(1-\bar{x})}{n} + \frac{\bar{y}(1-\bar{y})}{m}}} < u_\alpha \right\}$

[注]: 分母也可以考虑成: 原假设中的 $p_1 = p_2$ 成立时, 两组样本应该来自于同一个分布, 故考虑一个联合均值即 $\bar{p} = \frac{n\bar{x} + m\bar{y}}{n+m}$, 然后用 $\left\{ \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\bar{p}(1-\bar{p})}{n+m}}} < u_\alpha \right\}$ 作为拒绝域.

八、(10 分) $X \sim N(\mu, 4)$, 样本数为 n , 求 n 的取值范围使得 μ 的 95% 置信区间长度不大于 0.01.

Solution: μ 的置信区间是 $\bar{x} \pm \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}$, 此时 $\sigma = 2, \alpha = 0.05, z_{0.975} = 1.96$, 则区间长度为 $d = 2 \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}} = \frac{4}{\sqrt{n}} 1.96 \leq 0.01$, 则

$$\sqrt{n} \geq 400 \cdot 1.96$$

$$n \geq 614656$$

所以 n 至少为 614656.

九、(15 分) $X_i \sim N(\mu, \sigma^2)$, $i = 1, 2, \dots, n$, 服从多元正态, 任意两个样本相关系数皆为 ρ ,

(1)(5 分) 证明 $\rho \geq -\frac{1}{n-1}$;

(2)(5 分) 求 μ 的矩估计 $\hat{\mu}$;

(3)(5 分) 讨论 $\hat{\mu}$ 的无偏性、相合性.

Solution:

(1)

$$\begin{aligned} \text{Var} \left(\sum_{i=1}^n X_i \right) &= \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} \text{Cov}(X_i, X_j) \\ &= n\sigma^2 + 2 \cdot \frac{n(n-1)}{2} \rho\sigma^2 \\ &= n\sigma^2 + n(n-1)\rho\sigma^2 \geq 0 \end{aligned}$$

得 $\rho \geq -\frac{1}{n-1}$.

(2) $EX = \mu$, 所以 $\hat{\mu}_M = \bar{x}$ 是 μ 的矩估计.

(3) $E\bar{x} = \mu$, 所以 $\hat{\mu}_M$ 是 μ 的无偏估计. 对于相合性, 由于需要考虑样本量趋于无穷即 $n \rightarrow \infty$ 的情况, 因此可仅仅考虑 $\rho \geq 0$.

而 $\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n} + \frac{n-1}{n}\rho\sigma^2\right)$, 则 [i] $\rho = 0$ 根据大数定律, 显然有 $\bar{x} \rightarrow \mu$, a.s. [ii] $\rho > 0$ 对 $\forall \varepsilon > 0$, 有

$$\begin{aligned} P(\bar{x} - \mu \geq \varepsilon\sigma) &= P\left(\frac{\bar{x} - \mu}{\sigma\sqrt{\frac{1}{n} + \frac{n-1}{n}\rho}} \geq \frac{\varepsilon}{\sqrt{\frac{1}{n} + \frac{n-1}{n}\rho}}\right) \\ &= 1 - \Phi\left(\frac{\varepsilon}{\sqrt{\frac{1}{n} + \frac{n-1}{n}\rho}}\right) \rightarrow 1 - \Phi\left(\frac{\varepsilon}{\sqrt{\rho}}\right) \end{aligned}$$

于是 $\bar{x} \rightarrow \mu$. 综上所述, 当且仅当 $\rho = 0$ 时, $\hat{\mu}_M$ 是 μ 的强相合估计, 否则 $\hat{\mu}_M$ 不是 μ 的相合估计.

十、(15 分) 一个人出生在任意月份的概率为 $\frac{1}{12}$, 现抽取 100 人. 先从装有 5 个红球与 3 个黑球的袋中抽球, 若抽中红球, 回答: 生日是否在 7.1 之前; 若抽中黑球, 回答: 是否是同性恋. 最后统计到回答“是”的人为 35 人, 求人群中的同性恋比例.

Solution: 用事件 A 表示抽中红球, 用事件 B 表示回答 “是”, 则同性恋比例为

$$p = P(B | \bar{A})$$

则由全概率公式, 有

$$P(B) = P(B | A)P(A) + P(B | \bar{A})P(\bar{A})$$
$$\frac{35}{100} = \frac{1}{2} \cdot \frac{5}{8} + p \cdot \frac{3}{8}$$

解得 $p = 0.1$.

北大叉院-849 统计学-2018 年

一、(8 分) 有 4 份古卷放在书架上, 请问第 1 卷与第 2 卷相邻的概率为多少?

Solution: 这是一个古典概型问题, 全体样本点的数量是一个全排列 $\#\Omega = 4! = 24$. 而对于待研究事件, 使用捆绑法, 将第 1 卷与第 2 卷视为一个整体, 此时外部有 3 个物体待排列, 其中一个是第 1 卷与第 2 卷构成的整体, 其内部也有 2 个物体待排列, 由内外部两个排列的独立性知 $A = 2! \cdot 3! = 12$, 因此

$$P(A) = \frac{\#A}{\#\Omega} = \frac{12}{24} = \frac{1}{2}$$

二、(8 分) 甲、乙独立地向同一目标射击, 甲命中的概率是 0.6, 乙命中的概率是 0.8. 求在已知目标被命中的情况下, 是乙命中的概率.

Solution: 用事件 A 表示目标被射中, 则 $P(A) = 1 - (1 - 0.6) \cdot (1 - 0.8) = 0.92$. 再用事件 B 表示目标被乙射中, 则由贝叶斯公式

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)} = \frac{0.8}{0.92} = \frac{20}{23}$$

三、(10 分) 甲袋中装有 2 个白球和 1 个黑球, 乙袋中装有 2 个黑球和 1 个白球. 现在随机地先从甲袋中取出一球放入乙袋中, 再从乙袋中取出 1 球, 请问第二次从乙袋中取出黑球的概率是多少?

Solution: 用事件 B_i 表示拿到的第 i 个球是黑球, 则由全概率公式

$$\begin{aligned} P(B_2) &= P(B_2 | B_1)P(B_1) + P(B_2 | \bar{B}_1)P(\bar{B}_1) \\ &= \frac{3}{4} \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{2}{3} \\ &= \frac{1}{4} + \frac{1}{3} = \frac{7}{12} \end{aligned}$$

四、(10 分) 目前有 n 把外观相似的钥匙用于开一扇上锁的门, n 把钥匙中只有一把能打开. 随机从 n 把钥匙中取出一把用于开锁, 如果不能开锁就将其放回, 重新抽取. 请问成功开锁所需要的取钥匙次数的期望为多少?

Solution: 设取钥匙次数为 X , 显然有 $X \sim Ge(\frac{1}{n})$, 于是 $EX = n$.

五、(12 分) $X \sim f(x) = cx(1-x)I[0 < x < 1]$, 求

(1) c ;

(2) X 与 $\sqrt{X}$ 的相关系数.

Solution: 贝塔函数: $\mathbf{B}(p, q) = \int_0^1 x^{p-1}(1-x)^{q-1} dx = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$.

(1) 由概率密度函数的正则性, 有

$$c \int_0^1 x(1-x) dx = c\mathbf{B}(2, 2) = c \frac{\Gamma(2)\Gamma(2)}{\Gamma(4)} = \frac{c}{6} = 1$$

解得 $c = 6$.

(2) 对于 $\forall p > 0$,

$$EX^p = \int_0^1 6x^{p+1}(1-x) dx = 6\mathbf{B}(p+2, 2) = 6 \frac{\Gamma(p+2)\Gamma(2)}{\Gamma(p+4)} = \frac{6}{(p+3)(p+2)}$$

于是

$$\begin{aligned} \text{Cov}(X, \sqrt{X}) &= EX^{\frac{3}{2}} - EX \cdot EX^{\frac{1}{2}} \\ &= \frac{6}{\frac{9}{2} \cdot \frac{7}{2}} - \frac{6}{4 \cdot 3} \cdot \frac{6}{\frac{7}{2} \cdot \frac{5}{2}} \\ &= \frac{8}{21} - \frac{1}{2} \cdot \frac{24}{35} = \frac{4}{105} \end{aligned}$$

而 $\text{Var}(X) = EX^2 - (EX)^2 = \frac{6}{5.4} - \frac{1}{4} = \frac{1}{20}$ $\text{Var}(\sqrt{X}) = EX - (EX^{\frac{1}{2}})^2 = \frac{1}{2} - \left(\frac{24}{35}\right)^2 = \frac{73}{2450}$ 所以 $\text{Corr}(X, \sqrt{X}) = \frac{\frac{4}{20} \cdot \frac{73}{2450}}{\sqrt{\frac{1}{20} \cdot \frac{73}{2450}}} \approx 0.987$.

六、(12 分) 有来自总体 $f(x) = \frac{2\theta^2}{x^3} I[x \geq \theta]$ 的 n 个随机样本, 求 θ 的矩估计、最大似然估计.

Solution:

$$EX = \int_{\theta}^{+\infty} \frac{2\theta^2}{x^2} dx = 2\theta^2 \left(-\frac{1}{x} \right) \Big|_{\theta}^{+\infty} = 2\theta$$

所以 $\hat{\theta}_M = \frac{\bar{x}}{2}$ 是 θ 的矩估计. 似然函数 $L(\theta) = \frac{2^n}{\prod_{i=1}^n x_i^3} \theta^{2n} I_{\{x_{(1)} \geq \theta\}}$ 是 θ 在 $(-\infty, x_{(1)})]$ 上的单调递增函数, 因此 $\hat{\theta}_L = x_{(1)}$ 是 θ 的极大似然估计.

七、(15 分) 设简单随机样本 $X_1, \dots, X_n$ 服从 $[0, \theta]$ 上的均匀分布:

(1)(7 分) 求 θ 的极大似然估计;

(2)(8 分) 构造 θ 的 $1 - \alpha$ 置信区间.

Solution:

(1) 似然函数 $L(\theta) = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}$ 是 θ 在 $[x_{(n)}, +\infty)$ 上的减函数, 显然 $\hat{\theta}_L = x_{(n)}$ 是 θ 的极大似然估计.

(2) 用枢轴量法来构造置信区间: 假设来自总体为 $U(0, \theta)$ 的 n 个随机样本为 $X_1, \dots, X_n$, 那么

$$T = \frac{X_{(n)}}{\theta} \sim f(t) = nt^{n-1}, 0 < t < 1,$$

我们想找到 $0 \leq c < d \leq 1$, 使得

$$1 - \alpha = P\{c \leq T \leq d\}$$

我们可以取 $c = \alpha^{\frac{1}{n}}, d = 1$ 将满足

$$1 - \alpha = P\left\{\alpha^{\frac{1}{n}} \leq \frac{X_{(n)}}{\theta} \leq 1\right\}, \text{ 即 } 1 - \alpha = P\left\{X_{(n)} \leq \theta \leq \frac{X_{(n)}}{\alpha^{\frac{1}{n}}}\right\},$$

则 θ 的 $1 - \alpha$ 置信区间为 $\left[X_{(n)}, \frac{X_{(n)}}{\alpha^{\frac{1}{n}}}\right]$.

八、(15 分) 有来自总体 $X \sim N(\mu, \sigma^2)$ 的 n 个随机样本, μ 的 $1 - \alpha$ 置信区间长度为 L , 求 EL^2 .

Solution: μ 的置信区间是 $\bar{x} \pm \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$, 置信区间的长度是 $2 \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$, 则

$$EL^2 = E\left(2 \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)\right)^2 = \frac{4}{n} \left[t_{1-\frac{\alpha}{2}}(n-1)\right]^2 Es^2 = \frac{4\sigma^2}{n} \left[t_{1-\frac{\alpha}{2}}(n-1)\right]^2$$

九、(15 分) $X_0, X_1, \dots, X_n$ 独立同服从 $Ge(p)$, 求 $\text{Cov}\left(\sum_{i=1}^{X_0} X_i, \sum_{i=1}^{X_0} X_{X_0+i}\right)$.

Solution: 由重期望公式知

$$E\left(\sum_{i=1}^{X_0} X_i\right) = E\left[E\left(\sum_{i=1}^{X_0} X_i \mid X_0\right)\right] = E\left[\frac{X_0}{p}\right] = \frac{1}{p^2}$$

$$\text{同理 } E\left(\sum_{i=1}^{X_0} X_{X_0+i}\right) = \frac{1}{p^2}.$$

$$\begin{aligned} E\left[\left(\sum_{i=1}^{X_0} X_i\right)\left(\sum_{i=1}^{X_0} X_{X_0+i}\right)\right] &= E\left[E\left[\left(\sum_{i=1}^{X_0} X_i\right)\left(\sum_{i=1}^{X_0} X_{X_0+i}\right) \mid X_0\right]\right] \\ &= E\left[E\left[\left(\sum_{i=1}^{X_0} X_i\right)\left(\sum_{i=X_0+1}^{2X_0} X_i\right) \mid X_0\right]\right] \\ &= E\left[\frac{X_0^2}{p^2}\right] \\ &= \frac{1}{p^2} EX_0^2 = \frac{2-p}{p^4} \end{aligned}$$

$$\text{因此 } \text{Cov}\left(\sum_{i=1}^{X_0} X_i, \sum_{i=1}^{X_0} X_{X_0+i}\right) = \frac{2-p}{p^4} - \frac{1}{p^4} = \frac{1-p}{p^4}.$$

十、(15 分) 设随机变量 X 服从 $[\theta - \rho, \theta + \rho]$ 上的均匀分布, 试求 θ 和 ρ 的极大似然估计, 并说明其极大似然估计是否为无偏估计, 并证明你的结论.

Solution: 作一一变换 $\begin{cases} a = \theta - \rho \\ b = \theta + \rho \end{cases}$, 则 $\begin{cases} \theta = \frac{a+b}{2} \\ \rho = \frac{b-a}{2} \end{cases}$, 且总体 $X \sim U(a, b)$. 于是似然函数为 $L(a, b) = \frac{1}{(b-a)^n} \mathbf{I}_{\{x_{(1)} \geq a\}} \mathbf{I}_{\{x_{(n)} \leq b\}}$, 显然若想要似然函数取到最大值, 则要求 $(b-a)$ 取到最小值, 又注意到示性函数的存在, 则 a 与 b 的取值范围分别是 $(-\infty, x_{(1)})$ 与 $[x_{(n)}, +\infty)$, 因此当 $\begin{cases} a = x_{(1)} \\ b = x_{(n)} \end{cases}$ 时, $(b-a)$ 取到最小值.

$$\begin{cases} \hat{\theta} = \frac{x_{(1)} + x_{(n)}}{2} \\ \hat{\rho} = \frac{x_{(n)} - x_{(1)}}{2} \end{cases}$$

是 (θ, ρ) 的极大似然估计. 由均匀分布的性质容易知道

$$\frac{x_{(1)} - a}{b - a} \sim \text{Beta}(1, n), \quad \frac{x_{(n)} - a}{b - a} \sim \text{Beta}(n, 1)$$

则 $Ex_{(1)} = a + \frac{b-a}{n+1}$, $Ex_{(n)} = b - \frac{b-a}{n+1}$. 于是

$$\begin{cases} E\hat{\theta} = \frac{Ex_{(1)} + Ex_{(n)}}{2} = \frac{a+b}{2} = \theta \\ E\hat{\rho} = \frac{Ex_{(n)} - Ex_{(1)}}{2} = \frac{b-a - \frac{2}{n+1}(b-a)}{2} = \frac{n-1}{n+1} \frac{b-a}{2} = \frac{n-1}{n+1} \rho \end{cases}$$

即 $\hat{\theta}$ 是无偏估计, $\hat{\rho}$ 不是无偏估计.

十一、(15 分) 叙述中心极限定理, 并利用中心极限定理证明:

$$\lim_{n \rightarrow \infty} \sum_{k=0}^n \frac{n^k}{k!} e^{-n} = \frac{1}{2}.$$

Solution: $X_1, X_2, \dots, X_n$ 独立同分布, 且有 $EX_1 = \mu, \text{Var}(X_1) = \sigma^2 < +\infty$, 那么对于任意 $x \in R$,

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x\right) = \Phi(x)$$

这里 $\Phi(x)$ 是标准正态分布的分布函数. 取 $X_1, X_2, \dots, X_n$ i.i.d $\sim \text{Poisson}(1)$, 则 $EX_1 = \text{Var}(X_1) = 1$, 则

$$\lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n X_i - n}{\sqrt{n}} \leq 0\right) = \Phi(0) = \frac{1}{2}$$

又根据泊松分布的可加性知 $\sum_{i=1}^n X_i \sim \text{Poisson}(n)$, 于是有

$$P\left(\frac{\sum_{i=1}^n X_i - n}{\sqrt{n}} \leq 0\right) = P\left(\sum_{i=1}^n X_i \leq n\right) = \sum_{k=0}^n \frac{n^k}{k!} e^{-n}$$

因此 $\lim_{n \rightarrow \infty} \sum_{k=0}^n \frac{n^k}{k!} e^{-n} = \frac{1}{2}$.

十二、(15 分) 设有方程组

$$\begin{cases} y_1 = \theta_1 + \theta_2 + \theta_3 + \varepsilon_1, \\ y_2 = \theta_1 - \theta_2 - \theta_3 + \varepsilon_2, \\ y_3 = -\theta_1 + \theta_2 - \theta_3 + \varepsilon_3, \\ y_4 = -\theta_1 - \theta_2 + \theta_3 + \varepsilon_4. \end{cases}$$

其中, ε_i i.i.d $\sim N(0, \sigma^2)$, σ^2 未知, 求

(1)(7 分) $\theta_1, \theta_2, \theta_3$ 的 UMVUE;

(2)(8 分) θ_1 的置信度为 $1 - \alpha$ 的最短置信区间.

Solution:

(1) (Y_1, Y_2, Y_3, Y_4) 的联合密度函数是

$$f(y_1, y_2, y_3, y_4) = (2\pi\sigma^2)^{-2} \exp\left\{-\frac{(y_1 - \theta_1 - \theta_2 - \theta_3)^2}{2\sigma^2}\right\} \exp\left\{-\frac{(y_2 - \theta_1 + \theta_2 + \theta_3)^2}{2\sigma^2}\right\} \\ \exp\left\{-\frac{(y_3 + \theta_1 - \theta_2 + \theta_3)^2}{2\sigma^2}\right\} \exp\left\{-\frac{(y_4 + \theta_1 - \theta_2 - \theta_3)^2}{2\sigma^2}\right\}$$

只留下带有 (y_1, y_2, y_3, y_4) 的部分, 整理得

$$f \propto e^{-\frac{1}{2\sigma^2} [(y_1^2 + y_2^2 + y_3^2 + y_4^2) + 2\theta_1(-y_1 - y_2 + y_3 + y_4) + 2\theta_2(-y_1 + y_2 - y_3 + y_4) + 2\theta_3(-y_1 + y_2 + y_3 - y_4)]}$$

于是根据因子分解定理, $(\theta_1, \theta_2, \theta_3)$ 各自的充分统计量分别是

$$(y_1 + y_2 - y_3 - y_4, y_1 - y_2 + y_3 - y_4, y_1 - y_2 - y_3 + y_4)$$

其中令 $\hat{\theta}_1 = \frac{y_1 + y_2 - y_3 - y_4}{4} \sim N\left(\theta_1, \frac{\sigma^2}{4}\right)$, 而正态分布是完全族分布, 因此该统计量是完全的. 于是它是基于充分完全统计量给出的 θ_1 的无偏估计, 所以它是 θ_1 的 UMVUE. 同理 $\hat{\theta}_2 = \frac{y_1 - y_2 + y_3 - y_4}{4}$ 是 θ_2 的 UMVUE. $\hat{\theta}_3 = \frac{y_1 - y_2 - y_3 + y_4}{4}$ 是 θ_3 的 UMVUE.

$$(2) \text{ 记 } \begin{cases} \hat{y}_1 = \hat{\theta}_1 + \hat{\theta}_2 + \hat{\theta}_3 \\ \hat{y}_2 = \hat{\theta}_1 - \hat{\theta}_2 - \hat{\theta}_3 \\ \hat{y}_3 = -\hat{\theta}_1 + \hat{\theta}_2 - \hat{\theta}_3 \\ \hat{y}_4 = -\hat{\theta}_1 - \hat{\theta}_2 + \hat{\theta}_3 \end{cases} \text{ 令 } \hat{\sigma}^2 = \sum_{i=1}^4 (y_i - \hat{y}_i)^2, \text{ 则 } \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(1). \text{ (严格证明可据 Cochran 定理, 或}$$

直接利用自由度来推断) 又 $\hat{\sigma}^2$ 是 θ_1 的辅助统计量, 由 Basu 定理可以知道 $\hat{\sigma}^2$ 与 $\hat{\theta}_1$ 独立, 因此我们可以构造枢轴量

$$T = \frac{2(\hat{\theta}_1 - \theta_1)}{\hat{\sigma}} \sim t(1)$$

故得到 θ_1 的 $1 - \alpha$ 置信水平的最短置信区间

$$\hat{\theta}_1 \pm \frac{\hat{\sigma}}{2} t_{1-\frac{\alpha}{2}}(1)$$

北大叉院-849 统计学-2019 年

一、(10 分) 设 $A_1, \dots, A_n$ 是相互独立的随机事件且 $P(A_i) = \frac{1}{2}, i = 1, \dots, n$, 求 $P(\bigcap_i A_i)$ 与 $P(\bigcup_i A_i)$.

Solution: $P(\bigcap_i A_i) = \prod_{i=1}^n P(A_i) = \frac{1}{2^n}$ $P(\bigcup_i A_i) = 1 - P(\overline{\bigcup_i A_i}) = 1 - P(\bigcap_i \bar{A}_i) = 1 - \prod_{i=1}^n P(\bar{A}_i) = 1 - \frac{1}{2^n}$

二、(10 分) 设 X, Y 独立同服从标准正态分布, 求 $Z = 3X - 4Y$ 的密度函数.

Solution: 根据正态分布的性质, $Z = 3X - 4Y$ 依然是正态分布, 且

$$E(3X - 4Y) = 0, \text{Var}(3X - 4Y) = 9 + 16 = 25$$

所以 $Z \sim N(0, 5^2)$, 即

$$f_Z(z) = \frac{1}{5\sqrt{2\pi}} e^{-\frac{z^2}{50}}, -\infty < z < +\infty$$

三、(15 分) 总体 $X \sim N(2\mu, 1)$, 有 n 个随机样本, 求 μ 的置信度为 $1 - \alpha$ 的置信区间.

Solution: 取枢轴量 $Z = \sqrt{n}(\bar{X} - 2\mu) \sim N(0, 1)$, 令

$$P(c \leq \sqrt{n}(\bar{X} - 2\mu) \leq d) = 1 - \alpha$$

取等尾的分位数, 即 $c = -u_{1-\frac{\alpha}{2}}, d = u_{1-\frac{\alpha}{2}}$, 反解得到 μ 的置信区间是

$$\left[\frac{\bar{x}}{2} - \frac{u_{1-\frac{\alpha}{2}}}{2\sqrt{n}}, \frac{\bar{x}}{2} + \frac{u_{1-\frac{\alpha}{2}}}{2\sqrt{n}} \right]$$

四、(10 分) 甲袋中 2 白球 1 黑球、乙袋中 1 白球 2 黑球, 先从甲袋中拿出一球放入乙袋, 再从乙袋中取出一球, 求从乙袋中取出黑球的概率.

Solution: 用事件 B_i 表示第 i 次摸出黑球, 则由全概率公式

$$\begin{aligned} P(B_2) &= P(B_2 | B_1) P(B_1) + P(B_2 | \bar{B}_1) P(\bar{B}_1) \\ &= \frac{3}{4} \cdot \frac{1}{3} + \frac{1}{2} \cdot \frac{2}{3} = \frac{7}{12} \end{aligned}$$

五、(15 分) $X_1 \sim N(\mu_1, \sigma_1^2), X_2 | X_1 = x_1 \sim N\left(\mu_2 + \frac{\sigma_2}{2\sigma_1}(x_1 - \mu_1), \frac{3}{4}\sigma_2^2\right)$, 求 (X_1, X_2) 的联合分布以及 X_2 的边缘分布.

Solution: 由题意, (X_1, X_2) 服从二维正态分布, 且有

$$\begin{aligned} EX_1 &= \mu_1, EX_2 = E[E(X_2 | X_1)] = E\left[\mu_2 + \frac{\sigma_2}{2\sigma_1}(X_1 - \mu_1)\right] = \mu_2 \\ EX_1 X_2 &= E[E(X_1 X_2 | X_1)] = E\left[X_1 \left(\mu_2 + \frac{\sigma_2}{2\sigma_1}(X_1 - \mu_1)\right)\right] = \mu_1 \mu_2 + \frac{1}{2}\sigma_1 \sigma_2 \end{aligned}$$

因此, $\text{Cov}(X_1, X_2) = \frac{1}{2}\sigma_1 \sigma_2$, 而 $\text{Var}(X_1) = \sigma_1^2$, 以及

$$\begin{aligned} \text{Var}(X_2) &= E[\text{Var}(X_2 | X_1)] + \text{Var}[E(X_2 | X_1)] \\ &= E\left(\frac{3}{4}\sigma_2^2\right) + \text{Var}\left[\mu_2 + \frac{\sigma_2}{2\sigma_1}(X_1 - \mu_1)\right] \\ &= \frac{3}{4}\sigma_2^2 + \frac{\sigma_2^2}{4\sigma_1^2} \text{Var}(X_1) = \sigma_2^2 \end{aligned}$$

所以 $\text{Corr}(X_1, X_2) = \frac{1}{2}$, 则 $(X_1, X_2) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \frac{1}{2}), X_2 \sim N(\mu_2, \sigma_2^2)$.

六、(15 分) 袋中有红、黄、蓝球各 2 个, 从中不放回地取出 3 个, 求

(1)(7 分) 各颜色各一个的概率;

(2)(8 分) 恰有两种颜色的概率.

Solution:

$$(1) P(\text{每种颜色一个}) = \frac{(C_2^1)^3}{C_6^3} = \frac{8}{20} = \frac{2}{5}.$$

$$(2) P(\text{恰有两种颜色}) = \frac{C_3^1 C_2^2 C_4^1}{C_6^3} = \frac{3}{5}. (\text{注: 某种颜色的球抽了 2 个, 剩下 4 个中随便抽一个.})$$

七、(15 分) 百货公司举行抽奖活动, 参与者可以一直抽奖直到中奖, 每次抽取相互独立, 一次抽中的概率为 p , 求

(1)(7 分) 抽中奖品所需次数的概率分布: 抽中奖品所需次数的期望;

(2)(8 分) 最小整数 k , 使得 k 次以内抽中的概率大于 $1 - \alpha$.

Solution:

(1)

$$X \sim Ge(p), \text{ 即 } P(X = k) = p(1-p)^{k-1}, k = 1, 2, \dots$$

$$EX = p \sum_{k=1}^{\infty} k(1-p)^{k-1} = p \frac{1}{[1 - (1-p)]^2} = \frac{1}{p}$$

$$(2) \text{ 令 } \begin{cases} P(X \leq k) > 1 - \alpha \\ P(X \leq k-1) \leq 1 - \alpha \end{cases}, \text{ 即 } \begin{cases} P(X > k) < \alpha \\ P(X > k-1) \geq \alpha \end{cases} \quad \text{若记 } q = 1 - p, \text{ 有 } P(X > k) = p \sum_{i=k}^{\infty} q^i =$$

$$q^k, \text{ 于是上述不等式组可写为 } \begin{cases} q^k < \alpha \\ q^{k-1} \geq \alpha \end{cases}, \text{ 解得 } \begin{cases} k > \frac{\ln \alpha}{\ln(1-p)} \\ k-1 \leq \frac{\ln \alpha}{\ln(1-p)} \end{cases}, \text{ 即 } k = \left\lfloor \frac{\ln \alpha}{\ln(1-p)} \right\rfloor + 1.$$

八、(20 分) 有来自期望为 $\frac{1}{\lambda}$ 的指数分布总体 $X \sim \text{Exp}(\lambda)$ 的 n 个随机样本, 求 $H_0: \lambda \leq \lambda_0$ (备择假设是补集) 的拒绝域.

Solution: 选取检验统计量 $T = 2\lambda_0 \sum_{i=1}^n X_i$, 由于 $E(X) = \frac{1}{\lambda}$, 备择假设中较大的 λ 意味着样本之和 $\sum_{i=1}^n X_i$ 会较小, 因此我们倾向于拒绝较小的 T , 因此拒绝域可以写为 $W = \{T \leq c\}$, 这里 c 使得检验的水平是 α . 由于当 $\lambda = \lambda_0$ 时, $T = 2\lambda_0 \sum_{i=1}^n X_i \sim \chi^2(2n)$, 因此可求得 $c = \chi_{\alpha}^2(2n)$, 因此该检验的拒绝域是

$$W = \left\{ 2\lambda_0 \sum_{i=1}^n X_i \leq \chi_{\alpha}^2(2n) \right\}$$

九、(20 分) $R^2 \sim \text{Exp}(\frac{1}{2}), \theta \sim U(0, 2\pi)$ 相互独立, 求 $(X, Y) = (R \cos \theta, R \sin \theta)$ 的联合分布与边缘分布.

Solution: 茆诗松课后习题 3.3.19

(X, Y) 的联合密度函数是

$$f_{X,Y}(x, y) = \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}}.$$

所以 $(X, Y) \sim N(0, 0; 1, 1; 0)$. 于是 $X \sim N(0, 1), Y \sim N(0, 1)$.

十、(20 分) 有来自总体 $f(x) = \frac{2\theta^2}{x^3} I[x \geq \theta]$ 的 n 个随机样本, 求 θ 的矩估计与最大似然估计.

Solution: $EX = \int_{\theta}^{+\infty} \frac{2\theta^2}{x^3} dx = 2\theta^2 \left(-\frac{1}{x}\right) \Big|_{\theta}^{+\infty} = 2\theta$, 所以 θ 的矩估计是 $\hat{\theta}_M = \frac{\bar{x}}{2}$. 似然函数 $L(\theta) = \prod_{i=1}^n \frac{2\theta^2}{x_i^3} I_{\{x_i \geq \theta\}}$ 是 θ 在 $(0, x_{(1)}]$ 上的单调增加函数, 所以 $\hat{\theta}_L = x_{(1)}$ 是 θ 的最大似然估计.

北大叉院-849 统计学-2020 年

一、(15 分) 有 5 根线段, 长度分别为 1, 3, 5, 7, 9 厘米, 先从中随机抽取 3 根, 求能够组成三角形的概率.

Solution: 符合题意的事件可写为 $A = \{\{3, 5, 7\}, \{3, 7, 9\}, \{5, 7, 9\}\}$, 所以

$$P(A) = \frac{3}{C_5^3} = \frac{3}{10}$$

二、(15 分) 甲、乙两人独立射击一目标, 命中目标的概率是 0.6, 0.8. 现已知目标被击中, 求乙击中的概率.

Solution: 用事件 A 表示甲射中, 事件 B 表示乙命中, 则

$$P(B | A \cup B) = \frac{P(B)}{P(A \cup B)} = \frac{0.8}{1 - 0.4 \cdot 0.2} = \frac{0.8}{0.92} = \frac{20}{23}$$

三、(15 分) 已知随机变量 $N \sim \mathcal{P}(\lambda)$, $X_0 = 0$, 而 $X_1, \dots, X_n$ 是 i.i.d. 服从 $B(1, p)$ 的随机变量, 试证:

$$\sum_{i=0}^N X_i \sim \mathcal{P}(\lambda p).$$

Solution: 记 $Y = \sum_{i=0}^N X_i$, 则由全概率公式, 对 $k = 0, 1, \dots$, 有

$$\begin{aligned} P(Y = k) &= \sum_{n=k}^{\infty} P\left(\sum_{i=1}^n X_i = k\right) P(N = n) \\ &= \sum_{n=k}^{\infty} C_n^k p^k (1-p)^{n-k} \frac{\lambda^n}{n!} e^{-\lambda} \\ &= \sum_{n=k}^{\infty} \frac{n!}{k!(n-k)!} (\lambda p)^k [\lambda(1-p)]^{n-k} \frac{1}{n!} e^{-\lambda} \\ &= \frac{(\lambda p)^k}{k!} e^{-\lambda} \sum_{n=k}^{\infty} \frac{[\lambda(1-p)]^{n-k}}{(n-k)!} \\ &= \frac{(\lambda p)^k}{k!} e^{-\lambda} \sum_{j=0}^{\infty} \frac{[\lambda(1-p)]^j}{j!} \\ &= \frac{(\lambda p)^k}{k!} e^{-\lambda} \cdot e^{\lambda(1-p)} = \frac{(\lambda p)^k}{k!} e^{-\lambda p} \end{aligned}$$

即 $Y \sim \mathcal{P}(\lambda p)$.

四、(15 分) 已知甲袋中有 1 个黑球和 k 个白球, 乙袋中有 $k+1$ 个白球, 每次从两袋中各取一球进行交换, 记交换 n 次后黑球在甲袋的概率为 p_n , 试证:

$$\lim_{n \rightarrow \infty} p_n = \frac{1}{2}.$$

Solution: 用事件 A_n 表示交换 n 次后黑球还在甲袋, 则由全概率公式, 对于 $n = 0, 1, \dots$

$$\begin{aligned} P(A_{n+1}) &= P(A_{n+1} | A_n) P(A_n) + P(A_{n+1} | \bar{A}_n) P(\bar{A}_n) \\ &= \frac{k}{k+1} p_n + \frac{1}{k+1} (1-p_n) \\ &= \frac{k-1}{k+1} p_n + \frac{1}{k+1} \end{aligned}$$

注意到 $p_{n+1} = P(A_{n+1})$, 则上式可写为

$$\begin{aligned} p_{n+1} &= \frac{k-1}{k+1} p_n + \frac{1}{k+1} \\ p_{n+1} - \frac{1}{2} &= \frac{k-1}{k+1} \left(p_n - \frac{1}{2}\right) \end{aligned}$$

当 $k = 1$ 时, $p_n \equiv \frac{1}{2}$; 当 $k > 1$ 时, $p_n - \frac{1}{2} \rightarrow 0$, 所以 $p_n \rightarrow \frac{1}{2}$.

五、(15 分) 随机向量 (X, Y) 的密度函数是

$$f(x, y) = \begin{cases} ke^{-3x-4y}, & x > 0, y > 0, \\ 0, & \text{其他}, \end{cases}$$

(1)(5 分) 求 k ;

(2)(5 分) 求 $P(0 < X < 1, 0 < Y < 2)$;

(3)(5 分) 求 (X, Y) 的分布函数.

Solution:

(1) 由概率密度函数的正则性知 $\int_0^{+\infty} dx \int_0^{+\infty} ke^{-3x-4y} dy = k \int_0^{+\infty} e^{-3x} dx \int_0^{+\infty} e^{-4y} dy = \frac{k}{12} = 1$ 解得 $k = 12$.

(2) 容易发现 $X \sim \text{Exp}(3)$ 与 $Y \sim \text{Exp}(4)$ 是相互独立的, 所以

$$P(0 < X < 1, 0 < Y < 2) = F_X(1)F_Y(2) = (1 - e^{-3})(1 - e^{-8})$$

(3) 根据独立性可知,

$$F(x, y) = F_X(x)F_Y(y) = \begin{cases} (1 - e^{-3x})(1 - e^{-4y}), & x \geq 0, y \geq 0 \\ 0, & \text{其他} \end{cases}$$

六、(15 分) 已知 $X_1, \dots, X_n$ 是 i.i.d. $\sim f(x) = 2\lambda x e^{-\lambda x^2} I_{[x>0]}$ 的随机样本, 其中 $\lambda > 0$ 是未知参数.

(1)(5 分) 求 λ 的 MLE;

(2)(5 分) 验证无偏性;

(3)(5 分) 验证相合性.

Solution:

(1) 似然函数为 $L(\lambda) = 2^n \lambda^n (\prod_{i=1}^n x_i) e^{-\lambda \sum_{i=1}^n x_i^2}$, 取对数处理, 有

$$\ln L(\lambda) = n \ln 2 + n \ln \lambda + \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n x_i^2$$

令 $\frac{d \ln L}{d \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i^2 = 0$, 解得驻点 $\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^2}$. 又由于 $\frac{d^2 \ln L}{d \lambda^2} = -\frac{n}{\lambda^2} < 0$, 于是所求驻点是对数似然函数的极大值点, 综上所述 $\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^2}$ 是 λ 的 MLE.

(2) 作总体变换, 令 $Y = X^2$, 则 $Y \sim f_Y(y) = \lambda e^{-\lambda y}, y > 0$. 即 X_i^2 相互独立服从参数为 λ 的指数分布, 因为 $g(t) = \frac{1}{t}$ 在 $(0, +\infty)$ 上是严格凸函数, 所以由 Jensen 不等式

$$E(\hat{\lambda}) = E\left(\frac{n}{\sum_{i=1}^n x_i^2}\right) > n \frac{1}{E(\sum_{i=1}^n x_i^2)} = \frac{n}{n\lambda} = \lambda$$

于是 $\hat{\lambda}$ 不是 λ 的无偏估计. (需要注意的是, Jensen 不等式的取等条件为 “ $g(t)$ 几乎处处是线性函数”, 而此处显然不是, 于是 Jensen 不等式严格成立.) 或者利用 $\sum x_i^2 \sim Ga(n, \lambda)$, 计算得到 $E\left(\frac{n}{\sum_{i=1}^n x_i^2}\right) = \frac{n}{n-1}\lambda$, 同样可以说明它不是无偏估计, 但显然不如 Jensen 不等式来得快.

(3) 由于 X_i^2 相互独立, 均服从参数为 λ 的指数分布, 则根据强大数定律, 有

$$\frac{\sum_{i=1}^n x_i^2}{n} \rightarrow \frac{1}{\lambda}, \text{ a.s.}$$

故 $\sum_{i=1}^n \frac{1}{x_i^2} \rightarrow \lambda, a.s.$, 即 $\hat{\lambda}$ 是 λ 的强相合估计.

七、(15 分) $X_1, \dots, X_n$ 是来自密度函数 $f(x) = \frac{2\theta^2}{x^3} I_{[x \geq \theta]}$ 的随机样本, 求 θ 的矩估计与最大似然估计.

Solution: $EX = \int_{\theta}^{+\infty} \frac{2\theta^2}{x^3} dx = 2\theta^2 \left(-\frac{1}{x}\right) \Big|_{\theta}^{+\infty} = 2\theta$, 所以 θ 的矩估计是 $\hat{\theta}_M = \frac{\bar{x}}{2}$. 似然函数 $L(\theta) = \prod_{i=1}^n \frac{2\theta^2}{x_i^3} I_{\{x_{(1)} \geq \theta\}}$ 是 θ 在 $(0, x_{(1)})$ 上的单调增加函数, 所以 $\hat{\theta}_L = x_{(1)}$ 是 θ 的最大似然估计.

八、(15 分) $X_1, \dots, X_n$ 是 i.i.d. 的随机变量序列, 且 $EX_1 = \mu$, $\text{Var}(X_1) = \sigma^2$ 存在, 证明:

$$\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow{d} N(0, 1).$$

Solution: 记 $Y_i = \frac{X_i - \mu}{\sigma}$, 并记其特征函数为 $\varphi_Y(t)$, 则 $Z_n = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$ 有特征函数 $\varphi_{Z_n}(t) = \left[\varphi_Y\left(\frac{t}{\sqrt{n}}\right) \right]^n$. 由于 $EY_i = 0, EY_i^2 = \text{Var}(Y_i) = 1$, 于是 $\varphi_Y'(t) = 0, \varphi_Y''(t) = -1$. 将 $\varphi_Y\left(\frac{t}{\sqrt{n}}\right)$ 于 $t = 0$ 处展开, 有 $\varphi_Y\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{1}{2} \frac{t^2}{n} + o\left(\frac{1}{n}\right)$, 所以

$$\varphi_{Z_n}(t) = \left[1 - \frac{1}{2} \frac{t^2}{n} + o\left(\frac{1}{n}\right) \right]^n \rightarrow e^{-\frac{t^2}{2}}$$

右侧恰是标准正态分布的特征函数, 由连续性定理知

$$\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow{d} N(0, 1)$$

九、(15 分) $X_1, \dots, X_n$ 是来自总体 $U(0, \theta)$ 的随机样本, 试求

(1)(7 分) θ 的最大似然估计;

(2)(8 分) θ 的 $1 - \alpha$ 置信区间.

Solution:

(1) 似然函数 $L(\theta) = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}$ 是 θ 在 $[x_{(n)}, 1)$ 上的单调递减函数, 因此 θ 的极大似然估计是 $x_{(n)}$.

(2) 由于 $T = \frac{x_{(n)}}{\theta} \sim \text{Beta}(n, 1)$, 以此为枢轴量, 令

$$P(c \leq T \leq d) = 1 - \alpha$$

$$d^n - c^n = 1 - \alpha$$

反解得到此时的置信区间为 $\left[\frac{x_{(n)}}{d}, \frac{x_{(n)}}{c} \right]$, 现即求 $\frac{1}{c} - \frac{1}{d}$ 在 $d^n - c^n = 1 - \alpha$ 下的最小值, 由消元法易得 $d = 1, c = \alpha^{\frac{1}{n}}$ (消元法指的是用约束条件消去一个变量), 故置信区间是

$$\left[x_{(n)}, x_{(n)} \alpha^{-\frac{1}{n}} \right]$$

十、(15 分) $X_1, \dots, X_n$ 是来自总体 $N(\mu, \sigma^2)$ 的随机样本, 试给出一个 σ 的无偏估计.

Solution: 考虑基于样本标准差 $s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$ 来构造 σ 的无偏估计. 由于

$$T = \frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

所以

$$E\sqrt{T} = \int_0^{+\infty} t^{\frac{1}{2}} \frac{\left(\frac{1}{2}\right)^{\frac{n-1}{2}}}{\Gamma\left(\frac{n-1}{2}\right)} t^{\frac{n-1}{2}-1} e^{-\frac{1}{2}t} dt$$

$$= \frac{\sqrt{2}}{\Gamma\left(\frac{n-1}{2}\right)} \int_0^{+\infty} \left(\frac{t}{2}\right)^{\frac{n-2}{2}} e^{-\frac{1}{2}t} d\left(\frac{t}{2}\right) = \frac{\sqrt{2}\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)}$$

于是 $Es = \frac{\sigma}{\sqrt{n-1}} E\sqrt{T} = \frac{\sigma}{\sqrt{n-1}} \frac{\sqrt{2}\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)}$. 因此 σ 的无偏估计是 $\sqrt{\frac{n-1}{2}} \frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} s$.

北大叉院-849 统计学-2021 年

一、(10 分) 事件 A, B 独立, 且 $P(B - A) = P(A - B) = \frac{1}{4}$, 求 $P(A), P(B)$.

Solution: 根据独立性有

$$\begin{cases} P(B - A) = P(B) - P(BA) = P(B) - P(A)P(B) = \frac{1}{4} \\ P(A - B) = P(A) - P(AB) = P(A) - P(A)P(B) = \frac{1}{4} \end{cases}$$

解得 $P(A) = P(B) = \frac{1}{2}$.

二、(10 分) 盒中有 100 个球, 分别编号 1-100, 现从中抽出 10 个.

(1)(5 分) 有放回抽球, 求 10 个球编号和的期望;

(2)(5 分) 无放回抽取, 求 10 个球编号和的期望.

Solution:

(1) 设抽到第 i 个球的编号是 X_i , 则 $P(X_i = k) = \frac{1}{100} (k = 1, 2, \dots, 100)$ 所以 $EX_i = \sum_{k=1}^{100} \frac{k}{100} = 50.5$, 所以 $E\left(\sum_{i=1}^{10} X_i\right) = \sum_{i=1}^{10} EX_i = 10EX_1 = 505$.

(2) 此时 X_i 的分布与 (1) 中相同, 只是此时诸 X_i 不是独立的, 而 (1) 中诸 X_i 是独立的, 但根据期望的线性性, 这并不影响它们和的期望, 同样有

$$E\left(\sum_{i=1}^{10} X_i\right) = \sum_{i=1}^{10} EX_i = 10EX_1 = 505$$

三、(15 分) 现有 1000 名顾客, 无偏颇地选择两家剧院, 每家剧院皆有 N 个座位, 顾客进入剧院如果观察到座位已满则会被迫离开, 试确定合适的 N , 使得因无座而流失的顾客不超过 1%.

(1) 用二项分布给出表达式;

(2) 借助正态近似求解 N .

Solution:

(1) 设 $X_i = \begin{cases} 1, & \text{第 } i \text{ 个顾客选择甲剧院} \\ 0, & \text{第 } i \text{ 个顾客选择乙剧院} \end{cases}$, 则选择甲剧院的观众总数为 $\sum_{i=1}^{1000} X_i$, 选择乙剧院的观众总数是 $1000 - \sum_{i=1}^{1000} X_i$, 因此因座位不够而流失观众这一事件可记为

$$A = \left\{ \sum_{i=1}^{1000} X_i > N \right\} \cup \left\{ 1000 - \sum_{i=1}^{1000} X_i > N \right\}$$

找的合适的 N 使得 $P(A) \leq 0.01$, 即

$$P(\bar{A}) = P\left(1000 - N \leq \sum_{i=1}^{1000} X_i \leq N\right) \geq 0.99$$

而根据题意, $\sum_{i=1}^{1000} X_i \sim b\left(1000, \frac{1}{2}\right)$, 所以上式可写为

$$\sum_{k=1000-N}^N C_{1000}^k \left(\frac{1}{2}\right)^{1000} \geq 0.99$$

(2) 利用二项分布的正态近似, 我们知道 $\frac{\sum_{i=1}^{1000} X_i - 500}{\sqrt{250}} \sim N(0, 1)$, 因此

$$\begin{aligned} P\left(1000 - N \leq \sum_{i=1}^{1000} X_i \leq N\right) &= P\left(-\frac{N-500}{\sqrt{250}} \leq \frac{\sum_{i=1}^{1000} X_i - 500}{\sqrt{250}} \leq \frac{N-500}{\sqrt{250}}\right) \\ &\approx 2\Phi\left(\frac{N-500}{5\sqrt{10}}\right) - 1 \end{aligned}$$

于是令 $2\Phi\left(\frac{N-500}{5\sqrt{10}}\right) - 1 \geq 0.99$, 即 $\Phi\left(\frac{N-500}{5\sqrt{10}}\right) \geq 0.995$, 得

$$N \geq 500 + 5\sqrt{10}u_{0.995} = 500 + 5\sqrt{10} \cdot 2.5758 = 540.727$$

所以 N 至少是 541.

四、(15 分) $f(x) = \frac{A}{\sqrt{\pi}}e^{-x^2+2x+1}$ 是 X 的概率密度函数, 求

(1) A ;

(2) EX 和 $\text{Var}(X)$.

Solution: (1) 由概率密度函数的正则性, 有 $\int_{-\infty}^{+\infty} \frac{A}{\sqrt{\pi}}e^{-x^2+2x+1}dx = Ae^2 \int_{-\infty}^{+\infty} \frac{1}{\sqrt{\pi}}e^{-(x-1)^2}dx = Ae^2 = 1$ 解得 $A = e^{-2}$.

(2) 容易看出 $X \sim N(1, \frac{1}{2})$, 所以 $EX = 1, \text{Var}(X) = \frac{1}{2}$.

五、(15 分) X, Y 独立同服从标准正态分布, $Z = 5X + 4Y, W = 5X - 4Y$, 求

(1)(7 分) EZ, EW 与 $\text{Cov}(Z, W)$;

(2)(8 分) (Z, W) 的联合概率密度.

Solution:

(1)

$$EZ = E(5X + 4Y) = 0, EW = E(5X - 4Y) = 0$$

$$\text{Cov}(Z, W) = \text{Cov}(5X + 4Y, 5X - 4Y) = 25\text{Var}(X) - 16\text{Var}(Y) = 9$$

(2) $\text{Var}(Z) = \text{Var}(W) = 25 + 16 = 41$, 因此 $\text{Corr}(Z, W) = \frac{9}{41}$, 所以 $(Z, W) \sim N(0, 0; 41, 41; \frac{9}{41})$, 它们的联合密度函数是

$$\begin{aligned} f(z, w) &= \frac{1}{82\pi\sqrt{1-\frac{9^2}{41^2}}} \exp\left\{-\frac{1}{2\left(1-\frac{9^2}{41^2}\right)}\left[\frac{z^2}{41}-\frac{2\frac{9}{41}zw}{41}+\frac{w^2}{41}\right]\right\} \\ &= \frac{1}{80\pi} \exp\left\{-\frac{1}{2}\frac{1}{1600}\left(41z^2-18zw+41w^2\right)\right\} \end{aligned}$$

六、(15 分) (X, Y) 有联合概率密度 $f(x, y) = \frac{A}{1+x^2+y^2}$.

(1)(7 分) 求常数 A ;

(2)(8 分) $\text{Var}(X)$ 与 $\text{Var}(Y)$ 是否存在?

Solution:

(1)

积分发散, f 不构成密度函数.

(2)

自然不存在方差.

[注] 原题就是如此. 错题, 因此考场上指出该题出错之人都给分.

七、(15 分) $X_1, \dots, X_n$ 是来自总体 $U(a, b)$ 的随机样本, 求 a, b 的矩估计和最大似然估计, 并判断无偏性.

Solution: 先求矩估计, 由替换原理可得

$$\begin{cases} EX = \frac{a+b}{2} \\ \text{Var}(X) = \frac{(b-a)^2}{12} \end{cases} \Rightarrow \begin{cases} \hat{a}_M = \bar{x} - \sqrt{3}s \\ \hat{b}_M = \bar{x} + \sqrt{3}s \end{cases}$$

其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n X_i$, 易知 $E\bar{x} = EX_1 = \frac{a+b}{2}$; $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$, 易知 $Es^2 = \text{Var}(X) = \frac{(b-a)^2}{12}$. 由 Jensen 不等式, 考虑严格凹函数 $g(t) = \sqrt{t}$, 有 $g(Es^2) > Eg(s^2)$, 即有不等式 $\frac{b-a}{2\sqrt{3}} > Es$ 严格成立, 因此

$$E\hat{a}_M = E(\bar{x} - \sqrt{3}s) > \frac{a+b}{2} - \frac{b-a}{2} = a$$

$$E\hat{b}_M = E(\bar{x} + \sqrt{3}s) < \frac{a+b}{2} + \frac{b-a}{2} = b$$

所以矩估计 $\hat{a}_M, \hat{b}_M$ 不是无偏估计. 再求最大似然估计, 似然函数 $L(a, b) = \frac{1}{(b-a)^n} I_{\{x_{(1)} \geq a\}} I_{\{x_{(n)} \leq b\}}$ 想要达到最大值即要求 $b-a$ 达到最小值, 而 $b \geq x_{(n)}$ 以及 $a \leq x_{(1)}$, 所以 $\hat{a}_L = x_{(1)}, \hat{b}_L = x_{(n)}$ 是 (a, b) 的最大似然估计. 而 $\frac{x_{(1)}-a}{b-a} \sim \text{beta}(1, n)$, 所以 $Ex_{(1)} = a + \frac{b-a}{n+1}$, 即 $\hat{a}_L = x_{(1)}$ 不是 a 的无偏估计; 同样 $\frac{x_{(n)}-a}{b-a} \sim \text{beta}(n, 1)$, 所以 $Ex_{(n)} = b - \frac{b-a}{n+1}$, 即 $\hat{b}_L = x_{(n)}$ 不是 b 的无偏估计.

八、(15 分) $X_1, \dots, X_n$ 是来自总体 $N(\mu, 1)$ 的随机样本, $Y_1, \dots, Y_m$ 是来自总体 $N(\mu, 4)$ 的随机样本, 两组样本独立, 令

$$T = a \sum_{i=1}^n X_i + b \sum_{j=1}^m Y_j,$$

求 a, b 的值使得 T 无偏且方差最小.

Solution: 令 $ET = E\left(a \sum_{i=1}^n X_i + b \sum_{j=1}^m Y_j\right) = (an + bm)\mu = \mu$, 即 $an + bm = 1$. 于是我们便求 $\text{Var}(T) = \text{Var}\left(a \sum_{i=1}^n X_i + b \sum_{j=1}^m Y_j\right) = a^2n + 4b^2m$ 在 $an + bm = 1$ 下的条件最小值, 约束条件可写为 $a = \frac{1-bm}{n}$, 将其代入 $\text{Var}(T)$, 有

$$\text{Var}(T) = n \left(\frac{1-bm}{n} \right)^2 + 4mb^2 = \frac{1}{n} - \frac{2m}{n}b + \left(\frac{m^2}{n} + 4m \right) b^2$$

它是关于 b 的开口向上的二次函数, 其最小值在对称轴处取到, 即

$$b = -\frac{-\frac{2m}{n}}{2\left(\frac{m^2}{n} + 4m\right)} = \frac{1}{m+4n}$$

则 $a = \frac{1-bm}{n} = \frac{4}{m+4n}$.

九、(20 分) 已知 $y_i = a + bx_i + \varepsilon_i$, $i = 1, \dots, n$, 残差独立同服从标准正态分布, 有样本相关系数

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}.$$

(1)(6 分) 求 a, b 的最小二乘估计;

(2)(7 分) 求最小二乘估计的分布;

(3)(7 分) 证明: $r^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

Solution:

(1) 考虑使 $Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2$ 达到最小, 对 a 与 b 求偏导并置 0, 得正规方程组

$$\begin{cases} \frac{\partial Q}{\partial a} = -2 \sum_{i=1}^n (y_i - a - bx_i) = 0 \\ \frac{\partial Q}{\partial b} = -2 \sum_{i=1}^n x_i (y_i - a - bx_i) = 0 \end{cases}$$

解得 β_0, β_1 的最小二乘估计是 $\begin{cases} \hat{a} = \bar{y} - \hat{b}\bar{x} \\ \hat{b} = \frac{l_{xy}}{l_{xx}} \end{cases}$. 这里

$$l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, l_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

(2) 由于 $\mathbf{Y} = (y_1, \dots, y_n)^T \sim N(X\beta, \sigma^2 I_n)$, 这里 $\beta = (a, b)^T, X = \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$. 而 $\hat{\beta} = (\hat{a}, \hat{b})^T =$

$(X^T X)^{-1} X^T \mathbf{Y}$ 依然是正态分布, 且

$$\begin{aligned} E\hat{\beta} &= E\left(X^T X\right)^{-1} X^T \mathbf{Y} = \left(X^T X\right)^{-1} X^T X \beta = \beta \\ \text{Cov}(\hat{\beta}) &= \sigma^2 \left(X^T X\right)^{-1} X^T I_n X \left(X^T X\right)^{-1} = \sigma^2 \left(X^T X\right)^{-1} \\ \text{即 } \hat{\beta} &\sim N\left(\begin{pmatrix} a \\ b \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} & -\frac{\bar{x}}{l_{xx}} \\ -\frac{\bar{x}}{l_{xx}} & \frac{1}{l_{xx}} \end{pmatrix}\right). \end{aligned}$$

(3)

$$r^2 = \frac{l_{xy}^2}{l_{xx}l_{yy}} = \frac{\hat{b}^2 l_{xx}}{l_{yy}} = \frac{\sum_{i=1}^n [\hat{b}(x_i - \bar{x})]^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

十、(20 分) 对于某种疾病, 社会患病率为 α , 若一人患病, 他被准确测出患病的概率为 γ , 若一人不患病, 他被准确测为不患病的概率是 r . 现有一人在 n 次独立测试中被测出 k 次患病, 求他的确患病的概率.

Solution: 用事件 A 表示该人患病, 用事件 B 表示该人在 n 次独立测试中被测出 k 次患病, 则由 Bayes 公式, 有

$$\begin{aligned} P(A|B) &= \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|\bar{A})P(\bar{A})} \\ &= \frac{C_n^k \gamma^k (1-\gamma)^{n-k} \cdot \alpha}{C_n^k \gamma^k (1-\gamma)^{n-k} \cdot \alpha + C_n^k (1-r)^k r^{n-k} \cdot (1-\alpha)} \\ &= \frac{\gamma^k (1-\gamma)^{n-k} \cdot \alpha}{\gamma^k (1-\gamma)^{n-k} \cdot \alpha + (1-r)^k r^{n-k} \cdot (1-\alpha)} \end{aligned}$$

北大叉院-849 统计学-2022 年

一、(15 分) 假设某新冠检测试剂准确率为 100%, 用于下述情况的检验.

(1) 某工厂 100 人中有 2 人患新冠, 将 100 人分为 10 组筛查, 若某组呈阳性则再于组内逐一筛查, 求检测次数的分布.

(2) 某工厂 $m \times n$ 人中有 2 人患新冠, 分为 n 组筛查, 若某组呈阳性则再于组内逐一筛查, 求检测次数的分布.

Solution:

(1) 若 2 人在一组, 则检测 20 次; 若 2 人不在一组, 则检测 30 次.

$$P(X=20) = 10 \cdot \frac{C_2^2 C_{98}^8}{C_{100}^{10}} = \frac{1}{11}, P(X=30) = \frac{10}{11}$$

可先求两人都在第一组的概率, 即 100 人中选 10 人, 恰选中这两人的概率, 它是 $\frac{C_2^2 C_{98}^8}{C_{100}^{10}} = \frac{1}{110}$, 又考虑到总共有 10 组, 故题中所提的概率是 $\frac{1}{11}$.

(2) 若 2 人在一组, 则检测 $n+m$ 次; 若 2 人不在一组, 则检测 $n+2m$ 次.

$$P(X=n+m) = n \cdot \frac{C_2^2 C_{mn-2}^{m-2}}{C_{mn}^m} = \frac{m-1}{mn-1}, P(X=n+2m) = \frac{mn-m}{mn-1}$$

二、(20 分) 某昆虫产卵数服从泊松分布 $\mathcal{P}(\lambda)$, 虫卵能成虫的概率是 p , 求成虫数 Y 的分布.

Solution:

根据全概率公式: $P(\text{母虫有 } n \text{ 只后代}) = \sum_{k=n}^{+\infty} P(\text{母虫有 } n \text{ 只后代} | \text{母虫产 } k \text{ 个卵}) P(\text{母虫产 } k \text{ 个卵})$, 而 $P(\text{母虫产 } k \text{ 个卵}) = \frac{\lambda^k}{k!} e^{-\lambda}$, $P(\text{母虫有 } n \text{ 只后代} | \text{母虫产 } k \text{ 个卵}) = C_k^n p^n q^{k-n} = \frac{k!}{n!(k-n)!} p^n q^{k-n}$, $\therefore P(\text{母虫有 } n \text{ 只后代}) = \sum_{k=n}^{+\infty} \frac{k!}{n!(k-n)!} p^n q^{k-n} \cdot \frac{\lambda^k}{k!} e^{-\lambda} = \frac{\lambda^n p^n}{n!} e^{-\lambda} \sum_{k=n}^{+\infty} \frac{(q\lambda)^{k-n}}{(k-n)!} = \frac{\lambda^n p^n}{n!} e^{-\lambda} \sum_{i=0}^{+\infty} \frac{(q\lambda)^i}{i!} = \frac{\lambda^n p^n}{n!} e^{-\lambda} e^{q\lambda} = \frac{(\lambda p)^n}{n!} e^{-\lambda p}$. 它恰好是参数为 λp 的泊松分布.

三、(15 分) $X_1, X_2, \dots, X_n$ 是来自指数分布 $\mathcal{E}(\lambda)$ 的随机样本, 求 λ 的 MLE 以及 MLE 的期望.

Solution: $\hat{\lambda} = \frac{n}{\sum_{i=1}^n X_i}$, $E\hat{\lambda} = \frac{n}{n-1} \lambda$.

四、(15 分) 已知 $(X, Y) \sim \mathcal{N}(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$, 求 $E(\max\{X, Y\})$.

Solution: 利用 $\max\{X, Y\} = \frac{(X+Y)+|X-Y|}{2}$, 其中 $X+Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$, 和 $X-Y \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2)$, 算得有

$$E(X+Y) = \mu_1 + \mu_2$$

以及

$$E|X-Y| = \sqrt{\frac{2(\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2)}{\pi}} e^{-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2)}} + (\mu_1 - \mu_2) \left[2\Phi\left(\frac{\mu_1 - \mu_2}{\sqrt{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}}\right) - 1 \right]$$

于是有

$$E[\max\{X, Y\}] = \frac{1}{2} [\mu_1 + \mu_2 + E|X-Y|]$$

注: 这里先记 $X-Y \sim \mathcal{N}(\mu, \sigma^2)$, 算出 $E|X-Y|$ 后再代回 $\mu = \mu_1 - \mu_2, \sigma^2 = \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2$.

五、(20 分) $X_1, X_2 \sim \mathcal{N}(0, 1)$ 且相互独立, 求 $Y = \frac{(X_1 - X_2)^2}{2}$ 的分布.

Solution: 根据正态分布的性质, $X_1 - X_2 \sim \mathcal{N}(0, 2)$, 因此 $Y = \frac{(X_1 - X_2)^2}{2} \sim \chi_1^2$.

六、(20 分) 随机变量 $X \sim \mathcal{U}(0, 1)$, $a \in (0, 1)$ 是常数, 用 Y 表示 a 到 X 的距离, 试求当 $\rho_{XY} = 0$ 时 a 的取值.

Solution: $EX = \frac{1}{2}, EY = a^2 - a + \frac{1}{2}, EXY = \frac{a^3}{3} - \frac{a}{2} + \frac{1}{3}$, 令

$$\text{Cov}(X, Y) = \frac{a^3}{3} - \frac{a}{2} + \frac{1}{3} - \frac{1}{2}a^2 - \frac{1}{2}a + \frac{1}{4} = 0$$

得 $a = \frac{1}{2}$ 以及 $a = -\frac{-4 \pm \sqrt{240}}{8}$ (舍).

七、(20 分) 有一组乙肝患者随机分配到甲组和乙组分别用疫苗 I 与疫苗 II 进行治疗. 已通过预测试得出疫苗 I 转阴率为 p_1 , 疫苗 II 转阴率为 p_2 , 且 $p_1 > p_2$. 给定检验水平 α , 求疫苗医学效用不小于 β 时, 甲组和乙组的最少样本数, 其中甲组样本数是乙组的 r 倍.

Solution: 题意不明. 但都给分.

八、(20 分) 对于总体 $X \sim \mathcal{N}(\mu, \sigma^2)$, 其中 σ^2 已知. 试问想要构造 μ 的 $1 - \alpha$ 置信区间使得区间长度不大于 L , 至少需要多少的样本量 n .

Solution: 置信区间是 $\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}$, 令其长度 $2 \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}} \leq L$, 解得 $n \geq \frac{4\sigma^2}{L^2} z_{1-\frac{\alpha}{2}}^2$.

九、(20 分) 对于线性回归模型 $y_i = \beta x_i + \varepsilon_i$, 其中诸 ε_i 相互独立都服从 $\mathcal{N}(0, \sigma^2)$. 现有 n 个观测数据. 满足

(1) 求最小二乘估计 $\hat{\beta}$, 以及 σ^2 的无偏估计.

(2) β 的 $1 - \alpha$ 置信区间;

(3) 给定 x_0 , 求 y_0 的预测区间.

Solution: (1) 对残差平方和 $Q(\beta) = \sum_{i=1}^n (y_i - \beta x_i)^2$ 求导并置零, 得正规方程:

$$\sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i^2 = 0$$

解得最小二乘估计 $\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$. 此时残差平方和的制为 $n - 1$, 因此 $\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - x_i \hat{\beta})^2}{n - 1}$ 是 σ^2 的无偏估计.

(2) 考虑到 $\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} \sim \mathcal{N}\left(\beta, \frac{\sigma^2}{\sum_{i=1}^n x_i^2}\right)$ 且与 $(n - 1) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n - 1)$ 相互独立, 因此 β 的 $1 - \alpha$ 置信区间是

$$\hat{\beta} \pm \frac{\hat{\sigma}}{\sqrt{\sum_{i=1}^n x_i^2}} t_{1-\frac{\alpha}{2}}(n - 1)$$

(3) 由于 $y_0 \sim \mathcal{N}(\beta x_0, \sigma^2)$, $\hat{\beta} x_0 \sim \mathcal{N}\left(\beta x_0, \frac{x_0^2 \sigma^2}{\sum_{i=1}^n x_i^2}\right)$, 且二者独立, 所以 $y_0 - \hat{\beta} x_0 \sim \mathcal{N}\left(0, \left(1 + \frac{x_0^2}{\sum_{i=1}^n x_i^2}\right) \sigma^2\right)$, 且他与 $(n - 1) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n - 1)$ 独立, 因此 y_0 的 $1 - \alpha$ 预测区间是

$$\hat{\beta} x_0 \pm \sqrt{1 + \frac{x_0^2}{\sum_{i=1}^n x_i^2}} \hat{\sigma} t_{1-\frac{\alpha}{2}}(n - 1)$$

北大叉院-849 统计学-2023 年

一、灯泡 A_1, A_2 串联, 它们的寿命分别是期望为 $1/\lambda_1, 1/\lambda_2$ 的指数分布. 求整个系统的运行时长 Y 的分布与期望.

Solution: 分别用 $X_1 \sim E(\lambda_1)$ 和 $X_2 \sim E(\lambda_2)$ 表示灯泡 A_1, A_2 的寿命. 对于串联电路而言, 只要有一个灯泡损坏则该系统停止工作, 因此有 $Y = \min\{X_1, X_2\}$, 故对任意 $y > 0$, 有

$$\begin{aligned} P(Y > y) &= P(X_1 > y, X_2 > y) = P(X_1 > y)P(X_2 > y) \\ &= e^{-\lambda_1 y} \cdot e^{-\lambda_2 y} \\ &= e^{-(\lambda_1 + \lambda_2)y}. \end{aligned}$$

故 Y 的分布函数是

$$F_Y(y) = \begin{cases} 0, & y < 0, \\ 1 - e^{-(\frac{1}{\lambda_1} + \frac{1}{\lambda_2})y}, & y \geq 0, \end{cases}$$

即 $Y \sim E(\lambda_1 + \lambda_2)$, 即期望为 $\frac{1}{\lambda_1 + \lambda_2}$ 的指数分布. 因此 $E(Y) = \frac{1}{\lambda_1 + \lambda_2}$.

二、 (X, Y) 的联合密度是

$$f(x, y) = \begin{cases} c|xy|, & |x| + |y| < 1, \\ 0, & \text{其他.} \end{cases}$$

(1) 求 c ;

(2) 求边际分布, 并判断是否独立;

(3) 求 $\text{Cov}(X, Y)$, 并判断是否线性相关.

Solution:

(1) 根据概率密度函数的正则性, 有 $\iint_{|x|+|y|<1} c|xy| dx dy = 1$, 根据对称性, 有

$$\iint_{|x|+|y|<1} |xy| dx dy = 4 \iint_D xy dx dy,$$

其中 $D = \{x > 0, y > 0, x + y < 1\}$. 计算积分

$$\iint_D xy dx dy = \int_0^1 dx \int_0^{1-y} xy dx = \int_0^1 \frac{1}{2} y (1-y)^2 dy = \frac{1}{2} \cdot \frac{1}{12} = \frac{1}{24}.$$

故有 $c \cdot 4 \cdot \frac{1}{24} = 1$, 则 $c = 6$.

(2) 由对称性可知 X 与 Y 的边际分布是一样的, 我们计算 Y 的边际分布, 对于 $0 < y < 1$, 有

$$\begin{aligned} f_Y(y) &= \int_{y-1}^{1-y} 6|xy| dx = 6y \left(\int_0^{1-y} x dx - \int_{y-1}^0 x dx \right) \\ &= 6y \left(\frac{(y-1)^2}{2} + \frac{(y-1)^2}{2} \right) \\ &= 6y(y-1)^2. \end{aligned}$$

同理, 对于 $-1 < y < 0$, 有 $f_Y(y) = -6y(y+1)^2$, 综上所述 Y 的密度函数是

$$f_Y(y) = \begin{cases} 6y(y-1)^2, & 0 \leq y < 1, \\ -6y(y+1)^2, & -1 \leq y < 0, \\ 0, & \text{其他.} \end{cases}$$

它是一个关于 0 对称化后的贝塔分布, X 的密度函数与其相等, 故二者显然不独立, 因为 $f_X(x) \cdot f_Y(y) \neq f(x, y)$.

(3) 根据分布的对称性 (或直接计算期望) 可知 $E(X) = E(Y) = 0$. 又根据对称性有 $E(XY) = 0$, 故 $\text{Cov}(X, Y) = 0$. 所以 X 与 Y 不相关.

三、已知 X, Y 独立服从 $N(0, 1)$, 令 $Z = |X - Y|$, 求 $E(Z)$, $\text{Var}(Z)$.

Solution: 由正态分布的性质, 记 $T = X - Y \sim N(0, 2)$, 则

$$\begin{aligned} EZ = E|T| &= \int_{-\infty}^{\infty} |t| \frac{1}{\sqrt{4\pi}} e^{-\frac{t^2}{4}} dt = 2 \int_0^{\infty} \frac{t}{\sqrt{4\pi}} e^{-\frac{t^2}{4}} dt \\ (t = 2u) &\frac{1}{\sqrt{\pi}} \cdot \int_0^{\infty} 2ue^{-u^2} d(2u) \\ (u^2 = s) &\frac{4}{\sqrt{\pi}} \cdot \int_0^{\infty} \frac{1}{2} e^{-s} ds = \frac{2}{\sqrt{\pi}}. \end{aligned}$$

而 $EZ^2 = ET^2 = 2$, 故 $\text{Var}(Z) = 2 - \frac{4}{\pi}$.

四、已知 $Y_i = X_i^T \beta + \varepsilon_i, i = 1, 2, \dots, n, \varepsilon_i \text{ i.i.d. } \sim N(0, \sigma^2), X_i \in R^p, \beta \in R^p$.

(1) 求 β, σ^2 的 MLE $\hat{\beta}, \hat{\sigma}^2$;

(2) 当 X 是给定时, 求 $\hat{\beta}$ 的分布;

(3) $Y_i = a + bx_i + \varepsilon_i, i = 1, 2, \dots, n, \varepsilon_i \text{ i.i.d. } \sim N(0, \sigma^2)$, 求 MLE $\hat{a}, \hat{b}$, 并证明 $\hat{a}, \hat{b}$ 独立当且仅当 $\sum_{i=1}^n x_i = 0$.

Solution:

(1) $Y_i \sim N(X_i \beta, \sigma^2)$, 则样本的似然函数是

$$\begin{aligned} L(\beta, \sigma^2) &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - X_i^T \beta)^2 \right\} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{Y} - X\beta)^T (\mathbf{Y} - X\beta) \right\} \end{aligned}$$

其中 $\mathbf{Y} = (y_1, y_2, \dots, y_n)^T, X = [X_1, X_2, \dots, X_n]^T$, 对数似然函数是

$$\ln L(\beta, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{Y} - X\beta)^T (\mathbf{Y} - X\beta)$$

关于各个分量求偏导并置 0, 得到似然方程组,

$$\begin{cases} \frac{\partial \ln L}{\partial \beta} = \frac{1}{\sigma^2} (2X^T \mathbf{Y} - 2X^T X \beta) = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} - \frac{1}{2\sigma^4} (\mathbf{Y} - X\beta)^T (\mathbf{Y} - X\beta) = 0 \end{cases}$$

其中由于 X 满秩, 所以 $X^T X$ 是可逆的, 于是解得对数似然函数的唯一驻点 $\hat{\beta} = (X^T X)^{-1} X^T \mathbf{Y}, \hat{\sigma}^2 = \frac{1}{n} (\mathbf{Y} - X\hat{\beta})^T (\mathbf{Y} - X\hat{\beta})$, 而对数似然函数显然是一山函数, 于是该驻点为其唯一最大值点, 即 $\hat{\beta}$ 与 $\hat{\sigma}^2$ 便是 β 与 σ^2 的 MLE.

(2) $\mathbf{Y} = (Y_1, Y_2, \dots, Y_n)^T$ 服从多元正态分布, 即 $\mathbf{Y} \sim N(X\beta, \sigma^2 I_n)$. 而 $\hat{\beta} = (X^T X)^{-1} X^T \mathbf{Y}$, 于是 $\hat{\beta}$ 亦服从多元正态分布, 且 $E\hat{\beta} = (X^T X)^{-1} X^T X \beta = \beta, \text{Cov}(\hat{\beta}) = \sigma^2 (X^T X)^{-1} X^T I_n X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$. 于是 $\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$.

(3) 令 $\beta = (a, b)^T$, 利用 (1) 与 (2) 的结果可知,

$$\begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} \sim N \left(\begin{pmatrix} a \\ b \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} & -\frac{\bar{x}}{l_{xx}} \\ -\frac{\bar{x}}{l_{xx}} & \frac{1}{l_{xx}} \end{pmatrix} \right)$$

其中, $l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$, 由正态分布的性质, $\hat{a}$ 与 $\hat{b}$ 独立当且仅当 $\hat{a}$ 与 $\hat{b}$ 不相关. 而 $\hat{a}$ 与 $\hat{b}$ 不相关. 当且仅当 $\bar{x} = 0$, 即 $\sum_{i=1}^n x_i = 0$.

五、设有 N 个袋子, 每个袋子都是 n 白球和 m 黑球. 从第一个袋子里取出一个球放到第二个袋子里, 再从第二个袋子里取球放到第三个袋子里, 以此类推.

(1) 问在最后一个口袋取出白球的概率;

(2) 已知第一个口袋取出了白球, 问最后一个口袋取出白球的概率是多少.

Solution:

(1) 用事件 A_k 表示从第 k 个袋中取出白球, 记 $p_k = P(A_k)$, 则对 $2 \leq k \leq N$, 有

$$\begin{aligned} P(A_k) &= P(A_k | A_{k-1}) P(A_{k-1}) + P(A_k | \bar{A}_{k-1}) P(\bar{A}_{k-1}) \\ p_k &= \frac{n+1}{n+m+1} p_{k-1} + \frac{n}{n+m+1} (1 - p_{k-1}) \\ p_k &= \frac{1}{n+m+1} p_{k-1} + \frac{n}{n+m+1} \\ p_k - \frac{n}{n+m} &= \frac{1}{n+m+1} \left(p_{k-1} - \frac{n}{n+m} \right), \end{aligned}$$

则数列 $\{a_k\} = \left\{ p_k - \frac{n}{n+m} \right\}$ 是等比数列, 其公比是 $\frac{1}{n+m+1}$, 首项 $a_1 = p_1 - \frac{n}{n+m} = \frac{n}{n+m} - \frac{n}{n+m} = 0$, 因此 $a_k = a_1 \cdot \left(\frac{1}{n+m+1} \right)^{k-1} \equiv 0$, 故 $p_k \equiv \frac{n}{n+m}$, 因此有 $P(A_N) = \frac{n}{n+m}$.

(2) 已知道第一个口袋取出白球, 则第二个口袋中有 $n+1$ 白球与 m 黑球. 记 $q_k = P(A_k | A_1)$, 与 (1) 中同理, 对于 $3 \leq k \leq N$, 有

$$\begin{aligned} P(A_k | A_1) &= P(A_k | A_{k-1} A_1) P(A_{k-1} | A_1) + P(A_k | \bar{A}_{k-1} A_1) P(\bar{A}_{k-1} | A_1) \\ q_k &= \frac{n+1}{n+m+1} q_{k-1} + \frac{n}{n+m+1} (1 - q_{k-1}) \\ q_k - \frac{n}{n+m} &= \frac{1}{n+m+1} \left(q_{k-1} - \frac{n}{n+m} \right), \end{aligned}$$

而此时 $b_k = q_k - \frac{n}{n+m}$ 是等比数列, $b_2 = \frac{n+1}{n+m+1} - \frac{n}{n+m}$, 因此 $b_N = \left(\frac{n+1}{n+m+1} - \frac{n}{n+m} \right) \cdot \left(\frac{1}{n+m+1} \right)^{N-2}$, 则

$$P(A_N | A_1) = q_N = \left(\frac{n+1}{n+m+1} - \frac{n}{n+m} \right) \cdot \left(\frac{1}{n+m+1} \right)^{N-2} + \frac{n}{n+m}.$$

六、设有来自 $N(\mu, \sigma^2)$ 的 n 个 i.i.d. 样本.

(1) 设 σ 已知, 构造 μ 的 $1-\alpha$ 置信区间, 求最小样本量使得区间长度小于等于 $\frac{\sigma}{5}$;

(2) 设 σ 未知, 构造 μ 的 $1-\alpha$ 置信区间.

Solution:

(1) 当 σ 已知时, 正态均值 μ 的 $1-\alpha$ 置信区间是 $\bar{X} \pm \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sigma$, 区间长度是 $L = 2 \cdot \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sigma$, 令 $2 \cdot \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sigma \leq \frac{\sigma}{5}$, 则 $\sqrt{n} \geq 10z_{1-\frac{\alpha}{2}}$, 故 $n \geq 100z_{1-\frac{\alpha}{2}}^2$.

(2) 用枢轴量法, 取 $T = \frac{\sqrt{n}(\bar{X}-\mu)}{S} \sim t(n-1)$, 其中 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 令

$$P\left(a \leq \frac{\sqrt{n}(\bar{X}-\mu)}{S} \leq b\right) = 1 - \alpha,$$

取等尾置信区间, 即 $a = -t_{1-\frac{\alpha}{2}}(n-1)$, $b = t_{1-\frac{\alpha}{2}}(n-1)$, 反解得 μ 的 $1-\alpha$ 置信区间

$$\bar{X} \pm \frac{S}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1).$$

七、设有来自 $U(-\theta, \theta)$ 总体的 n 个 i.i.d. 样本.

(1) 求 θ 的 MLE;

(2) 判断无偏性;

(3) 判断相合性.

Solution:

(1) 似然函数是

$$L(\theta) = \frac{1}{(2\theta)^n} I_{\{X_{(1)} \geq -\theta\}} I_{\{X_{(n)} \leq \theta\}} = \frac{1}{(2\theta)^n} I_{\{\max\{-X_{(1)}, X_{(n)}\} \leq \theta\}},$$

是 θ 在 $\max\{-X_{(1)}, X_{(n)}\}$ 上的递减函数, 因此 $\hat{\theta} = \max\{-X_{(1)}, X_{(n)}\}$ 是 θ 的 MLE.

(2) 总体的密度函数是 $f(x) = \frac{1}{2\theta}$, $-\theta < x < \theta$, 总体的分布函数是

$$F(x) = \begin{cases} 0, & x \leq -\theta, \\ \frac{x+\theta}{2\theta}, & -\theta < x \leq \theta, \\ 1, & x > \theta. \end{cases}$$

考虑 $(X_{(1)}, X_{(n)})$ 的联合分布, 有

$$\begin{aligned} f_{1,n}(x_1, x_n) &= \frac{n!}{(n-2)!} f(x_1) \cdot [F(x_n) - F(x_1)]^{n-2} f(x_n), -\theta < x_1 < x_n < \theta \\ &= n(n-1) \frac{(x_n - x_1)^{n-2}}{(2\theta)^n}, -\theta < x_1 < x_n < \theta. \end{aligned}$$

记 $T = \hat{\theta} = \max\{-X_{(1)}, X_{(n)}\}$, 对于 $t \in [0, \theta]$, 有

$$\begin{aligned} P(T \leq t) &= P(-X_{(1)} \leq t, X_{(n)} \leq t) = P(-t \leq X_{(1)} \leq X_{(n)} \leq t) \\ &= \int_{-t}^t dx_1 \int_{x_1}^t n(n-1) \frac{(x_n - x_1)^{n-2}}{(2\theta)^n} dx_n \\ &= \int_{-t}^t \frac{1}{(2\theta)^n} n(t - x_1)^{n-1} dx_1 \\ &= \left(\frac{2t}{2\theta}\right)^n = \left(\frac{t}{\theta}\right)^n. \end{aligned}$$

则 $f_T(t) = n \frac{t^{n-1}}{\theta^n}$, $0 < t < \theta$, 即有 $\frac{T}{\theta} \sim \text{Beta}(n, 1)$, 因此 $E\hat{\theta} = \theta E\left(\frac{T}{\theta}\right) = \frac{n}{n+1}\theta$, 所以 $\hat{\theta}$ 不是 θ 的无偏估计.

(3) 由于

$$\begin{aligned} E\hat{\theta} &= \frac{n}{n+1}\theta \rightarrow \theta \\ \text{Var}(\hat{\theta}) &= \frac{1}{\theta^2} \text{Var}\left(\frac{\hat{\theta}}{\theta}\right) = \frac{1}{\theta^2} \frac{n}{(n+1)^2(n+2)} \rightarrow 0 \end{aligned}$$

因此 $\hat{\theta}$ 是 θ 的相合估计.

八、现有 A, B 两种药以及 500 个患者, 将患者分为甲乙两组: 甲 300 个, 痊愈 168 个; 乙 200 个, 痊愈 98 个. 问在 $\alpha = 0.05$ 下, 两个药的效果有没有差异.

Solution: 甲、乙样本痊愈率的近似分布是

$$\hat{p}_1 \sim AN\left(p_1, \frac{p_1(1-p_1)}{n_1}\right), \quad \hat{p}_2 \sim AN\left(p_2, \frac{p_2(1-p_2)}{n_2}\right),$$

在原假设 $H_0: p_1 = p_2$ 下, 有

$$\hat{p}_1 - \hat{p}_2 \sim AN\left(0, \left(\frac{1}{n_1} + \frac{1}{n_2}\right)p(1-p)\right),$$

构造 Z 统计量为

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)\hat{p}(1-\hat{p})}} \sim AN(0, 1),$$

拒绝域应是 $W = |Z| > 1.96$. 其中, 应用 500 人的均值来估计原假设成立时的 p , 即

$$\hat{p} = 0.532, \quad \hat{p}_1 = 0.56, \quad \hat{p}_2 = 0.49,$$

代入有

$$Z = \frac{0.56 - 0.49}{\sqrt{\left(\frac{1}{300} + \frac{1}{200}\right) \cdot 0.532 \cdot (1 - 0.532)}} = 1.53677,$$

故不能认为有显著差异.

九、设有 $x_1, x_2, \dots, x_n$ 是来自 $N(\mu, \sigma^2)$ 的随机样本, 定义

$$\tilde{\mu} = \arg \min_c \left\{ \sum_{i=1}^n (x_i - c)^2 + \lambda c^2 \right\},$$

其中 $\lambda > 0$ 是给定的常数.

- (1) 求 $\tilde{\mu}$ 的表达式;
- (2) 求 $E(\tilde{\mu}), Var(\tilde{\mu})$.

Solution:

- (1) 记目标函数 $f(c) = \sum_{i=1}^n (x_i - c)^2 + \lambda c^2$, 令

$$f'(c) = -2 \sum_{i=1}^n (x_i - c) + 2\lambda c = 0,$$

得驻点 $c = \frac{n\bar{X}}{n+\lambda}$. 而目标函数是凹函数, 因此该驻点是极小值点, 故有 $\tilde{\mu} = \frac{n\bar{X}}{n+\lambda}$.

- (2) 直接计算, 有 $E(\tilde{\mu}) = E\left(\frac{n\bar{X}}{n+\lambda}\right) = \frac{n\mu}{n+\lambda}$ 以及 $Var(\tilde{\mu}) = \frac{n^2}{(n+\lambda)^2} \frac{\sigma^2}{n} = \frac{n\sigma^2}{(n+\lambda)^2}$.

复旦大学-861 概率论与数理统计

复旦大学 861-861 概率论与数理统计-2018 年

一、(30 分) 解决下述问题:

- (1) 已知 A 与 $\bar{B}$ 互不相容, 且 $P(A) = 0.6, P(B) = 0.7$, 试求 $P(A | B)$;
- (2) 随机向量 $(X, Y) \sim N(0, 0; 1, 4; \rho)$, 且 $D(2X - Y) = 1$, 试求 ρ ;
- (3) X_i 是独立同分布的随机变量, 已知 $E(X_i) = D(X_i) = 1$, 试求

$$\lim_{n \rightarrow \infty} P\left(\sum_{i=1}^n X_i - n > \sqrt{n}\right)$$

Solution:

(1) 因为 A 与 $\bar{B}$ 互不相容, 所以有: $P(A\bar{B}) = 0$, 可以求得:

$$P(A | B) = \frac{P(AB)}{P(B)} = \frac{P(A) - P(A\bar{B})}{P(B)} = \frac{P(A)}{P(B)} = \frac{6}{7}.$$

(2) 根据题意有

$$\begin{aligned} 1 &= D(2X - Y) \\ &= 4D(X) - 4\text{Cov}(X, Y) + D(Y) \\ &= 4 - 8\rho + 4 \end{aligned}$$

解得 $\rho = \frac{7}{8}$.

(3) 由中心极限定理, 当 n 趋于无穷时, 有 $\sum_{i=1}^n X_i \sim N(n, n)$, $\frac{\sum_{i=1}^n X_i - n}{\sqrt{n}} \sim N(0, 1)$, 所以有

$$\lim_{n \rightarrow \infty} P\left(\sum_{i=1}^n X_i - n > \sqrt{n}\right) = \lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n X_i - n}{\sqrt{n}} > \frac{\sqrt{n}}{\sqrt{n}}\right) = 1 - \Phi(1).$$

二、(20 分) 设 $\{X_i\}$ 是来自标准正态分布的随机样本, 尝试解决以下问题

- (1) 试求 $S_n = \sum_{i=1}^n X_i$ 的分布;
- (2) 试求 $\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n}S_n\right| \leq \frac{1}{\sqrt{n}}\right)$.

Solution:

(1) 由正态分布的再生性 (可加性), 因为 $X_i \sim N(0, 1)$, 所以

$$S_n = \sum_{i=1}^n X_i \sim N(0, n).$$

(2) 因为 $\frac{S_n}{n} \leq N\left(0, \frac{1}{n}\right)$, 因此有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n}S_n\right| \leq \frac{1}{\sqrt{n}}\right) = \lim_{n \rightarrow \infty} P\left(\sqrt{n}\left|\frac{1}{n}S_n\right| \leq 1\right) = \Phi(1) - \Phi(-1).$$

三、(20 分) 解决下述问题:

(1) 用特征函数的方法证明: 若 X_i 是独立同分布, 均服从参数为 1 的泊松分布, 则 $\frac{1}{\sqrt{n}}(\sum_{i=1}^n X_i - n)$ 渐进服从标准正态分布;

(2) A, B, C 两两独立不同时发生, 且 $P(A) = P(B) = P(C) = p$, 试证明 $p \leq \frac{1}{2}$.

Solution:

(1) 根据泊松分布的性质, 我们知道 $X_1, X_2, \dots, X_n$ 期望为 1, 方差也为 1, 将 $X_i - 1$ 的特征函数 $\varphi_i(t) = E[e^{it(X_i-1)}]$ 展开到二阶, 得到 $\varphi_i(t) = 1 - \frac{t^2}{2} + o(t^2)$, 根据卷积公式, 得到 $\sum_{i=1}^n X_i - n$ 的特征函数是 $\prod_{i=1}^n \varphi_i(t) = \left[1 - \frac{t^2}{2} + o(t^2)\right]^n$, 因此有 $\frac{1}{\sqrt{n}}(\sum_{i=1}^n X_i - n)$ 的特征函数是 $g_n(t) = \prod_{i=1}^n \varphi_i\left(\frac{t}{\sqrt{n}}\right) = \left[1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right]^n \rightarrow e^{-\frac{t^2}{2}}$, 极限恰是 $N(0, 1)$ 的特征函数, 根据 Levy-Cramer 连续性定理, 有 $\frac{1}{\sqrt{n}}(\sum_{i=1}^n X_i - n) \xrightarrow{d} N(0, 1)$.

(2) 显然有

$$\begin{aligned} P(A \cup B) &\leq P(A \cup B \cup C), \text{ 而 } P(A \cup B) = P(A) + P(B) - P(AB) = 2p - p^2, \\ P(A \cup B \cup C) &= P(A) + P(B) + P(C) \\ &\quad - P(AB) - P(AC) - P(BC) + P(ABC) \\ &= 3p - 3p^2, \end{aligned}$$

分别代入不等式, 得到 $2p - p^2 \leq 3p - 3p^2$, 解得 $p \leq \frac{1}{2}$.

四、(50 分) 设 $\{X_i\}$ 是来自双参数指数分布的简单随机样本, 总体的密度函数为

$$f(x) = \begin{cases} \frac{1}{\lambda} e^{-\frac{x-\theta}{\lambda}}, & x > \theta \\ 0, & x \leq \theta \end{cases}$$

其中尺度参数 $\lambda > 0$ 已知.

- (1) 试求 θ 的矩估计及其均方误差;
- (2) 试求 θ 的极大似然估计及其均方误差;
- (3) 判断以上两个估计量是否是相合的;
- (4) 试求 θ 的一个充分统计量, 并求 $x_{(1)} - \theta$ 的分布, 判断其分布是否依赖于 θ ;
- (5) 给出 θ 的 $1 - \alpha$ 置信区间.

Solution:

(1) 作总体变换, 令 $Y_i = \frac{X_i - \theta}{\lambda} \sim \text{Exp}(1)$, 则有 $1 = E(Y_1) = \frac{1}{\lambda} [E(X_1) - \theta]$, 得到 $E(X_1) = \lambda + \theta$, 由替换原理得到矩估计 $\hat{\theta}_1 = \bar{X} - \lambda$, 它恰是无偏估计, 故

$$\text{mse}(\hat{\theta}_1) = \text{Var}(\hat{\theta}_1) = \frac{\text{Var}(X_1)}{n} = \frac{\lambda^2}{n}.$$

(2) 样本对应的似然函数是 $L(\theta | x) = \frac{1}{\lambda^n} e^{-\frac{1}{\lambda}(\sum_{i=1}^n x_i - n\theta)} \cdot I_{\{\theta < x_{(j)}\}} = C(x) e^{\frac{n}{\lambda}\theta} I_{\{\theta < x_{(j)}\}}$, 其中 $C(x)$ 是于参数无关的部分, 由于 $e^{\frac{n}{\lambda}\theta}$ 关于 θ 单调递增, 因此要使 $L(\theta)$ 尽量大, 则 θ 的取值要在取值范围内尽可能大, 故 θ 的极大似然估计是 $\hat{\theta}_2 = X_{(1)}$, 借助第 (1) 问的总体变换, 有 $Y_{(1)} = \frac{X_{(1)} - \theta}{\lambda} \sim \text{Exp}(n)$, 因此容易求出 $E(X_{(1)}) = \frac{\lambda}{n} + \theta$, $D(X_{(1)}) = \frac{\lambda^2}{n^2}$, 故 $\hat{\theta}_2$ 的均方误差是 $\text{mse}(\hat{\theta}_2) = D(X_{(1)}) + \left[E(X_{(1)}) - \theta\right]^2 = \frac{\lambda^2}{n^2} + \frac{\lambda^2}{n^2} = \frac{2\lambda^2}{n^2}$.

(3) 由于 $\lim_{n \rightarrow \infty} E(\hat{\theta}_1) = \lim_{n \rightarrow \infty} E(\hat{\theta}_2) = \theta$, $\lim_{n \rightarrow \infty} D(\hat{\theta}_1) = \lim_{n \rightarrow \infty} D(\hat{\theta}_2) = 0$, 因此很容易看出 $\hat{\theta}_1, \hat{\theta}_2$ 均为相合估计.

(4) 根据因子分解定理, θ 的充分统计量为 $X_{(1)}$, 因为 $Y_{(1)} = \frac{X_{(1)} - \theta}{\lambda}$ 服从参数为 n 的指数分布, 所以 $X_{(1)} - \theta$ 服从参数为 $\frac{n}{\lambda}$ 的指数分布, 与 θ 无关.

(5) 令 $T = Y_{(1)} = \frac{X_{(1)} - \theta}{\lambda} \sim \text{Exp}(n)$, 其分布与参数无关, 是枢轴量. 我们试导出基于该枢轴量的最短置信区间, 由于 $\{a < T < b\}$ 意味着 $\{X_{(1)} - \lambda b < \theta < X_{(1)} - \lambda a\}$, 因此最短区间的构造等同于在 $\int_a^b n e^{-nx} dx = 1 - \alpha$ 的条件下求 $b - a$ 的极小值, 而由于 $n e^{-nx}$ 单调递减, 因此显然有 $a = 0$ 时区间最短, 此时 $b = -\frac{\ln \alpha}{n}$, 故最短置信区间是 $\left[X_{(1)} + \frac{\lambda \ln \alpha}{n}, X_{(1)}\right]$.

五、(30 分) 设 $\{X_i\}$ 是来自均匀分布 $U(0, \theta)$ 的简单随机样本, 考虑如下的假设检验问题

$$H_0: \theta \leq \frac{1}{2} \quad \text{vs} \quad \theta > \frac{1}{2}$$

现给出一个拒绝域为 $W = \{x_{(n)} > c\}$, 其中 c 是一个待确定常数, 解决下述问题

- (1) 求该检验法的功效函数;
- (2) 找出最小的常数 c , 使得该检验犯第一类错误的概率不超过 0.05;
- (3) 对于 (2) 中确定的常数 c , 当 $\theta = \frac{3}{4}$ 时, 想要控制该检验犯第二类错误的概率不超过 0.02, 那么样本量 n 至少为多少;
- (4) 若样本容量 $n = 20$, 且 $x_{(20)} = 0.48$, 已知 $0.95^{\frac{1}{20}} = 0.9974$, 试在 0.05 的显著性水平下对该假设检验问题作出判断.

Solution:

- (1) 我们只考虑 c 取正数, 因为负数显然无讨论必要. 由功效函数的定义, 有

$$g(\theta) = P_{\theta}(X_{(n)} > c) = \begin{cases} 1 - [P_{\theta}(X_1 < c)]^n = 1 - \left(\frac{c}{\theta}\right)^n, & c < \theta, \\ 0, & c \geq \theta. \end{cases}$$

- (2) 犯第一类错误概率 $\alpha(\theta) = 1 - \frac{c^n}{\theta^n}, \theta \leq \frac{1}{2}$, 由于 $\sup_{\theta \leq \frac{1}{2}} \alpha(\theta) = \alpha\left(\frac{1}{2}\right) = 1 - (2c)^n$, 只要它小于等于 0.05 即可, 解得 $c_{\min} = \frac{\sqrt[n]{0.95}}{2}$.

- (3) 犯第二类错误概率

$$\beta\left(\frac{3}{4}\right) = 1 - g\left(\frac{3}{4}\right) = \frac{\frac{0.95}{2^n}}{\left(\frac{3}{4}\right)^n} = 0.95 \times \left(\frac{2}{3}\right)^n,$$

令其不超过 0.02, 解得 $n \geq 9.522$.

- (4) 根据前三题结论, 此时拒绝域应为

$$W = \left\{X_{(20)} > \frac{0.9974}{2}\right\},$$

但此时 $x_{(20)} = 0.48$ 没有落入拒绝域, 故不能拒绝原假设.

复旦大学 861-861 概率论与数理统计-2019 年

一 (20 分) 已知甲、乙两厂生产一等品概率分别为 p_1, p_2 . 某商店有 10 件商品, 其中 3 件来自甲厂, 7 件来自乙厂. 试求以下事件的概率

- (1) 在该商店中抽取一件商品, 抽中的是一等品;
- (2) 已知在该商店抽取一件商品为一等品, 该产品是来自甲厂的.

Solution: (1) 设事件 A 表示抽中的商品是甲生产的, 事件 B 表示抽中的是一等品, 根据题意有 $P(A) = 0.3, P(\bar{A}) = 0.7, P(B|A) = p_1, P(B|\bar{A}) = p_2$ 因此所以在该商店抽一件商品是一等品的概率为

$$\begin{aligned} P(B) &= P(A)P(B|A) + P(\bar{A})P(B|\bar{A}) \\ &= 0.3p_1 + 0.7p_2. \end{aligned}$$

(2) 根据贝叶斯公式, 有

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{P(A)P(B|A)}{P(B)} = \frac{0.3p_1}{0.3p_1 + 0.7p_2} = \frac{3p_1}{3p_1 + 7p_2}.$$

二、(20 分) 随机变量 X, Y 相互独立, 均服从 $(0, 1)$ 上的均匀分布, 解决以下问题

- (1) 试求 $P(X < Y)$;
- (2) 求 $Z = X - Y$ 的分布.

Solution: (1) 根据对称性, 有 $P(X < Y) = P(Y < X)$, 而由于

$$P(X < Y) + P(Y < X) = 1 - P(X = Y) = 1,$$

因此有 $P(X < Y) = \frac{1}{2}$.

(2) 令 $Z = X - Y, V = Y$, 有反函数

$$\begin{cases} X = Z + V, \\ Y = V, \end{cases} \text{ 对应 } \Rightarrow \begin{cases} x = z + v \\ y = v \end{cases}$$

雅可比行列式为 1, 故有

$$f_{Z,V}(z, v) = f_{X,Y}(z+v, v) = 1, 0 < z+v < 1, 0 < v < 1,$$

当 $-1 < z < 0$, 有 $f_Z(z) = \int_{-z}^1 dv = 1+z$, 当 $0 \leq z < 1$, 有 $f_Z(z) = \int_0^{1-z} dv = 1-z$, 因此有 $f_Z(z) = 1-|z|, -1 < z < 1$.

三、(30 分) 将 k 个不同的球随机放入 n 个盒子中 ($k \geq n$), 用 X 表示空盒的个数, 试求 EX 与 DX .

Solution: 令 $X_i = \begin{cases} 1, & \text{第 } i \text{ 个盒子为空盒,} \\ 0, & \text{第 } i \text{ 个盒子不为空盒,} \end{cases}$ 则有 $X_1, \dots, X_n$ 同服从 $B\left(1, \left(1 - \frac{1}{n}\right)^k\right)$, 但不独立. 设

$Y = \sum_{k=1}^n X_k$ 是总的空盒数, 有 $EY = nEX_1 = n\left(1 - \frac{1}{n}\right)^k = \frac{(n-1)^k}{n^{k-1}}$. 至于方差, 由于

$$E(Y^2) = E\left(\sum_{i=1}^n \sum_{j=1}^n X_i X_j\right) = nE(X_1^2) + n(n-1)E(X_1 X_2)$$

其中 $E(X_1^2) = \frac{(n-1)^k}{n^k}$, 而 $E(X_1 X_2) = P(X_1 = 1, X_2 = 1) = \left(\frac{n-2}{n}\right)^k$, 故有

$$E(Y^2) = \frac{(n-1)^k}{n^{k-1}} + \frac{(n-1)(n-2)^k}{n^{k-1}}$$

因此有

$$\begin{aligned} D(Y) &= E(Y^2) - (EY)^2 \\ &= \frac{(n-1)^k}{n^{k-1}} + \frac{(n-1)(n-2)^k}{n^{k-1}} - \frac{(n-1)^{2k}}{n^{2k-2}} \end{aligned}$$

四、(40 分) 设 $\{X_i\}$ 是来自均匀分布 $U(\theta_1, \theta_2)$ 的简单随机样本, 尝试解决以下问题

- (1) 求 θ_1, θ_2 的极大似然估计;
- (2) (1) 中求出的估计是无偏的吗? 如果不是, 尝试将其修正为无偏估计;
- (3) (2) 中得到的修正无偏估计是否是 UMVUE? 说明理由;
- (4) 求位置与尺度参数 $\left(\frac{\theta_1+\theta_2}{2}, \theta_2 - \theta_1\right)$ 的 UMVUE.

Solution: (1) 样本对应的似然函数是

$$L(\theta_1, \theta_2) = \frac{1}{(\theta_2 - \theta_1)^n} I_{\{\theta_1 < X_{(1)} < X_{(n)} < \theta_2\}}$$

发现要使似然函数尽可能大, 需要使得 $(\theta_2 - \theta_1)$ 在定义域内尽可能小, 因此有

$$\hat{\theta}_1 = X_{(1)}, \hat{\theta}_2 = X_{(n)}.$$

(2) 作总体变换, 令 $Y_i = \frac{X_i - \theta_1}{\theta_2 - \theta_1} \sim U(0, 1)$, 因此 $Y_1, Y_2, \dots, Y_n$ 是 i.i.d. 的来自均匀分布的随机变量, 故有 $Y_{(1)} \sim \text{Be}(1, n)$, $Y_{(n)} \sim \text{Be}(n, 1)$, 故有

$$E(Y_{(1)}) = \frac{1}{n+1}, E(Y_{(n)}) = \frac{n}{n+1},$$

对应可以求出

$$\begin{aligned} E(X_{(1)}) &= (\theta_2 - \theta_1) E(Y_{(1)}) + \theta_1 = \frac{n}{n+1}\theta_1 + \frac{1}{n+1}\theta_2 \\ E(X_{(n)}) &= (\theta_2 - \theta_1) E(Y_{(n)}) + \theta_1 = \frac{n}{n+1}\theta_2 + \frac{1}{n+1}\theta_1 \end{aligned}$$

故它们不是无偏的, 我们可以将其修正为无偏估计, 即令

$$\hat{\theta}'_1 = \frac{nX_{(1)} - X_{(n)}}{n-1}, \hat{\theta}'_2 = \frac{nX_{(n)} - X_{(1)}}{n-1}.$$

(3) 由因子分解定理知 $(X_{(1)}, X_{(n)})$ 是充分统计量, 下证其完备: $(X_{(1)}, X_{(n)})$ 的概率密度函数是

$$\begin{aligned} f(x_1, x_n) &= n(n-1)f(x_1)f(x_n)[F(x_n) - F(x_1)]^{n-2} \\ &= \frac{n(n-1)(x_n - x_1)^{n-2}}{(\theta_2 - \theta_1)^n}, \quad \theta_1 < x_1 < x_n < \theta_2, \end{aligned}$$

对 $\forall \varphi(X_{(1)}, X_{(n)})$ 满足 $E[\varphi(X_{(1)}, X_{(n)})] = 0$, 有

$$\int_{\theta_2}^{\theta_1} \left[\int_{\theta_1}^{x_n} \varphi(x_1, x_n) \frac{n(n-1)(x_n - x_1)^{n-2}}{(\theta_2 - \theta_1)^n} dx_1 \right] dx_n = 0,$$

即 $\int_{\theta_1}^{\theta_2} \left[\int_{\theta_1}^{x_n} \varphi(x_1, x_n) (x_1 - x_n)^{n-2} dx_1 \right] dx_n = 0$, 两侧对 θ_2 求导, 有

$$\int_{\theta_1}^{\theta_2} \varphi(x_1, \theta_2) (\theta_2 - x_1)^{n-2} dx_1 = 0,$$

两侧再对 θ_1 求导有 $-\varphi(\theta_1, \theta_2) (\theta_2 - \theta_1)^{n-2} = 0$, 因 $\theta_2 - \theta_1 \neq 0$, 故有

$$\varphi(\theta_1, \theta_2) \equiv 0, \forall 0 < \theta_1 < \theta_2,$$

这说明了 $(X_{(1)}, X_{(n)})$ 是完备统计量. 由 Lehmann-Scheffe 定理可知, (2) 中的修正无偏估计量是 UMVUE.

[注]: 有的同学可能会想着分别说明 $X_{(1)}$ 和 $X_{(n)}$ 完备来完成这题, 这是不行的. 这里要用二维函数说明它们完备, 因为: “任意 g_1, g_2 , 有 $g_1(X) = g_2(Y) = 0, \text{a.s.}$ ” 无法推出 “任意 g , 有 $g(X, Y) = 0, \text{a.s.}$ ”.

(4) 根据期望的线性性, 可以利用 (2) 中两个无偏估计来构造该题的无偏估计, 即

$$E\left(\frac{X_{(1)} + X_{(n)}}{2}\right) = \frac{\theta_1 + \theta_2}{2}, \quad E\left(\frac{(n+1)(X_{(n)} - X_{(1)})}{n-1}\right) = \theta_2 - \theta_1,$$

由 Lehmann-Scheffe 定理可知: $\left(\frac{\theta_1 + \theta_2}{2}, \theta_2 - \theta_1\right)$ 的 UMVUE 为

$$\left(\frac{X_{(n)} + X_{(1)}}{2}, \frac{n+1}{n-1}(X_{(n)} - X_{(1)})\right)$$

五、(20 分) 设 $\{X_i\}$ 是来自正态分布 $N(\mu, \sigma^2)$ 的简单随机样本, μ 与 σ^2 均未知, 若想对 $\mu + k\sigma$ 进行区间估计 (这里 k 是一个常数), 能否用

$$\frac{\bar{x} - (\mu + k\sigma)}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

作为枢轴量? 请说明理由, 并求 $\mu + k\sigma$ 的 $1 - \alpha$ 置信水平的置信区间.

Solution: 根据正态分布的性质, 有 $\bar{X} - \mu - k\sigma \sim N\left(-k\sigma, \frac{\sigma^2}{n}\right)$, 故有

$$\frac{\bar{X} - (\mu + k\sigma)}{\sqrt{\frac{\sigma^2}{n}}} \sim N(-k\sqrt{n}, 1),$$

而 $\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$, 故有

$$T = \frac{\bar{X} - (\mu + k\sigma)}{\sqrt{\frac{\sigma^2}{n}}} \times \sqrt{\frac{\sigma^2(n-1)}{\sum_{i=1}^n (X_i - \bar{X})^2}} = \sqrt{n(n-1)} \frac{\bar{X} - (\mu + k\sigma)}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2}}$$

的分布与未知参数无关, 是枢轴量, 可以用来构造置信区间. 而我们发现:

$$T = \frac{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} - k\sqrt{n}}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2}}} = \frac{N(-k\sqrt{n}, 1)}{\sqrt{\frac{\chi^2(n-1)}{n-1}}} \sim t(n-1, -k\sqrt{n}),$$

它是非中心 t 分布, 自由度为 $n-1$, 非中心参数是 $-k\sqrt{n}$, 因此置信区间是

$$\mu + k\sigma \in \left[\bar{X} - \frac{s}{\sqrt{n}} t_{0.975}, \bar{X} - \frac{s}{\sqrt{n}} t_{0.025}\right].$$

六、(20 分) $X_1, X_2, \dots, X_n$ 是来自均匀分布总体 $U(0, \theta)$ 的随机样本, 考虑如下的假设检验问题

$$H_0: \theta \leq \frac{1}{2} \quad \text{vs} \quad H_1: \theta > \frac{1}{2}$$

现给出一个拒绝域为 $W = \{x_{(n)} > c\}$, 其中 c 是一个常数, 解决下述问题

- (1) 求该检验的功效函数 $\rho_W(\theta)$;
- (2) 证明 $\rho_W(\theta)$ 是关于 θ 的不减函数.

Solution: (1) X_i 的概率密度函数是 $f_{X_i}(x) = \begin{cases} \frac{1}{\theta} & 0 < x < \theta \\ 0 & \text{其他} \end{cases}$, 故分布函数是

$$F_{X_i}(x) = \begin{cases} 0 & x < 0 \\ \frac{x}{\theta} & 0 \leq x < \theta \\ 1 & \theta \leq x \end{cases}$$

因此当 $\theta \leq c$, $\rho_W(\theta) = 0$, 而当 $\theta > c$,

$$\rho_W(\theta) = P_\theta(X_{(n)} > c) = 1 - [F_{X_i}(c)]^n = 1 - \frac{c^n}{\theta^n},$$

所以功效函数是 $\rho_W(\theta) = \begin{cases} 1 - \frac{c^n}{\theta^n}, & \theta > c, \\ 0, & \theta \leq c. \end{cases}$

(2) 当 $\theta > c$ 时, $\rho'_W(\theta) = \frac{nc^n}{\theta^{n+1}} > 0$, 故 $\rho_W(\theta)$ 单调递增, 再考虑到当 $\theta \leq c$ 时, $\rho_W(\theta) \equiv 0$, 因此 $\rho_W(\theta)$ 是单调不减函数.

复旦大学 861-861 概率论与数理统计-2020 年

一 (20 分) 随机变量 X, Y 相互独立, 均服从参数为 p 的几何分布, 记 $Z = \max\{X, Y\}$, 试求

(1) 随机向量 (Z, X) 的联合分布;

(2) X 关于 Z 的条件分布.

Solution: (1) 因为 X, Y 服从参数为 p 的几何分布, 有

$$P(X = k) = P(Y = k) = p(1-p)^{k-1}, k = 1, 2, 3, \dots,$$

考虑 (Z, X) 的联合分布, 当 $i > j$ 时, 有

$$P(Z = i, X = j) = P(Y = i, X = j) = p^2(1-p)^{i+j-2},$$

当 $i = j$ 时, 有

$$\begin{aligned} P(Z = i, X = j) &= \sum_{k=1}^j P(Y = k, X = j) \\ &= p(1-p)^{j-1} \sum_{k=1}^j p(1-p)^{k-1} \\ &= p(1-p)^{j-1} [1 - (1-p)^j] \end{aligned}$$

当 $i < j$ 时, 显然 $P(Z = i, X = j) = 0$. 综上所述, 有 (Z, X) 的联合分布是

$$P(Z = i, X = j) = \begin{cases} p^2(1-p)^{i+j-2}, & i > j \\ p(1-p)^{j-1} [1 - (1-p)^j], & i = j \\ 0, & i < j \end{cases}$$

(2) 先求 Z 的边缘分布, 有

$$\begin{aligned} P(Z = i) &= \sum_{j=1}^{\infty} P(Z = i, X = j) \\ &= \sum_{j=1}^{i-1} P(Z = i, X = j) + P(Z = i, X = i) \\ &= p(1-p)^{i-1} [1 - (1-p)^{i-1}] + p(1-p)^{i-1} [1 - (1-p)^i], \end{aligned}$$

因此, X 关于 Z 的条件分布是

$$P(X = j | Z = i) = \begin{cases} \frac{p(1-p)^{j-1}}{[1 - (1-p)^{i-1}] + [1 - (1-p)^i]}, & i > j, \\ \frac{(1-p)[1 - (1-p)^i]}{[1 - (1-p)^{i-1}] + [1 - (1-p)^i]}, & i = j, \\ 0, & i < j. \end{cases}$$

二 (25 分) 随机变量 X, Y 相互独立, 均服从标准正态分布, 试求

(1) $E|X - Y|$ 以及 $D|X - Y|$;

(2) $E(\max\{X, Y\})$ 与 $E(\min\{X, Y\})$.

Solution: (1) X, Y 相互独立且服从标准正态分布, 令 $T = X - Y$, 则 $T \sim N(0, 2)$, 故

$$\begin{aligned} E(|T|) &= \int_{-\infty}^{+\infty} |t| f(t) dt = 2 \int_0^{+\infty} \frac{t}{2\sqrt{\pi}} e^{-\frac{t^2}{4}} dt \\ &= \frac{1}{\sqrt{\pi}} \int_0^{+\infty} t e^{-\frac{t^2}{4}} dt = \frac{2}{\sqrt{\pi}}. \end{aligned}$$

而 $E(|T|^2) = E(T^2) = D(T) - E(T)^2 = 2$, 因此

$$D(|T|) = E(|T|^2) - E(|T|)^2 = 2 - \frac{4}{\pi}.$$

(2) 考虑到恒等式 $\max\{X, Y\} = \frac{X+Y+|X-Y|}{2}$, $\min\{X, Y\} = \frac{X+Y-|X-Y|}{2}$ 因此有

$$E(\max\{X, Y\}) = E\left(\frac{X+Y+|X-Y|}{2}\right) = \frac{1}{\sqrt{\pi}}$$

$$E(\min\{X, Y\}) = E\left(\frac{X+Y-|X-Y|}{2}\right) = -\frac{1}{\sqrt{\pi}}$$

三、(25 分) $\{X_i\}$ 是独立同分布, 均服从参数为 1 的泊松分布, 记 $S_n = \sum_{i=1}^n X_i$, 解决如下问题

(1) 试求 S_n 的分布.

(2) 试证明 $\frac{1}{\sqrt{n}}(\sum_{i=1}^n X_i - n)$ 渐进服从标准正态分布.

Solution: (1) 由泊松分布的可加性, 可知 S_n 服从参数为 n 的泊松分布, 故

$$P(S_n = k) = \frac{n^k}{k!} e^{-n}, \quad k = 0, 1, 2, \dots$$

(2) 因为 $E(X_i) = D(X_i) = 1$ 存在, 且 $X_1, X_2, \dots, X_n$ 独立且服从参数为 1 的泊松分布, 由中心极限定理知 $\frac{1}{\sqrt{n}}(\sum_{i=1}^n X_i - n) \xrightarrow{d} N(0, 1)$.

注: 也可参照 2018 三 (1), 用特征函数证明.

四、(30 分) 设 $\{X_i\}$ 是来自泊松分布 $\text{Poisson}(\theta)$ 的简单随机样本, 记 $\eta = P(X_1 \leq 1)$ 以及 $\hat{\eta}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{I}_{\{X_i \leq 1\}}$.

(1) 求 θ, η 的极大似然估计 $\hat{\theta}_L, \hat{\eta}_L$, 并判断它们是否是 UMVUE, 说明理由;

(2) $\hat{\theta}_L, \hat{\eta}_L$ 是否具有相合性, 说明理由;

(3) $\hat{\eta}_n$ 是否为 UMVUE? 定义 $\sigma^2 = n\text{Var}(\hat{\eta}_n)$, 求 σ 的矩估计.

Solution: (1) 样本对应的似然函数是 $L(\theta) = \frac{\theta^{\sum_{i=1}^n x_i}}{x_1! x_2! \cdots x_n!} e^{-n\theta}$, 取对数得

$$\ln L(\theta) = \sum_{i=1}^n x_i \ln \theta - \ln(x_1! x_2! \cdots x_n!) - n\theta,$$

求导得 $\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{\sum_{i=1}^n x_i}{\theta} - n$, 令其为 0, 解得 $\hat{\theta}_L = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}$. 而 $\eta = P(X_1 \leq 1) = P(X_1 = 0) + P(X_1 = 1) = (1 + \theta)e^{-\theta}$, 由极大似然估计的不变性知 η 的极大似然估计是 $\hat{\eta}_L = (1 + \bar{x})e^{-\bar{x}}$. 因为泊松分布总体是指数族, 所以 $\sum_{i=1}^n x_i$ 完备, 而由于 $E(\hat{\theta}_L) = E(\bar{X}) = \theta$, 故有 $\hat{\theta}_L$ 是 UMVUE. 至于 $\hat{\eta}_L$, 考虑到 $T = \sum_{k=1}^n X_k \sim \mathcal{P}(n\theta)$, 有

$$\begin{aligned} E(\hat{\eta}_L) &= E\left(e^{-\frac{T}{n}}\right) + \frac{1}{n} E\left(T e^{-\frac{T}{n}}\right) \\ &= \sum_{k=0}^{\infty} e^{-\frac{k}{n}} \frac{(n\theta)^k}{k!} e^{-n\theta} + \frac{1}{n} \sum_{k=0}^{\infty} k e^{-\frac{k}{n}} \frac{(n\theta)^k}{k!} e^{-n\theta} \\ &= \left(1 + \theta e^{-\frac{1}{n}}\right) e^{-n\theta \left(1 - e^{-\frac{1}{n}}\right)}, \end{aligned}$$

所以 $\hat{\eta}_L$ 不是无偏估计量, 不可能是 UMVUE.

(2) 由大数定律知 $\hat{\theta}_L \xrightarrow{P} \theta$, 故 $\hat{\theta}_L$ 具有相合性, 而 $\eta = g(\theta) = (1 + \theta)e^{-\theta}$ 是 θ 的连续函数, 故 $\hat{\eta}_L = g(\hat{\theta}_L) = (1 + \hat{\theta}_L)e^{-\hat{\theta}_L}$ 也是 η 的相合估计量.

(3) 由于 $I_{\{X_1 \leq 1\}}, I_{\{X_2 \leq 1\}}, \dots, I_{\{X_n \leq 1\}}$ 是独立同服从两点分布的, 且 $E[I_{\{X_1 \leq 1\}}] = P(X_1 \leq 1)$, 由大数定律知, $\hat{\eta}_n$ 是 η 的相合估计量, 且很容易看出它是无偏估计量. 而对于泊松分布总体, $T = \sum_{i=1}^n X_i$ 是充分完备统计量, 故 $E(\hat{\eta}_n | T)$ 才是 UMVUE, $\hat{\eta}_n$ 并不是 T 的函数, 故不是 UMVUE. 可以求得

$$\text{Var}(\hat{\eta}_n) = \frac{1}{n} \text{Var}(I_{\{X_1 \leq 1\}}) = \frac{P(X_1 \leq 1)P(X_1 > 1)}{n},$$

故有 $\sigma = \sqrt{P(X_1 \leq 1)P(X_1 > 1)}$, 由替换原理, 将样本中小于等于 1 和大于 1 的比例代入, 得矩估计为

$$\hat{\sigma} = \sqrt{\hat{\eta}_n(1 - \hat{\eta}_n)}$$

五、(30 分) $X_1, X_2, \dots, X_n$ 是来自参数为 λ 的指数分布总体的随机样本, 总体的密度函数为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

- (1) 求 $G = 2\lambda \sum_{i=1}^n X_i$ 的分布;
- (2) 基于枢轴量 G 给出参数 λ 的 $1 - \alpha$ 置信水平的置信区间;
- (3) 写出上述置信区间的对偶检验问题的拒绝域与检验统计量, 这一拒绝域具有哪些优良性?
- (4) 用统计量 $T = c \sum_{i=1}^n X_i$ 对总体均值进行估计, 其中 c 使其均方误差达到最小, 试求出 c .

Solution: (1) $X_i \sim \text{Exp}(\lambda) \sim \text{Ga}(1, \lambda)$, 所以 $\sum_{i=1}^n X_i \sim \text{Ga}(n, \lambda)$, 进一步有

$$2\lambda \sum_{i=1}^n X_i \sim \text{Ga}\left(n, \frac{1}{2}\right) = \chi^2(2n).$$

所以 G 服从参数为 $2n$ 的卡方分布.

(2) 考虑到第 (3) 问, 我们直接先构造一个双侧 UMPU 拒绝域, 再去将其反转. 考虑

$$H_0: \lambda = \lambda_0 \quad \text{vs} \quad H_1: \lambda \neq \lambda_0,$$

这是单参指数族, 其水平为 α 的 UMPU 检验由充分统计量 $T = \sum_{i=1}^n X_i$ 给出, 是 $T(X) = I_{\{Y < C_1\}} + I_{\{Y > C_2\}}$, 即对应拒绝域

$$W = \{Y < C_1\} \cup \{Y > C_2\},$$

其中 $Y = \sum_{k=1}^n X_k$ 是给定的检验统计量, 且 C_1, C_2 满足

$$\begin{cases} E_{\lambda_0}[T(X)] = \alpha, \\ E_{\lambda_0}[T(X) \times Y] = \alpha E_{\lambda_0}(Y), \end{cases}$$

由于 $T(X)$ 等价于 $T(X) = I_{\{2\lambda_0 Y < a\}} + I_{\{2\lambda_0 Y > b\}}$, 故上述两条条件等价于

$$\begin{cases} P_{\lambda_0}(a < 2\lambda_0 Y < b) = 1 - \alpha, \\ E_{\lambda_0}[I_{\{a < 2\lambda_0 Y < b\}} \times 2\lambda_0 Y] = (1 - \alpha)E_{\lambda_0}(2\lambda_0 Y), \end{cases}$$

写成积分形式有 $\int_a^b \chi_{2n}^2(x) dx = 1 - \alpha$ 以及 $\int_a^b x \chi_{2n}^2(x) dx = 2(1 - \alpha)n$, 第二个式子可以写为 $\int_a^b \chi_{2(n+1)}^2(x) dx = 1 - \alpha$, 这表明了 UMPU 检验由

$$W = \left\{ 2\lambda_0 \sum_{k=1}^n X_k < a \right\} \cup \left\{ 2\lambda_0 \sum_{k=1}^n X_k > b \right\}$$

其中 a, b 满足 $\int_a^b \chi_{2n}^2(x) dx = 1 - \alpha$ 及 $\int_a^b \chi_{2(n+1)}^2(x) dx = 1 - \alpha$. 对应的接受域是

$$\bar{W} = \left\{ a \leq 2\lambda_0 \sum_{k=1}^n X_k \leq b \right\},$$

反转后得到的置信区间是

$$\lambda \in \left[\frac{a}{2 \sum_{k=1}^n X_k}, \frac{b}{2 \sum_{k=1}^n X_k} \right],$$

其中 a, b 满足:

$$\begin{cases} \int_a^b \chi_{2n}^2(x) dx = 1 - \alpha, \\ \int_a^b \chi_{2(n+1)}^2(x) dx = 1 - \alpha. \end{cases}$$

(3) 由第 (2) 的置信区间可得该对偶检验问题的拒绝域:

$$W = \left\{ 2\lambda_0 \sum_{k=1}^n X_k < a \right\} \cup \left\{ 2\lambda_0 \sum_{k=1}^n X_k > b \right\}$$

其中 a, b 满足 $\int_a^b \chi_{2n}^2(x) dx = 1 - \alpha$ 及 $\int_a^b \chi_{2(n+1)}^2(x) dx = 1 - \alpha$.

(4) 由于 $E(c \sum_{i=1}^n X_i) = \frac{cn}{\lambda}$, $\text{Var}(c \sum_{i=1}^n X_i) = \frac{c^2 n}{\lambda^2}$, 故有

$$\text{mse} \left(c \sum_{i=1}^n X_i \right) = \left(\frac{cn}{\lambda} - \frac{1}{\lambda} \right)^2 + \frac{c^2 n}{\lambda^2} = \frac{(n^2 + n)c^2 - 2nc + 1}{\lambda^2},$$

可以看出, 当 $c = \frac{1}{n+1}$ 时, 上式最小.

六、(20 分) 设有收集到的数据集 $\{(x_{i1}, x_{i2}, \dots, x_{ip}, y_i)\}_{i=1,2,\dots,n}$, 满足线性回归模型

$$Y = X\beta + \varepsilon$$

其中 $\mathbf{Y} = (y_1, y_2, \dots, y_n)^T$, $X = [x_1^T, x_2^T, \dots, x_n^T]^T$, $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})^T$, $\beta = (\beta_1, \beta_2, \dots, \beta_p)^T$, $\varepsilon = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)^T$, 且有 ε_i i.i.d $\sim N(0, \sigma^2)$. 记 $\hat{\beta}$ 是 β 的最小二乘估计, 假设矩阵 X 是满秩的, 试证明

(1) $\text{Cov}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$;

(2) $\hat{\beta}$ 是 β 的最佳线性无偏估计.

[注]: 第 (2) 问意味着: 对任意 $p \times 1$ 向量 c , 有 $c^T \hat{\beta}$ 是 $c^T \beta$ 的最佳线性无偏估计 (BLUE).

Solution: (1) 记残差平方和为 $Q(\beta) = \|\mathbf{Y} - X\beta\|^2$, 求导有 $\frac{\partial Q}{\partial \beta} = -2X^T \mathbf{Y} + 2X^T X \beta$, 令其为 0, 解得最小二乘解为 $\hat{\beta} = (X^T X)^{-1} X^T \mathbf{Y}$, 由于 $\mathbf{Y}$ 期望方差已知, $\hat{\beta}$ 是 $\mathbf{Y}$ 的一个线性变换, 其期望为 $E(\hat{\beta}) = (X^T X)^{-1} X^T E(\mathbf{Y}) = \beta$, 协方差矩阵为

$$\begin{aligned} \text{Cov}(\hat{\beta}) &= (X^T X)^{-1} X^T \text{Cov}(\mathbf{Y}) \left((X^T X)^{-1} X^T \right)^T \\ &= \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1} \end{aligned}$$

(2) 对任意 c , 假设存在一个 d , 使得线性估计 $d^T Y$ 是 $c^T \beta$ 的无偏估计, 这意味着 $E(d^T Y) = d^T E(Y) = c^T \beta$ 对任意 β 成立. 即有

$$d^T X \beta = c^T \beta,$$

这要对任意 β 成立, 说明 $d^T X = c^T$, 也就是 $X^T d = c$. 因此有

$$\begin{aligned} \text{Cov}(c^T \hat{\beta}, c^T \hat{\beta} - d^T Y) &= \text{Cov} \left(c^T (X^T X)^{-1} X^T Y, \left(c^T (X^T X)^{-1} X^T - d^T \right) Y \right) \\ &= c^T (X^T X)^{-1} X^T \text{Cov}(Y, Y) \left(c^T (X^T X)^{-1} X^T - d^T \right)^T \\ &= \sigma^2 c^T (X^T X)^{-1} X^T (X (X^T X)^{-1} c - d) \\ &= \sigma^2 \left[c^T (X^T X)^{-1} c - c^T (X^T X)^{-1} X^T d \right] \\ &= \sigma^2 c^T (X^T X)^{-1} (c - X^T d) = 0. \end{aligned}$$

进而有

$$\begin{aligned} \text{Var}\left(d^T Y\right) &= \text{Var}\left(\left(d^T Y - c^T \hat{\beta}\right) + c^T \hat{\beta}\right) \\ &= \text{Var}\left(d^T Y - c^T \hat{\beta}\right) + 2\text{Cov}\left(d^T Y - c^T \hat{\beta}, c^T \hat{\beta}\right) + \text{Var}\left(c^T \hat{\beta}\right) \\ &= \text{Var}\left(d^T Y - c^T \hat{\beta}\right) + \text{Var}\left(c^T \hat{\beta}\right) \geq \text{Var}\left(c^T \hat{\beta}\right). \end{aligned}$$

[再注]: 这题都没有让求 MLE, 所以其实完全可以把正态假设去掉.

复旦大学 861-861 概率论与数理统计-2021 年

一、(20 分) 随机变量 X, Y 相互独立, 均服从参数为 p 的几何分布, 记 $Z = \max\{X, Y\}$, 试求

(1) 随机向量 (Z, X) 的联合分布;

(2) X 关于 Z 的条件分布.

Solution: (1) 因为 X, Y 服从参数为 p 的几何分布, 有

$$P(X = k) = P(Y = k) = p(1-p)^{k-1}, k = 1, 2, 3, \dots,$$

考虑 (Z, X) 的联合分布, 当 $i > j$ 时, 有

$$P(Z = i, X = j) = P(Y = i, X = j) = p^2(1-p)^{i+j-2},$$

当 $i = j$ 时, 有

$$\begin{aligned} P(Z = i, X = j) &= \sum_{k=1}^j P(Y = k, X = j) \\ &= p(1-p)^{j-1} \sum_{k=1}^j p(1-p)^{k-1} \\ &= p(1-p)^{j-1} [1 - (1-p)^j] \end{aligned}$$

当 $i < j$ 时, 显然 $P(Z = i, X = j) = 0$. 综上所述, 有 (Z, X) 的联合分布是

$$P(Z = i, X = j) = \begin{cases} p^2(1-p)^{i+j-2}, & i > j \\ p(1-p)^{j-1} [1 - (1-p)^j], & i = j \\ 0, & i < j \end{cases}$$

(2) 先求 Z 的边缘分布, 有

$$\begin{aligned} P(Z = i) &= \sum_{j=1}^{\infty} P(Z = i, X = j) \\ &= \sum_{j=1}^{i-1} P(Z = i, X = j) + P(Z = i, X = i) \\ &= p(1-p)^{i-1} [1 - (1-p)^{i-1}] + p(1-p)^{i-1} [1 - (1-p)^i], \end{aligned}$$

因此, X 关于 Z 的条件分布是

$$P(X = j | Z = i) = \begin{cases} \frac{p(1-p)^{j-1}}{[1 - (1-p)^{i-1}] + [1 - (1-p)^i]}, & i > j, \\ \frac{(1-p)[1 - (1-p)^i]}{[1 - (1-p)^{i-1}] + [1 - (1-p)^i]}, & i = j, \\ 0, & i < j. \end{cases}$$

二、(20 分) 将 k 个不同的球随机放入 n 个盒子中 ($k \geq n$), 用 X 表示空盒的个数, 试求 EX 与 DX .

Solution: 令

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 个盒子为空盒} \\ 0, & \text{第 } i \text{ 个盒子不为空盒} \end{cases}$$

则有 $X_1, \dots, X_n$ 同服从 $B\left(1, \left(1 - \frac{1}{n}\right)^k\right)$, 但不独立. 设 $Y = \sum_{k=1}^n X_k$ 是总的空盒数, 有

$$EY = nEX_1 = n\left(1 - \frac{1}{n}\right)^k = \frac{(n-1)^k}{n^{k-1}}. \text{ 至于方差, 由于}$$

$$E(Y^2) = E\left(\sum_{i=1}^n \sum_{j=1}^n X_i X_j\right) = nE(X_1^2) + n(n-1)E(X_1 X_2)$$

其中 $E(X_1^2) = \frac{(n-1)^k}{n^{k-1}}$, 而

$$E(X_1 X_2) = P(X_1 = 1, X_2 = 1) = \left(\frac{n-2}{n}\right)^k,$$

故有 $E(Y^2) = \frac{(n-1)^k}{n^{k-1}} + \frac{(n-1)(n-2)^k}{n^{k-1}}$, 因此有

$$D(Y) = E(Y^2) - (EY)^2$$

$$= \frac{(n-1)^k}{n^{k-1}} + \frac{(n-1)(n-2)^k}{n^{k-1}} - \frac{(n-1)^{2k}}{n^{2k-2}}.$$

三、(20 分) 设 $\{X_i\}$ 是来自标准正态分布的随机样本, 尝试解决以下问题

(1) 试求 $S_n = \sum_{i=1}^n X_i$ 的分布;

(2) 试求 $\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n}S_n\right| \leq \frac{1}{\sqrt{n}}\right)$.

Solution: (1) 由正态分布的再生性 (可加性), 因为 $X_i \sim N(0, 1)$, 所以

$$S_n = \sum_{i=1}^n X_i \sim N(0, n)$$

(2) 因为 $\frac{S_n}{n} \leq N\left(0, \frac{1}{n}\right)$, 因此有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n}S_n\right| \leq \frac{1}{\sqrt{n}}\right) = \lim_{n \rightarrow \infty} P\left(\sqrt{n}\left|\frac{1}{n}S_n\right| \leq 1\right) = \Phi(1) - \Phi(-1)$$

四、(40 分) 设 $\{X_i\}$ 是来自均匀分布 $U(0, \theta)$ 的简单随机样本, 解决以下问题

(1) 求 θ 的矩估计及其均方误差;

(2) 求 θ 的极大似然估计及其均方误差;

(3) 求 θ 的充分完备统计量;

(4) 求 θ 的一致最小方差无偏估计;

(5) 给出一个 $\frac{1}{\theta}$ 的无偏估计;

Solution: (1) 由于 $E(X) = \int_0^\theta xf(x)dx = \frac{\theta}{2}$, 由替换原理, 知 $\hat{\theta} = 2\bar{x}$. 根据

$$\text{Var}(2\bar{x}) = \frac{4}{n} \text{Var}(X_1) = \frac{\theta^2}{3n}$$

以及 $\hat{\theta}$ 的无偏性, 知 $\text{mse}(\hat{\theta}) = \frac{\theta^2}{3n}$.

(2) 样本对应的似然函数是

$$L(\theta) = \frac{1}{\theta^n} I_{\{x_{(n)} < \theta\}},$$

要使似然函数尽可能大, 则 θ 要在定义域内尽可能小, 所以 θ 的极大似然估计是

$$\hat{\theta}_L = X_{(n)},$$

由于 $\frac{X_{(n)}}{\theta} \sim \text{Be}(n, 1)$, 很快得到

$$E(X_{(n)}) = \frac{n}{n+1}\theta$$
$$\text{Var}(X_{(n)}) = \frac{n\theta^2}{(n+2)(n+1)^2}$$

因此得到

$$\text{mse}(\hat{\theta}_L) = \text{Var}(X_{(n)}) + \left(E(X_{(n)}) - \theta\right)^2 = \frac{2\theta^2}{(n+1)(n+2)}$$

(3) 由因子分解定理可知 $T = X_{(n)}$ 为充分统计量, 下证其完备. 设函数 $g(\cdot)$ 满足对 $\forall \theta > 0, E_\theta(g(T)) = 0$, 即有

$$\int_0^\theta g(t) \frac{nt^{n-1}}{\theta^n} dt = 0$$

等价于 $\int_0^\theta t^{n-1} g(t) dt = 0$ 对任意 $\theta > 0$ 成立, 等式两边对 θ 求导有 $\theta^{n-1} g(\theta) = 0$ 对任意 $\theta > 0$ 成立, 故可以得到 $g(\theta) \equiv 0, \forall \theta > 0$, 所以 $T = X_{(n)}$ 是完备统计量.

(4) 由于 $E(X_{(n)}) = \frac{n}{n+1}\theta$, 令 $W = \frac{n+1}{n}X_{(n)}$ 有 $E(W) = \theta$, 而 $T = X_{(n)}$ 是 θ 的充分完备统计量, 根据 Lehmann-Scheffe 定理, $W = \frac{n+1}{n}X_{(n)}$ 是 UMVUE.

(5) 可以发现, $E\left(\frac{1}{X_{(n)}}\right) = \int_0^\theta \frac{1}{x} \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta x^{n-2} dx = \frac{n}{(n-1)\theta}$, 因此有 $\frac{1}{\theta}$ 的无偏估计是 $\frac{n-1}{nX_{(n)}}$.

五、(30 分) $X_1, X_2, \dots, X_n$ 是来自泊松分布 $\text{Poisson}(\theta)$ 的随机样本, 解决以下问题

(1) 求 θ 的充分统计量;

(2) 基于该统计量求 θ 的 $1 - \alpha$ 置信区间;

(3) 这个置信区间具有哪些优良性?

Solution: (1) 样本对应的似然函数是 $L(\theta) = \frac{\theta^{\sum_{i=1}^n x_i}}{x_1! x_2! \dots x_n!} e^{-n\theta}$, 由因子分解定理知 $T = \sum_{i=1}^n X_i \sim \mathcal{P}(n\theta)$ 是 θ 的充分统计量.

(2) 考虑反转拒绝域的方法, 讨论假设检验问题

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta \neq \theta_0$$

其优良等尾拒绝域应是 $\{T \leq a\} \cup \{T \geq b\}$ 且

$$\sup_{\theta < \theta_0} P_\theta(T \leq a) = \sup_{\theta > \theta_0} P_\theta(T \geq b) = \frac{\alpha}{2},$$

而泊松分布是指数族, 上述上确界实际表明

$$P_{\theta_0}(T \leq a) = P_{\theta_0}(T \geq b) = \frac{\alpha}{2},$$

在 n 较大时, 由 N-P 引理, 这是近似 UMPU 检验. 考虑泊松-伽马恒等式

$$\sum_{k=m}^{\infty} \frac{(n\theta)^k}{k!} e^{-n\theta} = \int_0^n \frac{\theta^m}{\Gamma(m)} x^{m-1} e^{-\theta x} dx$$
$$\sum_{k=0}^{m-1} \frac{(n\theta)^k}{k!} e^{-n\theta} = \int_n^{+\infty} \frac{\theta^m}{\Gamma(m)} x^{m-1} e^{-\theta x} dx$$

当样本值 $t_0 = \sum_{k=1}^n x_k$ 给定, 我们会在 $P_{\theta_0}(T \leq t_0) < \frac{\alpha}{2}$ 或者 $P_{\theta_0}(T \geq t_0) < \frac{\alpha}{2}$ 时拒绝原假设, 反之, $P_{\theta_0}(T \leq t_0) \geq \frac{\alpha}{2}$ 且 $P_{\theta_0}(T \geq t_0) \geq \frac{\alpha}{2}$ 时接受原假设, 根据泊松-伽马恒等式, 有

$$P_{\theta_0}(T \leq t_0) = \int_n^{+\infty} G_{t_0+1, \theta_0}(x) dx = \int_{2\theta_0 n}^{+\infty} \chi_{2(t_0+1)}^2(x) dx \geq \frac{\alpha}{2}$$

等价于 $\theta_0 \leq \frac{\chi_{1-\frac{\alpha}{2}}^2(2(t_0+1))}{2n}$, 同理有

$$P_{\theta_0}(T \geq t_0) = \int_0^n G_{t_0, \theta_0}(x) dx = \int_0^{2\theta_0 n} \chi_{2t_0}^2(x) dx \geq \frac{\alpha}{2}$$

等价于 $\theta_0 \leq \frac{\chi_{\frac{\alpha}{2}}^2(2t_0)}{2n}$, 这说明接受域可以写成

$$\bar{W} = \left\{ T(X) : \frac{\chi_{\frac{\alpha}{2}}^2(2T)}{2n} < \theta_0 < \frac{\chi_{1-\frac{\alpha}{2}}^2(2(T+1))}{2n} \right\},$$

反转接受域得到置信区间为

$$\theta \in \left[\frac{\chi_{\frac{\alpha}{2}}^2(2T)}{2n}, \frac{\chi_{1-\frac{\alpha}{2}}^2(2(T+1))}{2n} \right].$$

值得注意的是样本的值是位于自由度上的.

(3) 由于该置信区间由渐近 UMPU 拒绝域反转得到, 故其是渐近无偏区间, 且比起正态近似好在它的水平是精确 $1 - \alpha$ 的.

六、(20 分) 设 $\{X_i\}$ 是来自正态分布 $N(\mu, \sigma^2)$ 的简单随机样本, 考虑假设检验问题:

$$H_0: \mu \leq \mu_0 \text{ vs } H_1: \mu > \mu_0$$

(1) 假设 $\sigma^2 = \sigma_0^2$ 已知, 该假设检验问题是否存在一致最大功效拒绝域? 如果有请在检验水平 α 下给出它并说明理由, 如果无请说明理由并给出一个检验水平 α 的拒绝域;

(2) 假设 σ^2 未知, 那么该假设检验问题是否存在一致最大功效拒绝域? 如果有请在检验水平 α 下给出它并说明理由, 如果无请说明理由并给出一个检验水平 α 的拒绝域.

Solution: (1) 存在, 当 $\sigma^2 = \sigma_0^2$ 已知时, 该样本是单参指数族, 由 N-P 引理, 可以利用充分统计量构造 UMPT, 即其拒绝域是 $W = \{\sum_{k=1}^n X_k > C\}$, 其中 C 使得该拒绝域水平恰为 α , 因此必须满足

$$\alpha = P_{\mu_0} \left(\sum_{k=1}^n X_k > C \right) = P_{\mu_0} \left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > C_1 \right),$$

因此 $C_1 = z_{1-\frac{\alpha}{2}}$, 故 UMP 拒绝域是

$$W = \left\{ \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{1-\alpha} \right\}.$$

(2) 不存在 UMPT, 因为当 σ^2 未知时, 该样本是双参指数族, 无法构造 UMPT, 但存在 UMPUT. 可以通过检验统计量 $T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \sim \mu_0 \sim (n-1)$ 来构造一个水平为 α 的拒绝域, 即 $W = \{T > t_{1-\alpha}(n-1)\}$. 并且可以证明它恰是 UMPUT.

南开大学-432 统计学

南开大学-432 统计学-2016 年

一、选择题 (每题 4 分, 共 28 分)

1. 下列事件运算表示“三个事件恰好一个发生”的是 ().

- A. $A \cup B \cup C$;
- B. $A\bar{B}\bar{C}$
- C. $\Omega - \bar{A}\bar{B}\bar{C}$
- D. $\bar{A}\bar{B}\bar{C} + A\bar{B}\bar{C} + \bar{A}B\bar{C} + \bar{A}\bar{B}C$.

Solution: B 选项 A 表示至少有一个事件发生; 选项 B 表示只有事件 A 发生; 选项 C 与选项 A 等价, 表示至少有一个事件发生; 选项 D 表示不超过一个事件发生.

2. 已知 $X \sim P(3)$, 利用切比雪夫不等式估计 $P(0 < X < 6)$ 的概率是 ().

- A. $P(0 < X < 6) \leq \frac{1}{3}$;
- B. $P(0 < X < 6) \geq \frac{1}{3}$
- C. $P(0 < X < 6) \leq \frac{2}{3}$;
- D. $P(0 < X < 6) \geq \frac{2}{3}$.

Solution: D $X \sim P(3)$, $EX = \text{Var}(X) = 3$, 则根据切比雪夫不等式, 有:

$$P(0 < X < 6) = P(|X - EX| < 3) \geq 1 - \frac{1}{3} = \frac{2}{3}$$

3. 桌上有 n 个信封与 n 封信, 现将它们随机匹配, 则匹配成功的信封数的期望是 ().

- A. 1
- B. 2;
- C. $1 + 1/n$
- D. $n(1 - 1/e)$.

Solution: A 如果匹配正确, 令 $X_i = 1$; 否则令 $X_i = 0$; 则有:

$$P(X_i = 1) = \frac{1}{n}, P(X_i = 0) = \frac{n-1}{n}$$

$$EX = E\left(\sum_{i=1}^n X_i\right) = n \cdot \frac{1}{n} = 1$$

4. 有来自二阶矩存在总体 X 的随机样本 $X_1, \dots, X_n$, 设 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 则 S 一定是总体标准差 σ 的 ().

- A. UMVUE;
- B. 相合估计;
- C. 无偏估计;
- D. MLE.

Solution: B 如果 $\hat{\theta}$ 为 θ 的相合估计, $g(\cdot)$ 为连续函数, 则 $g(\hat{\theta})$ 为 $g(\theta)$ 的相合估计; 由于 S^2 为 σ^2 的相合估计, 则 S 为 σ 的相合估计.

5. 下列不具有可加性的分布是 ().

- A. 伽马分布;
- B. 泊松分布;
- C. 柯西分布;

D. 麦克斯韦分布.

Solution: D AB 选项显然, 伽马分布和泊松分布均具有可加性; C 选项也成立, 若有: $X_i \text{ i.i.d } \sim \text{Cau}(\gamma, x_0)$, 则 $Y = \sum_{i=1}^n X_i \sim \text{Cau}(n\gamma, nx_0)$.

6. 已知 $(X, Y) \sim N(3, 6; 1, 4; 0.5)$, 则 $P(X - Y < -3) = ()$.

- A. 0.4
- B. 0.6
- C. 0.5;
- D. 0.645.

Solution: C $X - Y$ 仍服从正态分布, 其期望为 -3 , 则有

$$P(X - Y < -3) = 0.5$$

7. 已知 X, Y, Z 独立同服从标准正态分布, 则下列说法正确的是 ().

- A. $\frac{X^2}{X^2+Y^2} \sim F(1, 2)$
- B. $\frac{3X^2}{X^2+Y^2+Z^2} \sim F(1, 3)$
- C. $\frac{\sqrt{2}X}{\sqrt{Y^2+Z^2}} \sim t(2)$
- D. $\frac{X^2+Y^2}{Y^2+Z^2} \sim F(2, 2)$.

Solution: C 对于选项 ABC 的三个式子, 分子分母不相互独立; 对于选项 D, 有:

$$\frac{X}{\sqrt{\frac{1}{2}(Y^2+Z^2)}} = \frac{\sqrt{2}X}{\sqrt{Y^2+Z^2}} \sim t(2)$$

二、填空题 (每题 4 分, 共 32 分)

1. $U(-1, 1)$ 的特征函数是 _____.

Solution: $\frac{\sin t}{t}$

$$E(e^{itx}) = \int_{-1}^1 \frac{1}{2} e^{itx} dx = \int_{-1}^1 \frac{1}{2} (\cos tx + i \sin tx) dx = \int_0^1 \cos tx dx = \frac{\sin t}{t}$$

2. 设随机变量 $X \sim N(\mu, \sigma^2)$, 则 $E|X - \mu| =$ _____.

Solution: $\sigma\sqrt{\frac{2}{\pi}}$

$$\begin{aligned} E|X - \mu| &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} |x - \mu| e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\ &= \sigma\sqrt{\frac{2}{\pi}} \int_0^{+\infty} e^{-\frac{t^2}{2}} d\left(\frac{t^2}{2}\right) = \sigma\sqrt{\frac{2}{\pi}} \end{aligned}$$

3. 有 2 个五分硬币、3 个二分硬币和 5 个一分硬币, 随机抽取 5 个, 总和大于一角的概率是 _____.

Solution: 0.5 可能情况为: 2 枚五分, 3 枚其他; 1 枚五分, 3 枚 2 分, 1 枚 1 分; 1 枚五分, 2 枚 3 分, 2 枚 1 分. 则所求概率为

$$\frac{C_2^2 C_8^3 + C_2^1 C_3^3 C_5^1 + C_2^1 C_3^2 C_5^2}{C_{10}^5} = \frac{21}{42} = \frac{1}{2}$$

4. 已知在 $Y = y$ 的条件下, $X \sim N(y, y)$, 又 $Y \sim \text{Exp}(1)$, 则 $\text{Var}(X) =$ _____.

Solution: 2 由方差恒等式

$$\begin{aligned} \text{Var}(X) &= E[\text{Var}(X | Y)] + \text{Var}[E(X | Y)] \\ &= E(Y) + \text{Var}(Y) = 2 \end{aligned}$$

5. 已知 (X, Y) 服从单位圆内的均匀分布, 则 $\text{Corr}(X, Y) =$ _____.

Solution: 0 因为 X 和 Y 的边缘密度函数在对称区间上为偶函数, 则 X 和 Y 的期望为 0; 所以 $\text{Cov}(X, Y) = EXY = \frac{1}{\pi} \int_{-1}^1 \int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}} xy \, dx \, dy = 0$. 即 X 和 Y 的相关系数为 0.

6. 已知双参数指数分布随机变量 X 具有密度函数 $f(x) = \lambda e^{-\lambda(x-a)}$, 其中 $x > a$, 则 $EX = \underline{\hspace{2cm}}$, $\text{Var}(X) = \underline{\hspace{2cm}}$.

Solution: $\frac{1}{\lambda} + a$; $\frac{1}{\lambda^2}$ $X - a$ 服从参数为 λ 的单参数指数分布, 由指数分布的性质有

$$EX = a + \frac{1}{\lambda}, \text{Var}(X) = \frac{1}{\lambda^2}$$

7. 设 $X_1, X_2, \dots, X_n$ 为来自均匀分布 $U(0, \theta)$ 的简单随机样本, 则参数 θ 的充分统计量为 $\underline{\hspace{2cm}}$.

Solution: $x_{(n)}$ 样本的联合密度函数是 $f(x_1, x_2, \dots, x_n; \theta) = \left(\frac{1}{\theta}\right)^n \mathbf{I}_{\{x_{(n)} < \theta\}}$. 由因子分解定理可知, $x_{(n)}$ 为 θ 的充分统计量.

8. 有来自 $N(\mu, \sigma^2)$ 的 n 个随机样本 $x_1, \dots, x_n$, μ, σ 未知, $\bar{x}$ 和 s^2 是样本均值和样本方差, 则 μ 的 $1 - \alpha$ 置信区间是 $\underline{\hspace{2cm}}$.

Solution: $\bar{x} \pm \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$

三、解答题 (90 分)

1.(10 分) 甲乙两个抽屉中各有 3 个白球、2 个黑球, 从甲抽屉中抽取 1 个球放入乙抽屉中, 再从乙抽屉取 4 个球放入甲抽屉, X 表示 4 个球中黑球的个数, 求 X 的分布律.

Solution: 有 $3/5$ 的概率从甲中取出白球放入乙中, 此时乙中 4 白 2 黑; 有 $2/5$ 的概率从甲中取出黑球放入乙中, 此时乙中 3 白 3 黑; X 的可能取值为 0123. 所以

$$\begin{aligned} P(X=0) &= \frac{3}{5} \frac{C_4^4}{C_6^4} + \frac{2}{5} \cdot 0 = \frac{1}{25} \\ P(X=1) &= \frac{3}{5} \frac{C_4^3 C_2^1}{C_6^4} + \frac{2}{5} \frac{C_3^3 C_3^1}{C_6^4} = \frac{2}{5} \\ P(X=2) &= \frac{3}{5} \frac{C_4^2 C_2^2}{C_6^4} + \frac{2}{5} \frac{C_3^2 C_3^2}{C_6^4} = \frac{12}{25} \\ P(X=3) &= \frac{3}{5} \cdot 0 + \frac{2}{5} \frac{C_3^3 C_3^1}{C_6^4} = \frac{2}{25} \end{aligned}$$

2.(15 分) 二维随机变量 (X, Y) 独立同分布, X 取 $-1, 0, 1$ 的概率分别为 $1/4, 1/2, 1/4$.

$$U = \begin{cases} 1, & X \geq Y, \\ 0, & X < Y, \end{cases}$$

(1) 求 (X, Y) 的联合分布;

(2) U 与 X 是否独立, 说明理由;

(3) 求 $Z = X^2 + 1$ 的分布函数.

Solution:

(1)

$Y \setminus X$	-1	0	1
-1	1/16	1/8	1/16
0	1/8	1/4	1/8
1	1/16	1/8	1/16

(2) 当 $X = 1$ 时, 有 $P(Y \leq X) = 1$, 则 $P(U = 1 | X = 1) = 1$. 当 $X = -1$ 时, 有 $P(Y \leq X) = P(Y = -1) = \frac{1}{4}$, 则 $P(U = 1 | X = -1) = \frac{1}{4}$. $P(U = 1 | X = 1) \neq P(U = 1 | X = -1)$, 于是 X 和 U 不独立.

(3)

$P(Z=1)=P(Z=2)=\frac{1}{2}$, 所以

$$F_Z(z) = \begin{cases} 0, & z < 1 \\ 0.5, & 1 \leq z < 2 \\ 1, & z \geq 2 \end{cases}$$

3.(15 分) 设 $X_1, X_2, \dots, X_n$ 为来自正态总体 $N(0, \sigma^2)$ 的简单随机样本, 其中 σ^2 为未知参数, 记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

(1) 求 σ^2 的极大似然估计, 并记之为 $\hat{\sigma}^2$;

(2) 你认为 $\hat{\sigma}^2$ 与 S_n^2 哪个更好? 为什么.

Solution: (1) 似然函数为 $L(\sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum_{i=1}^n x_i^2}{2\sigma^2}\right\}$, 将其取对数, 关于 σ^2 求导并置 0, 得到似然方程

$$\frac{\partial \ln L(\sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n x_i^2}{2\sigma^4} = 0$$

解得 $\hat{\sigma}^2 = \frac{\sum_{i=1}^n x_i^2}{n}$ 是 σ^2 的 MLE.

(2) 容易验证 $\hat{\sigma}^2$ 与 S_n^2 都是 σ^2 的无偏估计, 而

$$\begin{aligned} \text{Var}(\hat{\sigma}^2) &= \frac{\sigma^2 \text{Var}\left(\sum_{i=1}^n \frac{x_i^2}{\sigma^4}\right)}{n^2} = \frac{2\sigma^4}{n} \\ \text{Var}(S_n^2) &= \frac{\sigma^2}{(n-1)^2} \text{Var}\left(\frac{(n-1)S_n^2}{\sigma^2}\right) = \frac{2\sigma^4}{n-1} \end{aligned}$$

则 $\text{Var}(\hat{\sigma}^2) < \text{Var}(S_n^2)$, 则 $\hat{\sigma}^2$ 是更有效的, 可以认为它更好.

4.(15 分) 设 $X_1, X_2, \dots, X_n$ 为来自两点分布 $B(1, p)$ 的简单随机样本, 其中 $p \in (0, 1)$, 记 n_1, n_2 为上述 n 个样本中取值分别为 1 和 0 的个数, 如记

$$q = 1 - p, \chi^2 = \frac{(n_1 - np)^2}{np} + \frac{(n_2 - nq)^2}{nq},$$

证明当 $n \rightarrow \infty$ 时, 有 χ^2 依分布收敛于 $\chi^2(1)$.

Solution: 由于 $n_2 = n - n_1$, 所以

$$\begin{aligned} \chi^2 &= \frac{(1-p)(n_1 - np)^2 + p(n_2 - nq)^2}{np(1-p)} \\ &= \frac{(1-p)(n_1 - np)^2 + p(np - n_1)^2}{np(1-p)} = \frac{(n_1 - np)^2}{np(1-p)} \end{aligned}$$

而 $n_1 = \sum_{i=1}^n X_i \sim B(n, p)$, 根据中心极限定理

$$\frac{n_1 - np}{\sqrt{np(1-p)}} \xrightarrow{L} N(0, 1)$$

于是 $\chi^2 = \frac{(n_1 - np)^2}{np(1-p)} \xrightarrow{L} \chi^2(1)$.

5.(15 分) 有来自总体 $X \sim N(\mu, \sigma^2)$ 的 n 个随机样本, S^2 是样本方差, 基于 S^2 构造的 σ^2 的最短置信区间是

$$\left[\frac{(n-1)S^2}{a}, \frac{(n-1)S^2}{b} \right],$$

试给出 a 与 b 的关系.

Solution: 以 $T = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 为枢轴量构建 σ^2 的 $1-\alpha$ 水平的置信区间. 令 $P\left(b < \frac{(n-1)S^2}{\sigma^2} < a\right) = 1-\alpha$, 反解得 $\left[\frac{(n-1)S^2}{a}, \frac{(n-1)S^2}{b}\right]$ 是 σ^2 的 $1-\alpha$ 水平的置信区间想要令区间长度最短, 等价于寻找在 $P\left(b < \frac{(n-1)S^2}{\sigma^2} < a\right) = 1-\alpha$ 条件下, 使得 $\frac{1}{b} - \frac{1}{a}$ 达到最小值的 a 与 b , 可利用拉格朗日乘数法记 $T = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 的密度函数为 $f_{n-1}(t)$, 令 $F(a, b, \lambda) = \frac{1}{b} - \frac{1}{a} + \lambda\left(\int_b^a f_{n-1}(t)dt - 1 + \alpha\right)$ 令

$$\begin{cases} \frac{\partial F}{\partial a} = \frac{1}{a^2} + \lambda f_{n-1}(a) \\ \frac{\partial F}{\partial b} = -\frac{1}{b^2} - \lambda f_{n-1}(b) \\ \frac{\partial F}{\partial \lambda} = 0 \end{cases}$$

解得 $\begin{cases} a^2 f_{n-1}(a) = b^2 f_{n-1}(b) \\ \int_b^a f_{n-1}(t)dt = 1 - \alpha \end{cases}$, 其中 $f_{n-1}(t) = \frac{1}{2^{\frac{n-1}{2}} \Gamma(\frac{n-1}{2})} t^{\frac{n-3}{2}} e^{-\frac{t}{2}}$, 于是有

$$\begin{cases} f_{n-1}(a) = f_{n-1}(b) \\ \int_b^a f_{n-1}(t)dt = 1 - \alpha \end{cases}$$

6.(10 分) 有来自总体 $X \sim B(1, p)$ 的随机样本 $X_1, \dots, X_n$, 给出一个 p^2 的无偏估计.

Solution: 由于 $E\bar{x} = p$, 而

$$\begin{aligned} E(\bar{x})^2 &= \text{Var}(\bar{x}) + (E\bar{x})^2 \\ &= \frac{p(1-p)}{n} + p^2 \\ &= \frac{p}{n} + \frac{n-1}{n} p^2 \end{aligned}$$

于是 $E\left[\frac{n}{n-1}(\bar{x}^2 - \frac{\bar{x}}{n})\right] = p^2$, 所以 $\hat{p}^2 = \frac{n}{n-1}(\bar{x}^2 - \frac{\bar{x}}{n})$ 是 p^2 的无偏估计.

7.(10 分) 有来自双参数指数分布总体 $X \sim \text{Exp}(a, \lambda)$ 的随机样本 $X_1, \dots, X_n$, 其密度函数是

$$f(x) = \lambda e^{-\lambda(x-a)}, x > a,$$

其中 a, λ 是未知参数, 求 (a, λ) 的充分统计量.

Solution: 样本的联合密度函数是

$$\begin{aligned} f(x_1, x_2, \dots, x_n; \lambda, a) &= \lambda^n \exp\left\{-\lambda \sum_{i=1}^n (x_i - a)\right\} \mathbf{I}_{\{x_{(1)} > a\}} \\ &= \lambda^n e^{n\lambda a} e^{-n\lambda \bar{x}} \mathbf{I}_{\{x_{(1)} > a\}} \end{aligned}$$

根据因子分解定理, $(x_{(1)}, \bar{x})$ 是 (a, λ) 的充分统计量.

南开大学-432 统计学-2017 年

一、选择题 (每题 4 分, 共 28 分) 1. 已知 $P(A) = P(B) = P(C) = \frac{1}{4}$, $P(AB) = 0$, $P(AC) = P(BC) = \frac{1}{16}$, 则 A, B, C 中至少发生一个的概率是 ().

- A. $\frac{5}{8}$;
- B. $\frac{3}{8}$;
- C. $\frac{3}{4}$;
- D. $\frac{1}{4}$.

Solution: A 由于 $0 \leq P(ABC) \leq P(AB) = 0$, 所以 $P(ABC) = 0$. 因此

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) \\ &\quad - P(AB) - P(AC) - P(BC) + P(ABC) \\ &= \frac{3}{4} - \frac{1}{8} = \frac{5}{8} \end{aligned}$$

2. 若随机变 X 的方差存在, 则 $\text{Var}(X) = 0$ 的充要条件是 ().

- A. X 几乎处处取某个常数 a ;
- B. $EX = 0$;
- C. $EX^2 = 0$;
- D. $P(X = 0) = 1$.

Solution: A 如果 X 恒为一个不为 0 的常数 a , 则

$$E(X) = a = 0, E(X^2) = a^2, P(X = 0) = 0$$

由此可以排除 BCD 选项.

3. 设随机变量 X, Y 独立同分布, 且 $P(X = -1) = P(X = 1) = \frac{1}{2}$, 则 $P(X = Y) = ()$.

- A. 0;
- B. $\frac{1}{4}$;
- C. $\frac{1}{2}$;
- D. 1.

Solution: C

$$\begin{aligned} P(X = Y) &= P(X = Y = -1) + P(X = Y = 1) \\ &= \frac{1}{4} + \frac{1}{4} = \frac{1}{2} \end{aligned}$$

4. 已知随机变量 X_1, X_2, X_3 相互独立, 且 $X_1 \sim U(0, 6)$, $X_2 \sim N(1, 3)$, $X_3 \sim \text{Exp}(3)$, $Y = X_1 - 2X_2 + 3X_3$, 则 $\text{Var}(Y) = 16()$.

- A. 16;
- B. $\frac{28}{3}$;
- C. 18;
- D. 10.

Solution: A

$$\begin{aligned} \text{Var}(Y) &= \text{Var}(X_1) + 4\text{Var}(X_2) + 9\text{Var}(X_3) \\ &= 3 + 12 + 1 = 16 \end{aligned}$$

5. 如果 $X_n \xrightarrow{l} a, Y_n \xrightarrow{l} Y$, 则下列结论不一定正确的是 ().

- A. $X_n \xrightarrow{p} a$;
- B. $X_n Y_n \xrightarrow{l} aY$;

C. $X_n + Y_n \xrightarrow{l} a + Y$;

D. $Y_n \xrightarrow{p} Y$.

Solution: D 依概率收敛强于依分布收敛, 只有在收敛到退化分布二者才等价; 所以, 在一般情况下由依分布收敛推不出依概率收敛.

6. 以下说法不正确的是 ().

A. 若接受原假设, 可能犯取伪错误;

B. 若拒绝原假设, 可能犯第一类错误;

C. 控制 α 是为了控制犯第二类错误的概率;

D. 增大样本容量 n 不能同时降低犯两类错误的概率.

Solution: C 原假设正确, 但被拒绝, 为第一类错误, 又称拒真错误; 原假设不真, 但被接受, 为第二类错误, 又称取伪错误; 提出显著性检验的概念是要控制犯第一类错误的概率不超过 α . 关于 D 选项, 它有时对有时不对, 依赖于拒绝域的选取. 考虑正态总体 $N(\mu, 1)$ 的 n 个样本, 探讨假设检验

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu = 1,$$

构造两个拒绝域:

$$W_1 = \left\{ \bar{x} > \frac{z_{1-\alpha}}{\sqrt{n}} \right\}, \quad W_2 = \left\{ \bar{x} > \frac{1}{2} \right\}.$$

有

$$\alpha_1 = P_{\mu=0} \left(\bar{x} > \frac{z_{1-\alpha}}{\sqrt{n}} \right) = \alpha, \quad \beta_1 = P_{\mu=1} \left(\bar{x} < \frac{z_{1-\alpha}}{\sqrt{n}} \right) = P_{\mu=1} \left(\sqrt{n}(\bar{x} - 1) < z_{1-\alpha} - \sqrt{n} \right) = \Phi(z_{1-\alpha} - \sqrt{n}),$$

当 n 增大时, α_1 永远不变, 但 β_1 随 n 增大而递减最终趋于 0.

再算 W_2 , 有

$$\alpha_2 = P_{\mu=0} \left(\bar{x} > \frac{1}{2} \right) = P_{\mu=0} \left(\sqrt{n}\bar{x} > \frac{\sqrt{n}}{2} \right) = 1 - \Phi \left(\frac{\sqrt{n}}{2} \right),$$

$$\beta_2 = P_{\mu=1} \left(\bar{x} < \frac{1}{2} \right) = P_{\mu=1} \left(\sqrt{n}(\bar{x} - 1) < -\frac{\sqrt{n}}{2} \right) = \Phi \left(-\frac{\sqrt{n}}{2} \right),$$

发现 α_2, β_2 都随 n 增大而递减最终趋于 0.

因此 D 模棱两可, 我们选更明显错误的 C.

7. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(\mu, \sigma^2)$ 的一组随机样本, 记 $\bar{x} = \frac{1}{n} \sum_{i=1}^n X_i, s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})^2$, 则下列结论正确的是 ().

A. s^2 是 σ^2 的最大似然估计;

B. $(n-1)s^2 \sim \chi^2(n-1)$;

C. s 是 σ 的无偏估计;

D. $\frac{\sqrt{n}(\bar{x}-\mu)}{s} \sim t(n-1)$.

Solution: D $\hat{\sigma}^2_{MLE} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$, 故 A 错误; $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 故只有当 $\sigma^2 = 1$ 时, B 才是正确的; 样本标准差不是总体标准差的无偏估计, C 错误;

二、填空题 (每题 4 分, 共 32 分)

1. 甲乙两人独立的向同一目标射击, 甲击中目标的概率为 0.5, 乙击中目标的概率为 0.6, 则目标被击中的概率为 _____.

Solution: 0.8 用事件 A 表示目标被击中, 被甲击中为 A_1 , 被乙击中为 A_2 . 则

$$P(\bar{A}) = P(\bar{A}_1 \bar{A}_2) = P(\bar{A}_1) P(\bar{A}_2) = 0.5 \times 0.4 = 0.2$$

于是 $P(A) = 1 - P(\bar{A}) = 0.8$.

2. 已知 $E(X) = -2, E(X^2) = 5$, 则 $Var(1 - 3X) =$ _____.

Solution: 9 因为 $Var(X) = E(X^2) - [E(X)]^2 = 5 - 4 = 1$, 所以

$$Var(1 - 3X) = Var(-3X) = 9 Var(X) = 9$$

3. 随机变量 X 与 Y 相互独立同分布, 服从 $N(\mu, 6^2)$, 令 $U = X + Y, V = X - Y$, 则 U 与 V 的相关系数为 _____.

Solution: 0 $Cov(U, V) = Cov(X + Y, X - Y)$, 而 $Cov(X, Y) = 0$, 所以

$$\begin{aligned} Cov(U, V) &= Cov(X, X) - Cov(Y, Y) \\ &= Var(X) - Var(Y) = 0 \end{aligned}$$

4. 设随机变量 X 与 Y 相互独立, $X \sim \text{Exp}(\lambda), Y \sim \text{Exp}(\mu)$, 则 $P(X < Y) =$ _____.

Solution: $\frac{\lambda}{\lambda + \mu}$ (X, Y) 的联合密度函数是 $p(x, y) = p(x)p(y) = \lambda\mu \cdot e^{-\lambda x - \mu y}, x > 0, y > 0$ 于是

$$\begin{aligned} P(X < Y) &= \int_0^{+\infty} dy \int_0^y \lambda\mu \cdot e^{-\lambda x - \mu y} dx \\ &= \int_0^{+\infty} \mu e^{-\mu y} (1 - e^{-\lambda y}) dy \\ &= \frac{\lambda}{\lambda + \mu} \end{aligned}$$

5. 随机变量 $X \sim F(n, n)$, 则 $P(X < 1) =$ _____.

Solution: 0.5 由于 $X \sim F(n, n)$, 则 $Y = \frac{1}{X} \sim F(n, n)$, 则

$$P(X < 1) = P(Y < 1) = P\left(\frac{1}{X} < 1\right) = P(X > 1)$$

又 $P(X < 1) + P(X > 1) = 1$, 所以 $P(X < 1) = 0.5$.

6. 设 $x_1, \dots, x_m$ 是来自 $N(\mu_1, \sigma_1^2)$ 的样本, $y_1, \dots, y_n$ 是来自 $N(\mu_2, \sigma_2^2)$ 的样本, 且两个样本相互独立, $\bar{x}$ 与 $\bar{y}$ 分别是样本均值, 在 σ_1^2 和 σ_2^2 已知时, $\mu_1 - \mu_2$ 的枢轴量为 _____.

Solution: $u = \frac{\bar{x} - \bar{y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right)$, 所以可采用

$$u = \frac{\bar{x} - \bar{y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim N(0, 1)$$

作为枢轴量.

7. 若有来自总体密度函数为 $f(x) = \begin{cases} \frac{\lambda^n}{\Gamma(n)} x^{n-1} e^{-\lambda x}, & x > 0; \\ 0, & \text{其他.} \end{cases}$ 的随机样本 $x_1, \dots, x_m$, 利用 $k(k < n)$ 阶矩

求出 λ 的矩估计是 _____.

Solution: $\sqrt[k]{\frac{\Gamma(n+k)m}{\Gamma(n)(\sum x_i^k)}}$

$$E(X^k) = \int_0^{+\infty} \frac{\lambda^n}{\Gamma(n)} x^k x^{n-1} e^{-\lambda x} dx = \frac{\lambda^n}{\Gamma(n)} \frac{\Gamma(n+k)}{\lambda^{n+k}} = \frac{\Gamma(n+k)}{\Gamma(n)} \frac{1}{\lambda^k},$$

于是 $\lambda^k = \frac{\Gamma(n+k)}{\Gamma(n)E(X^k)}$, 则 $\hat{\lambda} = \sqrt[k]{\frac{\Gamma(n+k)m}{\Gamma(n)(\sum_{i=1}^n x_i^k)}}$ 是 λ 的矩估计.

三、解答题 (90 分)

1.(10 分) 设随机变量 X 的密度函数为 $p(x) = \begin{cases} a + bx^2, & 0 \leq x \leq 1; \\ 0, & \text{其他.} \end{cases}$, 如果 $E(X) = \frac{2}{3}$, 求 a 和 b .

Solution: 根据概率密度函数的正则性, 有

$$\int_0^1 p(x)dx = \int_0^1 (a + bx^2) dx = 1$$

可得方程 $a + \frac{1}{3}b = 1$. 再根据题意

$$E(X) = \int_0^1 (ax + bx^3) dx = \frac{2}{3}$$

可知 $\frac{1}{2}a + \frac{1}{4}b = \frac{2}{3}$, 联解方程可得 $a = \frac{1}{3}, b = 2$.

2.(10 分) 假设有 10 只同种电器元件, 其中有两只不合格品, 装配仪器时, 从这批元件中任取一只, 如是不合格品, 则扔掉重新任取一只, 如仍是不合格品, 则扔掉再取一只, 试求在取到合格品之前, 已取出的不合格品数的数学期望.

Solution: 用 X 表示取到合格品前已取出的不合格品, 则 X 的分布列是

$$P(X=0) = \frac{4}{5}, P(X=2) = \frac{1}{45}$$

$$P(X=1) = 1 - \frac{4}{5} - \frac{1}{45} = \frac{8}{45}$$

所以 $EX = \frac{8}{45} + 2 \cdot \frac{1}{45} = \frac{2}{9}$

3.(10 分) 设 X 与 Y 的联合密度函数为

$$f(x, y) = \begin{cases} 3x, & 0 < x < 1, 0 < y < x; \\ 0, & \text{其他.} \end{cases}$$

试求 $Z = X - Y$ 的密度函数.

Solution: 先计算 Z 的分布函数, 当 $z \in (0, 1)$ 时, 有

$$\begin{aligned} F_z(z) &= P(Z < z) \\ &= P(X - Y \leq z) \\ &= \int_0^z \int_0^x 3xdydx + \int_z^1 \int_{x-z}^x 3xdydx \\ &= \frac{3}{2}z - \frac{1}{2}z^3 \end{aligned}$$

此时有 $f_z(z) = \frac{3}{2}(1 - z^2), 0 < z < 1$. 当 $z \notin (0, 1)$ 时, 显然有 $f_z(z) = 0$.

4.(10 分) 设随机变量 X 与 Y 独立同分布, 均服从参数为 λ 的泊松分布, 令 $U = 2X + Y, V = 2X - Y$, 求 U 和 V 的相关系数 $\text{Corr}(U, V)$.

Solution:

$$\text{Var}(U) = \text{Var}(2X + Y) = 4\text{Var}(X) + \text{Var}(Y) = 5\lambda$$

$$\text{Var}(V) = \text{Var}(2X - Y) = 4\text{Var}(X) + \text{Var}(Y) = 5\lambda$$

由于 X, Y 相互独立, 所以

$$\begin{aligned} \text{Cov}(U, V) &= \text{Cov}(2X + Y, 2X - Y) \\ &= 4\text{Var}(X) - \text{Var}(Y) \\ &= 3\lambda \end{aligned}$$

于是 $\text{Corr}(U, V) = \frac{3\lambda}{\sqrt{5\lambda} \cdot \sqrt{5\lambda}} = \frac{3}{5}$.

5.(10 分) 从均值为 μ , 方差为 σ^2 的总体中, 分别抽取容量为 n_1 和 n_2 的两独立样本, $\bar{x}_1$ 和 $\bar{x}_2$ 分别是这两个样本的均值. 试证, 对于任意常数 $a, b(a + b = 1), T = a\bar{x}_1 + b\bar{x}_2$ 都是 μ 的无偏估计, 并讨论当 a, b 取何值时, T 的方差达到最小.

Solution: 由于 $E(\bar{x}_1) = E(\bar{x}_2) = \mu$, 所以 $E(T) = E(a\bar{x}_1 + b\bar{x}_2) = (a+b)\mu = \mu$, 即对于任意常数 a, b, T 都是 μ 的无偏估计. 而 $\text{Var}(\bar{x}_1) = \frac{\sigma^2}{n_1}, \text{Var}(\bar{x}_2) = \frac{\sigma^2}{n_2}$, 于是

$$\begin{aligned}\text{Var}(T) &= \frac{a^2\sigma^2}{n_1} + \frac{(1-a)^2\sigma^2}{n_2} \\ &= \sigma^2 \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) a^2 - \frac{2}{n_2} a + \frac{1}{n_2} \right]\end{aligned}$$

上式是关于 a 的一个二次函数, 显然当 $a = \frac{n_1}{n_1+n_2}$ 时, $\text{Var}(T)$ 达到最小. 此时 $b = \frac{n_2}{n_1+n_2}$.

6.(15 分) 设 $x_1, \dots, x_n$ 为来自指数分布 $E(\lambda_1)$ 的样本, $Y_1, \dots, Y_m$ 为来自指数分布 $E(\lambda_2)$ 的样本, 且两组样本独立, 其中 λ_1, λ_2 是未知的正值参数.

(1) 求假设 $H_0: \lambda_1 = \lambda_2$ vs $H_1: \lambda_1 \neq \lambda_2$ 的广义似然比检验;

(2) 试证明上述检验法的拒绝域仅依赖于比值 $T = \frac{\sum_{i=1}^n X_i}{\sum_{j=1}^m Y_j}$;

(3) 给出原假设成立时, T 的分布.

Solution: (1) 两个样本的联合似然函数是 $L(\lambda_1, \lambda_2) = \lambda_1^n e^{-\lambda_1 \sum_{i=1}^n x_i} \lambda_2^m e^{-\lambda_2 \sum_{j=1}^m y_j}$. 自然参数空间以及原假设对应的参数空间分别是

$$\Theta = \{(\lambda_1, \lambda_2) : \lambda_1 > 0, \lambda_2 > 0\}$$

$$\Theta_0 = \{(\lambda_1, \lambda_2) : \lambda_1 = \lambda_2 > 0\}$$

在自然参数空间中容易求出 (λ_1, λ_2) 的极大似然估计, 只需将对数似然函数关于两个参数的偏导置 0 即可, 它们分别是

$$\hat{\lambda}_1 = \frac{n}{\sum_{i=1}^n x_i}, \hat{\lambda}_2 = \frac{m}{\sum_{j=1}^m y_j}$$

在原假设的参数空间中求 (λ_1, λ_2) 的约束极大似然估计, 只需在似然函数中令 $\lambda_1 = \lambda_2 = \lambda$, 并将对数似然函数关于 λ 的导数置 0, 可得到 (λ_1, λ_2) 共同的极大似然估计

$$\hat{\lambda}_0 = \frac{n+m}{\sum_{i=1}^n x_i + \sum_{j=1}^m y_j}$$

从而可计算得到似然比统计量

$$\Lambda = \frac{L(\hat{\lambda}_1, \hat{\lambda}_2)}{L(\hat{\lambda}_0, \hat{\lambda}_0)} = \frac{(\hat{\lambda}_1)^n (\hat{\lambda}_2)^m}{(\hat{\lambda}_0)^{n+m}} = \frac{n^n m^m}{(n+m)^{n+m}} \frac{\left(\sum_{i=1}^n x_i + \sum_{j=1}^m y_j\right)^{n+m}}{\left(\sum_{i=1}^n x_i\right)^n \left(\sum_{j=1}^m y_j\right)^m}$$

因此该问题的似然比拒绝域为 $W = \{\Lambda(\mathbf{X}, \mathbf{Y}) > c\}$, 这里常数 c 使得该拒绝域适合给定的显著性水平 α .

(2) 将似然比统计量改写为如下的形式

$$\begin{aligned}\Lambda &= \frac{n^n m^m}{(n+m)^{n+m}} \left(1 + \frac{\sum_{i=1}^n x_i}{\sum_{j=1}^m y_j}\right)^m \left(1 + \frac{\sum_{j=1}^m y_j}{\sum_{i=1}^n x_i}\right)^n \\ &= \frac{n^n m^m}{(n+m)^{n+m}} (1+T)^m \left(1 + \frac{1}{T}\right)^n\end{aligned}$$

其中 $T = \frac{\sum_{i=1}^n x_i}{\sum_{j=1}^m y_j}$, 同时注意到 $f(T) = (1+T)^m \left(1 + \frac{1}{T}\right)^n$ 关于 T 是一个先减后增函数, 并且 $f(0+) = +\infty, f(+\infty) = +\infty$, 于是

$$\{\Lambda(\mathbf{X}, \mathbf{Y}) > c\} \iff \{T < a\} \cup \{T > b\}$$

这里常数 a, b 满足

$$\begin{cases} f(a) = f(b) \\ P(\{T < a\} \cup \{T > b\} | \lambda_1 = \lambda_2) = 1 - \alpha \\ a < b \end{cases}$$

(3) 由指数分布、伽马分布、卡方分布之间的关系容易得到

$$\sum_{i=1}^n x_i \sim \text{Ga}(n, \lambda_1), 2\lambda_1 \sum_{i=1}^n x_i \sim \text{Ga}\left(n, \frac{1}{2}\right) = \chi^2(2n)$$

$$\sum_{j=1}^m y_j \sim \text{Ga}(m, \lambda_2), 2\lambda_2 \sum_{j=1}^m y_j \sim \text{Ga}\left(m, \frac{1}{2}\right) = \chi^2(2m)$$

于是当原假设成立时,

$$\frac{2m}{2n} T = \frac{\sum_{i=1}^n x_i/2n}{\sum_{j=1}^m y_j/2m} = \frac{2\lambda_1 (\sum_{i=1}^n x_i/2n)}{2\lambda_2 (\sum_{j=1}^m y_j/2m)} \sim F(2n, 2m)$$

7.(14 分) 设总体概率密度函数如下: $f(x; \theta, \mu) = \frac{1}{\theta} e^{-\frac{x-\mu}{\theta}}, x > \mu, \theta > 0, x_1, x_2, \dots, x_n$ 是来自该总体的随机样本, 求未知参数的极大似然估计.

Solution: 样本的似然函数是 $L(\theta, \mu) = \left(\frac{1}{\theta}\right)^n e^{-\sum_{i=1}^n \frac{(x_i - \mu)}{\theta}} I_{\{x_{(1)} \geq \mu\}}$. 对于 μ 而言, 无论 θ 取何值, $L(\theta, \mu)$ 是 μ 在 $(-\infty, x_{(1)})$ 上的单调增函数, 因此 μ 的极大似然估计是 $\hat{\mu} = x_{(1)}$. 对于 θ 而言, 先将 $\hat{\mu} = x_{(1)}$ 代入似然函数, 并将此时的对数似然函数关于 θ 的导数置 0, 即

$$\frac{d \ln L(\theta, \hat{\mu})}{d\theta} = -\frac{n}{\theta} + \frac{\sum_{i=1}^n (x_i - \hat{\mu})}{\theta^2} = 0$$

得 $\hat{\theta} = \frac{\sum_{i=1}^n (x_i - \hat{\mu})}{n} = \bar{x} - x_{(1)}$ 是 θ 的极大似然估计.

8.(15 分) 设 x_1, x_2 独立同分布, 其共同的密度函数为 $f(x; \theta) = \frac{3x^2}{\theta^3}, 0 < x < \theta, \theta > 0$.

(1) 证明: $T_1 = \frac{2}{3}(x_1 + x_2)$ 和 $T_2 = \frac{7}{6} \max\{x_1, x_2\}$ 都是 θ 的无偏估计;

(2) 计算 T_1 和 T_2 的均方误差并进行比较.

Solution:

(1) $E(X) = \int_0^\theta x \frac{3x^2}{\theta^3} dx = \frac{3}{4}\theta$, 于是 $E(T_1) = \frac{4}{3}E(X) = \theta$, 即 T_1 是 θ 的无偏估计. 记 $Y = \max\{x_1, x_2\}$, 求得其密度函数 $f_Y(y) = \frac{6y^5}{\theta^6}, 0 < y < \theta$. 于是 $E(T_2) = \frac{7}{6}E(Y) = \frac{7}{6} \int_0^\theta \frac{6y^6}{\theta^6} dy = \theta$, 则 T_2 是 θ 的无偏估计.

(2) 由于上述两个估计量都是无偏估计, 其方差便是均方误差.

$$E(X_1^2) = \int_0^\theta x^2 \frac{3x^2}{\theta^3} dx = \frac{3}{5}\theta^2$$

$$\text{Var}(X_1) = \frac{3}{5}\theta^2 - \left(\frac{3}{4}\theta\right)^2 = \frac{3}{80}\theta^2$$

则 $\text{MSE}(T_1) = \frac{8}{9} \text{Var}(X_1) = \frac{1}{30}\theta^2$.

$$E(Y^2) = \int_0^\theta y^2 \frac{6y^5}{\theta^6} dy = \frac{3}{4}\theta^2$$

$$\text{Var}(Y) = \frac{3}{4}\theta^2 - \left(\frac{6}{7}\theta\right)^2 = \frac{3}{196}\theta^2$$

则 $\text{MSE}(T_2) = \text{Var}(T_2) = \frac{1}{48}\theta^2$. 于是有 $\text{MSE}(T_2) < \text{MSE}(T_1)$.

南开大学-432 统计学-2018 年

一、选择题 (每题 4 分, 共 28 分) 1. 若 $P(B|A) = 1$, 则 ().

- A. $A \in B$;
- B. $B \in A$;
- C. $A - B = \phi$;
- D. $P(A - B) = 0$.

Solution: D 考虑 A 与 B 相差一个非空的零概率集, 则可排除 ABC 三个选项.

2. 袋子中有 5 个球, 其中 2 个黄球, 3 个白球, 现有两个人不放回的依次从中取球, 问第二个人取到黄球的概率是 ().

- A. $\frac{2}{5}$;
- B. $\frac{1}{5}$;
- C. $\frac{3}{10}$;
- D. $\frac{3}{5}$.

Solution: A

$$P = \frac{2}{5} \times \frac{1}{4} + \frac{3}{5} \times \frac{2}{4} = 0.4$$

3. 设 X_1, X_2, X_3 独立, 且都服从参数为 3 的泊松分布, 令 $Y = X_1 + X_2 + X_3$, 则 $E(Y^2) = ()$.

- A. 9;
- B. 12;
- C. 81;
- D. 90.

Solution: D $Y \sim \mathcal{P}(9)$, 则 $EY = DY = 9$, 故 $EY^2 = DY + (EY)^2 = 90$.

4. 设 $X_1, X_2, \dots, X_8$ 均为来自总体 $N(-1, 4)$ 的样本, $Y_1, Y_2, \dots, Y_{10}$ 为来自总体 $N(2, 5)$ 的样本, 则服从 $F(7, 9)$ 的是 ().

- A. $\frac{2S_1^2}{5S_2^2}$;
- B. $\frac{5S_1^2}{4S_2^2}$;
- C. $\frac{4S_1^2}{5S_2^2}$;
- D. $\frac{5S_1^2}{2S_2^2}$.

Solution: B 由于 $\frac{7S_1^2}{4} \sim \chi^2(7)$, $\frac{9S_2^2}{5} \sim \chi^2(9)$ 且两者独立, 所以有

$$\frac{S_1^2}{4} / \frac{S_2^2}{5} = \frac{5S_1^2}{4S_2^2} \sim F(7, 9).$$

5. 下列说法正确的是 ().

- A. 在一次实验中, 可以同时犯两类错误;
- B. 如果备择假设为真, 做出接受原假设, 则犯第一类错误;
- C. 增大样本容量 n , 可以使两类错误同时变小;
- D. 如果原假设为真, 做出拒绝备择假设, 则犯第二类错误.

Solution: C. 尽量选出一个最合理的选项. A: 在一次实验中, 只可能犯一种错误; B: 如果备择假设为真, 即原假设假, 但接受原假设, 则犯第二类错误 (取伪); C: 这个可对、可错. D: 如果原假设为真, 拒绝备择假设, 则未犯错误.

对于 C, 我们举例: 考虑正态总体 $N(\mu, 1)$ 的 n 个样本, 探讨假设检验

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu = 1,$$

构造两个拒绝域:

$$W_1 = \left\{ \bar{x} > \frac{z_{1-\alpha}}{\sqrt{n}} \right\}, \quad W_2 = \left\{ \bar{x} > \frac{1}{2} \right\}.$$

有

$$\alpha_1 = P_{\mu=0} \left(\bar{x} > \frac{z_{1-\alpha}}{\sqrt{n}} \right) = \alpha, \quad \beta_1 = P_{\mu=1} \left(\bar{x} < \frac{z_{1-\alpha}}{\sqrt{n}} \right) = P_{\mu=1} (\sqrt{n}(\bar{x}-1) < z_{1-\alpha} - \sqrt{n}) = \Phi(z_{1-\alpha} - \sqrt{n}),$$

当 n 增大时, α_1 永远不变, 但 β_1 随 n 增大而递减最终趋于 0.

再算 W_2 , 有

$$\alpha_2 = P_{\mu=0} \left(\bar{x} > \frac{1}{2} \right) = P_{\mu=0} \left(\sqrt{n}\bar{x} > \frac{\sqrt{n}}{2} \right) = 1 - \Phi \left(\frac{\sqrt{n}}{2} \right),$$

$$\beta_2 = P_{\mu=1} \left(\bar{x} < \frac{1}{2} \right) = P_{\mu=1} \left(\sqrt{n}(\bar{x}-1) < -\frac{\sqrt{n}}{2} \right) = \Phi \left(-\frac{\sqrt{n}}{2} \right),$$

发现 α_2, β_2 都随 n 增大而递减最终趋于 0.

因此 C 可对可错, 但其他都明显错误, 我们仅能选 C.

6. 若 (1) 代表按分布收敛, (2) 代表依概率收敛, (3) 代表几乎处处收敛, 则它们之间的关系为 ().

- A. (1) > (2) > (3);
- B. (2) > (3) > (1);
- C. (3) > (2) > (1);
- D. (1) > (3) > (2).

Solution: C

7. 设 X 服从 $N(\mu, 16)$, Y 服从 $N(\mu, 9)$, $p_1 = P\{X \geq \mu + 4\}$, $p_2 = P\{Y \leq \mu - 3\}$, 则 p_1 和 p_2 的大小关系为 ().

- A. $p_1 = p_2$;
- B. $p_1 > p_2$;
- C. $p_1 < p_2$;
- D. 不确定.

Solution: A

$$p_1 = P\left(\frac{X-\mu}{4} \geq 1\right) = 1 - \Phi(1), \quad p_2 = P\left(\frac{Y-\mu}{3} \leq -1\right) = \Phi(-1)$$

根据标准正态分布函数的性质可知 $p_1 = p_2$.

二、填空题 (每题 4 分, 共 32 分)

1. 若 δ 服从 $U(1, 6)$, 则方程 $X^2 + \delta X + 1 = 0$ 有实根的概率是 _____.

Solution: $\frac{4}{5}$

$$\Delta^2 = \delta^2 - 4 \geq 0 \Leftrightarrow \delta \geq 2, \text{ 则 } P(\text{有实根}) = P(\delta \geq 2) = \frac{4}{5}.$$

2. 若 ε 的概率分布为 $P\{\varepsilon = k\} = A\left(\frac{1}{2}\right)^k, k = 1, 2, 3, 4$, 则 $P\left\{\frac{1}{2} < \varepsilon < \frac{5}{2}\right\} =$ _____.

Solution: $\frac{4}{5}$

根据概率密度函数的正则性, $1 = A \sum_{k=1}^4 \left(\frac{1}{2}\right)^k = \frac{16}{15}A$, 得 $A = \frac{15}{16}$, 所以

$$P\left\{\frac{1}{2} < \varepsilon < \frac{5}{2}\right\} = P\{\varepsilon = 1\} + P\{\varepsilon = 2\} = \frac{16}{15} \left[\left(\frac{1}{2}\right) + \left(\frac{1}{2}\right)^2 \right] = \frac{4}{5}$$

3. 已知 $P\{X \geq 0, Y \geq 0\} = \frac{3}{7}$, $P\{X \geq 0\} = P\{Y \geq 0\} = \frac{4}{7}$, 则 $P\{\max(X, Y) \geq 0\} =$ _____.

Solution: $\frac{5}{7}$

$$P\{\max(X, Y) \geq 0\} = P\{X \geq 0\} + P\{Y \geq 0\} - P\{X \geq 0, Y \geq 0\} = \frac{5}{7}$$

4. 已知 X 服从 $N(\mu, 0.09)$, 抽取一个 $n = 9$ 的样本, $\bar{X} = 5$, 则 μ 的 0.95 置信区间为 _____.

Solution: [4.804, 5.196]

$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \Rightarrow \mu \in \bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}$, 代入数据可求得置信区间.

5. 已知元件寿命服从参数为 $1/100$ 的指数分布, 现在有 5 个元件串联, 问这个电路正常工作 100 个小时以上的概率为 _____.

Solution: e^{-5}

5 个元件串联, 则电路寿命为元件寿命最小值, 在根据指数分布的最小值分布的结论知道 $X_{(1)} \sim \text{Exp}(\frac{5}{100})$, 于是 $P(X_{(1)} \geq 100) = 1 - F_{X_{(1)}}(100) = e^{-5}$.

6. 已知 $f(x) = \begin{cases} \frac{1}{4}(x+1), & 0 < x < 2; \\ 0, & \text{其他.} \end{cases}$, 对 X 观察 8 次, Y 表示观察值大于 1 的次数, 则 $D(Y) =$ _____.

Solution: $\frac{15}{8}$

容易知道 $Y \sim b(8, p)$, 其中 $p = P(X \geq 1) = \int_1^2 \frac{1}{4}(x+1)dx = \frac{5}{8}$, 于是

$$DY = 8 \cdot \frac{5}{8} \cdot \frac{3}{8} = \frac{15}{8}$$

7. 有来自总体 $U(a, 1)$ 的简单随机样本 $X_1, X_2 \cdots X_n$, 则 a 的矩估计为 _____.

Solution: $2\bar{X} - 1$

$EX = \frac{1+a}{2}$, 根据替换原理得到矩估计 $\hat{a} = 2\bar{X} - 1$.

8. 已知 $X_1, X_2 \cdots X_4$ 为来自总体 $N(0, 4)$ 的样本, $Y = (X_1 + X_2)^2 + (X_3 - X_4)^2$, 当 $c =$ _____ 时, cY 服从 $\chi^2(2)$.

Solution: $\frac{1}{8}$

由于 $\frac{(X_1+X_2)}{\sqrt{8}}, \frac{(X_3-X_4)}{\sqrt{8}} \text{ i.i.d } \sim N(0, 1)$, 则 $\frac{1}{8}Y \sim \chi^2(2)$.

三、解答题 (90 分)

1.(10 分) 设 (X, Y) 服从以 $(-1, 0), (1, 0)$ 和 $(0, 1)$ 为顶点的三角形内的均匀分布, 求 $Z = X + Y$ 的概率密度.

Solution: 记 $D = \{y - 1 < x < 1 - y, 0 < y < 1\}$, 则 $S_D = 1$, 因此 (X, Y) 的联合密度是

$$f_{X,Y} = \begin{cases} 1, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

作变换 $\begin{cases} Z = X + Y \\ U = X \end{cases}$, 反解即 $\begin{cases} X = U \\ Y = Z - U \end{cases}$, 雅各比行列式为 1. 于是对 $\forall z, u$ 满足 $\begin{cases} 0 < z - u < 1 \\ z - u - 1 < u < 1 - z + u \end{cases}$,

即 $\begin{cases} \frac{z-1}{2} < u < z \\ -1 < z < 1 \end{cases}$, (Z, U) 有联合密度函数 $f_{Z,U} = f_{X,Y}(u, z-u) = 1$. 所以 Z 的边缘密度函数是

$$f_Z(z) = \int_{\frac{z-1}{2}}^z du = \frac{z+1}{2}, -1 < z < 1$$

2.(10 分) 有 n 张卡片, 上面分别标着 $1, 2 \cdots n$, 现随机有放回地抽取 k 张, 用 X 表示这 k 张卡片的和, 求 EX 和 DX .

Solution: 用随机变量 X_i 表示第 i 张卡片上标写的数字, 则显然诸 X_i 是独立同分布的, 其分布列为 $P(X_i = j) = \frac{1}{n} (j = 1, 2, \dots, n)$. 且有 $X = X_1 + \dots + X_k$. 下面先计算 EX_i 与 DX_i

$$EX_i = \frac{n+1}{2}$$

$$EX_i^2 = \frac{1}{n} \sum_{j=1}^n j^2 = \frac{(n+1)(2n+1)}{6}$$

$$DX_i = EX_i^2 - (EX_i)^2 = \frac{(n+1)(2n+1)}{6} - \left(\frac{n+1}{2}\right)^2 = \frac{n^2-1}{12}$$

因此 $EX = kEX_i = \frac{n+1}{2}k$, $DX = kDX_i = \frac{n^2-1}{12}k$

3.(10 分) 已知 $f(x) = \begin{cases} (a+1)x^a, & 0 < x < 1; \\ 0, & \text{其他.} \end{cases}$, $X_1, X_2, \dots, X_n$ 为来自该总体的简单随机样本, 求 a 的矩估计和极大似然估计.

Solution: $EX = \int_0^1 (a+1)x^{a+1}dx = \frac{a+1}{a+2}$, 由替换原理得矩估计 $\hat{a}_M = \frac{2\bar{X}-1}{1-\bar{X}}$. 似然函数为 $L(a) = (a+1)^n \prod_{i=1}^n x_i^a$, 取对数得到

$$\ln L(a) = n \ln(a+1) + a \sum_{i=1}^n \ln x_i$$

关于参数求导并置 0, 得似然方程

$$\frac{\partial \ln L}{\partial a} = \frac{n}{a+1} + \sum_{i=1}^n \ln x_i = 0$$

解得参数的极大似然估计是 $\hat{a}_{MLE} = -\frac{n}{\sum_{i=1}^n \ln x_i} - 1$.

4.(10 分) 有一项考试, 每个人优秀得 3 分, 合格得 2 分, 不合格得 1 分. 且根据以往经验, 优秀, 合格, 不合格的比例分别为 20%, 70%, 10%. 现有 100 人参加考试, 用中心极限定理估计总分在 180 至 200 之间的概率.

Solution: 计算得到 $EX = 2$, $EX^2 = 4.7$, 则 $DX = 0.29$, 于是根据中心极限定理

$$S = \sum_{i=1}^{100} X_i \sim AN(210, 29)$$

所以

$$P(180 \leq S \leq 200) = P\left\{\frac{-30}{\sqrt{29}} \leq \frac{S-210}{\sqrt{29}} \leq \frac{-10}{\sqrt{29}}\right\} \approx \Phi(-1.86) - \Phi(-5.57)$$

5.(10 分) 已知总体 $X \sim N(\mu, \sigma^2)$, 且 $X_1, X_2, \dots, X_n$ 为简单随机样本, 求 k 使得 $k \sum_{i=1}^n |X_i - \bar{X}|$ 为 σ 的无偏估计.

Solution: 由于 $Z_i = X_i - \bar{X}$ 是样本的一个线性组合, 因此根据正态分布的性质 Z_i 依然是正态分布, 且有 $EZ_i = 0$ 以及 $\text{Var}(Z_i) = \frac{n-1}{n}\sigma^2$, 所以 $Z_i \sim N(0, \frac{n-1}{n}\sigma^2)$. 记 $\sigma_0^2 = \frac{n-1}{n}\sigma^2$, 则

$$E|Z_i| = 2 \int_0^{+\infty} \frac{x}{\sqrt{2\pi}\sigma_0} \exp\left\{-\frac{x^2}{2\sigma_0^2}\right\} dx = \sqrt{\frac{2}{\pi}} \sqrt{\frac{n-1}{n}} \sigma$$

则 $E \sum_{i=1}^n Z_i = \sqrt{\frac{2}{\pi}} \sqrt{n(n-1)} \sigma$, 因此取修偏系数 $k = \sqrt{\frac{\pi}{2n(n-1)}}$.

6.(10 分) 已知 $f(x, y) = \begin{cases} axy, & 0 < x, y < 1; \\ 0, & \text{其他.} \end{cases}$ 求 a , 并证明 X, Y 相互独立.

Solution: 由于 $a \int_0^1 x dx \int_0^1 y dy = \frac{1}{4}a$, 根据正则性知 $a = 4$. 而 (X, Y) 的联合密度变量可分离, 即 $f_{X,Y}(x, y) = f_X(x)f_Y(y)$, 因此 X, Y 相互独立.

7.(15 分) 设总体 $X \sim N(\mu_1, \sigma^2)$, $Y \sim N(\mu_2, \sigma^2)$, 分别有来自于它们的 n, m 个随机样本, 考虑假设检验问题:

$$H_0: c\mu_1 + d\mu_2 = \delta \quad \text{vs} \quad H_1: c\mu_1 + d\mu_2 \neq \delta.$$

其中 $c \neq 0, d \neq 0, \delta$ 已知, 但 μ_1, μ_2, σ^2 未知, 求检验统计量以及拒绝域.

Solution: 当 H_0 为真时, $c\bar{X} + d\bar{Y} - \delta \sim N\left(0, \left(\frac{c^2}{n} + \frac{d^2}{m}\right)\sigma^2\right)$. 同时根据 Fisher 引理以及卡方分布的可加性知, $\frac{(n-1)S_X^2 + (m-1)S_Y^2}{\sigma^2} \sim \chi^2(n+m-2)$, 且它们之间是独立的. 于是可构造检验统计量:

$$\begin{aligned} T &= \frac{(c\bar{X} + d\bar{Y} - \delta) / \sqrt{\left(\frac{c^2}{n} + \frac{d^2}{m}\right)\sigma^2}}{\sqrt{[(n-1)S_X^2 + (m-1)S_Y^2] / [(n+m-2)\sigma^2]}} \\ &= \frac{c\bar{X} + d\bar{Y} - \delta}{S_w \sqrt{\frac{c^2}{n} + \frac{d^2}{m}}} \sim t(n+m-2) \end{aligned}$$

这里 $S_w^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$. 检验的拒绝域是

$$W = \left\{ |T| \geq t_{1-\frac{\alpha}{2}}(n+m-2) \right\}$$

8.(15 分) 设 $X \sim U(0, \theta)$, 且 $X_1, X_2 \cdots X_n$ 为简单随机样本.

(1) 证明 $\tilde{\theta}_1 = \max(X_1, X_2 \cdots X_n) + \min(X_1, X_2 \cdots X_n)$ 为 θ 的无偏估计;

(2) 求 c_n , 使 $\tilde{\theta}_2 = c_n \min(X_1, X_2 \cdots X_n)$ 也是 θ 的无偏估计, 并比较 $\tilde{\theta}_1$ 和 $\tilde{\theta}_2$ 的方差.

Solution:

(1) 作总体变换, 有 $Y_i = \frac{X_i}{\theta} \sim U(0, 1)$, 再根据标准均匀分布的最大最小值分布的结论知 $Y_{(1)} = \frac{X_{(1)}}{\theta} \sim \text{Beta}(1, n)$, $Y_{(n)} = \frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$ 所以 $E(X_{(1)} + X_{(n)}) = \theta E(Y_{(1)} + Y_{(n)}) = \theta \left(\frac{1}{n+1} + \frac{n}{n+1} \right) = \theta$, 即 $\tilde{\theta}_1$ 为 θ 的无偏估计.

(2) 仿照 (1) 中的变换容易算得 $EX_{(1)} = \frac{1}{n+1}\theta$, 因此可取修偏系数 $c_n = n+1$, 则 $\tilde{\theta}_2 = (n+1)X_{(1)}$ 也是 θ 的无偏估计. 而标准均匀分布的极差 $Y_{(n)} - Y_{(1)} = \theta(X_{(n)} - X_{(1)}) \sim \text{Beta}(n-1, 2)$, 利用该结论

$$\begin{aligned} \text{Var}(\tilde{\theta}_1) &= \text{Var}(X_{(1)} + X_{(n)}) \\ &= \text{Var}(X_{(1)}) + \text{Var}(X_{(n)}) - (-2\text{Cov}(X_{(1)}, X_{(n)})) \\ &= 2\text{Var}(X_{(1)}) + 2\text{Var}(X_{(n)}) - \left(\text{Var}(X_{(1)}) + \text{Var}(X_{(n)}) - 2\text{Cov}(X_{(1)}, X_{(n)}) \right) \\ &= 2\text{Var}(X_{(1)}) + 2\text{Var}(X_{(n)}) - \text{Var}(X_{(n)} - X_{(1)}) \\ &= \frac{2n + 2n - 2(n-1)}{(n+1)^2(n+2)}\theta^2 = \frac{2}{(n+1)(n+2)}\theta^2 \\ \text{Var}(\tilde{\theta}_2) &= (n+1)^2 \frac{n}{(n+1)^2(n+2)}\theta^2 = \frac{n}{n+2}\theta^2 \end{aligned}$$

所以当 $n > 1$ 时, $\tilde{\theta}_1$ 更优.

南开大学-432 统计学-2019 年

一、选择题 (每题 4 分, 共 28 分) 1. 4 对夫妇任意地排成一列, 每一位丈夫都排在他妻子后面的概率为 ().

- A. $1/2$;
- B. $1/8$;
- C. $1/16$;
- D. $1/70$.

Solution: C 用事件 A_i 表示第 i 个丈夫排在其妻子后面, 则所求概率即 $P(A_1 A_2 A_3 A_4)$, 利用乘法公式知 $P(A_1 A_2 A_3 A_4) = P(A_2 A_3 A_4 | A_1) P(A_1)$. 其中 $P(A_1) = \frac{1}{2}$, 而 $P(A_2 A_3 A_4 | A_1)$ 等同于求共有 3 对夫妇的情况下, 每一名丈夫都在其妻子后面的概率, 可再次使用乘法公式. 如此多次利用乘法公式可得

$$\begin{aligned} P(A_1 A_2 A_3 A_4) &= P(A_4 | A_1 A_2 A_3) P(A_3 | A_1 A_2) P(A_2 | A_1) P(A_1) \\ &= \left(\frac{1}{2}\right)^4 = \frac{1}{16} \end{aligned}$$

2. 设 $P(AB) = 0$, 则下列说法正确的是 ().

- A. A 和 B 不相容;
- B. A 和 B 相容;
- C. AB 是不可能事件;
- D. AB 不一定是不可能事件.

Solution: D 考虑 $AB = \phi$, 排除选项 A; 考虑 AB 是空集之外的零概率集, 则排除 BC 选项.

3. 学生在做一道有 4 个可选答案的单项选择题, 如果他不知道正确答案时就随机猜测. 假设该学生知道正确答案的概率为 0.2. 现从卷面上看该题答对了, 则在此情形下该学生确实知道正确答案的概率是 ().

- A. 0.4;
- B. 0.5;
- C. 0.6;
- D. 0.7.

Solution: B 用事件 A 表示学生确实知道正确答案, 事件 B 表示学生答对该题, 则由贝叶斯公式有

$$P(A | B) = \frac{P(AB)}{P(B)} = \frac{0.2}{0.2 + 0.8 \times 0.25} = 0.5$$

4. 设 $X_1, X_2 \cdots X_n$ 为来自正态总体 $N(\mu, \sigma^2)$ 的简单随机样本, 其中 μ, σ^2 均为未知, 则关于假设 $H_0: \mu \leq 0 \Leftrightarrow H_1: \mu > 0$ 的显著性检验为 ().

- A. 单侧 t 检验;
- B. 单侧 μ 检验;
- C. 双侧 t 检验;
- D. 双侧 μ 检验.

Solution: A 方差未知, 备择检验是单侧, 因此采用单侧 t 检验.

5. 设连续随机变量 X 的密度函数是一个偶函数, $F(x)$ 为 X 的分布函数, 则对任意实数 $a > 0$, 下列结论不成立的是 ().

- A. $F(-a) = 1 - F(a)$;
- B. $P(|X| < a) = 2F(a) - 1$;
- C. $P(|X| > a) = 2 - 2F(a)$;
- D. $E(a - X) = E(X - a)$.

Solution: D

显然不成立.

6. 设 $X_1, X_2, \dots, X_n$ 为来自正态总体 $N(0, \sigma^2)$ 的简单随机样本, 为使 $c \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 为 σ^2 的无偏估计, 则 $c = ()$.

- A. $\frac{1}{n-1}$;
- B. $\frac{1}{n}$;
- C. $\frac{1}{2(n-1)}$;
- D. $\frac{1}{2n}$.

Solution: C 由于 $X_{i+1} - X_i \sim N(0, 2\sigma^2)$, 所以

$$ET = cE \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2 = c2(n-1)\sigma^2$$

于是 $c = \frac{1}{2(n-1)}$.

7. 如果 $X_n \xrightarrow{l} c$ 以及 $Y_n \xrightarrow{l} Y$, 其中 c 是一个常数, Y 是一个随机变量, 那么以下说法不一定正确的是 ().

- A. $X_n \xrightarrow{p} c$;
- B. $Y_n \xrightarrow{p} Y$;
- C. $X_n + Y_n \xrightarrow{l} c + Y$;
- D. $X_n Y_n \xrightarrow{l} cY$.

Solution: B 按分布收敛弱于依概率收敛, 当按分布收敛到退化分布时 (此处常数可视为退化分布), 按分布收敛与依概率收敛等价, 因此 B 错误. 选项 C, D 为 Slutsky 定理的推论.

二、填空题 (每题 4 分, 共 32 分)

1. 某地区居民的肝癌发病率为 0.0004, 现用甲胎蛋白法进行普查. 研究表明, 化验结果是有错误的. 已知患有肝癌的人其化验结果 99% 呈阳性 (有病), 而没患肝癌的人其化验结果 99.9% 呈阴性 (无病). 现某人的检查结果呈阳性, 问他真的患有肝癌的概率为多少 _____.

Solution: 0.284 用事件 A 表示该人未患肝癌, 用事件 B 表示该人的检验呈阳性. 首先我们知道先验概率以及确诊率 $P(A) = 0.9996$, 根据贝叶斯公式, 有

$$P(\bar{A} | B) = \frac{P(\bar{A}B)}{P(B)} = \frac{0.99 \times 0.0004}{0.99 \times 0.0004 + 0.9996 \times 0.001} = 0.283749$$

2. 二维随机变量 (X, Y) 服从区域 $D = \{(x, y) | 0 < x < 1, 0 < x < y < 1\}$ 上的均匀分布, 则 X 与 Y 的相关系数为 _____.

Solution: $\frac{1}{2}$ (X, Y) 的联合密度函数是 $f(x, y) = 2I_{\{0 < x < y < 1\}}$, 于是

$$\begin{aligned} EX &= \int_0^1 dy \int_0^y 2x dx = \int_0^1 y^2 dy = \frac{1}{3}, EX^2 = \int_0^1 dy \int_0^y 2x^2 dx = \frac{2}{3} \int_0^1 y^3 dy = \frac{1}{6} \\ EY &= \int_0^1 dy \int_0^y 2y dx = 2 \int_0^1 y^2 dy = \frac{2}{3}, EY^2 = \int_0^1 dy \int_0^y 2y^2 dx = 2 \int_0^1 y^3 dy = \frac{1}{2} \end{aligned}$$

$$\text{则 } DX = \frac{1}{6} - \left(\frac{1}{3}\right)^2 = \frac{1}{18}, DY = \frac{1}{2} - \left(\frac{2}{3}\right)^2 = \frac{1}{18}.$$

$$EXY = \int_0^1 dy \int_0^y 2xy dx = \int_0^1 y^3 dy = \frac{1}{4}, \text{ 则 } \text{Cov}(X, Y) = \frac{1}{4} - \frac{1}{3} \cdot \frac{2}{3} = \frac{1}{36}.$$

所以 $\text{Corr}(X, Y) = \frac{1/36}{\sqrt{1/18} \cdot \sqrt{1/18}} = \frac{1}{2}$.

3. 设二维连续随机变量 (X, Y) 的联合密度函数为

$$f(x, y) = \begin{cases} \frac{21}{4}x^2y, & x^2 < y < 1; \\ 0, & \text{其他.} \end{cases}$$

则 $P(Y > 0.75 | X = 0.5) =$ _____.

Solution: $\frac{7}{15}$ X 的边际密度函数是 $f_X(x) = \int_{x^2}^1 f(x, y) dy = \frac{21}{8} x^2 (1 - x^4)$, $-1 < x < 1$. 则 Y 关于 X 的条件密度函数是 $f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)} = \frac{2y}{1-x^4}$, $x^2 < y < 1$. 因此 $P(Y > 0.75 | X = 0.5) = \int_{0.75}^1 \frac{2y}{1-(\frac{1}{2})^4} dy = \frac{7/16}{15/16} = \frac{7}{15}$.

4. 一份考卷由 99 道题目组成, 并按由易到难的顺序排列. 某学生答对第一题的概率为 0.99, 答对第二题的概率为 0.98, 一般地, 他答对第 i 道题的概率为 $1 - \frac{i}{100}$, ($i = 1, 2, \dots$). 假如该学生回答各道题目是相互独立的, 并且要回答对 60 题及以上才算通过考试, 则该同学通过考试的概率为 _____.

Solution: 0.005 设 $X_i = \begin{cases} 1, & \text{若学生答对第 } i \text{ 题,} \\ 0, & \text{若学生答错第 } i \text{ 题.} \end{cases}$ 于是 X_i 相互独立, 且服从不同的二点分布:

$$P(X_i = 1) = p_i = 1 - \frac{i}{100}, P(X_i = 0) = 1 - p_i = \frac{i}{100}, i = 1, 2, \dots, 99$$

而我们要求的是 $P\left(\sum_{i=1}^{99} X_i \geq 60\right)$, 考虑使用中心极限定理. 为使用中心极限定理, 我们可以设想从 X_{100} 开始的随机变量都与 X_{99} 同分布, 且相互独立. 由于

$$\begin{aligned} B_n &= \sqrt{\sum_{i=1}^n \text{Var}(X_i)} = \sqrt{\sum_{i=1}^n p_i(1-p_i)} \rightarrow +\infty \\ E(|X_i - p_i|^3) &= (1-p_i)^3 p_i + p_i^3 (1-p_i) \leq p_i(1-p_i) \\ \frac{1}{B_n^3} \sum_{i=1}^n E(|X_i - p_i|^3) &\leq \frac{1}{(\sum_{i=1}^n p_i(1-p_i))^{1/2}} \rightarrow 0 \end{aligned}$$

于是随机序列 $\{X_n\}$ 满足李雅普诺夫条件, 所以可以使用中心极限定理. 又

$$\begin{aligned} E\left(\sum_{i=1}^{99} X_i\right) &= \sum_{i=1}^{99} p_i = \sum_{i=1}^{99} \left(1 - \frac{i}{100}\right) = 49.5 \\ B_{99}^2 &= \sum_{i=1}^{99} \text{Var}(X_i) = \sum_{i=1}^{99} \left(1 - \frac{i}{100}\right) \left(\frac{i}{100}\right) = 16.665 \end{aligned}$$

所以该学生通过考试的可能性为

$$\begin{aligned} P\left(\sum_{i=1}^{99} X_i \geq 60\right) &= P\left(\frac{\sum_{i=1}^{99} X_i - 49.5}{\sqrt{16.665}} \geq \frac{60 - 49.5}{\sqrt{16.665}}\right) \\ &\approx 1 - \Phi(2.5735) = 0.005 \end{aligned}$$

注: 若记得这是茆书例题, 再结合该题是填空题的事实, 则无需验证李雅普诺夫条件直接使用中心极限定理即可.

5. 设总体服从韦布尔分布 $Weibull(m, \eta)$, 其密度函数为

$$f(x; m, \eta) = \frac{mx^{m-1}}{\eta^m} \exp\left\{-\left(\frac{x}{\eta}\right)^m\right\}, x > 0, m > 0, \eta > 0$$

则 $x_{(1)}$ 服从 _____.

Solution: $X_{(1)} \sim Wei\left(m, \eta n^{-\frac{1}{m}}\right)$ 总体的分布函数是 $F(x) = 1 - \exp\left\{-\left(\frac{x}{\eta}\right)^m\right\}$, 由最小值分布公式知

$$f_{X_{(1)}}(x) = n(1 - F(x))^{n-1} f(x) = \frac{mx^{m-1}}{\left(\eta n^{-\frac{1}{m}}\right)^m} \exp\left\{-\left(\frac{x}{\eta n^{-\frac{1}{m}}}\right)^m\right\}, x > 0$$

对比发现, 它就是 $Wei\left(m, \eta n^{-\frac{1}{m}}\right)$ 的密度函数.

6. $\lim_{n \rightarrow \infty} \left(1 + n + \frac{n^2}{2!} + \cdots + \frac{n^n}{n!}\right) e^{-n} = \underline{\hspace{2cm}}.$

Solution: $\frac{1}{2}$ 取独立同分布皆服从 $\mathcal{P}(1)$ 的随机变量序列 $\{X_i\}$, 则根据中心极限定理

$$P\left(\sum_{i=1}^n X_i \leq n\right) = P\left(\frac{\sum_{i=1}^n X_i - n}{\sqrt{n}} \leq 0\right) \rightarrow \Phi(0) = \frac{1}{2}$$

另一方面, 由泊松分布的可加性, $\sum_{i=1}^n X_i \sim \mathcal{P}(n)$, 所以

$$P\left(\sum_{i=1}^n X_i \leq n\right) = \sum_{j=0}^n \frac{n^j}{j!} e^{-n} = \left(1 + n + \frac{n^2}{2!} + \cdots + \frac{n^n}{n!}\right) e^{-n}$$

综上所述, 该极限收敛到 $\frac{1}{2}$.

7. 设总体 $X \sim U(0, \theta)$, 现从该总体中抽取容量为 10 的样本, 样本值为:

0.5 1.3 0.6 1.7 2.2 1.2 0.8 1.5 2.0 1.6

则参数 θ 的矩估计是 $\underline{\hspace{2cm}}.$

Solution: 2.68 $EX = \frac{\theta}{2}$, 所以 θ 的矩估计是 $2\bar{X} = 2 \cdot 1.34 = 2.68.$

8. 设一组来自正态总体 $N(\mu, 4)$ 的简单随机样本, 样本值为

12 11 9 9.5 8 8.5 10.5 11.5 9.8 10.2

则关于 μ 的置信水平为 90% 的置信区间为 $\underline{\hspace{2cm}}.$

Solution: $[8.96, 11.04]$ μ 的 90% 置信区间是

$$\bar{X} \pm \frac{\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}} = \bar{X} \pm \frac{2}{\sqrt{10}} \cdot 1.645 = [8.96, 11.04]$$

三、解答题 (90 分)

1.(10 分) 设随机变量 U_1 与 U_2 相互独立, 且都服从 $(0, 1)$ 上的均匀分布. $Z_1 = -2\ln U_1, Z_2 = 2\pi U_2$. 试证明:

(1) $Z_1 \sim \text{Exp}(\frac{1}{2}), Z_2 \sim U(0, 2\pi);$

(2) $X = \sqrt{Z_1} \cos Z_2$ 和 $Y = \sqrt{Z_1} \sin Z_2$ 是相互独立的标准正态分布随机变量.

Solution:

(1) $\begin{cases} Z_1 = -2\ln U_1 \\ Z_2 = 2\pi U_2 \end{cases}$, 反解得到 $\begin{cases} U_1 = e^{-\frac{1}{2}Z_1} \\ U_2 = \frac{Z_2}{2\pi} \end{cases}$. 所以 Z_1 的密度函数是

$$f_{Z_1}(z_1) = f_{U_1}\left(e^{-\frac{1}{2}z_1}\right) \left|\frac{de^{-\frac{1}{2}z_1}}{dz_1}\right| = \frac{1}{2}e^{-\frac{1}{2}z_1} I_{\{z_1 > 0\}}$$

所以 Z_1 服从参数为 $\frac{1}{2}$ 的指数分布, 即自由度为 2 的卡方分布. Z_2 的密度函数是

$$f_{Z_2}(z_2) = f_{U_2}\left(\frac{z_2}{2\pi}\right) \left|\frac{1}{2\pi}\right| = \frac{1}{2\pi} I_{\{0 < z_2 < 2\pi\}}$$

所以 $Z_2 \sim U(0, 2\pi).$

(2) $\begin{cases} Z_1 = X^2 + Y^2 \\ Z_2 = \arctan\left(\frac{Y}{X}\right), \end{cases}$ 但需要注意此时的变换并非是一一对应的关系, 一对 (Z_1, Z_2) 对应着 (X, Y) 与 $(-X, -Y)$, 两种情况的雅各比行列式均为

$$J = \begin{vmatrix} 2x & 2y \\ -\frac{y}{x^2} & \frac{1}{1+(\frac{y}{x})^2} \end{vmatrix} = \frac{2 + 2(\frac{y}{x})^2}{1 + (\frac{y}{x})^2} = 2$$

所以 (X, Y) 的联合密度函数是

$$\begin{aligned} f_{X,Y}(x, y) &= f_{Z_1, Z_2}\left(x^2 + y^2, \arctan\left(\frac{y}{x}\right)\right) 2I_{\{x>0\}} + f_{Z_1, Z_2}\left(x^2 + y^2, \arctan\left(\frac{y}{x}\right)\right) 2I_{\{x<0\}} \\ &= \frac{1}{2} e^{-\frac{x^2+y^2}{2}} \frac{1}{2\pi} \cdot 2I_{\{x>0\}} + \frac{1}{2} e^{-\frac{x^2+y^2}{2}} \frac{1}{2\pi} \cdot 2I_{\{x<0\}} \\ &= \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}}, -\infty < x, y < +\infty \end{aligned}$$

最后一步补充了在 $x = 0$ 处的定义. 可以看出 $(X, Y) \sim N(0, 0; 1, 1; 0)$.

2.(15 分) 设 $x_1, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 其样本均值和样本方差分别为

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \text{ 和 } s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

试证明:

- (1) $\bar{x}$ 与 s^2 相互独立;
- (2) $\bar{x} \sim N(\mu, \sigma^2/n)$;
- (3) $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$.

Solution: 构造正交矩阵

$$A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ \frac{1}{\sqrt{2 \cdot 1}} & -\frac{1}{\sqrt{2 \cdot 1}} & 0 & \cdots & 0 \\ \frac{1}{\sqrt{3 \cdot 2}} & \frac{1}{\sqrt{3 \cdot 2}} & -\frac{2}{\sqrt{3 \cdot 2}} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \cdots & -\frac{n-1}{\sqrt{n(n-1)}} \end{pmatrix}$$

记随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$, 则 $\mathbf{X}$ 服从 n 维正态分布, 令 $\mathbf{Y} = A\mathbf{X}$, 则由正态分布性质知, $\mathbf{Y}$ 也服从 n 维正态分布, 其均值向量为

$$E\mathbf{Y} = AE\mathbf{X} = A \begin{pmatrix} \mu \\ \mu \\ \vdots \\ \mu \end{pmatrix} = \begin{pmatrix} \sqrt{n}\mu \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

协方差矩阵为 $A^T(\sigma^2 I_n)A = \sigma^2 I_n$. 同时注意到

$$Y_1 = \frac{1}{\sqrt{n}}(X_1 + X_2 + \cdots + X_n) = \sqrt{n}\bar{X}$$

$$\sum_{i=1}^n X_i^2 = \sum_{i=1}^n Y_i^2$$

其中第二点是由正交矩阵的性质得到的. 利用上述第一点可以得到 $\bar{X} \sim \frac{Y_1}{\sqrt{n}} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$. 同时利用上述两点可以得到 $(n-1)S^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 = \sum_{i=1}^n Y_i^2 - Y_1^2 = Y_2^2 + Y_3^2 + Y_4^2 + \cdots + Y_n^2$ 且对于 $i = 2, \cdots, n$, 有 Y_i i.i.d $\sim N(0, \sigma^2)$, 所以 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$. 并且注意到 S^2 仅仅依赖于 $Y_2, Y_3, \cdots, Y_n$, 而 $\bar{X}$ 仅仅依赖于 Y_1 . 由正态分布独立与不相关等价的性质知道, Y_1 与 $Y_2, Y_3, \cdots, Y_n$ 是独立的, 所以 $\bar{X}$ 与 S^2 也是相互独立的.

3.(10 分) 设总体 $X \sim U(\theta - \frac{1}{2}, \theta + \frac{1}{2})$, $X_1, X_2, \cdots, X_n$ 为来自该总体的简单随机样本, 证明 $\frac{1}{2}(x_{(1)} + x_{(n)})$ 是 θ 的无偏估计.

Solution: 作总体变换, 令 $Y_i = X_i - \theta + \frac{1}{2}$ i.i.d $\sim U(0, 1)$, 则有

$$Y_{(1)} = X_{(1)} - \left(\theta - \frac{1}{2}\right) \sim Be(1, n), Y_{(n)} = X_{(n)} - \left(\theta - \frac{1}{2}\right) \sim Be(n, 1)$$

所以

$$E\left(\frac{X_{(1)} + X_{(n)}}{2}\right) = \theta - \frac{1}{2} + \frac{E(Y_{(1)} + Y_{(n)})}{2} = \theta - \frac{1}{2} + \frac{1}{2}\left(\frac{1}{n+1} + \frac{n}{n+1}\right) = \theta$$

即 $\frac{X_{(1)} + X_{(n)}}{2}$ 是 θ 的无偏估计.

4.(10 分) 某电工器材厂生产一种保险丝, 测量其熔化时间, 依通常情况方差为 400, 今从某天产品中抽取容量为 25 的样本, 测量其熔化时间并计算 $\bar{X} = 62.24, s^2 = 404.77$, 问这天保险丝熔化时间的方差与通常有无显著性差异 (取 $\alpha = 0.05$, 假定熔化时间服从正态分布).

Solution: 考虑假设检验问题 $H_0: \sigma^2 = 400$ vs $H_1: \sigma^2 \neq 400$, 检验统计量是

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} = \frac{24 \cdot 404.77}{400} = 24.2862$$

检验的拒绝域是

$$\begin{aligned} W &= \left\{ \chi^2 \leq \chi_{\frac{\alpha}{2}}^2(n-1) \right\} \cup \left\{ \chi^2 \geq \chi_{1-\frac{\alpha}{2}}^2(n-1) \right\} \\ &= \left\{ \chi^2 \leq \chi_{0.025}^2(24) \right\} \cup \left\{ \chi^2 \geq \chi_{0.975}^2(24) \right\} \\ &= \left\{ \chi^2 \leq 12.4012 \right\} \cup \left\{ \chi^2 \geq 39.3641 \right\} \end{aligned}$$

由此 $\chi^2 \notin W$, 在显著性水平 $\alpha = 0.05$ 下不能拒绝原假设, 可以认为当天保险丝熔化时间的方差与通常无差异.

5.(10 分) 设总体 X 的分布函数 $F(x)$ 是连续的, $x_{(1)}, \cdots, x_{(n)}$ 为取自此总体的次序统计量, 设 $\eta_i = F(x_{(i)})$, 试证:

(1) $\eta_1 \leq \eta_2 \leq \cdots \leq \eta_n$, 且它们是来自于总体 $U(0, 1)$ 的次序统计量;

(2) $E(\eta_i) = \frac{i}{n+1}, \text{Var}(\eta_i) = \frac{i(n+1-i)}{(n+1)^2(n+2)}, 1 \leq i \leq n$.

Solution:

(1) 作总体变换 $Y = F(X) \sim U(0, 1)$, 则 $\eta_1, \eta_2, \cdots, \eta_n$ 是总体 Y 的次序统计量. 即 $U(0, 1)$ 的次序统计量.

(2) 根据前一问的结论知, $\eta_1, \eta_2, \cdots, \eta_n$ 是 $U(0, 1)$ 的次序统计量, 则

$$\eta_i \sim \text{Beta}(i, n-i+1)$$

所以 $E\eta_i = \frac{i}{n+1}, D\eta_i = \frac{i(n-i+1)}{(n+1)^2(n+2)}$.

6.(15 分) 设有随机变量 X, Y , 且 X, Y 的方差均存在. 试证明:

(1) 相关系数 $\text{Corr}(X, Y)$ 存在;

(2) $-1 \leq \text{Corr}(X, Y) \leq 1$;

(3) $\text{Corr}(X, Y) = \pm 1$ 的充要条件为 X 与 Y 之间几乎处处有线性关系, 即存在 $a(a \neq 0)$ 与 b 使得 $P(Y = aX + b) = 1$, 其中当 $\text{Corr}(X, Y) = 1$ 时有 $a > 0$, 当 $\text{Corr}(X, Y) = -1$ 时有 $a < 0$.

Solution: 首先证明协方差不等式成立, 记 $g(t) = E[t(X - EX) + (Y - EY)]^2$, 它始终是非负的, 则

$$g(t) = \text{Var}(X)t^2 + 2\text{Cov}(X, Y)t + \text{Var}(Y) \geq 0$$

是一定成立的, 即判别式非正

$$\Delta^2 = 4[\text{Cov}(X, Y)]^2 - 4\text{Var}(X)\text{Var}(Y) \leq 0$$

移项得到 $[\text{Cov}(X, Y)]^2 \leq \text{Var}(X)\text{Var}(Y)$.

(1) 根据协方差不等式, 即 $[\text{Cov}(X, Y)]^2 \leq \text{Var}(X)\text{Var}(Y)$, 知随机变量 X 与 Y 的协方差一定存在, 同时它们的方差也存在, 所以它们的相关系数也一定存在.

(2) 对协方差不等式进行变形, 有

$$[\text{Cov}(X, Y)]^2 \leq \text{Var}(X)\text{Var}(Y)$$

$$\frac{[\text{Cov}(X, Y)]^2}{\text{Var}(X)\text{Var}(Y)} \leq 1$$

$$[\text{Corr}(X, Y)]^2 \leq 1 \Rightarrow -1 \leq \text{Corr}(X, Y) \leq 1$$

(3) [充分性] 由于 $P(Y = aX + b) = 1 (a \neq 0)$, 则

$$\text{Var}(Y) = a^2 \text{Var}(X), \text{Cov}(X, Y) = a \text{Cov}(X, X) = a \text{Var}(X)$$

$$\text{就有 } \text{Corr}(X, Y) = \frac{a \text{Var}(X)}{|a| \text{Var}(X)} = \begin{cases} 1, & a > 0 \\ -1, & a < 0 \end{cases}.$$

[必要性] 记 $\text{Var}(X) = \sigma_X^2, \text{Var}(Y) = \sigma_Y^2$, 则

$$\text{Var}\left(\frac{X}{\sigma_X} \pm \frac{Y}{\sigma_Y}\right) = 2[1 \pm \text{Corr}(X, Y)]$$

所以当 $\text{Corr}(X, Y) = 1$ 时, $\text{Var}\left(\frac{X}{\sigma_X} - \frac{Y}{\sigma_Y}\right) = 0$, 所以

$$P\left(\frac{X}{\sigma_X} - \frac{Y}{\sigma_Y} = c\right) = 1 \Rightarrow P\left(Y = \frac{\sigma_Y X}{\sigma_X} - \sigma_Y c\right) = 1$$

当 $\text{Corr}(X, Y) = -1$ 时, $\text{Var}\left(\frac{X}{\sigma_X} + \frac{Y}{\sigma_Y}\right) = 0$, 所以

$$P\left(\frac{X}{\sigma_X} + \frac{Y}{\sigma_Y} = c\right) = 1 \Rightarrow P\left(Y = -\frac{\sigma_Y X}{\sigma_X} + \sigma_Y c\right) = 1$$

7.(10分) 设 $x_1, \dots, x_n$ i. i. d. $\sim N(\mu, 1)$, 求 μ^2 的 UMVUE. 证明此 UMVUE 达不到 $C-R$ 下界, 即它不是有效估计.

Solution: 样本的联合分布是

$$\begin{aligned} f(\mathbf{X}, \mu) &= (2\pi)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\right\} \\ &= (2\pi)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2} \left[\sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2\right]\right\} \end{aligned}$$

由因子分解定理可知, $T = \sum_{i=1}^n X_i$ 是 μ 的充分统计量. 而由正态分布的可加性知 $T \sim N(n\mu, n)$, 又正态分布是完全族分布, 所以 $T = \sum_{i=1}^n X_i$ 是 μ 的充分完全统计量. 那么 $\bar{X} = \frac{1}{n}T \sim N(\mu, \frac{1}{n})$ 也是 μ 的充分完全统计量. 注意到 $E\left(\bar{X}^2 - \frac{1}{n}\right) = \left(\mu^2 + \frac{1}{n}\right) - \frac{1}{n} = \mu^2$, 所以 $\bar{X}^2 - \frac{1}{n}$ 是基于充分完全统计量而构造的 μ^2 的无偏估计, 根据 L-S 定理知它是 μ^2 的 UMVUE.

下面先求 μ 的 Fisher 信息量, $\ln f(x, \mu) = -\frac{1}{2} \ln(2\pi) - \frac{1}{2}(x - \mu)^2$, 则

$$I(\mu) = E \left(\frac{\partial \ln f(X, \mu)}{\partial \mu} \right)^2 = E(\mu - X)^2 = \text{Var}(X) = 1$$

所以 μ^2 的无偏估计的 C-R 下界是 $\frac{\left(\frac{d\mu^2}{d\mu}\right)^2}{nI(\mu)} = \frac{4\mu^2}{n}$. 再计算 $\bar{X}^2 - \frac{1}{n}$ 的方差, 即 $\bar{X}^2$ 的方差, 首先有 $E\bar{X}^2 = \mu^2 + \frac{1}{n}$, 下面计算 $E\bar{X}^4$, 由于 $\bar{X} \sim N\left(\mu, \frac{1}{n}\right)$, 尝试利用 Stein 引理

$$\begin{aligned} E\bar{X}^4 &= E\bar{X}^3(\bar{X} - \mu + \mu) \\ &= E\bar{X}^3(\bar{X} - \mu) + \mu E\bar{X}^3 \end{aligned}$$

其中根据 Stein 引理, $E\bar{X}^3(\bar{X} - \mu) = \text{Var}(\bar{X})E(3\bar{X}^2) = \frac{3}{n}(\mu^2 + \frac{1}{n})$, 而对于 $E\bar{X}^3$, 再次作拆分

$$\begin{aligned} E\bar{X}^3 &= E\bar{X}^2(\bar{X} - \mu + \mu) \\ &= E\bar{X}^2(\bar{X} - \mu) + \mu E\bar{X}^2 \end{aligned}$$

其中再根据 Stein 引理, $E\bar{X}^2(\bar{X} - \mu) = \text{Var}(X)E(2\bar{X}) = \frac{2}{n}\mu$, 所以

$$E\bar{X}^3 = \frac{2}{n}\mu + \mu\left(\mu^2 + \frac{1}{n}\right) = \mu^3 + \frac{3}{n}\mu$$

全部代回 $E\bar{X}^4$ 的式子, 有

$$\begin{aligned} E\bar{X}^4 &= \frac{3}{n}\left(\mu^2 + \frac{1}{n}\right) + \mu\left(\mu^3 + \frac{3}{n}\mu\right) \\ &= \mu^4 + \frac{6}{n}\mu^2 + \frac{3}{n^2} \end{aligned}$$

所以

$$\begin{aligned} \text{Var}(\bar{X}^2) &= \mu^4 + \frac{6}{n}\mu^2 + \frac{3}{n^2} - \left(\mu^2 + \frac{1}{n}\right)^2 \\ &= \frac{4\mu^2}{n} + \frac{2}{n^2} > \frac{4\mu^2}{n} \end{aligned}$$

所以 $\bar{X}^2 - \frac{1}{n}$ 不是 μ^2 的有效估计.

注: 不使用 Stein 引理, 直接计算积分也可, 计算量也较大.

8.(10 分) 设 $X_1, X_2, \dots, X_n$ 为来自两点分布 $b(1, p)$ 的简单随机样本, 其中 $p \in (0, 1)$, 记 n_1, n_2 为上述 n 个样本中取值分别为 1 和 0 的个数, 如记 $q = 1 - p$, $\chi^2 = \frac{(n_1 - np)^2}{np} + \frac{(n_2 - nq)^2}{nq}$, 证明 $\chi^2 \xrightarrow{L} \chi^2(1)$.

Solution: 由于 $n_2 = n - n_1$, 所以

$$\begin{aligned} \chi^2 &= \frac{(1-p)(n_1 - np)^2 + p(n_2 - nq)^2}{np(1-p)} \\ &= \frac{(1-p)(n_1 - np)^2 + p(np - n_1)^2}{np(1-p)} = \frac{(n_1 - np)^2}{np(1-p)} \end{aligned}$$

而 $n_1 = \sum_{i=1}^n X_i \sim B(n, p)$, 根据中心极限定理

$$\frac{n_1 - np}{\sqrt{np(1-p)}} \xrightarrow{L} N(0, 1)$$

于是 $\chi^2 = \frac{(n_1 - np)^2}{np(1-p)} \xrightarrow{L} \chi^2(1)$.

南开大学-432 统计学-2020 年

一、选择题 (每题 4 分, 共 28 分) 1. 随机变量 X 在 1-3 的正整数中等概率取值, 随机变量 Y 在 $1-X$ 的正整数中等概率取值, 则 $P(X=Y)=(\quad)$.

- A. 1;
- B. $1/5$
- C. $11/18$;
- D. $1/2$.

Solution: C

由全概率公式

$$\begin{aligned} P(X=Y) &= \sum_{i=1}^3 P(X=i)P(Y=i|X=i) \\ &= \sum_{i=1}^3 \frac{1}{3} \times \frac{1}{i} = \frac{11}{18} \end{aligned}$$

2. 已知 (X,Y) 服从以 $(0,1), (1,1), (1,0)$ 三点组成的三角形上的均匀分布, 则 $EY=(\quad)$.

- A. $1/2$;
- B. $2/3$;
- C. $1/3$;
- D. $1/6$.

Solution: B

设题目所提区域为 D , 则 $S_D = \frac{1}{2}$, 于是 $f(x,y) = 2, (x,y) \in D$. 则

$$\begin{aligned} EY &= \int_0^1 y dy \int_{1-y}^1 2 dx \\ &= 2 \int_0^1 y^2 dy = \frac{2}{3} \end{aligned}$$

3. 随机变量 X 以 0.5 概率取 1 和 -1, Y 服从标准正态分布且与 X 独立, 则 XY 的分布函数的间断点个数是 $(\quad)$.

- A. 0;
- B. 1;
- C. 2;
- D. 3.

Solution: A

先求 $Z = XY$ 的分布函数, 根据全概率公式有

$$\begin{aligned} F_Z(z) &= P(XY \leq z) \\ &= P(X=1)P(Y \leq z) + P(X=-1)P(Y \geq -z) \\ &= \frac{1}{2}\Phi(z) + \frac{1}{2}(1 - \Phi(-z)) \\ &= \Phi(z) \end{aligned}$$

于是 $Z = XY \sim N(0,1)$, 是连续性分布, 其分布函数没有间断点.

4. 已知命题 p : 随机变量 X 与 Y 相互独立; 命题 q : $X+Y$ 的特征函数是 X 与 Y 特征函数的乘积, 则 $(\quad)$.

- A. p 成立可推出 q 成立, 但反之不行;
- B. q 成立可推出 p 成立, 但反之不行;

- C. 它们互为充要条件;
D. 以上说法都不对.

Solution: A

p 推出 q 是显然的, q 不能推 p 的反例是: $X = Y \sim \text{Cauchy}(0, 1)$, 则 $X+Y$ 的特征函数 $\varphi_{X+Y}(t) = e^{-2|t|} = \varphi_X(t)\varphi_Y(t)$, 但 X, Y 显然是不独立的.

5. 如果总体的方差存在, 关于样本均值 $\bar{X}$ 和样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 说法正确的是 ().
A. $\bar{X}$ 与 S^2 相互独立;
B. $\bar{X}$ 是总体期望的无偏估计, 但 S^2 不是总体方差的无偏估计;
C. $\bar{X}$ 不是总体期望的无偏估计, S^2 是总体方差的无偏估计;
D. 它们分别是总体期望、方差的相合估计.

Solution: D

选项 A 仅正态分布时成立;

选项 B、C: 分别是总体期望、总体方差的无偏估计; 由大数定律, 相合性是显然的.

6. 有来自总体 X 的随机样本 $X_1, \dots, X_n$, 问当 X 服从何种分布时, $\sum_{i=1}^n X_i$ 不是充分统计量? ()
A. $X \sim \mathcal{P}(\lambda)$;
B. $X \sim \text{Ge}(p)$;
C. $X \sim N(\mu, 1)$;
D. $X \sim U(\theta, \theta + 1)$.

Solution: D

对于选项 D, 由因子分解定理有, $(X_{(1)}, X_{(n)})$ 为其充分统计量.

7. 有来自总体 $X \sim N(\mu, \sigma^2)$ 的随机样本 $X_1, \dots, X_n$, 其中 μ, σ^2 未知, 考虑假设检验问题

$$H_0: \mu = 70 \quad \text{vs} \quad H_1: \mu \neq 70,$$

给定显著性水平 α , 则拒绝域的形式是 ().

- A. $\left\{ \left| \frac{\sqrt{n}(\bar{x}-70)}{\sigma} \right| > z_{1-\alpha} \right\}$;
B. $\left\{ \left| \frac{\sqrt{n}(\bar{x}-70)}{\sigma} \right| > z_{1-\alpha/2} \right\}$;
C. $\left\{ \left| \frac{\sqrt{n}(\bar{x}-70)}{s} \right| > t_{1-\alpha}(n-1) \right\}$;
D. $\left\{ \left| \frac{\sqrt{n}(\bar{x}-70)}{s} \right| > t_{1-\alpha/2}(n-1) \right\}$.

Solution: D

方差 σ^2 未知, 故使用 t-检验, 排除 A B, 又根据备择假设双侧, 排除 C 选项.

二、填空题 (每题 4 分, 共 32 分)

1. 某班级有 2001 年出生的 n 个同学, 则没有任何两个人在同一天生日的概率是 _____.

Solution: $\frac{365!}{365^n(365-n)!}$

$$P = \frac{\binom{365}{n} n!}{365^n} = \frac{365!}{365^n(365-n)!}$$

2. 标准正态分布的特征函数是 _____.

Solution: $\exp\left(-\frac{t^2}{2}\right)$

$$\begin{aligned} Ee^{itX} &= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \exp(itx) dx \\ &= \exp\left(-\frac{t^2}{2}\right) \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-it)^2}{2}\right) dx \\ &= \exp\left(-\frac{t^2}{2}\right) \end{aligned}$$

3. 甲投掷 2019 次硬币, 乙投掷 2018 次硬币, 则甲投掷出的正面次数大于乙的概率是 _____.

Solution: $\frac{1}{2}$ 根据对称性, $P(\text{甲正} > \text{乙正}) = P(\text{甲反} > \text{乙反})$, 同时利用该离散型随机变量仅能取整数, 得到

$$P(\text{甲正} > \text{乙正}) = P(2019 - \text{甲正} \leq 2018 - \text{乙正}) = P(\text{甲反} \leq \text{乙反})$$

所以 $P(\text{甲正} > \text{乙正}) + P(\text{甲反} > \text{乙反}) = 1$, 因此 $P(\text{甲正} > \text{乙正}) = \frac{1}{2}$.

4. 在单位圆上任取 3 点, 恰能连成锐角三角形的概率是 _____.

Solution: $\frac{1}{4}$ 本题可以用条件概率积分做, 解析给出另一种思路: 对于每一个锐角三角形来说, 取任意顶点过圆心做射线与圆周相交, 可构成 (三角形对应顶点换成射线顶点) 一个新的钝角三角形, 而锐角三角形有 3 个顶点, 由此对于每一个锐角三角形对应三个钝角三角形, 又因为构成直角三角形的概率为 0, 于是我们可得:

$$\begin{cases} 3P_{\text{构成锐角三角形}} = P_{\text{构成钝角三角形}} \\ P_{\text{构成锐角三角形}} + P_{\text{构成钝角三角形}} = 1 \end{cases} \Rightarrow P_{\text{构成锐角三角形}} = \frac{1}{4}$$

5. 已知 $X_1, \dots, X_n$ 独立同服从分布函数 $F(x)$, 则 $T = -2 \sum_{i=1}^n \ln F(X_i)$ 的分布是 _____.

Solution: $\chi^2(2n)$ 令 $Y_i = F(X_i)$ i.i.d $\sim U(0, 1)$, 而对于 $z > 0$, 有

$$P(-\ln Y_i \leq z) = P(Y_i \geq e^{-z}) = 1 - e^{-z}$$

即 $Z_i = -\ln Y_i$ i.i.d $\sim \text{Exp}(1)$, 因此 $2Z_i \sim \chi^2(2)$, 根据卡方分布的可加性有

$$T = \sum_{i=1}^n 2Z_i \sim \chi^2(2n)$$

6. 已知 $X \sim \text{Exp}(\lambda)$, 则 λ 的 Fisher 信息量是 _____.

Solution: $\frac{1}{\lambda^2}$ X 的密度函数是 $p(x, \lambda) = \lambda \exp\{-\lambda x\}, x > 0$, 取对数有 $\ln p(x, \lambda) = \ln \lambda - \lambda x$ 所以 Fisher 信息量是

$$I(\lambda) = E\left(\frac{\partial \ln p}{\partial \lambda}\right)^2 = E\left(\frac{1}{\lambda} - X\right)^2 = \text{Var}(X) = \frac{1}{\lambda^2}$$

7. 有来自总体 $X \sim N(\mu, 4)$ 的 n 个随机样本, 为使得使得 μ 的 95% 置信区间长度不大于 0.01, 则 n 至少应为 _____.

Solution: 614656 置信区间是, $\mu \in \left[\bar{X} - \frac{1.96 \times 2}{\sqrt{n}}, \bar{X} + \frac{1.96 \times 2}{\sqrt{n}}\right]$, 区间长度是 $\frac{1.96 \times 4}{\sqrt{n}}$. 令 $\frac{1.96 \times 4}{\sqrt{n}} \leq 0.01$, 得到 $n \geq 614656$.

8. 设 A, B, C 是三个事件, 则其中不多于两个发生的事件可表示为 _____.

Solution: $\overline{ABC}$ 多于两个事件发生即三个事件发生, 即 ABC . 题目所提便是其对立事件.

三、解答题 (90 分)

1. (10 分) 在 $(0, 1)$ 中随机取 n 点, 求最远 2 点的距离不超过 $1/2$ 的概率.

Solution: 即求 $P(X_{(n)} - X_{(1)} \leq \frac{1}{2})$, 由于 $X_i \sim U(0, 1)$, 于是根据标准均匀分布的极差的分布 $X_{(n)} - X_{(1)} \sim \text{Beta}(n-1, 2)$, 有

$$P\left(X_{(n)} - X_{(1)} \leq \frac{1}{2}\right) = \int_0^{\frac{1}{2}} n(n-1)x^{n-2}(1-x)dx = \frac{n+1}{2^n}$$

2.(10 分) 已知当 $X = x$ 时, Y 服从 $(0, x)$ 上的均匀分布, 又 $X \sim \text{Exp}(1)$, 试求 EY .

Solution: 由题意可知 $Y | X = x \sim U(0, x)$, $X \sim \text{Exp}(1)$, 于是根据重期望公式

$$EY = E(E(Y | X)) = E\left(\frac{X}{2}\right) = \frac{1}{2}$$

3.(10 分) 有来自总体 X 的 n 个随机样本 $X_1, \dots, X_n$, 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 样本方差 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, 求证: $S_n^2 \xrightarrow{P} \sigma^2$.

Solution: 根据辛钦大数定律, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} EX$, $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} EX^2$, 所以

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \xrightarrow{P} EX^2 - (EX)^2 = \sigma^2$$

4.(10 分) 设 $X_1, \dots, X_m$ 独立同服从 $N(\mu, \sigma^2)$, $Y_1, \dots, Y_n$ 独立同服从 $N(\theta, \sigma^2)$, S_X^2, S_Y^2 分别是这两个样本对应的样本方差, 求证

$$S_w^2 = \frac{(m-1)S_X^2 + (n-1)S_Y^2}{\sigma^2} \sim \chi^2(m+n-2).$$

Solution: 根据 Fisher 引理知, $\frac{(m-1)S_X^2}{\sigma^2} \sim \chi^2(m-1)$, $\frac{(n-1)S_Y^2}{\sigma^2} \sim \chi^2(n-1)$, 并且二者相互独立, 再根据卡方分布的可加性可知

$$\frac{(m-1)S_X^2}{\sigma^2} + \frac{(n-1)S_Y^2}{\sigma^2} \sim \chi^2(m+n-2)$$

5.(15 分) 现有甲、乙两种工艺, 挑选 30 名工人测试他们完成两种工艺所花费的时间, 分别记作 X_i, Y_i . 若欲探究两种工艺所需工时的差异, 请回答:

(1) 若 X, Y 服从正态分布, 给出检验全过程;

(2) 若不知道 X, Y 的分布, 问应该怎么采取检验?

Solution:

(1) 为消除个人能力差异引起的误差, 本题应采取成对数据假设检验. 用 X_i 与 Y_i 分别表示第 i 个工人在甲、乙工艺上的耗时, 则有

$$Z_i = X_i - Y_i \sim N(\mu, \sigma^2)$$

考虑假设检验问题 $H_0: \mu = 0 \longleftrightarrow H_1: \mu \neq 0$ 检验统计量为 $T = \sqrt{n} \frac{\bar{Z}}{s} \sim t(n-1)$, 其中 s^2 是 $Z_1, Z_2, \dots, Z_n$ 的样本方差. 检验的拒绝域为 $W = \{|T| \geq t_{1-\frac{\alpha}{2}}(n-1)\}$, 其中 $n = 30$. 再计算检验统计量的观测值, 判断是否属于拒绝域, 再作出统计推断.

(2) 若 X, Y 的分布未知, 大样本场合根据中心极限定理依然可采用近似 t 检验. 在小样本场合, 可采用符号检验或 Wilcoxon 符号秩和检验.

6.(15 分) 有来自总体 $\mathcal{P}(\theta)$ 的 n 个随机样本, 考虑假设检验问题:

$$H_0: \theta = 2 \quad \text{vs} \quad H_1: \theta = 3,$$

有拒绝域 $W = \{\bar{x} \geq 2.8\}$, 问

(1) $n = 5$ 时, 犯两类错误的概率分别是多少?

(2) n 趋于无穷时, 犯两类错误的概率会有什么变化? 请说明.

Solution: (1) 根据泊松分布的可加性, 有 $n\bar{X} \sim P(n\theta)$, 再计算两类错误

$$\alpha = P(\bar{X} \geq 2.8 \mid \theta = 2) = P(5\bar{X} \geq 14 \mid \theta = 2) = \sum_{i=14}^{+\infty} \frac{10^i}{i!} e^{-10} \approx 0.1355$$

$$\beta = P(\bar{X} < 2.8 \mid \theta = 3) = P(5\bar{X} < 14 \mid \theta = 3) = \sum_{i=0}^{13} \frac{15^i}{i!} e^{-15} \approx 0.3632$$

(2) 对于犯第一类错误的概率, 利用切比雪夫不等式, 有

$$\begin{aligned} \alpha &= P(\bar{X} \geq 2.8 \mid \theta = 2) \\ &= P(n\bar{X} \geq 2.8n \mid \theta = 2) \\ &= P(n\bar{X} - 2n \geq 0.8n \mid \theta = 2) \leq P(|n\bar{X} - 2n| \geq 0.8n \mid \theta = 2) \\ &\leq \frac{2n}{(0.8n)^2} \rightarrow 0 \end{aligned}$$

对于犯第二类错误的概率, 利用中心极限定理, 有

$$\begin{aligned} \beta &= P(\bar{X} < 2.8 \mid \theta = 3) \\ &= P(n\bar{X} < 2.8n \mid \theta = 3) \\ &= P\left(\frac{n\bar{X} - 3n}{\sqrt{3n}} < \frac{-0.2n}{\sqrt{3n}} \mid \theta = 3\right) \sim \Phi\left(\frac{-0.2n}{\sqrt{3n}}\right) \rightarrow 0 \end{aligned}$$

7.(20 分) 有来自均匀分布总体 $U(0, \theta)$ 的 n 个随机样本, 求 θ 的

(1) 最大似然估计 $\hat{\theta}$, 问其是否无偏, 并在 $c\hat{\theta}$ 形式的估计量中找出使得均方误差最小的估计;

(2) 基于 $\hat{\theta}$ 给出 θ 的 $1 - \alpha$ 最短置信区间.

Solution: (1) 似然函数为 $L(\theta) = \frac{1}{\theta^n} I_{\{X_{(n)} \leq \theta\}}$, 它是 θ 在 $[X_{(n)}, +\infty)$ 上的单调递减函数, 因此 θ 的极大似然估计是 $\hat{\theta}_{MLE} = X_{(n)}$, 同时容易求得 $\frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$. 所以 $EX_{(n)} = \frac{n}{n+1}\theta \neq \theta$, 则它不是无偏估计. 再考虑均方误差准则,

$$\begin{aligned} MSE(c\hat{\theta}) &= \text{Var}(c\hat{\theta}) + (E(c\hat{\theta}) - \theta)^2 \\ &= c^2 \text{Var}(X_{(n)}) + \left(\frac{nc - n - 1}{n+1}\theta\right)^2 \\ &= \frac{nc^2}{(n+1)^2(n+2)}\theta^2 + \frac{(nc - n - 1)^2}{(n+1)^2}\theta^2 \\ \text{令 } \frac{\partial MSE(c\hat{\theta})}{\partial c} &= \frac{2cn\theta^2}{(n+1)^2(n+2)} + \frac{2n(nc - n - 1)\theta^2}{(n+1)^2} = 0, \end{aligned}$$

解得 $c = \frac{n+2}{n+1}$.

(2) 以 $\frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$ 为枢轴量, 令 $0 \leq c < d \leq 1$ 满足

$$1 - \alpha = P\left(c < \frac{X_{(n)}}{\theta} < d\right) = \int_c^d nx^{n-1} dx = d^n - c^n$$

反解得到置信区间 $\left[\frac{X_{(n)}}{d}, \frac{X_{(n)}}{c}\right]$, 则我们需在 $d^n - c^n = 1 - \alpha$ 条件下求出使得 $L(c, d) = \frac{1}{c} - \frac{1}{d}$ 取到最小值的点. 用消元法, $d^n - c^n = 1 - \alpha$ 即 $c = (d^n + \alpha - 1)^{\frac{1}{n}}$, 则 $L(c, d) = \frac{1}{c} - \frac{1}{d}$ 可化为关于 d 的一元函数, 即 $L(d) = (d^n + \alpha - 1)^{\frac{1}{n}} - d^{-1}$. 自变量的取值范围为 $0 \leq (d^n + \alpha - 1)^{\frac{1}{n}} < d \leq 1$ 即 $(1 - \alpha)^{\frac{1}{n}} \leq d \leq 1$.

$$\begin{aligned} L'(d) &= -d^{n-1} \cdot (d^n + \alpha - 1)^{-\frac{n+1}{n}} + \frac{1}{d^2} \\ &= d^{-2} \left[1 - \frac{d^{n+1}}{(d^n + \alpha - 1)^{\frac{n+1}{n}}} \right] = d^{-2} \left[1 - \left(\frac{d}{c}\right)^{n+1} \right] < 0 \end{aligned}$$

因此 $L(d)$ 是单调递减函数, 则 $d = 1$ 时其取最小值, 此时 $c = \alpha^{\frac{1}{n}}$. 所以由该枢轴量构造的最短置信区间为 $\left[X_{(n)}, \frac{X_{(n)}}{\alpha^{\frac{1}{n}}}\right]$.

南开大学-432 统计学-2021 年

一、选择题 (每题 4 分, 共 28 分) 1. 一条线段随机分成三段, 能组成三角形的概率是 ().

- A. $1/2$;
- B. $1/4$
- C. $1/3$;
- D. $1/6$.

Solution: B

不妨设总长度为 1, 设分段点分别为 X_1, X_2 i.i.d $\sim U(0, 1)$, 则三段的长度分别是

$$x_{(1)}, x_{(2)} - x_{(1)}, 1 - x_{(2)}$$

设事件 A 表示三段可以构成三角形, 则

$$\begin{aligned} A &= \{x_{(1)} + x_{(2)} - x_{(1)} > 1 - x_{(2)}\} \cap \{x_{(1)} + 1 - x_{(2)} > x_{(2)} - x_{(1)}\} \cap \{1 - x_{(2)} + x_{(2)} - x_{(1)} > x_{(1)}\} \\ &= \left\{x_{(2)} > \frac{1}{2}, x_{(2)} - x_{(1)} < \frac{1}{2}, x_{(1)} < \frac{1}{2}\right\} \end{aligned}$$

$$P(A) = \int_0^{\frac{1}{2}} 2 \, dx_1 \int_{\frac{1}{2}}^{x_1 + \frac{1}{2}} dx_2 = 2 \int_0^{\frac{1}{2}} x_1 \, dx_1 = \frac{1}{4}$$

(注: 这里 $(x_{(1)}, x_{(2)}) \sim f(x_1, x_2) = 2\mathbf{I}_{\{0 < x_1 < x_2 < 1\}}$)

2. 如随机变量 X 与 Y 满足: $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$, 则 ().

- A. X, Y 独立;
- B. X, Y 不相关;
- C. X, Y 互斥;
- D. $\text{Var}(XY) = \text{Var}(X)\text{Var}(Y)$.

Solution: B

$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$, 所以 $\text{Cov}(X, Y) = 0$, 即 X 与 Y 不相关.

3. 设 $X_1, X_2 \cdots X_n$ 为来自正态总体 $N(0, \sigma^2)$ 的简单随机样本, 令 $T = c \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$, 为使 T 成为 σ^2 的无偏估计, 则 $c = ()$.

- A. $\frac{1}{n-1}$;
- B. $\frac{1}{2(n-1)}$;
- C. $\frac{1}{n}$;
- D. $\frac{1}{2n}$.

Solution: B

由于 $X_{i+1} - X_i \sim N(0, 2\sigma^2)$, 所以

$$ET = cE \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2 = c2(n-1)\sigma^2$$

于是 $c = \frac{1}{2(n-1)}$.

4. 设随机变量 X 服从 $N(0, 1)$, 随机变量 Y 服从自由度为 3 的 t 分布, 则对于一个常数 $c(c > 2)$, 下述正确的是 ().

- A. $P(|X| \geq c) > P(|Y| \geq c)$;
- B. $P(|X| \geq c) < P(|Y| \geq c)$;
- C. $P(|X| \geq c) = P(|Y| \geq c)$;

D. 无法确定.

Solution: B

t 分布的尾部概率要大于正态分布, 即它是厚尾分布, 这是一个常用结论.

5. 设 $X_1, X_2, \dots, X_n$ 为来自正态总体 $N(\mu, \sigma^2)$ 的简单随机样本, μ, σ^2 是未知参数, 则 μ 的置信区间长度 ().

- A. 只和 $\bar{x}$ 有关;
- B. 只和 s^2 有关;
- C. 和 $\bar{x}, s^2$ 有关;
- D. 和 σ 有关.

Solution: B

μ 的置信区间是 $\bar{X} \pm \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$, 区间长度 $2 \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$ 只与 s 有关.

6. 设总体 $X \sim N(\mu, \sigma^2)$, 其中 μ 未知, σ^2 已知, (X_1, X_2, X_3) 为来自总体 X 的样本, 则以下哪一项不是统计量. ()

- A. $X_1 + 2X_2$;
- B. $\max\{X_1, X_2, X_3\}$;
- C. $\sum_{i=1}^n \frac{X_i^2}{\sigma^2}$;
- D. $\sum_{i=1}^n (X_i - \mu)$.

Solution: D

统计量的表达式中不应含有未知参数.

7. 设 $X_1, X_2, \dots, X_n$ 为来自正态总体 $N(\mu, 1)$ 的简单随机样本, 则关于假设

$$H_0: \mu \geq 1 \quad \text{vs} \quad H_1: \mu < 1$$

的显著性检验是 ().

- A. 单侧 u 检验;
- B. 单侧 t 检验;
- C. 双侧 u 检验;
- D. 双侧 t 检验.

Solution: A

正态总体, 方差已知, 备择假设单侧, 因此选用单侧 u 检验.

二、填空题 (每题 4 分, 共 32 分)

1. 已知 $X \sim N(\mu, \sigma^2)$, 则 σ 的费雪信息量是 _____.

Solution: $\frac{2}{\sigma^2}$

$$f(x, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \ln f(x, \sigma^2) \propto -\frac{1}{2} \ln \sigma^2 - \frac{(x-\mu)^2}{2\sigma^2}$$

则 $\frac{\partial^2 \ln f(x, \sigma^2)}{\partial (\sigma^2)^2} = \frac{1}{2\sigma^4} - \frac{(x-\mu)^2}{\sigma^6}$, 由指数族的性质算得

$$I(\sigma^2) = -E\left(\frac{\partial^2 \ln f(x, \sigma^2)}{\partial (\sigma^2)^2}\right) = -\left(\frac{1}{2\sigma^4} - \frac{\sigma^2}{\sigma^6}\right) = \frac{1}{2\sigma^4}$$

取 $g(\sigma^2) = \sqrt{\sigma^2}$, 则 $\sigma = g(\sigma^2)$ 的 Fisher 信息量是

$$I(\sigma) = \frac{I(\sigma^2)}{(g'(\sigma^2))^2} = \frac{1}{2\sigma^4} \cdot \frac{1}{\left(\frac{1}{2\sigma}\right)^2} = \frac{2}{\sigma^2}.$$

2. 有来自总体 $X \sim N(\mu, \sigma^2)$ 的样本 $X_1, \dots, X_n, X_{n+1}$, 令 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, $S_n^2 = \frac{1}{n-1} (X_i - \bar{X}_n)^2$, 则 $\sqrt{\frac{n}{n+1}} \frac{X_{n+1} - \bar{X}_n}{S_n}$ 服从的分布是 _____.

Solution: $t(n-1)$

根据 Fisher 引理知, $\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ 以及 $\frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2(n-1)$, 且二者相互独立的. 而它们显然都是与 X_{n+1} 独立的, 则

$$\frac{X_{n+1} - \bar{X}_n}{\sqrt{\frac{n+1}{n} \sigma^2}} \sim N(0, 1)$$

它与 $\frac{(n-1)S_n^2}{\sigma^2}$ 也是独立, 再根据 t 分布的定义有,

$$\frac{\frac{X_{n+1} - \bar{X}_n}{\sqrt{\frac{n+1}{n} \sigma^2}}}{\sqrt{\frac{(n-1)S_n^2}{\sigma^2} / (n-1)}} = \sqrt{\frac{n}{n+1}} \frac{X_{n+1} - \bar{X}_n}{S_n} \sim t(n-1).$$

3. 伽马分布 $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$ 的特征函数是 _____.

Solution: $\left(1 - \frac{it}{\beta}\right)^{-\alpha}$

$$\begin{aligned} \varphi(t) &= \int_0^\infty e^{itx} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx \\ &= \int_0^\infty \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-(\beta-it)x} dx \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} (\beta-it)^{-\alpha} \int_0^\infty [(\beta-it)x]^{\alpha-1} e^{-(\beta-it)x} dx \\ &= \left(1 - \frac{it}{\beta}\right)^{-\alpha}. \end{aligned}$$

4. 某圆盘的半径在区间 (a, b) 上服从均匀分布, 则该圆盘的平均面积为 _____.

Solution: $\frac{\pi(a^2+b^2+ab)}{3}$

半径 $R \sim U(a, b)$, 则期望面积为 $E(\pi R^2) = \frac{\int_a^b \pi r^2 dr}{b-a} = \frac{\pi(a^2+b^2+ab)}{3}$.

5. 现有 n 名男生与 m 名女生 ($m \leq n$) 随机地站成一排, 则任意两名女生都不相邻的概率是 _____.

Solution: $\frac{C_{n+1}^m}{C_{n+m}^m}$

由于本题无需考虑男女生个体的差异, 则全体样本空间中的样本点数量可视为 $n+m$ 个位置中选 m 个位置, 即 $\#\Omega = C_{n+m}^m$. 再利用隔板法, 先将 n 个男生排列好后, 将 m 个女生插入男生间隔处 (所有男生中间, 以及第一个男生前方与最后一个男生后方, 共 $n+1$ 个), 有利样本数为 $E = C_{n+1}^m$. 所求概率即

$$P(E) = \frac{\#E}{\#\Omega} = \frac{C_{n+1}^m}{C_{n+m}^m}.$$

6. 已知 $X \sim N(0, 1)$, 则 $Y = |X|$ 的密度函数是 _____.

Solution: $f_Y(y) = \sqrt{\frac{2}{\pi}} e^{-\frac{y^2}{2}}, y > 0$

用分布函数法, 对于 $\forall y > 0$, 有

$$F_Y(y) = P(|X| \leq y) = \Phi(y) - \Phi(-y)$$

因此 Y 的密度函数是

$$f_Y(y) = \frac{dF_Y(y)}{dy} = \sqrt{\frac{2}{\pi}} e^{-\frac{y^2}{2}}, y > 0$$

7. 有来自总体 $X \sim \text{Beta}(\theta, 1)$ 的 n 个随机样本 $X_1, \dots, X_n$, 则 $\frac{1}{\theta}$ 的 MLE 是 _____.

Solution: $-\frac{1}{n} \sum_{i=1}^n \ln X_i$

密度函数是 $f(x) = \theta x^{\theta-1}, 0 < x < 1$. 则似然函数为 $L(\theta) = \theta^n (\prod_{i=1}^n X_i)^{\theta-1}$, 取对数有 $\ln L(\theta) = n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln X_i$, 将其关于参数求导并置 0, 得似然方程

$$\frac{\partial \ln L}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^n \ln X_i = 0$$

解得 $\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln X_i}$ 是 θ 的 MLE. 由不变性易得答案.

8. 设随机样本 $X_1, \dots, X_n$ 独立同分布, 又已知 $EX_1 = 0, Var(X_1) = \sigma^2$, 则 $Cov(X_1, \bar{X}) =$ _____.

Solution: $\frac{1}{n}\sigma^2$

$$Cov(X_1, \bar{X}) = Cov\left(X_1, \frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} Cov(X_1, X_1) = \frac{1}{n}\sigma^2.$$

三、解答题 (90 分)

1.(10 分) 设盒中有 b 个黑球, r 个白球. 每次随机取出一个观察颜色后放回, 并加入 c 个同色球, 如此一直重复, 求第 N 次取得黑球的概率.

Solution: 用随机变量 X_i 表示第 i 次摸球放球后, 盒子中黑球的数量, 此时盒子中球的总数为 $b+r+ci$, 则

第 $i+1$ 摸出黑球的概率应为 $p_{i+1} = \frac{EX_i}{b+r+ci}$. 再设 0-1 随机变量 $\xi_i = \begin{cases} 1, & \text{第 } i \text{ 次摸出黑球} \\ 0, & \text{第 } i \text{ 次摸出白球} \end{cases}$, 显然

$$E\xi_i = p_i = \frac{EX_{i-1}}{b+r+c(i-1)}$$

再建立递推式, 即 $X_i = X_{i-1} + c\xi_i$, 利用这一递推式虽然无法求出 X_i 的分布, 但是我们可以对该式左右取期望, 即

$$EX_i = EX_{i-1} + cE\xi_i$$

$$EX_i = EX_{i-1} + c \frac{EX_{i-1}}{b+r+c(i-1)}$$

$$EX_i = \frac{b+r+ci}{b+r+c(i-1)} EX_{i-1}$$

$$\frac{EX_i}{b+r+ci} = \frac{EX_{i-1}}{b+r+c(i-1)}$$

注意到最后一个式子即 $p_{i+1} = p_i$, 这说明每一次摸出黑球的概率都是一样的, 所以

$$p_n = p_1 = \frac{EX_0}{b+r} = \frac{b}{b+r}.$$

2.(15 分) 有随机变量序列 $\{X_n\}$, 记 $Y_n = \frac{1}{n} \sum_{i=1}^n X_i, a_n = EY_n$, 证明: $\{X_n\}$ 服从大数定律的充要条件是

$$\lim_{n \rightarrow \infty} E \left[\frac{(Y_n - a_n)^2}{1 + (Y_n - a_n)^2} \right] = 0.$$

Solution: [充分性] 函数 $f(t) = \frac{t^2}{1+t^2} (t > 0)$ 为单调增的非负函数, 则可写出不等式

$$f(\varepsilon) I_{\{|Y_n - a_n| \geq \varepsilon\}} \leq f(|Y_n - a_n|) I_{\{|Y_n - a_n| \geq \varepsilon\}} \leq f(|Y_n - a_n|)$$

对该不等式最左和最右均取期望, 不等号仍然成立, 即

$$f(\varepsilon) P(|Y_n - a_n| \geq \varepsilon) \leq Ef(|Y_n - a_n|)$$

$$P(|Y_n - a_n| \geq \varepsilon) \leq \frac{1}{f(\varepsilon)} Ef(|Y_n - a_n|)$$

而 $\frac{1}{f(\varepsilon)} E f(|Y_n - a_n|) = \frac{1+\varepsilon^2}{\varepsilon^2} E \left(\frac{(Y_n - a_n)^2}{1+(Y_n - a_n)^2} \right) \rightarrow 0$, 所以 $Y_n - a_n \xrightarrow{P} 0$, 即 $\{X_n\}$ 服从大数定律.

[必要性] $\{X_n\}$ 服从大数定律, 即对任意 $\varepsilon > 0, \lim_{n \rightarrow \infty} P(|Y_n - a_n| \geq \varepsilon) = 0$. 再次考虑函数 $f(t) = \frac{t^2}{1+t^2} (t > 0)$ 为单调增的非负函数以及其具有上界 1, 利用重期望公式, 对于任意 $\varepsilon > 0$, 有

$$\begin{aligned} E \left[\frac{|Y - a_n|^2}{1 + |Y - a_n|^2} \right] &= E \left[\frac{|Y - a_n|^2}{1 + |Y - a_n|^2} \mid |Y_n - a_n| < \varepsilon \right] P(|Y_n - a_n| < \varepsilon) \\ &\quad + E \left[\frac{|Y - a_n|^2}{1 + |Y - a_n|^2} \mid |Y_n - a_n| \geq \varepsilon \right] P(|Y_n - a_n| \geq \varepsilon) \\ &\leq \frac{\varepsilon^2}{1 + \varepsilon^2} \cdot 1 + 1 \cdot P(|Y_n - a_n| \geq \varepsilon) \end{aligned}$$

其中 $P(|Y_n - a_n| \geq \varepsilon) \rightarrow 0$, 再根据 ε 的任意性知, 令 $\varepsilon \rightarrow 0$ 知

$$E \left[\frac{|Y - a_n|^2}{1 + |Y - a_n|^2} \right] \rightarrow 0$$

3.(10 分) 有来自总体 $F(x)$ 的 n 个随机样本, $F_n(x)$ 为经验分布函数, 试证明: 对任意 $x \in R, F_n(x)$ 均方收敛于 $F(x)$, 进而有依概率、按分布收敛于 $F(x)$.

Solution: 经验分布函数为 $F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq x\}}$, 由于 $I_{\{X_i \leq x\}} \text{ i.i.d } \sim b(1, F(x))$, 根据二项分布的可加性知道 $\sum_{i=1}^n I_{\{X_i \leq x\}} \sim B(n, F(x))$. 由于 $E F_n(x) = \frac{1}{n} \cdot n F(x) = F(x)$, 则 $F_n(x)$ 是 $F(x)$ 的无偏估计, 所以

$$\begin{aligned} E (F_n(x) - F(x))^2 &= \text{Var} (F_n(x)) \\ &= \frac{1}{n^2} \cdot n \cdot F(x) \cdot [1 - F(x)] \\ &\leq \frac{1}{n} \rightarrow 0 \end{aligned}$$

所以对于 $\forall x \in R$, 有 $F_n(x) \xrightarrow{L_2} F(x)$, 进而 $F_n(x) \xrightarrow{P} F(x), F_n(x) \xrightarrow{L} F(x)$.

4.(15 分) 有来自总体 $N(\mu, 1)$ 的 n 个随机样本, 考虑假设检验问题

$$H_0: \mu = 1 \quad \text{vs} \quad H_1: \mu > 1,$$

有拒绝域 $W_1 = \{\bar{x}: \bar{x} > 1 + \frac{z_{0.95}}{\sqrt{n}}\}$ 和 $W_2 = \{\bar{x}: 1 + \frac{z_{0.95}}{\sqrt{n}} > \bar{x} > 1 + \frac{z_{0.9}}{\sqrt{n}}\}$, 分别求它们的

(1) 两类错误和功效函数.

(2) 你认为谁更优, 为什么?

Solution: (1) 对于 W_1 , 其功效函数为

$$\begin{aligned} \rho_{W_1}(\mu) &= P \left(\bar{X} > 1 + \frac{z_{0.95}}{\sqrt{n}} \right) \\ &= P \left((\bar{X} - \mu) \sqrt{n} > \left(1 + \frac{z_{0.95}}{\sqrt{n}} - \mu \right) \sqrt{n} \right) \\ &= 1 - \Phi \left(\left(1 + \frac{z_{0.95}}{\sqrt{n}} - \mu \right) \sqrt{n} \right) \end{aligned}$$

所以犯两类错误的概率分别为

$$\alpha_1 = \rho_{W_1}(1) = 0.05$$

$$\beta_1(\mu) = 1 - \rho_{W_1}(\mu) = \Phi \left(\left(1 + \frac{z_{0.95}}{\sqrt{n}} - \mu \right) \sqrt{n} \right), \mu > 1$$

对于 W_2 , 其功效函数为

$$\begin{aligned}\rho_{W_2}(\mu) &= P\left(1 + \frac{z_{0.95}}{\sqrt{n}} > \bar{X} > 1 + \frac{z_{0.90}}{\sqrt{n}}\right) \\&= P\left(\left(1 + \frac{z_{0.95}}{\sqrt{n}} - \mu\right)\sqrt{n} > (\bar{X} - \mu)\sqrt{n} > \left(1 + \frac{z_{0.90}}{\sqrt{n}} - \mu\right)\sqrt{n}\right) \\&= \Phi\left(\left(1 + \frac{z_{0.95}}{\sqrt{n}} - \mu\right)\sqrt{n}\right) - \Phi\left(\left(1 + \frac{z_{0.90}}{\sqrt{n}} - \mu\right)\sqrt{n}\right)\end{aligned}$$

所以犯两类错误的概率分别为

$$\begin{aligned}\alpha_2 &= \rho_{W_2}(1) = 0.05 \\ \beta_2(\mu) &= 1 - \rho_{W_2}(\mu) \\&= 1 - \Phi\left(\left(1 + \frac{z_{0.95}}{\sqrt{n}} - \mu\right)\sqrt{n}\right) + \Phi\left(\left(1 + \frac{z_{0.90}}{\sqrt{n}} - \mu\right)\sqrt{n}\right), \mu > 1\end{aligned}$$

(2) W_1 是更优的, 根据 N-P 引理可以知道它是 UMP 拒绝域. 它是所有水平不超过 0.05 的检验中犯第二类错误概率最小的, 而根据 (1) 的分析, W_2 是一个水平为 0.05 的检验, 所以 W_1 要优于它.

5.(15 分) 有来自总体 $X \sim B(1, p)$ 的随机样本 $X_1, \dots, X_n, q = 1 - p$, 求

(1) pq 的 UMVUE;

(2) $(1 - p)^2$ 的 MLE, 问它是否无偏, 若不是请求出一个无偏估计.

Solution: (1) 总体的分布列是

$$\begin{aligned}P(X = x) &= p^x(1 - p)^{1-x} \\&= (1 - p) \left(\frac{p}{1 - p}\right)^x \\&= (1 - p) \exp\left\{x \ln\left(\frac{p}{1 - p}\right)\right\}, x = 0, 1\end{aligned}$$

所以 X 是一个单参的完全指数族分布, 由其标准形式密度函数可以看出参数 p 的充分完全统计量是 $T = \sum_{i=1}^n X_i$, 或者 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$. 计算可得到

$$\begin{cases} E\bar{X} = p \\ E\bar{X}^2 = \frac{p}{n} + \frac{n-1}{n}p^2 \end{cases}$$

于是 $E\left[\frac{n}{n-1}(\bar{X} - \bar{X}^2)\right] = p - p^2 = p(1 - p) = pq$, 所以根据 L-S 定理可知 $\frac{n}{n-1}(\bar{X} - \bar{X}^2)$ 是 pq 的 UMVUE.

(2) 似然函数为 $L(p) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$, 取对数并关于参数求偏导置 0, 得

$$\frac{\sum_{i=1}^n X_i}{p} - \frac{n - \sum_{i=1}^n X_i}{1 - p} = 0$$

解得 p 的 MLE 是 $\bar{X}$, 再根据不变性可知 $(1 - p)^2$ 的 MLE 为 $(1 - \bar{X})^2$, 而

$$E[(1 - \bar{X})^2] = \text{Var}(1 - \bar{X}) + (1 - p)^2 = (1 - p)^2 + \frac{p(1 - p)}{n},$$

它不是 $(1 - p)^2$ 的无偏估计, 取

$$M = (1 - \bar{X})^2 - \frac{n}{n-1}(\bar{X} - \bar{X}^2),$$

计算可验证其为 $(1 - p)^2$ 的无偏估计, 根据 L-S 定理知其为 UMVUE.

6.(15 分) 随机变量 $\varphi \sim U(0, 1)$, 随机变量 R 的密度函数是 $f(r) = re^{-\frac{r^2}{2}}, r > 0$, 且 R 与 φ 独立, 对于数列 $\{a_n\}$, 试证明: $\{X_n = R \cos(2\pi(a_n + \varphi))\}$ 是正态序列.

Solution: 对于任意的数列 $\{a_n\}, Y_n = 2\pi(a_n + \varphi) \sim U(2\pi a_n, 2\pi a_n + 2\pi)$, 考虑用微分法求 X_n 的密度函数, 有

$$\begin{aligned} P(X_n = x) &= P(R \cos Y_n = x) \\ &= \int_{2\pi a_n}^{2\pi a_n + 2\pi} P\left(R = \frac{x}{\cos y}\right) \frac{1}{2\pi} dy \\ &= \int_{2\pi a_n}^{2\pi a_n + 2\pi} \left(\frac{x}{\cos y} e^{-\frac{x^2}{2 \cos^2 y}} \frac{dx}{\cos y} I_{\{\frac{x}{\cos y} > 0\}} \right) \frac{1}{2\pi} dy \end{aligned}$$

注意第二行使用了连续场合的全概率公式, 该积分是对 y 的积分, 而 dx 则是微分法中的微元记号, 则被积函数中含有 y 的部分均为周期函数 $\cos y$, 且积分区间的长度是其周期 2π , 于是该积分等同于

$$\int_{-\frac{\pi}{2}}^{\frac{3}{2}\pi} \left(\frac{x}{\cos y} e^{-\frac{x^2}{2 \cos^2 y}} \frac{dx}{\cos y} I_{\{\frac{x}{\cos y} > 0\}} \right) \frac{1}{2\pi} dy$$

其中

$$\begin{aligned} \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} \frac{e^{-\frac{x^2}{2 \cos^2 y}}}{\cos^2 y} dy &= \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} e^{-\frac{1}{2}(x^2 \tan^2 y + x^2)} d(\tan y) \\ &= e^{-\frac{x^2}{2}} \int_{-\frac{\pi}{2}}^{\frac{\pi}{2}} e^{-\frac{1}{2}x^2 \tan^2 y} d(\tan y) \\ &= \frac{e^{-\frac{x^2}{2}}}{x} \int_{-\infty}^{+\infty} e^{-\frac{z^2}{2}} dz = \sqrt{2\pi} \frac{e^{-\frac{x^2}{2}}}{x} \end{aligned}$$

同理 $\int_{\frac{\pi}{2}}^{\frac{3\pi}{2}} \frac{e^{-\frac{x^2}{2 \cos^2 y}}}{\cos^2 y} dy = \sqrt{2\pi} \frac{e^{-\frac{x^2}{2}}}{x}$, 综上所述

$$P(X_n = x) = \begin{cases} \frac{x}{2\pi} \sqrt{2\pi} \frac{e^{-\frac{x^2}{2}}}{x} dx, & x > 0 \\ \frac{x}{2\pi} \sqrt{2\pi} \frac{e^{-\frac{x^2}{2}}}{x} dx, & x < 0 \end{cases} = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, -\infty < x < +\infty$$

这里最后一步补充了 $x = 0$ 处的定义. 于是发现 $X_n \sim N(0, 1)$.

7.(10 分) 有来自总体 $N(\mu, \sigma^2)$ 的随机样本 $X_1, \dots, X_n$, 考虑假设检验问题

$$H_0: \sigma^2 = \sigma_0^2 \quad \text{vs} \quad H_1: \sigma^2 \neq \sigma_0^2,$$

给定显著性水平 α , 证明该问题的似然比检验可由统计量 $\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$ 给出.

Solution: 似然函数为 $L(\mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum_{i=1}^n (X_i - \mu)^2}{2\sigma^2}\right\}$, 容易求得在无约束空间中以及约束空间 $\Theta_0 = \{\sigma^2 = \sigma_0^2\}$ 下参数的 MLE, 它们分别是 Θ 中 $\begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}_1^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} \end{cases}$, Θ_0 中 $\begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}_0^2 = \sigma_0^2 \end{cases}$, 则广义似

然比为

$$\begin{aligned}
 \Lambda &= \frac{L(\bar{X}, \hat{\sigma}^2)}{L(\bar{X}, \sigma_0^2)} \\
 &= \frac{(2\pi\hat{\sigma}^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{2\hat{\sigma}^2}\right\}}{(2\pi\sigma_0^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{2\sigma_0^2}\right\}} \\
 &= \left(\frac{\hat{\sigma}^2}{\sigma_0^2}\right)^{-\frac{n}{2}} \exp\left\{-\frac{n}{2} + \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{2\sigma_0^2}\right\} \\
 &= \left(\frac{n-1}{n} \frac{s^2}{\sigma_0^2}\right)^{-\frac{n}{2}} \exp\left\{\frac{(n-1)s^2}{2\sigma_0^2}\right\} e^{-\frac{n}{2}}
 \end{aligned}$$

记 $\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$, 则 $\Lambda = \left(\frac{1}{n}\right)^{-\frac{n}{2}} (\chi^2)^{-\frac{n}{2}} \exp\left\{\frac{\chi^2}{2}\right\} e^{-\frac{n}{2}}$ 是关于 χ^2 的先减后增函数, 因此似然比拒绝域

$$W = \{\Lambda \geq c\} \Leftrightarrow \{\chi^2 \leq a\} \cup \{\chi^2 \geq b\}$$

又注意到当 H_0 成立时, $\chi^2 \sim \chi^2(n-1)$, 所以给定显著性水平 α , 该假设检验问题的似然比拒绝域可写为

$$W = \{\chi^2 \leq \chi_{\frac{\alpha}{2}}^2(n-1)\} \cup \{\chi^2 \geq \chi_{1-\frac{\alpha}{2}}^2(n-1)\}.$$

南开大学-432 统计学-2022 年

一、选择题 (每题 4 分, 共 28 分) 1. 关于经验分布函数 $F_n(x)$, 说法错误的是 ()

- (a) 它是分布函数
- (b) 它是 x 的连续函数
- (c) 它是随机变量
- (d) 它依概率收敛于分布函数

Solution: B

A 正确, 它满足分布函数的定义; B 错误, 它在每个样本点的取值上间断; C 正确, 它依赖于样本, 具有随机性; D 正确, 根据大数定律.

2. X 的密度函数是 $f(x)$, 则 $Y = -X$ 的密度函数是 ()

- (a) $f(y)$
- (b) $1 - f(y)$
- (c) $f(-y)$
- (d) $-f(-y)$

Solution: C

用微分法, 有

$$P(Y = y) = P(-X = y) = P(X = -y) = f(-y) |d(-y)| = f(-y) dy$$

因此 C 正确.

3. 袋中有黑球 $2n$ 个, 白球 $2n-1$ 个, 现摸 n 个球, 已知摸到的球都是一个颜色, 求摸到的是黑球的概率 ()

- (a) $\frac{2}{3}$
- (b) $\frac{C_{2n}^n}{C_{4n-1}^n}$
- (c) $\frac{1}{3}$
- (d) $1 - \frac{C_{2n}^n}{C_{4n-1}^n}$

Solution: A

$P(\text{全黑}) = \frac{C_{2n}^n}{C_{4n-1}^n}$, $P(\text{全白}) = \frac{C_{2n-1}^n}{C_{4n-1}^n}$, 因此

$$P(\text{全黑} | \text{全相同}) = \frac{P(\text{全黑})}{P(\text{全黑}) + P(\text{全白})} = \frac{C_{2n}^n}{C_{2n}^n + C_{2n-1}^n} = \frac{\frac{(2n)!}{n!n!}}{\frac{(2n)!}{n!n!} + \frac{(2n-1)!}{n!(n-1)!}} = \frac{1}{1 + \frac{1}{2}} = \frac{2}{3}$$

4. 设随机变量 $X_1, X_2, \dots, X_n (n > 1)$ 独立同分布, 且其方差为 $\sigma^2 > 0$, 令 $Y = \frac{1}{n} \sum_{i=1}^n X_i$, 则下述结论正确的是 ()

- (A) $\text{Cov}(X_1, Y) = \frac{\sigma^2}{n}$
- (B) $\text{Cov}(X_1, Y) = \sigma^2$
- (C) $\text{Var}(X_1 + Y) = \frac{n+2}{n} \sigma^2$
- (D) $\text{Var}(X_1 - Y) = \frac{n+1}{n} \sigma^2$

Solution: A

$$\text{Cov}(X_1, Y) = \frac{1}{n} \text{Var}(X_1) = \frac{\sigma^2}{n}$$

$$\text{Var}(X_1 + Y) = \text{Var}(X_1) + \text{Var}(Y) + 2\text{Cov}(X_1, Y) = \sigma^2 + \frac{\sigma^2}{n} + \frac{2}{n} \sigma^2 = \frac{n+3}{n} \sigma^2$$

$$\text{Var}(X_1 - Y) = \text{Var}(X_1) + \text{Var}(Y) - 2\text{Cov}(X_1, Y) = \sigma^2 + \frac{\sigma^2}{n} - \frac{2}{n} \sigma^2 = \frac{n-1}{n} \sigma^2$$

5. $X_1, \dots, X_n$ 是 i.i.d. 是 $N(\mu, \sigma^2)$ 随机样本, 定义

$$S_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, S_2^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, S_3^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \mu)^2, S_4^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2,$$

则下列服从 $t(n-1)$ 的是 ()

- (a) $\frac{\bar{X} - \mu}{S_1 / \sqrt{n-1}}$
- (b) $\frac{\bar{X} - \mu}{S_2 / \sqrt{n-1}}$
- (c) $\frac{\bar{X} - \mu}{S_3 / \sqrt{n-1}}$
- (d) $\frac{\bar{X} - \mu}{S_4 / \sqrt{n-1}}$

Solution: B

B 项可写作

$$\frac{\bar{X} - \mu}{S_2 / \sqrt{n-1}} = \frac{(\bar{X} - \mu) / \sqrt{n}}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}} \sim t(n-1)$$

其他选项均不正确.

6. X_n 依概率收敛于 X , Y_n 按分布收敛于 c , 下列错误的是 ()

- (a) $X_n Y_n$ 依概率收敛于 cX
- (b) $g(x)$ 是实值函数, 则 $g(X_n)$ 依概率收敛于 $g(X)$
- (c) X_n / Y_n 按分布收敛于 $X/c, c \neq 0$
- (d) $a_n \rightarrow a, b_n \rightarrow b$, 则 $a_n X_n + b_n$ 按分布收敛于 $aX + b$

Solution: B

B 选项仅对连续函数成立, 反例: 记 $X_n = \frac{1}{n}$ 单点分布, $X = 0$ a.s. 则 $X_n \rightarrow_p X$, 取实值函数 $g(x) = \begin{cases} 1, & x \neq 0 \\ 0, & x = 0 \end{cases}$, 则显然 $g(X_n)$ 不依概率收敛于 $g(X)$.

7. 下列哪个总体的样本之和不是参数的充分统计量 ()

- (a) 正态
- (b) 泊松
- (c) 指数
- (d) 均匀

Solution: D

若支撑集与参数有关, 那么通常最大/最小次序统计量会是充分统计量.

二、填空题 (每题 4 分, 共 32 分)

1. $X \sim N(\mu, \sigma^2)$ 的特征函数是 _____.

Solution: $e^{i\mu t - \frac{\sigma^2 t^2}{2}}$.

2. 有 n 封信, 对应 n 个信封, 现随机进行配对, 配对成功的信封数的期望是 _____.

Solution: 1

利用期望的线性性以及对称性, 第 i 封信匹配成功记作 $X_i = 1$, 否则 $X_i = 0$, 显然 $X_i \sim b(1, \frac{1}{n})$, 因此匹配成功的信封数为 $\sum_{i=1}^n X_i$, 因此

$$E\left(\sum_{i=1}^n X_i\right) = nEX_1 = n \cdot \frac{1}{n} = 1$$

3. $P(A) = 0.3$, 且 A, B 互不相容, $P(B) = 0.4$, 则 $P(B | \bar{A}) =$ _____.

Solution: $P(B | \bar{A}) = \frac{P(B\bar{A})}{P(\bar{A})} = \frac{P(B) - P(AB)}{0.7} = \frac{4}{7}$.

4. (X, Y) 服从由 $1 < x < e^2$ 和 $0 < y < \frac{1}{x}$ 围成区域上的均匀分布, 则 $f_{Y|X=3}(y) = \underline{\quad}$.

Solution: $f_{Y|X=3}(y) = 3, 0 < y < \frac{1}{3}$.

$$f(x, y) = \begin{cases} \frac{1}{S_D}, & 1 < x < e^2, 0 < y < \frac{1}{x}, \\ 0, & \text{其他.} \end{cases} \text{ 其中 } S_D = \int_1^{e^2} dx \int_0^{\frac{1}{x}} dy = \int_1^{e^2} \frac{1}{x} dx = 2.$$

因此 $f_X(x) = \int_0^{\frac{1}{x}} \frac{1}{2} dy = \frac{1}{2x}, 1 < x < e^2$, 于是

$$f_{Y|X=3}(y) = \frac{f(3, y)}{f_X(3)} = \frac{\frac{1}{2}}{\frac{1}{6}} = 3, \quad 0 < y < 1/3.$$

5. 已知气温均值为 20, 标准差为 2, 某天天气气温大于 16 小于 24 的概率至少为 $\underline{\quad}$.

Solution: 根据切比雪夫不等式 $P(16 < X < 24) = P(|X - 20| < 4) \geq 1 - \frac{4}{16} = \frac{3}{4}$.

6. 已知 $X \sim B(1, p)$, 则 p 的 Fisher 信息量是 $\underline{\quad}$.

Solution: $\frac{1}{p(1-p)}$

$$I(p) = -E \left[\frac{\partial^2 \ln f(X; p)}{\partial p^2} \right] = -E \left[-\frac{X}{p^2} - \frac{1-X}{(1-p)^2} \right] = \frac{1}{p} + \frac{1}{1-p} = \frac{1}{p(1-p)}$$

7. 射击连射十次, 每次中的概率是 0.6, 设 X 是射中次数, 则 $E(X^2) = \underline{\quad}$.

Solution: 38.4

$X \sim B(10, 0.6)$, 则 $EX = 6, Var(X) = 10 \cdot 0.6 \cdot 0.4 = 2.4$, 所以 $EX^2 = (EX)^2 + Var(X) = 36 + 2.4 = 38.4$.

8. X 服从泊松分布, 且 $P(X=2) = P(X=3)$, 则 X 取偶数的概率是 $\underline{\quad}$.

Solution: $\frac{1+e^{-6}}{2}$

假设泊松分布的参数为 λ , 则 $P(X=2) = \frac{\lambda^2}{2!} e^{-\lambda} = \frac{\lambda^3}{3!} e^{-\lambda} = P(X=3)$, 解得 $\lambda = 3$.

而 X 取偶数的概率是

$$\sum_{k=0}^{\infty} P(X=2k) = \sum_{k=0}^{\infty} \frac{\lambda^{2k}}{(2k)!} e^{-\lambda} = e^{-\lambda} \frac{e^{\lambda} + e^{-\lambda}}{2} = \frac{1 + e^{-2\lambda}}{2} = \frac{1 + e^{-6}}{2}$$

三、解答题 (90 分)

1. (10 分) 设 $P(A) = \frac{1}{4}, P(B|A) = \frac{1}{3}, P(A|B) = \frac{1}{2}$, 令 $X = I_A, Y = I_B$, 求:

(1) 联合分布;

(2) 相关系数.

Solution: (1) $P(AB) = P(B|A)P(A) = \frac{1}{12}, P(B) = \frac{P(AB)}{P(A|B)} = \frac{1}{6}$, 故 $P(X=1, Y=1) = \frac{1}{12}, P(X=1, Y=0) = \frac{1}{6}, P(X=0, Y=1) = \frac{1}{12}, P(X=0, Y=0) = \frac{2}{3}$.

(2) 有 $EX = \frac{1}{4}, EY = \frac{1}{6}$, 以及 $E(XY) = \frac{1}{12}, D(X) = \frac{3}{16}, D(Y) = \frac{5}{36}$, 故 $\rho = \frac{\frac{1}{12} - \frac{1}{4} \cdot \frac{1}{6}}{\sqrt{\frac{3}{16}} \sqrt{\frac{5}{36}}} = \frac{1}{\sqrt{15}}$.

2. (10 分) 某班级成员一星期迟到共计 50 次, 其中星期一 12 次, 星期二 11 次, 星期三 9 次, 星期四 10 次, 星期五 8 次. 问迟到是否与星期几有关? (注: 记 $f_{\chi^2(n)}(x)$ 是卡方分布 $\chi^2(n)$ 的密度函数, 且 $\int_0^{9.48} f_{\chi^2(4)}(x) dx \approx 0.95, \int_0^{11.07} f_{\chi^2(5)}(x) dx \approx 0.95$)

Solution: 利用卡方拟合优度检验, 设 X 是某一次迟到可能发生在星期 k 的概率 ($k = 1, \dots, 5$), 建立假设检验问题: $H_0: P(X=k) = \frac{1}{5} (k=1, \dots, 5)$ 构造卡方检验统计量 $\chi^2 = \sum_{k=1}^r \frac{(np_k - n_k)^2}{np_k}$, 其中 r 表示随机变量可能的取值个数, 此处 $r = 5, n$ 为样本总数此时 $n = 50, n_k$ 为随机变量 $X = k$ 的观测值总数, p_k 等于原假设中的 $P(X=k)$ 此处 $p_k \equiv \frac{1}{5}$. 而 $W = \{\chi^2 \geq \chi_{1-\alpha}^2(r-1)\}$, 此时

$$W = \{\chi^2 \geq \chi_{0.95}^2(4)\} = \{\chi^2 \geq 9.48\}.$$

算得 $\chi^2 = \sum_{k=1}^r \frac{(np_k - n_k)^2}{np_k} = \frac{4+1+1+0+4}{10} = 1 \notin W$. 所以不能拒绝原假设, 某一次迟到可能发生在星期 k 的概率应该是相同的, 即迟到与星期几无关.

3.(15 分) 设 $p \in (0, 1), 0 < \alpha < (1-p)/p$. 已知一个家庭有 n 个小孩的概率是

$$p_n = \begin{cases} \alpha p^n, & n \geq 1, \\ 1 - \alpha p / (1 - p), & n = 0. \end{cases}$$

又设男婴和女婴的出生是等可能的. 回答:

(1) 求一个家庭有 k 个男孩的概率;

(2) 已知某家庭没有女孩, 求该家庭有 1 个男孩的概率.

Solution: 分别用 X_1 和 X_2 表示一个家庭的男孩、女孩数量, 则

(1) 根据全概率公式, $P(X_1 = k) = \sum_{n=k}^{\infty} C_n^k \left(\frac{1}{2}\right)^n p_n$,

若 $k = 0$, 则

$$P(X_1 = 0) = \sum_{n=0}^{\infty} C_n^0 \left(\frac{1}{2}\right)^n p_n = 1 - \frac{\alpha p}{1-p} + \sum_{n=1}^{\infty} C_n^0 \left(\frac{1}{2}\right)^n \alpha p^n = 1 - \frac{\alpha p}{1-p} + \alpha \sum_{n=1}^{\infty} \left(\frac{p}{2}\right)^n = 1 - \frac{\alpha p}{1-p} + \alpha \frac{p}{2-p}$$

当 $k \geq 1$, 则

$$P(X_1 = k) = \sum_{n=k}^{\infty} C_n^k \left(\frac{1}{2}\right)^n p_n = \sum_{n=k}^{\infty} C_n^k \left(\frac{1}{2}\right)^n \alpha p^n = \alpha \left(\frac{p}{2}\right)^{-1} \sum_{n=k+1}^{\infty} C_{n-1}^{(k+1)-1} \left(\frac{p}{2}\right)^n = \alpha \left(\frac{p}{2}\right)^{-1} \left(\frac{p}{2-p}\right)^{k+1} = \frac{2\alpha p^k}{(2-p)^{k+1}}$$

注意这里我们用到了负二项分布公式, 即设 Z 表示伯努利试验成功 r 次所需的总次数, 即 $Z \sim Nb(r, p)$, 有分布列 $1 = \sum_{n=r}^{\infty} C_{n-1}^{r-1} p^r q^{n-r} = \left(\frac{p}{q}\right)^r \sum_{n=r}^{\infty} C_{n-1}^{r-1} q^n$, 则有公式 $\sum_{n=r}^{\infty} C_{n-1}^{r-1} q^n = \left(\frac{q}{p}\right)^r$, 其中 $p = 1 - q$. 利用该公式可计算前面式中

$$\sum_{n=k+1}^{\infty} C_{n-1}^{(k+1)-1} \left(\frac{p}{2}\right)^n = \left(\frac{\frac{p}{2}}{1 - \frac{p}{2}}\right)^{k+1} = \left(\frac{p}{2-p}\right)^{k+1}$$

(2)

$$P(X_1 = 1 | X_2 = 0) = \frac{P(X_1 = 1, X_2 = 0)}{P(X_2 = 0)} = \frac{\frac{1}{2}\alpha p}{1 - \frac{\alpha p}{2-3p+p^2}}$$

4.(15 分) 设某电子产品的寿命服从如下分布:

$$F(x; \alpha, \beta) = \begin{cases} 1 - e^{-\frac{x-\alpha}{\beta}}, & x \geq \alpha \\ 0, & x < \alpha \end{cases}$$

现测得 n 个该电子产品的寿命为 $X_1, X_2, \dots, X_n$, 试求未知参数 α, β 的矩估计和极大似然估计.

Solution: 总体服从双参数指数分布 $\text{Exp}\left(\alpha, \frac{1}{\beta}\right)$, 其中 α 是位置参数, β 是尺度参数, 所以 $EX = \alpha +$

$\beta, \text{Var}(X) = \beta^2$, 所以令 $\begin{cases} \bar{x} = \alpha + \beta \\ s^2 = \beta \end{cases}$, 解得矩估计是

$$\begin{cases} \hat{\alpha}_M = \bar{x} - s \\ \hat{\beta}_M = s \end{cases}$$

样本的似然函数是

$$\begin{aligned} L(\alpha, \beta) &= \frac{1}{\beta^n} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \alpha)}{\beta}\right\} \mathbf{I}_{\{x_{(1)} \geq \alpha\}} \\ &= \frac{1}{\beta^n} e^{-\frac{n\bar{x}}{\beta}} e^{\frac{\alpha}{\beta}} \mathbf{I}_{\{x_{(1)} \geq \alpha\}} \end{aligned}$$

显然它是关于 α 在 $(-\infty, x_{(1)})$ 上的增函数, 于是 $\hat{\alpha}_L = x_{(1)}$ 是 α 的极大似然估计. 再求 β 的极大似然估计, 考虑将对数似然函数的偏导置零, 即

$$\frac{\partial \ln L(\alpha, \beta)}{\partial \beta} = -\frac{n}{\beta} + \frac{\sum_{i=1}^n (x_i - \alpha)}{\beta^2} = 0$$

解得 $\beta = \frac{1}{n} \sum_{i=1}^n (x_i - \alpha)$, 代入 $\hat{\alpha}_L = x_{(1)}$, 得 $\hat{\beta}_L = \bar{x} - x_{(1)}$ 是 β 的极大似然估计.

5.(10 分) 有一位市场调查员, 他感兴趣的是该地区成年人中购买某商品的比率 θ . 现他要事先确定需要访问多少顾客 (样本量 n) 才能使 $[\bar{x} - d, \bar{x} + d]$ 是 θ 的 0.95 置信区间? 其中 $\bar{x}$ 是样本中购买此种商品的顾客比例, d 是事先给定的常数. 又假如事先知道 $\theta < \theta_0 < \frac{1}{2}$, 会对其产生什么影响?

Solution: 这是茆诗松补充题. 利用正态近似, 有

$$P\left(\left|\sqrt{n} \frac{\bar{x} - \theta}{\sqrt{\theta(1-\theta)}}\right| < z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha,$$

反过来解得

$$\theta \in \left[\bar{x} - \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sqrt{\theta(1-\theta)}, \bar{x} + \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sqrt{\theta(1-\theta)}\right],$$

因此 d 一定要比 $\frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sqrt{\theta(1-\theta)}$ 还大才行, 所以也要比右侧的最大值大, 考虑到二次函数

$$x(1-x) \leq \frac{1}{4}, \quad \text{当 } x = 1/2 \text{ 时取等,}$$

因此有

$$d \geq \frac{z_{1-\frac{\alpha}{2}}}{2\sqrt{n}},$$

解得 $n \geq \left(\frac{z_{1-\frac{\alpha}{2}}}{2d}\right)^2$.

再考虑如果已经有 $\theta \leq \theta_0 < \frac{1}{2}$ 的条件, 那么二次函数的最大值就是

$$\theta(1-\theta) \leq \theta_0(1-\theta_0)^2,$$

因此有

$$d \geq \frac{z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sqrt{\theta_0(1-\theta_0)},$$

解得 $n > \theta_0(1-\theta_0) \left(\frac{z_{1-\frac{\alpha}{2}}}{d}\right)^2$.

6.(10 分) 有来自总体 $\mathcal{U}(0, \theta)$ 的简单随机样本 $X_1, X_2, \dots, X_n$, 试求 θ 的 $1-\alpha$ 水平区间估计.

Solution: 以 $T = \frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$ 为枢轴量, 令 $P\left(a < \frac{X_{(n)}}{\theta} < b\right) = 1 - \alpha$, 容易解得 $1 - \alpha$ 置信区间为

$$\left[X_{(n)}, \alpha^{-\frac{1}{n}} X_{(n)}\right].$$

7.(10 分) 对于总体 $f(x) = \theta x^{\theta-1}, 0 < x < 1$ 的两个随机样本 X_1, X_2 , 考虑假设检验问题:

$$H_0: \theta = 1 \text{ vs } H_1: \theta = 2$$

对检验 $g(x_1, x_2) = \begin{cases} 1, & x_1 x_2 > \frac{3}{4} \\ 0, & \text{其他} \end{cases}$, 试求出其势函数以及两类错误的概率.

Solution:

先求势函数,

$$\beta_g(1) = P\left(X_1 X_2 > \frac{3}{4} \mid \theta = 1\right) = \iint_{\{x_1 x_2 > \frac{3}{4}\}} dx_1 dx_2 = \frac{1}{4} + \frac{3}{4} \ln \frac{3}{4},$$

$$\beta_g(2) = P\left(X_1 X_2 > \frac{3}{4} \mid \theta = 2\right) = \iint_{\{x_1 x_2 > \frac{3}{4}\}} 4x_1 x_2 dx_1 dx_2 = \frac{7}{16} + \frac{9}{8} \ln \frac{3}{4},$$

所以两类错误概率分别是

$$\alpha = \frac{1}{4} + \frac{3}{4} \ln \frac{3}{4}, \quad \beta = \frac{9}{16} - \frac{9}{8} \ln \frac{3}{4}.$$

8.(10 分) $X_1, X_2, \dots, X_n$ 是来自期望为 θ 的指数分布总体的随机样本. 试求 θ 的 UMVUE.

Solution: 全体样本的联合分布为

$$f(x_1, \dots, x_n) = \lambda^{-n} \exp \left\{ \frac{1}{\lambda} \sum_{i=1}^n X_i \right\}$$

它是一个完备指数族分布, 故统计量 $T = \sum_{i=1}^n X_i$ 是参数 λ 的充分完备统计量, 而 $E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \cdot n \cdot EX_1 = \lambda$. 即 $\bar{X}$ 是 λ 的无偏估计. 根据 Lehmann-Scheffe 定理, 知 $\bar{X}$ 是 λ 的 UMVUE.

南开大学-432 统计学-2023 年

一、选择题 (每题 4 分, 共 28 分) 1. 离散型随机变量 X 可能的取值是 0, 2, 3, 且 $P(X=0)=0.3, P(X=2)=0.1, P(X=3)=0.6$, 令 $Y=3(X-1)^2$, 则 $E(Y)=()$

- (a) 8.4
- (b) 6
- (c) 4
- (d) 7.2

Solution: A

先计算 Y 的分布列, 有 $P(Y=3)=0.4, P(Y=12)=0.6$, 则 $EY=3 \cdot 0.4+12 \cdot 0.6=8.4$.

2. $X_1, X_2, \dots, X_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的简单随机样本, 记 $S_1^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, $S_2^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, 则以下结论不正确的是 ()

- (a) S_2 是 σ 的 MLE
- (b) S_1^2 是 σ^2 的相合估计
- (c) S_2^2 是 σ^2 的相合估计
- (d) $\frac{\sqrt{n-1}(\bar{X}-\mu)}{S_1} \sim t(n-1)$

Solution: D

D 项应改为 $\frac{\sqrt{n}(\bar{X}-\mu)}{S_1} \sim t(n-1)$.

3. 对于下述两个命题, 命题 A: $\hat{\theta}$ 是 θ 的有效估计; 命题 B: $\hat{\theta}$ 是 θ 的 UMVUE. 下列结论正确的是 ()

- (a) $A \Leftrightarrow B$
- (b) $A \Rightarrow B, B \nRightarrow A$
- (c) $A \nRightarrow B, B \Rightarrow A$
- (d) $A \nRightarrow B, B \nRightarrow A$

Solution: B

如果有效估计存在, 说明 C-R 不等式成立, 且有效估计的方差达到 C-R 下界, 那么它一定是 UMVUE.

反之, 如果 $\hat{\theta}$ 是 UMVUE, 有可能 $\hat{\theta}$ 的方差达不到 C-R 下界, 也有可能 θ 的有效估计根本不存在 (例如 $U(0, \theta)$ 总体, C-R 不等式不成立).

4. 下面关于独立性的说法中, 错误的是 ()

- (A) 随机向量的边际分布可以确定其联合分布
- (B) 随机变量 X, Y 独立当且仅当 $\varphi_X(t_1)\varphi_Y(t_2) = \varphi_{(X,Y)}(t_1, t_2)$, 其中 $\varphi_X(t_1), \varphi_Y(t_2), \varphi_{(X,Y)}(t_1, t_2)$ 分别是 X, Y 各自的特征函数以及它们的联合特征函数
- (c) 独立一定不相关
- (D) 对于二元正态分布而言, 其分量之间相互独立的充要条件是不相关

Solution: A

以二元随机变量为例, 边际分布 + 条件分布才能确定联合分布, 两个边际分布无法确定联合分布.

5. 在进行两总体 t 检验时, 在 $\alpha = 0.05$ 的显著性水平下拒绝了原假设, 则两总体均值相等的概率是 ()

- (a) $\frac{1}{19}$
- (b) $\frac{1}{20}$
- (c) $\frac{1}{18}$
- (d) 无法确定

Solution: B

显著性水平衡量了拒真概率, 即原假设 ($\mu_1 = \mu_2$) 为真, 但由于样本随机性导致样本落入拒绝域, 故原假设为真的概率恰是显著性水平 0.05.

6. 已知 X 的密度函数 $f(x)$ 是偶函数, 设 $F(x)$ 是其分布函数, 则对于正数 a , 下列说法正确的是 ()

- (a) $F(-a) + \frac{1}{2} = F(a)$
- (b) $F(-a) = 1 - F(a)$
- (c) $F(-a) + \frac{1}{4} = F(a)$
- (d) $F(a) + F(-a) = 0$

Solution: B

根据对称性, 有 $F(-a) = \int_{-\infty}^{-a} f(t) dt = \int_a^{+\infty} f(t) dt$, 而 $F(a) = \int_{-\infty}^a f(t) dt$, 故

$$F(-a) + F(a) = \int_{-\infty}^{\infty} f(t) dt = 1.$$

7. 下列说法不正确的是 ()

- (a) $X \sim N(0, 1)$, 则其特征函数 $\varphi(t) = e^{-\frac{t^2}{2}}$
- (b) 伽马分布不具有可加性
- (c) 若 $X_n + Y_n \xrightarrow{P} X + Y$
- (d) 均匀分布 $U(0, \theta)$ 不是指数族分布

Solution: B

伽马分布具有可加性.

二、填空题 (每题 4 分, 共 32 分)

1. 一位作家共有 p 本作品, p 本作品成套出售, 现将 n 套作品 (共 np 本) 打乱成 n 堆, 每堆都有 p 本, 则每堆作品都恰是一套作品的概率是 _____.

Solution: $\frac{(n!)^p (p!)^n}{(np)!}$

全体样本点是一个全排列, 即 $\#\Omega = (np)!$. 有利样本点可以按如下方式考虑: 我们先分配每一套作品的第一本书, 这 n 个第一本书可以随机地分配到任意一堆中, 此时排列数为 $n!$; 对于每一套作品的第二本书, 排列数也是 $n!$; 以此类推, 总计有 $(n!)^p$ 种排列数. 而每一堆书的内部 p 本书也可进行排列, 即 $(p!)^n$. 根据乘法原理总的有利样本点数是 $\#A = (n!)^p (p!)^n$.

1. 掷两枚骰子, 记事件 A 为“两枚骰子的点数和是 3”, 事件 B 为“至少掷出 1 个 1”, 则概率 $P(A | B) =$ _____.

Solution: $\frac{2}{11}$

利用条件概率公式 $P(A | B) = \frac{P(AB)}{P(B)}$, 其中 $P(B) = \frac{6+5}{6 \cdot 6} = \frac{11}{36}$, 而事件 AB 等价于“掷出 1 和 2”, 因此 $P(AB) = \frac{2}{36}$. 综上所述

$$P(A | B) = \frac{P(AB)}{P(B)} = \frac{2}{11}.$$

3. 现有 n 个不同的球, 分别标号为 $1, 2, \dots, n$, 进行有放回取球, 则抽出 r 种不同球时所用的平均次数是 _____.

Solution: $\sum_{k=1}^r \frac{n}{n-k+1}$

用 X_k 表示“现已经抽到 $k-1$ 个不同的球, 直至抽出一个新球所需的次数” ($k = 1, \dots, r$), 则显然有 $X_k \sim Ge\left(\frac{n-k+1}{n}\right)$, 题目中提及的抽出 r 种不同球时所用的次数可写作

$$Y = \sum_{k=1}^r X_k,$$

因此 $EY = \sum_{k=1}^r EX_k = \sum_{k=1}^r \frac{n}{n-k+1}$.

4. 随机变量 X, Y 独立, 皆服从标准正态分布 $N(0, 1)$, 则 $E[\max\{X, Y\}] =$ _____.

Solution: $\frac{1}{\sqrt{\pi}}$

记 $Z = \max\{X, Y\}$, 根据最大值分布的结论, Z 的密度函数是

$$f_Z(z) = 2\Phi(z)\varphi(z),$$

其中 Φ 与 φ 分别是标准正态分布的分布函数与密度函数, 因此 $EZ = \int_{-\infty}^{\infty} z2\Phi(z)\varphi(z)dz$, 注意到其中 $z\varphi(z) = -\varphi'(z)$, 因此用分部积分法

$$\begin{aligned} EZ &= \int_{-\infty}^{\infty} z2\Phi(z)\varphi(z)dz = -2\Phi(z)\varphi(z)|_{-\infty}^{\infty} + 2\int_{-\infty}^{\infty} [\varphi(z)]^2 dz \\ &= 0 + 2\int_{-\infty}^{\infty} \frac{1}{2\pi} e^{-x^2} dx = \frac{1}{\sqrt{\pi}} \end{aligned}$$

5. 设总体 $X \sim U(0, \theta)$, 现从该总体中抽取容量为 10 的样本, 样本值为:

0.5 1.3 0.6 1.7 2.2 1.2 0.8 1.5 2.0 1.6

则参数 θ 的矩估计是 _____.

Solution: 2.68 $EX = \frac{\theta}{2}$, 所以 θ 的矩估计是 $2\bar{X} = 2 \cdot 1.34 = 2.68$.

6. 有来自 $N(\mu, \sigma^2)$ 的 n 个随机样本 $x_1, \dots, x_n$, μ, σ 未知, $\bar{x}$ 和 s^2 是样本均值和样本方差, 则 μ 的 $1 - \alpha$ 置信区间是 _____.

Solution: $\bar{x} \pm \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)$

7. 随机变量 $X \sim B(N, p)$, 其中 N 已知, 则参数 p 的 Fisher 信息量是 _____.

Solution: $\frac{N}{p(1-p)}$

根据定义, $I(p) = -E\left[\frac{\partial^2 \log f(X;p)}{\partial p^2}\right]$, 而其中

$$\log f(X;p) = \log C_N^X + X \log p + (N-X) \log(1-p)$$

于是

$$\begin{aligned} I(p) &= -E\left[\frac{\partial^2 \log f(X;p)}{\partial p^2}\right] = -E\left[-\frac{X}{p^2} - \frac{N-X}{(1-p)^2}\right] \\ &= -\left(-\frac{Np}{p^2} - \frac{N-Np}{(1-p)^2}\right) \\ &= \frac{N}{p} + \frac{N}{1-p} = \frac{N}{p(1-p)}. \end{aligned}$$

8. 随机变量 X 的取值范围是 $[0, 1]$, 则 $\text{Var}(X)$ 最多不超过 _____.

Solution: $\frac{1}{4}$

利用经典结论 $\text{Var}(X) \leq E(X-c)^2$, 其中我们取 $c = \frac{1}{2}$, 则

$$\text{Var}(X) \leq E\left(X - \frac{1}{2}\right)^2 \leq E\left(1 - \frac{1}{2}\right)^2 = \frac{1}{4}.$$

下面再说明该上界是紧的, 只需说明存在符合题意的随机变量, 其方差是 $\frac{1}{4}$. 考虑两点分布 $X \sim b(1, \frac{1}{2})$, 则 $\text{Var}(X) = \frac{1}{4}$.

三、解答题 (90 分)

1. (10 分) 随机向量 (X, Y) 的联合密度函数是 $f(x, y) = x + y, 0 < x, y < 1$.

(1) 求 (X, Y) 的联合分布函数 $F(x, y)$;

(2) 求 X, Y 各自的边际密度函数;

(3) 判断 X, Y 是否独立.

Solution:

(1) 对于 $0 \leq x, y < 1$, 有

$$F(x, y) = \int_0^x du \int_0^y (u+v) dv = \frac{x^2 y + xy^2}{2},$$

对于 $0 \leq x < 1, y \geq 1$, 有 $F(x, y) = \frac{x^2 + x}{2}$;

对于 $0 \leq y < 1, x \geq 1$, 有 $F(x, y) = \frac{y^2 + y}{2}$;

对于 $x, y \geq 1$, 有 $F(x, y) = 1$.

综上所述,

$$F(x, y) = \begin{cases} \frac{x^2 y + xy^2}{2}, & 0 \leq x, y < 1, \\ \frac{x^2 + x}{2}, & 0 \leq x < 1, y \geq 1, \\ \frac{y^2 + y}{2}, & 0 \leq y < 1, x \geq 1, \\ 1, & x \geq 1, y \geq 1, \\ 0, & \text{其他.} \end{cases}$$

(2) 计算得 X 的边际密度函数

$$f_X(x) = \int_0^1 (x+y) dy = x + \frac{1}{2}, \quad 0 < x < 1$$

同理有 Y 的边际密度函数

$$f_Y(y) = \int_0^1 (x+y) dx = y + \frac{1}{2}, \quad 0 < y < 1$$

(3) 由于 $f_X(x)f_Y(y) \neq f(x, y)$, 故 X 和 Y 不独立.

2.(10 分) $X_1, X_2, \dots, X_n$ 是来自总体密度函数为

$$f(x) = (a+1)x^a, \quad 0 < x < 1.$$

的简单随机样本, 试求 a 的矩估计与 MLE.

Solution: 可以看出总体是贝塔分布 $Beta(a+1, 1)$, 因此 $EX = \frac{a+1}{a+2}$, 由替换原理得 $\hat{a}_M = \frac{1-2\bar{X}}{\bar{X}-1}$ 是 a 的矩估计.

样本的似然函数是

$$L(a) = (a+1)^n \left(\prod_{i=1}^n X_i \right)^a$$

对数似然函数

$$\ell(a) = n \log(a+1) + a \sum_{i=1}^n \log X_i$$

关于参数求偏导置 0, 有

$$\frac{\partial \ell}{\partial a} = \frac{n}{a+1} + \sum_{i=1}^n \log X_i = 0,$$

解得 $\hat{a}_L = -\frac{n}{\sum_{i=1}^n \log X_i} - 1$ 是 a 的 MLE.

3.(15 分) $X_1, X_2, \dots, X_n$ 是来自总体 $U(0, \theta)$ 的简单随机样本, 则

(1) 证明 $U = \frac{n+1}{n} X_{(n)}$ 与 $V = 2\bar{X}$ 均为 θ 的无偏估计;

(2) 判断并说明 U 与 V 二者谁更有效.

Solution:

(1) 由于 $\frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$, 故 $EX_{(n)} = \frac{n}{n+1}\theta$, 所以 $EU = \frac{n+1}{n} \cdot \frac{n}{n+1}\theta = \theta$.

而 $EV = 2E\bar{X} = 2EX = 2 \cdot \frac{\theta}{2} = \theta$.

所以 U, V 都是 θ 的无偏估计.

(2) 比较二者的方差, 由于 $\frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$, 所以 $\text{Var}(X_{(n)}) = \frac{n}{(n+1)^2(n+2)}\theta^2$, 因此

$$\text{Var}(U) = \frac{(n+1)^2}{n^2} \cdot \frac{n}{(n+1)^2(n+2)}\theta^2 = \frac{\theta^2}{n(n+2)}$$

而

$$\text{Var}(V) = 4\text{Var}(\bar{X}) = \frac{4}{n}\text{Var}(X) = \frac{4}{n} \cdot \frac{1}{12}\theta^2 = \frac{\theta^2}{3n}$$

所以 U 更有效.

4.(10 分) 已知随机序列 $X_n \xrightarrow{L} X$ 以及 $Y_n \xrightarrow{P} a$, 证明: $X_n + Y_n \xrightarrow{L} X + a$.

Solution:

5.(10 分) 为判断一枚骰子是否均匀, 掷 120 次, 得到的结果如下表:

1	2	3	4	5	6
x	20	20	20	20	$40-x$

则当 x 的值为多少时, 可以认为骰子是均匀的?

Solution:

利用卡方拟合优度检验, 当前情况下的卡方统计量是

$$\chi^2 = \sum_{i=1}^6 \frac{(N_i - 20)^2}{20} = \frac{(x - 20)^2}{10}$$

在原假设成立时 (即认为骰子是均匀的), 有 $\chi^2 \sim \chi^2(5)$, 我们在 $\chi^2 \leq \chi_{0.95}^2(5) = 11.07$ 时接受原假设, 因此

令

$$\frac{(x - 20)^2}{10} \leq 11.07$$

解得 $x \in 20 \pm \sqrt{110.7}$. 而 $\sqrt{110.7} = 10.5214$, 考虑到 x 是整数, 因此 x 的取值范围是 $\{10, 11, 12, \dots, 30\}$.

6.(10 分) 某住宅楼调查住户是否愿意安装电梯, 假设住户中愿意安装电梯的比例是 p ,

(1) 若 $p = 0.5$, 试用中心极限定理估计事件 $A =$ "25 位居民中至少有 14 位愿意安装电梯" 发生的概率;

(2) 若 p 未知, 调查得到居民中愿意安装电梯的比例是 $\bar{X}_n$, 且要求 p 的 90% 置信区间包含在 $[\bar{X}_n - 0.01, \bar{X}_n + 0.01]$ 中, 试求样本量 n .

Solution:

(1) 用 X 表示 25 位居民中愿意安装电梯的人数, 则 $X \sim B(25, 0.5)$, 则

$$\begin{aligned} P(X \geq 14) &= P\left(\frac{X - 12.5}{\sqrt{25 \cdot 0.25}} \geq \frac{14 - 12.5}{\sqrt{25 \cdot 0.25}}\right) \\ &= P\left(\frac{X - 12.5}{\sqrt{25 \cdot 0.25}} \geq \frac{1.5}{2.5}\right) \approx 1 - \Phi\left(\frac{3}{5}\right), \end{aligned}$$

其中 Φ 是标准正态分布的分布函数.

(2) 根据中心极限定理以及 Slutsky 定理, 有渐近枢轴量

$$\frac{\sqrt{n}(\bar{X} - p)}{\sqrt{\bar{X}(1 - \bar{X})}} \rightarrow N(0, 1)$$

故参数 p 的近似 90% 水平置信区间是

$$\bar{X} \pm \frac{\sqrt{\bar{X}(1 - \bar{X})}}{\sqrt{n}} z_{0.95}.$$

其中 $\bar{X}(1 - \bar{X}) \leq \frac{1}{4}$, 故令 $\frac{1/2}{\sqrt{n}} z_{0.95} \leq 0.01$, 解得

$$n \geq (50 \cdot 1.645)^2 = 82.25^2 = 6765.06.$$

故 n 至少是 6766.

7.(15 分) 现有 100 个来自总体 $N(\mu, 4)$ 的简单随机样本 $X_1, X_2, \dots, X_{100}$, 对于假设检验问题

$$H_0: \mu = 3 \text{ vs } H_1: \mu \neq 3,$$

(1) 给出显著性水平 $\alpha = 0.05$ 下的拒绝域;

(2) 求 $\mu = 3.5$ 时的第二类错误;

(3) 当 $\mu = 4$ 时, 当样本量增加为 n 且 $n \rightarrow \infty$ 时, 证明检验的功效 $\rightarrow 1$.

Solution:

(1) 检验统计量 $z = \frac{10(\bar{X}-3)}{2}$, 在原假设成立时它是标准正态分布.

拒绝域是

$$W = \{|z| \geq z_{1-\frac{\alpha}{2}}\} = \{|z| \geq z_{0.975}\} = \{|z| \geq 1.96\}$$

(2) 先求此时的功效, 有

$$\begin{aligned} \rho(3.5) &= P_{\mu=3.5} \left(\left| \frac{10(\bar{X}-3)}{2} \right| \geq z_{0.975} \right) \\ &= P_{\mu=3.5} \left(\frac{10(\bar{X}-3)}{2} \geq z_{0.975} \right) + P_{\mu=3.5} \left(\frac{10(\bar{X}-3)}{2} \leq -z_{0.975} \right) \\ &= P_{\mu=3.5} \left(\bar{X} - 3.5 \geq \frac{1}{5} z_{0.975} - \frac{1}{2} \right) + P_{\mu=3.5} \left(\bar{X} - 3.5 \leq -\frac{1}{5} z_{0.975} - \frac{1}{2} \right) \\ &= P_{\mu=3.5} \left(\frac{10(\bar{X}-3.5)}{2} \geq z_{0.975} - \frac{5}{2} \right) + P_{\mu=3.5} \left(\frac{10(\bar{X}-3.5)}{2} \leq -z_{0.975} - \frac{5}{2} \right) \\ &= 1 - \Phi \left(z_{0.975} - \frac{5}{2} \right) + \Phi \left(-z_{0.975} - \frac{5}{2} \right). \end{aligned}$$

则第二类错误的概率是 $\beta(3.5) = 1 - \rho(3.5) = \Phi \left(z_{0.975} - \frac{5}{2} \right) - \Phi \left(-z_{0.975} - \frac{5}{2} \right)$.

(3) 这时候检验统计量变为 $z = \frac{\sqrt{n}(\bar{X}-3)}{2}$, 拒绝域不变. 类似地有

$$\begin{aligned}\rho(4) &= P_{\mu=4} \left(\left| \frac{\sqrt{n}(\bar{X}-3)}{2} \right| \geq z_{0.975} \right) \\ &= P_{\mu=4} \left(\frac{\sqrt{n}(\bar{X}-3)}{2} \geq z_{0.975} \right) + P_{\mu=4} \left(\frac{\sqrt{n}(\bar{X}-3)}{2} \leq -z_{0.975} \right) \\ &= P_{\mu=4} \left(\bar{X} - 4 \geq \frac{2}{\sqrt{n}} z_{0.975} - 1 \right) + P_{\mu=3.5} \left(\bar{X} - 4 \leq -\frac{2}{\sqrt{n}} z_{0.975} - 1 \right) \\ &= P_{\mu=4} \left(\frac{\sqrt{n}(\bar{X}-4)}{2} \geq z_{0.975} - \sqrt{n} \right) + P_{\mu=4} \left(\frac{\sqrt{n}(\bar{X}-4)}{2} \leq -z_{0.975} - \sqrt{n} \right) \\ &= 1 - \Phi(z_{0.975} - \sqrt{n}) + \Phi(-z_{0.975} - \sqrt{n}) \rightarrow 1\end{aligned}$$

8.(10 分) $X_1, X_2, \dots, X_n$ 是来自总体瑞利分布总体的简单随机样本, 总体的密度函数是

$$f(x) = \frac{1}{\theta^2} x e^{-\frac{x^2}{2\theta^2}}, x > 0,$$

试求 θ 的 UMVUE.

Solution:

样本的联合分布是

$$f(x_1, \dots, x_n; \theta) = \theta^{-2n} \left(\prod_{i=1}^n x_i \right) e^{-\frac{1}{2\theta^2} \sum_{i=1}^n x_i^2},$$

它是一个完备的单参数指数族分布, 参数 θ 的充分完备统计量是 $T = \sum_{i=1}^n x_i^2$.

先求 $Y_i = X_i^2$ 的分布, 容易算得其密度函数是

$$f_Y(y) = \frac{1}{2\theta^2} e^{-\frac{y}{2\theta^2}}, y > 0,$$

即期望为 $2\theta^2$ 的指数分布 $Exp(\frac{1}{2\theta^2})$, 因此 $T = \sum_{i=1}^n Y_i \sim Gamma(n, \frac{1}{2\theta^2})$. 所以

$$\begin{aligned}E\sqrt{T} &= \int_0^{+\infty} \sqrt{t} \frac{\left(\frac{1}{2\theta^2}\right)^n}{(n-1)!} t^{n-1} e^{-\frac{t}{2\theta^2}} dt \\ u &= \frac{t}{2\theta^2} \sqrt{2\theta^2} \int_0^{+\infty} \frac{1}{(n-1)!} u^{n-\frac{1}{2}} e^{-u} du \\ &= \frac{\sqrt{2}\Gamma(n+\frac{1}{2})}{(n-1)!} \theta.\end{aligned}$$

故 $\frac{(n-1)!}{\sqrt{2}\Gamma(n+\frac{1}{2})} \sqrt{T}$ 是基于充分完备统计量给出的 θ 的无偏估计, 根据 L-S 定理知它是 θ 的 UMVUE.

南开大学-432 统计学-2024 年

一、(10 分) X_1, X_2 独立同服从 $N(0, \sigma^2)$, 求 $\left(\frac{X_1+X_2}{X_1-X_2}\right)^2$ 的分布.

Solution: 注意到 $Y_1 = X_1 + X_2$ 与 $Y_2 = X_1 - X_2$ 都服从 $N(0, 2\sigma^2)$, 故 $\frac{Y_1^2}{2\sigma^2} \sim \chi^2(1)$, $\frac{Y_2^2}{2\sigma^2} \sim \chi^2(1)$. 同时 $Cov(Y_1, Y_2) = Cov(X_1 + X_2, X_1 - X_2) = 0$, 故它们独立. 因此有

$$\left(\frac{X_1 + X_2}{X_1 - X_2}\right)^2 = \frac{Y_1^2/2\sigma^2}{Y_2^2/2\sigma^2} \sim F(1, 1).$$

二、(15 分) 甲乙打飞机, 甲命中率 0.9, 乙命中率 0.8. 飞机被命中一次则有 70% 概率被击落, 被命中两次则一定被击落.

(1) (3 分) 求飞机被击落概率.

(2) (4 分) 若已知飞机被击落, 求它是被一发炮弹击落的概率.

(3) (4 分) 若已知飞机被击中, 求它被击落的概率.

(4) (4 分) 若已知飞机被击中, 求它被甲中的概率.

Solution: (1) $P(\text{被击落}) = 0.9 \times (1 - 0.8) \times 0.7 + 0.8 \times (1 - 0.9) \times 0.7 + 0.9 \times 0.8 \times 1 = 0.902$.

(2) $P(\text{一发击落}|\text{被击落}) = \frac{P(\text{一发击落} \cap \text{被击落})}{P(\text{被击落})} = \frac{0.9 \times (1 - 0.8) \times 0.7 + 0.8 \times (1 - 0.9) \times 0.7}{0.902} \approx 0.202$.

(3) $P(\text{被击落}|\text{被击中}) = \frac{P(\text{被击落} \cap \text{被击中})}{P(\text{被击中})} = \frac{0.902}{1 - (1 - 0.9) \times (1 - 0.8)} \approx 0.920$.

(4) $P(\text{被甲中}|\text{被击中}) = \frac{P(\text{被甲中} \cap \text{被击中})}{P(\text{被击中})} = \frac{0.9}{0.9 + 0.8 - 0.9 \times 0.8} \approx 0.918$.

三、(15 分) 设 $F(x) = P(\xi < x)$, 其中 ξ 是随机变量. 证明:

(1) (5 分) $F(x)$ 不减;

(2) (5 分) $F(x)$ 左连续;

(3) (5 分) $F(-\infty) = 0, F(+\infty) = 1$.

Solution: (1) 设 $x_1 < x_2$, 则 $\{\xi < x_1\} \subset \{\xi < x_2\}$, 因此 $F(x_1) = P(\xi < x_1) \leq P(\xi < x_2) = F(x_2)$.

(2) 设 a_n 是任一单调下降趋于 0 的序列, 则由概率的连续性,

$$\lim_{x \rightarrow x_0^-} F(x) = \lim_{n \rightarrow \infty} F(x_0 - a_n) = \lim_{n \rightarrow \infty} P(\xi < x_0 - a_n) = P\left(\lim_{n \rightarrow \infty} \{\xi < x_0 - a_n\}\right) = P(\xi < x_0) = F(x_0).$$

(3) 先考虑左侧极限, 有

$$F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = \lim_{n \rightarrow +\infty} F(-n) = \lim_{n \rightarrow +\infty} P(\xi < -n) = P\left(\lim_{n \rightarrow +\infty} \{\xi < -n\}\right) = P(\emptyset) = 0.$$

同理右侧极限是

$$F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = \lim_{n \rightarrow +\infty} F(n) = \lim_{n \rightarrow +\infty} P(\xi < n) = P\left(\lim_{n \rightarrow +\infty} \{\xi < n\}\right) = P(\Omega) = 1.$$

四、(15 分) 第一条路到火车站的时间是 $N(40, 10^2)$, 第二条路到火车站的时间是 $N(50, 4^2)$.

(1) (7 分) 距离火车出发还有 60 分钟, 走哪条路赶上的概率大?

(2) (8 分) 距离火车出发还有 45 分钟, 走哪条路赶上的概率大?

Solution: (1) $P(\text{赶上火车} | \text{第一条路}) = \Phi\left(\frac{60-40}{10}\right) \approx 0.977$, $P(\text{赶上火车} | \text{第二条路}) = \Phi\left(\frac{60-50}{4}\right) \approx 0.994$, 选第二条.

(2) $P(\text{赶上火车} | \text{第一条路}) = \Phi\left(\frac{45-40}{10}\right) \approx 0.691$, $P(\text{赶上火车} | \text{第二条路}) = \Phi\left(\frac{45-50}{4}\right) \approx 0.106$, 选第一条.

Remark: 有同学认为应该考虑 $X > 0$ 的概率, 这确实是题目设置问题, 但不影响最后结论.

五、(15 分) 设 $X_1, \dots, X_m$ 来自总体 $N(\mu_1, \sigma^2)$, $Y_1, \dots, Y_n$ 来自总体 $N(\mu_2, \sigma^2)$.

(1) (7 分) 求 (μ_1, μ_2, σ^2) 的 MLE;

(2) (8 分) 判断上述估计是否无偏.

Solution: (1) 这是联合样本方差估计问题, 结果是

$$\hat{\mu}_1 = \bar{X}, \quad \hat{\mu}_2 = \bar{Y}, \quad \hat{\sigma}^2 = \frac{1}{m+n} \left(\sum_{i=1}^m (X_i - \bar{X})^2 + \sum_{j=1}^n (Y_j - \bar{Y})^2 \right).$$

(2) $\hat{\mu}_1, \hat{\mu}_2$ 是无偏的, 但 $\hat{\sigma}^2$ 不是无偏的, 用自由度修正为 $\frac{m+n}{m+n-2} \hat{\sigma}^2$ 才是无偏的.

六、(15 分) 甲和乙独立地找书中错字, 甲找了 120 个, 乙找了 124 个, 重复的有 80 个, 试用矩法估计求:

(1) (7 分) 错字总数;

(2) (8 分) 未被找到的错字数.

Solution: (1) 设错字总数是 n , 甲找错字的个数是 $X \sim B(n, p_1)$, 乙找错字的个数是 $Y \sim B(n, p_2)$, 且它们独立. 这里根据题干可以看出 p_1 和 p_2 是十分接近的, 因此不妨认为 $p_1 = p_2 = p$ 以减少参数. 因此有 $E(X) = E(Y) = np$, $E(\frac{XY}{n}) = np^2$.

用样本代替总体, 有方程

$$\begin{cases} 122 = \hat{n}\hat{p}, \\ 80 = \hat{n}\hat{p}^2, \end{cases} \Rightarrow \begin{cases} \hat{p} = \frac{40}{61}, \\ \hat{n} = 186.05, \end{cases}$$

但考虑到 n 是整数, 我们修正为 $\hat{n} = 186$.

(2) 总计找到的错字个数是 $120 + 124 - 80 = 164$, 还剩 22 个.

七、(15 分) 考虑回归模型: $Y = 0.5 + \beta X^2 + \varepsilon$.

(1) (3 分) 给出 Gauss-Markov 条件.

(2) (12 分) 已知数据 $(x_1, y_1), \dots, (x_n, y_n)$, 请给出 β 的 lse (最小二乘估计), 并证明其是 lse.

Solution: (1) **Gauss-Markov 条件:** 1. 线性模型: 模型必须是线性的. 2. 随机抽样: 观测值必须是随机抽样得到的. 3. 无完全共线性: 解释变量之间不能存在完全共线性. 4. 零条件期望误差: 误差项的条件期望值为零. 5. 同方差性 (Homoscedasticity): 所有误差项具有相同的方差. 6. 无自相关: 误差项之间相互独立, 不存在自相关.

(2) $\hat{\beta} = \frac{\sum_{i=1}^n x_i^2 y_i - 0.5 \sum_{i=1}^n x_i^2}{\sum_{i=1}^n x_i^4}$ 是 lse, 下证明之: 残差平方和 (RSS) 为:

$$RSS = \sum_{i=1}^n (y_i - (0.5 + \beta x_i^2))^2,$$

对 β 求偏导并使其等于零:

$$\frac{d}{d\beta} RSS = -2 \sum_{i=1}^n x_i^2 (y_i - 0.5 - \beta x_i^2) = 0,$$

解这个方程, 得到 β 的 LSE:

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i^2 y_i - 0.5 \sum_{i=1}^n x_i^2}{\sum_{i=1}^n x_i^4}$$

二阶导数为:

$$\frac{d^2}{d\beta^2} RSS = 2 \sum_{i=1}^n x_i^4 > 0.$$

因此, 得到的 $\hat{\beta}$ 确实是最小二乘估计.

八、(15 分) 已知样本 $Y_1, \dots, Y_n$, 且 $E(Y) = \mu$, $Var(Y) = \sigma^2$, 定义 $Q(\mu) = \sum_{i=1}^n (Y_i - \mu)^2 + \alpha \mu^2$.

(1) (5 分) 请最小化 $Q(\mu)$ 得到 $\hat{\mu}$.

(2) (10 分) 证明: 若 $\alpha > 0$, (1) 中的估计量有偏. 在此条件下, 试找到 α 使得 $mse(\hat{\mu}) < mse(\bar{Y})$?

Solution: (1) 求导得 $Q'(\mu) = -\sum_{i=1}^n 2(Y_i - \mu) + 2\alpha\mu$, 令其为 0, 得 $\hat{\mu} = \frac{\sum_{i=1}^n Y_i}{n+\alpha}$.

(2) 直接求期望, 得到 $E(\hat{\mu}) = \frac{n}{n+\alpha}\mu = \mu - \frac{\alpha}{n+\alpha}\mu \neq \mu$, 有偏. 我们知道 $\text{mse}(\bar{Y}) = \frac{\sigma^2}{n}$, 而

$$\text{mse}(\hat{\mu}) = \frac{n\sigma^2}{(n+\alpha)^2} + \frac{\alpha^2\mu^2}{(n+\alpha)^2} = \frac{n\sigma^2 + \alpha^2\mu^2}{(n+\alpha)^2},$$

令分子 $n\sigma^2 + \alpha^2\mu^2 < (n+\alpha)^2\sigma^2/n$, 解得 $(n\mu^2 - \sigma^2)\alpha - 2n\sigma^2 < 0$.

现在我们发现, 如果 $\mu = 0$, 那么不等式成为 $-\sigma^2\alpha - 2n\sigma^2 < 0$, 这是恒成立的, 随意取 α 即可.

此外, 如 $\mu \neq 0$, 就有 $\mu^2 > 0$, 那么当 n 增大时, 一定有 $n\mu^2 - \sigma^2 > 0$, 则 $(n\mu^2 - \sigma^2)\alpha - 2n\sigma^2 < 0$ 意味着 $0 < \alpha < \frac{2n\sigma^2}{n\mu^2 - \sigma^2} \rightarrow \frac{2\sigma^2}{\mu^2}$. 这说明只要我们将 α 取在 $(0, \frac{2\sigma^2}{\mu^2})$ 之间, 当 n 足够大时, 一定有 $\text{mse}(\hat{\mu}) < \text{mse}(\bar{Y})$.

在实际操作时, 我们是不知道 μ 和 σ^2 的真实值的, 但是如果有预先的抽样、经验知识或理论依据提示我们 $\frac{2\sigma^2}{\mu^2}$ 大概在什么范围, 则我们将 α 取得比其小即可.

九、(15 分) 有来自总体 $U(0, \theta)$ 的随机样本 $X_1, \dots, X_n$.

(1) (8 分) 证明 $\hat{\theta}_1 = \frac{n+1}{n}X_{(n)}$ 和 $\hat{\theta}_2 = (n+1)X_{(1)}$ 无偏.

(2) (7 分) 请比较他们的方差.

Solution: (1) 利用 $U(0, 1)$ 次序统计量 $Y_{(k)} \sim Be(k, n+k-1)$ 的结论, 我们有 $E(X_{(n)}) = \frac{n}{n+1}\theta$, $E(X_{(1)}) = \frac{1}{n+1}\theta$, 因此题设给的两个估计量都是无偏的.

(2) 利用 Beta 分布方差结论, 有

$$\text{Var}(\hat{\theta}_1) = \frac{(n+1)^2}{n^2} \frac{n}{(n+1)^2(n+2)} \theta^2 = \frac{1}{n(n+2)} \theta^2,$$

$$\text{Var}(\hat{\theta}_2) = (n+1)^2 \frac{n}{(n+1)^2(n+2)} \theta^2 = \frac{n}{n+2} \theta^2,$$

因此 $\hat{\theta}_1$ 的方差小.

十、(20 分) 有来自总体 $N(\mu, 1)$ 的随机样本 $X_1, \dots, X_n$. 考虑假设检验

$$H_0: \mu = 2 \quad \text{vs} \quad H_1: \mu = 3.$$

拒绝域是 $W = \{\bar{x} \geq 2.6\}$.

(1) (7 分) 设 $n = 20$, 求 α, β (两类错误).

(2) (7 分) 若要求 $\beta \leq 0.01$, 求 n 的最小值.

(3) (6 分) $n \rightarrow \infty$ 时, 证明两类错误均收敛于 0.

Solution: (1) 计算两类错误, 有 $\alpha = P(\bar{X} \geq 2.6 | \mu = 2) = 1 - \Phi\left(\frac{2.6-2}{\frac{1}{\sqrt{20}}}\right) \approx 0.0036$, $\beta = P(\bar{X} < 2.6 | \mu = 3) = \Phi\left(\frac{2.6-3}{\frac{1}{\sqrt{20}}}\right) \approx 0.0368$.

(2) 找到满足 $\Phi\left(\frac{2.6-3}{\frac{1}{\sqrt{n}}}\right) \leq 0.01$ 的最小 n 值. 计算结果显示最小的 n 大约是 34.

(3) 当 $n \rightarrow \infty$ 时, $\bar{X} \xrightarrow{P} \mu$, 因此

$$\alpha = P(\bar{X} \leq 2.6 | \mu = 2) \leq P(|\bar{X} - 2| \leq 0.6 | \mu = 2) \rightarrow 0,$$

$$\beta = P(\bar{X} < 2.6 | \mu = 3) \leq P(|\bar{X} - 3| < 0.4 | \mu = 3) \rightarrow 0.$$

中山大学-432 统计学

中山大学-432 统计学-2016 年

一、选择题 (每小题 3 分, 共 60 分)

1. 随机事件 A, B, C 中恰有两个事件发生的复合事件为 ()

- (A) $(A \cap B) \cup (A \cap C) \cup (B \cap C)$
- (B) $\overline{A \cup B \cup C}$
- (C) $(A \cap B \cap \bar{C}) \cup (A \cap \bar{B} \cap C) \cup (\bar{A} \cap B \cap C)$
- (D) $(A \cap \bar{B} \cap \bar{C}) \cup (\bar{A} \cap \bar{B} \cap C) \cup (\bar{A} \cap B \cap \bar{C})$

Solution: C

A, B, C 中恰有两个不发生也就是 AB 发生 C 不发生或者 AC 发生 B 不发生或者 BC 发生 A 不发生, 因此选项 C 正确.

选项 A 表示: 三个事件至少有两个发生.

选项 B 表示: 三个事件都不发生

选项 D 表示: 三个事件中恰有一个事件发生

2. 假设随机事件 A, B 都既不是不可能事件也不是必然事件, 并且 $A \neq B, \bar{A} \neq \bar{B}$ 。包含随机事件 A, B 的最小的 σ 域中元素的个数为 ()

- (A) 4
- (B) 8
- (C) 16
- (D) 32

Solution: 无答案

考虑 $AB \neq \phi$, 则将 A, B 两个事件分解为互不相交的子事件 $\{AB, A\bar{B}, \bar{A}B, \bar{A}\bar{B}\}$, 它们是完备事件组, 只需考虑该四个事件的并运算, 分别取其中 0, 1, 2, 3, 4 个进行并集运算, 共有 $C_4^0 + C_4^1 + C_4^2 + C_4^3 + C_4^4 = 2^4 = 16$ 种情况. 若 $AB = \phi$, 则此时的完备事件组是 $\{A, B, \overline{A \cup B}\}$, 所以最小事件域中共有 $2^3 = 8$ 个元素.

3. 以下哪条是概率的公理化定义中要求的? ()

- (A) 有限可加性
- (B) 可列可加性
- (C) 上连续性
- (D) 下连续性

Solution: B

概率的公理性定义为非负性、规范性和可列可加性. 故选项 B 正确

4. 从 $(0, 1)$ 中独立随机地取两个数 b, c , 则方程 $x^2 + bx + c = 0$ 有实根的概率为 ()

- (A) $1/24$
- (B) $1/12$
- (C) $1/6$
- (D) $1/4$

Solution: B

方程有实根的充要条件为: $b^2 - 4ac \geq 0$, 该不等式成立的概率为函数 $y = \frac{x^2}{4}$ 与正方形 $[0, 1] \times [0, 1]$ 相交的下半部分面积, 该面积 $S = \int_0^1 \frac{x^2}{4} dx = \frac{1}{12}$, 故选项 B 正确

5. 下面哪个选项不是随机事件 $A, B (0 < P(A), P(B) < 1)$ 相互独立的充要条件 ()

- (A) $P(A | B) = P(A | \bar{B})$

$$(B) P(A | B) + P(\bar{A} | \bar{B}) = 1$$

$$(C) P(A \cap \bar{B}) = P(A)P(\bar{B})$$

$$(D) P(A | B) + P(A | \bar{B}) = 1$$

Solution: D

A 与 B 相互独立有 $P(AB) = P(A)P(B)$

选项 A:

$$\begin{aligned} \frac{P(AB)}{P(B)} &= \frac{P(A\bar{B})}{P(\bar{B})} \\ \Leftrightarrow P(AB)P(\bar{B}) &= P(A\bar{B}) \cdot P(B) \\ \Leftrightarrow P(AB) \cdot [1 - P(B)] &= [P(A) - P(AB)] \cdot P(B) \\ \Leftrightarrow P(AB) - P(AB)P(B) &= P(A)P(B) - P(AB)P(B) \\ \Leftrightarrow P(AB) &= P(A)P(B) \end{aligned}$$

选项 B:

$$\begin{aligned} P(A | B) + P(\bar{A} | \bar{B}) &= P(A | B) + 1 - P(A | \bar{B}) = 1 \\ P(A | B) &= P(A | \bar{B}) \end{aligned}$$

由选项 A 可知它是相互独立的充分必要条件

选项 C: 由独立的定义显然成立

选项 D:

$$\begin{aligned} P(A | B) + P(A | \bar{B}) &= P(A | B) + 1 - P(\bar{A} | \bar{B}) = 1 \\ P(A | B) &= P(\bar{A} | \bar{B}) \\ P(\bar{A}\bar{B})P(B) &= P(AB) \cdot P(\bar{B}) \end{aligned}$$

若 AB 独立, 上式化简得到: $P(A) = P(\bar{A})$, 不恒成立. 故选项 D 错误

6. 已知 $P(A) = 0.4, P(B) = 0.25, P(A - B) = 0.25$, 则 $P(A \cup B) = ()$

(A) 0.4

(B) 0.5

(C) 0.6

(D) 0.65

Solution: B

$$P(A - B) = P(A) - P(AB), \text{ 故 } P(AB) = P(A) - P(A - B) = 0.15$$

得到: $P(A \cup B) = P(A) + P(B) - P(AB) = 0.4 + 0.25 - 0.15 = 0.5$ 选项 B 正确

7. 到达银行的顾客分为两类, 一类是办理现金业务, 一类是办理非现金业务。假设在特定时间内这两类顾客的到达人数服从泊松分布, 并相互独立。已知平均每小时 5 个人办理现金业务, 2 个人办理非现金业务, 则在一个小时内没有人到达银行的概率为 ()

(A) e^{-2}

(B) e^{-5}

(C) e^{-7}

(D) e^{-14}

Solution: C

参数为 λ 的泊松分布的概率质量函数为: $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$ 由题可知一小时内办理现金业务和非现金业务的人数分别服从参数为 5 和 2 的泊松分布, 一小时内没人办理现金业务的概率为: $\frac{5^0}{0!} e^{-5} = e^{-5}$,

一小时内没人办理非现金业务的概率为: $\frac{2^0}{0!}e^{-2} = e^{-2}$, 且两件事件相互独立, 所以一小时内没有人到达银行的概率为 $e^{-5} \cdot e^{-2} = e^{-7}$, 选项 C 正确

8. 选择题有四个答案, 只有一个是正确的。懂的学生能够准确回答, 不懂的学生从中四个答案中随机选择。假定一个学生懂与不懂的概率都是 0.5, 则答对的学生对该题不懂的概率为 ()

- (A) 0.1
- (B) 0.2
- (C) 0.4
- (D) 0.5

Solution: B

$$P(\text{答对}) = P(\text{懂}) + P(\text{答对且不懂}) = 0.5 + 0.5 \cdot 0.25 = 0.625$$

所以 $P(\text{不懂} | \text{答对}) = \frac{P(\text{答对且不懂})}{P(\text{答对})} = \frac{0.125}{0.625} = 0.2$, 选项 B 正确

9. 设 $X \sim B(100, 0.2)$, 设 $\Phi(x)$ 为标准正态分布的累积分布函数, 则 $X > 28$ 的概率大约是 ()

- (A) $1 - \Phi(2)$
- (B) $1 - \Phi(1)$
- (C) $\Phi(2)$
- (D) $2\Phi(2) - 1$

Solution: A

根据中心极限定理

$$P(X > 28) = P\left(\frac{X - 20}{4} > \frac{28 - 20}{4}\right) = P\left(\frac{X - 20}{4} > 2\right) \approx 1 - \Phi(2)$$

10. 设 (X, Y) 服从三角形区域 $D = \{(x, y) : 0 < x < y < 1\}$ 上的均匀分布, 则

- (A) $Y | X$ 服从区间 $(0, 1)$ 上的均匀分布
- (B) Y 服从区间 $(0, 1)$ 上的均匀分布
- (C) $Y | X$ 服从区间 $(X, 1)$ 上的均匀分布
- (D) Y 服从区间 $(X, 1)$ 上的均匀分布

Solution: C

依题意可得: (X, Y) 的联合概率密度函数为:

$$f(x, y) = \begin{cases} 2, & (x, y) \in D \\ 0, & \text{else} \end{cases}$$

则 X 的边缘密度:

$$f_X(x) = \begin{cases} \int_x^1 2dy = 2(1-x) & (x, y) \in D \\ 0 & \text{其他} \end{cases}$$

Y 的边缘密度为: $f_Y(y) = \begin{cases} \int_0^y 2dx = 2y & (x, y) \in D \\ 0 & \text{其他} \end{cases}$ 所以 $f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)} = \frac{1}{1-x}, x < y < 1$, 故选项 C 正确

11. 设 $X_1, \dots, X_{10}$ 来自正态分布 $N(\mu, \sigma^2)$ 的样本, $\bar{X} = (X_1 + \dots + X_{10})/10$, 若 $Y = a\bar{X} + b \sim N(0, 1)$, 则 ()

- (A) $a = 0, b = 1$
- (B) $a = \sqrt{10}/\sigma, b = -\sqrt{10}\mu/\sigma$

(C) $a = 10/\sigma^2, b = -10\mu/\sigma^2$

(D) $a = 1/\sigma, b = -\mu$

Solution: B

依题意, $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{10}\right), Y \sim N\left(a\mu + b, \frac{a^2\sigma^2}{10}\right)$, 所以有:

$$\begin{cases} a\mu + b = 0 \\ \frac{a^2\sigma^2}{10} = 1 \end{cases}$$

解得: $a = \sqrt{10}/\sigma, b = -\sqrt{10}\mu/\sigma$, 选项 B 正确

12. 若 $X \sim N(0, 1), Y \sim \chi^2(n)$, 则 $t = X/\sqrt{Y/n}$ 的分布是 ()

(A) $t(n)$

(B) $N(0, 1)$

(C) $t(n-1)$

(D) 不能确定

Solution: D

根据题目条件无法得知 X 与 Y 是否独立, 因此无法判断 t 的分布.

13. 设 $X_i \sim N(i-1, i), i = 1, 2, 3$, 且 X_1, X_2, X_3 之间相互独立. 令 $\bar{X} = (X_1 + X_2 + X_3)/3, S^2 = \sum_{i=1}^3 (X_i - \bar{X})^2/2$, 则 ()

(A) $2S^2 \sum_{i=1}^3 \frac{1}{i} \sim \chi^2(2)$

(B) $\sum_{i=1}^3 \frac{(X_i - \bar{X})^2}{i} \sim \chi^2(2)$

(C) $\frac{X_1}{\sqrt{\frac{(X_2-1)^2}{4} + \frac{(X_3-2)^2}{6}}} \sim t(2)$

(D) $\frac{\bar{X}}{S/\sqrt{3}} \sim t(2)$

Solution: C

依题意得 $X_1 \sim N(0, 1), X_2 \sim N(1, 2), X_3 \sim N(2, 3)$ 所以 $\frac{X_2-1}{\sqrt{2}} \sim N(0, 1), \frac{X_3-2}{\sqrt{3}} \sim N(0, 1)$, 由 X_1, X_2, X_3 相互独立可知, $\frac{(X_2-1)^2}{2} + \frac{(X_3-2)^2}{3} \sim \chi^2(2)$ 则 $\frac{X_1}{\sqrt{\frac{(X_2-1)^2}{4} + \frac{(X_3-2)^2}{6}}} \sim t(2)$, 选项 C 正确

14. 设 $X_1, \dots, X_n$ 来自正态分布 $N(0, \sigma^2)$ 的简单随机样本, 则 σ^2 的最大似然估计为 ()

(A) $\sum_{i=1}^n X_i^2/n$

(B) $\sum_{i=1}^n (X_i - \bar{X})^2/n$

(C) $\sum_{i=1}^n X_i^2/(n-1)$

(D) $\sum_{i=1}^n (X_i - \bar{X})^2/(n-1)$

Solution: A

似然函数为 $L(\sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum_{i=1}^n x_i^2}{2\sigma^2}\right\}$, 将其取对数, 关于 σ^2 求导并置 0, 得到似然方程

$$\frac{\partial \ln L(\sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n x_i^2}{2\sigma^4} = 0$$

解得 $\hat{\sigma}^2 = \frac{\sum_{i=1}^n x_i^2}{n}$ 是 σ^2 的 MLE. 故选项 A 正确

15. 设 $X_1, \dots, X_{25}$ 为来自均匀分布 $U(\theta-1, \theta+1)$ 的简单随机样本, 其顺序统计量记为 $X_{(1)}, X_{(2)}, \dots, X_{(25)}$, 则下列统计量是 θ 的充分统计量的是 ()

(A) $X_{(1)}$

(B) $X_{(25)}$

(C) $(X_{(1)}, X_{(25)})$

(D) $X_{(13)}$

Solution: C

样本的联合密度函数为:

$$f(x_1, x_2, \dots, x_{25}; \theta) = \frac{1}{2^n} \mathbf{I}_{\{x_{(1)} > \theta - 1\}} \mathbf{I}_{\{x_{(25)} < \theta + 1\}}$$

根据因子分解定理, 可知 θ 的充分统计量为 $(x_{(1)}, x_{(25)})$, 故选项 C 正确

16. $X_1, \dots, X_n$ 为来自正态分布 $N(\mu, 1)$ 的简单随机样本。记 Z_α 为标准正态分布的 $100\alpha\%$ 分位数, 则由此样本所构造的置信水平分别为 95% 与 90% 的双侧置信区间长度之比为 ()

(A) $2 \times \frac{z_{0.975}}{z_{0.95}}$

(B) $\frac{z_{0.975}}{z_{0.95}}$

(C) $2 \times \frac{z_{0.95}}{z_{0.90}}$

(D) $\frac{z_{0.95}}{z_{0.90}}$

Solution: B

依题意得 $\sqrt{n}(\bar{x} - \mu) \sim N(0, 1)$, 所以令 $P(|\sqrt{n}(\bar{x} - \mu)| \leq d) = 1 - \alpha$ 可得置信区间的长度为: $2d = \frac{2z_{1-\frac{\alpha}{2}}}{\sqrt{n}}$ 因此 95% 与 90% 双侧置信区间长度之比为 $\frac{z_{0.975}}{z_{0.95}}$. 选项 B 正确

17. $X_1, \dots, X_n$ 为来自正态分布 $N(\mu, 1)$ 的简单随机样本。令 $\bar{X}$ 为其样本均值, 若 $(\bar{X} - C_\alpha, \bar{X} + C_\alpha)$ 为 μ 的 $1 - \alpha$ 水平的置信区间, 其中 $0 < \alpha < 1, C_\alpha > 0$ 为常数。若从总体 $N(\mu, 1)$ 中新增一独立样品 X_{n+1} , 则 X_{n+1} 落在此置信区间的概率 ()

(A) 等于 $1 - \alpha$

(B) 小于 $1 - \alpha$

(C) 大于 $1 - \alpha$

(D) 与 $1 - \alpha$ 的大小关系不能确定

Solution: B

我们知道 $\frac{\bar{X} - \mu}{\sqrt{\frac{1}{n}}} \sim N(0, 1)$, 因此有 $C_\alpha = \sqrt{\frac{1}{n}} z_{1-\alpha}$, 其中 $z_{1-\alpha}$ 是标准正态上 α 分位数。而 $\frac{\bar{X} - X_{n+1}}{\sqrt{1 + \frac{1}{n}}} \sim N(0, 1)$, 因此 X_{n+1} 的预测区间是

$$X_{n+1} \in \left(\bar{X} - \sqrt{1 + \frac{1}{n}} z_{1-\alpha}, \bar{X} + \sqrt{1 + \frac{1}{n}} z_{1-\alpha} \right),$$

可以看出, X_{n+1} 落入上面的区间的概率是 $1 - \alpha$, 而题设区间比这个区间窄的多, 故选择 B.

18. X_1, X_2, X_3 为来自正态分布 $N(0, \sigma^2)$ 的简单随机样本。记 $Q_1 = \sum_{i=1}^3 X_i^2, Q_2 = \sum_{i=1}^3 (X_i - \bar{X})^2, \chi_\alpha^2(r)$ 为自由度为 r 的 χ^2 分布的 $100\alpha\%$ 分位数, 则下面哪个不是 σ^2 的 95% 的置信区间 ()

(A) $\left(\frac{Q_1}{\chi_{0.975}^2(3)}, \frac{Q_1}{\chi_{0.025}^2(3)} \right)$

(B) $\left(\frac{n\bar{X}^2}{\chi_{0.975}^2(1)}, \frac{n\bar{X}^2}{\chi_{0.025}^2(1)} \right)$

(C) $\left(\frac{Q_2}{\chi_{0.975}^2(2)}, \frac{Q_2}{\chi_{0.025}^2(2)} \right)$

(D) $\left(0, \frac{Q_2}{\chi_{0.95}^2(2)} \right)$

Solution: D

注意这里 χ_α^2 指的是上分位数。选项 A: $\frac{Q_1}{\sigma^2} \sim \chi^2(3)$, A 正确选项 B: 由于 $\frac{\sqrt{n}\bar{X}}{\sigma} \sim N(0, 1)$, 则 $\frac{n\bar{X}^2}{\sigma^2} \sim \chi^2(1)$. B 正确选项 C: $\frac{Q_2}{\sigma^2} \sim \chi^2(2)$, C 正确选项 D 为 σ^2 的 5% 的置信区间, 错误

19. 在单因素方差中, $X_{k1}, X_{k2}, \dots, X_{kn} \sim N(\mu_k, \sigma^2), k = 1, 2, 3$, 且 $X_{11}, \dots, X_{1n}, X_{21}, \dots, X_{2n}, X_{31}, \dots, X_{3n}$ 之间相互独立, 令 $\bar{X}_k = \frac{1}{n} \sum_{i=1}^n X_{ki}, k = 1, 2, 3, \bar{X} = \frac{1}{3n} \sum_{k=1}^3 \sum_{i=1}^n X_{ki}$. 若 $\sigma^2 = 1$, 则 ()

(A) $\sum_{k=1}^3 \sum_{i=1}^n (X_{ki} - \bar{X})^2 \sim \chi^2(3n - 1)$

(B) $\sum_{k=1}^3 (\bar{X}_k - \bar{X})^2 \sim \chi^2(2)$

$$(C) \sum_{k=1}^3 n (\bar{X}_k - \bar{X})^2 \sim \chi^2(2)$$

$$(D) \sum_{k=1}^3 \sum_{i=1}^n (X_{ki} - \bar{X}_k)^2 \sim \chi^2(3n-3)$$

Solution: D

$$\sum_{i=1}^n (x_{ki} - \bar{x}_k)^2 \sim \chi^2(n-1)$$

又由卡方分布的可加性知 $\sum_{k=1}^3 \sum_{i=1}^n (x_{ki} - \bar{x}_k)^2 \sim \chi^2(3n-3)$, 故选 D.

20. 在简单线性回归中, 以下关于回归系数最小二乘估计叙述错误的是 ()

(A) 求解最小二乘估计并不需要误差项服从正态分布

(B) 最小二乘估计是无偏估计

(C) 最小二乘估计是最优线性无偏估计 (BLUE)

(D) 最小二乘估计是最小方差无偏估计 (MVUE)

Solution: D

当给定误差项的正态假设后, 最小二乘估计必定是最小方差无偏估计, 否则它只能是最优线性无偏估计.

二、(共 24 分) 设二维随机向量 (X, Y) 有密度

$$f(x, y) = \begin{cases} (1+xy)/4, & |x| < 1, |y| < 1 \\ 0, & \text{其他.} \end{cases}$$

(1) (8 分) 判断 X 和 Y 是否相互独立。

(2) (8 分) 求在 $Y = 0.5$ 的条件下随机变量 X 的条件密度。

(3) (8 分) 求 $Z = X + Y$ 的密度函数。

Solution: (1)

$$f_X(x) = \int_{-1}^1 f(x, y) dy = \int_{-1}^1 \frac{1+xy}{4} dy = \begin{cases} \frac{1}{2} & |x| < 1 \\ 0 & \text{其他} \end{cases}$$

同理 $f_Y(y) = \begin{cases} \frac{1}{2} & |y| < 1 \\ 0 & \text{其他} \end{cases}$ 由于 $f_X(x)f_Y(y) \neq f(x, y)$, 故 X 与 Y 不独立.

(2) X 关于的 Y 条件密度函数 $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} = \frac{1+xy}{2}$, $-1 < x < 1$ 则 $f_{X|Y}(x|y=0.5) = \frac{1}{2} + \frac{x}{4}$, $-1 < x < 1$

(3) 当 $z < -2$ 或 $z \geq 2$ 时, $f(z) = 0$. 当 $-2 \leq z < 0$ 时,

$$f(z) = \int_{-1}^{z+1} f(x, z-x) dx = \int_{-1}^{z+1} \frac{1+x(z-x)}{4} dx = \frac{1}{3} + \frac{z^3}{24}$$

当 $0 \leq z < 2$ 时,

$$f(z) = \int_{z-1}^1 f(x, z-x) dx = \int_{z-1}^1 \frac{1+x(z-x)}{4} dx = \frac{1}{3} - \frac{z^3}{24}$$

综上,

$$f(z) = \begin{cases} \frac{1}{3} + \frac{z^3}{24}, & -2 \leq z < 0 \\ \frac{1}{3} - \frac{z^3}{24}, & 0 \leq z < 2 \\ 0, & \text{其他} \end{cases}$$

三、(共 22 分) 设总体 X 的密度函数 $f(x) = 2\theta^{-2}x$, $(0 < x < \theta)$, $X_1, \dots, X_n (n > 3)$ 为其简单随机样本。

(1) (6 分) 求 θ 的最大似然估计量 $\hat{\theta}_1$ 。

(2) (6 分) 求 θ 的矩法估计量 $\hat{\theta}_2$ 。

(3) (10 分) 据 MSE (mean squared error) 准则, 请计算比较 $\hat{\theta}_1$ 与 $\hat{\theta}_2$ 的优劣。

Solution: (1) 似然函数为 $L(\theta) = 2^n \theta^{-2n} (\prod_{i=1}^n x_i) I_{\{\theta \geq x_{(n)}\}}$, 该函数是 θ 在 $[x_{(n)}, +\infty)$ 上的单调减函数, 故 θ 的 MLE 为 $\hat{\theta}_1 = x_{(n)}$ 。

(2)

$$E(X) = \int_0^\theta x f(x) dx = \int_0^\theta 2\theta^{-2} x^2 dx = \frac{2}{3}\theta$$

即 $\theta = \frac{3}{2}E(X)$, 由替换原理得 θ 的矩估计为 $\hat{\theta}_2 = \frac{3}{2}\bar{x}$ 。

(3) 对任意 $t \in (0, \theta)$, $P(x_{(n)} < t) = [P(X < t)]^n = \frac{t^{2n}}{\theta^{2n}}$. 故可求得 $x_{(n)}$ 的密度函数为 $f_n(t) = \begin{cases} \frac{2nt^{2n-1}}{\theta^{2n}}, & 0 < t < \theta \\ 0, & \text{其他} \end{cases}$,

由此可计算得

$$\begin{aligned} E(\hat{\theta}_1) &= \int_0^\theta \frac{2nt^{2n}}{\theta^{2n}} dt = \frac{2n\theta}{2n+1} \\ E(\hat{\theta}_1^2) &= \int_0^\theta \frac{2nt^{2n+1}}{\theta^{2n}} dt = \frac{n\theta^2}{n+1} \end{aligned}$$

故

$$\begin{aligned} \text{MSE}(\hat{\theta}_1) &= E(\hat{\theta}_1 - \theta)^2 = E(\hat{\theta}_1^2) - 2\theta E(\hat{\theta}_1) + \theta^2 \\ &= \frac{\theta^2}{(2n+1)(n+1)} \end{aligned}$$

而

$$\begin{aligned} E(X^2) &= \int_0^\theta 2\theta^{-2} x^3 dx = \frac{\theta^2}{2} \\ \text{Var}(X) &= E(X^2) - E^2(X) = \frac{\theta^2}{18} \end{aligned}$$

又因为 $E(\hat{\theta}_2) = \frac{3}{2}E(\bar{x}) = \frac{3}{2}E(X) = \theta$, 所以 $\hat{\theta}_2$ 是 θ 的无偏估计, 故

$$\begin{aligned} \text{MSE}(\hat{\theta}_2) &= \text{Var}(\hat{\theta}_2) \\ &= \frac{9}{4} \text{Var}(\bar{x}) = \frac{9}{4n} \text{Var}(X) = \frac{\theta^2}{8n} \end{aligned}$$

题设中 $n > 3$, 所以 $\frac{1}{(2n+1)(n+1)} - \frac{1}{8n} = \frac{-2n^2+5n-1}{8n(n+1)(2n+1)} < 0$, 故 $\text{MSE}(\hat{\theta}_1) < \text{MSE}(\hat{\theta}_2)$, 所以根据 MSE 准则 $\hat{\theta}_1$ 更优. 实际上, 也可以从阶数上直接判断出 $\hat{\theta}_1$ 更优.

四、(22 分) 设 $X_1, \dots, X_n (n \geq 3)$ 为来自伯努利分布 $B(1, p)$ 的样本, 已知 $T = X_1 + \dots + X_n$ 为参数 p 的充分统计量。

(1) (8 分) 求 p^2 的最大似然估计, 并说明该估计不是 p^2 的无偏估计。(需要写出详细推导过程)。

(2) (6 分) 令 $M = X_1 X_2$, 证明 M 是 p^2 的无偏估计。

(3) (8 分) 寻找 p^2 的最小方差无偏估计 (需要写出具体形式)。

Solution: (1) 似然函数 $L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}$, 取对数得

$$\ln L = \sum_{i=1}^n x_i \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1-p)$$

令 $\frac{d \ln L}{dp} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0$, 解得驻点 $\hat{p} = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}$, 由最大似然估计的不变性知 $\hat{p}^2 = \bar{x}^2$ 是 p^2 的

MLE. 因为

$$\begin{aligned} E(\bar{x}^2) &= \text{Var}(\bar{x}) + E^2(\bar{x}) \\ &= \frac{\text{Var}(X)}{n} + E^2(X) \\ &= \frac{p(1-p)}{n} + p^2 \\ &\neq p^2 \end{aligned}$$

故 $\hat{p}^2$ 不是 p^2 的无偏估计.

(2) 由于 $X_1 X_2$ 相互独立, 故 $E(X_1 X_2) = E(X_1) E(X_2) = p^2$, 所以 M 是 p^2 的无偏估计.

(3) 取 $T = n\bar{x}$, 则

$$\begin{aligned} E(M | T = t) &= P(X_1 X_2 = 1 | T = t) \\ &= \frac{P(x_1 = 1, x_2 = 1, \sum_{i=3}^n x_i = t-2)}{P(\sum_{i=1}^n x_i = t)} \\ &= \frac{p \cdot p \cdot \binom{n-2}{t-2} p^{t-2} (1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} \\ &= \frac{t(t-1)}{n(n-1)} \end{aligned}$$

由指数族性质知 T 是充分完全统计量, 根据重期望公式可知 $\hat{\theta} = \frac{T(T-1)}{n(n-1)}$ 是 p^2 的无偏估计, 由 Lehmann-Scheffe 定理, $\hat{\theta}$ 是 p^2 的 UMVUE.

五、(22 分) 总体 X 服从如下分布. $X_1, \dots, X_4$ 为其样本量为 4 的简单随机样本。

X	-1	0	1
P	θ	$1-2\theta$	θ

令 $T(X_1, \dots, X_4) = \sum_{i=1}^4 I(X_i = 0)$, 其中 I 为示性函数。针对假设

$$H_0: \theta = \frac{1}{3} \quad \text{v.s.} \quad H_1: \theta = \frac{1}{4}$$

构建拒绝域 $C \{(x_1, x_2, x_3, x_4) : T(x_1, x_2, x_3, x_4) > 2\}$ 。

(1) (12 分) 求此检验的第一类错误概率 α 与第二类错误概率 β 。

(2) (10 分) 请判断此检验是否为显著性水平为 α 时的最优检验 (most powerful test)。

Solution: (1)

$$\begin{aligned} \alpha &= P\left(T > 2 \mid \theta = \frac{1}{3}\right) \\ &= P\left(T = 3 \mid \theta = \frac{1}{3}\right) + P\left(T = 4 \mid \theta = \frac{1}{3}\right) \\ &= C_4^3 \cdot \left(1 - 2 \cdot \frac{1}{3}\right)^3 \cdot \frac{2}{3} + C_4^4 \cdot \left(1 - 2 \cdot \frac{1}{3}\right)^4 = \frac{1}{9} \\ \beta &= 1 - P\left(T > 2 \mid \theta = \frac{1}{4}\right) \\ &= 1 - P\left(T = 3 \mid \theta = \frac{1}{4}\right) - P\left(T = 4 \mid \theta = \frac{1}{4}\right) \\ &= 1 - C_4^3 \cdot \left(1 - 2 \cdot \frac{1}{4}\right)^3 \cdot \frac{2}{4} + C_4^4 \cdot \left(1 - 2 \cdot \frac{1}{4}\right)^4 = \frac{11}{16} \end{aligned}$$

(2) 利用 N-P 引理, 总体对应的密度函数是

$$f(x; \theta) = (1 - 2\theta)^{I_{\{x=0\}}} \theta^{1-I_{\{x=0\}}},$$

则样本对应的似然函数是

$$L(\theta) = \theta^4 e^{T[\ln(1-2\theta) - \ln \theta]},$$

其中 $T = \sum_{i=1}^4 I_{\{X_i=0\}}$ 是充分统计量. 则似然比是

$$\Lambda = \frac{L\left(\frac{1}{4}\right)}{L\left(\frac{1}{3}\right)} = \frac{\left(\frac{1}{4}\right)^4 e^{T\left(\ln \frac{1}{2} - \ln \frac{1}{4}\right)}}{\left(\frac{1}{3}\right)^4 e^{T\left(\ln \frac{1}{3} - \ln \frac{1}{3}\right)}} = \left(\frac{3}{4}\right)^4 e^{T\left(\ln \frac{1}{2} - \ln \frac{1}{4}\right)},$$

其中考虑到 $\left(\frac{3}{4}\right)^4 e^{T\left(\ln \frac{1}{2} - \ln \frac{1}{4}\right)}$ 是 T 的单调增函数, 又根据 NP 引理, UMP 检验的形式是

$$\{\Lambda > \lambda_0\} \Leftrightarrow \{T > c\},$$

其中令检验的显著性水平为 α , 可解得 $C = 2$. 故结论得证.

中山大学-432 统计学-2017 年

一、选择题 (每小题 3 分, 共 60 分)

1. 在概率的公理化结构中, 把概率所满足的条件中的可列可加性换成有限可加性, 则下列概率的性质中不成立的是 ()

- (A) $P(\emptyset) = 0$
- (B) 对任何事件 $A, P(\bar{A}) = 1 - P(A)$
- (C) S_n 是一个单调不减的集序列, $\lim_{n \rightarrow \infty} P(S_n) = P(\lim_{n \rightarrow \infty} S_n)$
- (D) $P(AB) \geq P(A) + P(B) - 1$

Solution: C

选项 A: $P(\Omega) = P(\Omega + \emptyset) = P(\Omega) + P(\emptyset) = 1$, 由概率正则性和非负性可知, $P(\emptyset) = 0$, A 正确.

选项 B: $P(\Omega) = P(A + \bar{A}) = P(A) + P(\bar{A}) = 1$, B 正确.

选项 C: C 选项表示下连续性, 可列可加性的充要条件为: 1) 有限可加性; 2) 下连续性, 有限可加性不可推出可列可加性, C 错误.

选项 D: $P(A \cup B) = P(A) + P(B) - P(AB) \leq 1$, D 正确.

2. 对任意两个随机事件 A 与 B , 必有 $P(A \cap \bar{B}) = ()$

- (A) $P(A) - P(B)$
- (B) $P(A) - P(B) + P(AB)$
- (C) $P(A) + P(B)$
- (D) $P(A) - P(AB)$

Solution: D

由于 $P(A \cap B) + P(A \cap \bar{B}) = P(A)$, D 正确.

3. 从 5 双不同的鞋子中任取 4 只, 其中恰有一双配对的概率是 ()

- (A) $2/3$
- (B) $4/7$
- (C) $2/7$
- (D) $1/3$

Solution: B

总的取法为 C_{10}^4 , 要使恰有一双配对, 则可以先从 5 双鞋子中选取一双, 共 5 种取法; 然后从剩下的鞋子中任取两双, 共有 C_4^2 种取法; 最后从取出的两双鞋子中各取一只, 每一双鞋子有两种取法, 则总共有四种取法, 因此所求概率为

$$\frac{5 \times C_4^2 \times 4}{C_{10}^4} = \frac{4}{7}$$

B 正确.

4. 如果你的水平略高于对手, 为保证比赛的胜利, 你最期望以下哪种比赛规则 ()

- (A) 一局定输赢
- (B) 三局两胜
- (C) 五局三胜
- (D) 不能确定

Solution: C

设 p 表示某一局赢的概率 $p + q = 1, p > q$;

$$P(B) = C_3^2 p^2 q + p^3 > p = P(A)$$

$$P(C) = C_5^3 p^3 q^2 + C_5^4 p^4 q + p^5 > P(B)$$

故选 C.

5. 随机变量 X, Y 均只能取 0,1 两个值。下面哪个选项不是与“它们的相关系数为 0”等价 ()

- (A) 随机变量 X, Y 相互独立
- (B) $P(X=1, Y=0) = P(X=1)P(Y=0)$
- (C) $P(X=0, Y=0) = P(X=0)P(Y=0)$
- (D) $E(XY) = 0$

Solution: D

易证明 BC 两项等价于 X, Y 相互独立, 一个重要结论: 若 X 和 Y 都服从于两点分布, 则 X 与 Y 不相关和独立等价. 故 ABC 正确. 对于 D 选项, 若 $E(XY) = 0$, 则 $\rho_{XY} = -\frac{E(X)E(Y)}{\sqrt{D(X)D(Y)}}$, 故 $E(XY) = 0$ 与 $\rho_{XY} = 0$ 不等价, D 错误.

6. 有两条蚕, 每条蚕的产卵数相互独立并服从泊松分布, 参数分别为 λ_1 和 λ_2 。每个卵孵化成小蚕的概率为 $p(0 < p < 1)$, 且“每个卵能孵化为小蚕与否”相互独立。记两条蚕养活的小蚕总数为 Y , 则 (1) Y 服从的分布; (2) 两条蚕总共能孵化小蚕数的期望分别是 ()

- (A) 泊松分布, $(\lambda_1 + \lambda_2)p$
- (B) 泊松分布, $\lambda_1 + \lambda_2$
- (C) 二项分布, $(\lambda_1 + \lambda_2)p$
- (D) 二项分布, $\lambda_1 + \lambda_2$

Solution: A

记 X 为总产卵数, $Z_i \sim b(1, p)$ 且相互独立, 由泊松分布可加性知, 总产卵数 $X \sim \mathcal{P}(\lambda_1 + \lambda_2)$, 且有

$$Y = Z_1 + Z_2 + \cdots + Z_X,$$

考虑矩母函数

$$\psi_Z(t) = E[e^{tZ_1}] = pe^t + 1 - p = 1 + p(e^t - 1),$$

记 $\lambda = \lambda_1 + \lambda_2$, 由全期望公式, 有

$$\begin{aligned} E[e^{tY}] &= \sum_{n=0}^{\infty} P(X=n) E[e^{Z_1+\cdots+Z_n} | X=n] = \sum_{n=0}^{\infty} \frac{\lambda^n}{n!} e^{-\lambda} (1 + p(e^t - 1))^n \\ &= e^{-\lambda} \sum_{n=0}^{\infty} \frac{[\lambda(1 + p(e^t - 1))]^n}{n!} = e^{-\lambda} e^{\lambda(1+p(e^t-1))} = e^{\lambda p(e^t-1)}. \end{aligned}$$

这恰好是 $\mathcal{P}(\lambda p) = \mathcal{P}((\lambda_1 + \lambda_2)p)$ 的矩母函数, 因此 $Y \sim \mathcal{P}((\lambda_1 + \lambda_2)p)$. 服从泊松分布, 期望是 $(\lambda_1 + \lambda_2)p$.

7. 甲盒中有 4 个白球, 1 个黑球; 乙盒中有 4 个白球, 3 个黑球。从甲盒中任取一球放入乙盒, 然后再从乙盒中任取一球。则 (1) 在乙盒中取到的是白球的概率; (2) 如果已知在乙盒中取到的是白球, 从甲盒中取出放入乙盒中的也是白球的概率分别是 ()

- (A) $1/2, 5/6$
- (B) $3/5, 5/6$
- (C) $1/2, 4/5$
- (D) $3/5, 4/5$

Solution: B

记 A_i 表示第 i 次摸到白球, 则

$$\begin{aligned} P(A_2) &= P(A_2 | A_1) P(A_1) + P(A_2 | \bar{A}_1) P(\bar{A}_1) \\ &= \frac{5}{8} \times \frac{4}{5} + \frac{1}{2} \times \frac{1}{5} \\ &= \frac{3}{5} \end{aligned}$$

$$P(A_1 | A_2) = \frac{P(A_1 A_2)}{P(A_2)} = \frac{\frac{5}{8} \times \frac{4}{5}}{\frac{3}{5}} = \frac{5}{6}$$

故选 B.

8. 英国《观察家报》和 Opinium 公司 2016 年 6 月初进行的联合民意调查显示, 40% 英国民众支持留在欧盟。考虑一个由 600 名英国民众组成的随机样本, 以 X 表示这 600 人中支持留在欧盟的人数。记 $\Phi(x)$ 是标准正态分布的分布函数, 则 $222 < X < 258$ 的概率大约是 ()

- (A) $2\Phi(1.5) - 1$
- (B) $2\Phi(1.5)$
- (C) $2\Phi(2)$
- (D) $2\Phi(2) - 1$

Solution: A

$X \sim b(600, 0.4)$, 根据二项分布的正态近似可知 X 近似服从于 $N(240, 144)$, 则

$$\begin{aligned} P(222 < X < 258) &= P\left(\frac{222 - 240}{\sqrt{144}} < \frac{X - 240}{\sqrt{144}} < \frac{258 - 240}{\sqrt{144}}\right) \\ &= \Phi(1.5) - \Phi(-1.5) \\ &= 2\Phi(1.5) - 1 \end{aligned}$$

故选 A.

9. 设随机变量序列 X_n 几乎处处收敛到随机变量 X , 则下列说法不正确的是 ()

- (A) X_n 依概率收敛到 X
- (B) X_n 依分布收敛到 X
- (C) X_n 二阶矩收敛到 X
- (D) X_n^2 几乎处处收敛到 X^2

Solution: C

选项 A: 几乎处处收敛可以推出依概率收敛, A 正确.

选项 B: 依概率收敛可以推出依分布收敛, B 正确.

选项 C: r 阶收敛与几乎处处收敛之间一般无法相互推出, 可参考如下反例独立随机变量序列 $P(X_n = 0) = 1 - \frac{1}{n^2}, P(X_n = n) = \frac{1}{n^2}$, 显然有 $X_n \xrightarrow{a.s.} 0$, 但是 $EX_n^2 = 1 \not\rightarrow 0$.

选项 D: 若 $f(x)$ 是连续函数, $X_n \xrightarrow{a.s.} X$, 则 $f(X_n) \xrightarrow{a.s.} f(X)$, D 正确.

10. 设 X 和 Y 均服从标准正态分布, 则 ()

- (A) $X - Y$ 服从正态分布
- (B) $X^2 + Y^2$ 服从卡方分布
- (C) $Y | X$ 服从正态分布
- (D) X^2 服从卡方分布

Solution: D

当 $X = Y$ 时, 易知 ABC 都不正确, 由卡方分布的定义可知, $X^2 \sim \chi^2(1)$, D 正确.

11. 设 $X \sim \chi^2(1), Y \sim \chi^2(n)$, 则 $F = nX/Y$ 的分布是 ()

- (A) $t(n)$
- (B) $F(1, n)$
- (C) $F(n, 1)$
- (D) 不能确定

Solution: D

X, Y 的独立性未知, 无法判断 $\frac{nX}{Y}$ 的分布, 因此本题选 D.

12. 设 $X_1, \dots, X_n$ 为来自标准正态分布 $N(0, 1)$ 的简单随机样本。令 $\bar{X} = \sum_{i=1}^n X_i/n$ 为样本均值, $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)$ 为样本方差, 则 ()

- (A) $\frac{n\bar{X}^2}{S^2} \sim F(1, n-1)$
- (B) $n\bar{X}^2 \sim \chi^2(n)$
- (C) $nS^2 \sim \chi^2(n-1)$
- (D) $(n-1)S^2 \sim \chi^2(n)$

Solution: A

因为诸 X_i 相互独立, 服从标准正态分布, 故 $\bar{x}$ 与 s^2 相互独立, $\bar{X} \sim N(0, \frac{1}{n})$, $\sqrt{n}\bar{X} \sim N(0, 1)$, $n\bar{X}^2 \sim \chi^2(1)$, 选项 B 错误. $(n-1)S^2 \sim \chi^2(n-1)$, 故选项 C、D 错误.

$$\frac{n\bar{X}^2}{S^2} = \frac{\frac{n\bar{X}^2}{1}}{\frac{(n-1)S^2}{n-1}} = \frac{\frac{\chi^2(1)}{1}}{\frac{\chi^2(n-1)}{n-1}} \sim F(1, n-1), \text{A 正确.}$$

13. 设 $X_1, \dots, X_n$ 为来自均匀分布 $U(1-\theta, 1+\theta)$ 的简单随机样本, 其顺序统计量记为 $X_{(1)}, \dots, X_{(n)}$, 则 θ 的充分统计量为 ()

- (A) $X_{(1)}$
- (B) $X_{(n)}$
- (C) $\max_i \{|X_i - 1|\}$
- (D) $X_{(n)} - X_{(1)}$

Solution: C

样本的似然函数为

$$L(\theta) = \left(\frac{1}{2\theta}\right)^n \mathbf{I}_{\{1-\theta < x_i < 1+\theta\}} = \left(\frac{1}{2\theta}\right)^n \mathbf{I}_{\{\theta > \max\{|x_i - 1|\}\}}$$

由因子分解定理知: θ 的充分统计量为: $\max\{|x_i - 1|\}$.

14. 设 $X_1, \dots, X_n$ 为来自指数分布 $\text{Exp}(\lambda)$ 的简单随机样本, 密度函数为 $f(x; \lambda) = \lambda e^{-\lambda x}, x > 0$ 。令 $T = \sum_{i=1}^n X_i, Q = \sum_{i=1}^n (X_i - \bar{X})^2$, 则 ()

- (A) T 与 Q/T^2 独立
- (B) T 与 Q 独立
- (C) T 服从参数为 $n\lambda$ 的指数分布
- (D) T 服从参数为 λ/n 的指数分布

Solution: A

X 不服从正态分布, 其样本均值与样本方差不独立, 选项 B 错误. $E(T) = \frac{n}{\lambda}, D(T) = \frac{n}{\lambda^2}$, 参数为 $n\lambda$ 的指数分布的期望为 $\frac{1}{n\lambda}$, 参数为 $\frac{\lambda}{n}$ 的指数分布的方差为 $\frac{n^2}{\lambda^2}$, 故选项 CD 错误. 因为 $\frac{Q}{T^2}$ 为 λ 的辅助统计量, T 是关于 λ 的充分完备统计量, 根据 Basu 定理可知两者独立, 故选项 A 正确.

15. 设样本 $X_1, \dots, X_n (n \geq 2)$ 来自参数为 $\theta (> 0)$ 的泊松 (Poisson) 分布, 概率分布列为 $f(x; \theta) = \frac{\theta^x e^{-\theta}}{x!}, x = 0, 1, 2, \dots$ 。令 $\bar{X} = \sum_{i=1}^n X_i/n$ 为样本均值, $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)$ 为样本方差, 若 $Y = a\bar{X} + (1-a)S^2, 0 \leq a \leq 1$ 为 θ 的无偏估计, 则 ()

- (A) $a = 0$
- (B) $a = 1$
- (C) $a = 0.5$
- (D) 以上皆可

Solution: D

$$E(\bar{X}) = E(X_i) = \theta, E(S^2) = D(X_i) = \theta,$$

则 $E(Y) = aE(\bar{X}) + (1-a)E(S^2) = a\theta + (1-a)\theta = \theta$, 于是 Y 恒为 θ 的无偏估计, 与 a 的取值无关, 所以选项 D 正确.

16. 设 $X_1, \dots, X_n$ 为来自均值为 0, 方差为 σ^2 的总体的简单随机样本, 令 $Y = \sum_{i=1}^n X_i^2, Q = \sum_{i=1}^n (X_i - \bar{X})^2$, 则下列说法正确的是 ()

- (A) Q/n 是 σ^2 的最大似然估计
- (B) Y/n 是 σ^2 的最大似然估计
- (C) Q/n 是 σ^2 的无偏估计
- (D) Y/n 是 σ^2 的无偏估计

Solution: D

题目没有给出总体的概率密度函数, 无法求出 σ^2 的最大似然估计, 选项 A、B 错误.

$E\left(\frac{Q}{n}\right) = \frac{n-1}{n}\sigma^2$, 选项 C 错误.

$E\left(\frac{Y}{n}\right) = \frac{1}{n}E\left(\sum_{i=1}^n X_i^2\right) = \frac{1}{n}\left[\sum_{i=1}^n EX_i^2 + \sum_{i=1}^n (EX_i)^2\right] = \frac{1}{n}(n\sigma^2) = \sigma^2$, 故选项 D 正确.

17. 设 X_1, X_2, X_3 为来自均值为 μ 的总体的简单随机样本, 则下列 μ 的估计量中方差最小的是 ()

- (A) $\frac{1}{4}X_1 + \frac{1}{2}X_2 + \frac{1}{4}X_3$
- (B) $\frac{4}{5}X_1 + \frac{2}{5}X_2 - \frac{1}{5}X_3$
- (C) $\frac{2}{3}X_1 - \frac{1}{3}X_2 + \frac{2}{3}X_3$
- (D) $\frac{1}{2}X_1 + \frac{1}{3}X_2 + \frac{1}{6}X_3$

Solution: A

假设 X_i 的方差为 σ^2 , 四个选项的方差分别为:

$$\text{Var}(A) = \left(\frac{1}{4^2} + \frac{1}{2^2} + \frac{1}{4^2}\right)\sigma^2 = \frac{3}{8}\sigma^2$$

$$\text{Var}(B) = \left(\frac{4^2}{5^2} + \frac{2^2}{5^2} + \frac{1}{5^2}\right)\sigma^2 = \frac{21}{25}\sigma^2$$

$$\text{Var}(C) = \left(\frac{2^2}{3^2} + \frac{1}{3^2} + \frac{1}{3^2}\right)\sigma^2 = \sigma^2$$

$$\text{Var}(D) = \left(\frac{1}{2^2} + \frac{1}{3^2} + \frac{1}{6^2}\right)\sigma^2 = \frac{7}{18}\sigma^2$$

比较所得 A 选项方差最小, 所以选项 A 正确.

18. 设 $X_1, \dots, X_5$ 为来自均匀分布 $U(0, \theta)$ 的简单随机样本, 令 $Y_1 = \min\{X_i\}, Y_5 = \max\{X_i\}$, 则 θ 的 90% 置信区间为 ()

- (A) $\left(\frac{Y_1}{\sqrt[5]{0.95}}, \frac{Y_1}{\sqrt[5]{0.05}}\right)$
- (B) $\left(\frac{Y_5}{\sqrt[5]{0.95}}, \frac{Y_5}{\sqrt[5]{0.05}}\right)$
- (C) $\left(\frac{Y_1}{\sqrt[5]{0.9}}, \frac{Y_5}{\sqrt[5]{0.9}}\right)$
- (D) $\left(\frac{Y_1}{1-\sqrt[5]{0.1}}, \frac{Y_5}{\sqrt[5]{0.1}}\right)$

Solution: B

X_i 的概率密度函数: $f(x_i) = \begin{cases} \frac{1}{\theta} & x \in (0, \theta) \\ 0 & \text{其他} \end{cases}$ 所以 Y_5 的概率密度函数: $f_{Y_5}(y) = \begin{cases} \frac{5y^4}{\theta^5} & y \in (0, \theta) \\ 0 & \text{其他} \end{cases}$, 故

$\frac{Y_5}{\theta}$ 为枢轴量, 其概率密度函数:

$$f_{\frac{Y_5}{\theta}}(y) = \begin{cases} 5y^4 & y \in (0, 1) \\ 0 & \text{其他} \end{cases}$$

于是有 $P\left(\sqrt[5]{0.05} < \frac{Y_5}{\theta} < \sqrt[5]{0.95}\right) = 0.9$, 反解得到置信区间

$$\left(\frac{Y_5}{\sqrt[5]{0.95}}, \frac{Y_5}{\sqrt[5]{0.05}}\right)$$

[注]: 于情于理, 这里是不该用等尾的.

19. 设 $X_1, \dots, X_n$ 为来自正态总体 $N(\mu, 1)$ 的简单随机样本, 令 $\bar{X} = \sum_{i=1}^n X_i/n$ 为样本均值. 针对假设 $H_0: \mu \leq 0$ v.s. $H_1: \mu > 0$, 显著性水平 $\alpha = 0.05$, 拒绝域为 ()

(A) $\sqrt{n}\bar{X} < -1.96$

(B) $\sqrt{n}\bar{X} > 1.96$

(C) $\sqrt{n}\bar{X} < -1.64$

(D) $\sqrt{n}\bar{X} > 1.64$

Solution: D

$\bar{X} \sim N\left(\mu, \frac{1}{n}\right)$, 在该假设下, 拒绝域为: $\sqrt{n}\bar{X} > z_{0.95}, z_{0.95} = 1.64$.

20. 线性模型 $Y_i = aX_i + e_i, i = 1, \dots, n, e_i, i = 1, \dots, n$ 独立同分布于正态分布 $N(0, \sigma^2)$. 令 $\bar{X} = \sum_{i=1}^n X_i/n, \bar{Y} = \sum_{i=1}^n Y_i/n$ 则 a 的最大似然估计是 ()

(A) $\bar{X}$

(B) $\bar{Y}$

(C) $\frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$

(D) $\frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}$

Solution: D

$e_i \sim N(0, \sigma^2)$, 所以 $Y_i \sim N(ax_i, \sigma^2)$, 所以似然函数为:

$$L(y_1 \dots y_n | a) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_i - ax_i)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{\sum_{i=1}^n (y_i - ax_i)^2}{2\sigma^2}}$$

取对数并关于 a 求偏导置 0, 解得

$$\hat{a} = \frac{\sum_{i=1}^n X_i Y_i}{\sum_{i=1}^n X_i^2}$$

二、(24 分) 设随机向量 (X, Y) 的联合密度为

$$f(x, y) = \frac{1}{2}(x+y)e^{-(x+y)}, x > 0, y > 0.$$

(1) (8 分) 求 $X = 0.5$ 时, Y 的条件密度 $f(y | x = 0.5)$ 。

(2) (8 分) 求 X 和 Y 的相关系数 ρ 。

(3) (8 分) 求 $Z = X + Y$ 的密度函数。

Solution:

(1) 当 $x > 0$ 时,

$$\begin{aligned} f_X(x) &= \int_0^{+\infty} f(x, y) dy \\ &= \int_0^{+\infty} \frac{1}{2}(x+y)e^{-(x+y)} dy \\ &= \frac{1}{2} \int_0^{+\infty} xe^{-(x+y)} dy + \frac{1}{2} \int_0^{+\infty} ye^{-(x+y)} dy = \frac{1}{2}xe^{-x} + \frac{1}{2}e^{-x} \end{aligned}$$

同理, 当 $y > 0$ 时,

$$\begin{aligned} f_Y(y) &= \int_0^{+\infty} f(x, y) dx \\ &= \frac{1}{2} y e^{-y} + \frac{1}{2} e^{-y} \end{aligned}$$

于是 $f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)} = \frac{x+y}{x+1} e^{-y}, x > 0, y > 0$, 代入 $x = 0.5$

$$f_{Y|X}(y | x = 0.5) = \frac{1+2y}{3} e^{-y}, y > 0$$

(2)

$$\begin{aligned} E(X) &= \int_0^{+\infty} \frac{1}{2} x(x+1) e^{-x} dx = \frac{1}{2} \Gamma(3) + \frac{1}{2} \Gamma(2) = \frac{3}{2} \\ E(X^2) &= \int_0^{+\infty} \frac{1}{2} x^2(x+1) e^{-x} dx = \frac{1}{2} \Gamma(4) + \frac{1}{2} \Gamma(3) = 4 \end{aligned}$$

同理, $E(Y) = \frac{3}{2}, E(Y^2) = 4$. 所以 $D(X) = D(Y) = \frac{7}{4}$

$$\begin{aligned} E(XY) &= \iint xy f(x, y) dx dy \\ &= \frac{1}{2} \int_0^{+\infty} y e^{-y} dy \int_0^{+\infty} (x^2 + xy) e^{-x} dx \\ &= \int_0^{+\infty} y e^{-y} dy + \frac{1}{2} \int_0^{+\infty} y^2 e^{-y} dy \\ &= 2 \end{aligned}$$

于是 $\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = -\frac{1}{4}$, 从而

$$\rho = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)D(Y)}} = -\frac{1}{7}$$

(3) 当 $z \leq 0$ 时, $f(z) = 0$ 当 $z > 0$ 时,

$$\begin{aligned} f(z) &= \int_{-\infty}^{+\infty} f(x, z-x) dx \\ &= \int_0^z \frac{1}{2} z e^{-z} dx \\ &= \frac{1}{2} z^2 e^{-z} \end{aligned}$$

所以

$$f(z) = \begin{cases} \frac{1}{2} z^2 e^{-z} & z > 0 \\ 0 & z \leq 0 \end{cases}$$

三、(24 分) 设 $X_1, \dots, X_n$ 来自以下总体, 其密度函数为

$$f(x; \alpha, \beta) = \begin{cases} \frac{\alpha x^{\alpha-1}}{\beta^\alpha}, & 0 < x \leq \beta, \\ 0, & \text{其他.} \end{cases}$$

其中 $\alpha(>0)$ 和 $\beta(>0)$ 为未知参数。

(1) (6 分) 求总体的期望以及方差。

(2) (8 分) 写出 α 和 β 的充分统计量。

(3) (10 分) 求 α 和 β 的最大似然估计量。

Solution:

(1)

$$\begin{aligned}E(X) &= \int_0^\beta \frac{\alpha}{\beta^\alpha} x^\alpha dx = \frac{\alpha}{\alpha+1} \beta \\E(X^2) &= \int_0^\beta \frac{\alpha}{\beta^\alpha} x^{\alpha+1} dx = \frac{\alpha}{\alpha+2} \beta^2 \\D(X) &= E(X^2) - E^2(X) = \frac{\alpha\beta^2}{(\alpha+1)^2(\alpha+2)}\end{aligned}$$

(2)

$$\begin{aligned}f(x_1, x_2, \dots, x_n; \alpha, \beta) &= \prod_{i=1}^n \frac{\alpha x_i^{\alpha-1}}{\beta^\alpha} I_{(0 < x_i \leq \beta)} \\&= \frac{\alpha^n}{\beta^{n\alpha}} \left(\prod_{i=1}^n x_i \right)^{\alpha-1} I_{(x_{(n)} \leq \beta)}\end{aligned}$$

由因子分解定理得, α 和 β 的充分统计量为 $(\prod_{i=1}^n X_i, X_{(n)})$.

(3) 似然函数

$$L(\alpha, \beta) = \prod_{i=1}^n \frac{\alpha}{\beta^\alpha} x_i^{\alpha-1} = \frac{\alpha^n}{\beta^{n\alpha}} \left(\prod_{i=1}^n x_i \right)^{\alpha-1}$$

取对数得

$$\ln L = n \ln \alpha - n\alpha \ln \beta + (\alpha - 1) \sum_{i=1}^n \ln x_i$$

关于两个参数求偏导

$$\begin{cases} \frac{\partial \ln L}{\partial \alpha} = \frac{n}{\alpha} - n \ln \beta + \sum_{i=1}^n \ln x_i = 0 \\ \frac{\partial \ln L}{\partial \beta} = -\frac{n\alpha}{\beta} < 0 \end{cases}$$

其中关于 β 的偏导恒负, 而 $\beta \geq X_{(n)}$, 所以 $\hat{\beta} = X_{(n)}$ 是 β 的最大似然估计. 而将关于 α 的偏导置零, 再代入 $\hat{\beta} = X_{(n)}$, 解得 $\hat{\alpha} = \frac{n}{n \ln X_{(n)} - \sum_{i=1}^n \ln X_i}$ 是 α 的最大似然估计.

四、(24 分) 设样本 $X_1, \dots, X_n (n \geq 2)$ 来自参数为 $\theta (> 0)$ 的泊松 (Poisson) 分布, 概率分布列为 $f(x; \theta) = \frac{\theta^x e^{-\theta}}{x!}, x = 0, 1, 2, \dots$ 令 $g(\theta) = e^{-\theta}, Y = I(X_1 = 0)$, 其中 I 为示性函数.

(1) (6 分) 求 $g(\theta)$ 的最大似然估计量.

(2) (8 分) 证明 Y 是 $g(\theta)$ 的无偏估计量.

(3) (10 分) 求 $g(\theta)$ 的最小方差无偏估计量.

Solution:

(1) 似然函数为: $L(x_1 \dots x_n | \theta) = e^{-n\theta} \prod_{i=1}^n \left(\frac{\theta^{x_i}}{x_i!} \right)$ 两边取对数: $\ln L = -n\theta + \ln \theta \sum_{i=1}^n x_i - \sum_{i=1}^n \ln(x_i!)$, 对 θ 求导并置 0, 有

$$\frac{\partial \ln L}{\partial \theta} = -n + \frac{\sum_{i=1}^n x_i}{\theta} = 0$$

解得 θ 的最大似然估计 $\hat{\theta} = \bar{x}$, 再由最大似然估计的不变性可得 $g(\theta)$ 的最大似然估计: $e^{-\bar{x}}$.

(2) $E(Y) = P(X_1 = 0) = e^{-\theta} = g(\theta)$, 所以 Y 为 $g(\theta)$ 的无偏估计量.

(3) 根据因子分解定理以及指数族分布的性质, 由 1) 中的似然函数可看出: $\sum_{i=1}^n X_i$ 是充分完备统计量. 而 $E(Y) = E[E(Y | \sum_{i=1}^n X_i)] = g(\theta)$, 故 $E(Y | \sum_{i=1}^n X_i)$ 是无偏估计. 由 Lehmann-Scheffe 定理知 $E(Y | \sum_{i=1}^n X_i)$

为 $g(\theta)$ 的最小方差无偏估计量, 进一步计算, 得

$$\begin{aligned} E\left(Y \mid \sum_{i=1}^n X_i\right) &= P(X_1 = 0 \mid T = t) \\ &= \frac{P(x_1 = 0) P(\sum_{i=2}^n x_i = t)}{P(\sum_{i=1}^n x_i = t)} \\ &= \frac{\theta^0 e^{-\theta} \frac{[(n-1)\theta]^{t-0} e^{-(n-1)\theta}}{(t-0)!}}{\frac{(n\theta)^t e^{-n\theta}}{t!}} = \left(\frac{n-1}{n}\right) \sum_{i=1}^n x_i \end{aligned}$$

所以 $g(\theta)$ 的最小方差无偏估计: $\left(\frac{n-1}{n}\right) \sum_{i=1}^n x_i$.

五、(18 分) 设 $X_1, \dots, X_9$ 为来自正态总体 $N(\mu_1, 1)$ 的简单随机样本, $Y_1, \dots, Y_{16}$ 为来自正态总体 $N(\mu_2, 1)$ 的简单随机样本, 且两样本独立。针对假设 $H_0: \mu_1 = \mu_2 = 0$ v.s. $H_1: \mu_1 \neq 0$ 或 $\mu_2 \neq 0$ 。

(1) (8 分) 若给出拒绝域为 $C = \{|\bar{X} - \bar{Y}| > b\}$, 求常数 b , 使其显著性水平 $\alpha = 0.05$ 。

(2) (10 分) 给定显著性水平 $\alpha = 0.05$, 请构建似然比检验。要求: 写出似然比统计量, 并把它表示为一个服从 χ^2 分布的统计量 T 的函数形式, 并以 T 的形式给出拒绝域。

Solution: (1) 由题意可知 $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{25}{144})$, 对于所给假设, 检验的拒绝域为:

$$T = \left\{ |\bar{X} - \bar{Y}| > \frac{5}{12} z_{0.975} \right\},$$

由所给数据可知: $Z_{0.975} = 1.96$. 所以有 $b = \frac{5}{12} \times \frac{196}{100} = \frac{49}{60}$.

(2) (X, Y) 的联合概率密度函数: $f(x, y) = \frac{1}{2\pi} e^{-\frac{(x-\mu_1)^2 + (y-\mu_2)^2}{2}}$, 则似然函数为

$$L(x_1 \dots x_9, y_1 \dots y_{16} \mid \mu_1, \mu_2) = \prod_{i=1}^9 \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_i - \mu_1)^2}{2}} \prod_{i=1}^{16} \frac{1}{\sqrt{2\pi}} e^{-\frac{(y_i - \mu_2)^2}{2}}$$

取对数并分别对 μ_1, μ_2 求偏导并置 0, 得似然方程组

$$\begin{aligned} \frac{\partial \ln L}{\partial \mu_1} &= \sum_{i=1}^9 (x_i - \mu_1) = 0 \\ \frac{\partial \ln L}{\partial \mu_2} &= \sum_{i=1}^{16} (y_i - \mu_2) = 0 \end{aligned}$$

解得 μ_1, μ_2 的无约束最大似然估计分别为 $\hat{\mu}_1 = \frac{\sum_{i=1}^9 X_i}{9}, \hat{\mu}_2 = \frac{\sum_{i=1}^{16} Y_j}{16}$. 而在约束 $\mu_1 = \mu_2 = 0$ 下, μ_1, μ_2 的约束最大似然估计均为 $\hat{\mu}_0 = 0$, 于是似然比统计量为

$$\begin{aligned} \Lambda &= \frac{L(\hat{\mu}_0, \hat{\mu}_0)}{L(\hat{\mu}_1, \hat{\mu}_2)} \\ &= \frac{\left(\frac{1}{2\pi}\right)^{\frac{25}{2}} e^{-\frac{1}{2} [\sum_{i=1}^9 (x_i)^2 + \sum_{i=1}^{16} (y_i)^2]}}{\left(\frac{1}{2\pi}\right)^{\frac{25}{2}} e^{-\frac{1}{2} [\sum_{i=1}^9 (x_i - \hat{\mu}_1)^2 + \sum_{i=1}^{16} (y_i - \hat{\mu}_2)^2]}} \\ &= e^{-\frac{1}{2} (9\bar{X}^2 + 16\bar{Y}^2)} \end{aligned}$$

若记 $T = 9\bar{X}^2 + 16\bar{Y}^2$, 根据指数函数的单调性, 可将似然比拒绝域写为 $\{\Lambda < \lambda_0\} = \{T > c\}$. 这里 c 使得检验的水平是 0.05. 又因为 $\bar{X} \sim N(0, \frac{1}{9}), \bar{Y} \sim N(0, \frac{1}{16})$, 且它们是相互独立的, 所以

$$T = 9\bar{X}^2 + 16\bar{Y}^2 \sim \chi^2(2)$$

因此似然比拒绝域是 $\{9\bar{X}^2 + 16\bar{Y}^2 > \chi_{0.95}^2(2)\}$. 结合 $\chi^2(2)$ 就是 $Exp(1/2)$ 的事实, 解得 $\chi_{0.95}^2(2) = -\ln 0.05$.

中山大学-432 统计学-2018 年

一、选择题 (每小题 3 分, 共 60 分)

1. 以下哪条不是概率的公理化定义中概率函数的性质? ()

- (A) 有限可加性
- (B) 次可加性
- (C) 单调性
- (D) 右连续性

Solution: D

概率的公理化定义由三个条件, 分别为: 非负性、规范性、可列可加性. 其性质有: 次可加性、单调性、连续性 (上连续或下连续)、有限可加性、减法公式、加法公式等. 右连续性是分布函数的性质, 并非概率函数的性质, 故选 D.

2. 已知 A, B 两个随机事件满足 $P(A \cap B) = P(\bar{A} \cap \bar{B})$, 且 $P(A) = p$, 则 $P(B)$ 等于 ()

- (A) p
- (B) $1 - p$
- (C) $(1 - p)p$
- (D) p^2

Solution: B

由 $P(\bar{A} \cap \bar{B}) = P(\overline{A \cup B})$ 推出:

$$\begin{aligned} P(\bar{A} \cap \bar{B}) &= P(\overline{A \cup B}) = 1 - P(A \cup B) \\ &= 1 - [P(A) + P(B) - P(A \cap B)] \\ &= 1 - P(A) - P(B) + P(A \cap B) \end{aligned}$$

所以: $P(B) = 1 - P(A) = 1 - p$. 选项 B 正确

3. 设事件 A, B 互不相容, 且 $P(A) > 0, P(B) > 0$, 则有 ()

- (A) $P(B | A) > 0$
- (B) $P(A | B) = P(A)$
- (C) $P(A | B) = 0$
- (D) $P(AB) = P(A)P(B)$

Solution: C

因为事件 A 与 B 不相容, 所以: $P(AB) = 0$, 选项 D 错误, 又 $P(A | B) = \frac{P(AB)}{P(B)} = 0$ 所以选项 C 正确

4. 某班有 5 个士兵, 每人各有一支枪, 这些枪的外形完全一样。在一次夜间紧急集合中, 若每人随机取走一支枪, 恰好有三个人拿到自己的枪的概率是 ()

- (A) $1/4$
- (B) $1/5$
- (C) $1/6$
- (D) $1/12$

Solution: D

5 个士兵随机取走一支枪, 总共有 $5! = 120$ 种可能性, 恰有三个人拿到自己的枪支, 则剩下两个人只能取得另一个人的枪支, 有 $C_5^3 = 10$ 种可能故恰好有三个人拿到自己枪支的概率: $P = \frac{10}{120} = \frac{1}{12}$ 选项 D 正确

5. 若发报机以 0.7 和 0.3 的概率发出信号 0 和 1, 由于随机干扰的影响, 当发出信号 0 时, 接收机不一定收到 0, 而是以概率 0.8 和 0.2 收到信号 0 和 1; 同样地, 当发报机发出信号 1 时, 接收机以概率 0.9 和 0.1 收到信号 1 和 0。当接收机收到信号 1 时, 发报机是发出信号 1 的概率是 ()

- (A) 9/10
- (B) 56/59
- (C) 27/41
- (D) 17/32

Solution: C

设发报机发出信号 1 为事件 A, 接收机收到信号 1 为事件 B, 依题意有:

$$P(A) = 0.3, P(\bar{A}) = 0.7, P(B | A) = 0.9, P(B | \bar{A}) = 0.2$$

所以接收机收到信号 1 时, 发报机是发出信号 1 的概率:

$$\begin{aligned} P(A | B) &= \frac{P(AB)}{P(B)} = \frac{P(A)P(B | A)}{P(A)P(B | A) + P(\bar{A})P(B | \bar{A})} \\ &= \frac{0.3 \times 0.9}{0.3 \times 0.9 + 0.7 \times 0.2} = \frac{27}{41} \end{aligned}$$

选项 C 正确

6. 假设独立随机变量 X, Y 服从同一名称的概率分布 (二者的分布参数未必相同)。且 $X + Y$ 也服从同一名称的概率分布。则 X, Y 不可能服从 ()

- (A) 二项分布
- (B) 泊松分布
- (C) 正态分布
- (D) 指数分布

Solution: D

两个独立的随机变量服从二项分布、泊松分布或者正态分布时, 他们的和也服从于该随机变量的概率分布, 而若 XY 服从指数分布时, 他们的和不一定服从指数分布。例如: XY 服从参数为 λ 的指数分布服从 $Ga(1, \lambda)$, $X + Y$ 服从 $Ga(2, \lambda)$ 不服从指数分布。选项 D 错误

7. 设 X 和 Y 相互独立, 且 $X \sim N(0, 1), Y \sim N(1, 4)$, 则有 ()

- (A) $P(X + Y \leq 0) = 1/2$
- (B) $P(X + Y \leq 1) = 1/2$
- (C) $P(X - Y \leq 0) = 1/2$
- (D) $P(X - Y \leq 1) = 1/2$

Solution: B

X 和 Y 相互独立且都服从正态分布, 所以 $X + Y \sim N(1, 5), X - Y \sim N(-1, 5)$ $X + Y$ 的概率密度函数关于 $X = 1$ 对称, 故 $P(X + Y < 1) = \frac{1}{2}$ 。选项 B 正确

8. 以下哪项不是 (强) 大数定律的应用? ()

- (A) 观测值的算术平均值估计期望值
- (B) 事件发生的频率估计概率
- (C) 期望值的置信区间估计
- (D) 用蒙特卡洛法计算定积分

Solution: C

大数定律是指样本数量越多, 它的算术平均值就越接近于其期望值, 选项 ABD 均为其运用。选项 C 的期望值的置信区间是通过构造适当的区间来估计对应参数的真值所在范围, 属于中心极限定理的应用, 故选项 C 错误

9. 设总体分布为参数为 2 的指数分布 $\text{Exp}(2)$ (密度函数参看试卷末尾)。现分别有来自总体的容量分别为 200 和 400 的两独立样本, 则此两样本均值之差的绝对值大于 $\sqrt{3}/20$ 的概率大约是 ()

- (A) $2\Phi(1.5) - 1$
 (B) $2\Phi(1.5)$
 (C) $2\Phi(2)$
 (D) $2 - 2\Phi(2)$

Solution: D

参数为 2 的指数分布的概率密度函数: $f(x) = \begin{cases} 2e^{-2x} & x > 0 \\ 0 & \text{其他} \end{cases}$, 其期望与方差为: $E(x) = \frac{1}{2}, D(x) = \frac{1}{4}$ 另

$\bar{X}, \bar{Y}$ 分别表示样本容量为 200400 的样本均值有:

$$E(\bar{X}) = \frac{1}{2}, D(\bar{X}) = \frac{1}{800}, \quad E(\bar{Y}) = \frac{1}{2}, D(\bar{Y}) = \frac{1}{1600},$$

由中心极限定理: $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{3}{1600}}} \sim N(0, 1)$ 所以有:

$$\begin{aligned} P\left(|\bar{X} - \bar{Y}| > \frac{\sqrt{3}}{20}\right) &= 1 - P\left(-\frac{\sqrt{3}}{20} < \bar{X} - \bar{Y} < \frac{\sqrt{3}}{20}\right) \\ &= 1 - P\left(\frac{-\sqrt{3}/20}{\sqrt{3}/40} < \frac{\bar{X} - \bar{Y}}{\sqrt{3}/40} < \frac{\sqrt{3}/20}{\sqrt{3}/40}\right) \\ &= 1 - [\Phi(2) - \Phi(-2)] \\ &= 1 - [2\Phi(2) - 1] \\ &= 2 - 2\Phi(2) \end{aligned}$$

选项 D 正确

10. 关于随机变量序列 X_n 依概率收敛到随机变量 X , 则下列说法不正确的是 ()
 (A) X_n 概率 1 收敛到 X
 (B) X_n 依分布收敛到 X
 (C) X_n^2 阶矩不一定收敛
 (D) X_n^2 依概率收敛到 X^2

Solution: A

X_n 依概率收敛到 X , 可以推出其依分布收敛到 X , 但不能推出其概率 1 收敛到 X , 且由依概率收敛的四则运算法则可以推出 X_n^2 依概率收敛到 X^2 , 故选项 B C、D 正确, 选项 A 错误.

11. 若 X 服从标准正态分布 $N(0, 1)$, Y 服从自由度为 n 的卡方分布 $\chi^2(n)$, Z 服从自由度为 m 的卡方分布 $\chi^2(m)$, 则 ()

- (A) $X^2 \sim \chi^2(1)$
 (B) $\frac{x}{\sqrt{Y/n}} \sim t(n)$
 (C) $\frac{Y/n}{Z/m} \sim F(n, m)$
 (D) 以上皆对

Solution: A

因为 $X \sim N(0, 1)$, 故 $X^2 \sim \chi^2(1)$, A 选项正确; 由于 XYZ 之间独立性未知, 故 B、C、D 选项错误.

12. 设 $X_1, \dots, X_n$ 为正态分布 $N(\mu, \sigma^2)$ 的样本, μ 未知而 σ^2 已知. $\bar{X}$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本均值及样本方差. 记, $T_1 = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}, T_2 = \frac{\bar{x} - \mu}{s/\sqrt{n}}, T_3 = \frac{(n-1)S^2}{\sigma^2}$, 则 T_1, T_2, T_3 中统计量的个数为 ()

- (A) 0
 (B) 1
 (C) 2

(D) 3

Solution: B

统计量指样本的函数 $T(X_1, X_2, \dots, X_n)$; 统计量依赖且只依赖于样本, 它不含任何未知参数 (故一般其分布与未知参数有关). 由于 μ 未知, 故 T_1, T_2 不是统计量, T_3 是统计量.

13. 设 $X_1, \dots, X_n$ 为泊松分布 $\text{Pois}(\lambda)$ 的样本, $\bar{X}$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本均值及样本方差, 则 $E(n\bar{X}^2 + S^2)$ 为 ()

- (A) $(n+1)\lambda$
- (B) $(n+1)\lambda^2$
- (C) $n\lambda^2 + \lambda$
- (D) $n\lambda^2 + 2\lambda$

Solution: D

由于 $X \sim P(\lambda)$, 则 $E(X) = \lambda, D(X) = \lambda; E(\bar{x}^2) = D(\bar{x}) + E^2(\bar{x}) = \frac{D(X)}{n} + E^2(X) = \frac{\lambda}{n} + \lambda^2, E(s^2) = D(X) = \lambda, E(n\bar{x}^2 + s^2) = nE(\bar{x}^2) + E(s^2) = n\lambda^2 + 2\lambda$, 故 D 选项正确.

14. 设 $X_1, \dots, X_{10}$ 为正态总体 $X \sim N(0, 2)$ 的样本, 记 $T = \sum_{i=1}^{10} (X_i - \bar{X})^2$, 则 T 的方差为 ()

- (A) 9
- (B) 18
- (C) 36
- (D) 72

Solution: D

$\frac{T}{2} \sim \chi^2(9), D(T) = 4D\left(\frac{T}{2}\right) = 4 \times 18 = 72$, 故 D 选项正确.

15. 设 $X_1, \dots, X_n$ 为来自均匀分布 $U(\theta-1, \theta+1)$ 的简单随机样本, 其顺序统计量记为 $X_{(1)}, \dots, X_{(n)}$, 则 θ 的充分统计量为 ()

- (A) $X_{(1)}$
- (B) $X_{(n)}$
- (C) $\{X_{(1)}, X_{(n)}\}$
- (D) $X_{(n)} - X_{(1)}$

Solution: C

密度函数为 $f(x) = \frac{1}{2}I_{(\theta-1 \leq x \leq \theta+1)}$, 其联合分布函数为

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n \frac{1}{2} I_{(\theta-1 \leq x_i \leq \theta+1)} = \frac{1}{2^n} I_{(\theta \geq X_{(n)}-1)} I_{(\theta \leq X_{(1)}+1)}$$

故由因子分解定理知, 充分统计量为 $(X_{(1)}, X_{(n)})$, 选项 C 正确.

16. 设 $X_1, \dots, X_n$ 为正态分布 $N(0, \sigma^2)$ 的样本, $Y_1, \dots, Y_m$ 为正态分布 $N(1, \sigma^2)$ 的样本. 记 $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, S_Y^2 = \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2$, 则下列说法正确的是 ()

- (A) $(S_X^2 + S_Y^2)/2$ 是 σ^2 的无偏估计量
- (B) $(S_X^2 + S_Y^2)/2$ 是 σ^2 的最大似然估计量
- (C) $(S_X^2 + S_Y^2)/2$ 是 σ^2 的充分统计量
- (D) $(S_X + S_Y)/2$ 是 σ 的最大似然估计量

Solution: A

选项 A: 因为 $E(s_x^2) = \sigma^2, E(s_y^2) = \sigma^2$, 故 $E\left(\frac{s_x^2 + s_y^2}{2}\right) = \sigma^2$, A 选项正确;

选项 B: 似然函数

$$L(\sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} (\sum_{i=1}^n x_i^2 + \sum_{i=1}^m (y_i-1)^2)}$$

取对数得, $\ln L = -\frac{m+n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \left(\sum_{i=1}^n x_i^2 + \sum_{i=1}^m (y_i - 1)^2 \right)$

$$\text{令 } \frac{d \ln L}{d \sigma^2} = -\frac{m+n}{2\sigma^2} + \frac{\sum_{i=1}^n x_i^2 + \sum_{i=1}^m (y_i - 1)^2}{2\sigma^4} = 0,$$

求得 $\hat{\sigma}_{MLE}^2 = \frac{\sum_{i=1}^n x_i^2 + \sum_{i=1}^m (y_i - 1)^2}{m+n}$, B 选项错误;

选项 C: 联合分布函数 $f(x_1, x_2, \dots, x_n, y_1) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} (\sum_{i=1}^n x_i^2 + \sum_{i=1}^m (y_i - 1)^2)}$, 由因子分解定理知, 充分统计量为 $\sum_{i=1}^n x_i^2 + \sum_{i=1}^m (y_i - 1)^2$, C 选项错误;

选项 D: 由最大似然估计的不变性可知 $\hat{\sigma}_{MLE} = \sqrt{\frac{\sum_{i=1}^n x_i^2 + \sum_{i=1}^m (y_i - 1)^2}{m+n}}$, 选项 D 错误.

17. 设 $X_1, \dots, X_n$ 为参数为 λ 的指数分布 $\text{Exp}(\lambda)$, $\bar{X}$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本均值及样本方差. 则下列统计量的分布不依赖于 λ 的是 ()

- (A) $\bar{X}$
- (B) S
- (C) $\bar{X} - S$
- (D) $\bar{X}/S$

Solution: D

记 $Y_i = \lambda X_i$, 则 $f(y) = e^{-y}$, 故 Y_i 分布与参数 λ 无关. 而

$$\lambda \bar{x} = \lambda \frac{\sum_{i=1}^n x_i}{n} = \frac{\sum_{i=1}^n \lambda x_i}{n} = \bar{y}$$

$$\lambda^2 s^2 = \frac{\lambda^2}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \sum_{i=1}^n (\lambda x_i - \lambda \bar{x})^2 = s_y^2$$

故 $\frac{\bar{x}}{s} = \frac{\lambda \bar{x}}{\lambda s} = \frac{\bar{y}}{s_y}$ 分布与参数 λ 无关, 选项 D 正确.

18. 设 $X_1, \dots, X_n$ 为标准正态分布 $N(0, 1)$ 的样本, $\bar{X}$ 为样本均值, 则 ()

- (A) $\bar{X}^2 \sim \chi^2(1)$
- (B) $n\bar{X}^2 \sim \chi^2(1)$
- (C) $n\bar{X}^2 \sim \chi^2(n)$
- (D) $\sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n)$

Solution: B

$$\bar{x} \sim N\left(0, \frac{1}{n}\right), \sum_{i=1}^n (x_i - \bar{x})^2 \sim \chi^2(n-1);$$

$\sqrt{n}\bar{x} \sim N(0, 1)$, 故 $n\bar{x}^2 \sim \chi^2(1)$, B 选项正确.

19. 若总体 X 的密度函数为

$$f(x; \theta) = \begin{cases} \frac{6x(\theta-x)}{\theta^3}, & 0 < x < \theta, \\ 0, & \text{其他}, \end{cases}$$

其中 $\theta > 0$ 为未知参数. $X_1, \dots, X_n$ 是来自总体 X 的样本, 则 θ 的矩法估计量是 ()

- (A) $\bar{X}$
- (B) $2\bar{X}$
- (C) $3\bar{X}$
- (D) $4\bar{X}$

Solution: B

$$E(X) = \int_0^\theta \frac{6x^2(\theta-x)}{\theta^3} dx = 6\theta \int_0^\theta \frac{x^2}{\theta^2} \left(1 - \frac{x}{\theta}\right) d\frac{x}{\theta} \\ = 6\theta \text{Beta}(3, 2) = \frac{\theta}{2}$$

$\theta = 2E(X)$, 故 $\hat{\theta} = 2\bar{x}$, B 选项正确.

20. 设某总体 X 的一阶与二阶原点矩分别为 μ_1 和 μ_2 , $X_1, \dots, X_n$ 是来自总体 X 的样本, 令 $Q = \sum_{i=1}^n (X_i - \bar{X})^2$, 则下列说法正确的是 ()

- (A) $\bar{X}^2$ 是 μ_1^2 的无偏估计量
- (B) $\bar{X}^2$ 是 μ_2 的无偏估计量
- (C) $\bar{X}^2 + Q/n$ 是 μ_2 的无偏估计量
- (D) $\bar{X}^2 + Q/(n-1)$ 是 μ_2 的无偏估计量

Solution: C

$$E(\bar{x}^2) = D(\bar{x}) + E^2(\bar{x}) = \frac{D(X)}{n} + E^2(X) \\ = \frac{1}{n} (\mu_2 - \mu_1^2) + \mu_1^2 = \frac{1}{n} \mu_2 + \frac{n-1}{n} \mu_1^2, \\ E(Q) = (n-1) (\mu_2 - \mu_1^2), \\ E\left(\bar{x}^2 + \frac{Q}{n}\right) = \frac{1}{n} \mu_2 + \frac{n-1}{n} \mu_1^2 + \frac{n-1}{n} (\mu_2 - \mu_1^2) = \mu_2$$

故 C 选项正确.

二、(24 分) 设随机向量 (ξ, η) 服从 $D = \{(x, y) : 0 \leq x \leq 1, 0 \leq y \leq 2\}$ 上的均匀分布.

(1) (8 分) 求 $Z = \min\{\xi, \eta\}$ 的密度函数.

(2) (8 分) 令 $U = \begin{cases} 0, & \xi \leq \eta \\ 1, & \xi > \eta \end{cases}; V = \begin{cases} 0, & \xi \leq 2\eta \\ 1, & \xi > 2\eta \end{cases}$. 求 (U, V) 的分布.

(3) (8 分) 求 U, V 相关系数.

Solution:

(1) 随机向量所围成的面积 $S = 2$, 二维随机变量 (X, Y) 的概率密度函数:

$$f(x, y) = \begin{cases} \frac{1}{2} & 0 < x < 1, 0 < y < 2 \\ 0 & \text{其他} \end{cases}$$

$F_Z(z) = P(Z \leq z) = P(\min(\xi, \eta) \leq z)$, 当 $z < 0$ $F_Z(z) = 0$, 当 $0 < z < 1$, 有

$$F_Z(z) = 1 - \int_z^1 dx \int_z^2 \frac{1}{2} dy \\ = 1 - \frac{1}{2} (1-z)(2-z) \\ = -\frac{1}{2} z^2 + \frac{3}{2} z$$

当 $z > 1$, $F_Z(z) = 1$, 故 Z 的密度函数是

$$f_Z(z) = \begin{cases} -z + \frac{3}{2} & 0 < z < 1 \\ 0 & \text{其他} \end{cases}$$

(2)

$$P(U=0, V=0) = P(\xi \leq \eta, \xi \leq 2\eta) = 1 - \frac{1}{2} \int_0^1 dx \int_0^x dy = \frac{3}{4}$$

$$P(U=0, V=1) = P(\xi \leq \eta, \xi > \eta) = 0$$

$$P(U=1, V=0) = P(\xi > \eta, \xi \leq 2\eta) = \frac{1}{2} \int_0^1 dx \int_{\frac{x}{2}}^x dy = \frac{1}{8}$$

$$P(U=1, V=1) = 1 - \frac{3}{4} - \frac{1}{8} = \frac{1}{8}$$

可得 (U, V) 的联合分布列:

$U \setminus V$	0	1
0	$\frac{3}{4}$	0
1	$\frac{1}{8}$	$\frac{1}{8}$

(3) $P(U=0) = \frac{3}{4}, P(U=1) = \frac{1}{4}, P(V=0) = \frac{7}{8}, P(V=1) = \frac{1}{8}, E(U) = \frac{1}{4}, E(U^2) = \frac{1}{4}, D(U) = \frac{3}{16}$
 $E(V) = \frac{1}{8}, E(V^2) = \frac{1}{8}, D(V) = \frac{7}{64}, E(UV) = \frac{1}{8}, \text{Cov}(U, V) = E(UV) - E(U)E(V) = \frac{3}{32}$ 因此 U 和 V 的相关系数: $\rho_{U,V} = \frac{\text{Cov}(U,V)}{\sqrt{D(U)}\sqrt{D(V)}} = \frac{\sqrt{21}}{7}$

三、(20 分) 设 $X_1, \dots, X_n$ 为贝塔分布 $\text{Beta}(\theta, 1)$ 的样本, 密度函数为:

$$f(x; \theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1 \\ 0, & \text{其他.} \end{cases}$$

(1) (8 分) 求 θ 的矩法估计量 $\hat{\theta}_1$ 。

(2) (12 分) 求 θ 的最大似然估计量 $\hat{\theta}_2$; 并进一步求 $p = P(X < 0.5)$ 的最大似然估计量。

Solution: (1)

$$E(X) = \int_0^1 x f(x) dx = \theta \int_0^1 x^\theta dx = \frac{\theta}{\theta+1}$$

由矩法估计, 令样本均值近似期望: $\bar{X} = E(X) = \frac{\theta}{\theta+1}$ 得到 θ 的矩估计: $\hat{\theta}_1 = \frac{\bar{X}}{1-\bar{X}}$

(2) 似然函数为: $L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \theta^n \prod_{i=1}^n x_i^{\theta-1}$, 两边同时取对数, 有对数似然函数 $\ln L(\theta) = n \ln(\theta) + (\theta-1) \sum_{i=1}^n \ln(x_i)$, 对 θ 求导并置 0, 得

$$\frac{n}{\theta} + \sum_{i=1}^n \ln(x_i) = 0$$

得到 θ 的最大似然估计为: $\hat{\theta}_2 = -\frac{n}{\sum_{i=1}^n \ln(x_i)}$ 因为 $p = P(X < 0.5) = \int_0^{0.5} \theta x^{\theta-1} dx = 0.5^\theta$ 根据不变性,

$p = P(X < 0.5)$ 的最大似然估计为 $\hat{p} = 0.5^{-\frac{n}{\sum_{i=1}^n \ln(X_i)}}$

四、(20 分) 求下列情况中 θ 的 $1-\alpha$ 置信区间。

(1) (10 分) 设 $X_1, \dots, X_n$ 为正态分布 $N(\theta, \theta^2)$ 的样本, $\theta > 0, n > 10$, 且 $\bar{X} > 0$ 。

(2) (10 分) 设 $X_1, \dots, X_n$ 为正态分布 $N(\theta, \theta)$ 的样本, $\theta > 0, n > 10$, 且 $\bar{X} > 0$ 。

Solution: (1) 构造枢轴量 $T = \frac{\sqrt{n}(\bar{X}-\theta)}{\theta} \sim N(0, 1)$

$$P\left\{-u_{1-\alpha/2} \leq T \leq u_{1-\alpha/2}\right\} = 1 - \alpha$$

即

$$P\left\{\frac{\bar{X}}{1 + \frac{u_{1-\alpha/2}}{\sqrt{n}}} \leq \theta \leq \frac{\bar{X}}{1 - \frac{u_{1-\alpha/2}}{\sqrt{n}}}\right\} = 1 - \alpha$$

所以 θ 的 $1-\alpha$ 置信区间为 $\left[\frac{\bar{x}}{1+\frac{u_{1-\alpha/2}}{\sqrt{n}}}, \frac{\bar{x}}{1-\frac{u_{1-\alpha/2}}{\sqrt{n}}} \right]$.

(2) [注]: 这题可以用下述三个枢轴量

$$T_1 = \frac{(n-1)S^2}{\theta} \sim \chi^2(n-1), \quad T_2 = \sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\bar{X}}} \rightarrow_d N(0,1), \quad T_3 = \sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\theta}} \sim N(0,1)$$

显然 T_2 只是渐近的枢轴量, T_1, T_3 是严格的枢轴量, 但是 T_1 实际上丧失了总体期望是 θ 的这一信息, 因此 T_3 最佳.

构造枢轴量 $T = \frac{\sqrt{n}(\bar{x}-\theta)}{\sqrt{\theta}} \sim N(0,1)$ 则

$$P\left\{-u_{1-\alpha/2} \leq T \leq u_{1-\alpha/2}\right\} = 1-\alpha$$

又注意到 $T = \frac{\sqrt{n}(\bar{x}-\theta)}{\sqrt{\theta}}$ 是关于 θ 单调递减的, 因此不妨求解下述两个方程的根

$$\begin{cases} T = \frac{\sqrt{n}(\bar{x}-\theta)}{\sqrt{\theta}} = u_{1-\frac{\alpha}{2}} \\ T = \frac{\sqrt{n}(\bar{x}-\theta)}{\sqrt{\theta}} = -u_{1-\frac{\alpha}{2}} \end{cases}$$

先考虑 $\frac{\sqrt{n}(\bar{x}-\theta)}{\sqrt{\theta}} = u_{1-\frac{\alpha}{2}}$, 即 $\sqrt{n}\theta + u_{1-\frac{\alpha}{2}}\sqrt{\theta} - \sqrt{n}\bar{x} = 0$, 视其为关于 $\sqrt{\theta}$ 的二次方程, 解得其正根为 $\sqrt{\theta_1} = \frac{-u_{1-\frac{\alpha}{2}} + \sqrt{u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x}}}{2\sqrt{n}}$, 即

$$\theta_1 = \frac{2u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x} - 2u_{1-\frac{\alpha}{2}}\sqrt{u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x}}}{4n}$$

同理 $\frac{\sqrt{n}(\bar{x}-\theta)}{\sqrt{\theta}} = -u_{1-\frac{\alpha}{2}}$ 的根是

$$\theta_2 = \frac{2u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x} + 2u_{1-\frac{\alpha}{2}}\sqrt{u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x}}}{4n}$$

所以 θ 的 $1-\alpha$ 置信区间为

$$\left[\frac{2u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x} - 2u_{1-\frac{\alpha}{2}}\sqrt{u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x}}}{4n}, \frac{2u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x} + 2u_{1-\frac{\alpha}{2}}\sqrt{u_{1-\frac{\alpha}{2}}^2 + 4n\bar{x}}}{4n} \right]$$

五、(26 分) 设 $X_1, \dots, X_n$ 为正态分布 $N(0, \theta)$ 的样本, 密度函数为:

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-x^2/2\theta}, \quad -\infty < x < +\infty,$$

其中 θ 为方差 (未知)。令 $T = |\sum_{i=1}^n X_i|$ 。

(1) (10 分) 求 b , 使得 $E(bT)$ 为 $\sqrt{\theta}$ 的无偏估计量。

(2)(16 分) 考虑假设检验 $H_0: \theta = 1$ vs $H_1: \theta \neq 1$ 。构建拒绝域 $C = \{T > 2\sqrt{n}\}$ 。求此检验的势函数 (功效函数) 与第一类错误。(注: 用标准正态分布的累积分布函数 Φ 表示即可)。

Solution:

(1) 记 $Y = \frac{\sum_{i=1}^n X_i}{\sqrt{n\theta}} \sim N(0,1)$, 则

$$\begin{aligned} E(|Y|) &= \int_{-\infty}^{+\infty} |y| \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} y e^{-\frac{y^2}{2}} dy \\ &= \sqrt{\frac{2}{\pi}} \int_0^{+\infty} e^{-\frac{y^2}{2}} d\frac{y^2}{2} = \sqrt{\frac{2}{\pi}} \end{aligned}$$

$E(bT) = E(b\sqrt{n\theta}|Y|) = b\sqrt{\frac{2n}{\pi}}\theta$, 因为 bT 是 $\sqrt{\theta}$ 的无偏估计, 所以 $b = \sqrt{\frac{\pi}{2n}}$.

(2) 功效函数

$$\begin{aligned} g(\theta) &= P_{\theta}(T > 2\sqrt{n}) = P_{\theta}\left(\frac{|\sum_{i=1}^n X_i|}{\sqrt{n\theta}} > \frac{2}{\sqrt{\theta}}\right) = 1 - P_{\theta}\left(|Y| \leq \frac{2}{\sqrt{\theta}}\right) \\ &= 1 - \left(2\Phi\left(\frac{2}{\sqrt{\theta}}\right) - 1\right) = 2 - 2\Phi\left(\frac{2}{\sqrt{\theta}}\right) \end{aligned}$$

因此犯第一类错误的概率是 $\alpha = g(1) = 2 - 2\Phi(2)$.

中山大学-432 统计学-2019 年

一、选择题 (每小题 3 分, 共 60 分)

1. 将一个骰子独立地掷两次。引进事件: $A_1 = \{ \text{郑第一次出现奇数点} \}$, $A_2 = \{ \text{掷第二次出现偶数点} \}$, $A_3 = \{ \text{奇数点、偶数点各出现一次} \}$, $A_4 = \{ \text{奇数点出现两次} \}$, 则 ()

- (A) A_1, A_2, A_3 两两独立
- (B) A_1, A_2, A_3 相互独立
- (C) A_2, A_3, A_4 两两独立
- (D) A_2, A_3, A_4 相互独立

Solution: A

$$P(A_1) = \frac{1}{2}, P(A_2) = \frac{1}{2}, P(A_3) = \frac{1}{2}, P(A_4) = \frac{1}{4}$$

$P(A_2A_4) = \frac{1}{4} \neq P(A_2)P(A_4)$, 事件 A_2, A_4 不独立, 选项 C, D 错误对于事件 A_1, A_2, A_3 有:

$$P(A_1A_2) = P(A_1)P(A_2) = \frac{1}{4}$$

$$P(A_1A_3) = P(A_1)P(A_3) = \frac{1}{4}$$

$$P(A_2A_3) = P(A_2)P(A_3) = \frac{1}{4}$$

$$P(A_1A_2A_3) = \frac{1}{4} \neq P(A_1)P(A_2)P(A_3)$$

所以事件 A_1, A_2, A_3 两两独立不相互独立. 选项 A 正确

2. 下面的说法哪个是错误的? ()

- (A) $P(AB) \geq P(A) + P(B) - 1$
- (B) $|P(AB) - P(A)P(B)| \leq \frac{1}{4}$
- (C) $P(A \cup B) \leq P(A) + P(B)$
- (D) 两个随机变量不相关不可能推出两个随机变量独立

Solution: D

对于选项 A :

$$P(A) + P(B) - P(AB) = P(A \cup B) \leq 1,$$

有: $P(AB) \geq P(A) + P(B) - 1$ 选项 A 正确

对于选项 B : 另只有事件 A 发生的概率为 a, 只有事件 B 发生的概率为 b, 事件 A B 同时发生的概率为 c, 事件 A B 都不发生的概率为 d 有:

$$\begin{aligned} P(A) &= a + c & P(B) &= b + c \\ P(AB) - P(A)P(B) &= c - (a + c)(b + c) \\ &= c - ab - ac - bc - c^2 \\ &= c(1 - a - b - c) - ab \\ &= cd - ab \end{aligned}$$

因为: $a + b + c + d = 1$, 所以有

$$\begin{aligned} 2\sqrt{ab} &< a + b \leq 1, \sqrt{ab} \leq \frac{1}{2}, ab \leq \frac{1}{4}, \text{同理 } cd \leq \frac{1}{4} \\ -\frac{1}{4} &\leq cd - ab \leq \frac{1}{4}, |cd - ab| \leq \frac{1}{4} \quad \text{选项 B 正确} \end{aligned}$$

对于选项 C :

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \leq P(A) + P(B) \quad \text{正确}$$

对于选项 D：若两个随机变量服从二维正态分布，不相关与独立等价，选项 D 错误。

3. 某领导有 3 个顾问，假定每个顾问贡献正确意见的概率是 0.5。现为某事可行与否而个别征求各顾问意见，并按多数人的意见做出决策，则做出正确决策的概率是 ()

- (A) 0.5
- (B) 0.6
- (C) 2/3
- (D) 0.7

Solution: A

当有两个以上的顾问做出正确决策的时候，最终做出正确决策 $P = 0.5^3 + C_3^2 \times 0.5^2 \times (1 - 0.5) = 0.5$ 选项

A 正确

4. 甲、乙两人轮流射击，先击中目标者获胜。甲、乙击中目标的概率分别是 1/3 和 1/2，甲先射，甲获胜的概率是 ()

- (A) 1/3
- (B) 1/2
- (C) 2/3
- (D) 3/4

Solution: B

甲获胜的可能：第一局甲射中 + 第一局甲乙都没中、第二局甲射中 + 第一、

$$\begin{aligned} P(\text{甲获胜}) &= \frac{1}{3} + \frac{2}{3} \times \frac{1}{2} \times \frac{1}{3} + \left(\frac{2}{3} \times \frac{1}{2}\right)^2 \times \frac{1}{3} + \cdots \\ &= \frac{1}{3} \times \left(1 + \frac{1}{3} + \frac{1}{3^2} \cdots\right) \\ &= \frac{1}{3} \times \frac{3}{2} = \frac{1}{2} \end{aligned}$$

故选 B.

5. 从数 1234 中任取一个数，记为 X ；再从 $1, \dots, X$ 中任取一个数，记为 Y ，则 $P(Y = 3)$ 和 $P(X = 3 | Y = 3)$ 分别等于 ()

- (A) 1/4 和 1/3
- (B) 1/4 和 3/8
- (C) 7/48 和 4/7
- (D) 1/3 和 4/7

Solution: C

$$\begin{aligned} P(Y = 3) &= P(Y = 3 | X = 3) \times P(X = 3) + P(Y = 3 | X = 4) \times P(X = 4) \\ &= \frac{1}{3} \times \frac{1}{4} + \frac{1}{4} \times \frac{1}{4} = \frac{7}{48} \end{aligned}$$

$$P(X = 3 | Y = 3) = \frac{P(X=3, Y=3)}{P(Y=3)} = \frac{\frac{1}{4} \times \frac{1}{3}}{\frac{7}{48}} = \frac{4}{7} \quad \text{选项 C 正确}$$

6. 若随机变量 X 服从 $N(a, \sigma^2)$ ，则 $E|X - a|$ 等于 ()

- (A) $\sqrt{2/\pi}\sigma$
- (B) $\sigma/2$
- (C) σ
- (D) 2σ

Solution: A

考虑 $X - a = \sigma Y$, 其中 $Y \sim N(0, 1)$ 是标准正态, 有

$$E|Y| = \int_{-\infty}^{+\infty} |y| \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} ye^{-\frac{y^2}{2}} dy = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} e^{-\frac{y^2}{2}} d\left(\frac{y^2}{2}\right) = \sqrt{\frac{2}{\pi}}.$$

因此 $E|X - a| = \sigma E|Y| = \sqrt{2/\pi}\sigma$.

7. 随机变量 X 的密度函数为 $f(x) = 2e^{-2x}, x > 0$. 令 $Y = \min(X, 4)$, 则 $P(Y = 4)$ 等于 ()

- (A) e^{-2}
- (B) e^{-4}
- (C) e^{-8}
- (D) $1 - e^{-4}$

Solution: C

$$P(Y = 4) = P(X \geq 4) = \int_4^{+\infty} 2e^{-2x} dx = e^{-8}, \text{ 故选 C.}$$

8. 下面关于方差的叙述中, 不正确的是 ()

- (A) 若 η_1 与 η_2 独立, 则 $D(\eta_1 + \eta_2) = D(\eta_1) + D(\eta_2)$
- (B) 若 $D(\eta_1 + \eta_2) = D(\eta_1) + D(\eta_2)$, 则 η_1 与 η_2 不相关
- (C) 当 $\varepsilon > 0$ 时, $P\{|\eta - E\eta| \geq \varepsilon\} \leq \frac{D(\eta)}{\varepsilon^2}$
- (D) 当 $D(\eta) = 0$ 时, $P\{\eta = E\eta\} = 1$

Solution: C

对于选项 A: 根据 $D(\eta_1 + \eta_2) = D(\eta_1) + D(\eta_2) + 2\text{Cov}(\eta_1, \eta_2)$, 若 η_1, η_2 独立, 则协方差为 0, 则等式成立, 选项 A 正确.

对于选项 B: 由选项可知, η_1, η_2 的协方差为 0, 所以 η_1, η_2 不相关, 选项 B 正确.

对于选项 C: 由切比雪夫不等式

$$P\{|\eta - E\eta| \geq \varepsilon\} \leq \frac{D(\eta)}{\varepsilon^2},$$

故选项 C 错误.

对于选项 D: 因为

$$\begin{aligned} P(\eta \neq E\eta) &= \lim_{n \rightarrow \infty} P\left(\bigcup_{k=n}^{\infty} \left\{|\eta - E(\eta)| > \frac{1}{k}\right\}\right) \\ &\leq \lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} P\left\{|\eta - E(\eta)| > \frac{1}{k}\right\} \\ &\leq \lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} k^2 D(\eta) = 0 \end{aligned}$$

故选项 D 正确.

9. 设随机变量 X 与 Y 相互独立, 且都服从区间 $[0, 1]$ 上的均匀分布, 则 ()

- (A) $Z = X + Y$ 服从 $[0, 2]$ 上的均匀分布
- (B) $Z = X - Y$ 服从 $[-1, 1]$ 上的均匀分布
- (C) $Z = \max\{X, Y\}$ 服从 $[0, 1]$ 上的均匀分布
- (D) (X, Y) 服从区域 $\{(x, y) : 0 \leq x \leq 1, 0 \leq y \leq 1\}$ 上的均匀分布

Solution: D

由于 X, Y 是独立的, 因此 D 选项显然正确. A 选项显然错误, 独立的均匀分布不具有可加性, 其和并不服从均匀分布, B 选项同理. C 选项显然错误, 根据常用结论, 均匀分布的最大次序统计量应是 Beta 分布.

10. 一本书在交付印刷前, 作家和出版社先后对其进行校正. 该书有 300 页, 每页的错误数相互独立且都服从参数为 6 的泊松分布. 在作家的校对过程中, 每个错误相互独立地以概率 0.8 被订正. 在出版社进行的第二次

校正中,前一稿的打印错误相互独立地以概率 0.9 被订正。出版后整本书的错误数大于等于 30 的概率 (用标准正态分布函数 $\Phi(x)$ 表示) 大约是 ()

- (A) $\Phi(1)$
- (B) $\Phi(1.5)$
- (C) $\Phi(2)$
- (D) $2 - \Phi(2)$

Solution: A.

设这本书的错误数为 N , 则 $N \sim \mathcal{P}(1800)$, 每个错误 $X_1, \dots, X_N$ 未被修正的概率是 0.02, 用 $X_i = 1$ 表示第 i 个错误未被修正, 则有 $X_i \sim B(1, 0.02)$, 而最终的错误数是

$$Y = X_1 + X_2 + \dots + X_N = \sum_{k=1}^N X_k,$$

这是经典的复合泊松变量, 也算茆一道原题, 与中山 2017 第 6 题一致, $Y \sim \mathcal{P}(36) \approx N(36, 36)$, 因此

$$P(Y \geq 30) = P\left(\frac{Y - 36}{6} \geq \frac{30 - 36}{6}\right) = 1 - \Phi(-1) = \Phi(1).$$

11. 设 $X_1, \dots, X_n$ 为总体 X 的简单随机样本。若 EX 存在并记为 μ , $\bar{X}$ 为样本均值, 则 ()

- (A) $\bar{X}$ 是 μ 的相合 (consistent) 估计量
- (B) $\bar{X}$ 是 μ 的最大似然估计量
- (C) $\bar{X}$ 是 μ 的充分统计量
- (D) $|\bar{X}|$ 是 $|\mu|$ 的无偏估计量

Solution: A

由柯尔莫哥洛夫强大数定律知 $\bar{x} \xrightarrow{a.s.} \mu$, $\bar{x}$ 是 μ 的强相合估计, A 正确; 对于选项 BC, 随机变量具体分布未知时无法得到选项所提到的结论; 对于选项 D, 除非总体是不变号分布, 否则由 Jensen 不等式可推出其错误。

12. 设 $X_1, \dots, X_n$ 为标准正态分布 $N(0, 1)$ 的简单随机样本。记 $T_1 = \sum_{i=1}^n X_i^2, T_2 = \sum_{i=1}^n (X_i - \bar{X})^2$, 则 ()

- (A) $\frac{T_2/(n-1)}{T_1/n} \sim F(n-1, n)$
- (B) $\frac{T_2/(n-1)}{T_1/n} \sim \text{Beta}(n-1, n)$
- (C) $\frac{T_2}{T_1} \sim \text{Beta}(n-1, n)$
- (D) $\frac{T_2}{T_1} \sim \text{Beta}\left(\frac{n-1}{2}, \frac{1}{2}\right)$

Solution: D

$$T_2 = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 = T_1 - n\bar{x}^2$$

根据 Fisher 引理有 $\bar{x}$ 与 $\sum_{i=1}^n (x_i - \bar{x})^2$ 独立, 则 $T_1 - T_2 = n\bar{x}^2$ 与 T_2 相互独立; 又因为 $n\bar{x}^2 \sim \chi^2(1), \sum_{i=1}^n (x_i - \bar{x})^2 \sim \chi^2(n-1)$, 故

$$\frac{T_2}{T_1} = \frac{T_2}{T_1 - T_2 + T_2} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n\bar{x}^2 + \sum_{i=1}^n (x_i - \bar{x})^2} \sim \text{Beta}\left(\frac{n-1}{2}, \frac{1}{2}\right)$$

D 正确. (补充: 若 $X \sim Ga(\alpha_1, \lambda), Y \sim Ga(\alpha_2, \lambda)$, 且 X, Y 相互独立, 则 $\frac{X}{X+Y} \sim \text{Beta}(\alpha_1, \alpha_2)$)

13. 设 $X_1, \dots, X_n$ 为正态分布 $N(0, \sigma^2)$ 的简单随机样本。记 $T_1 = \sum_{i=1}^n X_i^2, T_2 = \sum_{i=1}^n (X_i - \bar{X})^2$, 则 ()

- (A) T_1 和 T_2 相互独立
- (B) T_1 和 $T_1 - T_2$ 相互独立
- (C) T_1 和 T_1/T_2 相互独立

(D) $T_1 + T_2$ 和 $T_1 - T_2$ 相互独立

Solution: C

由指数族性质可知 T_1 是 σ^2 的充分完全统计量, 记 $Y_i = \frac{X_i}{\sigma}$, 其分布与参数 σ 无关, 故 $\frac{T_1}{\sigma^2} = \sum_{i=1}^n Y_i^2$ 及 $\frac{T_2}{\sigma^2} = \sum_{i=1}^n (Y_i - \bar{Y})^2$ 分布与 σ 无关, 则 $\frac{T_1}{T_2} = \frac{T_1/\sigma^2}{T_2/\sigma^2}$ 分布也与 σ 无关, 由 Basu 定理知 T_1 与 $\frac{T_1}{T_2}$ 独立, C 正确.

14. 设 $X_1, \dots, X_n$ 为泊松分布 Poisson (λ) 的简单随机样本, $\bar{X}$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本均值及样本方差. 令 Z 为服从标准正态分布的随机变量, 则当 $n \rightarrow +\infty$ 时, ()

(A) $\frac{\sqrt{n}\bar{x}}{s}$ 依分布收敛到 Z

(B) $\frac{\sqrt{n}(\bar{X}-\lambda)}{\bar{X}/S}$ 依分布收敛到 Z

(C) $\frac{\sqrt{n}(\bar{x}-\lambda)}{\lambda}$ 依分布收敛到 Z

(D) $\frac{\sqrt{n}(\bar{x}-\lambda)}{\bar{x}}$ 依分布收敛到 Z

Solution: B

由矩估计的相合性知 $\bar{x} \xrightarrow{P} \lambda, s^2 \xrightarrow{P} \lambda$, 则 $\frac{\bar{x}}{s} \xrightarrow{P} \frac{\lambda}{\sqrt{\lambda}} = \sqrt{\lambda}$; 由中心极限定理知 $\frac{\sqrt{n}(\bar{x}-\lambda)}{\sqrt{\lambda}} \xrightarrow{L} Z$, 由 Slutsky 定理得

$$\frac{\sqrt{n}(\bar{x}-\lambda)}{\bar{x}/s} = \frac{\sqrt{n}(\bar{x}-\lambda)}{\sqrt{\lambda}} \cdot \frac{\sqrt{\lambda}}{\bar{x}/s} \xrightarrow{L} Z$$

B 正确.

15. 设 $X_1, \dots, X_n$ 为正态分布 $N(\mu, \sigma^2)$ 的简单随机样本, 其中 μ 已知而 σ^2 未知, 则下列不是统计量的是 ()

(A) $\sum_{i=1}^n X_i/\sigma$

(B) X_1

(C) $\sum_{i=1}^n X_i^2/n$

(D) $\sum_{i=1}^n X_i - n\mu$

Solution: A

统计量不包含未知参数, 故选择 A.

16. 设 $X_1, \dots, X_n$ 为均匀分布 $U(0, \theta)$ 的简单随机样本, 则 θ 的最大似然估计量为 ()

(A) $X_{(1)}$

(B) $\bar{X}$

(C) $X_{(n)}$

(D) $X_1, \dots, X_n$ 的中位数

Solution: C

似然函数 $L(\theta) = \prod_{i=1}^n \frac{1}{\theta} I_{(0 \leq x_i \leq \theta)} = \frac{1}{\theta^n} I_{(x_{(n)} \leq \theta)}$, 似然函数随 θ 单调减, 故 $\hat{\theta}_{MLE} = X_{(n)}$, C 正确.

17. 下列关于统计学常用的分布的判断中, 错误的是 ()

(A) 若 $Z \sim F(n_1, n_2)$, 则 $1/Z \sim F(n_2, n_1)$

(B) 若 $T \sim t(n)$, 则 $T^2 \sim F(1, n)$

(C) 若 $X \sim N(0, 1)$, 则 $X^2 \sim \chi^2(1)$

(D) 若 $X \sim N(0, 1), Y \sim \chi^2(n)$, 则 $X/Y \sim t(n)$

Solution: D

D 选项中, 当 XY 满足题干中要求且独立时, 随机变量 $\frac{X}{\sqrt{Y/n}} \sim t(n)$, D 错误.

18. 设 $X_1, \dots, X_n$ 为正态分布 $N(\mu, 1)$ 的简单样本, 则 μ 的双侧 95% 置信区间为 ()

(A) $\left(\bar{X} - \frac{1.64}{\sqrt{n}}, \bar{X} + \frac{1.64}{\sqrt{n}}\right)$

(B) $\left(\bar{X} - \frac{1.64}{\sqrt{n}}, \bar{X} + \frac{1.96}{\sqrt{n}}\right)$

(C) $\left(\bar{X} - \frac{1.96}{\sqrt{n}}, \bar{X} + \frac{1.64}{\sqrt{n}}\right)$

$$(D) \left(\bar{X} - \frac{1.96}{\sqrt{n}}, \bar{X} + \frac{1.96}{\sqrt{n}} \right)$$

Solution: D

$$\sqrt{n}(\bar{x} - \mu) \sim N(0, 1), P\left(-u_{1-\alpha/2} < \sqrt{n}(\bar{x} - \mu) < u_{1-\alpha/2}\right) = 1 - \alpha, \text{ 即}$$

$$P\left(\bar{x} - \frac{u_{1-\alpha/2}}{\sqrt{n}} < \mu < \bar{x} + \frac{u_{1-\alpha/2}}{\sqrt{n}}\right) = 1 - \alpha,$$

代入 $\alpha = 5\%$ 查表得 μ 的双侧 95% 置信区间为 $\left(\bar{x} - \frac{1.96}{\sqrt{n}}, \bar{x} + \frac{1.96}{\sqrt{n}}\right)$, D 正确.

19. 假设其他条件不变, 把置信度 α 从 2.5% 升到 5%, 则总体均值 μ 的置信程度为 $1 - \alpha$ 的置信区间的宽度将 ()

- (A) 变长
- (B) 不变
- (C) 变短
- (D) 可能变长, 也可能变短

Solution: C

由 18 题解析可知, 置信区间宽度为 $\frac{2u_{1-\alpha/2}}{\sqrt{n}}$, 当 α 由 2.5% 升到 5% 时, $u_{1-\alpha/2}$ 减小, 故置信区间变短, C 正确.

20. 设 $X_1, \dots, X_n$ 为正态分布 $N(\mu_1, \sigma^2)$ 的简单随机样本, $Y_1, \dots, Y_n$ 为正态分布 $N(\mu_2, \sigma^2)$ 的简单随机样本. 若采用方差分析检验: $H_0: \mu_1 = \mu_2, H_1: \mu_1 \neq \mu_2$, 检验统计量为 $F = \frac{MSB}{MSW}$, 其中组间方差 MSB 为 ()

- (A) $\frac{n(\bar{X} - \bar{Y})^2}{2}$
- (B) $\frac{(\bar{X} - \bar{Y})^2}{2}$
- (C) $(\bar{X} - \bar{Y})^2$
- (D) $\frac{\sum_{i=1}^n [(X_i - \bar{X})^2 + (Y_i - \bar{Y})^2]}{2n-2}$

Solution: A

$$MSB = \frac{SSB}{r-1} = \frac{n\left(\bar{X} - \frac{\bar{X} + \bar{Y}}{2}\right)^2 + n\left(\bar{Y} - \frac{\bar{X} + \bar{Y}}{2}\right)^2}{2-1} = \frac{n(\bar{X} - \bar{Y})^2}{2}$$

故 A 正确.

二、(22 分) 已知样本空间 $\Omega = \{\omega_1, \omega_2\}$, $P(\{\omega_1\}) = \frac{1}{3}, P(\{\omega_2\}) = \frac{2}{3}$. 随机变量 $\xi(\omega_1) = 0, \xi(\omega_2) = 1$; 随机变量 $\eta(\omega_1) = 2, \eta(\omega_2) = 1$.

- (1) (6 分) 写出 (ξ, η) 联合分布律.
- (2) (6 分) 求随机变量 ξ, η 相关系数.
- (3) (4 分) 写出随机变量 ξ 和 η 的关系.
- (4) (6 分) 求 $\xi - \eta$ 和 $\xi \cdot \eta$ 的概率分布.

Solution:

(1) (η, ξ) 的联合分布律如下:

(η, ξ)	$\xi = 0$	$\xi = 1$
$\eta = 1$	0	$\frac{2}{3}$
$\eta = 2$	$\frac{1}{3}$	0

$$(2) P(\xi\eta = 1) = \frac{2}{3}, P(\xi\eta = 0) = \frac{1}{3}, E(\xi\eta) = \frac{2}{3} P(\xi = 0) = \frac{1}{3}, P(\xi = 1) = \frac{2}{3}, E(\xi) = \frac{2}{3}, E(\xi^2) = \frac{2}{3}, D(\xi) = \frac{2}{9}$$

$$P(\eta = 1) = \frac{2}{3}, P(\eta = 2) = \frac{1}{3}, E(\eta) = \frac{4}{3}, E(\eta^2) = 2, D(\eta) = \frac{2}{9} \text{ Cov}(\xi, \eta) = E(\xi\eta) - E(\xi)E(\eta) = \frac{2}{3} - \frac{2}{3} \times \frac{4}{3} = -\frac{2}{9}$$

$$\rho_{\xi\eta} = \frac{\text{Cov}(\xi, \eta)}{\sqrt{D(\xi) \times D(\eta)}} = \frac{-\frac{2}{9}}{\sqrt{\frac{2}{9} \times \frac{2}{9}}} = -1$$

(3) 因为 $\rho_{\xi\eta} = -1$, 所以 $\exists a < 0, b \in R, \xi = a\eta + b$, 由 (1) 的分布列可以看出, $\xi + \eta = 2$.

(4) $P(\xi - \eta = -2) = \frac{1}{3}, P(\xi - \eta = 0) = \frac{2}{3}$, 故 $\xi - \eta$ 的概率分布是

$\xi - \eta$	-2	0
p	1/3	2/3

$P(\xi\eta = 1) = \frac{2}{3}, P(\xi\eta = 0) = \frac{1}{3}$, 故 $\xi\eta$ 的概率分布是

$\xi\eta$	0	1
p	1/3	2/3

三、(26 分) 设总体 X 密度函数为 $f(x; \theta) = e^{-(x-\theta)}, x \geq \theta$, 其中 $\theta \in (-\infty, +\infty)$ 为未知参数. $X_1, X_2, \dots, X_n$ 为取自该总体的简单随机样本.

(1) (6 分) 求 θ 的矩法估计量 $\hat{\theta}_1$.

(2) (10 分) 求 θ 的最大似然法估计量 $\hat{\theta}_2$; 并求该总体分布的中位数的最大似然估计量.

(3) (10 分) 基于 $\hat{\theta}_2$ 的分布, 构造 θ 的一个置信水平为 95% 的置信区间.

Solution:

(1)

$$E(X) = \int_{\theta}^{+\infty} x \cdot e^{-(x-\theta)} dx = \theta + 1,$$

由矩法估计, 由替换原理, 得到 θ 的矩法估计量 $\hat{\theta}_1 = \bar{x} - 1$

(2) 样本对应的似然函数是

$$L(\theta) = \prod_{i=1}^n e^{-(x_i-\theta)} I_{\{\theta \leq x_{(1)}\}} = e^{n\theta - \sum_{i=1}^n x_i} I_{\{\theta \leq x_{(1)}\}},$$

它在 θ 的定义域在单调递减, 所以 θ 的最大似然估计是 $\hat{\theta}_2 = x_{(1)}$. 设总体分布的中位数为 M , 有

$$\int_{\theta}^M e^{-(x-\theta)} dx = \frac{1}{2},$$

这说明 $M = \theta + \ln 2$, 由 MLE 的不变性, 该总体分布的中位数的最大似然估计是

$$\hat{M} = x_{(1)} + \ln 2.$$

(3) 因为 $\hat{\theta}_2 = X_{(1)}$, 且 $\theta \leq X_{(1)}$, 因此单侧区间更为合理, $\hat{\theta}_2$ 的概率密度函数是

$$f_{\hat{\theta}_2}(x) = \begin{cases} ne^{-n(x-\theta)}, & \hat{\theta}_2 \geq \theta \\ 0, & \text{其他} \end{cases}$$

设 a 使得 $\int_{\theta}^a ne^{-n(x-\theta)} dx = 0.95$, 解得 $a = \theta + \frac{\ln 20}{n}$. 因此

$$P\left(\theta < \hat{\theta}_2 < \theta + \frac{\ln 20}{n}\right) = 0.95 = P\left(\hat{\theta}_2 - \frac{\ln 20}{n} < \theta < \hat{\theta}_2\right)$$

得到 θ 的 95% 的置信区间是 $\left[x_{(1)} - \frac{\ln 20}{n}, x_{(1)}\right]$.

四、(18 分) 设 $X_1, \dots, X_n$ 为伯努利分布 Bernoulli (p) 的简单随机样本, $P(X_i = 1) = p, P(X_i = 0) = 1 - p$

(1) (8 分) 求 p 的 Fisher 信息 $I(p)$.

(2) (10 分) 证明: $\frac{n}{n-1}\bar{X}(1-\bar{X})$ 是 $p(1-p)$ 最优无偏估计量.

Solution:

(1) 总体的概率函数为 $f(x) = p^x(1-p)^{1-x}$, 故 Fisher 信息量

$$\begin{aligned} I(p) &= -E \left(\frac{\partial^2 \ln f(x)}{\partial p^2} \right) \\ &= E \left(\frac{x}{p^2} + \frac{1-x}{(1-p)^2} \right) \\ &= \frac{1}{p(1-p)}. \end{aligned}$$

(2) 由指数族性质可知 $\bar{x}$ 是充分完全统计量, 而

$$E(\bar{x}) = E(X) = p, D(\bar{x}) = \frac{D(X)}{n} = \frac{p(1-p)}{n},$$

同时有

$$E(\bar{x}^2) = D(\bar{x}) + E^2(\bar{x}) = \frac{p + (n-1)p^2}{n}$$

所以 $E\left(\frac{n-1}{n}\bar{x}(1-\bar{x})\right) = \frac{n-1}{n}(E(\bar{x}) - E(\bar{x}^2)) = p(1-p)$, 又因为 $\bar{x}$ 是充分完全统计量, 由 Lehmann-Scheffe 定理, $\frac{n-1}{n}\bar{x}(1-\bar{x})$ 是 $p(1-p)$ 的 UMVUE.

五、(24 分) 设 $X_1, \dots, X_5$ 为来自正态分布 $N(0, \theta)$ 的简单随机样本, $Y_1, \dots, Y_5$ 为来自正态分布 $N(1, \theta)$ 的简单随机样本. $\theta > 0$ 为未知参数. 令 $T = \sum_{i=1}^5 [X_i^2 + (Y_i - 1)^2]$.

(1) (8 分) 证明: T 是 θ 的充分统计量.

(2) (10 分) 给定显著性水平 $\alpha = 0.05$, 针对假设 $H_0: \theta = 1, H_1: \theta \neq 1$ 构建似然比检验。(注: 拒绝域的界值用分布的分位数表示即可)

(3) (6 分) 写出上述检验的势 (功效) 函数 (power function).

Solution:

(1) 样本联合密度函数为

$$\begin{aligned} f(x_1, \dots, x_5, y_1, \dots, y_5) &= (2\pi\theta)^{-\frac{5}{2}} e^{-\frac{1}{2\theta} \sum_{i=1}^5 x_i^2} (2\pi\theta)^{-\frac{5}{2}} e^{-\frac{1}{2\theta} \sum_{i=1}^5 (y_i - 1)^2} \\ &= (2\pi\theta)^{-5} e^{-\frac{1}{2\theta} \sum_{i=1}^5 [x_i^2 + (y_i - 1)^2]} \end{aligned}$$

由因子分解定理知 T 是 θ 的充分统计量.

(2) 似然函数为 $L(\theta) = (2\pi\theta)^{-5} e^{-\frac{1}{2\theta} T}$, 取对数有

$$\ln L = -5 \ln(2\pi\theta) - \frac{T}{2\theta}$$

对 θ 求导并置 0 得 θ 最大似然估计 $\hat{\theta} = \frac{T}{10}$, 则似然比为

$$\lambda = \frac{\sup_{\theta \in \Theta} L(\theta)}{\sup_{\theta \in \Theta_0} L(\theta)} = \frac{L(\hat{\theta})}{L(1)} = \left(\frac{10}{T}\right)^5 e^{\frac{T}{2}-5},$$

即似然比检验由 $\{\lambda \geq c\}$ 给出, 而 $\lambda = \left(\frac{10}{T}\right)^5 e^{\frac{T}{2}-5}$ 关于 T 先减后增, 故

$$\{\lambda \geq c\} = \{T \leq a\} \cup \{T \geq b\},$$

其中应有 $a^5 e^{-\frac{a}{2}} = b^5 e^{-\frac{b}{2}}$ 满足上式成立, 为满足水平为 α , 还应满足

$$\int_a^b \chi_{10}^2(t) dt = 1 - \alpha,$$

其中, $\chi_{10}^2(x)$ 表明自由度为 10 的卡方分布的密度函数. 为方便, 我们直接取等尾, 即

$$a = \chi_{0.025}^2(10), \quad b = \chi_{0.975}^2(10),$$

所以该似然比检验的拒绝域为

$$W = \left\{ T \leq \chi_{0.025}^2(10) \right\} \cup \left\{ T \geq \chi_{0.975}^2(10) \right\}$$

(3) 该检验的功效函数为

$$\begin{aligned} g(\theta) &= P_{\theta} \left(T \leq \chi_{0.025}^2(10) \right) + P_{\theta} \left(T \geq \chi_{0.975}^2(10) \right) \\ &= P_{\theta} \left(\frac{T}{\theta} \leq \frac{\chi_{0.025}^2(10)}{\theta} \right) + P_{\theta} \left(\frac{T}{\theta} \geq \frac{\chi_{0.975}^2(10)}{\theta} \right) \\ &= 1 - \int_{\frac{\chi_{0.025}^2(10)}{\theta}}^{\frac{\chi_{0.975}^2(10)}{\theta}} \chi_{10}^2(x) dx \end{aligned}$$

其中, $\chi_{10}^2(x)$ 表明自由度为 10 的卡方分布的密度函数.

中山大学-432 统计学-2020 年

一、选择题 (每小题 3 分, 共 30 分)

1. 在 6 对夫妻中任选 4 人, 则至少有一对夫妻被选中的概率为 ().

- (A) $\frac{C_6^1 C_{10}^2}{C_{12}^4}$;
- (B) $\frac{2^4 C_6^4}{C_{12}^4}$;
- (C) $\frac{C_6^4}{C_{12}^4}$;
- (D) $1 - \frac{2^4 C_6^4}{C_{12}^4}$.

Solution: D

考虑对立事件 $\bar{A}$ = “没有一对夫妻被选中”. 对于样本空间 Ω , 有 $\#\Omega = C_{12}^4$, 而 $\#\bar{A} = 2^4 C_6^4$, 因此

$$P(A) = 1 - \frac{2^4 C_6^4}{C_{12}^4}$$

2. 设 A, B, C 都是事件. 又 A 和 B 独立, B 和 C 独立, A 和 C 互不相容. $P(A) = 1/2, P(B) = 1/4, P(C) = 1/8$. 则概率 $P(A \cup B \cup C)$ 为 ().

- (A) $23/33$;
- (B) $23/32$;
- (C) $11/16$;
- (D) $2/3$.

Solution: B

根据题意, 有

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) - P(AB) - P(BC) - P(AC) + P(ABC) \\ &= P(A) + P(B) + P(C) - P(A)P(B) - P(B)P(C) \\ &= \frac{1}{2} + \frac{1}{4} + \frac{1}{8} - \frac{1}{2} \times \frac{1}{4} - \frac{1}{4} \times \frac{1}{8} \\ &= \frac{23}{32} \end{aligned}$$

故 B 选项正确.

3. 将一枚硬币独立地掷两次, 引进事件: $A_1 = \{ \text{第一次出现正面} \}, A_2 = \{ \text{第二次出现正面} \}, A_3 = \{ \text{正、反面各出现一次} \}, A_4 = \{ \text{正面出现两次} \}$, 则 ().

- (A) A_1, A_2, A_3 两两独立;
- (B) A_1, A_2, A_3 相互独立;
- (C) A_2, A_3, A_4 两两独立;
- (D) A_2, A_3, A_4 相互独立.

Solution: A

$$P(A_1) = \frac{1}{2}, P(A_2) = \frac{1}{2}, P(A_3) = \frac{1}{2}, P(A_4) = \frac{1}{4}$$

而 $P(A_1 A_2) = \frac{1}{4} = P(A_1) P(A_2), P(A_1 A_3) = \frac{1}{4} = P(A_1) P(A_3)$,

$$P(A_2 A_3) = \frac{1}{4} = P(A_2) P(A_3), P(A_1 A_2 A_3) = 0 \neq P(A_1) P(A_2) P(A_3),$$

$P(A_2 A_4) = \frac{1}{4} \neq P(A_2) P(A_4)$, 故 A 正确, BCD 错误.

4. 随机变量 X 有密度 $p(x) = \frac{c}{\sqrt{1-x^2}} I_{(-1,1)}(x)$, 则常数 c 的取值为 ().

- (A) 2;

- (B) π ;
 (C) $\pi/2$
 (D) $1/\pi$.

Solution: D

$$\int_{-1}^1 c \frac{1}{\sqrt{1-x^2}} = c \arcsin x \Big|_{-1}^1 = c\pi = 1, c = \frac{1}{\pi}, \text{D 正确.}$$

5. 设 Z 在 $[0, 1]$ 上服从均匀分布, 随机变量 X, Y 满足方程组 $\begin{cases} X + Y = 4Z + 1 \\ X - Y = 2Z - 1 \end{cases}$ 则 X 和 Y 各自落在 $[0, 1]$ 中的概率为 ().

- (A) $1/3$ 和 $1/2$;
 (B) $1/2$ 和 $1/2$;
 (C) $1/3$ 和 0 ;
 (D) $1/3$ 和 $2/3$.

Solution: C

解方程组, 得 $X = 3Z \sim U(0, 3), Y = Z + 1 \sim U(1, 2)$, 则 X 和 Y 各自落在 $[0, 1]$ 的概率为 $1/3$ 和 0 , C 正确. 6.C

$$X \sim P(\lambda), \text{ 则 } E(X) = D(X) = \lambda, P(X=1) = \lambda e^{-\lambda}, P(X=2) = \frac{\lambda^2}{2} e^{-\lambda}$$

6. 设随机变量 X 服从参数为 λ 的泊松分布, 则下列条件中导出参数 $\lambda = 2$ 的条件是 ().

- (A) $EX = 1/2$;
 (B) $\text{Var}(X) = 1/4$;
 (C) $P\{X=1\} = P\{X=2\}$;
 (D) $P\{X=2\} = 2P\{X=1\}$.

Solution: C

$X \sim P(\lambda)$, 则 $E(X) = D(X) = \lambda, P(X=1) = \lambda e^{-\lambda}, P(X=2) = \frac{\lambda^2}{2} e^{-\lambda}$ A 选项: 若 $E(X) = \frac{1}{2}$, 则 $\lambda = \frac{1}{2}$, A 错误. B 选项: 若 $D(X) = \frac{1}{4}$, 则 $\lambda = \frac{1}{4}$, B 错误. C 选项: $\frac{P(X=2)}{P(X=1)} = \frac{\frac{\lambda^2}{2} e^{-\lambda}}{\lambda e^{-\lambda}} = \frac{\lambda}{2} = 1, \lambda = 2$, C 正确. D 选项: $\frac{\lambda}{2} = 2, \lambda = 4$, D 错误.

1. 当随机向量 (X, Y) 服从单位圆 $D = \{(x, y) : x^2 + y^2 \leq 1\}$ 内的均匀分布, 记 Y 的边缘分布是 $F(y)$, Y 关于 X 的条件分布为 $G(y|x)$, 则 ().

- (A) $F(y)$ 不服从均匀分布, $G(y|x)$ 服从均匀分布;
 (B) $F(y)$ 服从均匀分布, $G(y|x)$ 不服从均匀分布;
 (C) 二者均服从均匀分布;
 (D) 二者均不服从均匀分布.

Solution: A

$S_D = \pi$, 于是 (X, Y) 的联合密度为

$$f(x, y) = \begin{cases} \frac{1}{\pi}, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

Y 的边缘密度函数是

$$f_Y(y) = \int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} \frac{1}{\pi} dx = \frac{2\sqrt{1-y^2}}{\pi}, -1 < y < 1$$

同理 X 的边缘密度函数是 $f_X(x) = \frac{2\sqrt{1-x^2}}{\pi}, -1 < x < 1$ 因此得到 Y 的条件密度函数为

$$f_{Y|X}(y|x) = \frac{f(x,y)}{f_X(x)} = \frac{1}{2\sqrt{1-x^2}}, \quad -\sqrt{1-x^2} < y < \sqrt{1-x^2}$$

故 Y 不服从均匀分布, $Y|X$ 服从均匀分布, A 正确.

8. 设随机变量 $X \sim t(n), n > 1, Y = 1/X^2$, 则 ().

- (A) $Y \sim \chi^2(n)$;
- (B) $Y \sim \chi^2(n-1)$;
- (C) $Y \sim F(1, n)$;
- (D) $Y \sim F(n, 1)$.

Solution: D

由于 $X \sim t(n)$, 故 X 可分解为 $X = \frac{Z}{\sqrt{V/n}}$, 其中 $Z \sim N(0, 1), V \sim \chi^2(n)$ 且 ZV 相互独立, 则 $Y = \frac{1}{X^2} = \frac{V/n}{Z^2} \sim F(n, 1)$, D 正确. 9.C A 选项错误:

$$D(X_i + \bar{X}) = D\left(\frac{n+1}{n}X_i + \frac{1}{n}\sum_{j \neq i} X_j\right) = \frac{(n+1)^2}{n^2}\sigma^2 + \frac{n-1}{n^2}\sigma^2 = \frac{n+3}{n}\sigma^2$$

9. 设 $X_1, X_2, \dots, X_n (n > 1)$ 为来自总体期望为 μ , 总体方差为 σ^2 的简单随机样本, 记 $\bar{X}$ 为样本均值, 则 ().

- (A) $D(X_i + \bar{X}) = \frac{n+2}{n}\sigma^2$;
- (B) $D(X_i - \bar{X}) = \frac{n+1}{n}\sigma^2$;
- (C) $\text{Cov}(X_i, \bar{X}) = \frac{1}{n}\sigma^2$;
- (D) $\text{Cov}(X_i, \bar{X}) = \sigma^2$.

Solution: B 选项错误:

$$D(X_i - \bar{X}) = D\left(\frac{n-1}{n}X_i - \frac{1}{n}\sum_{j \neq i} X_j\right) = \frac{(n-1)^2}{n^2}\sigma^2 + \frac{n-1}{n^2}\sigma^2 = \frac{n-1}{n}\sigma^2$$

C 选项正确, D 选项错误:

$$\text{Cov}(X_i, \bar{X}) = \text{Cov}\left(X_i, \frac{1}{n}X_i + \frac{1}{n}\sum_{j \neq i} X_j\right) = \text{Cov}\left(X_i, \frac{1}{n}X_i\right) = \frac{1}{n}\sigma^2$$

10. 设 $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; 0)$, 若 $P\{|X - \mu_1| < c\} < P\{|Y - \mu_2| < c\}$, 其中 c 为某一正数, 则 ().

- (A) $\sigma_1^2 < \sigma_2^2$;
- (B) $\sigma_1^2 > \sigma_2^2$;
- (C) $\mu_1 < \mu_2$;
- (D) $\mu_1 > \mu_2$;

Solution: B

由于 $P\left(\frac{|X-\mu_1|}{\sigma_1} < \frac{c}{\sigma_1}\right) < P\left(\frac{|Y-\mu_2|}{\sigma_2} < \frac{c}{\sigma_2}\right)$, 即

$$2\Phi\left(\frac{c}{\sigma_1}\right) - 1 < 2\Phi\left(\frac{c}{\sigma_2}\right) - 1,$$

这说明 $\Phi\left(\frac{c}{\sigma_1}\right) < \Phi\left(\frac{c}{\sigma_2}\right)$, 由于 $\Phi(x)$ 单调增, 故 $\frac{c}{\sigma_1} < \frac{c}{\sigma_2}, \sigma_1^2 > \sigma_2^2$, B 正确.

11. 设 $EX = 0, \text{Var}(X) = 1, EY = 1, \text{Var}(Y) = 4$, 相关系数 $\rho_{XY} = 1$, 则 ().

- (A) $P(2X - Y + 1 = 0) = 1$;
 (B) $P(2X - Y - 1 = 0) = 1$;
 (C) $P(2X + Y + 1 = 0) = 1$;
 (D) $P(2X + Y - 1 = 0) = 1$.

Solution: A

因为 X 与 Y 的相关系数为 1, 所以 X 和 Y 之间几乎处处存在正的线性关系, 即存在 $a > 0, P(Y = aX + b) = 1$. 所以有

$$\begin{cases} E(Y) = aE(X) + b, \\ Var(Y) = a^2 Var(X), \end{cases} \text{ 解得 } \begin{cases} a = 2, \\ b = 1, \end{cases}$$

因此 $P(Y = 2X + 1) = 1$, 即 $P(2X - Y + 1 = 0) = 1$, 选项 A 正确.

12. 在假设检验中, 第一类错误是指 (). (A) 当原假设为真时, 接受原假设;
 (B) 当原假设为真时, 拒绝原假设;
 (C) 当备择假设为真时, 接受原假设;
 (D) 当备择假设为真时, 拒绝原假设.

Solution: B

假设检验中存在两类错误. 第一类错误是: 原假设为真但拒绝原假设. 第二类错误是: 备择假设为真而接受原假设. 本题所问的是第一类错误, 故选项 B 正确.

13. 设 n 个随机变量 $X_1, X_2, \dots, X_n$ 独立同分布, $Var(X_1) = \sigma^2 < +\infty$, $\bar{X}$ 与 S^2 分别为样本均值与样本方差, 则 ().

- (A) S 与 $\bar{X}$ 相互独立;
 (B) S 是 σ 的相合估计量;
 (C) S 是 σ 的最大似然估计量;
 (D) S 是 σ 的无偏估计量.

Solution: B

当 $X_1, X_2, \dots, X_n$ 相互独立且服从正态分布时, $\bar{X}$ 与 S 相互独立, 且有 $E(S^2) = \sigma^2$, 但题目没给出具体分布, 故 A 错, 同理也无法求出 σ 的最大似然估计量, 因此 C 错误. 由 Jensen 不等式, D 错. 选项 B 正确, 因为我们知道 S^2 是 σ^2 的相合估计量, 由依概率收敛的运算法则, 有 S 是 σ 的相合估计量.

14. 设 $X_1, X_2, \dots, X_n$ 为来自正态分布 $N(\mu, \sigma^2)$ 的样本, 其中 μ 为已知, $\bar{X}$ 为样本均值, 则 σ^2 的最大似然估计为 ().

- (A) $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$;
 (B) $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$;
 (C) $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$;
 (D) $\frac{1}{n-1} \sum_{i=1}^n (X_i - \mu)^2$.

Solution: C

样本对应的似然函数是

$$L(\sigma) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

两边同时取对数得 $\ln L(\sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$, 对其求导并令其导数为 0, 得到 σ^2 的最大似然估计 $\hat{\sigma}^2 = \sum_{i=1}^n \frac{(x_i - \mu)^2}{n}$, 故选项 C 正确.

15. 设总体 X 的概率密度函数为 $f(x; \theta) = \begin{cases} e^{-(x-\theta)}, & x \geq \theta; \\ 0, & x < \theta \end{cases}$, $X_1, X_2, \dots, X_n$ 为来自总体 X 的样本, 则 θ 的矩估计量为 ().

- (A) $\bar{X}$;
 (B) $\bar{X} - 1$;
 (C) $\bar{x} + 1$;
 (D) $1/\bar{X}$.

Solution: B

$$E(X) = \int_{\theta}^{+\infty} x e^{-(x-\theta)} dx = \theta + 1,$$

由替换原理, 得到 θ 的矩估计为: $\hat{\theta} = \bar{X} - 1$

16. 设 $X_1, X_2, \dots, X_n$ 为来自正态分布 $N(\mu, \sigma^2)$ 的样本, 其中 σ^2 为已知, $\bar{X}$ 为样本均值. 考虑如下假设检验: $H_0: \mu \leq \mu_0$ v.s. $H_1: \mu > \mu_0$, 标准正态分布的 95% 分位数为 1.645, 在显著性水平为 0.05 时, 拒绝 H_0 等价于 (). (A) 单侧区间 $(\bar{X} + 1.645 \frac{\sigma}{\sqrt{n}}, +\infty)$ 不包含 μ_0 ;

- (B) 单侧区间 $(\bar{X} + 1.645 \frac{\sigma}{\sqrt{n}}, +\infty)$ 包含 μ_0 ;
 (C) 单侧区间 $(-\infty, \bar{X} - 1.645 \frac{\sigma}{\sqrt{n}})$ 不包含 μ_0 ;
 (D) 单侧区间 $(-\infty, \bar{X} - 1.645 \frac{\sigma}{\sqrt{n}})$ 包含 μ_0 .

Solution: D

依题意, 可知这是一个正态总体均值的右单侧检验, 拒绝域为

$$W = \left\{ \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > 1.645 \right\}$$

这等价于 $\mu_0 < \bar{X} - 1.645 \frac{\sigma}{\sqrt{n}}$, 所以选项 D 正确.

17. 设 $X_1, X_2, \dots, X_n$ 独立同分布, 具有期望 μ , 则 ().

- (A) $\exp(\bar{X})$ 是 e^μ 的相合估计量;
 (B) $\exp(\bar{X})$ 是 e^μ 的最大似然估计量;
 (C) $\exp(\bar{X})$ 是 e^μ 的无偏估计量;
 (D) $\exp(\bar{X})$ 是 e^μ 的充分统计量.

Solution: A

由大数定律和依概率收敛可以由连续函数传递, 得 A 正确. B, D 错误, 因为具体分布未知. C 错误, 根据 Jensen 不等式很快知道 $E(e^{\bar{x}}) \geq e^{E(\bar{x})} = e^\mu$, 除非 $\bar{X}$ 等于常数才有等号成立.

18. 设 X_1, X_2 都服从参数为 1 的指数分布, Y 服从参数为 2 的指数分布, $f(y) = 2e^{-2y}, 0 < y < \infty$, 且 X_1, X_2, Y 相互独立, 则 ().

- (A) $\frac{X_1+X_2}{4Y} \sim F(4, 2)$;
 (B) $\frac{X_1+X_2}{Y} \sim F(4, 2)$;
 (C) $\frac{X_1+X_2}{4Y} \sim F(2, 2)$;
 (D) $\frac{X_1+X_2}{Y} \sim F(2, 2)$.

Solution: A

我们知道对于参数为 λ 的指数分布 Z , 有 $2\lambda Z \sim \chi^2(2)$, 故有

$$\frac{X_1 + X_2}{4Y} = \frac{(2X_1 + 2X_2)/4}{4Y/2} \sim F(4, 2),$$

A 选项正确.

19. 设 $\hat{\theta}$ 为参数 θ 的估计量, 且 $\hat{\theta}$ 的期望与方差 σ^2 均存在, 则必有 ().

- (A) $P(|\hat{\theta} - \theta| \geq 2\sigma) \geq 0.5$;
 (B) $P(|\hat{\theta} - \theta| \geq 2\sigma) \leq 0.5$;

- (C) $P(|\hat{\theta} - \theta| \geq 2\sigma) \geq \frac{E(\hat{\theta} - \theta)^2}{4\sigma^2}$;
 (D) $P(|\hat{\theta} - \theta| \geq 2\sigma) \leq \frac{E(\hat{\theta} - \theta)^2}{4\sigma^2}$.

Solution: D

因为 $\hat{\theta}$ 的期望和方差均存在, 由马尔可夫不等式,

$$P(|\hat{\theta} - \theta| \geq 2\sigma) \leq \frac{E(\hat{\theta} - \theta)^2}{4\sigma^2},$$

故选项 D 正确

20. 设 $\hat{\theta}_n$ 为参数 θ 的估计量, 且 $\hat{\theta}_n$ 的期望与方差均存在, 当样本量 $n \rightarrow \infty$ 时, $E(\hat{\theta}_n) \rightarrow \theta, \text{Var}(\hat{\theta}_n) \rightarrow 0$, 则以下说法错误的是 ().

- (A) $\hat{\theta}_n$ 是 θ 的相合估计量;
 (B) $\hat{\theta}_n$ 依分布收敛到 θ ;
 (C) $P(\lim_{n \rightarrow \infty} \hat{\theta}_n = \theta) = 1$;
 (D) $\lim_{n \rightarrow \infty} E[(\hat{\theta}_n - \theta)^2] = 0$.

Solution: C

由于 $E(\hat{\theta}_n - \theta)^2 = (E(\hat{\theta}_n) - \theta)^2 + \text{Var}(\hat{\theta}_n)$, 因此题设条件可以推出均方收敛, 即 D 正确. 而均方收敛可以推出依概率收敛, 即 A 正确. 依概率收敛可以推出按分布收敛, 故 B 正确. C 错误, 反例如 $\hat{\theta}_n = \theta + X_n$, 其中 $X_1, \dots, X_n, \dots$ 独立, 且 $X_n \sim B(1, \frac{1}{n})$, 满足题设条件, 且 $P(|\hat{\theta}_n - \theta| > \varepsilon) = \frac{1}{n}$, 根据 Borel-Cantelli 第二引理, 有 $\hat{\theta}_n$ 不以概率 1 收敛于 θ .

二、(20 分) 已知简单随机样本 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} U(0, \theta)$.

- (1) 求 $X_{(1)}$ 的概率密度, 并求 $EX_{(1)}$;
 (2) 求 $(X_{(1)}, X_{(n)})$ 联合概率密度;
 (3) 求 $R = X_{(n)} - X_{(1)}$ 的概率密度函数;
 (4) 在 $X_{(n)} = y$ 条件下, 求 $X_{(1)}$ 的分布.

Solution:

(1) X 的概率密度函数为 $f(x) = \frac{1}{\theta}$, 分布函数 $F(x) = \frac{x}{\theta}$, 记 $U = X_{(1)}$, 则

$$F(u) = 1 - \left(1 - \frac{u}{\theta}\right)^n, f(u) = \frac{n}{\theta} \left(1 - \frac{u}{\theta}\right)^{n-1}$$

显然有 $\frac{X_{(1)}}{\theta} \sim \text{Beta}(1, n)$, 故 $EX_{(1)} = \frac{\theta}{n+1}$.

(2) 由次序统计量分布公式, 有 $(X_{(1)}, X_{(n)})$ 联合分布是

$$\begin{aligned} f(u, v) &= \frac{n!}{(n-2)!} f_X(u) f_X(v) (F(v) - F(u))^{n-2} \\ &= \frac{n(n-1)}{\theta^n} (v-u)^{n-2} \end{aligned}$$

(3) 作变量变换, 令 $Z_1 = X_{(n)} - X_{(1)}, Z_2 = X_{(n)}$, 有

$$\begin{cases} X_{(1)} = Z_2 - Z_1 \\ X_{(n)} = Z_2 \end{cases}$$

雅各比行列式 $J = \begin{vmatrix} \frac{\partial X_{(1)}}{\partial Z_1} & \frac{\partial X_{(1)}}{\partial Z_2} \\ \frac{\partial X_{(n)}}{\partial Z_1} & \frac{\partial X_{(n)}}{\partial Z_2} \end{vmatrix} = \begin{vmatrix} -1 & 1 \\ 0 & 1 \end{vmatrix} = -1$, 则

$$f(z_1, z_2) = |J| f(x_{(1)}, x_{(n)}) = \frac{n(n-1)}{\theta^n} (x_{(n)} - x_{(1)})^{n-2} = \frac{n(n-1)}{\theta^n} z_1^{n-2},$$

则有

$$\begin{aligned} f(r) &= f(z_1) = \int_{z_1}^{\theta} f(z_1, z_2) dz_2 = \int_{z_1}^{\theta} \frac{n(n-1)}{\theta^n} z_1^{n-2} dz_2 \\ &= \frac{n(n-1)}{\theta^n} z_1^{n-2} (\theta - z_1) = \frac{n(n-1)}{\theta^n} r^{n-2} (\theta - r), \end{aligned}$$

实际上, 有 $\frac{R}{\theta} \sim \text{Beta}(n-1, 2)$.

(4) 由于 $\frac{X_{(n)}}{\theta} \sim \text{Beta}(n, 1)$, 故有密度函数, $f(v) = n \frac{v^{n-1}}{\theta^n}$, 故条件分布是

$$\begin{aligned} f(u|v) &= \frac{f(u, v)}{f(v)} = \frac{\frac{n(n-1)}{\theta^n} (v-u)^{n-2}}{n \frac{v^{n-1}}{\theta^n}} = (n-1) \frac{1}{v} \left(1 - \frac{u}{v}\right)^{n-2}, \\ \text{故 } f(u|v=y) &= (n-1) \frac{1}{y} \left(1 - \frac{u}{y}\right)^{n-2}. \end{aligned}$$

三、(15 分) 已知随机样本 $X_1, \dots, X_n$ 来自于同一总体, 总体的密度函数为:

$$f(x|\theta) = \begin{cases} \theta, & 0 \leq x < 1 \\ 1-\theta, & 1 \leq x < 2 \end{cases}$$

记 M 为所有样本中小于 1 的个数.

- (1) 求 θ 的矩估计;
- (2) 求 θ 的 MLE;
- (3) 求 θ 的 MLE 的分布.

Solution:

(1)

$$E(X) = \int_0^1 x\theta dx + \int_1^2 x(1-\theta)dx = \frac{3}{2} - \theta$$

由替换原理, θ 的矩估计 $\hat{\theta}_1 = \frac{3}{2} - \bar{x}$.

(2) 似然函数 $L(\theta) = \theta^M (1-\theta)^{n-M}$, 取对数有

$$\ln L(\theta) = M \ln \theta + (n-M) \ln(1-\theta),$$

(3) 显然 $M = n\hat{\theta}_2$ 是二项分布, 故

$$P\left(\hat{\theta}_2 = \frac{k}{n}\right) = P(M=k) = \binom{n}{k} \theta^k (1-\theta)^{n-k}, k=0, 1, \dots, n.$$

四、(30 分) 已知随机样本 $X_1, \dots, X_n \stackrel{iid}{\sim} B(1, p)$, 定义统计量 $T = \sum_{i=1}^n X_i$.

- (1) 用充分统计量的定义证明 T 是 p 的充分统计量;
- (2) 定义 $h(X_1, \dots, X_k) = \begin{cases} 1, & X_1 = X_2 = \dots = X_k = 1; \\ 0, & \text{其他.} \end{cases}$, 证明它是 p^k 的无偏估计;
- (3) 求 p^k 的 UMVUE.

Solution: (1) 样本对应的似然函数是 $L(p) = p^t (1-p)^{n-t}$, 根据因子分解定理: T 为 p 的充分统计量.

(2) 由于各样本之间独立, 故

$$\begin{aligned} E(h(X_1, \dots, X_k)) &= P(X_1 = X_2 = \dots = X_k = 1) \\ &= P(X_1 = 1) P(X_2 = 1) \cdots P(X_k = 1), \\ &= p^k, \end{aligned}$$

所以 $h(X_1, \dots, X_k)$ 是 p^k 的无偏估计量.

(3) 因为 T 为 p 的充分统计量, 同时由指数族分布的性质知, 它还是完全统计量, 且由 (2), $h(X_1, \dots, X_k)$ 是 p^k 的无偏估计量. 可知:

$$E[E(h(X_1, \dots, X_k) | T)] = E(h(X_1, \dots, X_k)) = p^k,$$

由 Lehmann-Scheffe 定理知 $E(h(X_1, \dots, X_k) | T)$ 为 p^k 的 UMVUE. 当 $t < k$, 显然有

$$E(h(X_1, \dots, X_k) | T = t) = 0,$$

但对 $t \geq k$, 有

$$\begin{aligned} E(h(X_1, \dots, X_k) | T) &= \frac{P(h=1, T=t)}{P(T=t)} \\ &= \frac{P(x_1=x_2=\dots=x_k=1)P(\sum_{i=k+1}^n x_i=t)}{P(\sum_{i=1}^n x_i=t)} \\ &= \frac{p^k \cdot C_{n-k}^{t-k} \cdot p^{t-k} \cdot (1-p)^{n-t}}{C_n^t \cdot p^k \cdot (1-p)^{n-t}} = \frac{C_{n-k}^{t-k}}{C_n^t} \end{aligned}$$

所以 p^k 的 UMVUE 为

$$\hat{g} = \begin{cases} 0, & T < k, \\ \frac{C_{n-k}^{T-k}}{C_n^T}, & T \geq k. \end{cases}$$

五、(25 分) 设简单随机样本 $X_1, \dots, X_n$ 来自于总体

$$f(x | \theta) = \begin{cases} \frac{2x}{\theta} \exp\left(-\frac{x^2}{\theta}\right), & x \geq 0 \\ 0, & x < 0 \end{cases}$$

记 $T = \sum_{i=1}^n X_i^2$.

(1) 证明 T 是 θ 的充分统计量;

(2) 利用 T 构建 θ 的 95% 置信区间;

(3) 假设检验问题 $H_0: \theta = 1$ vs $H_1: \theta > 1$ 是否存在 UMP 拒绝域? 如果存在, 写出拒绝域; 如果不存在, 请说明理由.

Solution:

(1) 样本对应的似然函数是

$$L(\theta) = \prod_{i=1}^n 2x_i e^{-\frac{x_i^2}{\theta}} = 2^n \left(\prod_{i=1}^n x_i \right) e^{-\frac{\sum_{i=1}^n x_i^2}{\theta}},$$

由因子分解定理, $T = \sum_{i=1}^n X_i^2$ 是 θ 的充分统计量.

(2) 令 $Y = \frac{T}{\theta}$, 则它的分布函数是

$$\begin{aligned} F_Y(y) &= P(Y < y) = P\left(\frac{T}{\theta} < y\right) = P(T < \sqrt{\theta y}) \\ &= \int_0^{\sqrt{\theta y}} \frac{2x}{\theta} e^{-\frac{x^2}{\theta}} dx = 1 - e^{-y}, \quad y > 0, \end{aligned}$$

即 Y 服从参数为 1 的指数分布, 因此 $\frac{2T}{\theta} \sim Ga(n, 2) = \chi^2(2n)$, 故

$$P\left(\chi_{0.025}^2(2n) < \frac{2T}{\theta} < \chi_{0.975}^2(2n)\right) = 0.95,$$

故 θ 的 95% 置信区间为 $\left[\frac{2T}{\chi_{0.975}^2(2n)}, \frac{2T}{\chi_{0.025}^2(2n)}\right]$.

(3) 由于该问题是单参指数族的单侧检验问题, 因此存在 UMP 拒绝域, 构造似然比

$$\lambda = \frac{L(1)}{L(\theta_2)} = \frac{\prod_{i=1}^n f(x_i; 1)}{\prod_{i=1}^n f(x_i, \theta_2)} = \frac{(\prod_{i=1}^n 2x_i) e^{-T}}{(\prod_{i=1}^n \frac{2x_i}{\theta_2}) e^{-\frac{T}{\theta_2}}} = \frac{\theta_2^n e^{-T}}{e^{-\frac{T}{\theta_2}}} = \theta_2^n e^{T(\frac{1}{\theta_2} - 1)}$$

其中 θ_2 为一个大于 1 的常数, 可以得到 UMP 拒绝域由 $W = \{\lambda < C\}$ 导出, 而由于 $\lambda = \theta_2^n e^{T(\frac{1}{\theta_2} - 1)}$ 是 T 的单调减函数, 故拒绝域即为 $W = \{T > C_1\}$, 为使得其水平为 α , 可以求得 UMP 拒绝域是

$$W = \left\{T > \frac{\chi_{1-\alpha}^2(2n)}{2}\right\}.$$

中山大学-432 统计学-2021 年

一、选择题 (每小题 3 分, 共 30 分)

1. 设 X 和 Y 都服从标准正态分布, 则 ().

- (A) $X + Y$ 服从正态分布;
- (B) $X^2 + Y^2$ 服从卡方分布;
- (C) X^2 和 Y^2 都服从卡方分布;
- (D) X^2/Y^2 服从 F 分布.

Solution: C

若 X, Y 相互独立, 则 ABCD 皆成立; 未说明 X, Y 关系时, ABD 不一定正确. 例如当 $X = -Y \sim N(0, 1)$ 时, $X + Y = 0$ 不服从正态分布, A 错误, $X^2 + Y^2 = 2X^2 \sim Ga(\frac{1}{2}, \frac{1}{4})$, B 错误, $\frac{X^2}{Y^2} = 1$, D 错误. 故选择 C 选项.

2. 设 $X_1, X_2, \dots, X_n$ 为来自二项分布 $B(m, p)$ 的样本, $\bar{X}$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 分别为样本均值和样本方差, $\bar{X} + cS^2$ 为 mp^2 的无偏估计量, 则 $c =$ ().

- (A) $c = -2$;
- (B) $c = -1$;
- (C) $c = 1$;
- (D) $c = 2$.

Solution: B 由于

$$E(\bar{x} + cs^2) = mp + cmp(1-p) = -cmp^2 + m(c+1)p = mp^2,$$

故 $c = -1$, B 正确.

3. 已知 $X \sim \exp(\theta)$, 则 $P(X > EX) =$ ().

- (A) $1 - e^{-1}$;
- (B) $1 - e^{-2}$;
- (C) e^{-1} ;
- (D) e^{-2} .

Solution: C

$$EX = \frac{1}{\theta}, P(X > EX) = 1 - F\left(\frac{1}{\theta}\right) = e^{-\theta \frac{1}{\theta}} = e^{-1}$$

4. 已知 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \exp(1)$, F_n 是 $X_{(n)}$ 的 cdf, 则 $\lim_{n \rightarrow \infty} F_n(100) =$ ().

- (A) 0 ;
- (B) 0.5;
- (C) 1 ;
- (D) 不存在.

Solution: A

$$\begin{aligned} \lim_{n \rightarrow \infty} F_n(100) &= \lim_{n \rightarrow \infty} [F(100)]^n \\ &= \lim_{n \rightarrow \infty} (1 - e^{-100})^n \\ &= 0 \end{aligned}$$

5. 下列说法错误的是 ().

- (A) 如果 $X_n \rightarrow X, a.s.$, 那么 $X_n \xrightarrow{p} X$;
- (B) 如果 $E(X_n - X)^2 \rightarrow 0$, 那么 $X_n \rightarrow X, a.s.$;
- (C) 概率具有单调性, 下连续性, 有限可加性;
- (D) 分布函数具有单调性, 有界性, 并且是几乎处处可导的.

Solution: B B 错误, 均方收敛不一定能推出依概率收敛. 如 $X_1, \dots, X_n, \dots$ 独立, 且 $X_k \sim B(1, \frac{1}{n})$, 它满足均方收敛到 0 的条件, 但由 Borel-Cantelli 第二引理, 它不几乎处处收敛于 0.

6. 设 $h(x) = [x]$, 已知 $\xi \sim \exp(\theta)$, 则 $h(\xi)$ 的分布是 ().

- (A) 泊松分布, 参数为 $e^{-\theta}$;
- (B) 几何分布, 参数为 $e^{-\theta}$;
- (C) 泊松分布, 参数为 $1 - e^{-\theta}$;
- (D) 几何分布, 参数为 $1 - e^{-\theta}$.

Solution: $h(\xi) + 1$ 的分布是参数为 $(1 - e^{-\theta})$ 的几何分布 ξ 的分布函数是 $F_{\xi}(x) = \begin{cases} 1 - e^{-\theta x} & x > 0 \\ 0 & \text{其他} \end{cases}$

$$\begin{aligned} P(h(\xi) + 1 = x) &= P([\xi] = x - 1) \\ &= P(x - 1 \leq \xi < x) \\ &= F_{\xi}(x) - F_{\xi}(x - 1) \\ &= 1 - e^{-\theta x} - (1 - e^{-\theta(x-1)}) \\ &= e^{-\theta(x-1)-\theta} - e^{-\theta(x-1)} = e^{-\theta(x-1)} (1 - e^{-\theta}) \end{aligned}$$

故 $h(\xi) + 1$ 服从参数为 $(1 - e^{-\theta})$ 的几何分布.

7. 已知独立双样本 $X_1, \dots, X_n \stackrel{iid}{\sim} N(0, \sigma_X^2)$, $Y_1, \dots, Y_m \stackrel{iid}{\sim} N(0, \sigma_Y^2)$, 原假设为 $\sigma_X = \sigma_Y$. 问样本方差之比 S_X^2/S_Y^2 在原假设为真时服从的分布是 ().

- (A) $F(n, m)$;
- (B) $F(m, n)$;
- (C) $F(n - 1, m - 1)$;
- (D) $F(m - 1, n - 1)$.

Solution: C 因为

$$S_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}, \quad S_Y^2 = \frac{\sum_{i=1}^m (Y_i - \bar{Y})^2}{m - 1},$$

当 $\sigma_X = \sigma_Y$ 时, 有

$$\frac{S_X^2}{S_Y^2} = \frac{\frac{\chi^2(n-1)}{n-1}}{\frac{\chi^2(m-1)}{m-1}} \sim F(n - 1, m - 1),$$

注意这里是“样本方差”, 即使 μ 已知, 样本方差依然是 $S_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$, $S_Y^2 = \frac{\sum_{i=1}^m (Y_i - \bar{Y})^2}{m-1}$.

8. 一个人连续射击, 直到把子弹打完为止, 每次射击打中目标的概率为 $1/2$. 枪中含有的子弹个数为随机变量, 取值为 $\{1, 2, 3\}$, 概率均为 $1/3$, 则打中目标至少一次的概率是 ().

- (A) $17/24$;
- (B) $7/24$;
- (C) $3/4$;
- (D) $1/4$.

Solution: A 令事件 A_i 表示子弹数为 i 个, 令事件 B 表示一次都没命中, 由全概率公式, 得

$$\begin{aligned} P(B) &= P(B | A_1) P(A_1) + P(B | A_2) P(A_2) + P(B | A_3) P(A_3) \\ &= \frac{1}{3} \times \frac{1}{2} + \frac{1}{3} \times \frac{1^2}{2} + \frac{1}{3} \times \frac{1^3}{2} = \frac{1}{3} \times \frac{7}{8} = \frac{7}{24} \end{aligned}$$

故 $P(\bar{B}) = \frac{17}{24}$.

9. 已知 $(X, Y) \sim f(x, y) = 3(1 - y)I[0 < x < y < 1]$, 则 $P(X + Y < 1) = ()$.

- (A) $3/8$;
- (B) $5/8$;
- (C) $5/16$;
- (D) $3/4$.

Solution: A

$$\begin{aligned} P(X + Y < 1) &= 3 \int_0^{\frac{1}{2}} dx \int_x^{-x+1} (1 - y) dy \\ &= 3 \int_0^{\frac{1}{2}} \left(-x + \frac{1}{2}\right) dx \\ &= 3 \times \frac{1}{8} = \frac{3}{8}. \end{aligned}$$

10. 已知 $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$, $E\left[c \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2\right] = \sigma^2$, 则 $c = ()$.

- (A) $\frac{1}{2n}$;
- (B) $\frac{1}{2n-1}$;
- (C) $\frac{1}{2n-2}$;
- (D) $\frac{1}{n}$.

Solution: C

$$\begin{aligned} E[(X_{i+1} - X_i)^2] &= E[(X_{i+1})^2] - 2E(X_{i+1})E(X_i) + E[(X_i)^2] \\ &= 2(\mu^2 + \sigma^2) - 2\mu^2 = 2\sigma^2 \end{aligned}$$

$$E\left[c \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2\right] = c \sum_{i=1}^{n-1} 2\sigma^2 = 2c(n-1)\sigma^2 = \sigma^2$$

故 $c = \frac{1}{2n-2}$.

二、(20 分) 已知 $Y \sim N(\mu_Y, \sigma^2)$, $X | Y = y \sim N(ay + b, 2\sigma^2)$, 计算:

- (1) EX ;
- (2) DX ;
- (3) $\rho_{X,Y}$;
- (4) (X, Y) 的联合分布.

Solution:

(1) 由重期望公式, 得

$$E(X) = E(E(X | Y)) = E(aY + b) = a\mu_Y + b.$$

(2) 由方差分解定理 (方差恒等式), 得

$$\begin{aligned} D(X) &= E(D(X | Y)) + D(E(X | Y)) \\ &= E(2\sigma^2) + D(aY + b) \\ &= 2\sigma^2 + a^2\sigma^2 = (a^2 + 2)\sigma^2 \end{aligned}$$

(3) 由重期望公式, 得

$$\begin{aligned} E(XY) &= E[E(XY | Y)] = E[Y E(X | Y)] = E[Y(aY + b)] \\ &= aE(Y^2) + bE(Y) = a(\mu_Y^2 + \sigma^2) + b\mu_Y \end{aligned}$$

因此, 有

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = a\sigma^2$$

因此相关系数为

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sqrt{DX}\sqrt{DY}} = \frac{a\sigma^2}{\sqrt{(a^2+2)\sigma^2}\sqrt{\sigma^2}} = \frac{a}{\sqrt{a^2+2}}$$

(4) 用边缘分布乘条件分布, 得

$$\begin{aligned} f(x, y) &= f_X(x|y)f_Y(y) = \frac{1}{2\sigma\sqrt{\pi}}e^{-\frac{(x-ay-b)^2}{4\sigma^2}} \times \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(y-\mu_Y)^2}{2\sigma^2}} \\ &= \frac{1}{2\sqrt{2}\pi\sigma^2}e^{-\frac{(x-ay-b)^2+2(y-\mu_Y)^2}{4\sigma^2}}. \end{aligned}$$

三、(20 分) 已知独立同分布的随机变量 $X_1, \dots, X_n, X_i$ 的取值为 1, 3, 27 的概率分别为 1/2, 1/4, 1/4, 试用中心极限定理估计

$$3^{n-\sqrt{n}} \leq \prod_{i=1}^n X_i \leq 3^{n+\sqrt{n}}$$

发生的概率.

Solution: 令 $Y_i = \ln X_i$, 则 Y_i 的分布情况如下

$$P(Y_i = 0) = \frac{1}{2}, P(Y_i = \ln 3) = \frac{1}{4}, P(Y_i = 3 \ln 3) = \frac{1}{4},$$

可以求得 $E(Y_i) = \ln 3, D(Y_i) = \frac{3(\ln 3)^2}{2}$, 根据中心极限定理, 有

$$Y = \sum_{i=1}^n Y_i \sim N\left(n \ln 3, \frac{3n(\ln 3)^2}{2}\right)$$

因此

$$\begin{aligned} P\left(3^{n-\sqrt{n}} \leq \prod_{i=1}^n X_i \leq 3^{n+\sqrt{n}}\right) &= P((n-\sqrt{n}) \ln 3 \leq Y \leq (n+\sqrt{n}) \ln 3) \\ &\approx P\left(Z \leq \left|\frac{(n+\sqrt{n}) \ln 3 - n \ln 3}{\sqrt{3n(\ln 3)^2/2}}\right|\right) \\ &= 2\Phi\left(\sqrt{\frac{2}{3}}\right) - 1 \end{aligned}$$

四、(20 分) 已知 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \lambda) = \frac{2}{\sqrt{\lambda\pi}} \exp\left(-\frac{x^2}{\lambda}\right) I[x > 0], \lambda > 0$ 是未知参数.

(1) 使用一阶矩计算 λ 的矩估计;

(2) 请问 (1) 中的这个矩估计是不是无偏估计? 如果不是, 请求出 λ 的一个无偏矩估计.

Solution:

(1) 计算期望, 有

$$E(X) = \int_0^{+\infty} \frac{2x}{\sqrt{\lambda\pi}} e^{-\frac{x^2}{\lambda}} dx = \sqrt{\frac{\lambda}{\pi}},$$

又替换原理, 得到 λ 的矩估计为 $\hat{\lambda}_1 = \pi \bar{X}^2$.

(2) 计算二阶矩, 有

$$E(X^2) = \int_0^{+\infty} \frac{2x^2}{\sqrt{\lambda\pi}} e^{-\frac{x^2}{\lambda}} dx = \frac{\lambda}{2},$$

故 $D(X) = E(X^2) - E(X)^2 = \frac{\lambda}{2} - \frac{\lambda}{\pi}$, 因此有

$$E(\bar{X}) = \sqrt{\frac{\lambda}{\pi}}, \quad D(\bar{X}) = \frac{\lambda}{2n} - \frac{\lambda}{\pi n},$$

因此有 $E(\bar{X}^2) = D(\bar{X}) + E(\bar{X})^2 = \frac{\lambda}{2n} - \frac{\lambda}{\pi n} + \frac{\lambda}{\pi}$, 所以

$$E(\hat{\lambda}_1) = \frac{\lambda\pi}{2n} - \frac{\lambda}{n} + \lambda,$$

看出 $\hat{\lambda}_1 = \pi\bar{X}^2$ 不是 λ 的无偏估计. 由于 $E(2X^2) = \lambda$, 因此 λ 的无偏矩估计是 $\hat{\lambda}_2 = 2\frac{1}{n}\sum_{i=1}^n X_i^2$.

五、(20 分) 已知 $X_1, \dots, X_n \stackrel{iid}{\sim} b(1, p)$, $0 < p < 1$ 是未知参数. 令 $q = 1 - p$, 试求:

- (1) q^k 的 MLE;
- (2) q^k 的 UMVUE.

Solution:

(1) 记 $Y = \sum_{i=1}^n X_i \sim b(n, p)$, 样本对应的似然函数为

$$L(p) = p^Y (1-p)^{n-Y}$$

取对数并对 p 求偏导, 得故 $\hat{p}_{MLE} = \frac{Y}{n}$, 由最大似然估计的不变性知

$$\hat{q}_{MLE}^k = (1 - \hat{p}_{MLE})^k = \left(1 - \frac{Y}{n}\right)^k.$$

(2) 令 $\hat{\theta}_1 = \begin{cases} 1, & X_1 = X_2 = \dots = X_k = 0 \\ 0, & \text{其他} \end{cases}$, 则

$$E(\hat{\theta}_1) = P(X_1 = X_2 = \dots = X_k = 0) = q^k$$

故 $\hat{\theta}_1$ 是 q^k 的无偏估计. 由于 $Y = \sum_{i=1}^n X_i \sim b(n, p)$ 是指数族的充分完备统计量, 故由 Lehmann-Scheffe 定理, 有 $\hat{\theta}_2 = E(\hat{\theta}_1 | Y)$ 是 UMVUE. 显然若 $y > n - k$, 有

$$\hat{\theta}_2 = E(\hat{\theta}_1 | Y = y) = 0$$

而对 $y \leq n - k$, 有

$$\begin{aligned} \hat{\theta}_2 &= E(\hat{\theta}_1 | Y = y) = \frac{P(X_1 = X_2 = \dots = X_k = 0, Y = y)}{P(Y = y)} \\ &= \frac{P(X_1 = X_2 = \dots = X_k = 0, \sum_{i=k+1}^n X_i = y)}{P(Y = y)} = \frac{C_{n-k}^y}{C_n^y} \end{aligned}$$

因此 q^k 的 UMVUE 是

$$\hat{\theta}_2 = \begin{cases} 0, & Y > n - k, \\ \frac{C_{n-k}^Y}{C_n^Y} & Y \leq n - k. \end{cases}$$

六、(20 分) 已知 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta) = \frac{a}{\theta} \left(\frac{x}{\theta}\right)^{a-1} I[0 < x < \theta]$, 其中 $a > 0$ 是已知常数, $\theta > 0$ 是未知参数.

- (1) 计算 θ 的 MLE;
- (2) X_i/θ 服从什么分布?
- (3) 证明 $X_{(n)}/\theta$ 是枢轴量;
- (4) 利用 (3) 中的枢轴量构建 θ 的 $1 - \alpha$ 置信区间.

Solution:

(1) 样本对应的似然函数是 $L(\theta) = \frac{a^n}{\theta^{an}} \prod_{i=1}^n X_i^{a-1} I_{(X_{(n)} < \theta)}$, 它关于 θ 是单调减函数, 因此 θ 的 MLE 应是其定义域中最小值, 即 $\hat{\theta}_{MLE} = X_{(n)}$.

(2) 令 $Y_i = \frac{X_i}{\theta}$, 则 Y_i 密度函数为

$$\begin{aligned} f_Y(y) &= f_X(\theta y) |h'(y)| \\ &= ay^{a-1}, \quad 0 < y < 1 \end{aligned}$$

故 $Y_i \sim \text{Beta}(a, 1)$.

(3) 记 $T = \frac{X_{(n)}}{\theta}$, $F_T(t) = F_Y^n(t) = t^{an}$, 其分布与参数 θ 无关, 所以是枢轴量.

(4) 根据 (3), 我们发现 $T \sim \text{Beta}(an, 1)$, 考虑

$$\int_c^1 ant^{an-1} dt = 1 - \alpha$$

解得 $c = \alpha^{\frac{1}{an}}$, 故有 $P\left(\alpha^{\frac{1}{an}} \leq T \leq 1\right) = 1 - \alpha$, 即有置信区间 $\theta \in \left[X_{(n)}, \frac{X_{(n)}}{\sqrt[n]{\alpha}}\right]$.

七、(20 分) 已知 $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$, θ 是未知参数. 对假设检验问题

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta = \theta_1$$

给出水平为 α 的 UMP 拒绝域, (其中 $0 < \theta_0 < \theta_1$).

Solution: 构造似然比

$$\lambda = \frac{f(x_1, x_2, \dots, x_n, \theta_1)}{f(x_1, x_2, \dots, x_n, \theta_0)} = \begin{cases} \left(\frac{\theta_0}{\theta_1}\right)^n, & 0 < X_{(n)} < \theta_0, \\ \infty, & \theta_0 \leq X_{(n)} < \theta_1, \end{cases}$$

注意为使得分子分母至少一个有意义, $X_{(n)}$ 的自然定义域是 $X_{(n)} < \theta_1$. 根据 N-P 引理, UMP 拒绝域由 $W = \{\lambda > C\}$ 给出, 由于 λ 关于 $X_{(n)}$ 非降, 因此

$$W = \{\lambda > C\} = \{X_{(n)} > C_1\},$$

而 $T = X_{(n)}$ 密度函数为 $g(t) = \frac{nt^{n-1}}{\theta_0^n}$, 为使得拒绝域水平为 α , 由

$$\int_c^{\theta_0} \frac{nt^{n-1}}{\theta_0^n} dt = 1 - \frac{c^n}{\theta_0^n} = \alpha$$

解得 $c = \theta_0 \sqrt[n]{1-\alpha}$, 故 UMP 拒绝域为 $W = \{X_{(n)} > \theta_0 \sqrt[n]{1-\alpha}\}$.

中山大学-432 统计学-2022 年

一、选择题

1、甲乙两人轮流掷骰子, 先掷出 1 或 6 者取胜, 问先掷者获胜的概率是 ().

- A. $\frac{1}{3}$;
- B. $\frac{1}{2}$;
- C. $\frac{2}{5}$;
- D. $\frac{3}{5}$.

Solution: D

$$\frac{1}{3} \sum_{i=0}^{\infty} \left(\frac{2}{3}\right)^i = \frac{1}{3} \cdot \frac{1}{1 - \left(\frac{2}{3}\right)} = \frac{3}{5}$$

2、现有两个盒子, 第一个盒中装有 2 个红球与 3 个白球, 第二个盒子中装有 3 个红球和 5 个白球, 先随机选择一个盒子, 再从该盒中摸球, 现知摸出的是红球, 其来自于第一个盒子的概率是 ().

- A. $\frac{16}{31}$;
- B. $\frac{2}{5}$;
- C. $\frac{1}{5}$;
- D. $\frac{15}{31}$.

Solution: A

用贝叶斯公式, 有

$$\begin{aligned} P(A_1 | R) &= \frac{P(R | A_1) P(A_1)}{P(R | A_1) P(A_1) + P(R | A_2) P(A_2)} \\ &= \frac{\frac{2}{5} \cdot \frac{1}{2}}{\frac{2}{5} \cdot \frac{1}{2} + \frac{3}{8} \cdot \frac{1}{2}} = \frac{16}{31} \end{aligned}$$

3、随机变量 $X \sim \mathcal{N}(\mu, \sigma^2)$, 对于固定的 $a > 0$, 在 σ 增大时, 概率 $P(|X - \mu| < a)$ 的变化趋势是 ().

- A. 减小;
- B. 增大;
- C. 不变;
- D. 先增后减.

Solution: A

$P(|X - \mu| < a) = P\left(\frac{|X - \mu|}{\sigma} < \frac{a}{\sigma}\right)$ 是 σ 的单调减函数.

4、 $X_1, X_2, \dots, X_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的简单随机样本, 其中 μ, σ^2 均未知, 则样本方差 s^2 是 σ^2 的 ().

- A. 最大似然估计;
- B. 有效估计;
- C. 相合估计;
- D. 以上都是.

Solution: C

最大似然估计是 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} s^2$, 有效估计不存在, 相合性可由大数定律得到.

5、设 $[a, b]$ 是根据一组随机样本得到的关于未知参数 θ 的 95% 置信区间, 则以下说法正确的是 ().

- A. 有 95% 的随机样本落入该区间;
- B. 对于假设检验问题 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$, 在 0.05 的显著性水平下, 若 $\theta_0 \notin [a, b]$, 则拒绝原假设;
- C. θ 的估计量 $\hat{\theta}$ 以 95% 概率落入该区间;
- D. θ 的真实值以 95% 概率落入该区间.

Solution: B

反转一个接受域可得到置信区间, 而反转一个置信区间也可得到接受域, 故 B 正确.

D 项表述不正确, θ 不是随机变量, 不能谈概率. 正确的表述是 "有 95% 的把握称 θ 的真实值落入该区间."

6、考虑 p 值检验, 若 p 值越小, 则 ().

- A. 更有理由认为原假设不成立;
- B. 更有理由认为原假设成立;
- C. 以更大概率拒绝原假设;
- D. 以更大概率接受原假设.

Solution: A

C 项表述不正确, 在一般的场合, 我们要么做出拒绝原假设的决定, 要么做出接受原假设的决定, 概率是不变的. (注: 若考虑随机化检验, 则有时会以某个概率拒绝原假设, 但该概率也不随 p 值改变).

7、 $X_1, X_2, \dots, X_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的简单随机样本, 其中 μ, σ^2 均未知, 记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 下列说法正确的是 ().

- A. $\bar{X}, S, \frac{X_1 - X_2}{S}$ 两两独立;
- B. $\frac{\sqrt{2}(X_1 - X_2)}{\sigma} \sim N(0, 1)$;
- C. $\frac{X_1 - X_2}{S} \sim t(n-1)$;
- D. $\frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n)$.

Solution: A

前两个的独立性由 Fisher 引理. 而 $\bar{X}, S^2$ 分别是 μ, σ^2 的充分完备统计量, $\frac{X_1 - X_2}{S}$ 关于这两个参数均为辅助统计量, 根据 Basu 引理得独立性.

二、填空题

1、设 $f(x) = ae^{-|x|}, x \in \mathcal{R}$ 是某个随机变量的 p.d.f, 则 $a =$ _____.

Solution: 1/2

根据概率密度函数的正则性即可.

2、 $a, b \sim \mathcal{U}(0, 2)$, 且二者独立, 则方程 $x^2 + ax + b^2 = 0$ 有实根的概率是 _____.

Solution: 1/4

当 $\Delta = a^2 - 4b^2 \geq 0$ 时, 方程有实根, 则

$$P(a^2 - 4b^2 \geq 0) = P(a^2 \geq 4b^2) = P(|a| \geq 2|b|) = P(a \geq 2b) = \frac{1}{4}$$

3、已知有 $\sqrt{n}X_n \rightarrow_d \mathcal{N}(0, 1)$, 则 $\sqrt{n}(e^{X_n} - 1)$ 的依分布收敛极限是 _____.

Solution: $\mathcal{N}(0, 1)$

用 delta 方法, 取 $g(x) = e^x$, 则 $g'(0) = 1$, 于是有

$$\sqrt{n}(g(X_n) - g(0)) \rightarrow_d \mathcal{N}(0, [g'(0)]^2) = \mathcal{N}(0, 1)$$

4、 $X_1, X_2, \dots, X_9$ 是来自 $\mathcal{N}(\mu_1, \sigma_1^2)$ 的简单随机样本, $Y_1, Y_2, \dots, Y_{12}$ 是来自 $\mathcal{N}(\mu_2, \sigma_2^2)$ 的简单随机样本, 其中 $\sigma_1^2 = 3\sigma_2^2, \sigma_2^2$ 未知, 则 $\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间是 _____.

Solution: $(\bar{X} - \bar{Y}) \pm \sqrt{\frac{5}{12}} \sqrt{\frac{3S_X^2 + 11S_Y^2}{19}} \cdot t_{1-\frac{\alpha}{2}}(19)$

5、设 $X \sim \mathcal{U}(0, 1)$, 则 $Y = X^2$ 的 p.d.f 是 _____.

Solution: $f_Y(y) = \frac{1}{2\sqrt{y}}, 0 < y < 1$

$$f_Y(y) = f_X(\sqrt{y}) \left| \frac{1}{2\sqrt{y}} \right|, 0 < y < 1 = \frac{1}{2\sqrt{y}}, 0 < y < 1$$

6、甲欲检验某枚硬币掷出正面的概率是否小于 $\frac{1}{2}$, 即考虑假设检验问题 $H_0: p = \frac{1}{2}$ vs $H_1: p < \frac{1}{2}$. 现 10 次试验中有 2 次掷出正面, 则此时 p 值是 _____.

Solution: $\frac{7}{2^7}$

$$P(X \leq 2 | p = \frac{1}{2}) = \sum_{k=0}^2 C_{10}^k \left(\frac{1}{2}\right)^{10} = \frac{56}{2^{10}} = \frac{7}{2^7}.$$

7、 $X_1, X_2, \dots, X_n$ 是来自正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的简单随机样本, 其中 μ, σ^2 均未知, 则 σ^2 的 MLE 的均方误差是 _____.

Solution: $\frac{2n-1}{n} \sigma^4$

σ^2 的 MLE 是 $\frac{n-1}{n} S^2$, 于是

$$\begin{aligned} MSE\left(\frac{n-1}{n} S^2\right) &= E\left(\frac{n-1}{n} S^2 - \sigma^2\right)^2 \\ &= Var\left(\frac{n-1}{n} S^2\right) + \left(E\frac{n-1}{n} S^2 - \sigma^2\right)^2 \\ &= \frac{(n-1)^2}{n^2} \cdot \frac{2\sigma^4}{n-1} + \frac{\sigma^4}{n^2} = \frac{2n-1}{n^2} \sigma^4 \end{aligned}$$

三、解答题

1、设 $(X, Y) \sim \mathcal{N}(0, 0; 1, 1; \rho)$, 试求 $Z = |X - Y|$ 的 p.d.f 以及其数学期望.

Solution:

$X - Y \sim \mathcal{N}(0, 2 - 2\rho)$, 故 $Z = |X - Y|$ 是一个对称分布, 其 p.d.f 是

$$f_Z(z) = \frac{1}{\sqrt{\pi(1-\rho)}} e^{-\frac{z^2}{4(1-\rho)}}, z > 0$$

以及 $EZ = 2\sqrt{\frac{1-\rho}{\pi}}$.

2、对于来自负二项分布 $NB(r, p)$ 的单个样本 X , 其分布列是 $P(X = x) = C_{x-1}^{r-1} p^r (1-p)^{x-r}$, 试求 p^k 的 UMVUE (其中 $k < r$).

Solution:

拆分分布列, 对于 $\forall x \geq r$, 有

$$\begin{aligned} P(X = x) &= C_{x-1}^{r-1} p^r (1-p)^{x-r} \\ P(X = x) &= \frac{C_{x-1}^{r-1}}{C_{x-k-1}^{r-k-1}} p^k C_{x-k-1}^{r-k-1} p^{r-k} (1-p)^{x-r} \\ \frac{C_{x-k-1}^{r-k-1}}{C_{x-1}^{r-1}} P(X = x) &= p^k C_{x-k-1}^{r-k-1} p^{r-k} (1-p)^{x-r} \end{aligned}$$

两侧同时取在 $x = r, r+1, \dots, \infty$ 上求和, 有

$$\begin{aligned} \sum_{x=r}^{+\infty} \frac{C_{x-k-1}^{r-k-1}}{C_{x-1}^{r-1}} P(X = x) &= p^k \sum_{x=r}^{+\infty} C_{x-k-1}^{r-k-1} p^{r-k} (1-p)^{x-r} \\ \sum_{x=r}^{+\infty} \frac{(x-k-1)!}{(r-k-1)!(x-r)!} P(X = x) &= p^k \sum_{z=v}^{+\infty} C_{z-1}^{v-1} p^v (1-p)^{z-v} \\ E\left[\frac{(X-k-1)!(r-1)!}{(X-1)!(r-k-1)!}\right] &= p^k \end{aligned}$$

根据 Lehmann-Scheffe 定理, 有 $T = \frac{(X-k-1)!(r-1)!}{(X-1)!(r-k-1)!}$ 是 p^k 的 UMVUE.

3、有来自总体 $f(x) = \frac{\theta}{x^2} I_{\{x \geq \theta\}}$ 的随机样本 $X_1, X_2, \dots, X_n$, 其中未知参数 $\theta > 0$, 试解决下述问题.

- (1). 试求 θ 的 MLE;
- (2). 判断 1) 中的 MLE 是否为充分统计量;
- (3). 求 θ 的 95% 置信区间.

Solution:

- (1) 先写出似然函数

$$L(\theta) = \frac{\theta^n}{\prod_{i=1}^n x_i^2} I_{\{\theta \leq x_{(1)}\}},$$

这显然是 θ 的增函数, 故 θ 取 $X_{(1)}$ 时似然函数也达到最大. $\hat{\theta} = X_{(1)}$;

- (2) 是, 直接根据因子分解定理;

(3) 由于 $X_{(1)} \sim f_1(x) = \frac{n\theta^n}{x^{n+1}} I_{\{x \geq \theta\}}$, 故 $T = \frac{X_{(1)}}{\theta} \sim f_T(t) = \frac{n}{t^{n+1}} I_{\{t \geq 1\}}$, 其分布与 θ 无关, 可作为枢轴量. 算得 $F_T(t) = (1 - \frac{1}{t^n}) I_{\{t \geq 1\}}$.

若有 $P(a \leq T \leq b) = 1 - \alpha$, 则可反解得到 θ 的 $1 - \alpha$ 置信区间 $[\frac{X_{(1)}}{b}, \frac{X_{(1)}}{a}]$, 考虑到 $X_{(1)} \geq \theta$, 我们在上限处 a 取 1, 由此解

$$\int_1^b \frac{n}{t^{n+1}} dt = 1 - \alpha$$

得 $b = \alpha^{-1/n}$, 因此置信区间 $[(0.05)^{\frac{1}{n}} X_{(1)}, X_{(1)}]$.

4. 为验证某骰子是否均匀, 某人进行了 100 次试验, 其中数字 1, 2, 3, 4, 5, 6 出现的次数分别为 15, 18, 19, 14, 16, 18. 试用数学方法建立模型并解答, 无需代入具体数值计算.

Solution: 用拟合优度检验, 记一次投掷出现数字 i 的概率是 $p_i (i = 1, 2, \dots, 6)$, 考虑假设检验问题:

$$H_0 : p_i = \frac{1}{6} (i = 1, 2, \dots, 6)$$

卡方统计量为 $\chi^2 = \sum_{i=1}^6 \frac{(n_i - \frac{n}{6})^2}{\frac{n}{6}} \stackrel{H_0}{\sim} \chi_5^2$, 故在 α 的显著性水平下, 当 $\chi^2 \geq \chi_{5, 1-\alpha}^2$ 时拒绝原假设.

5. 现有来自总体 $f(x) = \theta x^{\theta-1} I_{\{0 \leq x \leq 1\}}$ 的简单随机样本 $X_1, X_2, \dots, X_n$, 考虑假设检验问题:

$$H_0 : \theta = 1 \text{ vs } H_1 : \theta \neq 1$$

- (1) 求上述问题显著性水平 α 的广义似然比拒绝域;
- (2) 求 (1) 中检验的功效函数;
- (3) 问 (1) 中检验是否为 UMP 检验?

Solution: (1) 注意到总体是 $Beta(\theta, 1)$, 对总体取负对数变换则为指数分布, 即 $Y_i = -\log X_i \sim \mathcal{E}(\theta)$. 可基于我们熟悉的指数分布样本 Y_i 构建拒绝域.

最终拒绝域可基于 $T = \sum_{i=1}^n Y_i = -\sum_{i=1}^n \log X_i$ 给出, 其形式为 $W = \{T \leq a\} \cup \{T \geq b\}$. 其中 a, b 满足 $ae^{-a} = be^{-b}$ 以及 $\int_{2\theta_0 a}^{2\theta_0 b} f_{2n}(t) dt = 1 - \alpha$, 这里 $f_{2n}(t)$ 表示 χ_{2n}^2 的 p.d.f.

或直接取等尾, 得近似 LRT, $W = \left\{T \leq \frac{\chi_{2n, \frac{\alpha}{2}}^2}{2\theta_0}\right\} \cup \left\{T \geq \frac{\chi_{2n, 1-\frac{\alpha}{2}}^2}{2\theta_0}\right\}$. 注意本题中 θ_0 是 1.

- (2)

$$\begin{aligned} \beta_W(\theta) &= P_\theta(T \leq a) + P_\theta(T \geq b) \\ &= 1 - P_\theta(a \leq T \leq b) \\ &= 1 - P_\theta(2\theta a \leq 2\theta T \leq 2\theta b) \\ &= 1 - \int_{2\theta a}^{2\theta b} f_{2n}(t) dt \end{aligned}$$

这里的 a, b 由 (1) 中的 LRT 条件给出.

(3) 不是 UMPT. 考虑任意 $\theta_1 > \theta_0$, 根据 N-P 引理, 在 θ_1 处唯一功效最大的检验是 $W_1 = \{T \leq 2\theta_0 \chi_\alpha^2\}$, 而我们前面得到的拒绝域 W 显然与它不一样, 故不可能是 UMP 检验.

实际上该假设检验问题的 UMP 检验是不存在的, 可以再考虑任意 $\theta_2 < \theta_0$, 根据 N-P 引理, 在 θ_2 处唯一功效最大的检验是 $W_2 = \{T \geq 2\theta_0\chi_{1-\alpha}^2\}$. 若 W_0 是该假设检验问题的 UMP 拒绝域, 则必须 $W_0 = W_1, a.s.$ 以及 $W_0 = W_2, a.s.$, 这显然是做不到的.

中山大学-432 统计学-2023 年

一、选择题 (每题 3 分, 共 12 空, 总 36 分)

1、设 $X \sim N(\mu, \sigma^2)$, 则 $E|X - \mu| = ()$

- A. σ^2 ;
- B. $\frac{\sigma}{2}$;
- C. σ ;
- D. $\sigma\sqrt{\frac{2}{\pi}}$.

Solution: D

记 $Y = \frac{X-\mu}{\sigma} \sim N(0, 1)$, 则

$$E|Y| = \int_{-\infty}^{\infty} \frac{|y|}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy = 2 \int_0^{\infty} \frac{y}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy = \sqrt{\frac{2}{\pi}}$$

因此 $E|X - \mu| = \sqrt{\frac{2}{\pi}}$

2、设随机变量 $X \sim N(0, 1)$, 若常数 x_p 满足 $P(X \leq x_p) = p$, 则称常数 x_p 为 p 分位数, 则 $|X|$ 的中位数是 () a. $x_{0.25}$ b. $x_{0.50}$ c. $x_{0.75}$ d. $x_{0.67}$

Solution: C

令

$$\frac{1}{2} = P(|X| \leq a) = P(-a \leq X \leq a) = \Phi(a) - \Phi(-a)$$

发现恰好是 $a = x_{0.75}$.

3、已知 $E(XY) = E(X)E(Y)$, 以下结论正确的是 () a. $\text{Var}(XY) = \text{Var}(X)\text{Var}(Y)$ b. $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ c. X 和 Y 独立 d. X 和 Y 不独立

Solution: B

都说明了 X 与 Y 不相关.

4、以下说法中, 错误的是 () a. 如果 $X_n \xrightarrow{D} a$, 那么 $X_n \xrightarrow{P} a$ b. 如果 $X_n \xrightarrow{D} X$, 那么 $X_n \xrightarrow{P} X$ c. 如果 $X_n \xrightarrow{P} X$, 那么 $X_n \xrightarrow{D} X$ d. 如果 $X_n \xrightarrow{D} X, Y_n \xrightarrow{P} a$, 那么 $X_n Y_n \xrightarrow{D} aX$ Solution: B

B 错误, 依分布收敛推不出依概率收敛, 除非是收敛到常数 (单点分布).

5、设 $X > 0$, 已知 $E(1/X)$ 和 $1/EX$ 均存在, 则以下关于 $E(1/X)$ 和 $1/EX$ 的大小关系的说法, 正确的是 () a. $E(1/X) \geq 1/EX$ b. $E(1/X) = 1/EX$ c. $E(1/X) \leq 1/EX$ d. 无法确定

Solution:

用 Jensen 不等式, 取凸函数 $g(t) = \frac{1}{t}$, 则有 $E(g(X)) \geq g(E(X))$, 即 $E(\frac{1}{X}) \geq \frac{1}{EX}$.

6、设简单随机样本 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 方差 σ^2 已知, 给定置信水平 $1 - \alpha$, 关于 μ 的置信区间, 以下说法不正确的是 () a. 样本量增大, 区间长度变短 b. 总体均值范围增大, 区间长度变宽 c. 方差增大, 区间长度变宽 d. $1 - \alpha$ 增大, 区间长度变宽

Solution: B

μ 的 $1 - \alpha$ 水平置信区间是 $\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}$. 区间长度是 $2 \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}$, 显然与总体均值 μ 无关, 因此 A C D 正确, B 错误.

7、设 X, Y 独立, 均服从伽马分布 $\Gamma(2, 4)$, 则 $X + Y$ 服从的分布是 () a. 伽马分布 $\Gamma(4, 8)$ b. 伽马分布 $\Gamma(4, 4)$ c. 贝塔分布 $Beta(2, 4)$ d. 贝塔分布 $Beta(4, 4)$

Solution: B

伽马分布 $\Gamma(n, \lambda)$ 具有可加性, 前提是比率参数 λ 参数相同, 其和只需将自由度相加.

8、设有来自某总体的简单随机样本, 其样本均值为 $\bar{X}$, 样本方差为 S^2 , 则下列说法正确的是 () a. S 和 $\bar{X}$ 独立 b. S 是 σ 的最大似然估计量 c. S 是 σ 的无偏估计量 d. S 是 σ 的相合估计量

Solution: D

题目未说是正态分布, A 错误. 未指明具体分布, B 也错误. 未指明分布也无法计算期望, C 错误, 且通常也是有偏估计. 如果总体的方差存在, 则样本方差的相合性成立, 这是由大数定律保证的. 再根据连续映射定理, 样本标准差的相合性也得以保证.

8、以下结论中, 与 $\text{Var}(E(Y | X)) = \text{Var}(Y)$ 互为充要条件的是 () a. X 以概率 1 能够用 Y 线性表示 b. $Y - E[Y | X] = 0$ c. $E(\text{Var}(Y | X)) = 0$ d. $E(Y - E(Y | X)) = 0$

Solution: C

根据条件方差恒等式, 即

$$\text{Var}(Y) = \text{Var}(E(Y | X)) + E(\text{Var}(Y | X)),$$

根据题意, 有

$$\text{Var}(E(Y | X)) = \text{Var}(Y) \Leftrightarrow E(\text{Var}(Y | X)) = 0$$

10、在假设检验问题中, 控制显著性水平 α 不变, 则增加样本容量, 发生的变化是 () a. 一类错误概率减小 b. 一类错误概率增大 c. 二类错误概率减小 d. 二类错误概率增大

Solution: C

控制了显著性水平, 则第一类错误概率不变. 第二类错误的概率随样本量增大而减小.

11、为研究某地区儿童的含铅量指标水平是否高于普通儿童, 应该设定的假设检验问题为 () a. 原假设 $\mu > \mu_0$, 备择假设 $\mu = \mu_0$ b. 原假设 $\mu < \mu_0$, 备择假设 $\mu = \mu_0$ c. 原假设 $\mu = \mu_0$, 备择假设 $\mu > \mu_0$ d. 原假设 $\mu = \mu_0$, 备择假设 $\mu < \mu_0$

Solution: C

通常将研究的问题放在备择假设, 想要拒绝的放在原假设.

12、对于均匀分布总体 $\overset{iid}{\sim} U(-\theta, \theta), \theta > 0$ 的一组简单随机样本, 以下说法正确的是 () a. $\min\{-X_{(1)}, X_{(n)}\}$ 是充分统计量 b. $(X_{(1)}, X_{(n)})$ 是完备统计量 c. $X_{(n)} - X_{(1)}$ 是辅助统计量 d. $X_{(n)}/X_{(1)}$ 是辅助统计量

Solution: D

似然函数是

$$L(\theta) = \frac{1}{(2\theta)^n} I_{\{X_{(1)} \geq -\theta\}} I_{\{X_{(n)} \leq \theta\}} = \frac{1}{(2\theta)^n} I_{\{\max\{-X_{(1)}, X_{(n)}\} \leq \theta\}},$$

因此 $\max\{-X_{(1)}, X_{(n)}\}$ 才是充分统计量.

取函数 $h(x_1, x_2) = x_1 + x_2$, 则根据对称性有 $Eh(X_{(1)}, X_{(n)}) = 0$, 但显然没有 $h(X_{(1)}, X_{(n)}) = 0, a.s.$ 所以 $(X_{(1)}, X_{(n)})$ 不是完备统计量.

C 项是位置参数的辅助统计量, D 是尺度参数的辅助统计量, 该总体显然是个尺度族而不是位置族, 因此 D 正确.

二、填空题 (每空 3 分, 共 14 空, 总 52 分)

1、一个人是 ABABO 型血的概率分别为 0.40.20.10.3, 现任意在人群中选四个人, 则他们血型全不相同的概率为 _____.

Solution: 0.0576

利用多项分布, 抽一个人即视为进行一次试验, 试验有四种结果, 每种结果发生的概率分别是 0.40.20.10.3. 重复进行 4 次试验, 则每种结果恰出现一次的概率是

$$P(X_1 = X_2 = X_3 = X_4 = 1) = 4! \cdot 0.4 \cdot 0.2 \cdot 0.1 \cdot 0.3 = 0.0576$$

2、袋中有 m 个白球与 n 个黑球, 现有放回摸球直到摸到白球停止, 则摸到白球之前黑球的个数的数学期望是 _____.

Solution: $\frac{n}{m}$

用 X 表示第一次摸到白球时的总摸球数, 则 $X \sim Ge\left(\frac{m}{n+m}\right)$, 所求即 $EX - 1 = \frac{n+m}{m} - 1 = \frac{n}{m}$

3、随机变量 X 的概率密度函数是 $f(x) = k \exp\left\{-\frac{x^2}{8}\right\}, x > 0$, 则 $k =$ _____.

Solution: $\frac{1}{\sqrt{2\pi}}$

由于

$$\int_0^{+\infty} e^{-\frac{x^2}{8}} dx = \frac{x}{2\sqrt{2}} \int_0^{+\infty} e^{-t^2} d(2\sqrt{2}t) = 2\sqrt{2} \int_0^{+\infty} e^{-t^2} dt = \sqrt{2} \cdot \Gamma\left(\frac{1}{2}\right) = \sqrt{2\pi}$$

根据概率密度函数的正则性, 有 $k = \frac{1}{\sqrt{2\pi}}$.

4、随机变量 X 的概率密度函数为 $f(x) = \frac{3}{8}x^2, 0 < x < 2$, 则 $E\left(\frac{1}{X^2}\right)$ _____.

Solution: $\frac{3}{4}$

直接计算, $E\left(\frac{1}{X^2}\right) = \int_0^2 \frac{3}{8} dx = \frac{3}{4}$.

5、 $X_1, \dots, X_n$ 是来自总体 $N(\mu, \sigma^2)$ 的简单随机样本, 其中 σ^2 已知, 则对于假设检验问题 $H_0: \mu = 1$ vs $H_1: \mu > 1$, 显著性水平为 α 的 UMP 拒绝域是_____, 该检验在 $\mu = 2$ 时的功效是_____.

Solution: $\left\{\frac{\sqrt{n}(\bar{X}-1)}{\sigma} \geq z_{1-\alpha}\right\}, 1 - \Phi\left(z_{1-\alpha} - \frac{\sqrt{n}}{\sigma}\right)$

根据 Karlin-Rubin 定理, 该正态总体均值检验的 UMP 拒绝域是 $W = \left\{\frac{\sqrt{n}(\bar{X}-1)}{\sigma} \geq z_{1-\alpha}\right\}$.

当 $\mu = 2$ 时, 功效

$$\rho(2) = P_{\mu=2}\left(\frac{\sqrt{n}(\bar{X}-1)}{\sigma} \geq z_{1-\alpha}\right) = P_{\mu=2}\left(\frac{\sqrt{n}(\bar{X}-2)}{\sigma} \geq z_{1-\alpha} - \frac{\sqrt{n}}{\sigma}\right) = 1 - \Phi\left(z_{1-\alpha} - \frac{\sqrt{n}}{\sigma}\right)$$

6、 $X_1, \dots, X_n$ 是来自泊松分布 $Poisson(\lambda)$ 总体的简单随机样本, 设 $\theta = \ln \lambda$, 则 θ 的最大似然估计是 $\hat{\theta} =$ _____, $\sqrt{n}(\hat{\theta} - \theta)$ 的极限分布是_____.


Solution: $\ln \bar{X}, N\left(0, \frac{1}{\lambda}\right)$

λ 的 MLE 是 $\bar{X}$, 根据 MLE 的不变性, 则 θ 的 MLE 是 $\ln \bar{X}$.

由于 $\sqrt{n}(\bar{X} - \lambda) \rightarrow N(0, \lambda)$, 用 Delta 方法, 取 $g(x) = \ln x$, 则 $\sqrt{n}(g(\bar{X}) - g(\lambda)) \rightarrow N\left(0, \lambda \cdot [g'(\lambda)]^2\right)$, 即

$$\sqrt{n}(\hat{\theta} - \theta) \rightarrow N\left(0, \frac{1}{\lambda}\right).$$

7、现对一组数据进行描述性统计, 绘制出下面的箱线图, 则图中 a, b, c 三个纵坐标对应的统计量分别是_____, _____, _____.



Solution: 下四分位数, 中位数, 上四分位数

8、对于某项 n 重伯努利试验, 现观测到事件发生了 $n-1$ 次, 则对于假设检验问题 $H_0: p = 1/2, H_1: p > 1/2$, 当前的 p 值是 _____.

Solution: $\frac{n+1}{2^n}$

直接计算 p 值:

$$P_{p=1/2}(X \geq n-1) = C_{n-1}^{n-1} \left(\frac{1}{2}\right)^n + C_n^n \left(\frac{1}{2}\right)^n = \frac{n+1}{2^n}$$

9、现有三组数据进行方差分析, 样本量均为 n , 试用每一组的样本方差 $S_i^2, i = 1, 2, 3$ 和每一组的组内均值 $\bar{Y}_i, i = 1, 2, 3$ 以及总均值 $\bar{\bar{Y}}$ 来给出组内均方 (MSW) 和组间均方 (MSB) 的表达式, 它们分别是 _____ 和 _____

Solution: $\frac{\sum_{i=1}^3 S_i^2}{3}, \frac{n \sum_{i=1}^3 (\bar{Y}_i - \bar{\bar{Y}})^2}{2}$

组内平方和是 $SSW = \sum_{i=1}^3 \sum_{j=1}^n (Y_{ij} - \bar{Y}_i)^2 = (n-1) \sum_{i=1}^3 S_i^2$, 自由度 $df_W = 3n - 3$, 因此组内均方

$$MSW = \frac{(n-1) \sum_{i=1}^3 S_i^2}{3n-3} = \frac{\sum_{i=1}^3 S_i^2}{3}$$

组间平方和是 $SSB = \sum_{i=1}^3 n (\bar{Y}_i - \bar{\bar{Y}})^2$, 自由度 $df_B = 2$, 因此组内均方

$$MSB = \frac{n \sum_{i=1}^3 (\bar{Y}_i - \bar{\bar{Y}})^2}{2}$$

三、解答题 (3 题, 共 72 分)

1 (22 分)、 $X_1, \dots, X_n$ 是来自两点分布 $B(1, p)$ 总体的简单随机样本, 记函数 $g(p) = p^2(1-p)$, 已知样本量 $n \geq 4$, 则

(1) (4 分) 证明 $X_1 X_2 (1 - X_3)$ 是 $g(p)$ 的无偏估计量

(2) (8 分) 计算 $X_1 X_2 (1 - X_3)$ 的相对效率

(3) (10 分) 试给出 $g(p)$ 的一致最小方差无偏估计

Solution:

(1) 计算期望, $E[X_1 X_2 (1 - X_3)] = (EX_1)(EX_2)[E(1 - X_3)] = p^2(1-p)$, 故 $X_1 X_2 (1 - X_3)$ 是 $g(p)$ 的无偏估计.

(2) 先计算 p 的 Fisher 信息量, $I(p) = -E \left[\frac{\partial^2 \log f(X;p)}{\partial p^2} \right] = \frac{1}{p(1-p)}$, 则 $g(p)$ 的无偏估计的方差的 C-R 下界是

$$\frac{[g'(p)]^2}{nI(p)} = \frac{p(1-p)}{n} \cdot (2p-3p^2)^2 = \frac{p(1-p)(2p-3p^2)^2}{n}$$

再计算 $U = X_1 X_2 (1 - X_3)$ 的方差, 有

$$\begin{aligned} EU^2 &= E(X_1^2 X_2^2 (1 - X_3)^2) = (EX_1^2)(EX_2^2)[E(1 - X_3)^2] \\ &= p \cdot p \cdot (1-p) = p^2(1-p), \end{aligned}$$

故

$$\text{Var}(U) = p^2(1-p) - [p^2(1-p)]^2 = p^2(1-p)[1 - p^2(1-p)].$$

因此该估计量的效率是

$$\text{Eff}(U) = \frac{\text{CR下界}}{\text{Var}(U)} = \frac{1}{n} \frac{p(1-p)(2p-3p^2)^2}{p^2(1-p)[1 - p^2(1-p)]} = \frac{1}{n} \frac{p(2-3p)^2}{1 - p^2 + p^3}$$

(3) 样本的联合分布是

$$f(x_1, \dots, x_n; p) = p^{\sum_{i=1}^n X_i} (1-p)^{n-\sum_{i=1}^n X_i} = e^{n \log(1-p)} e^{(\log p - \log(1-p)) \sum_{i=1}^n X_i}$$

是一个完备的单参数指数族分布, 参数 p 的充分完备统计量是 $T = \sum_{i=1}^n X_i$. 而显然估计量 $\varphi(T) = E[X_1 X_2 (1 - X_3) | T]$ 是基于 T 给出的 $g(p)$ 的无偏估计, 根据 L-S 定理, 它是 $g(p)$ 的 UMVUE. 下面求 $\varphi(T)$ 的具体分布:

注意到 $X_1 X_2 (1 - X_3) = 1$ 当且仅当 $X_1 = 1, X_2 = 1, X_3 = 0$, 否则 $X_1 X_2 (1 - X_3) = 0$, 因此

$$\varphi(t) = E[X_1 X_2 (1 - X_3) | T = t] = P\left(X_1 = 1, X_2 = 1, X_3 = 0 \mid \sum_{i=1}^n X_i = t\right)$$

显然当 $t = 0, 1$ 时, $\varphi(t) = 0$, 当 $t = 2, 3, \dots, n$ 时, 有

$$\begin{aligned} \varphi(t) &= \frac{P(X_1 = 1, X_2 = 1, X_3 = 0, \sum_{i=4}^n X_i = t-2)}{P(\sum_{i=1}^n X_i = t)} \\ &= \frac{p \cdot p \cdot (1-p) \cdot C_{n-3}^{t-2} p^{t-2} (1-p)^{n-t-1}}{C_n^t p^t (1-p)^{n-t}} \\ &= \frac{\frac{(n-3)!}{(t-2)!(n-t-1)!}}{\frac{n!}{t!(n-t)!}} = \frac{t \cdot (t-1) \cdot (n-t)}{n \cdot (n-1) \cdot (n-2)}. \end{aligned}$$

2、(26 分) 现有两组简单随机样本, 其中 $X_1, \dots, X_m \sim N(\mu_1, \sigma^2)$, $Y_1, \dots, Y_n \sim N(\mu_2, \sigma^2)$, 其中 μ_1, μ_2 均为未知参数, 记 $\theta = \mu_1 - \mu_2$, 试解决以下问题:

(1) (8 分) 若 σ^2 未知, 构建 θ 的枢轴量 T , 并推导它的分布;

(2) (8 分) 若 σ^2 未知, 对假设检验问题 $H_0: \theta = 0$ vs $H_1: \theta \neq 0$, 给出一个显著性水平为 α 的拒绝域, 并利用反转接受域的方法给出 θ 的一个 $(1-\alpha)100\%$ 水平置信区间;

(3) (10 分) 若 σ^2 已知, 求 (2) 中假设检验问题的广义似然比检验 (GLRT), 并判断该检验是否为一致最优势检验 (UMPT).

Solution:

(1) 枢轴量是 $T = \frac{\bar{X} - \bar{Y}}{S_w \sqrt{\frac{1}{m} + \frac{1}{n}}}$, 其中 $\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$, $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$, 并记 $S_X^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2$ 与 $S_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 是两组样本的样本方差, 有

$$S_w^2 = \frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}.$$

而枢轴量的分子, 根据正态分布的性质, 有 $\bar{X} - \bar{Y} \sim N\left(\theta, \left(\frac{1}{m} + \frac{1}{n}\right)\sigma^2\right)$, 对于 $\frac{(m+n-2)S_w^2}{\sigma^2}$, 根据 Fisher 引理, 它们二者之间是独立的. 因此有

$$T = \frac{\bar{X} - \bar{Y} - \theta}{S_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(n+m-2).$$

当原假设成立时, 有

$$T = \frac{\bar{X} - \bar{Y}}{S_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(n+m-2)$$

是自由度为 $n+m-2$ 的中心 t 分布.

(2) 利用枢轴量给出拒绝域, 一个显著性水平为 α 的拒绝域是

$$W = \left\{ |T| \geq t_{1-\frac{\alpha}{2}}(n+m-2) \right\}.$$

反转接受域, 可以得到 $(1-\alpha)100\%$ 水平的置信区间, 是

$$\theta \in (\bar{X} - \bar{Y}) \pm S_w \sqrt{\frac{1}{m} + \frac{1}{n}} \cdot t_{1-\frac{\alpha}{2}}(n+m-2).$$

(3) 似然函数是

$$L(\mu_1, \mu_2; \{X_i\}, \{Y_i\}) = (2\pi\sigma^2)^{-\frac{m+n}{2}} e^{-\frac{1}{2\sigma^2} \left\{ \sum_{i=1}^m (X_i - \mu_1)^2 + \sum_{i=1}^n (Y_i - \mu_2)^2 \right\}},$$

在原假设参数空间中 ($\mu = \mu_1 = \mu_2$), 有 $\hat{\mu}_0 = \frac{m\bar{X} + n\bar{Y}}{m+n}$, 在全参数空间中 $\hat{\mu}_1 = \bar{X}, \hat{\mu}_2 = \bar{Y}$. 因此广义似然比是

$$\begin{aligned} \Lambda &= \frac{\sup_{\Theta_0} L(\mu_1, \mu_2)}{\sup_{\Theta} L(\mu_1, \mu_2)} = \frac{L(\hat{\mu}_0, \hat{\mu}_0)}{L(\hat{\mu}_1, \hat{\mu}_2)} \\ &= \frac{\exp \left\{ -\frac{1}{2\sigma^2} \left[\sum_{i=1}^m X_i^2 - 2m\bar{X}\hat{\mu}_0 + m\hat{\mu}_0^2 + \sum_{i=1}^n Y_i^2 - 2n\bar{Y}\hat{\mu}_0 + n\hat{\mu}_0^2 \right] \right\}}{\exp \left\{ -\frac{1}{2\sigma^2} \left[\sum_{i=1}^m X_i^2 - m\bar{X}^2 + \sum_{i=1}^n Y_i^2 - n\bar{Y}^2 \right] \right\}} \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \left[m(\bar{X} - \hat{\mu}_0)^2 + n(\bar{Y} - \hat{\mu}_0)^2 \right] \right\} \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \left[m \left(\frac{n(\bar{X} - \bar{Y})}{m+n} \right)^2 + n \left(\frac{m(\bar{X} - \bar{Y})}{m+n} \right)^2 \right] \right\} \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \left[\frac{mn}{m+n} (\bar{X} - \bar{Y})^2 \right] \right\}. \end{aligned}$$

因此似然比拒绝域

$$\{\Lambda \leq \lambda_0\} \Leftrightarrow \left\{ (\bar{X} - \bar{Y})^2 \geq c_0 \right\} \Leftrightarrow \left\{ \frac{(\bar{X} - \bar{Y})^2}{\left(\frac{1}{m} + \frac{1}{n}\right)\sigma^2} \geq c \right\}$$

注意到在原假设成立时 $\frac{(\bar{X} - \bar{Y})^2}{\left(\frac{1}{m} + \frac{1}{n}\right)\sigma^2} \sim \chi^2(1)$, 为使检验的水平恰为 α , 取 $c = \chi_{1-\alpha}^2(1)$.

该检验不是 UMP 检验, 当 $\theta = 1$ 时, 考虑另外一个拒绝域 $W_2 = \left\{ \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{1}{m} + \frac{1}{n}}\sigma} > z_{1-\alpha} \right\}$ 该拒绝域是由 NP 引理给出的在 $\theta = 1$ 处唯一功效最大的拒绝域, 因此一定有 $\rho_W(1) < \rho_{W_2}(1)$. 故该广义似然比检验不是 UMPT.

3、(24 分) 设 $X_1, \dots, X_n$ 是来自均匀分布总体 $U(-\theta, 0)$ 的简单随机样本, 其中未知参数 $\theta > 0$, 考虑假设检验问题 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$.

- (1) (6 分) 求广义似然比检验统计量 Λ ;
- (2) (8 分) 当原假设成立时, 求 $-2 \log \Lambda$ 的精确分布;
- (3) (10 分) 给出一个显著性水平为 α 的检验, 并写出功效函数.

Solution:

(1) 似然函数是

$$L(\theta) = \frac{1}{\theta^n} I_{\{\theta \geq -X_{(1)}\}}.$$

在原假设参数空间中, θ 的 MLE 是 θ_0 . 在全参数空间中, θ 的 MLE 是 $-X_{(1)}$.

因此似然比统计量是

$$\Lambda = \frac{\sup_{\Theta_0} L(\theta)}{\sup_{\Theta} L(\theta)} = \frac{L(\theta_0)}{L(-X_{(1)})} = \begin{cases} \frac{(-X_{(1)})^n}{\theta_0^n}, & -X_{(1)} < \theta_0, \\ 0, & 0 < \theta_0 \leq -X_{(1)}. \end{cases}$$

(2) 考虑 $Y_i = -X_i \sim U(0, \theta)$, 且 $-X_{(1)} = Y_{(n)}$, 而 $Z = \frac{Y_{(n)}}{\theta} \sim \text{Beta}(n, 1)$.

因此当原假设成立时

$$T = -2 \log \Lambda = -2 \log \frac{(-X_{(1)})^n}{\theta_0^n} = -2n \log \frac{Y_{(n)}}{\theta_0} = -2n \log Z$$

根据随机变量函数的分布, 可求得 T 的密度函数是

$$\begin{aligned} f_T(t) &= \left| -\frac{1}{2n} e^{-\frac{t}{2n}} \right| \cdot n \cdot \left(e^{-\frac{t}{2n}} \right)^{n-1}, \quad 0 < e^{-\frac{t}{2n}} < 1 \\ &= \frac{1}{2} e^{-\frac{t}{2}}, \quad t > 0 \end{aligned}$$

即参数为 $1/2$ 的指数分布. 或自由度为 2 的卡方分布.

(3) 考虑似然比检验, 有似然比拒绝域

$$W = \{\Lambda < \lambda_0\} = \{-X_{(1)} < a\} \cup \{-X_{(1)} > b\}$$

考虑到当 $\theta_1 > \theta_0$ 时恒有 $\Lambda = 0$, 因此可取 $b = \theta_0$. 为使检验的水平是 α , 即

$$\alpha = P_{\theta_0}(-X_{(1)} < a) + P_{\theta_0}(-X_{(1)} > \theta_0) = P_{\theta_0}\left(\frac{Y_{(n)}}{\theta_0} < \frac{a}{\theta_0}\right) = \int_0^{\frac{a}{\theta_0}} n y^{n-1} dy = \left(\frac{a}{\theta_0}\right)^n$$

取 $a = \theta_0 \alpha^{\frac{1}{n}}$. 综上所述, 似然比拒绝域是

$$W = \{-X_{(1)} < \theta_0 \alpha^{\frac{1}{n}}\} \cup \{-X_{(1)} > \theta_0\}.$$

再计算检验的功效, 当 $\theta < \theta_0 \alpha^{\frac{1}{n}}$ 时, 有

$$\begin{aligned} \rho_W(\theta) &= P_{\theta}(-X_{(1)} < \theta_0 \alpha^{\frac{1}{n}}) + P_{\theta}(-X_{(1)} > \theta_0) \\ &= 1 + 0 = 1 \end{aligned}$$

当 $0 < \theta < \theta_0$ 时, 有

$$\begin{aligned}\rho_W(\theta) &= P_\theta(-X_{(1)} < \theta_0 \alpha^{\frac{1}{n}}) + P_\theta(-X_{(1)} > \theta_0) \\ &= P_\theta\left(\frac{Y_{(n)}}{\theta} < \frac{\theta_0 \alpha^{\frac{1}{n}}}{\theta}\right) + P_\theta\left(\frac{Y_{(n)}}{\theta} > \frac{\theta_0}{\theta}\right) \\ &= \int_0^{\frac{\theta_0 \alpha^{\frac{1}{n}}}{\theta}} n y^{n-1} dy + 0 \\ &= \left(\frac{\theta_0}{\theta}\right)^n \alpha\end{aligned}$$

当 $\theta \geq \theta_0$ 时, 有

$$\begin{aligned}\rho_W(\theta) &= P_\theta(-X_{(1)} < \theta_0 \alpha^{\frac{1}{n}}) + P_\theta(-X_{(1)} > \theta_0) \\ &= P_\theta\left(\frac{Y_{(n)}}{\theta} < \frac{\theta_0 \alpha^{\frac{1}{n}}}{\theta}\right) + P_\theta\left(\frac{Y_{(n)}}{\theta} > \frac{\theta_0}{\theta}\right) \\ &= \int_0^{\frac{\theta_0 \alpha^{\frac{1}{n}}}{\theta}} n y^{n-1} dy + \int_{\frac{\theta_0}{\theta}}^1 n y^{n-1} dy \\ &= \left(\frac{\theta_0}{\theta}\right)^n \alpha + \left(1 - \left(\frac{\theta_0}{\theta}\right)^n\right) = 1 - \left(\frac{\theta_0}{\theta}\right)^n (1 - \alpha).\end{aligned}$$

上海交通大学-432 统计学

上海交通大学-432 统计学-2016 年

一. 选择题 (10 小题, 每小题 6 分, 共 60 分)

1. 从一个 600 人的小区里抽住户, 先按单元分, 抽取若干单元的住户, 再从抽取的若干个单元中, 按完全随机的办法抽取 60 户, 这种是什么抽样方法? ()

- A. 整群抽样
- B. 分层抽样
- C. 系统抽样
- D. 多阶段抽样

Solution: D

多阶段抽样是先将一个很大的总体划分为若干个子总体, 即一阶单位, 再把一阶单位划分为若干个更小的单位, 称为二阶单位, 照此继续下去划分出更小的单位, 依次称为三阶单位、四阶单位等。然后分别按随机原则逐阶段抽样。

2. 为调查群众戴口罩的频率, 调查者采用问卷调查, 问卷中的一个问题为“您戴口罩的频率吗?”, 选项为“从来不戴”、“极少戴”、“偶尔戴”、“经常戴”。这一调查包含的误差类型是 ()

- A. 记忆误差
- B. 理解误差
- C. 无回答误差
- D. 有意识误差

Solution: B

3. 自填式问卷调查的缺点是什么? ()

- A. 回收率低
- B. 成本太高
- C. 只适合复杂的问卷
- D. 调查周期短

Solution: A

自填式问卷调查成本低、只适合简单问卷、调查周期长, 但回收率低。

4. 一个月份或季度的季节指数指的是该月份或季度数值 ()

- A. 占全年月份或季度数值总和的比率
- B. 占以往所有年份相应的月份或季度数值平均的比率
- C. 占全年月份或季度数值的平均数的比率
- D. 以上选项都不对

Solution: B

季节指数以平均数据进行计算。

5. 设 $X_1, \dots, X_5$ 为来自均匀分布 $U(0, \theta)$ 的简单随机样本, 令 $Y_1 = \min\{X_i\}, Y_5 = \max\{X_i\}$, 则 θ 的 90% 置信区间为 ()

- (A) $\left(\frac{Y_1}{\sqrt[5]{0.95}}, \frac{Y_1}{\sqrt[5]{0.05}}\right)$
- (B) $\left(\frac{Y_5}{\sqrt[5]{0.95}}, \frac{Y_5}{\sqrt[5]{0.05}}\right)$
- (C) $\left(\frac{Y_1}{\sqrt[5]{0.9}}, \frac{Y_5}{\sqrt[5]{0.9}}\right)$
- (D) $\left(\frac{Y_1}{1-\sqrt[5]{0.1}}, \frac{Y_5}{\sqrt[5]{0.1}}\right)$

Solution: B

X_i 的概率密度函数: $f(x_i) = \begin{cases} \frac{1}{\theta} & x \in (0, \theta) \\ 0 & \text{其他} \end{cases}$ 所以 Y_5 的概率密度函数: $f_{Y_5}(y) = \begin{cases} \frac{5y^4}{\theta^5} & y \in (0, \theta) \\ 0 & \text{其他} \end{cases}$, 故

$\frac{Y_5}{\theta}$ 为枢轴量, 其概率密度函数:

$$f_{\frac{Y_5}{\theta}}(y) = \begin{cases} 5y^4 & y \in (0, 1) \\ 0 & \text{其他} \end{cases}$$

于是有 $P(\sqrt[5]{0.05} < \frac{Y_5}{\theta} < \sqrt[5]{0.95}) = 0.9$, 反解得到置信区间

$$\left(\frac{Y_5}{\sqrt[5]{0.95}}, \frac{Y_5}{\sqrt[5]{0.05}} \right)$$

6. 甲乙两人轮流掷骰子, 先掷出 1 或 6 者取胜, 问先掷者获胜的概率是 ().

- A. $\frac{1}{3}$;
- B. $\frac{1}{2}$;
- C. $\frac{2}{5}$;
- D. $\frac{3}{5}$.

Solution: D

$$\frac{1}{3} \sum_{i=0}^{\infty} \left(\frac{2}{3} \right)^i = \frac{1}{3} \cdot \frac{1}{1 - \left(\frac{2}{3} \right)} = \frac{3}{5}$$

7. 设 $h(x) = [x]$, 已知 $\xi \sim \exp(\theta)$, 则 $h(\xi)$ 的分布是 ().

- (A) 泊松分布, 参数为 $e^{-\theta}$;
- (B) 几何分布, 参数为 $e^{-\theta}$;
- (C) 泊松分布, 参数为 $1 - e^{-\theta}$;
- (D) 几何分布, 参数为 $1 - e^{-\theta}$.

Solution: D

$h(\xi) + 1$ 的分布是参数为 $(1 - e^{-\theta})$ 的几何分布 ξ 的分布函数是 $F_{\xi}(x) = \begin{cases} 1 - e^{-\theta x} & x > 0 \\ 0 & \text{其他} \end{cases}$

$$\begin{aligned} P(h(\xi) + 1 = x) &= P([\xi] = x - 1) \\ &= P(x - 1 \leq \xi < x) \\ &= F_{\xi}(x) - F_{\xi}(x - 1) \\ &= 1 - e^{-\theta x} - (1 - e^{-\theta(x-1)}) \\ &= e^{-\theta(x-1)-\theta} - e^{-\theta(x-1)} = e^{-\theta(x-1)} (1 - e^{-\theta}) \end{aligned}$$

故 $h(\xi) + 1$ 服从参数为 $(1 - e^{-\theta})$ 的几何分布.

8. 已知独立双样本 $X_1, \dots, X_n \stackrel{iid}{\sim} N(0, \sigma_X^2)$, $Y_1, \dots, Y_m \stackrel{iid}{\sim} N(0, \sigma_Y^2)$, 原假设为 $\sigma_X = \sigma_Y$. 问样本方差之比 S_X^2/S_Y^2 在原假设为真时服从的分布是 ().

- (A) $F(n, m)$;
- (B) $F(m, n)$;
- (C) $F(n - 1, m - 1)$;
- (D) $F(m - 1, n - 1)$.

Solution: C

因为

$$S_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}, \quad S_Y^2 = \frac{\sum_{i=1}^m (Y_i - \bar{Y})^2}{m-1},$$

当 $\sigma_X = \sigma_Y$ 时, 有

$$\frac{S_X^2}{S_Y^2} = \frac{\frac{\chi^2(n-1)}{n-1}}{\frac{\chi^2(m-1)}{m-1}} \sim F(n-1, m-1),$$

注意这里是“样本方差”, 即使 μ 已知, 样本方差依然是 $S_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$, $S_Y^2 = \frac{\sum_{i=1}^m (Y_i - \bar{Y})^2}{m-1}$.

9. 设 $X_1, \dots, X_n$ 为正态分布 $N(\mu, \sigma^2)$ 的样本, μ 未知而 σ^2 已知. $\bar{X}$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本均值及样本方差. 记 $T_1 = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}$, $T_2 = \frac{\bar{x} - \mu}{s/\sqrt{n}}$, $T_3 = \frac{(n-1)S^2}{\sigma^2}$, 则 T_1, T_2, T_3 中统计量的个数为 ().

- (A) 0
- (B) 1
- (C) 2
- (D) 3

Solution: B

统计量指样本的函数 $T(X_1, X_2, \dots, X_n)$; 统计量依赖且只依赖于样本, 它不含任何未知参数 (故一般其分布与未知参数有关). 由于 μ 未知, 故 T_1, T_2 不是统计量, T_3 是统计量.

10. 设有来自方差为 σ^2 的总体的随机样本 $X_1, \dots, X_n$, 定义样本均值 $\bar{X}$, 则有 $\text{Var}(X_1 - \bar{X}) = ()$.

- A. σ^2
- B. $\frac{n-2}{n}\sigma^2$
- C. $\frac{n+1}{n}\sigma^2$
- D. $\frac{n-1}{n}\sigma^2$

Solution: D.

注意协方差不为 0, 有

$$\begin{aligned}\text{Var}(X_1 - \bar{X}) &= \text{Var}(X_1) + \text{Var}(\bar{X}) - 2\text{Cov}(X_1, \bar{X}) \\ &= \sigma^2 + \frac{\sigma^2}{n} - 2 \frac{\sigma^2}{n} = \frac{n-1}{n}\sigma^2.\end{aligned}$$

二、简答题

1. 抽样调查的主要优点有哪些?

Solution: 1、抽样调查可以减少调查的工作量, 调查内容可以求多、求全或求专, 可以保证调查对象的完整性。

2、可以从数量上以部分推算总体, 利用概率论和数理统计原理, 以一定的概率保证推算结果的可靠程度, 起到全面调查认识总体的功能, 可以保证调查的精度。

3、因为抽样调查是针对总体中的一部分单位进行的, 抽样调查可以大大减少调查费用, 提高调查效率。

4、收集、整理数据、综合样本的速度快, 保证调查的时效性。

2. (1) 比较均值、众数、中位数的特点, 并举例说明;

(2) 比较标准差和变异系数的特点, 并举例说明;

(3) 说明标准分数的计算公式, 并说明其意义。

Solution: (1) 平均数、中位数、众数都是度量一组数据集中趋势的统计量。所谓集中趋势是指一组数据向某一中心值靠拢的倾向, 测度集中趋势就是寻找数据一般水平的代表值或中心值。而这三个特征数又各有特点, 能够从不同的角度提供信息。

[平均数] 特点: 计算用到所有的数据, 它能够充分利用数据提供的信息, 它具有良好的数学性质, 因此在实际应用中较为广泛。但它受极端值的影响较大。应用场合: 没有极端值的情况下数据集中趋势的刻画, 例如考研数学平均衡量今年数学难度。

[中位数] 特点: 中位数是一组数据中间位置的代值。计算简单, 不受极端值的影响, 但不能充分利用每个数据所提供的信息。应用场合: 有极端值, 且无某数据重复出现多次的情况下集中趋势的刻画, 例如工资收入的中位数衡量了一个公司员工工资的整体水平。

[众数] 特点: 众数是一组数据中出现次数最多的数据。不受极端值的影响, 当一组数据中某些数据多次重复出现时, 众数往往是人们最关心的一个量。但它不能象平均数那样充分利用数据提供信息。应用场合: 有极端值, 有某些数据多次重复出现时, 如某鞋店卖出鞋码的众数应被进货最多。

(2) 1. 变异系数是无量纲的, 而平均值和标准差的量纲相同都为随机变量的量纲。2. 比较量纲不同的两个随机变量的分散度时用变异系数为好。3. 量纲相同的两个随机变量但平均值差别较大时用变异系数评价分散度。4. 用变异系数评价分散度时消除了平均值大小的影响。

(3) 用公式表示为: $z = (x - \mu)/\sigma$; 其中 z 为标准分数; x 为某一具体分数, μ 为平均数, σ 为标准差。 z 值的量代表着原始分数和母体平均值之间的距离, 是以标准差为单位计算。在原始分数低于平均值时 z 则为负数, 反之则为正数。

3. 随机变量 $X_i (i = 1, 2, 3, \dots, n)$ 独立同分布, 且 $E(X_i) = 1, E(X_i^2) = 2, E(X_i^4) = 8$, 则当 $n \rightarrow \infty$ 时, $\frac{\sum_{i=1}^n X_i^2}{n}$ 服从什么分布, 并说明概率密度函数的形态变化。

Solution:

由于 $X_1^2, \dots, X_n^2$ 是独立同分布的, 且其数学期望存在 $EX_1^2 = 2$, 那么根据大数定律, 有 $\frac{\sum_{i=1}^n X_i^2}{n} \xrightarrow{P} 2$.

另外, $Var(X_1^2) = 8 - 4 = 4$, 那么根据中心极限定理, 有 $\sqrt{n} \left(\frac{\sum_{i=1}^n X_i^2}{n} - 2 \right) \xrightarrow{d} N(0, 4)$.

当 n 增大时, $\frac{\sum_{i=1}^n X_i^2}{n}$ 的密度函数将会越来越聚集于一点。

4. 甲乙丙三人进行信息传递游戏, 通过表演将某个动物的名称传给下一个人。假设所有人都知道题目只有“猫”或“狗”。甲是第一个人, 他看到的动物是“猫”, 他以表演的方式将信息传递给乙, 乙再通过表演的方式将信息传递给丙, 丙说出动物名称。若每个人信息传递正确的概率均为 $\frac{1}{3}$, 求丙说出“猫”的概率。

Solution:

只需计算甲、乙都传递正确或甲乙都传递错误的概率, 是 $\frac{2}{3} \cdot \frac{2}{3} + \frac{1}{3} \cdot \frac{1}{3} = \frac{5}{9}$.

三. 计算题

1. 有下述一元线性的方差分析表

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	612	3			0.0001
残差					
总	888	30			

(1)(4 分) 样本量和参数分别是几个?

(2)(4 分) 补齐方差分析表。

(3)(5 分) 给定 $\alpha = 0.05$, 方程是否显著?

(4)(5 分) 给出 R^2 , 以及误差方差的估计量。

Solution:

(1) 回归平方和的自由度为 3, 说明参数为 4 个。总平方和的自由度为 30, 说明样本量是 31。

(2) 补齐后为

变量	平方和	自由度	均方	F 比	Prob(> F)
回归	612	3	204	19.96	0.0001
残差	276	27	10.22		
总	888	30			

(3) 方程是显著的, 因为 F 检验的 p 值是 $0.0001 < 0.05$, 拒绝原假设.

(4) $R^2 = \frac{612}{888} = 0.689$, 残差方差的估计量是残差对应的均方, 即 10.22.

2. 机场大巴从起点站到西单站恰有 n 站, 某次大巴从机场开出时有 m 位旅客, 每位旅客在每站下车都是等可能的 (即每人都有 n 次下车选择), 如果无人下车则中途不停车. 求机场大巴到西单站的平均停车次数.

设 $X_1, \dots, X_n$ 分别是各站停车次数, $X_1 = 1$ 表示在第一个站停车, $X_1 = 0$ 表示不停车, 则题目所求即为 $E(X) = E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n) = nE(X_1)$. 而

$$E(X_1) = P(X_1 = 1) = 1 - P(X_1 = 0) = 1 - \left(1 - \frac{1}{n}\right)^m,$$

因此 $E(X) = n \left[1 - \left(1 - \frac{1}{n}\right)^m\right]$.

四. 证明题

1. 设 $p \in (0, 1)$, $0 < \alpha < (1-p)/p$. 已知一个家庭有 n 个小孩的概率是

$$p_n = \begin{cases} \alpha p^n, & n \geq 1, \\ 1 - \alpha p/(1-p), & n = 0. \end{cases}$$

又设男婴和女婴的出生是等可能的. 回答:

(1) 求一个家庭有 k 个男孩的概率;

(2) 已知某家庭没有女孩, 求该家庭有 1 个男孩的概率.

Solution: 分别用 X_1 和 X_2 表示一个家庭的男孩、女孩数量, 则

(1) 根据全概率公式, $P(X_1 = k) = \sum_{n=k}^{\infty} C_n^k \left(\frac{1}{2}\right)^n p_n$,

若 $k = 0$, 则

$$P(X_1 = 0) = \sum_{n=0}^{\infty} C_n^0 \left(\frac{1}{2}\right)^n p_n = 1 - \frac{\alpha p}{1-p} + \sum_{n=1}^{\infty} C_n^0 \left(\frac{1}{2}\right)^n \alpha p^n = 1 - \frac{\alpha p}{1-p} + \alpha \sum_{n=1}^{\infty} \left(\frac{p}{2}\right)^n = 1 - \frac{\alpha p}{1-p} + \alpha \frac{p}{2-p}$$

当 $k \geq 1$, 则

$$P(X_1 = k) = \sum_{n=k}^{\infty} C_n^k \left(\frac{1}{2}\right)^n p_n = \sum_{n=k}^{\infty} C_n^k \left(\frac{1}{2}\right)^n \alpha p^n = \alpha \left(\frac{p}{2}\right)^{-1} \sum_{n=k+1}^{\infty} C_{n-1}^{(k+1)-1} \left(\frac{p}{2}\right)^n = \alpha \left(\frac{p}{2}\right)^{-1} \left(\frac{p}{2-p}\right)^{k+1} = \frac{2\alpha p^k}{(2-p)^{k+1}}$$

注意这里我们用到了负二项分布公式, 即设 Z 表示伯努利试验成功 r 次所需的总次数, 即 $Z \sim Nb(r, p)$, 有分布列 $1 = \sum_{n=r}^{\infty} C_{n-1}^{r-1} p^r q^{n-r} = \left(\frac{p}{q}\right)^r \sum_{n=r}^{\infty} C_{n-1}^{r-1} q^n$, 则有公式 $\sum_{n=r}^{\infty} C_{n-1}^{r-1} q^n = \left(\frac{q}{p}\right)^r$, 其中 $p = 1 - q$. 利用该公式可计算前面式中

$$\sum_{n=k+1}^{\infty} C_{n-1}^{(k+1)-1} \left(\frac{p}{2}\right)^n = \left(\frac{\frac{p}{2}}{1 - \frac{p}{2}}\right)^{k+1} = \left(\frac{p}{2-p}\right)^{k+1}$$

(2)

$$P(X_1 = 1 | X_2 = 0) = \frac{P(X_1 = 1, X_2 = 0)}{P(X_2 = 0)} = \frac{\frac{1}{2}\alpha p}{1 - \frac{\alpha p}{2-3p+p^2}}$$

上海交通大学-432 统计学-2017 年

一. 选择题 (10 小题, 每小题 6 分, 共 60 分)

1. 分布中位数小于平均数, 则一般来说, 该分布 ().

- A. 左偏
- B. 右偏
- C. 正偏
- D. 无偏

Solution: B.

2. 当一组数据呈对称分布时, 在平均数加减 2 个标准差的范围之内大约有 () 的数据.

- A. 68%
- B. 95%
- C. 99.7%
- D. 89%

Solution: B

利用标准正态分布来估计, $\Phi(2) - \Phi(-2) = 2\Phi(2) - 1 = 2 \cdot 0.9722 - 1 = 0.9444$.

3. 抽样推断的精确度与抽样误差的关系是 ().

- A. 前者提高说明后者变小
- B. 前者提高说明后者变大
- C. 前者提高说明后者不变
- D. 没有关系

Solution: A.

要求的精确度越高, 说明置信区间越短, 抽样误差越小.

4. 假设独立随机变量 X, Y 服从同一名称的概率分布 (二者的分布参数未必相同)。且 $X + Y$ 也服从同一名称的概率分布。则 X, Y 不可能服从 ()

- (A) 二项分布
- (B) 泊松分布
- (C) 正态分布
- (D) 指数分布

Solution: D

两个独立的随机变量服从二项分布、泊松分布或者正态分布时, 他们的和也服从于该随机变量的概率分布, 而若 XY 服从指数分布时, 他们的和不一定服从指数分布. 例如: XY 服从参数为 λ 的指数分布服从 $Ga(1, \lambda)$, $X + Y$ 服从 $Ga(2, \lambda)$ 不服从指数分布. 选项 D 错误

5. 设 $X \sim \chi^2(1), Y \sim \chi^2(n)$, 则 $F = nX/Y$ 的分布是 ()

- (A) $t(n)$
- (B) $F(1, n)$
- (C) $F(n, 1)$
- (D) 不能确定

Solution: D

X, Y 的独立性未知, 无法判断 $\frac{nX}{Y}$ 的分布, 因此本题选 D.

6. 设 $X_1, X_2, \dots, X_{n_1}$ 是来自正态总体 $N(\mu_1, \sigma_1^2)$ 的一个样本, 设 $Y_1, Y_2, \dots, Y_{n_2}$ 是来自正态总体 $N(\mu_2, \sigma_2^2)$ 的一个样本, 且 $X_i (i = 1, 2, 3, \dots, n_1)$ 与 $Y_i (i = 1, 2, 3, \dots, n_2)$ 相互独立, 已知 $n_1 n_2 S_1^2 S_2^2$, 通过查表可知 $F_{\alpha/2}(n_1, n_2) F_{\alpha/2}(n_2, n_1) F_{\alpha}$. 则方差之比 σ_1^2 / σ_2^2 的置信区间为 ().

- A. $\frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1, n_2)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2, n_1)$
 B. $\frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1-1, n_2-1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2-1, n_1-1)$
 C. $\frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1, n_2)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2/S_2^2}{F_{\alpha/2}(n_2, n_1)}$
 D. $\frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1-1, n_2-1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2/S_2^2}{F_{\alpha/2}(n_2-1, n_1-1)}$

Solution: B

注意这里用的应是上分位数, 根据 F 分布的对称性, 置信区间应为

$$\left[\frac{s_1^2/s_2^2}{F_{\frac{\alpha}{2}}(n_1-1, n_2-1)}, \frac{s_1^2/s_2^2}{F_{1-\frac{\alpha}{2}}(n_1-1, n_2-1)} \right] = \left[\frac{s_1^2/s_2^2}{F_{\frac{\alpha}{2}}(n_1-1, n_2-1)}, \frac{s_1^2}{s_2^2} F_{\frac{\alpha}{2}}(n_2-1, n_1-1) \right]$$

7. 设总体分布为参数为 2 的指数分布 $\text{Exp}(2)$ (密度函数概率密度函数: $f(x) = \begin{cases} 2e^{-2x} & x > 0 \\ 0 & \text{其他} \end{cases}$)。现分别有来自总体的容量分别为 200 和 400 的两独立样本, 则此两样本均值之差的绝对值大于 $\sqrt{3}/20$ 的概率大约是 ()

- (A) $2\Phi(1.5) - 1$
 (B) $2\Phi(1.5)$
 (C) $2\Phi(2)$
 (D) $2 - 2\Phi(2)$

Solution: D

参数为 2 的指数分布的概率密度函数: $f(x) = \begin{cases} 2e^{-2x} & x > 0 \\ 0 & \text{其他} \end{cases}$, 其期望与方差为: $E(x) = \frac{1}{2}, D(x) = \frac{1}{4}$ 另

$\bar{X}, \bar{Y}$ 分别表示样本容量为 200, 400 的样本均值有:

$$E(\bar{X}) = \frac{1}{2}, D(\bar{X}) = \frac{1}{800}, E(\bar{Y}) = \frac{1}{2}, D(\bar{Y}) = \frac{1}{1600},$$

由中心极限定理: $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{3}{1600}}} \sim N(0, 1)$ 所以有:

$$\begin{aligned} P\left(|\bar{X} - \bar{Y}| > \frac{\sqrt{3}}{20}\right) &= 1 - P\left(-\frac{\sqrt{3}}{20} < \bar{X} - \bar{Y} < \frac{\sqrt{3}}{20}\right) \\ &= 1 - P\left(\frac{-\sqrt{3}/20}{\sqrt{3}/40} < \frac{\bar{X} - \bar{Y}}{\sqrt{3}/40} < \frac{\sqrt{3}/20}{\sqrt{3}/40}\right) \\ &= 1 - [\Phi(2) - \Phi(-2)] \\ &= 1 - [2\Phi(2) - 1] \\ &= 2 - 2\Phi(2) \end{aligned}$$

选项 D 正确

8. 下面哪个选项不是随机事件 $A, B (0 < P(A), P(B) < 1)$ 相互独立的充要条件 ()

- (A) $P(A | B) = P(A | \bar{B})$
 (B) $P(A | B) + P(\bar{A} | \bar{B}) = 1$
 (C) $P(A \cap \bar{B}) = P(A)P(\bar{B})$
 (D) $P(A | B) + P(A | \bar{B}) = 1$

Solution: D

A 与 B 相互独立有 $P(AB) = P(A)P(B)$ 选项 A:

$$\begin{aligned}\frac{P(AB)}{P(B)} &= \frac{P(A\bar{B})}{P(\bar{B})} \\ \Leftrightarrow P(AB)P(\bar{B}) &= P(A\bar{B}) \cdot P(B) \\ \Leftrightarrow P(AB) \cdot [1 - P(B)] &= [P(A) - P(AB)] \cdot P(B) \\ \Leftrightarrow P(AB) - P(AB)P(B) &= P(A)P(B) - P(AB)P(B) \\ \Leftrightarrow P(AB) &= P(A)P(B)\end{aligned}$$

选项 B:

$$\begin{aligned}P(A|B) + P(\bar{A}|\bar{B}) &= P(A|B) + 1 - P(A|\bar{B}) = 1 \\ P(A|B) &= P(A|\bar{B})\end{aligned}$$

由选项 A 可知它是相互独立的充分必要条件选项 C: 由独立的定义显然成立选项 D:

$$\begin{aligned}P(A|B) + P(A|\bar{B}) &= P(A|B) + 1 - P(\bar{A}|\bar{B}) = 1 \\ P(A|B) &= P(\bar{A}|\bar{B}) \\ P(\bar{A}\bar{B})P(B) &= P(AB) \cdot P(\bar{B})\end{aligned}$$

若 AB 独立, 上式化简得到: $P(A) = P(\bar{A})$, 不恒成立. 故选项 D 错误

9. $X_1, \dots, X_n$ 为来自正态分布 $N(\mu, 1)$ 的简单随机样本. 记 Z_α 为标准正态分布的 $100\alpha\%$ 分位数, 则由此样本所构造的置信水平分别为 95% 与 90% 的双侧置信区间长度之比为 ()

- (A) $2 \times \frac{z_{0.975}}{z_{0.95}}$
(B) $\frac{z_{0.975}}{z_{0.95}}$
(C) $2 \times \frac{z_{0.95}}{z_{0.90}}$
(D) $\frac{z_{0.95}}{z_{0.90}}$

Solution: B

依题意得 $\sqrt{n}(\bar{x} - \mu) \sim N(0, 1)$, 所以令 $P(|\sqrt{n}(\bar{x} - \mu)| \leq d) = 1 - \alpha$ 可得置信区间的长度为: $2d = \frac{2z_{1-\frac{\alpha}{2}}}{\sqrt{n}}$ 因此 95% 与 90% 双侧置信区间长度之比为 $\frac{z_{0.975}}{z_{0.95}}$. 选项 B 正确

10. 设 $X_1, \dots, X_n$ 为来自均值为 0, 方差为 σ^2 的总体的简单随机样本, 令 $Y = \sum_{i=1}^n X_i^2, Q = \sum_{i=1}^n (X_i - \bar{X})^2$, 则下列说法正确的是 ()

- (A) Q/n 是 σ^2 的最大似然估计
(B) Y/n 是 σ^2 的最大似然估计
(C) Q/n 是 σ^2 的无偏估计
(D) Y/n 是 σ^2 的无偏估计

Solution: D

题目没有给出总体的概率密度函数, 无法求出 σ^2 的最大似然估计, 选项 A、B 错误. $E\left(\frac{Q}{n}\right) = \frac{n-1}{n}\sigma^2$, 选项 C 错误. $E\left(\frac{Y}{n}\right) = \frac{1}{n}E\left(\sum_{i=1}^n X_i^2\right) = \frac{1}{n}\left[\sum_{i=1}^n EX_i^2 + \sum_{i=1}^n (EX_i)^2\right] = \frac{1}{n}(n\sigma^2) = \sigma^2$, 故选项 D 正确.

二、简答题

1. 总体 $X \sim N(\mu_1, \sigma_0^2)$, σ_0^2 已知, 样本量为 n_1 . 总体 $Y \sim N(\mu_2, \sigma_1^2)$, 样本量为 n_2 . 两组样本独立.

- (1) 写出 μ_1 的 $1 - \alpha$ 置信区间;
(2) 写出 μ_2 的 $1 - \alpha$ 置信区间;
(3) 若 $\sigma_0^2 = \sigma_1^2$, 写出 $(\mu_1 - \mu_2)$ 的 $1 - \alpha$ 置信区间.

Solution: (1) 方差已知, 用枢轴量

$$u = \frac{\bar{X} - \mu_1}{\sigma_0/\sqrt{n_1}} \sim N(0, 1),$$

置信区间是

$$\mu_1 \in \left[\bar{X} - \frac{\sigma_0}{\sqrt{n_1}} u_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma_0}{\sqrt{n_1}} u_{\frac{\alpha}{2}} \right].$$

(2) 方差未知, 用枢轴量

$$t = \frac{\bar{Y} - \mu_1}{S_Y/\sqrt{n}} \sim t(n_2 - 1),$$

置信区间是

$$\mu_2 \in \left[\bar{Y} - \frac{S_Y}{\sqrt{n_2}} t_{\frac{\alpha}{2}}(n_2 - 1), \bar{Y} + \frac{S_Y}{\sqrt{n_2}} t_{\frac{\alpha}{2}}(n_2 - 1) \right].$$

(3) 由于 $\sigma_0 = \sigma_1$ 已知, 故有

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \left(\frac{1}{n_1} + \frac{1}{n_2}\right) \sigma_0^2\right),$$

枢轴量为

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \sim N(0, 1),$$

因此置信区间为

$$\mu_1 - \mu_2 \in \left[\bar{X} - \bar{Y} - u_{\frac{\alpha}{2}} \sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}, \bar{X} - \bar{Y} + u_{\frac{\alpha}{2}} \sigma_0 \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right)} \right].$$

2. 建立多元回归模型时, 为什么需要进行变量选择? 并阐述向前选择法的步骤.

Solution:

因变量可能会由多个自变量决定. 但是具体由多少个自变量决定是不清楚的, 所以我们需要通过变量选择, 判断这个具体的自变量个数. 另外有的时候若自变量之间存在相关性 (多重共线性问题), 将会导致估计量不有效或不唯一, 这时候也需要进行变量选择. 以及为了防止过多的加入无用变量导致过拟合, 我们也需要进行变量选择.

向前选择的步骤:

1. 对 k 个自变量分别拟合对因变量 y 的一元线性回归模型, 即得到 k 个一元线性回归模型, 然后找出 F 统计量值最高的模型及对应的变量 x_i , 并将该自变量首先引入模型中. 在此过程中, 需要注意的是: 如果所有模型的 F 统计量均未通过检验, 说明所搜集的自变量与因变量之间均为不显著, 说明模型构建不适合, 应当考虑换其他模型, 本方法的运算过程也就终止了.

2. 在已经引入的模型上, 分别引入剩余的 $k-1$ 个自变量, 分别得到 $k-1$ 个二元线性回归模型, 即变量组合为 $k-1$ 个二元线性回归模型, 继而得到 $k-1$ 个新的 F 统计量, 并从中找出 F 统计量的值为最高的模型, 此时, 该模型中含有两个自变量, 新增加的自变量即为经过筛选出来的应当引入模型的自变量. 同样地, 如果在此过程中, 没有 F 统计量通过检验, 则运算终止.

3. 按照第二步的筛选方法, 不断引入新的自变量, 直到引入的新的自变量也不能使得残差平方和 (SSE) 显著减少为止 (F 统计量均为通过检验). 向前选择法就是这样一个不断引入新变量, 进行 F 统计量检验的过程.

3. 随机变量 $X_i (i = 1, 2, 3, \dots, n)$ 独立同分布, 且 $E(X_i) = 1, E(X_i^2) = 2, E(X_i^4) = 8$, 则当 $n \rightarrow \infty$ 时, $\frac{\sum_{i=1}^n X_i^2}{n}$ 服从什么分布, 并说明概率密度函数的形态变化.

Solution:

由于 $X_1^2, \dots, X_n^2$ 是独立同分布的, 且其数学期望存在 $EX_1^2 = 2$, 那么根据大数定律, 有 $\frac{\sum_{i=1}^n X_i^2}{n} \xrightarrow{P} 2$.

另外, $Var(X_1^2) = 8 - 4 = 4$, 那么根据中心极限定理, 有 $\sqrt{n} \left(\frac{\sum_{i=1}^n X_i^2}{n} - 2 \right) \xrightarrow{d} N(0, 4)$.

当 n 增大时, $\frac{\sum_{i=1}^n X_i^2}{n}$ 的密度函数将会越来越聚集于一点.

4. 考虑一元线性回归 $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, 给出数据 (x_i, y_i) , 问什么情况下可以使用极大似然估计求未知参数, 并且解释极大似然估计和最小二乘法的区别和联系.

Solution: 当如果随机误差项的分布已经知时, 可以写出似然函数, 这时候可以使用极大似然估计法.

最小二乘法在任何时候都可以使用, 它仅需求出使得残差平方和最小的参数值作为估计. 而如果随机误差项是独立同方差, 均值为 0 的正态分布时, 极大似然估计的结果与最小二乘估计的结果等价.

三. 计算题

1. 作身高 (x) 与臂展 (y) 的一元线性回归: 总计有 $n = 1024$ 个样本, 回归结果如下表

Coefficient	Estimate	Std. Error	t-stat	Pr(> t)
(Intercept)	0.23835	1.91840	0.124	0.901
X	0.99882	0.01096	91.142	0.000

(1) 写出参数估计表达式, 根据分析结果写出经验回归方程.

(2) 写出误差方差估计的表达式.

(3) 说明最后一列 $\text{Pr}(>|t|)$ 的含义, 分别写出对应 H_0, H_1 , 并给出假设检验结果.

Solution: (1) 线性回归 $y = a + bx$ 的参数估计表达式是

$$\hat{b} = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

在回归表中, 结果是

$$y = 0.23835 + 0.99882x.$$

(2) 误差方差的估计是 $\hat{\sigma}^2 = \frac{S_e}{n-2}$, 其中 S_e 是残差平方和, 即 $S_e = \sum_{i=1}^n (y_i - \hat{y}_i)^2$.

(3) $\text{Pr}(>|t|)$ 是指系数是否为 0 的显著性检验的 p 值, 即假设检验问题

$$H_0: a = 0 \quad H_1: a \neq 0$$

和

$$H_0: b = 0 \quad H_1: b \neq 0$$

对应的 p 值. 这里 a 对应的 p 值为 0.901, 不能拒绝原假设, a 不显著. 这里 b 对应的 p 值为 0.000, 拒绝原假设, b 显著, 身高显著影响臂展.

2. 一个不透明的箱子里有 a 个白球和 b 个红球, k 个人不放回地抽球, 且 $k < a + b$, 求第 i 个人抽到红球的概率.

【提示】: 类似茆书原题 1.5.26, 1.5.27, 用数学归纳法. 这里我们用另外一种条件期望法做.

Solution: 设 X_i 表示第 i 个人抽球时盒中红球数量, 很显然

$$X_1 = b, \quad P(\text{第 } i \text{ 个人抽到红球}) = E\left(\frac{X_i}{a+b-(i-1)}\right) = \frac{1}{a+b-(i-1)} \cdot E(X_i),$$

如果 $X_{i-1} = x$ 已知, 则有

$$P(X_i = X_{i-1} - 1 | X_{i-1}) = \frac{X_{i-1}}{a+b-(i-2)}, \quad P(X_i = X_{i-1} | X_{i-1}) = 1 - \frac{X_{i-1}}{a+b-(i-2)},$$

求得条件期望为

$$E(X_i | X_{i-1}) = X_{i-1} \left(1 - \frac{1}{a+b-(i-2)}\right),$$

用重期望公式得

$$E(X_i) = E(X_{i-1}) \left(\frac{a+b-(i-1)}{a+b-(i-2)} \right),$$

用递推式得到

$$E(X_i) = E(X_1) \cdot \frac{a+b-1}{a+b} \cdot \frac{a+b-2}{a+b-1} \cdots \frac{a+b-(i-1)}{a+b-(i-2)} = \frac{a+b-(i-1)}{a+b} b,$$

代入得

$$P(\text{第}i\text{个人抽到红球}) = E\left(\frac{X_i}{a+b-(i-1)}\right) = \frac{1}{a+b-(i-1)} \cdot E(X_i) = \frac{b}{a+b}.$$

四. 证明题

1. 证明:

$$(1) \mathbb{P}(X+Y \geq x) \leq \mathbb{P}\left(X \geq \frac{x}{2}\right) + \mathbb{P}\left(Y \geq \frac{x}{2}\right);$$

$$(2) \mathbb{P}(|X+Y| \geq x) \leq \mathbb{P}\left(|X| \geq \frac{x}{2}\right) + \mathbb{P}\left(|Y| \geq \frac{x}{2}\right).$$

Solution:

(1) 记事件 $A = \{X+Y \geq x\}$, $B_1 = \{X \geq \frac{x}{2}\}$, $B_2 = \{Y \geq \frac{x}{2}\}$. 则

$$\bar{B}_1 \cap \bar{B}_2 = \left\{X < \frac{x}{2}, Y < \frac{x}{2}\right\} \subseteq \{X+Y < x\} = \bar{A},$$

因此根据概率的单调性有 $P(\bar{B}_1 \cap \bar{B}_2) \leq P(\bar{A})$, 再利用德摩根公式, 有

$$P(A) \leq P(\overline{\bar{B}_1 \cap \bar{B}_2}) = P(B_1 \cup B_2) \leq P(B_1) + P(B_2).$$

(2) 根据绝对值不等式, 有 $|X+Y| \leq |X| + |Y|$, 因此 $\{|X+Y| \geq x\} \subseteq \{|X| + |Y| \geq x\}$, 则

$$P(|X+Y| \geq x) \leq P(|X| + |Y| \geq x) \leq P\left(|X| \geq \frac{x}{2}\right) + P\left(|Y| \geq \frac{x}{2}\right).$$

其中后面一个不等式用到了 (1) 的结论.

上海交通大学-432 统计学-2018 年

一. 选择题 (10 小题, 每小题 6 分, 共 60 分)

1. 某医生为写论文收集数据, 使用了他自己过往的病情经历, 这种抽样方式称为 ().

- A. 整群抽样
- B. 非随机的方便抽样
- C. 系统抽样
- D. 简单随机抽样

Solution: B.

2. 设 X 和 Y 均服从标准正态分布, 则 ()

- (A) $X - Y$ 服从正态分布
- (B) $X^2 + Y^2$ 服从卡方分布
- (C) $Y | X$ 服从正态分布
- (D) X^2 服从卡方分布

Solution: D

当 $X = Y$ 时, 易知 ABC 都不正确, 由卡方分布的定义可知, $X^2 \sim \chi^2(1)$, D 正确.

3. 某个班男生的平均身高标准差为 6 cm, 为估计全校男生的平均身高, 置信水平 95%, 允许误差为 1, 请问所需要的样本个数至少为 ().

- A. 138
- B. 139
- C. 140
- D. 141

Solution: B.

考虑样本均值 $\bar{x}$ 是近似正态分布, 则置信区间为 $\mu \in [\bar{x} - z_{0.025} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{0.025} \frac{\sigma}{\sqrt{n}}]$, 令误差 $z_{0.025} \frac{\sigma}{\sqrt{n}} \leq 1$, 代入 $\sigma = 6$, $z_{0.025} = 1.96$, 解得 $n \geq 138.3$.

4. 在线性回归模型 $y_i = a + bx_i + \varepsilon_i, i = 1, \dots, n$ 中, 正确的是 ().

- A. (a, b) 的最小二乘估计与最大似然估计等价
- B. 最小二乘法中的残差和为 0
- C. 参数显著性 t 检验不需要假设正态分布
- D. 以上均错误

Solution: D.

如果不给定分布, 无法求得最大似然估计, A 错, 且只有在 ε 是正态分布时两者等价 (高斯-马尔可夫定理). 最小二乘法需求残差平方和最小, 与残差和无关, B 错. 如果没有正态假设, 无法导出检验统计量服从 t 分布, C 错.

5. 设 $X \sim B(100, 0.2)$, 设 $\Phi(x)$ 为标准正态分布的累积分布函数, 则 $X > 28$ 的概率大约是 ()

- (A) $1 - \Phi(2)$
- (B) $1 - \Phi(1)$
- (C) $\Phi(2)$
- (D) $2\Phi(2) - 1$

Solution: A

根据中心极限定理

$$P(X > 28) = P\left(\frac{X - 20}{4} > \frac{28 - 20}{4}\right) = P\left(\frac{X - 20}{4} > 2\right) \approx 1 - \Phi(2)$$

6. 已知总体 X 服从 $N(\mu_1, \sigma^2)$, 总体 Y 服从 $N(\mu_2, \sigma^2)$ 。现从总体 X 中抽取 n_1 个观测值, 其样本方差记为 S_1^2 ; 从总体 Y 中抽取 n_2 个观测值, 其样本方差记为 S_2^2 。已知两组样本相互独立, σ^2 未知, 那么 $\mu_1 - 2\mu_2$ 的置信度为 $1 - \alpha$ 的区间估计的长度应为: ()。

- A. $2t_{1-\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{1/n_1 + 4/n_2}$, 其中 $S_w = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$
 B. $2t_{1-\alpha/1}(n_1 + n_2 - 2) S_w \sqrt{1/n_1 + 1/n_2}$, 其中 $S_w = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$
 C. $2t_{1-\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{1/n_1 + 1/n_2}$, 其中 $S_w = \frac{(n_1-1)S_1^2 + 4(n_2-1)S_2^2}{n_1+n_2-2}$
 D. $2t_{1-\alpha/2}(n_1 + n_2 - 1) S_w \sqrt{1/n_1 + 1/n_2}$, 其中 $S_w = \frac{(n_1-1)S_1^2 + 4(n_2-1)S_2^2}{n_1+n_2-2}$

Solution: A

枢轴量是

$$\frac{[(\bar{x} - 2\bar{y}) - (\mu_1 - 2\mu_2)] / (\sqrt{1/n_1 + 4/n_2} * \sigma)}{\sqrt{((n_1 - 1) S_1^2 + (n_2 - 1) S_2^2) / (\sigma^2 * (n_1 + n_2 - 2))}} \sim t(n_1 + n_2 - 2)$$

所以区间长度为: $2t_{1-\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{1/n_1 + 4/n_2}$, 其中 $S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$

7. 交警部门发布报告称: 在被怀疑酒驾司机中, 72% 的司机被要求采用呼吸仪测量, 36% 的司机被要求采用血液仪测量, 18% 的司机被要求既采用呼吸仪测量又采用血液仪测量, 那么一个被怀疑酒驾的司机, 不用这两种仪器测量的比例是 ()

- A. 0.5
 B. 0.25
 C. 0.2
 D. 0.1

Solution: D

记事件 A “被怀疑酒驾司机中, 被要求采用呼吸仪测量”, 事件 B “被怀疑酒驾司机中, 被要求采用血液仪测量”, 则 $P(A) = 0.72, P(B) = 0.36, P(AB) = 0.18$. 则 $P(\bar{A}\bar{B}) = 1 - P(A \cup B) = 1 - (0.72 + 0.36 - 0.18) = 0.1$

8. 以下哪项不是 (强) 大数定律的应用? ()

- (A) 观测值的算术平均值估计期望值
 (B) 事件发生的频率估计概率
 (C) 期望值的置信区间估计
 (D) 用蒙特卡洛法计算定积分

Solution: C

大数定律是指样本数量越多, 它的算术平均值就越接近于其期望值, 选项 ABD 均为其运用. 选项 C 的期望值的置信区间是通过构造适当的区间来估计对应参数的真值所在范围, 属于中心极限定理的应用, 故选项 C 错误

9. 设 $X_1, \dots, X_n$ 为来自均匀分布 $U(\theta - 1, \theta + 1)$ 的简单随机样本, 其顺序统计量记为 $X_{(1)}, \dots, X_{(n)}$, 则 θ 的充分统计量为 ()

- (A) $X_{(1)}$
 (B) $X_{(n)}$
 (C) $\{X_{(1)}, X_{(n)}\}$
 (D) $X_{(n)} - X_{(1)}$

Solution: C

密度函数为 $f(x) = \frac{1}{2}I_{(\theta-1 \leq x \leq \theta+1)}$, 其联合分布函数为

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n \frac{1}{2} I_{(\theta-1 \leq x_i \leq \theta+1)} = \frac{1}{2^n} I_{(\theta \geq X_{(n)} - 1)} I_{(\theta \leq X_{(1)} + 1)}$$

故由因子分解定理知, 充分统计量为 $(X_{(1)}, X_{(n)})$, 选项 C 正确.

10. 某领导有 3 个顾问, 假定每个顾问贡献正确意见的概率是 0.5. 现为某事可行与否而个别征求各顾问意见, 并按多数人的意见做出决策, 则做出正确决策的概率是 ()

- (A) 0.5
- (B) 0.6
- (C) 2/3
- (D) 0.7

Solution: A

当有两个以上的顾问做出正确决策的时候, 最终做出正确决策 $P = 0.5^3 + C_3^2 \times 0.5^2 \times (1 - 0.5) = 0.5$ 选项 A 正确

二、简答题

1. 有来自 $U(0, \theta)$ 的简单随机样本, 试求样本极差 $R_n = x_{(n)} - x_{(1)}$ 的分布.

Solution: 总体的密度函数是 $f(x) = \frac{1}{\theta} I_{(0, \theta)}$, 分布函数是 $F(x) = \begin{cases} 0, & x < 0; \\ \frac{x}{\theta}, & 0 \leq x < \theta \\ 1, & x \geq \theta. \end{cases}$ 则 $(x_{(1)}, x_{(n)})$ 有联合密

度函数

$$f_{1,n}(x_1, x_n) = n(n-1) \frac{1}{\theta} \left(\frac{x_n - x_1}{\theta} \right)^{n-2} \frac{1}{\theta}, 0 < x_1 < x_n < \theta$$

作变换 $\begin{cases} U = x_{(n)} \\ V = x_{(n)} - x_{(1)} \end{cases}$, 则反解有 $\begin{cases} x_{(1)} = U - V \\ x_{(n)} = U \end{cases}$, 雅各比行列式 $J = \begin{vmatrix} 1 & -1 \\ 1 & 0 \end{vmatrix} = 1$, 因此 (U, V) 有联合密度函数

$$f_{U,V}(u, v) = f_{1,n}(u, u-v) |J| = n(n-1) \frac{1}{\theta^n} v^{n-2}, 0 < v < u < \theta,$$

对 u 积分, 得 V 的边缘密度函数

$$f_V(v) = \int_v^\theta n(n-1) \frac{1}{\theta^n} v^{n-2} du = n(n-1) \frac{1}{\theta^n} v^{n-2} (\theta - v), 0 < v < \theta$$

特别地, 当 $\theta = 1$ 时, $R_n \sim Be(n-1, 2)$, 这与 $x_{(n-1)}$ 是同分布的.

2. 从 $N(\mu, 1)$ 总体抽取 100 个随机样本 $x_1, \dots, x_{100}$, 为讨论假设检验问题

$$H_0: \mu = 0 \quad \text{vs} \quad H_1: \mu \neq 0$$

构造拒绝域 $W = \{|\bar{x}| < 0.001\}$.

(1)(8 分) 已知 $\Phi(0.01) < 0.505$, 证明犯第一类错误概率 $\alpha < 0.01$;

(2)(8 分) W 是一个合适的拒绝域吗? 为什么?

Solution: (1) 样本均值 $\bar{x} \sim N(\mu, \frac{1}{100})$, 故有

$$\alpha = P_{\mu=0}(|\bar{X}| < 0.001) = P_{\mu=0}(|10\bar{X}| < 0.01) = 2\Phi(0.01) - 1 < 0.01.$$

(2) 不是, $|\bar{x}| < 0.001$ 实际正反应了 $|\mu|$ 比较小, 接近于 0, 正确的拒绝域形式应是形如 $\{|\bar{x}| > c\}$, 其中 c 可由显著性水平确定.

3. 什么叫指标体系? 设计指标体系时应注意哪些问题?

Solution:

指标体系是指由若干个反映社会经济现象总体数量特征的相对独立又相互联系的统计指标所组成的有机整体. 在统计研究中, 如果要说明总体全貌, 那么只使用一个指标往往是不够的, 因为它只能反映总体某一方面的

数量特征。这个时候就需要同时使用多个相关指标了,而这多个相关的又相互独立的指标所构成的统一整体,即为指标体系。为了使指标体系科学化、规范化,在构建指标体系时,应遵循以下原则:

(1) 系统性原则。各指标之间要有一定的逻辑关系,它们不但要从不同的侧面反映出生态、经济、社会子系统的主要特征和状态,而且还要反映生态—经济—社会系统之间的内在联系。每一个子系统由一组指标构成,各指标之间相互独立,又彼此联系,共同构成一个有机统一体。指标体系的构建具有层次性,自上而下,从宏观到微观层层深入,形成一个不可分割的评价体系。

(2) 典型性原则。务必确保评价指标具有一定的典型代表性,尽可能准确反映出特定区域——高西沟的环境、经济、社会变化的综合特征,即使在减少指标数量的情况下,也要便于数据计算和提高结果的可靠性。另外,评价指标体系的设置、权重在各指标间的分配及评价标准的划分都应该与高西沟的自然和社会经济条件相适应。

(3) 动态性原则。生态—经济—社会效益的互动发展需要通过一定时间尺度的指标才能反映出来。因此,指标的选择要充分考虑到动态的变西北典型区生态脱贫途径研究化特点,应该收集若干年度的变化数值。

(4) 简明科学性原则。各指标体系的设计及评价指标的选择必须以科学性为原则,能客观真实地反映高西沟环境、经济、社会发展的特点和状况,能客观全面反映出各指标之间的真实关系。各评价指标应该具有典型代表性,不能过多过细,使指标过于繁琐,相互重叠,指标又不能过少过简,避免指标信息遗漏,出现错误、不真实现象,并且数据易获且计算方法简明易懂。

(5) 可比、可操作、可量化原则。指标选择上,特别注意在总体范围内的一致性,指标体系的构建是为区域政策制定和科学管理服务的,指标选取的计算量度和计算方法必须一致统一,各指标尽量简单明了、微观性强、便于收集,各指标应该要具有很强的现实可操作性和可比性。而且,选择指标时也要考虑能否进行定量处理,以便于进行数学计算和分析。

(6) 综合性原则。生态—经济—社会的互动“双赢”是生态经济建设的最终目标,也是综合评价的重点。在相应的评价层次上,全面考虑影响环境、经济、社会系统的诸多因素,并进行综合分析和评价。

4. 简述逐步回归的作用,向前选择与向后选择的差别。

Solution: 逐步回归分析方法的基本思路是自动从大量可供选择的变量中选取最重要的变量,建立回归分析的预测或者解释模型。其基本思想是:将自变量逐个引入,引入的条件是其偏回归平方和经检验后是显著的。同时,每引入一个新的自变量后,要对旧的自变量逐个检验,剔除偏回归平方和不显著的自变量。这样一直边引入边剔除,直到既无新变量引入也无旧变量删除为止。它的实质是建立“最优”的多元线性回归方程。

依据上述思想,可利用逐步回归筛选并剔除引起多重共线性的变量,其具体步骤如下:先用被解释变量对每一个所考虑的解釋变量做简单回归,然后以对被解释变量贡献最大的解释变量所对应的回归方程为基础,再逐步引入其余解释变量。经过逐步回归,使得最后保留在模型中的解释变量既是重要的,又没有严重多重共线性。

向前法:向前法的思想是变量由少到多,每次增加一个,直至没有可引入的变量为止。具体步骤如下。步 1:对 p 个回归自变量 $X_1, X_2, \dots, X_p$, 分别同因变量 Y 建立一元回归模型

$$Y = \beta_0 + \beta_i X_i + \epsilon, i = 1, \dots, p$$

计算变量 X_i , 相应的回归系数的 F 检验统计量的值,记为 $F_1^{(1)}, \dots, F_p^{(1)}$, 取其中的最大值 $F_{i_1}^{(1)}$, 即

$$F_{i_1}^{(1)} = \max \{F_1^{(1)}, \dots, F_p^{(1)}\}$$

对给定的显著性水平 α , 记相应的临界值为 $F_{i_1}^{(1)} \geq F^{(1)}$, 则将 X_{i_1} 引入回归模型,记 I_1 为选入变量指标集合。

步 2: 建立因变量 Y 与自变量子集 $\{X_{i_1}, X_1\}, \dots, \{X_{i_1}, X_{i_1-1}\}, \{X_{i_1}, X_{i_1+1}\}, \dots, \{X_{i_1}, X_p\}$ 的二元回归模型(即此回归模型的回归元为二元的),共有 $p-1$ 个。计算变量的回归系数 F 检验的统计量值,记为 $F_k^{(2)} (k \notin I_1)$, 选其中最大者,记为 $F_{i_2}^{(2)}$, 对应自变量脚标记为 i_2 , 即

$$F_{i_2}^{(2)} = \max \{F_1^{(2)}, \dots, F_{i_1-1}^{(2)}, F_{i_1+1}^{(2)}, \dots, F_p^{(2)}\}$$

对给定的显著性水平 α ，记相应的临界值为 $F_{i_2}^{(2)} \geq F^{(2)}$ 则变量 X_{i_2} 引入回归模型。否则，终止变量引入过程。依此方法重复进行，每次从未引入回归模型的自变量中选取一个，直到经检验没有变量引入为止。

向后法与向前法正好相反，它事先将全部自变量选入回归模型，然后逐个剔除对残差平方和贡献较小的自变量。后退法：与前进法相反，开始时先拟合包含所有自变量的回归方程，并预先指定留在回归方程中而不被剔除的自变量的假设检验标准。然后按自变量对应变量 Y 的贡献大小从小到大进行检验，对无统计学意义的自变量依次剔除。每剔除一个自变量都要重新计算并检验尚未被剔除自变量对应变量 Y 的贡献并决定是否剔除对模型贡献最小的自变量。重复上述过程，直到回归方程中的自变量均符合留在方程中的给定标准，没有自变量可被剔除为止。在整个过程中只考虑剔除自变量，自变量一旦被剔除，则不再考虑引入回归方程。

三. 计算题

1. 为发展我国机械化养鸡, 某研究所根据我国的资源情况, 研究用槐树粉、苜蓿粉等原料代替国外用鱼粉做鸡饲料的办法. 他们研究了三种饲料配方: 第一种, 以鱼粉为主的鸡饲料 第二种以槐树粉、苜蓿粉为主加少量鱼粉 第三种, 以槐树粉、苜蓿粉为主加少量化学药品. 后两种是他们研制的新配方. 为比较三种饲料在养鸡增肥上的效果, 各喂养 10 只母鸡, 于 60 天后观测它们的重量. 如下表所示:

第一种	1073	1058	1071	1037	1066	1026	1053	1049	1065	1051
第二种	1016	1058	1038	1042	1020	1045	1044	1061	1034	1049
第三种	1084	1069	1106	1078	1075	1090	1079	1094	1111	1092

请对本例进行方差分析, 在 $\alpha = 0.05$ 的前提下给出你的结论. 注: $F_{0.95}(2, 27) = 3.35$.

Solution:

列出计算过程表,

来源	数据量	$\sum_{j=1}^{r_i} y_{ij}$	$\sum_{j=1}^{r_i} y_{ij}^2$	$\frac{T_i^2}{r_i}$
水平1	10	549	32171	30140.1
水平2	10	407	18467	16564.9
水平3	10	878	78724	77088.4
总和	30	31841	129362	123793.4

于是,

$$SS_T = 33797362 - \frac{31841^2}{30} = 17243$$

$$SS_A = 33791793.4 - \frac{31841^2}{30} = 11675$$

$$SS_e = 17243 - 11675 = 5568$$

据此给出方差分析表,

来源	平方和	自由度	均方	F 统计量	p 值
因子	11675	2	5837.5	28.3	$< 10^{-6}$
误差	5568	27	206.2		
总和	17243	29			

p 值极小, 说明当原假设成立时, 发生比当前情况还要极端的事件的可能性非常小, 因此我们应该拒绝原假设. 或通过查表的方式, 给定显著性水平 0.05, 而 $F_{0.95}(2, 27) = 3.35$, 由于 $28.3 > 3.35$, 所以我们拒绝原假设, 也就是说三种不同饲料是会对鸡的体重产生显著影响的.

2. r 个人相互传球, 每传一次时, 传球者等可能地传给其余 $r - 1$ 人中之. 试求第 n 次传球时, 此球由最初发球者传出的概率 p_n (发球那一次算作第 0 次).

Solution:

由全概率公式得

$$p_n = p_{n-1} \cdot 0 + (1 - p_{n-1}) \frac{1}{r-1}$$

$$p_n = -\frac{1}{r-1} p_{n-1} + \frac{1}{r-1}, \quad n \geq 1, \quad p_0 = 1$$

代入差分方程的递推公式得

$$p_n = \left(\frac{-1}{r-1} \right)^n \left(1 - \frac{1}{r} \right) + \frac{1}{r} = \frac{1}{r} \left[1 - \left(\frac{-1}{r-1} \right)^{n-1} \right], \quad n \geq 1$$

四. 证明题

1. 设 $X_1, X_2, \dots, X_n$ 是来自密度为

$$f(x; \theta) = \frac{1}{2} e^{-|x-\theta|}$$

的总体的样本, $-\infty < \theta < +\infty$, 试求出 θ 的最大似然估计 $\hat{\theta}_n$.

Solution:

似然函数是 $L(\theta) = \frac{1}{2^n} e^{-\sum_{i=1}^n |x_i - \theta|}$, 为使似然函数最大, 考虑使 $h(\theta) = \sum_{i=1}^n |x_i - \theta|$ 最小.

$$h(\theta) = \sum_{i=1}^n |x_{(i)} - \theta| = \begin{cases} \sum_{j=1}^{n/2} (|x_{(j)} - \theta| + |x_{(n+1-j)} - \theta|), & n \text{ 是偶数} \\ \sum_{j=1}^{(n-1)/2} (|x_{(j)} - \theta| + |x_{(n+1-j)} - \theta|) + |x_{(\frac{n+1}{2})} - \theta|, & n \text{ 是奇数} \end{cases}$$

对 $\forall j$, 当 $\theta \in [x_{(j)}, x_{(n-j+1)}]$ 时, $(|x_{(j)} - \theta| + |x_{(n+1-j)} - \theta|)$ 取到最小值; 而当 n 是奇数时, 当 $\theta = x_{(\frac{n+1}{2})}$ 时, $|x_{(\frac{n+1}{2})} - \theta|$ 达到最小. 若 n 为偶数, 则当 $\theta \in \bigcap_{j=1}^{n/2} [x_{(j)}, x_{(n-j+1)}] = [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}]$ 时, 所有的 $(|x_{(j)} - \theta| + |x_{(n+1-j)} - \theta|)$ 均取最小值, 则此时 $h(\theta)$ 取最小值. 若 n 为奇数, 则当 $\theta \in \left\{ x_{(\frac{n+1}{2})} \right\} \cap \bigcap_{j=1}^{\frac{n-1}{2}} [x_{(j)}, x_{(n-j+1)}] = \left\{ x_{(\frac{n+1}{2})} \right\}$ 时, 所有的 $(|x_{(j)} - \theta| + |x_{(n+1-j)} - \theta|)$ 以及 $|x_{(\frac{n+1}{2})} - \theta|$ 均取最小值, 则此时 $h(\theta)$ 取最小值. 所以当 n 是奇数时, 样本中位数 $\hat{\theta}_n = x_{(\frac{n+1}{2})}$ 是 θ 的 MLE; 当 n 是偶数时, $\forall \hat{\theta}_n \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}]$ 都是 θ 的 MLE.

上海交通大学-432 统计学-2019 年

一. 选择题 (10 小题, 每小题 6 分, 共 60 分)

1. 如果数据没有离群值, 箱线图显示的信息不包括 ().

- A. 平均数
- B. 四分位数
- C. 极差
- D. 中位数

Solution: A.

2. 已知 A, B 两个随机事件满足 $P(A \cap B) = P(\bar{A} \cap \bar{B})$, 且 $P(A) = p$, 则 $P(B)$ 等于 ()

- (A) p
- (B) $1 - p$
- (C) $(1 - p)p$
- (D) p^2

Solution: B

由 $P(\bar{A} \cap \bar{B}) = P(\overline{A \cup B})$ 推出:

$$\begin{aligned} P(\bar{A} \cap \bar{B}) &= P(\overline{A \cup B}) = 1 - P(A \cup B) \\ &= 1 - [P(A) + P(B) - P(A \cap B)] \\ &= 1 - P(A) - P(B) + P(A \cap B) \end{aligned}$$

所以: $P(B) = 1 - P(A) = 1 - p$. 选项 B 正确

3. 下列关于直方图和箱线图不正确的是 ()

- A. 直方图柱形面积之和可以大于 1
- B. 箱线图可以展示更多数据
- C. 直方图分组时需要依据总体数量来分组
- D. 在绘制箱线图时, 需要的统计量有最小值、最大值、平均数、 $x_{0.25}$ 分位数和 $x_{0.75}$ 分位数

Solution: D.

还应该有中位数.

4. 抽样推断的精确度与抽样误差的关系是 () .

- A. 前者提高说明后者变小
- B. 前者提高说明后者变大
- C. 前者提高说明后者不变
- D. 没有关系

Solution: A.

要求的精确度越高, 说明置信区间越短, 抽样误差越小.

5. 如果你的水平略高于对手, 为保证比赛的胜利, 你最期望以下哪种比赛规则 ()

- (A) 一局定输赢
- (B) 三局两胜
- (C) 五局三胜
- (D) 不能确定

Solution: C

设 p 表示某一局赢的概率 $p + q = 1, p > q$;

$$P(B) = C_3^2 p^2 q + p^3 > p = P(A)$$

$$P(C) = C_5^3 p^3 q^2 + C_5^4 p^4 q + p^5 > P(B)$$

故选 C.

6. 选择题有四个答案, 只有一个是正确的. 懂的学生能够准确回答, 不懂的学生从中四个答案中随机选择. 假定一个学生懂与不懂的概率都是 0.5, 则答对的学生对该题不懂的概率为 ()

- (A) 0.1
- (B) 0.2
- (C) 0.4
- (D) 0.5

Solution: B

$$P(\text{答对}) = P(\text{懂}) + P(\text{答对且不懂}) = 0.5 + 0.5 \cdot 0.25 = 0.625$$

所以 $P(\text{不懂} | \text{答对}) = \frac{P(\text{答对且不懂})}{P(\text{答对})} = \frac{0.125}{0.625} = 0.2$, 选项 B 正确

7. $X_1, \dots, X_n$ 为来自正态分布 $N(\mu, 1)$ 的简单随机样本. 记 Z_α 为标准正态分布的 $100\alpha\%$ 分位数, 则由此样本所构造的置信水平分别为 95% 与 90% 的双侧置信区间长度之比为 ()

- (A) $2 \times \frac{z_{0.975}}{z_{0.95}}$
- (B) $\frac{z_{0.975}}{z_{0.95}}$
- (C) $2 \times \frac{z_{0.95}}{z_{0.90}}$
- (D) $\frac{z_{0.95}}{z_{0.90}}$

Solution: B

依题意得 $\sqrt{n}(\bar{x} - \mu) \sim N(0, 1)$, 所以令 $P(|\sqrt{n}(\bar{x} - \mu)| \leq d) = 1 - \alpha$ 可得置信区间的长度为: $2d = \frac{2z_{1-\frac{\alpha}{2}}}{\sqrt{n}}$. 因此 95% 与 90% 双侧置信区间长度之比为 $\frac{z_{0.975}}{z_{0.95}}$. 选项 B 正确

8. X, Y 各自服从: $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, 当 $P(|X - \mu_1| < 1) > P(|Y - \mu_2| < 1)$ 时, 比较 ().

- A. $\mu_1 > \mu_2$
- B. $\mu_1 < \mu_2$
- C. $\sigma_1 > \sigma_2$
- D. $\sigma_1 < \sigma_2$

Solution: D.

显然不等式条件无法分辨 μ_1 与 μ_2 . 而我们知道

$$2\Phi\left(\frac{1}{\sigma_1}\right) - 1 = P(|X - \mu_1| < 1) > P(|Y - \mu_2| < 1) = 2\left(\frac{1}{\sigma_2}\right) - 1,$$

这说明 $\sigma_1 < \sigma_2$.

9. 英国《观察家报》和 Opinium 公司 2016 年 6 月初进行的联合民意调查显示, 40% 英国民众支持留在欧盟. 考虑一个由 600 名英国民众组成的随机样本, 以 X 表示这 600 人中支持留在欧盟的人数. 记 $\Phi(x)$ 是标准正态分布的分布函数, 则 $222 < X < 258$ 的概率大约是 ()

- (A) $2\Phi(1.5) - 1$
- (B) $2\Phi(1.5)$
- (C) $2\Phi(2)$
- (D) $2\Phi(2) - 1$

Solution: A

$X \sim b(600, 0.4)$, 根据二项分布的正态近似可知 X 近似服从于 $N(240, 144)$, 则

$$\begin{aligned} P(222 < X < 258) &= P\left(\frac{222 - 240}{\sqrt{144}} < \frac{X - 240}{\sqrt{144}} < \frac{258 - 240}{\sqrt{144}}\right) \\ &= \Phi(1.5) - \Phi(-1.5) \\ &= 2\Phi(1.5) - 1 \end{aligned}$$

故选 A.

10. 设 $X_1, \dots, X_n$ 为正态分布 $N(\mu, \sigma^2)$ 的样本, μ 未知而 σ^2 已知. $\bar{X}$ 和 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本均值及样本方差. 记, $T_1 = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}}, T_2 = \frac{\bar{x} - \mu}{s/\sqrt{n}}, T_3 = \frac{(n-1)S^2}{\sigma^2}$, 则 T_1, T_2, T_3 中统计量的个数为 ()

- (A) 0
- (B) 1
- (C) 2
- (D) 3

Solution: B

统计量指样本的函数 $T(X_1, X_2, \dots, X_n)$; 统计量依赖且只依赖于样本, 它不含任何未知参数 (故一般其分布与未知参数有关). 由于 μ 未知, 故 T_1, T_2 不是统计量, T_3 是统计量.

二、简答题

1. $X_1, \dots, X_n$ 来自正态总体 $N(\mu, 1)$ 的简单随机样本, 对于简单假设检验问题 $H_0: \mu = \mu_0$ $H_1: \mu > \mu_0$, 设有拒绝域 $W = \{(x_1, \dots, x_n) \mid (\bar{x}) > c\}$.

- (1) 当 $c = \mu_0 + \frac{1.96}{\sqrt{n}}$, 求一类错误与二类错误概率 α 与 β , 是否有 $\alpha + \beta = 1$?
- (2) 若希望增加可靠性, 应该增大 c 还是减小 c ?

Solution:

$$\begin{aligned} (1) \alpha &= P_{H_0}(\bar{X} > \mu_0 + \frac{1.96}{\sqrt{n}}) = P_{H_0}(\sqrt{n}(\bar{X} - \mu_0) > 1.96) = 0.025, \beta(\mu) = 1 - P_{\mu}(\bar{X} > \mu_0 + \frac{1.96}{\sqrt{n}}) \\ &= P_{\mu}(\sqrt{n}(\bar{X} - \mu) \leq \sqrt{n}(\mu_0 - \mu) + 1.96) = \Phi(\sqrt{n}(\mu_0 - \mu) + 1.96). \end{aligned}$$

由于 β 不为常数, 因此等式不可能成立.

- (2) 增大 c 更不容易犯第一类错误, 减小 c 更不容易犯第二类错误.

2. 评价时间序列预测效果的方法有哪些? 请给出评价指标与计算表达式.

Solution:

残差平方和 SSE (the sum of squares due to error), 是观测值 (observed values) 与预测值 (predicted values) 的误差的平方和, 公式为:

$$SSE(y, \hat{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

均方误差 MSE (mean squared error), 是观测值 (observed values) 与预测值 (predicted values) 的误差的平方和的均值, 即 SSE/n . 它是误差的二阶矩, 包含估计量的方差 (variance) 及其偏差 (bias), 是衡量估计量质量的指标, 其公式为:

$$MSE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

均方根误差 RMSE (root mean squared error), 也称作 RMSD (root mean square deviation), 是 MSE 的算术平方根. 由于每个误差 (each error) 对 RMSD 的影响与误差的平方 (squared error) 成正比, 因此较大的误差会对 RMSE 影响过大, RMSE 对异常值很敏感. 其公式为:

$$RMSE(y, \hat{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

平均绝对值误差 MAE (mean absolute error), 是时间序列分析中预测误差常用的指标, 由于 MAE 使用的是与被测数据相同的尺度 (scale), 因此不能用于比较两个不同尺度的序列。MAE 又被称为 $L1$ 范数损失函数 (就是可以做为损失函数), 是真实数据与预测数据之差的绝对值的均值。公式为:

$$\text{MAE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

3. 简述年度折叠时间序列图与季节多元回归模型的作用。

Solution:

年度折叠时间序列图 (folded annual time series plot) 是一种特殊的时间序列图。绘制该图时, 需要将每年的数据分开画在图上, 也就是横轴只有一年的长度, 每年的数据分别对应纵轴。

如果时间序列只存在季节成分, 年度折叠时间序列图中的折线将会有交叉; 如果时间序列既含有季节成分又含有趋势, 那么年度折叠时间序列图中的折线将不会有交叉, 而且如果趋势是上升的, 后面年度的折线将会高于前面年度的折线, 如果趋势是下降的, 后面年度的折线将低于前面年度的折线。

季节多元回归模型为季节引入虚拟变量, 以消除季节趋势的影响, 一般来说可以考虑

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \alpha_1 D_{i1} + \alpha_2 D_{i2} + \alpha_3 D_{i3},$$

其中引入的虚拟变量 $D_{ik} = 1$ 说明第 i 个样本在第 k 个季度. 其中可以以第四个季度作为基准, 因此可以仅仅引入 3 个虚拟变量。

4. $X_1, \dots, X_n$ 独立同分布, 且 $\mathbb{E}(X^3) = 1, \mathbb{E}(X^6) = 4$, 求 n 趋于无穷的时候 $\frac{\sum_{i=1}^n X_i^3}{n}$ 的极限分布, 并解释其的密度函数的形状将如何变化。

Solution:

根据大数定律有 $T_n = \frac{\sum_{i=1}^n X_i^3}{n} \xrightarrow{p} EX^3 = 1$, 又 $\text{Var}(X^3) = EX^6 - (EX^3)^2 = 3$, 根据中心极限定理有 $\sqrt{n}(T_n - 1) \xrightarrow{d} N(0, 3)$.

极限分布正态, 故密度函数趋于对称, 方差收敛于 0, 说明慢慢趋于集中在一点。

三. 计算题

1. 某公司雇佣 3000 名推销员, 为了发放外出补贴, 需要估计推销员每年的平均乘车里程。从过去的经验可知, 通常每位推销员乘车里程的标准差为 4000 公里。随机选取 16 名推销员, 得到他们的年平均乘车里程是 12000 公里。

(1) 总体均值 μ 的估计量是多少?

(2) 确定总体均值 μ 的 95% 置信区间;

(3) 公司经理们认为均值应介于 11000 到 13000 公里之间, 那么该估计的置信度是多少?

(4) 如果在 (3) 的估计中希望有 95% 的置信水平, 这时所要求的样本容量是多少?

Solution:

(1) 用样本均值进行估计, $\bar{x} = 12000$.

(2) 总体标准差已知为 4000, 选取枢轴量: $(\bar{x} - \mu)\sqrt{n}/\sigma \sim N(0, 1)$, 解得 μ 的 95% 置信区间为: $\bar{x} \pm z_{0.025} \frac{\sigma}{\sqrt{n}} = [10040, 13960]$

(3) 根据 (2) 中的结论, 有 μ 的 $1 - \alpha$ 置信区间为: $\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}} = [11000, 13000]$ 有 $z_{\alpha/2} \frac{\sigma}{\sqrt{n}} = 1000 \rightarrow z_{\alpha/2} = 1, \alpha = 0.0794$, 故置信度是 92.07%

(4) $z_{0.025} \frac{\sigma}{\sqrt{n}} - 1.96 \times \frac{4000}{\sqrt{n}} = 1000, n = 61.17$, 所要求的样本容量是 62.

2. 作身高 (x) 与臂展 (y) 的一元线性回归: 总计有 $n = 1024$ 个样本, 回归结果如下表

Coefficient	Estimate	Std. Error	t-stat	Pr(> t)
(Intercept)	0.23835	1.91840	0.124	0.901
X	0.99882	0.01096	91.142	0.000

(1)(10 分) 写出参数估计表达式, 根据分析结果写出经验回归方程.

(2)(5 分) 写出误差方差估计的表达式.

(3)(5 分) 说明最后一列 $\Pr(>|t|)$ 的含义, 分别写出对应 H_0, H_1 , 并给出假设检验结果.

Solution: (1) 线性回归 $y = a + bx$ 的参数估计表达式是

$$\hat{b} = \frac{l_{xy}}{l_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

在回归表中, 结果是

$$y = 0.23835 + 0.99882x.$$

(2) 误差方差的估计是 $\hat{\sigma}^2 = \frac{S_e}{n-2}$, 其中 S_e 是残差平方和, 即 $S_e = \sum_{i=1}^n (y_i - \hat{y}_i)^2$.

(3) $\Pr(>|t|)$ 是指系数是否为 0 的显著性检验的 p 值, 即假设检验问题

$$H_0 : a = 0 \quad H_1 : a \neq 0$$

和

$$H_0 : b = 0 \quad H_1 : b \neq 0$$

对应的 p 值. 这里 a 对应的 p 值为 0.901, 不能拒绝原假设, a 不显著. 这里 b 对应的 p 值为 0.000, 拒绝原假设, b 显著, 身高显著影响臂展.

四. 证明题

(1) $g(x)$ 单调不减, 非负且连续, 证明对于任意的 $x > 0$, 不等式成立: $\mathbb{P}(X \geq x) \leq \frac{\mathbb{E}(g(X))}{g(x)}$

(2) $X \sim \text{Exp}(\lambda)$ X_i 独立同分布, 证: $\mathbb{P}(\sum_{i=1}^n X_i \geq nx) \leq 2^n e^{-\frac{(n\lambda x)}{2}}$

Solution:

(1) 利用示性函数 $I_{\{X \geq x\}}$, 有不等式 $g(x) I_{\{X \geq x\}} \leq g(X) I_{\{X \geq x\}} \leq g(X)$, 左右取数学期望, 有

$$\begin{aligned} g(x) \mathbb{P}(X \geq x) &\leq \mathbb{E}(g(X) I_{\{X \geq x\}}) \\ &\leq \mathbb{E}(g(X)) \end{aligned}$$

(2) 取函数 $g(x) = e^{\frac{\lambda}{2}x}$, 单调不减且非负, 则可利用上面的不等式. 另外, 考虑到指数分布与伽马分布的关系, 记 $T = \sum_{i=1}^n X_i \sim \text{Ga}(n, \lambda)$, 于是 $\mathbb{P}(T \geq nx) \leq \frac{\mathbb{E}(g(T))}{g(nx)}$, 其中 $g(nx) = e^{\frac{n\lambda x}{2}}$, 以及

$$\mathbb{E}(g(T)) = \int_0^\infty \frac{\lambda^n}{\Gamma(n)} t^{n-1} e^{-\lambda t} e^{\frac{\lambda}{2}t} dt = 2^n.$$

综上所述, 有

$$\mathbb{P}\left(\sum_{i=1}^n X_i \geq nx\right) \leq 2^n e^{-\frac{n\lambda x}{2}}.$$

上海交通大学-432 统计学-2020 年

一. 选择题 (30 小题, 每小题 2 分, 共 60 分)

1. 某学院共有 1000 名男生和 2000 名女生, 为调查学生的平均生活支出费用, 将全体男女学生以 1 比 2 抽样, 这种抽样方法是 ().

- A. 简单随机抽样
- B. 分层抽样
- C. 系统抽样
- D. 整体抽样

Solution: B

分层抽样法, 也叫类型抽样法。就是将总体单位按其属性特征分成若干类型或层, 然后在类型或层中随机抽取样本单位。分层抽样的特点是: 由于通过划类分层, 增大了各类型中单位间的共同性, 容易抽出具有代表性的调查样本。该方法适用于总体情况复杂, 各单位之间差异较大, 单位较多的情况。将男女分成两类, 属于分层抽样。

2. 有一批灯泡共 1000 箱, 每箱 200 个, 现随机抽取 20 箱并检查这些箱中全部灯泡, 此种检验属于 ()

- A. 纯随机抽样
- B. 类型抽样
- C. 整群抽样
- D. 等距抽样

Solution: C

整群抽样是指整群地抽取样本单位, 对被抽选的各群进行全面调查的一种抽样组织方式。例如, 检验某种零件的质量时, 不是逐个抽取零件, 而是随机抽若干盒 (每盒装有若干个零件), 对所抽各盒零件进行全面检验。

3. 为了解小区居民对物业服务的意见和看法, 管理人员随机抽取了 50 户居民, 上门通过问卷进行调查, 这种数据收集方法是 ()

- A. 面访式问卷调查
- B. 实验调查
- C. 观察式调查
- D. 自填式问卷调查

Solution: A

显然是面访式问卷调查。

4. 下面的哪一个图形适合于比较研究两个或多个样本或总体的结构性问题 ()

- A. 环形图
- B. 饼图
- C. 直方图
- D. 茎叶图

Solution: A

环形图与饼图类似, 环形图中间有一个“空洞”, 每个样本用一个环来表示, 样本中的每一部分数据用环中的一段表示, 因此环形图可显示多个样本各部分所占的相应比例, 有利于对构成做比较研究。故都适用多个总体比较。

5. 有四位同学的某一门课程成绩分别为 71, 82, 87, 90。则他们成绩的中位数是 ()

- A. 81
- B. 82.5
- C. 84.5

D. 87

Solution: C

容易计算 $= \frac{82+87}{2} = 84.5$

6. 下列描述分布离散程度的统计量中, 哪一个具有稳健性 ()

- A. 标准差
- B. 四分位差
- C. 极差
- D. 变异系数

Solution: B

四分位差受极端值影响最小, 类似于中位数.

7. 在某公司进行的英语水平测试中, 新员工的平均得分是 80 分, 标准差是 5 分, 中位数是 85 分, 则新员工得分的分布形状是 ()

- A. 对称的
- B. 左偏的
- C. 右偏的
- D. 无法确定

Solution: B

平均值小于中位数, 说明是左偏的.

8. $X_i \sim N(\mu, \sigma^2) i = 1, 2, 3, \dots, n$, 其中 μ 为已知常数, 则 σ^2 的充分无偏估计是 ().

- A. $\frac{1}{10} \sum_{i=1}^{10} (X_i - \bar{X})^2$
- B. $\frac{1}{10} \sum_{i=1}^{10} (X_i - \mu)^2$
- C. $\frac{1}{9} \sum_{i=1}^{10} (X_i - \mu)^2$
- D. $\frac{1}{9} \sum_{i=1}^9 (X_i - \mu)^2$

Solution: B

A, C 有偏, D 不充分.

9. 设 $X_1 X_2 X_3 X_4$ 是来自总体 X 的样本, $EX = \mu$ 则 () 是 μ 的最有效估计.

- A. $\hat{\mu}_1 = \frac{1}{5}x_1 + \frac{1}{5}x_2 + \frac{1}{5}x_3 + \frac{2}{5}x_4$
- B. $\hat{\mu}_2 = \frac{1}{3}x_1 + \frac{1}{3}x_2 + \frac{1}{6}x_3 + \frac{1}{6}x_4$
- C. $\hat{\mu}_3 = \frac{1}{4}x_1 + \frac{1}{4}x_2 + \frac{1}{4}x_3 + \frac{1}{4}x_4$
- D. $\hat{\mu}_4 = \frac{1}{9}x_1 + \frac{2}{9}x_2 + \frac{3}{9}x_3 + \frac{4}{9}x_4$

Solution: C

即找到方差最小的无偏估计, 这四个选项中 C 给出的估计量方差最小.

10. 设 $X_1, X_2, \dots, X_{n_1}$ 是来自正态总体 $N(\mu_1, \sigma_1^2)$ 的一个样本, 设 $Y_1, Y_2, \dots, Y_{n_2}$ 是来自正态总体 $N(\mu_2, \sigma_2^2)$ 的一个样本, 且 $X_i (i = 1, 2, 3, \dots, n_1)$ 与 $Y_i (i = 1, 2, 3, \dots, n_2)$ 相互独立, 已知 $n_1 n_2 S_1^2 S_2^2$, 通过查表可知 $F_{\alpha/2}(n_1, n_2)$, $F_{\alpha/2}(n_2, n_1)$, $F_{\alpha/2}(n_1 - 1, n_2 - 1)$, $F_{\alpha/2}(n_2 - 1, n_1 - 1)$. 则方差之比 σ_1^2 / σ_2^2 的置信区间为 ().

- A. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1, n_2)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2, n_1)$
- B. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1 - 1, n_2 - 1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2 - 1, n_1 - 1)$
- C. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1, n_2)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_2, n_1)}$
- D. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1 - 1, n_2 - 1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_2 - 1, n_1 - 1)}$

Solution: B

注意这里用的应是上分位数, 根据 F 分布的对称性, 置信区间应为

$$\left[\frac{s_1^2/s_2^2}{F_{\frac{\alpha}{2}}(n_1-1, n_2-1)}, \frac{s_1^2/s_2^2}{F_{1-\frac{\alpha}{2}}(n_1-1, n_2-1)} \right] = \left[\frac{s_1^2/s_2^2}{F_{\frac{\alpha}{2}}(n_1-1, n_2-1)}, \frac{s_1^2}{s_2^2} F_{\frac{\alpha}{2}}(n_2-1, n_1-1) \right]$$

11. 某公司宣称其产品质量大大高于标准, 为检验其说法是否真实, 应该建立原假设 ().

- A. 产品质量小于标准
- B. 产品质量等于标准
- C. 产品质量大于标准
- D. 产品质量不大于标准

Solution: D

应该建立单侧检验, 其次我们想要推翻该公司结论, 因此备择假设应该是 C 中的描述, 故原假设应该是 D.

选项 A 的问题是我们最好将等号放在原假设.

12. 方差分析的基本假设是 ().

- A. 多个总体具有相等方差
- B. 多个总体具有等方差的相同分布
- C. 多个总体具有等方差的正态分布
- D. 多个总体具有相同的正态分布

Solution: C

方差分析假设残差独立同分布, 服从正态分布, 而不同组的均值可以不同.

13. 根据以往的生产统计, 某种产品的合格率约为 90%, 现要求估计误差为 5%, 在 5% 的显著性水平下, 应抽取 () 个产品作为样本.

- A. 138
- B. 139
- C. 384
- D. 385

Solution: B

题目意为, 合格率为 π , 用抽样合格率 $\bar{X}$ 来估计 π , 试问需要多大的样本量, 才可以保证

$$P\left(\left|\bar{X} - \pi\right| \geq 0.05\right) \leq \alpha.$$

利用正态近似, $\sqrt{n}(\bar{X} - \pi) \sim N(0, \pi(1-\pi))$, 则

$$P\left(\left|\bar{X} - \pi\right| \geq 0.05\right) = P\left(\left|\frac{\sqrt{n}(\bar{X} - \pi)}{\sqrt{\pi(1-\pi)}}\right| \geq \frac{\sqrt{n}0.05}{\sqrt{\pi(1-\pi)}}\right) = \alpha$$

可近似解得 $\frac{\sqrt{n}0.05}{\sqrt{\pi(1-\pi)}} = z_{\frac{\alpha}{2}}$, 于是 $n = \frac{z_{\frac{\alpha}{2}}^2 \pi(1-\pi)}{0.05^2}$. 代入数据 π 约为 0.9, 有

$$n = \frac{z_{\frac{\alpha}{2}}^2 \pi(1-\pi)}{0.05^2} = \frac{1.96^2 \cdot 0.9 \cdot 0.1}{0.05^2} = 138.298$$

考虑到 n 是整数, 所以 n 至少为 139.

14. 以下关于 p 值的说法正确的是 ().

- A. 我们总是根据检验的 p 值来确定显著性水平;
- B. p 值是检验统计量大于统计量当前观测值的概率;

- C. p 值越小, 越倾向于拒绝原假设;
D. p 值是检验统计量出现比当前观测值更极端的概率.

Solution: D

A、C 项说反了, B 项不一定是大于, D 项说法正确.

15. 某一商场 30 分钟内到达的人数服从参数为 6 的泊松分布, 则 10 分钟内来商场的人数等于 3 的概率为 ().

- A. $\frac{4}{3}e^{-2}$
B. $\frac{6^9}{9!}e^{-6}$
C. $\frac{22}{3}e^{-2}$
D. $\frac{16}{3}e^{-2}$

Solution: A

10 分钟内来商场的人数 $X \sim \mathcal{P}(2)$, 则 $P(X=2) = \frac{2^2}{2!}e^{-2} = \frac{4}{3}e^{-2}$.

16. 假设 $X \sim N(\mu, \sigma^2)$, 则 $Y = e^X$ 的密度函数是 ().

- A. $\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(y-\mu)^2}{2\sigma^2}}$
B. $\frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}$
C. $\frac{1}{\sqrt{2\pi\sigma^2}y}e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}$
D. $\frac{1}{\sqrt{2\pi\sigma^2}y^2}e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}$

Solution: C

若记得对数正态分布的密度函数, 则直接选 C. 或者临场推导

$$\begin{aligned} P(Y=y) &= P(X=\ln y) = \frac{1}{\sqrt{2\pi\sigma^2}}e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}d\ln y, \ln y \in \mathbb{R} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \frac{1}{y} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}} dy, y > 0 \end{aligned}$$

17. 某科目学生的平均考分是 110 分, 标准差是 5 分. 若该科目学生的考分为近似正态的对称分布, 则可判断考分在 120 分以上的学生人数大约占 ()

- A. 95%
B. 48%
C. 5%
D. 2.5%

Solution: D

根据经验法则, 当一组数据近似服从正态分布时, 约有 68% 的数据在平均数 ± 1 个标准差的范围之内; 约有 95% 的数据在平均数 ± 2 个标准差的范围之内; 约有 99% 的数据在平均数 ± 3 个标准差的范围之内. 所以考分在 120 分以上的学生人数是两个标准差之外的一半 (另一半是 100 分以下), 大约占 2.5%。

18. 在单因素方差分析中, 已知 $SS_A = 156, SS_T = 240, df_A = 2, df_T = 15$, 则 F 统计量为 ()

- A. 0.08
B. 0.93
C. 1.86
D. 12.07

Solution: D

$$F = \frac{MS_A}{MS_e} = \frac{SS_A/df_A}{(SS_T - SS_A)/(df_T - df_A)} = \frac{156/2}{(240 - 156)/(15 - 2)} = 12.0714$$

19. 下列关于残差图的描述错误的是 ()

- A. 残差图的纵坐标只能是残差.
- B. 残差图的横坐标可以是编号、解释变量和预报变量.
- C. 残差点分布的带状区域的宽度越窄残差平方和越小.
- D. 残差点分布的带状区域的宽度越窄相关指数越小.

Solution: D

可用残差图判断模型的拟合效果, 残差点比较均匀地落在水平的带状区域中, 说明这样的模型比较合适. 带状区域的宽度越窄, 说明模型的拟合精度越高, 则对应相关指数越大, 故选项 D 错误. 故选 D.

20. 在多元线性回归模型中检验方程的显著性、回归系数的显著性, 下面正确的是 ()

- A. 用 t 分布检验方程显著性, 用 F 分布检验回归系数的显著性
- B. 用 F 分布检验方程显著性, 用 t 分布检验回归系数的显著性
- C. 用 F 分布检验方程显著性, 用 F 分布检验回归系数的显著性
- D. 用 t 分布检验方程显著性, 用 t 分布检验回归系数的显著性

Solution: B

在多元线性回归模型中, 用 F 分布检验方程显著性, 用 t 分布检验回归系数的显著性

21. 在多元线性回归分析中, 如果某个解释变量的回归系数不显著, 则意味着: 该解释变量与被解释变量之间 ()

- A. 不存在显著的线性关系
- B. 不存在显著的相关关系
- C. 不存在相关关系
- D. 可能存在显著的非线性关系

Solution: A

线性回归仅仅分析线性相关关系, 对于其他非线性关系我们无法下任何判断.

22. 当模型存在严重的多重共线性时, OLS 估计量将不具备 ()

- A. 线性
- B. 无偏性
- C. 有效性
- D. 一致性

Solution: C

严重多重共线性发生时, 设计矩阵接近奇异, 其逆矩阵特征值将非常大, 则估计量的方差会变大, 不再具有有效性.

23. 设随机变量 $X \sim N(0, 1)$, $Y \sim N(1, 4)$, 则 X, Y 的相关系数 $\rho_{XY} = 1$ 是 $Y = 2X + 1$ 的

- A. 充要条件;
- B. 充分不必要条件;
- C. 必要不充分条件;
- D. 不充分不必要条件.

Solution: C

$\rho_{XY} = 1$ 只能推出 $P(Y = 2X + 1) = 1$.

24. 利用估计的回归方程进行区间估计时, 关于平均值的置信区间和个别值预测区间, 下面说法正确的是 ().

- A. 置信区间比预测区间宽
- B. 预测区间比置信区间宽

C. 二者一样宽

D. 不一定

Solution: B

预测区间指的是

$$x_0 \hat{\beta} \pm \sqrt{1 + x_0^T (X^T X)^{-1} x_0} \hat{\sigma} \cdot t_{\frac{\alpha}{2}}(n - p - 1).$$

平均值的置信区间指的是

$$x_0 \hat{\beta} \pm \sqrt{x_0^T (X^T X)^{-1} x_0} \hat{\sigma} \cdot t_{\frac{\alpha}{2}}(n - p - 1).$$

相差的 1 实际来源于 y_0 本身的随机性 ($y_0 \sim N(x_0 \beta, \sigma^2)$), 而 $E y_0$ 不具有随机性. 那么显然预测区间的长度更长.

25. 设连续型随机变量 X 的密度函数为 $f(x) = \lambda^2 x \exp\{-\lambda x\}, x > 0, \lambda > 0$ | Y 服从 $U(0, X)$, 则 $E[X | Y = y] = ()$

A. $\lambda + y$

B. $\frac{1}{\lambda} + y$

C. λ

D. $y\lambda$

Solution: B

先求联合分布, 易得

$$f(x, y) = f_X f_{Y|X} = \lambda^2 e^{-\lambda x}, x > y > 0.$$

则 Y 的边缘分布是 $f_Y(y) = \int_y^{+\infty} \lambda^2 e^{-\lambda x} dx = \lambda e^{-\lambda y}, y > 0.$

因此 X 关于 Y 的条件分布是

$$f_{X|Y}(x) = \frac{\lambda^2 e^{-\lambda x}}{\lambda e^{-\lambda y}} = \lambda e^{-\lambda(x-y)}, x > y$$

它是双参数指数分布, 可以通过积分计算数学期望, 或直接利用双参数指数分布的数学期望公式 $E[X | Y = y] = \frac{1}{\lambda} + y.$

26. 将一个骰子独立地掷两次. 引进事件: $A_1 = \{ \text{掷第一次出现奇数点} \}, A_2 = \{ \text{掷第二次出现偶数点} \}, A_3 = \{ \text{奇数点、偶数点各出现一次} \}, A_4 = \{ \text{奇数点出现两次} \},$ 则 $()$

A. A_1, A_2, A_3 两两独立

B. A_1, A_2, A_3 相互独立

C. A_2, A_3, A_4 两两独立 D/ A_2, A_3, A_4 相互独立

Solution: A

$$P(A_1) = \frac{1}{2}, P(A_2) = \frac{1}{2}, P(A_3) = \frac{1}{2}, P(A_4) = \frac{1}{4}$$

$P(A_2 A_4) = \frac{1}{4} \neq P(A_2) P(A_4)$, 事件 A_2, A_4 不独立, 选项 C, D 错误对于事件 A_1, A_2, A_3 有:

$$P(A_1 A_2) = P(A_1) P(A_2) = \frac{1}{4}$$

$$P(A_1 A_3) = P(A_1) P(A_3) = \frac{1}{4}$$

$$P(A_2 A_3) = P(A_2) P(A_3) = \frac{1}{4}$$

$$P(A_1 A_2 A_3) = \frac{1}{4} \neq P(A_1) P(A_2) P(A_3)$$

所以事件 A_1, A_2, A_3 两两独立不相互独立. 选项 A 正确

27. 一本书在交付印刷前, 作家和出版社先后对其进行校正. 该书有 300 页, 每页的错误数相互独立且都服从参数为 6 的泊松分布. 在作家的校对过程中, 每个错误相互独立地以概率 0.8 被订正. 在出版社进行的第二次

校正中,前一稿的打印错误相互独立地以概率 0.9 被订正。出版后整本书的错误数大于等于 30 的概率 (用标准正态分布函数 $\Phi(x)$ 表示) 大约是 ()

- A. $\Phi(1)$
- B. $\Phi(1.5)$
- C. $\Phi(2)$
- D. $2 - \Phi(2)$

Solution: A

设这本书的错误数为 X , 经过两次校正后的错误数为 Y , 则 $X \sim \mathcal{P}(1800)$, 被修正后还剩下 0.2×0.1 , 故有 $Y \sim \mathcal{P}(36)$, $E(Y) = D(Y) = 36$, 根据中心极限定理有 Y 的近似分布为 $N(36, 36)$

$$P(Y \geq 30) = P\left(\frac{Y - 36}{6} \geq \frac{30 - 36}{6}\right) = 1 - \Phi(-1) = \Phi(1).$$

28. 设 $X_1, \dots, X_n$ 为正态分布 $N(\mu, \sigma^2)$ 的简单随机样本, 其中 μ 已知而 σ^2 未知, 则下列不是统计量的是 ()

- A. $\sum_{i=1}^n X_i / \sigma$
- B. X_1
- C. $\sum_{i=1}^n X_i^2 / n$
- D. $\sum_{i=1}^n X_i - n\mu$

Solution: A

统计量不包含未知参数, 故选择 A.

29. 从 5 双不同的鞋子中任取 4 只, 其中恰有一双配对的概率是 ()

- A. $2/3$
- B. $4/7$
- C. $2/7$
- D. $1/3$

Solution: B

总的取法为 C_{10}^4 , 要使恰有一双配对, 则可以先从 5 双鞋子中选取一双, 共 5 种取法; 然后从剩下的鞋子中任取两双, 共有 C_4^2 种取法; 最后从取出的两双鞋子中各取一只, 每一双鞋子有两种取法, 则总共有四种取法, 因此所求概率为

$$\frac{5 \times C_4^2 \times 4}{C_{10}^4} = \frac{4}{7}$$

B 正确.

30. 设 X 和 Y 均服从标准正态分布, 则 ()

- A. $X - Y$ 服从正态分布
- B. $X^2 + Y^2$ 服从卡方分布
- C. $Y | X$ 服从正态分布
- D. X^2 服从卡方分布

Solution: D

当 $X = Y$ 时, 易知 A, B, C 都不正确, 由卡方分布的定义可知, $X^2 \sim \chi^2(1)$, D 正确.

二、简答题

1. 为研究在旅游时候所花费在购物上的金额 Y (美元) 与性别 D 的关系, 我们建立一个回归模型, 同时我们将旅客月收入 X (美元) 也纳入考虑, 同时考虑 X 与 D 的交互, 回归结果见下表:

	coef.	std.error	tstat.	p.
(Intercept)	57.6113	3.5454	166.2494	0.0001
X	0.0118	0.0013	9.0281	0.0008
D	31.8731	3.831	8.3197	0.0011
X : D	-0.0088	0.0013	-6.693	0.0027

其中 $D = 1$ 表示女性, $D = 0$ 表示男性.

(1) 解释 D 的回归系数, 并说明其是否显著; ($\alpha = 0.05$)

(2) 解释 $X : D$ 的回归系数, 并说明其是否显著. ($\alpha = 0.05$)

Solution:

(1) D 的回归系数为 31.8731, 说明当其他情况不变时, 平均来看, 女性旅客比男性旅客会多花 31.8731 美元在旅行购物上. 其 t 检验 p 值为 $0.0011 < 0.05$, 因此在 0.05 的显著性水平下, 该结果是显著的.

(2) $X : D$ 的回归系数为 -0.0088, 说明当其他情况不变时, 同样是增加 1 美元的收入, 在平均意义下, 女性旅客会比男性旅客少花费 -0.0088 美元于旅行购物. 其 t 检验 p 值为 $0.0027 < 0.05$, 因此在 0.05 的显著性水平下, 该结果是显著的.

2. 阐述季节指数的计算方法.

Solution:

(1) 简单平均法.

首先要计算各年同期 (月或季度) 发展水平的序时平均数; 其次, 再计算全时期总平均数; 最后将各年同期平均数与全时期总平均数对比, 即得到各期 (月或季度) 的季节指数.

简单平均法的优点是计算简便, 但其也存在着缺陷: 第一, 未能消除长期趋势的影响; 第二, 季节指数的高低受各年数值大小的影响, 数值大的年份, 对季节指数影响大, 数值小的年份, 对季节指数的影响小. 从上面特点看, 简单平均法适合于长期趋势是水平趋势的时间数列的季节指数的变动, 若时间数列中不仅存在季节变动, 同时还存在着上升或下降的长期趋势, 用此方法计算的季节指数就会出现偏差.

(2) 移动平均趋势剔除法.

当时间数列中不仅存在季节变动, 同时也存在明显的上升或下降的长期趋势时, 计算季节指数时, 就需要首先消除长期趋势的影响. 剔除长期趋势的方法有很多, 如移动平均趋势剔除法、趋势线趋势剔除法等.

移动平均趋势剔除法的基本思想是先将时间数列中的趋势变动予以消除, 而后再计算季节指数. 具体的做法是: 首先根据各年的月 (或季度) 数据资料计算 12 个月 (或 4 个季度) 移动平均趋势值 T , 然后将各实际观察值除以相应的趋势值, 即 $Y/T = s \times I$, 最后, 将 $s \times I$ 重新按月 (或季度) 排列, 求得同月 (或季度) 平均数, 即将降低或消除不规则变动, 得到各月 (或季度) 季节指数 S .

这种方法由于先消除了长期趋势, 所得的季节指数已不受长期趋势的影响, 因此测定的季节波动比较精确.

3. 时间序列中加法模型和乘法模型的基本假定分别是什么?

Solution:

(1) 加法模型: 假设四种变动因素是完全独立的, 时间序列就是各因素相加的总和

$$Y = T + S + C + I$$

(2) 乘法模型假设四种变动因素呈相互交错影响的关系, 时间序列表现为各因素乘积:

$$Y = T * S * C * I$$

4. $X_1, \dots, X_n$ 独立同分布, 且 $E(X^3) = 1, E(X^6) = 4$, 求 n 趋于无穷的时候 $\frac{\sum_{i=1}^n X_i^3}{n}$ 的极限分布.

Solution:

由于 $X_1^2, \dots, X_n^2$ 是独立同分布的, 且其数学期望存在 $EX_3^2 = 1$, 那么根据大数定律, 有 $\frac{\sum_{i=1}^n X_i^3}{n} \xrightarrow{P} 1$.

另外, $Var(X_1^3) = 4 - 1 = 3$, 那么根据中心极限定理, 有 $\sqrt{n} \left(\frac{\sum_{i=1}^n X_i^3}{n} - 1 \right) \xrightarrow{d} N(0, 3)$.

当 n 增大时, $\frac{\sum_{i=1}^n X_i^2}{n}$ 的密度函数将会越来越聚集于一点.

三、计算题

1. 下面给出两种型号的计算器充电以后所能使用的时间 (单位:h) 的观测值

型号 A	5.5	5.6	6.3	4.6	5.3	5.0
6.2	5.8	5.1	5.2	5.9		
型号 B	3.8	4.3	4.2	4.0	4.9	4.5
5.2	4.8	4.5	3.9	3.7	4.6	

设两样本独立且数据所属的两正态总体的密度函数至多差一个平移量. 试问能否认为型号 A 的计算器平均使用时间明显比型号 B 来得长 (取 $\alpha = 0.01$)?

Solution:

这个问题可归结为关于两总体的均值是否相等的检验问题. 两正态总体方差相等但仍未知, 故应采用两样本 t 检验. 设 X 表示型号 A 的计算器充电以后所能使用的时间, Y 表示型号 B 的计算器充电以后所能使用的时间, 则依题意, $X \sim N(\mu_1, \sigma^2)$, $Y \sim N(\mu_2, \sigma^2)$, 待检验的假设为

$$H_0: \mu_1 = \mu_2 \quad \text{vs} \quad H_1: \mu_1 > \mu_2.$$

经计算,

$$\bar{x} = 5.5, \quad \bar{y} = 4.3667, \quad \sum_{i=1}^{11} (x_i - \bar{x})^2 = 2.74, \quad \sum_{i=1}^{12} (y_i - \bar{y})^2 = 2.4067,$$

从而

$$s_w = \sqrt{\frac{1}{11 + 12 - 2} (2.74 + 2.4067)} = 0.4951$$

$$t = \frac{5.5 - 4.3667}{0.4951 \sqrt{\frac{1}{11} + \frac{1}{12}}} = 5.4837$$

其拒绝域为 $\{t \geq t_{1-\alpha}(m+n-2)\} = \{t \geq t_{0.99}(21)\}$, 查表知 $t_{0.99}(21) = 2.5176$, 由于检验统计量的取值 $t > 2.5176$, 故拒绝 H_0 , 可以认为型号 A 的计算器平均使用时间明显比型号 B 来得长.

2. 为考察某种维尼纶纤维的耐水性能, 安排了一组试验, 测得其甲醇浓度 x 及相应的“缩醇化度” y 数据如下:

x	18	20	22	24	26	28	30
y	26.86	28.35	28.75	28.87	29.75	30.00	30.36

- (1) 求样本相关系数;
- (2) 建立一元线性回归方程;
- (3) 给出方差分析表, 对建立的回归方程作显著性检验 ($\alpha = 0.01$).

Solution:

(1) 由样本数据可以算得

$$\sum_{i=1}^n x_i = 168, \quad l_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 112,$$

$$\sum_{i=1}^n y_i = 202.94, \quad l_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = 8.4931,$$

$$l_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 29.6.$$

因此样本相关系数 $r = \frac{l_{xy}}{\sqrt{l_{xx}l_{yy}}} = \frac{29.6}{\sqrt{112 \times 8.4931}} = 0.9597$.

(2) 应用最小二乘估计公式, $\hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} = \frac{29.6}{112} = 0.2643$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 22.6482$, 于是一元线性回归方程为

$$\hat{y} = 22.6482 + 0.2643x.$$

(3) 首先计算几个平方和

$$S_T = l_{yy} = 8.4931,$$

$$S_R = \hat{\beta}_1^2 l_{xx} = 0.2643^2 \times 112 = 7.8237,$$

$$S_e = S_T - S_R = 0.6694,$$

将各平方和移入方差分析表, 继续计算, 可以得到

来源	SS	df	MS	F
	7.8237	1	7.8237	58.43
	0.6694	5	0.1339	
	8.4931	6		

若取 $\alpha = 0.01$, 查表知 $F_{0.99}(1, 5) = 16.26 < 58.43$, 拒绝域为 $W = \{F \geq 16.26\}$, 现检验统计量值落入拒绝域, 因此在显著性水平 0.01 下回归方程是显著的.

四. 证明题

(1) $g(x)$ 单调不减, 非负且连续, 证明对于任意的 $x > 0$, 不等式成立: $\mathbb{P}(X \geq x) \leq \frac{\mathbb{E}(g(X))}{g(x)}$

(2) $X \sim \text{Exp}(\lambda)$ X_i 独立同分布, 证: $\mathbb{P}(\sum_{i=1}^n X_i \geq nx) \leq 2^n e^{-\frac{(n\lambda x)}{2}}$

Solution:

(1) 利用示性函数 $I_{\{X \geq x\}}$, 有不等式 $g(x) I_{\{X \geq x\}} \leq g(X) I_{\{X \geq x\}} \leq g(X)$, 左右取数学期望, 有

$$\begin{aligned} g(x) \mathbb{P}(X \geq x) &\leq \mathbb{E}(g(X) I_{\{X \geq x\}}) \\ &\leq \mathbb{E}(g(X)) \mathbb{P}(X \geq x) \end{aligned}$$

(2) 取函数 $g(x) = e^{\frac{\lambda}{2}x}$, 单调不减且非负, 则可利用上面的不等式. 另外, 考虑到指数分布与伽马分布的关系, 记 $T = \sum_{i=1}^n X_i \sim \text{Ga}(n, \lambda)$, 于是 $\mathbb{P}(T \geq nx) \leq \frac{\mathbb{E}(g(T))}{g(nx)}$, 其中 $g(nx) = e^{\frac{n\lambda x}{2}}$, 以及

$$\mathbb{E}(g(T)) = \int_0^\infty \frac{\lambda^n}{\Gamma(n)} t^{n-1} e^{-\lambda t} e^{\frac{\lambda}{2}t} dt = 2^n.$$

综上所述, 有

$$\mathbb{P}\left(\sum_{i=1}^n X_i \geq nx\right) \leq 2^n e^{-\frac{n\lambda x}{2}}.$$

上海交通大学-432 统计学-2021 年

一. 选择题 (30 小题, 每小题 2 分, 共 60 分)

1. 为调查全国疫情情况, 调查组先从全国所有省份中随机抽取了八个省份, 再对每个省份中的所有单位进行调查, 这种抽样方法属于 ().

- A. 分层抽样
- B. 系统抽样
- C. 整群抽样
- D. 方便抽样

Solution: C

整群抽样是指整群地抽选样本单位, 对被抽选的各群进行全面调查的一种抽样组织方式.

2. 当一组数据呈对称分布时, 在平均数加减 2 个标准差的范围之内大约有 () 的数据.

- A. 68%
- B. 95%
- C. 99.7%
- D. 89%

Solution: B

利用标准正态分布来估计, $\Phi(2) - \Phi(-2) = 2\Phi(2) - 1 = 2 \cdot 0.9722 - 1 = 0.9444$.

3. 为调查群众戴口罩的频率, 调查者采用问卷调查, 问卷中的一个问题为“您戴口罩的频率吗?”, 选项为“从来不戴”、“极少戴”、“偶尔戴”、“经常戴”. 这一调查包含的误差类型是 ().

- A. 记忆误差
- B. 理解误差
- C. 无回答误差
- D. 有意识误差

Solution: B

4. 某奶粉生产企业欲了解消费者对奶粉成分的需求, 选译调查对奶粉购买力高、对奶粉成分有更高要求的年轻母亲, 这种抽样方法属于 ().

- A. 随机抽样
- B. 方便抽样
- C. 重点抽样
- D. 代表抽样

Solution: C

重点抽样是指从调查对象的全部单位中选择少数重点单位, 对其实施调查, 用于了解总体情况.

5. 在多元线性回归的线性关系检验与回归系数检验中, 若 F 检验不通过, 则某个系数的 t 检验 ().

- A. 可能通过也可能不通过
- B. 也不通过
- C. 一定通过
- D. 以上都不正确

Solution: B

6. 计算机辅助电话调查的特点是 ().

- A. 可以利用有形辅助物
- B. 调查过程难以控制
- C. 问卷难度可以复杂

D. 调查速度快

Solution: D

7. 区间估计中 95% 的置信水平是指 ().

- A. 总体参数落在一个特定的样本所构造的区间内的概率为 95%
- B. 总体参数落在一个特定的样本所构造的区间内的概率为 5%
- C. 在用同样方法构造的总体参数的多个区间中, 包含总体参数的区间比例为 95%
- D. 在用同样方法构造的总体参数的多个区间中, 包含总体参数的区间比例为 5%

Solution: C

A 的错误在于特定样本, 当样本给定时, 区间不具有随机性, 则要么包含真实参数, 要么不包含.

8. 假设检验中使用 p 值进行决策的优势是 ().

- A. 可以精确地反映决策的风险度
- B. 手工计算简便
- C. 进行决策的界限清晰
- D. 以上都不正确

Solution: A

p 值指的是, 在原假设成立下, 出现一个比当前样本要更加极端的观测的概率, 即反应了当前样本在原假设成立的情况下的极端程度, 它可以用来衡量犯第一类错误 (拒真) 的风险. 如果 p 值很小, 也就说明在原假设成立时, 当前的样本是一个非常极端的样本, 我们可以拒绝原假设, 此时也说明我们如果拒绝原假设, 那么犯拒真错误的风险较小.

9. 设 $X_1, X_2, \dots, X_{n_1}$ 是来自正态总体 $N(\mu_1, \sigma_1^2)$ 的一个样本, 设 $Y_1, Y_2, \dots, Y_{n_2}$ 是来自正态总体 $N(\mu_2, \sigma_2^2)$ 的一个样本, 且 $X_i (i = 1, 2, 3, \dots, n_1)$ 与 $Y_i (i = 1, 2, 3, \dots, n_2)$ 相互独立, 已知 $n_1 n_2 S_1^2 S_2^2$, 通过查表可知 $F_{\alpha/2}(n_1, n_2)$, $F_{\alpha/2}(n_2, n_1)$, $F_{\alpha/2}(n_1 - 1, n_2 - 1)$, $F_{\alpha/2}(n_2 - 1, n_1 - 1)$. 则方差之比 σ_1^2 / σ_2^2 的置信区间为 ().

- A. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1, n_2)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2, n_1)$
- B. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1 - 1, n_2 - 1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2 - 1, n_1 - 1)$
- C. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1, n_2)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_2, n_1)}$
- D. $\frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_1 - 1, n_2 - 1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2 / S_2^2}{F_{\alpha/2}(n_2 - 1, n_1 - 1)}$

Solution: B

注意这里用的应是上分位数, 根据 F 分布的对称性, 置信区间应为

$$\left[\frac{s_1^2 / s_2^2}{F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)}, \frac{s_1^2 / s_2^2}{F_{1 - \frac{\alpha}{2}}(n_1 - 1, n_2 - 1)} \right] = \left[\frac{s_1^2 / s_2^2}{F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)}, \frac{s_1^2}{s_2^2} F_{\frac{\alpha}{2}}(n_2 - 1, n_1 - 1) \right]$$

10. 多变量数据的图示中, 用于展示三个变量之间关系的是 ().

- A. 散点图
- B. 气泡图
- C. 雷达图
- D. 饼图

Solution: B

三个变量通常用气泡图 (横坐标、纵坐标、气泡大小)

11. 在假设检验中, 不拒绝原假设意味着 ().

- A. 原假设肯定是正确的
- B. 原假设肯定是错误的
- C. 没有证据证明原假设是正确的
- D. 没有证据证明原假设是错误的

Solution: D

A、B 说法过于绝对, 假设检验也是概率问题, 不拒绝原假设有可能犯第二类错误 (取伪).

12. 随机变量 $X_1 X_2 X_3 X_4$ 独立同分布于正态分布 $N(2, \sigma^2)$, 则 $\frac{(X_1 - X_2)^2}{(X_3 + X_4 - 4)^2}$ 服从于 () .

- A. $F(1, 1)$
- B. $F(2, 2)$
- C. $t(1)$
- D. $t(2)$

Solution: A

由于 $X_1 - X_2 \sim N(0, 2\sigma^2)$, $X_3 + X_4 \sim N(0, 2\sigma^2)$, 容易得 $\frac{(X_1 - X_2)^2}{(X_3 + X_4 - 4)^2} \sim F(1, 1)$.

13. 将 n 个球随机放入 N 个箱子内 ($n \leq N$), 每个球放入各个箱子的概率相等, 则每个箱子至多有一个球的概率为 () .

- A. $\frac{A_N^n}{N^n}$
- B. $\frac{A_N^n}{n^N}$
- C. $\frac{C_N^n}{N^n}$
- D. $\frac{C_N^n}{n^N}$

Solution: A

古典概型问题, 先考虑全集, 每个球均有 N 种选择, 共 n 个球, 故全集样本点为 N^n . 再考虑分子, 第一个球有 N 种选择, 第二个有 $N - 1$, 依此类推, 分子为 A_N^n

14. 设 $X_1 X_2 X_3 X_4$ 是来自总体 X 的样本, $EX = \mu$ 则 () 是 μ 的最有效估计.

- A. $\hat{\mu}_1 = \frac{1}{5}x_1 + \frac{1}{5}x_2 + \frac{1}{5}x_3 + \frac{2}{5}x_4$
- B. $\hat{\mu}_2 = \frac{1}{3}x_1 + \frac{1}{3}x_2 + \frac{1}{6}x_3 + \frac{1}{6}x_4$
- C. $\hat{\mu}_3 = \frac{1}{4}x_1 + \frac{1}{4}x_2 + \frac{1}{4}x_3 + \frac{1}{4}x_4$
- D. $\hat{\mu}_4 = \frac{1}{9}x_1 + \frac{2}{9}x_2 + \frac{3}{9}x_3 + \frac{4}{9}x_4$

Solution: C

即找到方差最小的无偏估计, 这四个选项中 C 给出的估计量方差最小.

15. 下列情况中, 可能存在多重共线性的是 () .

- A. 某个自变量的方差扩大因子 VIF 小于 10
- B. 模型中各个自变量显著不相关
- C. 回归系数的正负号与预期相同
- D. 某个自变量的容忍度小于 0.1

Solution: D

16. 多元线性回归中残差图的作用是 () .

- A. 检验线性关系是否显著
- B. 检验回归系数是否显著
- C. 判断自变量之间是否存在多重共线性
- D. 判断对误差项 ε 的假定是否成立

Solution: D

17. 时间序列中逐期环比值 (也称环比发展速度) 的几何平均数减 1 后的结果是 () .

- A. 平均增长率
- B. 环比增长率
- C. 定基增长率
- D. 年度化增长率

Solution: A

18. 如果一组数据分布的偏态系数是 0.4，则表明 ()。

- A. 该组数据呈右偏，且偏斜程度很高
- B. 该组数据呈右偏，且偏斜程度不高
- C. 该组数据呈左偏，且偏斜程度很高
- D. 该组数据呈左偏，且偏斜程度不高

Solution: B

19. 根据以往的生产统计，某种产品的合格率约为 90%，现要求估计误差为 5%，在 5% 的显著性水平下，应抽取 () 个产品作为样本。

- A. 138
- B. 139
- C. 384
- D. 385

Solution: B

题目意为，合格率为 π ，用抽样合格率 $\bar{X}$ 来估计 π ，试问需要多大的样本量，才可以保证

$$P\left(\left|\bar{X} - \pi\right| \geq 0.05\right) \leq \alpha.$$

利用正态近似， $\sqrt{n}(\bar{X} - \pi) \sim N(0, \pi(1 - \pi))$ ，则

$$P\left(\left|\bar{X} - \pi\right| \geq 0.05\right) = P\left(\left|\frac{\sqrt{n}(\bar{X} - \pi)}{\sqrt{\pi(1 - \pi)}}\right| \geq \frac{\sqrt{n}0.05}{\sqrt{\pi(1 - \pi)}}\right) = \alpha$$

可近似解得 $\frac{\sqrt{n}0.05}{\sqrt{\pi(1 - \pi)}} = z_{\frac{\alpha}{2}}$ ，于是 $n = \frac{z_{\frac{\alpha}{2}}^2 \pi(1 - \pi)}{0.05^2}$ 。代入数据 π 约为 0.9，有

$$n = \frac{z_{\frac{\alpha}{2}}^2 \pi(1 - \pi)}{0.05^2} = \frac{1.96^2 \cdot 0.9 \cdot 0.1}{0.05^2} = 138.298$$

考虑到 n 是整数，所以 n 至少为 139。

20. 估计的回归方程为 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3$ ，其中在 5% 的显著度下， $\hat{\beta}_1 \hat{\beta}_2$ 未通过 t 检验， $\hat{\beta}_3$ 通过了 t 检验，则在 5% 下我们可以认为 ()。

- A. $\beta_1, \beta_2 = 0; \beta_3 \neq 0$
- B. $\beta_1, \beta_2 \neq 0; \beta_3 = 0$
- C. $\beta_1, \beta_3 = 0; \beta_2 \neq 0$
- D. $\beta_2, \beta_3 \neq 0; \beta_1 = 0$

Solution: A

通过 t 检验说明显著，显著即不为 0。反之则为 0。

21. 某企业准备用三种方法组装一种新的产品，为确定哪种方法每小时生产的产品数量最多，随机抽取了 30 名工人，并指定每个人使用其中一种方法。通过对每个工人生产的产品数进行方差分析得到下面的结果：方差分析表

来源	SS	df	MS	F	P-value	F 临界值
组间	a	c	210	f	0.245946	3.354131
组内	3836	d	e	—	—	—
总计	b	29	—	—	—	—

补全上面的方差分析表 ().

A. $a = 420, b = 4256, c = 2, d = 27, e = 142.07, f = 1.478$

B. $a = 630, b = 4466, c = 3, d = 26, e = 147.54, f = 1.423$

C. $a = 420, b = 4256, c = 2, d = 27, e = 142.07, f = 0.099$

D. $a = 630, b = 4466, c = 3, d = 26, e = 147.54, f = 0.164$

Solution: A

有三种方法, 因此首先确定 $c = 2$, 然后 $d = 27$. 接着可以计算 $a = 2 \times 210 = 420$. $e = 3836/27 = 142.07, f = \frac{210}{142.074} = 1.4781$.

22. 关于方差分析中的多重比较方法中的最小显著差异 (LSD) 方法下列说法错误的是 ().

A. LSD 方法用于当自变量对因变量有显著影响时的进一步分析

B. LSD 方法通过两两配对来进一步检验哪些总体的方差之间有显著差异

C. LSD 方法的原假设通常为 $H_0: \mu_i = \mu_j$

D. $LSD = t_{\alpha/2} \sqrt{MSE \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$

Solution: B

LSD 是一种多重比较的方法, 用于检验组间均值是否有差异.

23. 下列关于调整的多重判定系数 R_α^2 说法错误的是 ().

A. 是度量多元回归方程拟合程度的一个统计量

B. 相比较多重判定系数 R^2 , 可剔除变量个数对拟合优度的影响

C. R_α^2 的值不一定小于 R^2 的值

D. R_α^2 的值不会由于模型中自变量的个数的增加而越来越接近 1

Solution: C

调整 R^2 一定更小.

24. 利用估计的回归方程进行区间估计时, 关于平均值的置信区间和个别值预测区间, 下面说法正确的是 ().

A. 置信区间比预测区间宽

B. 预测区间比置信区间宽

C. 二者一样宽

D. 不一定

Solution: B

预测区间指的是

$$x_0 \hat{\beta} \pm \sqrt{1 + x_0^T (X^T X)^{-1} x_0} \hat{\sigma} \cdot t_{\frac{\alpha}{2}} (n - p - 1).$$

平均值的置信区间指的是

$$x_0 \hat{\beta} \pm \sqrt{x_0^T (X^T X)^{-1} x_0} \hat{\sigma} \cdot t_{\frac{\alpha}{2}} (n - p - 1).$$

相差的 1 实际来源于 y_0 本身的随机性 ($y_0 \sim N(x_0 \beta, \sigma^2)$), 而 $E y_0$ 不具有随机性. 那么显然预测区间的长度更长.

25. 在使用指数平滑法进行预测时, 如果时间序列有较大的随机波动, 则平滑系数 α 的取值 ().

A. 应该小些

B. 应该大些

C. 应该等于 0

D. 应该等于 1

Solution: B

在使用指数平滑法进行预测时, 当时间序列变化剧烈时, 应该采用较大的平滑系数以跟上数据的变化.

26. 在比较计量单位不同的两组数据离散程度时, 应该使用 ().

- A. 离散系数
- B. 标准差
- C. 平均差
- D. 全距

Solution: A

离散系数可以消除量纲的影响.

27. 已知随机变量 $X = \frac{1}{2} + \frac{1}{\sqrt{2\pi}} \int_0^Y e^{-\frac{t^2}{2}} dt, X \sim U(0, 1)$, 其中 Y 是一个连续型随机变量, 则随机变量 Y 的概率密度函数 $g(y)$ 为 ().

- A. $\frac{1}{2} + \frac{1}{\sqrt{2\pi}} \int_0^Y e^{-\frac{t^2}{2}} dt$
- B. $\frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$
- C. $\frac{1}{\pi(1+x^2)}$
- D. $\frac{1}{2\pi + \frac{x^2}{\pi}}$

Solution: B

用微分法

$$P(Y=y) = P\left(X = \frac{1}{2} + \frac{1}{\sqrt{2\pi}} \int_0^Y e^{-\frac{t^2}{2}} dt\right) = \left| \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} \right| \cdot 1 dy = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy.$$

28. 随机变量 X, Y 相互独立且均服从于标准正态分布, 则随机变量 X/Y 的概率密度函数为 ().

- A. $\frac{1}{2} + \frac{1}{\sqrt{2\pi}} \int_0^Y e^{-\frac{t^2}{2}} dt$
- B. $\frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$
- C. $\frac{1}{\pi(1+x^2)}$
- D. $\frac{1}{2\pi + \frac{x^2}{\pi}}$

Solution: C

老生常谈.

29. $\xi, \eta \sim U(0, 1)$ 且相互独立, $X_1 = \min(\xi, \eta), X_2 = \max(\xi, \eta)$, 则 X_1, X_2 的联合密度函数为 ().

- A. $f(x_1, x_2) = 2I_{\{0 < x_1 \leq x_2 < 1\}}$
- B. $f(x_1, x_2) = I_{\{0 < x_1 \leq x_2 < 1\}}$
- C. $f(x_1, x_2) = I_{\{0 < x_1 < 1, 0 < x_2 < 1\}}$
- D. 以上都不正确

Solution: A

直接利用次序统计量的分布的结论.

30. 某一商场 30 分钟内到达的人数服从参数为 6 的泊松分布, 则 10 分钟内来商场的人数等于 3 的概率为 ().

- A. $\frac{4}{3}e^{-2}$
- B. $\frac{6^9}{9!}e^{-6}$
- C. $\frac{22}{3}e^{-2}$
- D. $\frac{16}{3}e^{-2}$

Solution: A

10 分钟内来商场的人数 $X \sim \mathcal{P}(2)$, 则 $P(X=2) = \frac{2^2}{2!}e^{-2} = \frac{4}{3}e^{-2}$.

二、简答题

1. 随机变量 X_1, X_2 相互独立, 且均服从于均值为 λ 的指数分布, 现有假设检验 $H_0: \lambda = 1; H_1: \lambda = 0.1$. 当拒绝域为 $X_1 > 3$, 犯第一类错误和第二类错误的概率分别为 α_1, β_1 ; 当拒绝域为 $\bar{X} > 3$, 其中 $\bar{X} = (X_1 + X_2)/2$, 犯第一类错误和第二类错误的概率分别为 α_2, β_2 .

(1) 求 $\alpha_1\beta_1$

(2) 求 $\alpha_1\beta_2$

(3) 说明随着样本量的增加 $\alpha_1, \beta_1, \alpha_2, \beta_2$ 怎样变化, 以及 $\alpha_2 + \beta_2 = 1$ 是否成立.

Solution:

(1) $\alpha_1 = P(X_1 > 3 | \lambda = 1) = e^{-3}, \beta_1 = 1 - P(X_1 > 3 | \lambda = 0.1) = 1 - e^{-0.3}.$

(2) $\alpha_2 = P(\bar{X} > 3 | \lambda = 1) = P(2(X_1 + X_2) > 12 | \lambda = 1) = \int_{12}^{+\infty} \chi_4^2(t) dt$, 这里 $\chi_4^2(t)$ 表示自由度为 4 的卡方分布的密度函数.

$\beta_2 = P(\bar{X} \leq 3 | \lambda = 0.1) = P(\frac{1}{5}(X_1 + X_2) \leq 1.2 | \lambda = 0.1) = \int_0^{1.2} \chi_4^2(t) dt.$

(3) 显然 α_1, β_1 不会变化. 而 $\alpha_2 = P(\bar{X} > 3 | \lambda = 1) \rightarrow 0$, 这是因为当 $\lambda = 1$ 时, 根据强大数定律有 $\bar{X} \rightarrow 1, a.s..$ 同理

$$\beta_2 = P(\bar{X} \leq 3 | \lambda = 0.1) = P(\bar{X} - 10 \leq -7 | \lambda = 0.1) \rightarrow 0.$$

而 $\alpha_2 + \beta_2 = 1$ 也是显然不成立的.

2. 阐述季节指数的计算方法.

Solution:

(1) 简单平均法.

首先要计算各年同期 (月或季度) 发展水平的序时平均数; 其次, 再计算全时期总平均数; 最后将各年同期平均数与全时期总平均数对比, 即得到各期 (月或季度) 的季节指数.

简单平均法的优点是计算简便, 但其中也存在着缺陷: 第一, 未能消除长期趋势的影响; 第二, 季节指数的高低受各年数值大小的影响, 数值大的年份, 对季节指数影响大, 数值小的年份, 对季节指数的影响小. 从上面特点看, 简单平均法适合于长期趋势是水平趋势的时间数列的季节指数的变动, 若时间数列中不仅存在季节变动, 同时还存在着上升或下降的长期趋势, 用此方法计算的季节指数就会出现偏差.

(2) 移动平均趋势剔除法.

当时间数列中不仅存在季节变动, 同时也存在明显的上升或下降的长期趋势时, 计算季节指数时, 就需要首先消除长期趋势的影响. 剔除长期趋势的方法有很多, 如移动平均趋势剔除法、趋势线趋势剔除法等.

移动平均趋势剔除法的基本思想是先将时间数列中的趋势变动予以消除, 而后再计算季节指数. 具体的做法是: 首先根据各年的月 (或季度) 数据资料计算 12 个月 (或 4 个季度) 移动平均趋势值 T , 然后将各实际观察值除以相应的趋势值, 即 $Y/T = sEI$, 最后, 将 sEI 重新按月 (或季度) 排列, 求得同月 (或季度) 平均数, 即将降低或消除不规则变动, 得到各月 (或季度) 季节指数 S .

这种方法由于先消除了长期趋势, 所得的季节指数已不受长期趋势的影响, 因此测定的季节波动比较精确.

3. 建立多元回归模型时, 为什么需要进行变量选择? 并阐述向前选择法的步骤.

Solution:

因变量可能会由多个自变量决定. 但是具体由多少个自变量决定是不清楚的, 所以我们需要通过变量选择, 判断这个具体的自变量个数. 另外有的时候若自变量之间存在相关性 (多重共线性问题), 将会导致估计量不有效或不唯一, 这时候也需要进行变量选择. 以及为了防止过多的加入无用变量导致过拟合, 我们也需要进行变量选择.

向前选择的步骤:

1. 对 k 个自变量分别拟合对因变量 y 的一元线性回归模型, 即得到 k 个一元线性回归模型, 然后找出 F 统计量值最高的模型及对应的变量 x_i , 并将该自变量首先引入模型中. 在此过程中, 需要注意的是: 如果所有模型的 F 统计量均未通过检验, 说明所搜集的自变量与因变量之间均为不显著, 说明模型构建不适合, 应当考虑换其他模型, 本方法的运算过程也就终止了.

2. 在已经引入的模型上, 分别引入剩余的 $k-1$ 个自变量, 分别得到 $k-1$ 个二元线性回归模型, 即变量组合为 $k-1$ 个二元线性回归模型, 继而得到 $k-1$ 个新的 F 统计量, 并从中找出 F 统计量的值为最高的模型, 此时,

该模型中含有两个自变量，新增加的自变量即为经过筛选出来的应当引入模型的自变量。同样地，如果在此过程中，没有 F 统计量通过检验，则运算终止。

3. 按照第二步的筛选方法，不断引入新的自变量，直到引入的新的自变量也不能使得残差平方和 (SSE) 显著减少为止 (F 统计量均为通过检验)。向前选择法就是这样一个不断引入新变量，进行 F 统计量检验的过程。

4. 随机变量 $X_i (i = 1, 2, 3, \dots, n)$ 独立同分布，且 $E(X_i) = 1, E(X_i^2) = 2, E(X_i^4) = 8$ ，则当 $n \rightarrow \infty$ 时， $\frac{\sum_{i=1}^n X_i^2}{n}$ 服从什么分布，并说明概率密度函数的形态变化。

Solution:

由于 $X_1^2, \dots, X_n^2$ 是独立同分布的，且其数学期望存在 $EX_1^2 = 2$ ，那么根据大数定律，有 $\frac{\sum_{i=1}^n X_i^2}{n} \xrightarrow{P} 2$ 。

另外， $Var(X_1^2) = 8 - 4 = 4$ ，那么根据中心极限定理，有 $\sqrt{n} \left(\frac{\sum_{i=1}^n X_i^2}{n} - 2 \right) \xrightarrow{d} N(0, 4)$ 。

当 n 增大时， $\frac{\sum_{i=1}^n X_i^2}{n}$ 的密度函数将会越来越聚集于一点。

三、计算题

1. 为估计两种方法组装产品所需时间的差异，分别对两种不同的组装方法随机安排 12 名工人，每个工人独立组装一件产品所需的时间见下表：

方法一	28.3	30.1	29.0	37.6	32.1	28.8
	36.0	37.2	38.5	34.4	28.0	30.0
方法二	27.6	22.2	31.0	33.8	20.0	30.2
	31.7	26.0	32.0	31.2	33.4	26.5

假定两种方法组装产品的时间服从正态分布，且方差相等。

(1) 试以 95% 的置信水平建立两种方法组装产品所需平均时间之差的置信区间 ($\alpha = 0.05$)；

(2) 这两种方法组装产品所需时间有无显著差别？($\alpha = 0.05$)

Solution:

(1) 假设方法一的组装时间 $X_1, \dots, X_{12} \sim N(\mu_1, \sigma^2)$ ，方法二的组装时间服从 $Y_1, \dots, Y_{12} \sim N(\mu_2, \sigma^2)$ 。则 $\mu_1 - \mu_2$ 的置信区间为

$$\begin{aligned}
 & (\bar{X} - \bar{Y}) \pm S_w \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \cdot t_{\frac{\alpha}{2}}(n_1 + n_2 - 2) \\
 & = (32.5 - 28.8) \pm \sqrt{\frac{\sum_{i=1}^{12} (X_i - \bar{X})^2 + \sum_{i=1}^{12} (Y_i - \bar{Y})^2}{22}} \cdot \sqrt{\frac{2}{12}} \cdot t_{0.025}(22) \\
 & = 3.7 \pm \sqrt{\frac{175.96 + 212.94}{22}} \cdot \sqrt{\frac{2}{12}} \cdot 2.0739 \\
 & = 3.7 \pm 3.56 = [0.14, 7.26].
 \end{aligned}$$

(2) 根据区间估计与假设检验的关系， $\mu_1 - \mu_2$ 的 95% 区间估计包含 0，那么在 0.05 显著性水平下，我们不能拒绝 $H_0: \mu_1 - \mu_2 = 0$ 。即认为两种方法组装产品所需时间无显著差别。

2. 一家房地产评估公司想对某城市的房地产销售价格 (y) 与地产评估价值 (x_1)、房产评估价值 (x_2) 和使用面积 (x_3) 建立一个模型，以便对销售价格进行合理预测。为此，收集了 15 栋住宅的房地产评估数据，经回归得到下面的有关结果 ($\alpha = 0.05$)

	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>p-value</i>
回归			23363343.03		0.00
残差				—	—
总计	14	75375973.33	—	—	—

	est.	std.error	t	p-value
截距	207.9037	617.0486	0.3369	0.7425
x_1	1.4378	0.5645	2.5472	0.0271
x_2	0.8545	0.2663	3.2091	0.0083
x_3	0.0626	0.0656	0.9538	0.3607

(1) 补全方差分析表, 写出销售价格对地产评估价值、房产评估价值、使用面积的多元线性回归方程, 并解释各回归系数的意义;

(2) 检验回归方程的线性关系是否显著; ($\alpha = 0.05$)

(3) 检验各回归系数是否显著; ($\alpha = 0.05$)

(4) 计算多重判定系数 R^2 , 并说明它的实际意义;

(5) 计算估计标准误差 S_e , 并说明它的实际意义

Solution:

(1)

这是一个三元的线性回归, 因此回归的自由度是 3, 残差的自由度是 11. 回归平方和 $SS_R = MS_R \cdot 3 = 23363343.03 \cdot 3 = 70090029.09$. 残差平方和 $SS_e = SS_T - SS_R = 75375973.33 - 70090029.09 = 5285944.24$, 残差均方为 $MS_e = SS_e/df_e = 5285944.24/11 = 480540$, 因此 F 统计量为 $F = \frac{MS_R}{MS_e} = \frac{23363343.03}{480540} = 48.6189$.

	df	SS	MS	F	p-value
回归	3	70090029.09	23363343.03	48.6189	0.00
残差	11	5285944.24	480540	—	—
总计	14	75375973.33	—	—	—

回归方程为

$$y = 207.9037 + 1.4378x_1 + 0.8545x_2 + 0.0626x_3,$$

其中截距项 207.9037 表明对于地产评估价值、房产评估价值、使用面积均为 0 的房屋, 其平均的基础销售价格为 207.9037;

以 x_1 的斜率 1.4378 为例, 当其他变量不变, 而地产评估价值提升一个单位时, 房屋销售价格平均提升 1.4378 个单位.

(2) 从回归的方差分析表可以看出, 回归的 F 检验的 p 值 < 0.01 , 因此在 0.05 的显著性水平下, 我们认为回归方程的线性关系显著成立.

(3) 从回归结果表来看, 针对截距项以及 x_3 的斜率项的 t 检验的 p 值大于 0.05, 因此该俩系数不显著. 关于 x_1 以及 x_2 的斜率项是显著的.

(4) $R^2 = \frac{SS_R}{SS_T} = \frac{70090029.09}{75375973.33} = 0.929872$. 多重判定系数或拟合优度衡量的是自变量对因变量的波动程度的解释程度, 拟合优度越接近 1 说明自变量对因变量的解释能力越强.

(5) $S_e = \sqrt{MS_e} = \sqrt{480540} = 693.21$, 它实际上是对线性回归残差项的标准差 σ 的估计, 它表明了因变量 y 没有被各个自变量所解释的部分的波动大小.

四. 证明题 (1 小题, 共 10 分)

1. 已知一系列随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立, 且都服从 $(0, 1)$ 上的均匀分布, 令

$$N = \min\{n \geq 1 : X_1 + X_2 + \dots + X_n > x\},$$

其中 $x \in (0, 1)$.

(1) 证明 $P(N > n) = \frac{x^n}{n!}$;

(2) 求 $E(N)$.

Solution:

(1) 有

$$P(N > n) = P(X_1 + \cdots + X_n \leq x) = \int_{\{x_1 + \cdots + x_n \leq x\}} dx_1 \cdots dx_n.$$

熟悉 n 重积分的同学不难计算该积分, 实际它是 N 维欧式空间中的一个锥体的体积 (二维空间中的一个直角三角形, 直角边长为 x ; 或三维空间中的一个四面体, 以原点为顶点, 延伸出的棱长均为 x). 我们直接计算:

$$\begin{aligned} \int_{\{x_1 + \cdots + x_n \leq x\}} dx_1 \cdots dx_n &= \int_0^x dx_n \int_{\{x_1 + \cdots + x_{n-1} \leq x - x_n\}} dx_1 \cdots dx_{n-1} \\ &= \int_0^x dx_n \int_0^{x-x_n} dx_{n-1} \cdots \int_0^{x-x_n-\cdots-x_3} dx_2 \int_0^{x-x_n-\cdots-x_2} dx_1 \\ &= \int_0^x dx_n \cdots \int_0^{x-x_n-\cdots-x_4} dx_3 \int_0^{x-x_n-\cdots-x_3} (x - x_n - \cdots - x_2) dx_2 \\ &= \int_0^x dx_n \cdots \int_0^{x-x_n-\cdots-x_4} \frac{1}{2} (x - x_n - \cdots - x_3)^2 dx_3 \\ &= \cdots = \int_0^x \frac{(x - x_n)^{n-1}}{(n-1)!} dx_n = \frac{x^n}{n!}. \end{aligned}$$

[注]: 或者利用归纳假设同样可以答案.

(2) 利用非负随机变量的数学期望公式, 有

$$E(N) = \sum_{n=0}^{+\infty} P(N > n) = \sum_{n=0}^{+\infty} \frac{x^n}{n!} = e^x.$$

上海交通大学-432 统计学-2022 年

一、选择题

1. 从一个 600 人的小区里抽住户，先按单元分，抽取若干单元的住户，再从抽取的若干个单元中，按完全随机的办法抽取 60 户，这种是什么抽样方法？（ ）

- A. 整群抽样
- B. 分层抽样
- C. 系统抽样
- D. 多阶段抽样

Solution: D

多阶段抽样是先将一个很大的总体划分为若干个子总体，即一阶单位，再把一阶单位划分为若干个更小的单位，称为二阶单位，照此继续下去划分出更小的单位，依次称为三阶单位、四阶单位等。然后分别按随机原则逐阶段抽样。

2. 进行一个调查，从一个老年人俱乐部入手，先调查几个老人，再让他们推荐其他人，再调查他们推荐的人，扩大调查范围，这种是什么抽样方法？（ ）

- A. 方便抽样
- B. 判断抽样
- C. 滚雪球抽样
- D. 整群抽样

Solution: C

滚雪球抽样是指先随机选择一些被访者并对其实施访问，再请他们提供另外一些属于所研究目标总体的调查对象，根据所形成的线索选择此后的调查对象。

3. 为研究两种稻谷的产量差异，分别种植了 10 个和 7 个样本，假设两种稻谷的产量分布为 $N(\mu_1, \sigma_1^2)$, $N(\mu_2, \sigma_2^2)$ ，计算样本可知： $s_1^2 = 4$, $s_2^2 = 3$ ，求 $\frac{\sigma_1^2}{\sigma_2^2}$ 的 95% 置信区间（ ）

- A. $[\frac{3}{4}F_{0.975}(6, 9), \frac{3}{4}F_{0.025}(6, 9)]$
- B. $[\frac{3}{4}F_{0.975}(7, 10), \frac{3}{4}F_{0.025}(7, 10)]$
- C. $[\frac{4}{3}F_{0.975}(6, 9), \frac{4}{3}F_{0.025}(6, 9)]$
- D. $[\frac{4}{3}F_{0.975}(7, 10), \frac{4}{3}F_{0.025}(7, 10)]$

Solution: A

注意这里用的应是上分位数，根据 F 分布的对称性，置信区间应为

$$\begin{aligned} \left[\frac{s_1^2/s_2^2}{F_{0.025}(9, 6)}, \frac{s_1^2/s_2^2}{F_{0.975}(9, 6)} \right] &= \left[\frac{s_1^2}{s_2^2} F_{0.975}(6, 9), \frac{s_1^2}{s_2^2} F_{0.025}(6, 9) \right] \\ &= \left[\frac{4}{3} F_{0.975}(6, 9), \frac{4}{3} F_{0.025}(6, 9) \right]. \end{aligned}$$

4. 若一个三元线性回归，线性关系的 F 检验显著， X_1 的回归系数检验显著，但 X_2, X_3 的回归系数 t 检验不通过，则（ ）

- A. 若使用 $X_1 X_2$ 构建二元回归方程，则有可能 t 检验通过
- B. 若使用 $X_1 X_3$ 构建二元回归方程，则不可能 t 检验通过
- C. 若使用 $X_2 X_3$ 各自作为单独变量构建一元回归方程，则 t 检验一定不通过
- D. 若使用 $X_2 X_3$ 各自作为单独变量构建一元回归方程，则有可能 t 检验通过

Solution: A D 均正确.

5. 一个机构对上交学生的 2021 年 9 月消费情况进行调查，但是只能收集到 2020 年 9 月的数据，该误差是什么误差？（ ）

- A. 抽样框误差
- B. 有意识误差
- C. 回答误差
- D. 测量误差

Solution: A

抽样框误差是因不准确或不完整的抽样框而引起的误差。从包含抽样误差的抽样框中抽取的样本有时无法正确地代表调研目标的实际情况，这就存在抽样框误差。

6. 自填式问卷调查的缺点是什么? ()

- A. 回收率低
- B. 成本太高
- C. 只适合复杂的问卷
- D. 调查周期短

Solution: A

自填式问卷调查成本低、只适合简单问卷、调查周期长，但回收率低。

7. 一枚均匀的硬币，抛 20 次，求正面次数大于反面次数的概率 ()

- A. $\frac{1}{2}$
- B. $\frac{1}{2} \left(1 - C_{20}^{10} \frac{1}{2^{20}}\right)$
- C. $\frac{1}{2} \left(1 - A_{20}^{10} \frac{1}{2^{20}}\right)$
- D. $C_{20}^{10} \frac{1}{2^{20}}$

Solution: B

用随机变量 X, Y 分别表示正面向上、反面向上的次数，则显然 $X + Y = 20$ ，且有

$$P(X > Y) + P(X < Y) + P(X = Y) = 1$$

根据对称性，以及 $X + Y = 20$ ，有

$$2P(X > Y) = 1 - P(X = 10)$$

$$P(X > Y) = \frac{1}{2} \left(1 - C_{20}^{10} \frac{1}{2^{20}}\right)$$

8. 某厂宣称自己的节能灯寿命大于 400 天，假设节能灯的寿命均值为 μ ，则收货商验货时应做的原假设，备择假设为 ()

- A. $H_0: \mu < 400$ v.s. $H_1: \mu \geq 400$
- B. $H_0: \mu \geq 400$ v.s. $H_1: \mu < 400$
- C. $H_0: \mu > 400$ v.s. $H_1: \mu \leq 400$
- D. $H_0: \mu \leq 400$ v.s. $H_1: \mu > 400$

Solution: D

通常将想要检验的内容 (不能轻易拒绝的) 放在备择假设，想要推翻的内容放在原假设，若拒绝原假设则称“显著通过”检验。

9. 比例估计，已知总体比率为 π ，可接受的最大误差为 E ，求样本量 n 的公式 ()

- A. $n = \frac{z_{\alpha/2}^2 \pi(1-\pi)}{E}$
- B. $n = \frac{z_{\alpha/2}^2 \pi(1-\pi)}{E^2}$
- C. $n = \frac{z_{\alpha/2} \pi(1-\pi)}{E^2}$
- D. $n = \frac{z_{\alpha/2} \pi(1-\pi)}{E}$

Solution: B

题目意为, 当某事件发生的概率为 π , 用重复试验发生的频率 $\bar{X}$ 来估计 π , 试问需要多大的样本量, 才可以保证

$$P\left(\left|\bar{X} - \pi\right| \geq E\right) \leq \alpha.$$

利用正态近似, $\sqrt{n}(\bar{X} - \pi) \sim N(0, \pi(1 - \pi))$, 则

$$P\left(\left|\bar{X} - \pi\right| \geq E\right) = P\left(\left|\frac{\sqrt{n}(\bar{X} - \pi)}{\sqrt{\pi(1 - \pi)}}\right| \geq \frac{\sqrt{n}E}{\sqrt{\pi(1 - \pi)}}\right) = \alpha$$

可近似解得 $\frac{\sqrt{n}E}{\sqrt{\pi(1 - \pi)}} = z_{\frac{\alpha}{2}}$, 于是 $n = \frac{z_{\frac{\alpha}{2}}^2 \pi(1 - \pi)}{E^2}$.

10. 希思罗机场声称自己是甲级机场, 机构为了验证说法是否属实, 进行假设检验, 则设立的原假设为 ()

- A. 希思罗机场没有达到甲级机场的标准
- B. 希思罗机场达到了甲级机场的标准
- C. 希思罗机场的自我评级与机构评级一致
- D. 希思罗机场的自我评级与机构评级不一致

Solution: A

将想要验证的放在备择假设.

11. 设 X, Y 相互独立, $X \sim P(\mu), Y \sim P(\lambda)$, 在 $X + Y = n > k$ 的条件下, 求 $P(X = k | X + Y = n)$

- A. $C_n^k \frac{\mu^k \lambda^{n-k}}{(\mu + \lambda)^n}$
- B. $C_n^k \frac{\lambda^k \mu^{n-k}}{(\mu + \lambda)^n}$
- C. $\frac{\mu^k \lambda^{n-k}}{(\mu + \lambda)^n}$
- D. $\frac{\lambda^k \mu^{n-k}}{(\mu + \lambda)^n}$

Solution: A

直接利用条件概率公式, 有

$$\begin{aligned} P(X = k | X + Y = n) &= \frac{P(X = k, Y = n - k)}{P(X + Y = n)} \\ &= \frac{\frac{\mu^k}{k!} e^{-\mu} \frac{\lambda^{n-k}}{(n-k)!} e^{-\lambda}}{\frac{(\mu + \lambda)^n}{n!} e^{-(\mu + \lambda)}} = C_n^k \frac{\mu^k \lambda^{n-k}}{(\mu + \lambda)^n} \end{aligned}$$

12. 一个月份或季度的季节指数指的是该月份或季度数值 ()

- A. 占全年月份或季度数值总和的比率
- B. 占以往所有年份相应的月份或季度数值平均的比率
- C. 占全年月份或季度数值的平均数的比率
- D. 以上选项都不对

Solution: B

季节指数以平均数据进行计算.

13. 含交互项的双因素方差分析, 行因素有 r 个水平, 列因素有 m 个水平, 每组重复 k 次, 总共有 n 个样本. 下面的方差分析表中 (I) (II) (III) 处的值缺失, 则缺失值 (III) 应该是 ()

来源	df	SS	MS	F
因素 A	2	1.078	0.539	40.86
因素 B	2	0.052	0.026	1.96
A:B	(I)	0.689	(II)	(III)
残差	18	0.238	0.013	
总计	26	2.057		

- A. 26.5
B. 13.25
C. 8.33
D. 5.89

Solution: B

可以看出 $r = m = 3$, 因此交互项的自由度应该是 $df_{A:B} = (r-1)(m-1) = 4$. 所以 $MS_{A:B} = \frac{SS_{A:B}}{df_{A:B}} = \frac{0.689}{4} = 0.1723$, $F_{A:B} = \frac{MS_{A:B}}{MSE} = \frac{0.1723}{0.013} = 13.25$.

14. 95% 置信区间的含义 ()
A. 一个特定样本算出的置信区间有 95% 的概率包含参数真值
B. 一个特定样本算出的置信区间有 5% 的概率包含参数真值
C. 100 个置信区间包含参数真值的个数大约为 95 个
D. 100 个置信区间包含参数真值的个数大约为 5 个

Solution: C

A 的错误在于特定样本, 当样本给定时, 区间不具有随机性, 则要么包含真实参数, 要么不包含.

15. 箱线图显示: 众数 < 中位数 < 平均数, 则该分布 ()
A. 左偏
B. 右偏
C. 对称
D. 无法判断

Solution: B

以连续型随机变量为例, 众数代表其密度函数的峰值点, 若众数 < 中位数 < 平均数, 则表明峰值点居于分布中心的左侧, 因此应该是右偏分布.

16. 利用 p 值决策的优势 ()
A. p 值可以精确度量原假设和备则假设不一致的程度
B. p 值反映拒绝一个真实原假设的风险度
C. p 值有明确的决策界限
D. p 值反映接受一个错误的原假设的风险度

Solution: B

p 值指的是, 在原假设成立下, 出现一个比当前样本要更加极端的观测的概率, 即反应了当前样本在原假设成立的情况下的极端程度, 它可以用来衡量犯第一类错误 (拒真) 的风险. 如果 p 值很小, 也就说明在原假设成立时, 当前的样本是一个非常极端的样本, 我们可以拒绝原假设, 此时也说明我们如果拒绝原假设, 那么犯拒真错误的风险较小.

17. 设随机变量 $X \sim U(0, \theta)$, $\hat{\theta}_1 = \frac{2}{n} \sum_{i=1}^n X_i$, $\hat{\theta}_2 = \frac{n+1}{n} X_{(n)}$, 则 ()
A. $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效
B. $\hat{\theta}_2$ 比 $\hat{\theta}_1$ 更有效
C. $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 一样有效

D. 因为两者的均值不同, 所以无法进行比较

Solution: B

容易算得二者均为 θ 的无偏估计, 但 $\hat{\theta}_2$ 是 θ 的 UMVUE, 因此肯定更有效.

18. 某含季节成分的数据是 84, 季节指数为 1.2, 则消除季节指数的数据是 ()

- A. 70
- B. 84
- C. 100.8
- D. 100

Solution: A

直接计算, $\frac{84}{1.2} = 70$.

19. 假如新冠肺炎患者, 用医学影像分析确诊的概率为 p , 没有得新冠肺炎但是确诊的概率为 $q = \frac{p}{200}$ 。现在已知一个城市得新冠的概率为 x , 如果一个人确诊了, 那么他得新冠的概率是多少 ()

- A. $\frac{200x}{1+199x}$
- B. $\frac{199x}{1+200x}$
- C. $\frac{199}{200}$
- D. $\frac{200}{201}$

Solution:

用事件 A 表示患病, 事件 B 表示确诊, 则由 Bayes 公式, 有

$$\begin{aligned} P(A|B) &= \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|\bar{A})P(\bar{A})} \\ &= \frac{px}{px + \frac{p}{200}(1-x)} = \frac{200px}{200px + p - px} = \frac{200x}{1 + 199x}. \end{aligned}$$

20. 设 $X_1, \dots, X_n i.i.d \sim U(\theta - 0.5, \theta + 0.5)$, 关于 θ 的极大似然估计, 下列说法正确的是 ()

- A. $\hat{\theta} = \frac{1}{2}(X_{(1)} + X_{(n)})$
- B. $\hat{\theta} = \frac{2}{X}$
- C. 极大似然估计不存在
- D. 极大似然估计不唯一

Solution: D

由于似然函数为

$$L(\theta) = I_{\{X_{(1)} \geq \theta - 0.5\}} I_{\{X_{(n)} \leq \theta + 0.5\}} = I_{\{X_{(n)} - 0.5 \leq \theta \leq X_{(1)} + 0.5\}},$$

则任意 $\hat{\theta} \in [X_{(n)} - 0.5, X_{(1)} + 0.5]$ 都是 θ 的 MLE.

21. 以下用哪种图表用来比较三个地区的销量的相似情况最好? ()

- A. 直方图
- B. 气泡图
- C. 雷达图
- D. 环形图

Solution: C

雷达图适用于分析多变量数据, 以及不同个体之间的相似性、差异性.

22. 以下哪些情况暗示回归模型可能存在多重共线性 ()

- A. 模型中两个自变量显著不相关
- B. 某个自变量容忍度小于 0.1

- C. 某个自变量 VIF 小于 10
D. F 检验通过, 至少有一个 t 检验通过

Solution: B

23. 多元回归中, 用 R_a^2 的目的是 ()
A. 调整自变量个数对误差平方和的影响
B. 调整自变量个数对回归平方和的影响
C. 防止由于增加统计不显著的自变量而低估 R^2
D. 防止由于增加统计不显著的自变量而高估 R^2

Solution: D

引入新的变量必定导致 R^2 提升, 而不一定提升调整 R^2 .

24. 设随机变量 $X_1 \dots X_{20}$ 独立同分布于一个正态分布 $N(\mu, \sigma^2)$, 记 $\bar{x} = \frac{\sum_{i=1}^{19} x_i}{19}$, $M^2 = \sum_{i=1}^{19} (x_i - \bar{x})^2$, 则统计量 $T = \frac{X_{20} - \bar{x}}{M} \sqrt{\frac{171}{10}}$ 服从什么分布? ()

- A. $F(1, 18)$
B. $F(1, 19)$
C. $t(18)$
D. $t(19)$

Solution: C

根据 Fisher 引理 $\bar{x} \sim N(\mu, \frac{\sigma^2}{19})$, $\frac{M^2}{\sigma^2} \sim \chi^2(18)$, 且二者独立. 而 X_{20} 与它们皆独立, 因此有 $\bar{x} - X_{20} \sim N(0, \frac{20}{19}\sigma^2)$ 与 M 独立, 综上所述,

$$\frac{(\bar{x} - X_{20}) / \sqrt{\frac{20}{19}}}{\sqrt{M^2/18}} = \frac{\bar{x} - X_{20}}{M} \sqrt{\frac{171}{10}} \sim t(18).$$

25. 一个假设检验, 如果在 $\alpha = 0.05$ 的时候拒绝了 H_0 , 说明 ()
A. 判断 H_0 为真, 错误的概率不超过 0.05
B. 判断 H_1 为真, 错误的概率超过 0.95
C. 判断 H_0 为假, 错误的概率不超过 0.05
D. 判断 H_1 为真, 错误的概率不超过 0.95

Solution: C

检验的显著性水平控制的是犯第一类错误 (拒真) 的概率, B、C 项的含义皆为拒真.

26. 设标准正态分布的峰度系数为 0, 若一个分布的峰度系数为 -0.5, 则该分布为 ()
A. 左偏分布
B. 右偏分布
C. 尖峰分布
D. 扁平分布

Solution: D

注意峰度与偏度的定义以及差别.

27. 相比两次运用单因素方差分析, 使用双因素方差分析有什么好处? ()
A. 双因素方差分析的 p 值一定比任一单因素方差分析中的 p 值大
B. 双因素方差分析的 p 值一定比任一单因素方差分析中的 p 值小
C. 双因素方差分析的残差效应更大
D. 双因素方差分析的残差效应更小

Solution: D

类似于分别建立一元线性回归以及建立二元线性回归模型的区别, 使用双因素方差分析, 残差平方和一定会减小.

28. 回归方程中的, 相同置信水平下, y_0 的预测区间以及其平均值 Ey_0 的置信区间的关系是 ()

- A. 平均值的置信区间更短
- B. 预测区间更短
- C. 平均值的置信上限严格大于预测上限
- D. 平均值的置信上限有可能大于预测上限

Solution: A

预测区间指的是

$$x_0\hat{\beta} \pm \sqrt{1 + x_0^T (X^T X)^{-1} x_0} \hat{\sigma} \cdot t_{\frac{\alpha}{2}}(n - p - 1).$$

平均值的置信区间指的是

$$x_0\hat{\beta} \pm \sqrt{x_0^T (X^T X)^{-1} x_0} \hat{\sigma} \cdot t_{\frac{\alpha}{2}}(n - p - 1).$$

相差的 1 实际来源于 y_0 本身的随机性 ($y_0 \sim N(x_0\beta, \sigma^2)$), 而 Ey_0 不具有随机性. 那么显然预测区间的长度更长.

如果考虑预测上限, 也一定是预测上限严格大于置信上限.

29. 设连续型随机变量 X 的密度函数为 $f(x) = \lambda^2 x \exp\{-\lambda x\}, x > 0, \lambda > 0$ | X 服从 $U(0, X)$, 则 $E[X | Y = y] = ()$

- A. $\lambda + y$
- B. $\frac{1}{\lambda} + y$
- C. λ
- D. $y\lambda$

Solution: B

先求联合分布, 易得

$$f(x, y) = f_X f_{Y|X} = \lambda^2 e^{-\lambda x}, x > y > 0.$$

则 Y 的边际分布是 $f_Y(y) = \int_y^{+\infty} \lambda^2 e^{-\lambda x} dx = \lambda e^{-\lambda y}, y > 0.$

因此 X 关于 Y 的条件分布是

$$f_{X|Y}(x) = \frac{\lambda^2 e^{-\lambda x}}{\lambda e^{-\lambda y}} = \lambda e^{-\lambda(x-y)}, x > y$$

它是双参数指数分布, 可以通过积分计算数学期望, 或直接利用双参数指数分布的数学期望公式 $E[X | Y = y] = \frac{1}{\lambda} + y.$

30. 在进行多元回归的 F 检验时, 如果接受原假设, 那么以下选项错误的是 ()

- A. 任何一个自变量都不显著
- B. 回归方程的线性关系不显著
- C. 没有找到充分的理由推翻原假设
- D. 自变量和因变量之间不可能有非线性关系

Solution: D

线性回归检验不了非线性关系.

二、简答题

1. 设随机变量 $X \sim \text{Exp}(\lambda_1), Y \sim \text{Exp}(\lambda_2)$, 且 X, Y 相互独立, $H_0: \frac{\lambda_2}{\lambda_1} = 1$ $H_1: \lambda_2 > \lambda_1$, 取拒绝域 $W = \{x > cy, c > 0\}$ 。

(1) 求第一类错误概率 α (3 分)

(2) 求第二类错误 β , 并求出 β 上限的最小值 (3 分)

(3) $\alpha + \beta = 1$ 是否成立 (2 分)

(4) 若要求 $\alpha < 0.05$, c 应该满足什么条件 (2 分)

Solution:

(1) 先求该检验的功效函数, 它是 λ_1, λ_2 的函数, 有

$$\begin{aligned} g_W(\lambda_1, \lambda_2) &= P(X > cY) = \int_0^{+\infty} P(X > cY | Y = y) f_Y(y) dy \\ &= \int_0^{+\infty} e^{-c\lambda_1 y} \lambda_2 e^{-\lambda_2 y} dy = \frac{\lambda_2}{c\lambda_1 + \lambda_2}. \end{aligned}$$

而第一类错误的概率为 $\alpha = P(X > cY | \lambda_1 = \lambda_2) = g_W(\lambda, \lambda) = \frac{1}{c+1}$.

(2) 对任意 $\lambda_2 > \lambda_1$, 第二类错误的概率是

$$\beta(\lambda_1, \lambda_2) = 1 - g_W(\lambda_1, \lambda_2) = \frac{c\lambda_1}{c\lambda_1 + \lambda_2}$$

其上确界为 $\sup_{\lambda_2 > \lambda_1} \beta(\lambda_1, \lambda_2) = \sup_{\lambda_2 > \lambda_1} \frac{c\lambda_1}{c\lambda_1 + \lambda_2} = \frac{c}{c+1}$.

当 $c > 0$ 时, 该上限的最小值为 0 (在 $c \rightarrow 0+$ 时取到.)

(3) 容易验证 $\alpha + \beta = \frac{1}{c+1} + \frac{c\lambda_1}{c\lambda_1 + \lambda_2} \neq 1$.

但 $\alpha + \sup_{\lambda_2 > \lambda_1} \beta = 1$ 成立.

(4) 令 $\frac{1}{c+1} < 0.05$, 解得 $c > 19$.

2. 某种商品价格的 4 年环比增长率 G_1, G_2, G_3, G_4

(1) 求年平均增长率.

(2) $(G_1 + 1)(G_2 + 1)(G_3 + 1)(G_4 + 1) - 1$ 表示哪种增长率, 用来描述什么?

(3) 增长率分析需要注意哪些问题.

Solution:

(1) 设年平均增长率为 x , 则

$$\begin{aligned} (1+x)^4 &= (G_1 + 1)(G_2 + 1)(G_3 + 1)(G_4 + 1) \\ x &= [(G_1 + 1)(G_2 + 1)(G_3 + 1)(G_4 + 1)]^{\frac{1}{4}} - 1 \end{aligned}$$

(2) 表示定基增长率, 如果观察的是若干个时期的数据, 每个时期的数据均与同一个基期数据进行对比, 则这种比较方法, 称为定基比较.

(3) (a) 当时间序列中的观察值出现 0 或负数时, 不宜计算增长率; (b) 不能单纯就增长率论增长率, 要注意增长率与绝对水平的综合分析; 大的增长率背后, 其隐含的绝对值可能很小, 小的增长率背后其隐含的绝对值可能很大.

3. 非线性趋势曲线有哪些, 写出他们的名称, 用来描述何种趋势, 写出趋势方程, 用什么方法计算模型里的参数?

Solution:

- 指数曲线 $y = ae^{bx}$, 用于描述以几何级数递增或递减的现象, 或者说时间序列的逐期观察值按一定的增长率增长或衰减. 一般的自然增长及大多数经济序列都有指数变化趋势. 可以通过两边取对数, 然后用最小二乘法进行参数估计. - 多项式曲线 $y = b_0 + b_1x + b_2x^2 + \cdots + b_mx^m$, 用来模仿一些难以理论建模的规律, 任意的连续函数均可以用多项式函数逼近. 可以将其视作多元线性回归模型, 并用多元线性回归的最小二乘法进行求解.

4. 随机变量 X 是大于 0 的连续型随机变量, $\ln X$ 的均值方差都存在, 设 $X_1, \dots, X_n$ 是来自总体 X 的简单随机样本, 试求 $Y_n = (X_1 X_2 \cdots X_n)^{\frac{1}{n}}$ 的渐近分布?

Solution: 记 $Z_n = \ln Y_n = \frac{1}{n} \sum_{i=1}^n \ln X_i$, 则根据大数定律, 有 $Z_n \xrightarrow{P} E(\ln X_1)$, 再根据连续函数保持依概率收敛, 有 $Y_n = \exp(Z_n) \xrightarrow{P} \exp^{E(\ln X_1)}$, 即单点分布.

另外, 根据中心极限定理,

$$\sqrt{n}(Z_n - E(\ln X)) \xrightarrow{d} N(0, \text{Var}(\ln X)),$$

而 $Y_n = \exp(Z_n)$, 根据 delta 方法, 有

$$\sqrt{n}(Y_n - e^{E(\ln X)}) \xrightarrow{d} N(0, e^{2E(\ln X)} \text{Var}(\ln X))$$

三、计算题 1. 为估计两种肥料的差异, 在土壤上分别使用两种不同的肥料各随机施肥 10 次, 得到两组简单随机样本 $X_1, \dots, X_{10}; Y_1, \dots, Y_{10}$, 分别来自 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ $\bar{x} = 600, \bar{y} = 570, S_1^2 = \frac{6400}{9}, S_2^2 = \frac{2400}{9}$.

(1) 假设 $\sigma_1^2 = \sigma_2^2$, 求 $\mu_1 - \mu_2$ 的 95% 置信下限.

(2) 在 $\alpha = 5\%$ 的显著性水平下, 试检验是否有 $\sigma_1^2 = \sigma_2^2$.

Solution:

(1) 枢轴量取作

$$t = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(18).$$

置信下限由 $(\bar{X} - \bar{Y}) - S_w \sqrt{\frac{1}{m} + \frac{1}{n}} \cdot t_{0.05}(18)$ 给出, 计算得

$$\begin{aligned} & (\bar{X} - \bar{Y}) - S_w \sqrt{\frac{1}{m} + \frac{1}{n}} \cdot t_{0.05}(18) \\ &= 30 - \sqrt{\frac{6400 + 2400}{18}} \cdot \sqrt{\frac{1}{10} + \frac{1}{10}} \cdot t_{0.05}(18) \\ &= 30 - 22.11 \cdot 0.447 \cdot 1.734 = 12.8626 \end{aligned}$$

(2) 假设检验问题为: $H_0: \sigma_1^2 = \sigma_2^2$ vs $H_1: \sigma_1^2 \neq \sigma_2^2$.

检验统计量是 $F = \frac{s_1^2}{s_2^2} \sim F(9, 9)$, 拒绝域为

$$W = \{F < F_{0.975}(9, 9)\} \cup \{F > F_{0.025}(9, 9)\} = \{F < 0.2484\} \cup \{F > 4.026\}$$

计算得 $F = \frac{8}{3} \notin W$, 因此不能拒绝原假设. 即认为 $\sigma_1^2 \neq \sigma_2^2$.

2. 货车的运输时间 (y , 单位: 小时) 与运输路程 (x , 单位: 英里) 有关, 取 10 个样本, 考虑运输时间与运输路程的一元回归模型. 给出下面一些统计量. 试解决以下问题: $\bar{x} = \frac{\sum_{i=1}^{10} x_i}{10} = 80, \bar{y} = \frac{\sum_{i=1}^{10} y_i}{10} = 67, \sum_{i=1}^{10} (x_i - \bar{x})^2 = 3441, \sum_{i=1}^{10} (y_i - \bar{y})^2 = 460.744, \sum_{i=1}^{10} (x_i - \bar{x})(y_i - \bar{y}) = 1079$.

(1) 补全方差分析表:

	df	SS	MS	F
回归				
残差			15.3	-
总和	9		-	-

(2) 设回归模型 $Y = a + bx + \varepsilon, \varepsilon \sim N(0, \sigma_2^2)$, 求 $\hat{a}, \hat{b}$, 并说明 $\hat{b}$ 的实际意义.

(3) 计算多重判定系数 R^2 , 并说明它的实际意义;

(4) 给定 $\alpha = 0.01$, 判断线性关系是否显著;

(5) 在 $\alpha = 0.05$ 的显著性水平下, 给定 $x_0 = 90$, 求 y_0 的预测区间.

Solution:

(1)

回归平方和 $SS_R = \frac{l_{xy}^2}{l_{xx}} = \frac{1079^2}{3441} = 338.344$, 回归自由度为 1, 回归均方 $MS_R = 338.344$.

残差的自由度为 8, 残差平方和为 $SS_e = MS_e \cdot df_e = 15.3 \cdot 8 = 122.4$.

总平方和为 $SS_T = SS_e + SS_R = 338.344 + 122.4 = 460.744$. F 统计量为 $\frac{MS_R}{MS_e} = \frac{338.344}{15.3} = 21.4142$.

	df	SS	MS	F
回归	1	338.334	338.334	21.4142
残差	8	122.4	15.3	-
总和	9	460.744	-	-

(2) $\hat{b} = \frac{l_{xy}}{l_{xx}} = \frac{1079}{3441} = 0.3136$, 其含义为 “当 x 增加一个单位, 那么在平均意义下, y 将会增加 0.3136 个单位”

$$\hat{a} = \bar{y} - \hat{b}\bar{x} = 67 - 80 \cdot 0.3136 = 41.912.$$

$$(3) R^2 = \frac{SS_R}{SS_T} = \frac{338.334}{460.744} = 0.7343.$$

它反应因变量的全部变异能通过回归关系被自变量解释的比例. 换句话说, 如果我们能控制自变量 x 不变, 则因变量 y 的变异程度会减少 73.43%.

(4) 我们已经计算得到 F 统计量的值为 21.4142, 当线性关系不成立时候, 应该有 $F \sim F(1, 8)$, 而 $F_{0.01}(1, 8) = 11.2586$, 所以我们拒绝原假设, 认为线性关系显著成立.

(5) y_0 的预测区间是

$$\begin{aligned} & \hat{a} + \hat{b}x_0 \pm \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} \hat{\sigma} \cdot t_{0.025}(8) \\ &= 41.912 + 0.3136 \cdot 90 \pm \sqrt{1 + \frac{1}{10} + \frac{10^2}{3441}} \cdot \sqrt{15.3} \cdot 2.306 \\ &= 70.136 \pm 9.5844 \\ &= [60.5516, 79.7204] \end{aligned}$$

四. 证明题 (1 小题, 共 10 分) 1. 定义连续型随机变量 X, Y 的密度函数为 $p(x) > 0, q(x) > 0$, 且 X, Y 的定义域 D 相同, 定义 Kullback-Leibler 散度: $KL(p||q) = \int_{x \in \mathbb{D}} p(x) \log \frac{p(x)}{q(x)} dx$

(1) 求证: $KL(p||q) = \int_{x \in \mathbb{D}} p(x) \log \frac{p(x)}{q(x)} dx \geq 0$;

(2) 若 $X \sim N(0, 1), Y \sim N(\mu, \sigma^2)$, 求 $KL(X||Y)$, 并说明 σ^2 变化时, $KL(X||Y)$ 的变化.

Solution:

(1) 主要利用 $-\log(x)$ 的凸性以及 Jensen 不等式,

$$KL(p||q) = E_p \left[\log \frac{p(x)}{q(x)} \right] = E_p \left[-\log \frac{q(x)}{p(x)} \right] \geq -\log \left(E_p \left[\frac{q(x)}{p(x)} \right] \right) = -\log \left(\int_{x \in D} \frac{q(x)}{p(x)} p(x) dx \right) = 0.$$

(2) 直接代入计算

$$\begin{aligned} KL(X||Y) &= E_X \left[\log \frac{\varphi(x)}{\frac{1}{\sigma} \varphi\left(\frac{x-\mu}{\sigma}\right)} \right] \\ &= E_X \left\{ \left[-\frac{X^2}{2} - \frac{1}{2} \log(2\pi) \right] - \left[-\frac{(X-\mu)^2}{2\sigma^2} - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log \sigma^2 \right] \right\} \\ &= E_X \left[\frac{(X-\mu)^2}{2\sigma^2} - \frac{X^2}{2} + \frac{1}{2} \log \sigma^2 \right] \\ &= \frac{1+\mu^2}{2\sigma^2} - \frac{1}{2} + \frac{1}{2} \log \sigma^2 \end{aligned}$$

而由于

$$\frac{\partial KL(X||Y)}{\partial \sigma^2} = -\frac{1+\mu^2}{2\sigma^4} + \frac{1}{2\sigma^2} = \frac{1}{2\sigma^2} \left(1 - \frac{\mu^2+1}{\sigma^2}\right),$$

因此当 $0 < \sigma^2 \leq \mu^2 + 1$ 时, $KL(X||Y)$ 关于 σ^2 递减, 而当 $\sigma^2 \geq \mu^2 + 1$ 时, $KL(X||Y)$ 关于 σ^2 递增.

上海交通大学-432 统计学-2023 年

一、选择题

1. 先在一个学校的所有班级中抽 10 个班级, 然后在这 10 个班级中的所有学生中抽 30%, 请问这属于什么抽样 ()

- A. 整群抽样
- B. 多阶段抽样
- C. 简单随机抽样
- D. 配额抽样

Solution: B

多阶段抽样是先将一个很大的总体划分为若干个子总体, 即一阶单位, 再把一阶单位划分为若干个更小的单位, 称为二阶单位, 照此继续下去划分出更小的单位, 依次称为三阶单位、四阶单位等。然后分别按随机原则逐阶段抽样。

2. 现有三个汽车厂商在江苏和浙江的销量数据, 如果想要比较他们的销售结构, 用下列哪种图来进行展示最合适 ()

- A. 雷达图
- B. 复式饼图
- C. 环形图
- D. 帕累托图

Solution: C

只有两个数据, 不适合用雷达图展示, 应该用环形图。

3. 一组数据的下四分位数是 20, 上四分位数是 30, 现已知某个数据是 61, 请问它属于以下哪种类型? ()

- A. 极端点
- B. 离群点
- C. 异常值
- D. 最大点

Solution: A

此处上下四分位数差 $IQR = 30 - 20 = 10$, 超过四分位数 1.5 个 IQR, 即 <5 或 >45 , 是离群点, 超过四分位数 3 个 IQR, 即 <-10 或 >60 , 是极端点。

4. 对某所学校的学生进行抽样, 一种方法是按男女比例 6 : 4 抽样, 另一种是按照文科理科比例 5 : 5 抽样, 请问这属于什么抽样方法? ()

- A. 典型抽样
- B. 重点抽样
- C. 滚雪球抽样
- D. 配额抽样

Solution: D

配额抽样也称“定额抽样”, 是指调查人员将调查总体样本按一定标志分类, 确定各类单位的样本数额, 在配额内任意抽选样本的抽样方式。

5. 一所大学准备采取一项学生在宿舍上网收费的措施, 为了解男女学生对这一措施的看法, 分别抽取了 150 名男学生和 120 名女学生进行调查, 得到的结果如下:

	男同学	女同学	合计
赞成	45	42	87
反对	105	78	183
合计	150	120	270

根据该列联表, 男女学生反对上网收费的期望频数分别为 ()

- A. 48 和 39
- B. 102 和 81
- C. 15 和 14
- D. 25 和 19

Solution: B

计算期望频数, 在列联表原假设下, 性别与是否反对是独立的, 则这里用边际分布的乘积即可

$$270 \cdot \frac{150}{270} \cdot \frac{183}{270} = 101.667, \quad 270 \cdot \frac{120}{270} \cdot \frac{183}{270} = 81.3333$$

6. 随机变量 X 和 Y 独立同分布, 分布列均为 $P(X = k) = 2^{-k}, k = 1, 2, 3, \dots$, 则 $P(X \geq nY) = ()$

- A. $\frac{2}{2^{n+1}-1}$
- B. $\frac{2}{2^n-1}$
- C. $\frac{1}{2}$
- D. $\frac{1}{2^{n+1}-1}$

Solution: A

由全概率公式, 有

$$\begin{aligned}
 P(X \geq nY) &= \sum_{k=1}^{\infty} P(X \geq nk) P(Y = k) \\
 &= \sum_{k=1}^{\infty} \left(2^{-k} \sum_{j=nk}^{\infty} 2^{-j} \right) \\
 &= \sum_{k=1}^{\infty} (2^{-k} \cdot 2^{1-nk}) \\
 &= \sum_{k=1}^{\infty} 2^{1-(n+1)k} = \frac{2}{2^{n+1}-1}
 \end{aligned}$$

7. 随机变量 X 和 Y 相互独立, 分别服从参数为 λ_1 和 λ_2 的指数分布, 则 $X + Y$ 的密度函数是 ()

- A. $(\lambda_1 + \lambda_2)e^{-(\lambda_1 + \lambda_2)z}, z > 0$
- B. $\frac{\lambda_1 \lambda_2}{\lambda_2 - \lambda_1} (\exp(-\lambda_1 z) - \exp(-\lambda_2 z)), z > 0$
- C. $(\lambda_1 - \lambda_2)e^{-(\lambda_1 - \lambda_2)z}, z > 0$
- D. $(\lambda_1 \lambda_2)e^{-(\lambda_1 \lambda_2)z}, z > 0$

Solution: B

记 $Z = X + Y$, 则

$$\begin{aligned}
 F_Z(z) &= P(X+Y \leq z) \\
 &= \int_0^z \int_0^{z-y} \lambda_1 \lambda_2 \exp(-\lambda_1 x - \lambda_2 y) dx dy \\
 &= \int_0^z \lambda_2 (1 - \exp(-\lambda_1(z-y))) \exp(-\lambda_2 y) dy \\
 &= 1 - \exp(-\lambda_2 z) - \frac{\lambda_2}{\lambda_2 - \lambda_1} (\exp(-\lambda_1 z) - \exp(-\lambda_2 z))
 \end{aligned}$$

因此 Z 的密度函数是

$$\begin{aligned}
 f(z) &= \lambda_2 \exp(-\lambda_2 z) - \frac{\lambda_2}{\lambda_2 - \lambda_1} (\lambda_2 \exp(-\lambda_2 z) - \lambda_1 \exp(-\lambda_1 z)) \\
 &= \frac{\lambda_1 \lambda_2}{\lambda_2 - \lambda_1} (\exp(-\lambda_1 z) - \exp(-\lambda_2 z))
 \end{aligned}$$

8. $\hat{\theta}_n$ 是参数 θ 的一个估计量, 假设 $\hat{\theta}_n$ 的期望与方差均存在, 且当样本量 n 趋于无穷时, $E[\hat{\theta}_n] \rightarrow \theta$, $Var(\hat{\theta}_n) \rightarrow 0$, 则以下说法中, 错误的是 ()

- A. $\hat{\theta}_n$ 是参数 θ 的一致估计量
- B. $\hat{\theta}_n$ 依分布收敛到 θ
- C. $P(\lim_{n \rightarrow +\infty} \hat{\theta}_n = \theta) = 1$
- D. $\lim_{n \rightarrow +\infty} E[(\hat{\theta}_n - \theta)^2] = 0$

Solution: C

A 是经典结论, B 可由 A 推出, C 表示几乎处处收敛, 这不一定成立. D 是均方收敛, 而 $MSE(\hat{\theta}) = Var(\hat{\theta}) + [E\hat{\theta} - \theta]^2$, 因此 D 也正确.

9. 对于正态总体的一组随机样本, 总体的方差 σ^2 已知. 考虑假设检验问题: $H_0: \mu = 100 \leftrightarrow H_1: \mu \neq 100$. 现已知 μ 的 95% 置信区间是 $[102.18, 109.82]$, 则对于前面提到的假设检验问题, 基于该数据算得的 p 值最有可能是 ()

- A. 0.0013
- B. 0.0026
- C. 0.0052
- D. 0.01

Solution: B

题目给出的置信区间说明样本均值 $\bar{X} = 106$, 半个置信区间的长度是 $3.82 = \frac{\sigma}{\sqrt{n}} z_{0.975}$, 得 $\frac{\sigma}{\sqrt{n}} = \frac{3.82}{1.96} = 1.9490$. 据此计算得到 Z 统计量

$$Z = \frac{\sqrt{n}(\bar{X} - 100)}{\sigma} = \frac{6}{1.9490} = 3.0785$$

则 p 值是

$$P(|Z| \geq 3.0785) = 1 - \Phi(3.0785) + \Phi(-3.0785) \approx 0.0026$$

10. 某电视台为统计收视率, 使用电话采访收集群众是否看过该电视台, 若要求 0.05 显著性水平下的误差不超过 10%, 则需要的最低样本量是 ()

- A. 193
- B. 97

C. 100

D. 200

Solution: B

题目意为, 收视率为 π , 用抽样收视率 $\bar{X}$ 来估计 π , 试问需要多大的样本量, 才可以保证

$$P\left(|\bar{X} - \pi| \geq 0.1\right) \leq 0.05$$

利用正态近似, $\sqrt{n}(\bar{X} - \pi) \sim N(0, \pi(1 - \pi))$, 则

$$P\left(|\bar{X} - \pi| \geq 0.1\right) = P\left(\left|\frac{\sqrt{n}(\bar{X} - \pi)}{\sqrt{\pi(1 - \pi)}}\right| \geq \frac{\sqrt{n}0.1}{\sqrt{\pi(1 - \pi)}}\right) = 0.05$$

可近似解得 $\frac{\sqrt{n}0.1}{\sqrt{\pi(1 - \pi)}} = z_{0.025}$, 于是 $n = 100 \cdot z_{0.025}^2 \pi(1 - \pi)$.

由于题目没有给出 π 的大概数值, 则利用不等式 $\pi(1 - \pi) \leq \frac{1}{4}$, 得 $n = 96.0365$. 考虑到 n 是整数, 所以 n 至少为 97.

11. 以下哪个分布不是指数族分布 ()

A. 二项分布

B. 双参数指数分布

C. 泊松分布

D. 正态分布

Solution: B

双参数指数分布的支撑集与参数有关, 因此不可能是指数族分布.

12. 有来自两点分布总体 $b(1, \theta)$ 的一组简单随机样本 $X_1, \dots, X_n$, 则 θ 的无偏估计的方差的 CR 下界是 ()

A. $\frac{\theta(1-\theta)}{n}$

B. $\frac{\theta}{n}$

C. $\theta(1 - \theta)$

D. $\frac{1-\theta}{n}$

Solution: A

先计算 Fisher 信息量, $I(\theta) = -E\left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta^2}\right] = \frac{1}{\theta} + \frac{1}{1-\theta} = \frac{1}{\theta(1-\theta)}$.

则 C-R 下界是 $\frac{1}{nI(\theta)} = \frac{\theta(1-\theta)}{n}$.

13. 某 4s 店声称其汽车达到了 10000 公里平均里程数的标准, 产检部门为检验他的说法是否属实, 应选取的备择假设是 ()

A. 平均里程数大于 10000 公里

B. 平均里程数小于 10000 公里

C. 平均里程数等于 10000 公里

D. 平均里程数大于等于 10000 公里

Solution: A

将想要检验的内容放在备择假设.

14. 某教授声称手术之后病人的胰岛素水平会降至 15 以下, 为了检验他的说法是否正确, 建立了假设检验问题 $H_0: \mu \geq 15 \leftrightarrow H_0: \mu < 15$, 现观测到经过手术后的 100 位病人的胰岛素水平并在 0.05 的显著性水平下拒绝了原假设, 则以下说法正确的是 ()

A. 没有充分的证据证明原假设错误

B. 原假设的可信度小于 5%

- C. 正确接受备择假设的概率至少为 95%
D. 正确接受备择假设的概率至少为 97.5%

Solution: C

显著性水平衡量的是 " 拒真 " 概率, 则拒绝了正确原假设的概率至多为 0.05, 换句话说: 正确接受备择假设的概率至少为 95%.

15. 含交互项的双因素方差分析, 行因素有 r 个水平, 列因素有 m 个水平, 每组重复 k 次, 总共有 n 个样本. 下面的方差分析表中 (I) (II) (III) 处的值缺失, 则缺失值 (III) 应该是 ()

来源	df	SS	MS	F
因素 A	2	1.078	0.539	40.86
因素 B	2	0.052	0.026	1.96
A:B	(I)	0.689	(II)	(III)
残差	18	0.238	0.013	
总计	26	2.057		

- A. 26.5
B. 13.25
C. 8.33
D. 5.89

Solution: B

可以看出 $r = m = 3$, 因此交互项的自由度应该是 $df_{A:B} = (r - 1)(m - 1) = 4$. 所以 $MS_{A:B} = \frac{SS_{A:B}}{df_{A:B}} = \frac{0.689}{4} = 0.1723$, $F_{A:B} = \frac{MS_{A:B}}{MSE} = \frac{0.1723}{0.013} = 13.25$.

16. 对一组数据建立三元线性回归,

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$$

其中只有 x_1 通过 t 检验, 则以下说法中错误的是 ()

- A. 无需对整个模型进行线性检验
B. x_2, x_3 不显著的原因可能是多重共线性造成的
C. 可以通过检验变量之间的相关系数来确定是否存在多重共线性
D. x_2, x_3 可以舍弃, 因为系数不显著, 没有意义

Solution: D

存在一个变量显著, 则 F 检验必定通过, A 正确. BC 说法正确. D 错误, 不应该直接舍弃, 可能的做法是先尝试舍弃其中一个变量.

17. 随机变量 $X \sim N(0, \sigma^2)$, 则 $Y = e^X$ 的概率密度函数是 ()

- A. $\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\ln y)^2}{2\sigma^2}\right)$
B. $\frac{1}{\sqrt{2\pi}\sigma y} \exp\left(-\frac{y^2}{2\sigma^2}\right)$
C. $\frac{1}{\sqrt{2\pi}\sigma y} \exp\left(-\frac{(\ln y)^2}{2\sigma^2}\right)$
D. $\frac{1}{\sqrt{2\pi}\sigma y} \exp\left(-\frac{(\ln y)^2}{2}\right)$

Solution: C

Y 是对数正态分布. 直接求其密度函数, 对任意 $y > 0$, 则

$$f_Y(y) = \left| \frac{1}{y} \right| \cdot f_X(\ln y) = \frac{1}{y} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\ln y)^2}{2\sigma^2}}$$

18. 关于拟合优度 R^2 和调整拟合优度 R_a^2 的关系, 以下说法错误的是 ()

- A. R_a^2 可能为负
- B. R_a^2 始终小于 R^2
- C. R_a^2 用样本量 n 和自变量个数 k 来进行调整后, 避免了引进不必要的自变量而高估 R^2
- D. 当自变量的个数越来越多的时候, R_a^2 取值会越来越接近 R^2

Solution: C

根据定义

$$R_a^2 = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1}$$

它可能是负数, 且显然小于 R^2 , 故 AB 均正确. C 也正确. D 错误, 当样本量增大而变量数固定时, 二者越来越接近.

19. 某时间序列数据存在 2 个拐点, 则用下列什么曲线来拟合更合适? ()

- A. 二阶
- B. 三阶
- C. 指数曲线
- D. 一阶

Solution: B

三阶曲线有 2 个拐点.

20. 以下哪一个指标不受时间序列平均水平和计量尺度的影响? ()

- A. 平均误差
- B. 平均绝对误差
- C. 均方误差
- D. 平均相对误差

Solution: D

四个选项均不受平均水平的影响, 而相对误差可以去除数据尺度的影响.

21. 现有规模一大一小两家公司, 若想比较工资的离散程度, 可以采用以下哪个指标? ()

- A. 方差
- B. 平均数
- C. 变异系数
- D. 异众比率

Solution: C

变异系数不受量纲影响, 用于比较数据的离散程度.

22. 以下哪项是标准化残差图的作用? ()

- A. 检验相关性和方差齐性
- B. 检验方差齐性和独立性
- C. 检验正态性和独立性
- D. 检验正态性和方差齐性

Solution: D

标准化残差图主要检验模型假设是否成立, 即随机误差项是否方差相等. 更进一步也可以检验随机误差项的正态性.

23. 报税时候将数据报高, 属于以下哪类误差? ()

- A. 有意识误差
- B. 无回答误差

- C. 理解误差
D. 系统误差

Solution: A

有意识误差, 当调查的问题比较敏感, 被调查者不愿意回答, 迫于各种原因又必须回答时, 可能就会提供一个不真实的数字。

而调查纳税情况时, 被调查者往往高报, 以表现自己没有漏税行为。

24. 面访式调查的缺点是 ()

- A. 提高回答率
B. 回答的质量难以控制
C. 不能对数据收集所花费的时间进行调解
D. 成本较高

Solution: D

25. 现有两条曲线, 曲线 A 的峰度系数是 2.5, 曲线 B 的峰度系数是 3.5, 则 ()

- A. 曲线 A 比曲线 B 略显陡峭
B. 曲线 A 比曲线 B 陡峭许多
C. 曲线 B 比曲线 A 略显陡峭
D. 曲线 B 比曲线 A 陡峭许多

Solution: D

峰度系数相差 1, 陡峭程度相差较大, 且峰度系数越高越陡峭。

26. 随机变量 $(X, Y) \sim N(0, 0, \sigma_1^2, \sigma_2^2, \rho)$, 则 $E[X | Y] = ()$

- A. Y
B. 0
C. $\rho \frac{\sigma_1}{\sigma_2} Y$
D. $\frac{\sigma_1}{\sigma_2} Y$

Solution: C

直接根据多元正态分布的条件分布公式

$$X | Y \sim N\left(\rho \frac{\sigma_1}{\sigma_2} Y, \sigma_1^2 (1 - \rho^2)\right)$$

则 $E(X | Y) = \rho \frac{\sigma_1}{\sigma_2} Y$.

27. $X_1, \dots, X_{20}$ 是来自总体 $N(\mu, \sigma^2)$ 的简单随机样本, 其中参数 μ 已知, 则以下哪个是 σ^2 的无偏的充分统计量 ()

- A. $\sum_{i=1}^{20} (X_i - \mu)^2$
B. $\sum_{i=1}^{20} (X_i - \bar{X})^2$
C. $\sum_{i=1}^{19} (X_i - \mu)^2$
D. $\sum_{i=1}^{19} (X_i - \bar{X})^2$

Solution: A

由于 A, C 已知, 那么根据因子分解定理 $\sum_{i=1}^{20} (X_i - \mu)^2$ 是 σ^2 的充分统计量, 因此 B D 错误. C 不是无偏估计.

28. 关于众数, 说法正确的是 ()

- A. 一组数据肯定有一个众数
B. 一组数据肯定不止一个众数
C. 众数用于描述顺序型数据的集中趋势

D. 众数用于描述分类型数据的集中趋势

Solution: A

当每一个数据出现的次数都相同时, 众数不存在.

29. 在某公司进行的英语水平测试中, 新员工的平均得分是 80 分, 标准差是 5 分, 中位数是 85 分, 则新员工得分的分布形状是 ()

- A. 对称的
- B. 左偏的
- C. 右偏的
- D. 无法确定

Solution: B

平均值小于中位数, 说明是左偏的.

30. 当模型存在严重的多重共线性时, OLS 估计量将不具备 ()

- A. 线性
- B. 无偏性
- C. 有效性
- D. 一致性

Solution: C

严重多重共线性发生时, 设计矩阵接近奇异, 其逆矩阵特征值将非常大, 则估计量的方差会变大, 不再具有有效性.

二、简答题

1. 现有一组某互联网公司的薪资数据, 数据包括了: 程序员年固 S 、工作年限 X (年)、学历 E (1: 本科 2: 硕士 3: 博士), 试构建合适的线性模型来预测程序员的年薪, 并解释各系数的意义.

Solution: 引入虚拟变量进行回归 (季节模型), 以本科为 baseline, 引入另外两个虚拟变量

$$E_{2i} = \begin{cases} 1, & \text{第 } i \text{ 个员工是硕士,} \\ 0, & \text{否则.} \end{cases}, \quad E_{3i} = \begin{cases} 1, & \text{第 } i \text{ 个员工是博士,} \\ 0, & \text{否则.} \end{cases}$$

建立线性回归模型:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 E_{2i} + \beta_3 E_{3i} + \varepsilon_i$$

其中 β_0 是截距项, β_1 表示每增加一年工作年限, 其薪资的平均增长. β_2 表示硕士学历相比本科学历的平均工资增长. β_3 表示博士学历相比本科学历的平均工资增长.

2. 名词解释: 复合型序列. 简述“移动平均趋势剔除法”的步骤, 以及所用的乘法模型公式, 用乘法模型公式表示分离季节成分.

Solution: 复合型序列是指含有趋势、季节、周期和随机成分的序列. 对这类序列的预测方法通常是将时间序列的各个因素依次分解出来, 然后再进行预测.

移动平均趋势剔除法:

- a. 计算移动平均值 M
- b. 剔除原序列中的趋势成分, 即用序列各项数据 Y 除以对应的移动平均值 M (乘法模型中分离各因素的影响)
- c. 消除不规则变动 I , 即求解各期季节指数 S
- d. 调整季节指数, 即用季节指数的调整系数对所求季节指数进行归一化处理

乘法模型是

$$y_t = T_t \cdot S_t \cdot C_t \cdot I_t$$

其中 T 表示长期趋势, S 表示季节变动, C 表示循环变动, I 表示不规则变动.

3. 随机变量 $X_1, X_2 \stackrel{i.i.d.}{\sim} U(0, \theta)$, 记 $Y = \max\{X_1, X_2\}, Z = \min\{X_1, X_2\}$.

(1) 求 (Y, Z) 的联合概率密度函数. (2) 考虑假设检验问题:

$$H_0: \theta \leq 1 \leftrightarrow H_0: \theta > 1$$

以及拒绝域 $W = \{(y, z) : yz > 0.9\}$, 求该检验的势函数.

Solution:

(1) 直接根据次序统计量的分布的结论, 有

$$f(y, z) = \frac{2}{\theta^2} I_{\{0 \leq z \leq y \leq \theta\}}$$

(2) 根据定义

$$\begin{aligned} \rho(\theta) &= P(YZ > 0.9) \\ &= \iint_{yz > 0.9, 0 \leq z \leq y \leq \theta} \frac{2}{\theta^2} dydz \end{aligned}$$

当 $\theta \in (0, \sqrt{0.9})$ 时, 被积区域是空集, 则 $\rho(\theta) = 0$;

当 $\theta \in [\sqrt{0.9}, +\infty)$ 时,

$$\begin{aligned} \rho(\theta) &= \int_{\sqrt{0.9}}^{\theta} \int_{\frac{0.9}{y}}^y \frac{2}{\theta^2} dydz \\ &= \int_{\sqrt{0.9}}^{\theta} \frac{2}{\theta^2} \left(y - \frac{0.9}{y} \right) dy \\ &= 1 - \frac{1.8}{\theta^2} \ln \theta - \frac{0.9}{\theta^2} + \frac{0.9 \ln 0.9}{\theta^2} \end{aligned}$$

4. 简单随机样本 $X_1, \dots, X_n$ 来自于标准正态总体 $N(0, 1)$, 试求 $Y_n = \sqrt{X_1^2 + \dots + X_n^2} - \sqrt{n}$ 的极限分布.

Solution:

记 $Z_n = \frac{X_1^2 + X_2^2 + \dots + X_n^2}{n}$, 则根据中心极限定理, 有

$$\sqrt{n}(Z_n - 1) \xrightarrow{d} N(0, 2)$$

取 $g(x) = \sqrt{x}$, 则 $g'(1) = \frac{1}{2}$, 则根据 Delta 方法,

$$\sqrt{n}(g(Z_n) - g(1)) \xrightarrow{d} N\left(0, 2 \cdot [g'(1)]^2\right)$$

即

$$Y_n = \sqrt{n} \left(\sqrt{\frac{X_1^2 + X_2^2 + \dots + X_n^2}{n}} - 1 \right) \xrightarrow{d} N\left(0, \frac{1}{2}\right)$$

三、计算题

1. 设简单随机样本 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$, 已知 $(\bar{X}, S_n^2)$ 为 (μ, σ^2) 的充分完备统计量, 其中

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

(1) 求 μ, σ 的极大似然估计;

(2) 求 $(\bar{X}, S_n^2)$ 的分布 (提示: $\chi^2(m)$ 的密度函数为 $f_m(x) = \frac{(1/2)^{\frac{m}{2}}}{\Gamma(m/2)} x^{\frac{m}{2}-1} e^{-\frac{x}{2}}$);

(3) 由充分完备统计量求 $\mu + 3\sigma$ 的 UMVUE;

(4) 由充分完备统计量求 $\frac{\mu^2}{\sigma^2}$ 的 UMVUE.

Solution:

(1) 过程略去, $(\bar{X}, \frac{n-1}{n}S_n^2)$ 是 (μ, σ^2) 的 MLE. 根据不变性, $(\bar{X}, \sqrt{\frac{n-1}{n}}S_n)$ 是 (μ, σ) 的 MLE

(2) 根据 Fisher 引理, $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$, $\frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2(n-1)$ 且二者独立. 因此 $(U, V) = (\bar{X}, S_n^2)$ 的联合密度函数是

$$f_{U,V}(u, v) = \frac{1}{\sqrt{2\pi\frac{\sigma^2}{n}}} e^{-\frac{n(u-\mu)^2}{2\sigma^2}} \cdot \frac{n-1}{\sigma^2} \frac{(1/2)^{\frac{n-1}{2}}}{\Gamma(\frac{n-1}{2})} \left(\frac{n-1}{\sigma^2}v\right)^{\frac{n-1}{2}-1} e^{-\frac{n-1}{2\sigma^2}v}$$

(3) 根据 L-S 定理, 只需基于充分完备统计量求 $\mu + 3\sigma$ 的无偏估计. 而 $\bar{X}$ 是 μ 的无偏估计. 而

$$\begin{aligned} E\left(\frac{\sqrt{n-1}}{\sigma}S_n\right) &= \int_0^{+\infty} t^{\frac{1}{2}} \frac{(1/2)^{\frac{n-1}{2}}}{\Gamma(\frac{n-1}{2})} t^{\frac{n-1}{2}-1} e^{-\frac{t}{2}} dt \\ &= \int_0^{+\infty} \frac{(1/2)^{\frac{n-1}{2}}}{\Gamma(\frac{n-1}{2})} t^{\frac{n}{2}-1} e^{-\frac{t}{2}} dt \\ &= \frac{1}{\Gamma(\frac{n-1}{2})} (1/2)^{-\frac{1}{2}} \int_0^{+\infty} \left(\frac{t}{2}\right)^{\frac{n}{2}-1} e^{-\frac{t}{2}} d\left(\frac{t}{2}\right) \\ &= \sqrt{2} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})}, \end{aligned}$$

即 $E(S_n) = \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})} \sqrt{\frac{2}{n-1}}\sigma$. 故 $\sqrt{\frac{n-1}{2}} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} S_n$ 是 σ 的无偏估计.

因此 $T = \bar{X} + 3\sqrt{\frac{n-1}{2}} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} S_n$ 是 $\mu + 3\sigma$ 的 UMVUE.

(4) 容易计算 $E(\bar{X}^2) = \mu^2 + \frac{\sigma^2}{n}$, 而

$$\begin{aligned} E\left(\frac{\sigma^2}{(n-1)S_n^2}\right) &= \int_0^{+\infty} \frac{1}{t} \frac{(1/2)^{\frac{n-1}{2}}}{\Gamma(\frac{n-1}{2})} t^{\frac{n-1}{2}-1} e^{-\frac{t}{2}} dt \\ &= \frac{1}{2\Gamma(\frac{n-1}{2})} \int_0^{+\infty} \left(\frac{t}{2}\right)^{\frac{n-1}{2}-2} e^{-\frac{t}{2}} d\left(\frac{t}{2}\right) \\ &= \frac{\Gamma(\frac{n-1}{2}-1)}{2\Gamma(\frac{n-1}{2})} = \frac{1}{2(\frac{n-1}{2}-1)} = \frac{1}{n-3}, \end{aligned}$$

故 $E\left(\frac{n-3}{(n-1)S_n^2}\right) = \frac{1}{\sigma^2}$. 则根据 $\bar{X}, S_n^2$ 的独立性, 有

$$E\left(\bar{X}^2 \cdot \frac{n-3}{(n-1)S_n^2}\right) = \frac{\mu^2}{\sigma^2} + \frac{1}{n}$$

综合以上, 有 $Z = \frac{(n-3)\bar{X}^2}{(n-1)S_n^2} - \frac{1}{n}$ 是 $\frac{\mu^2}{\sigma^2}$ 的 UMVUE.

2. 考虑一元线性回归模型: $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, 其中 y 表示成年男性的身高或成年女性的身高乘以 1.08, x 表示父母亲的平均身高, 已有统计量 $\sum_{i=1}^n x_i = 1750$, $\sum_{i=1}^n y_i = 1770$, $\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 300$, $\sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x}) = 625$, $\sum_{i=1}^n (y_i - \bar{y})(y_i - \bar{y}) = 400$, 样本量 $n = 10$.

(1) 求估计的回归方程;

(2) 求决定系数 R^2 并解释其意义;

(3) 已知某位家庭中, 父亲 190 cm 母亲 170 cm, 估计其儿女身高;

(4) 对于假设检验问题: $H_0: \beta_1 = 0.7$ v.s. $H_1: \beta_1 \neq 0.7$, 试在 5% 的显著度下进行假设检验.

Solution:

(1) 根据结论 $\hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} = \frac{300}{625} = 0.48$, 以及 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 177 - 0.48 \cdot 175 = 93$, 则回归方程是

$$\hat{y} = 93 + 0.48x$$

(2) $R^2 = \frac{l_{xy}^2}{l_{xx}l_{yy}} = \frac{300^2}{625 \cdot 400} = 0.36$, 这表示子女身高的变化有 36% 的部分可以由父母的平均身高来解释.

(3) 对于儿子: $\hat{y} = 93 + 0.48 \cdot \frac{190+170}{2} = 179.4$,

对于女儿: $\hat{y} = \frac{179.4}{1.08} = 166.111$.

(4) 注意到 $R^2 = 1 - \frac{SSE}{SST}$, 而 $SST = l_{yy}$, 故

$$\hat{\sigma}^2 = \frac{SSE}{n-2} = \frac{(1-R^2) \cdot 400}{8} = \frac{0.64 \cdot 400}{8} = 32$$

而 $\hat{\beta}_1$ 的标准误差是

$$se(\hat{\beta}_1) = \frac{1}{\sqrt{l_{xx}}} \hat{\sigma} = \frac{\sqrt{32}}{\sqrt{625}} = 0.226$$

故有 t 统计量,

$$t = \frac{\hat{\beta}_1 - 0.7}{se(\hat{\beta}_1)} = \frac{0.48 - 0.7}{0.226} = -0.973$$

原假设成立时, 其分布是自由度为 8 的 t 分布 $t(8)$. 因此检验的拒绝域是 $W = \{|t| \geq t_{0.975}(8)\} = \{|t| \geq 2.30\}$, 故不应拒绝原假设.

四. 证明题 (1 小题, 共 10 分) 1. 简单随机样本 $U_1, \dots, U_n$ 来自于均匀分布总体 $U(0, 1)$, 记 $T_n = \max_{1 \leq i \leq n} U_i$, 则

(1) 求 T_n 的分布函数

(2) 证明 $n(1 - T_n) \xrightarrow{L} \text{Exp}(1)$

Solution:

(1) 对于 $t \in [0, 1]$, 有

$$\begin{aligned} F_T(t) &= P(T_n \leq t) = P(X_1 \leq t, \dots, X_n \leq t) \\ &= [P(X_1 \leq t)]^n = t^n \end{aligned}$$

则 T_n 的分布函数是

$$F_T(t) = \begin{cases} 0, & t < 0, \\ t^n, & 0 \leq t < 1, \\ 1, & t \geq 1. \end{cases}$$

(2) 容易算得 T_n 的密度函数是

$$f_T(t) = nt^{n-1}, 0 < t < 1$$

记 $Z_n = n(1 - T_n)$, 由变量变换法, 有 Z_n 的密度函数

$$\begin{aligned} f_Z(z) &= \left| -\frac{1}{n} \right| \cdot n \cdot \left(1 - \frac{z}{n} \right)^{n-1}, 0 < 1 - \frac{z}{n} < 1 \\ &\rightarrow e^{-1}, z > 0 \end{aligned}$$

后者是 $\text{Exp}(1)$ 的密度函数, 故有 $n(1 - T_n) \xrightarrow{L} \text{Exp}(1)$.

上海交通大学-432 统计学-2024 年

一、选择题 (1-15 题每题 2 分, 16-25 题每题 3 分, 共 60 分)

1. 从某车厂抽了 20 辆同一类型的车进行测是, 根据这 20 车的数据得出结论, 表明这类型车百公里油耗小于 7.1 L, 这句话是 ()

- A. 对样本的描述
- B. 对样本的推断
- C. 对总体的描述
- D. 对总体的推断

Solution: D.

这是通过样本数据对总体的推断.

2. 某大学的马克思学院的老师对大学生玩手机的时间比较感兴趣, 因此从马克思学院的大一、大二、大三、大四, 各抽了 20 个人 ()

- A. 多阶段抽样
- B. 配额抽样
- C. 简单随机抽样
- D. 整群抽样

Solution: B.

3. 为研究不同人的甘油三酯和血糖的关系, 应该用什么图表 ()

- A. 条形图
- B. 对比条形图
- C. 散点图
- D. 饼图

Solution: C.

4. 淘宝调查某产品评价, 有人恶意差评, 请问这是什么误差 ()

- A. 随机误差
- B. 回答误差
- C. 无回答误差
- D. 抽样框误差

Solution: B.

5. 一组数据的均值是 0.078, 标准差是 0.03, 下列哪一个是异常值 ()

- A. 0.089
- B. 0.074
- C. 0.072
- D. 0.082

Solution: A.

6. 现有某大学的学生分数, 分数均值是 78, 中位数是 83, 标准差是 8, 则样本的分布是 ()

- A. 左偏
- B. 右偏
- C. 对称
- D. 不确定

Solution: A.

7. 假设 X 的分布列为 $\mathbb{P}(X=1)=0.2, \mathbb{P}(X=0)=0.7, \mathbb{P}(X=2)=0.1$, 问 X 的均值和方差, 以下错误的是 ()

- A. 众数和中位数均为 0
- B. 期望为 0.4
- C. 方差为 0.44
- D. 标准差为 0.2

Solution: D.

8. 总体 $X \sim N(\mu, \sigma^2)$, 随机变量 $F = \frac{k(\bar{X}-\mu)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$ 是 F 分布, 求 k 的参数 ()

- A. $n(n-1)$
- B. $\frac{n-1}{n}$
- C. 1
- D. $\frac{n}{n-1}$

Solution: 选 A.

我们知道 $U_1 = n(\bar{X} - \mu)^2 \sim \sigma^2 \chi^2(1)$, $U_2 = \sum_{i=1}^n (X_i - \bar{X})^2 \sim \sigma^2 \chi^2(n-1)$, 因此 $\frac{U_1}{U_2/(n-1)} \sim F(1, n-1)$, 对应系数得到 $k = n(n-1)$.

9. 设 $X \sim N(0, 1)$, 求 $Y = X^4$ 的概率密度函数 ()

- A. $\frac{1}{2\sqrt{2\pi}} y^{-3/4} \exp\left(-\frac{y^{1/2}}{2}\right), y > 0$.
- B. $\frac{1}{\sqrt{2\pi}} y^{-3/4} \exp\left(-\frac{y^{1/2}}{2}\right), y > 0$.
- C. $\frac{1}{4\sqrt{\pi}} y^{-3/4} \exp\left(-\frac{y^{1/2}}{2}\right), y > 0$.
- D. $\frac{1}{2\sqrt{\pi}} y^{-3/2} \exp\left(-\frac{y^{1/2}}{2}\right), y > 0$.

Solution: A.

微分法.

$$\begin{aligned} P(Y=y) &= P(X=y^{1/4}) + P(X=-y^{1/4}) = 2P(X=y^{1/4}) \\ &= 2p(y^{1/4}) dy^{1/4} = \frac{1}{2} y^{-3/4} p(y^{1/4}) dy = \frac{1}{2\sqrt{2\pi}} y^{-3/4} \exp\left(-\frac{y^{1/2}}{2}\right). \end{aligned}$$

10. 下列四个说法中, 哪个说法是错误的 ()

- A. 离散系数越小, 数据越分散
- B. 异众比率越小, 数据越集中
- C. 极差会受极端值影响
- D. 四分位差不是用于分类数据

Solution: A.

11. 研究在雨天的路上和晴天的路上的刹车距离, 20 辆车在两个路上进行测试, 测得雨天的刹车标准差是 45, 晴天的是 25, 假设刹车距离均为正态分布, 且雨天刹车距离的方差为 σ_1^2 , 晴天刹车距离的方差为 σ_2^2 , 检验问题:

$$H_0: \frac{\sigma_1^2}{\sigma_2^2} \leq 1 \leftrightarrow H_1: \frac{\sigma_1^2}{\sigma_2^2} > 1$$

则 () (分位数: $F_{0.05}(19, 19) = 2.17$)

- A. 拒绝原假设
- B. 不拒绝原假设
- C. 拒绝不拒绝都可以
- D. 无法确定

Solution: B.

$F = \frac{S_1^2}{S_2^2} = \frac{45}{25} = 1.8 < F_{0.05}(19, 19)$, 因此不拒绝原假设, 选 B.

12. 假设随机变量 $X \sim N(0, 36)$, $Y \sim N(1, 25)$, $\rho(X, Y) = 0.8$, 求 $\text{Var}(2X - Y) = (\quad)$.

A. 73

B. 144

C. 25

D. 169

Solution: A.

直接计算, 有

$$\begin{aligned}\text{Var}(2X - Y) &= 4 \cdot \text{Var}(X) + \text{Var}(Y) - 4 \text{Cov}(X, Y) \\ &= 144 + 25 - 4 \cdot 0.8 \cdot 5 \cdot 6 \\ &= 73\end{aligned}$$

13. 假设总体正态, 样本量是 16, 样本均值是 7.3, 样本方差是 0.64, 想要研究均值是否显著小于 7.5, 下列正确的是 ()

A. 原假设是大于等于 7.5, 检验统计量的形式是 $4 \frac{\bar{x} - 7.5}{s}$

B. 原假设是小于等于 7.5, 检验统计量的形式是 $4 \frac{\bar{x} - 7.5}{s}$

C. 原假设是小于等于 7.5, 检验统计量的形式是 $\frac{\bar{x} - 7.5}{0.8}$

D. 原假设是大于等于 7.5, 检验统计量的形式是 $\frac{\bar{x} - 7.5}{0.2}$

Solution: A.

D 虽然数据对上了, 但检验统计量的形式不是统一形式.

14. 假设总体 X , 样本均值和样本方差分别为 $\bar{X}$ 和 S^2 , 下列正确的是 ()

A. S 是 σ 的无偏估计

B. S 是 σ 的极大似然估计

C. S 是 σ 的一致估计

D. S 与 σ 独立

Solution: C.

我们知道 S^2 无偏, 故根据 Jensen 不等式, S 不是无偏的, A 错; 题目没有给分布, B 错; D 只有在正态情形正确, 故 D 错. 对于 C, 首先 $S^2 \xrightarrow{P} \sigma^2$, 利用依概率收敛对连续函数保持不变, 有 $S \xrightarrow{P} \sigma$.

15. 假设 $X \sim N(0, 1)$, 常数 $x < 0$, 求 $\mathbb{P}(x < X \mid X \leq 0) = (\quad)$

A. $2\Phi(-x) - 1$

B. $\Phi(-x) - 1$

C. $\Phi(-x) - 1/2$

D. $2\Phi(-x) - 1/2$

Solution: A.

直接计算

$$P(X > x \mid X < 0) = \frac{P(x < X < 0)}{P(X < 0)} = 2(\Phi(0) - \Phi(x)) = 1 - 2\Phi(x) = 2\Phi(-x) - 1.$$

16. 泊松分布 $\mathcal{P}$ 的 C-R 下界是多少? ()

A. $\frac{n}{\lambda}$

B. $\frac{1}{n\lambda}$

C. $\frac{\lambda}{n}$

D. $\frac{1}{n\lambda^2}$

Solution: C. $I(\lambda) = E\left[-\frac{\partial^2 f}{\partial \lambda^2}\right] = \frac{1}{\lambda}$, 故 CR 下界为 $\frac{\lambda}{n}$.

17. 总体 $X \sim N(\mu, \frac{1}{4})$, 要求满足 $\mathbb{P}(|\bar{X} - \mu| < 0.1) \geq 0.95$ 的最小样本量 () (分位数: $z_{0.95} = 1.64, z_{0.975} = 1.96$)

- A. 68
- B. 67
- C. 97
- D. 96

Solution: C.

令 $P(|\bar{X} - \mu| < 0.1) = P(|N(0, 1)| < 0.2\sqrt{n}) \geq 0.95$, 因此 $0.2\sqrt{n} \geq 1.96$, 解得 $n \geq 96.04$, 选 C.

18. (暂无题目, 有回忆者可以联系大师兄)

19. (暂无题目, 有回忆者可以联系大师兄)

20. 进行满意度调查, 结果如下:

性别/满意度	满意	一般	行和
男生	180	120	300
女生	130	70	200
列和	310	190	500

求男生女生满意的行百分比 ()

- A. 60%, 65%
- B. 33.3%, 30%
- C. 58%, 42%
- D. 62.07%, 37.93%

Solution: A.

21. 关于列联表, 下列说法正确的是 ()

- A. φ 相关系数适用于所有的列联表
- B. φ 相关系数是 V 相关系数的特殊情况
- C. c 相关系数取值在 $[0, 1]$ 的所有值
- D. φ 相关系数取值在 $[0, 1]$ 的所有值

Solution: B.

22. 调整后的多重判定系数为 0.7, $n = 10, k = 3$, 则 $R^2 =$ ().

- A. 0.85
- B. 0.75
- C. 0.25
- D. 0.8

Solution: D.

$R_a^2 = 1 - \frac{n-1}{n-k-1} R^2$, 解出 $R^2 = 0.8$.

23. 样本量 $n = 36$, 回归方程 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4$, 得到估计的回归方程: $\hat{y} = 6.8 + \hat{\beta}_1 x_1 + 1.2 x_2 + \hat{\beta}_3 x_3$, 且 $\hat{\beta}_2$ 的标准误是 0.3, $t_{0.025}(32) = 2.036933$, 则 ()

- A. 线性关系显著
- B. 无多重共线性
- C. X_2 对 Y 显著
- D. X_1 对 Y 显著

Solution: A, C.

这里 $t_2 = \frac{1.2}{0.3} = 4 > t_{0.025}(32)$, 拒绝原假设, 因此 X_2 对 Y 是显著的. 如果模型中至少有一个变量显著, 则模型自身也是显著的. 而对于 B 和 D, 没有其他信息的情况下无法判断.

24. 某品牌手机销售量是先增长缓慢, 再突然暴增, 再增长缓慢至饱和, 请问用什么曲线进行拟合? ()

- A. 指数曲线
- B. 修正过后的指数曲线
- C. 三次曲线
- D. 逻辑斯蒂曲线

Solution: D.

这种曲线符合种群人口增长的模型, 同时可以发现 A、B、C 都是无界的, 只有 D 有界满足题设的饱和.

25. 季节指数, 1.1, 0.8, 0.9, 1.2, 预测方程 $Y_t = 6000 + 200t$, 2023 年第三季度的值是 9000, 求 2024 年第一季度的预测值是 ()

- A. 11440
- B. 7000
- C. 10340
- D. 9400

Solution: A.

$\frac{9000}{0.9} + 200 \cdot 2 = 10400$, 再乘上季节指数 1.1 得 A.

二、简答题 (每题 10 分, 共 40 分)

1. 序列 $Y_1, \dots, Y_n$ 预测: 什么是指数平滑? 什么是二次指数平滑? 结合指数平滑和二次指数平滑, 以序列举例进行预测.

Solution: 指数平滑和二次指数平滑是时间序列分析中用于预测的两种技术. 它们通过给历史数据不同的权重来预测未来的值.

一次指数平滑 (Simple Exponential Smoothing): 指数平滑是一种预测技术, 适用于没有明显趋势和季节性的时间序列. 它通过对最近的数据给予更大的权重, 并对更早的数据给予递减的权重来计算平滑值. 指数平滑的公式

$$S_t = \alpha Y_t + (1 - \alpha) S_{t-1}$$

其中, S_t 是时刻 t 的平滑值, Y_t 是时刻 t 的实际观测值, α 是平滑参数 ($0 < \alpha \leq 1$).

二次指数平滑 (Double Exponential Smoothing): 二次指数平滑适用于有趋势但没有季节性的时间序列. 它的公式包括两个方程:

$$S_t = \alpha Y_t + (1 - \alpha)(S_{t-1} + T_{t-1})$$

$$T_t = \beta(S_t - S_{t-1}) + (1 - \beta)T_{t-1}$$

其中, S_t 是时刻 t 的平滑值, T_t 是时刻 t 的趋势项, Y_t 是时刻 t 的实际观测值, α 和 β 是平滑参数.

2. 为了研究户型、房价指数、房东收入对二手房价的影响, 其中如果户型是三室两厅记作 1, 两室两厅记作 0, 请你建立线性回归方程并检验模型是否显著.

Solution: 为了研究二手房价 (Y) 与户型 (X_1)、房价指数 (X_2) 和房东收入 (X_3) 的关系, 我们建立以下多元线性回归模型:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$$

其中, X_1 是一个虚拟变量, 表示户型, 模型中, β_0 是截距, $\beta_1, \beta_2, \beta_3$ 分别是与 X_1, X_2, X_3 相关的系数, 而 ε 代表误差项. 为了检验模型的显著性, 我们通常进行以下两种检验: (i) F 检验 (整体显著性检验): 检验模型中所有自变量对因变量的联合影响是否显著. (ii) t 检验 (单个系数的显著性检验): 检验模型中每个自变量对因变量的独立影响是否显著.

1. 设有总体指数分布 $X \sim f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}$ 的三个样本 X_1, X_2, X_3 , 找出 α 使 $\alpha X_{(1)} + (1-\alpha) X_{(3)}$ 是 θ 的无偏估计.

Solution: 对于指数分布, 我们有结论: $E(X_{(1)}) = \frac{1}{n} E(X)$, $E(X_{(n)}) = (1 + \frac{1}{2} + \cdots + \frac{1}{n}) E(X)$, 因此这里 $E(X_{(1)}) = \frac{1}{3}\theta$, $E(X_{(3)}) = \frac{11}{6}\theta$, 故有 $\alpha = \frac{5}{9}$.

4. 似然比检验, 假设总体 $X \sim N(\mu, \sigma^2)$, 给出检验问题:

$$H_0: \mu = \mu_0 \quad \text{vs} \quad H_1: \mu \neq \mu_0$$

的似然比检验.

Solution: 茆书例题 7.4.1 原题.

三、计算题 (前 2 题每题 15 分, 第 3 题 20 分, 共 50 分)

1. 设 $\begin{pmatrix} X \\ Y \end{pmatrix} \sim N\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 4 \end{pmatrix}\right)$, $\rho \in (-2, 2)$, 求 $P(X \geq 0, Y \geq 0)$.

Solution: 这是复旦 432-2022-第五题原题. 利用 (X, Y) 与 $(-X, -Y)$ 同分布, 有

$$P(X \geq 0, Y \geq 0) = P(-X \geq 0, -Y \geq 0),$$

这两个事件并起来恰好意味着 X, Y 同号. 因此 $P(X \geq 0, Y \geq 0) = \frac{1}{2} P(XY \geq 0) = \frac{1}{2} P\left(\frac{Y}{X} \geq 0\right)$, 作独立变换, 找合适的 W 使得 $Y = \rho X + \sqrt{4-\rho^2}W$, 同时恰好 $(X, W) \sim N(0, 0; 1, 1; 0)$, 因此有

$$P\left(\frac{Y}{X} \geq 0\right) = P\left(\rho + \sqrt{4-\rho^2} \frac{W}{X} \geq 0\right) = P\left(\frac{W}{X} \geq -\frac{\rho}{\sqrt{4-\rho^2}}\right) = F\left(\frac{\rho}{\sqrt{4-\rho^2}}\right),$$

这里 F 是标准柯西分布分布函数, 且用到了 $P\left(\frac{W}{X} \geq -x\right) = P\left(\frac{W}{X} \leq x\right)$, 因此不难求出

$$P(X \geq 0, Y \geq 0) = \frac{1}{4} + \frac{1}{2\pi} \arctan \frac{\rho}{\sqrt{4-\rho^2}} = \frac{1}{4} + \frac{1}{2\pi} \arcsin \rho.$$

2. 设有来自 $N(0, \sigma^2)$ 的简单随机样本 $X_1, \dots, X_n$, 记 $\hat{\sigma} = \sum_{i=1}^n w_i |X_i|$, 求最优权重 w_i 使得 $\hat{\sigma}$ 是无偏估计且的方差最小.

Solution: 首先 $E(|X|) = \frac{\sqrt{2}}{\sqrt{\pi}} \sigma$, $E(|X|^2) = \sigma^2$. 因此需要满足 $\sum_{i=1}^n w_i = \frac{\sqrt{2}}{\sqrt{\pi}}$, 这也意味着: 令 $Z_i = \frac{\sqrt{2}}{\sqrt{\pi}} |X_i|$, 其中 $E(Z) = \sigma$, 找最优权重 l_i , 满足 $\sum_{i=1}^n l_i = 1$, 使其方差最小.

实际上不难看出, 对于 i.i.d. 样本, $l_1 = l_2 = \cdots = l_n = 1/n$ 时, 方差最小, 证明是简单的: 用柯西-施瓦茨不等式,

$$\text{Var}\left(\sum_{i=1}^n l_i Z_i\right) = \sigma_z^2 \sum_{i=1}^n l_i^2 = \sigma_z^2 \frac{1}{n} \sum_{i=1}^n l_i^2 \sum_{i=1}^n 1^2 \geq \sigma_z^2 \frac{1}{n} \left(\sum_{i=1}^n l_i \cdot 1\right)^2 = \frac{\sigma_z^2}{n},$$

当且仅当 $l_1 = l_2 = \cdots = l_n = 1/n$ 时取等, 此时 $w_i = \frac{\sqrt{2}}{n\sqrt{\pi}}$.

当然, 也可以用拉格朗日乘数法.

3. 有来自总体 $U(0, \theta)$ 的简单随机样本 $X_1, \dots, X_n$. 其次序统计量是 $X_{(1)} \leq \cdots \leq X_{(n)}$.

(1) 求 $X_{(k)}$ 的概率密度, 期望、方差.

(2) 证明 $n\left(1 - \frac{X_{(n)}}{\theta}\right)$ 按分布收敛于 $\text{Exp}(1)$.

(3) 求 θ 的 95% 的渐近置信区间. (用渐近分布)

(4) 给出 $H_0: \theta \leq 1$ vs $H_1: \theta > 1$ 的渐近拒绝域.

Solution: (1) 利用均匀分布次序统计量结论, 有 $\frac{X_{(k)}}{\theta} \sim \text{Be}(k, n+1-k)$, 因此有

$$p_k(x) = \frac{n!}{(k-1)!(n-k)!} \frac{1}{\theta^n} x^{k-1} (\theta-x)^{n-k}, \quad 0 < x < \theta.$$

期望是 $E(X_{(k)}) = \frac{k}{n+1}\theta$, $Var(X_{(k)}) = \frac{k(n-k+1)\theta^2}{(n+2)(n+1)^2}$.

(2) 直接求分布函数即可, 有

$$P\left(n\left(1 - \frac{X_{(n)}}{\theta}\right) > x\right) = P\left(1 - \frac{X_{(n)}}{\theta} > \frac{x}{n}\right) = P\left(\frac{X_{(n)}}{\theta} < 1 - \frac{x}{n}\right) = \left(1 - \frac{x}{n}\right)^n \rightarrow e^{-x},$$

因此 $P\left(n\left(1 - \frac{X_{(n)}}{\theta}\right) \leq x\right) \rightarrow 1 - e^{-x}$, 这确实是 $\text{Exp}(1)$.

(3) 单侧双侧都可以, 最好是单侧, 因为 θ 应该在形如 $[X_{(n)}, c]$ 的区间中更合理. 我们有

$$P\left(0 < n\left(1 - \frac{X_{(n)}}{\theta}\right) < -\ln(0.05)\right) \approx 0.95,$$

通过反解得到置信区间

$$\left[X_{(n)}, \frac{X_{(n)}}{1 + \frac{1}{n} \ln(0.05)}\right].$$

(4) 拒绝域形式应是 $W = \{X_{(n)} > c\}$, 注意原假设时 $\theta = 1$, 我们表示为

$$W = \{X_{(n)} > c\} = \left\{n\left(1 - X_{(n)}\right) < n(1 - c)\right\},$$

因此为使得水平为 α , 应有 $n(1 - c) \approx -\ln(1 - \alpha)$, 即 $c \approx 1 + \frac{\ln(1 - \alpha)}{n}$, 故拒绝域可以是

$$W = \left\{X_{(n)} \geq 1 + \frac{\ln(1 - \alpha)}{n}\right\}$$

或者直接是 $W = \left\{n(1 - X_{(n)}) \leq -\ln(1 - \alpha)\right\}$.

上海财经大学-432 统计学

上海财经大学-432 统计学-2023 年

一、选择题 (每题 2 分, 共 20 题, 总 40 分)

1、盒中共有 a 个白球, b 个黑球以及 c 个红球, 现无放回摸球, 则白球比黑球先摸出的概率是 ()

- A. $\frac{a}{a+b}$
- B. $\frac{b}{a+b}$
- C. $\frac{a}{a+b+c}$
- D. $\frac{b}{a+b+c}$

Solution: A

用事件 A 表示“白球比黑球先摸出”, 显然红球的数量对该事件无影响, 故设 $P(A) = x$, 用事件 W_1, R_1, B_1 分别表示首次摸球摸出白、红、黑球, 则由全概率公式有

$$\begin{aligned} P(A) &= P(A | W_1) \cdot P(W_1) + P(A | R_1) \cdot P(R_1) + P(A | B_1) \cdot P(B_1) \\ x &= 1 \cdot \frac{a}{a+b+c} + x \cdot \frac{c}{a+b+c} + 0 \cdot \frac{b}{a+b+c} \\ (a+b+c) \cdot x &= a + cx \\ x &= \frac{a}{a+b} \end{aligned}$$

2、设 $X \sim P(\lambda)$, 以下判断正确的是 ()

- A. $P(X > 2\lambda) \leq 1 - \frac{1}{\lambda}$
- B. $P(X > 2\lambda) \leq \frac{1}{\lambda}$
- C. $P(X > 2\lambda) \geq \frac{1}{\lambda}$
- D. $P(X > 2\lambda) \geq 1 - \frac{1}{\lambda}$

Solution: B

利用切比雪夫不等式,

$$P(X > 2\lambda) = P(X - \lambda > \lambda) \leq P(|X - \lambda| > \lambda) \leq \frac{\text{Var}(X)}{\lambda^2} = \frac{1}{\lambda}$$

3、从某市 200 个学校随机抽 40 个学校, 再从每个学校的班级里抽取一些班级, 再从班级里抽取一定数量的老师学生, 属于以下哪种抽样方法 ()

- A. 分层抽样
- B. 多阶段抽样
- C. 系统抽样
- D. 简单随机抽样

Solution: B

多阶段抽样方法是指将总体分成若干层次, 然后按照一定的顺序, 从每一层次中随机抽取一部分单位, 直到达到所需的样本规模。

在这个问题中, 总体是某市的所有学校、班级和老师学生, 分成了三个层次: 学校、班级和老师学生。第一阶段是从 200 个学校中随机抽取 40 个学校, 第二阶段是从每个学校的班级里抽取一些班级, 第三阶段是从班级里抽取一定数量的老师学生。

4、指数平滑法是通过过去的观察值加权平均进行预测的一种方法, 该方法使 $t+1$ 期的预测值 ()

- A. 等于 t 期的实际观察值与 t 期的预测值的加权平均值

- B. 等于 t 期的实际观察值与 $t+1$ 期的预贬值的加权平均值
 C. 等于 $t+1$ 期的实际观察值与 t 期的预测值的加权平均值
 D. 等于 $t+1$ 期的实际观察值与 $t+1$ 期的预贬值的加权平均值

Solution: A

指数平滑法的基本思想是: $t+1$ 期的预测值等于 t 期的实际观察值与 t 期的预测值的加权平均值, 其中权重是一个常数 α , 称为平滑系数, 取值在 0 到 1 之间:

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha) \hat{y}_t$$

其中, $\hat{y}_{t+1}$ 是 $t+1$ 期的预测值, y_t 是 t 期的实际观察值, $\hat{y}_t$ 是 t 期的预测值。

根据这个公式, 可以看出, 选项 A 正确。

5、设 $X \sim N(\mu, 1)$, 考虑假设检验问题 $H_0: \mu = 1$ v.s. $H_1: \mu = 2$, 有拒绝域为 $W = \{\bar{x} > c\}$, 则下列说法不正确的是 ()

- A. 功效函数随着 μ 单调增
 B. 功效函数随着 c 单调增
 C. 第一类错误的概率等于 $1 - \Phi(\sqrt{n}(c - 1))$
 D. 第二类错误的概率等于 $\Phi(\sqrt{n}(c - 2))$

Solution:

样本均值 $\bar{x}$ 服从正态分布 $N(\mu, \frac{1}{n})$, 所以 $\sqrt{n}(\bar{x} - \mu)$ 服从正态分布 $N(0, 1)$ 。

功效函数是指在原假设为假时, 拒绝原假设的概率, 即

$$\beta(\mu) = P(\bar{x} > c | \mu) = 1 - \Phi(\sqrt{n}(c - \mu))$$

其中, Φ 是标准正态分布的累积分布函数。

根据这个公式, 可以看出:

- 功效函数随着 μ 单调增, 因为 $\sqrt{n}(c - \mu)$ 随着 μ 单调减, 而 Φ 是单调增的函数。所以选项 A 正确。
- 功效函数随着 c 单调减, 因为 $\sqrt{n}(c - \mu)$ 随着 c 单调增, 而 Φ 是单调增的函数。所以选项 B 错误。
- 第一类错误的概率等于在原假设为真时, 拒绝原假设的概率, 即

$$\alpha = P(\bar{x} > c | \mu = 1) = 1 - \Phi(\sqrt{n}(c - 1))$$

所以选项 C 正确。

- 第二类错误的概率等于在备择假设为真时, 接受原假设的概率, 即

$$\beta = P(\bar{x} \leq c | \mu = 2) = \Phi(\sqrt{n}(c - 2))$$

所以选项 D 正确。

综上所述, 选项 B 是不正确的说法。

6、A, B, C 都是事件, 下列关于事件运算的表达式中, 正确的是 ()

- A. $(A - B) - C = A - (B - C)$
 B. $AC = \emptyset, B \subset A$, 则 $BC = \emptyset$
 C. $(A \cup B) - B = A$
 D. $(A - B) + B = A$

Solution: B

- 选项 A 错误, 因为 $(A - B) - C$ 是指包含 A 中但不包含 B 和 C 中元素的事件, 而 $A - (B - C)$ 是指包含 A 中但不包含 $B - C$ 中元素的事件。这两个事件不一定相等, 例如当 $C \subset A - B$ 时, $(A - B) - C = \emptyset$, 而 $A - (B - C) = C \neq \emptyset$ 。

- 选项 B 正确, 因为如果 $AC = \emptyset$, 则表示 A 和 C 没有共有元素, 如果又有 $B \subset A$, 则表示 B 中的所有元素都属于 A , 那么就一定不属于 C , 所以 $BC = \emptyset$ 。

- 选项 C 错误, 因为 $(A \cup B) - B$ 是指包含属于 $A \cup B$ 但不属于 B 的元素的事件, 而这些元素就是属于 $A - B$ 的元素。所以 $(A \cup B) - B = A - B \neq A$, 除非 $B \subset A$, 那么才有 $(A \cup B) - B = A - B = A$

- 选项 D 错误, 因为 $(A - B) + B = A \cup B \neq A$, 除非 $B \subset A$, 那么才有 $(A - B) + B = A \cup B = A$

综上所述, 选项 B 是正确的说法。

7、下列时间序列过程中, 一定平稳的是 ()

A. ARIMA(1, 0, 1)

B. ARIMA(0, 0, 1)

C. ARIMA(1, 1, 1)

D. ARIMA(1, 0, 0)

Solution: B

ARIMA 模型的定义如下:

- ARIMA(p, d, q) 模型是指差分 d 次后的时间序列 y_t 可以用自回归模型 AR(p) 和移动平均模型 MA(q) 来描述, 即

$$\Delta^d y_t = \phi_0 + \phi_1 \Delta^d y_{t-1} + \cdots + \phi_p \Delta^d y_{t-p} + \theta_0 \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$

- 其中, $\Delta^d y_t = y_t - y_{t-1}$ 表示一阶差分, $\Delta^d y_t = \Delta^{d-1} y_t - \Delta^{d-1} y_{t-1}$ 表示 d 阶差分, ϵ_t 表示白噪声序列。- 如果 $d = 0$, 则表示原始的时间序列 y_t 就是平稳的, 不需要差分, 即

$$y_t = \phi_0 + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \theta_0 \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$

根据这个定义, 可以看出:

- 选项 A: 因为 ARIMA(1, 0, 1) 模型表示 y_t 是一个 AR (1) 和 MA (1) 的组合, 即

$$y_t = \phi_0 + \phi_1 y_{t-1} + \theta_0 \epsilon_t + \theta_1 \epsilon_{t-1}$$

当 $|\phi_1| < 1$ 时, 这是一个平稳的时间序列过程。

- 选项 B 正确, 因为 ARIMA(0, 0, 1) 模型表示 y_t 是一个 MA (1) 的过程, 即

$$y_t = \phi_0 + \theta_0 \epsilon_t + \theta_1 \epsilon_{t-1}$$

这是一个平稳的时间序列过程。

- 选项 C : 因为 ARIMA(1, 1, 1) 模型表示 y_t 需要一阶差分后才能用 AR (1) 和 MA (1) 的组合来描述, 即

$$\Delta y_t = \phi_0 + \phi_1 \Delta y_{t-1} + \theta_0 \epsilon_t + \theta_1 \epsilon_{t-1}$$

这说明原始的时间序列 y_t 不是平稳的。

- 选项 D : 因为 ARIMA(1, 0, 0) 模型表示 y_t 是一个 AR (1) 的过程, 即

$$y_t = \phi_0 + \phi_1 y_{t-1} + \theta_0 \epsilon_t$$

当 $|\phi_1| < 1$ 时, 这是一个平稳的时间序列过程。

综上所述, 选项 B 正确。

8、设 $X \sim b(1, p)$, 则以下选项中, p^2 的无偏估计是 ()

A. $\frac{n}{n-1} (\bar{x}^2 - \frac{\bar{x}}{n})$

B. $\bar{x}^2$

C. $\bar{x}^2 - \frac{\bar{x}}{n}$

D. $\frac{n-1}{n} (\bar{x}^2 - \frac{\bar{x}}{n})$

Solution: A

$$E\left(\frac{n}{n-1} \left(\bar{x}^2 - \frac{\bar{x}}{n}\right)\right) = \frac{n}{n-1} \left(E(\bar{x}^2) - \frac{E(\bar{x})}{n}\right) = \frac{n}{n-1} \left(p^2 + \frac{p(1-p)}{n} - \frac{p}{n}\right) = p^2$$

9、设 $E(X) = -2, E(X^2) = 5$, 则 $\text{Var}(100 - 3X) = ()$

A. 9

B. 3

C. 1

D. 2

Solution: A

$$\text{Var}(100 - 3X) = 9 \text{Var}(X) = 9 \times \left(E(X^2) - E^2(X)\right) = 9$$

10、两个正整数相加为偶数的概率为 ()

A. 1/8

B. 1/4

C. 1/3

D. 1/2

Solution: D

假设从正整数中抽一个数, 为奇数、偶数的概率均为 1/2, 则答案显然为 D.

11、关于假设检验中的概念, 以下说法正确的是 ()

A. 第一类错误是指 H_0 为假时, 接受备择假设

B. 第二类错误是指 H_1 为假时, 接受原假设

C. 检验功效是指 H_0 为假时, 假设检验拒绝原假设的概率

D. 检验功效是指 H_1 为假时, 假设检验接受原假设的概率

Solution: C

首先, 假设检验中的概念如下:

- 原假设 H_0 是指被检验的假设, 通常是一个等式或者不等式。

- 备择假设 H_1 是指与原假设相反的假设, 通常是一个不等式。

- 拒绝域 W 是指根据样本数据拒绝原假设的区域, 通常是一个区间或者两个区间。

- 第一类错误是指 H_0 为真时, 拒绝原假设的错误, 其概率记为 α 。

- 第二类错误是指 H_1 为真时, 接受原假设的错误, 其概率记为 β 。

- 检验功效是指 H_1 为真时, 拒绝原假设的概率, 其值为 $1 - \beta$ 。

根据这些定义, 可以看出: 选项 C 正确

12、假设人的 IQ 服从 $N(100, 15^2)$, 则 IQ 在 70 分以下的比例为 ()

A. 2.5%

B. 5%

C. 10%

D. 16%

Solution: A

根据 3σ 准则, 两倍标准差内的数据量为 95.45%, 故两倍标准差之外的数据量大约为 4.55, 只考虑单边则为 2.275, 与 A 最接近.

13、调查镜片的曲率, 据调查 500 个镜片的平均曲率为 0.5。则调查的总体是 ()

- A. 抽查的 500 个镜片
- B. 最近 500 个镜片
- C. 今天销售的所有镜片
- D. 该厂生产的所有镜片

Solution: D

总体是指我们感兴趣的研究对象的全体，也就是我们想要推断的对象的集合。抽样是指从总体中随机地选取一部分个体作为样本，以便用样本的统计量来估计总体的参数。

根据这些定义，可以看出：

- 选项 A 错误，因为抽查的 500 个镜片是样本，而不是总体。
- 选项 B 错误，因为最近 500 个镜片也是样本，而不是总体。
- 选项 C 错误，因为今天销售的所有镜片也是样本，而不是总体。
- 选项 D 正确，因为该厂生产的所有镜片才是总体，也就是我们想要推断的对象的集合。

14、抓五只蚊子，患有某疾病的蚊子个数应该服从以下哪种分布 ()

- A. 正态分布
- B. 泊松分布
- C. 二项分布
- D. 学生 t 分布

Solution: C

15、以下关于泊松分布的参数空间和随机变量的取值说法正确的是 ()

- A. 参数空间是离散的，随机变量是离散的
- B. 参数空间是连续的，随机变量是离散的
- C. 参数空间是离散的，随机变量是连续的
- D. 参数空间是连续的，随机变量是连续的

Solution: B

泊松分布的定义如下：

- 泊松分布是指一个离散型的随机变量，其概率质量函数为

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots$$

其中 λ 是单位时间内发生的平均次数，也是泊松分布的唯一参数。

- 泊松分布的参数空间是指 λ 可以取的所有可能的值的集合，也就是 $(0, +\infty)$ ，这是一个连续的区间。
- 泊松分布的随机变量是指发生的次数 X ，它只能取非负整数的值，也就是 $\{0, 1, 2, \dots\}$ ，这是一个离散的集合。

综上所述，选项 B 是正确的说法。

16、某调查员想检验一中 coffee 包装是否少于 500g，那么他采取的假设检验应该为 ()

- A. 双侧检验
- B. 单侧且备择假设为小于 500g
- C. 单侧且备择假设为大于 500g
- D. 单双侧检验均可

Solution: B

在假设检验中，将我们想要检验的结论放在备择假设。

- 选项 A 错误，因为双侧检验是用于检验是否不等于某个值的情况，而不是是否小于某个值的情况。
- 选项 B 正确，因为单侧且备择假设为小于 500g 是符合调查员的目的的，即他想要证明 coffee 包装的重量低于标准值。

- 选项 C 错误, 因为单侧且备择假设为大于 500g 是与调查员的目的相反的, 即他想要证明 coffee 包装的重量高于标准值。

- 选项 D 错误, 因为单双侧检验不是可以随意选择的, 而是要根据备择假设的形式来确定的。

综上所述, 选项 B 是正确的说法。

17、以下关于区间估计的说法正确的是 ()

A. 区间估计是指用一个区间来估计总体参数的真值

B. 区间估计是指用一个点来估计总体参数的真值

C. 区间估计是指用一个区间来估计样本统计量的真值

D. 区间估计是指用一个点来估计样本统计量的真值

Solution: A

- 选项 A 正确, 因为区间估计就是指用一个区间来估计总体参数的真值, 例如用 $(\bar{x} - t_{\alpha/2} \frac{s}{\sqrt{n}}, \bar{x} + t_{\alpha/2} \frac{s}{\sqrt{n}})$ 来估计总体均值 μ 的真值。

- 选项 B 错误, 因为用一个点来估计总体参数的真值是点估计, 而不是区间估计, 例如用 $\bar{x}$ 来估计总体均值 μ 的真值。

- 选项 C 错误, 因为区间估计的目的是估计总体参数, 而不是样本统计量, 样本统计量的真值是可以直接观察到的, 不需要估计。

- 选项 D 错误, 因为同理, 点估计的目的也是估计总体参数, 而不是样本统计量。

18、大约有 50% 的数据会大于

A. 中位数

B. 平均数

C. 众数

D. 均值

Solution: A

19、设 y 为响应变量, x 为自变量, 线性回归这种方法最适合于以下哪种场合 ()

A. y 是连续变量, x 是离散变量

B. y 是连续变量, x 是连续变量

C. y 是离散变量, x 是离散变量

D. y 是离散变量, x 是连续变量

Solution: A

线性回归是指一种用于分析响应变量和自变量之间线性关系的统计方法, 其基本模型为

$$y = \beta_0 + \beta_1 x + \epsilon$$

其中, y 是响应变量, x 是自变量, β_0 和 β_1 是回归系数, ϵ 是随机误差项。

线性回归的目的是通过最小化残差平方和来估计回归系数, 从而得到拟合的直线方程, 并用于预测或解释响应变量的变化。

- 选项 A 错误, 因为线性回归不适合于自变量是离散变量的情况, 因为这样会导致拟合的直线没有意义或者不准确。

- 选项 B 正确, 因为线性回归最适合于响应变量和自变量都是连续变量的情况, 因为这样可以更好地反映两者之间的线性关系, 并且可以用拟合的直线来预测或解释响应变量的变化。

- 选项 C 错误, 因为线性回归不适合于响应变量是离散变量的情况, 因为这样会导致拟合的直线不能很好地描述响应变量的分布或者违反误差项的正态性假设。

- 选项 D 错误, 因为线性回归也不适合于响应变量是离散变量的情况, 同理。

20、以下选项中, 不是联合分布函数 $F_{X,Y}(x,y)$ 的性质的是 ()

- A. 非负性
- B. 单调性
- C. 有界性
- D. 左连续性

Solution: D

A, B, C 显然正确. 按照茆书的定义, 分布函数具有右连续性.

二、填空题 (每题 3 分, 共 5 题, 总 15 分)

1、 X_1, X_2 独立同分布, 均服从泊松分布 $P(\lambda)$, 则 $Y = \max\{X_1, X_2\}$ 的分布列是 _____

Solution:

由于 $Y = \max\{X_1, X_2\}$, 有

$$P(Y = k) = P(\max\{X_1, X_2\} = k)$$

利用条件概率公式, 可以将上式改写为

$$P(Y = k) = P(X_1 = k)P(X_2 \leq k|X_1 = k) + P(X_2 = k)P(X_1 \leq k|X_2 = k) - P(X_1 = k)P(X_2 = k)$$

而 X_1, X_2 独立同分布, 故

$$P(X_2 \leq k|X_1 = k) = P(X_2 \leq k), P(X_1 \leq k|X_2 = k) = P(X_1 \leq k), P(X_1 = k) = P(X_2 = k)$$

因此, 上式可以化简为

$$P(Y = k) = 2P(X_1 = k)P(X_1 \leq k) - P(X_1 = k)^2$$

将泊松分布的概率质量函数代入上式, 得到

$$P(Y = k) = 2 \frac{\lambda^k e^{-\lambda}}{k!} \sum_{i=0}^k \frac{\lambda^i e^{-\lambda}}{i!} - \left(\frac{\lambda^k e^{-\lambda}}{k!} \right)^2, k = 0, 1, 2, \dots$$

2、等车时间服从指数分布 $E(\frac{1}{5})$, 如果等候时间大于 10 则小明会选择走路上班, 假如小明一周上班五天, 且每天等待公交车的时间独立, 则一周走路上班次数 Y 的分布是 _____

Solution:

容易看出这是一个 n 重伯努利事件, 某天走路上班的概率是 $P(X \geq 10) = e^{-\frac{10}{5}} = e^{-2}$, 故 $Y \sim B(5, e^{-2})$.

3、现有随机变量 X , 设 $EX = 2$, 若 $\hat{\theta}_1, \hat{\theta}_2$ 分别是 $E(X)^2, E(X)^3$ 的无偏估计, 则用 $\hat{\theta}_1, \hat{\theta}_2$ 表示 X 三阶中心矩的无偏估计是 _____

Solution:

由于 $E((X - EX)^3) = E(X^3) - 3E(X)E(X^2) + 2E(X)^3$, 将 $\hat{\theta}_1, \hat{\theta}_2$ 替换, 并将 $EX = 2$ 代入, 则 $\hat{\theta}_2 - 6\hat{\theta}_1 + 16$.

4、已知 $X = \ln Y \sim N(\mu, \sigma^2)$, 记 $\bar{x} = \sum_{i=1}^n x_i/n, s_n^2 = \sum_{i=1}^n (x_i - \bar{x})^2/n, s^2 = \sum_{i=1}^n (x_i - \bar{x})^2/(n-1)$. 则 $e^{\mu + \frac{\sigma^2}{2}}$ 的 MLE 是 _____

Solution:

由于 $(\bar{x}, s_n^2)$ 是 (μ, σ^2) 的 MLE, 根据不变性, 有 $e^{\bar{x} + \frac{s_n^2}{2}}$ 是 $e^{\mu + \frac{\sigma^2}{2}}$ 的 MLE.

5、随机变量 X_1, X_2 相互独立, 分别服从 $P(\lambda_1), P(\lambda_2)$, 则 $E(X | X + Y = n) =$ _____

Solution: 先求条件分布, 对于 $x = 0, 1, 2, \dots, n$, 有

$$\begin{aligned} P(X_1 = x | X_1 + X_2 = n) &= \frac{P(X_1 = x, X_1 + X_2 = n)}{P(X_1 + X_2 = n)} \\ &= \frac{P(X_1 = x, X_2 = n - x)}{P(X_1 + X_2 = n)} \\ &= \frac{\frac{\lambda_1^x}{x!} e^{-\lambda_1} \frac{\lambda_2^{n-x}}{(n-x)!} e^{-\lambda_2}}{\frac{(\lambda_1 + \lambda_2)^n}{n!} e^{-(\lambda_1 + \lambda_2)}} \\ &= \frac{n!}{x!(n-x)!} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2}\right)^x \left(\frac{\lambda_2}{\lambda_1 + \lambda_2}\right)^{n-x} \end{aligned}$$

其中利用了泊松分布的可加性, 即 $X_1 + X_2 \sim P(\lambda_1 + \lambda_2)$. 容易发现实际上

$$(X_1 = x | X_1 + X_2 = n) \sim B\left(n, \frac{\lambda_1}{\lambda_1 + \lambda_2}\right),$$

因此 $E(X_1 = x | X_1 + X_2 = n) = n \frac{\lambda_1}{\lambda_1 + \lambda_2}$.

三、计算题 (4 题, 共 70 分)

1、(10 分) 已知某个产品的尺寸 $\sim N(4.55, 0.108^2)$, 该次抽查先测量了 9 个产品, 平均尺寸为 4.84, 如果产品尺寸方差未发生改变, 是否可认为现在生产的产品尺寸仍为 4.55? (取显著性水平 $\alpha = 0.05$)

Solution:

这是一个假设检验问题, 首先建立假设:

$$H_0: \mu = 4.55 \quad \text{v.s.} \quad H_1: \mu \neq 4.55$$

正态样本, 方差已知, 检验统计量为

$$z = \frac{\sqrt{n}(\bar{x} - \mu_0)}{\sigma} = \frac{3 \cdot (4.84 - 4.55)}{0.108} = 8.056$$

在显著性水平 $\alpha = 0.05$ 下, 拒绝域是

$$W = \{|z| > z_{0.975}\} = \{|z| > 1.96\}$$

检验统计量落在拒绝域中, 因此拒绝原假设, 认为产品尺寸发生了显著变化。

2、(20 分) 考虑如下时间序列数据

周	1	2	3	4	5	6
观测值	8	13	15	17	16	9

(1) 对此时间序列作用三周滑动平均, 求第七周预测值.

(2) 计算三周滑动平均法的训练均方误差 MSE.

(3) 用 $\alpha = 0.2$ 的指数平滑法第七周预测值.

(4) 比较上述两种方法哪种的预测效果更好.

Solution:

(1) 对此时间序列作用三周滑动平均, 求第七周预测值.

三周滑动平均法是一种 ** 移动平均模型 **, 它的原理是用最近三周的观测值的算术平均数作为下一周的预测值. 公式如下:

$$\hat{y}_{t+1} = \frac{y_t + y_{t-1} + y_{t-2}}{3}$$

其中 $\hat{y}_{t+1}$ 表示第 $t+1$ 周的预测值, y_t 表示第 t 周的观测值。
根据题目给出的数据, 我们可以计算出前 4-7 周的预测值如下:

$$\begin{aligned}\hat{y}_4 &= \frac{8 + 13 + 15}{3} = 12 \\ \hat{y}_5 &= \frac{13 + 15 + 17}{3} = 15 \\ \hat{y}_6 &= \frac{15 + 17 + 16}{3} = 16 \\ \hat{y}_7 &= \frac{17 + 16 + 9}{3} = 14\end{aligned}$$

所以第七周的预测值为 14。

(2) 计算三周滑动平均法的训练均方误差 MSE。

训练均方误差 MSE 是一种衡量预测模型好坏的指标, 它的定义是预测值与观测值之差的平方和除以样本量。公式如下:

$$MSE = \frac{\sum_{t \in \mathcal{T}} (y_t - \hat{y}_t)^2}{\#\mathcal{T}}$$

其中 y_t 表示第 t 周的观测值, $\hat{y}_t$ 表示第 t 周的预测值, $\mathcal{T}$ 表示用于计算 MSE 的样本集合。

根据题目给出的数据, 我们可以用 4-6 周的数据来计算 MSE, 即

$$MSE = \frac{(17 - 12)^2 + (16 - 15)^2 + (9 - 16)^2}{3} = 25$$

所以三周滑动平均法的训练均方误差为 12.75。

(3) 用 $\alpha = 0.2$ 的指数平滑法第七周预测值。

指数平滑法是一种 ** 自回归模型 **, 它的原理是用最近一期的观测值和上一期的预测值加权平均作为下一期的预测值。公式如下:

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha) \hat{y}_t$$

其中 $\hat{y}_{t+1}$ 表示第 $t+1$ 期的预测值, y_t 表示第 t 期的观测值, $\hat{y}_t$ 表示第 t 期的预测值, α 表示平滑系数, 取值在 0 到 1 之间。

根据题目给出的数据和 $\alpha = 0.2$, 我们可以计算出前四期的预测值如下:

假设初始预测值 $\hat{y}_1 = 8$

$$\begin{aligned}\hat{y}_2 &= 0.2 \times 8 + (1 - 0.2) \times 8 = 8 \\ \hat{y}_3 &= 0.2 \times 13 + (1 - 0.2) \times 8 = 9 \\ \hat{y}_4 &= 0.2 \times 15 + (1 - 0.2) \times 9 = 10.2 \\ \hat{y}_5 &= 0.2 \times 17 + (1 - 0.2) \times 10.2 = 11.56 \\ \hat{y}_6 &= 0.2 \times 16 + (1 - 0.2) \times 11.56 = 12.448 \\ \hat{y}_7 &= 0.2 \times 9 + (1 - 0.2) \times 12.448 = 11.7584\end{aligned}$$

所以第七周的预测值为 11.7584。

(4) 一般来说, 比较预测效果的好坏可以用 MSE 或其他误差指标来衡量, 误差越小, 预测效果越好。为保证公平, 我们同样用 4-6 周的数据来计算 MSE, 有

$$MSE = \frac{(17 - 10.2)^2 + (16 - 11.56)^2 + (9 - 12.448)^2}{3} = 25.9474$$

所以指数平滑法的 MSE 为 25.9474, 比三周滑动平均法的 MSE 大。因此, 我们可以判断三周滑动平均法的预测效果更好。

3、(20 分) 帕累托分布的分布函数如下

$$F(y | \theta_1, \theta_2) = \begin{cases} 1 - \left(\frac{\theta_1}{y}\right)^{\theta_2} & 0 < \theta_1 \leq y, \theta_2 > 0 \\ 0 & \text{其他} \end{cases}$$

现有简单随机样本 $y_1, y_2, \dots, y_n$, 试求 θ_1, θ_2 的 MLE.

Solution:

先求总体的密度函数, 有

$$f(y | \theta_1, \theta_2) = \frac{\theta_2}{y^{\theta_2+1}} \theta_1^{\theta_2}, y \geq \theta_1.$$

似然函数为

$$L(\theta_1, \theta_2) = \prod_{i=1}^n f(y_i | \theta_1, \theta_2) = \prod_{i=1}^n \frac{\theta_2 \theta_1^{\theta_2}}{y_i^{\theta_2+1}} I_{[\theta_1, \infty)}(y_i)$$

其中 $I_{[\theta_1, \infty)}(y_i)$ 是示性函数, 表示当 $y_i \geq \theta_1$ 时为 1, 否则为 0.

对数似然函数为

$$l(\theta_1, \theta_2) = \log L(\theta_1, \theta_2) = n \log \theta_2 + n \theta_2 \log \theta_1 - (\theta_2 + 1) \sum_{i=1}^n \log y_i + \sum_{i=1}^n \log I_{[\theta_1, \infty)}(y_i)$$

对 θ_1 求偏导数, 并令其等于零, 得到

$$\frac{\partial l}{\partial \theta_1} = \frac{n \theta_2}{\theta_1} - \sum_{i=1}^n \frac{I'_{[\theta_1, \infty)}(y_i)}{I_{[\theta_1, \infty)}(y_i)} = 0$$

其中 $I'_{[\theta_1, \infty)}(y_i)$ 是示性函数的导数, 表示当 $y_i = \theta_1$ 时为正无穷, 否则为 0.

由于示性函数的导数只有在 $y_i = \theta_1$ 时才不为零, 所以我们可以将数据集按照从小到大排序, 记最小的观测值为 $y_{(1)}$, 那么只有当 $\theta_1 = y_{(1)}$ 时, 上式才成立。因此我们得到 $\hat{\theta}_1 = y_{(1)}$ 。

对 θ_2 求偏导数, 并令其等于零, 得到

$$\frac{\partial l}{\partial \theta_2} = \frac{n}{\theta_2} + n \log \hat{\theta}_1 - \sum_{i=1}^n \log y_i = 0$$

其中我们已经代入了 $\hat{\theta}_1 = y_{(1)}$ 的结果。解得

$$\hat{\theta}_2 = -\frac{n}{n \log y_{(1)} - \sum_{i=1}^n \log y_i}$$

综上, 我们得到 θ_1, θ_2 的 MLE 为

$$\hat{\theta}_1 = y_{(1)}, \quad \hat{\theta}_2 = -\frac{n}{n \log y_{(1)} - \sum_{i=1}^n \log y_i}$$

4、(20 分) 某元件寿命服从 $\text{Exp}(1)$, 某系统由 n 个这样的元件组成当系统工作时, 这 n 个元件相互独立, 令 $X_1, \dots, X_n$ 表示这 n 个元件的寿命, 并记 $X_{(1)}, \dots, X_{(n)}$ 为样本的次序统计量, 令 $Z_1 = nX_{(1)}, Z_2 = (n-1)(X_{(2)} - X_{(1)}), \dots, Z_i = (n-i+1)(X_i - X_{i-1}), \dots, Z_n = X_{(n)} - X_{(n-1)}$, 解决以下问题:

(1) 试求 $Z_1, \dots, Z_n$ 的联合密度函数.

(2) 求 Z_1 的边际密度.

(3) 当 n 个原件中的 k 个 ($1 \leq k \leq n$) 失效时整个系统失效, 求此系统的平均寿命.

Solution:

(1) $Z_1, \dots, Z_n$ 的联合密度函数可以由 $X_{(1)}, \dots, X_{(n)}$ 的联合密度函数推导出来, 后者可以根据全体次序统计量联合密度公式得到, 即

$$f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n) = n! \prod_{i=1}^n f(x_i) = n! e^{-\sum_{i=1}^n x_i}, 0 \leq x_1 \leq \dots \leq x_n$$

利用 $Z_1, \dots, Z_n$ 的定义, 可以写出:

$$X_{(1)} = \frac{Z_1}{n}, \quad X_{(i)} = X_{(i-1)} + \frac{Z_i}{n-i+1}, \quad i=2, \dots, n$$

这个变换的雅可比矩阵是:

$$J = \begin{bmatrix} \frac{1}{n} & 0 & 0 & \dots & 0 \\ * & \frac{1}{n-1} & 0 & \dots & 0 \\ * & * & \frac{1}{n-2} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ * & * & * & \dots & 1 \end{bmatrix}$$

其中 * 表示可能不为 0, 但不重要, 因为这是一个下三角矩阵, 容易计算雅可比行列式是:

$$|J| = \frac{(-1)^{n-1}}{n!(n-1)!(n-2)! \dots 2!1!} Z_2 Z_3^2 Z_4^3 \dots Z_n^{n-1}$$

因此, $Z_1, \dots, Z_n$ 的联合密度函数是:

$$f_{Z_1, \dots, Z_n}(z_1, \dots, z_n) = n! \cdot \frac{1}{n!} \cdot e^{-\sum_{i=1}^n z_i} = e^{-\sum_{i=1}^n z_i}, \quad z_1, \dots, z_n > 0$$

(2) 从 (1) 的结果容易看出, $Z_1, Z_2, \dots, Z_n$ 独立同分布, 均服从参数为 1 的指数分布. 即有

$$f_{Z_1}(z_1) = e^{-z_1}, z_1 > 0$$

(3) 相当于求 $EX_{(k)}$, 当 $k=1$ 时,

$$EX_{(1)} = \frac{1}{n} EZ_1 = \frac{1}{n}$$

当 $k=2, 3, \dots, n$ 时,

$$\begin{aligned} EX_{(k)} &= E \left[X_{(k-1)} + \frac{Z_k}{n-k+1} \right] \\ &= E \left[\left\{ X_{(k-2)} + \frac{Z_{k-1}}{n-k} \right\} + \frac{Z_k}{n-k+1} \right] \\ &= E \left[\sum_{i=1}^k \frac{Z_i}{n-i+1} \right] = \sum_{i=1}^k \frac{1}{n-i+1} \end{aligned}$$

四、计算题 (1 题, 共 25 分)

1、(25 分) 考虑简单一元线性回归模型:

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad \varepsilon_i \text{i.i.d.} \sim N(0, \sigma^2)$$

- (1) 现收集到 n 个样本 $(x_1, y_1), \dots, (x_n, y_n)$, 求 $\alpha, \beta, \sigma^2, \sigma$ 的 MLE.
 (2) 若现有三个样本观测值 $(1, 8), (3, 2), (5, 1)$, 试计算上面四个 MLE 的具体值.
 (3) 给出 α, β, σ^2 的 MLE 的各两条性质, 并说出理由.

Solution:

- (1) 一元线性回归模型的参数 $\alpha, \beta, \sigma^2, \sigma$ 的最大似然估计 (MLE) 非常常见, 此处略去过程, 有

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{l_{xy}}{l_{xx}}$$

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta}x_i)^2$$

根据 MLE 的不变性, 有 $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$

其中 $\bar{x}$ 和 $\bar{y}$ 是样本均值.

- (2) 根据上面的公式, 我们可以计算出三个样本观测值的 MLE:

$$\bar{x} = \frac{1+3+5}{3} = 3$$

$$\bar{y} = \frac{8+2+1}{3} = 3.67$$

$$l_{xx} = (1-3)^2 + (3-3)^2 + (5-3)^2 = 8$$

$$l_{xy} = (1-3)(8-3.67) + (3-3)(2-3.67) + (5-3)(1-3.67) = -14$$

故 $\hat{\beta} = \frac{-14}{8} = -\frac{7}{4}$, $\hat{\alpha} = 3.67 - (-\frac{7}{4}) \times 3 = 8.92$.

$$\hat{\sigma}^2 = \frac{1}{3} \left[(8-8.92+1.75 \cdot 1)^2 + (2-8.92+1.75 \cdot 3)^2 + (1-8.92+1.75 \cdot 5)^2 \right] = 1.3889$$

以及 $\hat{\sigma} = \sqrt{1.3889} = 1.17852$.

- (3)

$\hat{\alpha}$ 是 α 的无偏估计, 且是 UMVUE.

$\hat{\beta}$ 是 β 的无偏估计, 且是 UMVUE.

$\hat{\sigma}^2$ 是 σ^2 的渐进无偏估计, 且是渐进有效估计.

众号·

大师兄统计

已统计



1

众助